

matematisk statistik eksamensbesvarelse

2025-06-02

til start sætter jeg et seed så alle mulige simulationer jeg laver kommer til at stemme over ens med dem der bliver genereret når jeg knitter filen til slut

```
set.seed(42)
```

opgave 1

1.1

ideen er her at vi skal lave en homogenitetstest

jeg vil ligesom i opgavebeskrivelsen lade i alderen. vi har at hvert år er antallet af produkter der fejler er binomialfordelt som er ekvivalent med multinomialfordelt med 2 kasser

altså:

$$M_0 : (A_{i1}, A_{i2}) \sim \text{Multinomial}(n_i, (\pi_i, 1 - \pi_i)) \quad \text{for } i \in \{1, 2, 3, 4, 5\}$$

med :

$$\pi_1 \geq 0$$

og n_i er antallet af maskiner med alderen i også betegnet summen i tabellen

hypotesen er at antallet af fejl er ens for alle aldre altså:

$$H_0 : \pi_i = \pi \quad \forall i \in \{1, 2, 3, 4, 5\}$$

hvor $\pi \geq 0$ er den fælles sandsynlighed for at hver enhed fejler på et givet år

1.2

vi ønsker umildbart at lave en G test, G testen er baseret på en transformation af likelihood ratio testen som er approximativt χ^2 fordelt under visse betingelser og er den type test vi har brugt til at lave homogenitetstesten

i dette tilfælde vil den have 4 frihedsgrader da vi har 5 frie parametre i grundmodellen og 1 fri parameter under hypotesen $5-1=4$

testen laves med kode givet i undervisningen

```
obs=rbind(c(4,2030),c(5,977),c(7,744),c(13,757),c(9,782))
ex=outer(rowSums(obs),colSums(obs))/sum(obs)
obs1=ifelse(obs==0,1,obs)
G=2*sum(obs*log(obs1/ex))
pval=1-pchisq(G,(dim(obs)[1]-1)*(dim(obs)[2]-1))
c(Forventede=ex)
```

```
## Forventede1 Forventede2 Forventede3 Forventede4 Forventede5 Forventede6
## 14.506757 7.003754 5.356231 5.491742 5.641517 2019.493243
## Forventede7 Forventede8 Forventede9 Forventede10
## 974.996246 745.643769 764.508258 785.358483
```

```
c(G=G,Pvaerdi=pval)
```

```
## G Pvaerdi
## 2.103271e+01 3.119746e-04
```

alle de forventede er større end 5 da er G-testoren approximativt χ^2 fordelt med 4 frihedsgrader med en teststørrelse på $G = 21.03$ giver det os en p værdi på $p_{obs} = 0.0003$ som er langt under 0.05 da forkastes hypotesen om homogenitet da data strider imod den.

1.3

jeg ønsker igen at bruge G-testet hvis de forventede er store nok. man skal dog holde tungen lige i munden når man regner dem her.

vi skal stadig egentlig lave en G test men de forventede under hypotesen regnes lidt anderledes end vi plejer

```
th<-0.00286
n<-c(2034,982,751,770,791)
p<-c(1,2,3,4,5)*th
e<-c(n*p,n*(1-p))
e
```

```
## [1] 5.81724 5.61704 6.44358 8.80880 11.31130 2028.18276
## [7] 976.38296 744.55642 761.19120 779.68870
```

alle de forventede er større end 5 så vores testor er valid og approximativt χ^2 fordelt

```
A<-c(4,5,7,13,9,2030,977,744,757,782)
```

```
k<-1
```

```
gtest<-2*sum(A*log(A/e))
pval<-1-pchisq(gtest,5-k)
c(Gteststørrelse=gtest,Pværdi=pval)
```

```
## Gteststørrelse Pværdi
## 3.0327123 0.5523661
```

en G teststørrelse på $G = 3.03$ som udfald af en $\chi^2(4)$ fordeling giver os en p værdi på $p_{obs} = 0.55$ langt større end 0.05 betyder at data ikke strider imod H_0^* og at det derved er rimeligt at antage at sandsynligheden for fejl stiger lineært i alderen(men diskret)

jeg tænker fællen her er antallet af frihedsgrader under hypotesen som er 1 altså har testoren 5(fra før)-1=4 frihedsgrader G testoren er approximativt $\chi^2(4)$ fordelt

opgave 2

2.1

jeg laver simulationseksperimentet hvor jeg genererer 100000 estimer for p hat

```
set.seed(42)

Nsim<-10^5
Nantal<-50
values<-numeric(Nsim)
r=3
p=0.6
for (i in 1:Nsim){
  x<-rbinom(n=Nantal,r,p)
  values[i]<-mean(x)/var(x)
}
```

hvorefter jeg finder middelværdien

```
mean(values)
```

```
## [1] 0.6367293
```

altså $\bar{p} = 0.637$ (samme notation som vi plejer at bruge om den empiriske middelværdi) en smule større end 0.6 hvilket kan tyde på positivt bias

2.2

jeg indlæser dataen

```
dat1<-read.csv("negbiom.csv")
head(dat1)
```

```
##    x
## 1 2
## 2 0
## 3 1
## 4 2
## 5 3
## 6 0
```

jeg regner værdien af p hat i datasættet

```
mean(dat1$x)/var(dat1$x)
```

```
## [1] 0.6089371
```

som rundes op til $\hat{p} = 0.61$ ved 2 betydende cifre

jeg simulerer bootstrap fordelingen

```

set.seed(42)
my.sample<-dat1$x
N <- 10^5
my.boot <- numeric(N)
for (i in 1:N) {
  x <- sample(my.sample, replace = TRUE) # draw resample
  my.boot[i] <- mean(x)/var(x) # compute mean, store in my.boot
}


```

jeg tegner et histogram for at se hvad jeg arbejder med

```

hist(my.boot,freq=F,breaks=50)
abline(v=mean(my.boot))

```



jeg regner percentil intervallet ved at kalde “quantile” i R

```
quantile(my.boot,c(0.025,1-0.025))
```

```
##      2.5%      97.5%
## 0.4719547 0.9062087
```

altså har vi et percentilinterval for $\hat{p}$ [0.4719547 , 0.9062087]

bootstrap estimat for bias regner vi bare ved at tage middelværdien for estimatet ved bootstrap minus estimatet fra sample som er ≈ 0.61

```
mean(my.boot)-mean(dat1$x)/var(dat1$x)
```

```
## [1] 0.03101601
```

altså bootstraestimatet for bias at vi har positivt bias altså at estimatet muligvis har positivt bias
bemærk at det her stort set er det samme som det observerede bias vi så i den tidligere opgave

2.3

vi vil igen lave en G test hvis de forventede er store nok

jeg er lidt i tvivl om hvordan spørgsmålet skal læses om 0.61 er estimatet der giver den største likelihood når vi fitter for p eller om jeg skal teste om fittet af fordelingen med $p=0.61$ og $r=3$ den eneste forskel det gør er antallet af frihedsgrader under G testen

jeg går ud fra nummer 2 altså teste om fittet af $\text{nbinom } r=3$ og $p=0.61$ kan passe til data altså at modellen under hypotesen har 0 frihedsgrader

jeg finder de forventede

```
p<-0.61
r=3
A<-c(11,15,11,4,4,1,4)
l=0:5
# jeg danner en vector af sandsynlighederne for at være i hver kasse
# sandsynligheden for at være i den sidste kasse er 1- sandsynligheden for at være i de andre
mellem<-dnbinom(l,r,p)
sands<-c(mellem,1-sum(mellem))

#herefter finder jeg de forventede
e<-sum(A)*sands
e
```

```
## [1] 11.349050 13.278388 10.357143  6.732143  3.938304  2.150314  2.194658
```

vi ønsker at alle de forventede er større end 5 for at vores G testor blive approximativt χ^2 fordelt da slår jeg de sidste 3 kasser sammen og regner de forventede og den justerede aktuelle observation

```
An<-c(11,15,11,4,9)
ln<-0:3
mellem<-dnbinom(ln,r,p)
sandsn<-c(mellem,1-sum(mellem))
en<-sum(An)*sandsn
en
```

```
## [1] 11.349050 13.278388 10.357143  6.732143  8.283276
```

nu er alle de forventede større end 5 og vi kan lave vores G test
som nu vil have $4(\text{antallet af kasser})-0=4$ frihedsgrader

```
k=0
gtest<-2*sum(An*log(An/en))
pval<-1-pchisq(gtest,length(An)-1-k)
c(Gteststørrelse=gtest,Pværdi=pval)
```

```
## Gteststørrelse      Pværdi
##      1.623891      0.804492
```

vores G teststørrelse $G = 1.624$ som udfald fra en $\chi^2(4)$ fordeling giver os en p værdi på 0.8

med en pværdi på 0.8 forkaster vi ikke hypotesen om at data kommer fra en negativ binomialfordeling og det er derved en rimelig antagelse

opgave 3

3.1

det histogram der passer bedst er histogram A t.test finder som default p værdien for t test under hypotesen om at middelværdien er lig 0 og variansen er ukendt

da rnorm uden specificerede parametre trækker fra en standard normal fordeling ved vi at vi simulerer under t testens 0 hypotese

vi ved at under svage betingelser er p værdien for en test uniformt fordelt på intervallet fra 0 til 1 under 0 hypotesen og siden histogrammet approximerer tæthedsfunktionen for nok udfald må histogrammet være nogenlunde flat


ingen af de andre har en “fladhed” som kommer tæt på

som et lille sanity check har jeg lavet et identisk eksperiment

```
set.seed(42)

Nsim<-10^5
Nantal<-10
values<-numeric(Nsim)
for (i in 1:Nsim){
  x<-rnorm(Nantal)
  values[i]<-t.test(x)$p.value
}
```

```
hist(values,freq=F,breaks=50)
```



hvor jeg som håbet får et nogenlunde flat histogram

opgave 4

4.1

jeg kopierer først lige kode fra opgaven

```
wooddata <- read.csv("wood.csv")
humid <- wooddata$humid
hfac <- as.factor(wooddata$h)
wfac <- as.factor(wooddata$w)
lmfit_m1 <- lm(humid ~ hfac + wfac + hfac:wfac)
lmfit_m2 <- lm(humid ~ hfac + wfac)
anova(lmfit_m2,lmfit_m1)
```

```
## Analysis of Variance Table
##
## Model 1: humid ~ hfac + wfac
## Model 2: humid ~ hfac + wfac + hfac:wfac
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      91 21.226
## 2      75 15.996 16    5.2301 1.5326 0.1107
```

den første model er en lineær normal model der lader hver kombination af højde og bræde have sin egen middelværdi men hvor de alle har ens varians(et kriterie for at være en lineær normal model)

også skrevet

$$M_1 : X_{i,j,k} \sim N(\mu_{j,k}, \sigma^2) \quad i \in \{1, \dots, n_{j,k}\} \quad j \in \{1, 2, 3, 4, 5\} \quad k \in \{1, 2, 3, 4, 5\}$$

hvor $\sigma^2 > 0$ og $\mu_{i,j}$ varierer frit

modellen vi reducere ned til er en additiv model hvor hver ærði af hver faktor bidrager med sit eget led, sagt med andre ord er der ikke nogen interaktion mellem de 2 faktorvariable

også skrevet

$$M_2 : X_{i,j,k} \sim N(\alpha_j + \beta_k, \sigma^2) \quad i \in \{1, \dots, n_{j,k}\} \quad j \in \{1, 2, 3, 4, 5\} \quad k \in \{1, 2, 3, 4, 5\}$$

vi laver et F test som er ekvivalent med likelihood ratio testen fra 1 lineær normal model til en anden. likelihood ratiotesten tester forholdet mellem likelihooden(under maximering i de 2 modeller) og derved hvor meget “værre” det er at tro på modellen under hypotesen/den reducerede model

i praksis bruger vi anova. anova kører en f test hvor testoren er $F(d_1 - d_2, n - d_1)$ fordelt under hypotesen hvor d_i er dimensionen af det lineære underrum hvor modellernes middelværdier kan fittes


i dette case har vi en F test med teststørrelsen $F = 1.533$ som ved udfald af en $F(16,75)$ fordeling giver os en p værdi på $0.1107 > 0.05$ da forkaster vi ikke hypotesen og det er derved rimeligt at reducere til den additive model(hvis kontroltegningerne også er fine)

4.2

jeg tænker umildbart at gøre 2 ting qqplot for residualerne interaktionsplot for at tjekke validiteten af den additive model


først residualplottet

```
qqnorm(lmfit_m2$residuals)
qqline(lmfit_m2$residuals)
```




data snorer sig fint omkring qqline og residualerne strider derved ikke imod den additive model
jeg laver 2 interaktionsplots

```
interaction.plot(hfac,wfac,humid,col=)
```



vi ser at linjerne er nogenlunde parrallele med et par undtagelser primært 5 og 4 som afviger en smule ved hfac=4 alt i alt et pænt interaktionsplot som jeg ikke vil sige strider imod additivitetsantagelsen

```
interaction.plot(wfac,hfac,humid)
```



igen pæne nogenlunde parrallele kurver som ikke strider imod additivitetsantagelsen

ud fra additivitetsplottene ser vi at wfac=1 eller wfac=5 har højest fugtighed og at hfacs=1 eller hfacs=5 har højest fugtighed alt i alt kan man sige at hjørnerne har højest fugtighed mens den falder når man går længere og længere ind mod midten

fugtighed: højst i hjørnene lavest i midten

4.3

variansestimatet trækker jeg direkte ud af R

```
s2<-sigma(lmfit_m2)^2
s2
```

```
## [1] 0.2332563
```

og får $S(x) = 0.233$

siden vi er i en lineær normal model ved vi at variansestimatet

$$S^2(X) = \frac{\|x - P(x)\|^2}{n - d} \sim \frac{\sigma^2 * \chi^2(n - d)}{n - d}$$

hvor $n = \text{antalobservationer}$ og $d = \text{dim}(L)$ hvor L er ligepræcis det lineære underrum hvor vores midelværdivektor kan fittes i den lineære model specificeret i dette tilfælde $9 = \text{basecase } (1,1) + 4 \text{ for skift i højde og } 4 \text{ for skift i brede(for snittet)}$ altså

$$S^2(X) \sim \frac{\sigma^2 * \chi^2(91)}{91} \Leftrightarrow \frac{S^2(X)}{\sigma^2} \sim \frac{\chi^2(91)}{91}$$

hvilket vi kan validere ved at tjekke i R

```
summary(lmfit_m2)$df
```

```
## [1] 9 91 9
```

hvor det er den midterste vi skal have fat i for konfidensintervallet skal vi lige skrive

fra slidesættet om 1 normalfordelt observationsrække har vi $1-\alpha$ konfidensintervallet for vilkårlige frihedsgrader i præcis det setup

$$\frac{S^2(X)}{\sigma^2} \sim \frac{\chi^2(91)}{91}$$

er

$$\left[\frac{91 * s^2(x)}{\chi^2_{1-\alpha/2}(91)}, \frac{91 * s^2(x)}{\chi^2_{\alpha/2}(91)} \right]$$

hvor det i nævneren er hhv $1 - \alpha/2$ og $\alpha/2$ fraktilen som jeg regner

```
c(nedre=91*s2/qchisq(1-0.025,df=91),oevere=91*s2/qchisq(0.025,df=91))
```

```
##      nedre      oevere
## 0.1779509 0.3191895
```

altså intervallet [0.1779509 , 0.3191895]

4.4

fra slide om variansanalysetabellen ser jeg: $A = n - d_1$ $B = d_1 - d_2$ $C = F$ teststørrelsen $D = P$ -værdi

da modellene er fittet præcis som før må vi have forskellen i d må være den samme som tidligere altså 16 så $B=16$ vi ser også at $A = n - d_2 + B$ hvor $n - d_2$ er opgiet altså $A=41+16=57$ herefter regner jeg F teststørrelsen og dens p -værdi

```
B<-16
A<-16+41
ssq<-4.1937
rss1<-5.6808
f<-(ssq/B)/(rss1/A)
f
```

```
## [1] 2.629921
```

altså $C=2.630$

og så regner jeg p værdien

```
1-pf(f,B,A)
```

```
## [1] 0.00383326
```

$A=57$

$B=16$

$C=2.630$ (afrundet)

$D=0.0038$


4.5

jeg fitter modellen og laver modelkontrol

```
m3<-lm(humid~h+w,data=wooddata)
```


jeg tjekker først residualerne først bare ved qq plot og dernest mod de forklarende variable

```
qqnorm(m3$residuals)  
qqline(m3$residuals)
```




altså i ser nogle hak op og ned men ellers ikke så meget de stider imod normalitet man kunne godt argumenterer for at den hakker for meget og man derfor skal være mere skeptisk i resten af analysen

```
plot(m3$residuals~wooddata$h)
```



vi ser at det her det er langt fra støj og at de forskellige grupperinger overhovedet ikke har samme middelværdi

```
plot(m3$residuals~wooddata$w)
```



samme konklusion som før

residualerne er systematisk for høje mod kanterne og for lave mod midten (for begge forklarende variable) vi konkludere derved at modellen ikke passer særlig godt på data da residualerne ikke er uafhængige af de forklarende variable da modellen ikke passer særlig godt til data vil vi ikke arbejde videre med den

4.6

jeg danner 2 nye rækker i datasættet

```
wooddata$kw=wooddata$w^2
wooddata$kh=wooddata$h^2
head(wooddata)
```

```
##   humid h w kw kh
## 1  8.49 1 1  1  1
## 2  6.42 1 2  4  1
## 3  6.03 1 3  9  1
## 4  5.94 1 4 16  1
## 5  8.09 1 5 25  1
## 6  8.23 1 1  1  1
```


jeg tænker ideen er at lave en lineær model med kvadraterne altså:

$$M_4 : X_i \sim N(\alpha + \beta_1 * w_i^2 + \beta_2 * h_i^2, \sigma^2) \quad i \in \{1, \dots, n\}$$

den prøver jeg at fitte og lave kontroltegninger på


```
m4<-lm(humid~kh+kw,data = wooddata)
```

```
qqnorm(m4$residuals)  
qqline(m4$residuals)
```




her ser vi allerede at residualerne er langt pænere ud

```
plot(m4$residuals~wooddata$kw)
```



```
plot(m4$residuals~wooddata$kw)
```



igen ser vi en systematik i residualerne der stadig er for høje i kanterne og for lave i midten
så jeg laver en ny model som tager kvadratafgivelse fra midten altså


$$M_5 : X_i \sim N(\alpha + \beta_1 * (w_i - 3)^2 + \beta_2 * (h_i - 3)^2, \sigma^2) \quad i \in \{1, \dots, n\}$$

jeg danner nye datarækker og fitter denne model

```
wooddata$kah<-(wooddata$h-3)^2
wooddata$kaw<-(wooddata$w-3)^2
```


```
m5<-lm(humid~kah+kaw,data = wooddata)
```

```
qqnorm(m5$residuals)
qqline(m5$residuals)
```




her ser residualernes kvartiler egentlig super pæne ud snor sig super fint ad qqlinien

```
plot(m5$residuals~wooddata$w)
```



```
plot(m5$residuals~wooddata$h)
```



og systematikken vi så fra før er fuldstændig væk

jeg går derved videre med model 5

4.7

jeg laver prediktionsinterval i R

jeg laver det nye datapunkt og manipulerer det så alle datatyperne er rigtige

```
ny.data=data.frame(h=3,w=3)
ny.data$kah<-(ny.data$h-3)^2
ny.data$kaw<-(ny.data$w-3)^2
ny.data$h<-factor(ny.data$h)
ny.data$w<-factor(ny.data$w)
```

nu finder jeg de prediktionsintervallerne med R's funktion for M_2

jeg bøvler med at få R til at virke så jeg redefinerer lige fittet

```
m2<-lm(humid~factor(w)+factor(h),data=wooddata)
```

```
predict(m2,ny.data,interval="prediction")
```

```
##      fit      lwr      upr
## 1 3.7342 2.732606 4.735794
```

som giver os intervallet $[2.732606, 4.735794]$

for M_5 er dette lige præcis skæringen dat det er når vi er præcis i centrum

```
predict(m5,ny.data,interval="prediction")
```

```
##           fit      lwr      upr
## 1 3.822229 2.84033 4.804127
```

altså intervallet $[2.84033, 4.804127]$

altså 2 intervaller meget tæt på hinanden