

Opgavesættet indeholder 4 opgaver med i alt 14 delopgaver.

Opgave 1

I forbindelse med en kvalitetskontrol ønsker en fabrikant at undersøge, hvordan et produkts alder påvirker risikoen for fejl. Der er derfor blevet indsamlet data for $n = 5328$ eksemplarer af produktet, hvor man har noteret produktionsår (og dermed alder i år) samt, hvorvidt der er registreret fejl på produktet. Resultatet fremgår af tabellen nedenfor.

Produktionsår	Alder	Fejl		Sum
		Ja	Nej	
2024	1	4	2030	2034
2023	2	5	977	982
2022	3	7	744	751
2021	4	13	757	770
2020	5	9	782	791
Sum		38	5290	5328

For at beskrive sammenhængen defineres π_i , $i = 1, 2, 3, 4, 5$, som sandsynligheden for, at der er registreret en fejl på et produkt med en alder på i år.

1° Opstil en statistisk model for datasættet og angiv med modellens parametre hypotesen om, at sandsynligheden for fejl ikke afhænger af produktets alder.

2° Vis, at hypotesen fra 1° afvises.

Fabrikanten er dernæst interesseret i at beskrive, hvordan sandsynligheden for fejl afhænger af alderen, og opstiller derfor hypotesen

$$H_0^* : \pi_i = i\theta \quad i = 1, 2, 3, 4, 5,$$

hvor θ er en ukendt parameter med $0 < \theta < 1/5$. Det må uden argument benyttes, at maksimum likelihood estimatet for θ under H_0^* med tre betydende cifre er $\hat{\theta} = 0.00286$.

3° Undersøg H_0^* og angiv konklusionen. Udover teststørrelsen og p -værdien skal også den approksimative fordeling af testoren angives.

Opgave 2

Betragt en stokastisk variabel X med

$$\mathbb{P}(X = k) = \binom{k+r-1}{k} p^r (1-p)^k, \quad k = 0, 1, 2, \dots$$

Fordelingen af X kaldes *den negative binomialfordeling* og kan blandt andet bruges til at beskrive antallet af “flaskoer” til den r 'te “succes” opnås i en sekvens af afhængige Bernoulli-forsøg med succes-sandsynlighed $p \in (0, 1)$. Der gælder at

$$p = \frac{\mathbb{E}[X]}{\text{Var}[X]}. \quad (1)$$

Lad $X_1, \dots, X_n$ være en observationsrække fra den negative binomialfordeling. På grund af (1) betragtes ofte estimatoren

$$\hat{p} = \frac{\bar{X}}{s^2},$$

dvs. forholdet mellem gennemsnittet og den empiriske varians.

Den negative binomialfordeling kan benyttes i **R** ved hjælp af `nbinom`. Fordelingsfunktionen er implementeret ved `pnbinom`, sandsynlighedsfunktionen (PMF-en) ved `dnbinom`, og der kan trækkes tilfældige udfald fra fordelingen med `rnbinom`.

- 1° Foretag et simulationseksperiment for at estimere middelværdien af $\hat{p}$, hvor $\hat{p}$ er baseret på $n = 50$ observationer, og observationerne følger en negativ binomialfordeling med $r = 3$ og $p = 0.6$. Dit estimat skal være baseret på mindst 10000 simulerede værdier.

På filen *negbiom.csv* findes et datasæt, der består af én søjle ved navn x med $n = 50$ observationer. I Tabel 1 er datasættet opsummeret. Den øverste række angiver de forskellige værdier, som x antager, og den nederste række angiver, hvor mange gange den pågældende værdi forekommer i datasættet.

	0	1	2	3	4	5	6
antal	11	15	11	4	4	1	4

Tabel 1: Opsummering af data fra filen *negbiom.csv*.

- 2° Vis, at værdien af $\hat{p}$ for datasættet med to betydende cifre er 0.61. Simulér bootstrap fordelingen for estimatoren $\hat{p}$ og beregn et 95%-percentil interval, samt beregn et bootstrap estimat for bias af $\hat{p}$.
- 3° Foretag et *Goodness of fit test* til at undersøge om datasættet kan antages at komme fra en negativ binomial fordeling med $r = 3$ kendt. Som estimat af den ukendte parameter p benyttes 0.61.


Opgave 3

Ved et simulationseksperiment er R-kode 1 kørt 10000 gange og p -værdien fra `t.test` er gemt hver gang.

R-kode 1

```
x = rnorm(10)
t.test(x)$p.value
```


1° Der er lavet et histogram af p -værdierne. Histogrammet er ét af de fire histogrammer på Figur 1. Angiv hvilket histogram er det korrekte, og giv en teoretisk begrundelse for dit svar.



Figur 1: Fire mulige histogrammer

Opgave 4

I et forsøg ønsker man at undersøge, hvordan fugt trænger ind i en planke af træ. Planken er derfor blevet udsat for et fugtigt miljø i noget tid, hvorefter den er blevet skåret i 4 stykker, og fugtigheden i træet er blevet målt i et gitter bestående af 25 punkter for hvert stykke. Der måles i højden $h = 1, 2, 3, 4, 5$ cm og bredden $w = 1, 2, 3, 4, 5$ cm, se nedenstående figur. Data findes på filen *wood.csv*, der består af søjlerne *humid*, *h* og *w*, som indeholder henholdsvis fugtighedsmålingerne samt de tilhørende værdier af højde og bredde.



På R-kode 2 nedenfor fittes to modeller til data. Modellen, der svarer til `lmfit_m1`, vil i opgaven blive betegnet med M_1 og modellen, der svarer til `lmfit_m2`, vil i opgaven blive betegnet med M_2 .

R-kode 2

```
wooddata <- read.csv("wood.csv")
humid <- wooddata$humid
hfacs <- as.factor(wooddata$h)
wfacs <- as.factor(wooddata$w)
lmfit_m1 <- lm(humid ~ hfacs + wfacs + hfacs:wfacs)
lmfit_m2 <- lm(humid ~ hfacs + wfacs)
anova(lmfit_m2, lmfit_m1)
```

- 1° Opskriv modellerne M_1 og M_2 matematisk og beskriv i ord, det test der udføres.
- 2° Foretag en grafisk modelkontrol af modellen M_2 . Beskriv, ved hjælp af en eller flere af dine figurer, hvor i planken fugtigheden er højest og hvor den er lavest.
- 3° Angiv estimat for variansen i modellen M_2 og angiv den tilsvarende estimators fordeling. Angiv dernæst et 95%-konfidensinterval for variansen.

For en anden planke har man lavet samme eksperiment, men dog med den forskel, at man her kun skærer planken i 2 stykker. Selve datasættet skal ikke bruges i opgaven, og er derfor ikke vedlagt. Man har fittet to modeller på tilsvarende vis som på R-kode 2, og en del af variansanalysetabellen findes på R-udskrift 1.

R-udskrift 1

Analysis of Variance Table

Model 1: humid ~ hfac + wfac

Model 2: humid ~ hfac + wfac + hfac:wfac

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	41	9.8745				
2	A	5.6808	B	4.1937	C	D

4° På R-udskrift 1 er 4 af tallene erstattet med A, B, C og D. Beregn de manglende tal.

Vi vender nu tilbage til det oprindelige datasæt fra filen *wood.csv*.

Lad x_{hwi} for $h = 1, 2, 3, 4, 5$, $w = 1, 2, 3, 4, 5$ og $i = 1, \dots, 4$ angive målingen af fugtigheden hørende til højde h og bredde w , for stykke i , og lad X_{hwi} betegne den tilsvarende stokastiske variabel. Betragt modellen

$$M_3 : X_{hwi} \sim N(\alpha + \beta_1 h + \beta_2 w, \sigma^2),$$

hvor de stokastiske variable er uafhængige.

5° Lav en grafisk modelkontrol af M_3 og gør rede for, at modellen ikke passer særligt godt til datasættet.

6° På grund af resultatet i 5° ønsker man at inddrage kvadraterne på højden og bredden. Opstil en passende model og foretag en grafisk modelkontrol af denne.

7° Angiv 95%-prædiktionsintervaller for fugtigheden i centrum af planken for både modellen M_2 og modellen du fandt frem til i delspørgsmål 6°.