

Opgavesættet indeholder fire opgaver med i alt femten delopgaver. Held og lykke!

Opgave 1

I denne opgave skal du analysere længden af 500 tilfældigt udvalgte tidsintervaller mellem to på hinanden følgende jordskælv med en styrke på 6 eller mere, som blev registreret i USA mellem 1970 og 2009.

Intervallerne blev inddelt i 7 længdeklasser, og dataene er opsummeret i Tabel 1.

Tabel 1: Antal intervaller i længdeklasse

Længde (dage)	(0, 3]	(3, 6]	(6, 10]	(10, 15]	(15, 22]	(22, 35]	(35, ∞)
Observeret antal	96	47	64	70	67	77	79

- (a) Angiv et konfidensinterval for sandsynligheden for, at intervallet mellem to jordskælv er længere end 35 dage.

Tidsintervallet mellem to jordskælv modelleres ofte ved en eksponentialfordeling eller en gammafordeling. Når vi fitter en Gamma $\Gamma(r, \lambda)$ fordeling ved maksimum likelihood til data i Tabel 1, får vi $\hat{r} = 0.8557$ og $\hat{\lambda} = 0.0449$ (r betegner formparametren, og λ rateparametren).

Tabel 2: Observeret og forventet antal intervaller i længdeklasse

Længde (dage)	(0, 3]	(3, 6]	(6, 10]	(10, 15]	(15, 22]	(22, 35]	(35, ∞)
Observeret antal	96	47	64	70	67	77	79
Forventet antal	89.3	62.9	65.9	63.1	64.0	72.1	82.7

- (b) Eftersis, at det forventede antal af intervaller, der er længere end 35 dage, er 82.7, hvis tiderne følger gammafordelingen med de estimerede parametre ($\hat{r} = 0.8557$ og $\hat{\lambda} = 0.0449$).
- (c) Lav et test for nulhypotesen, at data stammer fra en (uspecificeret) gammafordeling. Beregn p -værdien, og angiv konklusionen.

I den næste delopgave undersøges på en anden måde, om data lige så godt kan modelleres med en eksponentialfordeling.

- (d) Antag, at tidsintervallerne mellem to jordskælv kan modelleres med gammafordelingen $\Gamma(r, \lambda)$. Angiv et 95% konfidensinterval for parametren r , idet det antages, at maksimum likelihood estimatoren $\hat{r}$ er normalfordelt, $\hat{r} \sim N(r, \text{SE}(\hat{r})^2)$. Det oplyses, at standardfejlen for $\hat{r}$ er $\text{SE}(\hat{r}) = 0.0618$, og estimatet fra data var $\hat{r} = 0.8557$.
- Brug konfidensintervallet til at afgøre, om data svarer til en eksponentialfordeling (vink: eksponentialfordelingen er et specialtilfælde af gammafordelingen).

(Data er et uddrag af Quakes data fra pakken resampledats3)

Opgave 2

Lad $X_1, \dots, X_n$ være en i.i.d. stikprøve fra en fordeling med tæthed

$$f(x; \theta) = \begin{cases} 2\theta^2 x^3 \exp(-\theta x^2), & x > 0, \\ 0, & \text{ellers,} \end{cases} \quad \text{hvor } \theta > 0.$$

For denne fordeling gælder $EX = 3\sqrt{\pi}/(4\sqrt{\theta})$ og $EX^2 = 2/\theta$.

Vi vil nu betragte to estimatorer for θ : maksimum likelihood estimatoren $\hat{\theta}_{\text{mle}}$ og momentestimatoren $\hat{\theta}_{\text{mom}}$.

(a) Vis, at maksimum-likelihood estimatoren er givet ved

$$\hat{\theta}_{\text{mle}} = \frac{2n}{\sum_{i=1}^n X_i^2}.$$

(b) Er $\hat{\theta}_{\text{mle}}$ unbiased? Giv et kort teoretisk argument for dit svar.

(c) Angiv formlen for momentestimatoren, $\hat{\theta}_{\text{mom}}$.

(d) Lav et skøn over bias og MSE for begge estimatorer ved simulation, i tilfældet $\theta = 5$ og stikprøvestørrelse $n = 10$. I simulationen skal du lave $N_{\text{sim}}=10000$ gentagelser af stikprøven. Til simuleringen kan du uden bevis benytte, at $X_i = \sqrt{Z_i}$, $i = 1, \dots, n$, hvor Z_i har en Gamma fordeling med formparameter $\alpha = 2$ og rateparameter $\beta = \theta$, det vil sige, $Z_i \sim \Gamma(2, \theta)$.

- Beskriv kort dine resultater — hvilken estimator har den mindste bias, hvilken har den mindste MSE?
- Gentag derefter simuleringen for $n = 100$. Ser du væsentlige ændringer når stikprøvestørrelsen øges?


Opgave 3

Nedenunder ser I kode og output fra et simulationseksperiment vedrørende R-funktionen `var.test`. Denne funktion giver resultatet af et F -test for nulhypotesen, at to stikprøver kommer fra populationer med identisk varians, mod alternativet, at varianserne er forskellige.

Kode:

```
Nsim <- 10000
pval <- numeric(Nsim)
for (i in 1:Nsim){
  x1 <- rt(20, 3)
  x2 <- rt(10, 3)
  pval[i] <- var.test(x1, x2)$p.value
}
plot(ecdf(pval))
```

Output fra koden:



(a) Læs koden og besvar de følgende spørgsmål:

- Findes der nogen forudsætninger for F -testet, som ikke er opfyldt i simulationen, og hvis ja, hvilke forudsætninger er det?
- Simuleres fra nulhypotesen eller fra alternativhypotesen?

(b) Hvor stor er, ifølge ecdf-plottet, den estimerede sandsynlighed for at forkaste hypotesen om éns varians i simulationseksperimentet, hvis vi forkaster når p -værdien er mindre end 0.05? Angiv, hvilken af de følgende svarmuligheder passer bedst:

- (i) ca. 0.05, (ii) > 0.90 , (iii) ca. 0.25, (iv) < 0.01 ,
(v) noget helt andet, (vi) kan ikke aflæses af den slags diagram.

Hvis dit svar er (v), så angiv også sandsynligheden som du aflæser.

Opgave 4

Forskere undersøgte, om æggenes piskeevne afhænger af produktionstypen (buræg, skrabeæg og økologiske æg). Som et mål for æggenes piskeevne registrerede de volumen af skummet, der blev produceret ved piskning af æg, som en procentdel af den oprindelige æggehvite. Da de forventede, at ægstørrelsen havde indflydelse på skumvolumen, gentog de målingerne med æg i to størrelser, M og L. For hver kombination af produktionstype og størrelse blev 10 æg undersøgt. Data findes i filen `aeg.csv` og indeholder variablerne `skumvol` (skumvolumen i %), `stor` (ægstørrelse) og `type` (produktionstype). Brug signifikansniveauet $\alpha = 0.05$ i analysen af data.

- (a) Opstil en statistisk model for data, hvor skumvolumen har en normalfordeling, hvor middelværdi og varians afhænger af kombinationen af produktionstype og ægstørrelse. Undersøg grafisk, om normalfordelingsantagelsen passer.
- (b) Vis ved et test, at det kan antages, at der er samme varians i alle 6 grupper.

I hvad følger betegner vi modellen med éns varians som M_1 .

- (c) Angiv et 95% konfidensinterval for standardafvigelsen σ i modellen M_1 .
- (d) Opskriv hypotesen, at modellen M_1 kan reduceres til den additive model M_2 , hvor middelværdien af skumvolumen er summen af et bidrag fra produktionstype og et bidrag fra ægstørrelse. Undersøg grafisk, om data kan forklares ved en additiv model. Lav så et test for hypotesen, at M_1 kan reduceres til M_2 .
- (e) Undersøg, om modellen M_2 kan reduceres yderligere. Husk at angive den faglige konklusion.

(Problemstillingen stammer fra en undersøgelse i Food Chemistry (Hidalgo et al, 2008), data er simuleret på baggrund af publikationen).