

Opgavesættet indeholder tre opgaver med i alt 11 delopgaver.

Obs: Beregninger skal altid dokumenteres, herunder skal der ved brug af CAS-værktøj enten angives den kommando man bruger eller der skal tages et billede af kommando og resultat på CAS-værktøjet.

Husk altid at *angive* beregnede resultater, såsom konfidensintervaller eller estimater; et R udskrift alene er ikke nok.

Opgave 1

Data i denne opgave vedrører koncentrationen af Hydroxymethylfuran (HMF) i bihonning, specifikt at denne stiger med lagringstiden. Der er data for fjorten glas honning, idet koncentrationen er målt både da honningen er frisk fra biavleren og igen efter to måneder.

Data er i filen *honey.csv* med søjlerne *honeysample*, der betegner honningglasset, *start*: koncentrationen i mg/kg ved første måling og *increase*: differensen mellem koncentrationen efter to måneder og koncentrationen *start* ved første måling.


- (a) Antag først, at stigning i HMF koncentration er normalfordelt. Beregn 90%-konfidensintervallet for middelværdien af stigningen under denne antagelse.
- (b) Simuler stikprøvefordelingen af gennemsnittet for *increase* ved bootstrapmetoden, og lav et histogram af de simulerede tal. Understøtter histogrammet en antagelse om, at stikprøvegennemsnit er normalfordelt? Vurder endvidere, på anden grafisk vis end ved et histogram, en antagelse om at bootstrapgennemsnittet er normalfordelt.
- (c) Beregn et bootstrap-t-konfidensinterval for middelværdien af stigningen i HMF koncentration. Sammenhold med intervallet du fik ved brug af normalfordelingsantagelsen, og vurder hvilket interval du synes er bedst.

I en yderligere undersøgelse baseret på disse data, vil man gerne bestemme sandsynligheden p for, at et tilfældig valgt glas honning efter to måneder indeholder mere end 20 mg/kg HMF (bemærk, det er indholdet efter to måneder, ikke stigning i løbet af to måneder).

- (d) Estimer sandsynligheden p for en honningprøve med et HMF indhold efter to måneder på mere end 20 mg/kg, og angiv et konfidensinterval med konfidensniveau på 0.90.

Opgave 2

I denne opgave betragtes sammenhængen mellem logaritmen til vægten og logaritmen til længden for 78 laks delt op efter køn. Sammenhængen er illustreret i figur 1. Data er i filen *salmon.csv*, der har tre søjler med overskrifterne *Sex*, *LnLength* og *LnWeight*. Det kan i opgaven antages, at for en given længde og et givet køn er logaritmen til vægten normalfordelt.



Figur 1: Logaritmen til vægten afsat mod logaritmen til længden for 42 laks af hankøn (o) og for 36 laks af hunkøn (+).

- (a) Navngiv de forskellige målte værdier. Formuler den statistiske model, hvor hvert køn har sin egen lineære sammenhæng mellem middelværdien af *logaritmen til vægten* og den forklarende variabel *logaritmen til længden*, og hvert køn har sin egen varians omkring regressionslinjen.

Lav to deldatasæt svarende til de to køn, og lav for hvert køn et skøn over variansen omkring regressionslinjen. Lav et test for, at de to køn har samme varians omkring regressionslinjen.

- (b) Betragt modellen, hvor den lineære sammenhæng mellem middelværdien af *logaritmen til vægten* og den forklarende variabel *logaritmen til længden* afhænger af køn, og de to køn har samme varians omkring regressionslinjen.

Lav et normalt qqplot for residualerne i denne model. Kommenter på, hvad du ser i figuren.

For at finde residualerne har du lavet et kald til *lm* i R. Forklar, hvad de forskellige led repræsenterer i din modelformel i kaldet af *lm*.

- (c) Lav et *F*-test for hypotesen, at der er samme hældning i regressionslinjerne for de to køn (husk at opskrive model og hypotese).
- (d) Betragt nu modellen, hvor der er samme hældning i regressionslinjen for de to køn, og lav et 95%-konfidensinterval for forskel i skæring af regressionslinjen mellem hankøn og hunkøn. Kan det antages, at de to skæringer er ens?

Opgave 3

I denne opgave skal I se på sammenhængen mellem et biologisk mål, nemlig ekspressionsniveauet for et *microRNA*, og en generel *helbredsscore*. Ekspressionsniveauet kan enten være *lav* eller *høj* og helbredsscoren kan være *orr-1*, *orr-2* eller *orr-3*. Antallene i de 6 mulige "kasser" fremgår af følgende tabel.

microRNA	Helbredsscore			total
	orr-1	orr-2	orr-3	
Lav	11	25	10	46
Høj	12	46	20	78

- (a) Lad antal_{ij} være antallet af personer i kategori i af *microRNA* (1:Lav, 2:Høj) og i kategori j af *helbredsscore* (1:orr-1, 2:orr-2, 3:orr-3). Opskriv den statistiske model for 2×3 matricen af de tilhørende stokastiske variable. Angiv hypotesen om uafhængighed mellem de to inddelingskriterier *microRNA* og *helbredsscore*.
- (b) Undersøg, om det kan antages, at de to inddelingskriterier *microRNA* og *helbredsscore* er uafhængige.
- (c) Betragt nu kun data vedrørende inddeling efter *helbredsscore*. Betragt hypotesen, at sandsynlighederne for de tre muligheder for *helbredsscore* er

$$P(\text{orr-1}) = \theta^2, \quad P(\text{orr-2}) = 2\theta(1 - \theta), \quad P(\text{orr-3}) = (1 - \theta)^2, \quad 0 \leq \theta \leq 1.$$

Opstil likelihoodfunktionen for θ baseret på data i tabellen ovenfor.

Find en formel for maksimum likelihood estimatet, og vis, at for data i opgaven her er $\hat{\theta} = 0.4718$.