

mat-stat re-eksamen 2023

#1

##1.1 jeg indlæser data

```
dat1<-read.csv("amitrip.csv")
```


```
head(dat1)
```

```
##      x   t1  t2  t3 t4
## 1 1763.91 2200 220 140 70
## 2 1530.01 1975 200 100 80
## 3 1963.71 3600 205 111 60
## 4 1529.07  675 160 120 80
## 5 1475.90  750 185  83 60
## 6 1379.38 2500 180  80 60
```

$M_0 : X_i \sim N(\alpha + \sum_{j=1}^4 \beta_j * t_{j,i}, \sigma^2) \text{ for } i \in \{1, \dots, 17\}$



```
lm1<-lm(x~t1+t2+t3+t4,data=dat1)
```

```
qqnorm(lm1$residuals)
qqline(lm1$residuals)
```





residualerne ser rimelige ud


```
par(mfrow=c(1,2))
plot(lm1$residuals~dat1$t1)
plot(lm1$residuals~dat1$t2)
```



```
plot(lm1$residuals~dat1$t3)
plot(lm1$residuals~dat1$t4)
```



```
plot(lm1$residuals~lm1$fitted.values)
```



og der virker ikke til at være en systematik i afvigelserne når man ser dem som funktion af t'erne

##1.2

```
summary((lm1))
```

```
##
## Call:
## lm(formula = x ~ t1 + t2 + t3 + t4, data = dat1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -238.58 -125.41   14.80   99.55  201.11
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1368.98780  476.76126   2.871  0.01405 *
## t1             0.13702   0.03608   3.798  0.00254 **
## t2            -0.84260   2.03436  -0.414  0.68605
## t3             4.99893   1.93865   2.579  0.02416 *
## t4            -5.69701   4.40048  -1.295  0.21980
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 151.9 on 12 degrees of freedom
## Multiple R-squared:  0.7256, Adjusted R-squared:  0.6341
## F-statistic: 7.931 on 4 and 12 DF,  p-value: 0.002288
```

p værdien for hypotesen om at t_2 's koeficient er 0 er størst da lader vi den gå ud

```
lm2<-lm(x~t1+t3+t4,data=dat1)
summary(lm2)
```

```
##
## Call:
## lm(formula = x ~ t1 + t3 + t4, data = dat1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -238.958 -116.985  -5.664   76.373  201.723
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1231.09710   330.21528   3.728  0.00253 **
## t1           0.13071    0.03165   4.130  0.00118 **
## t3           4.71083    1.75096   2.690  0.01853 *
## t4          -5.27348    4.14140  -1.273  0.22519
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 147 on 13 degrees of freedom
## Multiple R-squared:  0.7216, Adjusted R-squared:  0.6574
## F-statistic: 11.23 on 3 and 13 DF,  p-value: 0.0006498
```

her har vi at den største p værdi er ved t_4 da lader vi den gå ud

```
lm3<-lm(x~t1+t3,data=dat1)
summary(lm3)
```

```
##
## Call:
## lm(formula = x ~ t1 + t3, data = dat1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -201.64 -162.83   31.84  107.04  206.34
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  870.5210   173.6026   5.014 0.000189 ***
## t1           0.1366    0.0320   4.269 0.000779 ***
## t3           4.4543    1.7775   2.506 0.025177 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 150.3 on 14 degrees of freedom
## Multiple R-squared:  0.6869, Adjusted R-squared:  0.6422
## F-statistic: 15.36 on 2 and 14 DF,  p-value: 0.0002949
```

her ser vi at ingen p værdier for “irrelevans” er større end niveauet specificeret til 0.05 da stopper backwards selection metoden

vi tjekker modelreduction mode anova

```
anova(lm3,lm1)
```

```
## Analysis of Variance Table
##
## Model 1: x ~ t1 + t3
## Model 2: x ~ t1 + t2 + t3 + t4
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      14 316065
## 2      12 277055  2      39011 0.8448 0.4537
```

p værdien for f-testet er $0.45 > 0.05$ da lader vi modellen reducere og går videre med

##1.3 vi kalder fra vores modelfit

```
lm3$coefficients
```

```
## (Intercept)          t1          t3
## 870.5210022    0.1365905    4.4542940
```

```
confint(lm3)
```

```
##              2.5 %      97.5 %
## (Intercept) 498.18056528 1242.8614392
## t1           0.06796675    0.2052143
## t3           0.64190725    8.2666808
```

skæring: $\hat{\alpha} = 870.52$ med 95% konfidensinterval $[498.18056528, 1242.8614392]$ koeficienter: β_1 : $\hat{\beta}_1 = 0.1366$ med 95% konfidensinterval $[0.06796675, 0.2052143]$ β_3 : $\hat{\beta}_3 = 4.4542940$ med 95% konfidensinterval $[0.64190725, 8.2666808]$

##1.4

vi kalder predict functionen

```
nytpunkt<-data.frame(t1=1100,t3=80)
```

```
predict(lm3,nytpunkt,interval = "prediction")
```

```
##      fit      lwr      upr
## 1 1377.114 1037.51 1716.719
```

dette giver os den fittede værdi + konfidensintervallet (som jeg har specificeret til prediction) ##1.5 vi kender fordelingen af $s^2(X) = \frac{\|X - P(X)\|^2}{n - d} \sim \frac{\sigma^2 * \chi^2(n - d)}{n - d} \Leftrightarrow \frac{s^2(X)}{\sigma^2} * (n - d) \sim \chi^2(n - d)$ da har vi (noter at

jeg dropper frihedsgraden på χ^2 fraktilen men den stadig er der implicit) $P(\chi^2_{\frac{\alpha}{2}} \leq \frac{s^2(X)}{\sigma^2} * (n - d) \leq$

$$\chi^2_{1-\frac{\alpha}{2}}) = 1 - \alpha$$

$$\Leftrightarrow P\left(\frac{\chi^2_{\frac{\alpha}{2}}}{s^2(X) * (n - d)} \leq \frac{1}{\sigma^2} \leq \frac{\chi^2_{1-\frac{\alpha}{2}}}{s^2(X) * (n - d)}\right)$$

altså kan vi regne intervallet ud

```
qchisq(0.025,df=lm3$df.residual)/sigma(lm3)^2/lm3$df.residual
```

```
## [1] 1.780875e-05
```

```
qchisq(1-0.025,df=lm3$df.residual)/sigma(lm3)^2/lm3$df.residual
```

```
## [1] 8.263787e-05
```

```
s<-summary(lm3)$sigma
(qchisq(0.025,df=14)/s^2/14)
```

```
## [1] 1.780875e-05
```

```
(qchisq(1-0.025,df=14)/(s^2*14))
```

```
## [1] 8.263787e-05
```

altså har vi et konfidensinterval for præcisionen [1.780875e-05 ,8.263787e-05] hvilket virker utroligt lavt men når man kigger på vores standard error i vores fittede model er det måske ikke så værst

#2

##2.1

$H_0 : \pi_1 = \pi_2 = \pi_3 = \pi_4 = \frac{1}{4}$ for at undersøge hypotesen bruger vi likelihood ratio testoren og i forlængelse G testoren her noterer vi at der ikke er nogle frie parametre under hypotesen så vi behøver ikke gå i gang med at finde MLE for parametre og k i formellerne senere er 0 dette giver os simpelthen

```
A<-c(21,6,9,8)
k<-0
p=c(1/4,1/4,1/4,1/4)
e<-p*sum(A)
gtest<-2*sum(A*log(A/e))
pval<-1-pchisq(gtest,length(p)-1-k)
c(Gteststørrelse=gtest,Pværdi=pval)
```

```
## Gteststørrelse      Pværdi
##      11.17737907      0.01080439
```

p værdien er $0.01 < 0.05$ altså forkastes hypotesen om at forbrugerne er “lige Glade” for alle samgsvarianterne

##2.2 likelihood funktionen for en generel multinomial model med generelle parametre π_i er $L(\pi_1, \pi_2, \pi_3, \pi_4) = \frac{n!}{a_1!a_2!a_3!a_4!} * \pi_1^{a_1} * \pi_2^{a_2} * \pi_3^{a_3} * \pi_4^{a_4}$ lad $\pi_1 = 1 - 3p, \pi_2 = \pi_3 = \pi_4 = p$ da bliver

L blot en funktion af p $L(p) = \frac{n!}{a_1!a_2!a_3!a_4!} * (1 - 3p)^{a_1} * p^{a_2} p^{a_3} p^{a_4} = \frac{n!}{a_1!a_2!a_3!a_4!} (1 - 3p)^{a_1} * p^{a_2+a_3+a_4}$ her er $\frac{n!}{a_1!a_2!a_3!a_4!}$ blot en konstant som ikke afhænger af p som vi kan kalde C $\frac{n!}{a_1!a_2!a_3!a_4!} (1 - 3p)^{a_1} * p^{a_2+a_3+a_4} = C * (1 - 3p)^{a_1} * p^{a_2+a_3+a_4}$ som ønsket vist

##2.3 vi begrner de forventede under hypotesen $e_i = \pi_i(p)$ vi smider blot mle estimatet ind i funktionerne for sandsynlighederne og regner de forventede under hypotesen

```
ph=(6+9+8)/132
p=c((1-3*ph),ph,ph,ph)
e=44*p
e
```

```
## [1] 21.000000 7.666667 7.666667 7.666667
```

##2.4 vi kører G-test for at reducere modellen i den nye model er der en fri variable p da K=1

```
A<-c(21,6,9,8)
k<-1
p=c((1-3*ph),ph,ph,ph)
e<-p*sum(A)
gtest<-2*sum(A*log(A/e))
pval<-1-pchisq(gtest,length(p)-1-k)
c(Gteststørrelse=gtest,Pværdi=pval)
```

```
## Gteststørrelse      Pværdi
##      0.6256520      0.7313771
```

p værdien er temeligt høj så hypotesen om lige præferencer mellem de gamle smagsvarianter forkastes ikke

##2.5 $L(p) = C * (1 - 3p)^{a_1} * p^{a_2+a_3+a_4}$
 $l(p) = \log(C) + a_1 * \log(1 - 3p) + (a_2 + a_3 + a_4) * \log(p)$
 $\frac{\partial l}{\partial p} = \frac{-3 * a_1}{1 - 3p} + \frac{a_2 + a_3 + a_4}{p} = 0 \Leftrightarrow 3 * a_1 * p = (a_2 + a_3 + a_4) * (1 - 3p)$
 $3 * a_1 * p + 3 * p * (a_2 + a_3 + a_4) = a_2 + a_3 + a_4$
 $\Leftrightarrow \hat{p} = \frac{a_2 + a_3 + a_4}{3 * n} = \frac{a_2 + a_3 + a_4}{132}$ vi tjekker om det er et maksimum

$\frac{\partial^2 l}{\partial p^2} = \frac{-9a_1}{(1 - 3p)^2} - \frac{a_2 + a_3 + a_4}{p^2} < 0$ den andenafledte er negativ da har vi et maksimum #3

##3.a stikprøve D's 3. kvartil er over 4 det eneste boxplot hvor det er tilfældet er boxplot nummer 2 altså D hører sammen med 2

##3.b for en uniformt fordelt variable er CDF'en lineær og derved må den empiriske også være nogen lunde lineær den stikprøve som kommer tættest på er stikprøve B så mit svar er B

##3.c for boxplottet af en normal fordeling har vi at

#4

##4.1

```
dat2<-read.csv("/Users/asgeraircool/Desktop/matstat eksamenssæt/reksamen 2023/bilister.csv")
```

vi ønsker at lave en parret test for at eliminere variansen af at nogle mennesker har naturligt lavere eller højere reaktionsid

```
head(dat2)
```

```
## personID foer efter
## 1      1 4.44 4.50
## 2      2 4.77 3.88
```

```
## 3      3 6.56  6.05
## 4      4 5.07  5.74
## 5      5 5.13  5.49
## 6      6 6.72  7.48
```

vi ønsker at teste hypotesen $H_0 : \mu_{efter} - \mu_{foer} = 0$ $H_A : \mu_{efter} - \mu_{foer} > 0$ i matched pairs vil vi dog kun bytte rundt på indgange det er samme person under hypotesen vil vi kunne bytte rundt på dem lige så tosset vi har lyst så ideen er at vi prøver at gøre det en hel masse gange og ser hvor ekstrem den vi faktisk har observeret faktisk er (under denne hypotese kun i den store retning) vi gør dette med en permutationstest

```
obs<-mean(dat2$efter)-mean(dat2$foer)


d<-dat2$efter-dat2$foer
n<-length(d)

N<-10^5
result<-numeric(N)
for (i in 1:N){
  signs<-sample(c(1,-1),n,replace = TRUE)
  result[i] <- mean(signs*d)
}

p_lille<-(sum(result<=obs)+1)/(N+1)
p_stor<-(sum(result>=obs)+1)/(N+1)

p_2sidet<-2*min(p_lille,p_stor)
```

```
hist(result,freq = F)
abline(v=obs)
```



```
p_stor
```

```
## [1] 0.02532975
```

vi får at kun ca 2.5% af permutationerne giver os en værdi mindst lige så ekstrem da p værdien < 0.05 forkaster vi hypotesen om at reaktionshastigheden for folk der har drukket en svaps er den samme som folk der ikke har