

Opgavesættet indeholder fire opgaver med i alt tolv delopgaver.

Der lægges vægt på, at det af besvarelsen tydeligt fremgår, hvordan man kommer frem til de forskellige resultater. Hvis du bruger CAS, så angiv kommandoer, du har indtastet.

Yderlige bemærkninger:

- Ved log menes den naturlige logaritme.
- Den vedhæftede RMarkdown skabelon (MaSta-F2024R-besvarelse.rmd) indeholder lidt kommentarer med LaTeX koder fra formler i opgaverne 1 og 2; dette er ment som en hjælp. Kommentarer starter med `<!--` og ender med `-->`.

Held og lykke!

Opgave 1

En bestemt behandling gives højst to gange til en patient. Lykkes behandlingen ikke i første forsøg, får patienten endnu en behandling. Der er altså tre mulige udfald for en patient: S, behandlingen lykkes i første forsøg, FS, behandlingen mislykkes i første men lykkes i andet forsøg, og FF, behandlingen mislykkes i begge forsøg. Vi ser her på resultatet af behandlingen for 120 personer, som blev

$S(x_1)$	$FS(x_2)$	$FF(x_3)$	i alt
78	30	12	120

Lad θ_1 være sandsynligheden for at den første behandling lykkes, og lad θ_2 være den betingede sandsynlighed for at den anden behandling lykkes, givet at den første behandling mislykkes.

Antag, at vi som model for de observerede antal kan benytte multinomialmodellen

$$M_0 : (X_1, X_2, X_3) \sim \text{Multinom}(120, (p_1, p_2, p_3)),$$

hvor

$$(p_1, p_2, p_3) = (\theta_1, (1 - \theta_1)\theta_2, (1 - \theta_1)(1 - \theta_2)).$$

Der skal først undersøges, om sandsynligheden for succes er den samme for den første og den anden behandling. Betragt altså hypotesen

$$H_0 : \theta_1 = \theta_2.$$

(a) Gør rede for, at likelihood funktionen under H_0 er

$$L(\theta) = \binom{120}{x_1 \ x_2 \ x_3} \theta^{x_1+x_2} (1-\theta)^{x_2+2x_3},$$

hvor θ er den fælles værdi af θ_1 og θ_2 .

(b) Vis, at maksimum likelihood estimatet for den fælles værdi $\theta = \theta_1 = \theta_2$ under H_0 er

$$\hat{\theta} = \frac{x_1 + x_2}{2 \cdot 120 - x_1},$$

altså den relative frekvens af de vellykkede behandlinger, $x_1 + x_2$, blandt de ialt $2 \cdot 120 - x_1$ udførte behandlinger. Vis desuden, at de forventede antal, e_1, e_2 og e_3 , under H_0 med tre decimalers nøjagtighed er

$$(e_1, e_2, e_3) = (80.000, 26.667, 13.333).$$

(c) Test hypotesen H_0 og fortolk resultatet i forhold til problemstillingen.

Fra tidligere erfaringer formodes, at sandsynligheden for, at behandling lykkes, er 0.75, uanset om der er tale om første eller andet forsøg. I modellen M_0 svarer det til hypotesen

$$H_0^* : \theta_1 = \theta_2 = 0.75.$$

(d) Test hypotesen H_0^* (under M_0).

Opgave 2

Lad $X_1, \dots, X_n$ være i.i.d. kontinuert fordelte variable med tæthed givet ved

$$f(x; \alpha, \beta) = \begin{cases} \alpha \beta^\alpha x^{-(\alpha+1)}, & x \geq \beta, \\ 0, & x < \beta, \end{cases}$$

hvor $(\alpha, \beta) \in (0, \infty)^2$ er ukendte parametre.

- (a) Gør rede for, at maksimum likelihood estimatoren for β er givet ved

$$\hat{\beta} = \min(x_1, \dots, x_n).$$

Er estimatoren unbiased, eller har den en positiv eller negativ bias? Giv en kort begrundelse for dit svar.

- (b) Antag nu, at parametren β er kendt. Udled likelihoodligningen for maksimum likelihood estimatoren for α , og gør rede for, at estimatoren er givet ved


$$\hat{\alpha} = \frac{n}{\sum_{i=1}^n \log(x_i / \beta)}.$$

Er estimatoren unbiased, eller har den en positiv eller negativ bias? Giv en kort begrundelse for dit svar. Der oplyses, at $E \log(X_1 / \beta) = 1/\alpha$.

Opgave 3

Gordon Moore var medstifter af virksomheden Intel, der fremstiller mikroprocessorer til computere. Omkring 1975 formulerede Moore en forudsigelse om, at antallet af transistorer i mikroprocessorer vil fordobles hvert andet år. Forudsigelsen kaldes ofte "Moore's lov", som opgaven her vedrører.

Figur 1 viser et scatterplot af logaritmen til antallet mod årstallet.



Figur 1: Den naturlige logaritme til antallet af transistorer tegnet op mod årstallet, samt regressionslinje.

Datasættet Intel.csv indeholder variablerne Processor (processornavn), Year (udgivelsesår) og Transistors (antal af transistorer i processoren) for de 30 processorer vist i figuren ovenover.

Lad x_i og y_i betegne henholdsvis årstallet og logaritmen af antallet svarende til det i -te år, $i = 1, \dots, 30$. Figur 1 strider ikke mod rimeligheden af en lineær regression af logantal på årstallet, det vil sige af modellen

$$M_1 : Y_i \sim N(\alpha + \beta x_i, \sigma^2), \quad i = 1, \dots, 30,$$

som betragtes i det følgende.

- Angiv estimat og 95% konfidensinterval for såvel afskæringen som hældningen i model M_1 .
- Gør rede for, at ifølge den lineære regressionsmodel M_1 vokser antallet af transistorer med en faktor $e^{2\beta}$ i en toårsperiode.
- Angiv et konfidensinterval for $e^{2\beta}$. Er data i overensstemmelse med Moores lov?

Opgave 4

For at teste hypotesen, om to stikprøver kommer fra populationer med samme varians, kan der bruges et tosidet F -test, eller et tilsvarende permutationstest, hvor der bruges ratio mellem de to stikprøvevarianser som teststørrelse.

Ved begge tests antages, at observationerne er uafhængige. Der findes dog yderlige forudsætninger, som skal opfyldes, for at sikre, at signifikansniveauet overholdes.

Ute har lavet et simulationsstudie for at vurdere, om de to tests er passende for at teste éns varians i fire forskellige scenarier. Tabel 1 nedenunder viser koden som er brugt til at simulere to stikprøver x_a og x_b . For hver simulation af to stikprøver beregnes p -værdien fra F -test og p -værdien fra permutationstest med 9999 permutationer. Baseret på 50000 simulationer af to stikprøver estimeres så sandsynligheden for, at p -værdien p_{obs} er mindre end 0.05. Denne sandsynlighed kaldes $\hat{a}$ i tabellen.

Tabel 1: Kode til simulation af stikprøver i fire scenarier, samt estimerede sandsynligheder for at få en p -værdi på 0.05 eller mindre, ved et almindeligt F -test og et permutationstest. Sandsynligheder rundet til 3 decimaler.

Scenario	kode	estimeret ssh $\hat{a} = \hat{P}(p_{\text{obs}} \leq 0.05)$	
		F -test	permutationstest
(i)	<code>xa <- rnorm(20, 2, 1)</code> <code>xb <- rnorm(30, 2, 1)</code>	0.050	0.050
(ii)	<code>xa <- rnorm(20, 2, 1)</code> <code>xb <- rnorm(30, 10, 1)</code>	0.050	0.383
(iii)	<code>xa <- rnorm(20, 0, 1.5)</code> <code>xb <- rnorm(30, 0, 1)</code>	0.495	0.455
(iv)	<code>xa <- rlnorm(20, 0, 1)</code> <code>xb <- rlnorm(30, 0, 1)</code>	0.502	0.048

(a) Forklar simulationsresultaterne i tabel 1 for hver af de fire scenarier, ved at overveje følgende spørgsmål for F -testet og permutationstestet:

- simuleres fra testets nulhypotese?
- er alle forudsætninger opfyldt?

(b) Filen `sim.csv` indeholder et af de simulerede datasæt. Data er gemt som en tabel med to søjler: `x` indeholder de numeriske værdier, og `grp` angiver, hvilken stikprøve, a eller b, de tilhører.

Undersøg ved boxplot og normalfraktildiagrammer, hvilket af de fire ovenstående scenarier data må formodes at stamme fra. Giv så en anbefaling: hvilket test der bør anvendes for at undersøge, om varianserne er éns i begge populationer.

(c) Beregn p -værdien i det almindelige F -test og permutations- F -testet for datasættet i `sim.csv` fra delopgave (b). Hvilken p -værdi ville du indrapportere?