

Reeksamen 2024

2025-05-30

opgave 1

1.a

vi kan starte med at skrive likelihood fuktionen for en vilkårlig multinomialfordeling op

$$L(\pi_1, \pi_2, \pi_3) = \frac{n!}{a_1!a_2!a_3!} * \pi_1^{a_1} \pi_2^{a_2} \pi_3^{a_3}$$

ved at indæstte udtrykkene for π_i først under M_0

$$L(\theta_1, \theta_2) = \frac{n!}{a_1!a_2!a_3!} * (\theta_1)^{a_1} * ((1 - \theta_1)\theta_2)^{a_2} * ((1 - \theta_1)(1 - \theta_2))^{a_3}$$

under hypotesen har vi $\theta_1 = \theta_2$ ved at sætte det ind i udtrykket fra før får vi

$$L(\theta) = \frac{n!}{a_1!a_2!a_3!} * (\theta)^{a_1} * ((1 - \theta)\theta)^{a_2} * ((1 - \theta)(1 - \theta))^{a_3} = (\theta) = \frac{n!}{a_1!a_2!a_3!} * \theta^{a_1+a_2} * (1 - \theta)^{a_2+2a_3}$$

som ønsket

1.b

vi tager log og maksimerer

$$l(\theta) = \log(C) + (a_1 + a_2) * \log(\theta) + (a_2 + 2a_3)\log(1 - \theta)$$

$$\frac{\partial l}{\partial \theta} = \frac{a_1 + a_2}{\theta} - \frac{a_2 + 2a_3}{1 - \theta} = 0 \Leftrightarrow (a_1 + a_2)(1 - \theta) = (a_2 + 2a_3)\theta$$

$$\Leftrightarrow a_1 + a_2 = (a_1 + 2a_2 + 2a_3)\theta = (2n - a_1)\theta \Leftrightarrow \hat{\theta} = \frac{a_1 + a_2}{2n - a_1} = \frac{a_1 + a_2}{2 * 120 - a_1}$$

for det aktuelle tilfælde

```
ph<-(78+30)/(2*120-78)
e<-120*c(ph,ph*(1-ph),(1-ph)^2)
c(expected=e, MLE=ph)
```

```
## expected1 expected2 expected3      MLE
## 80.0000000 26.6666667 13.3333333  0.6666667
```

siden de forventede er større end 5 vil G testet være assymptotisk χ^2

1.c

jeg ser at M_0 faktisk bare er en ganske normal multinomialfordeling da vi vor en hver kombination af (p_1,p_2,p_3)(som er valide ift fordelingen) kan vælge thetaer så dette bliver opfyldt altså svare testen bare til den normale modelreduktion fra den basale multinomialfordeling så vi laver g test fra 2 frie parametre til 1 frit parameter altså har G testoren 1 frihedsgrad

```
A<-c(78,30,12)

k<-1

gtest<-2*sum(A*log(A/e))
pval<-1-pchisq(gtest,length(A)-1-k)
c(Gteststørrelse=gtest,Pværdi=pval)
```

```
## Gteststørrelse      Pværdi
##      0.5887517      0.4429022
```

p værdi på 0.44 betyder at vi ikke forkaster hypotesen og at det derved er rimeligt at reducere modellen ned til den hvor de har fælles sandsynlighed for at lykkedes

1.d

endnu en g test denne gange til en model med 0 frihedsgrader så vi regner de forventede og køre test

```
A<-c(78,30,12)
p<-0.75
k<-0
e<-120*c(p,(1-p)*p,(1-p)^2)
gtest<-2*sum(A*log(A/e))
pval<-1-pchisq(gtest,length(A)-1-k)
c(Gteststørrelse=gtest,Pværdi=pval)
```

```
## Gteststørrelse      Pværdi
##      6.21727984      0.04466166
```

p værdi under 0.05 betyder at vi forkaster hypotesen om at den fælles ærdi for theta er 0.75 og at det bedste bud for en model er den fremstillet under H_0 og ikke H_0^*

opgave 2

2.a

vi skriver Likelihood funktionen op

$$L(\alpha, \beta) = \prod_{i=1}^n \mathbb{I}(x_i \geq \beta) * \alpha * \beta^\alpha * x_i^{-(\alpha+1)}$$

$AFM : \hat{\beta} > \min(x_1, \dots, x_n) \Rightarrow L(\hat{\alpha}, \hat{\beta}) = 0$ da en af indikator fuktioner vil være 0

$$\text{set } \hat{\beta}' \leq \min(x_1, \dots, x_n) \text{ da } L(\hat{\alpha}, \hat{\beta}') > 0$$

da må vi have $\hat{\beta} \leq \min(x_1, \dots, x_n)$

$$AFM : \hat{\beta} < \min(x_1, \dots, x_n) \text{ set } \hat{\beta}' \in (\hat{\beta}, \min(x_1, \dots, x_n))$$

$$\text{da } L(\hat{\alpha}, \hat{\beta}') = \hat{\alpha}^n * \hat{\beta}'^{n*a} * \prod_{i=1}^n x_i^{-(\alpha-1)} > \hat{\alpha}^n * \hat{\beta}^{n*a} * \prod_{i=1}^n x_i^{-(\alpha-1)} = L(\hat{\alpha}, \hat{\beta})$$

estimatoren vil have for stort bias da den mindste altid vil være blødt større end β da sandsynligheden for at en af de n er lig β er lig nul da vi er i en kontinuert fordeling vil vi altid have positivt bias mens den stadig konvergerer asymptotisk

$$\hat{\beta} = \min(x_1, \dots, x_n) \geq \beta \text{ per konstruktion af fordelingen}$$

da der er positiv sandsynlighed for større udfald er estimatoren biased den har positiv bias

2.b

$$L(\alpha, \beta) = \prod_{i=1}^n \mathbb{I}(x_i \geq \beta) * \alpha * \beta^\alpha * x_i^{-(\alpha+1)}$$

da vi antager β kendt er indikatorfunktionen lige meget og vi kan blot tage log og maksimere

$$l(\alpha) = n * \log(\alpha) + n * \alpha * \log(\beta) - (\alpha + 1) \sum_{i=1}^n \log(x_i)$$

$$\frac{\partial l}{\partial \alpha} = \frac{n}{\alpha} + n * \log(\beta) - \sum_{i=1}^n \log(x_i) = 0$$

$$\Leftrightarrow \frac{n}{\alpha} = \sum_{i=1}^n \log(x_i) - \log(\beta) = \sum_{i=1}^n \log\left(\frac{x_i}{\beta}\right)$$

$$\Leftrightarrow \hat{\alpha} = \frac{n}{\sum_{i=1}^n \log\left(\frac{x_i}{\beta}\right)}$$

$$\frac{\partial^2 l}{\partial \alpha^2} = -\frac{n}{\alpha^2}$$

vi har per Jensens ulighed at siden $\frac{1}{x}$ er en konvekts funktion at

$$E[\hat{\alpha}] = E\left[\frac{n}{\sum_{i=1}^n \log\left(\frac{X_i}{\beta}\right)}\right] > \frac{n}{E\left[\sum_{i=1}^n \log\left(\frac{X_i}{\beta}\right)\right]}$$

$$= \frac{n}{\sum_{i=1}^n E\left[\log\left(\frac{X_i}{\beta}\right)\right]} = \frac{n}{n * \frac{1}{\alpha}} = \alpha$$

$1/n$ er konstant så vi lader den bare stå da er estimatet for stort og har derved positivt bias # opgave 3

3.a

jeg indlæser data

```
dat1<-read.csv("Intel.csv")
```

```
dat1$logtran<-log(dat1$Transistors)
head(dat1)
```

```
##              Processor Year Transistors  logtran
## 1      Intel 4004 (4-bit, 16-pin) 1971      2250  7.718685
## 2      Intel 8008 (8-bit, 18-pin) 1972      3500  8.160518
## 3      Intel 8080 (8-bit, 40-pin) 1974      6000  8.699515
## 4      Intel 8086 (16-bit, 40-pin) 1978     29000 10.275051
## 5 Intel 8088 (16-bit, 8-bit data bus) 1979     29000 10.275051
## 6      Intel 80286 (16-bit, 68-pin) 1982    134000 11.805595
```

herefter fitter jeg en lineær model

```
m1<-lm(dat1$logtran~dat1$Year)
summary(m1)
```

```
##
## Call:
## lm(formula = dat1$logtran ~ dat1$Year)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.99502 -0.36476 -0.04292  0.42461  1.71551
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -645.33832   20.61794  -31.30  <2e-16 ***
## dat1$Year     0.33144    0.01031   32.15  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8433 on 28 degrees of freedom
## Multiple R-squared:  0.9736, Adjusted R-squared:  0.9727
## F-statistic: 1034 on 1 and 28 DF,  p-value: < 2.2e-16
```

vi kalder confint for at få intervallerne

```
confint(m1)
```

```
##              2.5 %       97.5 %
## (Intercept) -687.5722628 -603.1043728
## dat1$Year     0.3103269    0.3525611
```

altså har vi 95% konfidensintervallerne for hhv. skæring α : [-687.5722628 -603.1043728] hældning β : [0.3103269 0.3525611]

3.b

i vores model har vi at vi forventer at $\log(T)$ stiger med $2 * \beta$ på 2 år

$$\log(\Delta T) = 2 * \beta \Leftrightarrow \Delta T = \exp(2 * \beta)$$

3.c

vi har allerede konfidensintervallet

$$\beta \in [l, h] \Leftrightarrow 2\beta \in [2l, 2h] \Leftrightarrow \exp(2\beta) \in [\exp(2l), \exp(2h)]$$

intervallet regner vi bare ud fra før

```
c(l=exp(2*0.3103269),h=exp(2*0.3525611))
```

```
##          l          h
## 1.860144 2.024094
```

på 2 år er vores 95% konfidensinterval for faktoren der skal ganges på [1.860144 2.024094] da 2 er i dette strider data ikke imod moores lov

opgave 4

4.a

1. simuleres der fra nulhypotesen? altså $\sigma_1^2 = \sigma_2^2$
2. er alle forudsætninger opfyldt? for F test og permutationstest F test kræver at begge rækker er normalfordelte observationsrækker som hver for sig har ens middelværdi altså hver række har fælles middelværdi og at de er uafhængige permutationstest kræver bare at hver observationsrække er uafhængige (og delvist også at hver observationsrække er ombyttelig hvilket aldrig bliver et problem i denne opgave da vi laver simulationer)

vi ser mange steder at permutationstesten bonger ud steder hvor nulhypotesen er sand disse fejl kommer fra at permutationstesten faktisk testor om rækkefølgen af alle de observerede er ligegyldig så egentlig ikke nødvendig vis hvad vi ønsker

i. 1: ja begge simulationer er normalfordelte med samme middelværdi og varians

2. ja begge observationsrækker er uafhængige og normalfordelte

ii.

1. ja begge er normalfordelte med samme varians

2. ja begge er uafh og normalfordelte

iii.

1. nej vi simulerer ikke fra nulhypotesen da vi har forskellige standardafvigelser 1.5 i den ene og 1.0 i den anden

2. ja begge rækker er normalfordelte og uafhængige

iv.

1. ja de 2 fordelinger har samme varians

2. nej de 2 er lognormale derved ikke normale


4.b

```
dat2<-read.csv("sim - Copy.csv")
head(dat2)
```

```
##      x grp
## 1 0.613  a
## 2 0.268  a
## 3 1.952  a
## 4 1.894  a
## 5 1.365  a
## 6 0.167  a
```


```
grpa<-subset(dat2,subset=grp=="a")
grpb<-subset(dat2,subset=grp=="b")
```

```
boxplot(dat2$x~dat2$grp)
```




```
qqnorm(grpa$x)
```

Normal Q-Q Plot




```
hist(grpa$x)
```

Histogram of grpa\$x




```
qqnorm(grpb$x)
```

Normal Q-Q Plot





```
hist(grpb$x)
```

Histogram of grpb\$x



vi ser at der ikke er nogen udfald under 0 hvilket tyder på at vi har at gøre med de lognormale data så jeg prøver at logge de 2 datasæt og ser hvordan qqplotsene ser ud efter

```
grpa$logx<-log(grpa$x)
grpb$logx<-log(grpb$x)
par(mfrow=c(1,2))
qqnorm(grpa$logx)
qqline(grpa$logx)
qqnorm(grpb$logx)
qqline(grpb$logx)
```



hvor data nu ser rigtig fint ud da tænker jeg at vi har et af de lognormale datasæt

ud fra tabellen vil jeg helt klart anbefale at bruge permutationstestet jeg vil dog passe på med at sige det i gennerellitet og vil egentlig meget hellere have en transformation af data og køre f test men siden jeg ikke har den mulighed så en permutationstest

4.c

vi laver den normale f-test ved var-test i r

```
var.test(grpa$x,grpb$x)
```

```
##
## F test to compare two variances
##
## data:  grpa$x and grpb$x
## F = 0.37418, num df = 19, denom df = 29, p-value = 0.02872
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.1676963 0.8987500
## sample estimates:
## ratio of variances
##      0.3741763
```

nu permutationstest

```

obj<-dat2$x

obs<-var(grpa$x)/var(grpb$x)

N<-10^4-1
result<-numeric(N)
for (i in 1:N){
  index<-sample(length(obj),size=length(grpa$x),replace = FALSE)
  result[i]<-var(obj[index])/var(obj[-index])
}
p_lille<-(sum(result<=obs)+1)/(N+1)
p_stor<-(sum(result>=obs)+1)/(N+1)

p_2sidet<-2*min(p_lille,p_stor)

```

```
p_2sidet
```

```
## [1] 0.6414
```

nu vartest på transformeret data

```
var.test(grpa$logx,grpb$logx)
```

```

##
## F test to compare two variances
##
## data:  grpa$logx and grpb$logx
## F = 1.0995, num df = 19, denom df = 29, p-value = 0.7989
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.4927811 2.6410070
## sample estimates:
## ratio of variances
##          1.09953

```

vi valgte at permutationstesten nok var bedst før fordi data ikke er normalfordelt af de 2 vil jeg da helst indrappotere permutationstestens p værdi på 0.64 og ikke forkaste hypotesen

helst ville jeg nok stadig helst indrappotere p værdien for f testen af de transformerede data