

*Dette dokument indeholder eksamenssættet sammen med mine egne kommentarer til de forskellige opgaver og udgør som sådan en vejledende besvarelse. Der tages behørigt forbehold for trykfejl, ligesom det skal understreges at det **ikke** er forventningen, at de indleverede besvarelser har samme format som nedenstående - Lars.*

Opgavesættet indeholder 3 opgaver med i alt 13 delopgaver.

Opgave 1

I tabellen nedenfor ses antallet af hjemmesejre, uafgjorte og udesejre i superligaen for 78 kampe i efteråret 2020 og for 114 kampe i foråret 2021.

Runde	Hjemmesejr	Uafgjort	Udesejr	Total
Efterår	37	17	24	78
Forår	49	31	34	114
Sum	86	48	58	192

- 1° Opstil en statistisk model for data og angiv med modellens parametre hypotesen om samme fordeling på *hjemmesejr*, *uafgjort* og *udesejr* for de to halvår.
- 2° Lav et test for hypotesen om samme fordeling på de to halvår.
- 3° Find estimat og 95%-konfidensinterval for sandsynligheden for *hjemmesejr* i sæsonen 2020-2021.
- 4° Benyt de samlede antal hjemmesejre, uafgjorte og udesejre til at undersøge, om sandsynlighederne for *hjemmesejr*, *uafgjort* og *udesejr* er ens.
- 1° Vi lader A_{ij} , $i = 1, 2 = \text{Efterår, Forår}$, $j = 1, 2, 3 = \text{Hjemmesejr, Uafgjort, Udesejr}$ betegne den stokastiske variabel der angiver antallet af resultater af typen j til tid i . Modellen kan da skrives

$$(A_{11}, A_{12}, A_{13}) \sim \text{multinom}(78, (\pi_{11}, \pi_{12}, \pi_{13})), \pi_{1j} \geq 0, \pi_{11} + \pi_{12} + \pi_{13} = 1$$

$$(A_{21}, A_{22}, A_{23}) \sim \text{multinom}(114, (\pi_{21}, \pi_{22}, \pi_{23})), \pi_{2j} \geq 0, \pi_{21} + \pi_{22} + \pi_{23} = 1$$

og hypotesen bliver

$$(\pi_{11}, \pi_{12}, \pi_{13}) = (\pi_{21}, \pi_{22}, \pi_{23})$$

- 2° Vi finder først det forventede antal under hypotesen

Runde	Hjemmesejr	Uafgjort	Udesejr	Total
Efterår	34.9375	19.5	23.5625	78
Forår	51.0625	28.5	34.4375	114
Sum	86	48	58	192

Vi finder teststørrelsen $G = 0.7658531$, som vi kan regne som approksimativt $\chi^2(2)$

fordelt da alle de forventede værdier er ≥ 5 . p -værdien findes dermed til

$$p_{\text{obs}} = 0.681863$$

og vi kan ikke afvise hypotesen af fordelingen er ens i de to halvår.
Ovenstående er fundet vha. følgende R-kode:

R-kode 1

```
# data indskrives
# Bruger G-test Afsnit 1.6

obs=rbind(c(37,17,24),c(49,31,34))

# forventede, teststørrelse og p-værdi beregnes
ex=outer(rowSums(obs),colSums(obs))/sum(obs)
gTest=2*sum(obs*log(obs/ex))
pval=1-pchisq(gTest,(dim(obs)[1]-1)*(dim(obs)[2]-1))

list(Forventede=ex,G=gTest,Pvaerdi=pval)
```

3° På grund af svaret i 2° betragtes nu summerne $A_j = A_{.j}$, $j = 1, 2, 3$ og vi betragter modellen

$$(A_1, A_2, A_3) \sim \text{multinom}(192, (\pi_1, \pi_2, \pi_3)), \pi_j \geq 0, \pi_1 + \pi_2 + \pi_3 = 1$$

På grund af egenskaberne for multinomial fordelingen gælder at $A_1 \sim \text{bin}(192, \pi_1)$ og konfidensintervallet findes vha. MSRR p. 214 -215. til (0.37928, 0.51859) eller (0.3767700, 0.5211815) hvis **prop.test** benyttes uden at specificere **correct=FALSE**, hvilket er o.k.

Koden er som følger:

R-kode 2

```
# 1. metode
u = qnorm(0.975)
x = 86
n = 192
(x+u^2/2+c(-1,1)*u*sqrt(x*(n-x)/(n+u^2/4)))/(n+u^2)

# 2. metode
prop.test(86, 192, conf.level = .95, correct = FALSE)$conf

# 3. metode
prop.test(86, 192, conf.level = .95)$conf
```

4° Modellen er som i 3°.

Det forventede antal findes to $(1, 1, 1) \cdot 192/3 = (64, 64, 64)$ og G -test-størrelsen findes til 11.78332 som er approksimativt $\chi^2(3-1)$ -fordelt (igen fordi de forventede er ≥ 5 . p -værdien bliver 0.002762391 og vi afviser hypotesen at sandsynligheden er ens for de tre typer resultater.

Koden er:

R-kode 3

```
a=c(86,48,58)
n=sum(a)
ex=n*rep(1,3)/3
G=2*sum(a*log(a/ex))
c(G=G, pval=1-pchisq(G,3-1), ex=ex)
```

Opgave 2

Det har længe været kendt, at sølv er bakteriehæmmende. Dette forsøger man at anvende ved at binde sølv til nanopartikler. Data i denne opgave vedrører 3 *hæmmere* anvendt på 4 *bakterietyper*. De tre hæmmere betegnes *soelv1* og *soelv2* samt *anti*, som står for brugen af et antibiotikum. De fire bakterietyper betegnes blot *B1*, *B2*, *B3* og *B4*. For hver kombination af metode og bakterietype er der foretaget 5 målinger. Selve målingen består i, at det anvendte materiale påføres en bakteriebelægning, og der måles efterfølgende radius af en cirkel, der dækker det område, der bliver bakteriefrit. De 60 dataværdier findes i filen **bakteriehaemmer.csv**, der har tre søjler med overskrifterne *Haemmer*, *Bakterietype* og *radius*. Det kan antages, at for hver kombination af hæmmer og bakterietype er det målte respons normalfordelt.

- 1° Opstil en statistisk model for data, og undersøg om det kan antages at der er samme varians i de $3 \cdot 4 = 12$ grupper af data.
- 2° Lav en grafisk undersøgelse af, om data kan beskrives med en additiv model for middelværdien med et bidrag fra henholdsvis hæmmer og fra bakterietype.
- 3° Lav et test for hypotesen om additivitet.
- 4° Angiv, under den additive model, skøn og 95%-konfidensinterval for forskellen i middelværdi mellem de to hæmmere *anti* og *soelv1*.
- 5° Undersøg om den additive model kan reduceres yderligere.


(Data i denne opgave er simulerede, men ligger tæt op ad data i artiklen *Ultrasmall AG⁺-rich nanoclusters as highly efficient nanoreservoirs for bacterial killing*, Nano Research, 2013.)

1°

Vi lader *H* og *B* betegne de to faktorer. Vi indfører betegnelserne $(1, 2, 3) = (\text{anti}, \text{soelv1}, \text{soelv2})$ og $(1, 2, 3, 4) = (B1, B2, B3, B4)$ for de respektive niveauer. Vi kan da opstille modellen, at den *i*th måling af radius r_i er udfald af en stokastisk variabel R_i hvor,

$$M_0 : R_i \sim N(\mu_{B_i, H_i}, \sigma_{B_i, H_i}^2) \quad i = 1, \dots, n$$
$$(\mu_{11}, \dots, \mu_{34}, \sigma_{11}^2, \dots, \sigma_{34}^2) \in \mathbb{R}^{12} \times \mathbb{R}_+^{12}$$

Vi kan nu undersøge om varianserne kan testes ens $\sigma_{ij}^2 = \sigma^2$. Koden er indsat nedenfor og vi ser at værdien af teststørrelsen er $Ba = 12.27$ som kan antages at være udfald af en approksimativ $\chi^2(11)$ fordeling, hvilket resulterer i en *p*-værdi på 0.3435. Vi kan ikke afvise at varianserne er ens, og kører derfor videre med modellen M_1 , hvor dette er tilfældet.



Figur 1: interaktionsplot

R-kode 4

```
dat=read.csv("bakteriehaemmer.csv",header=TRUE,stringsAsFactors=TRUE)
r=dat$radius
B=dat$Bakterietype
H=dat$Haemmer
bartlett.test(r,B:H)
```

2°

Vi tegner interaktionsplot vha. koden

R-kode 5

```
par(mfrow=c(1,2))
interaction.plot(B,H,r)
interaction.plot(H,B,r)
```

Resultatet er på Figur 1. Begge figurer viser næsten parallelle kurver, hvilket er i overensstemmelse med additive model.

3°

Vi ønsker nu at undersøge om vi kan reducere til en additiv model, det vil sige at vi undersøger hypotesen

$$H : \mu_{bh} = \eta_b + \zeta_h \quad h = 1, 2, 3 \quad b = 1, 2, 3, 4$$

Testet udføres ved hjælp af **anova**, mere specifikt **anova(lm(r~B+H), lm(r~B*H))**. Vi finder at F -teststørrelsen er 1.0969 som under hypotesen kommer fra en $F(6, 48)$ -fordeling.

Vi finder en p -værdi på 0.378. Data strider således ikke mod den additive struktur.

4°

Vi er nu i modellen M_2 ,

$$M_2 : \eta_b + \zeta_h \quad h = 1, 2, 3 \quad b = 1, 2, 3, 4$$

Vi ønsker vi at finde skøn og 95% konfidensinterval for differensen $\text{zeta}_{\text{soelv1}} - \text{zeta}_{\text{anti}} = \text{zeta}_2 - \text{zeta}_1$

Vi kører nu koden

R-kode 6

```
fit = lm(r~B+H)
summary(fit)
confint(fit)
```

Ved at aflæse den relevante linie i **summary** ser vi skønnet er -15.12 og ved at benytte **confint** findes og 95%-konfidensinterval er $[-16.67, -13.58]$. Behandling med antibiotikum giver altså radii der i middel er cirka 15 større end ved behandling soelv1.

5°

Vi er stadig modellen M_2 ,

$$M_2 : \eta_b + \zeta_h \quad h = 1, 2, 3 \quad b = 1, 2, 3, 4$$

Vi ønsker nu at undersøge hypoteserne

$$\begin{aligned} H_{3H} : \mu_{bh} &= \zeta_h & h = 1, 2, 3 & \quad b = 1, 2, 3, 4 \\ H_{3B} : \mu_{bh} &= \eta_b & h = 1, 2, 3 & \quad b = 1, 2, 3, 4 \end{aligned}$$

De to hypoteser er undersøgt på koden

R-kode 7

```
# Tester for ingen effekt af bakterietype under additive model:
anova(lm(r~H), lm(r~B+H))

# Tester for ingen effekt af haemmer under additive model:
anova(lm(r~B), lm(r~B+H))
```

og i begge tilfælde afvises det, at vi kan reducere modellen yderligere. ($p_{\text{obs}} = 8.422e - 12$
og $p_{\text{obs}} < 2.2e - 16$)

Opgave 3

Lad F betegne fordelingsfunktionen givet ved

$$F(x) = \begin{cases} 1 - e^{-\lambda\sqrt{x}}, & \text{hvis } x \geq 0 \\ 0 & \text{ellers} \end{cases},$$

hvor $\lambda > 0$. På filen **sim.csv** findes et datasæt, der består af 100 observationer af en variabel $Xsim$, som skal benyttes i opgaven.

1° Vis, at p -fraktilen q_p , $0 < p < 1$, for F er givet ved

$$q_p = \frac{(\log(1-p))^2}{\lambda^2}.$$

2° Benyt resultatet fra 1° til at tegne et fraktildiagram, der undersøger, om det er rimeligt at antage, at observationerne af $Xsim$ udgør en observationsrække fra fordelingen med fordelingsfunktion F med $\lambda = 1$.

Lad nu $X_1, \dots, X_n$ betegne en i.i.d. følge af stokastiske variable med fordelingsfunktion F , hvor $\lambda > 0$ er en ukendt parameter. I opgave 3° og 4° må det uden bevis benyttes at X_i , $i = 1, \dots, n$, har samme fordeling som Z^2 , hvor Z er eksponentialfordelt med rateparameter λ .

3° Vis, at man ved at benytte momentmetoden kommer frem til følgende estimator for λ :

$$\hat{\lambda}^M = \sqrt{\frac{2}{\bar{X}}},$$

hvor $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, og angiv estimatet for λ beregnet ud fra observationerne af $Xsim$.

4° Udfør et simulationseksperiment, der genererer 1000 udfald af $\hat{\lambda}^M$ baseret på observationsrækker med $n = 100$ observationer og $\lambda = 1$. Lav et histogram af udfaldene, og angiv et estimat for standardafvigelsen af $\hat{\lambda}^M$.

1°

Lettest bare at indsætte - bemærk at for $0 < p < 1$ er $q_p > 0$ så

$$\begin{aligned} F(q_p) &= 1 - e^{-\lambda\sqrt{q_p}} = 1 - e^{-\lambda\sqrt{\frac{\log(1-p)^2}{\lambda^2}}} \\ &= 1 - e^{-\sqrt{\log(1-p)^2}} \\ &= 1 - e^{-|\log(1-p)|} \\ &= 1 - e^{\log(1-p)} \\ &= 1 - (1 - p) = p \end{aligned}$$

2°

Fraktildiagrammet findes på Figur 2, og kan konstrueres vha.

R-kode 8

```
X = read.csv(file="sim.csv",header = TRUE)

N = length(X$Xsim)

seq = ((1:N) - 0.5)/N
xs = log(1-seq)^2

plot(xs,sort(X$Xsim))
abline(a=0,b=1)
```

Vi bemærker at punkterne smyger sig omkring identitetslinien, og figuren støtter antagelsen om at data kommer fra den pågældende fordeling.

3°

Vi ønsker først at finde middelværdien af X . Det er lettest at benytte hintet og skrive


$$\mathbb{E}[X] = \mathbb{E}[Z^2] = \mathbb{V}\text{ar}[Z] + (\mathbb{E}[Z])^2 = \frac{1}{\lambda^2} + \left(\frac{1}{\lambda}\right)^2 = \frac{2}{\lambda^2}.$$

Hvor man for middelværdi og varians faktisk kan henvise til bogen: Theorem B.8.1 . Alternativ kan middelværdien beregnes ved at opstillende et passende integral. Moment estimatoren findes dernæst ved at løse

$$\frac{2}{\lambda^2} = \bar{X}.$$

jvf. Bogen kap 6.2 eller Eksempel 2.2 i noterne og kan implementeres vha. `sqrt(2/mean(X$Xsim))` Estimatet hørende til $Xsim$ beregnes til 1.026533.

4°




Figur 2: qqplot

Et eksempel på hvordan simulationseksperimentet kan udføres er følgende:

R-kode 9

```
N = 100
R = 5000
out = rep(0, R)
for(i in 1:R) {
  X = rexp(N, rate=1)^2
  out[i] = sqrt(2/mean(X))
}
hist(out)
sd(out)
```

Standardafvigelsen estimeres til cirka 0.11 og histogrammet skal ligne Figur 3



Figur 3: Histogram