

*Dette dokument indeholder eksamenssættet sammen med mine egne kommentarer til de forskellige opgaver og udgør som sådan en vejledende besvarelse. Der tages behørigt forbehold for trykfejl, ligesom det skal understreges at det **ikke** er forventningen, at de indleverede besvarelser har samme format som nedenstående - Lars.*

Opgavesættet indeholder 3 opgaver med i alt 12 delopgaver.

Opgave 1

Ved en multiple choice opgave stilles de studerende et spørgsmål, som skal besvares med ét blandt tre mulige svar. Svarmulighederne er A , B eller C . De studerende er placeret i to grupper $G1$ og $G2$, men det vides ikke hvorledes gruppeplaceringerne er foretaget.

		Svar			Sum
		A	B	C	
Gruppe	$G1$	15	17	57	89
	$G2$	40	56	35	131
	Sum	55	73	92	220

Tabel 1: Multiple choice svar fordelt på gruppe ($G1$ og $G2$) og svarmulighed (A , B og C).

Man ønsker at undersøge, om der er uafhængighed mellem gruppeplaceringen og de afgivne svar.

- 1° Opstil en statistisk model for data, og undersøg om der er uafhængighed mellem inddelingskriterierne *svar* og *gruppe*.

Et mindre hold af studerende blev ligeledes inddelt i to grupper og stillet en anden multiple choice opgave, som i dette tilfælde havde fire svarmuligheder.

		Svar				Sum
		A	B	C	D	
Gruppe	$H1$	2	1	1	10	14
	$H2$	4	5	4	4	17
	Sum	6	6	5	14	31

Tabel 2: Multiple choice svar for et mindre hold af studerende.

- 2° Undersøg om det for det lille hold kan antages, at der er uafhængighed mellem inddelingskriterierne *svar* og *gruppe*.

1. Det fremgår at vi ønsker at udføre et test for uafhængighed. Som startmodel betragtes

derfor

$$M_{I0} : (A_{11}, \dots, A_{rk}) \sim \text{multinom}(n, (\pi_{11}, \pi_{12}, \dots, \pi_{rk}))$$
$$\pi_{ij} \geq 0 \quad \pi_{11} + \pi_{12} + \dots + \pi_{rk} = 1$$

hvor $n = 220$, $r = 2$ og $k = 3$ jf. afsnit 1.7 i webbogen. Uafhængighedshypotesen er at der findes α_i og β_j således at $\pi_{ij} = \alpha_i \beta_j$ $i = 1, 2$, $j = 1, 2, 3$. I dette tilfælde kan vi direkte bruge R -koden fra afsnittet vedrørende homogenitetstestet med det givne datasæt indskrevet, dvs.

R-kode 1

```
# data indskrives
obs=rbind(c(15,17,57),c(40,56,35))

# forventede, teststørrelse og p-værdi beregnes
ex=outer(rowSums(obs),colSums(obs))/sum(obs)
gTest=2*sum(obs*log(obs/ex))
pval=1-pchisq(gTest,(dim(obs)[1]-1)*(dim(obs)[2]-1))

list(Forventede=ex,G=gTest,Pvaerdi=pval)
```

Dette viser at alle forventede er ≥ 5 kan vi pga. G teststørrelsen på 30.99704 og p -værdien $1.858144e-07$ konkludere at det ikke kan antages at der er uafhængighed mellem inddelingskriterierne.

2. Situationen vedrørende modellen er i dette spørgsmål er identisk med situationen i 1° og vi kører først R-kode 1 med data fra den lille gruppe. Vi bemærker at vi *ikke* kan benytte vores χ^2 -test, da der ikke er tilstrækkeligt mange celler med forventede ≥ 5 . Vi benytter i stedet Fishers eksakte test, **fisher.test(obs)**, og får en p -værdi på 0.07261 således at vi ikke kan afvise at der er uafhængighed mellem observationskriterierne i den lille gruppe.

Et alternativ til Fishers eksakte test er et permutationstest, som beskrevet i webbogens afsnit 1.8 - Dette vil resultere i en G teststørrelse på 7.883871 og en p -værdi på cirka 0.09, og er også et korrekt svar. Forskellen på de to p -værdier skyldes at **fisher.test** ikke bruger G -størrelsen som teststørrelse, men derimod den betingede sandsynlighed for den observerede tabel.

Opgave 2

Ved et forsøg ønskede man at undersøge sammenhængen mellem samtidige målinger af hjertets slagvolumen (målt i ml/kg) og blodtrykket (målt i cm H_2O) hos tre arter af skildpadder, som vi i opgaven kalder A , B og C .

I opgaven tages udgangspunkt i en model, hvor middelværdien af slagvolumen afhænger lineært af blodtrykket inden for de tre arter. Vi lader x_{gi} betegne den i te måling af slagvolumen for art g , og idet data kan betragtes som normalfordelt, opstilles modellen, hvor målingerne af slagvolumen er udfald af stokastiske variable

$$M_0 : X_{gi} \sim N(\alpha_g + \beta_g b_{gi}, \sigma_g^2), \quad g = A, B, C, \quad i = 1, \dots, n_g,$$

hvor b_{gi} angiver den i te måling af blodtrykket for art g , og X_{gi} -erne er uafhængige. Der er foretaget 10 målinger for hver af de tre arter, så $n_A = n_B = n_C = 10$.

Datasættet findes på filen **turtles.csv**, som indeholder de tre søjler **art**, **slagvolumen** og **blodtryk**.

- 1° Vis, at det kan antages, at variansen inden for de tre grupper er ens, og angiv estimatet for den fælles varians.

På grund af resultatet i 1° betragtes nu modellen

$$M_1 : X_{gi} \sim N(\alpha_g + \beta_g b_{gi}, \sigma^2), \quad g = A, B, C, \quad i = 1, \dots, n_g.$$

- 2° Lav grafisk model kontrol af M_1 baseret på residualerne.

- 3° Vis, at det kan antages, at der er fælles hældning og angiv estimat og 95% konfidensinterval for den fælles hældning.

I delspørgsmål 4° og 5° betragtes modellen

$$M_2 : X_{gi} \sim N(\alpha_g + \beta b_{gi}, \sigma^2), \quad g = A, B, C, \quad i = 1, \dots, n_g.$$

- 4° Angiv 95% konfidensinterval for variansen σ^2 i modellen M_2 .

- 5° Angiv 95% konfidensintervaller for de tre afskæringer α_A , α_B og α_C i M_2 .

1°

Vi tilpasser koden i afsnit 5.2, der omhandler gruppespecifik regression.

R-kode 2

```
dat = read.csv(file="turtles.csv",header = TRUE,stringsAsFactors = TRUE)

# gruppespecifik model analyseres
lmUD1=lm(slagvolumen[art=="A"]~blodtryk[art=="A"],data = dat)
lmUD2=lm(slagvolumen[art=="B"]~blodtryk[art=="B"],data = dat)
lmUD3=lm(slagvolumen[art=="C"]~blodtryk[art=="C"],data = dat)
```

```
# Bartlett's test  
bartlett.test(list(lmUD1, lmUD2, lmUD3))
```

Vi finder derved en værdi af Bartlett's teststørrelse på $Ba = 1.8235$ som er approksimativt udfald af en $\chi^2(2)$ fordeling. p -værdien findes til 0.4018, så vi kan godt acceptere hypotesen om ens varians.

Vi fitter derefter en lineær normal model mod gruppespecifik regression og finder estimatet for den fælles varians:

R-kode 3

```
M1 = lm(slagvolumen~art*blodtryk, data = dat)  
summary(M1)$sigma^2
```

Estimatet for den fælles varians findes til 1.302162
2°

Vi ønsker at undersøge om residualerne i M_1 kan antages at være normalfordelt og 2° samt hvorvidt der er systematiske afvigelser fra nullinjen og om variansen ser ud til at afhænge af den forklarende variabel.

Figureerne laves ved hjælp af R-koden :

R-kode 4

```
qqnorm(M1$residuals)  
plot ( dat$blodtryk , M1$residuals )  
abline (0 ,0)
```

De relevante plots findes i Figure 1. Fraktilplottet er fint, da punkterne smyer sig om en ret linie uden systematiske afvigelser, og i residualplottet ser vi heller ikke systematisk afvigelser fra nullinjen eller indikationer af at variansen afhænger af den forklarende variabel.


3°

Testet for reduktion fra modellen med gruppespecifik hældning, til modellen med fælles hældning foretages vha.

R-kode 5

```
M2 = lm(slagvolumen~art + blodtryk, data = dat)  
anova(M2, M1)  
summary(M2)  
confint(M2)
```

Vi ser at teststørrelsen bliver $F = 1.7662$ for er udfald af en F -fordeling med 2 frihedsgrader i tælleren og 26 frihedsgrader i nævneren 0.1925. Estimatet findes vha. **summary** til -0.5251 og et 95% konfidensinterval ved at køre **confint** på den fittede model og vi



Figur 1: Residualplot og qqplot til modelkontrol af model $M1$

finder konfidensintervallet for den fælleshældning til $(-0.7665044, -0.2836816)$

4°

Fra resultat 2.6.1 har vi formelen for konfidensintervallet for σ^2 . Antallet af frihedsgrader er 26, hvilket vi kan aflæse fra **Summary** eller tælle os frem til. Konfidensintervallet kan beregnes vha.

R-kode 6

```
df = 26 #aflases
sigsq = summary(M2)$sigma^2
c(df*sigsq/qchisq(0.975,df),df*sigsq/qchisq(0.025,df))
```

Vi finder et 95% konfidensinterval for variansen på $(0.8551778 \text{ } 2.5897148)$.

5°

Oversigt over mulige parametriseringer i Afsnit 5.1 fortæller at vi kan få en model frem med de forskellige afskæringer ved at køre `lm(slagvolumen ~ art -1 + blodtryk, data = dat)`. I sin helhed bliver R-koden derved

R-kode 7

```
M2noint = lm(slagvolumen~art -1 + blodtryk, data = dat)
confint(M2noint)
```

Konfidensintervallerne aflæses til

artA	2.8072498	6.1909190
artB	3.6642088	7.0264864
artC	4.8220277	8.2630858

Opgaven kan også løses ved at bruge **predict** funktionen og få konfidensinterval hørende til værdien 0 af den forklarende variabel (blodtryk).

Opgave 3

I nærværende opgave betragtes parameterestimation og test i en delmodel af $\text{Beta}(a, b)$ modellen. En $\text{Beta}(a, b)$ -fordelt stokastisk variabel X , hvor $a > 0, b > 0$, har middelværdi og varians

$$E[X] = \frac{a}{a+b} \quad \text{og} \quad \text{Var}[X] = \frac{ab}{(a+b)^2(a+b+1)}.$$

Vi ser på delmodellen med parameter $b = 2$, og en i.i.d. følge $X_1, \dots, X_n$ fra denne.

1° Gør rede for, at momentestimatoren for a er givet ved

$$\hat{a} = \frac{2\bar{X}}{1 - \bar{X}}, \quad \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Beregn estimatet for a ud fra datasættet $\mathbf{x}$, som genereres ved hjælp af kodestumpen i R-kode 8.

R-kode 8

```
set.seed(42)
x <- rbeta(100, 3, 2)
```

2° Lav ud fra datasættet fra R-kode 8 et histogram af bootstrap fordelingen for estimatoren $\hat{a}$ og beregn et 90% percentil interval.

3° Gør kort rede for, at fordelingen af gennemsnittet $\bar{X}$ kan approksimeres ved

$$\bar{X} \sim N\left(\frac{a}{a+2}, \frac{2a}{n(a+2)^2(a+3)}\right).$$

Vi ønsker at benytte approksimationen til at lave et test af nulhypotesen $a = 3$ mod alternativet $a < 3$, ved brug af stikprøvegennemsnittet, $\bar{X}$, som teststørrelse. Gør rede for, at det er oplagt at lave et ensidet test og beregn p -værdien for en observeret stikprøve med $n = 100$ og $\bar{x} = 0.59$.

4° I modellen $X \sim \text{Beta}(a, 2)$ foreslås et test af nulhypotesen $a = 3$ mod alternativet $a < 3$ som følger: Forkast nulhypotesen, når gennemsnittet af 100 værdier er mindre end $C = 0.57$.

Beregn, ved brug af normalapproksimationen fra 3°, sandsynligheden for type I fejl ved dette test, samt sandsynligheden for type II fejl når den sande parameter er $a = 2.5$.

5° Betragt situationen fra 4°. Lav et simulationseksperiment for at skønne sandsynligheder for type I og type II fejl. Skønnene skal beregnes ved hjælp af simulationer af 10000 stikprøver af størrelse $n = 100$ hver fra nulmodellen (hvor $a = 3$) og fra alternativmodellen (med $a = 2.5$).

1° Estimatoren findes ved at løse ligningen

$$\frac{\hat{a}}{\hat{a} + 2} = \bar{X}.$$

for $\hat{a}$. Idet vi bemærker at $\bar{X} \neq 1$ med sandsynlighed 1 har vi

$$\frac{\hat{a}}{\hat{a} + 2} = \bar{X} \Rightarrow \hat{a}(1 - \bar{X}) = 2\bar{X} \Rightarrow \hat{a} = \frac{2\bar{X}}{1 - \bar{X}}$$

Estimatet for datasættet findes til 2.878335 ved hjælp af følgende *R*-kode:

R-kode 9

```
set.seed(42)
x <- rbeta(100, 3, 2)

M1 <- mean(x)
2*M1/(1-M1)
```

2°

Koden til bootstrapping og histogram er


R-kode 10

```
N <- 10000
aboot <- numeric(N)
abootmean <- numeric(N)
for (i in 1:N){
  xboot <- sample(x, replace = TRUE)
  M1 <- mean(xboot)
  abootmean[i] = M1
  aboot[i] <- 2*M1/(1-M1)
}
hist(aboot)
```

Histogrammet er i Figur 2. - percentil-intervallet findes til (2.524034, 3.288573) ved hjælp af

R-kode 11

```
quantile(aboot, c(0.05, 0.95))
```



Figur 2: Histogram til opgave 3.2

3°

Vi har fra s. 84 i MSRR fortolkning af CLT, som værende at fordelingen af $\bar{X}$ for n tilstrækkelig stor approsimativt normal med middelværdi μ og spredning σ/n hvor μ og σ er hhv. middelværdi og spredning for X . Sættes $b = 2$ i de udtryk der er opgivet i starten, fås umiddelbart den ønskede normalfordelingsapproximation, dvs.

$$\bar{X} \sim N\left(\frac{a}{a+2}, \frac{2a}{n(a+2)^2(a+3)}\right)$$

konkret for $a = 3$ og $n = 100$:

$$\bar{X} \sim N(0.6, 0.0004)$$

Middelværdien af $\bar{X}$ vokser monoton med a , derfor forventes der små værdier af $\bar{X}$ når a er lille og omvendt. Da vi tester mod alternativet $a < 3$, vil vi helst forkaste nulhypotesen når $\bar{X}$ er lille.

Beregning af p -værdi foretages vha. `pnorm(.59, .6, sqrt(0.0004))` og giver 0.3085375

4° Sandsynligheden for type 1 er sandsynligheden for at forkaste hypotesen (dvs. observere $\bar{X} < 0.57$), når hypotesen er sand, dvs. når $a = 3$. Sandsynligheden for type 2 er sandsynligheden for at acceptere hypotesen (dvs. observere $\bar{X} \geq 0.57$), når alternativet er sandt, d.v.s. når $a = 2.5$.

Ved hjælp af R -koden på 12 findes tallene 0.0668072 og 0.2477062 for hhv. type 1 og type 2 fejl.

R-kode 12

```
C <- .57
```

```
# type 1
a <- 3
n <- 100
p1 <- pnorm(C, a/(a+2), sqrt(2*a/(a+2)^2/(a+3) / n))
pnorm( (C - a/(a+2))/(sqrt(2*a/(a+2)^2/(a+3) / n)), 0, 1)
# type 2
a <- 2.5
n <- 100
p2 <- 1- pnorm(C, a/(a+2), sqrt(2*a/((a+2)^2*(a+3)) / n))
c("type_1"=p1, "type_2"=p2)
```

5°

Simulationskoden findes på R-kode 13.

R-kode 13

```
C <- .57
Nsim <- 10000
xbarnul <- numeric(N)
xbaralt <- numeric(N)
for (i in 1:N){
  xbarnul[i] <- mean(rbeta(100, 3, 2))
  xbaralt[i] <- mean(rbeta(100, 2.5, 2))
}
c("type_1"=mean(xbarnul < C), "type_2"=mean(xbaralt >= C))
```

Tallene skal ligne de tal som fandtes i opgave 4°.