

eksamen juni 2019 besvarelse

Nanna Liv Berdiin

2025-05-31

opgave 1

Efter det sidste Europavalg i 2014 var 5 af de valgte medlemmer fra Danmark kvinder, og 8 var mænd; i Sverige var 11 ud af 20 medlemmer kvinder og i Finland var det 7 ud af 13. Undersøg ved et test, om kvindernes chancer for at blive medlem i Europaparlamentet er den samme i de tre lande. Giv korte svar:

a)

Hvilket test bruger du, og hvilken fordeling antages for teststørrelsen under nulhypotesen?

jeg ville gøre dette under multinomialfordelingen her har vi en G teststørrelse som er approksimativt chi i anden fordelt, χ^2 . så jeg ville lave en homogenitetstest/test for uafhængighed.

b)

Angiv teststørrelsen og p-værdien.

```
obs=rbind(c(5,11,7),c(8,9,6))
# forventede , teststørrelse og p-værdi beregnes
ex=outer(rowSums(obs),colSums(obs))/sum(obs)

gTest=2*sum(obs*log(obs/ex))

pval=1-pchisq(gTest,(dim(obs)[1]-1)*(dim(obs)[2]-1))

list(Forventede=ex,G=gTest,Pvaerdi=pval)
```

```
## $Forventede
##      [,1] [,2] [,3]
## [1,]  6.5  10  6.5
## [2,]  6.5  10  6.5
##
## $G
## [1] 0.975921
##
## $Pvaerdi
## [1] 0.6138771
```

fordi de forventede alle er over 5 kan jeg bruge denne. vi ser at teststørrelsen er 0.976 og p-værdien er 0.614. vi afviser ikke hypotesen om ens sandsynligheder.

c)

Hvad er den faglige konklusion?

at vi godt kan antage at kvinder chancer for at blive medlem er ens i de tre lande.

opgave 2

Trykstyrke er en af de vigtigste egenskaber ved beton. Datasættet `betonstyrke.csv`, som skal analyseres i denne opgave, stammer fra et forsøg vedrørende trykstyrke af en betonblanding. Ved forsøget blev der anvendt tre forskellige blandemaskiner og to forskellige trykstyrkemålere. For hver kombination af blandemaskine og trykstyrkemåler blev fem betonblokke fremstillet med den pågældende blandemaskine, og trykstyrken blev målt med den pågældende trykstyrkemåler. Variablerne indeholdt i datasættet er styrke - trykstyrke, målt i N/mm², blander - angiver de tre blandemaskiner, maaler - angiver de to trykstyrkemålere, og gruppe - angiver de seks grupper, dannet ved kombination af blandemaskine og tryk- styrkemåler. I det følgende kan det antages, at for hver af de seks grupper er trykstyrken normalfordelt. Obs: Opskriv undervejs formelt de modeller du bruger.

a)

Opstil en statistisk model for disse trykstyrker. Vis ved et test, at det kan antages, at variansen af trykstyrken ikke afhænger af gruppen.

vi har lige nu modellen

$$M_1 : X_{ijk} \sim N(\mu_{ij}, \sigma_i^2), i = 1, 2, j = 1, 2, 3, k = 1, \dots, n_{ij}$$

og vil teste hypotesen om at variansen er ens

$$H_{0\sigma^2} : \sigma_i^2 = \sigma^2, i = 1, 2, 3, 4, 5, 6$$

dette gør vi med bartletts test

```
betonstyrke <- read.csv("betonstyrke.csv")

respons_variabel <- betonstyrke$styrke
forklarende_variabel <- betonstyrke$gruppe

#kører bartlett test for ens varians
bartlett.test(respons_variabel ~ 1 + forklarende_variabel)

##
## Bartlett test of homogeneity of variances
##
## data:  respons_variabel by forklarende_variabel
## Bartlett's K-squared = 6.8635, df = 5, p-value = 0.231
```

her får vi en p-værdi på 0.231 og vi afviser altså ikke hypotesen om ens varians. det betyder at vi nu har modellen

$$M_1^* : X_{ijk} \sim N(\mu_{ij}, \sigma^2), i = 1, 2, j = 1, 2, 3, k = 1, \dots, n_{ij}$$

b)

Vis ved et test, at det kan antages, at der er additiv virkning af blandemaskine og trykstyrkemåler på trykstyrken.

dette kan vi teste med et kald til anova ved at skrive den additive model op også

```
lmfit_m1star <- lm(betonstyrke$styrke ~ 1 + betonstyrke$gruppe)
lmfit_m2 <- lm(betonstyrke$styrke ~ betonstyrke$blander + betonstyrke$maaler)
anova(lmfit_m2, lmfit_m1star)
```

```
## Analysis of Variance Table
##
## Model 1: betonstyrke$styrke ~ betonstyrke$blander + betonstyrke$maaler
## Model 2: betonstyrke$styrke ~ 1 + betonstyrke$gruppe
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      44 1035.1
## 2      42 1027.4  2    7.7867 0.1592 0.8534
```

her har vi en p-værdi på 0.85 og vi afviser altså ikke hypotesen om additiv virkning. det betyder vi nu har modellen

$$M_2 : X_{ijk} \sim N(\alpha_i + \beta_j, \sigma^2), i = 1, 2, j = 1, 2, 3, k = 1, \dots, n_{ij}$$

c)

Tag udgangspunkt i modellen med additiv virkning af blandemaskine og trykstyrkemåler – den model du endte med i delopgave (b). Vis ved et test, at der kan antages, at der ikke er virkning af blandemaskiner på trykstyrken.

vi gør nu det samme igen hvor vi fjerner blandemaskinen fra modellen

```
lmfit_m3 <- lm(betonstyrke$styrke ~ betonstyrke$maaler)
anova(lmfit_m3, lmfit_m1star)
```

```
## Analysis of Variance Table
##
## Model 1: betonstyrke$styrke ~ betonstyrke$maaler
## Model 2: betonstyrke$styrke ~ 1 + betonstyrke$gruppe
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      46 1065.6
## 2      42 1027.4  4   38.242 0.3908 0.814
```

her får vi en p-værdi på 0.53 og vi afviser altså heller ikke hypotesen om at der ikke er virkning af blandemaskiner på trykstyrken. vi har da modellen

$$M_3^r : X_{ijk} \sim N(\alpha_i, \sigma^2), i = 1, 2, j = 1, 2, 3, k = 1, \dots, n_i$$

d)

Tag udgangspunkt i modellen du endte med i delopgave (c). Find estimat og 95%-konfidensinterval for forskellen i middelværdien af trykstyrken mellem de to trykstyrkemålere. Kan der antages, at der ikke er forskel på de to trykstyrkemålere?

```
coef(lmfit_m3)
```

```
##          (Intercept) betonstyrke$maalerb  
##          54.045833          -5.866667
```

```
confint(lmfit_m3)
```

```
##                2.5 %    97.5 %  
## (Intercept)      52.068255 56.023411  
## betonstyrke$maalerb -8.663384 -3.069949
```

vi kan her se at estimat for forskellen i middelværdi er -5.87 og et 95% konfidensinterval er $[-8.66, -3.07]$. så vi kan nok ikke antage at der ikke er forskel, da 0 ikke lige i intervallet.

e)

Find 95%-konfidensinterval for residualvariansen i modellen du endte med i delopgave (c).

vi har fra side 66 i de supplerende noter at vi kan finde konfidensintervallet af σ^2 med

$$[s_{02}^2(X)/(\chi_{1-\alpha/2}^2(f_{02})/f_{02}), \quad s_{02}^2(X)/(\chi_{\alpha/2}^2(f_{02})/f_{02})]$$

som så giver mig

```
s_sq = sigma(lmfit_m3)^2  
alpha = 0.05  
f = df.residual(lmfit_m3)  
  
lower <- f*s_sq/qchisq(1-alpha/2, df = f)  
upper <- f*s_sq/qchisq(alpha/2, df = f)  
  
c(lower, upper)
```

```
## [1] 15.99602 36.54311
```

altså et konfidensinterval for residualvariansen er $[16.0, 36.5]$

opgave 3

a)

Nogle gange logaritmetransformeres observerede data for at disse kan beskrives med en normalfordeling. Figuren nedenunder viser til venstre et normalfraktilplot, som er lavet på logaritmen af varigheden i dage, af sygehusophold for 55 borgere, der opsøgte skadestuen med akutte mavesmerter. Til højre ses boxplots af tre datasæt på 55 observationer hver. Et af de tre boxplots A, B eller C er for de oprindelige varighedsdata før logaritmetransformation. Angiv, hvilket boxplot der svarer til de oprindelige varighedsdata, og giv en kort begrundelse for dit valg.

da vi har at normalfraktildiagrammet er over $\log(x)$ og de ser meget normalfordelte ud så må vi altså have at de originale data må være steget eksponentielt, det må betyde en god samling af lave værdier og så viledere og viledere outliers opad. det betyder altså at jeg mener det er boxplot C som passer til.

jeg tror det er B istedet for!!

b)

Firmaet Trinamix udvikler 3D kameraer baseret på afstandsmåling under brug af infrarødt lys. For hvert 3D punkt i billedet tages n målinger; så beregnes gennemsnittet $\bar{d}$ af aftanden. Spredning en på en enkelt måling er 0.34 mm. Hvor stor må n være for at opnå en spredning $SE[\bar{d}]$ på maksimalt 0.05 mm?

vi antager pga CLT? at gennemsnittet er normalfordelt og vi har derfor at den totale spredning er σ^2/n og vi skal så bare isolere så den er lig med de 0.05, altså

```
n = 0.34^2/0.05^2
n
```

```
## [1] 46.24
```

så n skal være på minimum 46.24 for at opnå end spredning på maks 0.05.

c)

Ved klimaopvarmning frygtes, at vi i fremtiden vil få flere voldsomme storme også i Danmark. For at undersøge, om dette allerede er ved at ske, har en klimaforsker optalt antallet af voldsomme storme i Danmark med middelvind på mindst 26.4 m/s i perioden 1999-2008 (X_1) og i perioden 2009 - 2018 (X_2). Angiv en statistisk model for data, og formuler en nulhypotese og en alternativhypotese der kan bruges til at besvare den ovenfor omtalte frygt. Angiv så den faglige konklusion, når man ved et test af denne hypotese får en p-værdi på $p_{obs} = 0.97$.

en statistisk model for data kan være

$$M_0 : X_i \sim N(\mu_i, \sigma_i^2), i = 1, 2$$

vi snakker om antallet af voldsomme storme, så derfor må vores nulhypotese være at antallet er det samme i de to perioder, altså

$$H_0 : \mu_1 = \mu_2$$

og vores alternativhypotese er at der er flere storme nu, så

$$H_A : \mu_1 < \mu_2$$

hvis man får en p-værdi på 0.97 betyder det altså at vi ikke afviser nulhypotesen, så vi kan antage at der har været lige mange voldsomme storme i de to perioder.

det kan være man også skulle tage højde for variansen her men vel ikke det vi egentlig kigger på?

eksamen 2019 august besvarelse

Nanna Liv Berdiin

2025-05-30

```
set.seed(42)
```

opgave 1

Hvordan kan strømmen af cyklister på en cykelsti modelleres? Byrådsmedlem Bent J. ville gerne finde ud af det og registrerede derfor med et stopur tiden, der gik mellem forbisusende cyklister nedad Langelandsgade ved busstoppestedet “Universitet” en lørdag morgen mellem kl. 10:00 og 10:10. I alt kom der 49 cyklister forbi, og den gennemsnitlige tid mellem to cyklister var 12.2 sekunder. I litteraturen anføres ofte, at eksponentialfordelingen er en god model til disse ventetider mellem cyklister. For at undersøge dette nærmere har Bent grupperet tiderne som vist i følgende tabel. Tabellen inderholder også de forventede antal under eksponentialfordelingen med middelværdi 12.2.

a)

Gør rede for, at det forventede antal ventetider af en længde mellem 2 og 4 sekunder er 6.3, under modellen hvor tiderne følger en eksponentialfordeling.

jeg kigger altså på sandsynligheden for mellem 2 og 4 sekunder under eksponentialfordelingen med middelværdi 12.2 (som betyder at lambda er $1/12.2$ fordi det er raten og ikke middelværdien!)

$$P(x \leq 4) - P(x \leq 2) = 1 - \exp(-4 \cdot (1/12.2)) - (1 - \exp(-2 \cdot (1/12.2)))$$

som vi kan regne i R

```
(1-exp(-4*(1/12.2)) - (1-exp(-2*(1/12.2))))*49
```

```
## [1] 6.288669
```

som var det jeg skulle vise.

b)

Lav et test for nulhypotesen, at data stammer fra en eksponentialfordeling. Beregn p-værdien, og angiv konklusionen.

```

#skriv din data ind!
observerede <- c(6,9,7,9,6,7,5)
kasser = 7
frie_parametre = 0
n = 49
forventede = c(7.4, 6.3, 5.3, 8.4, 7.3, 8.0, 6.3)

#beregns teststørrelse
Gobs = 2*sum((observerede*log(observerede/forventede)))
Gobs

```

```
## [1] 2.506286
```

```

#beregns p-værdi
1-pchisq(Gobs,kasser-1-frie_parametre)

```

```
## [1] 0.8677635
```

så vi får en p-værdi på 0.87 og vi afviser altså ikke denne hypotese om at data stammer fra en eksponentialfordeling.

opgave 2

Bageriet Sundbrød producerer rugbrødet “Motion Mette” i 1000 g pakker. Pakkernes vægt antages at være normalfordelt med middelværdi 1000 g og en standardafvigelse på 20 g. Firmaet er sikker på, at middelværdien overholdes, men er bekymret for, at der er for meget variation i vægten – dette kunne give anledning til reklamationer. Derfor tages jævnligt tilfældige stikprøver på 100 pakker, og den empiriske varians s^2 bestemmes for stikprøven. Hvis s^2 overstiger $500g^2$ tvivler bageriet på, at standardafvigelsen ligger på 20 g.

modellen om pakkernes vægt er

$$M_0 : X_i \sim N(1000, 20^2)$$

eftersom $20^2 = 400$ så har vi altså nulhypotesen

$$H_0 : \sigma^2 = 400$$

og alternativhypotesen

$$H_A : \sigma^2 > 400$$

under H_0 gælder det at teststørrelsen har fordelingen

$$s^2(X)/\sigma_0^2 \sim \chi^2(n)/(n-1)$$

b)

Beregn sandsynligheden for type 1 fejl i firmaets test.

type 1 fejl er at nulhypotesen forkastes givet at nulhypotesen er sand. vi har her 100 stikprøver og så er det alle dem hvor variansen er over givet, den kritiske værdi er her 500 fordi det er der de begynder at tvile på at standardafvigelsen er 20.

$$P(s^2(X) > 500) = P(t > (n-1)500/(\sigma_0^2)) = P(t > 99 \cdot 500/400) = P(t > 123.75)$$

her vil $t \sim \chi^2(n)$ fordelt ud fra omskrivninger fra opgave a)

```
1 - pchisq(123.75, df=100)
```

```
## [1] 0.05385617
```

som altså betyder at der er 0.054 procents sandsynlighed for type 1 fejl som passer rigtig godt med at sandsynligheden for type 1 fejl er signifikansniveauet og det typisk sættes til 0.05.

opgave 3

I et eksperiment lavet på en skole skulle undersøges, om lysfarven påvirker plantevækst. Atten bønner blev sået i pletter med en bønne per plette, og pletterne tilfældigt delt i to lige store grupper. Den ene gruppe blev udsat for rødt lys, og den anden for grønt lys. To uger efter spiring blev skudhøjden målt. Datasættet beans.csv, som udleveredes med digital eksamen, indeholder variabelen growth med skudhøjden i cm, og variabelen color med lysfarven.

a)

Undersøg ved hjælp af et permutationstest, om der er forskel mellem de to grupper. Brug forskellen mellem medianerne som teststørrelse. Husk at angive den faglige konklusion.

jeg laver en permutationstest for forskellen mellem medianerne (så ikke middelværdi!!) er min teststørrelse.

```
set.seed(42)
beans <- read.csv("beans.csv")

grpG <- subset(beans, color == "red")$growth
grpR <- subset(beans, color == "green")$growth

obj <- beans$growth
obs = median(grpG) - median(grpR)

N <- 10^4 - 1
result <- numeric(N)
for (i in 1:N) {
  index <- sample(length(obj), size = length(grpG), replace = FALSE) #ret til for gruppe G
  result[i] <- median(obj[index]) - median(obj[-index])
}

#og finder p-værdien
pval = (2*min(sum(result < obs), sum(result >= obs)) + 1) / (N+1)
pval
```

```
## [1] 0.0781
```

så her får jeg altså en p-værdi på 0.078 og hypotesen om ens median afvises altså ikke.

opgave 4

Når der skal bygges motorveje eller landeveje i Florida, inviterer Department of Transportation (DOT) forskellige byggeentreprenører til at afgive tilbud. Entreprenørerne skal sende deres tilbud i en forseglet konvolut, og dem der byder den laveste pris vinder anlægskontrakten. Ingeniører som er ansat i DOT beregner altid et estimat på omkostningerne i forvejen, og i de fleste tilfælde passer den fint med den endelige pris. I 1970'erne og '80'erne kunne der dog registreres flere tilfælde, hvor byggeentreprenørerne havde manipuleret prisen opad ved hemmelige pris-aftaler (price-fixing). Formålet med denne opgave er at finde en model, der forudsiger den endelige pris ud fra manipulationsforhold og ingeniørernes estimat. Det udleverede datasæt FloridaRoads.csv er indsamlet af Floridas justitsministerium i 1980'erne og indeholder 235 observationer med fem variable: • cost : pris i 1000 US dollars, • logcost: logaritmen til cost, • DOTestimate: prisen som DOTs ingeniører har estimeret (i 1000 US\$), • logDOTestimate: logaritmen til DOTestimate, • bid: en faktorvariabel med niveauer competitive og fixed. Niveaueet fixed betyder at prisen var manipuleret. I alt var 50 af de 235 observationer manipuleret, mens 185 overholder reglerne. Lad Y_{gj} betegne den endelige pris, og x_{gj} estimatet som ingeniørerne beregnede, hvor $g = 1, 2$ betegner gruppen ifølge bid (1: competitive, 2: fixed), og $j = 1, \dots, n_g$ nummererer observationen indenfor gruppen, $n_1 = 185$ og $n_2 = 50$. Som udgangspunkt betragter vi to modeller, henholdsvis for de oprindelige og for de log-transformerede data:

$$\tilde{M}_1 : Y_{gj} \sim N(\tilde{\alpha}_g + \tilde{\gamma}_g \cdot x_{gj}, \tilde{\sigma}^2)$$

$$M_1 : \log(Y_{gj}) \sim N(\alpha_g + \gamma_g \cdot \log(x_{gj}), \sigma^2)$$

a)

Indlæs datasættet og fit modellen $\tilde{M}_1$. Beregn residualerne, og undersøg ved en grafisk analyse, om de er normalfordelt og om variansen af Y_{gj} afhænger af x_{gj} . Gør det samme med modellen M_1 . Hvilken af de to modeller passer bedst til data?

jeg loader data og tjekker


```
floridaroads <- read.csv("FloridaRoads.csv", stringsAsFactors = TRUE)
```

først for modellen $\tilde{M}_1$


```
lmfit_0 <- lm(floridaroads$cost ~ floridaroads$DOTestimate*floridaroads$bid)

residualer_0 <- lmfit_0$residuals
#lav qqplot over residualerne
qqnorm(residualer_0, col = "purple2")
qqline(residualer_0, col = "green3")
```

Normal Q-Q Plot



```
plot(residualer_0~floridaroads$DOTestimate, col = "blue")
```




vi kan se at det ikke virker til at være en særlig god model. og så for M_1


```
lmfit_log <- lm(logcost ~ logDOTestimate*bid, data = floridaroads)

residualer_log <- lmfit_log$residuals
#lav qqplot over residualerne
qqnorm(residualer_log, col = "purple2")
qqline(residualer_log, col = "green3")
```

Normal Q-Q Plot



```
plot(residualer_log~floridaroads$logD0Testimate, col = "blue")
```



vi kan se at denne er en del bedre. så det er altså klart modellen hvor begge data er logget som passer bedst, altså M_1

b)

Opstil model M_2 for $\log(Y_{gj})$, hvor hældningen ikke afhænger af, om budet var manipuleret (angiv som formel). Eftersis ved et test, at modellen M_1 kan reduceres til M_2 . Fit modellen M_2 og angiv alle estimerede parameter eksplicit, inklusive variansen, med de betegnelser du brugte i formelen.

vi vil altså gerne undersøge modellen

$$M_2 : \log(Y_{gj}) \sim N(\alpha_g + \gamma \cdot \log(x_{gj}), \sigma^2)$$

vi kan teste denne reducere med anova, så skriver den nye model op også og tester

```
lmfit_m2 <- lm(logcost ~ logDOTestimate + bid, data = floridaroads)
anova(lmfit_m2, lmfit_log)
```

```
## Analysis of Variance Table
##
## Model 1: logcost ~ logDOTestimate + bid
## Model 2: logcost ~ logDOTestimate * bid
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1     232 5.5562
## 2     231 5.5405  1  0.015641 0.6521 0.4202
```

så skal jeg også angive alle de estimerede parametre i modellen

```
summary(lmfit_m2)
```

```
##
## Call:
## lm(formula = logcost ~ logDOTestimate + bid, data = floridaroads)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.51577 -0.08786  0.01888  0.10048  0.38265
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -0.146721   0.048456  -3.028  0.00274 **
## logDOTestimate  1.005407   0.007422 135.462 < 2e-16 ***
## bidfixed       0.216622   0.024750   8.753 4.38e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1548 on 232 degrees of freedom
## Multiple R-squared:  0.9875, Adjusted R-squared:  0.9874
## F-statistic: 9178 on 2 and 232 DF, p-value: < 2.2e-16
```

```
0.2166218 - (-0.1467206)
```

```
## [1] 0.3633424
```

```
0.1548^2
```

```
## [1] 0.02396304
```

her får jeg estimatet for skæringen hvor der ikke var match fixing er -0.15, når der er match fixing er den 0.36 og hældningen er 1.01. samt variansen er 0.024.

c)

Eftervis, at modellen M_2 ikke kan reduceres yderligere.

hvis vi skulle reducere modellen yderligere ville vi starte med at tjekke om de har samme skæring, dette kan vi også tjekke med anova

```
lmfit_m2star <- lm(logcost ~ logDOTestimate, data = floridaroads)
anova(lmfit_m2star, lmfit_log)
```

```
## Analysis of Variance Table
##
## Model 1: logcost ~ logDOTestimate
## Model 2: logcost ~ logDOTestimate * bid
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1      233 7.3908
## 2      231 5.5405  2    1.8503 38.572 3.516e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

her får vi en p-værdi på langt under 0.05 og vi afviser derfor hypotesen om videre reduktion. Hvis vi kiggede på summary kaldet fra tidligere kunne vi også se på p-værdierne der at alle dele var vigtige for modellen.

d)

Beregn et 95%-konfidensinterval for den fælles hældning i M_2 , og test, om hældningen kan antages at være lig med 1.

vi kan finde et 95%-konfidensinterval for den fælles hældning i M_2 med

```
confint(lmfit_m2)
```

```
##              2.5 %      97.5 %  
## (Intercept) -0.2421900 -0.05125113  
## logD0Testimate 0.9907840  1.02003057  
## bidfixed      0.1678592  0.26538438
```

altså er et 95% konfidensinterval for den fælles hældning altså $[0.99, 1.02]$. eftersom 1 ligger i dette konfidensinterval kan vi godt antage at hældningen er 1.

e)

Brug modellen M_2 til at beregne et 90% prædiktionsinterval for prisen Y (i 1000 US dollars), når ingeniørerne forudsiger omkostninger til at være 3 millioner US dollars og prisen ikke er manipuleret. (Vink: $3mio = 3000 \cdot 1000$)

vi skal finde prædiktionsinterval

```
nyData = data.frame(logD0Testimate = log(3000), bid = "competitive")  
exp(predict(lmfit_m2, nyData, interval = "prediction", level = 0.9))
```

```
##      fit      lwr      upr  
## 1 2705.224 2091.997 3498.206
```

vi skal huske at vi nu kigger på Y og ikke $\log(Y)$ og derfor tager vi $\exp$ af tallene, et 90% prædiktionsinterval for Y er dermed $[2092, 3498]$

eksamen 2020 juni

Nanna Liv Berdiin

2025-05-25

opgave 1

a)

jeg skal lave et permutationstest for nulhypotesen, at den gennemsnitlige HMF koncentration ikke ændrer sig. indlæser mine data:


```
honning <- read.csv("honning.csv")
```

fordi vi tester at den gennemsnitlige ikke ændrer sig kan vi altså teste om forskellen i gennemsnit er 0. vi tester altså hypotesen

$$H : \mu_1 = \mu_2$$

```
#vi laver permutationstest hvor vi tester om forskellen er 0
start <- honning$HMFstart
slut <- honning$HMFend
obs = mean(slut)-mean(start)
d = slut - start
n = length(d)
N <- 10^4 - 1
result <- numeric(N)
for (i in 1:N) {
  signs <- sample(c(-1,1),n,replace=TRUE)
  result[i] <- mean(signs*d)
}

#laver et histogram
hist(result, col = "lightblue3")
abline(v=obs, col = "red2")
```



```
#og finder p-værdien
pval = (sum(result >= obs) + 1) / (N+1)
pval
```

```
## [1] 1e-04
```

da p-værdien er klart under 0,05 som er det alpha vi normal ville teste efter må vi altså afvise nulhypotesen om at den gennemsnitlige HMF koncentration ikke ændrer sig.

den alternative hypotese vi tesede imod var:

$$H_A : \mu_1 < \mu_2$$

den alternative hypotese vi ender med er altså at koncentrationen steg på de to måneder.

opgave 2

```
musling <- read.csv("musling.csv", stringsAsFactors = TRUE)
```

a)

så jeg skriver modellen op med hver sin middelværdi og varians:

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2), i = 1, 2, 3, 4, 5, j = 1, 2, 3, 4, 5$$

så skal jeg så undersøge om variansen er ens, jeg skal altså undersøge hypotesen

$$H_{0\sigma^2} : \sigma_i^2 = \sigma^2, i = 1, 2, 3, 4, 5$$

jeg undersøger dette med bartlett's test


```
bartlett.test(musling$Protein ~ 1 + musling$Tid)
```

```
##  
## Bartlett test of homogeneity of variances  
##  
## data: musling$Protein by musling$Tid  
## Bartlett's K-squared = 2.1247, df = 4, p-value = 0.7128
```

så vi kan se at vi ikke afviser hypotesen om ens varians.


b)

```
#plot data  
plot(musling$Protein~musling$Tid, col = rainbow(5))
```




```
#find residualer
lmfit <- lm(musling$Protein~musling$Tid)
residualer <- lmfit$residuals
#lav qqplot over residualerne
qqnorm(residualer, col = "purple2")
qqline(residualer, col = "green3")
```

Normal Q-Q Plot



```
#samt et boxplot over de 5 "datasæt"
boxplot(musling$Protein~musling$Tid, col = rainbow(5))
```



så vi kan især se fra qqnorm at det er relativt sandsynligt de er normalfordelte vi kan se især fra boxplot at de højest sandsynligt ikke har samme middelværdi, så der holder hypotesen nok. jeg har valgt at plotte data for lige at få et overblik over hvordan de egentlig er placeret og se på om jeg umiddelbart kan se forskelle, om nogle af dem har højere middelværdi, som boxplot hjælper en del mere specifikt med. derudover ville jeg teste om det passede med de var normalfordelte, derfor qqplot af residualerne.

c)

så jeg skriver modellen op med hver sin middelværdi og ens varians:

$$M_0 : X_{ij} \sim N(\mu_i, \sigma^2), i = 1, 2, 3, 4, 5, j = 1, 2, 3, 4, 5$$

så skal jeg lave et konfidensinterval for forskellen i middelværdi mellem gruppe 1 og gruppe 5. det betyder altså jeg nu har to normalfordelte rækker med ens varians. jeg bruger confint på den samlede

```
faktortid <- as.factor(musling$Tid)
confint(lm(musling$Protein~faktortid))
```

```
##           2.5 %    97.5 %
## (Intercept) 523.297975 584.94203
## faktortid21  -5.808926  81.36893
## faktortid36  -8.528926  78.64893
## faktortid52 -18.008926  69.16893
## faktortid65  19.891074 107.06893
```

```
coef(lm(musling$Protein~faktortid))
```

```
## (Intercept) faktortid21 faktortid36 faktortid52 faktortid65
##      554.12      37.78      35.06      25.58      63.48
```

så vi får altså et 95% konfidensinterval for forskellen i middelværdien til at være den nederste række i vores output fordi den er forskellen fra intercept(som er tid 0) til tid 65(som er gruppe 5)

[19.89, 107.07]

vi kan se at de altså ihvertfald ikke burde have ens middelværdi.

d)

jeg skriver modellen op med middelværdi afhængig af tid og ens varians:

$$M_1 : X_{ij} \sim N(\alpha + \beta \cdot t_i, \sigma^2), i = 1, 2, 3, 4, 5, j = 1, 2, 3, 4, 5$$

så det altså bliver en lineær regression for middelværdien.

```
lmfit_m1 <- lm(Protein~Tid,data=musling)
lmfit_m2 <- lm(Protein~faktortid,data=musling)
anova(lmfit_m2,lmfit_m1)
```

```
## Analysis of Variance Table
##
## Model 1: Protein ~ faktortid
## Model 2: Protein ~ Tid
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      20 21833
## 2      23 25571 -3   -3738.5 1.1415 0.3564
```

så vi kan se at vi ikke afviser hypotesen om en lineær normal model ved alpha på 0,05.

e)

så vi gør ligesom før, men nu med tid ikke som en faktor

```
confidence <- confint(lm(musling$Protein~musling$Tid))
confidence
```

```
##              2.5 %      97.5 %
## (Intercept) 536.337101 586.604109
## musling$Tid  0.115525   1.322946
```

```
#her er tiden jo hældningen, og der er 65 dage imellem dem,
#så vi skal altså finde forskellen i middelværdi
#fra tid 0 til tid 65 og derfor finde 95%konfidensinterval
#for hældningen over 65 dage, som så er
confidence[2][1]*65
```

```
## [1] 7.509126
```

```
confidence[4][1]*65
```

```
## [1] 85.99149
```

så vi får altså konfidensintervallet

[7.51, 86.00]

så vi kan se at forskellen her er lidt mindre generelt, vi forventer altså at deres forskel i middelværdi er mindre.

opgave 3

jeg skriver først min data ind

```
ivf <- c(29, 21, 21, 129)
```

a)

jeg har en multinomial model med 4 kasser, der er i alt

```
sum(ivf)
```

```
## [1] 200
```

200 målinger så vi får

$$(A_1, A_2, A_3, A_4) \sim \text{multinom}(200, (\pi_1, \pi_2, \pi_3, \pi_4))$$

med

$$\pi_i \geq 0, \pi_1 + \pi_2 + \pi_3 + \pi_4 = 1$$

b)

her er den generelle likelihoodfunktion

$$L(\pi) = \binom{200}{a_1 \cdot a_2 \cdot a_3 \cdot a_4} \cdot \pi_1^{a_1} \cdot \pi_2^{a_2} \cdot \pi_3^{a_3} \cdot \pi_4^{a_4}$$

for vores model lyder den så

$$\begin{aligned} L(\theta) &= \binom{200}{a_1 \cdot a_2 \cdot a_3 \cdot a_4} \cdot \theta^{a_1} \cdot (\theta(1-\theta))^{a_2} \cdot ((1-\theta)^2 \cdot \theta)^{a_3} \cdot ((1-\theta)^3)^{a_4} \\ &= \binom{200}{a_1 \cdot a_2 \cdot a_3 \cdot a_4} \cdot \theta^{a_1+a_2+a_3} \cdot (\theta(1-\theta))^{a_2+2a_3+3a_4} \end{aligned}$$

da vi ved hvad vores a-værdier er får vi så

```
29+21+21
```

```
## [1] 71
```

```
21+2*21+3*129
```

```
## [1] 450
```

så vi har, vi kan fjerne konstanten foran fordi den ikke har indflydelse på vores maksimum likelihood estimat

$$= \theta^{71} \cdot (1 - \theta)^{450}$$

dette er fordi vi kigger på

$$\hat{\theta} = \arg(\max_{\theta}(L(\theta)))$$

finder log-likelihood så

$$\downarrow(\theta) = 71 \cdot \log(\theta) + 450 \cdot \log(1 - \theta)$$

differentier

$$\downarrow'(\theta) = 71/\theta - 450/(1 - \theta) = 0 \Leftrightarrow 71/\theta = 450/(1 - \theta) \Leftrightarrow 71 - 71\theta = 450\theta \Leftrightarrow 71 = 521\theta \Leftrightarrow \hat{\theta} = 71/521$$

```
71/521
```

```
## [1] 0.1362764
```

så vi har altså at $\hat{\theta} = 0.1362$. som var det vi skulle vise.

c)

jeg skal nu lave en test for min hypotese om fast-rate (fast rate), jeg bruger her

```
observerede = ivf
n = 200
thetahat = 0.1362764
#note: forventede skal altid rettes til alt efter hvor mange kasser du har
#jeg har 4 her så derfor:
#beregner forventede:
forventede = n*c(thetahat, (1-thetahat)*thetahat, (1-thetahat)^2*thetahat, (1-thetahat)^3)
#beregner teststørrelse:
Gobs = 2*sum((observerede*log(observerede/forventede)))
#beregner p-værdi, husk at denne skal rettes til med hvor mange kasser man har!!
1-pchisq(Gobs,4-1-1)
```

```
## [1] 0.8122586
```

så vi kan se at det altså ikke er en hypotese der afvises.

opgave 4

a)

fordi at hældningen cirka er standard deviation kan jeg så finde hældningen² for cirka at have variansen for grafen med qqnorm/qqplot hvor jeg skal bestemme variansen.

```
((3.5-0.5)/(2-(-2)))^2
```

```
## [1] 0.5625
```

så jeg får altså at σ^2 er cirka 0.5, og dermed er det rigtige svar altså c).

b)

jeg skal nu skrive noget lidt vilkårlig kode

```
"
T0 = vektor med udfald af T
T1 = vektor med udfald af T1, som er under alternativ hypotese
crit = den kritiske værdi
Nsim = antal gange vi kører testen

type1fejl = sum(T0<=crit) /Nsim #sandsynligheden type 1 fejl
type2fej = sum(T1>crit) / Nsim #sandsynligheden type 2 fejl
"
```

```
## [1] "\nT0 = vektor med udfald af T\nT1 = vektor med udfald af T1, som er under alternativ hypotese\n"
```

så altså den summer over dem hvor man havde fået en fejl og så dividere med antal. det hele står lige som en kommentar ellers kan jeg ikke gemme dokumentet fordi der jo ikke er rigtigt tal.

eksamen 2021 juni besvarelse

Nanna Liv Berdiin

2025-05-26

Opgave 1

a)

vi kan se at der laves en ensidet test fordi vi kun tester om theta er højere ikke lavere. dette svarer også til at det er på intervallet $[C, \infty)$ da vi jo tester at den er større.

b)

vi kan vise at den holder ved at indsætte den givne værdi for q_p ind i $P(X \leq q_p) = F(q_p)$ og dermed får vi altså

$$\begin{aligned} F(q_p) &= 1 - 2 \cdot e^{-(-\theta \cdot \ln(1-\sqrt{p}))/\theta} + 2 \cdot e^{-2(-\theta \cdot \ln(1-\sqrt{p}))/\theta} \\ &= 1 - 2 \cdot e^{\ln(1-\sqrt{p})} + 2 \cdot e^{2\ln(1-\sqrt{p})} \\ &= 1 - 2 \cdot (1 - \sqrt{p}) + (1 - \sqrt{p})^2 = 1 - 2 + 2\sqrt{p} + 1 + p - 2\sqrt{p} = p \end{aligned}$$

som var det jeg skulle vise.

c)

jeg skal beregne den kritiske værdi for signifikansniveau $\alpha = 0.05$. da min nulhypotese er at $\theta = 4$ og jeg bruger et signifikansniveau på 0.05 får jeg altså at $p = 0.95$ fordi det bliver den del hvor den ikke accepteres, så C er her q_p med disse tal

```
C = -4*log(1-sqrt(0.95))
C
```

```
## [1] 14.70455
```

så den kritiske værdi er da 14.70. når jeg skal beregne styrken af denne test for alternativet $\theta = 8$ vi skal altså kigge på de værdier hvor H_0 forkastes på grundlag af x , da

$$\beta(\theta) = 1 - \text{pow}(\theta) = 1 - P_\theta(T \in \mathcal{T}_R) = 1 - F(C)$$

```
beta = 1 - (1 - 2*exp(-C/8) + exp(-2*C/8))
beta
```

```
## [1] 0.2929282
```

så styrken under $\theta = 8$ er da 0.29.

d)

vi har at

$$E(X) = (3/2)\theta$$

så vi regner middelværdien og sætter lig hinanden

```
middelværdi = sum(c(12,5,15,20,8))/5
theta_hat = middelværdi*2/3
theta_hat
```

```
## [1] 8
```

så jeg får altså at vi ville forvente at $\theta = 8$ som ikke passer med min hypotese.

e)

den centrale grænseværdisætning siger at $\bar{X}$ er cirka normalfordelt, vi har i opgaven fået oplyst expected og varians som så bliver middelværdi og varians / antal observationer, vi har stadig hypotesen at $\theta = 4$

```
EX = 3/2*4
var = 5/4*(4^2) / 5
EX
```

```
## [1] 6
```

```
var
```

```
## [1] 4
```

så derfor ender vi altså med en model:

$$\bar{X} \sim N(6, 4)$$

jeg skal også bestemme C , jeg kigger altså på $P(X \leq C_1) = 0.05$ da det er en normalfordeling har vi da

$$P(X \leq C_1) = \Phi((x - \mu)/\sigma) = 0.95$$

og så skal vi så bare isolere C_1 (kan basically bare tage den på den anden side og så isolere x)

```
C_1 = EX + qnorm(0.95)*sqrt(var)
C_1
```

```
## [1] 9.289707
```

så vi ser altså at vores kritiske værdi er 9.29 som betyder at vi forkaster vores nulhypotese hvis $\bar{X} > 9.29$

f)

nu skal vi så simulere. her bruger jeg den givne funktion i opgaven

```
# Funktion rmeanwait:
#   simulation af stikprøvegennemsnit fra ventetidsfordelingen i opgave 1.
#
# Argumenter:
#   n = antal simulerede stikprøver,
#   size = stikprøvestørrelse,
#   theta = fordelingsparameter. Default værdi: theta = 1.
# Eksempel:
#   rmeanwait(3, 5, 8)
# simulerer 3 stikprøver af størrelse 5 fra ventetidsfordelingen med theta = 8
# og returnerer en vektor med de 3 stikprøvegennemsnit.

rmeanwait <- function(n, size = 1, theta = 1) {
  replicate(n, theta * mean(-log(1 - sqrt(runif(size)))))
}
```

```
Nsim = 10000
x_bar <- rmeanwait(Nsim, size = 5, theta = 4)
p_val <- mean(x_bar >= C_1)
p_val
```

```
## [1] 0.0638
```

den burde være større, fordi jeg får en lidt for høj p-værdi, hvis nu den istedet var 9.6 fik jeg

```
mean(x_bar >= 9.6)
```

```
## [1] 0.0524
```

opgave 2

a)

jeg har altså det er multinomial fordeling, med $n=97$, så min model lyder

$$(A_1, A_2, A_3, A_4) \sim \text{multinom}(97, (\pi_1, \pi_2, \pi_3, \pi_4))$$

med

$$\pi_i \geq 0, \pi_1 + \pi_2 + \pi_3 + \pi_4 = 1$$

b)

vi finder 95% konfidensinterval for π_4 med

```
prop.test(43,97)$conf.int
```

```
## [1] 0.3436332 0.5475056
## attr("conf.level")
## [1] 0.95
```

så mit 95% konfidensinterval er $[0.34, 0.55]$

c)

vi kigger altså på de to muligheder vi har fået givet under den multiplikative model så vi har at hvis vi ligger deres sandsynligheder sammen, det her er nok ikke helt rigtig notation, men

$$P(A_1 + A_2) = \rho\theta + \rho(1 - \theta) = \rho$$

samt

$$P(A_1 + A_3) = \rho\theta + (1 - \rho)\theta = \theta$$

de er begge binomialt fordelet fordi det er en enten eller situation, enten de to eller ikke de to, og de har de to sandsynligheder jeg har regnet og der er n forsøg, og derfor hhv.

$$(A_1 + A_2) \sim \text{binom}(n, \rho)$$

og

$$(A_1 + A_3) \sim \text{binom}(n, \theta)$$

som var det jeg skulle vise.

d)

jeg skal lave en test under den multiplikative model, jeg har fået givet de forventede værdier, jeg bruger derfor kode vi har fået, men bruger her at de forventede er givet, så den er ikke helt det samme som ellers!

```
observerede <- c(16,17,21,43)
kasser = 4
frie_parametre = 2
n = 97
forventede = c(12.59, 20.41, 24.42, 39.58)
Gobs = 2*sum((observerede*log(observerede/forventede))) #beregner teststørrelse
Gobs
```

```
## [1] 2.244742
```

```
1-pchisq(Gobs,kasser-1-frie_parametre) #beregner p-værdi
```

```
## [1] 0.1340692
```

så jeg kan se at da $p = 0.13$ så afviser jeg altså ikke min hypotese.

opgave 3

a)

```
oktan <- read.csv("oktan.csv")
```

jeg har den multiple regressionsmodel med 5 variable

$$M_1 : X_i \sim N(\alpha + t_{i1} \cdot T1 + t_{i2} \cdot T2 + t_{i3} \cdot T3 + t_{i4} \cdot T4 + t_{i5} \cdot T5, \sigma^2), i = 1, 2, 3, 4, 5$$

b)

vi opstiller vores første model og kører summary, her er signifikansniveauet 0.05 i mine t-test

```
lmfit1 <- lm(oktan ~ T1 + T2 + T3 + T4 + T5, data = oktan)
summary(lmfit1)

##
## Call:
## lm(formula = oktan ~ T1 + T2 + T3 + T4 + T5, data = oktan)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.70559 -0.16640  0.00369  0.14092  0.69024
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   91.225      2.364  38.584 < 2e-16 ***
## T1            -89.771      6.123 -14.661 < 2e-16 ***
## T2             30.505     10.096   3.021  0.00384 **
## T3            -37.670     40.097  -0.939  0.35168
## T4             28.279     29.113   0.971  0.33570
## T5             22.732     16.322   1.393  0.16941
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2732 on 54 degrees of freedom
## Multiple R-squared:  0.9708, Adjusted R-squared:  0.9681
## F-statistic: 359.2 on 5 and 54 DF,  p-value: < 2.2e-16
```

den højeste p-værdi her er for T3 så den fjerner vi og kører igen

```
lmfit2 <- lm(oktan ~ T1 + T2 + T4 + T5, data = oktan)
summary(lmfit2)

##
## Call:
## lm(formula = oktan ~ T1 + T2 + T4 + T5, data = oktan)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.73920 -0.15023  0.00228  0.15407  0.68630
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   93.053      1.342  69.316 < 2e-16 ***
## T1            -92.543      5.360 -17.267 < 2e-16 ***
## T2             32.227      9.918   3.249  0.00197 **
## T4              3.975     13.339   0.298  0.76683
## T5             12.904     12.516   1.031  0.30703
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## Residual standard error: 0.2729 on 55 degrees of freedom
## Multiple R-squared: 0.9703, Adjusted R-squared: 0.9682
## F-statistic: 449.8 on 4 and 55 DF, p-value: < 2.2e-16
```

nu fjerner vi så T4

```
lmfit3 <- lm(oktan ~ T1 + T2 + T5, data = oktan)
summary(lmfit3)
```

```
##
## Call:
## lm(formula = oktan ~ T1 + T2 + T5, data = oktan)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.73731 -0.14391 -0.00221  0.15662  0.67330
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  92.7552     0.8892 104.314 < 2e-16 ***
## T1          -91.5582     4.1856 -21.875 < 2e-16 ***
## T2           30.5806     8.1686   3.744 0.00043 ***
## T5           15.5788     8.6521   1.801 0.07715 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2707 on 56 degrees of freedom
## Multiple R-squared: 0.9703, Adjusted R-squared: 0.9687
## F-statistic: 609.6 on 3 and 56 DF, p-value: < 2.2e-16
```

T5 er lidt på kanten, men jeg vælger stadig at fjerne den, vil gerne have få

```
lmfit4 <- lm(oktan ~ T1 + T2, data = oktan)
summary(lmfit4)
```

```
##
## Call:
## lm(formula = oktan ~ T1 + T2, data = oktan)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.78638 -0.16527  0.01215  0.17415  0.58995
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  92.8562     0.9047 102.64 <2e-16 ***
## T1          -97.6559     2.5076 -38.94 <2e-16 ***
## T2           44.5063     2.6802  16.61 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.276 on 57 degrees of freedom
## Multiple R-squared: 0.9686, Adjusted R-squared: 0.9675
## F-statistic: 878.3 on 2 and 57 DF, p-value: < 2.2e-16
```

nu kan vi se at der ikke er nogen vi vil fjerne, de er alle vigtige for modellen.

c)

jeg skal nu køre anova på min første model og den jeg ender med

```
anova(lmfit4, lmfit1)
```

```
## Analysis of Variance Table
##
## Model 1: oktan ~ T1 + T2
## Model 2: oktan ~ T1 + T2 + T3 + T4 + T5
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      57 4.3414
## 2      54 4.0313   3    0.3101 1.3846 0.2574
```


da p-værdien her er 0.26 så afviser jeg altså ikke hypotesen om at kunne reducere min model ned til kun T1 og T2.

d)

jeg skal nu finde residualerne for min reducerede model og tjekke grafisk om de er normalfordelte, jeg tjekker altså

```
residualer <- residuals(lmfit4)
qqnorm(residualer, col = "skyblue2")
qqline(residualer, col = "orange")
```

Normal Q-Q Plot



de ser rimelig normalfordelte ud.

e)

vi skal så angive parameterskøn og 95%-konfidensintervaller for regressionsparametrene i den multiple regressionsmodel med de forklarende variable T1 og T2

```
coef(lmfit4) # giver parameterskøn
```

```
## (Intercept)      T1      T2
##    92.85617   -97.65594   44.50628
```

```
confint(lmfit4) #giver 95% konfidensinterval for parametrene
```

```
##           2.5 %    97.5 %
## (Intercept)  91.04452  94.66783
## T1          -102.67741 -92.63447
## T2           39.13918  49.87338
```

eksamen august 2021 besvarelse

Nanna Liv Berdiin

2025-05-28

opgave 1

Data i denne opgave vedrører koncentrationen af Hydroxymethylfuran (HMF) i bihonning, specifikt at denne stiger med lagringstiden. Der er data for fjorten glas honning, idet koncentrationen er målt både da honningen er frisk fra biavleren og igen efter to måneder. Data er i filen honey.csv med søjlerne honeysample, der betegner honningglasset, start: koncentrationen i mg/kg ved første måling og increase: differensen mellem koncentrationen efter to måneder og koncentrationen start ved første måling.

a)

Antag først, at stigning i HMF koncentration er normalfordelt. Beregn 90%-konfidensintervallet for middelværdien af stigningen under denne antagelse.

```
honey <- read.csv("honey.csv")
```

jeg har at konfidensintervallet for μ er

$$[\bar{x} - \sqrt{s^2/n} \cdot t_{1-\alpha/2}(n-1), \bar{x} + \sqrt{s^2/n} \cdot t_{1-\alpha/2}(n-1)]$$

dette kan jeg beregne i R

```
xbar <- mean(honey$increase)
s <- sd(honey$increase)
n <- length(honey$increase)
alpha = 0.10
t_095 <- qt(1-0.10/2, n-1)
#så jeg får
lower <- xbar - sqrt(s^2/n)*t_095
upper <- xbar + sqrt(s^2/n)*t_095
c(lower, upper)
```


```
## [1] 0.6782457 3.2074686
```

så jeg får altså 90% konfidensintervallet [0.68, 3.21] for middelværdien af stigningen.


b)

Simuler stikprøvefordelingen af gennemsnittet for increase ved bootstrapmetoden, og lav et histogram af de simulerede tal. Understøtter histogrammet en antagelse om, at stikprøvegennemsnit er normalfordelt? Vurder endvidere, på anden grafisk vis end ved et histogram, en antagelse om at bootstrap gennemsnittet er normalfordelt. jeg skal nu lave en bootstrap test.


```
data_test <- honey$increase
n <- length(honey$increase)
N <- 10^4
test.mean <- replicate(N, mean(sample(data_test, size=n, replace = TRUE)))
hist(test.mean, main = "Bootstrap distribution of means", col = "skyblue", breaks=50)
abline(v = mean(data_test), col = "blue", lty = 2)
```



```
boxplot(test.mean, col = "orange")
```



```
plot.ecdf(test.mean, col = "pink2")
```



så vi kan se at den ser nogenlunde normalfordelt ud, men dog ikke helt symmetrisk. på boxplot kan vi se at det passer med at der ligger meget tæt på midten, men at halerne heller ikke er helt lige.

c)

Beregn et bootstrap-t-konfidensinterval for middelværdien af stigningen i HMF koncentration. Sammenhold med intervallet du fik ved brug af normalfordelings- antagelsen, og vurder hvilket interval du synes er bedst.


Note: det her er basically kode for hele opgave 1, men det man skal er egentlig oppe i b'eren også at regne T_{star} og så bruge den.

```
Nsim <- 10^4
mean_vec <- numeric(Nsim)
T_star <- numeric(Nsim)

for (i in 1:Nsim) {
  new_samp <- sample(honey$increase, 14, replace = TRUE)
  mean_vec[i] <- mean(new_samp)
  T_star[i] <- (mean_vec[i] - mean(honey$increase)) / (sd(new_samp) / sqrt(14))
}

hist(mean_vec, breaks = 100, prob = TRUE)
```

Histogram of mean_vec




```
Qs <- quantile(T_star, c(0.95, 0.05))  
Qs
```

```
##      95%      5%  
## 1.364476 -3.193617
```

```
qqnorm(mean_vec)  
qqline(mean_vec)
```

Normal Q-Q Plot



```
mean(honey$increase) - Qs * sd(honey$increase)/sqrt(14)
```

```
##          95%          5%  
## 0.9684941 4.2233975
```

```
new_contents <- honey$start + honey$increase  
mean(new_contents > 20)
```

```
## [1] 0.2857143
```

så her har vi konfidensinterval på $[0.98, 4.19]$ modsat $[0.68, 3.21]$ fra før kan vi se at konfidensintervallet er lidt mindre, men ikke meget. jeg ville nok mene at det lidt mindre interval er bedst.

d)

I en yderligere undersøgelse baseret på disse data, vil man gerne bestemme sandsy ligheden p for, at et tilfældig valgt glas honning efter to måneder indeholder mere end 20 mg/kg HMF (bemærk, det er indholdet efter to måneder, ikke stigning i løbet af to måneder).

estimer sandsynligheden p for en honningprøve med et HMF indhold efter to måneder på mere end 20 mg/kg og angiv et konfidensinterval med konfidensniveau på 0.90. jeg starter med at lave en ny kollone med total HMF efter 2 måneder

```
honey$total2 <- honey$start + honey$increase
```

sandsynligheden for at en honningprøve er over 20 efter 2 måneder er da

```
sand <- length(subset(honey$total2, honey$total2 >= 20))
n <- length(honey$total2)
sand/ n
```

```
## [1] 0.2857143
```

altså hvor mange der er over de 20 over hvor mange der er i alt. så det er altså 29% for at være over 20 mg/kg.

```
prop.test(sand,n, conf.level = 0.90)$conf.int
```

```
## [1] 0.1115869 0.5405088
## attr(,"conf.level")
## [1] 0.9
```

her får jeg så 90% konfidensintervallet for p er [0.11, 0.54]

opgave 2

I denne opgave betragtes sammenhængen mellem logaritmen til vægten og logaritmen til længden for 78 laks delt op efter køn. Sammenhængen er illustreret i figur 1. Data er i filen salmon.csv, der har tre søjler med overskrifterne Sex, LnLength og LnWeight. Det kan i opgaven antages, at for en given længde og et givet køn er logaritmen til vægten normalfordelt.

a)

Navngiv de forskellige målte værdier. Formuler den statistiske model, hvor hvert køn har sin egen lineære sammenhæng mellem middelværdien af logaritmen til vægten og den forklarende variabel logaritmen til længden, og hvert køn har sin egen varians omkring regressionslinjen. Lav to deldatasæt svarende til de to køn, og lav for hvert køn et skøn over variansen omkring regressionslinjen. Lav et test for, at de to køn har samme varians omkring regressionslinjen.

jeg starter med at hente data.

```
salmon <- read.csv("salmon.csv")
```

jeg skal navngive de forskellige målte værdier, ved ikke lige hvad de mener de har allerede navn? modellen hvor hvert køn har sin egen lineære sammenhæng mellem middelværdien og egen varians

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2), i = 1, 2, j = 1, \dots, n_i$$

så skal jeg så undersøge om variansen er ens, jeg skal altså undersøge hypotesen

$$H_{0\sigma^2} : \sigma_i^2 = \sigma^2, i = 1, 2$$

jeg skal så dele op i to grupper og finde skøn over variansen for hver gruppe:

```

kvinder <- subset(salmon, Sex == "hun")
mænd <- subset(salmon, Sex == "han")

lmfitkvinder <- lm(kvinder$LnWeight ~ kvinder$LnLength)
lmfitmænd <- lm(mænd$LnWeight ~ mænd$LnLength)

summary(lmfitkvinder)

```

```

##
## Call:
## lm(formula = kvinder$LnWeight ~ kvinder$LnLength)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.31602 -0.05387 -0.01102  0.05618  0.39574
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -8.7425     0.7746  -11.29 4.82e-13 ***
## kvinder$LnLength  3.1470     0.2249   13.99 1.14e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1076 on 34 degrees of freedom
## Multiple R-squared:  0.8521, Adjusted R-squared:  0.8477
## F-statistic: 195.8 on 1 and 34 DF,  p-value: 1.141e-15

```

```
summary(lmfitmænd)
```

```

##
## Call:
## lm(formula = mænd$LnWeight ~ mænd$LnLength)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.226543 -0.071406 -0.002839  0.070291  0.243001
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -10.2091     0.7504   -13.6 <2e-16 ***
## mænd$LnLength  3.5420     0.2147   16.5 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1062 on 40 degrees of freedom
## Multiple R-squared:  0.8719, Adjusted R-squared:  0.8687
## F-statistic: 272.2 on 1 and 40 DF,  p-value: < 2.2e-16

```

```

sigmakvinder <- 0.1076^2
sigmamænd <- 0.1062^2
sigmakvinder

```

```
## [1] 0.01157776
```

```
sigmamænd
```

```
## [1] 0.01127844
```

så vi ser altså for kvinderne er et skøn for variansen 0.01157776 og for mændene er det 0.01127844. så de ligner umiddelbart de er meget ens. tjekker om deres varians er ens hypotesen

```
bartlett.test(salmon$LnWeight ~ salmon$Sex)
```

```
##  
## Bartlett test of homogeneity of variances  
##  
## data: salmon$LnWeight by salmon$Sex  
## Bartlett's K-squared = 0.14019, df = 1, p-value = 0.7081
```

så her er p-værdien 0.7081 og vi forkaster altså ikke hypotesen om ens varians.

b)

Betragt modellen, hvor den lineære sammenhæng mellem middelværdien af logaritmen til vægten og den forklarende variabel logaritmen til længden afhænger af køn, og de to køn har samme varians omkring regressionslinjen. Lav et normalt qqplot for residualerne i denne model. Kommenter på, hvad du ser i figuren. For at finde residualerne har du lavet et kald til lm i R. Forklar, hvad de forskellige led repræsenterer i din modelformel i kaldet af lm.


jeg har altså modellen

$$M_1 : X_{ij} \sim N(\alpha_i + \beta_i \cdot t_i, \sigma^2), i = 1, 2, j = 1, \dots, n_i$$

jeg skal lave et qqplot med qqnorm for residualerne

```
lmfit <- lm(LnWeight ~ LnLength*Sex, data = salmon)  
residualer <- residuals(lmfit)  
qqnorm(residualer, col = "skyblue2")  
qqline(residualer, col = "orange")
```

Normal Q-Q Plot



vi kan her se at det ser normalfordelt ud i midten men at halerne ikke helt passer. jeg har skrevet * fordi jeg så får både vekselvirkningsleddet og leddet fra både længde og køn "hver for sig".

c)

Lav et F-test for hypotesen, at der er samme hældning i regressionslinjerne for de to køn (husk at opskrive model og hypotese).

jeg vil gerne vise modellen

$$M_2 : X_{ij} \sim N(\alpha_i + \beta \cdot t_i, \sigma^2), i = 1, 2, j = 1, \dots, n_i$$

med hypotesen

$$H_{0\beta} : \beta_i = \beta, i = 1, 2$$

jeg skal så lave min F-test

```
lmfit_m2 <- lm(LnWeight ~ LnLength + Sex, data = salmon)
anova(lmfit_m2, lmfit)
```

```
## Analysis of Variance Table
##
## Model 1: LnWeight ~ LnLength + Sex
## Model 2: LnWeight ~ LnLength * Sex
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      75 0.86327
## 2      74 0.84482  1  0.018455 1.6166 0.2076
```

her får jeg en p-værdi på 0.21 og dermed afvises hypotesen om ens hældning altså ikke og vi kan reducere modellen.

d)

Betragt nu modellen, hvor der er samme hældning i regressionslinjen for de to køn, og lav et 95%-konfidensinterval for forskel i skæring af regressionslinjen mellem hankøn og hunkøn. Kan det antages, at de to skæringer er ens ?

```
confint(lmfit_m2)
```

```
##                2.5 %    97.5 %  
## (Intercept) -10.62792888 -8.4564197  
## LnLength    3.04060955  3.6616840  
## Sexhun      0.04549679  0.1476483
```

så har vi altså at forskellen imellem de to køn er [0.045, 0.148] så rimelig småt. de er dog begge over 0 som betyder at med 95% sandsynlighed har de ikke præcis samme skæring, men når man så kigger på hvor små tal de er kan man evt vælge at sige man stadig tror på det, og lave en videre test for at tjekke.

opgave 3

I denne opgave skal I se på sammenhængen mellem et biologisk mål, nemlig ekspressionsniveauet for et microRNA, og en generel helbredsscore. Ekspressionsniveauet kan enten være lav eller høj og helbredsscoren kan være orr-1, orr-2 eller orr-3. Antallene i de 6 mulige "kasser" fremgår af følgende tabel.

a)

Lad antal_{ij} være antallet af personer i kategori i af microRNA (1:Lav, 2:Høj) og i kategori j af helbredsscore (1:orr-1, 2:orr-2, 3:orr-3). Opskriv den statistiske model for 2×3 matricen af de tilhørende stokastiske variable. Angiv hypotesen om uafhængighed mellem de to inddelingskriterier microRNA og helbredsscore.

jeg har modellen

$$M_0 : (A_{11}, A_{12}, A_{13}, A_{21}, A_{22}, A_{23}) \sim \text{multinom}(6, (\pi_{11}, \pi_{12}, \pi_{13}, \pi_{21}, \pi_{22}, \pi_{23}))$$

$$\pi_{ij} \geq 0, \pi_{11} + \pi_{12} + \pi_{13} + \pi_{21} + \pi_{22} + \pi_{23} = 1$$

og hypotesen om uafhængighed er så

$$\pi_{ij} = \alpha_i \cdot \beta_j$$

$$\alpha_1 + \alpha_2 = 1, \beta_1 + \beta_2 + \beta_3 = 1$$

b)

Undersøg, om det kan antages, at de to inddelingskriterier microRNA og helbredsscore er uafhængige. jeg bruger her koden fra noterne givet til os i løbet af undervisningen og skriver mine data ind

```

obs <- rbind(c(11,25,10), c(12,46,20))
r=dim(obs)[1]; k=dim(obs)[2]
rs=rowSums(obs)
cs=colSums(obs)
h=rep(c(1:r),rs)
m=rep(c(1:k),cs)

Gfct=function(Amat){
ex=outer(rowSums(Amat),colSums(Amat))/sum(Amat)
A1=ifelse(Amat==0,1,Amat)
return(2*sum(Amat*log(A1/ex)))
}
Gobs=Gfct(obs)

nSim=10^4-1
Gval=rep(0,nSim)
for (i in 1:nSim){
msamp=sample(m)
tabelsamp=table(h,msamp)
Gval[i]=Gfct(tabelsamp)
}
pval=(1+sum(Gval>=Gobs))/(1+nSim)
c(G=Gobs,pværdi=pval)

```

```

##          G    pværdi
## 1.394372 0.555300

```

her får jeg en p-værdi på 0.55 og jeg vil derfor ikke afvise hypotesen om uafhængighed.

c)

Betragt nu kun data vedrørende inddeling efter helbredsscore. Betragt hypotesen, at sandsynlighederne for de tre muligheder for helbredsscore er

$$P(orr = 1) = \theta^2, P(orr = 2) = 2\theta(1 - \theta), P(orr = 3) = (1 - \theta)^2, 0 \leq \theta \leq 1$$

Opstil likelihoodfunktionen for θ baseret på data i tabellen ovenfor. Find en formel for maksimum likelihood estimatet, og vis, at for data i opgaven her er $\hat{\theta} = 0.4718$

nu er mine data da

```

obs <- c(11+12, 25+46, 10+20)
obs

```

```
## [1] 23 71 30
```

likelihoodfunktionen er

$$L(\pi) = \binom{46+78}{a_1 \cdot a_2 \cdot a_3} \cdot \pi_1^{a_1} \cdot \pi_2^{a_2} \cdot \pi_3^{a_3}$$

som for de givne data bliver

$$= \binom{124}{23 \cdot 71 \cdot 30} \cdot \theta^{2 \cdot 23} \cdot (2\theta(1 - \theta))^{71} \cdot (1 - \theta)^{2 \cdot 30}$$

```
2*23+71
```

```
## [1] 117
```

```
2*30+71
```

```
## [1] 131
```

$$= C \cdot \theta^{117} \cdot (1 - \theta)^{131} \cdot 2^{71}$$

hvor C er en konstant ikke afhængig af θ for at finde maksimum likelihood estimatet finder vi log likelihood, differentierer og sætter lig 0

$$l(\theta) = \log(C) + 71\log(2) + 117\log(\theta) + 131\log(1 - \theta)$$

differentier

$$l'(\theta) = 117/\theta - 131/(1 - \theta) = 0$$

$$\Leftrightarrow 117(1 - \theta) = 131\theta \Leftrightarrow 117 = 248\theta \Leftrightarrow \hat{\theta} = 117/248$$

```
thetahat = 117/248  
thetahat
```

```
## [1] 0.4717742
```

så $\hat{\theta} = 0.4718$ som var det jeg skulle vise.

eksamen 2022 juni besvarelse

Nanna Liv Berdiin

2025-06-01

opgave 1

I tabellen nedenfor ses antallet af hjemmesejre, uafgjorte og ude sejre i superligaen for 78 kampe i efteråret 2020 og for 114 kampe i foråret 2021.

1)

Opstil en statistisk model for data og angiv med modellens parametre hypotesen om samme fordeling på hjemmesejr, uafgjort og ude sejr for de to halvår.

jeg har modellen

$$M_0 : (A_{11}, A_{12}, A_{13}) \sim \text{multinom}(78, (\pi_{11}, \pi_{12}, \pi_{13}))$$
$$(A_{21}, A_{22}, A_{23}) \sim \text{multinom}(114, (\pi_{21}, \pi_{22}, \pi_{23}))$$

$$\pi_{ij} \geq 0, \pi_{11} + \pi_{12} + \pi_{13} = 1, \pi_{21} + \pi_{22} + \pi_{23} = 1$$

og hypotesen om samme fordeling er så

$$H_0 : \pi_{ij} = \pi_i, \quad \text{for } j = 1, 2, 3$$

tror jeg så modellen hedder?

2)

Lav et test for hypotesen om samme fordeling på de to halvår.

```
obs=rbind(c(37, 17, 24),c(49, 31, 34))
# forventede , teststørrelse og p-værdi beregnes
ex=outer(rowSums(obs),colSums(obs))/sum(obs)

gTest=2*sum(obs*log(obs/ex))

pval=1-pchisq(gTest,(dim(obs)[1]-1)*(dim(obs)[2]-1))

list(Forventede=ex,G=gTest,Pvaerdi=pval)
```

```
## $Forventede
##      [,1] [,2] [,3]
## [1,] 34.9375 19.5 23.5625
## [2,] 51.0625 28.5 34.4375
##
## $G
## [1] 0.7658531
##
## $Pvaerdi
## [1] 0.681863
```

eftersom alle de forventede er over 5 kan jeg bruge denne test og jeg får en p-værdi på 0.68 som altså betyder at jeg ikke afviser hypotesen.

3)

Find estimat og 95%-konfidensinterval for sandsynligheden for hjemmesejr i sæsonen 2020-2021.

jeg bruger her prop.test for at finde konfidensinterval, estimat finder jeg med hvor mange der er i kassen over dem der er i alt.

```
n <- 192 #antal observerede i alt
kasse_i <- 86 #antal i kasse i der skal findes sandsynlighed for

kasse_i/n
```

```
## [1] 0.4479167
```

```
#kør prop.test
prop.test(kasse_i,n)$conf.int
```

```
## [1] 0.3767700 0.5211815
## attr(,"conf.level")
## [1] 0.95
```

så vi får altså estimatet på 0.48 og et 95% konfidensinterval [0.38, 0.52]

4)

Benyt de samlede antal hjemmesejre, uafgjorte og udesejre til at undersøge, om sandsynlighederne for hjemmesejr, uafgjort og udesejr er ens.

så vi har altså hypotesen at

$$H_1 : \pi_i = 1/3$$

jeg finder altså de forventede under denne hypotese og tester om den passer ud fra data

```
observerede = c(86, 48, 58)
kasser = 3 #antal kasser de kan falde i
frie_parametre = 0 #antal frie parametre i modellen

#beregner forventede værdier eller skriv vektoren alt efter hvad er givet i opgaven!
```

```
forventede = 192*c(1/3, 1/3, 1/3) #SKAL RETTES!

#beregnet teststørrelse:
Gobs = 2*sum((observerede*log(observerede/forventede)))

#beregnet p-værdi
1-pchisq(Gobs,kasser-1-frie_parametre)
```

```
## [1] 0.002762391
```

her får vi en p-værdi på 0.0028 og vi afviser dermed hypotesen om ens sandsynlighed.

opgave 2

Det har længe været kendt, at sølv er bakteriehæmmende. Dette forsøger man at anvende ved at binde sølv til nanopartikler. Data i denne opgave vedrører 3 hæmmere anvendt på 4 bakterietyper. De tre hæmmere betegnes soelv1 og soelv2 samt anti, som står for brugen af et antibiotikum. De fire bakterietyper betegnes blot B1, B2, B3 og B4. For hver kombination af metode og bakterietype er der foretaget 5 målinger. Selve målingen består i, at det anvendte materiale påføres en bakteriebelægning, og der måles efterfølgende radius af en cirkel, der dækker det område, der bliver bakteriefrit. De 60 dataværdier findes i filen bakteriehaemmer.csv, der har tre søjler med overskrifterne Haemmer, Bakterietype og radius. Det kan antages, at for hver kombination af hæmmer og bakterietype er det målte respons normalfordelt.

1)

Opstil en statistisk model for data, og undersøg om det kan antages at der er samme varians i de $3 \cdot 4 = 12$ grupper af data.

modellen vi har til at starte med

$$M_0 : X_{ijk} \sim N(\mu_{ij}, \sigma_{ij}^2), i = 1, 2, 3, j = 1, 2, 3, 4, k = 1, \dots, n_{ij}$$

hypotesen om ens varians imellem grupperne

$$H_{0\sigma^2} : \sigma_{ij}^2 = \sigma^2, i = 1, 2, 3, j = 1, 2, 3, 4$$

dette kan vi teste med en bartlett test.

```
bakteriehaemmer <- read.csv("bakteriehaemmer.csv", stringsAsFactors = TRUE)

respons_variabel <- bakteriehaemmer$radius
gruppe <- interaction(bakteriehaemmer$Haemmer, bakteriehaemmer$Bakterietype)
lmfit_m1 <- lm(radius ~ Haemmer*Bakterietype, data = bakteriehaemmer)

#lav test
bartlett.test(respons_variabel ~ gruppe)

##
## Bartlett test of homogeneity of variances
##
## data: respons_variabel by gruppe
## Bartlett's K-squared = 12.273, df = 11, p-value = 0.3435
```

så her får jeg altså en p-værdi på 0.34 og vi afviser derfor ikke hypotesen om ens varians imellem grupperne, det betyder at jeg nu har modellen.


$$M_1 : X_{ijk} \sim N(\mu_{ij}, \sigma^2), i = 1, 2, 3, j = 1, 2, 3, 4, k = 1, \dots, n_{ij}$$

2)


Lav en grafisk undersøgelse af, om data kan beskrives med en additiv model for middelværdien med et bidrag fra henholdsvis hæmmer og fra bakterietype.

her burde man lave et interaction plot

```
interaction.plot(bakteriehaemmer$Haemmer, bakteriehaemmer$Bakterietype, bakteriehaemmer$radius, col = "b")
```



```
interaction.plot(bakteriehaemmer$Bakterietype, bakteriehaemmer$Haemmer, bakteriehaemmer$radius, col = "r")
```



da vi kan se at begge tegninger er nogenlunde parallelle og derfor kan vi godt antage additivitetsmodellen. jeg skal altså undersøge om vi har modellen


$$M_2 : X_{ijk} \sim N(\alpha_i + \beta_j, \sigma^2), i = 1, 2, 3, j = 1, 2, 3, 4, k = 1, \dots, n_{ij}$$

for at lave en grafisk undersøgelse vil jeg undersøge et residualplot for denne hypotese


```
lmfit_m2 <- lm(radius ~ Haemmer + Bakterietype, data = bakteriehaemmer)
residualer <- lmfit_m2$residuals
```

```
#lav qqplot over residualerne
qqnorm(residualer, col = "purple2")
qqline(residualer, col = "green3")
```

Normal Q-Q Plot



```
plot(bakteriehaemmer$radius, residualer, col = "orangered")
```



vi kan her se at qqplot ser rigtig godt ud, så vi tror på modellen, vi kan også se når vi plotter residualerne at der er ingen systematisk afvigelse som er et godt tegn for at modellen er sand.

3)

Lav et test for hypotesen om additivitet.

dette kan vi gøre med et kald til anova

```
anova(lmfit_m2, lmfit_m1)
```

```
## Analysis of Variance Table
##
## Model 1: radius ~ Haemmer + Bakteriotype
## Model 2: radius ~ Haemmer * Bakteriotype
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      54 321.96
## 2      48 283.14  6    38.821 1.0969 0.378
```

her får vi en p-værdi på 0.38 og vi afviser altså ikke hypotesen om additivitet, modellen har jeg skrevet i opgaven over.

4)

Angiv, under den additive model, skøn og 95%-konfidensinterval for forskellen i middelværdi mellem de to hæmmere anti og soelv1.

```
coef(lmfit_m2)
```

```
##      (Intercept)  Haemmersoelv1  Haemmersoelv2  BakterietyeB2  BakterietyeB3
##           29.8830         -15.1235         -10.6235           2.2320           8.0000
## BakterietyeB4
##           1.4320
```

```
confint(lmfit_m2)
```

```
##              2.5 %      97.5 %
## (Intercept)  28.3349176  31.431082
## Haemmersoelv1 -16.6715824 -13.575418
## Haemmersoelv2 -12.1715824 -9.075418
## BakterietyeB2  0.4444284  4.019572
## BakterietyeB3  6.2124284  9.787572
## BakterietyeB4 -0.3555716  3.219572
```

fordi jeg har skrevet min model op som jeg har bliver dette forskellen fordi min “intercept” faktisk er anti så er et estimat for forskellen i middelværdi mellem anti og soelv1 altså -15.12 og et 95% konfidensinterval for forskellen er $[-16.67, -13.58]$.

5)

Undersøg om den additive model kan reduceres yderligere.

hvis jeg skulle reducere den additive model yderligere ville første trin være at se om jeg enten kan fjerne virkningen af Haemmer eller Bakterietye, begge disse kan undersøges ved kald til anova. hvis en af dem kan reduceres til skal vi så kigge videre. så jeg starter med at undersøge om vi kan fjerne Haemmer

```
lmfit_m3B <- lm(radius ~ Bakterietye, data = bakteriehaemmer)
anova(lmfit_m3B, lmfit_m1)
```

```
## Analysis of Variance Table
##
## Model 1: radius ~ Bakterietye
## Model 2: radius ~ Haemmer * Bakterietye
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1      56 2734.16
## 2      48  283.14  8      2451 51.939 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

her kan vi se at vi får en meget lille p-værdi og vi kan altså ikke reducere til modellen hvor Haemmer har ingen betydning

$$M_3^B : X_{ijk} \sim N(\beta_j, \sigma^2), j = 1, 2, 3, 4, k = 1, \dots, n_{ij}$$

jeg undersøger så om vi kan fjerne bakterietype

```
lmfit_m3H <- lm(radius ~ Haemmer, data = bakteriehaemmer)
anova(lmfit_m3H, lmfit_m1)
```

```
## Analysis of Variance Table
##
## Model 1: radius ~ Haemmer
## Model 2: radius ~ Haemmer * Bakterietype
##   Res.Df    RSS Df Sum of Sq      F      Pr(>F)
## 1      57 877.27
## 2      48 283.14   9    594.12 11.191 3.549e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

her får vi også en meget lille p værdi og vi kan altså heller ikke reducere her.

$$M_3^H : X_{ijk} \sim N(\alpha_i, \sigma^2), i = 1, 2, 3, j = 1, 2, 3, 4, k = 1, \dots, n_{ij}$$

det betyder altså at modellen M_2 ikke kan reduceres yderligere, begge faktorer er vigtige.

opgave 3

Lad F betegne fordelingsfunktionen givet ved

$$F(x) = \begin{cases} 1 - e^{-\lambda \cdot \sqrt{x}}, & \text{hvis } x \geq 0, \\ 0, & \text{ellers} \end{cases}$$

hvor $\lambda > 0$. På filen sim.csv findes et datasæt, der består af 100 observationer af en variabel Xsim, som skal benyttes i opgaven.

1)

Vis, at p-fraktilen $q_p, 0 < p < 1$, for F er givet ved

$$q_p = \frac{(\log(1-p))^2}{\lambda^2}$$

vi kan finde p-fraktilen ved at løse

$$F(q_p) = p$$

for q_p dette giver mig altså

$$\begin{aligned} 1 - e^{-\lambda \cdot \sqrt{q_p}} = p &\Leftrightarrow \log(1-p) = -\lambda \cdot \sqrt{q_p} \\ \Leftrightarrow q_p &= \frac{(\log(1-p))^2}{\lambda^2} \end{aligned}$$

som var det jeg skulle vise.

2)

Benyt resultatet fra 1) til at tegne et fraktildiagram, der undersøger, om det er rimeligt at antage, at observationerne af Xsim udgør en observationsrække fra fordelingen med fordelingsfunktion F med $\lambda = 1$.


Jeg kan her bruge fraktilfunktionen fundet i opgave 1, når $\lambda = 1$ har jeg da

$$q_p = (\log(1-p))^2$$

som så giver mig fraktilplottet

```
sim <- read.csv("sim.csv")

qqplot((log(1-ppoints(100)))^2, sort(sim$Xsim, ), col = "palevioletred2")
abline(0,1, col = "orange")
```



som så ser ud til at passe rimelig godt.

3)

Lad nu $X_1, \dots, X_n$ betegne en i.i.d. følge af stokastiske variable med fordelingsfunktion F , hvor $\lambda > 0$ er en ukendt parameter. I opgave 3) og 4) må det uden bevis benyttes at $X_i, i = 1, \dots, n$, har samme fordeling som Z^2 , hvor Z er eksponentialfordelt med rateparameter λ .

Vis, at man ved at benytte momentmetoden kommer frem til følgende estimator for λ :

$$\hat{\lambda}^M = \sqrt{\frac{2}{\bar{X}}}, \quad \bar{X} = \frac{1}{n} \cdot \sum_{i=1}^n X_i$$

og angiv estimatet for λ beregnet ud fra observationerne af X_{sim} .

når vi bruger momentmetoden sætter vi $E(X) = \bar{X}$. vi har fået at vide at X_i har samme fordeling som Z^2 med Z er eksponentialfordelt, jeg kan her bruge at for eksponentialfordelingen gælder det at

$$E[X^n] = n!/\lambda^n$$

som altså betyder at jeg får

$$E(X^2) = 2!/\lambda^2 = 2/\lambda^2$$

jeg sætter dem så lig med hianden og løser for lambda

$$\frac{2}{\lambda^2} = \bar{X} \Leftrightarrow \lambda^2 = \frac{2}{\bar{X}} \Leftrightarrow \hat{\lambda}^M = \sqrt{\frac{2}{\bar{X}}}$$

som var det jeg skulle vise.

ud fra Xsim får jeg så estimatet

```
lambdahat <- sqrt(2/mean(sim$Xsim))  
lambdahat
```

```
## [1] 1.026533
```

mit estimat for lambda er altså 1.03.


4)

Udfør et simulationseksperiment, der genererer 1000 udfald af $\hat{\lambda}^M$ baseret på observationsrækker med $n = 100$ observationer og $\lambda = 1$. Lav et histogram af udfaldene, og angiv et estimat for standardafvigelsen af $\hat{\lambda}^M$.

jeg bruger her at jeg ved fordelingen af X ift eksponentialfordelingen, så jeg får

```
set.seed(13)  
n <- 100  
N <- 10^3  
lambda.vec <- numeric(N)  
  
for (i in 1:N) {  
  X <- rexp(100, rate= 1)^2  
  lambda.vec[i] <- sqrt(2/mean(X))  
}  
hist(lambda.vec, col = "mediumvioletred", breaks = 25)
```

Histogram of lambda.vec



```
sd(lambda.vec)
```

```
## [1] 0.1130756
```

så et estimat for standardafvigelsen er altså 0.11

eksamen 2022 august besvarelse

Nanna Liv Berdiin

2025-05-30

opgave 1

Lad $X_1, \dots, X_n$ være i.i.d. stokastiske variable med fælles tæthed

$$f(x; \beta) = \begin{cases} -1/\beta \cdot \ln(x/\beta), & 0 \leq x \leq \beta, \\ 0, & \text{ellers,} \end{cases}$$

hvor $\beta > 0$. Det må i opgaven uden bevis benyttes at $X_i, i = 1, \dots, n$ har samme fordeling som YZ hvor Y og Z er uafhængige stokastiske variable, der er henholdsvis $Unif[0, 1]$ og $Unif[0, \beta]$ fordelt.

1)

Udled en estimator for β ved hjælp af momentmetoden, og beregn det tilsvarende estimat for datasættet med $n = 5$ observationer, som er givet i Tabel 1.

```
data <- c(3.23, 2.19, 2.50, 1.89, 3.09)
```

da Z og Y er uafhængige må vi have, pga fordelingerne af Z og Y , at

$$E(X) = E(Y) \cdot E(Z) = (1/2) \cdot (\beta/2) = \beta/4$$

sætter dette lig med det empiriske moment

$$\beta/4 = 1/n \cdot \sum_{i=1}^n X_i \Leftrightarrow \beta = 4/n \cdot \sum_{i=1}^n X_i$$

og derfor er et estimat for β ud fra det givne datasæt altså

```
beta = 4*(sum(data)/5)
beta
```

```
## [1] 10.32
```

så mit estimat for β er altså 10.32.


opgave 2

For 2 forskellige behandlinger, A og B, observeres en variabel, som i opgaven betegnes X . Man har målt X 8 gange ved behandling A og 10 gange ved behandling B. Datasættet er gengivet i Tabel 2 og findes på filen Behandling.csv.

1)

Lav boxplots for de to behandlinger. Er der nogen outliers i datasættet? jeg loader data og laver boxplot

```
behandling <- read.csv("Behandling.csv", stringsAsFactors = TRUE)
boxplot(x~Behandling, data = behandling, col = rainbow(2))
```



vi kan se at der er en meget stor outlier i A datasættet.

2)

Benyt et permutationstest til at undersøge om der er forskel i middelværdien for de to behandlinger.

```
grpA <- subset(behandling, Behandling == "A")$x
grpB <- subset(behandling, Behandling == "B")$x

obj <- behandling$x
obs = mean(grpA) - mean(grpB)
oneofthem = grpA

N <- 10^4 - 1
result <- numeric(N)
for (i in 1:N) {
  index <- sample(length(obj), size = length(oneofthem), replace = FALSE)
  result[i] <- mean(obj[index]) - mean(obj[-index])
}
```

```

}

#og finder p-værdien
pval = (2*min(sum(result < obs),sum(result >= obs)) + 1) / (N+1)
pval

## [1] 0.6571

```

her får vi en p-værdi på 0.66 og dermed afviser vi ikke hypotesen om ens middelværdi.

3)

Det viser sig, at der er begået en fejl da datasættet blev indtastet, idet der er kommet et minus på den første observation hørende til behandling A. Observationen -2.20 skulle derfor være 2.20 . Ret ovenstående fejl, og undersøg dernæst ved hjælp af en grafisk analyse om det rettede datasæt kan antages at stamme fra modellen

$$M_1 : X_{ij} \sim N(\mu_i, \sigma_i^2), \quad i = A, B, \quad j = 1, \dots, n_i$$


hvor X_i 'erne er uafhængige og $n_A = 8$ og $n_B = 10$.

jeg retter data til, laver boxplot, qqnorm osv for grafisk undersøgelse:


```

behandling[1,1] <- 2.2
source("qqnorm_multi.R")
boxplot(x~Behandling, data = behandling, col = rainbow(2))

```



```
qqnorm_multi(behandling$x, behandling$Behandling)
```



vi kan tydeligt se fra boxplots at de nok har forskellig middelværdi. vi kan se fra qqnorm_multi funktionen at de begge ser normalfordelte ud, og at det ovenikøbet ligner de måske har samme varians da de har samme hældning.

4)

Vis, at varianserne σ_A^2 og σ_B^2 kan antages at være ens i M_1 , og opskriv den reducerede model. Kan det antages at middelværdierne μ_A og μ_B er ens i den nye model?

vi så som sagt at det lignede at middelværdierne var ens og vi tester

```
grpAny <- subset(behandling, Behandling == "A")$x
grpBny <- subset(behandling, Behandling == "B")$x
var.test(grpAny, grpBny)
```

```
##
## F test to compare two variances
##
## data: grpAny and grpBny
## F = 0.39422, num df = 7, denom df = 9, p-value = 0.233
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.09392785 1.90140647
```

```
## sample estimates:
## ratio of variances
##          0.3942195
```

her får vi en p-værdi på 0.233 og vi afviser altså ikke hypotesen om at de to grupper har ens varians. vi har altså den reducerede model

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2), \quad i = A, B, \quad j = 1, \dots, n_i$$

jeg kan lave en t.test for at se om middelværdierne er ens

```
t.test(grpAny, grpBny, var.equal = TRUE)
```

```
##
## Two Sample t-test
##
## data:  grpAny and grpBny
## t = 2.4651, df = 16, p-value = 0.02539
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  0.1261087 1.6748913
## sample estimates:
## mean of x mean of y
##    2.6725    1.7720
```

det er de stadig ikke, vi afviser hypotesen, kunne vi også se fra boxplot nok ikke var så sandsynligt.

opgave 3

For 100 tilfældigt udvalgte slagtegrise er kødprocenten bestemt. I Figur 1 ses to mulige normal fraktilsammenligninger for de 100 målinger, og i nedenstående tabel er angivet gennemsnit $\bar{x}$ og empirisk varians s^2 for de 100 målinger.

1)

Angiv, hvilket af de to qqplots i Figur 1 der svarer til de 100 kødprocenter. Begrund dit svar.

vi har fået oplyst at $s^2 = 6.748$ vi kan aflæse variansen fra de to qqplots som hældningen i anden

```
((64-56)/4)^2
```

```
## [1] 4
```

```
((70-50)/4)^2
```

```
## [1] 25
```

der er ikke nogen af dem der er så præcise, men nok mest til qqplot 1. vi har også fået oplyst at $\bar{x} = 60.42$ og selvom begge tegninger er tæt på 60 så ligner det at qqplot 2 er lidt under og qqplot 1 er lidt over. som igen hænger sammen med at jeg tror det er qqplot 1.

2)

Lav et 95%-konfidensinterval for middelværdien af kødprocenten. vi kan ud fra det givne qqplot antage at kødprocenten er normalfordelt og vi kan derfor finde 95% konfidensinterval som (fordi vi har ukendt varians)

$$[\bar{x} - t_{1-\alpha/2}(n-1) \cdot s/\sqrt{n}, \quad \bar{x} + t_{1-\alpha/2}(n-1) \cdot s/\sqrt{n}]$$

som altså giver mig et interval

```
xbar <- 60.43
s <- sqrt(6.748)
n <- 100
alpha <- 0.05

lowermu <- xbar - qt(1-alpha/2, df= n-1)*s/sqrt(n)
uppermu <- xbar + qt(1-alpha/2, df= n-1)*s/sqrt(n)
c(lowermu, uppermu)
```

```
## [1] 59.91456 60.94544
```

så mit 95% konfidensinterval for middelværdien er altså [59.91, 60.95].

3)

Angiv et 95%-konfidensinterval for spredningen. Kan det antages at spredningen er lig 3?

vi kan finde konfidensinterval for variansen med

$$[(n-1)s^2/\chi_{1-\alpha/2}^2(n-1), \quad (n-1)s^2/\chi_{\alpha/2}^2(n-1)]$$

som så giver mig (vi tager kvadratroden for at finde spredningen)

```
lowersigma <- (n-1)*s^2/qchisq(1-alpha/2, df= n-1)
uppersigma <- (n-1)*s^2/qchisq(alpha/2, df= n-1)
c(sqrt(lowersigma), sqrt(uppersigma))
```

```
## [1] 2.280791 3.017674
```

så mit 95% konfidensinterval for variansen er altså [2.28, 3.08]. så vi kan godt antage at spredningen er 3.

opgave 4

Data i denne opgave vedrører overlevelsen af bakterien E.coli i husdyrgødning under en anaerob nedbrydningsproces. Mængden af bakterier er målt på forskellige tidspunkter efter starten på nedbrydningsprocessen. Måleenheden for antal bakterier er cfu/g og tiden måles i dage. Data er i filen nedbrydning.csv der har to søjler.

1)

Gør rede for at logaritmen til bakterie-antallet kan beskrives med den lineære regressionsmodel med tiden som den forklarende variabel. Opskriv den statistiske model.

```
nedbrydning <- read.csv("nedbrydning.csv")
nedbrydning$logCFU <- log(nedbrydning$CFU)
```

vi har altså modellen


$$M_0 : X_i \sim N(\alpha + \beta \cdot t_i, \sigma^2), i = 1, \dots, 12$$

vi tester med residualerne om det passer

```
respons_variabel <- nedbrydning$logCFU
forklarende_variabel <- nedbrydning$Tid

lmfit <- lm(respons_variabel ~ forklarende_variabel)
residualer <- residuals(lmfit)
qqnorm(residualer, col = "skyblue2")
qqline(residualer, col = "orange")
```

Normal Q–Q Plot



```
summary(lmfit)
```

```
##
## Call:
## lm(formula = respons_variabel ~ forklarende_variabel)
##
## Residuals:
```

##	Min	1Q	Median	3Q	Max
----	-----	----	--------	----	-----

```
## -0.30195 -0.12618 -0.03140 0.06374 0.42807
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      5.170353   0.108184  47.79 3.88e-13 ***
## forklarende_variabel -0.062080   0.003699 -16.78 1.18e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2231 on 10 degrees of freedom
## Multiple R-squared:  0.9657, Adjusted R-squared:  0.9623
## F-statistic: 281.7 on 1 and 10 DF,  p-value: 1.182e-08
```

vi kan se at den passer rimelig godt i starten men får lidt væk oppe mod højre hjørne. vi kan også se at den forklarende variabel er vigtig for at forklare logCFU via summary?

2)

Angiv et 95%-konfidensinterval for hældningen i den lineære sammenhæng for middelværdien.
denne finder vi med confint

```
confint(lmfit)
```

```
##              2.5 %      97.5 %
## (Intercept)      4.92930396  5.41140175
## forklarende_variabel -0.07032147 -0.05383889
```

så vi har altså at hældningen har konfidensinterval $[-0.0703, -0.0538]$

3)

Den tid det tager, halveringstiden T_h , for at bakterie-antallet er halveret, kan skrives som $T_h - \ln(2)/\beta$, hvor β er hældningen i den lineære sammenhæng for middelværdien af logaritmen til bakterie-antallet. Angiv et 95%-konfidensinterval for halveringstiden.

vi burde bare kunne bruge det vi har fundet ovenover?

```
c(-log(2)/(-0.07032147), -log(2)/(-0.05383889))
```

```
## [1] 9.856836 12.874470
```

så vi får et konfidensinterval på $[9.86, 12.87]$

eksamen juni 2023 besvarelse

Nanna Liv Berdiin

2025-05-31

opgave 1

Ved en multiple choice opgave stilles de studerende et spørgsmål, som skal besvares med et blandt tre mulige svar. Svarmulighederne er A, B eller C. De studerende er placeret i to grupper G1 og G2, men det vides ikke hvorledes gruppeplaceringerne er foretaget. Man ønsker at undersøge, om der er uafhængighed mellem gruppeplaceringen og de afgivne svar.

1)

Opstil en statistisk model for data, og undersøg om der er uafhængighed mellem inddelingskriterierne svar og gruppe.

jeg har modellen

$$M_0 : (A_{11}, A_{12}, A_{13}, A_{21}, A_{22}, A_{23}) \sim \text{multinom}(200, (\pi_{11}, \pi_{12}, \pi_{13}, \pi_{21}, \pi_{22}, \pi_{23}))$$

$$\pi_{ij} \geq 0, \pi_{11} + \pi_{12} + \pi_{13} + \pi_{21} + \pi_{22} + \pi_{23} = 1$$

og hypotesen om uafhængighed er så

$$\pi_{ij} = \alpha_i \cdot \beta_j$$

$$\alpha_1 + \alpha_2 = 1, \beta_1 + \beta_2 + \beta_3 = 1$$

for at teste afhængighedshypotesen bruger jeg kode fra supplerende noter

```
# data indskrives
obs=rbind(c(15,17,57),c(40,56,35))
# forventede , teststørrelse og p-værdi beregnes
ex=outer(rowSums(obs),colSums(obs))/sum(obs)

gTest=2*sum(obs*log(obs/ex))

pval=1-pchisq(gTest,(dim(obs)[1]-1)*(dim(obs)[2]-1))

list(Forventede=ex,G=gTest,Pvaerdi=pval)

## $Forventede
##      [,1]      [,2]      [,3]
## [1,] 22.25 29.53182 37.21818
## [2,] 32.75 43.46818 54.78182
##
## $G
```

```
## [1] 30.99704
##
## $Pvaerdi
## [1] 1.858144e-07
```

her får jeg en meget lav p-værdi og jeg afviser dermed hypotesen om uafhængighed imellem svar og gruppe.

2)

Et mindre hold af studerende blev ligeledes inddelt i to grupper og stillet en anden multiple choice opgave, som i dette tilfælde havde fire svarmuligheder. Undersøg om det for det lille hold kan antages, at der er uafhængighed mellem inddelingskriterierne svar og gruppe.

note: her kunne jeg også have brugt fishers eksakte test

```
obs <- rbind(c(2,1,1,10), c(4,5,4,4))
fisher.test(obs)
```

```
##
## Fisher's Exact Test for Count Data
##
## data: obs
## p-value = 0.07261
## alternative hypothesis: two.sided
```

jeg kan også bruge en permutationstest for den nye data.

```
#ret til
obs <- rbind(c(2,1,1,10), c(4,5,4,4))

#brug kode
r=dim(obs)[1]; k=dim(obs)[2]
rs=rowSums(obs)
cs=colSums(obs)
h=rep(c(1:r),rs)
m=rep(c(1:k),cs)

Gfct=function(Amat){
  ex=outer(rowSums(Amat),colSums(Amat))/sum(Amat)
  A1=ifelse(Amat==0,1,Amat)
  return(2*sum(Amat*log(A1/ex)))
}
Gobs=Gfct(obs)

nSim=10^4-1
Gval=rep(0,nSim)
for (i in 1:nSim){
  msamp=sample(m)
  tabelsamp=table(h,msamp)
  Gval[i]=Gfct(tabelsamp)
}
pval=(1+sum(Gval>=Gobs))/(1+nSim)
c(G=Gobs,pværdi=pval)
```

```
##          G    pværdi
## 7.883871 0.092100
```

her får jeg en p-værdi på 0.095 og jeg afviser derfor ikke hypotesen om uafhængighed imellem svar og gruppe for denne anden inddeling.

opgave 2

Ved et forsøg ønskede man at undersøge sammenhængen mellem samtidige målinger af hjertets slagvolumen (målt i ml/kg) og blodtrykket (målt i cm H_2O) hos tre arter af skildpadder, som vi i opgaven kalder A, B og C. I opgaven tages udgangspunkt i en model, hvor middelværdien af slagvolumen afhænger lineært af blodtrykket inden for de tre arter. Vi lader x_{gi} betegne den i te måling af slagvolumen for art g , og idet data kan betragtes som normalfordelt, opstilles modellen, hvor målingerne af slagvolumen er udfald af stokastiske variable

$$M_0 : X_{gi} \sim N(\alpha_g + \beta_g \cdot b_{gi}, \sigma_g^2), g = A, B, C, i = 1, \dots, n_g$$

hvor b_{gi} angiver den i te måling af blodtrykket for art g , og X_{gi} -erne er uafhængige. Der er foretaget 10 målinger for hver af de tre arter, så $n_A = n_B = n_C = 10$. Datasættet findes på filen turtles.csv, som indeholder de tre søjler art, slagvolumen og blodtryk.

1)

Vis, at det kan antages, at variansen inden for de tre grupper er ens, og angiv estimatet for den fælles varians. til dette laver jeg en bartlett test for at tjekke om varianshomogenitet.

```
turtles <- read.csv("turtles.csv", stringsAsFactors = TRUE)
turtlesA <- subset(turtles, art == "A")
turtlesB <- subset(turtles, art == "B")
turtlesC <- subset(turtles, art == "C")

#vi er vidst nødt til at skrive det op som 3 forskellige her
lmfita <- lm(slagvolumen~blodtryk, data = turtlesA)
lmfitb <- lm(slagvolumen~blodtryk, data = turtlesB)
lmfitc <- lm(slagvolumen~blodtryk, data = turtlesC)

#kører bartlett test for ens varians
bartlett.test(list(lmfita, lmfitb, lmfitc))
```

```
##
## Bartlett test of homogeneity of variances
##
## data: list(lmfita, lmfitb, lmfitc)
## Bartlett's K-squared = 1.8235, df = 2, p-value = 0.4018
```

her får vi en p-værdi på 0.40 og vi afviser altså ikke hypotesen om ens varians. modellen hvor de har ens varians er så

$$M_1 : X_{gi} \sim N(\alpha_g + \beta_g \cdot b_{gi}, \sigma^2), g = A, B, C, i = 1, \dots, n_g$$

som vi kan skrive op og finde variansskøn for

```
lmfit <- lm(slagvolumen ~ blodtryk*art, data = turtles)
sigma(lmfit)^2
```

```
## [1] 1.302162
```


så vi har altså et skøn for variansen er 1.30.

2)


Lav grafisk model kontrol af M_1 baseret på residualerne.

vi kan gøre dette ved at tjekke om residualerne er normalfordelte.

```
residualer <- lmfit$residuals
#lav qqplot over residualerne
qqnorm(residualer, col = "purple2")
qqline(residualer, col = "green3")
```



```
plot(turtles$blodtryk, residualer, col = "pink3")
```



vi kan se at de ser rimelig normalfordelte ud. og når vi plotter residualerne som funktion af blodtryk ser vi ikke nogen tydelig sammenhæng.

3)

Vis, at det kan antages, at der er fælles hældning og angiv estimat og 95% konfidensinterval for den fælles hældning.

hvis der er fælles hældning har vi modellen

$$M_2 : X_{gi} \sim N(\alpha_g + \beta \cdot b_{gi}, \sigma^2), g = A, B, C, i = 1, \dots, n_g$$

denne kan vi undersøge med anova

```
lmfit_m2 <- lm(slagvolumen ~ blodtryk + art, data = turtles)
anova(lmfit_m2, lmfit)
```

```
## Analysis of Variance Table
##
## Model 1: slagvolumen ~ blodtryk + art
## Model 2: slagvolumen ~ blodtryk * art
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      26 35.852
## 2      24 31.252   2   4.5999 1.7662 0.1925
```

her får vi en p-værdi på 0.18 og afviser altså ikke hypotesen om ens hældning. et 95% konfidensinterval for hældningen er så

```
coef(lmfit_m2)
```

```
## (Intercept)   blodtryk      artB      artC
##   4.4990844  -0.5250930   0.8462632   2.0434723
```

```
confint(lmfit_m2)
```

```
##           2.5 %    97.5 %
## (Intercept) 2.8072498 6.1909190
## blodtryk   -0.7665044 -0.2836816
## artB       -0.2332653  1.9257917
## artC       0.9635337  3.1234109
```

så hældningen er her blodtryk som så er -0.525 med konfidensinterval $[-0.77, -0.28]$

4)

Angiv 95% kondidensinterval for variansen σ^2 i modellen M_2 .

vi har fra side 66 i de supplerende noter at vi kan finde konfidensintervallet af σ^2 med

$$[s_{02}^2(X)/(\chi_{1-\alpha/2}^2(f_{02})/f_{02}), \quad s_{02}^2(X)/(\chi_{\alpha/2}^2(f_{02})/f_{02})]$$

vi kan aflæse f_{02} i et kald til summary

```
summary(lmfit_m2)
```

```
##
## Call:
## lm(formula = slagvolumen ~ blodtryk + art, data = turtles)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.6146 -0.6567 -0.1117  0.8983  1.7646
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    4.4991     0.8231   5.466 9.86e-06 ***
## blodtryk      -0.5251     0.1174  -4.471 0.000136 ***
## artB           0.8463     0.5252   1.611 0.119174
## artC           2.0435     0.5254   3.889 0.000623 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.174 on 26 degrees of freedom
## Multiple R-squared:  0.5679, Adjusted R-squared:  0.5181
## F-statistic: 11.39 on 3 and 26 DF,  p-value: 5.917e-05
```

hvor vi ser at der er 26 degrees of freedom

som så giver mig

```
s_sq = sigma(lmfit_m2)^2
alpha = 0.05
f = 26

lower <- f*s_sq/qchisq(1-alpha/2, df = f)
upper <- f*s_sq/qchisq(alpha/2, df = f)

c(lower, upper)
```

```
## [1] 0.8551778 2.5897148
```

som vi giver mig et interval for variansen som [0.86, 2.59]

5)

Angiv 95% kondidensintervaller for de tre afskæringer α_A , α_B og α_C i M_2 .

denne kan vi finde meget let ved at skrive M_2 en lille smugle om så der står 0+ så får vi nemlig specifikt hver gruppes skæring uden at skulle regne noget på den.

```
lmfit_m2star <- lm(slagvolumen ~ 0 + blodtryk + art, data = turtles)
confint(lmfit_m2star)
```

```
##           2.5 %      97.5 %
## blodtryk -0.7665044 -0.2836816
## artA      2.8072498  6.1909190
## artB      3.6642088  7.0264864
## artC      4.8220277  8.2630858
```

så vi har for A er det [2.81, 6.19] for B [3.66, 7.03] og for C [4.82, 8.26]

opgave 3

I nærværende opgave betragtes parameterestimation og test i en delmodel af $Beta(a, b)$ modellen. En $Beta(a, b)$ -fordelt stokastisk variabel X , hvor $a > 0, b > 0$, har middelværdi og varians

$$E(X) = a/(a+b), \quad \text{var}(X) = ab/((a+b)^2(a+b+1))$$

Vi ser på delmodellen med parameter $b = 2$, og en i.i.d. følge $X_1, \dots, X_n$ fra denne.

1)

Gør rede for, at momentestimatoren for a er givet ved

$$\hat{a} = 2\bar{X}/(1 - \bar{X}), \quad \bar{X} = 1/n \cdot \sum_{i=1}^n X_i$$

Beregn estimatet for a ud fra datasættet x , som genereres ved hjælp af kodestumpen i R-kode 1.

jeg skal vise at momentestimatorer for a er givet som der er oplyst. momentestimatoren for a findes ved at sætte $E(X)$ lig med det empiriske moment $\bar{X}$ som er defineret som ovenover og så isolere for a , så dette gør jeg.

$$\begin{aligned} a/(a+b) &= \bar{X} \Leftrightarrow a = \bar{X}a - \bar{X}b \Leftrightarrow a(1 - \bar{X}) = \bar{X}b \\ \Leftrightarrow \hat{a} &= \bar{X}b/(1 - \bar{X}) = 2\bar{X}/(1 - \bar{X}) \end{aligned}$$

eftersom $b=2$ i dette tilfælde. jeg skal så også regne den

```
set.seed(42)
x <- rbeta(100, 3, 2)
ahat <- 2*mean(x)/(1-mean(x))
ahat
```

```
## [1] 2.878335
```

så jeg får altså at $\hat{a} = 2.88$.

2)

Lav ud fra datasættet fra R-kode 1 et histogram af bootstrap fordelingen for estimatoren $\hat{a}$ og beregn et 90% percentil interval.

jeg skal altså bootstrappe a

```
#skriv parameter ind
data_test <- x


#regner
n <- length(data_test)
N <- 10^4

test.a <- numeric(N)

for (i in 1:N) {
  x_sample <- sample(data_test, size=n, replace = TRUE)
  test.a[i] <- 2*mean(x_sample)/(1-mean(x_sample))
}

hist(test.a, main = "Bootstrap distribution of a", col = "skyblue", breaks=60)
abline(v = 2*mean(x)/(1-mean(x)) , col = "blue", lty = 2)
```

Bootstrap distribution of a



vi kan finde bootstrap percentil interval med

```
alpha = 0.10
quantile(test.a, probs=c(alpha/2, 1-alpha/2))
```

```
##          5%          95%
## 2.524034 3.288573
```

så jeg får altså 90% percentil interval til at være $[2.52, 3.29]$.

3)

Gør kort rede for, at fordelingen af gennemsnittet $\bar{X}$ kan approksimeres ved

$$\bar{X} \sim N(a/(a+2), 2a/(n(a+2)^2(a+3)))$$

Vi ønsker at benytte approksimationen til at lave et test af nulhypotesen $a = 3$ mod alternativet $a < 3$, ved brug af stikprøvegennemsnittet, $\bar{X}$, som teststørrelse. Gør rede for, at det er oplagt at lave et ensidet test og beregn p-værdien for en observeret stikprøve med $n = 100$ og $\bar{x} = 0.59$

Vi ved dette pgs. central limit theorem CLT da den siger netop dette når vi ved hvad den forventede værdi og varians af X er. det er normalfordelt med middelværdien $E(X)$ og variansen $\text{var}(X)/n$. eftersom $\bar{X}$ er en estimator for middelværdien får vi da

$$\bar{X} \sim N(\mu, \sigma^2/n)$$

det er oplagt at lave ensidet test fordi vores nulhypotese er $a=3$ og alternativhypotesen er $a>3$ så vi kigger altså kun på en side.

fordi den er normalfordelt kan jeg finde sandsynligheden for at den er over de 0.59

```
mean_a3 <- 3/(3+2)
sd_a3 <- sqrt((2*3)/(100*(3+2)^2*(3+3)))
pnorm(0.59, mean = mean_a3, sd = sd_a3)
```

```
## [1] 0.3085375
```

så vi får en p-værdi på 0.31 for den observerede stikprøve.

4)

I modellen $X \sim \text{Beta}(a, 2)$ foreslås et test af nulhypotesen $a = 3$ mod alternativet $a < 3$ som følger: Forkast nulhypotesen, når gennemsnittet af 100 værdier er mindre end $C = 0.57$. Beregn, ved brug af normalapproximationen fra 3), sandsynligheden for type I fejl ved dette test, samt sandsynligheden for type II fejl når den sande parameter er $a = 2.5$.

type 1 fejl er når vi afviser nulhypotesen givet at nulhypotesen er sand, og type 2 fejl er at vi accepterer nulhypotesen givet at nulhypotesen er falsk. så sandsynligheden for type 1 fejl er altså sandsynligheden for at gennemsnittet er under 0.57

```
C = 0.57
#sandsynligheden for type 1 fejl:
#her simulerer vi fra nulhypotesen a=3, vi afviser hypotesen når den er under 0.57
pnorm(0.57, mean = mean_a3, sd = sd_a3)
```

```
## [1] 0.0668072
```

og dermed er sandsynligheden for type 1 fejl altså 0.067. vi finder også sandsynligheden for type 2 fejl, her skal nulhypotesen være falsk og derfor $a=2.5$

```
mean_a25 <- 2.5/(2.5+2)
sd_a25 <- sqrt((2*2.5)/(100*(2.5+2)^2*(3+2.5)))
1- pnorm(0.57, mean = mean_a25, sd = sd_a25)
```

```
## [1] 0.2477062
```

så sandsynligheden for type 2 fejl når $a=2.5$ er altså 0.25.

5)

Betragt situationen fra 4). Lav et simulationsekspirement for at skønne sandsynligheder for type I og type II fejl. Skønnene skal beregnes ved hjælp af simulationer af 10000 stikprøver af størrelse $n = 100$ hver fra nulmodellen (hvor $a = 3$) og fra alternativmodellen (med $a = 2.5$).

jeg kan simulere fra beta-fordelingen med rbeta. simulerer først type 1 fejl

```

a = 3
a_star = 2.5
n <- 100
N <- 10^4
C = 0.57

# type 1 fejl:
mean.vec <- numeric(N)
mean.vec2 <- numeric(N)

for (i in 1:N) {
  x1 <- rbeta(n, a, 2)
  x2 <- rbeta(n, a_star, 2)
  mean.vec[i] <- mean(x1)
  mean.vec2[i] <- mean(x2)
}

p_val <- mean(mean.vec < C)
c("type 1 fejl:", p_val)

```

```
## [1] "type 1 fejl:" "0.071"
```

```

p_val2 <- mean(mean.vec2 >= C)
c("type 2 fejl:", p_val2)

```

```
## [1] "type 2 fejl:" "0.248"
```

her ser vi altså at under simulering er sandsynlighederne cirka de samme som for opgaven ovenover.

eksamen august 2023 besvarelse

Nanna Liv Berdiin

2025-05-27

opgave 1

```
amitrip <- read.csv("amitrip.csv")
```


1)

så vi skal opskrive den multiple regressionsmodel med 4 variable og 17 patienter i alt

$$M_1 : X_i \sim N(\alpha + t_{i1} \cdot t1 + t_{i2} \cdot t2 + t_{i3} \cdot t3 + t_{i4} \cdot t4, \sigma^2), i = 1, \dots, 17$$

jeg skal grafisk tjekke om residualerne er normalfordelte.

```
lmfit1 <- lm(x ~ t1 + t2 + t3 + t4, data = amitrip)
residualer <- residuals(lmfit1)
qqnorm(residualer, col = "skyblue2")
qqline(residualer, col = "orange")
```



vi kan se at de svinger en del, vi kan også se via y-aksen at der er høj varians, men overordnet set ligger de tæt på linjen, bare ikke tydeligt normalfordelte, der er også kun 17 datapunkter.

2)

nu skal vi lave backward selektion med signifikansniveau $\alpha = 0.05$. så vi kører vores opskrevne startmodel

```
summary(lmfit1)
```

```
##
## Call:
## lm(formula = x ~ t1 + t2 + t3 + t4, data = amitrip)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -238.58 -125.41   14.80    99.55   201.11
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1368.98780   476.76126   2.871  0.01405 *
## t1           0.13702    0.03608    3.798  0.00254 **
## t2          -0.84260    2.03436  -0.414  0.68605
## t3           4.99893    1.93865    2.579  0.02416 *
## t4          -5.69701    4.40048   -1.295  0.21980
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 151.9 on 12 degrees of freedom
## Multiple R-squared:  0.7256, Adjusted R-squared:  0.6341
## F-statistic: 7.931 on 4 and 12 DF,  p-value: 0.002288
```

her kan vi se at vi fjerner t2

```
lmfit2 <- lm(x ~ t1 + t3 + t4, data = amitrip)
summary(lmfit2)
```

```
##
## Call:
## lm(formula = x ~ t1 + t3 + t4, data = amitrip)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -238.958 -116.985  -5.664   76.373  201.723
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1231.09710   330.21528   3.728  0.00253 **
## t1           0.13071    0.03165   4.130  0.00118 **
## t3           4.71083    1.75096   2.690  0.01853 *
## t4          -5.27348    4.14140  -1.273  0.22519
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 147 on 13 degrees of freedom
## Multiple R-squared:  0.7216, Adjusted R-squared:  0.6574
## F-statistic: 11.23 on 3 and 13 DF,  p-value: 0.0006498
```

nu fjerner vi så t4

```
lmfit3 <- lm(x ~ t1 + t3, data = amitrip)
summary(lmfit3)
```

```
##
## Call:
## lm(formula = x ~ t1 + t3, data = amitrip)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -201.64 -162.83   31.84  107.04  206.34
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  870.5210   173.6026   5.014 0.000189 ***
## t1           0.1366    0.0320   4.269 0.000779 ***
## t3           4.4543    1.7775   2.506 0.025177 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 150.3 on 14 degrees of freedom
## Multiple R-squared:  0.6869, Adjusted R-squared:  0.6422
## F-statistic: 15.36 on 2 and 14 DF,  p-value: 0.0002949
```

og nu vil vi ikke længere fjerne noget. vi skal så lave et F-test for reduktion fra den fulde model til slutmodellen, dette gøres med anova.

```
anova(lmfit3, lmfit1)
```

```
## Analysis of Variance Table
##
## Model 1: x ~ t1 + t3
## Model 2: x ~ t1 + t2 + t3 + t4
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      14 316065
## 2      12 277055  2      39011 0.8448 0.4537
```

da p-værdien her er 0.45 kan vi så se at vi ikke afviser at vi kan reducere vores model så det kun er t1 og t3 der har indflydelse.

3)

jeg skal nu angive estimer og 95%-konfidensintervaller for skæringen samt regressionskoefficienterne i M2.

```
coef(lmfit3) # giver parameterskøn
```

```
## (Intercept)      t1      t3
## 870.5210022  0.1365905  4.4542940
```

```
confint(lmfit3) #giver 95% konfidensinterval for parametrene
```

```
##              2.5 %      97.5 %
## (Intercept) 498.18056528 1242.8614392
## t1          0.06796675   0.2052143
## t3          0.64190725   8.2666808
```

som så kan aflæses her, øverst har vi estimerne og nedenunder har vi 95% konfidensinterval.

4)

nu skal jeg så angive et 95%-prædiktionsinterval for mængden af AMI i blodet, når værdien af T1 er 1100 og værdien af T3 er 80.

```
nyData = data.frame(t1 = c(1100), t3 = c(80))
predict(lmfit3, nyData, interval = "prediction")
```

```
##      fit      lwr      upr
## 1 1377.114 1037.51 1716.719
```

så vi får altså 95% prædiktionsintervallet er [1037.5, 1716.7]

5)

Lad σ^2 betegne variansen i modellen. Parameteren $1/\sigma^2$ kaldes præcisionen. Angiv 95%-konfidensinterval for præcisionen i modellen M2. dette kan jeg gøre ved at finde 95% konfidensinterval for sigma og så regne ud for $1/\sigma$

```
alpha = 0.05
df_value= 14
sigma2 <- sigma(lmfit3)^2
c(sigma2/(qchisq(1-alpha/2, df = df_value)/df_value), sigma2/(qchisq(alpha/2, df = df_value)/df_value))

## [1] 12100.99 56152.16

c(1/56152.16, 1/12100.99)

## [1] 1.780875e-05 8.263787e-05
```

opgave 2

1)

Formulér hypotesen om at der er samme præference blandt forbrugerne for de fire smagsvarianter ved hjælp af modellens parametre og undersøg hypotesen. jeg antager at der med dette henvises til at de har samme sandsynlighed for dem alle, så vi har

$$H_0 : \pi_i = 0.25, i = 1, 2, 3, 4$$

så ville vi altså kunne regne de forventede værdier og teste hypotesen

```
observerede <- c(21,6,9,8)
kasser = 4
frie_parametre = 0
n = 44
forventede = c(44/4, 44/4, 44/4, 44/4)

#beregneteststørrelse
Gobs = 2*sum((observerede*log(observerede/forventede)))
Gobs
```

```
## [1] 11.17738
```

```
#beregnetp-værdi
1-pchisq(Gobs,kasser-1-frie_parametre)
```

```
## [1] 0.01080439
```

så vi afviser altså hypotesen om at de alle har samme præference.

2)

jeg skal gøre rede for at likelihoodfunktionen under H1 er på formen, jeg starter derfor med den generelle og indsætter

$$L(\pi) = \binom{44}{a_1 \cdot a_2 \cdot a_3 \cdot a_4} \cdot \pi_1^{a_1} \cdot \pi_2^{a_2} \cdot \pi_3^{a_3} \cdot \pi_4^{a_4} \\ = C \cdot (1 - 3p)^{a_1} \cdot p^{a_2} \cdot p^{a_3} \cdot p^{a_4} = C \cdot (1 - 3p)^{a_1} \cdot p^{a_2 + a_3 + a_4}$$

som var det jeg skulle vise. da vi har at både 44 og a_i 'erne er reelle tal som ikke er afhængige af p.

3)

vi får altså oplyst en $\hat{p}$ og kan da regne de forventede værdier under H1

```
phat = (6+9+8)/132
forventedeH1 = n*c((1-3*phat), phat, phat, phat) #SKAL RETTES!
forventedeH1
```

```
## [1] 21.000000  7.666667  7.666667  7.666667
```

```
sum(forventedeH1)
```

```
## [1] 44
```

som altså så er mine 4 forventede værdier under H1.

4)

jeg skal nu teste hypotesen H1

```
frie_parametre = 1
n = 44

#beregner teststørrelse
Gobs = 2*sum((observerede*log(observerede/forventedeH1)))
Gobs
```

```
## [1] 0.625652
```

```
#beregner p-værdi
1-pchisq(Gobs,kasser-1-frie_parametre)
```

```
## [1] 0.7313771
```

så vi kan se at denne hypotese afvises ikke. og det kan altså godt antages at der er samme præference for de gamle smagsvarianter.

5)

for at finde maksimum likelihood-estimatet finder vi først log likelihood differentierer den og sætter lig 0 og kan så isolere p. vi har fra tidligere

$$L(p) = C \cdot (1 - 3p)^{a_1} \cdot p^{a_2 + a_3 + a_4}$$

log likelihood er da

$$l(p) = \ln(C) + a_1 \ln(1 - 3p) + (a_2 + a_3 + a_4) \ln(p)$$

differentier

$$\begin{aligned} l'(p) &= (a_1/(1 - 3p)) \cdot (-3) + (a_2 + a_3 + a_4)/p = 0 \\ \Leftrightarrow (a_2 + a_3 + a_4)/p &= 3a_1/(1 - 3p) \Leftrightarrow (a_2 + a_3 + a_4)(1 - 3p) = 3a_1p \\ \Leftrightarrow (a_2 + a_3 + a_4) - ((a_2 + a_3 + a_4)3 - 3a_1)p &= 0 \\ \Leftrightarrow p &= (a_2 + a_3 + a_4)/((a_1 + a_2 + a_3 + a_4) \cdot 3) \end{aligned}$$

da jeg har at $a_1 + a_2 + a_3 + a_4 = n$ pga multinomialmodellen så vi har altså

$$\hat{p} = (a_2 + a_3 + a_4)/(44 \cdot 3) = (a_2 + a_3 + a_4)/132$$

som var det jeg skulle vise.

opgave 3

1)

a)

hvilket boxplot hører til tikprøve D? vi kan i stikprøve D se at de 50% på y-aksen er cirka ved 4, det er der ikke nogen af de andre der har og derfor ved jeg så at det er boxplot nr. 2 der hører til stikprøve D.

b)

hvilken stikprøve stemmer overens med en uniformt fordelt variabel? det gør stikprøve B, da vi kan se at den har nogenlunde konstant hældning, og vi kan se at kvartilerne på y-aksen passer med hvor langt hen af x-aksen vi er gået. fx er 50% ved 3, og den går fra 1 til 5, samt at 25% og 75% er ved hhv. 2 og 4.

c)

hvilket boxplot stemmer overens med en normalfordelt stikprøve? når vi har en normalfordelt stikprøve vil vi forvente af størstedelen af målingerne ligger tæt på middelværdien og så falder de når man går væk derfra, nogenlunde ens på begge sider. det er derfor boxplot 4 der passer med en normalfordelt stikprøve, vi kan se at de midterste 50% ligger tæt og der er flere "outliers" som ligger lige meget over og under.

opgave 4

Overvej om der skal foretages et parret eller et uparret test og kørs testet med 10 000 tilfældige permutationer. Angiv til slut den faglige konklusion. note: parret er matched pairs test. i en matched pairs test kigger vi på at der ikke burde være forskel på middelværdien alt efter hvilken en man trækker fra den anden, den er god hvis man har lavet flere målinger på de samme mennesker, det er der her og jeg vil derfor mene at vi skal lave matched pairs test.

```
bilister <- read.csv("bilister.csv")
foer <- bilister$foer
efter <- bilister$efter

obs = mean(efter)-mean(foer)
d = efter - foer
n = length(d)
N <- 10^4 - 1
result <- numeric(N)
for (i in 1:N) {
  signs <- sample(c(-1,1),n,replace=TRUE) #med tilbagelægning!!
  result[i] <- mean(signs*d)
}

(sum(result >= obs) + 1)/(N + 1)
```

```
## [1] 0.0271
```

her er p-værdien så lille at hypotesen om at de har fælles middelværdi altså afvises, og da det er en ensidet test, hvor vi har testet at efter er større end før får vi altså at politiet måske har ret og der er en længere reaktionstid når man har drukket.

eksamen 2024 juni besvarelse

Nanna Liv Berdiin

2025-05-29

opgave 1

I denne opgave skal du analysere længden af 500 tilfældigt udvalgte tidsintervaller mellem to på hinanden følgende jordskælv med en styrke på 6 eller mere, som blev registreret i USA mellem 1970 og 2009. Intervallerne blev inddelt i 7 længdeklasser, og dataene er opsummeret i Tabel 1.

a)

Angiv et konfidensinterval for sandsynligheden for, at intervallet mellem to jordskælv er længere end 35 dage.

```
data <- c(96, 47, 64, 70, 67, 77, 79)
sand <- 79
n <- sum(data)
sand/ n
```

```
## [1] 0.158
```

```
#samt konfidensinterval for p
alpha = 0.05
prop.test(sand,n, conf.level = 1-alpha)$conf.int
```

```
## [1] 0.1277415 0.1936355
## attr(,"conf.level")
## [1] 0.95
```

så konfidensintervallet er altså, $[0.128, 0.194]$ for at intervallet mellem to jordskælv er længere end 35 dage.

b)

Tidsintervallet mellem to jordskælv modelleres ofte ved en eksponentialfordeling eller en gammafordeling. Når vi fitter en Gamma $\Gamma(r, \lambda)$ fordeling ved maksimum likelihood til data i Tabel 1, får vi $\hat{r} = 0.8557$ og $\hat{\lambda} = 0.0449$ (r betegner formparametren, og λ rateparametren). Eftervis, at det forventede antal af intervaller, der er længere end 35 dage, er 82.7, hvis tiderne følger gammafordelingen med de estimerede parametre ($\hat{r} = 0.8557$ og $\hat{\lambda} = 0.0449$)

```
forventede <- c(89.3, 62.9, 65.9, 63.1, 64.0, 72.1, 82.7)
```

jeg starter altså med at finde sandsynligheden under gammafordelingen og så gange med 500 som var antal observationer i alt.

```
ss_over35 <- 1-pgamma(35, shape = 0.8557, rate = 0.0449)
500*ss_over35
```

```
## [1] 82.65862
```

som var det jeg skulle vise at vi forventer 82.7 over 35.

c)

Lav et test for nulhypotesen, at data stammer fra en (uspecificeret) gammafordeling. Beregn p-værdien, og angiv konklusionen.

fordi vi har fået at vide at de forventede værdier er fået via maksimum likelihood kan vi lave en test for p-værdien

```
observerede <- data
kasser = 7
frie_parametre = 2
n = 500

#beregneteststørrelse
Gobs = 2*sum((observerede*log(observerede/forventede)))
Gobs
```

```
## [1] 6.315096
```

```
#beregnetp-værdi
1-pchisq(Gobs,kasser-1-frie_parametre)
```

```
## [1] 0.1768201
```

så vi får en p-værdi på 0.18 og vi afviser derfor ikke hypotesen om at data kommer fra en gammafordeling.

d)

I den næste delopgave undersøges på en anden måde, om data lige så godt kan modelleres med en eksponentialfordeling. Antag, at tidsintervallerne mellem to jordskælv kan modelleres med gammafordelingen $\Gamma(r, \lambda)$. Angiv et 95% konfidensinterval for parametren r , idet det antages, at maksimum likelihood estimatoren $\hat{r}$ er normalfordelt, $\hat{r} \sim N(r, SE(\hat{r})^2)$. Det oplyses, at standardfejlen for $\hat{r}$ er $SE(\hat{r}) = 0.0618$, og estimatet fra data var $\hat{r} = 0.8557$ Brug konfidensintervallet til at afgøre, om data svarer til en eksponentialfordeling (vink: eksponentialfordelingen er et specialtilfælde af gammafordelingen).

Vi har at for en normalfordeling for en estimator er et 95% konfidensintervallet som

$$[\bar{x} - 1.96 \cdot sd, \quad \bar{x} + 1.96 \cdot sd]$$

vi får altså

```
xbar <- 0.8557
sigma <- 0.0618
#så vi får
lower <- xbar - 1.96*sigma
upper <- xbar + 1.96*sigma
c(lower, upper)
```

```
## [1] 0.734572 0.976828
```

altså et konfidensinterval på $[0.734, 0.977]$ eksponentialfordelingen er et specialtilfælde af gammafordelingen hvor $r = 1$ så vi kan se at vi er tæt på det kan være en eksponentialfordeling, men at det nok ikke er.

opgave 2

a)

Vis, at maksimum-likelihood estimatoren er givet ved

$$\hat{\theta}_{mle} = 2n / (\sum_{i=1}^n X_i^2)$$

for at gøre dette bruger vi at

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n f(X_i; \theta) = \prod_{i=1}^n 2\theta^2 x^3 \exp(-\theta X_i^2) \\ &= (2\theta^2 x^3)^n \exp(-\theta \sum_{i=1}^n X_i^2) \end{aligned}$$

og vi kan derfor finde log likelihood, differentiere og sætte lig 0 og så isolere.

$$l(\theta) = n \cdot \ln(2) + 2n \cdot \ln(\theta) + 3n \cdot \ln(x) - \theta \sum_{i=1}^n X_i^2$$

differentier

$$l'(\theta) = 2n/\theta - \sum_{i=1}^n X_i^2 = 0 \Leftrightarrow \hat{\theta}_{mle} = 2n / (\sum_{i=1}^n X_i^2)$$

som var det jeg skulle vise.

b)

Er $\hat{\theta}_{mle}$ unbiased? Giv et kort teoretisk argument for dit svar. en unbiased estimator har

$$Bias(\hat{\theta}_{mle}) = E_{\theta}(\hat{\theta}_{mle}) - \theta = 0$$

vi kan nu bruge Jensens ulighed der siger: : lad G være en strengt konveks funktion og X en ikke degenereret stokastisk variabel, så er

$$E(g(x)) > g(E(X))$$

det betyder altså at vi har at

$$E(\hat{\theta}_{mle}) = E(2n/(\sum_{i=1}^n X_i^2)) > 2n/(\sum_{i=1}^n E(X_i^2))$$

vi kan nu bruge at vi fra opgaven har at

$$EX^2 = 2/\theta$$

som altså betyder at

$$2n/(\sum_{i=1}^n E(X_i^2)) = 2n/(\sum_{i=1}^n 2/\theta) = 2n(2n/\theta) = \theta$$

og vi har dermed vist at

$$E(\hat{\theta}_{mle}) > \theta$$

og dermed kan det altså ikke være unbiased.

c)

Angiv formelen for momentestimatoren, $\hat{\theta}_{mom}$. vi har fra opgaven at

$$E(X) = 3\sqrt{\pi}/(4\sqrt{\theta})$$

vi finder da $\hat{\theta}_{mom}$ ved at sætte den lig med det empiriske moment

$$M_1 = 1/n \cdot \sum_{i=1}^n X_i$$

Dette giver mig

$$\begin{aligned} 3\sqrt{\pi}/(4\sqrt{\theta}) &= 1/n \cdot \sum_{i=1}^n X_i \\ \Leftrightarrow (4\sqrt{\theta}) \cdot \sum_{i=1}^n X_i &= 3n\sqrt{\pi} \Leftrightarrow \sqrt{\theta} = 3n\sqrt{\pi}/(4 \sum_{i=1}^n X_i) \\ \Leftrightarrow \hat{\theta}_{mom} &= (3n\sqrt{\pi}/(4 \sum_{i=1}^n X_i))^2 \end{aligned}$$

som så er momentestimatoren.

c)

Lav et skøn over bias og MSE for begge estimatorer ved simulation, i tilfældet $\theta = 5$ og stikprøvestørrelse $n = 10$. I simulationen skal du lave $Nsim = 10000$ gentagelser af stikprøven. Til simuleringen kan du uden bevis benytte, at $X_i = Z_i, i = 1, \dots, n$, hvor Z_i har en Gamma fordeling med formparameter $\alpha = 2$ og rateparameter $\beta = \theta$, det vil sige, $Z_i \sim \Gamma(2, \theta)$. • Beskriv kort dine resultater — hvilken estimator har den mindste bias, hvilken har den mindste MSE? • Gentag derefter simuleringen for $n = 100$. Ser du væsentlige ændringer når stikprøvestørrelsen øges?

jeg estimerer da

```

theta = 5
n = 10
Nsim = 10000
alpha = 2
theta_mle <- numeric(Nsim)
theta_mom <- numeric(Nsim)
for (i in 1:Nsim){
  Z <- rgamma(n, shape=alpha, rate = theta)
  X <- sqrt(Z)
  theta_mle[i] <- 2*n/(sum(X^2))
  theta_mom[i] <- (3*n*sqrt(pi)/(4*sum(X)))^2
}
mean(theta_mle)

```

```
## [1] 5.239611
```

```
mean(theta_mom)
```

```
## [1] 5.182883
```

```
c("bias theta_mle:", mean(theta_mle)-5)
```

```
## [1] "bias theta_mle:" "0.239611143435241"
```

```
c("bias theta_mom:", mean(theta_mom)-5)
```

```
## [1] "bias theta_mom:" "0.18288314626808"
```

```
c("MSE theta_mle:", mean((theta_mle-theta)^2))
```

```
## [1] "MSE theta_mle:" "1.53286758214503"
```

```
c("MSE theta_mom:", mean((theta_mom-theta)^2))
```

```
## [1] "MSE theta_mom:" "1.53597302490662"
```

eftersom theta er 5 ser vi altså at da bias ad mle er 0,27 og bias af mom er 0,22 (disse er simulerede så ikke sikkert de passer perfekt med det den gemmer dem med, kan være kørt igen!) så har mom altså det mindste bias. vi kan dog se at mle har et lidt mindre MSE på 1.63 modsat 1.64 for mom.

vi skal også køre den for n=100:

```

theta = 5
n = 100
Nsim = 10000
alpha = 2
theta_mle <- numeric(Nsim)
theta_mom <- numeric(Nsim)
for (i in 1:Nsim){

```

```

Z <- rgamma(n, shape=alpha, rate = theta)
X <- sqrt(Z)
theta_mle[i] <- 2*n/(sum(X^2))
theta_mom[i] <- (3*n*sqrt(pi)/(4*sum(X)))^2
}
mean(theta_mle)

```

```
## [1] 5.027145
```

```
mean(theta_mom)
```

```
## [1] 5.021403
```

```
c("bias theta_mle:", mean(theta_mle)-5)
```

```
## [1] "bias theta_mle:"      "0.0271450916213549"
```

```
c("bias theta_mom:", mean(theta_mom)-5)
```

```
## [1] "bias theta_mom:"      "0.0214031220657791"
```

```
c("MSE theta_mle:", mean((theta_mle-theta)^2))
```

```
## [1] "MSE theta_mle:"      "0.129238303106947"
```

```
c("MSE theta_mom:", mean((theta_mom-theta)^2))
```

```
## [1] "MSE theta_mom:"      "0.13532598020969"
```

her ser vi at de går mod hinanden. det er stadig mom med mindste bias og mle med mindste MSE.

opgave 3


a)

Nedenunder ser I kode og output fra et simulationseksperiment vedrørende R-funktionen `var.test`. Denne funktion giver resultatet af et F-test for nulhypotesen, at to stikprøver kommer fra populationer med identisk varians, mod alternativet, at varianserne er forskellige.

```

Nsim <- 10000
pval <- numeric(Nsim)
for (i in 1:Nsim){
  x1 <- rt(20, 3)
  x2 <- rt(10, 3)
  pval[i] <- var.test(x1, x2)$p.value
}
plot(ecdf(pval))

```



Læs koden og besvar de følgende spørgsmål: • Findes der nogen forudsætninger for F-testet, som ikke er opfyldt i simulationen, og hvis ja, hvilke forudsætninger er det? • Simuleres fra nulhypotesen eller fra alternativhypotesen?

ja var.test tester two samples fra en normalfordeling, og dette er fra en t-fordeling, så vi tester altså ikke under de rigtige vilkår. vi simulerer fra en t-fordeling som begge har 3 frihedsgrader, de har altså samme varians men det er ikke fordi vi som sådan kan bruge det til noget i den test vi sidder med.

b)

Hvor stor er, ifølge ecdf-plottet, den estimerede sandsynlighed for at forkaste hypotesen om ens varians i simulationseksperimentet, hvis vi forkaster når p-værdien er mindre end 0.05? Angiv, hvilken af de følgende svarmuligheder passer bedst: (i) ca. 0.05, (ii) > 0.90 , (iii) ca. 0.25, (iv) < 0.01 , (v) noget helt andet, (vi) kan ikke aflæses af den slags diagram. Hvis dit svar er (v), så angiv også sandsynligheden som du aflæser.

så vi skal altså aflæse x-værdien når y-værdien er 0.95 fordi så har vi at vi forkaster den hvis vi er over. dette giver os noget lidt over 0.90 og derfor er det rigtige svar (ii)

opgave 4

Forskere undersøgte, om æggenes piskeevne afhænger af produktionstypen (buræg, skrabeæg og økologiske æg). Som et mål for æggenes piskeevne registrerede de volumen af skummet, der blev produceret ved piskning af æg, som en procentdel af den oprindelige æggehvite. Da de forventede, at ægstørrelsen havde indflydelse på skumvolumen, gentog de målingerne med æg i to størrelser, M og L. For hver kombination af produktionstype og størrelse blev 10 æg undersøgt. Data findes i filen aeg.csv og indeholder variablerne

skumvol (skumvolumen i procent), stor (ægstørrelse) og type (produktionstype). Brug signifikansniveauet $\alpha = 0.05$ i analysen af data.

a)

Opstil en statistisk model for data, hvor skumvolumen har en normalfordeling, hvor middelværdi og varians afhænger af kombinationen af produktionstype og ægstørrelse. Undersøg grafisk, om normalfordelingsantagelsen passer.

modellen med hver sin middelværdi og varians:


$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2), i = 1, 2, 3, 4, 5, 6, j = 1, \dots, 10$$

altså at der er 6 grupper fordi der er en gruppe for både mellem og store æg for hver af de tre typer af æg. jeg loader data og tjekker grafisk


```
aeg <- read.csv("aeg.csv", stringsAsFactors = TRUE)
respons_variabel <- aeg$skumvol
antal <- 6

#find residualer
lmfit <- lm(respons_variabel ~ aeg$type*aeg$stor)
residualer <- lmfit$residuals

#lav qqplot over residualerne
qqnorm(residualer, col = "purple2")
qqline(residualer, col = "green3")
```



```
boxplot(respons_variabel ~ aeg$type*aeg$stor, col = rainbow(antal))
```



vi kan se fra residualerne at det ser rimelig normalfordelt ud, men ikke helt perfekt, dette kan være fordi de ikke har ens varians som vi stadig ikke har vist. på boxplots ligner det ihvertfald at det er ret tydeligt at de har forskellig middelværdi og varians, men ellers kan de godt være normalfordelte. note: husk her at vi måske burde lave 6 forskellige plots med hver af modellerne!

b)

Vis ved et test, at det kan antages, at der er samme varians i alle 6 grupper.

hypotesen om at variansen er ens

$$H_{0\sigma^2} : \sigma_i^2 = \sigma^2, i = 1, 2, 3, 4, 5, 6$$

vi kører her bartlett.test, jeg skal lige skrive de 6 forskellige op dog

```
bartlett.test(aeg$skumvol ~ interaction(aeg$type,aeg$stor))
```

```
##
## Bartlett test of homogeneity of variances
##
## data: aeg$skumvol by interaction(aeg$type, aeg$stor)
## Bartlett's K-squared = 4.3553, df = 5, p-value = 0.4995
```

så da $p=0.5$ afviser vi altså ikke hypotesen om ens varians. modellen med hver sin middelværdi og ens varians:

$$M_0 : X_{ij} \sim N(\mu_i, \sigma^2), i = 1, 2, 3, 4, 5, 6, j = 1, \dots, 10$$

c)

I hvad følger betegner vi modellen med ens varians som M1. Angiv et 95% konfidensinterval for standardafvigelsen σ i modellen M1.

vi har fra formel 2.17 i de supplerende noter at vi kan finde konfidensintervallet af σ med

$$[fs^2(X)/(\chi^2_{1-\alpha/2}(f)), fs^2(X)/(\chi^2_{\alpha/2}(f))]$$

vi kan aflæse s i summary

```
summary(lmfit)
```

```
##
## Call:
## lm(formula = respons_variabel ~ aeg$type * aeg$stor)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.700  -6.850   0.300   5.225  21.700
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      480.300      3.181  150.988 < 2e-16 ***
## aeg$typeoeko       53.000      4.499   11.781 < 2e-16 ***
## aeg$typeskrabe     36.700      4.499    8.158 5.49e-11 ***
## aeg$storM          2.500      4.499    0.556  0.5807
## aeg$typeoeko:aeg$storM -13.400      6.362   -2.106  0.0398 *
## aeg$typeskrabe:aeg$storM -6.800      6.362   -1.069  0.2899
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.06 on 54 degrees of freedom
## Multiple R-squared:  0.8115, Adjusted R-squared:  0.7941
## F-statistic: 46.5 on 5 and 54 DF,  p-value: < 2.2e-16
```

så jeg har altså

```
s = 10.06
antal_obs = 60
alpha = 0.05

f = antal_obs-1
lower <- f*s^2/qchisq(1-alpha/2, df = f)
upper <- f*s^2/qchisq(alpha/2, df = f)

c(sqrt(lower), sqrt(upper))
```

```
## [1]  8.527199 12.269799
```

som altså betyder at et 95% konfidensinterval for σ , standardafvigelsen er [8.53, 12.30]. Note: tror ikke den her er rigtig, har forskellige antal degrees of freedom.

d)

Opskriv hypotesen, at modellen M1 kan reduceres til den additive model M2, hvor middelværdien af skumvolumen er summen af et bidrag fra produktionstype og et bidrag fra ægstørrelse. Undersøg grafisk, om data kan forklares ved en additiv model. Lav så et test for hypotesen, at M1 kan reduceres til M2.

jeg har altså hypotesen

$$H_{0\mu} : \mu_i = \alpha_i + \beta_l, i = 1, 2, 3, l = 1, 2$$


hvor i er de 3 produktionstyper og l er de to ægstørrelser. jeg vil altså gerne vise modellen

$$M_2 : X_{ilj} \sim N(\alpha_i + \beta_l, \sigma^2), \quad i = 1, 2, 3, \quad l = 1, 2, \quad j = 1, \dots, 10$$

for den grafiske undersøgelse laver jeg residualplot

```
lmfit_m2 <- lm(respons_variabel ~ aeg$type + aeg$stor)
residualer <- lmfit_m2$residuals

#lav qqplot over residualerne
qqnorm(residualer, col = "purple2")
qqline(residualer, col = "green3")
```



vi kan se at residualerne her er endnu pængere og liger de passer rigtig godt til denne model.

jeg sammenligner så med anova for at tjekke om jeg kan reducere modellen

```
anova(lmfit_m2,lmfit)
```

```
## Analysis of Variance Table
##
## Model 1: respons_variabel ~ aeg$type + aeg$stor
## Model 2: respons_variabel ~ aeg$type * aeg$stor
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      56 5913.2
## 2      54 5464.3  2    448.93 2.2183 0.1186
```

her er p-værdien 0.12 og jeg afviser altså ikke hypotesen om at modellen kan reduceres yderligere.

e)

Undersøg, om modellen M2 kan reduceres yderligere. Husk at angive den faglige konklusion.

jeg skal undersøge om jeg kan reducere mere, her ville jeg for eksempel prøve på at reducere hvor det kun er enten produktion eller størrelse der har betydning og se om vi kan reducere til en af de to modeller, og i sidste ende måske tjekke om jeg kan reducere til modellen hvor det bare er en normalfordelt række så det ikke er afhængigt af hverken produktionsmetode eller størrelse, kun hvis de andre ikke afvises.

jeg skriver begge modellerne op og tjekker med anova.

```
lmfit_prod <- lm(respons_variabel ~ aeg$type)
lmfit_str <- lm(respons_variabel ~ aeg$stor)
anova(lmfit_prod,lmfit)
```

```
## Analysis of Variance Table
##
## Model 1: respons_variabel ~ aeg$type
## Model 2: respons_variabel ~ aeg$type * aeg$stor
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      57 6182.0
## 2      54 5464.3  3    717.75 2.3643 0.0812 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(lmfit_str,lmfit)
```

```
## Analysis of Variance Table
##
## Model 1: respons_variabel ~ aeg$stor
## Model 2: respons_variabel ~ aeg$type * aeg$stor
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1      58 28723.8
## 2      54  5464.3  4    23260 57.464 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

jeg kan se at for modellen hvor det kun er produktionstype afvises min hypotese ikke, men hvor det kun er størrelse afvises min hypotese. dette ville også tyde på at jeg altså ikke kan fjerne afhængigheden af produktionstype.

```
lmfit_0 <- lm(respons_variabel ~ 1)
anova(lmfit_0,lmfit)
```

```
## Analysis of Variance Table
##
## Model 1: respons_variabel ~ 1
## Model 2: respons_variabel ~ aeg$type * aeg$stor
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1      59 28992.6
## 2      54  5464.3   5    23528 46.503 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

her kan vi se at vi ikke kan reducere til modellen hvor produktionstype ingen betydning har.

den faglige konklusion er da at produktionstype har indflydelse på volumen af skum af piskede æg, men det har størrelsen ikke nødvendigvis.

eksamen 2024 august besvarelse

Nanna Liv Berdiin

2025-05-30

opgave 1

En bestemt behandling gives højst to gange til en patient. Lykkes behandlingen ikke i første forsøg, får patienten endnu en behandling. Der er altså tre mulige udfald for en patient: S, behandlingen lykkes i første forsøg, FS, behandlingen mislykkes i første men lykkes i andet forsøg, og FF, behandlingen mislykkes i begge forsøg. Vi ser her på resultatet af behandlingen for 120 personer, som blev

```
observerede <- c(78, 30, 12)
```

Lad θ_1 være sandsynligheden for at den første behandling lykkes, og lad θ_2 være den betingede sandsynlighed for at den anden behandling lykkes, givet at den første behandling mislykkes. Antag, at vi som model for de observerede antal kan benytte multinomialmodellen

$$M_0 : (X_1, X_2, X_3) \sim \text{Multinom}(120, (p_1, p_2, p_3)),$$

hvor

$$(p_1, p_2, p_3) = (\theta_1, (1 - \theta_1)\theta_2, (1 - \theta_1)(1 - \theta_2)).$$

Der skal først undersøges, om sandsynligheden for succes er den samme for den første og den anden behandling. Betragt altså hypotesen

$$H_0 : \theta_1 = \theta_2$$

a)

Gør rede for, at likelihood funktionen under H_0 er

$$L(\theta) = \binom{120}{x_1 \ x_2 \ x_3} \theta^{x_1+x_2} (1-\theta)^{x_2+2x_3},$$

hvor θ er den fælles værdi af θ_1 og θ_2 .

dette skal jeg gøre rede for. jeg indsætter altså i den generelle likelihoodfunktion med 3 kasser som vi har her:

$$L(\pi) = \binom{120}{a_1 \cdot a_2 \cdot a_3} \cdot \pi_1^{a_1} \cdot \pi_2^{a_2} \cdot \pi_3^{a_3}$$

så indsætter jeg mine givne værdier for sandsynlighederne fra opgaven

$$\begin{aligned} &= C \cdot (\theta_1)^{a_1} \cdot ((1 - \theta_1)\theta_2)^{a_2} \cdot ((1 - \theta_1)(1 - \theta_2))^{a_3} \\ &= C \cdot \theta^{a_1} \cdot ((1 - \theta)\theta)^{a_2} \cdot ((1 - \theta)(1 - \theta))^{a_3} \end{aligned}$$

hvor C er en konstant uafhængig af theta

$$= C \cdot \theta^{a_1+a_2} \cdot (1 - \theta)^{a_2+2 \cdot a_3}$$

som var det jeg skulle vise.

b)

Vis, at maksimum likelihood estimatet for den fælles værdi $\theta = \theta_1 = \theta_2$ under H_0 er

$$\hat{\theta} = \frac{x_1 + x_2}{2 \cdot 120 - x_1}$$

altså den relative frekvens af de vellykkede behandlinger, $x_1 + x_2$, blandt de ialt $2 \cdot 120 - x_1$ udførte behandlinger. Vis desuden, at de forventede antal, e_1 , e_2 og e_3 , under H_0 med tre decimalers nøjagtighed er

$$(e_1, e_2, e_3) = (80.000, 26.667, 13.333)$$

for at bevise maksimum likelihood estimatet bruger jeg likelihoodfunktionen fra ovenover, finder log likelihood, differentierer sætter lig 0 og isolerer theta. log likelihood funktionen er

$$l(\theta) = \log(C) + (a_1 + a_2)\log(\theta) + (a_2 + 2 \cdot a_3)\log(1 - \theta)$$

differentier

$$l'(\theta) = (a_1 + a_2)/\theta - (a_2 + 2a_3)/(1 - \theta) = 0 \Leftrightarrow \theta(a_2 + 2a_3) = (a_1 + a_2)(1 - \theta)$$

$$\Leftrightarrow \theta(a_2 + 2a_3) + (a_1 + a_2)\theta = a_1 + a_2 \Leftrightarrow \theta(2a_2 + 2a_3 + a_1) = a_1 + a_2$$

nu bruger vi så at $a_1 + a_2 + a_3 = 120$ så vi får da

$$\hat{\theta} = (a_1 + a_2)/(2a_2 + 2a_3 + a_1) = (a_1 + a_2)/(2 \cdot 120 - a_1)$$

som var det jeg skulle vise. derudover skal jeg finde de forventede under H_0 , jeg kan her beregne thetahat og så finde dem

```
n <- 120
thetahat <- (78+30)/(2*120-78)
thetahat
```

```
## [1] 0.6666667
```

```
forventede <- n*c(thetahat, (1-thetahat)*thetahat, (1-thetahat)*(1-thetahat))
forventede
```

```
## [1] 80.00000 26.66667 13.33333
```

så jeg får altså at de forventede med 3 decimalers nøjagtighed er (80.000, 26.667, 13.333)

c)

Test hypotesen H_0 og fortolk resultatet i forhold til problemstillingen.

```
kasser = 3 #antal kasser de kan falde i
frie_parametre = 1 #antal frie parametre i modellen

#beregner teststørrelse:
Gobs = 2*sum((observerede*log(observerede/forventede)))

#beregner p-værdi
1-pchisq(Gobs,kasser-1-frie_parametre)
```

```
## [1] 0.4429022
```

så jeg får en p-værdi på 0.44 som altså betyder at vi ikke afviser hypotesen om ens at vi bare har en parameter θ . dette svarer så til en fast-rate hypotese vi har vist og så har vi en fast-rate model.

d)

Fra tidligere erfaringer formodes, at sandsynligheden for, at behandling lykkes, er 0.75, uanset om der er tale om første eller andet forsøg. I modellen M_0 svarer det til hypotesen

$$H_0^* = \theta_1 = \theta_2 = 0.75$$

så jeg skal altså lave samme udregning som ovenover med en ny theta

```
thetany <- 0.75
forventede1 <- n*c(thetany, (1-thetany)*thetany, (1-thetany)*(1-thetany))
kasser = 3 #antal kasser de kan falde i
frie_parametre = 0 #antal frie parametre i modellen

#beregner teststørrelse:
Gobs = 2*sum((observerede*log(observerede/forventede1)))

#beregner p-værdi
1-pchisq(Gobs,kasser-1-frie_parametre)

## [1] 0.04466166
```

så her får jeg en p-værdi på 0.045 som er lige under den grænse vi normalt ville bruge på 0.05 så jeg ville afvise hypotesen, hvis vi har et lavere alpha ville den dog ikke blive afvist.

opgave 2

Lad $X_1, \dots, X_n$ være i.i.d. kontinuert fordelte variable med tæthed givet ved

$$f(x; \alpha, \beta) = \begin{cases} \alpha\beta^\alpha x^{-(\alpha+1)}, & x \geq \beta, \\ 0, & x < \beta, \end{cases}$$

hvor $(\alpha, \beta) \in (0, \infty)^2$ er ukendte parametre.

a)

Gør rede for, at maksimum likelihood estimatoren for β er givet ved

$$\hat{\beta} = \min(x_1, \dots, x_n)$$

Er estimatoren unbiased, eller har den en positiv eller negativ bias? Giv en kort begrundelse for dit svar.

vi kan se på tæthedsfunktionen at der er ingen x under β og derfor giver det altså mening at bedste bud på β altså er den laveste målte værdi, fordi hvis vi valgte en over ved vi altså at den ikke ville være den rigtige, fordi vi ved der er en lavere som alt i alt må være tættere på β . vi ved at den enten har positiv bias eller er unbiased, og højest sandsynligt har den positiv bias. dette er fordi bias er

$$\text{bias}(\hat{\theta}) = E_{\theta}(\hat{\theta}) - \theta$$

vi må altså have at

$$E_{\theta}(\hat{\theta}) \geq \theta$$

og jeg vil derfor antage at den har positiv bias.

b)

Antag nu, at parametren β er kendt. Udled likelihoodligningen for maksimum likelihood estimatoren for α , og gør rede for, at estimatoren er givet ved

$$\hat{\alpha} = \frac{n}{\sum_{i=1}^n \log(x_i/\beta)}$$

Er estimatoren unbiased, eller har den en positiv eller negativ bias? Giv en kort begrundelse for dit svar. Der oplyses, at $E(\log(X_1/\beta)) = 1/\alpha$

likelihoodligningen er produktet for dem alle

$$L(\alpha; \mu) = \prod_{i=1}^n \alpha \beta^\alpha x_i^{-(\alpha+1)} = \alpha^n \beta^{n\alpha} \prod_{i=1}^n x_i^{-(\alpha+1)}$$

log likelihood

$$l(\alpha) = n \log(\alpha) + n \alpha \log(\beta) - (\alpha + 1) \sum_{i=1}^n \log(x_i)$$

differentier

$$l'(\alpha) = n/\alpha + n \log(\beta) - \sum_{i=1}^n \log(x_i) = 0$$

$$\Leftrightarrow n/\alpha + n \log(\beta) = \sum_{i=1}^n \log(x_i) \Leftrightarrow n = \alpha \left(\sum_{i=1}^n \log(x_i) - n \log(\beta) \right)$$

vi bruger nu en logaritmeregneregler der siger

$$\log(a/b) = \log(a) - \log(b)$$

i den modstatte rækkefølge og indsætter i summen (herfra forsvinder n.

$$\Leftrightarrow \hat{\alpha} = n / \left(\sum_{i=1}^n \log(x_i/\beta) \right)$$

som var det jeg skulle vise. jeg skal også kigge på om estimatoren er unbiased eller biased. her har jeg fået at vide at $E(\log(X_1/\beta)) = 1/\alpha$ jeg kan her bruge Jensens ulighed der siger

$$E(g(x)) > g(E(X))$$

altså at

$$E(\hat{\alpha}) = E\left(n / \left(\sum_{i=1}^n \log(x_i/\beta) \right)\right) > n / \left(\sum_{i=1}^n E(\log(x_i/\beta)) \right) = n / \left(\sum_{i=1}^n 1/\alpha \right) = n / (n/\alpha) = \alpha$$

så dermed har vi altså

$$E(\hat{\alpha}) > \alpha \Rightarrow \text{bias}(\hat{\alpha}) > 0$$

og vi ser altså at α har positiv bias.

opgave 3

Gordon Moore var medstifter af virksomheden Intel, der fremstiller mikroprocessorer til computere. Omkring 1975 formulerede Moore en forudsigelse om, at antallet af transistorer i mikroprocessorer vil fordobles hvert andet år. Forudsigelsen kaldes ofte "Moore's lov", som opgaven her vedrører. Figur 1 viser et scatterplot af

logaritmen til antallet mod året. Figur 1: Den naturlige logaritme til antallet af transistorer tegnet op mod året, samt regressionslinje. Datasættet Intel.csv indeholder variablerne Processor (processornavn), Year (udgivelsesår) og Transistors (antal af transistorer i processoren) for de 30 processorer vist i figuren ovenover. Lad x_i og y_i betegne henholdsvis året og logaritmen af antallet svarende til det i -te år, $i = 1, \dots, 30$. Figur 1 strider ikke mod rimeligheden af en lineær regression af logantal på året, det vil sige af modellen

$$M_1 : Y_i \sim N(\alpha + \beta \cdot x_i, \sigma^2), \quad i = 1, \dots, 30$$

som betragtes i det følgende.

a)

Angiv estimat og 95% konfidensinterval for såvel afskæringen som hældningen i model M_1 .

jeg indlæser data opskriver modellen og finder 95% konfidensinterval for hældning og skæring, vi husker at vi skal have logaritmen her af den forklarende variabel og vi tæller år fra 1971 som er år 1

```
intel <- read.csv("Intel.csv")
intel$logtransistors <- log(intel$Transistors)
intel$year0 <- intel$Year - 1970

respons_variabel <- intel$logtransistors
forklarende_variabel <- intel$year0

lmfit <- lm(respons_variabel ~ forklarende_variabel)
confint(lmfit)
```

```
##                2.5 %    97.5 %
## (Intercept)      6.8999839 8.3128207
## forklarende_variabel 0.3103269 0.3525611
```

så vi får at for skæringen har vi 95% konfidensinterval på $[6.90, 8.31]$ og for hældningen $[0.31, 0.35]$

b)

Gør rede for, at ifølge den lineære regressionsmodel M_1 vokser antallet af transistorer med en faktor $\exp(2\beta)$ i en toårsperiode.

vi skal huske at den model vi har fundet er for logaritmen til transistorerne, så hvis den vokser med β på logaritmeskalaen vokser den altså med $\exp(\beta)$ når vi ikke er på logaritmeskalaen, så over en toårig periode ville den jo så vokse med 2β på logartimeskalaen og dermed vokser antallet af transistorer med $\exp(2\beta)$ over en toårig periode.

c)

```
lower <- exp(2*0.3103269)
upper <- exp(2*0.3525611)
c( lower, upper)
```

```
## [1] 1.860144 2.024094
```

så vi ser altså at da dette er hældningen over 2 år passer det så meget godt med at antallet fordobles på 2 år.

opgave 4

For at teste hypotesen, om to stikprøver kommer fra populationer med samme varians, kan der bruges et tosidet F-test, eller et tilsvarende permutationstest, hvor der bruges ratio mellem de to stikprøvevarianser som teststørrelse. Ved begge tests antages, at observationerne er uafhængige. Der findes dog yderlige forudsætninger, som skal opfyldes, for at sikre, at signifikansniveauet overholdes. Ute har lavet et simulationsstudie for at vurdere, om de to tests er passende for at teste ens varians i fire forskellige scenarier. Tabel 1 nedenunder viser koden som er brugt til at simulere to stikprøver x_a og x_b . For hver simulation af to stikprøver beregnes p-værdien fra F-test og p-værdien fra permutationstestet med 9999 permutationer. Baseret på 50000 simulationer af to stikprøver estimeres så sandsynligheden for, at p værdien pobs er mindre end 0.05. Denne sandsynlighed kaldes $\hat{\alpha}$ i tabellen. Tabel 1: Kode til simulation af stikprøver i fire scenarier, samt estimerede sandsynligheder for at få en p-værdi på 0.05 eller mindre, ved et almindeligt F-test og et permutationstest. Sandsynligheder rundet til 3 decimaler.

a)

Forklar simulationsresultaterne i tabel 1 for hver af de fire scenarier, ved at overveje følgende spørgsmål for F-testet og permutationstestet: • simuleres fra testets nulhypotese? • er alle forudsætninger opfyldt?

jeg går igennem de 4 test: i) her simuleres fra nulhypotesen, de har ens varians, alt er opfyldt, vi simulerer fra normalfordelingen og jeg antager at stikprøverne er udvalgt tilfældigt.

ii) her simuleres fra nulhypotesen, de har ens varians, alt er opfyldt, vi simulerer fra normalfordelingen og jeg antager at stikprøverne er udvalgt tilfældigt.


iii) her simuleres fra den alternative hypotese, de har ikke samme varians, det er stadig normalfordelingen dog.

iv) dette er nulhypotesen om ens varians, men det er ikke normalfordelingen vi simulerer fra.

b)

Filen sim.csv indeholder et af de simulerede datasæt. Data er gemt som en tabel med to søjler: x indeholder de numeriske værdier, og grp angiver, hvilken stikprøve, a eller b, de tilhører. Undersøg ved boxplot og normalfraktildiagrammer, hvilket af de fire ovenstående scenarier data må formodes at stamme fra. Giv så en anbefaling: hvilket test der bør anvendes for at undersøge, om varianserne er ens i begge populationer.


```
sim <- read.csv("sim.csv", stringsAsFactors = TRUE)
boxplot(sim$x ~ sim$grp, col = rainbow(2))
```



```
xa <- subset(sim, grp == "a")
xb <- subset(sim, grp == "b")


qqnorm(xa$x, col = "skyblue2")
qqline(xa$x, col = "blue2")
```

Normal Q-Q Plot




```
qqnorm(xb$x, col = "pink")  
qqline(xb$x, col = "red")
```

Normal Q-Q Plot



```
plot(sim$x, col = sim$grp)
```



vi kan se at for begge simulationer er der ingen værdier under 0, det ligner de har enten samme middelværdi eller meget tæt på hinanden. ud fra boxplot ser vi at middelværdien ser ud til at være 1 for begge grupper. vi kan derfor udelukke både (i), (ii) og (iii) da de ikke har middelværdier der passer til data. det ser altså ud til at jeg kun har (iv) tilbage. hvis jeg prøver at køre denne kan jeg også se at man ikke får værdier under 0, samt at hvis jeg kører den et par gange ligger de og svinger omkring mit dataeksempel.


```
xatest <- rlnorm(20, 0, 1)
xbtest <- rlnorm(30, 0, 1)
mean(xatest)
```

```
## [1] 1.926031
```

```
mean(xbtest)
```

```
## [1] 1.906326
```

```
boxplot(xatest, xbtest, col = rainbow(2))
```



dette giver også mening ud fra mine qqplots hvor jeg ser en rimelig tydelig systematisk afvigelse som vi ville forvente hvis det ikke er simuleret fra en normalfordeling.

jeg syntes man burde bruge en F-test da den giver høj sandsynlighed for lav p-værdi (som ville gøre vi afviste hypotesen om ens varians) for de to modeller der enten har forskellig varians eller ikke er en normalfordeling.

c)

Beregn p-værdien i det almindelige F-test og permutations-F-testet for datasættet i sim.csv fra delopgave (b). Hvilken p-værdi ville du indrapportere?

ført den almindelige F-test med en bartlett test.

```
var.test(xa$x,xb$x)
```

```
##
## F test to compare two variances
##
## data:  xa$x and xb$x
## F = 0.37418, num df = 19, denom df = 29, p-value = 0.02872
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.1676963 0.8987500
## sample estimates:
## ratio of variances
##      0.3741763
```

her afviser vi hypotesen om ens varians da p-værdien er 0.029, dette er fordi det ikke er en normalfordeling vi simulerer fra. så en permumations-F-test:

```
obj <- sim$x

obs = var(xa$x)/var(xb$x)
oneofthem = xa$x

N <- 10^4 - 1
result <- numeric(N)
for (i in 1:N) {
  index <- sample(length(obj), size = length(oneofthem), replace = FALSE)
  result[i] <- var(obj[index])/var(obj[-index])
}

#og finder p-værdien
pval = (2*min(sum(result < obs),sum(result >= obs)) + 1) / (N+1)
pval
```

```
## [1] 0.6019
```

her bliver hypotesen heller ikke afvist.

vi vil gerne bruge permutationstesten her da vores data ikke er normalfordelte og dermed er F-testen ikke troværdig.