
Opgavesamling til Matematisk Statistik

Lars Nørvang Andersen



Udgave: 10. april 2025

© Lars Nørvang Andersen

Institut for Matematiske Fag
Det Naturvidenskabelige Fakultet
Aarhus Universitet
April 2025

Indhold

1 Opgaver	1
Litteratur	59

Kapitel 1

Opgaver

Opgave 1.1 Betragt modellen for to uafhængige normalfordelte observationsrækker med ens varians

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed}$$

og lad x_{ij} , $i = 1, 2$, $j = 1, \dots, n_i$ betegne udfald fra M_1 . I denne opgave vises de maksimeringsresultater, som omtales i Afsnit 3.1 ved at benytte profilmaksimering som omtalt i Afsnit 2.3.

1° Vis, at likelihoodfunktionen og log likelihoodfunktionen er givet ved henholdsvis

$$L(\mu_1, \mu_2, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left(-\frac{1}{2\sigma^2} \left(\sum_{i=1}^{n_1} (x_{1i} - \mu_1)^2 + \sum_{i=1}^{n_2} (x_{2i} - \mu_2)^2 \right) \right).$$

og

$$\ell(\mu_1, \mu_2, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \left(\sum_{i=1}^{n_1} (x_{1i} - \mu_1)^2 + \sum_{i=1}^{n_2} (x_{2i} - \mu_2)^2 \right)$$

2° Vis, at for σ^2 holdt fast har $L(\mu_1, \mu_2, \sigma^2)$ unikt maksimum for $\mu_1 = \bar{x}_1$. og $\mu_2 = \bar{x}_2$.


På grund af resultatet i 2° indfører vi nu

$$\begin{aligned} \tilde{L}(\sigma^2) = L(\bar{x}_1, \bar{x}_2, \sigma^2) &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left(-\frac{1}{2\sigma^2} \left(\sum_{i=1}^{n_1} (x_{1i} - \bar{x}_1)^2 + \sum_{i=1}^{n_2} (x_{2i} - \bar{x}_2)^2 \right) \right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left(-\frac{1}{2\sigma^2} (\text{SSD}_{(1)} + \text{SSD}_{(2)}) \right) \end{aligned}$$

3° Vis, at maksimum for $\tilde{L}$ er

$$\hat{\sigma}^2 = \frac{\text{SSD}_{(1)} + \text{SSD}_{(2)}}{n}$$

Opgave 1.2 I denne opgave udledes forskellige nyttige egenskaber for tætheden f i $N(\mu, \sigma^2)$ -fordelingen. I delspørgsmål 2° skal I finde f s vendepunkter, d.v.s. de lokale ekstrema for f' .



Figur 1.1: Stiliseret fremstilling af tætheden i normalfordelingen.

- 1° Find kurvens maksimum (x - og y -værdien).
- 2° Bestem vendepunkter, samt deres y -værdi. Hvor højt ligger vendepunkter i forhold til maksimum?

Det er også meget nyttigt at vide, hvilke værdier fra en $N(\mu, \sigma^2)$ fordeling er “store” eller “små”. Lad $X_1, \dots, X_{100}$ være en stikprøve fra $N(\mu, \sigma^2)$ fordelingen, dvs, de er uafhængige, identisk fordelte stokastiske variable. Lad

$$M(t) = \mathbb{E} \left[\sum_{i=1}^{100} \mathbb{1}_{[-t, t]}(X_i - \mu) \right].$$

(Forklaringen til symbolet $\mathbb{1}$ i appendikset til de supplerende noter.)

- 3° Gør rede for, at $M(t)$ er den forventede antal af værdier i stikprøven, der ligger mellem $\mu - t$ og $\mu + t$.
- 4° Vis, at $M(\sigma) \approx 68$, $M(\frac{5}{3}\sigma) \approx 90$ og $M(2\sigma) \approx 95$ (se Figur 1.1).
- 5° Find t således, at $M(t) = 50$ – det kan nogle gange også være nyttigt at vide, det svarer da til det centrale område, der indeholder halvdelen af udfald af en normalfordelt stokastisk variabel.

Opgave 1.3 (Prædiktionsintervaller)

Når vi ud fra nogle data og en model for de pågældende data forsøger at udtale os om værdien af en ny observation kalder vi det *prædiktion*. Vi forsøger ikke at angive en enkelt værdi, men derimod

et interval, hvor observationen vil falde med en specificeret sandsynlighed, for eksempel et 95% *prædiktionsinterval*.

Betragt en normalfordelt observationsrække,

$$X_i \sim N(\mu, \sigma^2), \quad i = 1, \dots, n,$$

og lad X_0 betegne en stokastisk variabel, som er uafhængig af $X_1, \dots, X_n$ og $N(\mu, \sigma^2)$ fordelt.

1° Vis, at

$$\mathbb{P}(\mu - u_{1-\alpha/2}\sigma < X_0 < \mu + u_{1-\alpha/2}\sigma) = 1 - \alpha,$$

altså at uligheden

$$\mu - u_{1-\alpha/2}\sigma < X_0 < \mu + u_{1-\alpha/2}\sigma \quad (1.1)$$

holder med sandsynlighed $1 - \alpha$.

2° Vis, at

$$\frac{Y - \bar{X}}{s(\mathbf{X})\sqrt{1 + 1/n}} \sim t(n - 1)$$

og dermed følgende ulighed holder med sandsynlighed $1 - \alpha$:

$$\bar{X} - t_{1-\alpha/2}(n - 1)s(\mathbf{X})\sqrt{1 + 1/n} < X_0 < \bar{X} + t_{1-\alpha/2}(n - 1)s(\mathbf{X})\sqrt{1 + 1/n}, \quad (1.2)$$

hvor $s^2(\mathbf{X})$ er den middelværdirette estimator for σ^2 og $t_{1-\alpha/2}(n - 1)$ er $1 - \alpha/2$ fraktilen i $t(n - 1)$ fordelingen.

Udtrykket fra (1.2) kan virke kompliceret ved første øjekast, men vi observerer at det har samme form som (1.1), blot med estimators indsat på de ukendte parametres pladser.

Intervallet (1.2) med de observerede værdier fra stikprøven indsat er altså et $1 - \alpha$ prædiktionsinterval.

3° Overvej hvilken betydning størrelsen n af den stikprøve, som bruges til estimation af modellens parametre har, og sammenlign med konfidensintervallet for middelværdien.

Opgave 1.4 *Hvor mange outliers forventes i et boxplot?*

I et boxplot markeres observationer, der ligger uden for intervallet $[Q_1 - 1.5 \cdot \text{IQR}, Q_3 + 1.5 \cdot \text{IQR}]$, ved punkter. Her er Q_1 og Q_3 henholdsvis første og tredje kvartil af stikprøven, og $\text{IQR} = Q_3 - Q_1$. Som nævnt i [Chihara and Hesterberg \[2022\]](#) betragtes disse punkter som “outliers”, selvom man skal være opmærksom på, at betegnelsen dækker over flere forskellige begreber inden for statistik.

I denne opgave undersøges fordelingen af antallet af outliers først teoretisk og derefter ved simulation. I begge tilfælde beskriver vi stikprøven ved i.i.d. stokastiske variable $X_1, X_2, \dots, X_n$ (i.i.d. = *independent and identically distributed*).

Den teoretiske del: Fordelingen af antallet af outliers afhænger på en kompliceret måde af stikprøvestørrelsen n , men vi kan “snyde” lidt ved at erstatte de empiriske kvartiler med teoretiske fraktiler. Dette er en fremgangsmåde, man tit benytter, og den begrundes ofte med “asymptotikken”. Med “asymptotisk” menes her, at vi lader stikprøvestørrelsen n vokse mod uendelig, idet Q_1 og Q_3 da vil konvergere mod de teoretiske fraktiler $q_{0.25}$ og $q_{0.75}$ af den bagvedliggende fordeling af X_i . Vi holder os til normalfordelingen i den teoretiske del.

- 1° Beregn intervallet $[Q_1 - 1.5 \cdot \text{IQR}, Q_3 + 1.5 \cdot \text{IQR}]$ for en uendeligt stor stikprøve fra $N(0, 1)$ -fordelingen, dvs. brug fraktilerne fra $N(0, 1)$ -fordelingen og sæt $Q_1 = u_{0.25}$ og $Q_3 = u_{0.75}$.
- 2° Hvor stor er sandsynligheden for, at en stokastisk variabel $Y \sim N(0, 1)$ falder uden for det interval, I beregnede i delopgave 1°?
- 3° Lad N_{punkt} betegne antallet af prikker i den “asymptotiske boxplot” for en tilfældig stikprøve fra standardnormalfordelingen, hvor stikprøvestørrelsen er n . Med “asymptotisk boxplot” mener vi her, at intervallet fra (a), hvor $n = \infty$, bruges til at afgøre, hvilke værdier er outliers. Da vi ser på tilfældige stikprøver, er N_{punkt} en stokastisk variabel. Gør rede for, at N_{punkt} er binomialfordelt. Hvilke parametre har denne binomialfordeling, og hvad er middelværdien $\mathbb{E}[N_{\text{punkt}}]$ af antallet af outliers?
- 4° Overvej, om noget ændrer sig, hvis data stammer fra en anden normalfordeling, en uniform fordeling på $[0, 1]$ eller en eksponentialfordeling? Du behøver ikke nødvendigvis lave beregninger for at besvare dette spørgsmål – kvalitativ argumentation er fint.

Den praktiske del: Lav et simulationsstudie for at tjekke, om det gennemsnitlige antal outliers, I beregnede i 3°, også passer ved mindre stikprøvestørrelser, og om I har gættet rigtigt i delopgave 4°.

Vi vil bruge **R**-funktionen `boxplot.stats`. Den udregner alt, hvad der er nødvendigt for at tegne et boxplot, og gemmer informationen i en liste. Det er en datatype, som kombinerer flere elementer, og elementerne tilgås ved `$`.

- 5° Kør **R**-koden 1.1, og beskriv outputtet (med undtagelse af `$conf`):

R-kode 1.1

```
stikprove <- c(0, 2, 15:21, 25, 30)
boxplot(stikprove)
boxplot.stats(stikprove)
boxplot.stats(stikprove)$out
length(boxplot.stats(stikprove)$out)
```

- 6° Udforsk **R**-funktionen `replicate`. Afprøv følgende kodelinjer:

R-kode 1.2

```
replicate(5, 3)
replicate(5, mean(rnorm(4)))
```

Forklar, hvad der simuleres med følgende **R**-kode:

R-kode 1.3

```
replicate(100, length(boxplot.stats(rnorm(10))$out))
mean(replicate(100, length(boxplot.stats(rnorm(10))$out)))
```

7° Bestem det gennemsnitlige antal prikker i et boxplot af en stikprøve af størrelse n fra en $N(0, 1)$ -fordeling ved simulation, baseret på 10 000 simulerede stikprøver, for $n = 10, 100, 1000$. Sammenhold de tal, I får, med den teoretiske forventning fra 3°, og se på forholdet mellem det simulerede og det forventede antal. Kan I se en tendens med voksende stikprøvestørrelse n ?

8° Modifier simulationen, så I kan tjekke jeres overvejelser i delopgave 4°.

Opgave 1.5 Afskæring og hældning af **qqline**

Simulér stikprøver af størrelse $n = 50$ fra normalfordelingerne $N(0, 1)$, $N(0, 2^2)$ og $N(1, 1)$, og tegn normalfraktildiagrammer (**qqnorm**) samt den tilpassede **qqline**. For stikprøven fra $N(0, 1)$ -fordelingen skulle den linje, der tegnes af **qqline**, gerne svare til identitetslinjen, men hvad ser du, når data stammer fra de andre normalfordelinger? Spørgsmålene nedenfor peger frem mod et svar.

- 1° Betragt qqplots fra stikprøver af $N(0, 2^2)$ - og $N(1, 1)$ -fordelingerne. Skøn ved øjemål, hvilken afskæring (a) og hældning (b) **qqline** tegner. Notér afskæring og hældning i begge tilfælde, og gentag eventuelt simulationen for at se, om resultaterne varierer. Overvej desuden, om punkterne snor sig lige så pænt omkring linjen, som de gør det for stikprøver fra $N(0, 1)$ -fordelingen.
- 2° Relatér dine skøn for afskæring og hældning til de pågældende normalfordelingers parametre. Kan du se en sammenhæng? Hvis du har en formodning, så prøv at opstille en formel for afskæring og hældning i det generelle tilfælde, hvor stikprøven følger en $N(\mu, \sigma^2)$ -fordeling.
- 3° Når du har fundet en formel i del 2°, så simulér en stikprøve fra $N(-2, 3^2)$ -fordelingen for at tjekke, om din formel passer. Du kan indtegne en linje med afskæring a og hældning b i et **qqnorm**-plot ved at bruge **abline** (a , b) .

Opgave 1.6 Let X_1 og X_2 være uafhængige $N(\mu, \sigma^2)$ -fordelte stokastiske variable, og betragt $\bar{X} = (X_1 + X_2)/2$ og $\text{SSD}_{\mathbf{X}} = \sum_{i=1}^2 (X_i - \bar{X})^2$.

- 1° Vis, at $\text{SSD}_{\mathbf{X}} = (X_1 - X_2)^2/2$. Benyt derefter dette resultat til at vise at $\text{SSD}_{\mathbf{X}} \sim \sigma^2 \chi^2(1)$.

- 2° Vis, at $\text{Cov}(X_1 + X_2, X_1 - X_2) = 0$ og gør rede for, at vi derudfra kan konkludere at $\text{SSD}_{\mathbf{X}}$ er uafhængig af $\bar{X}$.

Opgave 1.7 Lad $x_1, \dots, x_n$ være en observationsrække fra Poissonfordelingen med parameter $\lambda > 0$, det vil sige fra den diskrete fordeling, der har sandsynlighedsfunktionen

$$po(x; \lambda) = e^{-\lambda} \frac{\lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

- 1° Angiv likelihoodfunktionen, log likelihoodfunktionen og likelihoodligningen.

- 2° Vis, at løsningen til likelihoodligningen er:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

og vis, at løsningen maksimerer likelihoodfunktionen.

- 3° Angiv maksimum likelihood estimatoren for λ , og angiv sandsynligheden for, at maksimum likelihood estimatet eksisterer.

- 4° Betragt hypotesen $H_0: \lambda = \lambda_0$ og vis, at likelihood ratio teststørrelsen for H_0 er:

$$Q(\mathbf{x}) = (n\lambda_0/x)^{x \cdot} \exp(-n\lambda_0 + x).$$

- 5° Vis, at Q som funktion af x er strengt voksende for $x \leq n\lambda_0$ og strengt aftagende for $x \geq n\lambda_0$.

- 6° Antag, at $n = 5$, $\lambda_0 = 3$, og at $\sum x_i = 20$. Angiv de observationer der er mere eller ligeså kritiske for H_0 som $\sum x_i = 20$, og beregn testssandsynligheden.

Opgave 1.8 Lad x være en observation fra en binomialfordeling med sandsynlighedsparameter $\pi \in]0, 1[$ og antalsparameter $n (\in N)$, det vil sige fra den diskrete fordeling, der har sandsynlighedsfunktionen

$$b(x; n, \pi) = \binom{n}{x} \pi^x (1 - \pi)^{n-x}, \quad x \in \{0, 1, \dots, n\}.$$

- 1° Angiv likelihoodfunktionen, log likelihoodfunktionen og likelihoodligningen.

- 2° Angiv maksimum likelihood estimatet for π og angiv sandsynligheden for at maksimum likelihood estimatet eksisterer.

- 3° Betragt hypotesen $H_0: \pi = \pi_0 = 1/2$ og angiv likelihood ratio teststørrelsen for H_0 .

- 4° Antag, at $n = 10$ og $x = 1$. Angiv de observationer der er mere end eller ligeså kritiske for H_0 som $x = 1$, og angiv testsandsynligheden.

- 5° Betragt dernæst hypotesen $H_0: \pi = \pi_0 = 1/4$, og antag at $n = 10$ og $x = 1$. Angiv de observationer der er mere end eller ligeså kritiske for H_0 som $x = 1$, og angiv testsandsynligheden.

Opgave 1.9 Antag vi har observeret *et* udfald $x \in \mathbb{R}$ fra normalfordelingen med ukendt middelværdi μ og *kendt* varians $\sigma_0 > 0$, altså fra $X \sim N(\mu, \sigma_0^2)$.

1° Opskriv likelihoodfunktionen og log likelihoodfunktionen for μ .

2° Vis at maksimum likelihood estimatet $\hat{\mu}$ for μ er $\hat{\mu} = x$.

3° Betragt hypotesen $H : \mu = \mu_0$. Vis, at likelihood-ratio-teststørrelsen er

$$Q(x) = e^{-\frac{(x-\mu_0)^2}{2\sigma_0^2}},$$

samt at hvis vi definerer

$$u(x) = \frac{x - \mu_0}{\sigma_0},$$

så gælder

$$\begin{aligned} P_{\mu_0}(Q(X) \leq Q(x)) &= P_{\mu_0}(|U(X)| \leq |u(x)|) \\ &= 2[1 - \Phi(|u(x)|)], \end{aligned} \quad (1.3)$$

hvor $X \sim N(\mu_0, \sigma_0^2)$ under hypotesen, og Φ er fordelingsfunktionen for standardnormalfordelingen (se Afsnit (A.3.1)).

Bemærk, at hypotesen H er en *simpel* hypotese, og at udtrykket (1.3) derfor er testsandsynligheden $p_{\text{obs}}(x)$ for H .

4° Vis ved hjælp af 3°, at et $1 - \alpha$ konfidensinterval for μ på baggrund af observationen x er

$$C_{1-\alpha}(x) = (x - \sigma_0 u_{1-\alpha/2}, x + \sigma_0 u_{1-\alpha/2}),$$

hvor $u_{1-\alpha/2}$ er $1 - \alpha/2$ fraktilen i standard normalfordelingen.

5° Betragt nu situationen, hvor vi ikke bare har én observation fra $N(\mu, \sigma_0)$ men en observationsrække $x_1, \dots, x_n$ fra $N(\mu, \sigma_0)$. Gør rede for at

$$\bar{X} \sim N(\mu, \frac{\sigma_0^2}{n}),$$

og vis derved at

$$C_{1-\alpha}(\mathbf{x}) = \left(\bar{x} - \frac{\sigma_0}{\sqrt{n}} u_{1-\alpha/2} \leq \mu \leq \bar{x} + \frac{\sigma_0}{\sqrt{n}} u_{1-\alpha/2} \right).$$

Opgave 1.10 Betragt den kontinuerte fordeling på $\mathbb{R}^2$ med tætheden

$$f(x, y; \theta) = \frac{1}{2\pi} \sqrt{1 - \theta^2} \exp(\theta xy - \frac{x^2 + y^2}{2}), \quad (x, y) \in \mathbb{R}^2, \quad (1.4)$$

hvor θ er en ukendt parameter i intervallet $(-1, 1)$.

Lad $(x_1, y_1), \dots, (x_n, y_n)$ betegne realisationer af uafhængige og identisk fordelte stokastiske variable med en fordeling givet ved tætheden i (1.4).

1° Angiv likelihoodfunktionen, og vis at log likelihoodfunktionen er

$$l(\theta) = -n \log(2\pi) + \frac{n}{2} \log(1 - \theta^2) + \theta \sum_{i=1}^n x_i y_i - \frac{1}{2} \sum_{i=1}^n x_i^2 - \frac{1}{2} \sum_{i=1}^n y_i^2.$$

Vis dernæst, at likelihood ligningen er

$$\frac{\theta}{1 - \theta^2} = \frac{1}{n} \text{SP}_{xy},$$

hvor $\text{SP}_{xy} = \sum_{i=1}^n x_i y_i$.

2° Vis, at maksimum likelihood estimatet er

$$\hat{\theta} = \frac{-1 + \sqrt{1 + 4(\text{SP}_{xy}/n)^2}}{2\text{SP}_{xy}/n}.$$

2° Man ønsker at teste hypotesen $H_0: \theta = \theta_0$. Angiv likelihood ratio teststørrelsen Q for H_0 .

3° Man interesserer sig nu specielt for $\theta_0 = 0$, det vil sige $H_0: \theta = 0$. Man tager en stikprøve med $n = 25$ observationer, hvor $\text{SP}_{xy} = 11$. Find $\hat{\theta}$ og test H_0 .

Opgave 1.11 (Ensidet variansanalyse med kendt varians.)

Lad X_{ij} , $j = 1, \dots, n_i$, $i = 1, \dots, k$, være indbyrdes uafhængige

$$X_{ij} \sim N(\mu_i, \sigma_{0i}^2), \quad \mu_i \in \mathbb{R}, \quad \sigma_{0i}^2 > 0, \quad (1.5)$$

hvor σ_{0i}^2 er kendt.

1° Vis, at maksimum likelihood estimatoren $(\hat{\mu}_1, \dots, \hat{\mu}_k)$ for $(\mu_1, \dots, \mu_k)$ er givet ved

$$(\hat{\mu}_1, \dots, \hat{\mu}_k) = (\bar{X}_1, \dots, \bar{X}_k),$$

hvor $\bar{X}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} X_{ij}$. Angiv maksimum likelihood estimatorens fordeling.

Betragt hypotesen om fælles middelværdi for alle observationsrækkerne, det vil sige

$$H_{01} : \mu_i = \mu, \quad i = 1, \dots, k.$$

2° Vis, at maksimum likelihood estimatoren $\hat{\mu}$ for μ under H_{01} er givet ved

$$\hat{\mu} = \frac{\sum_{i=1}^k \frac{n_i \bar{X}_i}{\sigma_{0i}^2}}{\sum_{i=1}^k \frac{n_i}{\sigma_{0i}^2}},$$

det vil sige $\hat{\mu}$ er det vejede gennemsnit af estimatorerne $\bar{X}_i$ fra de enkelte observationsrækker med deres inverse varianser som vægte. Angiv fordelingen for $\hat{\mu}$.

3° Vis, at likelihood ratio testoren for H_{01} under hypotesen (1.5) er

$$Q_1(X) = e^{-\frac{1}{2} \sum_{i=1}^k \frac{n_i}{\sigma_{0i}^2} (\bar{X}_{i\cdot} - \hat{\mu})^2}.$$

Vis endvidere, at $-2 \ln Q_1(X)$ er χ^2 fordelt med $k - 1$ frihedsgrader og uafhængig af $\hat{\mu}$.

Opgave 1.12 (*middelværdi og varians for affin transformation*)

I denne opgave bestemmes middelværdi og varians for en affin transformation (begrebet forklares nedenfor) af en vektor af stokastiske variable.

Lad $\mathbf{X} = (X_1, \dots, X_n)^*$ være en n -dimensional stokastisk søjlevektor, med middelværdi vektor $E\mathbf{X} = \boldsymbol{\mu}$ og kovariansmatriks $\text{Cov}(\mathbf{X}) = \boldsymbol{\Sigma}$, det vil sige

$$\boldsymbol{\mu} = (E X_1, \dots, E X_n)^*$$

og

$$\text{Cov}(\mathbf{X}) = \boldsymbol{\Sigma} = \begin{pmatrix} \text{Cov}(X_1, X_1) & \cdots & \text{Cov}(X_1, X_n) \\ \vdots & & \vdots \\ \text{Cov}(X_n, X_1) & \cdots & \text{Cov}(X_n, X_n) \end{pmatrix}.$$

1° Betragt nu en *affin* transformation af $\mathbf{X}$, altså $\boldsymbol{\xi} + \mathbf{B}\mathbf{X}$ hvor $\boldsymbol{\xi}$ er en k -dimensional vektor og $\mathbf{B}$ er en $k \times n$ matriks. Vis, at

$$E(\boldsymbol{\xi} + \mathbf{B}\mathbf{X}) = \boldsymbol{\xi} + \mathbf{B}\boldsymbol{\mu} \quad \text{og} \quad \text{Cov}(\boldsymbol{\xi} + \mathbf{B}\mathbf{X}) = \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}^*.$$

Opgave 1.13 I denne opgave skal resultatet i Opgave 1.12 benyttes. Lad X_i $i = 1, \dots, n$ betegne en følge af uafhængige stokastiske variable, der alle har middelværdi $E X_i = 1$ og varians $\text{Var } X_i = 1$. Lad $Y_i = X_1 + \dots + X_i$ og lad $\mathbf{Y} = (Y_1, \dots, Y_n)^*$. Bestem middelværdivektoren $E(\mathbf{Y})$ samt kovariansmatriksen $\text{Cov}(\mathbf{Y})$.

Opgave 1.14 Lad $x_1, \dots, x_n$ være en observationsrække fra $N(\mu, \sigma^2)$ fordelingen.

1° Vis, at likelihood ratio teststørrelsen $Q(x)$ for hypotesen

$$H_0 : \sigma^2 = \sigma_0^2$$

er

$$Q(x) = r^{\frac{n}{2}} e^{-\frac{n}{2}(r-1)},$$

hvor

$$r = \hat{\sigma}^2 / \sigma_0^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 / \sigma_0^2.$$

2° Gør rede for at likelihood ratio testet forkaster for store og små værdier af r .

Opgave 1.15 Opgaven er baseret på Eksamensopgave 1 Forår 2018 for Introduktion til Matematisk Statistik (det hed kurset dengang).

Lad $X_1, \dots, X_n$ være i.i.d. stokastiske variable med værdier i $\{1, 2, 3\}$,

$$\mathbb{P}(X_i = 1) = \theta, \quad \mathbb{P}(X_i = 2) = 2\theta, \quad \mathbb{P}(X_i = 3) = 1 - 3\theta,$$

hvor θ er en ukendt parameter, $0 \leq \theta \leq 1/3$.

1° Brug moment metoden til at udlede en estimator for θ .

2° Er din estimator unbiased som estimator for θ ?

Opgave 1.16 I denne opgave skal I redegøre for nogle af de matematiske detaljer i afsnittet (*Case Study: Wind Energy*) i [Chihara and Hesterberg \[2022\]](#) 6.1.3 samt tegne et fraktildiagram. Datasættet hedder `Turbine`, og den variabel, der betragtes, er `AveSpeed`.

1° Vis udtrykket for likelihoodfunktionen og udtrykket for log likelihoodfunktionen for en stikprøve fra Weibull fordelingen, som er angivet midtfor på side 157[†], dvs.

$$L(k, \lambda, x_1, x_2, \dots, x_n) = \frac{k^n}{\lambda^{kn}} \prod_{i=1}^n x_i^{k-1} e^{-\sum_{i=1}^n (x_i/\lambda)^k}$$

og

$$\ln(L(k, \lambda)) = n \ln(k) - kn \ln(\lambda) + (k-1) \sum_{i=1}^n \ln(x_i) - \sum_{i=1}^n \left(\frac{x_i}{\lambda}\right)^k.$$

2° Stadig på side 157[†], vis udtrykkene for likelihood-ligningerne (formel (6.9) og (6.10)), og gør rede for, hvordan formlerne (6.11) og (6.12) følger af disse. Når I gennemgår dette til TØ, er I også velkomne til at diskutere, hvordan formlerne benyttes til at finde estimatorerne for k og λ .

3° I afsnittet findes estimatorerne $\hat{k} = 3.169$ og $\hat{\lambda} = 7.661$, og modellen vurderes grafisk ved hjælp af et histogram og en empirisk fordelingsfunktion i figur 6.4. Tegn et fraktildiagram, der sammenligner fraktilerne fra den estimerede Weibull-fordeling med fraktilerne fra den empiriske fordelingsfunktion.

Vink: Fraktilerne i Weibull-fordelingen kan beregnes vha. `qweibull` og følgen

$$\left(\frac{1 - \frac{1}{2}}{n}, \frac{2 - \frac{1}{2}}{n}, \dots, \frac{n - \frac{1}{2}}{n}\right)$$

kan laves med

[†]Side 159 i [Chihara and Hesterberg \[2018\]](#)

[†]Side 159 i [Chihara and Hesterberg \[2018\]](#)

R-kode 1.4

```
((1:n)-0.5)/n
```

Husk, at en vektor `x` sorteres med kommandoen `sort(x)`. Hvis I er i tvivl om, hvad der konkret skal plottes, kan formel (1.4) i de supplerende noter måske hjælpe.

Opgave 1.17 Vink og ekstra-spørgsmål til Opgave 8.48 i Chihara and Hesterberg [2022][‡]. Ifølge Neyman-Pearson lemmaet skal I udlede testet baseret på likelihood ratio testoren og I kan følge udregningerne i Example 8.22 s. 282 i Chihara and Hesterberg [2022][‡] som omhandler en lignende situation. I skal vise at det kritiske område er

$$\mathcal{R} = \{(X_1, \dots, X_n) \in \mathbb{R}^n \mid \sum_{i=1}^n X_i > c_2\}$$

for et reelt tal c_2 .

1° Beregn c_2 når $n = 10$ og signifikansniveauet er $\alpha = 0.05$.

2° Beregn styrken af testet under H_A .

Ifølge Opgave 4.30 i Chihara and Hesterberg [2022] er $X_{\min}$ eksponentialfordelt med parameter $n\lambda$ og vi kan betragte et test på formen

$$\mathcal{R} = \{(X_1, \dots, X_n) \in \mathbb{R}^n \mid X_{\min} > c_3\}$$

3° Beregn c_3 når $n = 10$ og signifikansniveauet er $\alpha = 0.05$.

4° Beregn styrken af testet under H_A .

Opgave 1.18 I Opgave 6.18 Chihara and Hesterberg [2022] benyttes momentmetoden til at estimere parametrene i en gammafordeling. I denne opgave løser vi samme problemstilling ved hjælp af maksimum-likelihood-estimation. Fremgangsmåden svarer til den, der er benyttet i afsnit (*Case Study: Wind Energy*) i Chihara and Hesterberg [2022] 6.1.3.

Lad $x_1, \dots, x_n$ være en stikprøve fra en gammafordeling.

1° Vis, at likelihoodfunktionen er givet ved

$$L(\lambda, r) = \lambda^{nr} \Gamma(r)^{-n} \left(\prod_{i=1}^n x_i \right)^{r-1} \exp\left(-\lambda \sum_{i=1}^n x_i\right).$$

[‡]Opgave 8.43 i Chihara and Hesterberg [2018]

[‡]Example 8.20 s.272 i Chihara and Hesterberg [2018]

2° Vis, at likelihood ligningerne bliver

$$\begin{aligned}\frac{\partial l(\lambda, r)}{\partial \lambda} &= \frac{nr}{\lambda} - \sum_{i=1}^n x_i = 0 \\ \frac{\partial l(\lambda, r)}{\partial r} &= n \log \lambda - n\psi(r) + \sum_{i=1}^n \log x_i = 0,\end{aligned}$$

hvor ψ betegner digammafunktionen, $\psi(x) = \frac{d}{dx} \log \Gamma(x)$.

Lad $A_n := \frac{1}{n} \sum_{i=1}^n x_i$ og $B_n := \frac{1}{n} \sum_{i=1}^n \ln(x_i)$ være henholdsvis gennemsnittet af observationerne x_i og gennemsnittet af logaritmerne til x_i . På baggrund af resultaterne i 1° og 2° gælder, at for fastholdt r er maksimum-likelihood-estimatet $\hat{\lambda}(r)$ af λ givet ved

$$\hat{\lambda}(r) = \frac{r}{A_n},$$

mens maksimum-likelihood-estimatet af r er den entydige løsning til ligningen

$$\psi(r) - \ln(r) = B_n - \ln(A_n).$$

3° Lav et simuleret datasæt ved at køre kommandoerne i R-kode 1.5.

R-kode 1.5

```
set.seed(1)
x <- rgamma(1000, shape = 2, rate = 3)
```

Skriv et **R**-program, der numerisk beregner maksimum-likelihood-estimaterne for parametrene ud fra det simulerede datasæt. Bemærk, at digamma-funktionen er implementeret i **R** under navnet `digamma`, og at man kan bruge `uniroot` til at finde rødder af funktioner af én variabel. Se eventuelt filen `funk.pdf` for hjælp til at definere funktioner i **R**.

Opgave 1.19 Lad $x_i, i = 1, \dots, n$ være en stikprøve fra normalfordelingen med ukendt middelværdi $\mu \in \mathbb{R}$ og kendt varians $\sigma_0^2 > 0$, altså modellen hvor x_i erne er realisationer af uafhængige, identisk fordelte stokastiske variable $X_i, i = 1, \dots, n$, som er $N(\mu, \sigma_0^2)$ -fordelt.

1° Vis, at likelihoodfunktionen og log likelihoodfunktionen er givet ved henholdsvis

$$L(\mu) = \left(\frac{1}{2\pi\sigma_0^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2} \quad (1.6)$$

og

$$\ell(\mu) = -\frac{n}{2} \log(2\pi\sigma_0^2) - \frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2. \quad (1.7)$$

2° Vis at maksimum likelihood estimatet $\hat{\mu}$ for μ er $\hat{\mu} = \bar{x}$. hvor

$$\bar{x} \stackrel{\text{def}}{=} \frac{1}{n} \sum_{i=1}^n x_i.$$

3° Betragt hypotesen $H : \mu = \mu_0$. Vis at likelihood ratio teststørrelsen er

$$Q(\mathbf{x}) = e^{-\frac{n(\bar{x} - \mu_0)^2}{2\sigma_0^2}}$$

samt at hvis vi sætter $u(\mathbf{x}) \stackrel{\text{def}}{=} \sqrt{n}(\bar{x} - \mu_0)/\sigma_0$ vil

$$\mathbb{P}_{\mu_0}(Q(\mathbf{X}) \leq Q(\mathbf{x})) = \mathbb{P}_{\mu_0}(|U(\mathbf{X})| \geq |u(\mathbf{x})|) = 2(1 - \Phi(|u(\mathbf{x})|)), \quad (1.8)$$

hvor Φ er fordelingsfunktionen i standard normalfordelingen. Bemærk at hypotesen H er en *simpel* hypotese, og at udtrykket (1.8) derfor er testsandsynligheden $p_{\text{obs}}(\mathbf{x})$ for H .

Opgave 1.20 Lad x_i , $i = 1, \dots, n$ være en observationsrække fra normalfordelingen med ukendt middelværdi $\mu \in \mathbb{R}$ og ukendt varians $\sigma^2 > 0$, altså modellen hvor x_i erne er realisationer af uafhængige, identisk fordelte stokastiske variable X_i $i = 1, \dots, n$, som er $N(\mu, \sigma^2)$ -fordelt.

1° Vis, at likelihoodfunktionen og log likelihoodfunktionen er givet ved henholdsvis

$$L(\mu, \sigma^2) = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2} \quad (1.9)$$

og

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2. \quad (1.10)$$

2° Vis, at $\hat{\mu} = \bar{x}$. maksimerer

$$\mu \mapsto \ell(\mu, \sigma^2),$$

det vil sige log likelihoodfunktionen som funktion af μ og med σ^2 holdt fast.

3° Lad

$$\tilde{\ell}(\sigma^2) \stackrel{\text{def}}{=} \ell(\bar{x}, \sigma^2).$$

Vis, at $\tilde{\ell}$ maksimeres af

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

4° Vis, at

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

og gør rede for at den tilsvarende estimator, det vil sige $\bar{X}$, er unbiased som estimator for μ .

Opgave 1.21 Antag $X \sim \text{Binom}(n, p)$ og lad $\hat{\theta} = \hat{\theta}(X)$ være en unbiased estimator for p .

1° Benyt Cramer–Raos ulighed til at vise at

$$\text{Var}(\hat{\theta}) \geq \frac{p(1-p)}{n}.$$

2° Hvad siger 1° om estimatoren $\hat{p} = X/n$ for p ?

Opgave 1.22 Lad $x_1, x_2, \dots, x_n$ være en stikprøve fra eksponentialfordelingen med parameter λ . Formålet med denne opgave er at illustrere resultaterne omkring approksimativ likelihood teori.

1° Gør rede for, at likelihoodfunktionen for λ er

$$L(\lambda) = \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right),$$

og at log likelihoodfunktionen er

$$l(\lambda) = n \log(\lambda) - \lambda \sum_{i=1}^n x_i.$$

Det følger af Example 6.2 i [Chihara and Hesterberg \[2022\]](#) at MLE for λ er

$$\hat{\lambda} = \frac{1}{\bar{X}}.$$

2° Betragt hypotesen $H : \lambda = 1$. Vis, at likelihood ratio testoren er

$$Q(\mathbf{X}) = (\bar{X})^n \exp\left(-\sum_{i=1}^n X_i + n\right)$$

og at

$$-2 \log(Q(\mathbf{X})) = -2n \log(\bar{X}) + 2 \sum_{i=1}^n X_i - 2n$$

Ifølge approksimativ likelihood teori vil $-2 \log(Q(\mathbf{X}))$ være approksimativt $\chi^2(1)$ fordelt, når n er stor og hypotesen er sand (d.v.s når $\lambda = 1$)?

3° Lav et simulationseksperiment der illustrerer ovenstående resultat. Vælg f.eks. $n = 10$ og simulér $R = 10000$ replikationer af $-2 \log(Q(\mathbf{X}))$.

4° Antag at der for vores datasæt gælder at $n = 10$ og

$$\bar{x} = 1.1$$

Angiv estimatet for $\hat{\lambda}$ – kan vi acceptere hypotesen $H : \lambda = 1$?

Opgave 1.23 Denne opgave bygger oven på Example 7.13 i [Chihara and Hesterberg \[2022\]](#), så læs det eksempel først.

Lad $X_1, \dots, X_n \sim U[0, \beta]$ ^{i.i.d}

1° Gør rede for at

$$\frac{\bar{X}_n/\beta - 1/2}{1/\sqrt{12n}} \approx N(0, 1)$$

Altså at $(\bar{X}_n/\beta - 1/2)/(1/\sqrt{12n})$ er approksimativt standard normalfordelt.

2° Vis ved hjælp af 1° at

$$\left(\frac{\bar{X}_n}{1/2 + \frac{1.96}{\sqrt{12n}}}, \frac{\bar{X}_n}{1/2 - \frac{1.96}{\sqrt{12n}}} \right).$$

er et approksimativt 95% konfidensinterval for β .

3° Sæt $\beta = 10$ og $n = 8$ og lav et simulationseksperiment der undersøger hvor ofte konfidensintervallet fra 2° indeholder 10 (altså den sande værdi af β). Kommentér på dit resultat.

Opgave 1.24 Lad Z være en stokastisk variabel som har en eksponentialfordeling med rateparameter 1, og betragt den stokastiske variabel $Y = \sqrt{Z}$.

1° Vis, at fordelingsfunktionen F_Y for Y er givet ved

$$F_Y(y) = \begin{cases} 1 - e^{-y^2}, & \text{for } y \geq 0, \\ 0, & \text{for } y < 0. \end{cases}$$

2° Vis, at for $0 < p < 1$ er p -fraktilen givet ved

$$x_p = \sqrt{-\ln(1-p)}$$

3° Beregn første kvartil, median og tredje kvartil for F_Y og bekræft dit resultat ved simulere $n = 10^6$ udfald af Y og benytte **fivenum**.

Opgave 1.25 Lad $X_1, \dots, X_n$ uafhængige og identisk fordelte stokastiske variable med (fælles) fordelingsfunktion F . Den empiriske fordelingsfunktion er givet ved

$$\hat{F}_n(x) = \frac{\#\{i : X_i \leq x\}}{n} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{]-\infty, x]}(X_i) \quad x \in \mathbb{R}$$

Den empiriske fordelingsfunktion opfattes altså her som en funktion af de stokastiske variable og for fast x er den derfor en stokastisk variabel. Vi har ovenfor benyttet notationen $\mathbb{1}_A(\cdot)$ for *indikatorfunktionen* som opfylder

$$\mathbb{1}_A(a) = \begin{cases} 1 & a \in A \\ 0 & a \notin A \end{cases}.$$

1° Før rede for at $n\hat{F}_n(x)$ er binomial fordelt med antalsparameter n og sandsynlighedsparameter $F(x)$.

2° Vis, at

$$\begin{aligned}\mathbb{E} \hat{F}_n(x) &= F(x) \\ \mathbb{V}\text{ar} \hat{F}_n(x) &= \frac{1}{n} F(x) (1 - F(x))\end{aligned}$$

3° Gør rede for at $\hat{F}_n(x)$ konvergerer mod $F(x)$ i sandsynlighed, altså at der gælder at

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{F}_n(x) - F(x)| > \delta) = 0, \quad \text{for alle } \delta > 0.$$

Opgave 1.26 *Curve funktionen*

Denne øvelse vedrører funktionen `curve`. Husk, at hvis man skriver “?” foran et funktionsnavn i `R`, åbnes for den pågældende funktion, og for eksempel findes dokumentationen for `curve` med `?curve`.

1° Brug R-funktionen `curve` til at tegne grafen for funktionen $f(x) = \log x$, for $0 \leq x \leq 2$. Prøv at se, hvad `abline(h = 0, lty = "dashed")` gør. Prøv så, at indtegne en vertikal ret linje, svarende til $x = 1$.

2° Prøv at tegne kurverne af $f(x) = x \cdot \sin(x^2)$ og $g(x) = x \cdot \cos(x^2)$ tilsammen i én plot, for $0 \leq x \leq 2\pi$. Man kan få funktionen `curve` til at tegne i en eksisterende plot ved at angive et funktionsargument `add = TRUE`.

Opgave 1.27 *Histogrammer*

I denne opgave skal du fremstille en figur, der ligner Figur 1.1 i de supplerende noter, baseret på `Weight` i datasættet `TXBirths2004`. Figuren viser et histogram, hvis samlede areal er 1. Sådanne histogrammer svarer til et estimat af en tæthedsfunktion, som er stykvis konstant. Du får dette ved at sætte argumentet `freq = FALSE` i funktionen `hist`.

Som standard vil `hist(x)` ellers tegne et histogram, hvor højden af søjlerne svarer til antallet af observerede værdier i histogrammets intervaller (også kaldet *bins*). Et eksempel ses på side 24 i [Chihara and Hesterberg \[2022\]](#), i figurerne 2.2 og 2.3, hvor y -aksen i disse histogrammer i en dansk kontekst kan være misvisende benævnt “*Frequency*”.

1° Indlæs pakken `resampledta3` og kørs `View(TXBirths2004)`.

2° Lav et histogram af `Weight` med en søjlebredde på 250 gram. Til dette formål skal du angive en vektor, der indeholder søjlernes inddelinger på x -aksen, som argumentet `breaks` i funktionen `hist`. Du kan generere en sådan vektor (fra 500 til 5000 i trin på 250) ved:

R-kode 1.6

```
seq(500, 5000, 250)
```

- 3° Indtegn derefter kurven for tætheden af normalfordelingen $N(\mu, \sigma^2)$, hvor du vælger estimerer for middelværdi og varians som parametrene μ og σ^2 . Du kan enten implementere tætheden selv eller benytte **dnorm**. Hvis du bruger **dnorm**, så husk, at **R** benytter standardafvigelsen (ikke variansen) som argument.
- 4° Gentag ovenstående, men sæt nu søjlebredde til 50. Ville man drage andre konklusioner ud fra disse to forskellige histogrammer?

Opgave 1.28 *Inferens om middelværdi*

I bjergegne danner floder en **alluvialkegle** når de aflejrer sedimenter ved foden af bjerget. Disse kegler beskrives ofte som værende symmetriske, men forfatterne til artiklen **Interactions between alluvial fans and axial rivers in Yukon, Canada and Alaska, USA** sætter spørgsmålstegn ved dette. For 63 alluvialkegler har forfatterne målt en længde af keglen i hver sin side og dannet forholdet mellem de to længder, kegleforholdet: $F = L_D/L_U$, hvor D og U står for downstream og upstream for vandløbet nedenfor keglen. En symmetrisk kegle svarer til at kegleforholdet har værdien 1. Målingerne findes i filen *Alluvialkegle.txt*.

Indlæs data fra filen *Alluvialkegle.txt* med kommandoen **scan("Alluvialkegle.txt")**. Denne opgave kan nu formuleres kort som følger. Opstil en statistisk model for kegleforholdet, lav inferens for parametrene i modellen og overvej en hypotese, om at keglerne er symmetriske. Skrevet ud bliver dette til følgende spørgsmål.

- 1° Undersøg grafisk, om kegleforholdet kan beskrives med en normalfordeling via et histogram og et qqplot. Overvej om det er bedre at beskrive logaritmen til kegleforholdet med en normalfordeling. Opskriv en statistisk model for data.
- 2° Lav en tabel med skøn og 95%-konfidensinterval for middelværdien, variansen og spredningen i en normalfordelingsmodel.
- 3° Overvej, om data er i overensstemmelse med teorien om symmetriske kegler.

Uanset, om I beskriver de oprindelige kegleforhold eller logaritmen til disse, vil I finde, at spredningen er så stor, at et kegleforhold under 1 vil have en sandsynlighed på cirka 16% i den estimerede normalfordeling (overvej dette). Forfatterne diskuterer ud fra fluiddynamiske betragtninger, både hvorfor kegleforholdet ofte er større end 1, men også hvorfor værdier mindre end 1 kan forekomme.

Opgave 1.29 *Parret t-test*

I artiklen **Effect of metallic iron from grinding on ferrous iron determinations** måles indholdet af

jern (Fe^0) i en række klippestykker ved to målemetoder betegnet som HgCl_2 og CuCl_2 . I tabellen nedenfor er kun medtaget de prøver, hvor jernindholdet er under 0.05 procent.

Nummer	HgCl_2	CuCl_2	Differens	Nummer	HgCl_2	CuCl_2	Differens
1	0.025	0.030	0.005	7	0.003	0.016	0.013
2	0.022	0.031	0.009	8	0.009	0.018	0.009
3	0.014	0.019	0.005	9	0.008	0.012	0.004
4	0.001	0.000	-0.001	10	0.004	0.013	0.009
5	0.002	0.004	0.002	11	0.031	0.037	0.006
6	0.003	0.016	0.013	12	0.020	0.041	0.021

I denne opgave skal I ud fra differenserne mellem de to målinger angive den viden, vi har om en eventuel forskel mellem de to målemetoder. Middelværdien af differensen siger noget om, hvilken generel tendens der er i forskellen mellem de to metoder, og spredningen repræsenterer den kombinerede måleusikkerhed fra de to målinger på den samme prøve. Data findes i filen *Jern.csv*, som er organiseret i 12 rækker og tre søjler: første søjle angiver prøvenummer, anden søjle angiver HgCl_2 -målingen og tredje søjle angiver CuCl_2 -målingen.

- 1° Indlæs data, og lav en figur, hvor indholdet af jern fra CuCl_2 metoden tegnes op mod indholdet fra HgCl_2 metoden. Indtegn identitetslinjen i figuren. Prøv at beskrive i ord, hvad figuren viser om forskel i jernindhold mellem de to målemetoder.
- 2° Betragt nu de 12 differenser mellem jernindhold fra de to målemetoder. Lav et qqplot af data, og opskriv den statistiske model, hvor differensen er normalfordelt.
- 3° Lav et test for hypotesen, at middelværdien af differensen er nul, svarende til hypotesen, at der ikke er forskel mellem de to målemetoder. Lav dernæst et 95%-konfidensinterval for middelværdien af differensen. Hvad bliver konklusionen af disse udregninger ?

Når I laver et *t*-test for at middelværdierne af *differenserne* er nul, kaldes dette et *parret t-test*: observationerne fra de to målemetoder er parret, ved at der er målt på det samme klippestykke. For en given målemetode er der stor variation i jernindholdet mellem klippestykkerne, og det kan være svært at se en forskel mellem to målemetoder, hvis vi forestiller os et alternativt eksperiment, hvor der er indsamlet 12 klippestykker, der analyseres med den ene målemetode, og 12 andre klippestykker der analyseres med den anden målemetode. I kan se dette ved at prøve at lave et two-sample *t*-test for data i denne opgave, hvor det ene observationssæt er data fra den ene målemetode, og det andet observationssæt er data fra den anden målemetode (two-sample *t*-test skal I arbejde med i Opgave 1.30).

Opgave 1.30 Two-sample *t*-test, samme varians

Gøgen lægger sine æg i andre fugles reder. I artiklen [The eggs of Cuculus canorus. An Inquiry into the dimensions of the cuckoo's egg and the relation of the variations to the size of the eggs of the foster-parent, with notes on coloration](#) undersøges det, om der er sket en selektion, således at gøgen er tilpasset den fugl, der bruges som vært for æggene. For de to værtsarter Engpiber og Hvid vipstjert er gøgens æg indsamlet, og bredden af ægget divideret med længden af ægget er beregnet

(kaldet æggets *form* fremover). Data ligger i filen *Goegen.csv* i form af to søjler, hvor første søjle er værtsart, og anden søjle er æggets form.

- 1° Indlæs data og dan vektorerne *art* og *form* ud fra søjlerne i de indlæste data. Dan dernæst to datasæt *formEng* og *formVip* med værdierne fra *form* hørende til henholdsvis Engpibe og Vipstjert.

Lav en figur med et qqplot for hvert af de to datasæt. Synes du, at gøgeæggenes form for hver værtsart kan beskrives med en normalfordeling?

Lav også en figur med boxplot for hvert af de to datasæt. Flere boxplots kan laves med kommandoen `boxplot(form~art)` eller ved hjælp af `boxplot(a,b)` hvor *a* og *b* vektorer med formen svarende til de to arter. Hvilke ligheder og forskelle mellem de to datasæt kan du se i denne figur?

- 2° Opstil modellen, hvor hvert datasæt (*formEng* og *formVip*) følger sin egen normalfordeling. Opsummer de to datasæt i form af en tabel, som for hvert datasæt indeholder antallet af observationer, gennemsnit, empirisk spredning og et 95%-konfidensinterval for middelværdien. Antallet af elementer i en vektor kan i **R** findes med funktionen *length*.

- 3° Opskriv hypotesen, at de to varianser er ens, og lav *F*-testet for ens varianser. Er det rimeligt at antage, at variansen af æggets form er den samme for de to værtsarter?

- 4° Opstil nu modellen, hvor data er normalfordelt, og de to datasæt har hver sin middelværdi, men samme varians. Opstil hypotesen at de to middelværdier er ens, og lav et test af denne hypotese.

Er det rimeligt at antage, at æggets form har samme middelværdi for de to værtsarter?

- 5° Angiv et 95%-konfidensinterval for forskellen i middelværdi af æggets form mellem værtsarten Engpiber og Hvid vipstjert.


Synes du, at forskellen mellem de to middelværdier i denne opgave er stor?

Opgave 1.31 *Two-sample t-test, forskellig varians*

I artiklen [In the shades of the uncanny valley: An experimental study of human-chatbot interaction](#) undersøges, hvordan forsøgspersoner påvirkes af at interagere med en *chatbot*, enten en simpel tekst-chatbot eller en chatbot, der oplæser beskederne.

I artiklen betegnes de to situationer med *Text* og *Avatar*. Som et af målepunkterne i eksperimentet måles den gennemsnitlige puls af forsøgspersonerne: 16 personer i Text-gruppen og 15 personer i Avatar-gruppen. Data ligger i filen *Chatbot.csv* i form af to søjler, hvor første søjle angiver chatbotsituationen, og anden søjle er pulsen. Data i denne fil er simulerede på en sådan måde, at informationen i figur 8 i den ovennævnte artikel efterlignes.

- 1° Benyt kommandoen `read.csv` til at indlæse data fra filen *Chatbot.csv*. Lav to datasæt med puls svarende til grupperne *Text* og *Avatar* - hvis datasættet er indlæst i *dat*, kan dette f.eks. gøres ved hjælp af kommandoen `subset(dat, subset = Chatbot=="Text")`. Lav qqplot - gerne i samme figur - for de to datasæt.



Synes du, at pulsen for hver chatbotsituation kan beskrives med en normalfordeling?

Lav en figur, der indeholder boxplot for de to chatbotsituationer. Hvilke ligheder og forskelle mellem de to datasæt kan du se i denne figur?

- 2° Opstil modellen, hvor hvert datasæt følger sin egen normalfordeling. Opsummer de to datasæt i form af en tabel, som for hvert datasæt indeholder antallet af observationer, gennemsnit, empirisk spredning og et 95%-konfidensinterval for middelværdien.
- 3° Opstil hypotesen, at de to varianser er ens. Eftersig, at data strider mod at sige, at variansen på pulsen er den samme for Text-gruppen som for Avatar-gruppen.
- 4° Angiv et 95%-konfidensinterval for forskellen i middelværdi af pulsen mellem Text-gruppen og Avatar-gruppen.

Synes du, at forskellen mellem de to middelværdier er stor?

- 5° Prøv til sidst at betragte logaritmen til pulsen. Lav qqplots for at se, om disse data kan beskrives med en normalfordeling. Lav et test, for at varianserne er ens, og lav et 95%-konfidensinterval for forskel i middelværdi af logaritmen til pulsen.

Oversæt det fundne konfidensinterval for forskel i middelværdi af logaritmen til pulsen til et 95%-konfidensinterval for forholdet mellem middelværdierne af pulsen, jævnfør Afsnit 3.1.2 i de supplerende noter. Hvor mange gange større er middelværdien af pulsen for Avatar-gruppen i forhold til Text-gruppen?

Opgave 1.32 “Standard error” kontra “standard deviation”

I skal i denne opgave lave en figur, der illustrerer standard deviation i forhold til standard error. Start med at dele plotvinduet op i to dele med ordren `par(mfrow=c(1,2))`.

- 1° Simuler $n = 20$ observationer $x_1, \dots, x_{20}$ fra en standard normalfordeling (benyt `rnorm(20)` til dette). Beregn den empiriske spredning s , beregn skøn $\hat{\mu} = \bar{x}$ over middelværdien og standard error for middelværdiskønnet, $sd(\hat{\mu})$.
- 2° Lav en figur med kaldet `boxplot(x, xlim=c(0, 3), ylim=c(-3, 3))`, hvor x er en vektor med de simulerede værdier.
- 3° Benyt `lines` til at indsætte to lodrette linjestykker med yderpunkter henholdsvis $\hat{\mu} \pm s$ og $\hat{\mu} \pm s/\sqrt{n}$. Disse skal placeres ud for 1.5 og 2.0 på førsteaksen. hvor `lower=c(hat{mu}-s, hat{mu}-s/sqrt(n))`, og `upper` er tilsvarende med plus i stedet for minus. Indsæt endelig et vandret linjestykke til at markere værdien af $\hat{\mu}$.
- 4° Gentag ovenstående simulering og tegning med $n = 200$ observationer. Hvilke dele skal ligne hinanden i de to tegninger, og hvilke skal ikke?

Opgave 1.33 *Teste to varianser ens*

Betragt to variansskøn $s_i^2 \sim \sigma_i^2 \chi^2(f_i)/f_i$, $i = 1, 2$. I skal i denne opgave vise, at F -testet for ens varianser fra Afsnit 3.1.1, i tilfældet med $f_1 = f_2$, er identisk med testet baseret på log likelihood ratio testoren.

Lad den fælles værdi af frihedsgraderne være f , lad $v = s_1^2/s_2^2$, og lad $\lambda(v)$ være $-2 \log Q$ teststørrelsen fra (3.26) med $k = 2$.

- 1° Vis, at $\lambda(v) = f \cdot \log\left(\frac{(1+v)^2}{4v}\right)$.
- 2° Vis, at $\lambda(v) = \lambda(1/v)$.
- 3° Lad $v < 1$. Vis, at $P(\lambda(V) \geq \lambda(v)) = F_{F(f,f)}(v) + 1 - F_{F(f,f)}(1/v)$.
- 4° Vis, med $v < 1$, at $P(\lambda(V) \geq \lambda(v)) = 2 \cdot F_{F(f,f)}(v)$.

Opgave 1.34 *Styrke af F-test*

Når vi tester om to varianser er ens ved et test på niveau 0.05, forkaster vi, hvis s_1^2/s_2^2 er mindre end eller lig med $F_{0.025}(f_1, f_2)$, eller hvis s_1^2/s_2^2 er større end eller lig med $F_{0.975}(f_1, f_2)$, hvor f_i , $i = 1, 2$, er frihedsgraderne hørende til de to variansskøn og $F_p(f_1, f_2)$ er p -fraktilen for $F(f_1, f_2)$ -fordelingen.

Betragt nu alternativet, hvor $\tau^2 = \sigma_2^2/\sigma_1^2 \neq 1$.

- 1° Vis, at sandsynligheden for at forkaste hypotesen om ens varianser (styrken) er

$$F_{F(f_1, f_2)}(\tau^2 F_{0.025}(f_1, f_2)) + 1 - F_{F(f_1, f_2)}(\tau^2 F_{0.975}(f_1, f_2))$$

- 2° Vælg værdier for de to frihedsgradsantal, og lav en figur, der viser styrken som funktion af variansforholdet τ^2 .
- 3° Lad $\tau^2 = 2$ og lad de to frihedsgradsantal være ens. Lav en figur, der viser styrken som funktion af frihedsgradsantallet.

Opgave 1.35 Eksamensopgave fra Matematisk Modellering 1 2006

Lad $x_1, \dots, x_n$ være udfald af uafhængige og identisk fordelte stokastiske variable $X_1, \dots, X_n$ hvor der gælder $X_i \sim N(\mu_0, \sigma^2)$ for $i = 1, \dots, n$. Antag at μ_0 er kendt, mens $\sigma^2 > 0$ er ukendt.

- 1° Find likelihoodfunktionen $L(\sigma^2)$ for den ukendte parameter σ^2 . Vis, at log likelihood funktionen, $l(\sigma^2)$, er

$$l(\sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2.$$

- 2° Vis at maksimum likelihood estimatet for σ^2 er $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2$ og angiv maksimum likelihood estimatorens fordeling.

Opgave 1.36 Eksamensopgave fra Matematisk Modellering 1 2008

Lad X_1, X_2, X_3 være uafhængige normalfordelte stokastiske variable, således at

$$X_1 \sim N(\mu, \sigma_0^2), \quad X_2 \sim N(\mu, \sigma_0^2), \quad X_3 \sim N(2\mu, \sigma_0^2),$$

hvor $\mu \in \mathbb{R}$ er ukendt, mens variansen $\sigma_0^2 > 0$ er kendt.

- 1° Gør rede for, at likelihoodfunktionen for μ er givet ved

$$L(\mu) = \left(\frac{1}{2\pi\sigma_0^2} \right)^{\frac{3}{2}} e^{-\frac{1}{2\sigma_0^2}((x_1-\mu)^2 + (x_2-\mu)^2 + (x_3-2\mu)^2)},$$

hvor x_i er udfaldet af den stokastiske variabel X_i , $i = 1, 2, 3$.

- 2° Vis, at maksimum likelihood estimatet af μ for

$$\hat{\mu} = \frac{x_1 + x_2 + 2x_3}{6}.$$

- 3° Vis, at


$$\frac{X_1 + X_2 + 2X_3}{6} \sim N\left(\mu, \frac{\sigma_0^2}{6}\right),$$

og udled en formel for et 95% konfidensinterval for μ .

Opgave 1.37 Regression

Et mål for udviklingen af kompleksiteten af computerchips er antallet af transistorer på en chip. På adressen [Transistor count](#) kan man finde en tabel med antallet af transistorer for 108 chips produceret i perioden 1971-2016. [Moore's lov](#) siger, at antallet af transistorer på en chip fordobles cirka hvert andet år. Dette blev formuleret af Gordon Moore, som var medstifter af *Intel* (Moore's udsagn går helt tilbage til 1965 og 1975).

I skal nedenfor undersøge dette udsagn ved at se på de $\log_2$ transformererede antal transistorers afhængighed af produktionsår. Ved at bruge totals-logaritmen opnår vi, at en fordobling af antal transistorer svarer til en stigning på 1.



Figur 1.2: Replika af den første transistor, opfundet ved Bell Labs i 1947

Filen *Moore.csv* indeholder data. Filen har to søjler, hvor første søjle er produktionsår regnet med udgangspunkt i 1950 (en værdi på 24 svarer således til 1974), og anden søjle er antal transistorer på chippen.

- 1° Indlæs data, og dan variablene `Aar` og `Antal` med indholdet af de to søjler. Dan endvidere variablen `log2Antal=log2(Antal)` med de $\log_2$ transformerede antal transistorer. Lav en figur, hvor `log2Antal` tegnes op mod `Aar` (`Aar` langs førsteaksen og `log2Antal` langs andenaksen). Er det rimeligt at sige, at der er en lineær sammenhæng mellem de to variable?
- 2° Opskriv den lineære regressionsmodel for data. Estimer parametrene i modellen, og lav figurer til modelkontrol. I residualplottet skal du indtegne to vandrette linjer, der skærer andenaksen i punkterne $\pm 2s_{02}$, hvor s_{02} er skønnet over spredningen i regressionsmodellen.
- 3° Beregn 95%-konfidensintervaller for henholdsvis skæring og hældning i den lineære sammenhæng mellem middelværdien af `log2Antal` og `Aar`. Eftersis, at konfidensintervallet for hældningen, fundet gennem et kald til `confint`, er korrekt ved at bruge oplysninger i output fra `summary`.
- 4° Overvej, om data er i overensstemmelse med en teori, der siger, at antallet af transistorer på en chip fordobles hvert andet år?

Opgave 1.38 Regressionsanalyse med prædiktion

I denne opgave skal I se på muligheden for at prædiktere den tid, der skal bruges til at teste et

program ud fra oplysning om, hvor lang tid der er brugt på at kode programmet. Data i filen *Testtid.csv* indeholder oplysninger for 95 programmer. Filen har to søjler, hvor første søjle er tid brugt på at kode, og anden søjle er tid brugt på at teste programmet (begge tider er i timer). Data er simulerede ud fra oplysningerne i figur 3 i artiklen [Software effort estimation with multiple linear regression: review and practical application](#).

I opgaven her skal I etablere en lineær sammenhæng mellem middelværdien af logaritmen til testtiden og logaritmen til kodningstiden og bruge denne sammenhæng til at prædiktere testtiden ved forskellige givne værdier af kodningstiden.

- 1° Lad `logKode` være en vektor med logaritmen til kodningstiderne, og lad `logTest` være en vektor med logaritmen til testtiderne. Lav en figur, hvor `logTest` afsættes mod `logKode`. Er det rimeligt at sige, at der er en lineær sammenhæng mellem de to variable?

Opskriv den lineære regressionsmodel for data, og estimer parametrene i denne via `lm` og `summary`. Indtegn den fundne linje i figuren med data.

Prøv i ord at beskrive sammenhængen i data, ud fra hvad du ser i figuren.

- 2° Lav et test, for hypotesen at hældningen er nul. Hvad bliver konklusionen af dit test? Lav dernæst et 95%-konfidensinterval for hældningen. Kommenter på betydningen af, at hældningen ser ud til at være væsentlig mindre end 1.

Lav et skøn over ændringen i middelværdi af `logTest` mellem en værdi af `logKode` på 2 og 4, og sammenhold denne med spredningen omkring regressionslinjen (jævnfør din egen beskrivelse af sammenhængen i data sidst i foregående spørgsmål).

- 3° Lav et 95%-konfidensinterval for middelværdien af `logTest`, når `logKode` er 6.

Lav dernæst et prædiktionsinterval for en kommende måling, når `logKode` er 6.

Prøv at forklare, hvorfor prædiktionsintervallet er noget bredere end konfidensintervallet.

- 4° I dette spørgsmål skal du beregne konfidensintervallet og prædiktionsintervallet i mange punkter og indtegne disse som en kurve i figuren fra spørgsmål 1°. Til beregningen kan du kalde `predict` med nye datapunkter givet ved `data.frame(logKode=c(0:100)*0.07)`.

Opgave 1.39 Regression med kendt skæring

Data i denne opgave stammer oprindeligt fra artiklen [Rainfall erosivity over Rhodesia](#). Ønsket er at etablere en sammenhæng mellem årlig middelnedbør og erosionsraten, således at der kan laves et erosionskort over Rhodesia (nuværende Zambia og Zimbabwe). Erosionsraten beregnes ud fra en mere detaljeret nedbørsregistrering end årlig middelnedbør. Data består af årlig middelnedbør (mm) og erosionsraten (joule mm/m²/hr) for 25 målepunkter i Highveld regionen af Rhodesia. Data findes i filen *RhodesiaHighveld.csv*, hvor første søjle er årlig middelnedbør (*regnHigh*) og anden søjle er erosionsraten (*erosionHigh*).

- 1° Lav en figur, hvor *erosionHigh* afsættes mod *regnHigh*, og hvor førsteaksen går fra 0 til 1000, og andenaksen går fra 0 til 15000.



Figur 1.3: Historisk kort over det sydlige Afrika

Opstil regressionsmodellen M_2 , hvor middelværdien af *erosionHigh* afhænger lineært af *regnHigh*. Estimer denne model via **lm**, og indtegn den fundne linje.

Angiv et 95%-konfidensinterval for hældning og for skæring.

Angiv et 95%-konfidensinterval for middelværdien af erosionen (linjens værdi), når den årlige nedbør er 500 mm.

2° Det er rimeligt at forestille sig, at hvis der ingen nedbør er, så er der heller ikke nogen erosion. Lav et *t*-test, for at skæringen med andenaksen er i punktet nul. Er det rimeligt at sige, at linjen går gennem (0,0)?

3° Opskriv regressionmodellen M_3^* , hvor middelværdien af *erosionHigh* er proportional med *regnHigh* (linjen har skæring med andenaksen i nul). Estimer denne model i **R** ved et passende kald til **lm**.

Angiv et 95%-konfidensinterval for hældningen i model M_3^* .

Angiv et 95%-konfidensinterval for middelværdien af erosionen (linjens værdi), når den årlige nedbør er 500 mm.

Prøv at beskrive i ord forskellen mellem de to konfidensintervaller i dette spørgsmål og de to konfidensintervaller i spørgsmål 1°.

Opgave 1.40 *Prøve kalibreringsberegning*

Denne opgave omhandler måden, hvorpå absorption af lys i en væske afhænger af koncentrationen af et absorberende molekyle i væsken, og hvordan vi kan bruge dette til at estimere koncentrationen ud fra en målt lysintensitet. Man måler lysintensiteten I ved forskellige kendte koncentrationer af det absorberende molekyle. På denne måde får man etableret en kalibreringskurve, der efterfølgende kan benyttes til at finde koncentrationen af molekylet i en prøve ud fra en måling af lysintensiteten efter lysets passage gennem prøven.

Absorption af denne type beskrives typisk via Lambert-Beers lov:

$$I = I_0 \exp \{ -\varepsilon v c \}. \quad (1.11)$$

Her er ε absorptionskoefficienten for det absorberende molekyle, v er vejlængden gennem materialet, c er koncentrationen af molekylet og I_0 er lysintensiteten når koncentrationen er nul.

I denne opgave betragter vi en serie målinger af lysintensiteten I som funktion af koncentrationen for en opløsning af Rhodamine 6G i ethanol. Den benyttede vejlængde gennem opløsningen er $v = 1.00$ cm. Egentligt burde man i modelleringen af data også tage hensyn til, at koncentrationen af opløsningsmidlet ethanol ændrer sig, når koncentrationen af Rhodamine ændres, men denne effekt er så lille, at vi kan se bort fra den. Tager vi logartimen på begge sider i Lambert-Beers lov (1.11), får vi

$$H = \alpha - \varepsilon v c, \quad (1.12)$$

hvor $\alpha = \log(I_0)$ og $H = \log(I)$.

Data i filen *LambertBeer.csv* giver den målte værdi af lysintensiteten I for 16 forskellige valg af koncentrationen. Filen har to søjler, hvor første søjle er koncentration, og anden søjle er lysintensiteten.

1. Dan en variabel *logLys* med logaritmen til de målte lysintensiteter og en variabel *konc* med koncentrationerne af Rhodamine 6G. Lav en figur, hvor *logLys* afsættes mod koncentrationen *konc*. Synes I, at der er en lineær sammenhæng i data? Synes I, at sammenhængen er god, med henblik på at estimere koncentration ud fra lysintensiteten?
2. Opskriv den lineære regressionsmodel, hvor respons er logaritmen til lysintensiteten, og den forklarende variabel er koncentration. Forklar, at regressionskoefficienten β i denne model er $\beta = -\varepsilon v$. Estimer modellen og indtegn den estimerede linje i figuren ovenfor.
3. Beregn et 95%-konfidensinterval for den ukendte koncentration af Rhodamine 6G i tre tilfælde med en enkelt ny måling af lysintensiteten *Lys*. De tre tilfælde er $Lys = 2654$, $Lys = 4512$ og $Lys = 7688$. Lav en tabel med resultaterne.



Opgave 1.41 Løvejagt

I denne opgave skal I bruge en lineær regressionsmodel til at sige noget om værdien af den forklarende variabel ud fra en målt responsværdi. I opgaven her er den forklarende variabel alderen af en løve, og respons er fraktion af sort pigment i løvens næsetip.

I artiklen [Sustainable trophy hunting of African lions](#) diskuteres hvordan trofæjagt af løver kan gøres bæredygtigt. Forfatterernes konklusion er, at man skal sørge for, at de løver, der jages, er hanløver over en vis alder. Ofte bruger jægeren størelsen og farven af løvens manke til at vurdere alderen, men dette er en meget usikker metode. En mere sikker metode består i at bruge andelen af sort pigment i løvens næsetip. I opgaven her skal I se på, hvordan andelen af sort pigment afhænger af alderen, og hvor godt vi kan estimere alderen ud fra dette.

Data for 32 hanløver fra Serengeti og Ngorongoro nationalparkerne ligger i filen *Loeve.csv*, der har to søjler med henholdsvis alder (år) og fraktion af sort.

- 1° Lav en figur, hvor *fraktion af sort* afsættes mod *alder*. Styr start og slut på andenaksen med tilføjelsen `ylim=c(0,1)` til `plot`. Synes du, at der er en lineær sammenhæng i data? Synes du, at sammenhængen er god med henblik på at estimere alder ud fra fraktion af sort i næstippen?
- 2° Opskriv den lineære regressionsmodel, hvor respons er fraktion af sort i næstippen, og den forklarende variabel er alder.
Find skøn og 95%-konfidensinterval for hældning og skæring, og indtegn den skønnede linje i figuren fra foregående spørgsmål. Angiv også et skøn over spredningen σ omkring den lineære sammenhæng.
Lav figurer, der kan bruges til modelkontrol, og kommenter på disse figurer.
- 3° Betragt situationen, hvor en ny løve registreres, og fraktion af sort i næsen for denne løve er 0.2. Beregn et 95%-konfidensinterval for løvens alder i dette tilfælde.

Gentag beregningen i tre andre tilfælde, hvor en løve er observeret med henholdsvis 0.4, 0.6 og 0.8 for fraktionen af sort i næsen. Lav en tabel med resultaterne for de fire tilfælde.

Hvis vi kun ønsker at skyde løver, der er mindst 5 år gamle, hvor stor synes du så fraktionen af sort i næsen skal være, før du skyder?

Opgave 1.42 *Uafhængighed af gennemsnit og hældning.*

Betragt regressionsmodellen $X_i \sim N(\alpha + \beta t_i, \sigma^2)$ fra afsnit 4.1.

- 1° Vis at $\text{Cov}(\bar{X}, \hat{\beta}(\mathbf{X})) = 0$ og gør rede for $\bar{X}$ er uafhængig af $\hat{\beta}(\mathbf{X})$ således som det hævdes på s. 60 i de supplerende noter.

Opgave 1.43 *Udlede skøn*

Betragt regressionsmodellen $X_i \sim N(\beta t_i, \sigma^2)$, $i = 1, \dots, n$, $(\beta, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+$, hvor skæringen er kendt og lig med nul.

- 1° Udled formelen for maksimum likelihood estimatet $\hat{\beta}$.
- 2° Udled fordelingen af $\hat{\beta}$.
- 3° Idet du må bruge, at $\hat{\beta}$ og variansskøn er uafhængige, skal du udlede et t -test for hypotesen $\beta = \beta_0$.

Opgave 1.44 *Kovarians*

- 1° Vis, ud fra definitionen på kovarians, at $\text{Cov}(a + bX, c + dY) = b \cdot d \cdot \text{Cov}(X, Y)$, hvor a, b, c, d er konstanter.

Opgave 1.45 *Fordeling af skøn*

Betragt den lineære regressionsmodel $X_i \sim N(\alpha + \beta t_i, \sigma^2)$, $i = 1, \dots, n$, og lad t_* være en fast kendt værdi af den forklarende variabel t . Som skøn over $\theta = \alpha + \beta t_*$ bruger vi $\hat{\theta} = \hat{\alpha} + \hat{\beta} t_*$.

- 1° Vis, at $\hat{\theta} \sim N\left(\theta, \sigma^2 \left(\frac{1}{n} + \frac{(t_* - \bar{t})^2}{SSD_t}\right)\right)$.

Opgave 1.46 *Fordeling af SSD i lineær regression*

Betragt den lineære regressionsmodel

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n. \quad (1.13)$$

hvor X_i erne er uafhængige.

1° Vis, at hvis vi betragter SSD størrelsen med de sande parametre indsat, det vil sige

$$\sum_{i=1}^n (X_i - (\alpha + \beta t_i))^2,$$

så vil denne have en $\sigma^2 \chi^2(n)$ fordeling.

Opgave 1.47 Fordeling af $\hat{\beta}$

I denne opgave vil vi vise fordelingsresultatet vedrørende $\hat{\beta} = \hat{\beta}(\mathbf{X})$ fra (4.7) i de supplerende noter. Betragt den lineære regressionsmodel

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n.$$

hvor X_i erne er uafhængige. Vi benytter som i de supplerende noter betegnelserne:

$$\bar{t} = \frac{1}{n} \sum_{i=1}^n t_i, \quad \text{SSD}_{\mathbf{t}} = \sum_{i=1}^n (t_i - \bar{t})^2, \quad \text{SPD}_{\mathbf{Xt}} = \sum_{i=1}^n (X_i - \bar{X})(t_i - \bar{t}),$$

hvor $\bar{x}$ er defineret på samme måde som $\bar{t}$, dvs.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

1° Vis, at

$$\sum_{i=1}^n (t_i - \bar{t}) = 0$$

og slut heraf, at

$$\text{SPD}_{\mathbf{Xt}} = \sum_{i=1}^n X_i (t_i - \bar{t}).$$

2° Vis, at

$$\text{SPD}_{\mathbf{Xt}} \sim N(\beta \text{SSD}_{\mathbf{t}}, \sigma^2 \text{SSD}_{\mathbf{t}})$$

og slut heraf, at $\hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{\text{SSD}_{\mathbf{t}}}\right)$ som angivet i (4.7).

Opgave 1.48 Ensidede variansanalyse

I denne opgave bruger vi data fra artiklen [Grain size discrimination between sands of desert and coastal dunes from northwestern Mexico](#). Forfatterne ønsker at undersøge, om der er forskel i størrelsesfordelingen af sandprøver indsamlet tre forskellige steder i *Altar ørkenen* i det nordlige Mexico, nær grænsen til USA. Størrelsesfordelingen bestemmes ved brug af en *Laser Particle Size Analyzer*, og i denne opgave ser vi på *middelkornstørrelsen* for hver sandprøve.

Datasættet rummer 14 prøver fra *San Luis Rio Colorado*-området (kodet som `SanLuis` i datafilen), 16 prøver fra *Pinacate North* (`PinaNorth`) og 8 prøver fra *Pinacate South* (`PinaSouth`). De tre områder ligger omtrent 100 km fra hinanden. Data ligger i filen `Sandproever.csv`. Der er 38 rækker i filen svarende til de 38 sandprøver i eksperimentet, og to søjler med henholdsvis område og middelkornstørrelse. Kornstørrelsen måles på Phi-skalaen, der fremkommer ved at tage to-tals logaritmen til kornstørrelsen i millimeter. Gennemsnit og empirisk spredning for hvert område er gengivet i Tabel 1.1.



Figur 1.4: Altar ørkenen i Sonora, Mexico

Område	San Luis Rio Colorado	Pinacate north	Pinacate south
Antal sandprøver	14	16	8
Gennemsnit	2.066	2.609	2.585
Empirisk spredning	0.154	0.084	0.159

Tabel 1.1: Beskrivelse af sandprøverne fra de tre områder.

- 1° Indlæs data, og dan de to variable `omraade` og `kornstr` med indholdet af de to søjler. Lav et boxplot og et QQplot af `kornstr` opdelt efter område. Overvej, hvad disse figurer viser om forholdet mellem spredningerne i de tre områder og forholdet mellem middelværdierne.
- 2° Opskriv den statistiske model, hvor data er delt ind i tre grupper svarende til de tre områder, og data er normalfordelt med en middelværdi og varians, der afhænger af gruppen.
Opskriv hypotesen, at de tre varianser er ens. Benyt R-funktionen `bartlett.test` til at udføre Bartlett's test, for at de tre varianser er ens. Hvad bliver konklusionen af testet?
- 3° Opskriv den statistiske model, hvor middelværdien afhænger af området, men de tre varianser er ens. Find estimator i denne model (både for middelværdierne og for spredningen). Benyt parametertabellen til at lave et t -test for hypotesen, at $\mu_{\text{PinaNorth}} = \mu_{\text{PinaSouth}}$.
Angiv et 95%-konfidensinterval for $\mu_{\text{SanLuis}} - \mu_{\text{PinaNorth}}$.
- 4° Opskriv hypotesen, at de tre middelværdier er ens, og lav et test for denne hypotese ved et passende kald til `anova`.
Hvad bliver konklusionen i denne opgave: er det rimeligt at sige, at der er samme middelværdi af middelnørstørrelsen i de tre områder af Altar ørkenen?

Opgave 1.49 *Tosidet variansanalyse*

I artiklen [Environmental heterogeneity does not affect levels of phenotypic plasticity in natural populations of three *Drosophila* species](#) undersøges, hvordan forskellige arter og geografisk adskilte

grupper af bananfluer reagerer på miljøpåvirkninger. I denne opgave skal I se på en delmængde af data, hvor der betragtes *D. melanogaster* indsamlet i henholdsvis Danmark og Italien. Fra ægstadiet og frem udsættes fluerne for tre forskellige behandlinger: *C* (constant), *PF* (predictable fluctuation) og *UF* (unpredictable fluctuation).

For *C*-gruppen holdes temperaturen konstant på 23 °C hen over døgnet, for *PF* følger temperaturen en sinuskurve med maksimum på 18 °C og minimum på 13 °C, og for *UF* følger temperaturen også en sinuskurve, men med stokastiske maksimum og minimum for hvert døgn. Ved en given alder udsættes fluerne for en kritisk varmepåvirkning (37.5 °C uafbrudt), og tiden (målt i minutter) indtil fluen går i koma registreres. Formålet er at undersøge, om forskelle i opvækstbetingelserne påvirker fluernes evne til at tåle varmepåvirkningen, og om der er forskel mellem de to geografiske populationer med hensyn til denne evne.

Gennemsnit og empirisk spredning for logaritmen til tiden indtil koma er gengivet for hver kombination af land og behandling i Tabel 1.2.

(Land, Behandling)	(DK, <i>C</i>)	(DK, <i>PF</i>)	(DK, <i>UF</i>)	(IT, <i>C</i>)	(IT, <i>PF</i>)	(IT, <i>UF</i>)
Antal fluer	20	20	20	20	20	20
Gennemsnit	4.09	4.69	4.26	3.89	4.28	4.06
Empirisk spredning	0.54	0.49	0.44	0.55	0.52	0.54

Tabel 1.2

Data i artiklen kan findes under *Dryad Digital Repository*. Data til opgaven her er i filen *Bananfluer.csv*, hvor søjle 1 angiver land, søjle 2 angiver behandling og søjle 3 angiver tiden i minutter, indtil fluen går i koma.

- 1° I skal først se på, om tidsmålingerne kan beskrives med en normalfordeling, eller om man først bør tage logaritmen til tidsmålingerne. Indlæs data og dan variablene `land`, `behandling` og `tid`. Udvælg tre af de seks kombinationer af land og behandling, og lav QQplot af `tid` for hver af disse. Lav dernæst tilsvarende qqplots for logaritmen til `tid`.

Hvad bliver din konklusion ud fra de to figurer?

Lav dernæst interaktionsplot for logaritmen til tiden i forhold til de to faktorer land og behandling.

- 2° Opskriv modellen, hvor logaritmen til tidsmålingen hørende til hver gruppe bestemt af land og behandling følger sin egen normalfordeling.

Opskriv hypotesen, at varianserne i de 6 grupper er ens, og benyt `bartlett.test` til at have udføre Bartlett's test for denne hypotese. Er det rimeligt at sige, at de seks varianser er ens?

- 3° Opskriv modellen, hvor logaritmen til tiden er normalfordelt, og hver gruppe bestemt af land og behandling har sin egen middelværdi, og alle har den samme varians. Opskriv inden for denne model additivitetshypotesen, hvor middelværdien består af et bidrag fra land og et bidrag fra behandling.

Lav et test, for at data kan beskrives med den additive model. Hvad bliver konklusionen af testet? Stemmer konklusionen, med hvad du kan se i interaktionsplottet?

- 4° Lav et test for henholdsvis ingen effekt af behandling og ingen effekt af land inden for den additive model.
 - 5° Angiv inden for den additive model et 95%-konfidensinterval for forskellen i middelværdi af logaritmen til tiden mellem de to lande.
- Oversæt det fundne interval til et interval for forholdet mellem middelværdierne af tid indtil koma for de to lande.

Opgave 1.50 *Teste for en lineær sammenhæng*

I hydrologi benyttes ofte **Darcys lov** til at beregne vandgennemstrømningen i jordlag. Loven siger, at vandgennemstrømningen er proportional med trykforskellen (trykgradienten). Darcy formulerede loven i 1856 på baggrund af eksperimenter, hvor vand strømmer gennem et rør fyldt med sand. Sidenhen er der tilføjet flere aspekter til loven, så man kan tage højde for yderligere forhold ved vandgennemstrømning.

Darcys lov kan skrives som $Q = \alpha \cdot P$, hvilket fører til en lineær sammenhæng på logaritmisk skala:

$$\log(Q) = \gamma + \beta \cdot \log(P),$$

hvor Q er vandgennemstrømningen, og P er trykforskellen. Man forventer her, at $\beta = 1$. I skal i denne opgave undersøge, om der er en lineær sammenhæng i logaritmisk skala, og dernæst om $\beta = 1$.

De data, I skal bruge, er Darcys oprindelige målinger suppleret med to simulerede gentagelser af eksperimentet (i artiklen nævnes, at chefingeniør Mr. Baumgarten gentog eksperimentet, men data herfra er ikke opgivet). Disse data findes i filen *Darcy.csv*, som indeholder 30 rækker og 2 søjler: hver række svarer til én måling, hvor søjle 1 angiver trykforskel (i meter vandsøjle), og søjle 2 angiver vandgennemstrømning (i liter per minut). For hver trykforskel er der tre målinger af vandgennemstrømningen.

vandgennemstrømningen inddrages.

- 1° Indlæs data, og dan de to variable `logTryk` og `logVand` med logaritmen til trykforskel og logaritmen til vandgennemstrømningen. Lav en figur, hvor logaritmen til vandgennemstrømningen afsættes mod logaritmen til trykforskel. Dan en faktor `fakTryk` ud fra variabelen `logTryk`. Beregn gennemsnit (benyt f.eks. `tapply(logVand, fakTryk, mean)`) for hver trykforskelgruppe og indtegn disse gennemsnit som en kurve i figuren. Indsæt endelig regressionslinjen fra en regression af `logVand` på `logTryk`.
 - 2° Opskriv den statistiske model M_1 , hvor hver trykforskelgruppe har sin egen middelværdi af logaritmen til vandgennemstrømningen, og varianserne er ens.
- Opskriv også den statistiske model M_2 , hvor middelværdien af `logVand` afhænger lineært af `logTryk`.

Lav nu F -testet for reduktion fra model M_1 til model M_2 . Hvad bliver konklusionen af testet: er det rimeligt at sige, at middelværdien af logaritmen til vandgennemstrømningen afhænger lineært af logaritmen til trykforskel?

- 3° Angiv 95%-konfidensintervaller for skæring og hældning og for spredning omkring linjen i den lineære regressionsmodel. Kan det antages, at hældningen er 1 i overensstemmelse med Darcys lov?

Opgave 1.51 *Scanning and browsing*

I artiklen [Effects of user age on smartphone and tablet use, measured with an eye-tracker via fixation duration, scan-path duration, and saccades proportion](#) undersøges, hvordan brugen af smartphones og tablets varierer mellem forskellige aldersgrupper. Under brugen registreres en persons øjenbevægelser, og herudfra dannes et mål, SPD (scan-path duration, målt i millisekunder). SPD afspejler en persons evne til at bruge redskabet, idet en længere SPD indikerer mindre effektiv scanning og browsing.

Personerne opdeles i tre aldersgrupper: unge, midaldrende og ældre. Derudover inddeles de i to eksperimenter (Ex1 og Ex2). Hvert eksperiment omfatter ni opgaver inden for brugen af forskellige smartphone-apps, og hver opgave varierer mellem de to eksperimenter.

Data er i filen *Smartphone.csv* der har tre søjler med henholdsvis eksperiment, aldersgruppe og SPD -målingen.

- 1° Lav en figur med 3 delplots med QQplots af SPD for de tre aldersgrupper for eksperiment 1. Kommenter på figuren.

Opskriv den statistiske model, hvor hver gruppe bestemt af aldersgruppe og eksperiment har sin egen middelværdi og sin egen varians af SPD , og data er normalfordelt. Lav et test for hypotesen, at der er samme varians i de 6 grupper.

- 2° Lav et interaktionsplot, og kommenter på hvad du ser i figuren. Opskriv modellen, hvor hver gruppe bestemt af aldersgruppe og eksperiment har sin egen middelværdi af SPD , og alle grupperne har den samme varians. Opskriv hypotesen om en additiv struktur af middelværdien med et bidrag fra aldersgruppe og fra eksperiment. Lav F -testet for hypotesen om additivitet.

- 3° Undersøg, om det kan antages, at aldersgruppe ikke har nogen effekt på SPD . Undersøg også, om eksperiment har nogen effekt på SPD . Husk at skrive modellerne op.

- 4° Angiv skøn over middelværdien blandt de ældre for eksperiment Ex1. Angiv et 95%-konfidensinterval for forskellen i middelværdi af SPD mellem gruppen af unge og gruppen af ældre inden for den additive model.

Angiv skøn over spredningen på SPD i den additive model.

Opgave 1.52 *Bartlett's test*

Betragt k uafhængige varianssskøn $V_1, \dots, V_k$ med $V_j \sim \sigma_j^2 \chi^2(f_j)/f_j$. Skriver man tætheden op for

V_j , kan man se, at logaritmen til likelihoodfunktionen baseret på V_j er

$$l_j(\sigma_j^2; v_j) = \log \left(\frac{(f_j/2)^{f_j/2} v_j^{f_j/2-1}}{\Gamma(f_j/2)} \right) - \frac{f_j}{2} \log(\sigma_j^2) - \frac{f_j}{2\sigma_j^2} v_j.$$

1° Vis, at maksimum likelihoodskønnet for σ_j^2 baseret på tætheden af V_j er $\hat{\sigma}_j^2 = V_j$. Vis dernæst, at maksimum af log-likelihoodfunktionen er

$$l_j(\hat{\sigma}_j^2; v_j) = \log \left(\frac{(f_j/2)^{f_j/2} v_j^{f_j/2-1}}{\Gamma(f_j/2)} \right) - \frac{f_j}{2} \log(v_j) - \frac{f_j}{2}.$$

2° Betragt nu hypotesen, at de k varianser er ens, hvor vi betegner den fælles værdi med σ^2 . Vis, at under hypotesen om ens varianser er maksimum likelihoodskønnet for den fælles varians σ^2 givet ved $\hat{\sigma}^2 = \sum_j f_j V_j / f$, hvor $f = f_1 + \dots + f_k$.

3° Betragt nu log-likelihoodratio teststørrelsen, her betegnet med λ_{Ba} , på formen

$$\lambda_{Ba} = -2 \left\{ \sum_j l_j(\hat{\sigma}; v_j) - \sum_j l_j(\hat{\sigma}_j; v_j) \right\}.$$

Vis, at

$$\lambda_{Ba} = f \cdot \log(\hat{\sigma}^2) - \sum_j f_j \log(\hat{\sigma}_j^2).$$

Dette er Bartlett teststørrelsen fra (3.26) på nær divisoren C . Faktoren C findes ved at lave en Taylorudvikling af middelværdien af λ_{Ba} .

Opgave 1.53 *Selv udregne F -test*

Gå tilbage til spørgsmål 4° i Opgave 1.48, hvor der laves et F -test for at middelværdierne i de tre grupper er ens.

1° Udregn F -teststørrelsen ved kun at bruge output fra `summary(lm(modelformel))` for passende valg af modelformler.

2° F -teststørrelsen er på formen $s^2(M_1, M_2)/s_{01}^2$. Udregn $s^2(M_1, M_2)$ ved kun at benytte `lm(modelformel)$fitted.values` eller `predict` for passende valg af modelformler.

Opgave 1.54 *Selv udregne Bartlett's teststørrelse*

Gå tilbage til spørgsmål 2° i Opgave 1.48, hvor Bartlett's test for ens varianser betragtes.

Beregn Bartlett's teststørrelse baseret udelukkende på informationen i Tabel 1.1 med gennemsnit og empiriske spredninger i de tre grupper.

Opgave 1.55 *Selv udregne konfidensinterval*

Gå tilbage til spørgsmål 5° i Opgave 1.49, hvor der findes et konfidensinterval for forskellen i middelværdi af logaritmen til tiden mellem de to lande. Beregn dette interval baseret på den information du får fra et passende kald til `summary(lm(modelformel))`.

Opgave 1.56 *Flere regressionslinjer*

I denne opgave betragtes længde og bredde af sprækker i jordoverfladen i de canadiske Rocky Mountains samt i Kyushu i Japan og Kilve i England. Data er fra artiklen [A modern regression approach to determining fault displacement-length scaling relationships](#).

Data findes i filen *Spraekker.csv*, der har tre søjler. Den første søjle angiver området (med værdierne RM, Kyushu og Kilve), den anden søjle indeholder længden og den tredje søjle bredden af sprækkerne, begge målt i meter.

- 1° Indlæs data, og dan variablen `omr` med område og variablene `logL` og `logB` med henholdsvis logaritmen til længden og logaritmen til bredden. Hvis `omr` ikke er en faktor efter indlæsningen, skal du omdanne den til en faktor.

Lav en figur, hvor logaritmen til bredden afsættes mod logaritmen til længde, og hvor hver af de tre områder har sin egen farve (dette opnås med tilføjelsen `col=omr` til `plot`-kommandoen).

Estimer for hver af de tre områder parametrene i modellen, hvor middelværdien af logaritmen til bredden afhænger lineært af logaritmen til længden. Indtegn efterfølgende de tre estimerede linjer i jeres figur (Husk, at en regressionslinje kan indtegnes ved at benytte `abline`, hvor input er output fra et kald til `lm`).

- 2° Opstil den statistiske model, hvor hvert område har sin egen lineære sammenhæng mellem middelværdien af `logB` og `logL`, og hvert område har sin egen varians omkring den lineære sammenhæng. Opstil hypotesen, at der er samme varians for de tre områder. Benyt Bartlett's test for at vurdere denne hypotese.

- 3° Opstil nu den reducerede model, hvor der er samme varians i de tre regressionsmodeller (selvom p -værdien i Bartlett's test var lidt under 5%, vælger vi at sige samme varians). Undersøg, om det kan antages, at de tre hældninger er ens.

Undersøg dernæst, om det kan antages, at de tre skæringer er ens.

- 4° For modellen, hvor der er den samme hældning for de tre områder, skal du angive skøn og konfidensinterval for de parametre, der indgår i modellen.

Kan det antages, at hældningen er 1, svarende til at bredden er proportional med længden?

Opgave 1.57 *Multipel regression*

Hvordan måler man vægten af en bjørn? Man kunne umiddelbart tænke, at det blot kræver en stor vægt i felten og en bjørn, der villigt træder op på den. I praksis er dette imidlertid ikke så ligetil, og inden for vildtpleje vil man ofte kunne have behov for at vurdere vægt ud fra mere tilgængelige morfometriske mål. I denne opgave skal betragtes en multipel regressionsmodel til at beskrive bjørnens vægt ud fra sådanne mål, som er lette at foretage, når bjørnen er bedøvet.

Hvorfor er det relevant at kende bjørnens vægt? I artiklen [Estimating the Live Body Weight of American Black Bears in Florida](#) påpeger forfatterne, at "Collecting body weight measurement is therefore recommended during handling because demographic and reproductive variables are functionally dependent on weight rather than age."

Det er dog ikke data fra den nævnte artikel der benyttes i denne opgave, men derimod et datasæt fra **R**-pakken `Bolstad`. Oprindelsen af datasættet beskrives i pakken således: *"This data set was supplied by Gary Alt."* Data findes på kursushjemmesiden i filen `Bear.csv`.

Datasættet har søjlerne `headlen` (hovedlængde i tommer), `headwid` (hovedbredde i tommer), `neck` (nakkeomkreds i tommer), `length` (bjørnens længde i tommer), `chest` (brystomkreds i tommer) og `weight` (vægt i pund). En rumfangsbetragtning gør, at man kan forestille sig en relation, der siger, at vægt er proportional med længde gange brystomkreds. Denne type tankegang gør, at det er en fordel at bruge log-transformerede data i den multiple regressionsmodel.

1° Indlæs data fra filen `Bear.csv`, og dan variable med logaritmen til værdierne i de seks søjler.

Opskriv den fulde regressionsmodel, model M_1 , hvor middelværdien af logaritmen til vægten afhænger lineært af de fem logaritmer til de morfometriske mål.

Lav et QQplot af residualerne i denne model.

2° Reducer den fulde multiple regressionsmodel ved successivt at fjerne led i modellen (backward-selektion). Lav en tabel som for hver model i den successive procedure indeholder model, spredningsskøn $s(M)$, den største p -værdi for test af hypotese om at en regressionskoefficient er nul og angivelse af den tilhørende hypotese.

Lav desuden et F -test for reduktion fra den fulde model til slutmodellen ved backward selektionsproceduren.

3° Lav figurer med residualerne for slutmodellen afsat mod hver af de forklarende variable og med nullinjen indsat (linjen med skæring nul og hældning nul). Lav desuden et QQplot af residualerne. Lav endelig en figur hvor logaritmen til vægten afsættes mod de forventede værdier og indsæt identitetslinjen (linjen med skæring i nul og hældning 1) i denne figur.

Giver slutmodellen en god beskrivelse af data? Inddrag eventuelt spredningsskønnet $s(M)$ for slutmodellen i din diskussion. Husk at modellen er for logaritmen til vægten, således at en spredning på for eksempel 0.05 svarer til en 5 procents spredning på vægten.

4° Lav et 95%-konfidensinterval for middelværdien af logaritmen til vægten og et 95%-prædiktionsinterval for logaritmen til vægten for en ny bjørn med `length`=45, `chest`=25 og `neck`=13.

Benyt `predict` i **R**.

Oversæt det sidste interval til et interval for vægten.

5° I en model på formen

$$\text{weight} = \text{constant} \cdot \text{length}^\alpha \cdot \text{chest}^\gamma \cdot \text{neck}^\tau$$

vil vi ud fra en "dimensionsanalyse" forvente at $\alpha + \gamma + \tau = 3$. Stemmer dette overens med skønnene over regressionskoefficienterne i den multiple regressionsmodel?

Opgave 1.58 BMI for fisk

Data i filen `Tampere.csv` giver tre længdemål samt højde, bredde og vægt for 126 fisk fordelt på fem arter. De tre længdemål adskiller sig ved, hvor langt ud langs halen der måles. Data er oprindeligt

publiceret i artiklen *Bidrag till kaennedom on fiskbestondet i vaera sjoeaer. Laengelmaevesi*, men er her hentet på adressen [JSE Data Archive](#).

- 1° Indlæs data og dan variablene `Art` (første søjle), `logL1`, `logL2`, `logL3`, `logH`, `logB`, `logV` med logaritmen til værdierne i søjlerne 2 til 8, og dan til sidst variabelen `logBMI=logV-3*logL3+log(1000)`. Den sidste variabel er logaritmen til et body mass index for fiskene på formen $BMI = V/(L^3/10)^3$.
Lav to deldatasæt for henholdsvis Aborre og Brasen med kommandoerne `logAborre=logBMI[Art=="Aborre"]` og `logBrasen=logBMI[Art=="Brasen"]`, eller ved at bruge `subset`.
- 2° For de 56 aborrrer i datasættet er der 9, der har et BMI over 12. Opstil en statistisk model til beskrivelse af observationen 9, og lav et 95%-konfidensinterval for sandsynligheden, for at en aborre har et BMI over 12.
- 3° For de 34 brasen i datasættet er der 4, der har et BMI over 12. Undersøg, om der er samme frekvens af fisk med BMI over 12 blandt de to arter aborre og brasen.
- 4° Opstil en statistisk model til beskrivelse af data i `logAborre` og `logBrasen`. Lav et test for hypotesen, at der er samme middelværdi af logaritmen til BMI for de to fiskearter.
- 5° Betragt nu logaritmen til BMI for alle fem fiskearter. Opstil en statistisk model for data, og undersøg først, om der er samme varians for de fem arter, og dernæst, om der er samme middelværdi for de fem arter.
- 6° Opstil en multipel regressionsmodel til beskrivelse af logaritmen til vægten (`logV`) for aborre ud fra aborre-værdierne for de fem forklarende variable `logL1`, `logL2`, `logL3`, `logH` og `logB`. Reducer modellen ved brug af backward-selektion og lav grafisk kontrol af slutmodellen. Lav et test for reduktion fra startmodel til slutmodel og angiv 95%-konfidensintervaller for parametrene i slutmodellen.

Opgave 1.59 *Multipel regression baseret på NIR-spektrum*

I artiklen [Near-infrared spectroscopy as a novel non-invasive tool to assess Spiny Lobster nutritional condition](#) undersøges muligheden for at anvende near-infrarød (NIR) spektrometri til at vurdere den ernæringsmæssige tilstand hos [languster](#). Forfatterne forklarer selv motivationen således: “A practical, rapid and non-invasive technique to analyse lobster nutritional condition has considerable potential to assist with the management of wild stocks, ...”

I denne opgave ønsker man at undersøge muligheden for at beskrive *abdomial muscle dry matter content* (AMDM) ud fra NIR-spektret. Data for 89 languster findes i filen *Lobster.txt*. Hver række i datasættet svarer til én languster, og de første 495 søjler angiver NIR-spektret for bølgelængder i området 1063–1334 nm. Søjle 496 rummer værdierne af AMDM. Spektret er oprindeligt målt for bølgelængder i intervallet 1063–2354 nm, men forfatterne vælger kun at benytte intervallet 1063–1334 nm til at beskrive AMDM.

1° Indlæs de 89 spektre og de 89 AMDM-værdier med kommandoerne

R-kode 1.7

```
dat=matrix(scan("Lobster.txt"),89,496,byrow=TRUE)
spek=dat[, -496]; amdm=dat[, 496]
```

Benyt **R**-funktionen `forward` til at opbygge en multipel regressionsmodel ved forward selektion med op til 15 forklarende variable. Lav en figur med to delfigurer. Den venstre delfigur skal vise skøn over spredning $s(M_j)$, $j = 1, \dots, 15$, hvor M_j er modellen med j forklarende variable, og den højre delfigur skal vise p -værdien for test af hypotesen $\beta_j = 0$, hvor β_j er regresionskoefficienten hørende til det sidste led i modellen M_j . Lav endvidere en tabel med numrene på de forklarende variable i den rækkefølge som de inkluderes.

Vurder ud fra disse figurer, hvor mange led der skal medtages i den multiple regressionsmodel.

2° Lav en figur, hvor både spredningsskøn $s(M_j)$ og crossvalidation prædiktionsspredningen s_{cv} afsættes mod j , med hver sin farve.

Hvilken model vil man vælge til beskrivelse af AMDM ud fra NIR-spektret?

3° For den valgte multiple regressionsmodel skal der laves en figur, hvor den målte værdi af AMDM afsættes mod den forventede værdi, og identitetslinjen indtegnes. Indtegn desuden to linjer med hældning 1 i afstanden $\pm 2s_{cv}$, hvor s_{cv} hører til den valgte model. Ser denne figur ud, som forventet?

Lav desuden et QQplot af residualerne i modellen.

Diskuter størrelsen af crossvalidation prædiktionsspredningen s_{cv} for den valgte model i forhold til variationsområdet for AMDM (forfatterne nævner en værdi på 1.41 for prædiktionsspredningen for en noget mere kompliceret model end den I betragter i opgaven her).

Opgave 1.60 *Firmaers værdi*

Opgaven er baseret på en eksamensopgave i MM1, forår 2004.

I denne opgave studeres sammenhængen mellem amerikanske firmaers markedsværdi og omsætning. I alt har vi data for 35 firmaer fordelt på tre sektorer. Mere præcist er 10 af firmaerne beskæftiget med detailhandel, 15 firmaer er indenfor energisektoren og de resterende 10 firmaer er i industri-sektoren.

Der ønskes en beskrivelse data med en model, hvor der for hver sektor er en lineær sammenhæng mellem markedsværdien og omsætningen. Data findes i filen `Firmaer.csv` der har fire søjler: observationsnummer, `sektor` angiver sektoren, `vaerdi` angiver firmaets markedsværdi, og `omsaet` firmaets omsætning. Husk i spørgsmålene nedenfor at opskrive den statistiske model.

- 1° Lav et plot af omsætning mod værdi, hvor hver sektor har sin egen farve, og indtegn en regressionslinje til hver sektor.
- 2° Vis, at det kan antages, at variansen ikke afhænger af sektoren.
- 3° Vis, at det kan antages, at der er samme hældning på de tre regressionslinjer.
- 4° Vis, at det ikke kan antages, at den fælles hældning er 0.
- 5° Angiv et 95%-konfidensinterval for spredningen på omsætningen.
- 6° Angiv et 95%-konfidensinterval for den fælles hældning på de tre regressionslinjer.

Opgave 1.61 Data i denne opgave stammer fra en undersøgelse foretaget af Bo Utoft, Afdeling for Zoologi, Biologisk Institut, Aarhus Universitet.

Undersøgelsen drejede sig om kromoptagelsen i befrugtede ørredæg, *Salmon trutta L.* æggene blev rekvireret fra et dambrug og blev kunstigt befrugtet i laboratoriet. Æggene blev anbragt i inkubatorer med vand, som indeholdt krom. Der var i alt 8 inkubatorer, hvor vandet indeholdt krom i stigende koncentration fra 1 $\mu\text{g Cr/L}$ til 1000 $\mu\text{g Cr/L}$. På visse dage blev fem æg udtaget fra hver koncentration, og kromoptagelsen blev målt ved hjælp af en ^{51}Cr -isotop, som var tilsat forsøgsvandet. Æggene blev talt i en brøndkrystal på en tovejsscientilationstæller, og tællertallet blev derefter omregnet til kromindhold per gram tørvægt. Data er gengivet i Tabel 1.3 med én decimal, og findes på filen `fishchrome.csv`, der indeholder de tre søjler `conc`, `days` og `logchrom` som dækker over henholdsvis kromkoncentration i vandet, antal dage æggene var i vandet og logaritmen til indholdet af krom.

Formålet med forsøget er at belyse, hvordan kromindhold afhænger af eksponeringen, både med hensyn til varigheden og koncentrationen.

Nærmere studium af data viser, at jo større kromindholdet er, desto større er variationen, så derfor foretages den videre analyse på logaritmen til kromindholdet.

Der tages udgangspunkt i grundmodellen, at logaritmen til kromindholdet i æggene, x_{ij} , efter i dage i inkubatoren med den j te koncentration af krom, er en realisation af en normalfordelt stokastisk variabel, X_{ij} , hvis middelværdi, μ_{ij} , afhænger både af dage og af kromkoncentrationen, mens variansen σ^2 antages at være den samme for alle dage og alle kromkoncentrationer. Modellen kan kort skrives

$$M_1 : X_{ij} \sim N(\mu_{ij}, \sigma^2),$$

idet vi som sædvanlig antager, at observationerne er uafhængige. Kontroltegninger viser endvidere, at man kan acceptere additivitetsmodellen

$$M_2 : X_{ij} \sim N(\alpha_i + \beta_j, \sigma^2).$$

- 1° Lav et interaktionsplot til kontrol af M_2 .
- 2° Undersøg, om kromindholdet i æggene afhænger af, hvor længe æggene har ligget i inkubatorerne.

Dage	<i>Kromkoncentration i vandet i inkubatorerne</i> ($\mu\text{g Cr/L}$)							
	1	5	10	50	100	200	500	1000
1	2.0	3.9	4.5	11.3	15.3	19.4	30.1	36.1
2	2.2	3.9	5.3	10.8	14.8	19.5	29.6	37.8
3	2.0	3.7	5.5	10.9	15.2	18.7	30.4	45.3
4	2.1	4.1	5.8	13.8	14.4	23.9	34.3	42.0
6	2.5	4.5	6.3	12.1	17.3	23.0	34.2	44.0
8	2.0	4.6	5.5	11.9	15.0	22.3	31.5	44.8
14	3.1	5.6	10.2	16.5	22.9	28.4	49.3	54.8
22	3.7	6.5	11.0	19.8	27.9	32.7	53.7	54.8
29	4.2	7.1	11.7	21.4	31.2	37.2	58.7	69.6
37	4.6	8.5	9.5	23.3	34.0	36.4	62.0	82.9
43	3.8	6.6	10.6	28.0	30.2	42.2	58.7	75.2
49	3.8	7.5	8.7	21.6	30.2	37.7	54.3	70.2
57	4.9	9.1	14.1	25.9	41.5	50.5	69.4	105.5

Tabel 1.3: Kromindholdet i æggene i μg per gram tørvægt gengivet her med én decimal. Dage angiver, hvor længe æggene har ligget i inkubatorerne, inden deres kromindhold er målt.

- 3° Undersøg, om kromindholdet i æggene afhænger af kromkoncentrationen i vandet i inkubatorerne.
- 4° Angiv 95% konfidensintervallet for differensen mellem middelværdien af logaritmen til kromindholdet for æg, som har ligget 1 dag i vandet, og æg, som har ligget 57 dage i vandet.

Opgave 1.62 Denne opgave benytter samme data som Opgave 1.61. Opgaven giver en mere præcis beskrivelse af, hvordan kromindholdet i æggene afhænger af kromkoncentrationen i vandet. I første omgang koncentrerer vi os om de æg, som har ligget én dag i vandet.

- 1° Tegn *logaritmen til kromindholdet* i æggene op mod *logaritmen til kromkoncentrationen* i vandet og begrund en lineær regressionsmodel med *logaritmen til kromindholdet* i æggene som afhængig variabel og *logaritmen til kromkoncentration* i vandet som forklarende variabel.
- 2° Estimer parametrene i regressionsmodellen og indtegn den estimerede regressionslinje i tegningen i 1°.

Vi går herefter over til igen at betragte alle data.

- 3° Vurder om det er rimeligt at arbejde videre med en model med 13 regressionslinjer, som siger, at logaritmen til kromindholdet i æggene, x_{ij} , efter i dage i inkubatoren med den j te koncentration af krom, er en realisation af en normalfordelt stokastisk variabel, X_{ij} , hvis middelværdi afhænger lineært af logaritmen til kromkoncentrationen i inkubatorerne (t_j). Både afskæring, hældning og varians kan i første omgang antages at afhænge af, hvor mange dage æggene har ligget i inkubatoren.

	<i>Logaritmen til kromkoncentrationen</i>	<i>Logaritmen til indholdet af krom</i>
<i>j</i>	<i>i vandet t_j</i>	<i>i æg x_j</i>
1	0.000	0.698
2	1.609	1.352
3	2.303	1.501
4	3.912	2.422
5	4.605	2.727
6	5.298	2.965
7	6.215	3.406
8	6.908	3.587

Tabel 1.4: Sammenhørende værdier af logaritmen til kromkoncentration i vandet og logaritmen til kromindholdet i de æg, som har ligget én dag i inkubatorerne. Som i Tabel 1.3 indikerer j kromkoncentrationerne.

Modellen kan kort skrives

$$M_2: X_{ij} \sim N(\alpha_i + \beta_i t_j, \sigma_i^2),$$

idet vi underforstår, at observationerne er uafhængige.

4° Undersøg, om det kan antages, at varianserne er ens for de 13 regressionslinjer.

5° Undersøg, om det kan antages, at der er samme hældning for alle 13 regressionslinjer.

Opgave 1.63 *Beregne estimater ved hjælp af designmatricen*

1° Overvej, at R-kode 1.8 nedenfor danner realisationer $x_1, \dots, x_{10}$ fra en følge af 10 uafhængige normalfordelte stokastiske variable X_i , $i = 1, \dots, n$, hvor $X_i \sim N(i, 1)$.

R-kode 1.8

```
set.seed(0)
n = 10
t = 1:n
x = rnorm(n) + t
```

2° Hvis I opstiller en lineær regressionsmodel for x_i -erne, kan I estimere koefficienterne ved hjælp af

R-kode 1.9

```
coef(lm(x~t))
```

der her giver output

R-udskrift 1.1

```
(Intercept)      t
0.4976448    0.9747780
```

Fra Afsnit 5.7 i de supplerende noter har I, at tallene fra R-udskrift 1.1 kan findes som

$$(\mathbf{T}^*\mathbf{T})^{-1}\mathbf{T}^*\mathbf{x}$$

hvor $\mathbf{T}$ er designmatricen i modellen. Eftersis dette, ved at beregne $\mathbf{T}$ (benyt `model.matrix`) i **R** og beregne det relevante matrixprodukt.

Opgave 1.64 *Meyer*

Meyer er et terningspil som spilles med to terninger. Det bedste kast er “Meyer”, hvor terningerne hhv. viser 1 og 2 øjne. Dette følges af “Lille Meyer” (1 og 3) og “Par seks” (6 og 6). Formålet med denne opgave er, at simulere kast med to terninger, og bestemme sandsynligheden for Meyer og Par seks.

- 1° Beregn sandsynlighederne for Meyer og Par seks ved et kast. Hvilken fordeling har antallet af Meyer og Par seks i N kast?
- 2° På R-kode 1.10 og 1.11 findes programstumper, som kan hjælpe i simulationsopgaven. Slå evt. ukendte **R** funktioner op i hjælpen. (Det med `L` bag tallerne siger til **R**, at tallene skal behandles som heltal). Afprøv med forskellige værdier af `kast`.

R-kode 1.10

```
kast <- c(2L, 1L)
meyer <- identical (sort(kast), c(1L, 2L))
```

Tilføj en programlinje, der laver en logisk variabel `par6`, som antager værdien **TRUE** når `kast` er to seksere. Kør så de følgende to linjer, og forklar, hvad de laver:

R-kode 1.11

```
N <- 100
Meyer <- logical(N)
```

- 3° Skriv et **R** program, der simulerer $N = 100$ kast med to terninger og registrerer alle Meyer og Par seks udfald. Brug en **for**-løkke og kommandoen `sample` til at simulere terningekast. Beregn antallet af alle Meyer og Par seks i din simulation
- 4° Estimer sandsynlighederne for Meyer og Par seks ud af simulationsresultatet. Prøv det hele igen, nu baseret på $N = 10000$ kast. Hvad ændrer sig?

Opgave 1.65 Summen af uniform fordelte stokastiske variable

Lad $X_1, X_2, \dots$ være i.i.d. stokastiske variable, med en uniform fordeling på intervallet $[-1, 1]$. Vi kigger på *partialsummen*

$$S_m = \sum_{i=1}^m X_i,$$

som i sig selv er en stokastisk variabel.

- 1° Gør rede for, at X_1 har middelværdi $E[X_1] = 0$ og varians $\text{Var}[X_1] = 1/3$. Beregn så middelværdi og varians af S_m .
- 2° Prøv at gætte, hvad for en fordeling S_2 har, og kørså et simulationseksperiment. Passer dit gæt? For at vurdere det, lav et histogram af 10000 simulerede værdier af S_2 . Tjek også, om den empiriske varians (beregnet på de 10000 simulerede værdier) passer til jeres resultat fra delspørgsmål 1°.
- 3° Sammenhold fordelingerne af S_2, S_3, S_4 og S_{12} med normalfordelingen, ved `qqnorm` plots af 1000 simulerede værdier hver. Beskriv, hvad I ser.
- 4° Hvad ville ændre sig i 1°-3°, hvis X_i erne var uniformt fordelt på intervallet $[0, 1]$ frem for intervallet $[-1, 1]$?

Opgave 1.66 Estimatorer i binomialfordelingen

Sædvanligvis estimeres sandsynlighedsparameteren p i en binomialfordeling som $\hat{p} = X/n$, hvor X er antal positive udfald i n Bernoulli forsøg. I Eksempel 6.15, [Chihara and Hesterberg \[2022\]](#), diskuteres en alternativ estimator $\hat{p}_2$ for p , givet ved $\hat{p}_2 = (X + 1)/(n + 2)$. Figur 6.6 viser MSE for begge estimatorer som funktion af den sande værdi af p , for $n = 16$.

- 1° Genskab Figur 6.6 med $n = 30, n = 50, n = 100, n = 200$. Beskriv og diskuter, hvad I ser i kurverne, og besvar spørgsmålet: Er $\hat{p}_2$ en konsistent estimator?

Kurven til Figur 6.6 er angivet i bogen. Kurven kan også laves ved hjælp af:

R-kode 1.12

```
n <- 16
funMSE1 <- function(x) x*(1-x)/n
funMSE2 <- function(x) n*(1-x)*x/(n+2)^2 + (1-2*x)^2/(n+2)^2
curve(funMSE1, from=0, to=1, xlab="p", ylab="MSE")
curve(funMSE2, add=TRUE, col="blue", lty=2)
```

Opgave 1.67 *Estimation i Log-normalfordelingen*

Når $X \sim N(\mu, \sigma^2)$, så har $Y = \exp(X)$ en *log-normalfordeling* med parametre μ og σ . Men disse parametre er ikke middelværdi og standardafvigelse af Y .

1° Det vises i 4° at middelværdien af Y er $\mathbb{E}[Y] = \exp(\mu + \sigma^2/2)$.

Estimer $\mathbb{E}[Y]$ ved hjælp af en stor (f.eks. $n = 10000$) simuleret stikprøve, for $(\mu, \sigma) = (0, 1)$, $(\mu, \sigma) = (1, 1)$ og $(\mu, \sigma) = (0, 2)$. Passer dine simulationsresultater nogenlunde med udtrykket for $\mathbb{E}[Y]$?

R-vink: log-normalfordeling kan simuleres med `rlnorm`, men I kan også simulere fra normalfordelingen og så transformere.

2° Giv et teoretisk argument for, at $\mathbb{E}[Y] > \exp(\mu)$ når $\sigma^2 > 0$.

3° Gøre rede for at $\text{median}[Y] = \exp(\mu)$.

4° Vis, at $\mathbb{E}[Y] = \exp(\mu + \sigma^2/2)$.

Vink: Benyt resultatet fra ISS vedrørende tæthedsfunktionerne f_X og f_Y af en kontinuert stokastisk variabel X og den stokastiske variable $Y = g(X)$, hvor g er en strengt voksende og differentiabel funktion, som har en invers funktion g^{-1} , nemlig:

$$f_Y(y) = f_X(g^{-1}(y)) \frac{dg^{-1}(y)}{dy}.$$

Opgave 1.68 *Markovs og Chebyshevs uligheder*

Betragt en stokastisk variabel $X \sim \text{Bin}(n, p)$ hvor $p = 0.1$. Find en øvre grænse for sandsynligheden $P(X \geq \frac{1}{2}n)$.

1° Brug Markovs ulighed.

2° Brug Chebyshevs ulighed.

Vink: benyt, at $P((X - \mu) \geq k) \leq P(|X - \mu| \geq k)$.

Opgave 1.69 *Approksimativt konfidensinterval for Poisson fordelingen*

I denne øvelse betragter vi stikprøver $(X_1, \dots, X_n)$ fra en Poisson fordeling med parameter λ . Maksimum likelihood estimatoren for λ er givet ved

$$\hat{\lambda} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

1° Gør rede for, at $(\bar{X} - \lambda)/\sqrt{\lambda/n}$ er approksimativt $N(0, 1)$ fordelt.

2° Brug normalapproksimationen til at udlede konfidensintervallet for λ ,

$$\left[\bar{x} + \frac{u_{1-\alpha/2}^2}{2n} - \frac{u_{1-\alpha/2}}{\sqrt{n}} \sqrt{\bar{x} + \frac{u_{1-\alpha/2}^2}{4n}}, \bar{x} + \frac{u_{1-\alpha/2}^2}{2n} + \frac{u_{1-\alpha/2}}{\sqrt{n}} \sqrt{\bar{x} + \frac{u_{1-\alpha/2}^2}{4n}} \right],$$

hvor $u_{1-\alpha/2}$ er $(1 - \alpha/2)$ -fraktilen af $N(0, 1)$ fordelingen.

- 3° Betragt en simulation af en stikprøve fra Poisson fordeling med $\lambda = 8$, hvor udfaldene er 4, 6, 8, 9, 9, 10. Beregn 90%-konfidensintervallet for λ fra denne stikprøve.
- 4° Simuler selv tre stikprøver af størrelse $n = 6$ fra Poisson fordelingen med $\lambda = 8$. Beregn konfidensintervallerne til niveauet $1 - \alpha = 0.90$, og noter til hver konfidensinterval, om den sande parameter λ var indeholdt. Sammenlign jeres resultater i TØ.
- 5° Hvor stor er sandsynligheden for, at 30 uafhængigt simulerede konfidensintervaller til niveauet $1 - \alpha = 0.9$ alle indeholder den sande værdi? Antag, at den angivende dækningsgrad overholdes.

Opgave 1.70 *Fordeling af p-værdier*

Som det er nævnt i de supplerende noter kan p -værdier $p_{obs}(\mathbf{x})$ betragtes som udfald af stokastiske variable $p_{obs}(\mathbf{X})$, og under visse betingelser vil disse stokastiske variable være uniformt fordelt, når den tilsvarende hypotese er sand. I denne opgave illustreres dette ved simulation.

- 1° Illustrer resultatet ved en simulation af t -testet som følger. Simuler stikprøver af størrelse $n = 10$ fra en $N(5, 1)$ -fordeling, og lav t -test af hypotesen $H_0 : \mu = 5$ mod $H_A : \mu \neq 5$. Det kan gøres ved følgende R-kode:

R-kode 1.13

```
nsim <- 10000
pval <- numeric(nsim)
for (i in 1 : nsim){
  pval[i] <- t.test(rnorm(10, 5, 1), mu = 5)$p.value
}
```

Plot histogrammet og den empiriske fordelingsfunktion af de simulerede p -værdier.

Nu skal vi se på fordelingen af p -værdierne når H_0 ikke er sand.

- 2° Overvej, hvordan histogrammet og den empiriske fordelingsfunktion for p -værdierne ændrer sig, hvis den sande værdi af μ er 4. Kør simulationer til at verificere dine formodninger.
- 3° Estimer, ud fra dine simulationer, styrken af testet af nulhypotesen $H_0 : \mu = 5$, når den sande middelværdi er $\mu = 4$, og der betragtes test med signifikansniveau $\alpha = 0.05$. Gentag styrkeestimationen for test med signifikansniveau $\alpha = 0.01$.

I de næste to delspørgsmål betragtes situationen hvor alternativhypotesen er $H_A : \mu < 5$. I **R** kan hypotesen med dette alternativ undersøges ved hjælp af følgende R-kode:

R-kode 1.14

```

nsim <- 10000
pval <- numeric(nsim)
for (i in 1 : nsim){
  pval[i] <- t.test(rnorm(10, 5, 1), mu = 5, alternative = "less")$p.value
}

```

4° Gentag delspørgsmål 2°, men hvor de sande værdier nu først er $\mu = 4$ dernæst $\mu = 6$.

5° Gentag delspørgsmål 3°, hvor alternativhypotesen er $H_A : \mu < 5$.

Opgave 1.71 *Styrke for test af variansparameteren.*

I modellen for én observationsrække hvor $X_1, \dots, X_n$ er en i.i.d. følge fra $N(\mu, \sigma^2)$ er testet for hypotesen

$$H_0 : \sigma^2 = \sigma_0^2 \quad \text{versus} \quad H_A : \sigma^2 \neq \sigma_0^2,$$

baseret på teststørrelsen SSD,

$$\text{SSD} = \sum_{i=1}^n (X_i - \bar{X})^2.$$

1° Gør rede for, at det kritiske område er givet ved $\mathcal{R} = [0, C_1) \cup (C_2, \infty)$, hvor

$$C_1 = \sigma_0^2 \cdot q_1 \quad \text{og} \quad C_2 = \sigma_0^2 \cdot q_2,$$

hvor $q_1 = \chi_{\alpha/2}^2(n-1)$ og $q_2 = \chi_{1-\alpha/2}^2(n-1)$ er henholdsvis $\alpha/2$ og $1 - \alpha/2$ fraktiler i χ^2 fordelingen med $n-1$ frihedsgrader.

2° Vis, at sandsynligheden for type 2 fejl, når den sande varians er σ_A^2 , er givet ved

$$\beta = F_{\chi_{n-1}^2} \left(\frac{\sigma_0^2}{\sigma_A^2} \cdot q_2 \right) - F_{\chi_{n-1}^2} \left(\frac{\sigma_0^2}{\sigma_A^2} \cdot q_1 \right).$$

$F_{\chi_{n-1}^2}$ betegner fordelingsfunktionen af χ^2 fordelingen med $n-1$ frihedsgrader, og q_1 og q_2 er fraktilerne som i delopgave 1°.

3° Skriv et lille R-program som udregner de kritiske værdier og styrken. Tegn styrken af testet til $H_0 : \sigma_0^2 = 1$ som en funktion af σ_A^2 , for $n = 10, 40, 400$ i en samlet diagram (brug $\alpha = 0.1$). Lav et lignende diagram som viser styrkekurver ved $\alpha = 0.01, 0.05, 0.1, 0.2$, hvor $n = 10$ fastholdes.

Opgave 1.72 Antag $X \sim \text{Binom}(n, p)$ og lad $\hat{\theta} = \hat{\theta}(X)$ være en unbiased estimator for p .

1° Benyt Cramer–Raos ulighed til at vise at

$$\text{Var}(\hat{\theta}) \geq \frac{p(1-p)}{n}.$$

2° Hvad siger 1° om estimatoren $\hat{p} = X/n$ for p ?

Opgave 1.73 Lad $x_1, x_2, \dots, x_n$ være en stikprøve fra eksponentialfordelingen med parameter λ . Formålet med denne opgave er at illustrere resultaterne omkring approksimativ likelihood teori.

1° Gør rede for at likelihoodfunktionen for λ er

$$L(\lambda) = \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right),$$

og at log likelihoodfunktionen er

$$l(\lambda) = n \log(\lambda) - \lambda \sum_{i=1}^n x_i.$$

Det følger af Example 6.2 s. 153–154 i MSRR at MLE for λ er

$$\hat{\lambda} = \frac{1}{\bar{X}}.$$

2° Betragt hypotesen $H : \lambda = 1$. Vis, at likelihood ratio testoren er

$$Q(\mathbf{X}) = (\bar{X})^n \exp\left(-\sum_{i=1}^n X_i + n\right)$$

og at

$$-2 \log(Q(\mathbf{X})) = -2n \log(\bar{X}) + 2 \sum_{i=1}^n X_i - 2n.$$

Ifølge approksimativ likelihood teori vil $-2 \log(Q(\mathbf{X}))$ være approksimativt $\chi^2(1)$ fordelt, når n er stor og hypotesen er sand (d.v.s når $\lambda = 1$)

3° Lav et simulationseksperiment der illustrerer ovenstående resultat. Vælg f.eks. $n = 10$ og simulér $R = 10000$ replikationer af $-2 \log(Q(\mathbf{X}))$.

4° Antag at der for vores datasæt gælder at $n = 10$ og


$$\bar{x} = 1.1$$

Angiv estimatet for $\hat{\lambda}$ – kan vi acceptere hypotesen $H : \lambda = 1$?

Vink til 3°: I **R** kan summen af indgangene i en vektoren **x** beregnes ved **sum(x)**.

Vink til 4°: p -værdien fremgår af formel (6.36) i de supplerende, hvor vi her skal sætte $k = 1$, fordi vi fjerner en parameter (λ) når vi går fra grundmodellen til hypotesen.

Preliminary Determination of Epicenters
358,214 Events, 1963 - 1998



Opgave 1.74 *Goodness of fit test: Uniform fordeling*

I 2009 publicerede Pieter Vermeesch en lille note med den provokerende titel **Lies, damned lies, and statistics (in geology)**. I noten betragter forfatteren 118415 jordskælv af styrke 4 eller over på Richterskalaen i perioden 1/1-1999 til 1/1-2009 (data fra usgs.gov) og fordeler disse på ugedag. Billedet ovenfor viser, hvor jordskælv optræder. Data kan ses i Tabel 1.5 og findes i filen *JordskaelvDag.csv*.

Data	Mandag	Tirsdag	Onsdag	Torsdag	Fredag	Lørdag	Søndag
Observeret	16853	16553	16490	17399	16348	17019	17753

Tabel 1.5: Jordskælv fordelt på ugedage

- 1° Opstil multinomialmodellen for disse data, hvor sandsynlighederne for at falde i de syv kasser er vilkårlige.
- 2° Opskriv, inden for den opstillede multinomialmodel, hypotesen om ligelig fordeling på de syv ugedage. Udregn de forventede antal, og lav G -testet for hypotesen. Hvad bliver konklusionen af testet?

Den overraskende konklusion er, at jordskælvne ikke fordeler sig ligeligt på de syv ugedage. Vermeesch ser dette resultat som udtryk for en svaghed i de statistiske metoder.

Har Vermeesch ret, eller bruger han metoderne forkert? Når vi laver goodness of fit test for en ligelig fordeling på de syv ugedage, sammenligner vi med *uafhængige* kast af en syvsidet terning.

Som påpeget af Sornette og Pisarenko i artiklen [On the correct use of statistical tests: Reply to "Lies, damned lies and statistics \(in geology\)"](#), er det helt store problem mangel på uafhængighed på grund af efterskælv og klynger af små skælv. I datasættet er cirka 2/3 af skælvne efterskælv! Et andet stort problem er, at for de små jordskælv kan data indeholde menneskeskabte hændelser, og der kan være forskel i baggrundsstøj på de syv ugedage. Sornette og Pisarenko foreslår at betragte jordskælv med en styrke over 5 på Richterskalaen for at komme ud over det sidstnævnte problem, og foretager også en rensning af disse for at fjerne efterskælv (dette kan ikke gøres fuldstændigt sikkert). Data kan ses i Tabel 1.6.

Data	Mandag	Tirsdag	Onsdag	Torsdag	Fredag	Lørdag	Søndag
Over 5	2374	2511	2291	2497	2153	2282	2360
Renset	780	847	793	831	785	821	779

Tabel 1.6: Jordskælv med styrke over 5 og rensset for efterskælv fordelt på ugedage

3° Lav et G -test for en ligelig fordeling, både for alle jordskælv med en styrke over 5 og for delmængden, hvor efterskælv er fjernet.

Ifølge Wikipedia blev udtrykket *lies, damned lies and statistics* gjort kendt af Mark Twain, som skrev "There are three kinds of lies: lies, damned lies, and statistics". Mark Twain mente, at udtrykket stammede fra den britiske premierminister Benjamin Disraeli, men dette kan tilsyneladende ikke bekræftes.

Opgave 1.75 *Goodness of fit, poissonfordeling*


Data i denne opgave tager udgangspunkt i forsøg med bakterieceller, hvor man ofte har behov for at tælle, hvor mange af disse man har i en given opløsning. Dette gøres ved at udtage en mindre del af opløsningen og tage billede af denne i et mikroskop, hvor bakterierne så kan tælles.

Et eksempel på et sådant billede er vist på Figur 1.5, hvor de små sorte områder er enkelte *E. coli* bakterier. De store områder i midten af billedet er hver på $50 \times 50 \mu\text{m}^2$, og her inden for tælles antallet af bakterier. For at sikre konsistens tælles en bakteriecelle, der ligger ind over en kant, kun med hvis det er den venstre eller den øverste kant, der berøres.

I filen *CelleData.txt* ligger data fra optælling fra 14 sådanne billeder, hver med 16 områder. Data er indsamlet med henblik på opgaven her og stillet til rådighed af Morten Bormann Nielsen.

1° Indlæs de 224 kvadrattællinger med ordren `nColi=scan("CelleData.txt")`.

Lav et histogram af data med intervalendepunkter `endePkt=c(4:32)-0.5` (det første interval er fra 3.5 til 4.5, svarende til at den mindste værdi i *nColi* er 4, og det sidste interval er fra 30.5 til 31.5, svarende til at den største værdi i *nColi* er 31). Indsæt titler på akserne i figuren ved at benytte `xlab` og `ylab` i kaldet til `hist`. Placer antallet af observationer i



Figur 1.5: Bakterieceller under mikroskop

hvert interval i en vektor `antal`. Vælg et af intervallerne ud, og eftervis antallet i `antal` ved en direkte optælling blandt de 224 dataværdier.

- 2° Opskriv multinomialmodellen for den stokastiske antalsvektor Antal , hvor sandsynligheden for at falde i de forskellige kasser er vilkårlig.

I denne opgave skal I lave et goodness of fit test for at antallet af bakterier i et kvadrat er poissonfordelt. Lad λ være rateparameteren i poissonfordelingen (enhed: antal per $50^2 \mu\text{m}^2$). Da den første “kasse” i multinomialmodellen indeholder tælleantal mindre end eller lig med fire, vil hypotesen om en poissonfordeling betyde at sandsynligheden for at falde i den første kasse er $\sum_{j=0}^4 (\lambda^j / j!) e^{-\lambda}$. Den anden kasse indeholder alle tælleantal med værdien 5, og sandsynligheden for at falde i den anden kasse er $(\lambda^5 / 5!) e^{-\lambda}$, og så videre op til kasse 27. Sandsynligheden for at falde i den sidste kasse (kasse nummer 28) er 1 minus summen af sandsynlighederne for de første 27 kasser.

Som skøn over λ bruges gennemsnittet af de 224 observationer, se Proposition 6.2 i [Chihara and Hesterberg \[2022\]](#) (Proposition 6.1.2 i [Chihara and Hesterberg \[2018\]](#)).

- 3° Opskriv, inden for din multinomialmodel, hypotesen om, at antallet af bakterier i et kvadrat er poissonfordelt.

Beregn de forventede antal under hypotesen. Hertil kan du benytte R-kode 1.15. I **R** beregnes punktsandsynligheder i poissonfordelingen med `dpois(x, lambda)`, og sandsynligheden for en værdi mindre end eller lig med `x` beregnes med `ppois(x, lambda)`. Forklar, at koden giver de forventede værdier.

R-kode 1.15

```
lamhat=3324/224
endePkt=c(4:32)-0.5
endePkt0=endePkt[2:28]
pr0=ppois(endePkt0, lamhat)
pr=c(pr0, 1)-c(0, pr0)
forvent=224*pr
round(forvent, 2)
```

Indtegn de forventede antal i histogrammet fra spørgsmål 1° som en rød kurve med kommandoen `lines(c(4:31), forvent, col=2)`, hvor `forvent` er vektoren med de forventede antal.

- 4° Lav *G*-testet for hypotesen, at antal bakterier i et kvadrat er poissonfordelt. Slå kasser sammen, hvis de forventede ikke er større end 5 (slå kasser sammen fra hver sin ende, indtil det forventede antal er større end 5).

Hvad bliver konklusionen af dit goodness of fit test? Kan du give en forklaring på resultatet?

Konklusionen af ovenstående analyse er, at poissonfordelingen ikke er en særlig god beskrivelse af data. Man kan indse, at de 224 tællingerne viser større spredning, end hvad man forventer i en poissonfordeling. Fortolkningen af dette er, at bakterierne ikke er tilfældigt spredt ud over området, nogle områder har større intensitet af bakterier end andre områder (bakterierne klumper).

Opgave 1.76 *Goodness of fit, normalfordeling*

I *menneske-maskine-interaktion* betragtes blandt andet, hvordan man flytter pointeren på en computerskærm via musen. Figur 1.6 viser en typisk opstilling, hvor en person skal flytte pointeren fra område *A* til område *B*.


Data er simulerede baseret på informationen i figur 1 i artiklen [An error model for pointing based on Fitts' Law](#). Der er 269 observationer målt relativt til midtpunkt af målområdet (enheden angives i figuren som "pixels"). Data ligger i filen *Position.txt*. Opgaven går ud på at lave et goodness of fit test for, at pointerpositionen kan beskrives med en normalfordeling.

- 1° Indlæs de 269 positioner med kommandoen `scan("Position.txt")`, og placer disse i variablen `pointer`. Lav et tæthedshistogram af data med intervalinddelingen

```
endePkt=c((-9):8)*2+0.5.
```

Placer antallet af observationer i hvert af de 17 intervaller i en vektor `antal`.

Hvis positionen af pointer skal beskrives med en normalfordeling, er det bedste valg af middelværdi $\hat{\mu} = 0.1843$, og det bedste valg af spredning er $\hat{\sigma} = 4.9938$. Indtegn normalfordelings-tætheden i histogrammet med kommandoen på R-kode 1.16



Figur 1.6: I eksperimentet undersøges det, hvordan cursoren flyttes fra område A til område B.

R-kode 1.16

```
curve(dnorm(x,0.1843,4.9938),from=-20,to=20,add=TRUE)
```

2° Opskriv multinomialmodellen for den stokastiske vektor *Antal*, hvor sandsynlighederne for at falde i de forskellige intervaller er vilkårlige.

Opskriv dernæst hypotesen, at sandsynlighederne for at falde i de 17 intervaller er givet ved sandsynlighederne for intervallerne i en normalfordeling med middelværdi μ og spredning σ . Husk at i denne sammenhæng skal det første interval opfattes som intervallet fra minus uendelig til -15.5, og det sidste interval skal opfattes som intervallet fra 14.5 til uendelig.

Beregn de forventede antal under hypotesen. Hertil kan du benytte R-kode 1.17. I **R** beregnes sandsynligheden for en værdi mindre end eller lig med x i en normalfordeling med kommandoen **pnorm**(x, μ, σ). Forklar, at R-kode 1.17 giver de forventede værdier.

R-kode 1.17

```
muhat=0.1843
sigmahat=4.9938
endePkt0=c((-8):7)*2+0.5
prob=pnorm(endePkt0,muhat,sigmahat)
forvent=269*(prob[1],prob[2:16]-prob[1:15],1-prob[16])
round(forvent,2)
```

3° Lav *G*-testet for hypotesen, at pointerpositionen er normalfordelt. Kan disse data beskrives med en normalfordeling?

Opgave 1.77 Homogenitetstest

I bogen *Human-Computer Interaction: An Empirical Research Perspective* omtales kort et eksperiment, hvor kvinder og mænd observeres for at vurdere deres måde at scrolle i en tekst. Hver person

klassificeres efter, om vedkommende bruger enten rullehjulet på musen til at scrolle i en tekst, bruger rullepanel på skærmen eller bruger tastaturtasterne. Der er 65 kvinder og 43 mænd i undersøgelsen. Fordelingen på de tre metoder for henholdsvis kvinder og mænd kan ses i Tabel 1.7.

Køn	Rullehjul	Rullepanel	Tastatur	Total
Kvinder	37	16	12	65
Mænd	20	16	7	43

Tabel 1.7: Fordeling af brugere efter køn og inputenhed

Vi ønsker med data at se, om der er kønsspecifikke måder at arbejde med computeren på.

- 1° Opstil den statistiske model, hvor tælle tallene for hvert køn følger sin egen multinomialfordeling. Angiv inden for den opstillede model hypotesen, at der er samme sandsynlighedsvektor for kategorierne (Rullehjul, Rullepanel, Tastatur) for de to køn.
- 2° Undersøg, om data er i overensstemmelse med hypotesen om samme sandsynlighedsvektor for kategorierne (Rullehjul, Rullepanel, Tastatur) for de to køn (benyt eventuelt R-kode 8.14 i de supplerende noter).

Opgave 1.78 *Poissonmodel med proportionale parametre*

Antallet af jordskælv i et bestemt område og med en styrke i et givet interval beskrives ofte med en poissonfordeling. Et eksempel er artiklen [A Poisson model for earthquake frequency uncertainties in seismic hazard analysis](#). I artiklen betragtes blandt andet jordskælv i New Zealand. Information om disse kan findes på nettet under adressen www.geonet.org.nz.

Data i tabellen nedenfor viser antallet for tre styrkeintervaller og for perioden 1930-2015. Styrken er på Richterskalaen, som er en logaritmisk skala. Hvis styrken stiger med 1, stiger den samlede energi i jordskælvet med $10^{3/2} = 31.6$. Gutenberg-Richter loven for jordskælv angiver forholdet mellem antallet af jordskælv af forskellig styrke. I tabellen er dette forhold angivet for de tre styrkeintervaller (med “b-value” i Gutenberg-Richter loven sat til 1).

Styrkeinterval	Antal	Forhold
6.0–6.3	72	1
6.3–6.6	41	1/2
6.6–6.9	25	1/4

Tabel 1.8: Fordeling af antal observationer pr. styrkeinterval og tilhørende forhold

I opgaven her skal I kun betragte de to første styrkeintervaller, 6.0-6.3 og 6.3-6.6. Idet vi vil bruge data til at vurdere holdbarheden af Gutenberg-Richter loven, skrives raterne i de to intervaller som $86\lambda_1$ og $0.5 \cdot 86\lambda_2$, eftersom en beregning viser, at under Gutenberg-Richter loven (med “b-value” lig med 1) er raten i det andet styrkeinterval halvt så stor som raten i det første styrkeinterval.

Enheden på λ er antal forventede jordskælv per år. Gutenberg-Richter loven svarer således til hypotesen $\lambda_1 = \lambda_2$.

Lad os formulere situationen generelt gennem modellen

$$Y_1 \sim \text{pois}(t_1\lambda_1), \quad Y_2 \sim \text{pois}(t_2\lambda_2), \quad t_1 = 86, \quad t_2 = 0.5 \cdot 86,$$

hvor Y_1 og Y_2 er de stokastiske tælleletal svarende til de to styrkeintervaller.

For at teste hypotesen $\lambda_1 = \lambda_2$ kan man benytte følgende teoretiske resultat. Hvis vi forestiller os, at $Y_1 + Y_2$ er fast (dvs. vi betinger med summen), så vil Y_1 være binomialfordelt:

$$Y_1 \mid Y_1 + Y_2 = n \sim \text{binom}(n, p), \quad p = \frac{t_1\lambda_1}{t_1\lambda_1 + t_2\lambda_2}. \quad (1.14)$$

Hvis $\lambda_1 = \lambda_2$ bliver $p = t_1/(t_1 + t_2)$. Et test for hypotesen $\lambda_1 = \lambda_2$ kan derfor laves som et test i binomialfordelingen for hypotesen, at sandsynlighedsparameteren p har værdien $p = t_1/(t_1 + t_2)$. I vores tilfælde bliver dette hypotesen, at $p = 2/3$.

- 1° Find p -værdien for et test af hypotesen $\lambda_1 = \lambda_2$, for data i de to første rækker af tabellen ovenfor, ved at teste $p = 2/3$ i modellen (1.14). Hvad bliver konklusionen af dette test?

Bemærkning: Hvis data strider mod hypotesen $\lambda_1 = \lambda_2$, vil vi være interesseret i at indføre en parameter θ , således at $\lambda_2 = \theta\lambda_1$. Parameteren θ angiver, hvor mange gange større λ_2 er i forhold til λ_1 . Hvis vi lader $p = t_1/(t_1 + \theta t_2)$, kan vi løse for θ , og får $\theta = (1-p)t_1/(pt_2)$. Konfidensinterval for sandsynlighedsparameteren p i binomialmodellen (1.14) kan derfor oversættes til et konfidensinterval for forholdet θ .

Hvis denne metode benyttes på data i første og tredje styrkeinterval i tabellen ovenfor, får vi intervallet $[0.65, 0.82]$ for 95%-konfidensintervallet af sandsynlighedsparameteren p . Oversat til forholdet θ mellem rateparametrene i de to styrkeintervaller giver dette intervallet $[0.22, 0.55]$. Dette interval indeholder værdien $\frac{1}{4}$, som svarer til Gutenberg-Richter loven.

Opgave 1.79 Ændring i stormmønster

DMI vedligeholder en side med alle **storme i Danmark** siden 1891. Stormene klassificeres i fire styrke kategorier ud fra vindstyrken. I Tabel 1.9 er antallet af storme optalt i de forskellige kategorier for fire 30-års perioder.

- 1° Opstil den statistiske model, hvor antallet af storme for hver periode følger sin egen multinomialfordeling på de tre kategorier 1, 2 og 3+4. Angiv inden for den opstillede model hypotesen, at der er samme sandsynlighedsvektor for de tre styrke kategorier 1, 2 og 3+4 for de fire tidsperioder.
- 2° Undersøg, om data er i overensstemmelse med hypotesen om samme sandsynlighedsvektor for kategorierne 1, 2 og 3+4 for de fire tidsperioder.

Periode	Stormstyrke 1	Stormstyrke 2	Stormstyrke 3 og 4
1891–1920	39	16	4
1921–1950	21	8	8
1951–1980	14	12	5
1981–2010	18	12	10

Tabel 1.9: Antal storme fordelt på perioder og styrkeniveauer

For storme i Danmark finder I således ikke en ændring i fordeling på styrkekategori. Tabel 1.10 viser fordelingen af **hurricanes** fra verdenshavene på styrke kategorierne 1-3 og 4-5. Der er data fra to tidsperioder: 1975-1989 og 1990-2004. Data er fra artiklen **Changes in Tropical Cyclone Number, Duration, and Intensity in a Warming Environment**.

Periode	Hurricanes 1–3	Hurricanes 4–5
1975–1989	617	171
1990–2004	508	269

Tabel 1.10: Antal hurricanes fordelt på perioder og intensitetsniveauer

3° Undersøg om fordelingen af hurricanes på de to styrke kategorier er den samme for de to tidsperioder.

For hurricanes ser det således ud til, at der er sket en ændring. I det sidste spørgsmål i denne opgave skal du se på, om ændringen er den samme i de forskellige verdenshave. Tabel 1.11 viser fordelingen af de største hurricanes (kategori 4-5) på fem verdenshave for de to tidsperioder.

Verdenshav	1975–1989	1990–2004
East Pacific Ocean	36	49
West Pacific Ocean	85	116
North Atlantic	16	25
Southwestern Pacific	10	22
Indian	24	57

Tabel 1.11: Antal hurricanes (kategori 4-5) i forskellige verdenshave i to perioder

4° Opstil model for data, og undersøg, om fordeling på de fem verdenshave er den samme i de to perioder.

Opgave 1.80 Uafhængighedstest

I denne opgave benyttes et datasæt fra artiklen **Corporate Social Responsibility and Workers' Well-being in Nigerian Banks**. Forfatterne har spurgt 137 personer, der arbejder i banksektoren, om de

bruger de sundhedsmuligheder banken stiller til rådighed og om sundhedstilbuddene er tilstrækkelige. Data er gengivet i Tabel 1.12.

Tilbud tilstrækkelige	Ja	Nej
Bruger muligheder: Ja	97	8
Bruger muligheder: Nej	26	6

Tabel 1.12: Sammenhæng mellem vurdering af tilbud og brug af muligheder

- 1° Opstil en model for data i tabellen. Opstil dernæst en hypotese om sammenhængen mellem de to inddelingskriterier.
- 2° Lav både G -testet for den opstillede hypotese, såvel som permutationstestet og Fishers eksakte test. Kommenter på resultaterne.

Opgave 1.81 *Betingning i poissonmodel*

Lad $X_i \sim \text{Pois}(\lambda_i)$, $i = 1, \dots, k$, være uafhængige stokastiske variable.

- 1° Angiv fordelingen af $N = X_1 + X_2 + \dots + X_k$.
- 2° Find den betingede sandsynlighed $P(X_1 = x_1, \dots, X_k = x_k | N = n)$. Hvad er den betingede fordeling af $(X_1, \dots, X_k)$ givet at $N = n$?

Opgave 1.82 *Simulere styrke*

I denne opgave skal I finde styrken af et test ved simulering. Betragt modellen

$$X_1 \sim \text{binom}(n_1, p_1) \quad X_2 \sim \text{binom}(n_2, p_2)$$

hvor X_1 og X_2 er uafhængige, og test af hypotesen $p_1 = p_2$. Styrken skal beregnes i tilfældet, hvor vi forkaster hypotesen, når p -værdien fra Resultat 8.6.1 er mindre end 0.05. I kodevinduet nedenfor er vist det meste af den nødvendige kode.

R-kode 1.18

```
# setup for simulering defineres
n1=20
n2=20
p1=0.4
p2=0.4
nsim=10000

# data simuleres
x1=rbinom(nsim,)
x2=rbinom(nsim,)

# teststørrelse beregnes
```

```

phat=(x1+x2)/(n1+n2)
qTest=(phat^(x1+x2)*(1-phat)^(n1+n2-x1-x2))/
((x1/n1)^x1*(1-x1/n1)^(n1-x1)*(x2/n2)^x2*(1-x2/n2)^(n2-x2))

gTest=
pvaerdi=1-pchisq(gTest,1)

# simuleret p-værdi beregnes
sum()/nsim

```

- 1° Indsæt de manglende argumenter i de to kald til `rbinom`. Hvilket formel benyttes ved beregningen af likelihood ratio teststørrelsen `qTest`? Indsæt den manglende kode for `gTest`. Indsæt den manglende kode i `sum` i den sidste linje for at beregne den simulerede styrke.
- 2° Benyt koden til at finde ud af, hvor stor $n_1 = n_2$ skal være, for at styrken er mindst 0.80 i tilfældet, hvor $p_1 = 0.4$ og $p_2 = 0.5$.

Litteratur

Laura M Chihara and Tim C Hesterberg. *Mathematical statistics with resampling and R (2nd edition)*. John Wiley & Sons, 2018.

Laura M Chihara and Tim C Hesterberg. *Mathematical statistics with resampling and R (3rd edition)*. John Wiley & Sons, 2022.