

Matematisk Statistik

Introduktion og deskriptiv statistik

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Forelæsninger

- 2×2 timer per uge

Øvelser

- 2 timer per uge. Starter i Uge 2.

StatLab.

- 2 timer per uge. Starter i Uge 1.

Obligatorisk program

- 7 godkendte afleveringsopgaver, ud af 10.

Eksamen

- 4 timer, skriftlig, digital
- Evaluering efter 7-trins skalaen, ekstern censur.

Statistisk programpakke:

- **R** med RStudio som brugerflade.

Litteratur:

- MSRR :
Laura Chihara, Tim Hesterberg (2022): Mathematical Statistics with Resampling and R (3rd edition).
- 2. udgave fra 2018 kan også bruges.
- Supplerende noter.

MSRR har en hjemmeside, hvor I blandt andet finder data og liste med trykfejl. Hjemmesiden er

<https://github.com/lchihara/MathStatsResamplingR>

Matematisk Statistik

Data er typisk organiseret i tabeller, hvor hver række udgør en *observation* og søjlerne udgør *variable*.

Flight	Carrier	FlightNo	Destination	DepartTime	Delay	Delayed30
1	UA	403	DEN	4-8am	-1	No
2	UA	405	DEN	8-Noon	102	Yes
3	UA	409	DEN	4-8pm	4	No
4	UA	511	ORD	8-Noon	-2	No
5	UA	667	ORD	4-8am	-3	No
6	UA	669	ORD	4-8am	0	No
7	UA	673	ORD	8-Noon	-5	No
8	UA	677	ORD	8-Noon	0	No
9	UA	679	ORD	Noon-4pm	10	No
10	UA	681	ORD	Noon-4pm	60	Yes
⋮						

Eksempel på datasæt - Del af FlightDelays datasættet fra Case Study 1.1

- *Kategoriske variable/kvalitative variable/faktorvariable/faktorer.*
Danner en gruppdeling af observationer.
De mulige værdier af en faktor kaldes *niveauer* (eng: *levels*) eller *kategorier*.
- *Numeriske variable/Kvantiative variable* Tal, hvor vi meningsfyldt kan betragte f.eks. minimum eller gennemsnit.

Kategoriske variable inddeles i *ordinale* kategoriske variable og *nominale* kategoriske variable. En ordinal (kategorisk) variabel er en variabel, hvor niveauerne kan rangordnes (f.eks. god/bedre/bedst), mens en nominal ikke har en rangorden. Under tiden kaldes en kategorisk variabel med to niveauer for en *dikotom/binær* variabel.

Numeriske variable inddeles i *diskret* (numeriske) variable og *kontinuerte* variable. Hvis de mulige værdier af en numerisk variabel udgør en tællelig mængde kaldes variable diskret og ellers kaldes den kontinuert. Diskrete variable optræder typisk ved tællinger, men kontinuerte variable er resultatet af målinger.

Table 1.2 Variables in data set `FlightDelays`.

Variable	Description
Carrier	UA=United Airlines, AA=American Airlines
FlightNo	Flight number
Destination	Airport code
DepartTime	Scheduled departure time in 4 h intervals
Day	Day of week
Month	May or June
Delay	Minutes flight delayed (negative indicates early departure)
Delayed30	Departure delayed more than 30 min?
FlightLength	Length of time of flight (minutes)

Potentielle spørgsmål

- Er forsinkelserne forskellige for de to flyselskaber
- Afhænger forsinkelserne af ugedagen
- Er der større risiko for forsinkelse om morgenen?

I bogen skelnes mellem en stikprøve (sample) (af størrelse n) eller en hel population (af størrelse N).

Populationer kan være endelige eller uendelige. En stikprøve kan fremkomme som resultatet af udtrækning, og ved små populationer kan det være vigtigt at skelne mellem *trækning med tilbagelægning* og *trækning uden tilbagelægning*.

Numeriske egenskaber ved populationen kaldes *parametre*.

Fortolkning af association mellem variable

MSRR § 1.11

Eksempel: rygning og kræft

Datasæt med *forklarende variabel* “ryger” (ja/nej) og *interessevariabel* “kræftpatient” (ja/nej).

Andel af kræftpatienter er højere ved ryger.

- Observationelt studie: Datasættet er givet uden indflydelse fra forskeren. Association mellem variable må ikke uden videre fortolkes som årsag! (*"Correlation does not imply causation"*)
- Eksperiment: Forskere manipulerer forklarende variabler og randomiserer deres niveau ved individer. Fx laboratoriemus bliver tilfældigt tildelt rygergruppen. Kausale konklusioner kan være tilladt.

Dataanalyse i R

csv filer: tekstformat for tabeller - tabelrække = tekstlinje.
celler i tabellen separeret ved komma (eller andre tegn).

Start af `FlightDelays.csv`:

```
"ID", "Carrier", "FlightNo", "Destination", "DepartTime", "  
1, "UA", 403, "DEN", "4-8am", "Fri", "May", 281, -1, "No"  
2, "UA", 405, "DEN", "8-Noon", "Fri", "May", 277, 102, "Yes"  
3, "UA", 409, "DEN", "4-8pm", "Fri", "May", 279, 4, "No"  
4, "UA", 511, "ORD", "8-Noon", "Fri", "May", 158, -2, "No"
```

Indlæs i **R**

```
FlightDelays <- read.csv("FlightDelays.csv")
```

giver en `data.frame` objekt med navn `FlightDelays` og
komponenter `ID`, `Carrier`, ...

Tilgås f.eks. `FlightDelays$Carrier`

`read.csv` er en specialiseret udgave af `read.table`

Eller, I kan bruge RStudio

Deskriptiv dataanalyse: Kategoriske variable (MSRR 2.1)

Deskriptiv dataanalyse: en kategorisk variabel

Hyppighedstabel

Tabel af antal observationer af hver kategori, d.v.s. hvert niveau af en kategorisk variabel.

```
table(FlightDelays$Carrier)
```

For at arbejde videre med hyppighedstabellen gemmes denne:


```
tab <- table(FlightDelays$Carrier)
```

Så kan vi lave et *bar plot*, som giver en visualisering af hyppighedstabellen. Højden af baren svarer til antallet af individer af hver kategori.

```
barplot(tab)
```

Outputtet af ovenstående ses på næste slide

Deskriptiv dataanalyse: en kategorisk variabel



Barplot af `Carrier` variablen

Dot plot / prikdiagram

En lav-det-selv version af bar plot: tegn en punkt for hvert individ af en kategori.

Kontingenstabel

Tabel med tællinger for hver kombination af niveauer af to eller flere kategoriske variable.

R koden

```
table(FlightDelays$Carrier, FlightDelays$Delayed30)
```

giver output

	No	Yes
UA	919	204
AA	2513	393

Bemærk at vi indirekte har lavet en ny faktorvariabel med fire niveauer. Tabellen gemmes

```
tab <- table(FlightDelays$Carrier, FlightDelays$Delayed30)
```

Kontingenstabel

Ved hjælp af `prop.table` kan vi normalisere kontingenstabellen så alle celler/alle rækker/alle søjler summer til 1:

```
prop.table(tab)
```

giver

	No	Yes
UA	0.22809630	0.05063291
AA	0.62372797	0.09754281

```
prop.table(tab, 1)
```


giver

	No	Yes
UA	0.8183437	0.1816563
AA	0.8647626	0.1352374

Sammenlign med Table 2.2 i [1].

Deskriptiv dataanalyse:
numeriske variable
(MSRR, resten af kapitel 2, samt
supplerende noter)

- Kan approksimere en tæthedsfunktion.
- Konstrueres ved at inddele spænd (range) i et passende antal delintervaller.
- Data i hvert delinterval repræsenteres ved en kasse, hvis areal er proportional med hyppighed eller relativ hyppighed.



Histogram (med relative hyppigheder) for 10000 simulerede udfald fra exponential fordelingen med parameter 1, sammen tætheden $f(x) = e^{-x} \quad x > 0$.

Histogrammer kan give et indtryk af om data er højre/venstre skævt eller symmetrisk.




Figure 2.2 Histogram of lengths of flight delays for United Airlines. The distribution is right skewed.







Figure 2.3 Histogram of average January temperatures in Washington state (1895–1999). The distribution is left skewed.

Antallet af intervaller skal vælges passende, som følgende figur illustrer.



3 histogrammer for `Weight` variabelen fra datasættet `TXBirths`, baseret på forskellige antal interval-inddelinger.

Histogrammer kan være “ustabile” som nedenstående figur illustrerer:



Figur 1: To histogrammer for samme datasæt med $\Delta t_i = 20$ for alle i . Det venstre histogram har $t_1 = 1400$ mens det højre har $t_1 = 1409$. Figuren er tilpasset fra [2].

Histogrammer kan også gøre det svært at se om fordelingen har “tunge haler”, hvilket vi ser et eksempel på senere.

Numeriske deskriptive mål

Vi betragter en numerisk variabel i et datasæt.

Mål for position

- median
- empirisk middelværdi/middelværdi/gennemsnit
- trimmed gennemsnit
- Modus (*mode*)

Modus for en stokastisk variabel er der, hvor den tilhørende PMF/PDF maksimeres. Hvis der kun er en modus kan fordelingen *unimodal*.

Mål for variation

- spænd (*range*)
- kvartilsafstand (*interquartile range*)
- varians, standard afvigelse.

Både-og:

- Five number summary.

Data er $\mathbf{x} = (x_1, \dots, x_n)$

◆ *Gennemsnit*

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

`mean(x)`

◆ *Median*

$$\text{median}(\mathbf{x}) = \begin{cases} \frac{1}{2} \left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right), & \text{hvis } n \text{ er lige} \\ x_{(\frac{n+1}{2})} & \text{hvis } n \text{ er ulige} \end{cases}$$

hvor $x_{(1)}, \dots, x_{(n)}$ er datasættet sorteret efter størrelse, det vil sige $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$

`median(x)`

◆ *Trimmet gennemsnit* Fjern først en andel $0 < \alpha < 0.5$ fra begge sider af den ordnede stikprøve $x_{(1)}, \dots, x_{(n)}$ og returner middelværdien af de resterende observationer

`mean(x, trim = 0.25)`

Angiver: minimum, 1.kvartil (Q_1), median, 3.kvartil (Q_3) samt maximum af stikprøven. I MSRR angives følgende metode til beregning af Q_1 og Q_3 :

- 1. kvartil Q_1 : median af alle tal som er *mindre* eller lig medianen
- 3. kvartil Q_3 : median af alle tal som er *større* eller lig medianen

Eksempel 2.4: data ($n = 15$) er givet ved

9, 10, 11, 11, 12, 14, 16, 17, 19, 21, 25, 31, 32, 41, 61

`fivenum(x)` eller

`summary(x)`

- inkluderer også gennemsnittet
- bruger en lidt anderledes beregning af kvartilerne Q_1 og Q_3

`summary` kommandoen bruges i flere andre sammenhænge.

Spænd, variationsbredde (range)

$$\text{Spænd} = \text{maksimum} - \text{minimum} = x_{(n)} - x_{(1)}$$

Kvartilsafstand (interquartile range)

$$IQR = Q_3 - Q_1$$

Kan opfattes som en trimmet udgave af spændet.

◆ *Vars og standardafvigelse*

Populationsvars

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2, \mu = \frac{1}{N} \sum_{i=1}^N x_i$$

Stikprøvevars

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2, \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Boxplots

Boxplots visualiserer tallene fra five-number summary.

Table 2.4 A set of 21 data values.

5	6	6	8	9	11	11
14	17	17	19	20	21	21
22	23	24	32	40	43	49




Figure 2.5 Boxplot for Table 2.4.

fivenum returnerer

```
5 11 19 23 49
```

Boxplots

Boxplots egner sig godt til at sammenligne fordelinger på tværs af niveauerne af en kategorisk variabel.




Figure 2.6 Distribution of lengths of the flight delays for United Airlines across the days of the week.

Den empiriske fordelingsfunktion

Den *empiriske fordelingsfunktion* estimerer populationens fordelingsfunktion (CDF) $F(x) = \mathbb{P}(X \leq x)$.

Konkret defineres $\hat{F}_n$ svarende til observationerne $x_1, x_2, \dots, x_n$ som

$$\hat{F}_n(x) = \frac{\#\{x_i \leq x\}}{n} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{(-\infty, x]}(x_i).$$

Den empiriske fordelingsfunktion

Empiriske fordelingsfunktioner kan sammenlignes direkte:




Figure 2.14 Ecdf's for male and female beer consumption. The vertical line is at 25 oz.


Kan laves med `plot.ecdf`

Den empiriske fordelingsfunktion

Den empiriske fordelingsfunktion kan også bruges til at vurdere den antagelse at data $x_1, \dots, x_n$ er realisationer af uafhængige identisk fordelte (i.i.d.) $X_1, \dots, X_n$ med fælles fordelingsfunktion F .

På grund af de store tals lov vil der gælde at

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{(-\infty, x]}(X_i) \xrightarrow{\mathbb{P}} F(x).$$



Fraktiler

I stedet for at sammenligne fordelingsfunktionerne sammenlignes disses *fraktiler*.

Definition


Lad F være en fordelingsfunktion for en stokastisk variabel X . For ethvert $p \in [0, 1]$ er p -fraktilen for F mængden x_p givet ved

$$x_p = \{x \in \mathbb{R} : F(x-) \leq p \leq F(x)\}.$$

$x_{0.50}$ kaldes for en median for F , mens $x_{0.25}$ og $x_{0.75}$ kaldes henholdsvis nedre og øvre kvartil for F .

Selvom fraktiler altså strengt taget er mængder af tal undertrykkes dette ofte, og man skriver f.eks. $x_{0.1} = 0.632$ som i Figur 2 på næste slide.

Fraktiler




Figur 2: Illustration af fraktiler for en fordelingsfunktion F . Det ses at $x_{0.1} = 0.632$, $x_{0.4} = x_{0.5} = 1$ og $x_{0.8} = [2, 3]$

Fraktiler

En fraktilfunktion er en funktion der giver fraktiler - for eksempel

$$F^{-}(p) \stackrel{\text{def}}{=} \inf\{x \in \mathbb{R} : p \leq F(x)\} = \min\{x \in \mathbb{R} : p \leq F(x)\}.$$



Hvis F er kontinuert og strengt voksende består x_p kun af ét punkt, nemlig $F^{-1}(p)$, det vil sige at

$$x_p = F^{-1}(p), \quad p \in]0, 1[.$$

Fraktiler

For en talfølge $x_1, x_2, \dots, x_n$ kaldes fraktilerne for $\hat{F}_n$ for empiriske fraktiler. Kan beregnes med `quantile`, ved at vælge `type=1` som svarer til $\hat{F}^-$. `type=2` tager gennemsnit i diskontinuitetspunkter, hvilket svarer til den måde medianen for $x_1, x_2, \dots, x_n$ blev beregnet. De resterende muligheder for `type` omtales på hjælpesiden for funktionen (`?quantile`).


Fraktildiagrammer for normalfordelingen

Et fraktil diagram for normalfordeling kan nu laves ved at indtegne punkterne: ($\Phi^{-1}(\frac{i - \frac{1}{2}}{n})$, $x_{(i)}$) $i = 1, \dots, n$.


R-koden (x er data fra figuren på slide 28)

```
qqnorm(x)
```

giver





Fraktildiagrammer for normalfordelingen



Weight variablen fra datasættet TXBirths.



Fraktildiagrammer for normalfordelingen

I fraktildiagrammer ser vi efter *systematiske* afvigelser fra en ret linje.



Transformation af data

Hvis man ikke umiddelbart kan finde en statistisk model for data kan en mulig løsning være at anvende en transformation.



Venstre: Fraktildiagram for reaktionstid for fluer. Højre: Fraktildiagram for logritmen til reaktionstiden. Bemærk at de teoretisk fraktiler er på y-aksen.

Scatterplot (punktdiagram)

MSRR 2.6


Visualiser sammenhæng mellem interessevariabel y og forklarende variabel x . Hver observation giver en punkt i diagrammet. R:

```
plot (x, y)
```

eller formel-syntaks:

interessevariabel $\sim$ forklarende variabel

```
plot (Beer  $\sim$  Hotwings, data=Beerwings)
```



Skewness og kurtosis

Lad X være en stokastisk variabel med middelværdi $\mathbb{E}[X] = \mu$ og standard afvigelse $\sqrt{\text{Var}[X]} = \sigma$. Da indføres *skewness* (skævhed) og *kurtosis* (topstejlhed) som

$$\gamma_1 = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{\mu_3}{\sigma^3}$$
$$\gamma_2 = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] - 3 = \frac{\mu_4}{\sigma^4} - 3,$$

hvor $\mu_k = \mathbb{E}(X - \mu)^k$ betegner de *centrale momenter*. Til tider betegnes $\mu^4/\sigma^4 - 3$ *excess kurtosis* og μ^4/σ^4 som kurtosis.

Skewness og kurtosis

Skewness kan under rette omstændigheder fortolkes som et kvantitativt mål for skævheden:






Figure 2.2 Histogram of lengths of flight delays for United Airlines. The distribution is right skewed.

$$\hat{\gamma}_1 = 4.807$$



$$\hat{\gamma}_1 = 0.003$$




$$\hat{\gamma}_1 = -0.751$$

Estimerede værdier af skewness

Skewness og kurtosis

Kurtosis kan (igen under rette omstændigheder) fortolkes som et kvantitativt for hvor tunge fordelings haler er (*og i denne forstand* hvor “spids” toppen er).



Estimerede værdier af excess kurtosis

Bibliografi



Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (2nd edition).

John Wiley & Sons, 2018.



Alan Julian Izenman.

Modern multivariate statistical techniques.

Springer Texts in Statistics. Springer, New York, 2008.

Regression, classification, and manifold learning.

Matematisk Statistik

Normalfordelte data - Én observationsrække

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Normalfordelte data

Indledende modeller:

- Én observationsrække
- Flere observationsrækker
- Lineær regression

Alle er eksempler på *lineære normale modeller*.

Uanset hvilken model vi betragter, vil $\mathbf{x}$ betegne en vektor der indeholder observationerne og $\mathbf{X}$ betegne en (stokastisk) vektor, der indeholde de tilsvarende stokastisk variable.

Én normalfordelt observationsrække

I forbindelse med gennemgangen af én normalfordelt observationsrække indføres *centrale statistiske begreber* såsom:

- 1 Model og modelkontrol
- 2 Estimer og estimatorer
- 3 Hypoteser, teststørrelser, testorer
- 4 p -værdier (testsandsynligheder)
- 5 Konfidensintervaller

Begreberne introduceres i forbindelse med Eksempel 2.1.

En observationsrække

Fagligt problem og data

Under en automatiseret svejseproces måles løbende kritiske værdier, såsom spændingen i volt, for at sikre korrekt svejsning. Ved en kvalitetskontrol er der udført $n = 30$ spændingsmålinger. Det tilstræbes at spændingen er på 22.0 V.

Målingerne fremgår af Tabel 1.

21.89	22.25	21.95	22.45	22.37
22.20	22.41	21.27	22.36	22.10
21.80	22.35	22.56	22.48	22.07
22.75	22.01	22.11	22.43	21.56
22.26	22.71	22.19	22.16	21.94
21.88	22.22	22.42	21.36	22.29

Tabel 1: Målinger af spænding ved en automatiseret svejsningsproces.

Én observationsrække - kendt varians

Model

Som model vil vi anvende *én normalfordelt observationsrække*. Erfaringen viser nemlig, at denne typer målinger er normalfordelte. De $n = 30$ observationer

$$X_1, \dots, X_n$$

antages at være realisationer af uafhængige identisk normalfordelte stokastiske variable


$$X_1, \dots, X_n$$

med ukendt middelværdi μ og *kendt* varians σ_0^2 . Erfaringen med produktionen indikerer, at spredningen σ_0 er $\sqrt{0.23}$ V, så det vil vi indledningsvis regne med. Vi opskriver modellen

$$M_1 : X_i \sim N(\mu, \sigma_0^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

Hvor “+ uafhængighed” over, at $X_1, \dots, X_n$ udgør en følge af stokastisk uafhængige variable.

En observationsrække - kendt varians



Modellen M_1 kontrolleres ved hjælp af et fraktildiagram for normalfordelingen. Da punkterne i diagrammet ikke afviger systematisk fra en ret linje, giver det ikke anledning til at tvivle på modellen.

Én observationsrække - kendt varians

Estimation

Først ser vi på, hvad man kan sige om middelværdien μ ud fra observationerne. Vi *skønner* over μ , eller *estimerer* μ . Traditionelt benytter man gennemsnittet af observationerne

$$\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = 22.16 \text{ V}.$$

Det er vigtigt at skelne mellem den teoretiske, men ukendte middelværdi μ og skønnet $\bar{x}$. Vi benytter notationen $\mu \leftarrow \bar{x}$. som læses “estimatet for μ er $\bar{x}$ ”. Her $\mu \leftarrow 22.16 \text{ V}$.

En observationsrække - kendt varians

Fordeling af estimator

Den stokastiske variabel, som estimatet er et udfald af, omtales som en *estimator*. Fra A.3.1.3 fås, at der for estimatoren for middelværdien μ gælder, at

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma_0^2}{n}\right).$$

Bemærk følgende egenskaber ved estimatoren:

- 1 $\bar{X} = \mu$ så middelværdien af estimatoren er netop den parameter, vi estimerer (estimatoren er “unbiased”).
- 2 Variansen af estimatoren går mod 0, når n , antallet af observationer vokser, dvs. for store n ligger estimatet $\bar{x}$ tæt ved den parameter μ , vi estimerer.

En observationsrække - kendt varians

Hypotese

Om spændingen rammer den ideelle værdi 22.0 V, kan i modellen M_1 formuleres som spørgsmålet, om middelværdien μ er lig med 22.0 V. Vi betragter derfor nulhypotesen

$$H_0 : \mu = \mu_0 = 22.0$$

Test af hypotese

Da $\mu \leftarrow \bar{x}$, forekommer det rimeligt

- at forkaste H_0 , hvis $\bar{x}$. ligger langt fra μ_0
- ikke at forkaste H_0 , hvis $\bar{x}$. ligger tæt på μ_0

Spørgsmålet er om differensen $\bar{x} - \mu_0 = 22.16 - 22.0 = 0.16$ er "tæt" på 0. Svaret må afhænge af variansen på $\bar{X}$.

En observationsrække - kendt varians

Teststørrelse

Vi beregner derfor *teststørrelsen*

$$u(\mathbf{x}) = u(x_1, \dots, x_n) = \frac{\bar{x} - \mu_0}{\sqrt{\frac{\sigma_0^2}{n}}} = \frac{22.16 - 22.0}{\sqrt{\frac{0.23}{30}}} = 1.827329,$$

som er differensen normeret med spredningen på gennemsnittet. Dette er et eksempel på en *teststørrelse*, da det er en *stikprøvefunktion*, der kan bruges til at undersøge en hypotese. Teststørrelsen $u(\mathbf{x})$ er en realisation af den stokastiske variabel

$$u(\mathbf{X}) = u(X_1, \dots, X_n) = \frac{\bar{X} - \mu_0}{\sqrt{\frac{\sigma_0^2}{n}}} = \frac{\bar{X} - 22.0}{\sqrt{\frac{0.23}{30}}},$$

som under H_0 vil have en $N(0, 1)$ fordeling.

$u(\mathbf{X})$ kaldes en *testor*.

Én observationsrække - kendt varians

Vi vil notationsmæssigt skelne mellem teststørrelsen $u(\mathbf{x})$ og testoren $u(\mathbf{X})$, ved at angive, om u skal opfattes som en funktion af $\mathbf{x}$ eller $\mathbf{X}$, men vil også til tider droppe $\mathbf{x}/\mathbf{X}$ og blot skrive u for teststørrelse eller testor, hvis det er oplagt ud fra sammenhængen, hvad der er tale om. Dette vil også gælde for estimater, estimatorer og andre teststørrelser og testorer, som vi senere hen indfører.

En observationsrække - kendt varians

p-værdi - Testsandsynlighed

Værdier af teststørrelsen $u(\mathbf{x})$, som ligger tæt på 0, er ikke kritiske for hypotesen H_0 . Værdier af u , hvis numeriske værdi er større end eller lig den observerede værdi 1.827329, siges at være mindst lige så kritiske for hypotesen som den observerede. Man beregner derfor *p-værdien* - eller *testsandsynligheden* - p_{obs} , som er *sandsynligheden under nulhypotesen for en mere kritisk værdi af teststørrelsen end den observerede*. Det vil sige

$$\begin{aligned} p_{obs}(\mathbf{x}) &= \mathbb{P}_{\mu_0}(|U(\mathbf{X})| \geq |u(\mathbf{x})|) \\ &= \mathbb{P}_{\mu_0}(U(\mathbf{X}) \geq |u(\mathbf{x})|) + \mathbb{P}_{\mu_0}(U(\mathbf{X}) \leq -|u(\mathbf{x})|) \\ &= 1 - \Phi(|u(\mathbf{x})|) + \Phi(-|u(\mathbf{x})|) \\ &= 2(1 - \Phi(|u(\mathbf{x})|)) = 2(1 - \Phi(1.827329)) = 0.06765035. \end{aligned}$$

Én observationsrække - kendt varians

Forkastes H_0 ?

Der er altså en sandsynlighed på ca. 6.8% for at få udfald af u , der er mere kritiske end det observerede 1.83.

Hvad nu, hvis vi havde fundet at $u(\mathbf{x}) = 3.43$ og dermed en testsandsynlighed på $p_{obs}(\mathbf{x}) = 0.06\%$?

- Med en testsandsynlighed på 6.8% kan hypotesen ikke afvises.
- Med en testsandsynlighed på 0.06% er det ikke særlig sandsynligt, at H_0 er sand.

Vi *forkaster* derfor H_0 , hvis $p_{obs}(\mathbf{x}) = 0.06\%$, og vi forkaster ikke, hvis p_{obs} er på ca. 6.8%.

Hvor går grænsen mellem at forkaste og ikke forkaste?

En observationsrække - kendt varians

Signifikansniveau

Hvis vi:

- forkaster H_0 , hvis $p_{obs}(\mathbf{x}) < \alpha$

og

- ikke forkaster H_0 , hvis $p_{obs}(\mathbf{x}) \geq \alpha$

kaldes α testets *signifikansniveau*.

I dette kursus benyttes signifikansniveauet $\alpha = 0.05 = 5\%$ med mindre andet er nævnt.

Én observationsrække - kendt varians

Faglig konklusion

Da $p_{obs}(\mathbf{x}) = 0.068 > 0.05$ forkastes hypotesen $H_0 : \mu = 22.0$ ikke, omend det er tæt på.

Vi har således ikke i den her betragtede kontrol fundet afvigelser fra den tilstræbte ideelle spænding.

Vi siger, at vi ikke kan forkaste H_0 på niveau $\alpha = 0.05$. (Vi accepterer H_0 på niveau α).

En observationsrække - kendt varians

Konfidensinterval for μ

For hvilke μ_0 vil vi ikke forkaste $H : \mu = \mu_0$ på niveau α ?

$$\begin{aligned} & \{\mu_0 \in \mathbb{R} \mid p_{obs} \geq \alpha\} \\ &= \{\mu_0 \in \mathbb{R} \mid 2(1 - \Phi(|u(\mathbf{x})|)) \geq \alpha\} \\ &= \{\mu_0 \in \mathbb{R} \mid |u(\mathbf{x})| \leq u_{1-\alpha/2}\} \\ &= \{\mu_0 \in \mathbb{R} \mid \left| \frac{\bar{x} - \mu_0}{\sqrt{\sigma_0^2/n}} \right| \leq u_{1-\alpha/2}\} \\ &= \{\mu_0 \in \mathbb{R} \mid \bar{x} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \leq \mu_0 \leq \bar{x} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2}\}. \end{aligned}$$

Vi ser altså $H_0 : \mu = \mu_0$ accepteres for μ_0 i intervallet

$$\left[\bar{x} - \sqrt{\sigma_0^2/n} u_{1-\alpha/2}, \bar{x} + \sqrt{\sigma_0^2/n} u_{1-\alpha/2} \right]$$

En observationsrække - kendt varians

Konfidensinterval som stokastisk interval

Indsætter vi de stokastiske variable X_i i udtrykket for konfidensintervallet fås

$$\left[\bar{X} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2}, \bar{X} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \right]$$

fås et stokastisk interval defineret ved de to endepunkter

$$L = \bar{X} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \quad \text{og} \quad U = \bar{X} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2},$$

Hvad er sandsynligheden i M_1 for at dette interval indeholder den sande værdi af den ukendte parameter μ ?

En observationsrække - kendt varians

Konfidensinterval som stokastisk interval - fortsat

Vi finder at

$$\mathbb{P} \left[\bar{X}_{\cdot} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \leq \mu \leq \bar{X}_{\cdot} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \right] =$$
$$\mathbb{P} \left[u_{\alpha/2} \leq \frac{\bar{X}_{\cdot} - \mu}{\sqrt{\sigma_0^2/n}} \leq u_{1-\alpha/2} \right] = 1 - \alpha.$$

Vi er at uligheden

$$\bar{X}_{\cdot} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \leq \mu \leq \bar{X}_{\cdot} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2}$$

holder med sandsynlighed $1 - \alpha$.

Én observationsrække - kendt varians

Faglig konklusion - fortsat

For datasættet i Eksempel 2.1 finder vi

$$\left[22.16 \pm 1.960 \cdot \sqrt{\frac{0.23}{30}} \right] = [21.9883, 22.3316] \text{ V}$$

der indeholder den ideelle værdi på 22.0 V (som det skal).

En observationsrække - ukendt varians

Vi vil nu droppe antagelsen om at variansen er kendt.

I denne model er der $n = 30$ observationer

$$X_1, \dots, X_n$$

udfald af uafhængige identisk fordelte stokastiske variable

$$X_1, \dots, X_n$$

med ukendt middelværdi μ og *ukendt* varians σ^2 , dvs. modellen hvor

$$M_1 : X_i \sim N(\mu, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed. }$$

Modellen har to parametre μ og σ^2 , der skal estimeres fra data.

En observationsrække - ukendt varians

Modelkontrol

Modellen M_1 kontrolleres ved hjælp af fraktildiagrammet for normalfordelingen (som før).

Estimation

Som tidligere estimeres μ ved gennemsnittet af observationerne

$$\mu \leftarrow \hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = 22.16 \text{ V}.$$

mens σ^2 estimeres ved $s^2(\mathbf{x})$ hvor

$$s^2(\mathbf{x}) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{3.5636}{29} = 0.122883.$$

De tilsvarende estimatorer $\bar{X}$ og $s^2(\mathbf{X})$ er uafhængige.

En observationsrække - ukendt varians

Der gælder at

$$s^2(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \sigma^2 \chi^2(n-1)/(n-1).$$

Se afsnit A.3.2 i appendikset for notation vedr. χ^2 -fordelingen.

Der gælder dermed

$$\mathbb{E}[s^2(\mathbf{X})] = \sigma^2$$

og

$$\mathbb{V}\text{ar}[s^2(\mathbf{X})] = \frac{2\sigma^4}{n-1}.$$

Bemærk, at ved at dividere kvadratsummen med $n-1$ fås en estimator, som har en middelværdi σ^2 , det vil sige at vi opnår en unbiased estimator.

Én observationsrække - ukendt varians

Hypotesen $H_0 : \mu = \mu_0$

Hvis variansen var kendt og lig med σ^2 betragtede vi u -teststoren

$$u(\mathbf{X}) = u(X_1, \dots, X_n) = \frac{\bar{X} - \mu_0}{\sigma^2/n}.$$

Nu kender vi ikke σ^2 , så derfor benyttes i stedet s^2 , og vi får t -teststoren

$$t(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{\frac{s^2(\mathbf{X})}{n}}},$$

ved at erstatte den ukendte varians i u -teststoren med s^2 .

En observationsrække - ukendt varians

Testsandsynlighed i t -testet

Som ved u -testet er numerisk store værdier kritiske for H_0 . Da

$$t(\mathbf{X}) \sim t(n-1)$$

under H_0 bliver testsandsynligheden

$$\begin{aligned} p_{\text{obs}} &= \mathbb{P}_{\mu_0}(|T(\mathbf{X})| \geq |t(\mathbf{x})|) \\ &= 2(1 - F_{t(n-1)}(|t(\mathbf{x})|)). \end{aligned}$$

I Eksempel 2.1 fås

$$t(\mathbf{x}) = t(x_1, \dots, x_n) = \frac{\bar{x} - \mu_0}{\sqrt{\frac{s^2(\mathbf{x})}{n}}} = 2.49997,$$

og

$$p_{\text{obs}} = 2(1 - F_{t(29)}(2.49997)) = 0.0183265.$$

Vi ser at vi i denne model *afviser* H_0 .

Én observationsrække - ukendt varians

Faglig konklusion

Da $p_{obs}(\mathbf{x}) = 0.0183$ forkastes hypotesen $H_0 : \mu = 22.0$ V.

Hvilken model tror vi mest på?

En observationsrække - ukendt varians

Konfidensinterval for μ

Som i tilfældet med kendt varians kan vi undersøge hvor hvilke μ_0 hypotesen $H_0 : \mu = \mu_0$ ikke forkastes ved et test på niveau α .

Tilsvarende beregninger giver

$$\left[\bar{x} - \sqrt{\frac{s^2}{n}} t_{1-\alpha/2}(n-1), \bar{x} + \sqrt{\frac{s^2}{n}} t_{1-\alpha/2}(n-1) \right],$$

og vi finder også

$$\mathbb{P} \left[\bar{X} - \sqrt{\frac{s^2(\mathbf{X})}{n}} t_{1-\alpha/2}(n-1) \leq \mu \leq \bar{X} + \sqrt{\frac{s^2(\mathbf{X})}{n}} t_{1-\alpha/2}(n-1) \right] =$$

$$\mathbb{P} \left[t_{\alpha/2}(n-1) \leq \frac{\bar{X} - \mu}{\sqrt{s^2(\mathbf{X})/n}} \leq t_{1-\alpha/2}(n-1) \right] = 1 - \alpha.$$

En observationsrække - ukendt varians

Hypotesen $H_0 : \sigma^2 = \sigma_0^2$

Da $\sigma^2 \leftarrow s^2$ vil vi under H_0 forvente at $s^2(\mathbf{x})/\sigma_0^2 \approx 1$. Endvidere gælder under H_0 for den tilsvarende testor, at

$$\frac{s^2(\mathbf{X})}{\sigma_0^2} \sim \frac{\chi^2(f)}{f}.$$

hvor $f = n - 1$.

Vi har

$$\frac{s^2(\mathbf{x})}{\sigma_0^2} = \frac{0.122883}{0.23} = 0.555742.$$

Oplagt vil værdier af $s^2(\mathbf{X})/\sigma_0^2$ der er *mindre* end 0.555742 være kritiske for H_0 , men hvilke store værdier?

En observationsrække - ukendt varians

Hypotesen $H_0 : \sigma^2 = \sigma_0^2$ - fortsat

Idé: beregn p_{obs} som to gange sandsynligheden for, at $\frac{s^2(\mathbf{X})}{\sigma_0^2}$ er mindre end $\frac{s^2(\mathbf{x})}{\sigma_0^2}$.

$$\begin{aligned} p_{obs} &= 2\mathbb{P}_{\sigma_0^2}(s^2(\mathbf{X})/\sigma_0^2 \leq s^2(\mathbf{x})/\sigma_0^2) \\ &= 2F_{\chi^2(f)/f}(s^2(\mathbf{x})/\sigma_0^2) = 2F_{\chi^2(f)}(fs^2(\mathbf{x})/\sigma_0^2) \\ &= 2F_{\chi^2(29)}(29 \cdot 0.534273) = 0.038458, \end{aligned}$$

hvor $f = n - 1$.

En observationsrække - ukendt varians

Hypotesen $H_0 : \sigma^2 = \sigma_0^2$ - fortsat

Generelt udtryk for p_{obs} ?

Første bud: Brug 1 som afskæring, dvs.

$$\tilde{p}_{obs}(\mathbf{x}) = \begin{cases} 2F_{\chi^2(f)/f}(\frac{s^2}{\sigma_0^2}), & \text{hvis } \frac{s^2}{\sigma_0^2} \leq 1, \\ 2\left(1 - F_{\chi^2(f)/f}(\frac{s^2}{\sigma_0^2})\right), & \text{hvis } \frac{s^2}{\sigma_0^2} \geq 1. \end{cases}$$

Problem: $\tilde{p}_{obs}(\mathbf{x})$ kan blive større end 1.

Andet bud: Brug medianen $m \stackrel{\text{def}}{=} \chi_{1/2}^2(f)/f$ som afskæring, dvs.

$$p_{obs}(\mathbf{x}) = \begin{cases} 2F_{\chi^2(f)/f}(\frac{s^2}{\sigma_0^2}), & \text{hvis } \frac{s^2}{\sigma_0^2} \leq m \\ 2\left(1 - F_{\chi^2(f)/f}(\frac{s^2}{\sigma_0^2})\right), & \text{hvis } \frac{s^2}{\sigma_0^2} \geq m \end{cases}$$

som p -værdi.

Hypotesen $H_0 : \sigma^2 = \sigma_0^2$ - fortsat

Denne foretrækkes fordi

$$p_{obs}(\mathbf{x}) = 2 \min \left\{ F_{\chi^2(f)/f} \left(\frac{s^2}{\sigma_0^2} \right), 1 - F_{\chi^2(f)/f} \left(\frac{s^2}{\sigma_0^2} \right) \right\}.$$

En observationsrække - ukendt varians

$1 - \alpha$ konfidensinterval for σ^2

I M_1 gælder at $s^2(\mathbf{X})/\sigma^2 \sim \chi^2(f)/f$ og dermed,

$$\begin{aligned} 1 - \alpha &= \mathbb{P} \left[\frac{\chi_{\alpha/2}^2(f)}{f} \leq \frac{s^2(\mathbf{X})}{\sigma^2} \leq \frac{\chi_{1-\alpha/2}^2(f)}{f} \right] \\ &= \mathbb{P} \left[\frac{fs^2(\mathbf{X})}{\chi_{1-\alpha/2}^2(f)} \leq \sigma^2 \leq \frac{fs^2(\mathbf{X})}{\chi_{\alpha/2}^2(f)} \right]. \end{aligned}$$

hvor $f = n - 1$. Dermed er

$$\left[\frac{fs^2(\mathbf{X})}{\chi_{1-\alpha/2}^2(f)}, \frac{fs^2(\mathbf{X})}{\chi_{\alpha/2}^2(f)} \right]$$

et $1 - \alpha$ konfidensinterval. Intervallet er identisk med det, vi var kommet frem til hvis vi havde beregnet $\{\sigma_0^2 \mid p_{obs}(\mathbf{x}) > \alpha\}$.

En observationsrække - ukendt varians

For datasættet i Eksempel 2.1 fås

$$\begin{aligned} & \left[\frac{fs^2(\mathbf{x})}{\chi^2_{1-\alpha/2}(f)}, \frac{fs^2(\mathbf{x})}{\chi^2_{\alpha/2}(f)} \right] \\ &= \left[29 \cdot \frac{0.12288}{45.7223}, 29 \cdot \frac{0.12288}{16.0471} \right] \\ &= [0.07794011, 0.22207167] \end{aligned}$$

Faglig konklusion

Da $H_0 : \sigma^2 = 0.23$ afvises, foretrækker vi modellen hvor variansen er ukendt.

En observationsrække - ukendt varians

Beregninger og terminologi

Estimatet for σ^2 kaldes den empiriske varians og er

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Kvadratsummen kaldes SSD, som står for *Sum of Squares of Deviations* eller *Sum of Squared Deviations* og vi kan skrive

$$s^2 = \frac{1}{n-1} \text{SSD}.$$

Vi skriver $\text{SSD}(\mathbf{x})$ eller $\text{SSD}_{\mathbf{x}}$, hvis vi ønsker at fremhæve afhængigheden af x_i -erne.

Vi indfører desuden $\text{USS}_{\mathbf{x}}$ ("Uncorrected Sum of Squares") som

$$\text{USS}_{\mathbf{x}} = \sum_{i=1}^n x_i^2.$$

Lemma

Lad $a, b, c > 0$. Da gælder, at funktionerne

$$x \mapsto -b \ln(cx) - \frac{a}{x} \quad \text{og} \quad x \mapsto \frac{1}{(cx)^b} e^{-\frac{a}{x}} \quad x > 0$$

har et entydigt maksimum for $x = \frac{a}{b}$.

Vi betragter modellen med ukendt middelværdi og varians. Likelihoodfunktionen er den simultane tæthed for observationerne, opfattet som en funktion af parametrene

$$\begin{aligned} p(\mathbf{x}; \mu) &= f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu)^2} \\ &= \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}, \end{aligned}$$

og derfor er likelihoodfunktionen L givet ved

$$L(\mu, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}.$$

log likelihoodfunktionen er logaritmen til likelihoodfunktionen:

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Først maksimeres ℓ for fast σ^2 (“profilmaksimering”). Derved fås

$$\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Vi finder derved

$$\ell(\mu, \sigma^2) \leq \ell(\bar{x}, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Dette maksimeres med hensyn til σ^2 og vi finder

$$\hat{\sigma}^2 = \hat{\sigma}^2(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Samlet:

$$(\hat{\mu}, \hat{\sigma}^2) = \left(\bar{x}, \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right).$$

Bemærk, at $\hat{\sigma}^2$ *ikke* er unbiased.

Likelihood test for $H : \mu = \mu_0$.

Likelihood ratio teststørrelsen

$$Q(\mathbf{x}) \stackrel{\text{def}}{=} \frac{\max_{\sigma^2 \in \mathbb{R}_+} L(\mu_0, \sigma^2)}{\max_{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+} L(\mu, \sigma^2)} = \frac{L\left(\mu_0, \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2\right)}{L(\bar{x}, \hat{\sigma}^2)},$$

og vi finder

$$Q(\mathbf{x}) = \left[\frac{1}{1 + \frac{t^2(\mathbf{x})}{n-1}} \right]^{\frac{n}{2}} \quad \text{hvor} \quad t(\mathbf{x}) = \frac{\bar{x} - \mu_0}{\sqrt{\frac{s^2(\mathbf{x})}{n}}}.$$

Vi ser at likelihood ratio testet er *ækvivalent* med t -testet, i den forstand at

$$p_{\text{obs}}(\mathbf{x}) = \mathbb{P}_{\mu_0}(Q(\mathbf{X}) \leq Q(\mathbf{x})) = \mathbb{P}_{\mu_0}(|t(\mathbf{X})| \geq |t(\mathbf{x})|).$$

Matematisk Statistik

To normalfordelte observationsrækker

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

To normalfordelte observationsrækker
Ens varians

k normalfordelte observationsrækker

Modellen for k normalfordelte observationsrækker er, at data

Gruppe 1	x_{11}	$\dots$	x_{1j}	$\dots$	x_{1n_1}
$\vdots$		$\vdots$		$\vdots$	
Gruppe i	x_{i1}	$\dots$	x_{ij}	$\dots$	x_{in_i}
$\vdots$		$\vdots$		$\vdots$	
Gruppe k	x_{k1}	$\dots$	x_{kj}	$\dots$	x_{kn_k}

er realisationer af uafhængige, normalfordelte stokastiske variable

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, \dots, k, \quad j = 1, \dots, n_i.$$

k observationsrækker: notation

Notation vedrørende modellen

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, \dots, k, \quad j = 1, \dots, n_i.$$

I den i te række er

- antallet af observationer: n_i
- den empiriske middelværdi eller gennemsnittet:

$$\bar{x}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} x_{ij}$$

- den empiriske varians

$$s_{(i)}^2 = \frac{1}{n_i - 1} \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i\cdot})^2$$

- antallet af frihedsgrader: $f_{(i)} = n_i - 1$

Eksempel 1.5

Data

I dette eksempel stammer fra to eksperimenter, hvor man målte fluers reaktion, efter de var blevet udsat for en nervegas.

Målingen for den enkelte flue består i den tid - reaktionstiden - der går fra fluen bringes i kontakt med giften og indtil den ikke længere kan stå på benene.

Fagligt problem

Afhænger reaktionstiden af kontakttiden?

Transformation

Fraktildiagrammerne i Figur 1.6 og 1.7 viser, at vi er nødt til at logaritmetransformere reaktionstiderne for at opnå normalitet.

Eksempel 1.5

Model og modelkontrol

Lad x_{ij} være den naturlige logaritme til j te observation af reaktionstiden i den i te gruppe. Vi betragter da modellen

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i + \text{uafhængighed}.$$

Idet $i = 1$ svarer til en kontakttid på 30 s og $i = 2$ til 60 s, er $n_1 = 16$ og $n_2 = 15$.

Fraktildiagrammet i Figur 1.7 strider ikke mod denne model og antyder tillige, at kontakttiden ikke har nogen betydning for reaktionstiden.

Eksempel 1.5

Estimation i M_0

$$\mu_1 \leftarrow \bar{x}_{1.} = 2.8072$$

$$\bar{X}_{1.} \sim N(\mu_1, \sigma_1^2/n_1)$$

$$\mu_2 \leftarrow \bar{x}_{2.} = 2.7154$$

$$\bar{X}_{2.} \sim N(\mu_2, \sigma_2^2/n_2)$$

$$\sigma_1^2 \leftarrow s_{(1)}^2 = 1.102779$$

$$s_{(1)}^2(\mathbf{X}) \sim \sigma_1^2 \chi^2(f_{(1)})/f_{(1)}$$

$$\sigma_2^2 \leftarrow s_{(2)}^2 = 1.023778$$

$$s_{(2)}^2(\mathbf{X}) \sim \sigma_2^2 \chi^2(f_{(2)})/f_{(2)}$$

De 4 estimatorer er uafhængige (se A.1.2).

Hypoteser og test

I modellen for to normalfordelte observationsrækker

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i,$$

er det sædvanligvis hypotesen *ens middelværdier*,

$$H_{0\mu} : \mu_1 = \mu_2$$

der er af primær interesse.

Testet for $H_{0\mu}$ afhænger af, om det kan antages, at de to rækker har ens varians. Vi tester derfor først hypotesen

$$H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2.$$

Test af $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$

Da $\sigma_1^2 \leftarrow s_{(1)}^2$ og $\sigma_2^2 \leftarrow s_{(2)}^2$, må man under $H_{0\sigma^2}$ forvente, at

$$\frac{s_{(1)}^2}{s_{(2)}^2} \approx 1$$

Under $H_{0\sigma^2}$ er $s_{(1)}^2/s_{(2)}^2$ $F(f_{(1)}, f_{(2)})$ -fordelt (se A.3.4), og et første bud på p -værdien er derfor

$$\tilde{p}_{obs}(\mathbf{x}) = \begin{cases} 2F_{F(f_{(1)}, f_{(2)})}\left(\frac{s_{(1)}^2}{s_{(2)}^2}\right), & \text{hvis } \frac{s_{(1)}^2}{s_{(2)}^2} \leq 1, \\ 2\left(1 - F_{F(f_{(1)}, f_{(2)})}\left(\frac{s_{(1)}^2}{s_{(2)}^2}\right)\right), & \text{hvis } \frac{s_{(1)}^2}{s_{(2)}^2} \geq 1, \end{cases}$$

hvor $F_{F(f_{(1)}, f_{(2)})}$ er fordelingsfunktionen for $F(f_{(1)}, f_{(2)})$ -fordelingen.

Test af $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$

I stedet benyttes dog (med samme argument som for $H : \sigma^2 = \sigma_0^2$)

$$p_{obs}(\mathbf{x}) = 2 \min \left\{ F_{F(f_{(1)}, f_{(2)})} \left(\frac{s_{(1)}}{s_{(2)}} \right), 1 - F_{F(f_{(1)}, f_{(2)})} \left(\frac{s_{(1)}}{s_{(2)}} \right) \right\}.$$

For data i Eksempel 1.5 har vi

$$\mathcal{F}(\mathbf{x}) = \frac{s_{(1)}^2(\mathbf{x})}{s_{(2)}^2(\mathbf{x})} = \frac{1.102779}{1.023778} = 1.077.$$

og da

$$\mathbb{P}[\mathcal{F}(\mathbf{X}) > 1.077] = 1 - F_{F(f_{(1)}, f_{(2)})}(1.077) = 0.447$$

finder vi

$$p_{obs}(\mathbf{x}) = 2\mathbb{P}(\mathcal{F}(\mathbf{X}) > 1.077) = 0.894.$$

så $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$ forkastes ikke.

Faglig konklusion

Data strider ikke mod at antage, at de to observationsrækker har ens varians.

Ens varians

Modellen M_1

Da vi ikke forkaster $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$ reduceres modellen M_1 til

$$M_1 : X_{ij} \sim (\mu_i, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed. }$$

som har tre ukendte parametre, middelværdierne μ_1 og μ_2 i de to rækker og den fælles varians σ^2 .

Estimation i M_1

$$\mu_1 \leftarrow \hat{\mu}_1(\mathbf{x}) = \bar{x}_1. \quad \text{hvor} \quad \bar{X}_1. \sim N(\mu_1, \sigma^2/n_1)$$

$$\mu_2 \leftarrow \hat{\mu}_2(\mathbf{x}) = \bar{x}_2. \quad \text{hvor} \quad \bar{X}_2. \sim N(\mu_2, \sigma^2/n_1)$$

$$\sigma^2 \leftarrow s_1^2 = \frac{\text{SSD}_{(1)} + \text{SSD}_{(2)}}{n_1 + n_2 - 2} = \frac{f_{(1)}s_{(1)}^2 + f_{(2)}s_{(2)}^2}{f_{(1)} + f_{(2)}} = \frac{\text{SSD}_1}{f_1} \sim \frac{\sigma^2 \chi^2(f_1)}{f_1}.$$

hvor $f_1 = n_1 + n_2 - 2$, antallet af observationer minus antallet af ukendte parametre i middelværdien.

Eksempel 1.5 : Estimation i M_1

Eksempel 1.5

Estimaterne for parametrene i M_1 er

$$\mu_1 \leftarrow \bar{x}_{1\cdot} = 2.8072$$

$$\mu_2 \leftarrow \bar{x}_{2\cdot} = 2.7154$$

$$\sigma^2 \leftarrow s^2 = 1.064638$$

De tre fordelinger er henholdsvis $N(\mu_1, \sigma^2/16)$, $N(\mu_2, \sigma^2/15)$ og $\sigma^2\chi^2(29)/29$ og de tilsvarende stokastiske variable er uafhængige.

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_1

Testet er baseret på en sammenligning af estimerterne for middelværdierne. Da

$$\bar{X}_{1.} \sim N\left(\mu_1, \frac{\sigma^2}{n_1}\right) \quad \text{og} \quad \bar{X}_{2.} \sim N\left(\mu_2, \frac{\sigma^2}{n_2}\right),$$

og fordelingerne er uafhængige, gælder der under $H_{\mu 0}$ at

$$\bar{X}_{1.} - \bar{X}_{2.} \sim N\left(0, \sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)\right).$$

Derfor er

$$\frac{\bar{X}_{1.} - \bar{X}_{2.}}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1).$$

Da σ^2 er ukendt, indsættes i stedet skønnet s^2 .

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_1 (fortsat)

Dette giver t -testoren

$$t(\mathbf{X}) = \frac{\bar{X}_{1\cdot} - \bar{X}_{2\cdot}}{\sqrt{s^2(\mathbf{X}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \underset{\text{under } H_{0\mu}}{\sim} t(f_1).$$

Da numerisk store værdier af t er kritiske, bliver testsandsynligheden for t -testet

$$p_{obs}(\mathbf{x}) = 2 \left[1 - F_{t(f_1)}(|t(\mathbf{x})|) \right].$$

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_1 (fortsat)

Den estimerede spredning på $\bar{x}_1. - \bar{x}_2.$ er

$$\text{StdError}(\bar{x}_1. - \bar{x}_2.) = \sqrt{s_1^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$$

og 95% konfidensintervallet for $\mu_1 - \mu_2$ kan skrives

$$\bar{x}_1. - \bar{x}_2. \pm t_{0.975}(f_1) \text{StdError}(\bar{x}_1. - \bar{x}_2.)$$

95% konfidensintervallet for σ^2 er

$$\left(\frac{f_1 s_1^2}{\chi_{0.975}^2(f_1)}, \frac{f_1 s_1^2}{\chi_{0.25}^2(f_1)} \right)$$

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_1 (fortsat)

Eksempel 1.5

Den observerede værdi af teststørrelsen $t(\mathbf{x})$ er

$$t(\mathbf{x}) = \frac{2.8072 - 2.7154}{\sqrt{1.064638 \left(\frac{1}{16} + \frac{1}{15}\right)}} = \frac{0.0918}{0.3708} = 0.2475.$$

så hypotesen $H_{0\mu} : \mu_1 = \mu_2$ forkastes ikke, da

$$p_{obs}(\mathbf{x}) = 2 [1 - F_{t(f_1)}(|t(\mathbf{x})|)] = 2 [1 - F_{t(29)}(0.2475)] = 0.81,$$

Da $t_{0.975}(29) = 2.0452$, bliver 95% konfidensintervallet for $\mu_1 - \mu_2$

$$0.0918 \pm 0.3708 \cdot 2.0452 = [-0.6666, 0.8501].$$

Faglig konklusion

I forsøget er det ikke påvist, at kontakttiderne har nogen indflydelse på reaktionstiderne

Eksempel 1.5 - transformation af parametre

Parameterestimer og tilhørende konfidensintervaller i M_0 findes i Tabel 2.2.

Kontaktid	Estimer	
	Middelværdi μ	Varsians σ^2
30 sekunder	2.8072	1.102779
60 sekunder	2.7154	1.023778
95% Konfidensintervaller		
30 sekunder	[2.2476, 3.3668]	[0.6018, 2.6416]
60 sekunder	[2.1551, 3.2757]	[0.5489, 2.5469]

Konfidensintervallerne for μ_1 og μ_2 kan transformeres til konfidensintervaller for e^{μ_1} og e^{μ_2} og disse findes til [9.47, 28.98] og [8.63, 26.46].

Bemærk at e^{μ_i} $i = 1, 2$ er medianen (ikke middelværdien) i fordelingerne af de ikke-transformerede reaktionstider.

Eksempel 1.5 - transformation af parametre

I M_1 fandt vi 95% konfidensintervallet for $\mu_1 - \mu_2$ til $[-0.6666, 0.8501]$.

Dette kan transformeres til et konfidensinterval for $e^{\mu_1 - \mu_2} = e^{\mu_1} / e^{\mu_2}$. Det transformerede konfidensinterval findes til

$$[\exp(-0.6666), \exp(0.8502)] = [0.51, 2.34].$$

Dette er som udgangspunkt et forhold mellem medianerne, men da $U \sim N(\mu, \sigma^2) \Rightarrow \mathbb{E}[e^U] = e^{\mu + \sigma^2/2}$ kan det også fortolkes som et forhold mellem middelværdierne af de ikke-transformerede reaktionstider i M_1 .

Ens varians og ens middelværdi

Modellen M_2

Forkastes hypotesen $H_{0\mu} : \mu_1 = \mu_2$ ikke ved test i modellen M_1 , reduceres M_1 til

$$M_2 : X_{ij} \sim N(\mu, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.}$$

dvs. alle observationerne har samme fordeling og kan betragtes som én observationsrække.

Estimerer i M_2

$$\mu \leftarrow \bar{X}_{..} \quad \text{hvor} \quad \bar{X}_{..} \sim N\left(\mu, \frac{\sigma^2}{n_{..}}\right)$$

$$\sigma^2 \leftarrow s^2(\mathbf{X}) \quad \text{hvor} \quad s^2(\mathbf{X}) \sim \sigma^2 \chi^2(n_{..} - 1) / (n_{..} - 1)$$

hvor $n_{..} = n_1 + n_2$.

Beregninger i R

Alle de gennemgående udtryk kan beregnes i **R** ved hjælp af funktioner som **mean**, **sd** og **var**.

T-test for $H_0 : \mu = \mu_0$ i én observationsrække (med ukendt varians) og $H_{0\mu} : \mu_1 = \mu_2$ i to observationsrækker kan foretages med **t.test**. Ved at specificere **var.equal = TRUE** eller **var.equal = FALSE** kan man angive, om man ønsker at testet skal udføres under antagelse varianshomogenitet eller ikke. *F*-testet for varianshomogenitet $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$ i to

observationsrækker kan udføres ved hjælp af kommandoen **var.test**.

Matematisk Statistik

To normalfordelte observationsrækker

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

To normalfordelte observationsrækker
Forskellig varians

Eksempel 3.1

Fagligt problem og data

Ældre kvinder er i risiko for knogleskørhed og man ønsker at undersøge effekten af en behandling for dette. Ved hjælp af røntgen-absorptionsmetri foretages derfor calciummålinger i albueknoglen på 31 ældre kvinder. $n_1 = 16$ tilhører en behandlingsgruppe og $n_2 = 15$ tilhører en kontrolgruppe.

Model og modelkontrol


Lad x_{ij} være den j te observation i den i te gruppe. Vi betragter da modellen

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed. }$$

Idet $i = 1$ svarer til behandlingsgruppen og $i = 2$ til kontrolgruppen, er $n_1 = 16$ og $n_2 = 15$.

Den faglige problemstilling kan undersøges ved at sammenligne middelværdierne i de to grupper.

Eksempel 3.1 - Modelkontrol



Data fremstår pænt normalfordelt, bortset muligvis fra en enkelt outlier i kontrolgruppen.

Er data normalfordelt: qqplots

To qqplots i samme figur:

```
datrange <- range(kontrolgruppe,behandlingsgruppe)
qqnorm(kontrolgruppe,ylim=datrange,pch=15)
qqnormobj <- qqnorm(behandlingsgruppe,plot=FALSE)
points(qqnormobj,col=2,pch=16)
legend("topleft",legend=c("kontrolgruppe",
                           "behandlingsgruppe"),col=c(1,2),pch=c(15,16))
```

Eksempel 3.1

Estimation i

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.}$$

$$\mu_1 \leftarrow \bar{x}_{1.} = -3.55625 \quad \text{hvor} \quad \bar{X}_{1.} \sim N(\mu_1, \sigma_1^2/n_1),$$

$$\mu_2 \leftarrow \bar{x}_{2.} = -7.59333 \quad \text{hvor} \quad \bar{X}_{2.} \sim N(\mu_2, \sigma_2^2/n_2),$$

$$\sigma_1^2 \leftarrow s_{(1)}^2 = 7.367958 \quad \text{hvor} \quad s_{(1)}^2(\mathbf{X}) \sim \sigma_1^2 \chi^2(f_{(1)})/f_{(1)},$$

$$\sigma_2^2 \leftarrow s_{(2)}^2 = 18.38495 \quad \text{hvor} \quad s_{(2)}^2(\mathbf{X}) \sim \sigma_2^2 \chi^2(f_{(2)})/f_{(2)}.$$

De 4 stokastiske variable er uafhængige.

Eksempel 3.1: test af $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$

Ved hjælp af estimerne findes teststørrelsen

$$\mathcal{F} = \frac{s_{(1)}^2}{s_{(2)}^2} = \frac{7.367958}{18.38495} = 0.40076$$

som under hypotesen er udfald af en $F(15, 14)$ -fordeling.

p -værdien findes til

$$p_{obs}(\mathbf{x}) = 2F_{F(15,14)}(0.40076) = 0.08974.$$

$H_{0\sigma^2}$ kan ikke afvises, men p -værdien er lav og vi alligevel gerne undersøge $H_{0\mu} : \mu_1 = \mu_2$ uden at gøre nogen antagelser om variansen.

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_0

$$I \quad M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i, \text{ testes} \\ H_{0\mu} : \mu_1 = \mu_2$$

ved hjælp testoren

$$t(\mathbf{X}) = \frac{\bar{X}_{1\cdot} - \bar{X}_{2\cdot}}{\sqrt{s_{(1)}^2/n_1 + s_{(2)}^2/n_2}} \approx t(\bar{f}),$$

hvor

$$\bar{f} = \frac{\left(\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2}\right)^2}{\frac{\left(\frac{s_{(1)}^2}{n_1}\right)^2}{f_{(1)}} + \frac{\left(\frac{s_{(2)}^2}{n_2}\right)^2}{f_{(2)}}}.$$

Testsandsynligheden er

$$p_{obs} = 2(1 - F_{t(\bar{f})}(|t(\mathbf{X})|)).$$

Konfidensinterval for $\mu_1 - \mu_2$ i M_0

Da den estimerede spredning på $\bar{x}_1. - \bar{x}_2.$ er

$$\text{StdError}(\bar{x}_1. - \bar{x}_2.) = \sqrt{s_{(1)}^2/n_1 + s_{(2)}^2/n_2}$$

bliver 95 % konfidensintervallet for $\mu_1 - \mu_2$

$$\bar{x}_1. - \bar{x}_2. \pm t_{0.975}(\bar{f}) \text{StdError}(\bar{x}_1. - \bar{x}_2.).$$

Eksempel 3.1: Test af $H_{0\mu} : \mu_1 = \mu_2$

Den observerede værdi af teststørrelsen $t(\mathbf{x})$ er

$$t(\mathbf{x}) = \frac{-3.55625 - (-7.593333)}{\sqrt{0.460497 + 1.22566}} = \frac{4.03708}{1.29852} = 3.10898.$$

$\bar{f}$ beregnes til 23.41172 så

$$p_{obs} = 2(1 - F_{t(23.41172)}(|3.10898|)) = 0.0048743,$$

og hypotesen $H_{0\mu} : \mu_1 = \mu_2$ forkastes.

Da $t_{0.975}(23.41172) = 2.066646$, bliver 95% konfidensintervallet for $\mu_1 - \mu_2$

$$4.03708 \pm 2.066646 \cdot 1.29852 = [1.353496, 6.720670].$$

Faglig konklusion

Det kan ikke antages, at middelværdien af calciumindholdet er ens i de to grupper. Da estimatet for behandlingsgruppen er højere end for kontrolgruppen, tyder data på, at patienterne i førstnævnte har haft gavn af behandlingen.

Matematisk Statistik

k normalfordelte observationsrækker

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

k normalfordelte observationsrækker

Modellen for k normalfordelte observationsrækker med hver sin middelværdi og hver sin varians er, at data

$$\begin{array}{ccccccc} x_{11} & \dots & x_{1j} & \dots & x_{1n_1} & & \\ & & \vdots & & \vdots & & \\ x_{i1} & \dots & x_{ij} & \dots & x_{in_i} & & \\ & & \vdots & & \vdots & & \\ x_{k1} & \dots & x_{kj} & \dots & x_{kn_k} & & \end{array}$$

er realisationer af uafhængige, normalfordelte stokastiske variable, dvs.

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

Modeller og hypoteser

I $M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i$,
betragtes *hypotesen om varianshomogenitet*

$$H_{0\sigma^2} : \sigma_1^2 = \dots = \sigma_k^2.$$

som reducerer M_0 til modellen for k normalfordelte observationsrækker med hver sin middelværdi og samme varians

$$M_1 : X_{ij} \sim (\mu_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

I M_1 betragtes *hypotesen om ens middelværdier*

$$H_{0\mu} : \mu_1 = \dots = \mu_k$$

som reducerer M_2 til modellen for én normalfordelt observationsrække

$$M_2 : X_{ij} \sim (\mu, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

k observationsrækker: notation

Notation vedrørende modellen

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

I den i te række er:

- antallet af observationer: n_i
- den empiriske middelværdi eller gennemsnittet:

$$\bar{x}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} x_{ij}$$

- den empiriske varians

$$s_{(i)}^2 = \frac{1}{n_i - 1} \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i\cdot})^2$$

- antallet af frihedsgrader: $f_{(i)} = n_i - 1$.

Eksempel 3.2

Fagligt problem

Hvordan påvirker stress væksten af sojabønner?

52 stiklinger blev plantet i pletter, én i hver plette. De 52 stiklinger blev tilfældigt inddelt i fire grupper med 13 i hver. Stiklingerne i to af grupperne blev stresset ved at blive rystet i tyve minutter dagligt, mens stiklingerne i de to andre grupper ikke blev rystet. Desuden voksede to af grupperne i svagt lys, og de andre to grupper i moderat lys, således at de fire grupper fik hver sin behandling:

Gruppe 1 : svagt lys, ingen stress

Gruppe 2 : svagt lys, stress

Gruppe 3 : moderat lys, ingen stress

Gruppe 4 : moderat lys, stress

Eksempel 3.2 - data

Samlet areal i cm ²			
Gruppe			
1	2	3	4
200	163	268	201
215	182	271	216
225	188	273	241
229	195	282	257
230	202	285	259
232	205	299	267
241	212	309	269
253	214	310	282
256	215	314	283
264	230	320	291
268	235	337	291
288	255	340	312
288	272	345	326
Middelværdier			
245.31	212.92	304.08	268.85

Tabel 1: Gruppe 1: svagt lys, ingen stress; Gruppe 2: svagt lys, stress; Gruppe 3: moderat lys, ingen stress; Gruppe 4: moderat lys, stress.

Eksempel 3.2

Model og modelkontrol


Lad x_{ij} være bladarealet efter 16 dages vækst for den j te plante i den i te gruppe. Vi betragter da modellen

$$M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

med $k = 4$ og $n_1 = n_2 = n_3 = n_4 = 13$.

Fraktildiagrammerne i Figur 3.2 strider ikke mod denne model. De rette linjer, som punkterne fordeler sig om, har ikke meget forskellige hældninger, så fraktildiagrammerne tyder på, at varianserne er ens. Til gengæld er fraktildiagrammerne forskudt i forhold til hinanden og det tyder på forskellig middelværdi i de fire observationsrækker.

Eksempel 3.2 - fraktildiagram



Figur 1: Fraktildiagrammer for data i Tabel 3.4.

Estimation i M_0

Estimation i

$$M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

$$\begin{array}{ll} \mu_i \leftarrow \bar{X}_{i.} & \text{hvor} \quad \bar{X}_{i.} \sim N(\mu_i, \sigma_i^2/n_i), \\ \sigma_i^2 \leftarrow s_{(i)}^2 & \text{hvor} \quad s_{(i)}^2(\mathbf{X}) \sim \sigma_i^2 \chi^2(f_{(i)})/f_{(i)}. \end{array}$$

De $2k$ estimatorer er uafhængige.

Estimaterne for varianserne findes til

$$s_{(1)}^2 = 730.231 \quad s_{(2)}^2 = 884.910 \quad s_{(3)}^2 = 724.910 \quad s_{(4)}^2 = 1241.308$$

Estimation i M_1

Estimation i

$$M_1 : X_{ij} \sim (\mu_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

middelværdier

$$\mu_i \leftarrow \bar{X}_i.$$

fælles varians

Med $f_1 = f_{(1)} + \dots + f_{(k)}$ har vi

$$\begin{aligned} s_1^2 &= \frac{\text{SSD}_1}{f_1} = \frac{\text{SSD}_{(1)} + \dots + \text{SSD}_{(k)}}{f_{(1)} + \dots + f_{(k)}} \\ &= \frac{f_{(1)} s_{(1)}^2 + \dots + f_{(k)} s_{(k)}^2}{f_{(1)} + \dots + f_{(k)}}. \end{aligned}$$

Den tilsvarende estimator er $\sigma^2 \chi^2(f_1)/f_1$ -fordelt.

De i alt $k + 1$ estimatorer er uafhængige.

Test af fælles varians

Hypotesen om varianshomogenitet

$$H_{0\sigma^2} : \sigma_1^2 = \dots \sigma_k^2 = \sigma^2$$

testes med udgangspunktet i skønnene $s_{(1)}^2, \dots, s_{(k)}^2$ over varianserne $\sigma_1^2, \dots, \sigma_k^2$ i M_0 .

Hvis Q er likelihood ratio testet baseret på variansskønnenes fordeling

$$s_{(i)}^2 \sim \sigma_i^2 \chi^2(f_{(i)})/f_{(i)}, \quad i = 1, \dots, k,$$

gælder der at

$$-2 \ln Q(\mathbf{x}) = f_1 \ln s_1^2 - \sum_{i=1}^k f_{(i)} \ln s_{(i)}^2.$$

Detaljer til Bartlett's test

Udgangspunkt: k grupper, uden () om indekser.

Fra hver gruppe et variansskøn s_j^2 , $j = 1, \dots, k$, uafhængige

Model: s_j^2 er udfald af $S_j^2 \sim \sigma_j^2 \chi^2(f_j)/f_j$ eller $\frac{f_j S_j^2}{\sigma_j^2} \sim \chi^2(f_j)$

Hypotese: $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$

Test: tage udgangspunkt i likelihood ratio test

Tæthed for $\chi^2(f)$ fordeling (MSRR B.10/A.3.2)

$$f(x) = \frac{x^{f/2-1}}{2^{f/2}\Gamma(f/2)} e^{-x/2} \quad 0 \leq x < \infty$$

Detaljer til Bartlett's test

Likelihoodfunktion for j 'te led:

$$L_j(\sigma_j^2) = K(f_j, s_j^2) \frac{1}{(\sigma_j^2)^{f_j/2}} e^{-\frac{1}{2} f_j s_j^2 / \sigma_j^2}$$

Fra dette udledes: $\hat{\sigma}_j^2 = s_j^2$ og $L_j(\hat{\sigma}_j^2) = K(f_j, s_j^2) \frac{1}{(s_j^2)^{f_j/2}} e^{-\frac{1}{2} f_j}$

Den fulde likelihoodfunktion bliver derfor:

$$L(\sigma_1^2, \dots, \sigma_k^2) = L_1(\sigma_1^2) \cdots L_k(\sigma_k^2), \quad \text{og}$$

$$L(\hat{\sigma}_1^2, \dots, \hat{\sigma}_k^2) = L_1(s_1^2) \cdots L_k(s_k^2)$$

Detaljer til Bartlett's test

Når varianserne er ens har vi med $f = f_1 + \dots + f_k$

$$L(\sigma^2, \dots, \sigma^2) = \left(\prod_j K(f_j, s_j^2) \right) \frac{1}{(\sigma^2)^{f/2}} e^{-\frac{1}{2}f(\sum_j f_j s_j^2 / f) / \sigma^2}$$

som giver

$$\hat{\sigma}^2 = \frac{\sum_j f_j s_j^2}{f} = s^2$$

og

$$L(s^2, \dots, s^2) = \left(\prod_j K(f_j, s_j^2) \right) \frac{1}{(s^2)^{f/2}} e^{-\frac{1}{2}f}$$

Detaljer til Bartlett's test

Likelihood ratio teststørrelse bliver

$$Q = \frac{L(s^2, \dots, s^2)}{L(s_1^2, \dots, s_k^2)} = \frac{\frac{1}{(s^2)^{f/2}} e^{-\frac{1}{2}f}}{\prod_j \frac{1}{(s_j^2)^{f_j/2}} e^{-\frac{1}{2}f_j}}$$

og dermed

$$-2 \log(Q) = f \log(s^2) - \sum_j f_j \log(s_j^2).$$

Test af fælles varians

Approksimativt gælder der for store værdier af $f_{(i)}$, at

$$-2 \ln Q(\mathbf{x}) \sim \chi^2(k-1)$$

fordi man reducerer fra en model med k parametre $\sigma_1^2, \dots, \sigma_k^2$ til en model med 1 parameter σ^2 .

M.S. Bartlett viste i 1937, at approksimationen til χ^2 -fordelingen kunne forbedres, hvis man dividerer $-2 \ln Q$ med konstanten

$$C = 1 + \frac{1}{3(k-1)} \left[\left(\sum_{i=1}^k \frac{1}{f_{(i)}} \right) - \frac{1}{f_1} \right].$$

Teststørrelsen

$$Ba = \frac{-2 \ln Q(\mathbf{x})}{C}$$

kaldes *Bartletts test*. Approksimationen til $\chi^2(k-1)$ -fordelingen er tilfredsstillende, hvis $f_{(i)} \geq 2$ for $i = 1, \dots, k$, dvs. hvis $n_i \geq 3$, $i = 1, \dots, k$, altså der er mindst tre observationer i hver observationsrække.

Test af fælles varians

Da $-2 \log Q$ er et likelihood ratio test, er det små værdier af Q , der er kritiske for nulhypotesen, og dermed store værdier af $-2 \log Q$, der er kritiske for nulhypotesen.

Testsandsynligheden beregnes derfor som

$$p_{\text{obs}}(\mathbf{x}) = 1 - F_{\chi^2(k-1)}(Ba),$$

hvor $F_{\chi^2(k-1)}$ er fordelingsfunktionen for χ^2 -fordelingen med $k - 1$ frihedsgrader.

Test af fælles varians - Eksempel 3.2

Estimatet for den fælles varians i M_1 findes til

$$s_1^2 = \frac{730.231 + 884.910 + 724.910 + 1241.308}{4} = 895.340.$$

Vi finder derved

$$-2 \ln Q = 1.1999,$$

og

$$C = 1.03472,$$

og dermed

$$Ba = \frac{-2 \ln Q}{C} = \frac{1.1999}{1.03472} = 1.160$$

Vi kan da finde testsandsynligheden:

$$p_{obs}(\mathbf{x}) = 1 - F_{\chi^2(3)}(1.160) = 0.763,$$

så hypotesen om varianshomogenitet forkastes ikke.

Faglig konklusion

Data strider ikke mod antagelsen om ens varians i de fire grupper.

Test af fælles middelværdi

I $M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i$,
ønsker vi at teste *hypotesen om ens middelværdier*

$$H_{0\mu} : \mu_1 = \mu_2 = \dots = \mu_k .$$

Vi går frem således

- Angiver likelihood ratio testoren Q
- Viser Q er ækvivalent med en F-teststørrelse
- Fortolker F-teststørrelsen, angiver dens fordeling og testsandsynligheden.

Test af fælles middelværdi

Vi viser senere at M_1 og M_2 er eksempler på *lineære normale modeller* og og når man reducerer fra en lineær model til en undermodel bliver likelihood ratio testet

$$Q(\mathbf{x}) = \left[\frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} \right]^{\frac{n}{2}},$$

hvor $\hat{\sigma}_i^2$, $i = 1, 2$ er maksimum likelihood estimatorerne for varianserne i M_1 og M_2 .

I dette tilfælde gælder

$$\hat{\sigma}_2^2 = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{..})^2 \stackrel{\text{def}}{=} \frac{1}{n} \text{SSD}_T$$

og


$$\hat{\sigma}_1^2 = \frac{1}{n} (\text{SSD}_{(1)} + \text{SSD}_{(2)} + \cdots + \text{SSD}_{(k)}).$$

Test af fælles middelværdi

Der gælder at

$$SSD_T = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{..})^2 = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.})^2 + \sum_{i=1}^k n_i (\bar{x}_{i.} - \bar{x}_{..})^2 = \underbrace{\sum_{i=1}^k SSD_{(i)}}_{SSD_E} + \underbrace{\sum_{i=1}^k n_i (\bar{x}_{i.} - \bar{x}_{..})^2}_{SSD_H}.$$

Hvor SSD_E fortolkes som variationen indenfor grupper og SSD_H fortolkes som variationen mellem grupper.



Test af fælles middelværdi

Vi har følgende omskrivning af Q :

$$\begin{aligned} Q(\mathbf{x}) &= \left[\frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} \right]^{\frac{n}{2}} = \left[\frac{\frac{1}{n} \text{SSD}_E}{\frac{1}{n} \text{SSD}_T} \right]^{\frac{n}{2}} \\ &= \left[\frac{1}{1 + \frac{\text{SSD}_H}{\text{SSD}_E}} \right]^{\frac{n}{2}} = \left[\frac{1}{1 + \frac{k-1}{n-k} \mathcal{F}(\mathbf{x})} \right]^{\frac{n}{2}}, \end{aligned}$$

hvor $\mathcal{F}(\mathbf{x}) \stackrel{\text{def}}{=} \frac{\text{SSD}_H}{k-1} / \frac{\text{SSD}_E}{n-k} = \frac{\text{SSD}_H}{k-1} / s_1^2$ Bemærk at $\mathcal{F}(\mathbf{x})$ er en aftagende funktion af $Q(\mathbf{x})$ og omvendt, så små værdier af Q vil svare til store værdier af $\mathcal{F}$.

Test af fælles middelværdi

Vi viser senere at under $H_{0\mu}$ gælder det at

$$\mathcal{F}(\mathbf{X}) = \frac{\frac{SSD_H}{k-1}}{s_1^2} \sim F(k-1, n-k).$$

Små værdier af Q er kritiske for $H_{0\mu}$. Små værdier af Q svarer til store værdier af $\mathcal{F}$, *så store værdier af $\mathcal{F}$ er kritiske*, hvilket svarer til, at variationen mellem grupper er stor i forhold til variationen indenfor grupper.

Testsandsynligheden beregnes derfor som

$$p_{obs} = \mathbb{P}(\mathcal{F}(\mathbf{X}) \geq \mathcal{F}(\mathbf{x})) = 1 - F_{F(k-1, n-k)}(\mathcal{F}(\mathbf{x})),$$

hvor $F_{F(k-1, n-k)}$ er fordelingsfunktionen for F -fordelingen med $k-1$ frihedsgrader i tælleren og $f_1 = n-k$ frihedsgrader i nævneren.

Test af fælles middelværdi

Eksempel 3.2

I dette tilfælde finder vi

$$SSD_H = 100612.673 - 42976.308 = 57636.365$$

og dermed

$$\frac{SSD_H}{k-1} = \frac{57636.365}{3} = 19212.122.$$

kan teststørrelsen $\mathcal{F}$ beregnes som

$$\mathcal{F}(\mathbf{x}) = \frac{19212.122}{895.340} = 21.46.$$

$\mathcal{F}$ skal vurderes i en $F(3, 48)$ fordeling, og da kun store værdier er kritiske, er

$$p_{obs} = 1 - F_{F(3,48)}(21.46) = 0.000000006.$$

Test af fælles middelværdi

Eksempel 3.2 (fortsat)

Da $p_{obs} < 0.05$ forkastes $H_{0\mu}$, og dermed reduktionen til modellen M_2 . Modellen for data er stadig M_1 : fire normalfordelte observationsrækker med hver sin middelværdi og fælles varians.

Faglig konklusion

Forsøget viser, at lys og stress påvirker væksten af sojabønner.

Oplagt opfølgende spørgsmål: Hvordan på virker lys og stress *hver for sig* væksten af sojabønner?

Matematisk Statistik

Lineær regression

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Eksempel 4.1

Fagligt problem


Det er vigtigt at kunne foretage hurtig E. coli-detektion for opdage aktuel forurening af vand, men sædvanlige målemetoder er langsomme. Man er derfor interesseret i at udvikle alternative målemetoder, og en mulighed er at måle *GLUase-aktivitet*. Vi ønsker at vurdere muligheden for at angive indholdet af E. coli ud fra målinger af GLUase-aktivitet.

Data

Data består af 98 samhørende målinger af logaritmen til mængden af E.coli og logaritmen til GLUase aktiviteten fra vandprøver fra forskellige Østrigske floder indsamlet gennem 1998 og 1999.

Eksempel 4.1

logColi	logGlu
2.80	-1.05
2.86	-1.04
2.88	-1.10
$\vdots$	$\vdots$
3.38	-1.01
2.83	-1.05



Del af datasæt fra Eksempel 4.1 samt scatterplot.

Modellen for lineær regression svarende til talparrene (t_i, x_i) , $i = 1, \dots, n$, hvor t -erne er faste (ikke-stokastiske), er

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n.$$

og X_i -erne er uafhængige.

- Modellen omtales som en lineær regression af x på t
- Den rette linje $x(t) = \alpha + \beta t$ kaldes *regressionslinjen*
- Parameteren α kaldes afskæringen (intercept)
- Parameteren β kaldes hældningen (slope) eller regressionskoefficienten
- t kaldes den uafhængige eller den forklarende variabel
- x kaldes den afhængige variabel eller responsen

I Eksempel 4.1 er

- $n = 98$
- t_i den i te måling af logaritmen til mængden af E.coli
- x_i den i te måling af logaritmen til GLUase-aktiviteten

Ifølge modellen

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n.$$

er $\alpha + \beta t$ den forventende af logaritmen til GLUase-aktiviteten når logaritmen til mængden af E.coli er t .

- den forventede GLUase aktivitet afhænger lineært af logaritmen til mængden af E.coli
- variansen på målingerne af GLUase aktiviteten afhænger ikke af logaritmen til mængden af E.coli
- variationen omkring linjen er normalfordelt

I M_2 er likelihoodfunktionen

$$\begin{aligned} L(\alpha, \beta, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \alpha - \beta t_i)^2} \\ &= \frac{1}{\sqrt{2\pi\sigma^2}^n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \alpha - \beta t_i)^2}. \end{aligned}$$

så log likelihoodfunktionen er

$$l(\alpha, \beta, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n \{x_i - (\alpha + \beta t_i)\}^2.$$

Estimation

Det vises, at

$$\hat{\beta} = \frac{\text{SPD}_{\mathbf{xt}}}{\text{SSD}_{\mathbf{t}}}, \quad \hat{\alpha} = \bar{x} - \hat{\beta}\bar{t} \quad \text{og}$$
$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \{x_i - (\hat{\alpha} + \hat{\beta}t_i)\}^2$$


Som estimator for σ^2 benyttes

$$s_{02}^2(\mathbf{X}) = \frac{1}{n-2} \sum_{i=1}^n \{X_i - (\hat{\alpha} + \hat{\beta}t_i)\}^2 \sim \sigma^2 \chi^2(f_{02})/f_{02}$$

med $f_{02} = n - 2$, som har middelværdi σ^2 .

Bemærk, at antallet af frihedsgrader for variansskønnet s_{02}^2 er lig med antallet af observationer minus antallet af ukendte parametre i middelværdien.

Eksempel 4.1, estimation.



Figur 1: Scatterplot, med estimeret regressionslinje indtegnet, samt to parallelle linjer i afstanden $\pm 2s_{02}$.

For data i Eksempel 4.1 findes estimerterne i M_2 :

$$\alpha \leftarrow \hat{\alpha} = -3.887245 \quad \beta \leftarrow \hat{\beta} = 0.8493586 \quad \sigma^2 \leftarrow s_{02}^2 = 0.09575192$$

Estimatet for linjens værdi i t_i er den *prædikterede værdi* eller den *fittede værdi* for x_i

$$\hat{x}_i \stackrel{\text{def}}{=} \hat{\alpha} + \hat{\beta}t_i.$$

Residualerne er forskellen mellem observationerne og de fittede værdier:

$$r_i \stackrel{\text{def}}{=} x_i - (\hat{\alpha} + \hat{\beta}t_i).$$

Fordeling af estimatorer

I modellen

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

har vi følgende fordelinger af forskellige estimatorer:

$$\text{Skæring: } \hat{\alpha}(\mathbf{X}) \sim N\left(\alpha, \sigma^2 \left[\frac{1}{n} + \frac{\bar{t}^2}{\text{SSD}_t} \right] \right),$$

$$\text{Hældning: } \hat{\beta}(\mathbf{X}) \sim N\left(\beta, \frac{\sigma^2}{\text{SSD}_t}\right),$$

$$\text{Linjens værdi: } \hat{\alpha} + \hat{\beta}t \sim N\left(\alpha + \beta t, \sigma^2 \left(\frac{1}{n} + \frac{(t - \bar{t})^2}{\text{SSD}_t} \right) \right)$$


$$\text{Varianssskøn: } s_{02}^2(\mathbf{X}) \sim \sigma^2 \chi^2(n-2)/(n-2).$$

Desuden gælder der, at fordelingen for $(\hat{\alpha}, \hat{\beta})$ er uafhængig af fordelingen for s_{02}^2 , samt at $\hat{\beta}$ og $\bar{X}$ er uafhængige.


Varians på estimer

$$\hat{\beta} : \frac{\sigma^2}{SSD_t}$$



SSD_t stor



SSD_t lille



$$\hat{\alpha} : \sigma^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{SSD_t} \right)$$



t-værdier langt fra nul

Der er i fire centrale antagelser i den lineære regressionsmodel

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

- *Linearitet*: Middelværdien af responsen er en lineær funktion af den forklarende variabel t .
- *Varianshomogenitet*: Variansen af X_i er identisk for alle i og afhænger ikke af t_i , $i = 1, \dots, n$.
- *Normalfordeling*: X_i , $i = 1, \dots, n$ er normalfordelte.
- *Uafhængighed*: $X_1, \dots, X_n$ er uafhængige.

De første tre antagelser kan vurderes ved hjælp af kontroltegninger.

Ved hjælp af et scatterplot af punkterne (t_i, x_i) , $i = 1, \dots, n$ kan man vurdere antagelserne om linearitet og varianshomogenitet i modellen:


$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n.$$

Punkterne i plottet skal ligge

- omkring en ret linje (linearitet af middelværdien)
- i et bånd af nogenlunde konstant bredde (konstant varians)

Scatterplottet i Eksempel 4.1 strider ikke mod modellen M_2 .



Modelkontrol



Figur 2: Tre figurer baseret på samme datasæt: Til venstre et scatterplot, i midten et residualplot og til højre er residualerne plottet med de fittede værdier.

Varianshomogenitet kan yderligere kontrolleres ved hjælp af et *residualplot*, hvor residualerne afsættes mod den forklarende variabel, dvs. en figur med punkterne (t_i, r_i) eller ved at afsætte residualerne afsættes mod de fittede værdier.



Modelkontrol. Eksempel 1: ikke-linearitet



Data er simuleret fra en $N(t_i + 0.6t_i^2, 0.1^2)$ -fordeling.

Analyse lavet i model $X_i \sim N(\alpha + \beta t_i, \sigma^2)$

Modelkontrol. Eksempel 2: stigende varians



Data er simuleret fra en $N(3 + 5t_i, 0.4 + 0.9 \cdot t_i)$ -fordeling.

Analyse lavet i model $X_i \sim N(\alpha + \beta t_i, \sigma^2)$

Residualer - fordelingsresultater

Modelkontrol af antagelsen normalfordeling baseres på residualerne.

Hvis

$$R_i = X_i - \hat{\alpha}(\mathbf{X}) - \hat{\beta}(\mathbf{X})t_i$$

har vi

$$R_i = X_i - \hat{\alpha}(\mathbf{X}) - \hat{\beta}(\mathbf{X})t_i \sim N\left(0, \sigma^2\left(1 - \frac{1}{n} - \frac{(t_i - \bar{t})^2}{\text{SSD}_t}\right)\right).$$

Variansen på R_i kan skrives som $\sigma^2(1 - h_i)$ hvor

$$h_i = \frac{1}{n} + \frac{(t_i - \bar{t})^2}{\text{SSD}_t}.$$

Størrelsen h_i kaldes *leverage*.

Bemærk at variansen på R_i -erne ikke er konstant.

Residualer - fordelingsresultater

For at opnå ens varians betragtes de *skalerede* residualer

$$r_i^\dagger = \frac{r_i}{\sqrt{1 - h_i}}.$$


I M_2 gælder at $r_i^\dagger$ erne er udfald af en $N(0, \sigma^2)$ fordeling.

Afhængigheden af σ^2 kan fjernes ved at dividere med σ og vi betragter derfor de *studentiserede skalerede residualer* (eng.: *studentized residuals*)


$$r_i^{\dagger \text{ def}} = \frac{r_i}{\sqrt{s^2 (1 - h_i)}}.$$

Disse vil have en *approksimativ t*-fordeling, som i forbindelse med kontroltegninger vil opfatte som en approksimativ normalfordeling.

Modelkontrol, Eksempel 4.1



Residualplot



Fraktilplot for studentiserede residualer

Hypoteser, test og konfidensintervaller

Generelt resultat: Antag, at vi har et estimator $\hat{\xi}$ for parameteren ξ således, at

$$\hat{\xi} \sim N(\xi, k\sigma^2)$$

hvor k er en kendt konstant og σ^2 er ukendt, samt en estimator

$$\sigma^2 \leftarrow s^2 \sim \sigma^2 \chi^2(f)/f$$

således at $\hat{\xi}$ og s^2 er uafhængige.

Da testes hypotesen $\xi = \xi_0$, hvor ξ_0 er kendt, ved t -testørrelsen

$$t = \frac{\hat{\xi} - \xi_0}{\sqrt{ks^2}} = \frac{\hat{\xi} - \xi_0}{\text{StdError}(\hat{\xi})} \sim t(f),$$

hvor store værdier af $|t|$ er kritiske.

$(1 - \alpha)$ -konfidensintervallet for ξ har grænser:

$$[\hat{\xi} - \sqrt{s^2 k} t_{1-\alpha/2}(f), \hat{\xi} + \sqrt{s^2 k} t_{1-\alpha/2}(f)].$$

Konfidensintervaller

I M_2 er der følgende $(1 - \alpha)$ konfidensintervaller:

Afskæringen α :

$$\left[\hat{\alpha} - \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{SSD_t} \right)} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{SSD_t} \right)} t_{1-\alpha/2}(f_{02}) \right],$$

Hældningen β :

$$\left[\hat{\beta} - \sqrt{\frac{s_{02}^2}{SSD_t}} t_{1-\alpha/2}(f_{02}), \hat{\beta} + \sqrt{\frac{s_{02}^2}{SSD_t}} t_{1-\alpha/2}(f_{02}) \right].$$

Værdien af $\alpha + \beta t_0$ (linjens værdi i t_0):

$$\left[\hat{\alpha} + \hat{\beta} t_0 - s_{02} \sqrt{\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \hat{\beta} t_0 + s_{02} \sqrt{\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}) \right].$$

Variansen σ^2 (findes som i Afsnit 2.2.1)

$$\left[\frac{s_{02}^2}{\chi_{1-\alpha/2}^2(f_{02})/f_{02}}, \frac{s_{02}^2}{\chi_{\alpha/2}^2(f_{02})/f_{02}} \right].$$

Prædiktionsintervaller

Hvis t_0 er en værdi af den forklarende variabel ønsker vi at udtale os om værdien af en tilhørende “ny” observation X_0 fra M_2 .

Matematisk: Antag $X_0 \sim N(\alpha + \beta t_0, \sigma^2)$ er uafhængig af $X_1, \dots, X_n$.

Vi har da

$$X_0 - (\hat{\alpha} + \hat{\beta}t_0) \sim N\left(0, \sigma^2\left(1 + \frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}\right)\right)$$

og dermed

$$\frac{X_0 - (\hat{\alpha} + \hat{\beta}t_0)}{\sqrt{s_{02}^2 \left(1 + \frac{1}{n} + \frac{(t - \bar{t})^2}{SSD_t}\right)}} \sim t(f_{02})$$

således at uligheden

$$-t_{1-\alpha/2}(f_{02}) < \frac{X_0 - (\hat{\alpha} + \hat{\beta}t_0)}{\sqrt{s_{02}^2 \left(1 + \frac{1}{n} + \frac{(t - \bar{t})^2}{SSD_t}\right)}} < t_{1-\alpha/2}(f_{02})$$

holder med sandsynlighed $1 - \alpha$.

Vi finder dermed $1 - \alpha$ *prædiktionsintervallet*

$$\left[\hat{\alpha} + \hat{\beta}t_0 - s_{02} \sqrt{1 + \frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \hat{\beta}t_0 + s_{02} \sqrt{1 + \frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}) \right] .$$

Sammenlign med konfidensinterval for linjens værdi i t_0 :

$$\left[\hat{\alpha} + \hat{\beta}t_0 - s_{02} \sqrt{\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \hat{\beta}t_0 + s_{02} \sqrt{\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}) \right] .$$

Eksempel 4.1

For data i Eksempel 4.1 finder vi:


<i>logColi</i>	fittet værdi	95 % konfidensinterval	95 % prædiktionsinterval
4.9	0.2746	(0.2092,0.3401)	(-0.3431,0.8923)
5.7	0.9541	(0.8634,1.0448)	(0.3332,1.5750)
6.8	1.8884	(1.7455,2.0312)	(1.2578,2.5190)

Tabel 1: Beregnede 95 % konfidensintervaller og 95 % prædiktionsintervaller svarende til værdierne 4.9, 5.7 og 6.8 af *logColi*. Endvidere er de fittede værdier også angivet.


Bredden på konfidensintervallerne er henholdsvis:
0.1309,0.1814,0.2857.

Bredden på prædiktionsintervallerne er henholdsvis:
1.2354,1.2418,1.2612.

Eksempel 4.1



Fittede værdier for $\log \text{Coli}$ på 4.9, 5.7 og 6.8 sammen med 95 % konfidensintervaller



Fittede værdier for $\log \text{Coli}$ på 4.9, 5.7 og 6.8 sammen med 95 % prædiktionsintervaller .

Lineær regression med gentagelser - Eksempel 4.2

Fagligt problem Model for sigtning af sand

Hvis man placerer noget sand, hvor alle sandkornene cirka har den samme størrelse, på en sigte og roterer den, vil der i begyndelsen komme meget sand igennem sigten, men gradvist mindre og mindre. Denne observation kan formuleres således: den mængde sand, der passerer sigten per tidsenhed er proportional med den mængde sand, der er tilbage på sigten. Hvis $x(t)$ betegner vægten af den mængde sand, der til tid t er tilbage i sigten, kan modellen formuleres

$$\frac{dx(t)}{dt} = cx(t).$$

Denne differentialligning har løsningen

$$x(t) = x(0)e^{ct},$$

hvor c er en negativ konstant, da mængden af sand i sigten aftager som tiden går. $x(0)$ er vægten af sandet i sigten til tid 0.

Lineær regression med gentagelser - Eksempel 4.2

Tages logaritmen på begge sider af fås

$$\ln x(t) = \ln x(0) + ct.$$

Logaritmen til massen af det sand, som er tilbage på sigten, er altså en lineær funktion af tiden.

Data I Tabel 4.3 er gengivet resultatet af i alt 12 sigtninger af den samme portion sand. Vægten af denne er 60 g. I de fire af sigtningerne er sigten roteret 170 gange (maskinen kører med konstant hastighed og foretager 43 rotationer per minut), i fire andre er der foretaget 530 rotationer, og i de fire sidste er der foretaget 880 rotationer. Tallene i Tabel 4.3 angiver logaritmen til den masse (målt i gram), der er tilbage på sigten efter det nævnte antal rotationer.

Regression med gentagelser


Under specifikke omstændigheder kan man teste hypoteserne om konstant varians og hypotesen om lineær regression. Det kan man, hvis flere observationspar har den samme værdi af responsen, således at data kan opdeles i k observationsrækker:

<i>Responsvariabel :</i>	<i>Forklarende variabel</i>
$x_{11} \quad \dots \quad x_{1j} \quad \dots \quad x_{1n_1}$	$t_1 = t_{1j}, \quad j = 1, \dots, n_1$
$\vdots$	
$x_{i1} \quad \dots \quad x_{ij} \quad \dots \quad x_{in_i}$	$t_i = t_{ij}, \quad j = 1, \dots, n_i$
$\vdots$	
$x_{k1} \quad \dots \quad x_{kj} \quad \dots \quad x_{kn_k}$	$t_k = t_{kj}, \quad j = 1, \dots, n_k$

De n_i observationer i gruppe i har samme værdi af den uafhængige variabel, og den fælles værdi betegnes med t_i .

I Eksempel 4.2 er der tre observationsrækker hver med fire observationer, dvs $k = 3$ og $n_1 = n_2 = n_3 = 4$.

Lineær regression med gentagelser - Eksempel 4.2



Scatterplot af masse mod rotationer indikerer

- lineært forløb.
- varianshomogenitet
- observationerne (logaritmen til masse) er normalfordelt.

Man ville umiddelbart godt kunne acceptere regressionsmodellen M_2 . Men vi ønsker at tage så lidt som muligt for givet og kontrollere så meget som muligt.

Modeller og hypoteser

I modellen for k normalfordelte observationsrækker med hver sin middelværdi og hver sin varians

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i,$$

betragtes hypotesen om varianshomogenitet

$$H_{01} : \sigma_1^2 = \dots \sigma_k^2 = \sigma^2$$

som reducerer M_0 til modellen for k normalfordelte observationsrækker med hver sin middelværdi og samme varians

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i,$$

I M_1 betragtes hypotesen om lineær regression

$$H_{02} : \mu_i = \alpha + \beta t_i \quad i = 1, 2, \dots, k$$

som reducerer M_1 til modellen for lineær regression

$$M_2 : X_{ij} \sim N(\alpha + \beta t_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

Eksempel 4.2 - reduktion fra M_0 til M_1


Da der kun er fire observationer i hver observationsrække i M_0 , giver det ikke mening at lave fraktildiagrammer til modelkontrol.

Reduktionen fra M_0 til M_1 foretages ved hjælp af Bartlett's test.


Teststørrelsen beregnes til $Ba = 0.82107$, som skal testes i en χ^2 -fordeling med $k - 1 = 2$ frihedsgrader. p -værdien er

$$p_{obs} = 1 - F_{\chi^2(2)}(0.82107) = 0.6633.$$

Test af lineær regression: F -test



Gruppegennemsnit er markeret med • og forbundet en linie der knækker ved 530 rotationer.



Indtegnet regressionslinje og prædikterede værdier markeret med •.

I M_1 hver gruppe sin egen middelværdi, som er den prædikterede værdi svarende til t_i $i = 1, 2, 3$.

I M_2 er den prædikterede værdi bestemt af regressionslinjen.

Test af lineær regression: F -test

Hvis SSD_1 betegner variationen indenfor grupper og SSD_2 betegner variationen omkring regressionslinjen, dvs

$$SSD_1 = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2 \quad \text{og} \quad SSD_2 = \sum_{i=1}^k n_i (\bar{x}_i - (\hat{\alpha} + \hat{\beta} t_i))^2$$

betragtes teststørrelsen

$$\mathcal{F}(\mathbf{x}) = \frac{s_2^2}{s_1^2}$$

hvor $s_1 = \frac{SSD_1}{n-k}$ og $s_2^2 = \frac{SSD_2}{k-2}$.

Store værdier af F -teststørrelsen er kritiske, da variationen omkring regressionslinjen i så tilfælde er stor i forhold til variationen indenfor grupper.

Test af lineær regression: F -test

I dette tilfælde findes tælleren til 0.0052 og teststørrelsen bliver dermed

$$\mathcal{F}(\mathbf{x}) = \frac{0.0052}{0.002022} = 2.57 ,$$


som skal testes i $F(1, 9)$ fordeling. Vi finder testsandsynligheden

$$p_{obs}(\mathbf{x}) = 1 - F_{F(1,9)}(2.57) = 0.14 ,$$

og da denne er større en 0.05 accepterer vi hypotesen on lineær regression.

Regression som kalibreringskurve

Chart 1: A linear calibration function of an instrument's Absorbance (A) vs. Analyte's Concentration ($\mu\text{g/l}$)



Kalibrering

Prøver laves med kendt indhold af t , respons x måles

$$\text{Model: } X_i \sim N(\alpha + \beta t_i, \sigma^2) \rightarrow \hat{\alpha}, \hat{\beta}, s_{02}^2$$

Nye responsmålinger $y_1, \dots, y_m$ alle med samme ukendte værdi af t

ukendte værdi: parameter, kaldes θ

$$\bar{Y}. \sim N(\alpha + \beta\theta, \sigma^2/m)$$

skøn over θ : $\hat{\theta} = (\bar{y}. - \alpha)/\beta$, bruger $\hat{\theta} = (\bar{y}. - \hat{\alpha})/\hat{\beta}$

Konfidensinterval for θ :

$$\text{Benyt: } \bar{Y}. - (\hat{\alpha} + \hat{\beta}\theta) \sim N\left(0, \sigma^2 \left\{ \frac{1}{m} + \frac{1}{n} + \frac{(\theta - \bar{t}.)^2}{\text{SSD}_t} \right\}\right)$$

Kalibrering

Prøver laves med kendt indhold af t , respons x måles

Model: $X_i \sim N(\alpha + \beta t_i, \sigma^2) \rightarrow \hat{\alpha}, \hat{\beta}, s_{02}^2$

Nye responsmålinger $y_1, \dots, y_m$ alle med samme ukendte værdi af t

ukendte værdi: parameter, kaldes θ

$$\bar{Y}. \sim N(\alpha + \beta\theta, \sigma^2/m)$$

skøn over θ : $\hat{\theta} = (\bar{y}. - \alpha)/\beta$, bruger $\hat{\theta} = (\bar{y}. - \hat{\alpha})/\hat{\beta}$

Konfidensinterval for θ :

$$\text{Benyt: } \bar{Y}. - (\hat{\alpha} + \hat{\beta}\theta) \sim N\left(0, \sigma^2 \left\{ \frac{1}{m} + \frac{1}{n} + \frac{(\theta - \bar{t}.)^2}{\text{SSD}_t} \right\}\right)$$

Kalibrering

Dette giver:

$$t(\theta) = \frac{\bar{Y}_{\cdot} - (\hat{\alpha} + \hat{\beta}\theta)}{s_{02} \sqrt{\frac{1}{m} + \frac{1}{n} + \frac{(\theta - \bar{t}_{\cdot})^2}{SSD_t}}} \sim t(n-2)$$

Konfidensinterval: $\theta : -t_0 \leq t(\theta) \leq t_0$

$$t_0 = t_{0.975}(n-2)$$

Løse andengradslikning: benytte [inversReg](#):

giver nedre og øvre grænse i konfidensintervallet

Andengradsledning

$$(\bar{Y} - (\hat{\alpha} + \hat{\beta}\theta))^2 = t_0^2 s_{02}^2 \left(\frac{1}{m} + \frac{1}{n} + \frac{(\theta - \bar{t})^2}{SSD_t} \right)$$

eller

$$\hat{\beta}^2 (\theta - \hat{\theta})^2 = t_0^2 s_{02}^2 \left(\frac{1}{m} + \frac{1}{n} + \frac{(\theta - \hat{\theta} + \hat{\theta} - \bar{t})^2}{SSD_t} \right)$$

$$(\theta - \hat{\theta})^2: \hat{\beta}^2 - t_0^2 s_{02}^2 / SSD_t$$

$$(\theta - \hat{\theta}): -2t_0^2 s_{02}^2 \frac{\hat{\theta} - \bar{t}}{SSD_t} = -2t_0^2 s_{02}^2 \frac{\bar{y} - \bar{x}}{\hat{\beta} SSD_t}$$

Eksempel 4.1


Betragtes en enkelt måling af $\log Glu$ på 1.05 bliver intervallet

$$(5.085127, 6.552178).$$

Hvis vi i stedet antager, at der er foretaget fire målinger af $\log Glu$, som alle er 1.05, findes det tilsvarende interval for $\log Coli$ til

$$(5.439088, 6.198216).$$


Eksempel 4.1



Resultat af kalibrering for **én** måling af $\log \text{Glu}$ på 1.05

Resultat af kalibrering for **fire** målinger af $\log \text{Glu}$ på 1.05

Hypoteser og modeller



M_3 : Kendt hældning $\beta = \beta_0$

M_3^* : Kendt afskæring $\alpha = \alpha_0$

M_4 : Kendt afskæring og hældning $\alpha = \alpha_0 \quad \beta = \beta_0$

$$H_{03} : \beta = \beta_0$$

- $\hat{\beta}(\mathbf{X}) \sim N\left(\beta, \frac{\sigma^2}{\text{SSD}_t}\right)$
- $t(\mathbf{X}) = \frac{\hat{\beta} - \beta_0}{\sqrt{s_{02}^2 / \text{SSD}_t}} = \frac{\hat{\beta} - \beta_0}{\text{StdError}(\hat{\beta})} \sim t(n - 2)$
- $p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-2)}(-|t(\mathbf{x})|) = 2(1 - F_{t(n-2)}(|t(\mathbf{x})|))$
- $\text{StdError}(\hat{\beta}) = \sqrt{s_{02}^2 / \text{SSD}_t}$
- 95% konfidensintervallet for β har grænser
$$\hat{\beta} \pm t_{0.975}(n - 2) \text{StdError}(\hat{\beta})$$

$$H_{03}^* : \alpha = \alpha_0$$

- $\hat{\alpha}(\mathbf{X}) \sim N(\alpha, \sigma^2 \left(\frac{1}{n} + \frac{\bar{t}_t^2}{\text{SSD}_t} \right))$
- $t(\mathbf{X}) = \frac{\hat{\alpha} - \alpha_0}{\sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}_t^2}{\text{SSD}_t} \right)}} = \frac{\hat{\alpha} - \alpha_0}{\text{StdError}(\hat{\alpha})}$
- $p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-2)}(-|t(\mathbf{x})|) = 2(1 - F_{t(n-2)}(|t(\mathbf{x})|))$
- $\text{StdError}(\hat{\alpha}) = \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}_t^2}{\text{SSD}_t} \right)}$
- 95% konfidensintervallet for α har grænser

$$\hat{\alpha} \pm t_{0.975}(n-2) \text{StdError}(\hat{\alpha})$$

$$M_3 : X_i \sim N(\alpha + \beta_0 t_i, \sigma^2)$$

Estimator

$$\alpha \leftarrow \hat{\alpha}_{M_3} = \bar{X} - \beta_0 \bar{t} \quad \text{hvor} \quad \bar{X} - \beta_0 \bar{t} \sim N\left(\alpha, \frac{\sigma^2}{n}\right),$$

$$\sigma^2 \leftarrow s_{03}^2 = \frac{1}{n-1} \sum_{i=1}^n \{x_i - (\hat{\alpha}_{M_3} + \beta_0 t_i)\}^2 = \frac{1}{n-1} [\text{SSD}_{02} + (\hat{\beta} - \beta_0)^2 \text{SSD}_t]$$

Test af $H_{04} : \alpha = \alpha_0$

- $t(\mathbf{X}) = \frac{\hat{\alpha} - \alpha_0}{\sqrt{s_{03}^2/n}} \sim t(n-1)$
- $p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-1)}(-|t(\mathbf{x})|) = 2(1 - F_{t(n-1)}(|t(\mathbf{x})|))$
- 95% konfidensintervallet for α har grænser

$$\hat{\alpha}_{M_3} \pm t_{0.975}(n-1) \sqrt{s_{03}^2/n}$$

$$M_3^* : X_i \sim N(\alpha_0 + \beta t_i, \sigma^2)$$

Estimator

$$\beta \leftarrow \hat{\beta}_{M_3^*} = \frac{\sum_{i=1}^n t_i (X_i - \alpha_0)}{\sum_{i=1}^n t_i^2} \quad \text{hvor} \quad \frac{\sum_{i=1}^n t_i (X_i - \alpha_0)}{\sum_{i=1}^n t_i^2} \sim N\left(\beta, \frac{\sigma^2}{\text{USS}_t}\right),$$

$$\sigma^2 \leftarrow s_{03}^{*2} = \frac{1}{n-1} \sum_{i=1}^n \left\{ X_i - \left(\alpha_0 + \hat{\beta}_{M_3^*} t_i \right) \right\}^2 = \frac{1}{n-1} \left[\text{USS}_x + n\alpha_0^2 - 2\alpha_0 \bar{x} - \hat{\beta}_{M_3^*}^2 \text{USS}_t \right].$$

Test af $H_{04}^* : \beta = \beta_0$

- $t(\mathbf{x}) = \frac{\hat{\beta}_{M_3^*} - \beta_0}{\sqrt{s_{03}^{*2} / \text{USS}_t}} \quad \text{hvor} \quad t(\mathbf{X}) \sim t(n-1).$
- $p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-1)}(-|t(\mathbf{x})|) = 2(1 - F_{t(n-1)}(|t(\mathbf{x})|))$
- 95% konfidensintervallet for β har grænser

$$\hat{\beta}_{M_3^*} \pm t_{0.975}(n-1) \sqrt{s_{03}^{*2} / \text{USS}_t}$$

$$M_4^* : X_i \sim N(\alpha_0 + \beta_0 t_i, \sigma^2)$$

Til slut har vi estimatet for parameteren i M_4

$$\sigma^2 \leftarrow s_{04}^2 = \frac{1}{n} \sum_{i=1}^n \{x_i - (\alpha_0 + \beta_0 t_i)\}^2$$

hvor den tilsvarende estimator har en $\chi^2(n)/n$ fordeling.

Eksempel 4.2

I Eksempel 4.2 havde vi modellen

$$\ln x(t) = \ln x(0) + ct,$$

hvor $x(t)$ er tilbageværende masse til tid t . I M_2 er $\alpha = \ln x(0)$ en fri parameter, der estimeres ud fra data, men hvis beskrivelsen af eksperimentet er korrekt skal der gælde at $\alpha = \ln 60$ og vi opstiller derfor hypotesen

$$H_{03}^* : \alpha = \alpha_0 = \ln 60 = 4.0943.$$

t -teststørrelsen findes til

$$t(\mathbf{x}) = \frac{4.0581 - 4.0943}{\sqrt{0.002342 \left(\frac{1}{12} + \frac{(6320/12)^2}{1008266.67} \right)}} = -1.249.$$

Testsandsynligheden findes til

$$p_{\text{obs}}(\mathbf{x}) = 2 F_{t(10)}(-|-1.249|) = 0.24.$$

Eksempel 4.2

Slutmodellen bliver derfor

$$M_3^* : X_{ij} \sim N(\alpha_0 + \beta t_i, \sigma^2),$$

hvor estimatet for β beregnes til

$$\beta_{M_3^*} = \frac{21984.8 - 4.0943 \cdot 6320}{4336800} = -0.00089725.$$

Tilsvarende findes estimatet i M_2 til -0.000844 , så de to estimater er stort set ens. Konfidensintervallet i M_3^* er dog cirka halvt så bredt som konfidensintervallet i M_2 .

Faglig konklusion: Det er rimeligt at beskrive den mængde sand, der passerer sigten per tidsenhed som værende proportional med den mængde sand, der til tid t er tilbage i sigten.

Matematisk Statistik

Ekstra slides

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

lm og summary

```
lmfit <- lm(logGlu ~ logColi)
summary(lmfit)
```

eller

```
lmfit <- lm(logGlu ~ 1 + logColi)
summary(lmfit)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.8872	0.1334	-29.14	<2e-16 ***
logColi	0.8494	0.0286	29.69	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3094 on 96 degrees of freedom

Multiple R-squared: 0.9018, Adjusted R-squared: 0.9008

F-statistic: 881.7 on 1 and 96 DF, p-value: < 2.2e-16

Sammenlign:

$$\alpha \leftarrow \hat{\alpha} = -3.887245 \quad \beta \leftarrow \hat{\beta} = 0.8493586 \quad \sigma^2 \leftarrow s_{02}^2 = 0.09575192$$

lm og summary

Hvis output fra `summary` gemmes, kan det bruges i sammenhænge.

```
sumfit <- summary(lmfit)
sumfit$coefficients
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.8872452	0.13339304	-29.14129	1.802966e-49
logColi	0.8493586	0.02860352	29.69420	3.546582e-50

Koefficienterne kan også findes ved at bruge `coef` på `lmfit`

```
coef(lmfit)
```

(Intercept)	logColi
-3.8872452	0.8493586

Konfidensintervaller for linjens værdi og prædiktionsintervaller

```
nyData = data.frame(logColi = c(4.9,5.7,6.8))  
predict(lmfit,nyData,interval = "confidence")  
predict(lmfit,nyData,interval = "prediction")
```

Output fra ovenstående kode bliver

```
> predict(lmfit,nyData,interval = "confidence")  
      fit      lwr      upr  
1 0.2746120 0.2091721 0.3400519  
2 0.9540989 0.8633519 1.0448458  
3 1.8883933 1.7455389 2.0312478  
> predict(lmfit,nyData,interval = "prediction")  
      fit      lwr      upr  
1 0.2746120 -0.3430939 0.8923178  
2 0.9540989  0.3332018 1.5749959  
3 1.8883933  1.2577702 2.5190165
```

lm og summary

```
rotationer <- c(170,170,170,170,530,530,530,530,880,880,880,880)
masse <- c(3.89,3.95,3.85,3.91,...,3.30,3.26,3.30,3.34)
lmfit_m2 <- lm(masse ~ 1 + rotationer)
summary(lmfit_m2)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.058e+00	2.897e-02	140.08	< 2e-16 ***
rotationer	-8.445e-04	4.819e-05	-17.52	7.78e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04839 on 10 degrees of freedom
Multiple R-squared: 0.9685, Adjusted R-squared: 0.9653
F-statistic: 307.1 on 1 and 10 DF, p-value: 7.78e-09

Estimator: $\hat{\alpha} = 4.05810$ $\hat{\beta} = -0.00084$

Prædikterede værdier: $4.05810 - 0.00084 \cdot 170 = 3.915, 3.6129$ og 3.3189

Invers regression med 1 observation af logGlu på 1.05.

```
lmfit=lm(logGlu~logColi)

invRegLog=inversReg(lmfit,1.05)
invRegLog$Konfidensinterval
exp(invRegLog$Konfidensinterval)
```

```
5.085127 6.552178
161.6004 700.7684
```

Invers regression med 4 observationer af logGlu på 1.05.

```
invRegLog=inversReg(lmfit,rep(1.05,4))
invRegLog$Konfidensinterval
exp(invRegLog$Konfidensinterval)
```

```
5.439088 6.198216
230.2321 491.8709
```

Hypotesetest med **summary** - lineær regression

I modellen M_2 for simpel lineær regression ønsker vi til slut at undersøge

$$H_{03}^* : \alpha = \alpha_0 = \ln 60 = 4.0943.$$

Vi betragter de transformerede variable $\tilde{X}_i = X_i - \ln 60$. I M_2 vil der gælde at

$$\tilde{X}_i \sim N(\tilde{\alpha} + \beta t_i, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed}$$

hvor $\tilde{\alpha} = 0$, således at hypotesen kan formuleres som

$$H_{03}^* : \tilde{\alpha} = 0.$$

Hypotesetest med **summary** - lineær regression

```
masse_minus_ln60 <- masse - log(60)
lmfit_m2 <- lm(masse_minus_ln60 ~ 1 + rotationer)
summary(lmfit_m2)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.625e-02	2.897e-02	-1.251	0.239
rotationer	-8.445e-04	4.819e-05	-17.524	7.78e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04839 on 10 degrees of freedom
Multiple R-squared: 0.9685, Adjusted R-squared: 0.9653
F-statistic: 307.1 on 1 and 10 DF, p-value: 7.78e-09

Lineær regression med kendt afskæring

Når vi skal estimere i M_3^* skal skrive 0 i modelformlen, for at specificere at afskæringen er $\alpha_0 = 0$.

```
lmfit_m3star <- lm(masse_minus_ln60 ~ 0 + rotationer)
summary(lmfit_m3star)
```

Parametertabellen bliver

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
rotationer -8.973e-04  2.383e-05  -37.66 5.59e-13 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04962 on 11 degrees of freedom
Multiple R-squared:  0.9923,    Adjusted R-squared:  0.9916
F-statistic: 1418 on 1 and 11 DF,  p-value: 5.588e-13
```

Lineær regression med kendt afskæring

Konfidensintervaller: findes med **confint**

```
confint(lmfit_m2)
confint(lmfit_m3star)
```

```
> confint(lmfit_m2)
              2.5 %          97.5 %
(Intercept) -0.100799208  0.0283015671
rotationer  -0.000951861 -0.0007371102
> confint(lmfit_m3star)
              2.5 %          97.5 %
rotationer -0.0009497517 -0.00084487
```

Bredder af konfidensintervallerne:

```
confint(lmfit_m2)[2,2]-confint(lmfit_m2)[2,1]
confint(lmfit_m3star)[2]-confint(lmfit_m3star)[1]
```

```
> confint(lmfit_m2)[2,2]-confint(lmfit_m2)[2,1]
[1] 0.0002147508
> confint(lmfit_m3star)[2]-confint(lmfit_m3star)[1]
[1] 0.0001048818
```

Matematisk Statistik

Lineære Normale Modeller

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Den lineære normale model, Afsnit 5.1

Lad $x_1, \dots, x_n$ være realisationer af uafhængige normalfordelte stokastiske variable $X_1, \dots, X_n$, hvor

$$X_i \sim N(\mu_i, \sigma^2), \quad i = 1, \dots, n.$$

Bemærk, at alle observationerne forudsættes at have **samme varians**.

Opfattes observationerne og middelværdierne som søjlevektorer i $\mathbb{R}^n$,

$$\begin{aligned}\mathbf{x} &= (x_1, \dots, x_n)^* \\ \boldsymbol{\mu} &= (\mu_1, \dots, \mu_n)^*,\end{aligned}$$

har vi en *lineær normal model* M specificeret ved underrummet L af $\mathbb{R}^n$, hvis

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^* \in L.$$

Vi sætter $\dim L = d$ og skriver kort

$$M : \boldsymbol{\mu} \in L.$$

Vi vil omtale $n - d$ som *fejlladets frihedsgrader*.

Den lineære normale model, Afsnit 5.1

Lad $x_1, \dots, x_n$ være realisationer af uafhængige normalfordelte stokastiske variable $X_1, \dots, X_n$, hvor

$$X_i \sim N(\mu_i, \sigma^2), \quad i = 1, \dots, n.$$

Bemærk, at alle observationerne forudsættes at have **samme varians**.

Opfattes observationerne og middelværdierne som søjlevektorer i $\mathbb{R}^n$,

$$\begin{aligned}\mathbf{x} &= (x_1, \dots, x_n)^* \\ \boldsymbol{\mu} &= (\mu_1, \dots, \mu_n)^*,\end{aligned}$$

har vi en *lineær normal model* M specificeret ved underrummet L af $\mathbb{R}^n$, hvis

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^* \in L.$$

Vi sætter $\dim L = d$ og skriver kort

$$M : \boldsymbol{\mu} \in L.$$

Vi vil omtale $n - d$ som *fejlladets frihedsgrader*.

Den lineære normale model, Afsnit 5.1

Lad $x_1, \dots, x_n$ være realisationer af uafhængige normalfordelte stokastiske variable $X_1, \dots, X_n$, hvor

$$X_i \sim N(\mu_i, \sigma^2), \quad i = 1, \dots, n.$$

Bemærk, at alle observationerne forudsættes at have **samme varians**.

Opfattes observationerne og middelværdierne som søjlevektorer i $\mathbb{R}^n$,

$$\begin{aligned}\mathbf{x} &= (x_1, \dots, x_n)^* \\ \boldsymbol{\mu} &= (\mu_1, \dots, \mu_n)^*,\end{aligned}$$

har vi en *lineær normal model* M specificeret ved underrummet L af $\mathbb{R}^n$, hvis

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^* \in L.$$

Vi sætter $\dim L = d$ og skriver kort

$$M : \boldsymbol{\mu} \in L.$$

Vi vil omtale $n - d$ som *fejlladets frihedsgrader*.

Eksempler, én observationsrække.

Her er $\mu_i = \mu$ for alle i , så

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix} = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \mu \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Med andre ord gælder der at $\boldsymbol{\mu} \in L$ hvor

$$L = \text{span}\left(\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}\right).$$

Vi definerer $\mathbf{1} \stackrel{\text{def}}{=} (1, \dots, 1)^*$ således at $L = \text{span}(\mathbf{1})$. Bemærk at dimensionen af L er $d = 1$.

Eksempler, én observationsrække.

Her er $\mu_i = \mu$ for alle i , så

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix} = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \mu \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Med andre ord gælder der at $\boldsymbol{\mu} \in L$ hvor

$$L = \text{span}\left(\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}\right).$$

Vi definerer $\mathbf{1} \stackrel{\text{def}}{=} (1, \dots, 1)^*$ således at $L = \text{span}(\mathbf{1})$. Bemærk at dimensionen af L er $d = 1$.

Eksempler, én observationsrække.

Her er $\mu_i = \mu$ for alle i , så

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix} = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \mu \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Med andre ord gælder der at $\boldsymbol{\mu} \in L$ hvor

$$L = \text{span}\left(\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}\right).$$

Vi definerer $\mathbf{1} \stackrel{\text{def}}{=} (1, \dots, 1)^*$ således at $L = \text{span}(\mathbf{1})$. Bemærk at dimensionen af L er $d = 1$.

Eksempler, To observationsrækker.

Her er $n = n_1 + n_2$ og $\mu_i = \eta_1, i = 1, \dots, n_1$, og $\mu_i = \eta_2, i = n_1 + 1, \dots, n_1 + n_2$. Derfor er

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_{n_1} \\ \mu_{n_1+1} \\ \vdots \\ \mu_{n_1+n_2} \end{pmatrix} = \eta_1 \begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \eta_2 \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \left. \begin{array}{l} \left. \vphantom{\begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}} \right\} n_1 \text{ gange} \\ \left. \vphantom{\begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix}} \right\} n_2 \text{ gange} \end{array} \right\} (1)$$

Vektorerne på højresiden af (1) indføres nu som $\mathbf{1}_1$ og $\mathbf{1}_2$, hvor koordinaterne for $\mathbf{1}_1$ og $\mathbf{1}_2$ altså er givet ved henholdsvis

$$(\mathbf{1}_1)_j = \begin{cases} 1, & \text{for } j = 1, \dots, n_1, \\ 0, & \text{for } j = n_1 + 1, \dots, n_1 + n_2, \end{cases}$$

og

$$(\mathbf{1}_2)_j = \begin{cases} 0, & \text{for } j = 1, \dots, n_1, \\ 1, & \text{for } j = n_1 + 1, \dots, n_1 + n_2. \end{cases}$$

således at vi har $\boldsymbol{\mu} \in L$ for

$$L = \text{span}(\mathbf{1}_1, \mathbf{1}_2).$$

Dimensionen af L er $d = 2$, da $\mathbf{1}_1$ og $\mathbf{1}_2$ er lineært uafhængige.

Eksempler, To observationsrækker.

Her er $n = n_1 + n_2$ og $\mu_i = \eta_1, i = 1, \dots, n_1$, og $\mu_i = \eta_2, i = n_1 + 1, \dots, n_1 + n_2$. Derfor er

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_{n_1} \\ \mu_{n_1+1} \\ \vdots \\ \mu_{n_1+n_2} \end{pmatrix} = \eta_1 \begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \eta_2 \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \left. \begin{array}{l} \left. \vphantom{\begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}} \right\} n_1 \text{ gange} \\ \left. \vphantom{\begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix}} \right\} n_2 \text{ gange} \end{array} \right\} \quad (1)$$

Vektorerne på højresiden af (1) indføres nu som $\mathbf{1}_1$ og $\mathbf{1}_2$, hvor koordinaterne for $\mathbf{1}_1$ og $\mathbf{1}_2$ altså er givet ved henholdsvis

$$(\mathbf{1}_1)_j = \begin{cases} 1, & \text{for } j = 1, \dots, n_1, \\ 0, & \text{for } j = n_1 + 1, \dots, n_1 + n_2, \end{cases}$$

og

$$(\mathbf{1}_2)_j = \begin{cases} 0, & \text{for } j = 1, \dots, n_1, \\ 1, & \text{for } j = n_1 + 1, \dots, n_1 + n_2. \end{cases}$$

således at vi har $\boldsymbol{\mu} \in L$ for

$$L = \text{span}(\mathbf{1}_1, \mathbf{1}_2).$$

Dimensionen af L er $d = 2$, da $\mathbf{1}_1$ og $\mathbf{1}_2$ er lineært uafhængige.

Eksempler, To observationsrækker.

Her er $n = n_1 + n_2$ og $\mu_i = \eta_1, i = 1, \dots, n_1$, og $\mu_i = \eta_2, i = n_1 + 1, \dots, n_1 + n_2$. Derfor er

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_{n_1} \\ \mu_{n_1+1} \\ \vdots \\ \mu_{n_1+n_2} \end{pmatrix} = \eta_1 \begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \eta_2 \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \left. \begin{array}{l} \left. \vphantom{\begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}} \right\} n_1 \text{ gange} \\ \left. \vphantom{\begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix}} \right\} n_2 \text{ gange} \end{array} \right\} \quad (1)$$

Vektorerne på højresiden af (1) indføres nu som $\mathbf{1}_1$ og $\mathbf{1}_2$, hvor koordinaterne for $\mathbf{1}_1$ og $\mathbf{1}_2$ altså er givet ved henholdsvis

$$(\mathbf{1}_1)_j = \begin{cases} 1, & \text{for } j = 1, \dots, n_1, \\ 0, & \text{for } j = n_1 + 1, \dots, n_1 + n_2, \end{cases}$$

og

$$(\mathbf{1}_2)_j = \begin{cases} 0, & \text{for } j = 1, \dots, n_1, \\ 1, & \text{for } j = n_1 + 1, \dots, n_1 + n_2. \end{cases}$$

således at vi har $\boldsymbol{\mu} \in L$ for

$$L = \text{span}(\mathbf{1}_1, \mathbf{1}_2).$$

Dimensionen af L er $d = 2$, da $\mathbf{1}_1$ og $\mathbf{1}_2$ er lineært uafhængige.

k normalfordelte observationsrækker

For generelt k skriver vi

$$X_{ij} \sim N(\eta_i, \sigma^2), \quad j = 1, \dots, n_i, i = 1, \dots, k.$$

Hvis

$$\mathbf{x} = (x_{11}, \dots, x_{1n_1}, \dots, x_{i1}, \dots, x_{in_i}, \dots, x_{k1}, \dots, x_{kn_k})^*$$

$$\boldsymbol{\mu} = (\eta_1, \dots, \eta_1, \dots, \eta_i, \dots, \eta_i, \dots, \eta_k, \dots, \eta_k)^*$$

$$\mathbf{1}_i = (0, \dots, 0, \dots, 1, \dots, 1, \dots, 0, \dots, 0)^*, \quad i = 1, \dots, k$$

er

$$\boldsymbol{\mu} = \eta_1 \mathbf{1}_1 + \dots + \eta_i \mathbf{1}_i + \dots + \eta_k \mathbf{1}_k,$$

så

$$L = \text{span}\{\mathbf{1}_1, \dots, \mathbf{1}_i, \dots, \mathbf{1}_k\} \quad \text{og} \quad d = k.$$

Lineær regression, designmatrix/modelmatrix

Her er $\mu_i = \alpha + \beta t_i$, så

$$\boldsymbol{\mu} = \begin{pmatrix} \alpha + \beta t_1 \\ \alpha + \beta t_2 \\ \vdots \\ \alpha + \beta t_n \end{pmatrix} = \alpha \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} + \beta \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{pmatrix}.$$

Man ser, at $L = \text{span}(\mathbf{1}, \mathbf{t})$, hvor $\mathbf{1}$ er defineret tidligere, og

$$\mathbf{t} = (t_1, \dots, t_n)^*.$$

Dimensionen af L er 2, hvis der er mindst to forskellige værdier af den uafhængige variabel t .

Bemærk at når $L = \text{span}(\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)})$ kaldes matricen

$$\mathbf{T} = \{\mathbf{t}_{(1)}, \mathbf{t}_{(2)}, \dots, \mathbf{t}_{(q)}\},$$

for en *designmatrix* eller en *modelmatrix*, og L er således søjlerummet for designmatricen.

Lineær regression, designmatrix/modelmatrix

Her er $\mu_i = \alpha + \beta t_i$, så

$$\boldsymbol{\mu} = \begin{pmatrix} \alpha + \beta t_1 \\ \alpha + \beta t_2 \\ \vdots \\ \alpha + \beta t_n \end{pmatrix} = \alpha \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} + \beta \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{pmatrix}.$$

Man ser, at $L = \text{span}(\mathbf{1}, \mathbf{t})$, hvor $\mathbf{1}$ er defineret tidligere, og

$$\mathbf{t} = (t_1, \dots, t_n)^*.$$

Dimensionen af L er 2, hvis der er mindst to forskellige værdier af den uafhængige variabel t .

Bemærk at når $L = \text{span}(\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)})$ kaldes matricen

$$\mathbf{T} = \{\mathbf{t}_{(1)}, \mathbf{t}_{(2)}, \dots, \mathbf{t}_{(q)}\},$$

for en *designmatrix* eller en *modelmatrix*, og L er således søjlerummet for designmatricen.

Lineær regression, designmatrix/modelmatrix

Her er $\mu_i = \alpha + \beta t_i$, så

$$\boldsymbol{\mu} = \begin{pmatrix} \alpha + \beta t_1 \\ \alpha + \beta t_2 \\ \vdots \\ \alpha + \beta t_n \end{pmatrix} = \alpha \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} + \beta \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{pmatrix}.$$

Man ser, at $L = \text{span}(\mathbf{1}, \mathbf{t})$, hvor $\mathbf{1}$ er defineret tidligere, og

$$\mathbf{t} = (t_1, \dots, t_n)^*.$$

Dimensionen af L er 2, hvis der er mindst to forskellige værdier af den uafhængige variabel t .

Bemærk at når $L = \text{span}(\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)})$ kaldes matricen

$$\mathbf{T} = \{\mathbf{t}_{(1)}, \mathbf{t}_{(2)}, \dots, \mathbf{t}_{(q)}\},$$

for en *designmatrix* eller en *modelmatrix*, og L er således søjlerummet for designmatricen.

Lineær normale modeller, estimation, Afsnit 5.2

Først opskrives likelihood funktionen:

$$L(\boldsymbol{\mu}, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu_i)^2} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}\|^2}.$$

For fast σ^2 finder vi at

$$L(\boldsymbol{\mu}, \sigma^2) \leq L(P(\mathbf{x}), \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - P(\mathbf{x})\|^2}.$$

hvor $P(\mathbf{x})$ betegner den ortogonale projektion af $\mathbf{x}$ på L .

Vi finder dernæst

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Likelihood funktionens maksimum findes til:

$$L(\hat{\boldsymbol{\mu}}, \hat{\sigma}^2) = L(P(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2) = \left(\frac{n}{2\pi \|\mathbf{x} - P(\mathbf{x})\|^2} \right)^{\frac{n}{2}} e^{-\frac{n}{2}}.$$

Lineær normale modeller, estimation, Afsnit 5.2

Først opskrives likelihood funktionen:

$$L(\boldsymbol{\mu}, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu_i)^2} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}\|^2}.$$

For fast σ^2 finder vi at

$$L(\boldsymbol{\mu}, \sigma^2) \leq L(P(\mathbf{x}), \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - P(\mathbf{x})\|^2}.$$

hvor $P(\mathbf{x})$ betegner den ortogonale projektion af $\mathbf{x}$ på L .

Vi finder dernæst

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Likelihood funktionens maksimum findes til:

$$L(\hat{\boldsymbol{\mu}}, \hat{\sigma}^2) = L(P(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2) = \left(\frac{n}{2\pi \|\mathbf{x} - P(\mathbf{x})\|^2} \right)^{\frac{n}{2}} e^{-\frac{n}{2}}.$$

Lineær normale modeller, estimation, Afsnit 5.2

Først opskrives likelihood funktionen:

$$L(\boldsymbol{\mu}, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu_i)^2} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}\|^2}.$$

For fast σ^2 finder vi at

$$L(\boldsymbol{\mu}, \sigma^2) \leq L(P(\mathbf{x}), \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - P(\mathbf{x})\|^2}.$$

hvor $P(\mathbf{x})$ betegner den ortogonale projektion af $\mathbf{x}$ på L .

Vi finder dernæst

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Likelihood funktionens maksimum findes til:

$$L(\hat{\boldsymbol{\mu}}, \hat{\sigma}^2) = L(P(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2) = \left(\frac{n}{2\pi \|\mathbf{x} - P(\mathbf{x})\|^2} \right)^{\frac{n}{2}} e^{-\frac{n}{2}}.$$

Lineær normale modeller, estimation, Afsnit 5.2

Først opskrives likelihood funktionen:

$$L(\boldsymbol{\mu}, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu_i)^2} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2}\|\mathbf{x} - \boldsymbol{\mu}\|^2}.$$

For fast σ^2 finder vi at

$$L(\boldsymbol{\mu}, \sigma^2) \leq L(P(\mathbf{x}), \sigma^2) = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2}\|\mathbf{x} - P(\mathbf{x})\|^2}.$$

hvor $P(\mathbf{x})$ betegner den ortogonale projektion af $\mathbf{x}$ på L .


Vi finder dernæst

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Likelihood funktionens maksimum findes til:

$$L(\hat{\boldsymbol{\mu}}, \hat{\sigma}^2) = L(P(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2) = \left(\frac{n}{2\pi \|\mathbf{x} - P(\mathbf{x})\|^2}\right)^{\frac{n}{2}} e^{-\frac{n}{2}}.$$

Geometrien for estimation i en lineær normal model



Geometrien for estimation i en lineær normal model.

Når vi ønsker at reducere fra en lineær normal model M_1 til en anden model M_2 vil vi stå med to underrum L_1 og L_2 som skal opfylde $L_2 \subset L_1$.

Under M_1 gælder der altså at $\mu \in L_1$ og under M_2 gælder der at $\mu \in L_2$, eller, formuleret ved hjælp af en hypotese: I grundmodellen har vi

$$M_1 : \mu \in L_1$$

og ønsker at undersøge hypotesen

$$H_1 : \mu \in L_2 .$$

Likelihood ratio testet for hypotesen findes til

$$Q(\mathbf{x}) = \frac{L\left(P_2(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_2(\mathbf{x})\|^2\right)}{L\left(P_1(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_1(\mathbf{x})\|^2\right)} = \left(\frac{\|\mathbf{x} - P_1(\mathbf{x})\|^2}{\|\mathbf{x} - P_2(\mathbf{x})\|^2}\right)^{\frac{n}{2}} .$$

Når vi ønsker at reducere fra en lineær normal model M_1 til en anden model M_2 vil vi stå med to underrum L_1 og L_2 som skal opfylde $L_2 \subset L_1$.

Under M_1 gælder der altså at $\mu \in L_1$ og under M_2 gælder der at $\mu \in L_2$, eller, formuleret ved hjælp af en hypotese: I grundmodellen har vi

$$M_1 : \mu \in L_1$$

og ønsker at undersøge hypotesen

$$H_1 : \mu \in L_2 .$$

Likelihood ratio testet for hypotesen findes til

$$Q(\mathbf{x}) = \frac{L\left(P_2(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_2(\mathbf{x})\|^2\right)}{L\left(P_1(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_1(\mathbf{x})\|^2\right)} = \left(\frac{\|\mathbf{x} - P_1(\mathbf{x})\|^2}{\|\mathbf{x} - P_2(\mathbf{x})\|^2}\right)^{\frac{n}{2}} .$$

Test: Notation

model	M_1	M_2
underrum	L_1	L_2
dimension	d_1	d_2
estimat for μ	$P_1(\mathbf{x})$	$P_2(\mathbf{x})$
estimat for σ^2	$\frac{\ \mathbf{x} - P_1(\mathbf{x})\ ^2}{n - d_1}$	$\frac{\ \mathbf{x} - P_2(\mathbf{x})\ ^2}{n - d_2}$
frihedsgrader	$n - d_1$	$n - d_2$
$e^{\frac{n}{2}} L(\hat{\mu}, \hat{\sigma}^2)$	$\left(\frac{n}{2\pi \ \mathbf{x} - P_1(\mathbf{x})\ ^2} \right)^{\frac{n}{2}}$	$\left(\frac{n}{2\pi \ \mathbf{x} - P_2(\mathbf{x})\ ^2} \right)^{\frac{n}{2}}$

F-testet.

Ved at benytte Pythagoras' Sætning fås, at idet d_i betegner dimensionen af L_i har vi

$$Q(\mathbf{x}) = \left(\frac{1}{1 + \frac{d_1 - d_2}{n - d_1} F(\mathbf{x})} \right)^{\frac{n}{2}},$$

hvor

$$F(\mathbf{x}) = \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2 / (d_1 - d_2)}{\|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - d_1)}.$$

Det kan vises at $F(\mathbf{x})$ er et udfald fra en $F(d_1 - d_2, n - d_1)$ -fordeling forudsat H_1 er sand, og vi får således

$$p_{obs}(\mathbf{x}) = 1 - F_{F(d_1 - d_2, n - d_1)}(F(\mathbf{x})).$$

F-testet.

Ved at benytte Pythagoras' Sætning fås, at idet d_i betegner dimensionen af L_i har vi

$$Q(\mathbf{x}) = \left(\frac{1}{1 + \frac{d_1 - d_2}{n - d_1} F(\mathbf{x})} \right)^{\frac{n}{2}},$$

hvor

$$F(\mathbf{x}) = \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2 / (d_1 - d_2)}{\|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - d_1)}.$$

Det kan vises at $F(\mathbf{x})$ er et udfald fra en $F(d_1 - d_2, n - d_1)$ -fordeling forudsat H_1 er sand, og vi får således

$$p_{obs}(\mathbf{x}) = 1 - F_{F(d_1 - d_2, n - d_1)}(F(\mathbf{x})).$$

Geometrien for test i en lineær normal model




Illustration af de centrale størrelser i test af reduktionen fra M_1 til M_2

Lineære normale modeller i R

Forsimpelt kald til **lm** :

```
lm(formula, data = navn på datasæt)
```

Modelformel:

```
responsvariabel ~ liste med forklarende variable
```

Data fra Eksempel 2.1

```
Volt <- c(21.89, 22.20, ..., 21.94, 22.29)
```

Fitte model for én observationsrække:

```
lmfit <- lm(Volt ~ 1)
```

Køres `anova(lmfit)` fås *variansanalysetabellen* for den fittede model

```
Analysis of Variance Table
```

```
Response: Volt
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Residuals	29	3.5636	0.12288		

Sammenlign med s. (2.10) i de supplerende noter

$$s^2(\mathbf{x}) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{3.5636}{29} = 0.122883.$$

anova kan bruges til at reducere fra en lineær normal model til en lineær normal undermodel.

I Eksempel 2.1 ønsker vi at undersøge $H : \mu = 22.0$ i M_1 hvor

$$M_1 : X_i \sim N(\mu, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed,}$$

det vil sige reducere M_1 til M_2 , hvor

$$M_2 : X_i \sim N(22.0, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

Men M_2 er *ikke* en lineær normal model.

Hypotesetest med **anova**

Løsning: Træk 22.0 fra alle variable $\tilde{X}_i = X_i - 22.0 \quad i = 1, \dots, 30$
og undersøge om

$$M_1 : \tilde{X}_i \sim N(\tilde{\mu}, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed,}$$

hvor $\tilde{\mu} = \mu - 22.0$ kan reduceres til

$$M_2 : \tilde{X}_i \sim N(0, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

Både M_1 og M_2 er lineære normale modeller og M_2 er en delmodel af M_1 .

Hypotesetest med **anova**

Variansanalysetabellen for reduktionen fra M_1 til M_2 kan nu dannes:

```
Volt_minus_22 <- Volt - 22
lmfit_m1 <- lm(Volt_minus_22 ~ 1)
lmfit_m2 <- lm(Volt_minus_22 ~ 0)
anova(lmfit_m2, lmfit_m1)
```

Analysis of Variance Table

Model 1: Volt_minus_22 ~ 0

Model 2: Volt_minus_22 ~ 1

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	30	4.3316				
2	29	3.5636	1	0.768	6.2499	0.01833 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Sammenlign med (2.12):

$$p_{\text{obs}} = 2(1 - F_{t(29)}(2.49997)) = 0.0183265.$$

og bemærk at

$$t(\mathbf{x})^2 = 2.49997^2 \approx 6.2499 = F$$

Variansanalysetabellen

Indholdet af variansanalysetabellen er

Analysis of Variance Table						
Model 1: Modelformel for M_2						
Model 2: Modelformel for M_1						
	Res.df.	RSS	Df	Sum of Sq	F	Pr(>F)
1	$n - d_2$	$\ \mathbf{x} - P_2(\mathbf{x})\ ^2$				
2	$n - d_1$	$\ \mathbf{x} - P_1(\mathbf{x})\ ^2$	$d_1 - d_2$	$\ P_1(\mathbf{x}) - P_2(\mathbf{x})\ ^2$	$F(M_1, M_2)$	p_{obs}

hvor $F(M_1, M_2)$ og p_{obs} er henholdsvis

$$F(M_1, M_2) = \mathcal{F}(\mathbf{x}) = \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2 / (d_1 - d_2)}{\|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - d_1)} \quad \text{og}$$

$$p_{obs} = p_{obs}(\mathbf{x}) = 1 - F_{F(d_1 - d_2, n - d_1)}(\mathcal{F}(\mathbf{x})).$$

Hypotesetest med **anova** - k - observationsrækker

Først indlæses data fra Eksempel 3.2 indlæses og vises

```
soya <- read.csv(file="soya.csv",stringsAsFactors=TRUE)
head(soya)
```

	area	light	stress	group
1	200	low	low	A
2	215	low	low	A
3	225	low	low	A
4	229	low	low	A
5	230	low	low	A
6	232	low	low	A

stringsAsFactors sikrer at **group** opfattes som faktorvariabel.

Hypotesetest med **anova** - k - observationsrækker

For at undersøge $H_{0\mu}$ fittes modellerne til data og vi kalder **anova** .

```
lmfit_m1 <- lm(area~group,data=soya)
lmfit_m2 <- lm(area~1,data=soya)
anova(lmfit_m2,lmfit_m1)
```

Analysis of Variance Table

Model 1: area ~ 1

Model 2: area ~ group

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	51	100613				
2	48	42976	3	57636	21.458	5.867e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

På side 55 fandt vi

$$SSD_H = 100612.673 - 42976.308 = 57636.365 \quad \text{og} \quad \frac{SSD_H}{k-1} = \frac{57636.365}{3} = 19212.122$$

$$\mathcal{F}(\mathbf{x}) = \frac{19212.122}{895.340} = 21.46.$$

Hypotesetest med **anova** - lineær regression

Data fra Tabel 4.3 indlæses:

```
rotationer <- rep(c(170, 530, 880), each=4)
masse <- c(3.89, 3.95, 3.85, 3.91, ..., 3.71, 3.30, 3.26, 3.30, 3.34)
```

Som i Appendiks til Afsnit 4.1 fittes modellen for simpel lineær regression:

```
lmfit_m2 = lm(masse ~ 1 + rotationer)
```

Når vi undersøger hypotesen om lineær regression tager vi udgangspunkt i en model med $k = 3$ observationsrækker (én for hver forskellig værdi af rotationer), og derfor skal **rotationer** opfattes som en faktorvariabel:

```
rotationer_som_faktor = as.factor(rotationer)
```

Hypotesetest med **anova** - lineær regression

Vi kan nu fitte modellen for k observationsrækker (M_1) og undersøge om vi kan reducere til modellen for simpel lineær regression (M_2)

```
lmfit_m1 = lm(masse ~ 1 + rotationer_som_faktor)
anova(lmfit_m2, lmfit_m1)
```

Analysis of Variance Table

Model 1: masse ~ 1 + rotationer

Model 2: masse ~ 1 + rotationer_som_faktor

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	10	0.023415				
2	9	0.018200	1	0.0052153	2.579	0.1428

Fra (4.23) har vi

$$p_{obs}(\mathbf{x}) = 1 - F_{F(1,9)}(2.57) = 0.14,$$

Bartlett's test i R

Bartlett's test kan udføres med `bartlett.test`

```
bartlett.test(masse ~ 1 + rotationer_som_faktor)
```

Output bliver

```
Bartlett test of homogeneity of variances

data:  masse by rotationer_som_faktor
Bartlett's K-squared = 0.82107, df = 2, p-value = 0.6633
```

Som stemmer overens med det vi tidligere regnede ud.

Hypotesetest med **anova** - lineær regression

I modellen M_2 for simpel lineær regression ønsker vi til slut at undersøge

$$H_{03}^* : \alpha = \alpha_0 = \ln 60 = 4.0943.$$

Som i Appendix til afsnit 4.1 betragter vi transformerede variable $\tilde{X}_i = X_i - \ln 60$. I M_2 vil der gælde at

$$\tilde{X}_i \sim N(\tilde{\alpha} + \beta t_i, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed}$$

hvor $\tilde{\alpha} = 0$, således at hypotesen kan formuleres som

$$H_{03}^* : \tilde{\alpha} = 0.$$

Hypotesetest med **anova** - lineær regression

For at undersøge H_{03}^* køres nedenstående R-kode, hvor vi bemærker at **1** i M_2 udskiftes med **0** i M_3^* .

```
masse_minus_ln60 = masse - log(60)
lmfit_m2 = lm(masse_minus_ln60 ~ 1 + rotationer)
lmfit_m3star = lm(masse_minus_ln60 ~ 0 + rotationer)
anova(lmfit_m3star, lmfit_m2)
```

Variansanalysetabellen bliver

Analysis of Variance Table

Model 1: masse_minus_ln60 ~ 0 + rotationer

Model 2: masse_minus_ln60 ~ 1 + rotationer

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	11	0.027081				
2	10	0.023415	1	0.0036659	1.5656	0.2393

Bemærk at

$$t(\mathbf{x}) = (-1.249)^2 \approx 1.5656 = \mathbf{F},$$

samt at p -værdien stemmer overens med (4.27).

Matematisk Statistik

Tosidet variansanalyse

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Tilbage til Eksempel 3.2

Fagligt problem

Hvordan påvirker stress væksten af sojabønner?

52 stiklinger blev plantet i potter, én i hver potte. De 52 stiklinger blev tilfældigt inddelt i fire grupper med 13 i hver. Stiklingerne i to af grupperne blev stresset ved at blive rystet i tyve minutter dagligt, mens stiklingerne i de to andre grupper ikke blev rystet. Desuden voksede to af grupperne i svagt lys, og de andre to grupper i moderat lys, således at de fire grupper fik hver sin behandling:

Gruppe 1 : svagt lys, ingen stress

Gruppe 2 : svagt lys, stress

Gruppe 3 : moderat lys, ingen stress

Gruppe 4 : moderat lys, stress

Kan vi sige noget om effekten af lys og effekten af stress hver for sig?

Eksempel 3.2 - data

Samlet areal i cm ²			
Gruppe			
1	2	3	4
200	163	268	201
215	182	271	216
225	188	273	241
229	195	282	257
230	202	285	259
232	205	299	267
241	212	309	269
253	214	310	282
256	215	314	283
264	230	320	291
268	235	337	291
288	255	340	312
288	272	345	326
Middelværdier			
245.31	212.92	304.08	268.85

Tabel 1: Gruppe 1: svagt lys, ingen stress; Gruppe 2: svagt lys, stress; Gruppe 3: moderat lys, ingen stress; Gruppe 4: moderat lys, stress.

Eksempel 3.2

Konklusion fra Afsnit 3.2:

$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, 3, 4 \quad j = 1, \dots, 13 \quad + \text{ uafhængighed.}$

Estimer for middelværdier:

$$\begin{aligned}\mu_1 &\leftarrow \bar{x}_{1\cdot} = 245.308 & \mu_2 &\leftarrow \bar{x}_{2\cdot} = 212.923 \\ \mu_3 &\leftarrow \bar{x}_{3\cdot} = 304.077 & \mu_4 &\leftarrow \bar{x}_{4\cdot} = 268.846.\end{aligned}$$

Først: Parametertabellen i ensidet variansanalyse.

summary - k - observationsrækker

Først præsenteres parametertabellen for k -observationsrækker ved hjælp af Eksempel 3.2.

Soya-datasættet indlæses

```
soya <- read.csv(file="soya.csv",stringsAsFactors=TRUE)
head(soya)
```

	area	light	stress	group
1	200	low	low	A
2	215	low	low	A
3	225	low	low	A
4	229	low	low	A
5	230	low	low	A
6	232	low	low	A

summary - k - observationsrækker

Modellen M_1 fittes:

```
lmfit_m1 <- lm(area ~ 1 + group, data=soya)
```

Skriver vi $\text{group}_i = \zeta_i$ kan modelformlen læses som

$$\alpha \cdot 1 + \zeta_i \quad i = 1, 2, 3, 4.$$

I denne opskrivning er der 5 parametre:

$$\alpha, \zeta_1, \zeta_2, \zeta_3, \zeta_4$$

og modellen er *overparametriseret*, fordi vi betragter parametrene relativt til en referencegruppe. Relationen til μ_i erne er:

$$\begin{aligned} \alpha &= \mu_1 & \zeta_1 &= \mu_1 - \mu_1 = 0 & \zeta_2 &= \mu_2 - \mu_1 \\ \zeta_3 &= \mu_3 - \mu_1 & \zeta_4 &= \mu_4 - \mu_1 \end{aligned}$$

summary - k - observationsrækker

Køres `summary(lmfit_m1)` fås parametertabellen:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	245.308	8.299	29.559	< 2e-16 ***
groupB	-32.385	11.736	-2.759	0.00817 **
groupC	58.769	11.736	5.007	7.86e-06 ***
groupD	23.538	11.736	2.006	0.05056 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.92 on 48 degrees of freedom

Multiple R-squared: 0.5729, Adjusted R-squared: 0.5462

F-statistic: 21.46 on 3 and 48 DF, p-value: 5.867e-09

Vi ser at $\hat{\alpha} = \hat{\mu}_1 = 245.308$ og

$$\hat{\zeta}_2 = \hat{\mu}_2 - \hat{\mu}_1 = 212.923 - 245.308 = -32.385$$

$$\hat{\zeta}_3 = \hat{\mu}_3 - \hat{\mu}_1 = 304.077 - 245.308 = 58.769$$

$$\hat{\zeta}_4 = \hat{\mu}_4 - \hat{\mu}_1 = 268.846 - 245.308 = 23.538$$

summary - k - observationsrækker

Information om niveauerne for en faktorvariabel kan fås med **levels**

Valg af referencegruppe kan foretages med **relevel**, f.eks. giver

```
levels(soya$group)
```

```
[1] "A" "B" "C" "D"
```

```
groupBref <- relevel(soya$group, "B")  
levels(groupBref)
```

```
[1] "B" "A" "C" "D"
```

summary - k - observationsrækker

Hvis 0 tilføjes til modelformlen, fjernes interceptet.

```
lmfit_m1 <- lm(area ~ 0 + group, data=soya)
```

Køres `summary(lmfit_m1)` fås parametertabellen:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
groupA	245.308	8.299	29.56	<2e-16	***
groupB	212.923	8.299	25.66	<2e-16	***
groupC	304.077	8.299	36.64	<2e-16	***
groupD	268.846	8.299	32.40	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 29.92 on 48 degrees of freedom

Multiple R-squared: 0.9879, Adjusted R-squared: 0.9869

F-statistic: 981 on 4 and 48 DF, p-value: < 2.2e-16


Vi har fittet *to forskellige parametriseringer af samme model.*

Eksempel 3.2




Den ekstra tilvækst ved moderat lys, ser ikke ud til afhænge af stress/ikke stress, og effekten af stress ser ikke til at afhænge af lys.

Kontroltegning - interaktionsplot



Interaktionsplot for *lys*.
Gruppegennemsnit er markeret med •.



Interaktionsplot for *stress*.
Gruppegennemsnit er markeret med •.

Eksempel 3.2

Ny opstilling af data fra Eksempel 3.2:

		Stress	
		Ingen stress	Stress
Lys	Svagt	200 215	163 182
		225 229	188 195
		230 232	202 205
		241 253	212 214
		256 264	215 230
		268 288	235 255
		288	272
	Moderat	268 271	201 216
		273 282	241 257
		285 299	259 267
		309 310	269 282
		314 320	283 291
		337 340	291 312
		345	326

Tilsvarende indeksering:

$$M_1 : X_{ijk} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, 2, \quad j = 1, 2, \quad k = 1, \dots, 13.$$

Eksempel 3.2 - additivitetsmodellen

Ønsker at undersøge om vi kan reducere til *additivitetsmodellen*

$$M_2 : X_{ijk} \sim N(\alpha_i + \beta_j, \sigma^2), \quad i = 1, 2, j = 1, 2, k = 1, \dots, 13,$$

I additivitetsmodellen er der ikke *vekselvirkning* mellem *lys* og *stress* og vi kan der sige noget om *virkningen* af lys og stress hver for sig.

De interessante parametre i M_2 :

- $\alpha_1 - \alpha_2$ (*virkning* af lys)
- $\beta_1 - \beta_2$ (*virkning* af stress)

Additiv effekt

Forskel af stress under additive model:

Ingen Stress – Stress

Svagt lys	$\beta_1 - \beta_2$	$\gamma = \beta_1 - \beta_2$
Moderat lys	$\beta_1 - \beta_2$	

Forskel af stress er det samme for de to niveauer af lys

Forskel af lys under additive model:

	Ingen Stress	Stress	$\delta = \alpha_1 - \alpha_2$
Svagt lys – Moderat lys	$\alpha_1 - \alpha_2$	$\alpha_1 - \alpha_2$	

Forskel af lys er det samme for de to niveauer af stress

Med $\mu = \alpha_2 + \beta_2$ har vi:

	Ingen Stress	Stress	3 parametre.
Svagt lys	$\mu + \gamma + \delta$	$\mu + \delta$	
Moderat lys	$\mu + \gamma$	μ	

Additiv model og i vekselvirkning **R**

For at undersøge reduktionen fra M_1 til M_2 skal vi fitte de to modeller og bruge **anova** .
 M_1 fittes med kaldet

```
lmfit_m1 <- lm(area ~ light+stress+light:stress, data=soya)
```

Leddet **stress:light** er et *vekselvirkningsled* - en faktor, der giver samme inddeling som **group** .

M_2 fittes ved hjælp af kaldet

```
lmfit_m2 <- lm(area ~ light+stress, data=soya)
```

Køres **anova**(lmfit_m2, lmfit_m1) fås variansanalysetabellen

Analysis of Variance Table

Model 1: area ~ light + stress

Model 2: area ~ light + stress + light:stress

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	49	43003				
2	48	42976	1	26.327	0.0294	0.8646

Reduktionen til M_2 afvises ikke, og denne er modellen for data.

I M_2 kan vi undersøge om stress har betydning for væksten:

$$M_3^r : X_{ijk} \sim N(\alpha_i, \sigma^2), \quad i = 1, 2, j = 1, 2, k = 1, \dots, 13,$$

I M_3^r har kun **r**ækkerne (lys) en effekt.

Vi kan også undersøge om lys har betydning for væksten

$$M_3^s : X_{ijk} \sim N(\beta_j, \sigma^2), \quad i = 1, 2, j = 1, 2, k = 1, \dots, 13.$$

I M_3^s har kun **s**øjlerne (stress) en effekt.

Rækkeeffekter og søjleeffekter i R

Både M_3^r og M_3^s er modeller for $k = 2$ observationsrækker og fittes som sådan:

```
lmfit_m3s <- lm(area ~ stress, data=soya)
lmfit_m3r <- lm(area ~ light, data=soya)
anova(lmfit_m3s, lmfit_m2)
anova(lmfit_m3r, lmfit_m2)
```

Varsiansanalysetabellerne bliver

Analysis of Variance Table

Model 1: area ~ stress

Model 2: area ~ light + stress

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	50	85754				
2	49	43003	1	42752	48.714	7.136e-09 ***

og

Analysis of Variance Table

Model 1: area ~ light

Model 2: area ~ light + stress

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	50	57861				
2	49	43003	1	14858	16.931	0.0001479 ***

Estimater i additivitetsmodellen

Estimaterne i additivitetsmodellen findes i parametertabellen, som vi får med `summary(lmfit_m2)` :

```
Call:
lm(formula = area ~ light + stress, data = soya)

Residuals:
    Min       1Q   Median       3Q      Max
-68.558 -19.029  -0.385  18.846  59.788

Coefficients:
              Estimate Std. Error   t value    Pr(>t)
(Intercept)   $\hat{\alpha}_2 + \hat{\beta}_2 =$  269.558      7.116    37.883 < 2e-16 ***
lightlow      $\hat{\alpha}_1 - \hat{\alpha}_2 =$  -57.346      8.216    -6.980 7.14e-09 ***
stresslow     $\hat{\beta}_1 - \hat{\beta}_2 =$  33.808      8.216     4.115 0.000148 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.62 on 49 degrees of freedom
Multiple R-squared:  0.5726,    Adjusted R-squared:  0.5551
F-statistic: 32.82 on 2 and 49 DF,  p-value: 9.029e-10
```

Parametriseringen forstås ved at skrive:

$$\alpha_i + \beta_j = (\alpha_2 + \beta_2) + (\alpha_i - \alpha_2) + (\beta_j - \beta_2) = 1 + \text{light} + \text{stress}$$

Estimer i additivitetsmodellen

Estimaterne findes dermed til:

$$\begin{array}{llll} \text{Lys:} & \alpha_1 - \alpha_2 & \leftarrow & -57 \text{ cm}^2 & [-74 \text{ cm}^2, -41 \text{ cm}^2] \\ \text{Stress:} & \beta_1 - \beta_2 & \leftarrow & 34 \text{ cm}^2 & [17 \text{ cm}^2, 50 \text{ cm}^2] \end{array}$$

Konfidensintervallerne kan findes med `confint(lmfit_m2)`

```
          2.5 %    97.5 %
(Intercept) 255.25846 283.85692
lightlow    -73.85748 -40.83482
stresslow    17.29636  50.31902
```

Parametrisering med vekselvirkningsled

Da vi fittede M_1 brugte vi modelformlen `area ~ light+stress+light:stress`

Køres `summary(lmfit_m1)` fås parametertabellen:

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    268.846      8.299   32.395 < 2e-16 ***
lightlow       -55.923     11.736   -4.765 1.79e-05 ***
stresslow       35.231     11.736    3.002 0.00425 **
lightlow:stresslow -2.846    16.598   -0.171 0.86457
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Bruges indeksering fra (5.18) kan parametriseringen forstås ved at skrive:

$$\mu_{ij} = \mu_{22} + (\mu_{i2} - \mu_{22}) + (\mu_{2j} - \mu_{22}) + (\mu_{ij} - \mu_{i2} - \mu_{2j} + \mu_{22})$$
$$1 + \text{light} + \text{stress} + \text{light:stress}$$

og benytte

$$\begin{aligned}\mu_{11} &\leftarrow \hat{\mu}_{11} = \bar{x}_{11}. = 245.308 & \mu_{12} &\leftarrow \hat{\mu}_{12} = \bar{x}_{12}. = 212.923 \\ \mu_{21} &\leftarrow \hat{\mu}_{21} = \bar{x}_{21}. = 304.077 & \mu_{22} &\leftarrow \hat{\mu}_{22} = \bar{x}_{22}. = 268.846 .\end{aligned}$$

For eksempel er `(Intercept)` = $\hat{\mu}_{22}$ og `lightlow` = $\hat{\mu}_{12} - \hat{\mu}_{22}$ og
`lightlow:stresslow` = $\hat{\mu}_{22} - \hat{\mu}_{21} - \hat{\mu}_{12} + \hat{\mu}_{11}$.

Generelt om tosidet variansanalyse

Generelt i tosidet variansanalyse tænker vi på en faktor R med r niveauer og en faktor S med s niveauer. Data er organiseret i en $r \times s$ tabel med rs celler.

Vi betragter 5 modeller:

Grundmodellen

$$M_1 : \quad X_{ijk} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, \dots, r, j = 1, \dots, s, k = 1, \dots, n_{ij}.$$

Additivitetsmodellen

$$M_2 : \quad X_{ijk} \sim N(\alpha_i + \beta_j, \sigma^2), \quad i = 1, \dots, r, j = 1, \dots, s, k = 1, \dots, n_{ij}.$$

Modellen med *kun rækkevirkning*

$$M_3^r : \quad X_{ijk} \sim N(\alpha_i, \sigma^2), \quad i = 1, \dots, r, j = 1, \dots, s, k = 1, \dots, n_{ij}.$$

Modellen med *kun søjlevirkning*


$$M_3^s : \quad X_{ijk} \sim N(\beta_j, \sigma^2), \quad i = 1, \dots, r, j = 1, \dots, s, k = 1, \dots, n_{ij}.$$

Modellen for én observationsrække

$$M_\infty : \quad X_{ijk} \sim N(\mu, \sigma^2), \quad i = 1, \dots, r, j = 1, \dots, s, k = 1, \dots, n_{ij}.$$

Generelt om tosidet variansanalyse

Det indbyrdes forhold mellem additivitetsmodellen og dennes undermodeller er:



Additivitetsmodellen

Den centrale egenskab ved additivitetsmodellen er at forskellen i middelværdi mellem to forskellige rækker g og h ikke afhænger af søjlen:

$$EX_{gjk} - EX_{hjk} = (\alpha_g + \beta_j) - (\alpha_h + \beta_j) = \alpha_g - \alpha_h.$$

og forskellen i middelværdi mellem to forskellige søjler l og m ikke afhænger rækken:

$$EX_{ilk} - EX_{imk} = (\alpha_i + \beta_l) - (\alpha_i + \beta_m) = \beta_l - \beta_m.$$

Modelkontrol - interaktionsplot

Vi kan lave modelkontrol af additivitetsmodellen ved at lave *interaktionsplot*, som er baseret på skønnene over middelværiderne $EX_{ijk} \leftarrow \bar{x}_{ij}$.

Interaktionsplot for rækkerne:

Afsæt punkterne $(j, \bar{x}_{ij.})$ for $j = 1, \dots, s$.

Disse skal give r kurver med konstant lodret afstand.

Interaktionsplot for søjlerne:

Afsæt punkterne $(i, \bar{x}_{ij.})$ for $i = 1, \dots, r$.

Disse skal give s kurver med konstant lodret afstand.

Kan laves i **R** med `interaction.plot`.

Fortolkning og antal gentagelser n_{ij}

Når modellerne regnes igennem i **R** er der ikke nogen krav på antallet af observationer i den ij -te celler.

Der er fortolkningsmæssige fordele, hvis der gælder at

$$n_{ij} = \frac{n_{i.} \cdot n_{.j}}{n_{..}}, \quad (\spadesuit)$$

En af fordelene er at det er let at regne estimer ud. Når betingelsen er opfyldt gælder der i M_2 at $\bar{X}_{i.} \sim N(\alpha_i + \bar{\beta}_{.}, \sigma^2/n_{i.})$, hvor

$$\bar{\beta}_{.} = \frac{1}{n_{..}} \sum_{j=1}^s n_{.j} \beta_j,$$

så skønnet over forskellen i virkning mellem niveau g og h af R er

$$\alpha_g - \alpha_h \leftarrow \bar{X}_{g.} - \bar{X}_{h.} \sim N(\alpha_g - \alpha_h, \sigma^2(1/n_{g.} + 1/n_{h.})).$$

Hvis $(\spadesuit)$ ikke er opfyldt afhænger fordelingen af $\bar{X}_{g.} - \bar{X}_{h.}$ og kan ikke anvendes som skøn over $\alpha_g - \alpha_h$.

Et tilsvarende resultat gælder for estimation af virkningen af søjlerne.

Fortolkning og antal gentagelser n_{ij}

En yderligere fordel når ($\spadesuit$) er opfyldt er at skønnet over forskellen mellem virkningerne på to niveauer af R er det samme i modellen M_2 som i M_3^r . Med andre ord afhænger skønnet ikke af, om S har en betydning. Et tilsvarende udsagn gælder, hvis vi bytter om på rollerne af rækker og søjler.

Dette stemmer overens med den fortolkning som ønsker at have af M_2 .

En sidste fordel er at testet for om R har en betydning *sjældent* vil afhænge af om dette undersøges i M_2 eller i M_3^r , idet tællerne i F -testet i de to situationer vil være identiske.

Eksempel 5.7

Data i dette eksempel stammer fra seks boringer i et givent område. For hver boring er der taget en borekerne af jord, og man har målt pH-værdien af jorden i toppen, i midten og i bunden af borekernen. Da de seks boringer er foretaget i et større område, er det ikke rimeligt at anse de seks boringer for gentagne målinger af den samme størrelse. Det er heller ikke rimeligt at betragte de tre målinger fra hver borekernes top, midte og bund som gentagne målinger af samme størrelse, fordi man netop forventer en systematisk ændring af surhedsgraden ned gennem kernen.

Indledningsvis arbejdes der derfor med en model, hvor alle observationer er uafhængige, og hver observation har sin egen middelværdi. Vi forudsætter, at alle målingerne er normalfordelte med samme varians,

Eksempel 5.7

kerne	bund	midte	top	<i>gennemsnit</i>
1	7.2	7.6	7.5	7.43
2	6.7	7.1	7.2	7.00
3	7.0	7.2	7.3	7.17
4	7.0	7.4	7.5	7.30
5	7.0	7.7	7.7	7.47
6	6.9	7.7	7.6	7.40
<i>gennemsnit</i>	6.97	7.45	7.47	7.29


Udgangspunktet er modellen M_1 hvor alle observationer har deres egen middelværdi og med en fælles varians.

$$M_1 : X_{ij} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, \dots, 6, j = 1, 2, 3,$$

Denne model kan ikke kontrolleres og vi kan ikke lave et test for om vi kan reducere til M_2 .


Vi betragter interaktionsplot.

Eksempel 5.7



Figur 1: Grafisk kontrol af additivetsmodellen M_2 . Under M_2 er de tre kurver parallelforskuet i forhold til hinanden bortset fra tilfældige udsving.

Eksempel 5.7



Figur 2: Grafisk kontrol af additivetsmodellen M_2 . Under M_2 er de seks kurver parallelforskuet i forhold til hinanden bortset fra tilfældige udsving.

Eksempel 5.7

Kontroltegningerne gør at vi godt bruge additivitetsmodellen.
Yderligere modelreduktion viser sig ikke at være mulig.

Matematisk Statistik

Gruppespecifik regression

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

m lineære regressioner

Udgangspunktet er modellen for m lineære regressioner

$$M_0 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma_i^2).$$

hvor X_{ij} er indbyrdes uafhængige $i = 1, \dots, m, j = 1, \dots, n_i$, og (t_{ij}, X_{ij}) er sammenhørende observationer af den afhængige variabel X_{ij} og den uafhængige variabel t_{ij} .

Sammenligning af de m regressionslinjer udføres ved hjælp af teorien for lineære normale modeller, hvilket kræver, at alle observationer har samme varians, det vil sige, at hypotesen

$$H_{01} : \sigma_1^2 = \dots = \sigma_m^2$$

ikke forkastes.

Test af varianshomogenitet

Hypotesen om varianshomogenitet

$$H_{01} : \sigma_1^2 = \dots = \sigma_m^2$$

testes ved hjælp af de uafhængige estimatorer for varianserne $s_{(i)}^2$ i de m regressioner, idet

$$s_{(i)}^2 \sim \sigma_i^2 \chi(n_i - 2)/(n_i - 2) \quad , \quad i = 1, \dots, m.$$

Hypotesen H_{01} testes ved hjælp af

- F -test, hvis $m = 2$
- Bartlett's test, hvis $m \geq 3$ og $n_i \geq 4$

Forkastes H_{01} ikke, reduceres modellen M_0 til den lineære normale model

$$M_1 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma^2) \quad i = 1, \dots, m, j = 1, \dots, n_i.$$

hvor X_{ij} erne er uafhængige.


Modeller og hypoteser

Vi betragter følgende lineære normale regressionsmodeller

- $M_1 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma^2),$ *samme* varians.
 $M_2 : X_{ij} \sim N(\alpha + \beta_i t_{ij}, \sigma^2),$ *samme* afskæring.
 $M_2^* : X_{ij} \sim N(\alpha_i + \beta t_{ij}, \sigma^2),$ *samme* hældning.
 $M_3 : X_{ij} \sim N(\alpha + \beta t_{ij}, \sigma^2),$ *sammenfaldende* regressionslinjer.

Modeller og hypoteser

De fire modeller og de hypoteser, der giver sammenhængen mellem dem, kan skematisk angives således



Alle modellerne er eksempler på lineære normale modeller og kan behandles med **lm**.

Eksempel 5.8


Fagligt problem

Det er velkendt, at menneskers blodtryk stiger med alderen, men har denne stigning noget med ens profession at gøre?

Data

I Tabel 5.5 er alder og systolisk blodtryk angivet for 28 mænd, som endvidere er inddelt i to grupper efter deres profession. De 13 er journalister og de 15 er universitetslærere. I Figur 5.10 findes et scatterplot af data med alder ud ad førsteaksen og blodtryk op ad andenaksen, og man ser man begge professioner, at blodtrykket tilsyneladende stiger lineært med alderen

Eksempel 5.8



Figur 1: Separate tegninger for de to professioner.

Estimator i M_1

Data indlæses:

```
Blodtryk = read.csv("blodtryk.csv", header = TRUE, stringsAsFactors = TRUE)
head(Blodtryk)
```

Første 6 observationer:

	stilling	alder	blodtryk
1	Journalist	68	188.7
2	Underviser	55	162.9
3	Journalist	62	184.2
4	Underviser	49	155.9
5	Journalist	49	151.3
6	Underviser	60	170.5

Analysen af M_0 kan foretages ved at opdele datasættet i to datasæt:

```
Journalister <- subset(Blodtryk, subset = stilling == "Journalist")
Undervisere <- subset(Blodtryk, subset = stilling == "Underviser")
```


Eksempel 5.8

I modellen for to regressionslinjer med hver sin varians

$$M_0 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma_i^2) \quad i = 1, 2, j = 1, \dots, n_i$$

hvor $n_1 = 13$ og $n_2 = 15$, er estimerterne

Gruppe	α	β	σ^2
<i>journalist</i>	84.99521966	1.52956813	18.14950
<i>universitetslærer</i>	75.62986190	1.56238397	19.44954

Test af $H_{01} : \sigma_1^2 = \sigma_2^2$:

F -teststørrelsen for H_{01} er

$$\mathcal{F} = \frac{18.14950}{19.44954} = 0.933.$$

p -værdien er 0.92 og H_{01} afvises ikke.

Eksempel 5.8

F -testet for varianshomogenitet bør benyttes her, for der er to variansskøn. Hvis vi alligevel ønskede at benytte Bartlett's test, kan dette gøres med

```
LM_Journalister <- lm(blodtryk ~ 1+alder, data = Journalister)
LM_Undervisere <- lm(blodtryk ~ 1+alder, data = Undervisere)

bartlett.test(list(LM_Journalister, LM_Undervisere))
```

Output bliver da

```
Bartlett test of homogeneity of variances

data:  list(LM_Journalister, LM_Undervisere)
Bartlett's K-squared = 0.013654, df = 1, p-value = 0.907
```

Eksempel 5.8

I modellen for to regressionslinjer med fælles varians

$$M_1 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma^2) \quad i = 1, 2, j = 1, \dots, n_i$$

beregnes estimatet for σ^2 som det vægtede gennemsnit, med frihedsgraderne som vægte, af estimerterne for σ^2 i de to grupper under M_0 :

$$s_{01}^2 = \frac{11 \cdot 18.14950 + 13 \cdot 19.44954}{11 + 13} = 18.85369.$$

Estimerterne i M_1 er

Gruppe	α	β	σ^2
<i>journalist</i>	84.99521966	1.52956813	18.85369
<i>universitetslærer</i>	75.62986190	1.56238397	

Estimator i M_1

Vi kan fitte M_1 til datasættet ved hjælp af

```
LM_Blodtryk_M1 <- lm(blodtryk~1+stilling+alder+alder:stilling, data=Blodtryk)
```

Modelformlen kan læses som

$$\alpha \cdot 1 + \zeta_{\text{stl}} + \beta \cdot \text{alder} + \eta_{\text{stl}} \cdot \text{alder} \quad \text{stl} \in \{\text{journalist}, \text{underviser}\}.$$

I denne opskrivning er der 6 parametre:

$$\alpha, \zeta_{\text{journalist}}, \zeta_{\text{underviser}}, \beta, \eta_{\text{journalist}} \quad \text{og} \quad \eta_{\text{underviser}}$$

og modellen er *overparametriseret*, fordi vi betragter parametrene relativt til en referencegruppe. Relationen til “oprindelige” parametre er:

$$\begin{aligned} \alpha &= \alpha_1, & \zeta_{\text{journalist}} &= \alpha_1 - \alpha_1 = 0, & \zeta_{\text{underviser}} &= \alpha_2 - \alpha_1 & \text{og} \\ \beta &= \beta_1, & \eta_{\text{journalist}} &= \beta_1 - \beta_1 = 0, & \eta_{\text{underviser}} &= \beta_2 - \beta_1. \end{aligned}$$

Estimater i M_1

Parametertabellen fås ved at køre `summary(LM_Blodtryk_M1)`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	$\hat{\alpha} = 84.99522$	7.74255	10.978	7.71e-11 ***
stillingUnderviser	$\hat{\zeta}_{\text{underviser}} = -9.36536$	12.74975	-0.735	0.470
alder	$\hat{\beta} = 1.52957$	0.13509	11.322	4.12e-11 ***
stillingUnderviser:alder	$\hat{\eta}_{\text{underviser}} = 0.03282$	0.22419	0.146	0.885

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: $\hat{\sigma} = 4.342$ on 24 degrees of freedom

Multiple R-squared: 0.9049, Adjusted R-squared: 0.893

F-statistic: 76.13 on 3 and 24 DF, p-value: 2.103e-12

Sammenlign med estimaterne fra tabellen:

Gruppe	α	β	σ^2
journalist	84.99521966	1.52956813	18.85369
universitetslærer	75.62986190	1.56238397	

Estimater i M_1

Hvis vi ønsker at få estimaterne for de oprindelige parametre, kan vi opnå dette ved at fitte modellen uden intercept og alder-leddet.

```
LM_Blodtryk_M1_nooverparm <- lm(blodtryk~0+stilling+alder:stilling,data=Blodtryk)
```

Parametertabellen bliver da

```
Call:
lm(formula = blodtryk ~ 0 + stilling + alder:stilling, data = Blodtryk)
```

Residuals:

Min	1Q	Median	3Q	Max
-8.644	-3.019	1.201	1.785	7.219

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
stillingJournalist	84.9952	7.7426	10.978	7.71e-11	***
stillingUnderviser	75.6299	10.1296	7.466	1.05e-07	***
stillingJournalist:alder	1.5296	0.1351	11.322	4.12e-11	***
stillingUnderviser:alder	1.5624	0.1789	8.732	6.47e-09	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 4.342 on 24 degrees of freedom

Multiple R-squared: 0.9994, Adjusted R-squared: 0.9993

F-statistic: 1.045e+04 on 4 and 24 DF, p-value: < 2.2e-16

Modeller og hypoteser

Delmodeller af M_1



Hvilken af de to hypoteser $H_{02} : \alpha_i = \alpha$ og $H_{02}^* : \beta_i = \beta$, der skal testes afhænger af den faglige sammenhæng.

For dette datasæt må det være faglige og ikke statistiske grunde, der afgør valget mellem de to modeller. Det skal vi ikke komme ind på her, men i første omgang antage, at vi foretrækker H_{02} , dvs. testet fra M_1 til M_2 .

Test: $M_1 \rightarrow M_2 - H_{02} : \alpha_h = \alpha$

Det fremgår af parametertabellen fra `summary(LM_Blodtryk_M1)`, at vi godt kan acceptere H_{02} idet linjen ud for `stillingUnderviser` fortæller os at testsandsynligheden for hypotesen $H : \zeta_{\text{underviser}} = 0$ er 0.470 og da $\zeta_{\text{underviser}} = \alpha_2 - \alpha_1$ betyder det netop at der er ens afskæring i modellen.

Vi kan også teste hypotesen med `anova` ved først at fitte M_2 :

```
LM_BlodTryk_M2 <- lm(blodtryk~1+alder+alder:stilling,data=Blodtryk)
```

Bemærk at `stilling` er fjernet så modelformlen kan læses som

$$\alpha \cdot 1 + \beta \cdot \text{alder} + \eta_{\text{stl}} \cdot \text{alder} \quad \text{stl} \in \{\text{journalist}, \text{underviser}\}.$$

hvor parameteren ζ_{stl} er fjernet fra det tidligere udtryk.

Køres `anova(LM_BlodTryk_M2, LM_BlodTryk_M1)` fås

Analysis of Variance Table

```
Model 1: blodtryk ~ 1 + alder + alder:stilling
Model 2: blodtryk ~ 1 + stilling + alder + alder:stilling
  Res.Df    RSS Df Sum of Sq    F Pr(>F)
1      25 462.66
2      24 452.49  1    10.173 0.5396 0.4697
```

Bemærk at $t \text{ value}^2 = t(\mathbf{x})^2 = (-0.735)^2 \approx 0.5396 = F$

Estimater i M_2

Parametertabellen for M_2 fås ved at køre

summary (LM.Blodtryk_M2) fås parametertabellen:

```
Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)      81.54148     6.09451  13.379 6.74e-13 ***
alder             1.58910     0.10709   14.839 6.69e-14 ***
alder:stillingUnderviser -0.13049     0.02867   -4.551 0.000119 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.302 on 25 degrees of freedom
Multiple R-squared:  0.9028,    Adjusted R-squared:  0.895
F-statistic: 116.1 on 2 and 25 DF,  p-value: 2.225e-13
```

hvilket svarer til estimaterne

<i>Gruppe</i>	α	β	σ^2
<i>journalist</i>	81.54148011	1.58909585	18.50645
<i>universitetslærer</i>		1.45860666	

Tabel 1: Estimaterne for parametrene i modellen M_2 .

Test: $M_2 \rightarrow M_3 - H_{03} : \beta_h = \beta$

Det fremgår af linjen `alder:stillingUnderviser` at denne hypotese afvises. Det kan også bekræftes ved følgende kørsel af `anova` :

```
LM_Blodtryk_M3 <- lm(blodtryk~1+alder,data=Blodtryk)
anova(LM_Blodtryk_M3,LM_Blodtryk_M2)
```

med output

Analysis of Variance Table

Model 1: blodtryk ~ 1 + alder


Model 2: blodtryk ~ 1 + alder + alder:stilling

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	26	845.97				
2	25	462.66	1	383.31	20.712	0.0001193 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Modeller og hypoteser

For illustrationens skyld, tester vi nu efter følgende plan:



Figur 2: Undermodeller og hypoteser i lineær regression.

Test: $M_1 \rightarrow M_2^* - H_{02}^* : \beta_i = \beta$

Vi ved fra parameter Tabellen fra `summary(LM_Blodtryk_M1)` at hypotesen accepteres med en p -værdi på 0.885.

Vi kan også se det ved at fitte M_2^* med

```
LM_Blodtryk_M2star <- lm(blodtryk~1+stilling+alder, data=Blodtryk)
```

Leddene `alder:stilling` som svarer til η_{stl} er fjernet fra modelformlen. Det betyder svarer til at

$$\alpha \cdot 1 + \zeta_{stl} + \beta \cdot alder + \eta_{stl} \cdot alder \quad stl \in \{\text{journalist, underviser}\}.$$

bliver til

$$\alpha \cdot 1 + \zeta_{stl} + \beta \cdot alder \quad stl \in \{\text{journalist, underviser}\}.$$

Køres `anova(LM_Blodtryk_M2star, LM_Blodtryk_M1)` fås variansanalysetabellen

Analysis of Variance Table

Model 1: blodtryk ~ 1 + stilling + alder

Model 2: blodtryk ~ 1 + stilling + alder + alder:stilling

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	25	452.89				
2	24	452.49	1	0.40394	0.0214	0.8849

Test: $M_1 \rightarrow M_2^* - H_{02}^* : \beta_i = \beta$

Parametertabellen for **summary** (LM_Blodtryk_M2star) bliver

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	84.32064421	6.09856330	13.82631	3.2555e-13 ***
stillingUnderviser	-7.51476484	1.61325341	-4.65814	9.0379e-05 ***
alder	1.54148319	0.10568193	14.58606	9.8526e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.256254 on 25 degrees of freedom

Multiple R-squared: 0.90482708, Adjusted R-squared: 0.89721324

F-statistic: 118.83988 on 2 and 25 DF, p-value: 1.7037957e-13


hvilket svarer til

Gruppe	α	β	σ^2
<i>journalist</i>	84.32064422	1.54148319	18.11570
<i>universitetslærer</i>	76.80587938		

Tabel 2: Estimer for parametrene i modellen M_2^* .


Vi ser at parametertabellen at yderligere reduktion ikke er mulig.

Indtegnede regressionlinjer




Figur 3: Estimerede regressionlinjer i M_1

Indtegnede regressionslinjer




Figur 4: Estimerede regressionslinjer i modellen M_2 : samme afskæring. 23/29

Indtegnede regressionlinjer



Figur 5: Estimerede regressionlinjer i M_2^* : parallelle regressionslinjer

Indtegnede regressionslinjer



Figur 6: Regressionslinjer i modellen M_3 : sammenfaldende regressionslinjer. Det fremgår klart, at modellen er urimelig, idet de to professioner overvejende ligger på hver sin side af regressionslinjen.

Parametriseringer

Nedenfor ses yderligere parametriseringer for gruppespecifik regression:

Model	Modelformel	Parametre
M_1	$gr * t$	$(\alpha_1, \alpha_2 - \alpha_1, \dots, \alpha_k - \alpha_1, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$
M_1	$gr + t + gr:t$	$(\alpha_1, \alpha_2 - \alpha_1, \dots, \alpha_k - \alpha_1, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$
M_1	$0 + gr + gr:t$	$(\alpha_1, \alpha_2, \dots, \alpha_k, \beta_1, \beta_2, \dots, \beta_k)$
M_1	$0 + gr + t + gr:t$	$(\alpha_1, \alpha_2, \dots, \alpha_k, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$
M_2	$gr + t$	$(\alpha_1, \alpha_2 - \alpha_1, \dots, \alpha_k - \alpha_1, \beta)$
M_2	$0 + gr + t$	$(\alpha_1, \alpha_2, \dots, \alpha_k, \beta)$
M_2^*	$t + gr:t$	$(\alpha, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$
M_2^*	$gr:t$	$(\alpha, \beta_1, \beta_2, \dots, \beta_k)$
M_3	t	(α, β)

Variansanalysetabel

Vi bruger primært **anova** til undersøge reduktionen fra en lineær normal model til en undermodel.

Køres **anova** med én fittet model, hvor modelformlen er

$$x \sim A_k + A_{k-1} + \dots + A_i + \dots + A_2 + A_1$$

Laves en variansanalysetabel med hvis indhold er

Analysis of Variance Table

Response: x

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
A_k	$d_k - d_{k+1}$	$\ P_k(\mathbf{x}) - P_{k+1}(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	(*)
A_{k-1}	$d_{k-1} - d_k$	$\ P_{k-1}(\mathbf{x}) - P_k(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
A_i	$d_i - d_{i+1}$	$\ P_i(\mathbf{x}) - P_{i+1}(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
A_1	$d_1 - d_2$	$\ P_1(\mathbf{x}) - P_2(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	

Variansanalysetabel

Variansanalysetabellen kan give et groft overblik over en model reduktion af formen

$$M_1 \rightarrow M_2 \rightarrow \dots \rightarrow M_k \rightarrow M_{k+1}$$

hvor

$$M_1: \quad x \sim A_k + A_{k-1} + \dots + A_1 + \dots + A_2 + A_1$$

$$M_2: \quad x \sim A_k + A_{k-1} + \dots + A_1 + \dots + A_2$$

$\vdots$

$$M_i: \quad x \sim A_k + A_{k-1} + \dots + A_1$$

$\vdots$

$$M_k: \quad x \sim A_k$$

$$M_{k+1}: \quad x \sim 1$$

Det vil sige, hvor der successivt fjernes led fra højre mod venstre i modelformlen. Man skal dog være opmærksom på at det er variansskønnet s_1^2 fra den fulde model der bruges når F -teststørrelserne beregnes, således at p -værdierne til højre ikke svarer til de værdier, man vil beregne, hvis man løbende opdaterer sin model.

Køres følgende kode med M_1 :

```
LM_Blodtryk_M1 <- lm(blodtryk~1+stilling+alder+alder:stilling, data=Blodtryk)
anova(LM_Blodtryk_M1)
```

fås variansanalysetabellen

Analysis of Variance Table

Response: blodtryk

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
stilling	1	451.6	451.6	23.9509	5.44e-05	***
alder	1	3854.2	3854.2	204.4254	3.07e-13	***
stilling:alder	1	0.4	0.4	0.0214	0.8849	
Residuals	24	452.5	18.9			

Læses R-udskriften nedefra, at vi godt kan reducere fra M_1 til M_2^* men at vi næppe kan reducere til en model hvor **alder** ikke er med.

Matematisk Statistik

Multipel regression

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Multipel regression

I simpel lineær regression betragtede vi en situation med én responsvariabel og én forklarende variabel. Data bestod af talpar:

$$(t_1, x_1), (t_2, x_2), \dots, (t_n, x_n)$$

I Multipel regression betragter vi modeller, hvor der er flere (d) forklarende variable.

Data består af $(d+1)$ -tupler:

$$(t_{11}, \dots, t_{1d}, x_1), (t_{21}, \dots, t_{2d}, x_1), \dots, (t_{n1}, \dots, t_{nd}, x_n)$$

Vi indfører

$$\mathbf{t}_{(j)} = (t_{1j}, t_{2j}, \dots, t_{nj})^* \in \mathbb{R}^n \quad \text{og} \quad \mathbf{t}_i = (t_{i1}, t_{i2}, \dots, t_{id})^* \in \mathbb{R}^d$$

og kan skrive datasættet som

$$(\mathbf{t}_1^*, x_1), (\mathbf{t}_2^*, x_2), \dots, (\mathbf{t}_n^*, x_n)$$

Multipel regression

Modellen er at x_i erne ud udfald X_i , $i = 1, \dots, n$, som er uafhængige stokastiske variable, der opfylder

$$M_1 : X_i \sim N(\alpha + t_{i1} \beta_1 + \dots + t_{id} \beta_d, \sigma^2), \quad i = 1, \dots, n.$$

De forklarende variable kaldes også *regressionsvariable*, og de ukendte parametre $\beta_1, \dots, \beta_d$ kaldes *regressionskoefficienter*.

- *Linearitet*: Middelværdien af responsen er en lineær funktion af de forklarende variable.
- *Varianshomogenitet*: Variansen af X_i er identisk for alle i og afhænger ikke af t_i , $i = 1, \dots, n$.
- *Normalfordeling*: X_i , $i = 1, \dots, n$ er normalfordelte.
- *Uafhængighed*: $X_1, \dots, X_n$ er uafhængige.

Modelkontrollen foretages ved hjælp af kontroltegninger.

Multipel regression - Eksempel 5.9

Fagligt problem

Hvordan hænger volumen sammen med diameter og højde for kirsebærtræer?

Data


Som datasæt benyttede det i `R` indbyggede `trees` data. Datasættet indeholder målinger af diameter, højde og volumen for 31 fældede kirsebærtræer.

log Volume er responsen.

log Diameter og *Log Height* er forklarende variable.

Multipel regression - Eksempel 5.9

Først tegnes scatterplots for de tre par af variable.



Vi bemærker at *log Diameter* beskriver *log Volumen* godt, men hældningen for *log Volume* på *log Diameter* estimeres til 2.2.

Endvidere fremstår *log Diameter* og *Log Height* korrelerede.

I Afsnit 1.2 indførte vi den *empiriske fordelings funktion* $\hat{F}_n$ svarende til observationerne $x_1, x_2, \dots, x_n \in \mathbb{R}$:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{(-\infty, x]}(x_i).$$

Denne giver os den *empiriske fordeling* knyttet til $x_1, x_2, \dots, x_n$. Mere generelt kan vi for en følge $\mathbf{x}_1, \dots, \mathbf{x}_n$ i $\mathbb{R}^k$ betragte det til følgen hørende *empiriske mål* ved

$$\mathbb{P}_e(\cdot) = \frac{1}{n} \sum_{i=1}^n \delta_{\mathbf{x}_i}(\cdot),$$

hvor for $\mathbf{x} \in \mathbb{R}^k$, $\delta_{\mathbf{x}}(\cdot)$ betegner *punktmålet*: $\delta_{\mathbf{x}}(A) = \mathbb{1}_A(\mathbf{x})$, $A \subseteq \mathbb{R}^k$.

Hvis $\mathbf{X}$ er en stokastisk vektor som følger den empiriske fordeling for talfølgen $\mathbf{x}_1, \dots, \mathbf{x}_n$ så gælder

$$\mathbb{P}(\mathbf{X} = \mathbf{x}_i) = \frac{\#\{j \in \{1, 2, \dots, n\} \mid \mathbf{x}_j = \mathbf{x}_i\}}{n}.$$

Specielt gælder at hvis alle $\mathbf{x}_i$ -erne er forskellige er $\mathbb{P}(\mathbf{X} = \mathbf{x}_i) = 1/n$.

Hvis vi betragter en følge $\mathbf{x} = x_1, \dots, x_n$ af reelle tal samt en stokastisk variabel X med den tilknyttede empiriske fordeling gælder

$$\mathbb{E} X = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}. \quad \text{og} \quad \mathbb{V}\text{ar } X = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \text{SSD}_{\mathbf{x}}.$$

Vi betragter nu en følge $(x_1, y_1), \dots, (x_n, y_n)$ i $\mathbb{R}^2$ og lader (X, Y) betegne en stokastisk vektor, hvis fordeling er den tilknyttede empiriske fordeling.

Så gælder at fordelingen af X (henholdsvis Y) er den empiriske fordeling for følgen $x_1, \dots, x_n$ (henholdsvis $y_1, \dots, y_n$).

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}),$$

samt at korrelationen (den *empiriske korrelation*) mellem X og Y er

$$\text{Cor}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\text{SPD}_{\mathbf{xy}}}{\sqrt{\text{SSD}_{\mathbf{x}} \text{SSD}_{\mathbf{y}}}} \stackrel{\text{def}}{=} r_{\mathbf{xy}}.$$

For data fra en lineær regressionsmodel (t_i, x_i) ser vi

$$\hat{\beta} = \frac{\sqrt{\text{SSD}_{\mathbf{x}}}}{\sqrt{\text{SSD}_{\mathbf{t}}}} r_{\mathbf{tx}} = \frac{\sigma_{\mathbf{x}}}{\sigma_{\mathbf{t}}} r_{\mathbf{tx}},$$

hvor $\sigma_{\mathbf{x}} = \sqrt{\text{SSD}_{\mathbf{x}}/n}$ og $\sigma_{\mathbf{t}} = \sqrt{\text{SSD}_{\mathbf{t}}/n}$.

Multipel regression - Eksempel 5.9

Lader vi x_i betegne den i -te værdi af *log Volume* og t_{i1} , t_{i2} tilsvarende betegne henholdsvis *log Diameter* og *log Height*, betragter vi modellen:

$$M_1 : X_i \sim N(\alpha + \beta_1 t_{i1} + \beta_2 t_{i2}, \sigma^2), \quad i = 1, \dots, n, \quad + \text{ uafhængighed.}$$



Eller: $\log \text{Volume}_i \sim N(\xi_i, \sigma^2)$ hvor

$$\xi_i = \alpha + \beta_{\log \text{Diameter}} \log \text{Diameter}_i + \beta_{\log \text{Height}} \log \text{Height}_i.$$

Først ønskes kontroltegninger. Data indlæses og M_1 fittes:

```
trees$LogDiameter = log(trees$Girth)
trees$LogHeight = log(trees$Height)
trees$LogVolume = log(trees$Volume)
lmfit <- lm(LogVolume ~ LogDiameter + LogHeight, data=trees)
```

Mupel regression - Eksempel 5.9



Residualer og prædikterede værdier findes ved hjælp af

```
residualer <- residuals(lmfit)
prædikterede_værdier <- predict(lmfit)
stud_resid <- rstandard(lmfit)
```

Multipel regression - Eksempel 5.9

Parameterestimer og tilhørende tests findes ved hjælp af parametertabellen fra `summary(lmfit)` :

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -6.63162    0.79979  -8.292 5.06e-09 ***
LogDiameter  1.98265    0.07501  26.432 < 2e-16 ***
LogHeight    1.11712    0.20444   5.464 7.81e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.08139 on 28 degrees of freedom
Multiple R-squared:  0.9777,    Adjusted R-squared:  0.9761
F-statistic: 613.2 on 2 and 28 DF,  p-value: < 2.2e-16
```

Vi aflæser at

$$\hat{\alpha} = -6.63162 \quad \hat{\beta}_{\text{LogDiameter}} = 1.98265 \quad \hat{\beta}_{\text{LogHeight}} = 1.11712$$

hvilket svarer til at *Volumen* cirka er proportional med $\text{Diameter}^2 \text{Højde}$.

Multipel regression - Eksempel 5.9

Prædiktions- og konfidensintervaller findes som for simpel lineær regression:


```
nytData = data.frame(LogDiameter=c(2.5,2.2),LogHeight=c(4.3,4.1))  
predict(lmfit,nytData,interval="confidence")  
predict(lmfit,nytData,interval="prediction")
```

Output:

```
> predict(lmfit,nytData,interval="confidence")  
      fit      lwr      upr  
1 3.128638 3.097052 3.160224  
2 2.310418 2.224244 2.396593  
> predict(lmfit,nytData,interval="prediction")  
      fit      lwr      upr  
1 3.128638 2.958960 3.298316  
2 2.310418 2.122752 2.498085
```

Multipel regression

Multipel regression: auktionspriser på bornholmerure



Auktionspris for bornholmerure


Ønsker tommelfingerregel for pris af bornholmerure

Hvordan skal vi beskrive pris ud fra *alder* på ur og *bydere* til auktion ?

Data for 32 bornholmerure			
Nummer	Alder (år)	Antal Bydere	Pris (pund)
1	127	13	1235
2	115	12	1080
⋮			
31	194	5	1356
32	168	7	1262

Plot af data

Respons: pris, Forklarende variable: alder, byder



Punkter med numerisk største residualer ved regression af pris på alder er markeret.

Afvielser ved regression af *pris* på *alder* kan måske forklares ved antallet *bydere*

alder og *bydere* tilsammen vil nok give bedre beskrivelse af data end *alder* alene.

Regression

Model: $\text{Pris}_i \sim N(\xi_i, \sigma^2)$

data er normalfordelt med ens varianser

$\xi_i = \alpha + \beta_{\text{alder}} \cdot \text{alder}_i + \beta_{\text{byder}} \cdot \text{byder}_i$ (multipel regression)

Fittede værdier: $\hat{\xi}_i = \hat{x}_i = \hat{\alpha} + \hat{\beta}_{\text{alder}} \cdot \text{alder}_i + \hat{\beta}_{\text{byder}} \cdot \text{byder}_i$,

Residual: $r_i = x_i - \hat{\xi}_i$





alder og byder er *regressionsvariable*

Kørsel i **R**: `lm (pris~alder+byder)`

Residualplot fra pris~alder+byder

Forventede: $\hat{\xi}_i = \hat{\alpha} + \hat{\beta}_{\text{alder}} \cdot \text{alder}_i + \hat{\beta}_{\text{byder}} \cdot \text{byder}_i$,

Residual: $r_i = \text{pris}_i - \hat{\xi}_i$



Spredningen i den multiple regressionsmodel estimeres til 133.4847.

Parametertabel

Model: $\text{pris}_i \sim N(\alpha + \beta_{\text{alder}} \cdot \text{alder}_i + \beta_{\text{byder}} \cdot \text{byder}_i, \sigma^2)$

R: `lm(pris~alder+byder)`

`summary(lmfit)`

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -1338.9513    173.8095  -7.704 1.71e-08 ***
alder         12.7406      0.9047   14.082 1.69e-14 ***
bydere        85.9530      8.7285    9.847 9.34e-11 ***
Residual standard error: 133.5 on 29 degrees of freedom
```


Intercept: $\hat{\alpha}$, alder: $\hat{\beta}_{\text{alder}}$, byder: $\hat{\beta}_{\text{byder}}$

T-test: både alder og byder er vigtige for at beskrive data

```
confint(lmfit)
              2.5 %      97.5 %
(Intercept) -1694.43162 -983.47106
alder         10.89017   14.59098
bydere        68.10115  103.80482
```

Kan vi gøre det bedre ?

Hvis vi opdeler i grupper baseret på antal bydere ser vi følgende:



Ikke additivitet: tyder på interaktion

Inkludere interaktion

Model: $\text{Pris}_i \sim N(\alpha + \beta_{\text{alder}} \cdot \text{alder}_i + \beta_{\text{byder}} \cdot \text{byder}_i + \beta_{AB} AB_i, \sigma^2)$

$$AB_i = \text{alder}_i \cdot \text{byder}_i$$

```
AB = alder*bydere  
lmfit = lm(pris~alder+bydere+AB)  
summary(lmfit)
```

Coefficients:





	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	320.4580	295.1413	1.086	0.28684	
alder	0.8781	2.0322	0.432	0.66896	
bydere	-93.2648	29.8916	-3.120	0.00416	**
AB	1.2978	0.2123	6.112	1.35e-06	***

Residual standard error: 88.91 on 28 degrees of freedom

Vi bemærker at den nye regressionskoefficient er signifikant og at spredningsskønnet går fra 133 til 88.

Residualplot fra pris~alder+byder+AB

Forventede: $\hat{\xi}_i = \hat{\alpha} + \hat{\beta}_{\text{alder}} \cdot \text{alder}_i + \hat{\beta}_{\text{byder}} \cdot \text{byder}_i + \hat{\beta}_{\text{AB}} \cdot \text{AB}_i$



Model selektion

Vi vil omtale to metoder til *model selektion* (variabel selektion):

- Backward-selektion
- Forward-selektion

Backward-selektion: Opstil “fuld model” og reducer i denne.

Forward-selektion: Byg model op “fra bunden”.

Flere andre metoder, f.eks.: *Best-Subset Selection* og *LASSO-regression*.

Backward-selektion

Ved **Backward-selektion** forstås følgende procedure:

I hvert trin køres `summary(lm(modelformel))` for den aktuelle model. Den største p -værdi blandt t -testene, for at en regressionskoefficient er nul, identificeres. Hvis denne p -værdi er større end en selvvalgt grænse (for eksempel 0.05), fjernes den tilhørende regressionsvariabel fra modellen. Proceduren stopper, når ingen af p -værdierne er over grænsen, og den tilhørende model kaldes slutmodellen.

Backward-selektion

Analyse af nedsivnings-data.



Nedsivningsdata

Patle, G. T., et al. (2018). *Geology, Ecology, and Landscapes*

Fagligt problem: Vandnedsivning er en vigtig parameter for udnyttelse af jord, og skal kunne beskrive hvis man ønsker forudsige hvor meget der skal vandes.

Respons: Infiltration Rate (IR) (nedsivning)

Regressionsvariable: Sand, Silt, BD (bulk density), PD (particle density), MC (moisture content), OC (organic carbon)


Sa, Si, BD, PD, MC, OC

Backward selection: inkluder alle 6 variable, fjern de “overflødige”

Forward selection: inkluder variable enkeltvis sålænge det giver forbedring

OBS: 6 forklarende variable, men kun $n = 25$ observationer.

Figur med data. Farve fra Sa-IR relation



R-kode: Backward selection

Vi fitter modellen alle 6 variable og betragter parametertabellen:

```
summary( lm(IR~Sa+Si+BD+PD+MC+OC) )
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-58.6841	18.0818	-3.245	0.00449	**
Sa	0.7766	0.1500	5.178	6.33e-05	***
Si	0.1483	0.2486	0.596	0.55835	
BD	-13.8184	5.5728	-2.480	0.02327	*
PD	3.1628	2.5295	1.250	0.22717	
MC	0.3375	0.1498	2.253	0.03698	*
OC	31.5894	33.9847	0.930	0.36492	

Residual standard error: 2.428 on 18 degrees of freedom
Multiple R-squared: 0.7776, Adjusted R-squared: 0.7035

Vi *vælger* at fjerne `Si`, som har den højeste p -værdi for hypotesen $\beta_{\text{variabel}} = 0$

R-kode, trin 2

```
summary(lm(IR~Sa+BD+PD+MC+OC))
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-55.0772	16.7489	-3.288	0.00386	**
Sa	0.7097	0.0978	7.256	6.92e-07	***
BD	-14.2181	5.4378	-2.615	0.01704	*
PD	3.0177	2.4747	1.219	0.23761	
MC	0.3688	0.1379	2.674	0.01502	*
OC	42.5031	28.1472	1.510	0.14749	

Residual standard error: 2.386 on 19 degrees of freedom
Multiple R-squared: 0.7732, Adjusted R-squared: 0.7136

Vi *vælger* at fjerne PD: p -værdi = 0.24

R-kode, trin 3

```
summary(lm(IR~Sa+BD+MC+OC))
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-53.00517	16.86407	-3.143	0.00512	**
Sa	0.69996	0.09866	7.095	7.07e-07	***
BD	-14.10503	5.50275	-2.563	0.01854	*
MC	0.36462	0.13955	2.613	0.01666	*
OC	60.96554	24.01541	2.539	0.01955	*

Residual standard error: 2.415 on 20 degrees of freedom
Multiple R-squared: 0.7555, Adjusted R-squared: 0.7066

Ved grænse på 0.05: fjerner ikke flere led

Slutmodel $E(IR) = \alpha + \beta_{Sa} \cdot Sa + \beta_{BD} \cdot BD + \beta_{MC} \cdot MC + \beta_{OC} \cdot OC$

Skøn over spredning σ : 2.42

Test fra startmodel til slutmodel:

```
anova(lm(IR~Sa+BD+MC+OC), lm(IR~Sa+Si+BD+PD+MC+OC))
```

p -værdi = 0.4256

Bekymring

Fire variable, men kun 25 observationer: måske overfitting

Tre variable er kun svagt signifikante

Prøve med lavere grænse: 0.01

```
anova(lm(IR~Sa+BD+MC+OC))
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-53.00517	16.86407	-3.143	0.00512	**
Sa	0.69996	0.09866	7.095	7.07e-07	***
BD	-14.10503	5.50275	-2.563	0.01854	*
MC	0.36462	0.13955	2.613	0.01666	*
OC	60.96554	24.01541	2.539	0.01955	*

Residual standard error: 2.415 on 20 degrees of freedom
Multiple R-squared: 0.7555, Adjusted R-squared: 0.7066

Vi *vælger* at fjerne OC : p -værdi = 0.020

R-kode, trin 4

```
anova(lm(IR~Sa+BD+MC))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-21.9224	13.0133	-1.685	0.1069
Sa	0.6449	0.1080	5.971	6.31e-06 ***
BD	-15.9413	6.1214	-2.604	0.0166 *
MC	0.2291	0.1447	1.584	0.1282

Residual standard error: 2.71 on 21 degrees of freedom
Multiple R-squared: 0.6767, Adjusted R-squared: 0.6305

Vi *vælger* at fjerne MC : p -værdi = 0.13

R-kode, trin 5

```
anova (lm (IR~Sa+BD))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-14.5180	12.5536	-1.156	0.2599
Sa	0.5697	0.1003	5.682	1.03e-05 ***
BD	-13.5907	6.1389	-2.214	0.0375 *

Residual standard error: 2.801 on 22 degrees of freedom
Multiple R-squared: 0.6381, Adjusted R-squared: 0.6052

Vi *vælger* at beholde BD da modellen kun har to led

Slutmodel $E(IR) = \alpha + \beta_{Sa} \cdot Sa + \beta_{BD} \cdot BD$

Skøn over spredning σ : 2.80

Test fra startmodel til slutmodel:

```
anova (lm (IR~Sa+BD) , lm (IR~Sa+Si+BD+PD+MC+OC) )
```

p -værdi = 0.06

Fortolkning af slutmodel


Variablen S_a angiver procentdel af sand:

jo mere sand jo nemmere trænger vand ned

Variablen BD angiver bulk density: vægt divideret med volumen af jordprøve

jo større tæthed jo sværere for vandet at trænge ned

Modelkontrol. Modelformel: $IR \sim Sa + BD$



Hvor god er modellen ?

Kan vi forudsige middel-nedsivningsraten for et nyt datasæt med værdierne:

$(\tilde{S}a, \tilde{B}D)$?

Simpel lineær regression: “linjens værdi i et punkt”

Multipel regression: *prædikteret værdi*:

$$\hat{\xi}^P = \hat{x} = -14.52 + 0.57 \cdot \tilde{S}a - 13.59 \cdot \tilde{B}D$$

Konfidensinterval for ξ^P

Prædiktionsinterval for ny måling: $\hat{x} + \text{støj}$

Prædiktion, beregning i R

Eksempel:

Udelad obs nummer 25, genestimer model, lav prædiktion

```
IR1=IR[-25]; Sa1=Sa[-25]; BD1=BD[-25];  
  
lmfit=lm(IR1~Sa1+BD1)  
NyData=data.frame(Sa1=Sa[25],BD1=BD[25])
```

```
predict(lmfit,NyData,interval="confidence")
```

giver interval: [9.1, 13.7]

```
predict(lmfit,NyData,interval="prediction")
```

giver interval: [5.2, 17.5]

observeret værdi: 15.3

Backward-selektion, Eksempel 5.10

Fagligt problem

Hvilke variable beskriver den globale temperatur?

Data


Respons:

Globale temperaturs afvigelse fra et 30 års gennemsnit for årene 1979 - 2010 (32 observationer)


Forklarende variable:

Målinger af CO_2 , solens udstråling, vulkanaktivitet og *El Niño*-effekten.

Backward-selektion, Eksempel 5.10




Temperatur (sort) og CO₂ (grøn).



Temperatur afsat mod CO₂.

Figur 1: Udvikling af temperatur og CO₂ fra 1979 til 2010.

Backward-selektion, Eksempel 5.10



Udvikling fra 1979 til 2010 af de fire forklarende variable fra Eksempel 5.10

Backward-selektion, Eksempel 5.10

Lad X være temperaturen, C mængden af CO_2 i atmosfæren, S solens udstråling, V vulkanaktiviteten og E El Niño-effekten.

Vi vil også inddrage interaktion, ved at medtage produkterne:

$$\begin{aligned}CS &= C \cdot S, & CV &= C \cdot V, & CE &= C \cdot E, \\SV &= S \cdot V, & SE &= S \cdot E, & VE &= V \cdot E.\end{aligned}$$

Med disse betegnelser kan vi opstille den multiple regressionsmodel som følger:

$$\begin{aligned}X_i &\sim N(\xi_i, \sigma^2), \quad i = 1, \dots, 32, \quad + \text{uafhængighed}, \\ \text{hvor} \quad \xi_i &= \alpha + \beta_C \cdot C_i + \beta_S \cdot S_i + \beta_V \cdot V_i + \beta_E \cdot E_i \\ &\quad + \beta_{CS} CS_i + \beta_{CV} CV_i + \beta_{CE} CE_i + \beta_{SV} SV_i \\ &\quad + \beta_{SE} SE_i + \beta_{VE} VE_i.\end{aligned}$$

Backward-selektion, Eksempel 5.10

Data indlæses fra *co2data.csv* til `co2data` og variablene standardiseres.

```
C = co2data$C; S = co2data$S; V = co2data$V; E = co2data$E; Temp = co2data$Temp;
C=(C-mean(C))/sd(C)
S=(S-mean(S))/sd(S)
V=(V-mean(V))/sd(V)
E=(E-mean(E))/sd(E)

CS=C*S; CV=C*V; CE=C*E; SV=S*V; SE=S*E; VE=V*E

lmfit <- lm(Temp ~ C + S + V + E + C + S + CV + CE + SV + SE + VE )
```

Backward-selektion, Eksempel 5.10

Køres `summary(lmfit)` fås parametertabellen:

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   30.363      1.803   16.841 1.13e-13 ***
C              15.464      1.547    9.996 1.95e-09 ***
S              8.067      1.766    4.568 0.000167 ***
V             14.453      4.371    3.307 0.003358 **
E              5.542      1.202    4.610 0.000151 ***
CS            -1.156      1.025   -1.128 0.272145
CV              3.602      2.151    1.674 0.108935
CE              1.609      1.434    1.122 0.274616
SV            -10.760      4.106   -2.620 0.015984 *
SE              1.424      1.315    1.083 0.291211
VE              1.200      2.320    0.517 0.610266
```

og vi ser at `VE` er første variabel der kan fjernes.

Backward-selektion, Eksempel 5.10

Slutmodellen bliver

$$X_i \sim N(\alpha + \beta_C C_i + \beta_S S_i + \beta_V V_i + \beta_E E_i + \beta_{SV} \cdot SV_i, \sigma^2), \quad i = 1, \dots, 32,$$

og p -værdien for reduktionen fra startmodel til slutmodel findes til 0.2137.

Parametrene i slutmodellen er:

	α	C	S	V	E	SV
Estimate	31.5334	16.1674	6.8994	12.3519	5.7220	-10.4519
Std. Error	1.3215	1.3633	1.6971	3.0498	1.1519	4.2719
ρ_{obs}	0.0000	0.0000	0.0004	0.0004	0.0000	0.0215

Den empiriske spredning på C er 15.3 så regressionskoefficienten for de ikke-standardiserede variable er $16.2/15.3 \approx 1$.

Forward-selektion

Vi betragter nu *forward-selektion*.


Ved forward-selektion forestiller os at vi starter med modellen for en normalfordelt observationsrække. Derefter tilføjer vi trinvis nye variable.

Proceduren kan beskrives som følger:

I hvert trin prøver man på skift at inkludere en af de variable, der endnu ikke er med i modellen. Fra parametertabellen, for modellen med den ekstra variabel inkluderet, findes spredningsskønnet $s(M)$ og p -værdien for test af hypotesen, at regressionskoefficienten hørende til den ekstra variabel er nul. Når alle variable er afprøvet, vælges den variabel med det laveste spredningsskøn, og hvis den tilhørende p -værdi er under en selvvalgt grænse (for eksempel 0.05), inkluderes variabelen i modellen, og forward-selektions proceduren fortsættes. Proceduren stopper, når p -værdien for den valgte variabel er over grænsen.

Illustration af forward-selektion

Forward stepwise selection example with 5 variables:



Forward-selektion på nedsivnings-data

Laver regression af IR på en enkelt variabel.

Først køres `summary(lm(IR~Sa))`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-36.8688	8.0691	-4.569	0.000136	***
Sa	0.5827	0.1083	5.383	1.81e-05	***

Residual standard error: 3.03 on 23 degrees of freedom

Dernæst køres `summary(lm(IR~Si))`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	13.1153	3.2181	4.076	0.000466	***
Si	-0.4677	0.2180	-2.146	0.042663	*

Residual standard error: 4.157 on 23 degrees of freedom

Variabel	Sa	Si	BD	PD	MC	OC
<i>p</i> -værdi	0.000	0.043	-	-	-	-
<i>s</i> (<i>M</i>)	3.030	4.157	-	-	-	-

Forward selection

Vi fortsætter med de resterende variable:

`lm(IR~Sa)` , `lm(IR~Sa)` , ..., `lm(IR~OC)` ,

Variabel	Sa	Si	BD	PD	MC	OC
p -værdi	0.000	0.043	0.110	0.396	0.292	0.294
$s(M)$	3.030	4.157	4.304	4.482	4.444	4.445

p -værdi: test for $\beta = 0$

$s(M)$: spredningsskøn

Vi *vælger* at inkludere variablen Sa

Forward-selektion på nedsivnings-data

Vi betragter dernæst modeller hvor Sa er med sammen med en af de andre variable ad gangen:

Først køres `summary(lm(IR~Sa + Si))`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-62.1123	14.6171	-4.249	0.000328	***
Sa	0.8315	0.1597	5.206	3.2e-05	***
Si	0.4733	0.2344	2.020	0.055774	.

Residual standard error: 2.845 on 22 degrees of freedom

Variabel	Sa	Si	BD	PD	MC	OC
<i>p</i> -værdi	*	0.056	-	-	-	-
<i>s</i> (<i>M</i>)	*	2.845	-	-	-	-

Dernæst køres `summary(lm(IR~Sa + BD))` og så fremdeles.

Forward-selektion på nedsivnings-data

Laver regression af IR på en enkelt variabel udover Sa

P -værdi: test for $\beta_{\text{variabel}} = 0$

`lm(IR~Sa+Si)` , `lm(IR~Sa+BD)` , ..., `lm(IR~Sa+OC)` ,

Variabel	Sa	Si	BD	PD	MC	OC
p -værdi	-	0.056	0.038	0.083	0.392	0.081
$s(M)$	-	2.845	2.801	2.888	3.045	2.887

Vi *vælger* at inkludere variabelen BD udover Sa

Forward selection

Laver regression af IR på en enkelt variabel udover Sa og BD, det vil sige at vi **summary** på følgende:

`lm(IR~Sa+BD+Si)` , `lm(IR~Sa+BD+PD)`

`lm(IR~Sa+BD+MC)` , `lm(IR~Sa+BD+OC)`

Variabel	Sa	Si	BD	PD	MC	OC
p -værdi	-	0.084	-	0.104	0.128	0.155
$s(M)$	-	2.666	-	2.689	2.710	2.730

Vi *inkluderer ikke* flere variable

Slutmodel Forward: Sa + BD

$$s(M_F) = 2.80$$

Slutmodel (5% grænse) Backward: Sa + BD + MC + OC

$$s(M_B) = 2.42$$

forward

forward funktionen fra *Rfunktioner.txt* kan benyttes:

```
bT = cbind(Sa, Si, BD, PD, MC, OC)
forward(bT, IR)
```

```
$sny
[1] 3.029664

$med
[1] 1

$pval
           [,1]
Intercept 0.0001362327
X          0.0000181329
```

Dernæst køres **forward**(bT, IR, c(1))

Køres

```
forward(bT, IR, c(1))
```

bliver output:

```
$sny
[1] 2.801384

$med
[1] 1 3

$pval
           [,1]
Intercept 0.2598898772
Sa         0.0000102851
BD         0.0375102028
```

Opsummering

Forward og backward selection giver generelt forskellige modeller

For nedsivningsdata: ingen af modellerne er “fantastisk”:

$$s/\text{mean}(\text{IR}) \approx 0.4$$

Stor spredning: svært at prædiktere nedsivning

Foregående eksamen viser at vi inden for multipel regression godt kan betragte forklarende variable, der er konstrueret som ikke-lineære funktioner af andre forklarende variable. Vi illustrerer dette med *polynomiel regression*.

På R-koden simuleres 30 uafhængige observatoier af t og x hvor


$$X = 3t^2 - 2t - 1 + N(0, 1),$$

```
set.seed(1)
n = 30
bt = seq(from = -1,to=1,length.out=n)
bx = 3*bt^2-2*bt-1 + rnorm(n)
```

x	t	t^2
3.37	-1.00	1.00
3.65	-0.93	0.87
2.12	-0.86	0.74
$\vdots$	$\vdots$	$\vdots$
0.42	1.00	1.00

Tabellen viser værdierne af x og t samt t^2 . Som det fremgår består t variabelen af 30 ækvidistante punkter i intervallet $[-3, 3]$.

På et scatterplot af t på x ses en tydelig kvadratisk sammenhæng. Vi ville ikke opstille en model for simpel lineær regression for dette datasæt.



Vi kan inkludere t^2 som forklarende variabel på flere måder. Funktionen `I` gør at vi kan lave aritmetiske operationer inde i selve modelformlen. Funktionen `poly` giver her et 2.grad polynomium. Funktionen giver *ortogonale* polynomier som default, derfor skrives `raw=TRUE` .

```
bt2 = bt^2
lmfit <- lm(bx~bt+bt2)
lmfit <- lm(bx~bt+I(bt^2))
lmfit <- lm(bx~poly(bt,2,raw=TRUE))
```

`summary(lmfit)` vil returnere det samme i alle tre tilfælde, bortset fra navngivningen af koefficienterne.


	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-0.7094	0.2553	-2.779	0.009814	**
bt	-2.1689	0.2849	-7.613	3.45e-08	***
I(bt^2)	2.4160	0.5345	4.520	0.000111	***

Vi ser, at det estimerede andengradspolynomium er

$$f(t) = -0.7094 - 2.1689 t + 2.4160 t^2,$$

samt at koefficienten til t^2 er signifikant.

Polynomiel regression kan let resultere i *overfitting*.



Til venstre er det estimerede 2.gradspolynomium indtegnet. På figuren til højre er et estimerede 10.gradspolynomium indtegnet.

Underfitting, overfitting og model selektion

Sande model: $E(X_i) = \alpha + \beta_1 t_i + \beta_1 t_i^2$

Fitter model: $E(X_i) = \alpha + \beta_1 t_i + \beta_2 t_i^2 + \cdots + \beta_k t_i^k$

Hvor skal k vælges, hvis f.eks. forward- og backward-selektion giver forskellige svar?

Både underfitting og overfitting er problematisk, men overfitting kan være sværere at "se":

Typisk: jo større k er, jo bedre et fit får vi: $s(M_k)$ er lille.

Husk

$$s^2 = \frac{1}{n-d} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Hvis $k = n$ er $s(M_k) = 0$!

Overfitting: problem

En god model skal kunne forudsige nye observationer.

Overfitting giver dårlig *predictor* (linear prediction function):

Generel formulering - vi betragter en multipel regressionsmodel:

Data: $x_i, t_{1i}, t_{2i}, \dots, t_{ki}, \quad i = 1, \dots, n$

Model: $E(X_i) = \alpha + \beta_1 t_{1i} + \beta_2 t_{2i} + \dots + \beta_k t_{ki}$

Fitted modellen kan vi finde estimator: $\hat{\alpha}, \hat{\beta}_1, \dots, \hat{\beta}_k, \quad s(M)$

En "predictor" returnerer estimeret middelværdi (prædikeret værdi) svarende til nye værdier $\tilde{t}_1, \tilde{t}_2, \dots, \tilde{t}_k$:

$$\text{Predictor}(\tilde{t}_1, \tilde{t}_2, \dots, \tilde{t}_k) = \hat{\alpha} + \hat{\beta}_1 \tilde{t}_1 + \dots + \hat{\beta}_k \tilde{t}_k$$

Predictor i polynomiell regression:

$$\text{Predictor}(\tilde{t}_{ny}) = \hat{\alpha} + \hat{\beta}_1 \tilde{t}_{ny} + \dots + \hat{\beta}_k \tilde{t}_{ny}^k$$

Beregning i R: benyt *predict*

Prædiktionsevne

$\hat{\beta}$ estimeres ud fra data (træningsdata)

Hvor gode er vi til at forudsige respons $\tilde{X}$ hørende til nye værdier $\tilde{t}_1, \dots, \tilde{t}_k$

Prædiktion: $\hat{\beta}_1 \tilde{t}_1 + \dots + \hat{\beta}_k \tilde{t}_k$

Idé: Vælge model, som er bedst til at prædiktere.

PrædiktionsMeanSquaredError: $E\{(\tilde{X} - (\hat{\beta}_1 \tilde{t}_1 + \dots + \hat{\beta}_k \tilde{t}_k))^2 | \text{data}\}$

$= E\{(\tilde{X} - (\beta_1 \tilde{t}_1 + \dots + \beta_k \tilde{t}_k) - ((\hat{\beta}_1 - \beta_1) \tilde{t}_1 + \dots + (\hat{\beta}_k - \beta_k) \tilde{t}_k))^2 | \text{data}\}$

$= \sigma^2 + \{(\hat{\beta}_1 - \beta_1) \tilde{t}_1 + \dots + (\hat{\beta}_k - \beta_k) \tilde{t}_k\}^2 = \sigma^2 + \{(\hat{\beta} - \beta)^T \tilde{\mathbf{t}}\}^2$

Kaldes *prædiktionsMSE* eller *prædiktionsvarsians*.

Angiver hvor gode vi er til prædiktere ny observation *for de specifikke værdier af $\tilde{t}_1, \dots, \tilde{t}_k$* .

Afhænger af de ukendte parametre.


Overfitting: problem

Hvis vi overfitter giver dette typisk en dårligere prediktor:

$E\{(X_{ny} - \text{Prediktor}(t_{ny}))^2\}$ bliver større

k=1	k=2	k = 3	k=4	k=5	k=6	k=8	k=12	k=15
0.832	0.049	0.0503	0.495	0.121	0.153	0.165	0.277	0.454

Betragter data fra Afsnit 5.7.1, k graden af fittet polynomium, t_{ny} uniform .



To problematikker:

Hvordan vælger vi en simpel model ? og Hvordan måler vi overfitting ?

Forslag

Beregn prædiktionsvarians (prædiktionsMSE) ud fra et *testsæt*
 $(\tilde{t}_{i1}, \dots, \tilde{t}_{ik}, \tilde{x}_i) \ i = 1, \dots, m$

Skøn over prædiktionsvariansen:

$$\frac{1}{m} \sum_{i=1}^m (\tilde{x}_i - (\hat{\beta}_1 \tilde{t}_{i1} + \dots + \hat{\beta}_k \tilde{t}_{ik}))^2$$

MEN: typisk har vi ikke et testsæt til rådighed

Alternativ: Dele oprindelige datasæt op i et "træningssæt" og et "testsæt"

crossvalidation

Træningssæt / testsæt

Træningssæt:

Data $x_1, \dots, x_n$ bruges til at estimere model

$$X_i \sim N(\alpha + \beta_1 t_{i1} + \dots + \beta_k t_{ik}, \sigma^2)$$

$t_1, \dots, t_k$: forklarende variable (regressionsvariable)

Testsæt: $\tilde{x}_i, \tilde{t}_{i1}, \dots, \tilde{t}_{ik}, i = 1, \dots, m$


data der IKKE blev brugt til at finde skøn $\hat{\alpha}, \hat{\beta}$

Beregn prædikterede værdier $\hat{x}_i = \hat{\alpha} + \hat{\beta}_1 \tilde{t}_{i1} + \dots + \hat{\beta}_k \tilde{t}_{ik}$

Skøn over prædiktionsspredning: $s_P = \sqrt{\frac{1}{m} \sum_{i=1}^m (\tilde{x}_i - \hat{x}_i)^2}$

Illustration af overfitting

1.-akse: antal variable i model; 2.-akse: hvor godt passer model til data



Blå kurve viser bedre og bedre tilpasning til trænings-data ved inkludering af flere variable

Rød kurve viser prædiktionsspredning på test-data

Testdata - crossvalidation

Hvordan vurderer vi om vi overfitter, hvis vi ikke har et test-datasæt ?

Crossvalidation: Data deles op i forskellige *træningssæt* og *testsæt*

Træningssættet bruges til at estimere parametre i model M

Testsættet bruges til at beregne prædikterede værdier $\tilde{\xi}_i^P(M)$ baseret på estimerede parametre fra træningssættet og de forklarende variable i testsættet, index i løber over testsæt

giver bidrag til prædiktionsvariansen på formen $(x_i - \hat{\xi}_i^P)^2$

Prædiktionsspredning ved crossvalidation: $s_{cv} = \sqrt{\frac{1}{m} \sum (x_i - \hat{\xi}_i^P)^2}$

m er antal led i summen

Eksempel: 5-fold crossvalidation

5-fold crossvalidation:

Betragt tilfælde med 50 observationer

Vi deler dem op i 5 blokke: 1-10, 11-20, 21-30, 31-40 og 41-50

1° estimerer model baseret på 1-40, tester på 41-50

2° estimerer model baseret på 1-30 + 41-50 og tester på 31-40


⋮

5° estimerer model baseret på 11-50 og tester på 1-10

I beregning af prædiktionsspredningen får vi nu 50 led

Eventuelt gentage flere gange med forskellige opdelinger.

Illustration of 5-fold crossvalidation



Leave one out crossvalidation

Leave one out crossvalidation (LOOCV):

Specialtilfælde af crossvalidation, hvor testsættet kun består af 1 observation:

- 1° observation i tages ud
- 2° model M estimeres fra de resterende $n - 1$ observationer
- 3° prædikteret værdi $\hat{x}^{-i}$ beregnes for den udeladte observation

Prædiktionsspredning ved crossvalidation

$$s_{cv} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}^{-i})^2}$$

Illustration of LOOCV



Beregning

Prædiktionsspredning ved crossvalidation : $s_{cv} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}^{-i})^2}$

Sætter vi

$$r^{-i} \stackrel{\text{def}}{=} x_i - \hat{x}^{-i} \quad i = 1, \dots, n$$

fås de *rå sletningsresidualer*.

Det kan vises at

$$r^{-i} = \frac{r_i}{1 - h_i}$$

hvor r_i er (det almindelige) i -te residual og h_i er *leverage* for den i -te observation.

For simpel lineær regression gælder der ifølge (4.10)

$$h_i = \frac{1}{n} + \frac{(t_i - \bar{t})^2}{SSD_t}.$$

For en fittet model kan vektoren $\mathbf{h} = (h_1, \dots, h_n)^*$ beregnes i **R** ved hjælp af

```
lm.influence(fit)$h
```

Prædiktionsspredningen kan derfor beregnes som

```
loocv=function(fit){  
  h=lm.influence(fit)$h  
  return(sqrt(mean((residuals(fit)/(1-h))^2)))  
}
```

Overfitting: eksempel

Sande model: $E(X_i) = \alpha + \beta_1 t_i$


Fitter model: $E(X_i) = \alpha + \beta_1 t_i + \beta_2 t_i^2 + \cdots + \beta_k t_i^k$

Typisk: jo større k er, jo bedre et fit får vi: $s(M_k)$ er lille


hvis $k = n$ er $s(M_k) = 0$!

Fitte polynomium: LOOCV


$k = 1$ $s = 2.84$ $scv = 3.18$




$k = 2$ $s = 2.86$ $scv = 3.25$




$k = 3$ $s = 1.99$ $scv = 3.01$




$k = 4$ $s = 2.18$ $scv = 9.39$



$k = 6$ $s = 1.68$ $scv = 324.25$




$k = 8$ $s = 1.07$ $scv = 224205.5$



Fitte 4.gradspolynomium: LOOCV

Fitter 4.gradspolynomium med et punkt udeladt



$$s_{cv}^2 = \frac{1}{10}((-9.2)^2 + (5.41)^2 + (-5.27)^2 + \dots + (-14.97)^2 + (22.62)^2) = 9.39^2$$

LOOCV for multipel regressionsmodel

Model: $X_i \sim N(\alpha + \beta_1 t_{i1} + \cdots + \beta_k t_{ik}, \sigma^2)$

Observation i udelades, model estimeres:

estimator: $\hat{\alpha}^{-i}, \hat{\beta}_1^{-i}, \dots, \hat{\beta}_k^{-i}$

Prædikteret værdi beregnes:

$$\hat{x}_i^{-i} = \hat{\alpha}^{-i} + \hat{\beta}_1^{-i} t_{i1} + \cdots + \hat{\beta}_k^{-i} t_{ik}$$

prædiktionsfejl: $x_i - \hat{x}_i^{-i}$

Prædiktionsspredning:

$$s_{cv} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i^{-i})^2}$$

LOOCV for nedsivnings-data

Respons: Infiltration Rate (IR)

Regressionsvariable: Sand, Silt, BD (bulk density), PD (particle density), MC (moisture content), OC (organic carbon)

Sa, Si, BD, PD, MC, OC

Backward selection: Sa+BD+MC+OC

$$s(M_B) = 2.42, \quad s_{cv}(M_B) = 3.02 \quad \text{lm}(\text{IR} \sim \text{Sa} + \text{BD} + \text{MC} + \text{OC})$$

Forward selection: Sa+BD

$$s(M_F) = 2.80, \quad s_{cv}(M_F) = 3.12 \quad \text{lm}(\text{IR} \sim \text{Sa} + \text{BD})$$

s_{cv} afspejler både usikkerhed i skøn $\hat{\xi}_i^{-i}$ og spredning σ i model

Begge modeller er lige gode, ingen tegn på overfitting

Konklusion

LOOCV i en multipel regressionsmodel er vist

I multiple regressionsmodeller med få variable bibringer crossvalidation ofte ikke noget nyt

Næste: Multipel regression med mange variable

Data

Data er analyseret i artiklen "Application of near-infrared reflectance spectroscopy to compositional analysis of biscuits and biscuit dough", Journal of the Science of Food and Agriculture, 1984

Ønsker at kunne prædiktere mængden af vand i dej ud fra gennemlysning med lys


NIR: Near Infrared Reflectance spectroscopy
måler refleksion ved 700 bølgelængder i intervallet 1100-2500 nm

Data: vektor x med vandindhold i $n = 39$ prøver

39×700 matrix med refleksioner
hver række giver spektrum for prøve, hver søjle er en forklarende variabel

multipl regression med 700 forklarende variable!


Tre spektre



Respons: Vandindhold. Forklarende variable: Bølgelængder.


Regression på individuelle spektre

$$\hat{\alpha} = -2.64 \quad \hat{\beta} = 42.16$$




Søjle 114

$$\hat{\alpha} = -2 \quad \hat{\beta} = 27.72$$




$$\hat{\alpha} = -4.8 \quad \hat{\beta} = 49.5$$



Søjle 85



$$\hat{\alpha} = -1.89 \quad \hat{\beta} = 18.43$$






Forward

Når antal forklarende variable er større end antal prøver:
de forventede værdier i multipel regresion = responsværdier
 $s^2(M) = 0$

Enten lægge restriktioner på $\hat{\beta}$ (ridge-regression,
LASSO-regression)
eller: forward selektion
nødvendigt med crossvalidation.



Vise beregninger til figur



Venstre figur: `sigma(lm(x~tj))`

Midterste figur: `sigma(lm(x~t114+tj))`

Højre figur:





`sigma(lm(x~t114+t85+t142+t285+t78+t75+tj))`

I alle figurer: $j = 1, \dots, 700$

Illustration af residualer

r1: residual fra $x \sim t114$, v1: residual fra $t85 \sim t114$

r2: residual fra $x \sim t85 + t114$, v1: residual fra $t142 \sim t85 + t114$



R-beregning: crossvalidation

OBS: ikke crossvalidation som for en given multipel regressionsmodel

LOOCV med j led i forward algoritme: Fjerner observation i fra datasæt, kører forward selektion på reducerede datasæt indtil j variable er inkluderet



Finde cross validation prædiktionspredning:

```
cvForward(T, x, m)
```

m : det maksimale antal led der ønskes undersøgt

R-beregning: crossvalidation

Figur for Dej-data



Crossvalidation prædiktionspredninger fra FWcrossval:

1	2	3	4	5	6	7	8	9	10
0.92	0.61	0.47	0.33	0.24	0.22	0.24	0.25	0.26	0.28

Tyder på at 6 variable er et godt valg


Prædiktionsspredning fra ægte testsæt

Der er indsamlet 31 nye prøver

Beregner prædiktionsspredning på disse baseret på forward selektion på oprindelige data (træningssæt) med 2 til 10 variable.

Antal	1	2	3	4	5	6	7	8	9	10
Variabelnummer	114	+85	+142	+285	+78	+75	+81	+206	+166	+205
Prædiktionsspredning	0.80	0.39	0.39	0.28	0.30	0.26	0.25	0.25	0.24	0.25

Tyder på at vi godt kan tage lidt flere end 6 variable



Matematisk Statistik

Multipel regression som lineær normal model

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Multipl regression

Når vi skal beskrive multipl regression som lineær normal model er det nyttigt at benytte følgende opskrivning:

$$M_1 : X_i \sim N(t_{i1}\beta_1 + t_{i2}\beta_2 + \cdots + t_{id}\beta_d, \sigma^2), \quad i = 1, \dots, n.$$

Hvis $t_{11} = t_{21} = \cdots = t_{n1} = 1$ fås et intercept-led som tidligere.

Sættes $\beta \stackrel{\text{def}}{=} (\beta_1, \beta_2, \dots, \beta_d)^*$ og $\mathbf{t}_i = (t_{i1}, t_{i2}, \dots, t_{id})^*$ kan modellen skrives

$$X_i \sim N(\mathbf{t}_i^* \beta, \sigma^2).$$

Designmatricen

Betragtes middelværdivektoren $\boldsymbol{\mu} = (\mathbb{E}[X_1], \mathbb{E}[X_2], \dots, \mathbb{E}[X_n])^*$ har vi

$$\boldsymbol{\mu} = \begin{pmatrix} \mathbf{t}_1^* \boldsymbol{\beta} \\ \vdots \\ \mathbf{t}_i^* \boldsymbol{\beta} \\ \vdots \\ \mathbf{t}_n^* \boldsymbol{\beta} \end{pmatrix} = \mathbf{T} \boldsymbol{\beta}$$

hvor $\mathbf{T}$ er $n \times d$ matricen, hvis i -te række er $\mathbf{t}_i^*$, det vil sige

$$\mathbf{T} \stackrel{\text{def}}{=} \left\{ \begin{pmatrix} \mathbf{t}_1^* \\ \vdots \\ \mathbf{t}_i^* \\ \vdots \\ \mathbf{t}_n^* \end{pmatrix} \right\}.$$

Vi vil antage at $d < n$ samt at $\mathbf{T}$ har fuld rang d . Matricen $\mathbf{T}$ kaldes en *designmatrix* eller en *modelmatrix*.

Designmatricen

Værdierne af den j -te forklarende variabel er:

$$\mathbf{t}_{(j)} = (t_{1j}, t_{2j}, \dots, t_{nj})^*.$$

og disse udgør *søjlerne* i *søjlerne* i $\mathbf{T}$:

$$\mathbf{T} = \{ \mathbf{t}_{(1)} , \mathbf{t}_{(2)} , \dots , \mathbf{t}_{(d)} \} .$$

Vi har dermed

$$\mu = \mathbf{T}\boldsymbol{\beta} = \mathbf{t}_{(1)}\beta_1 + \mathbf{t}_{(2)}\beta_2 + \dots + \mathbf{t}_{(d)}\beta_d .$$

Det betyder at modellen kan opfattes som en lineær normal model specificeret ved $L = \text{col}(\mathbf{T}) = \textit{søjlerummet}$ for $\mathbf{T}$

Designmatricen

For lineære normale modeller har vi generelt

$$\hat{\mu} = P(\mathbf{x}) \quad \text{og} \quad \hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2,$$

hvor $P(\mathbf{x})$ er *projektion* af $\mathbf{x}$ ned L . Projektionen kan udtrykkes ved hjælp af designmatricen: $P = \mathbf{T}(\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^*$.

I multipel regression gælder derfor

$$\hat{\mu} = \mathbf{T}(\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x} \quad \text{og} \quad \hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - \mathbf{T}(\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x}\|^2.$$

Maksimum likelihood estimat for β

Maksimum likelihood estimatet for β findes ved opskrive likelihoodfunktionen:

$$\begin{aligned} L(\beta, \sigma^2) &= L(\beta_1, \beta_2, \dots, \beta_d, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mathbf{t}_i^* \beta)^2} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mathbf{t}_i^* \beta)^2} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \mathbf{T}\beta\|^2}. \end{aligned}$$

Der gælder at

$$\|\mathbf{x} - \mathbf{T}\beta\|^2 = \|\mathbf{T}(\beta - \hat{\beta})\|^2 + k,$$

hvor $k \in \mathbb{R}$ ikke afhænger af β og

$$\hat{\beta} \stackrel{\text{def}}{=} (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x}$$

Vi ser dermed at $\hat{\beta}$ er maksimum likelihood esimatet for β .

Designmatricer for lineære normale modeller

Eksempler på designmatricer for forskellige modeller findes ved hjælp af afsnit 5.1:

- Én observationsrække kan specificeres ved $\mathbf{T} = \mathbf{1}$, hvor $\mathbf{1}$ blev defineret i Eksempel 5.1.
- To observationsrækker kan specificeres ved $\mathbf{T} = \{\mathbf{1}_1 \quad \mathbf{1}_2\}$ hvor $\mathbf{1}_1$ og $\mathbf{1}_2$ blev defineret i Eksempel 5.3
- k observationsrækker kan specificeres ved $\mathbf{T} = \{\mathbf{1}_1 \quad \mathbf{1}_2 \quad \dots \quad \mathbf{1}_k\}$ hvor $\mathbf{1}_i$ erne blev defineret i Eksempel 5.4
- Simpel lineær regression kan specificeres ved $\mathbf{T} = \{\mathbf{1} \quad \mathbf{t}\}$ hvor $\mathbf{t}$ blev defineret i Eksempel 5.6

Designmatricer er *ikke* unikke: Forskellige designmatricer kan svare til *forskellige parametriseringer* af *samme model*.

Designmatricen

Modellen for to observationsrækker, hvor x_{ij} er udfald af

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.}$$

svarer f.eks. til designmatricerne $\mathbf{T}$ og $\tilde{\mathbf{T}}$

$$\mathbf{T} = \{\mathbf{1}_1 \quad \mathbf{1}_2\} = \left\{ \begin{array}{cc} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 0 & 1 \\ \vdots & \vdots \\ 0 & 1 \end{array} \right\} \quad \tilde{\mathbf{T}} = \{\tilde{\mathbf{1}} \quad \mathbf{1}_2\} = \left\{ \begin{array}{cc} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{array} \right\} \quad \left. \begin{array}{l} \\ \\ \\ \\ \\ \\ \end{array} \right\} \begin{array}{l} n_1 \text{ gange} \\ \\ \\ \\ n_2 \text{ gange} \end{array}$$

Vi ser at $\mathbf{T}$ svarer til parametriseringen hvor $\beta_1 = \mu_1$ og $\beta_2 = \mu_2$,
og $\tilde{\mathbf{T}}$ svarer til parametriseringen hvor $\beta_1 = \mu_1$ og $\beta_2 = \mu_2 - \mu_1$.

Dette svarer til at:

$$\hat{\beta} = (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x} = \left\{ \begin{array}{cc} \frac{1}{n_1} & 0 \\ 0 & \frac{1}{n_2} \end{array} \right\} \begin{pmatrix} x_{1\cdot} \\ x_{2\cdot} \end{pmatrix} = \begin{pmatrix} \bar{x}_{1\cdot} \\ \bar{x}_{2\cdot} \end{pmatrix},$$

$$\hat{\tilde{\beta}} = (\tilde{\mathbf{T}}^* \tilde{\mathbf{T}})^{-1} \tilde{\mathbf{T}}^* \mathbf{x} = \left\{ \begin{array}{cc} \frac{1}{n_1} & -\frac{1}{n_1} \\ -\frac{1}{n_1} & \frac{1}{n_1} + \frac{1}{n_2} \end{array} \right\} \begin{pmatrix} x_{1\cdot} + x_{2\cdot} \\ x_{2\cdot} \end{pmatrix} = \begin{pmatrix} \bar{x}_{1\cdot} \\ \bar{x}_{2\cdot} - \bar{x}_{1\cdot} \end{pmatrix}.$$

Designmatricen i R

Designmatricen kan findes ved hjælp af `model.matrix`.
Vi betragter Eksempel 1.5.

```
grp30 <- c(3,5,5,7,9,9,10,12,20,24,24,34,43,46,58,140)
grp60 <- c(2,5,5,7,8,9,14,18,24,26,26,34,37,42,90)
loggrp30 <- log(grp30)
loggrp60 <- log(grp60)
gruppe = rep(c("loggrp30", "loggrp60"), c(16,15))
flies = data.frame(reac = c(loggrp30, loggrp60), gruppe = gruppe)
lmfit = lm(reac~1+gruppe, data=flies)
```

Køres `model.matrix(lmfit)` fås

	(Intercept)	gruppeloggrp60
1	1	0
2	1	0
⋮		
15	1	0
16	1	0
17	1	1
18	1	1
⋮		
30	1	1
31	1	1

hvilket svarer til $\tilde{T}$.

Fittes modellen uden intercept ledet:

```
lmfit = lm(reac~0+gruppe,data=flies)
```

bliver output af **model.matrix**(lmfit)

```
(Intercept)  gruppeloggrp60
1           1             0
2           1             0
⋮
15          1             0
16          1             0
17          0             1
18          0             1
⋮
30          0             1
31          0             1
```

hvilket svarer til **T**.

Designmatricen i R

Estimaterne i Eksempel 1.5 fandtes i Tabel 3.1 til

Kontaktid	Middelværdi μ	Varians σ^2
30 sekunder	2.8072	1.064638
60 sekunder	2.7154	

Dette passer med at

```
summary(lm(reac~1+gruppe, data=flies))
```

er

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	2.80722	0.25793	10.883	9.35e-12	***
gruppeloggrp60	-0.09168	0.37080	-0.247	0.806	

mens output af

```
summary(lm(reac~0+gruppe, data=flies))
```

er

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
gruppeloggrp30	2.8072	0.2579	10.88	9.35e-12	***
gruppeloggrp60	2.7155	0.2664	10.19	4.26e-11	***

Designmatricen i R

model.matrix kan også køres med en modelformel som input, og det er ikke nødvendigt at angive nogen responsvariabel i denne.

```
fac1 <- factor(c("A", "A", "B", "B", "B"))  
model.matrix(~fac1)
```

giver output

	(Intercept)	facB
1	1	0
2	1	0
3	1	1
4	1	1
5	1	1

```
model.matrix(~0+fac1)
```

giver output

	fac1A	fac1B
1	1	0
2	1	0
3	0	1
4	0	1
5	0	1

Designmatricen i R

Følgende eksempler viser designmatricen, når vi inkluderer kontinuerte variable:

```
bt = c(1.1, 2.0, 3.2, 4.5, 5.0)
model.matrix(~bt)
```

```
  (Intercept)  bt
1           1  1.1
2           1  2.0
3           1  3.2
4           1  4.5
5           1  5.0
```

```
bt1 = c(0.0, 1.0, 3.2, 4.5, 5.0)
bt2 = c(3.1, 3.0, 2.6, 5.0, 5.0)
model.matrix(~bt1 + bt2 + exp(bt1))
```

```
  (Intercept)  bt1  bt2    exp(bt1)
1           1  0.0  3.1    1.000000
2           1  1.0  3.0    2.718282
3           1  3.2  2.6   24.532530
4           1  4.5  5.0   90.017131
5           1  5.0  5.0  148.413159
```

Som det fremgår tilføjes der en søjle for hver forklarende variabel.

Når en faktor indgår i modelformlen, vil der som udgangspunkt tilføjes et antal søjler svarende til antallet niveauer. Dog skal designmatricen stadig have fuld rang.

Designmatricen i R

I følgende eksempel introduceres en ny faktor og vi angiver modelformlen for additivitetsmodellen i tosidet variansanalyse:

```
fac1 <- factor(c("A", "A", "B", "B", "B"))  
fac2 <- factor(c("C", "C", "C", "D", "D"))  
model.matrix(~fac1+fac2)
```

Designmatricen bliver da

	(Intercept)	fac1B	fac2D
1	1	0	0
2	1	0	0
3	1	1	0
4	1	1	1
5	1	1	1

Designmatricen i R

Sidste eksempel på en designmatrix er fra gruppespecifik regression:

```
fac1 <- factor(c("A","A","B","B","C"))
bt = c(1.1,2.0,3.2,4.5,5.0)
model.matrix(~fac1 + bt + fac1:bt)
```

Dette giver output

	(Intercept)	fac1B	fac1C	bt	fac1B:bt	fac1C:bt
1	1	0	0	1.1	0.0	0
2	1	0	0	2.0	0.0	0
3	1	1	0	3.2	3.2	0
4	1	1	0	4.5	4.5	0
5	1	0	1	5.0	0.0	5

Bemærk at leddet `fac1:bt` giver en ny søjle i designmatricen, for hvert niveau af `fac`, med undtagelse af referenceniveauet.

Fordelingsresultater i multipel regression

Hvis vi betragter estimatoren svarende til

$$s^2 = \frac{1}{n-d} \|\mathbf{x} - \mathbf{T}\hat{\beta}\|^2,$$

så gælder der

$$s^2 \sim \sigma^2 \chi^2(n-d)/(n-d),$$

Hvis vi betragter estimatoren svarende til

$$s^2 = \frac{1}{n-d} \|\mathbf{x} - \mathbf{T}\hat{\beta}\|^2,$$

så vil

$$s^2 \sim \sigma^2 \chi^2(n-d)/(n-d),$$

og hvis vi betragter estimatoren svarende til $\hat{\beta}$, så vil

$$\hat{\beta} \sim N_d(\beta, \sigma^2(\mathbf{T}^* \mathbf{T})^{-1}),$$

hvilket betyder at $\hat{\beta}$ er *d-dimensionalt normalfordelt* med middelværdivektor β og kovariansmatrix $\sigma^2(\mathbf{T}^* \mathbf{T})^{-1}$.

fordelingsresultater i multipel regression

En stokastisk vektor $\mathbf{X} = (X_1, \dots, X_p)^*$ siges at være *p-dimensional normalfordelt*, hvis det for enhver vektor $\mathbf{a} = (a_1, \dots, a_p) \in \mathbb{R}^p$ gælder, at

$$\mathbf{a} \cdot \mathbf{X} = a_1 X_1 + a_2 X_2 + \dots + a_p X_p$$

er normalfordelt.

Hvis $X_1, \dots, X_p$ er uafhængige stokastiske variable med $X_i \sim N(\mu_i, \sigma_i^2)$, vil der gælde, at

$$\begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix} = \mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \text{ hvor } \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{pmatrix} \text{ og } \boldsymbol{\Sigma} = \begin{Bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_p^2 \end{Bmatrix}.$$

Specielt gælder at hvis $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_n^2 = \sigma^2$ så er $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_p)$, hvor $\mathbf{I}_p$ er den $p \times p$ -dimensionale identitetsmatrix.

Fordelingsresultater i multipel regression

Føromtalte resultater følger af fordelingsresultater:

Proposition

Lad $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\mathbf{B}$ en $k \times p$ matriks og $\boldsymbol{\eta} \in \mathbb{R}^k$, da er

$$\mathbf{Y} = \boldsymbol{\eta} + \mathbf{B}\mathbf{X} \sim N_k(\boldsymbol{\eta} + \mathbf{B}\boldsymbol{\mu}, \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}^*).$$

Proposition

Hvis $\mathbf{Y}$ er $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ fordelt og $\mathbf{B}$ er en $k \times p$ matriks og $\mathbf{C}$ er en $m \times p$ matrix, så er $\mathbf{B}\mathbf{Y}$ og $\mathbf{C}\mathbf{Y}$ uafhængige, hvis og kun hvis $\mathbf{B}\boldsymbol{\Sigma}\mathbf{C}^* = \mathbf{0}$.

Specielt gælder, at hvis $\boldsymbol{\Sigma} = \sigma^2 \mathbf{I}_p$ med $\sigma^2 > 0$ vil $\mathbf{B}\mathbf{X}$ og $\mathbf{C}\mathbf{X}$ være uafhængige hvis og kun hvis $\mathbf{B}\mathbf{C}^* = \mathbf{0}$.

Proposition

Antag $\mathbf{Y} \sim N_p(\mathbf{0}, \sigma^2 \mathbf{I}_p)$ og at $\mathbf{B}$ er en $p \times p$ matrix som opfylder $\mathbf{B}^2 = \mathbf{B}$ (idempotent) og $\mathbf{B}^* = \mathbf{B}$ (symmetrisk). Så gælder det, at

$$\|\mathbf{B}\mathbf{Y}\|^2 \sim \sigma^2 \chi^2(k)$$

hvor k er rangen af $\mathbf{B}$.

fordelingsresultater i multipel regression

Det følger af

$$\hat{\beta} \sim N_d(\beta, \sigma^2(\mathbf{T}^* \mathbf{T})^{-1}),$$

af

$$\hat{\beta}_j \sim N(\beta_j, \sigma^2 c^{jj}). \quad (1)$$

hvor c^{jj} er den j -te diagonalindgang i $(\mathbf{T}^* \mathbf{T})^{-1}$.

Da s^2 er uafhængig af $\hat{\beta}$ gælder under $H : \beta_j = 0$ at

$$t_j = \frac{\hat{\beta}_j}{\sqrt{s^2 c^{jj}}} \sim t(n-d), \quad (2)$$

Derudover findes spredningen på estimatet,

$$\text{std error}(\hat{\beta}_j) = \sqrt{s^2 c^{jj}}, \quad (3)$$

og testsandsynligheden for $H : \beta_j = 0$

$$p_{obs} = 2 (1 - F_{t(n-d)}(|t_j|)), \quad (4)$$

hvor $F_{t(n-d)}$ betegner fordelingsfunktionen for t fordelingen med $n-d$ frihedsgrader.

Estimaterne svarende til (1),(2),(3), og (4) er netop, hvad **R** udskriver, når parametertabellen beregnes ved hjælp af **summary**.

Multiple R-squared

I udskriften fra **summary** findes **Multiple R-squared** og **Adjusted R-squared**. Disse kan findes ved at tage udgangspunkt i en multipel regressionsmodel, og denne betragte undermodellen, hvor alle observationer har samme middelværdi.

I denne har vi dekompositionen af den total variation SSD_T :

$$SSD_T = SSD_E + SSD_H,$$

i den del af variationen der forklares af hypotesen (SSD_H) der er forklaret af modellen og uforklaret variation (SSD_E):

$$SSD_E = \sum_{i=1}^n (x_i - \hat{x}_i)^2 \quad \text{og} \quad SSD_H = \sum_{i=1}^n (\hat{x}_i - \bar{x}_.)^2.$$

Vi har da:

$$R^2 = \frac{SSD_H}{SSD_T} = 1 - \frac{SSD_E}{SSD_T} \quad \text{og} \quad R_{adj}^2 = 1 - \frac{\frac{SSD_E}{n-d}}{\frac{SSD_T}{n-1}}.$$

Når der kun er én forklarende variabel er R^2 lig kvadratet på den empiriske korrelationskoefficient mellem responsvariablen og den forklarende variabel.

Matematisk Statistik

Grundbegreber indenfor statistisk analyse

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Modelopstilling og modelkontrol

Vi betragter et datasæt $\mathbf{x}$, der opfattes som en realisation af en stokastisk vektor $\mathbf{X}$.

- $\mathbf{x} \in \mathcal{X}$ hvor $\mathcal{X}$ kaldes *udfaldsrummet* - i praksis $\mathbb{N}^n/\mathbb{Z}^n$ eller $\mathbb{R}_+^n/\mathbb{R}^n$.
- Fordeling af $\mathbf{X}$ beskrives ved CDF F eller PMF/PDF f .

Statistisk model i praksis: En parametriseret klasse af fordelingsfunktioner, $\mathcal{F} = \{F_\theta | \theta \in \Theta\}$, eller en parametriseret klasse af tætheder $\{f(\cdot; \theta) | \theta \in \Theta\}$, hvor Θ kaldes parametermængden. Parameteren θ er en vektor, $\theta = (\theta_1, \dots, \theta_k)^*$.

Funktionen

$$\begin{aligned}\mathcal{X} \times \Theta &\rightarrow \mathbb{R} \\ (\mathbf{x}, \theta) &\mapsto f(\mathbf{x}; \theta)\end{aligned}$$

kaldes for *modelfunktionen*. Modelfunktionen er tætheden som funktion af både udfaldet $\mathbf{x}$ og parameteren θ .

Modelopstilling og modelkontrol

De indledende skridt i analysen af data er

- Modelopstilling (primært et spørgsmål om at identificere en relevant fordelingsklasse).
- Modelkontrol (indledningsvist grafisk: histogrammer, fraktildiagrammer, scatterplots).

Modelkontrollen er ikke nødvendigvis begrænset til kun at finde sted indledningsvist.

Statistisk inferens

Efter valget af statistisk model ønsker vi at formulere udsagn om parameteren θ - og dermed om det faglige problem - på baggrund af data $\mathbf{x}$.

Først ønskes et bud på θ :

$$\begin{aligned}\tilde{\theta} : \mathcal{X} &\rightarrow \Theta \\ \mathbf{x} &\mapsto \tilde{\theta}(\mathbf{x}),\end{aligned}\tag{1}$$

der til data $\mathbf{x}$ tilordner en bestemt parameter værdi $\tilde{\theta}(\mathbf{x})$.

Terminologi:

- $\theta \leftarrow \tilde{\theta} = \tilde{\theta}(\mathbf{x})$ et *estimat*.
- $\tilde{\theta}(\mathbf{X})$ en *estimator*.

Estimatorer har egenskaber som *bias*, *MSE* etc.

Estimer er “bare” tal.

En normalfordelt observationsrække - en normalfordelt stikprøve

Supp. §2

Middelværdi og varians ukendt.

- $x_1, \dots, x_n$ realisationer af *uafhængige og identisk fordelte* stokastiske variable $X_1, \dots, X_n$.
- $X_i \sim N(\mu, \sigma^2)$ $i = 1, \dots, n$
- $\mathcal{X} = \mathbb{R}^n$
- $\theta = (\mu, \sigma^2)$ $\Theta = \mathbb{R} \times \mathbb{R}_+$

Varians kendt $\sigma^2 = \sigma_0^2$, middelværdi ukendt.

- $\theta = \mu$ $\Theta = \mathbb{R}$

Estimator for middelværdi:

$$\bar{X}_{\cdot} = \frac{1}{n} \sum_{i=1}^n X_i,$$

Estimatorer for varians:

$$\hat{\sigma}^2 = \hat{\sigma}^2(\mathbf{X}) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_{\cdot})^2 \quad \text{eller} \quad s^2 = s^2(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_{\cdot})^2.$$

En metode til at udlede estimatorer når vi står med en stikprøve er den såkaldte *moment metode*. Her finder vi først funktioner

$$\begin{aligned}\mathbb{E}_{\theta}[X] &= g_1(\theta_1, \dots, \theta_k) \\ \mathbb{E}_{\theta}[X^2] &= g_2(\theta_1, \dots, \theta_k) \\ &\vdots \\ \mathbb{E}_{\theta}[X^k] &= g_k(\theta_1, \dots, \theta_k)\end{aligned}$$

og sætter disse lig de tilsvarende *empiriske* momenter

$$M_j = \frac{1}{n} \sum_{i=1}^n X_i^j \quad j = 1, \dots, k,$$

og løses for $\theta_1, \dots, \theta_k$.

- $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d}}{\sim} \text{Unif}[0, \beta]: \hat{\beta}^m = 2\bar{X}.$
- $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d}}{\sim} E(\lambda): \hat{\lambda}^m = 1/\bar{X}.$
- $X_1, X_2, \dots, X_n$ i.i.d hvor X_i har pdf $f(x; \lambda, \delta) = \lambda e^{-\lambda(x-\delta)}, x > \delta :$
 $1/\lambda = \sqrt{m_2 - \bar{X}^2}$ og $\delta = \bar{X} - \sqrt{m_2 - \bar{X}^2}$ hvor $m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$

Vi ønsker at undersøge om data kan en simplere statistisk model, end den først opstillede og betragter derfor for $\Theta_0 \subset \Theta$ *hypotesen*:

$$H_0 : \theta \in \Theta_0 .$$

Hvis $\Theta_0 = \{\theta_0\}$ kaldes hypotesen *simpel* og ellers *sammensat*.

Vi ønsker på baggrund af data $\mathbf{x}$ at afgøre om vi kan forkaste H_0 og et *test* er derfor en partition af $\mathcal{X}$ i

$$R = \{\mathbf{x} \in \mathcal{X} : H_0 \text{ forkastes på grundlag af } \mathbf{x}\}$$

$$A = \{\mathbf{x} \in \mathcal{X} : H_0 \text{ forkastes ikke på grundlag af } \mathbf{x}\} .$$

Ofte fås denne opdeling som urbillede af en funktion $T : \mathcal{X} \mapsto \mathbb{R}$, hvorom der gælder at $\mathcal{T} \stackrel{\text{def}}{=} T(\mathcal{X}) = \mathcal{T}_R \cup \mathcal{T}_A$ og

$$R = T^{-1}(\mathcal{T}_R) = \{\mathbf{x} \in \mathcal{X} : T(\mathbf{x}) \in \mathcal{T}_R\}$$

$$A = T^{-1}(\mathcal{T}_A) = \{\mathbf{x} \in \mathcal{X} : T(\mathbf{x}) \in \mathcal{T}_A\} ,$$

Testteori

I denne situation betegnes $T = T(\mathbf{X})$ som en *testor* af H_0 og $T(\mathbf{x})$ omtales som *teststørrelsen*.

I praksis er T et (relativt) mål for, hvor kritisk $\mathbf{x}$ er for H_0 i den forstand at vi kan sige at $\mathbf{x}_1$ er ligeså eller mere kritisk for H_0 end $\mathbf{x}_2$ hvis

$$T(\mathbf{x}_1) \geq T(\mathbf{x}_2),$$

(eller omvendt). Mængden $\{\mathbf{y} \in \mathcal{X} \mid T(\mathbf{y}) \geq T(\mathbf{x})\}$ er da alle de udfald, som er mere kritiske for H_0 end $\mathbf{x}$.

Hvis vi betragter en simpel hypotese $H: \theta = \theta_0$ kan vi i dette tilfælde angive sandsynligheden for denne mængde under antagelse af at hypotesen er sand som

$$p_{\text{obs}}(\mathbf{x}) = \mathbb{P}_{\theta_0}(\{\mathbf{y} \in \mathcal{X} \mid T(\mathbf{y}) \geq T(\mathbf{x})\}) = \mathbb{P}_{\theta_0}(T(\mathbf{X}) \geq T(\mathbf{x})).$$

Bemærk at $p_{\text{obs}}(\mathbf{x})$ afhænger af data $\mathbf{x}$ og vi kan derfor betragte den stokastiske variabel $p_{\text{obs}}(\mathbf{X})$. Under relativt svage betingelser gælder at $p_{\text{obs}}(\mathbf{X}) \sim U(0, 1)$ når hypotesen er sand.

- Hvis $X_1, \dots, X_n$ er uafhængige og identisk fordelte $X_i \sim N(\mu, \sigma_0^2)$, så er $|u(\mathbf{X})|$, hvor

$$u(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{\sigma_0^2/n}}$$

en testor for hypotesen $H_0 : \mu = \mu_0$.

- Hvis variansen er ukendt er $|t(\mathbf{X})|$ en testor for H_0 , hvor


$$t(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{s^2(\mathbf{X})/n}}.$$

Målet i likelihood inferens er at finde en generel metodik til at finde estimatorer og testorer. Udgangspunktet er *likelihoodfunktionen*. Likelihoodfunktionen er modelfunktionen betragtet som funktion af θ .

$$L(\theta) = f(\mathbf{x}; \theta) \quad \theta \in \Theta, \quad (2)$$

Motivationen er fortolkningen (i rette forstand) af modelfunktionen som sandsynligheden for at observere $\mathbf{x}$ når parameteren er θ .

Figure 6.2 Estimate of area under curve by rectangle.



Likelihoodfunktionen

- fortolkes som graden af *trolighed* af parameteren θ i lyset af data $\mathbf{x}$.
- laver en ordning i parametermængden Θ i den forstand at hvis $L(\theta_1) > L(\theta_2)$ så tror vi mere på θ_1 end θ_2 i lyset af data $\mathbf{x}$.

Idé: Vælg θ til at være den *mest* trolige værdi:

$$L(\hat{\theta}) > L(\theta) \quad \text{for alle } \theta \in \Theta \text{ således at } \theta \neq \hat{\theta},$$

(underforstået at denne eksisterer). Dette er *maksimum likelihood estimation*. Vi skriver:

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} L(\theta).$$

Dette er maksimum likelihood estimatet (MLE). Bemærk at $\hat{\theta}$ kan opfattes som en funktion af $\mathbf{x}$, dvs. $\hat{\theta} = \hat{\theta}(\mathbf{x})$.

Bemærkninger:

- Ofte lettere at betragte log likelihood funktionen

$$l(\theta) = \ln L(\theta) \quad \theta \in \Theta.$$

- MLE kan findes ved at løse

$$\frac{\partial l}{\partial \theta_j}(\theta) = 0, \quad j = 1, 2, \dots, k. \quad (3)$$

(enten eksakt eller numerisk) og undersøge om der er tale om et maksimum.

- Den afledte af log likelihood funktionen betegnes *score funktionen*.
- Hvis data udgør en stikprøve vil L og l splitte op:

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

og

$$l(\theta) = \sum_{i=1}^n \ln f(x_i; \theta).$$

$L(\hat{\theta}(\mathbf{x}))$, fortolkes som maksimale sandsynlighed for data $\mathbf{x}$ i den givne statistiske model. For en hypotese $H : \theta \in \Theta_0$ kan vi lade $\hat{\theta}_0(\mathbf{x})$ betegne maksimum likelihood estimatet for θ under H_0 og betragter *Likelihood ratio teststørrelsen* $Q(\mathbf{x})$:

$$Q(\mathbf{x}) = \frac{\max_{\theta \in \Theta_0} L(\theta)}{\max_{\theta \in \Theta} L(\theta)} = \frac{L(\hat{\theta}_0(\mathbf{x}))}{L(\hat{\theta}(\mathbf{x}))}. \quad (4)$$

Fortolkningen af denne er at $\mathbf{x}$ er kritisk for H_0 hvis $Q(\mathbf{x})$ er lille og at $\mathbf{x}_1$ er mere (eller lige så) kritisk for H_0 som $\mathbf{x}_2$, hvis

$$Q(\mathbf{x}_1) \leq Q(\mathbf{x}_2).$$

Hvis $\Theta = \{\theta_0\}$ kan testsandsynligheden beregnes som

$$p_{obs}(\mathbf{x}) = P_{\theta_0}(\{\mathbf{y} \in \mathcal{X} : Q(\mathbf{y}) \leq Q(\mathbf{x})\}) = P_{\theta_0}(Q(\mathbf{X}) \leq Q(\mathbf{x})). \quad (5)$$

Hvis hypotesen er sammensat beregnes p-værdien som

$$p_{obs}(\mathbf{x}) = \sup_{\theta \in \Theta_0} \mathbb{P}_{\theta}(Q(\mathbf{X}) \leq Q(\mathbf{x})).$$

Hvis p_{obs} er lille forkastes H_0 . Hvad der er “lille”?

Specificeres af *signifikansniveauet* α , som er den værdi ved hvilken vi vælger at forkaste H_0 , d.v.s. vi forkaster H_0 hvis $p_{obs}(\mathbf{x}) \leq \alpha$.

Ofte vælge $\alpha = 0.05$.

- Proposition 6.1 / 6.1.1 i MSRR, Example 8.10 i IPSR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p) = \text{Binomial}(1, p)$

$$\hat{p} = \frac{X}{n} \quad \text{hvor } X = \sum_{i=1}^n X_i$$

- Example 6.2 i MSRR, Example 8.10 i IPSR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} E(\lambda)$

$$\hat{\lambda} = \frac{1}{\bar{X}}$$

- Example 6.4 i MSRR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} U[0, \beta]$

$$\hat{\beta} = X_{(n)}$$

- Example 6.56 i MSRR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} U(0, \beta)$

$\hat{\beta}$ eksisterer ikke.

● Example 6.7 i MSRR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Cauchy}(\theta)$
fælles tæthed :

$$f(x; \theta) = \frac{1}{\pi(1 + (x - \theta)^2)}$$

Likelihood:

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\pi(1 + (x_i - \theta)^2)}$$

Log likelihood:

$$\ell(\theta; x_1, \dots, x_n) = -n \log \pi - \sum_{i=1}^n \log(1 + (x_i - \theta)^2)$$

Maximeres numerisk

Afsnit 2.3.3 i Supp.

Example 8.26 i [Chihara and Hesterberg(2022)]

Example 8.24 i [Chihara and Hesterberg(2018)]

En stikprøve $x_1, \dots, x_n$ fra normal fordelingen, d.v.s. x_i -erne er udfald af $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$

$$L(\mu, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2},$$

og log likelihood funktionen er

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Vi finder

$$\hat{\mu} = \bar{x} \stackrel{\text{def}}{=} \frac{1}{n} \sum_{i=1}^n x_i$$

Vi finder derved

$$\ell(\mu, \sigma^2) \leq \ell(\bar{x}, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Dette maksimeres med hensyn til σ^2 og vi finder

$$\hat{\sigma}^2 = \hat{\sigma}^2(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Samlet:

$$(\hat{\mu}, \hat{\sigma}^2) = \left(\bar{x}, \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right).$$

Likelihood test for $H : \mu = \mu_0$.

Likelihood ratio teststørrelsen

$$Q(\mathbf{x}) \stackrel{\text{def}}{=} \frac{\max_{\sigma^2 \in \mathbb{R}_+} L(\mu_0, \sigma^2)}{\max_{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+} L(\mu, \sigma^2)} = \frac{L\left(\mu_0, \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2\right)}{L(\bar{x}, \hat{\sigma}^2)},$$

og vi finder

$$Q(\mathbf{x}) = \left[\frac{1}{1 + \frac{t^2(\mathbf{x})}{n-1}} \right]^{\frac{n}{2}} \quad \text{hvor} \quad t(\mathbf{x}) = \frac{\bar{x} - \mu_0}{\sqrt{\frac{s^2(\mathbf{x})}{n}}}.$$

Vi ser at likelihood ratio testet er *ækvivalent* med t -testet, i den forstand at

$$p_{\text{obs}}(\mathbf{x}) = \sup_{\theta \in \Theta_0} P_{\theta}(Q(\mathbf{X}) \leq Q(\mathbf{x})) = P_{\mu_0}(|t(\mathbf{X})| \geq |t(\mathbf{x})|)$$

Estimatorernes egenskaber

- Bias
- Efficiens
- MSE (mean square error)
- konsistens
- omparametrisering, Jensens ulighed
- Asymptotisk normalitet af ML estimatorer

For nemheds skyld betragter vi en en-dimensional parameter θ .

Bias for en estimator $\hat{\theta} = \hat{\theta}(\mathbf{X})$ er givet ved

$$\text{Bias}[\hat{\theta}] = E_{\theta}[\hat{\theta}] - \theta$$

Unbiased (eller *Middelværdiret*, *central*) estimator: $E_{\theta}[\hat{\theta}] = \theta$ d.v.s.

$\text{Bias}[\hat{\theta}] = 0$ for alle $\theta \in \Theta$.

Eksempler

- (Proposition 6.3/6.3.1 i MSRR) $X_1, X_2, \dots, X_n \sim \text{Bern}(p)$ så er $\mathbb{E}[\hat{p}] = p$, hvor $\hat{p} = \bar{X}$.
- Hvis $X_1, \dots, X_n$ er en i.i.d. følge med $\text{Var}[X_i] = \sigma^2 < \infty$. Så er *stikprøvevariansen/den empiriske varians*

$$s^2 = s^2(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

unbiased som estimator for σ^2 .

Bemærk at $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ er biased.

- For $X_1, \dots, X_n \stackrel{i.i.d}{\sim} U[0, \beta]$ er MLE for β lig $\hat{\beta} = X_{(n)}$. Der gælder at

$$\mathbb{E}[X_{(n)}] = \frac{n}{n+1} \beta,$$

så estimatoren er biased, men $\frac{n+1}{n} X_{(n)}$ er unbiased.

Limitations of Unbiasedness

(Afsnit 6.3.1.1 i [Chihara and Hesterberg(2018)])

Middelværdirethed/unbiasedness er “nice to have”, men ikke “need to have”.

- Det kan være umuligt at finde en unbiased estimator.
- Unbiased estimatorer kan “urimelige” (f.eks. unbiased estimator for p i en geometrisk fordeling).
- Unbiased estimation kan upraktisk (f.eks. for standardafvigelsen σ)
- Et krav om at en estimator kan være unbiased kan resultere i en høj MSE.

Asymptotisk middelværdiret estimator

(Afsnit 6.3.1.2 i [Chihara and Hesterberg(2018)])

Ofte afhænger bias for en estimator af antallet af observationer n , og hvis bias forsvinder når n går mod uendeligt siger vi at estimatoren er asymptotisk unbiased. (strengt taget, følgen af estimators)

Eksempler:

$$\lim_{n \rightarrow \infty} \mathbb{E}[\hat{\sigma}^2] = \lim_{n \rightarrow \infty} \frac{n-1}{n} \sigma^2 = \sigma^2.$$

MLE for β for en stikprøve fra $U[0, \beta]$ -fordelingen er $X_{(n)}$. Vi har

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_{(n)}] = \lim_{n \rightarrow \infty} \frac{n}{n+1} \beta = \beta.$$

Motivation

Tit findes mange middelværdirette estimatorer for den samme parameter — hvilken skal så foretrækkes?

Eksempel

Hvis X_1, X_2, X_3 er *i.i.d.* med middelværdi μ og varians σ^2 da er både

$$\bar{X} = \frac{1}{3}(X_1 + X_2 + X_3)$$

og

$$Y = \frac{1}{6}X_1 + \frac{1}{3}X_2 + \frac{1}{2}X_3$$

middelværdirette estimatorer for μ .

Men

$$\text{Var}(\bar{X}) = \frac{1}{3}\sigma^2 \quad \text{mens} \quad \text{Var}(Y) = \frac{7}{18}\sigma^2.$$

Definition

Hvis $\hat{\theta}_1$ og $\hat{\theta}_2$ begge er middelværdirette estimatorer til samme parameter θ , men $\mathbb{V}\text{ar}(\hat{\theta}_1) < \mathbb{V}\text{ar}(\hat{\theta}_2)$, så kaldes $\hat{\theta}_1$ for mere efficient end $\hat{\theta}_2$.

Den *relative efficiens* af middelværdirette estimatorer $\hat{\theta}_1$ og $\hat{\theta}_2$ defineres som

$$e(\hat{\theta}_1, \hat{\theta}_2) = \frac{\mathbb{V}\text{ar}[\hat{\theta}_1]}{\mathbb{V}\text{ar}[\hat{\theta}_2]}$$

Betragt igen $X_1, X_2, \dots, X_n \stackrel{i.i.d}{\sim} U[0, \beta]$. Hvilken af de to unbiased estimatorer $2\bar{X}$ og $\frac{n+1}{n}X_{(n)}$ er mest efficient?

Cramér-Rao ulighed

(Afsnit 6.3.2.1 i [Chihara and Hesterberg(2018)])

Lad $X_1, \dots, X_n$ betegne en stikprøve med n observationer. Ifølge Cramér-Rao uligheden under visse betingelser gælder at en unbiased estimator $\hat{\theta}$ for θ opfylder uligheden:

$$\mathbb{V}\text{ar}_{\theta}[\hat{\theta}] \geq \frac{1}{n\mathcal{I}(\theta)}.$$

Udtrykket i nævneren kaldes for *Fisher information*,

$$\mathcal{I}(\theta) := E \left[\left(\frac{\partial}{\partial \theta} \log(f(X; \theta)) \right)^2 \right].$$

Dette er variansen af score funktionen (fra MLE). Bemærk at der under svage antagelser gælder at

$$\mathcal{I}(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log(f(X; \theta)) \right].$$

Mean squared error kombinerer præcision og nøjagtighed i ét mål:
Mean square error af en estimator $\hat{\theta}$ er defineret som

$$\text{MSE}[\hat{\theta}] = \mathbb{E}_{\theta}[(\hat{\theta} - \theta)^2]$$

og vi har Proposition 6.3.3 i MSRR (Bias-variance decomposition)

$$\text{MSE}[\hat{\theta}] = \text{Var}[\hat{\theta}] + (\text{Bias } \hat{\theta})^2$$

Ex. 6.15 i MSRR : Estimatorer til p i binomialfordelingen

Der betragtes antal af success i n uafhængige Bernoulli eksperimenter, altså en stokastisk variabel $X \sim \text{Binom}(n, p)$, med n kendt og p ukendt. ML estimator til successraten:

$$\hat{p}_1 = \frac{X}{n}$$

$$\mathbb{E}[\hat{p}_1] = p, \quad \mathbb{V}\text{ar}[\hat{p}_1] = \frac{p(1-p)}{n} \Rightarrow \text{MSE}[\hat{p}_1] = \frac{p(1-p)}{n}$$

har stor MSE når p ligger i nærheden af 0.5. Alternativ estimator:

$$\hat{p}_2 = \frac{X+1}{n+2}$$

$$\mathbb{E}[\hat{p}_2] = \frac{np+1}{n+2}, \quad \mathbb{V}\text{ar}[\hat{p}_2] = \frac{np(1-p)}{(n+2)^2} \Rightarrow$$

$$\text{MSE}[\hat{p}_2] = \frac{np(1-p)}{(n+2)^2} + \left(\frac{np+1}{n+2} - p \right)^2 = \frac{np(1-p) + (1-2p)^2}{(n+2)^2}$$

Den nye estimator er biased, men har mindre MSE for mellemstore værdier af p , som ikke ligger tæt ved 0 eller 1.

Ex. 6.15, fortsat




Figure 6.6 Mean square error against p , $n = 16$.

Vi lader (som altid) n betegne antallet af observationer og betragter nu en følge af estimatorer $\{\hat{\theta}_n\}_{n=1}^{\infty}$ for parameteren θ . Vi siger følgen er konsistent hvis og kun hvis

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\theta}_n - \theta| < \epsilon) = 1$$

for alle $\epsilon > 0$.

Betingelsen er ækvivalent med $\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\theta}_n - \theta| \geq \epsilon) = 0$ og skrives

$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta.$$

Vi er sjældent interesseret i estimatorer, der ikke er konsistente.

Følgen er *konvergent i sandsynlighed*, se §7.2.5 i [Pishro-Nik(2014)].

Tilstrækkelige betingelser for konsistens

Proposition 6.5 i [Chihara and Hesterberg(2022)]

Proposition 6.3.4 i [Chihara and Hesterberg(2018)]

Lad $\hat{\theta}_n$ være en følge af estimatorer for θ , som opfylder

$$\lim_{n \rightarrow \infty} \mathbb{E}[\hat{\theta}_n] = \theta \quad \text{og} \quad \lim_{n \rightarrow \infty} \text{Var}[\hat{\theta}_n] = 0.$$

Så er $\{\hat{\theta}_n\}_{n=1}^{\infty}$ en konsistent følge af estimatorer for θ .

Eksempel 6.18: Cauchy-fordelingen

Lad $X_1, \dots, X_n$ være en stikprøve fra Cauchy-fordelingen, d.v.s fælles tæthed

$$f(x; \theta) = \frac{1}{\pi(1 + (x - \theta)^2)}$$

- $\bar{X}$ er *ikke* konsistent for θ .
- medianen er konsistent (illustreres ved simulation).

Markovs ulighed og Chebyshevs ulighed

(§6.2.2 i [Pishro-Nik(2014)], ikke pensum på ISS)

Markovs ulighed:

Lad X være en stokastisk variabel, $X \geq 0$, og lad $c > 0$. Så gælder

$$\mathbb{P}(X \geq c) \leq \frac{E[X]}{c}$$

Chebyshevs ulighed:

(Theorem A.11 i [Chihara and Hesterberg(2022)],

Theorem A.6.2 i [Chihara and Hesterberg(2018)])

Lad X være en stokastisk variabel med endelig middelværdi μ og endelig varians σ^2 . Så gælder for alle $k > 0$

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}$$

Et umiddelbart korollar er at $\bar{X}_n$ er konsistent for μ når både μ og σ^2 er endelige.

Transformation af middelværdirette estimators

Antag, at $\hat{\theta}$ er en god estimator for θ . Vi vil dog gerne estimere $g(\theta)$ for en given bijektiv funktion g . Er $g(\hat{\theta})$ også en god estimator? Svar:

- Hvis $\hat{\theta}$ er MLE for θ , så er $g(\hat{\theta})$ også MLE estimator for $g(\theta)$.
- Hvis $\hat{\theta}$ er en middelværdiret estimator for θ , så er $g(\hat{\theta})$ generelt *ikke* middelværdiret for $g(\theta)$.

Eksempel (MSRR, s. 163 / s. 166) For en stikprøve fra $U[0, \beta]$ har vi at momentmetoden for β var $\hat{\beta}^m = 2\bar{X}$. og denne er unbiased. Er $(\hat{\beta}^m)^2$ en unbiased estimator for β^2 ?

$$\begin{aligned}\mathbb{E}[(\hat{\beta}^m)^2] &= \mathbb{E}[(2\bar{X})^2] = 4 \mathbb{E}[\bar{X}^2] = 4(\text{Var}[\bar{X}] + \mathbb{E}[\bar{X}]^2) \\ &= 4 \left(\frac{\beta^2}{12n} + \left(\frac{\beta^2}{2} \right)^2 \right) = \beta^2 + \frac{\beta^2}{3n}\end{aligned}$$

Så der gælder altså at $\mathbb{E}[(\hat{\beta}^m)^2] > \beta^2$.

Transformation af middelværdirette estimerer, Jensens ulighed

Generelt har vi (en udgave af) *Jensens Ulighed* som siger:

Sætning

Lad g være en strengt konveks funktion og X en ikke degenereret stokastisk variabel. Så er

$$\mathbb{E} g(X) > g(\mathbb{E}[X])$$

Det følger at hvis $\hat{\theta}$ er en unbiased estimator for θ og hvis g er en strengt konveks funktion, så er

$$\mathbb{E}[g(\hat{\theta})] > g(\theta).$$

Asymptotisk normalitet af ML estimatorer

MSRR § 6.3.6, Supp § 6.7

Vi betragter som tidligere en stikprøve med n observationer, hvor vi tænker på at n vokser, og lader $\hat{\theta}_n$ betegne MLE for n observationer. Når visse betingelser er opfyldt, vil maksimum likelihood estimatorer være approksimativt normalfordelt:

$$\hat{\theta}_n \approx N\left(\theta, \frac{1}{n\mathcal{I}(\theta)}\right) \quad (\spadesuit)$$

hvor $\mathcal{I}(\theta)$ er Fisher informationen fra C-R uligheden

$$\mathcal{I}(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log(f(X; \theta)) \right)^2 \right] = -E \left[\left(\frac{\partial^2}{\partial^2 \theta} \log(f(X; \theta)) \right) \right].$$

Bemærk at $(\spadesuit)$ medfører at

$$n\mathcal{I}(\theta) \left(\hat{\theta}_n - \theta \right)^2 \approx \chi^2(1)$$

Approximativ likelihood teori Supp § 6.7

Ved at lave en anden ordens Taylor udviklinger af log likelihood funktionen om MLE fås approksimationen

$$l(\theta) - l(\hat{\theta}) \approx (\theta - \hat{\theta})l'(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^2 l''(\hat{\theta}) = \frac{1}{2}(\theta - \hat{\theta})^2 l''(\hat{\theta}).$$

Indfører vi nu $j(\theta; \mathbf{x}) = -l''(\theta; \mathbf{x})$ kan dette skrives som

$$l(\theta) - l(\hat{\theta}) \approx -\frac{1}{2}(\theta - \hat{\theta})^2 j(\theta; \mathbf{x})$$


Bemærk at $j(\theta; \mathbf{x})$ er den observerede udgave af $j(\theta; \mathbf{X})$ og at der for en stikprøve gælder at

$$\mathbb{E}_{\theta} j(\theta; \mathbf{X}) = n\mathcal{I}(\theta).$$

På grund af den asymptotiske normalitet af MLE virker det derfor ikke helt urimeligt at tro at

$$\begin{aligned} -2 \ln(Q(\mathbf{x})) &= -2 \ln\left(\frac{L(\theta)}{L(\hat{\theta})}\right) = \\ &-2(l(\theta) - l(\hat{\theta})) \approx (\theta - \hat{\theta})^2 j(\theta; \mathbf{x}) \approx n\mathcal{I}(\theta)(\theta - \hat{\theta})^2 \approx \chi^2(1) \end{aligned}$$

Figur 6.6



Den normerede log likelihood funktion $\bar{l}(\cdot) = l(\cdot) - l(\hat{\theta})$ og den approksimerende parabel $p(\cdot)$ svarende til observationen $x = 8$ i binomialmodellen med sandsynlighedsparameter θ og antalsparameter $n = 20$.

Bibliografi

 Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (2nd edition).
John Wiley & Sons, 2018.

 Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (3rd edition).
John Wiley & Sons, 2022.

 H. Pishro-Nik.

Introduction to Probability, Statistics, and Random Processes.
Kappa Research, LLC, 2014.
ISBN 9780990637202.

URL

https://books.google.dk/books?id=3yq_oQEACAAJ.

Matematisk Statistik

Permutationstest

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Hvad kan man stille op, hvis man ikke kan finde en god model for sit datasæt eller hvis man ikke kan udlede fordelingen for en testor?

I sådanne situationer kan *permutationstests* være en mulighed.

Vi husker vores indledende fortolkning af testorer som stikprøvefunktioner, der måler hvor kritisk et givet datasæt $\mathbf{x}$ er for en hypotese H_0 .

Introducerende eksempel

Løber mus, der får medicin langsommere igennem en labyrint?

Drug			Control		
30	25	20	18	21	22

Model:

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.}$$

hvor $n_1 = n_2 = 3$

Undersøge $H : \mu_1 = \mu_2$ mod $H_A : \mu_1 > \mu_2$.

T testor:

$$T(\mathbf{X}) = \frac{\bar{X}_{1\cdot} - \bar{X}_{2\cdot}}{\sqrt{s^2(\mathbf{X}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \underset{\sim}{\text{under } H_0} t_{(n_1 + n_2 - 2)}.$$

p -værdi i ensidet test

$$1 - F_{t_{(n_1 + n_2 - 2)}}(t(\mathbf{x}))$$

```
behandling = c(30,25,20)
kontrol = c(18,21,22)
t.test(behandling, kontrol, alt="greater")
```

```
data:  behandling and kontrol
t = 1.4924, df = 4, p-value = 0.1049
alternative hypothesis: true difference in means is greater than 0
```

Introducerende eksempel

Løber mus, der får medicin langsommere igennem en labyrint?

Drug			Control		
30	25	20	18	21	22

Differens i middelværdier:

$$25s - 20.33s = 4.67s$$

Hvis medicinen ingen effekt har, burde det være ligeså sandsynligt at vi havde observeret:

Drug			Control		
30	25	18	20	21	22

Her bliver differensen i middelværdi 3.33s.

Introducerende eksempel

Vi kan finde alle $\binom{6}{3} = 20$ kombinationer:

Table 3.1 All possible distributions of {30, 25, 20, 18, 21, 22} into two sets.

Drug			Control			$\bar{X}_D$	$\bar{X}_C$	Difference in means
18	20	21	22	25	30	19.67	25.67	-6.00
18	20	22	21	25	30	20	25.33	-5.33
18	20	25	21	22	30	21	24.33	-3.33
18	20	30	21	22	25	22.67	22.67	0.00
18	21	22	20	25	30	20.33	25	-4.67
18	21	25	20	22	30	21.33	24	-2.67
18	21	30	20	22	25	23	22.33	0.67
18	22	25	20	21	30	21.67	23.67	-2.00
18	22	30	20	21	25	23.33	22	1.33
18	25	30	20	21	22	24.33	21	3.33
20	21	22	18	25	30	21	24.33	-3.33
20	21	25	18	22	30	22	23.33	-1.33
20	21	30	18	22	25	23.67	21.67	2.00
20	22	25	18	21	30	22.33	23	-0.67
20	22	30	18	21	25	24	21.33	2.67
20	25	30	18	21	22	25	20.33	4.67 *
21	22	25	18	20	30	22.67	22.67	0.00
21	22	30	18	20	25	24.33	21	3.33
21	25	30	18	20	22	25.33	20	5.33 *
22	25	30	18	20	21	25.67	19.67	6.00 *

Rows where the difference in means exceeds the original value are highlighted.

Vi ser at 3 af de 20 muligheder har differens der er ligeså eller større end 4.67s hvilket her giver en p -værdi på $3/20 = 0.15$.

Beerwings -eksempel

I Beerwings -datasættet angives antal spiste hotwings sammen med køn (15 M/K). Vi ønsker at undersøge

$$H_0 : \mu_M - \mu_F = 0 \quad \text{versus} \quad H_A : \mu_M - \mu_F > 0$$

Table 3.2 Hot wings consumption.

Females					Males				
4	5	5	6	7	7	8	8	11	13
7	8	9	11	12	13	14	16	16	17
12	13	13	14	14	17	18	18	21	21

Vi betragter $\bar{X}_M - \bar{X}_F$ og har en observeret værdi på $t = 5.2$.

Idé: Hvis der ikke er forskel på de på to grupper vil enhver inddeling af observationerne være lige sandsynlig - f.eks.

Females					Males				
5	6	7	7	8	4	5	7	8	9
8	11	12	13	14	11	12	13	13	13
14	14	16	16	21	17	17	18	18	21

Her er differensen 0.93. Problem: Der er $\binom{30}{15} = 155\,117\,520$ kombinationer.

Løsning: Vælg et stort antal tilfældige inddelinger/kombinationer.
Lad t betegne testtestørrelsen $t = T(\mathbf{x})$.

- Generer N tilfældige inddelinger $\mathbf{X}_1^*, \mathbf{X}_2^*, \dots, \mathbf{X}_N^*$ af datasættet $\mathbf{x}$.
- Beregn

$$p = p_{\text{stor}} = \frac{1}{N+1} \left(1 + \sum_{i=1}^N \mathbb{1}(T(\mathbf{X}_i^*) \geq t) \right)$$

når store T betragtes som kritiske og

$$p = p_{\text{lille}} = \frac{1}{N+1} \left(1 + \sum_{i=1}^N \mathbb{1}(T(\mathbf{X}_i^*) \leq t) \right)$$

når små T betragtes som kritiske.

- Ved tosidet test beregnes p_{obs} som $p = 2 \min(p_{\text{lille}}, p_{\text{stor}})$

Implementation - Beerwings

Testoren er $T(\mathbf{x}) = \bar{x}_1. - \bar{x}_2.$

```
library(dplyr)
Beerwings %>% group_by(Gender) %>% summarize(mean(Hotwings))

tapply(Beerwings$Hotwings, Beerwings$Gender, mean)
observed <- 14.5333 - 9.3333

hotwings <- Beerwings$Hotwings
N <- 10^5 - 1 # number of times to repeat this process
result <- numeric(N) # space to save the random differences
for (i in 1:N)
{ # sample of size 15, from 1 to 30, without replacement
  index <- sample(30, size = 15, replace = FALSE)
  result[i] <- mean(hotwings[index]) - mean(hotwings[-index]) holder værdier af T
}

(sum(result >= observed) + 1)/(N + 1)
```


0.00091

Kaldet `sample(30, size = 15, replace = FALSE)` vælger 15 af tallene 1, 2, ..., 30 uden tilbagelægning.

Implementation - Beerwings

```
hist(result, xlab = "xbar1 - xbar2",  
      main = "Permutation Distribution for hot wings")  
abline(v = observed, col = "blue")
```

Permutation Distribution for hot wings



Alternativ implementation - Beerwings

```
# Alternativ implementation - benyt sample direkte på hotwings

hotwings = Beerwings$Hotwings
gender = factor(Beerwings$Gender)
result <- numeric(N) # space to save the random differences
for (i in 1:N) {
  gennemsnitMK = tapply(sample(hotwings), gender, mean)
  result[i] = gennemsnitMK[2] - gennemsnitMK[1]
}
```

Her bruges **sample** til at blande (“permutere”) observationerne i
hotwings

Implementation

- Valg af testor.
- Læg 1 til i tæller og nævner.
- Sample with replacement *blandt resamples/inddelinger*.
- Flere samples giver mere præcision.

Verizon eksempel

Er Verizon hurtigere til at reparere for egne kunder (ILEC) (gennemsnit 8.4 timer) end for andre kunder (CLEC) (gennemsnit 16.5 timer) ?




Figure 3.4 Distribution of repair times for Verizon (ILEC) and competitor (CLEC) customers. Note that the Y-axis scales are different.

Almindeligt (ensidet) t -test giver p -værdi på 0.03, men kan vi stole på det?

Verizon eksempel - implementation

```
Time <- subset(Verizon, select = Time, drop = TRUE)
Time.ILEC <- subset(Verizon, select = Time,
                    subset = Group == "ILEC", drop = TRUE)
Time.CLEC <- subset(Verizon, select = Time,
                    subset = Group == "CLEC", drop = TRUE)

# Observeret differens:
observed <- mean(Time.ILEC) - mean(Time.CLEC)

N <- 10^4 - 1
result <- numeric(N)
for (i in 1:N)
{
  index <- sample(1687, size = 1664, replace = FALSE)
  result[i] <- mean(Time[index]) - mean(Time[-index])
}


(sum(result <= observed) + 1) / (N + 1)
```

Der er 1664 ILEC kunder ud af 1687 i alt, derfor

```
index <- sample(1687, size = 1664, replace = FALSE) .
```

Verizon eksempel

Verizon eksemplet kan også bruges til at illustrere at permutationstest er fleksible mht. valg af testor:



Obs: Man må ikke “fiske” efter statistisk signifikans, ved at prøve at masse forskellige testorer af!

Navnet “Permutationstest” kommer fra at vi løst sagt antager at alle permutationer af datasættet er lige sandsynlige.

En *permutation* σ af $1, \dots, n$ er en bijektiv afbildning af $\{1, \dots, n\}$ på $\{1, \dots, n\}$ og for en stokastisk vektor $\mathbf{X} = (X_1, \dots, X_n)$ definerer vi

$$\mathbf{X}_\sigma = (X_{\sigma(1)}, X_{\sigma(2)}, \dots, X_{\sigma(n)})$$

og under antagelsen er at $\mathbf{X}_\sigma \sim \mathbf{X}$.

Table 3.3 Partial view of Beerwings data set.

Gender Hot wings			Gender Hot wings		
1	F	4	11	F	9
2	F	5	26	F	17
3	F	5	25	F	17
4	F	6	2	F	5
5	F	7	4	F	6
6	F	7	8	F	8
7	M	7	3	M	5
8	F	8	20	F	14
9	M	8	10	M	8
10	M	8	18	M	13
$\vdots$			$\vdots$		

The Gender column is held fixed and the rows of the Hotwings variable are permuted. The first column indicates which rows of the hot wing values were permuted.

Vi kan bruge denne fortolkning og ændre implementation af eksemplerne, så vi direkte samler en permutation og bruger denne til at simulere et udfald af vores testor.

Vi kan også belyse hvornår permutationstestet ikke fungerer - f.eks. vil det ikke fungere i en situation hvor vi har to meget ubalancerede observationsrækker med forskellig varians

$$X_{ij} \sim N(0, \sigma_i^2) \quad i = 1, 2 \quad j = 1, \dots, n_i$$

hvor $\sigma_1^2 = 10^6$, $\sigma_2^2 = 1$, $n_1 = 10^2$ og $n_2 = 10^6$. Vi kan illustrere dette ved simulation.

Hvis data er fremkommet ved at man har foretaget flere målinger på samme objekt/samme individ, kan det ofte være mest relevant at se på differenser af målinger for de enkelte individer. I bogen betragtes point for udspring ved et svømmestævne:

Table 3.4 Partial view of diving scores in file `Diving2017`.

Name	Country	Semifinal	Final
Cheog Jun Hoong	Malaysia	325.5	397.5
Si Yajie	China	382.8	396.00
Ren Qian	China	367.5	391.95
Kim Mi Rae	North Korea	346.00	385.55
:			

Vi ønsker at undersøge om der er forskel på middelværdien af pointene ved hhv. semifinalen og finalen og her vil det være mest relevant at betragte differenserne - den centrale observation er at hvis der ikke er forskel vil det være lige så sandsynligt at observere “finale - semifinale” som “semifinale - finale” og dette bruges til at lave et permutationstest.

Matched pairs - implementation

```
obs = mean(Diving2017$Semifinal) - mean(Diving2017$Final)

d = Diving2017$Semifinal - Diving2017$Final
n = length(d)

N <- 10^4 - 1
result <- numeric(N)
for (i in 1:N)
{
  signs <- sample(c(-1,1),n,replace=TRUE)
  result[i] <- mean(signs*d)
}
```

Vektoren `d` indeholder differenser. `sample` tilordner tilfældige fortegn.

Matematisk Statistik

Sampling Distributions

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Stikprøvefunktioner og sampling distributions - terminologi

Når vi har en statistisk model, hvor data $\mathbf{x} = (x_1, \dots, x_n)^*$ er udfald af en stokastisk vektor $\mathbf{X} = (X_1, \dots, X_n)^*$ kaldes en funktion af $T(\mathbf{X})$ (f.eks. estimatorer og testorer) generelt for en *stikprøvefunktion*. Fordelingen af $T = T(\mathbf{X})$ kaldes for *sampling distribution/stikprøvefordelingen* og spredningen af T kaldes *standard error*.

Eksempler:

Example 4.1 (næste slide)

Example 4.2 Fordeling af $\bar{X}$ når $X_1, \dots, X_n \stackrel{i.i.d}{\sim} E(\frac{1}{15})$

Example 4.3 og 4.4 Fordeling af $X_{(12)}$ (maksimum) når $X_1, \dots, X_{12}$ er $U[0, 1]$.


Example 4.1

Population: $w_1 = 3, w_2 = 4, w_3 = 6, w_4 = 6$.

$\mathbb{P}_e(X = 3) = \mathbb{P}_e(X = 4) = 1/4, \mathbb{P}_e(X = 6) = 1/2$

Sampling distribution of sample mean: $(X_1 + X_2)/2$.

Figure 4.3 Dot plot for sampling distribution of sample means.




Sample mean	w_1, w_1	w_1, w_2	w_1, w_3	w_1, w_4	w_2, w_1	w_2, w_2	w_2, w_3	w_2, w_4
	3	3.5	4.5	4.5	3.5	4	5	5
Sample mean	w_3, w_1	w_3, w_2	w_3, w_3	w_3, w_4	w_4, w_1	w_4, w_2	w_4, w_3	w_4, w_4
	4.5	5	6	6	4.5	5	6	6

Example 4.2 - sampling distribution ved simulation

```
Xbar <- numeric(1000) # space for results (vector of 0's)
for (i in 1:1000) {
  x <- rexp(100, rate = 1/15) # draw random sample of size 100
  Xbar[i] <- mean(x) # compute mean, save in position i
}
hist(Xbar, freq=FALSE, breaks = 20)



# Eksakt fordeling
curve(dgamma(x, shape=100, rate=100/15), add=TRUE, lwd=2, col="red")

# Normal approksimation
curve(dnorm(x, mean=15, sd=15/10), add=TRUE, lwd=2, col="blue")
```



Example 4.2 - sampling distribution ved simulation

```
plot(qgamma( (1:1000-0.5)/1000, shape=100, rate=100/15), sort(Xbar), xlab="Theoretical Quantiles")  
qqnorm(Xbar)
```




Example 4.4

$X_1, X_2, \dots, X_{12} \stackrel{\text{i.i.d.}}{\sim} U[0, 1]$

$$F_{X_{(12)}}(a) = 12a^{11}$$

```
maxY <- numeric(1000)
for (i in 1:1000)
{
  y <- runif(12) # draw random sample of size 12
  maxY[i] <- max(y) # find max, save in position i
}
hist(maxY, freq=F)

fun <- function(a) {12*a^11}
curve(fun, add=TRUE, lwd = 2)
```



Calculating Sampling Distributions - exact calculations

I visse tilfælde, kan vi benytte egenskaber for fordelingen af $\mathbf{X}$ til at udlede fordelingen af $T(\mathbf{X})$.

Corollary A.2 [‡] : $X_1, \dots, X_n \stackrel{i.i.d}{\sim} N(\mu, \sigma^2) \Rightarrow \bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

Theorem B. 16 [§] : Stadig $X_1, \dots, X_n \stackrel{i.i.d}{\sim} N(\mu, \sigma^2)$

- 1) $\bar{X}$ og $s^2(\mathbf{X})$ er uafhængige stokastiske variable.
- 2) $(n-1)s^2(\mathbf{X})/\sigma^2 \sim \chi^2(n-1)$

Theorem 4.1 [¶] : For en i.i.d. følge af kontinuerte stokastiske variable $X_1, \dots, X_n$ gælder at

$$f_{X_{(1)}}(x) = n(1 - F(x))^{n-1}f(x) \quad \text{og} \\ f_{X_{(n)}}(x) = nF^{n-1}(x)f(x).$$

Dette giver fordeling af MLE for $X_1, \dots, X_n \stackrel{i.i.d}{\sim} U[0, \beta]$

Example 4.6: $X_1, \dots, X_n$ uafhængige med $X_i \sim \text{Pois}(\lambda_i)$ så er $X_1 + X_2 + \dots + X_n \sim \text{Pois}(\sum_{i=1}^n \lambda_i)$

[‡]Corollary A.5.3 i [Chihara and Hesterberg(2018)]


[§]Theorem B.10.5 i [Chihara and Hesterberg(2018)], Thm 8.3 i [Pishro-Nik(2014)]

[¶]Theorem 4.2.1 i [Chihara and Hesterberg(2018)]

Example 4.6

```
set.seed(1)
X <- rpois(10^4, 5)
Y <- rpois(10^4, 12)
W <- X + Y
hist(W, prob = TRUE, breaks = 2:38+0.5) # prob = TRUE, scales hist to 1
lines(2:35, dpois(2:35, 17), type = "b", col="blue", pch=16) #overlay pmf for Pois(17)

curve(dnorm(x, mean=17, sd=sqrt(17)), lwd=2, add=TRUE, col="red")
```



The Central Limit Theorem

Central limit theorem (Den central grænseværdisætning) siger at for en stikprøve med middelværdi μ og varians σ^2 er $\bar{X}$. approksimativt normalfordelt:

Sætning (Thm. 4.2 (4.3.1 i [Chihara and Hesterberg(2018)]))

Let $X_1, X_2, \dots, X_n$ be independent, identically distributed random variables with mean μ and variance σ^2 , both finite. Then for any constant z ,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z \right) = \Phi(z)$$

where Φ is the cdf of the standard normal distribution.

Mange alternative opskrivinger - blandt andet

$$Z \stackrel{\text{def}}{=} \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{\bar{X} - \mathbb{E}[\bar{X}]}{\text{SE}[\bar{X}]}$$

Anvendelser af CLT

Example 4.7

Lad $X_1, X_2, \dots, X_{30}$ være en stikprøve fra gamma fordelingen med form-parameter $r = 5$ og rate-paramter $\lambda = 2$. Benyt CLT til at approksimere $\mathbb{P}(\bar{X} > 3)$.

Vi finder

$$\mathbb{P}(\bar{X} > 3) \approx \mathbb{P}(Z > 2.4495) = 1 - \Phi(2.4495) = 0.0072.$$

Vi kan også benytte simulation the at finde en approksimation til $\text{Prob}(\bar{X} > 3)$.

Example 4.8

Er det plausibelt at $\bar{x} = 21.9$, hvis vi står med en stikprøve med $n = 17$ observationer fra Gamma(100, 5)-fordelingen?

Anvendelser af CLT - Normalapproximation for binomialfordelingen

Sætning (Corollary 4.2 (4.3.2 i [Chihara and Hesterberg(2018)]))

Let $X \sim \text{Binom}(n, p)$ være en binomialfordelt stokastisk variabel og lad $\hat{p} = X/n$ være frekvensen af "succes"-er. Hvis både np og $n(1 - p)$ er store, så er fordelingen af $\hat{p}$ approksimativt normal, med middelværdi p og spredning $\sqrt{p(1 - p)/n}$.

Tilsvarende er fordelingen af X approksimativt normal med middelværdi np og spredning $\sqrt{np(1 - p)}$.

Eksempler:

Example 4.10

Hvis 28% af >25-årige har en bachelorgrad, hvad er sandsynligheden for at mindst 30% af deltagerne i en stikprøve med $n = 64$ individer har en bachelorgrad?

Example 4.11

Lad $X \sim \text{Binom}(120, 0.3)$ beregn $\mathbb{P}(X \leq 25)$.

Bibliografi

 Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (2nd edition).
John Wiley & Sons, 2018.

 H. Pishro-Nik.

Introduction to Probability, Statistics, and Random Processes.
Kappa Research, LLC, 2014.
ISBN 9780990637202.
URL

https://books.google.dk/books?id=3yq_oQEACAAJ.

Matematisk Statistik

Konfidensintervaller

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Motiverende eksempel

Example 7.1

Data $\mathbf{x}$ udgør en stikprøve $n = 150$ fra $N(\mu, 24.6^2)$ fordelingen.

Estimatet for μ er $\bar{x} = 95$ pund. Hvor præcist er estimatet?

Observation: I modellen gælder $\bar{X} \sim N(\mu, 24.6^2/150)$ så vi kan regne:

$$\begin{aligned} 0.95 &= \mathbb{P}(-1.96 < \frac{\bar{X} - \mu}{24.6/\sqrt{150}} < 1.96) \\ &= \mathbb{P}(\bar{X} - 3.937 < \mu < \bar{X} + 3.937) \end{aligned}$$

Fra Supp s. 19. 95% K.I. når variansen er kendt:

$$\bar{X} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \leq \mu \leq \bar{X} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2}$$

Med $\bar{x} = 95$ bliver konfidensintervallet (91.1, 98.9).

R-note fra MSRR

```
counter <- 0
# set counter to 0
plot(x = c(22, 28), y = c(1, 100), type = "n", xlab = "", ylab = "")
# set up a blank plot with specified ranges
for (i in 1:1000)
{
  x <- rnorm(30, 25, 4) # draw a random sample of size 30
  L <- mean(x) - 1.96*4/sqrt(30) # lower limit
  U <- mean(x) + 1.96*4/sqrt(30) # upper limit
  if (L < 25 && 25 < U) # check if 25 is in interval
    counter <- counter + 1 # if yes, increase counter by 1
  if (i <= 100) # plot first 100 intervals
    segments(L, i, U, i)
}
abline(v = 25, col = "red") # vertical line at mu
counter/1000 # proportion of times interval contains mu
```

R-note fra MSRR - Figur 7.1




Figure 7.1 Random confidence intervals, $X_i \sim N(25, 4^2)$, $n = 30$. Notice that several miss the mean 25.

Konfidensintervaller - fortolkning

Example 7.2 An engineer tests the gas mileage of a random sample of 30 of a certain car model that are ready to be sold. The 95% confidence interval for the mean mileage of all the cars is (29.5, 33.4) miles per gallon. Critique the following statements:

- 1) We are 95% confident that the gas mileage for cars of this model is between 29.5 and 33.4 mpg.
- 2) 95% of all samples will give an average mileage between 29.5 and 33.4 mpg.
- 3) There is a 95% chance that the true mean is between 29.5 and 33.4 mpg.

- Konfidensintervaller vedrører populationsparametre, ikke individer. (*prædiktionsintervaller* vedrører individer).
- Et konkret konfidensinterval er knyttet den specifikke stikprøve og en nye stikprøve vil give et nyt konfidensinterval.
- Populationsparameteren er et fast (ukendt) ikke-tilfældigt tal.

Konfidensintervaller for middelværdien, kendt varians.

Model: Observationerne $x_1, \dots, x_n$ er realisationer af de uafhængige og identisk fordelte stokastiske variable

$$X_1, \dots, X_n, X_i \sim N(\mu, \sigma_0^2), i = 1, \dots, n$$

$$\left\{ \mu \mid \bar{x} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \leq \mu \leq \bar{x} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \right\}$$

som er udfald af det stokastiske interval

$$\left\{ \mu \mid \bar{X} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \leq \mu \leq \bar{X} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \right\}$$

Findes i Afsnit 8.3.3 i IPSR, Afsnit 2.1 i Supp. og findes i MSRR:

Z Confidence Interval for a Normal Mean with Known Standard Deviation

If $X_i \sim N(\mu, \sigma^2), i = 1 \dots n$, with σ known, then a $(1 - \alpha) \times 100\%$ confidence interval for μ is given by

$$\left(\bar{X} - q \frac{\sigma}{\sqrt{n}}, \bar{X} + q \frac{\sigma}{\sqrt{n}} \right), \quad (7.3)$$

where q denotes the $(1 - \alpha/2)$ quantile of $N(0, 1)$.

It is common to notate the $(1 - \alpha/2)$ quantile, $q_{1-\alpha/2}$, for a $N(0, 1)$ distribution as $z_{\alpha/2}$ and write the interval as $\bar{X} \pm z_{\alpha/2} (\sigma / \sqrt{n})$.

Margin of Error

Ofte er konfidensintervallerne symmetriske og på formen:

$$(\text{estimat} \pm \text{“noget”})$$

I dette tilfælde kaldes “noget”-leddet for *margin of error (MOE)*.

I det foregående eksempel er $\text{MOE} = u_{1-\alpha/2}\sigma_0/\sqrt{n}$.

Konfidensinterval for μ i modellen med en observationsrække fra modellen

$$M_1 : X_i \sim N(\mu, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

fra (2.9) fandtes til

$$\left\{ \mu \mid \bar{x} - \sqrt{\frac{s^2}{n}} t_{1-\alpha/2}(n-1) \leq \mu \leq \bar{x} + \sqrt{\frac{s^2}{n}} t_{1-\alpha/2}(n-1) \right\}$$

hvor $t_{1-\alpha/2}(n-1)$ er $1 - \alpha/2$ fraktilen i t -fordelingen med

$$n - 1$$

frihedsgrader, og $s^2 = s^2(\mathbf{x}) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ er estimatet for variansen.

Findes (også) i Afsnit 8.3.3 i IPSR og i MSRR:

7 Confidence Interval for a Normal Mean with Unknown Standard Deviation

If $X_i \sim N(\mu, \sigma^2)$, $i = 1 \dots n$, with σ unknown, then a $(1 - \alpha) \times 100\%$ confidence interval for μ is given by

$$\left(\bar{X} - g \frac{S}{\sqrt{n}}, \bar{X} + g \frac{S}{\sqrt{n}} \right), \quad (7.4)$$

where g denotes the $(1 - \alpha/2)$ quantile of the t distribution with $(n - 1)$ degrees of freedom.

It is common to notate the $(1 - \alpha/2)$ quantile, $g_{1-\alpha/2}$, for a t distribution with $n - 1$ degrees of freedom as $t_{\alpha/2, n-1}$ and write the interval as $\bar{X} \pm t_{\alpha/2, n-1} (s/\sqrt{n})$.

KI-er for middelværdien, ukendt varians. Figure 7.3




Figure 7.3 og Figure 7.4 illustrerer at t -fordelingen har tungere haler end normalfordelingen.

Robustheden af konfidensintervaller overfor afvigelser fra antagelsen om at observationerne er normalfordelte kan undersøges v.h.a. simulation og illustreres ved at se på sampling distribution af $T = (\bar{X} - \mu)/(s/\sqrt{n})$:




Figure 7.6 Quantile-quantile plot of t statistics versus a t distribution with $n - 1$ degrees of freedom for samples from (a) a uniform distribution with $n = 10$, (b) an exponential distribution with $n = 10$, and (c) an exponential distribution with $n = 100$.

KI for differens af middelværdier Supp 3.1 , MSRR 7.1.3

I modellen for to observationsrækker med forskellig varians:

$$M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed ,}$$

fra Afsnit 3.1.3 fandt vi konfidensintervallet for $\mu_1 - \mu_2$ til

$$\left\{ \bar{x}_1 - \bar{x}_2 - \sqrt{\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2}} t_{1-\alpha/2}(\bar{f}) \leq \mu_1 - \mu_2 \leq \bar{x}_1 - \bar{x}_2 + \sqrt{\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2}} t_{1-\alpha/2}(\bar{f}) \right\}.$$

hvor $\bar{f}$ fandtes i (3.17). (Welch's test)

I MSRR bogen:

T Confidence Interval for a Normal Difference in Means

If $X_i \sim N(\mu_1, \sigma_1^2)$, $i = 1, 2, \dots, n_1$ and $Y_j \sim N(\mu_2, \sigma_2^2)$, $j = 1, 2, \dots, n_2$, then an approximate $(1 - \alpha) \times 100\%$ confidence interval for $\mu_1 - \mu_2$ is

$$(\bar{X} - \bar{Y}) \pm q \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \quad (7.8)$$

where the degrees of freedom ν is given by Equation 7.7 and q denotes the $(1 - \alpha/2)$ quantile of the t distribution with ν degrees of freedom.

Robusthed af konfidensintervaller for 2 stikprøver

MSRR 7.1.3.1




Figure 7.8 Quantile-quantile plot of t statistics versus a t distribution when both samples are exponential and when the sample sizes are (a) $n_1 = 10, n_2 = 10$, (b) $n_1 = 10, n_2 = 15$, and (c) $n_1 = 10, n_2 = 100$. The degrees of freedom for the theoretical t quantiles are obtained using known variances in Welch's approximation.

Problemet med skævhed af den bagvedliggende fordeling er mindre når vi undersøger differens af to middelværdier.

I MSRR bogen findes også en udledning af konfidensintervallet i situationen med varianshomogenitet, men MSRR anbefaler ikke at bruge dette test.

For en generel parameter $\theta \in \Theta \subseteq \mathbb{R}^k$ kan vi betragte en *område-estimator*, som er en stokastisk mængde $R(\mathbf{X}) \subseteq \Theta$ og vi indfører da *dækningsgraden/dækningssandsynligheden* til at være

$$\mathbb{P}_{\theta}(\theta \in R(\mathbf{X})).$$

Et $1 - \alpha$ -konfidensområde skal opfylde

$$\mathbb{P}_{\theta}(\theta \in R(\mathbf{X})) \geq 1 - \alpha \quad \theta \in \Theta$$

I det en-dimensionale tilfælde betragtes konfidensintervaller og disse angives vi deres nedre og øvre grænse: $L = g_1(\mathbf{X})$, $U = g_2(\mathbf{X})$ og skal altså opfylde

$$\mathbb{P}_{\theta}(L \leq \theta \leq U) \geq 1 - \alpha.$$

I en statistisk model hvor fordelingen af $\mathbf{X}$ afhænger af $\theta \in \Theta$ kaldes en funktion

$$h : \mathcal{X} \times \Theta \rightarrow \mathbb{R}$$

en *pivot*, hvis fordelingen af

$$Y = h(X_1, \dots, X_n, \theta)$$

ikke afhænger af θ .

Konstruktion af konfidensintervaller

- Find en pivot $h(\cdot, \theta)$.
- Bestem

$$q_1 = \alpha/2\text{-fraktil}$$

$$q_2 = 1 - \alpha/2\text{-fraktil}$$

for $Y = h(\mathbf{X}, \theta)$

- Løs ligningerne

$$q_1 = h(\mathbf{X}, \theta) \quad \text{og} \quad q_2 = h(\mathbf{X}, \theta)$$

for θ for at finde intervalgrænserne L og U .

I Supp Afsnit 1.2 indførte vi *positions-skala familien frembragt af F_Y*

$$\mathcal{F} = \{F_Y(\frac{x - \theta_L}{\theta_S}) \mid \theta_L \in \mathbb{R}, \theta_S > 0\}$$

hvor F_Y er fordelingsfunktion for en stokastisk variabel Y .

Vi kan også betragte de to ting (position og skala) hver for sig: En positions-familie frembragt F_Y er klassen

$$\mathcal{F} = \{F_Y(x - \theta) \mid \theta \in \mathbb{R}\}$$

og tilsvarende er en skala-familie

$$\mathcal{F} = \{F_Y(x/\theta) \mid \theta > 0\}.$$

Pivoter i positions- og skalafamilier MSRR 7.2.1 og Supp Afsnit 1.2

- Hvis $\hat{\theta}$ en estimator til parameteren af en positions-familie, med

$$\hat{\theta}(X_1 + a, \dots, X_n + a) = \hat{\theta}(X_1, \dots, X_n) + a$$

så er $\hat{\theta} - \theta$ pivot.

- Hvis $\hat{\theta}$ en estimator til parameteren af en skala-familie, med

$$\hat{\theta}(bX_1, \dots, bX_n) = b\hat{\theta}(X_1, \dots, X_n)$$

så er $\hat{\theta}/\theta$ pivot.

- Hvis $\hat{\theta}_L$ og $\hat{\theta}_S$ er estimatorer for parametrene i en positions-skala familie og hvis

$$\hat{\theta}_L(bX_1 + a, \dots, bX_n + a) = b\hat{\theta}_L(X_1, \dots, X_n) + a$$

$$\hat{\theta}_S(bX_1 + a, \dots, bX_n + a) = b\hat{\theta}_S(X_1, \dots, X_n)$$

så er $\hat{\theta}_S/\theta_S$ og $(\hat{\theta}_L - \theta_L)/\theta_S$ pivoter.

Inversion af signifikanstest Supp Afsnit 1.2

Remark Indeed “thinking backward” yields a very general way to create confidence intervals, to *invert a significance test* – to let the confidence interval include all values of θ for which a two-sided significance test would not reject the null hypothesis for that θ .

Vi kan også indføre konfidensområder som

$$C_{1-\alpha}(\mathbf{x}) = \{ \theta_0 \mid \text{hypotesen } H_0 : \theta = \theta_0 \text{ accepteres ved et signi-} \\ \text{fikanstest på niveau } \alpha \text{ på grundlag af data } \mathbf{x} \}.$$

Dette er gjort i (6.23) i Supp.

Under svage antagelser vil der gælde at

$$\mathbb{P}(\theta \in C_{1-\alpha}(\mathbf{X})) = 1 - \alpha \quad \theta \in \Theta.$$

Det er vist i Kapitel 2 i Supp at for t -testet og u -testet giver denne metode de konfidensintervaller, som I kender fra ISS og MSRR Afsnit 7.1.2.

Fra ISS ved I, at for en normalfordelt stikprøve $X_1, \dots, X_n \stackrel{i.i.d}{\sim} N(\mu, \sigma_0^2)$ kan hypotesen kan testoren $W = \sqrt{n}(\bar{X} - \mu_0)/\sigma_0$ bruges til at vurdere hypotesen $H : \mu = \mu_0$ i modellen hvor $\mu \leq \mu_0$. Der gælder

$$p_{\text{obs}}(\mathbf{x}) = \Phi(w_1)$$

hvor $w_1 = \sqrt{n}(\bar{X} - \mu_0)/\sigma_0$ er den observerede værdi af W (teststørrelsen).

I MSRR Afsnit 8.6.2 vises at dette også kan udledes som et likelihood ratio test.

Når variansen er ukendt er testoren $W = \sqrt{n}(\bar{X} - \mu_0)/s$ hvor $s^2 = s^2(\mathbf{X})$ er den middelværdidirekte estimator for variansen og der gælder her

$$p_{\text{obs}}(\mathbf{x}) = F_{t(n-1)}(w_1)$$

Ensidede konfidensintervaller er konfidensintervaller på formen $(-\infty, U]$ eller $[L, \infty)$, og kan findes ved hjælp af pivoter eller ved at invertere hypotese-test.

Eksempler: Når $X_1, \dots, X_n \stackrel{i.i.d}{\sim} N(\mu, \sigma^2)$ bliver et nedre $1 - \alpha$ -konfidens interval

$$(-\infty, \bar{X} + t_{1-\alpha}(n-1) \frac{s}{\sqrt{n}}]$$

og et øvre $1 - \alpha$ -konfidens interval

$$[\bar{X} - t_{1-\alpha}(n-1) \frac{s}{\sqrt{n}}, \infty)$$

One-sided Confidence Interval for a Normal Mean

If $X_1, X_2, \dots, X_n$ are a random sample from a normal distribution with unknown mean μ , and q is the $(1 - \alpha)$ quantile of the t distribution with $n - 1$ degrees of freedom, then a $(1 - \alpha) \times 100\%$ lower confidence bound is

$$\bar{X} - q \frac{s}{\sqrt{n}} \leq \mu$$

with corresponding upper confidence interval

$$[\bar{X} - q \frac{s}{\sqrt{n}}, \infty)$$

and a $(1 - \alpha) \times 100\%$ upper confidence bound is

$$\mu \leq \bar{X} + q \frac{s}{\sqrt{n}}$$

with corresponding lower confidence interval

$$(-\infty, \bar{X} + q \frac{s}{\sqrt{n}}]$$

Konfidensinterval for binomialfordelingen MSRR 7.4

Model: Data x er udfald af en stokastisk variabel $X \sim \text{Binom}(n, p)$.

Estimatoren for p er $\hat{p} = X/n$ og vi ved fra korollar 4.3.2 at

$Z = (\hat{p} - p) / \sqrt{p(1-p)/n}$ er approksimativt standard normalfordelt og dermed

$$\mathbb{P}(-u_{1-\frac{\alpha}{2}} < \frac{\hat{p} - p}{\sqrt{p(1-p)/n}} < u_{1-\frac{\alpha}{2}}) = 1 - \alpha$$

konfidensintervallets nedre grænser L og U er løsninger til

$$\frac{\hat{p} - p}{\sqrt{p(1-p)/n}} = u_{1-\frac{\alpha}{2}}$$

(samme løsninger til $\frac{\hat{p} - p}{\sqrt{p(1-p)/n}} = -u_{1-\frac{\alpha}{2}}$)

Dette giver konfidensintervallet (L, U) hvor

$$L = \frac{\hat{p} + \frac{u_{1-\alpha/2}^2}{2n} - u_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{u_{1-\alpha/2}^2}{4n^2}}}{1 + \frac{u_{1-\alpha/2}^2}{n}},$$

og

$$U = \frac{\hat{p} + \frac{u_{1-\alpha/2}^2}{2n} + u_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{u_{1-\alpha/2}^2}{4n^2}}}{1 + \frac{u_{1-\alpha/2}^2}{n}}.$$

Dette resultat er givet i Theorem 7.2 i
[Chihara and Hesterberg(2022)][‡].

[‡]Theorem 7.4.1 i [Chihara and Hesterberg(2018)]

Hypotesetests for middelværdier MSRR 8.1 og MSRR 8.3.1

Både t -test for $H : \mu = \mu_0$ i modellen

$$M_1 : X_i \sim N(\mu, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

fra (2.9) og t -test for $H : \mu_1 = \mu_2$ i modellen

$$M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed,}$$

fra Afsnit 3.1.3 findes i MSRR:

T-Test for a Normal Mean

Let $X_1, X_2, \dots, X_n$ be a random sample from a normal population with unknown μ and σ . Let $\bar{X}$ and S denote the sample mean and standard deviation. To test

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_A : \mu \neq \mu_0,$$

we form the t -test statistic

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}.$$

Under the null hypothesis, T has a t distribution with $(n - 1)$ degrees of freedom. The P -value is the probability that chance alone would produce a test statistic as extreme as or more extreme than the observed value $t = (\bar{x} - \mu_0)/(s/\sqrt{n})$, if the null hypothesis is true.

Two Sample t-Test For Difference of Normal Means

Let $X_1, X_2, \dots, X_{n_1} \sim N(\mu_1, \sigma_1^2)$ and $Y_1, Y_2, \dots, Y_{n_2} \sim N(\mu_2, \sigma_2^2)$ be two independent normal random samples with sample means and standard deviations $\bar{X}, S_1$ and $\bar{Y}, S_2$, respectively. To test

$$H_0 : \mu_1 = \mu_2 \quad \text{versus} \quad H_A : \mu_1 \neq \mu_2,$$

we form the test statistic

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}.$$

If the null hypothesis is true, then T has approximately a t distribution with degrees of freedom given by Equation 7.7.

The P -value is the probability that chance alone would produce a test statistic as extreme or more extreme than the observed value if the null hypothesis is true.

Hvis vi betragter en model hvor x er udfald af en binomialfordelt stokastisk variabel X hvor

$$M_1 : X \sim \text{binom}(n, p),$$

kan vi være interesserede i at undersøge $H : p = p_0$. Vi ved at i M_1 gælder at $\hat{p} = X/n$, så samme argument som ved t -testet i normalfordelingen leder frem til følgende:

One-sample Proportion Test

Let X be a binomial random variable, $X \sim \text{Binom}(n, p)$. Suppose $X = x$ is observed. To test

$$H_0 : p = p_0 \quad \text{versus} \quad H_A : p \neq p_0,$$

we compute $P(X \geq x)$ if $x \geq np_0$ or $P(X \leq x)$ if $x \leq np_0$.

For instance,

$$P(X \geq x) = \sum_{i=x}^n \binom{n}{i} p_0^i (1-p_0)^{n-i}.$$

For the two-sided test, we double this probability to obtain the P -value.

Vi betragter en hypotese $H_0 : \theta \in \Theta_0 \subset \Theta$ og husker at et test er en opdeling af $\mathcal{X}$ i disjunkte mængder:

$$R = \{\mathbf{x} \in \mathcal{X} : H_0 \text{ forkastes på grundlag af } \mathbf{x}\}$$

$$A = \{\mathbf{x} \in \mathcal{X} : H_0 \text{ forkastes ikke på grundlag af } \mathbf{x}\},$$

og at vi for en testor T betragtede vi $\mathcal{T}_R$ hvor

$$R = T^{-1}(\mathcal{T}_R) = \{\mathbf{x} \in \mathcal{X} : T(\mathbf{x}) \in \mathcal{T}_R\}$$

	H_0 forkastes	H_0 accepteres
H_0 sand	type I	ingen
H_0 falsk	ingen	type II

De forskellige typer af fejl i testteorien.

	H_0 forkastes	H_0 accepteres
H_0 sand	type I	ingen
H_0 falsk	ingen	type II

Vi kan da betragte *styrkefunktionen*

$$pow(\theta) = P_{\theta}(T \in \mathcal{T}_R), \quad \theta \in \Theta.$$

I ord: Sandsynligheden for at afvise H_0 når den sande parameter er θ .
Vi kan også betragte sandsynligheden for at lave en fejl af type II, denne betegnes $\beta(\theta)$

$$\beta(\theta) = \mathbb{P}_{\theta}(\text{acceptere } H_0 \mid H_0 \text{ er falsk}) = 1 - pow(\theta) \quad \theta \in \Theta \setminus \Theta_0.$$

Definition 8.4 *Power* is the probability of correctly rejecting a false null hypothesis.

$$1 - \beta = P(\text{Reject } H_0 \mid H_A \text{ true}).$$

||

I simple tilfælde kan styrkefunktionen beregnes, f.eks. Example 8.17 i MSRR

Illustration:




Figure 8.4 Distributions under the null and alternative hypotheses. Shaded regions represent power ($1 - \beta$) and significance level (α). Moving the critical value ($\mu_0 + q\sigma / \sqrt{n}$) to the left increases power.

Neyman-Pearson Lemmaet fortæller at hvis vi lægger os fast på en sandsynlighed for type I fejl, kan vi for simple hypoteser finde et test med størst mulig styrke:

Theorem 8.6.1 (The Neyman–Pearson Lemma) Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with parameter θ . Suppose we wish to test two simple hypotheses

$$H_0 : \theta = \theta_0 \quad \text{versus} \quad H_A : \theta = \theta_A.$$

The LRT rejects the null hypothesis if the test statistic $T = L(\theta_0)/L(\theta_A)$ satisfies $T < c$ at a significance level α . Then any test with significance level less than or equal to α has power less than or equal to the power for this LRT. That is, for a fixed α , the LRT minimizes the probability of a type II error. $\square$

Bibliografi

 Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (2nd edition).

John Wiley & Sons, 2018.

 Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (3rd edition).

John Wiley & Sons, 2022.

Matematisk Statistik

Multinomialmodellen

Lars Nørvang Andersen

Multinomialmodellen




Binomial: falde i en ud af to kasser



Multinomial: falde i en ud af 6 kasser

Multinomial: Inddele data i k kasser



Teste hypotese om sandsynlighederne for at falde i kasserne
Eksempel: Teste at en terning er "fair"

seks kasser, teste sandsynlighed er $\frac{1}{6}$ for hver kasse

Multinomialfordeling

Binomialmodel: n delforsøg hver med to kasser (1 eller 2)

X = antal gange hvor kasse 1 rammes ($n - X$ rammer kasse 2)

Multinomial: n delforsøg hver med k kasser ($1, 2, \dots, k$)

A_j = antal gange kasse j rammes: $A_1 + A_2 + \dots + A_k = n$

π_j : sandsynlighed for at ramme kasse j : $\pi_1 + \pi_2 + \dots + \pi_k = 1$

$(A_1, A_2, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \pi_2, \dots, \pi_k))$

I ord: multinomialfordelt med antalsværdi n og sandsynlighedsparameter $\pi = (\pi_1, \dots, \pi_k)$

Eksempel: Embryoer af zebrafisk i nanopartikelopløsning



Dødstidspunkt delt op på 3 kasser:

kasse 1: 0-48 timer, kasse 2: 48-96 timer, kasse 3: over 96 timer

$$a_1 = 15, \quad a_2 = 19, \quad a_3 = 66, \quad n = 100$$

Hypotese: Samme dødsrate i de tre perioder

Hypotese: $P(\text{kasse 1}) = \theta$, $P(\text{kasse 2}) = (1 - \theta)\theta$, $P(\text{kasse 3}) = (1 - \theta)^2$

Skøn over θ : $\hat{\theta} = \frac{a_1 + a_2}{a_1 + a_2 + a_2 + 2a_3} = 0.1838$ (metode: se senere)

Zebrafisk: test

Forventede under hypotesen:

$$e_1 = n\hat{\theta}, \quad e_2 = n(1 - \hat{\theta})\hat{\theta}, \quad e_3 = n(1 - \hat{\theta})^2$$

Kasse	1	2	3	Total
Observerede a_j	15	19	66	100
Forventede e_j	18.38	15.00	66.62	100

Hvordan skal man sammenligne 3 observerede tal med 3 forventede ?


Teststørrelse forklares nedenfor

$$\begin{aligned} \text{Teststørrelse: } G &= 2 \left(a_1 \cdot \log \left(\frac{a_1}{e_1} \right) + a_2 \cdot \log \left(\frac{a_2}{e_2} \right) + a_3 \cdot \log \left(\frac{a_3}{e_3} \right) \right) \\ &= 2 \left(15 \cdot \log \left(\frac{15}{18.38} \right) + 19 \cdot \log \left(\frac{19}{15.00} \right) + 66 \cdot \log \left(\frac{66}{66.62} \right) \right) = 1.6522 \end{aligned}$$

Store værdier er kritiske for hypotesen

Zebrafisk: test

$$p\text{-værdi} \\ = P(G(X) \geq 1.6522):$$



Hvor ofte vil man ved gentagelse af eksperimentet få en værdi større end 1.6522 under forudsætning af samme dødelighed (hypotesen)?

P-værdi kan ikke beregnes eksakt, og vi benytter approksimativ likelihood teori. Man kan vise at fordelingen af den stokastiske variabel G ligner en χ^2 -fordeling.

Approximation gyldig hvis alle $e_j \geq 5$:

$$p\text{-værdi} \approx 1 - F_{\chi^2(3-1-1)}(1.6522) = 0.199$$

Data strider ikke mod samme dødsrate da $p\text{-værdi} > 0.05$

beregninger i R

På nedenstående R-kode gennemføres beregningerne i R.

```
observerede = c(15,19,66) #indtast datasæt
n = 100
thetahat = 0.1838
forventede = n*c(thetahat, (1-thetahat)*thetahat, (1-thetahat)^2) #beregner forventede
Gobs = 2*sum((observerede*log(observerede/forventede))) #beregner teststørrelse
1-pchisq(Gobs, 3-1-1) #beregner p-værdi
```

Output bliver:

```
> Gobs
[1] 1.651205
> 1-pchisq(Gobs, 3-1-1)
[1] 0.198795
```

Vi kan benytte et simulationseksperiment til at illustrere at når hypotesen er sand, har G en $\chi^2(1)$ fordeling og sammenligne med G_{obs} .

Simulationseksperiment

```
nsim=1000000
th=0.1838
n=100

#Nedenstående giver en 1000000 x 3 vektor med multinomialfordelte udfald
x=t(rmultinom(nsim,n,c(th, (1-th)*th, (1-th)^2)))

thhat=(x[,1]+x[,2])/(x[,1]+2*x[,2]+2*x[,3])
e1=n*thhat; e2=n*thhat*(1-thhat); e3=n*(1-thhat)^2
x1=ifelse(x==0,1,x)
G=2*(x[,1]*log(x1[,1]/e1)+x[,2]*log(x1[,2]/e2)+
        x[,3]*log(x1[,3]/e3))

hist(G,breaks=seq(from=0,to=ceiling(max(G)),length.out=100),probability=TRUE)
curve(dchisq(x,df=1),from=0,to=20,add=TRUE,lwd=2)
abline(v = 1.6522,col="red",lwd=2)
mean(G >1.6522)
```

Multinomialmodel: detaljer

$$P((A_1, A_2, \dots, A_k) = (a_1, a_2, \dots, a_k)) = \binom{n}{a_1 \dots a_k} \pi_1^{a_1} \pi_2^{a_2} \dots \pi_k^{a_k}$$

Model M_0 : π kan variere frit:

$$\pi_j \geq 0, \pi_1 + \pi_2 + \dots + \pi_k = 1$$

skøn over π_j : observeret frekvens: $\hat{\pi}_j(M_0) = \frac{a_j}{n}, \quad j = 1, \dots, k$

Dette er maksimumspunktet for likelihoodfunktionen:

$$L(\pi) = \binom{n}{a_1 \dots a_k} \pi_1^{a_1} \cdot \pi_2^{a_2} \dots \pi_k^{a_k}$$

= sandsynligheden for det observerede som funktion af parameteren

Bevis

Hvis $(A_1, A_2, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \pi_2, \dots, \pi_k))$ så er

$$A_1 \sim \text{binom}(n, \pi_1)$$

skøn over π_1 : maximere $L_{A_1}(\pi_1) \propto \pi_1^{A_1} (1 - \pi_1)^{n-A_1}$, $\hat{\pi}_1 = \frac{A_1}{n}$

Generelt: Likelihoodfunktion $L(\pi_1, \dots, \pi_k) \propto \pi_1^{A_1} \pi_2^{A_2} \dots \pi_k^{A_k}$

indfør $\pi_1 = p$, $v_j = \frac{\pi_j}{1-p}$, $v_j \geq 0$, $v_2 + \dots + v_k = 1$ så

$$\pi_1^{A_1} \pi_2^{A_2} \dots \pi_k^{A_k} = \left\{ p^{A_1} (1-p)^{n-A_1} \right\} \cdot \left\{ v_2^{A_2} \dots v_k^{A_k} \right\},$$

p og $(v_2 \dots v_k)$ varierer uafhængigt af hinanden og de to udtryk kan maximeres hver for sig.

Ovenstående svarer til opsplitting:

$$L(\pi_1, \dots, \pi_k) = L_{A_1}(\pi_1) L_{A|A_1}(\pi_1, \dots, \pi_k)$$

Multinomialkoefficient

Fortolkning: antallet af måder, hvorpå man kan fordele n elementer i k kasser, med a_j elementer i kasse j , $j = 1, \dots, k$.

formel:
$$\binom{n}{a_1 \dots a_k} = \frac{n!}{a_1! \cdot a_2! \cdot \dots \cdot a_k!}$$

Eksempel: $\binom{4}{2,1,1} = \frac{24}{2 \cdot 1 \cdot 1} = 12$

A	B	C	D
1	1	2	3
1	1	3	2
1	2	1	3
1	3	1	2
1	2	3	1
1	3	2	1
2	1	1	3
3	1	1	2
2	1	3	1
3	1	2	1
2	3	1	1
3	2	1	1

Hypotese og test

Hypotese fra Zebrafisk-eksempel (model M_1): $(\pi_1, \dots, \pi_k)$ har en bestemt form

$$\pi_j = p_j(\theta), \quad p_j \text{ kendt funktion, } \theta \text{ ukendt parameter}$$

$$\theta \text{ har } d \text{ koordinater, } \theta \in \mathbb{R}^d$$

Skøn over θ : den værdi der maksimerer $L(p_1(\theta), \dots, p_k(\theta))$

$$\hat{\pi}_j(M_1) = p_j(\hat{\theta}), \quad \text{forventede } e_j = n \cdot p_j(\hat{\theta})$$

I Zebrafisk-eksemplet er $\theta = \theta$ og

$$\begin{aligned} L(\theta, \theta(1 - \theta), (1 - \theta)^2) &= \theta^{A_1} (\theta(1 - \theta))^{A_2} ((1 - \theta)^2)^{A_3} \\ &= \theta^{A_1 + A_2} (1 - \theta)^{A_2 + 2A_3} \end{aligned}$$

$$\hat{\theta} = \frac{A_1 + A_2}{A_1 + A_2 + A_2 + 2A_3}$$

Hypotese og test

Tesstørrelse: $G = 2 \sum_{i=1}^k A_j \log \left(\frac{A_j}{e_j} \right)$

$$G = -2 \log(Q) = -2 \log \left(\frac{\max_{M_1} L(\pi)}{\max_{M_0} L(\pi)} \right) = -2 \log \left(\frac{L(\hat{\pi}_1(M_1), \dots, \hat{\pi}_k(M_1))}{L(\hat{\pi}_1(M_0), \dots, \hat{\pi}_k(M_0))} \right)$$

p-værdi fra approksimativ likelihood teori: $p\text{-værdi} \approx 1 - F_{\chi^2(k-1-d)}(G)$
(hvis alle $e_j \geq 5$)


$k - 1$: frie parametre i grundmodellen

d : frie parametre under hypotesen

Baggrund - illustration


$\pi_1, \pi_2, \pi_3 = 1 - \pi_1 - \pi_2$, (π_1, π_2) varierer i trekant i M_0

Under M_1 : $(\pi_1, \pi_2) = (\theta, (1 - \theta)\theta)$



Trekant: ML-estimat i M_0 : $(\hat{\pi}_1, \hat{\pi}_2)$, Cirkel: ML-estimat i M_1 : $(\hat{\theta}, \hat{\theta}(1 - \hat{\theta}))$

Baggrund - yderligere illustration



$M_0: (\pi_1, \dots, \pi_k)$ kan variere frit

$$\hat{\pi}_j(M_0) = \frac{A_j}{n}$$

$$L(\hat{\pi}_1(M_0), \dots, \hat{\pi}_k(M_0)) = \binom{n}{A_1, \dots, A_k} \left(\frac{A_1}{n}\right)^{A_1} \dots \left(\frac{A_k}{n}\right)^{A_k}$$

$M_1: \pi_j = p_j(\theta), \quad \theta$ "kan variere frit"

$$\hat{\pi}_j(M_1) = p_j(\hat{\theta})$$

$$L(\hat{\pi}_1(M_1), \dots, \hat{\pi}_k(M_1)) = \binom{n}{A_1, \dots, A_k} p_1(\hat{\theta})^{A_1} \dots p_k(\hat{\theta})^{A_k}$$

$$Q = \frac{\binom{n}{A_1, \dots, A_k} p_1(\hat{\theta})^{A_1} \dots p_k(\hat{\theta})^{A_k}}{\binom{n}{A_1, \dots, A_k} \left(\frac{A_1}{n}\right)^{A_1} \dots \left(\frac{A_k}{n}\right)^{A_k}} = \frac{1}{\left(\frac{A_1}{np_1(\hat{\theta})}\right)^{A_1} \dots \left(\frac{A_k}{np_k(\hat{\theta})}\right)^{A_k}} = \frac{1}{\left(\frac{A_1}{e_1}\right)^{A_1} \dots \left(\frac{A_k}{e_k}\right)^{A_k}},$$

Likelihoodratioetest generelt

$$G = -2 \log(Q) = -2 \log \left(\frac{\max_{M_1} L(\pi)}{\max_{M_0} L(\pi)} \right) = 2 \sum_{j=1}^k A_j \log \left(\frac{A_j}{e_j} \right)$$

Generelt vil G som en approksimation følge en $\chi^2(f)$ med

$$f = d_0 - d_1$$

d er antallet af frie parametre i modellen

Fulde multinomialmodel:

$$\pi_j \geq 0 \quad \pi_1 + \cdots + \pi_k = 1 \text{ har } k - 1 \text{ frie parametre}$$

Model $(\pi_1, \dots, \pi_k) = (\theta, \theta(1 - \theta), (1 - \theta)^2)$ har 1 fri parameter

Resultat 8.3.1

Betragt multinomialmodellen $(A_1, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k))$, $\pi_j \geq 0$, $\pi_1 + \dots + \pi_k = 1$ (model M_0) og hypotesen $\pi_j = p_j(\theta)$, $j = 1, \dots, k$, hvor θ har d frie parametre (model M_1). Betragt testoren

$$G = -2 \ln(Q) = 2 \sum_{j=1}^k A_j \ln \left(\frac{A_j}{e_j} \right), \quad e_j = np_j(\hat{\theta}),$$

og lad G_{obs} være den tilsvarende observerede værdi. Hvis alle de forventede $e_j = np_j(\hat{\theta})$ er større end eller lig med 5, har vi approksimativt

$$p\text{-værdi} = P(G \geq G_{\text{obs}}) = 1 - F_{\chi^2(k-1-d)}(G_{\text{obs}}).$$

Sceneskift

Fra: generelt test i multinomialmodel

Til: teste at data følger en bestemt fordeling




Klassisk goodness of fit test

Bortkiewicz: $n = 280$ observationer af dødsfald ved hestespark inden for et år (20 år, 14 regimenter). Observationer: $x_1, \dots, x_n$, total: 196 dødsfald.

Lad X være antal dødsfald i et år

Undersøge om $X \sim \text{pois}(\lambda)$ for et $\lambda \geq 0$

Skabe overblik over data gennem antalshistogram (søjlehøjde er *antal* i interval).



Grafisk sammenligning

Vælg λ således at poisson sandsynligheder passer bedst med histogram

$$\hat{\lambda} = \bar{x} = \frac{196}{280} = 0.7 \text{ (næste slide)}$$


forventede med værdi 0: $e_1 = 280 \cdot \text{dpois}(0, \hat{\lambda})$

forventede med værdi 1: $e_2 = 280 \cdot \text{dpois}(1, \hat{\lambda})$,

$\vdots$

forventede med værdi ≥ 4 : $e_5 = 280 \cdot (1 - \text{ppois}(3, \hat{\lambda}))$

R : `dpois` (x, λ) udregner sandsynligheder i en $\text{pois}(\lambda)$ -fordeling



Estimation i poissonfordeling

Model: $X_i \sim \text{poisson}(\lambda)$

Likelihoodfunktion: $L(\lambda) = \prod_i \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum x_i}}{\prod x_i!} e^{-n\lambda}$

$$\frac{d}{d\lambda} \log(L(\lambda)) = \frac{\sum x_i}{\lambda} - n \Rightarrow \hat{\lambda} = \frac{1}{n} \sum x_i = \bar{x}.$$

Multinomialmodel

Når vi laver et antalshistogram bliver vi naturligt ledt over i multinomialmodel

A_1 : antal med værdien 0, A_2 : antal med værdien 1

A_3 : antal med værdien 2, A_4 : antal med værdien 3

A_5 : antal med værdier ≥ 4

Model M_0 : $(A_1, \dots, A_5) \sim \text{multinom}(n, \pi)$

π_j vilkårlig, $\pi_1 + \pi_2 + \pi_3 + \pi_4 + \pi_5 = 1$

fortolkning: $\pi_1 = P(X = 0)$, $\pi_2 = P(X = 1)$, $\pi_3 = P(X = 2)$

$\pi_4 = P(X = 3)$, $\pi_5 = P(X \geq 4)$

Multinomialmodel

Hypotese: $\pi_1, \pi_2, \pi_3, \pi_4, \pi_5$ er givet ved at X er poissonfordelt:

der findes $\lambda \geq 0$ således at

$$\pi_1 = \frac{\lambda^0}{0!} e^{-\lambda}, \quad \pi_2 = \frac{\lambda^1}{1!} e^{-\lambda}, \quad \pi_3 = \frac{\lambda^2}{2!} e^{-\lambda}$$

$$\pi_4 = \frac{\lambda^3}{3!} e^{-\lambda}, \quad \pi_5 = 1 - \pi_1 - \pi_2 - \pi_3 - \pi_4$$

Under hypotesen betegnes modellen med M_1 :

teste reduktion fra model M_0 til model M_1

Skøn over λ : benytter $\hat{\lambda} = \bar{x}$.

([Chihara and Hesterberg(2022)] Prop 6.2

[Chihara and Hesterberg(2018)] Prop 6.1.2)

Observerede og forventede

Index	1	2	3	4	5
Værdi	0	1	2	3	≥ 4
A_j	144	91	32	11	2
e_j	139.04	97.33	34.07	7.95	1.61

$$\hat{\lambda} = \frac{196}{280} = 0.7$$

$$e_1 = 280 \cdot \text{dpois}(0, 0.7) = 139.04, \quad e_5 = 280 \cdot (1 - \text{ppois}(3, 0.7)) = 1.61$$

Ønsker $e_j \geq 5$: nødvendigt at slå kasse 4 og 5 sammen

Index	1	2	3	4
Værdi	0	1	2	≥ 3
A_j	144	91	32	13
e_j	139.04	97.33	34.07	9.56

Slå sammen

Index	1	2	3	4
Værdi	0	1	2	≥ 3
A_j	144	91	32	13
e_j	139.04	97.33	34.07	9.56

$k = 4$ kasser, $d = 1$ parameter

$$\text{teststørrelse: } G = 2 \sum_j a_j \log \left(\frac{a_j}{e_j} \right) = 1.84$$

$$p\text{-værdi} = 1 - \text{pchisq}(1.84, 4 - 1 - 1) = 0.399$$

Konklusion: data strider ikke mod poissonfordelingen

Goodness of fit test generelt

Målinger $x_1, x_2, \dots, x_n$ fra stokastisk variabel X

Del talakse op i intervaller:

endepunkter: $z_0, z_1, \dots, z_k$ ($z_0 : -\infty, z_k : +\infty$)

A_j : antal i interval $(z_{j-1}, z_j]$

Model M_0 : $(A_1, \dots, A_k) \sim \text{multinom}(n, \pi)$

π_j vilkårlig, $\pi_1 + \pi_2 + \dots + \pi_k = 1$;

fortolkning: $\pi_j = P(z_{j-1} < X \leq z_j)$

Model M_1 : $\pi_j = p_j(\theta) = F(z_j, \theta) - F(z_{j-1}, \theta), j = 1, \dots, k$

θ ukendt parameter

$P(X \leq z)$ er givet ved $F(z, \theta)$

Poissoneksemplet ovenfor $\theta = \lambda$ - $F(z, \lambda) = \sum_{x=0}^z \frac{\lambda^x}{x!} e^{-\lambda}$


Goodness of fit test generelt

- Find skøn $\hat{\theta}$ over θ
- Udregn $\hat{\pi}_j(M_1) = p_j(\hat{\theta}) = F(z_j, \hat{\theta}) - F(z_j - 1, \hat{\theta})$
- Udregn forventede: $e_j = n \cdot p_j(\hat{\theta})$
- slå eventuelt kasser sammen
- Beregn G -teststørrelse og p -værdi

$$G = 2 \sum \text{observerede} \log \left(\frac{\text{observerede}}{\text{forventede}} \right)$$

Kontinuert variabel: alle værdier er mulige

The average drive distance (in yards) for 199 professional golfers during a week on the men's PGA tour in 2015 (DASL)



Forventede antal i interval $(a, b]$: $\approx n \cdot P(a < X \leq b) = n \int_a^b f(x) dx$

Goodness of fit test: data

Indlæsning: `golfdriives=scan("golf2015.txt")`

Intervalinddeling: `endePkt=260+c(0:12)*5`

antal i intervaller: `a=hist(golfdriives,breaks=endePkt)$counts`

Model M_0 : $(A_1, \dots, A_{12}) \sim (\text{multinom}(199, (\pi_1, \dots, \pi_{12})))$
 $(\pi_1, \dots, \pi_{12})$ kan variere frit

Hypotese (model M_1): der findes μ og σ således at:

$$\pi_1 = p_1(\mu, \sigma) = \text{pnorm}(265, \mu, \sigma),$$

$$\pi_2 = p_2(\mu, \sigma) = \text{pnorm}(270, \mu, \sigma) - \text{pnorm}(265, \mu, \sigma), \dots$$

$$\pi_{11} = p_{11}(\mu, \sigma) = \text{pnorm}(315, \mu, \sigma) - \text{pnorm}(310, \mu, \sigma),$$

$$\pi_{12} = p_{12}(\mu, \sigma) = 1 - \text{pnorm}(315, \mu, \sigma)$$

Goodness of fit test: Finde parameterskøn

Strengt taget bør vi ikke benytte *ML*-estimerne fra en observationsrække.

I stedet:

```
endePkt=260+c(0:12)*5
a=hist(golfdrives,breaks=endePkt,plot=FALSE)$counts

loglik=function(th){
  prob=pnorm(endePkt[2:12],th[1],th[2])
  probInterval=c(prob,1)-c(0,prob)
  return(sum(-a*log(probInterval)))
}

nlm(loglik,c(288,9))
```

Goodness of fit test: forventede

Skøn over μ og σ : $\hat{\mu} = 288.5796$ og $\hat{\sigma} = 9.1315$

(**mean**(golfdrives) = 288.6854 **sd**(golfdrives) = 9.2811)

Beregning af forventede:

```
endePkt=260+c(0:12)*5
```

```
prob=pnorm(endePkt[2:12],288.5796,9.1315)
```

```
ex=199*(c(prob,1)-c(0,prob))
```

Kasse	1	2	3	4	5	6	7	8	9	10	11	12
a_j	1	2	9	23	34	47	37	24	12	9	0	1
e_j	1.0	3.2	9.5	20.9	34.6	42.6	39.2	27.0	13.8	5.3	1.5	0.4

Goodness of fit test: forventede

Vi slår kasse 1 og 2 samme og kasserne 10, 11 og 12 (Cochrans regel)

Kasse	1+2	3	4	5	6	7	8	9	10-12
a_{1j}	3	9	23	34	47	37	24	12	10
e_{1j}	4.2	9.5	20.9	34.6	42.6	39.2	27.0	13.8	7.2


Beregning af G og p -værdi:

```
G=2*sum(a1*log(a1/e1))
```

```
c(G,1-pchisq(G,9-1-2))
```

```
[1] 2.7293672 0.8419664
```

Goodness of fit test: figur



Teste samme rate i flere poissonfordelinger

8 dør af hestespark i løbet af 20 år i regiment 1

17 dør af hestespark i løbet af 20 år i regiment 2

hypotese: samme rate af dødsfald i de to regimenter

Model: $X_1 \sim \text{poisson}(20\lambda_1)$, $X_2 \sim \text{poisson}(20\lambda_2)$

hypotese: $\lambda_1 = \lambda_2$

Intuitivt: hvis samme rate skal de 25 dødsfald fordeles tilfældigt på de to regimenter

Teste proportionale poissonparametre

Generelt: $X_i \sim \text{poisson}(\lambda_i)$, $i = 1, \dots, k$

hypotese: $\lambda_i = m_i \lambda$, m_i kendte tal

Lad $n = X_1 + \dots + X_k$. For "fastholdt" n vil vi have modellen

$$(X_1, X_2, \dots, X_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k))$$
$$\pi_j = \lambda_j / \lambda_{\cdot}, j = 1, \dots, k, \lambda_{\cdot} = \sum_j \lambda_j$$

I denne model testes hypotesen

$$\pi_j = \frac{m_j}{m_{\cdot}}, j = 1, \dots, k, m_{\cdot} = m_1 + \dots + m_k$$

$$\text{Forventede: } e_j = n \frac{m_j}{m_{\cdot}}, j = 1, \dots, k,$$

$$\text{Beregn } G \text{ og } p\text{-værdi} = 1 - \chi_{\text{cdf}}^2(G, k - 1 - 0)$$

Bevis for betingning

$X_i \sim \text{poisson}(\lambda_i), i = 1, \dots, k, X_{\cdot} = X_1 + \dots + X_k \sim \text{poisson}(\lambda_{\cdot})$

$$\lambda_{\cdot} = \lambda_1 + \dots + \lambda_k$$

$$P(X_1 = x_1, \dots, X_k = x_k | X_{\cdot} = n) = \frac{P(X_1 = x_1, \dots, X_k = x_k)}{P(X_{\cdot} = n)} = \frac{\prod_j \frac{\lambda_j^{x_j}}{x_j!} e^{-\lambda_j}}{\frac{\lambda_{\cdot}^n}{n!} e^{-\lambda_{\cdot}}}$$

$$\binom{n}{x_1, \dots, x_k} \left(\frac{\lambda_1}{\lambda_{\cdot}}\right)^{x_1} \dots \left(\frac{\lambda_k}{\lambda_{\cdot}}\right)^{x_k}$$

$$\sim \text{multinom}(n, (\pi_1, \dots, \pi_k)), \pi_j = \frac{\lambda_j}{\lambda_{\cdot}}$$

χ^2 -test

I webbogen bruges teststørrelsen: $G = 2 \sum \text{observeret} \cdot \log \left(\frac{\text{observeret}}{\text{forventet}} \right)$

Ude i verden (og i MSRR) bruges ofte af historiske grunde:

$$C = \sum \frac{(\text{observeret} - \text{forventet})^2}{\text{forventet}}$$

For store datasæt er der ikke forskel. For små datasæt kan χ^2 -approximationen være lidt bedre for G end for C

Bibliografi



Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (2nd edition).

John Wiley & Sons, 2018.



Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (3rd edition).

John Wiley & Sons, 2022.

Matematisk Statistik

Homogenitetstest og test for uafhængighed

Lars Nørvang Andersen



Det er undersøgelser af fedme og overvægt blandt unge på session, der har dokumenteret problemet. Billedet af de værnepligtige er taget på Høvelte Kaserne i anden anledning. Arkivfoto: Carsten Lundager

Kurven er knækket:

Færre fede unge

**Nye sessionstal for værnepligtige viser
overraskende dyk i antallet af fede unge**

Af Morten Herrup Poulsen
mhp@sorndagsavisen.dk

Den eksplosive udvikling af fedme blandt unge har måske kulmineret. Søndagsavisen har gransket de seneste data fra de værnepligtiges session fra andet halvår

2003. De viser overraskende, at andelen af smækfede unge på session er faldet i perioden fra første halvår 2003 til andet halvår 2003.

Det er netop undersøgelser af fedme og overvægt blandt unge på session, der har været med til at dokumentere, at fedme er et hastigt voksende problem i Danmark.

SIDE 3

Periode	Antal på session	Antal med BMI > 30	Procent
1. halvdel 2003	11 527	796	6,9%
2. halvdel 2003	12 259	825	6,7%

Har søndagsavisen ret ?

Umiddelbare formulering: er der forskel mellem de to halvår ?

Eller er data i overensstemmelse med en hypotese om ingen forskel ?

hypotese: Der er samme sandsynlighed for højt BMI i de to halvår.

Statistisk model

	Kasse 1	Kasse 2	Total
Data:			
Gruppe 1	a_1	$n_1 - a_1$	n_1
Gruppe 2	a_2	$n_2 - a_2$	n_2
Sum	$a.$	$n - a.$	n

Statistisk Model (model M_0):

$$A_1 \sim \text{binomial}(n_1, p_1), \quad A_2 \sim \text{binomial}(n_2, p_2) \quad A_1 \perp\!\!\!\perp A_2$$

Hypotese: $p_1 = p_2$ (model M_1)

Parameterskøn under M_0 : $\hat{p}_1 = \frac{A_1}{n_1}$, $\hat{p}_2 = \frac{A_2}{n_2}$

Parameterskøn under M_1 : $\hat{p} = \frac{A.}{n}$ $A. = A_1 + A_2$

Likelihoodratio test

Likelihoodfunktion: $L(p_1, p_2) = \binom{n_1}{A_1} p_1^{A_1} (1 - p_1)^{n_1 - A_1} \binom{n_2}{A_2} p_2^{A_2} (1 - p_2)^{n_2 - A_2}$

$$Q = \frac{\max_p L(p, p)}{\max_{p_1, p_2} L(p_1, p_2)} = \frac{\hat{p}^{A_1} (1 - \hat{p})^{n_1 - A_1} \hat{p}^{A_2} (1 - \hat{p})^{n_2 - A_2}}{\left(\frac{A_1}{n_1}\right)^{A_1} \left(1 - \frac{A_1}{n_1}\right)^{n_1 - A_1} \left(\frac{A_2}{n_2}\right)^{A_2} \left(1 - \frac{A_2}{n_2}\right)^{n_2 - A_2}}$$
$$= \frac{1}{\left(\frac{A_1}{n_1 \hat{p}}\right)^{A_1} \left(\frac{n_1 - A_1}{n_1 (1 - \hat{p})}\right)^{n_1 - A_1} \left(\frac{A_2}{n_2 \hat{p}}\right)^{A_2} \left(\frac{1 - A_2}{n_2 (1 - \hat{p})}\right)^{n_2 - A_2}}$$

Teststørrelse: $G = -2 \log Q$:

$$G = 2 \sum_{4 \text{ celler}} \text{observeret} \cdot \log \left(\frac{\text{observeret}}{\text{forventet}} \right)$$

Forventede: $e_{11} = n_1 \hat{p}$, $e_{12} = n_1 (1 - \hat{p})$, $e_{21} = n_2 \hat{p}$, $e_{22} = n_2 (1 - \hat{p})$

Kritiske værdier: Q lille eller $G = -2 \log(Q)$ stor

Approximation: $G \approx \chi^2(1)$

Sessionstal

Observeret

	BMI < 30	BMI > 30	Total
2003-1	11527	796	12323
2003-2	12259	825	13084
Sum	23786	1621	25407

Forventet

	BMI < 30	BMI > 30
2003-1	11536.78	786.22
2003-2	12249.22	834.78

$$e_{11} = 12323 \cdot \frac{23786}{25407} = 11536.78$$

$$G = 2 \left[11527 \cdot \log \left(\frac{11527}{11536.78} \right) + 796 \cdot \log \left(\frac{796}{786.2236} \right) \right. \\ \left. + 12259 \cdot \log \left(\frac{12259}{12249.22} \right) + 825 \cdot \log \left(\frac{825}{834.7764} \right) \right] = 0.2520978$$

$$p_{\text{obs}} = 1 - F_{\chi^2(1)}(0.2520978) = 0.6156$$

Generel formulering

A_{ij} : Antal i kasse j i den i 'te række

	kasse						
	1	2	...	j	...	k	sum
række 1	a_{11}	a_{12}	...	a_{1j}	...	a_{1k}	n_1
række 2	a_{21}	a_{22}	...	a_{2j}	...	a_{2k}	n_2
...							...
række i	a_{i1}	a_{i2}	...	a_{ij}	...	a_{ik}	n_i
...							...
række r	a_{r1}	a_{r2}	...	a_{rk}	...	a_{rk}	n_r
sum	$a_{.1}$	$a_{.2}$	...	$a_{.j}$	...	$a_{.k}$	n

Række i : $\mathbf{a}_{i*} = (a_{i1}, a_{i2}, \dots, a_{ik})$

Søjlesum: $a_{.j} = a_{1j} + a_{2j} + \dots + a_{rj}$

Homogenitetshypotesen

r grupper eller rækker, $\mathbf{a}_{i*} = (a_{i1}, \dots, a_{ik})$, $\boldsymbol{\pi}_{i*} = (\pi_{i1}, \dots, \pi_{ik})$

Model M_0 : $\mathbf{A}_{1*} \sim \text{multinom}(n_1, \boldsymbol{\pi}_{1*})$
 $\mathbf{A}_{2*} \sim \text{multinom}(n_2, \boldsymbol{\pi}_{2*})$
 $\vdots$
 $\mathbf{A}_{r*} \sim \text{multinom}(n_r, \boldsymbol{\pi}_{r*})$

Rækker er uafhængige, sandsynligheder er vilkårlige i hver række

Homogenitetshypotesen: alle grupperne (eller rækkerne) har det samme sæt sandsynligheder $(\pi_1, \pi_2, \dots, \pi_k)$ (model M_1):

Eller: $\boldsymbol{\pi}_{1*} = \boldsymbol{\pi}_{2*} = \dots = \boldsymbol{\pi}_{r*}$

Homogenitetshypotesen

Fulde model (M_0):

	kasse				sum
	1	2	...	k	
række 1	π_{11}	π_{12}	...	π_{1k}	1
række 2	π_{21}	π_{22}	...	π_{2k}	1
$\vdots$					
række r	π_{r1}	π_{r2}	...	π_{rk}	1

Hypotese (model M_1):

	kasse				sum
	1	2	...	k	
række 1	π_1	π_2	...	π_k	1
række 2	π_1	π_2	...	π_k	1
$\vdots$					
række r	π_1	π_2	...	π_k	1

Estimation

Vi kender estimerterne i en multinomialmodel med frie parametre: under M_0 : $\hat{\pi}_{ij} = \frac{a_{ij}}{n_i}$

Under model M_1 er likelihoodfunktionen

$$L_{M_1}(\pi_1, \dots, \pi_k) = \prod_{i=1}^r \binom{n_i}{\mathbf{a}_{i*}} \pi_1^{a_{i1}} \dots \pi_k^{a_{ik}} \propto \pi_1^{a_{\cdot 1}} \dots \pi_k^{a_{\cdot k}}$$

Estimation af $(\pi_1 \dots \pi_k)$ under model M_1 svarer til at bruge

$$(\mathbf{A}_{\cdot 1} \dots, \mathbf{A}_{\cdot k}) \sim \text{multinom}(n, (\pi_1 \dots \pi_k))$$

Forventede

Under hypotesen estimeres den fælles π ved de observerede frekvenser for de k kasser

$$\hat{\pi}_j = \frac{\sum_i a_{ij}}{n} = \frac{a_{.j}}{n}, j = 1, \dots, k, \quad n = n_1 + \dots + n_k$$

De *forventede* i kasse j for den i 'te gruppe: $e_{ij} = n_i \hat{\pi}_j = \frac{n_i a_{.j}}{n}$

antal i gruppe i gange skøn over sandsynlighed for kasse j

rækkesum gange søjlesum divideret med samlede antal

Likelihood ratio

Likelihoodratio teststørrelse Q :

$$\begin{aligned} Q &= \frac{\max_{M_1} L}{\max_{M_0} L} = \frac{\prod_i \binom{n_i}{\mathbf{a}_{i*}} \hat{\pi}_1^{a_{i1}} \dots \hat{\pi}_k^{a_{ik}}}{\prod_i \binom{n_i}{\mathbf{a}_{i*}} \hat{\pi}_{i1}^{a_{i1}} \dots \hat{\pi}_{ik}^{a_{ik}}} \\ &= \prod_i \prod_j \frac{\hat{\pi}_j^{a_{ij}}}{\hat{\pi}_{ij}^{a_{ij}}} = \prod_i \prod_j \frac{1}{\left(\frac{a_{ij}}{(n_i a_{.j})/n} \right)^{a_{ij}}} \end{aligned}$$

Små værdier af Q er det samme som store værdier af $G = -2 \log(Q)$

$$G = 2 \sum_{i=1}^r \sum_{j=1}^k a_{ij} \log \left(\frac{a_{ij}}{e_{ij}} \right), \quad e_{ij} = \frac{n_i a_{.j}}{n}$$

P-værdi

Teststørrelse: $G_{\text{obs}} = 2 \cdot \sum_{i=1}^r \sum_{j=1}^k a_{ij} \log\left(\frac{a_{ij}}{e_{ij}}\right)$

Approksimativ p -værdi: *Hvis* $e_{ij} \geq 5$, for alle i, j :

$$p\text{-værdi} \approx 1 - F_{\chi^2((r-1)(k-1))}(G_{\text{obs}}) = 1 - \text{pchisq}(G_{\text{obs}}, (r-1)(k-1))$$

Frihedsgrader = $(r-1)(k-1)$: antal rækker minus 1 gange antal søjler minus 1

Nakkesmerter ved brug af smartphone

Observeret antal:

Tidsforbrug	Nakkesmerter		Total
	Nej	Ja	
Lav	16	4	20
Medium	15	19	24
Høj	7	30	37
sum	38	53	91

$\text{Pers}_{ij} \quad i = L, M, H \text{ (lav, medium, høj)}, j = \text{Nej, Ja}$

Model:

$$\begin{aligned}(\text{Pers}_{L,\text{Nej}}, \text{Pers}_{L,\text{Ja}}) &\sim \text{multinom}(20, (\pi_{L,\text{Nej}}, \pi_{L,\text{Ja}})) \\ &\quad \pi_{L,j} \geq 0, \pi_{L,\text{Nej}} + \pi_{L,\text{Ja}} = 1 \\ (\text{Pers}_{M,\text{Nej}}, \text{Pers}_{M,\text{Ja}}) &\sim \text{multinom}(24, (\pi_{M,\text{Nej}}, \pi_{M,\text{Ja}})) \\ &\quad \pi_{M,j} \geq 0, \pi_{M,\text{Nej}} + \pi_{M,\text{Ja}} = 1 \\ (\text{Pers}_{H,\text{Nej}}, \text{Pers}_{H,\text{Ja}}) &\sim \text{multinom}(37, (\pi_{H,\text{Nej}}, \pi_{H,\text{Ja}})) \\ &\quad \pi_{H,j} \geq 0, \pi_{H,\text{Nej}} + \pi_{H,\text{Ja}} = 1\end{aligned}$$

Hypotese: $(\pi_{L,\text{Nej}}, \pi_{L,\text{Ja}}) = (\pi_{M,\text{Nej}}, \pi_{M,\text{Ja}}) = (\pi_{H,\text{Nej}}, \pi_{H,\text{Ja}})$

Beregning i R

```
obs=rbind(c(16,4),c(15,19),c(7,30))

ex=outer(rowSums(obs),colSums(obs))/sum(obs)

obs1=ifelse(obs==0,1,obs)
G=2*sum(obs*log(obs1/ex))

pval=1-pchisq(G,(dim(obs)[1]-1)*(dim(obs)[2]-1))

list(Forventede=ex,G=G,Pvaerdi=pval)
```

rowSums: rækkesummer; colSums: søjlesummer

outer (**x**,**y**): 3×2 matriks indgange $x_i y_j$

Baggrund: Antal frihedsgrader i χ^2 -fordeling generelt

Data $\sim$ model M_0

Hypotese: Data $\sim$ model M_1

Test: $Q = \frac{\max_{M_1} L}{\max_{M_0} L}, \quad G = -2 \log(Q)$

$$p_{\text{obs}} \approx 1 - F_{\chi^2(df)}(G)$$

$df = \text{antal frie parametre i } M_1 - \text{antal frie parametre i } M_2$

Goodness of fit: $df = (k - 1) - d$

Homogenitetstest: $df = r(k - 1) - (k - 1) = (r - 1)(k - 1)$

Introduktion til uafhængighedstest

Skema angiver sandsynlighed for at en tilfældig stoppet bilist jævnligt taler i mobiltelefon under kørsel, og om vedkommende har været indblandet i trafikuheld indenfor de seneste to år:

	uheld	ikke uheld	sum
mobil	0.1	0.1	0.2
ikke mobil	0.1	0.7	0.8
sum	0.2	0.8	1.0

Er risikoen for at have været indblandet i et trafikuheld uafhængig af bilisten snakker i mobil?

Introduktion til uafhængighedstest

Skema angiver sandsynlighed for at en tilfældig person er ryger og om vedkommende er kaffedrikker:

	ryger	ikke ryger	sum
kaffe	0.10	0.30	0.40
ikke kaffe	0.15	0.45	0.60
sum	0.25	0.75	1.00

Er rygevaner uafhængig af kaffedrikning?

Uafhængighed

	ryger	ikke ryger	sum
kaffe	αp	$(1 - \alpha)p$	p
ikke kaffe	$\beta(1 - p)$	$(1 - \beta)(1 - p)$	$(1 - p)$
sum	—	—	1

Uafhængighed: $\frac{\alpha p}{(1 - \alpha)p} = \frac{\beta(1 - p)}{(1 - \beta)(1 - p)}$ eller $\frac{\alpha}{1 - \alpha} = \frac{\beta}{1 - \beta}$

Eller: $\alpha = \beta$

	ryger	ikke ryger	sum
kaffe	αp	$(1 - \alpha)p$	p
ikke kaffe	$\alpha(1 - p)$	$(1 - \alpha)(1 - p)$	$(1 - p)$
sum	α	$1 - \alpha$	1

Produkt!

Uafhængighed

Definition fra ISS : X og Y er uafhængige hvis

$$P(X = x, Y = y) = P(X = x) \cdot P(Y = y)$$

	ryger	ikke ryger	sum
kaffe	αp	$(1 - \alpha)p$	p
ikke kaffe	$\alpha(1 - p)$	$(1 - \alpha)(1 - p)$	$(1 - p)$
sum	α	$1 - \alpha$	1

Test for uafhængighed

Data




Figure 8-16
Biology of Plants, Seventh Edition
© 2005 W.H. Freeman and Company

Data

Genetisk eksperiment: nedarves farve *uafhængigt* af form (tomater)

	nonbeaked	beaked	sum
rød	142	112	254
gul	113	133	246
sum	255	245	500

A_{ij} : antal i række i og søjle j , $i = 1, 2$, $j = 1, 2$

$$n = A_{11} + A_{12} + A_{21} + A_{22} = 500$$

Multinomialmodel M_0 :

$$(A_{11}, A_{12}, A_{21}, A_{22}) \sim \text{multinom}(500, (\pi_{11}, \pi_{12}, \pi_{21}, \pi_{22}))$$

$$\pi_{ij} \geq 0, \pi_{11} + \pi_{12} + \pi_{21} + \pi_{22} = 1$$

Uafhængighedshypotese (model M_1): $\pi_{ij} = \alpha_i \beta_j$,

$$\alpha_1 + \alpha_2 = 1, \beta_1 + \beta_2 = 1$$

G-teststørrelse

Likelihood: $L(\pi) = \binom{n}{\mathbf{A}} \prod_{i,j} \pi_{ij}^{A_{ij}}$

Model M_0 : π -erne varierer frit, $\hat{\pi}_{ij} = \frac{A_{ij}}{n}$

Model M_1 : $\pi_{ij} = \alpha_i \beta_j$ $\alpha_i \geq 0, \alpha_{\cdot} = 1$ $\beta_j \geq 0, \beta_{\cdot} = 1$

$$L(\{\alpha_i \beta_j\}) = \binom{n}{\mathbf{A}} \alpha_1^{A_{1\cdot}} \alpha_2^{A_{2\cdot}} \beta_1^{A_{\cdot 1}} \beta_2^{A_{\cdot 2}}$$

$$\hat{\alpha}_1 = \frac{A_{1\cdot}}{n}, \quad \hat{\beta}_1 = \frac{A_{\cdot 1}}{n}$$

$$A_{i\cdot} = A_{i1} + \cdots + A_{ik}, \text{ rækkesum}$$

$$A_{\cdot j} = A_{1j} + \cdots + A_{rj}, \text{ søjlesum}$$

Forventede under M_1 : $e_{ij} = n \hat{\alpha}_i \hat{\beta}_j = \frac{A_{i\cdot} A_{\cdot j}}{n}$

$$G\text{-test: } G = -2 \log \left(\frac{\max_{M_1} L}{\max_{M_0} L} \right) = 2 \sum_{ij} a_{ij} \log \left(\frac{a_{ij}}{e_{ij}} \right)$$

G-test

	nonbeaked	beaked	sum
rød	142	112	254
gul	113	133	246
sum	255	245	500

	<i>Forventede</i>	
	nonbeaked	beaked
rød	129.54	124.46
gul	125.46	120.54

$$G = 2 \left\{ 142 \cdot \log\left(\frac{142}{129.54}\right) + 112 \cdot \log\left(\frac{112}{124.46}\right) + 113 \cdot \log\left(\frac{113}{125.46}\right) + 133 \cdot \log\left(\frac{133}{120.54}\right) \right\} = 4.98$$

Da alle forventede er ≥ 5 bruger vi:

$$p_{\text{værdi}} = 1 - F_{\chi^2(3-2)}(4.98) = 0.026$$

Konklusion: data giver anledning til skepsis over for uafhængighed.

Bemærk: Samme beregning som ved test for homogenitet!

Forbindelse til homogenitetstest

Erstat π_{ij} med $\alpha_i \gamma_{ij}$ (r rækker, k søjler)

α_i sandsynlighed for at falde i række i

γ_{ij} betingede ss for at falde i søjle j givet række i

Model M_{I0} : $(A_{1,1}, \dots, A_{r,k}) \sim \text{multinom}(n, (\pi_{11}, \dots, \pi_{rk}))$, $\pi_{ij} = \alpha_i \gamma_{ij}$

$$\alpha_1 + \dots + \alpha_r = 1, \quad \gamma_{i1} + \gamma_{i2} + \dots + \gamma_{ik} = 1, \quad i = 1, \dots, r$$

$$\mathbf{A}_{* \cdot} = (A_{1 \cdot}, \dots, A_{r \cdot}) \sim \text{multinom}(n, (\alpha_1, \dots, \alpha_r))$$

uafhængighed: $\gamma_{ij} = \beta_j$ afhænger ikke af i

Næste slide: fra M_{I0} til M_0 fra homogenitetstestet via betingning

Betinge med rækkesummer

$$\begin{aligned} P(\mathbf{A} = \mathbf{a} | A_{1\cdot} = a_{1\cdot}, \dots, A_{r\cdot} = a_{r\cdot}) &= \frac{\binom{n}{\mathbf{a}} \prod_{ij} (\alpha_i \gamma_{ij})^{a_{ij}}}{\binom{n}{\mathbf{a}_{* \cdot}} \prod_i \alpha_i^{a_{i \cdot}}} \\ &= \prod_i \binom{a_{i \cdot}}{a_{i*}} \gamma_{i1}^{a_{i1}} \cdots \gamma_{ik}^{a_{ik}} \end{aligned}$$

Dette er model M_0 fra homogenitetstest: r multinomialfordelinger

uafhængighedshypotesen = homogenitetshypotesen

Derfor: samme G og skal vurderes i samme χ^2 -fordeling:

Frihedsgrader: $(rs - 1) - \{(r - 1) + (k - 1)\} = (r - 1)(k - 1)$

Rækkesummer og søjlesummer

Under hypotesen om uafhængighed og givet rækkesummer:

rækker er uafhængige og $\text{multinom}(A_{i.}, \beta)$

Summen af rækkerne (= søjlesummer), givet rækkesummer, er derfor

$\text{multinom}(n, \beta), \quad n = \sum_i A_{i.}$

denne afhænger ikke af $A_{*.}$, derfor uafhængighed

mellem rækkesummer og søjlesummer!

Betinge med rækkesummer og søjlesummer

Vi har vist følgende opsplitning

$$L_{\mathbf{A}}(\{\alpha_i \beta_j\}) \propto L_{\mathbf{A}_{* \cdot}}(\alpha) L_{\mathbf{A}_{\cdot *}}(\beta)$$

Inferens om α baseres på rækkesummerne

og inferens om β baseres på søjlesummerne

Cochrans regel

Contingency tables with more than 1 d.f. If relatively few expectations are less than 5 (say in 1 cell out of 5 or more, or 2 cells out of 10 or more), a minimum expectation of 1 is allowable in computing X^2 . (Cochran 1954, p. 420).

Alle forventede skal være større end eller lig med 1

højst 20 procent må være under 5

Lad os vende tilbage til Goodness Of Fit (GOF).

Cochrans regel

Index	1	2	3	4	5
Værdi	0	1	2	3	≥ 4
A_j	144	91	32	11	2
e_j	139.04	97.33	34.07	7.95	1.61

Slår to sidste kasser sammen: $G = 1.84$, p -værdi = 0.399

Slår ikke sammen: $G = 1.86$, p -værdi = 0.603

Kasse	1	2	3	4	5	6	7	8	9	10	11	12
a_j	1	2	9	23	34	47	37	24	12	9	0	1
e_j	1.0	3.2	9.5	20.9	34.6	42.6	39.2	27.0	13.8	5.3	1.5	0.4

Slår to første og tre sidste kasser sammen: $G = 2.73$, p -værdi = 0.84

Slår to første og to sidste kasser sammen: $G = 3.57$, p -værdi = 0.83

χ^2 -test C - og G -teststørrelsen

I noterne bruges teststørrelsen: $G = 2 \sum \text{observeret} \cdot \log \left(\frac{\text{observeret}}{\text{forventet}} \right)$

Ude i verden (og i MSRR) bruges ofte af historiske grunde:

$$C = \sum \frac{(\text{observeret} - \text{forventet})^2}{\text{forventet}}$$

For store datasæt er der ikke forskel. For små datasæt kan χ^2 -approximationen være lidt bedre for G end for C .

R bruger denne i `chisq.test(obs)`

Matematisk Statistik

Fishers eksakte test

Lars Nørvang Andersen

Tea party - Fishers eksakte test

En person bliver givet 8 kopper med te og mælk blandet sammen. De 4 af kopperne er lavet ved at der først er hældt te i koppen og dernæst mælk, og de 4 andre kopper er lavet ved at mælk er hældt i først og dernæst te. Personen ved ikke noget om hvordan de 8 kopper er fordelt på de to typer.

Hypotese: Person kan ikke kende forskel (= vælger tilfældigt)

X_1 antal gange der siges "te først" blandt de 4 med te først

X_2 antal gange der siges "te først" blandt de 4 med mælk først

Model: $X_1 \sim \text{binom}(4, p_1)$, $X_2 \sim \text{binom}(4, p_2)$

Hypotese $p_1 = p_2$

Tea party

Observerede			Forventede		
	Siger te	Siger mælk		Siger te	Siger mælk
Te først	$x_1 = 4$	0	Te først	2	2
Mælk først	$x_2 = 0$	4	Mælk først	2	2

Kan ikke bruge Cochrans regel

Der er 25 kombinationer af x_1 og x_2 med $n_1 = n_2 = 4$ men kun 7 forskellige værdier af G (p = fælles værdi af $p_1 = p_2$)

G	0.00	0.54	1.53	2.09	3.45	6.09	11.09
$Prob, p = 0.5$	0.273	0.375	0.062	0.125	0.094	0.062	0.008
$P_{val}, p = 0.5$	1.00	0.726	0.351	0.289	0.164	0.07	0.008
$Prob, p = 0.1$	0.518	0.029	0.383	0.002	0.064	0.005	0.000
$P_{val}, p = 0.1$	1.00	0.483	0.454	0.071	0.069	0.005	0.00
$\chi^2(1), \geq$	1.000	0.462	0.216	0.148	0.063	0.014	0.001

Fishers eksakte test

Hvis $p_1 = p_2$ så er $X_1 + X_2 \sim \text{binom}(n_1 + n_2, p)$, $\hat{p} = \frac{X_1 + X_2}{n_1 + n_2}$

vi er ikke interesseret i p , kun i spørgsmålet $p_1 = p_2$

Betinge med værdien af $X_1 + X_2$:

0 4 4	1 3 4	2 2 4	3 1 4	4 0 4
4 0 4	3 1 4	2 2 4	1 3 4	0 4 4
4 4 8	4 4 8	4 4 8	4 4 8	4 4 8

G	11.09	2.09	0.00	2.09	11.09
$P()$	0.014	0.229	0.514	0.229	0.014

P -værdi fra betingede test = $0.014 + 0.014 = 0.028$ (uafhængig af p under hypotesen)

Betinge i 2×2 tabel

Model: $X_1 \sim \text{binom}(n_1, p)$, $X_2 \sim \text{binom}(n_2, p)$, $X_1 \perp\!\!\!\perp X_2$.

Betinge med $X_1 + X_2$

$$P(X_1 = x_1, X_2 = x_2 | X_1 + X_2 = k)$$

$$= \frac{\binom{n_1}{x_1} p^{x_1} (1-p)^{n_1-x_1} \binom{n_2}{k-x_1} p^{k-x_1} (1-p)^{n_2-(k-x_1)}}{\binom{n}{k} p^k (1-p)^{n-k}}, \quad x_1 + x_2 = k, \quad n_1 + n_2 = n$$

$$= \frac{\binom{n_1}{x_1} \binom{n_2}{k-x_1}}{\binom{n}{k}}$$

Afhænger IKKE af p derfor "eksakt" test

Beregning af betingede sandsynlighed i R: `dhyperv(x, b, c, d)`

x	b-x	b
d-x	c-d+x	c
d	n-d	n=b+c

Kritisk område

Hvad er "mere kritisk" i betingede fordeling ?

$\mathbf{R}$, `fisher.test` : alle udfald hvor betingede sandsynlighed er $\leq$ betingede sandsynlighed for faktiske observation

Alternativ: alle udfald i betingede fordeling med $G(x) \geq G(x_{\text{obs}})$

Sceneskift

Næste: Fishers eksakte test for 2×3 tabel

x_{11}	x_{12}	x_{13}	n_1
x_{21}	x_{22}	x_{23}	n_2
$a = x_{11} + x_{21} \quad b = x_{12} + x_{22} \quad c = x_{13} + x_{23}$			$n = n_1 + n_2$

Betinge i 2×3 tabel

Model:

$(X_{11}, X_{12}, X_{13}) \sim \text{multinom}(n_1, \pi)$, $(X_{21}, X_{22}, X_{23}) \sim \text{multinom}(n_2, \pi)$,
betinge med $(X_{11} + X_{21}, X_{12} + X_{22}, X_{13} + X_{23})$

$$P(X_{11} = x, X_{12} = y | X_{11} + X_{21} = a, X_{12} + X_{22} = b, X_{13} + X_{23} = c)$$

$$= \binom{n_1}{x, y, n_1 - x - y} \binom{n_2}{a - x, b - y, n_2 - (a - x) - (b - y)} / \binom{n}{a, b, c}$$

Eksempel: defingrupperes aktivitetsmønster

	Rejse	Spise	Leg	Sum
Morgen	6	28	38	72
Aften	13	56	10	79
Sum	19	84	48	151

```
obs=rbind(c(6,28,38),c(13,56,10))  
fisher.test(obs)
```

Giver $p_{obs} = 4.867e - 07$, (praktisk talt) samme som approksimativt test baseret på G-teststørelsen.

Cereals

Datasæt fra MSRR: cereals.csv

$n = 43$ morgenmadsprodukter klassificeret efter

Rettet mod "adult" eller "children" (H)

Placering på hyld: bottom, middle, top (M)

	ID	Age	Shelf	Sodiumgram	Proteingram
1	1	adult	bottom	0.007000000	0.10000000
2	2	children	bottom	0.006666667	0.06666667
...					
42	42	adult	top	0.000000000	0.09259259
43	43	adult	top	0.002452830	0.09433962

Fulde data på individniveau

n individer inddeles efter to inddelingskriterier, H og M

data: $(H_1, M_1), (H_2, M_2), \dots, (H_n, M_n)$

H har r niveauer, M har k niveauer

$$P(H = i) = \alpha_i, \quad P(M = j | H = i) = \gamma_{ij}$$

Samlet sandsynlighed: $P(\text{Data}) = \prod_{u=1}^n \alpha_{h_u} \gamma_{h_u, m_u}$

Hypotese om uafhængighed: $\gamma_{ij} = \beta_j$

$$P(\text{Data}) = \prod_u \alpha_{h_u} \beta_{m_u}$$

Fordeling af $(H_1, \dots, H_n)$ er irrelevant for spørgsmålet om uafhængighed

Første betingning

Betingelser med $H_1, \dots, H_n$

$$P(\text{Data}|H) = \frac{\prod_u \alpha_{h_u} \gamma_{h_u, m_u}}{\prod_u \alpha_{h_u}} = \prod_u \gamma_{h_u, m_u}$$

hypotese om uafhængighed: $P(\text{Data}|H) = \prod_u \beta_{m_u}$

Fordeling af M ($\beta_1, \dots, \beta_k$) er irrelevant for spørgsmålet om uafhængighed

betingelser med hvor mange der er på hvert niveau

$B_j =$ antal M_u -er med værdien $j, j = 1, \dots, k, B_j = \sum_u 1(M_u = j)$

$(B_1, \dots, B_k) \sim \text{multinom}(n, (\beta_1, \dots, \beta_k))$

Anden betingning

$$P(\text{Data}|H, B) = \frac{\prod_u \beta_{m_u}}{\binom{n}{b_1, \dots, b_k} \beta_1^{b_1} \dots \beta_k^{b_k}} = \frac{1}{\binom{n}{b_1, \dots, b_k}}$$

I den betingede fordeling er alle kombinationer af $(m_1, m_2, \dots, m_n)$, som opfylder at antal med værdien j er b_j , $j = 1, \dots, k$, lige sandsynlige

Vi kan simulere betingede fordeling ved at lave tilfældige permutationer af dataværdierne $m_1, \dots, m_n$

R: `sample(m)` m er en vektor med $m_1, \dots, m_n$

Næste slide: grundlæggende dele af program

Simulere

Vi kan simulere p -værdi for test i den dobbelt-betingede fordeling baseret på en teststørrelse der beregnes i *testFct*:

```
nSim=10000
tval=rep(0,nSim)

for (i in 1:nSim){
  msamp=sample(m)
  datsamp=table(h,msamp)
  tval[i]=testFct(datsamp)
}

tobs=testFct(table(h,m))
pval=(1+sum(tval>=tobs))/(1+nSim)
```

Teststørrelse

Vi mangler at specificere en teststørrelse

Fra fulde data til $r \times k$ tabel:

$$A_{ij} = \sum_{u=1}^n 1(H_u = i, M_u = j), \quad i = 1, \dots, r, \quad j = 1, \dots, k$$

Model M_{I0} : $(A_{1,1}, \dots, A_{r,k}) \sim \text{multinom}(n, (\pi_{11}, \dots, \pi_{rk}))$

Teste *uafhængighedshypotesen*: der eksisterer et sæt sandsynligheder $(\alpha_1 \dots, \alpha_r)$ og et andet sæt sandsynligheder $(\beta_1 \dots \beta_k)$ således at

$$\pi_{ij} = \alpha_i \beta_j \text{ for alle } i, j \text{ (model } M_{I1})$$

Bruge G-teststørrelsen i simulationsbaserede metode

R-kørsel

Simuleret p -værdi når der bruges teststørrelsen $C = \sum_{ij} (A_{ij} - e_{ij})^2 / e_{ij}$:

```
chisq.test(obs, simulate.p.value=TRUE, B=9999)
```

Matematisk Statistik

The Bootstrap

Lars Nørvang Andersen

The Bootstrap



pull oneself up by one's bootstraps:
to help oneself without the aid of others; use one's resources
(www.collinsdictionary.com)

Grundlæggende problemstilling: Vi står med data $x_1, \dots, x_n$ og en stikprøvefunktion $g(x_1, \dots, x_n)$, f.eks. gennemsnittet:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Vi kender $g(x_1, \dots, x_n)$, men ikke $g(X_1, \dots, X_n)$ (stikprøvefordeling/sampling distribution) der afhænger af F .

Idé: Betragt den fordeling der opstår, hvis vi trækker fra $x_1, \dots, x_n$ med *tilbagelægning*.

Notation: $x_1^*, \dots, x_n^*$.

The Bootstrap Idea

The original sample approximates the population from which it was drawn. So resamples from this sample approximate what we would get if we took many samples from the population. The bootstrap distribution of a statistic, based on many resamples, approximates the sampling distribution of the statistic, based on many samples.

The Bootstrap

Table 5.1 All possible samples of size 3 from 3969, 3204, and 2892.

x_1^*	x_2^*	x_3^*	$\bar{x}^*$
3969	3969	3969	3969
3969	3969	3204	3714
3969	3969	2892	3610
3969	3204	3969	3714
3969	3204	3204	3459
3969	3204	2892	3355
3969	2892	3969	3610
3969	2892	3204	3355
3969	2892	2892	3251
3204	3969	3969	3714
3204	3969	3204	3459
3204	3969	2892	3355
3204	3204	3969	3459
3204	3204	3204	3204
3204	3204	2892	3100
3204	2892	3969	3355
3204	2892	3204	3100
3204	2892	2892	2996
2892	3969	3969	3610
2892	3969	3204	3355
2892	3969	2892	3251
2892	3204	3969	3355
2892	3204	3204	3100
2892	3204	2892	2996
2892	2892	3969	3251
2892	2892	3204	2996
2892	2892	2892	2892

Fordelingen svarende til $x_1^*, \dots, x_n^*$ kaldes den *teoretiske bootstrap fordeling*.

For $n = 3$ er der $3^3 = 27$ måder at trække med tilbagelægning (når vi tager højde for rækkefølge). Dog kun $\binom{5}{2} = 10$ forskellige værdier af $\bar{x}^*$.

The Bootstrap

I princippet kunne vi godt beregne sandsynlighederne i bootstrap fordelingen, men i praksis er det lettere at simulere udfald fra den.

Bootstrap for a Single Population

Given a sample of size n from a population:


- 1) Draw a resample of size n with replacement from the sample. Compute a statistic that describes the sample, such as the sample mean.
- 2) Repeat this resampling process many times, say, 10 000.
- 3) Construct the bootstrap distribution of the statistic. Inspect its center, spread, and shape.

Vi kan let trække fra bootstrapfordelingen ved at bruge **sample** kommandoen.

Eksempel

```
set.seed(123)
my.sample <- rgamma(16, 1, 1/2)
mean(my.sample)
sd(my.sample)
```

```
> mean(my.sample)
[1] 2.322472
> sd(my.sample)
[1] 2.183536
```



Eksempel

```
N <- 10^5
my.boot <- numeric(N)
for (i in 1:N) {
  x <- sample(my.sample, 16, replace = TRUE) # draw resample
  my.boot[i] <- mean(x) # compute mean, store in my.boot
}
mean(my.boot)
sd(my.boot)
```


```
> mean(my.boot)
[1] 2.32181
> sd(my.boot)
[1] 0.5298087
```

Eller vi at bruge **replicate** :

```
my.boot <- replicate(N, mean(sample(my.sample, replace = TRUE)))
mean(my.boot)
sd(my.boot)
```

```
> mean(my.boot)
[1] 2.32338
> sd(my.boot)
[1] 0.5277297
```


Eksempel





Bootstrap Distributions and Sampling Distributions

For most statistics, bootstrap distributions approximate the spread, bias, and shape of the actual sampling distribution.

Bemærk: “bias” *ikke* “center”.


Eksempel



Til venstre: Bootstrapfordelingen sammen med stikprøvefordelingen.

Til højre: Bootstrapfordelingen centreret i 2 sammen med stikprøvefordelingen.

Eksempel



Bootstrappedfordelingen sammenlignet med normalapproximationen (grøn) og stikprøvefordelingen (gul).

The Bootstrap kan opfattes som et eksempel på plug-in principle, hvor vi erstatter den ukendte fordelingsfunktion F med den *empiriske fordelingsfunktion* $\hat{F}_n$.




Figure 5.4 Diagram of the process of creating a sampling distribution. Many (infinitely many) samples are drawn from the population, a statistic like $\bar{X}$ is calculated for each. The distribution of the statistics is the sampling distribution.

Figure 5.5 Diagram of the process of creating a bootstrap distribution. This is like Figure 5.4, except that the original data take the place of the population. We draw many samples from the original data, calculate $\bar{X}^*$ or another statistic for each, and collect the statistics to form the bootstrap distribution.


“For most common estimators and under fairly general distribution assumptions, the following hold.”

- *Spredning/“spread”* ✓ Spredningen af bootstrapfordelingen svarer til spredningen af stikprøvefordelingen - $SE[\hat{\theta}^*] \approx SE[\hat{\theta}]$
- *Bias* ✓ Bias af bootstrapfordelingen svarer til bias af stikprøvefordelingen - $\text{Bias } \hat{\theta}^* = \mathbb{E}[\hat{\theta}^*] - \hat{\theta} \approx \mathbb{E}[\hat{\theta}] - \theta = \text{Bias } \hat{\theta}$
- *Skævhed* ✓ Skævhed af bootstrapfordelingen svarer til skævhed af stikprøvefordelingen
- *Center/position* ✗ Bootstrapfordelingen vil være centreret samme sted som den oprindelige stikprøve, f.eks. vil bootstrap fordelingen $\bar{X}^*$ være centreret omkring $\bar{x}$. (og ikke μ).

Bemærk til sidste punkt: Man skal *ikke* forvente at bootstrap-metoden skal kunne bruges til at opnå forbedrede estimater.

Example 5.3



Eksemplet vedrører målinger af arsenik i vandmålinger i Bangladesh. Vi undersøger bootstrap fordelingen af gennemsnittet.



```
library(resampledData3)
Arsenic <- Bangladesh$Arsenic
n <- length(Arsenic)
N <- 10^4
arsenic.mean <- replicate(N,mean(sample(Arsenic, replace = TRUE)))

hist(arsenic.mean, main = "Bootstrap distribution of means")
abline(v = mean(Arsenic), col = "blue", lty = 2)
```

Example 5.3



```
> mean(arsenic.mean) # bootstrap mean
[1] 125.3243
> mean(arsenic.mean)-mean(Arsenic) # bias
[1] 0.00437369
> sd(arsenic.mean) # bootstrap SE
[1] 18.15877
```

Example 5.3

```
> mean(arsenic.mean)-1.96*sd(arsenic.mean)
[1] 89.73312
> mean(arsenic.mean)+1.96*sd(arsenic.mean)
[1] 160.9155
> sum(arsenic.mean > 160.9155)/N
[1] 0.0333
> sum(arsenic.mean < 89.73312)/N
[1] 0.0159
```

Vi ser at cirka 1.6% af bootstrap samples er mindre end gennemsnit minus $2 * SE$ og 3.3% er over gennemsnit plus $2 * SE$, så vi konkluderer at stikprøvefordelingen for gennemsnittet ikke kan betragtes som normalfordelt.

Bootstrap Percentile Confidence Intervals

The interval between the 2.5 and 97.5 percentiles of the bootstrap distribution of a statistic is a 95% *bootstrap percentile confidence interval* for the corresponding parameter.

Beregnes ved hjælp af `quantile(x, probs=c(0.025, 0.975))`, hvor `x` indeholder bootstrap samples.

For arsenik-eksemplet finder vi

```
quantile(arsenic.mean, probs=c(0.025, 0.975))
```

som giver

2.5%	97.5%
92.80887	163.96348

Bemærk at dette kan skrives som $(\bar{x}^* - 32.5154, \bar{x}^* + 38.63918)$ - ikke symmetrisk omkring $\bar{x}^*$.

Percentil Intervallerne skal betragtes med visse forbehold - kan være overraskende dårlige.

Bootstrap for Comparing Two Populations

Given independent samples of sizes m and n from two populations:


- 1) Draw a resample of size m with replacement from the first sample and a separate resample of size n from the second sample. Compute a statistic that compares the two groups, such as the difference between the two sample means.
- 2) Repeat this resampling process many times, say, 10 000.
- 3) Construct the bootstrap distribution of the statistic. Inspect its spread, bias, and shape.

```
ILEC <- subset(Verizon, select = Time, subset = Group=="ILEC", drop=TRUE)
CLEC <- subset(Verizon, select = Time, subset = Group=="CLEC", drop=TRUE)
m <- length(ILEC)
n <- length(CLEC)
B <- 10^4

BootMean <- numeric(B)

for(i in 1:B) {
  sampleILEC <- sample(ILEC, m, replace=TRUE) # "m" er strengt tage ikke nødvendig.
  sampleCLEC <- sample(CLEC, n, replace=TRUE)
  BootMean[i] <- mean(sampleILEC) - mean(sampleCLEC)
}
```

replicate kan også bruges.



Histogram af bootstrapfordelingen for gennemsnittet. De stiplede linjer er empiriske 2.5% og 97.5% fraktiler.

```
quantile(BootMean, c(0.025, 0.975))
```

giver output

2.5%	97.5%
-16.982860	-1.665015


Bootstrap-metoden er i princippet meget fleksibel. I eksemplet nedenfor findes et 95%-percentil interval for *medianen*

```
n = 10
B = 1000
x <- rexp(n, rate = 1)
boot_medians <- replicate(B, median(sample(x, replace=TRUE)))
perc <- quantile(boot_medians, probs = c(0.025, 0.975))
```

Ved hjælp af et simulationseksperiment estimerer vi dækningssandsynligheden til 94% i dette tilfælde.

Bootstrap fordeling af 25%-trimmed mean og histogram.

```
for(i in 1:B) {  
  sampleILEC <- sample(ILEC,m,replace=TRUE)  
  sampleCLEC <- sample(CLEC,n,replace=TRUE)  
  BootTrimmedMean[i] <- mean(sampleILEC,trim=0.25) - mean(sampleCLEC,trim=0.25)  
}
```



Bootstrap metoden kan bruges til at estimere Bias $\hat{\theta} = \mathbb{E}[\hat{\theta}] - \theta$.

Bias vurderes bedst relativt til SE , $b = \text{Bias} / SE$

[Chihara and Hesterberg(2022)] advarer mod tab af nøjagtighed af percentil-intervaller, hvis $|b|$ er større end 0.02.

I [Chihara and Hesterberg(2022)] Verizon-eksempel med ratio-of-means fås $b = 0.2172$ så percentil-intervallet er nok ikke særligt nøjagtigt.

For trimmed-mean eksemplet fås:

```
> mean(BootTrimmedMean) - (mean(ILEC,trim=0.25) - mean(CLEC,trim=0.25))  
[1] 0.009031481  
> sd(BootTrimmedMean)  
[1] 2.688956
```

Her bør vi kunne have tillid til percentil-intervallet.

For et datasæt $x_1, \dots, x_n$ er der n^n mulige udfald $\mathbf{x}^* = (x_1^*, \dots, x_n^*)$ af den teoretiske bootstrap fordeling.

Når vi trækker N bootstrap samples approksimerer vi denne fordeling, og der derfor to kilder til variation:

- 1 Det oprindelige udfald $\mathbf{x}$ er udfald af den bagvedliggende s.v. $\mathbf{X}$.
- 2 N Bootstrap samples $\mathbf{x}^*$ er trukket ved hjælp af $\hat{F}_n$.

Vi kan (i princippet) gøre variationen fra (2) så lille som vi ønsker ved at gøre N stor. I §5.9 anbefales $N = 10000$.




Figure 5.17 Bootstrap distribution for the mean, $n = 50$. The left column shows the population and five samples. The middle column shows the sampling distribution, and bootstrap distributions from each sample. The right column shows five more bootstrap distributions from the first sample, with $N = 1000$ or $N = 10^4$.




Figure 5.18 Bootstrap distributions for the mean, $n = 9$. The left column shows the population and five samples. The middle column shows the sampling distribution and bootstrap distributions from each sample. The right column shows five more bootstrap distributions from the first sample, with $N = 1000$ or $N = 10^4$.

Idéen i *bootstrap t confidence intervals* er at bootstrappe t -teststørrelsen:

$$t = \frac{\bar{X}_{\cdot} - \mu_0}{\sqrt{\frac{s^2(\mathbf{X})}{n}}},$$


det vil sige finde bootstrap-fordelingen af

$$T^* = \frac{\bar{X}_{\cdot}^* - \bar{X}_{\cdot}}{s^*/\sqrt{n}}.$$

```
Arsenic <- Bangladesh$Arsenic
xbar <- mean(Arsenic)
N <- 10^4
n <- length(Arsenic)

Tstar <- numeric(N)
for (i in 1:N)
{
  xboot <- sample(Arsenic, size = n, replace = T)
  Tstar[i] <- (mean(xboot)-xbar) / (sd(xboot)/sqrt(n))
}
```

R-kode til arsenik-eksempel.



Scatterplot med s^* afsat mod $\bar{x}^*$ viser at disse er positivt korrelerede.

Bootstrap fordelingen af T bliver venstre skæv.

Det sædvanlige t -test udledes ved at benytte, at for én normalfordelt observationsrække har vi

$$1 - \alpha = \mathbb{P}(-t_{1-\alpha/2}(n-1) \leq T(\mathbf{x}) \leq t_{1-\alpha/2}(n-1))$$

Bruges samme udledning på

$$1 - \alpha = \mathbb{P}(Q_1 \leq T \leq Q_2)$$


fås bootstrap bootstrap t confidence intervals:

Bootstrap t Confidence Interval for μ


For each of many resamples, calculate the bootstrap t statistic $T^* = \frac{\bar{X} - \bar{x}}{S^*/\sqrt{n}}$.

Let $\hat{Q}_1$ and $\hat{Q}_2$ be the empirical $\alpha/2$ and $(1 - \alpha/2)$ quantiles of T^* , respectively (i.e. the interval between them contains the middle $(1 - \alpha) \times 100\%$ of all the bootstrap t statistics). The bootstrap t confidence interval is

$$\left(\bar{x} - \hat{Q}_2 \frac{s}{\sqrt{n}}, \bar{x} - \hat{Q}_1 \frac{s}{\sqrt{n}} \right).$$




Estimerede dækningssandsynligheder tre slags konfidensintervaller for middelværdien som funktion af n . Data er simuleret fra uafhængige standard eksponential fordelte stokastiske variable.





Figur svarende til Figure 7.14 i MSRR.

For $n = 5, 10, 20, 50, 250, 1000$ ses estimerede sandsynligheder for at konfidensintervallerne ligger over (nederste kurver) eller under (øverste kurver).

De næste slides viser 100 simulerede konfidensintervaller af hver type







Bibliografi



Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (3rd edition).

John Wiley & Sons, 2022.