

Matematisk Statistik

Introduktion og deskriptiv statistik

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Forelæsninger

- 2×2 timer per uge

Øvelser

- 2 timer per uge. Starter i Uge 2.

StatLab.

- 2 timer per uge. Starter i Uge 1.

Obligatorisk program

- 7 godkendte afleveringsopgaver, ud af 10.

Eksamen

- 4 timer, skriftlig, digital
- Evaluering efter 7-trins skalaen, ekstern censur.

Statistisk programpakke:

- **R** med RStudio som brugerflade.

Litteratur:

- MSRR :
Laura Chihara, Tim Hesterberg (2022): Mathematical Statistics with Resampling and R (3rd edition).
- 2. udgave fra 2018 kan også bruges.
- Supplerende noter.

MSRR har en hjemmeside, hvor I blandt andet finder data og liste med trykfejl. Hjemmesiden er

<https://github.com/lchihara/MathStatsResamplingR>

Matematisk Statistik

Data er typisk organiseret i tabeller, hvor hver række udgør en *observation* og søjlerne udgør *variable*.

Flight	Carrier	FlightNo	Destination	DepartTime	Delay	Delayed30
1	UA	403	DEN	4-8am	-1	No
2	UA	405	DEN	8-Noon	102	Yes
3	UA	409	DEN	4-8pm	4	No
4	UA	511	ORD	8-Noon	-2	No
5	UA	667	ORD	4-8am	-3	No
6	UA	669	ORD	4-8am	0	No
7	UA	673	ORD	8-Noon	-5	No
8	UA	677	ORD	8-Noon	0	No
9	UA	679	ORD	Noon-4pm	10	No
10	UA	681	ORD	Noon-4pm	60	Yes
⋮						

Eksempel på datasæt - Del af `FlightDelays` datasættet fra Case Study 1.1

- *Kategoriske variable/kvalitative variable/faktorvariable/faktorer.*
Danner en gruppdeling af observationer.
De mulige værdier af en faktor kaldes *niveauer* (eng: *levels*) eller *kategorier*.
- *Numeriske variable/Kvantiative variable* Tal, hvor vi meningsfyldt kan betragte f.eks. minimum eller gennemsnit.

Kategoriske variable inddeles i *ordinale* kategoriske variable og *nominale* kategoriske variable. En ordinal (kategorisk) variabel er en variabel, hvor niveauerne kan rangordnes (f.eks. god/bedre/bedst), mens en nominal ikke har en rangorden. Under tiden kaldes en kategorisk variabel med to niveauer for en *dikotom/binær* variabel.

Numeriske variable inddeles i *diskret* (numeriske) variable og *kontinuerte* variable. Hvis de mulige værdier af en numerisk variabel udgør en tællelig mængde kaldes variable diskret og ellers kaldes den kontinuert. Diskrete variable optræder typisk ved tællinger, men kontinuerte variable er resultatet af målinger.

Table 1.2 Variables in data set `FlightDelays`.

Variable	Description
Carrier	UA=United Airlines, AA=American Airlines
FlightNo	Flight number
Destination	Airport code
DepartTime	Scheduled departure time in 4 h intervals
Day	Day of week
Month	May or June
Delay	Minutes flight delayed (negative indicates early departure)
Delayed30	Departure delayed more than 30 min?
FlightLength	Length of time of flight (minutes)

Potentielle spørgsmål

- Er forsinkelserne forskellige for de to flyselskaber
- Afhænger forsinkelserne af ugedagen
- Er der større risiko for forsinkelse om morgenen?

I bogen skelnes mellem en stikprøve (sample) (af størrelse n) eller en hel population (af størrelse N).

Populationer kan være endelige eller uendelige. En stikprøve kan fremkomme som resultatet af udtrækning, og ved små populationer kan det være vigtigt at skelne mellem *trækning med tilbagelægning* og *trækning uden tilbagelægning*.

Numeriske egenskaber ved populationen kaldes *parametre*.

Fortolkning af association mellem variable

MSRR § 1.11

Eksempel: rygning og kræft

Datasæt med *forklarende variabel* “ryger” (ja/nej) og *interessevariabel* “kræftpatient” (ja/nej).

Andel af kræftpatienter er højere ved ryger.

- Observationelt studie: Datasættet er givet uden indflydelse fra forskeren. Association mellem variable må ikke uden videre fortolkes som årsag! (*“Correlation does not imply causation”*)
- Eksperiment: Forskere manipulerer forklarende variabler og randomiserer deres niveau ved individer. Fx laboratoriemus bliver tilfældigt tildelt rygergruppen. Kausale konklusioner kan være tilladt.

Dataanalyse i R

csv filer: tekstformat for tabeller - tabelrække = tekstlinje.

celler i tabellen separeret ved komma (eller andre tegn).

Start af `FlightDelays.csv`:

```
"ID", "Carrier", "FlightNo", "Destination", "DepartTime", "  
1, "UA", 403, "DEN", "4-8am", "Fri", "May", 281, -1, "No"  
2, "UA", 405, "DEN", "8-Noon", "Fri", "May", 277, 102, "Yes"  
3, "UA", 409, "DEN", "4-8pm", "Fri", "May", 279, 4, "No"  
4, "UA", 511, "ORD", "8-Noon", "Fri", "May", 158, -2, "No"
```

Indlæs i **R**

```
FlightDelays <- read.csv("FlightDelays.csv")
```

giver en `data.frame` objekt med navn `FlightDelays` og
komponenter `ID`, `Carrier`, ...

Tilgås f.eks. `FlightDelays$Carrier`

`read.csv` er en specialiseret udgave af `read.table`

Eller, I kan bruge RStudio

Deskriptiv dataanalyse: Kategoriske variable (MSRR 2.1)

Deskriptiv dataanalyse: en kategorisk variabel

Hyppighedstabel

Tabel af antal observationer af hver kategori, d.v.s. hvert niveau af en kategorisk variabel.

```
table(FlightDelays$Carrier)
```

For at arbejde videre med hyppighedstabellen gemmes denne:


```
tab <- table(FlightDelays$Carrier)
```

Så kan vi lave et *bar plot*, som giver en visualisering af hyppighedstabellen. Højden af baren svarer til antallet af individer af hver kategori.

```
barplot(tab)
```

Outputtet af ovenstående ses på næste slide

Deskriptiv dataanalyse: en kategorisk variabel



Barplot af `Carrier` variablen

Dot plot / prikdiagram

En lav-det-selv version af bar plot: tegn en punkt for hvert individ af en kategori.

Kontingenstabel

Tabel med tællinger for hver kombination af niveauer af to eller flere kategoriske variable.

R koden

```
table(FlightDelays$Carrier, FlightDelays$Delayed30)
```

giver output

	No	Yes
UA	919	204
AA	2513	393

Bemærk at vi indirekte har lavet en ny faktorvariabel med fire niveauer. Tabellen gemmes

```
tab <- table(FlightDelays$Carrier, FlightDelays$Delayed30)
```

Kontingenstabel

Ved hjælp af `prop.table` kan vi normalisere kontingenstabellen så alle celler/alle rækker/alle søjler summer til 1:

```
prop.table(tab)
```

giver

	No	Yes
UA	0.22809630	0.05063291
AA	0.62372797	0.09754281

```
prop.table(tab, 1)
```


giver

	No	Yes
UA	0.8183437	0.1816563
AA	0.8647626	0.1352374

Sammenlign med Table 2.2 i [1].

Deskriptiv dataanalyse:
numeriske variable
(MSRR, resten af kapitel 2, samt
supplerende noter)

- Kan approksimere en tæthedsfunktion.
- Konstrueres ved at inddele spænd (range) i et passende antal delintervaller.
- Data i hvert delinterval repræsenteres ved en kasse, hvis areal er proportional med hyppighed eller relativ hyppighed.



Histogram (med relative hyppigheder) for 10000 simulerede udfald fra exponential fordelingen med parameter 1, sammen tætheden $f(x) = e^{-x} \quad x > 0$.

Histogrammer kan give et indtryk af om data er højre/venstre skævt eller symmetrisk.




Figure 2.2 Histogram of lengths of flight delays for United Airlines. The distribution is right skewed.







Figure 2.3 Histogram of average January temperatures in Washington state (1895–1999). The distribution is left skewed.

Antallet af intervaller skal vælges passende, som følgende figur illustrer.



3 histogrammer for `Weight` variabelen fra datasættet `TXBirths`, baseret på forskellige antal interval-inddelinger.

Histogrammer kan være “ustabile” som nedenstående figur illustrerer:



Figur 1: To histogrammer for samme datasæt med $\Delta t_i = 20$ for alle i . Det venstre histogram har $t_1 = 1400$ mens det højre har $t_1 = 1409$. Figuren er tilpasset fra [2].

Histogrammer kan også gøre det svært at se om fordelingen har “tunge haler”, hvilket vi ser et eksempel på senere.

Numeriske deskriptive mål

Vi betragter en numerisk variabel i et datasæt.

Mål for position

- median
- empirisk middelværdi/middelværdi/gennemsnit
- trimmed gennemsnit

Mål for variation

- spænd (*range*)
- kvartilsafstand (*interquartile range*)
- varians, standard afvigelse.

Både-og:

- Five number summary.

Data er $\mathbf{x} = (x_1, \dots, x_n)$

◆ *Gennemsnit*

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

`mean(x)`

◆ *Median*

$$\text{median}(\mathbf{x}) = \begin{cases} \frac{1}{2} \left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right), & \text{hvis } n \text{ er lige} \\ x_{(\frac{n+1}{2})} & \text{hvis } n \text{ er ulige} \end{cases}$$

hvor $x_{(1)}, \dots, x_{(n)}$ er datasættet sorteret efter størrelse, det vil sige $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$

`median(x)`

◆ *Trimmet gennemsnit* Fjern først en andel $0 < \alpha < 0.5$ fra begge sider af den ordnede stikprøve $x_{(1)}, \dots, x_{(n)}$ og returner middelværdien af de resterende observationer

`mean(x, trim = 0.25)`

Angiver: minimum, 1.kvartil (Q_1), median, 3.kvartil (Q_3) samt maximum af stikprøven. I MSRR angives følgende metode til beregning af Q_1 og Q_3 :

- 1. kvartil Q_1 : median af alle tal som er *mindre* eller lig medianen
- 3. kvartil Q_3 : median af alle tal som er *større* eller lig medianen

Eksempel 2.4: data ($n = 15$) er givet ved

9, 10, 11, 11, 12, 14, 16, 17, 19, 21, 25, 31, 32, 41, 61

`fivenum(x)` eller

`summary(x)`

- inkluderer også gennemsnittet
- bruger en lidt anderledes beregning af kvartilerne Q_1 og Q_3

`summary` kommandoen bruges i flere andre sammenhænge.

Spænd, variationsbredde (range)

$$\text{Spænd} = \text{maksimum} - \text{minimum} = x_{(n)} - x_{(1)}$$

Kvartilsafstand (interquartile range)

$$IQR = Q_3 - Q_1$$

Kan opfattes som en trimmet udgave af spændet.

◆ *Vars og standardafvigelse*

Populationsvars

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2, \mu = \frac{1}{N} \sum_{i=1}^N x_i$$

Stikprøvevars

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Boxplots

Boxplots visualiserer tallene fra five-number summary.

Table 2.4 A set of 21 data values.

5	6	6	8	9	11	11
14	17	17	19	20	21	21
22	23	24	32	40	43	49




Figure 2.5 Boxplot for Table 2.4.

fivenum returnerer

```
5 11 19 23 49
```

Boxplots

Boxplots egner sig godt til at sammenligne fordelinger på tværs af niveauerne af en kategorisk variabel.




Figure 2.6 Distribution of lengths of the flight delays for United Airlines across the days of the week.

Den empiriske fordelingsfunktion

Den *empiriske fordelingsfunktion* estimerer populationens fordelingsfunktion (CDF) $F(x) = \mathbb{P}(X \leq x)$.

Konkret defineres $\hat{F}_n$ svarende til observationerne $x_1, x_2, \dots, x_n$ som

$$\hat{F}_n(x) = \frac{\#\{x_i \leq x\}}{n} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{(-\infty, x]}(x_i).$$

Den empiriske fordelingsfunktion

Empiriske fordelingsfunktioner kan sammenlignes direkte:




Figure 2.14 Ecdf's for male and female beer consumption. The vertical line is at 25 oz.


Kan laves med `plot.ecdf`

Den empiriske fordelingsfunktion

Den empiriske fordelingsfunktion kan også bruges til at vurdere den antagelse at data $x_1, \dots, x_n$ er realisationer af uafhængige identisk fordelte (i.i.d.) $X_1, \dots, X_n$ med fælles fordelingsfunktion F .

På grund af de store tals lov vil der gælde at

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{(-\infty, x]}(X_i) \xrightarrow{\mathbb{P}} F(x).$$



Fraktiler

I stedet for at sammenligne fordelingsfunktionerne sammenlignes disses *fraktiler*.

Definition


Lad F være en fordelingsfunktion for en stokastisk variabel X . For ethvert $p \in [0, 1]$ er p -fraktilen for F mængden x_p givet ved

$$x_p = \{x \in \mathbb{R} : F(x-) \leq p \leq F(x)\}.$$

$x_{0.50}$ kaldes for en median for F , mens $x_{0.25}$ og $x_{0.75}$ kaldes henholdsvis nedre og øvre kvartil for F .

Selvom fraktiler altså strengt taget er mængder af tal undertrykkes dette ofte, og man skriver f.eks. $x_{0.1} = 0.632$ som i Figur 2 på næste slide.

Fraktiler




Figur 2: Illustration af fraktiler for en fordelingsfunktion F . Det ses at $x_{0.1} = 0.632$, $x_{0.4} = x_{0.5} = 1$ og $x_{0.8} = [2, 3]$

Fraktiler

En fraktilfunktion er en funktion der giver fraktiler - for eksempel

$$F^{-}(p) \stackrel{\text{def}}{=} \inf\{x \in \mathbb{R} : p \leq F(x)\} = \min\{x \in \mathbb{R} : p \leq F(x)\}.$$



Hvis F er kontinuert og strengt voksende består x_p kun af ét punkt, nemlig $F^{-1}(p)$, det vil sige at

$$x_p = F^{-1}(p), \quad p \in]0, 1[.$$

Fraktiler

For en talfølge $x_1, x_2, \dots, x_n$ kaldes fraktilerne for $\hat{F}_n$ for empiriske fraktiler. Kan beregnes med `quantile`, ved at vælge `type=1` som svarer til $\hat{F}^-$. `type=2` tager gennemsnit i diskontinuitetspunkter, hvilket svarer til den måde medianen for $x_1, x_2, \dots, x_n$ blev beregnet. De resterende muligheder for `type` omtales på hjælpesiden for funktionen (`?quantile`).


Fraktildiagrammer for normalfordelingen

Et fraktil diagram for normalfordeling kan nu laves ved at indtegne punkterne: ($\Phi^{-1}(\frac{i - \frac{1}{2}}{n})$, $x_{(i)}$) $i = 1, \dots, n$.


R-koden (x er data fra figuren på slide 28)

```
qqnorm(x)
```

giver





Fraktildiagrammer for normalfordelingen



Weight variablen fra datasættet TXBirths.



Fraktildiagrammer for normalfordelingen

I fraktildiagrammer ser vi efter *systematiske* afvigelser fra en ret linje.



Transformation af data

Hvis man ikke umiddelbart kan finde en statistisk model for data kan en mulig løsning være at anvende en transformation.



Venstre: Fraktildiagram for reaktionstid for fluer. Højre: Fraktildiagram for logritmen til reaktionstiden. Bemærk at de teoretisk fraktiler er på y-aksen.

Scatterplot (punktdiagram)

MSRR 2.6


Visualiser sammenhæng mellem interessevariabel y og forklarende variabel x . Hver observation giver en punkt i diagrammet. R:

```
plot (x, y)
```

eller formel-syntaks:

interessevariabel $\sim$ forklarende variabel

```
plot (Beer  $\sim$  Hotwings, data=Beerwings)
```



Skewness og kurtosis

Lad X være en stokastisk variabel med middelværdi $\mathbb{E}[X] = \mu$ og standard afvigelse $\sqrt{\text{Var}[X]} = \sigma$. Da indføres *skewness* (skævhed) og *kurtosis* (topstejlhed) som

$$\gamma_1 = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{\mu_3}{\sigma^3}$$
$$\gamma_2 = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] - 3 = \frac{\mu_4}{\sigma^4} - 3,$$

hvor $\mu_k = \mathbb{E}(X - \mu)^k$ betegner de *centrale momenter*. Til tider betegnes $\mu^4/\sigma^4 - 3$ *excess kurtosis* og μ^4/σ^4 som kurtosis.

Skewness og kurtosis

Skewness kan under rette omstændigheder fortolkes som et kvantitativt mål for skævheden:






Figure 2.2 Histogram of lengths of flight delays for United Airlines. The distribution is right skewed.

$$\hat{\gamma}_1 = 4.807$$



$$\hat{\gamma}_1 = 0.003$$




$$\hat{\gamma}_1 = -0.751$$

Estimerede værdier af skewness

Skewness og kurtosis

Kurtosis kan (igen under rette omstændigheder) fortolkes som et kvantitativt for hvor tunge fordelings haler er (*og i denne forstand* hvor “spids” toppen er).



Estimerede værdier af excess kurtosis

Bibliografi



Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (2nd edition).

John Wiley & Sons, 2018.



Alan Julian Izenman.

Modern multivariate statistical techniques.

Springer Texts in Statistics. Springer, New York, 2008.

Regression, classification, and manifold learning.