

Matematisk Statistik

To normalfordelte observationsrækker

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

To normalfordelte observationsrækker
Ens varians

k normalfordelte observationsrækker

Modellen for k normalfordelte observationsrækker er, at data

Gruppe 1	x_{11}	$\dots$	x_{1j}	$\dots$	x_{1n_1}
$\vdots$		$\vdots$		$\vdots$	
Gruppe i	x_{i1}	$\dots$	x_{ij}	$\dots$	x_{in_i}
$\vdots$		$\vdots$		$\vdots$	
Gruppe k	x_{k1}	$\dots$	x_{kj}	$\dots$	x_{kn_k}

er realisationer af uafhængige, normalfordelte stokastiske variable

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, \dots, k, \quad j = 1, \dots, n_i.$$

k observationsrækker: notation

Notation vedrørende modellen

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, \dots, k, \quad j = 1, \dots, n_i.$$

I den i te række er

- antallet af observationer: n_i
- den empiriske middelværdi eller gennemsnittet:

$$\bar{x}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} x_{ij}$$

- den empiriske varians

$$s_{(i)}^2 = \frac{1}{n_i - 1} \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i\cdot})^2$$

- antallet af frihedsgrader: $f_{(i)} = n_i - 1$

Eksempel 1.5

Data

I dette eksempel stammer fra to eksperimenter, hvor man målte fluers reaktion, efter de var blevet udsat for en nervegas.

Målingen for den enkelte flue består i den tid - reaktionstiden - der går fra fluen bringes i kontakt med giften og indtil den ikke længere kan stå på benene.

Fagligt problem

Afhænger reaktionstiden af kontakttiden?

Transformation

Fraktildiagrammerne i Figur 1.6 og 1.7 viser, at vi er nødt til at logaritmetransformere reaktionstiderne for at opnå normalitet.

Eksempel 1.5

Model og modelkontrol

Lad x_{ij} være den naturlige logaritme til j te observation af reaktionstiden i den i te gruppe. Vi betragter da modellen

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i + \text{uafhængighed}.$$

Idet $i = 1$ svarer til en kontakttid på 30 s og $i = 2$ til 60 s, er $n_1 = 16$ og $n_2 = 15$.

Fraktildiagrammet i Figur 1.7 strider ikke mod denne model og antyder tillige, at kontakttiden ikke har nogen betydning for reaktionstiden.

Eksempel 1.5

Estimation i M_0

$$\mu_1 \leftarrow \bar{x}_{1.} = 2.8072$$

$$\bar{X}_{1.} \sim N(\mu_1, \sigma_1^2/n_1)$$

$$\mu_2 \leftarrow \bar{x}_{2.} = 2.7154$$

$$\bar{X}_{2.} \sim N(\mu_2, \sigma_2^2/n_2)$$

$$\sigma_1^2 \leftarrow s_{(1)}^2 = 1.102779$$

$$s_{(1)}^2(\mathbf{X}) \sim \sigma_1^2 \chi^2(f_{(1)})/f_{(1)}$$

$$\sigma_2^2 \leftarrow s_{(2)}^2 = 1.023778$$

$$s_{(2)}^2(\mathbf{X}) \sim \sigma_2^2 \chi^2(f_{(2)})/f_{(2)}$$

De 4 estimatorer er uafhængige (se A.1.2).

Hypoteser og test

I modellen for to normalfordelte observationsrækker

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i,$$

er det sædvanligvis hypotesen *ens middelværdier*,

$$H_{0\mu} : \mu_1 = \mu_2$$

der er af primær interesse.

Testet for $H_{0\mu}$ afhænger af, om det kan antages, at de to rækker har ens varians. Vi tester derfor først hypotesen

$$H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2.$$

Test af $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$

Da $\sigma_1^2 \leftarrow s_{(1)}^2$ og $\sigma_2^2 \leftarrow s_{(2)}^2$, må man under $H_{0\sigma^2}$ forvente, at

$$\frac{s_{(1)}^2}{s_{(2)}^2} \approx 1$$

Under $H_{0\sigma^2}$ er $s_{(1)}^2/s_{(2)}^2$ $F(f_{(1)}, f_{(2)})$ -fordelt (se A.3.4), og et første bud på p -værdien er derfor

$$\tilde{p}_{obs}(\mathbf{x}) = \begin{cases} 2F_{F(f_{(1)}, f_{(2)})}\left(\frac{s_{(1)}^2}{s_{(2)}^2}\right), & \text{hvis } \frac{s_{(1)}^2}{s_{(2)}^2} \leq 1, \\ 2\left(1 - F_{F(f_{(1)}, f_{(2)})}\left(\frac{s_{(1)}^2}{s_{(2)}^2}\right)\right), & \text{hvis } \frac{s_{(1)}^2}{s_{(2)}^2} \geq 1, \end{cases}$$

hvor $F_{F(f_{(1)}, f_{(2)})}$ er fordelingsfunktionen for $F(f_{(1)}, f_{(2)})$ -fordelingen.

Test af $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$

I stedet benyttes dog (med samme argument som for $H : \sigma^2 = \sigma_0^2$)

$$p_{obs}(\mathbf{x}) = 2 \min \left\{ F_{F(f_{(1)}, f_{(2)})} \left(\frac{s_{(1)}}{s_{(2)}} \right), 1 - F_{F(f_{(1)}, f_{(2)})} \left(\frac{s_{(1)}}{s_{(2)}} \right) \right\}.$$

For data i Eksempel 1.5 har vi

$$\mathcal{F}(\mathbf{x}) = \frac{s_{(1)}^2(\mathbf{x})}{s_{(2)}^2(\mathbf{x})} = \frac{1.102779}{1.023778} = 1.077.$$

og da

$$\mathbb{P}[\mathcal{F}(\mathbf{X}) > 1.077] = 1 - F_{F(f_{(1)}, f_{(2)})}(1.077) = 0.447$$

finder vi

$$p_{obs}(\mathbf{x}) = 2\mathbb{P}(\mathcal{F}(\mathbf{X}) > 1.077) = 0.894.$$

så $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$ forkastes ikke.

Faglig konklusion

Data strider ikke mod at antage, at de to observationsrækker har ens varians.

Ens varians

Modellen M_1

Da vi ikke forkaster $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$ reduceres modellen M_1 til

$$M_1 : X_{ij} \sim (\mu_i, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed. }$$

som har tre ukendte parametre, middelværdierne μ_1 og μ_2 i de to rækker og den fælles varians σ^2 .

Estimation i M_1

$$\mu_1 \leftarrow \hat{\mu}_1(\mathbf{x}) = \bar{x}_1. \quad \text{hvor} \quad \bar{X}_1. \sim N(\mu_1, \sigma^2/n_1)$$

$$\mu_2 \leftarrow \hat{\mu}_2(\mathbf{x}) = \bar{x}_2. \quad \text{hvor} \quad \bar{X}_2. \sim N(\mu_2, \sigma^2/n_1)$$

$$\sigma^2 \leftarrow s_1^2 = \frac{\text{SSD}_{(1)} + \text{SSD}_{(2)}}{n_1 + n_2 - 2} = \frac{f_{(1)}s_{(1)}^2 + f_{(2)}s_{(2)}^2}{f_{(1)} + f_{(2)}} = \frac{\text{SSD}_1}{f_1} \sim \frac{\sigma^2 \chi^2(f_1)}{f_1}.$$

hvor $f_1 = n_1 + n_2 - 2$, antallet af observationer minus antallet af ukendte parametre i middelværdien.

Eksempel 1.5 : Estimation i M_1

Eksempel 1.5

Estimaterne for parametrene i M_1 er

$$\mu_1 \leftarrow \bar{x}_{1\cdot} = 2.8072$$

$$\mu_2 \leftarrow \bar{x}_{2\cdot} = 2.7154$$

$$\sigma^2 \leftarrow s^2 = 1.064638$$

De tre fordelinger er henholdsvis $N(\mu_1, \sigma^2/16)$, $N(\mu_2, \sigma^2/15)$ og $\sigma^2\chi^2(29)/29$ og de tilsvarende stokastiske variable er uafhængige.

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_1

Testet er baseret på en sammenligning af estimerterne for middelværdierne. Da

$$\bar{X}_{1.} \sim N\left(\mu_1, \frac{\sigma^2}{n_1}\right) \quad \text{og} \quad \bar{X}_{2.} \sim N\left(\mu_2, \frac{\sigma^2}{n_2}\right),$$

og fordelingerne er uafhængige, gælder der under $H_{\mu 0}$ at

$$\bar{X}_{1.} - \bar{X}_{2.} \sim N\left(0, \sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)\right).$$

Derfor er

$$\frac{\bar{X}_{1.} - \bar{X}_{2.}}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1).$$

Da σ^2 er ukendt, indsættes i stedet skønnet s^2 .

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_1 (fortsat)

Dette giver t -testoren

$$t(\mathbf{X}) = \frac{\bar{X}_{1\cdot} - \bar{X}_{2\cdot}}{\sqrt{s^2(\mathbf{X}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \underset{\text{under } H_{0\mu}}{\sim} t(f_1).$$

Da numerisk store værdier af t er kritiske, bliver testsandsynligheden for t -testet

$$p_{obs}(\mathbf{x}) = 2 \left[1 - F_{t(f_1)}(|t(\mathbf{x})|) \right].$$

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_1 (fortsat)

Den estimerede spredning på $\bar{x}_1. - \bar{x}_2.$ er

$$\text{StdError}(\bar{x}_1. - \bar{x}_2.) = \sqrt{s_1^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$$

og 95% konfidensintervallet for $\mu_1 - \mu_2$ kan skrives

$$\bar{x}_1. - \bar{x}_2. \pm t_{0.975}(f_1) \text{StdError}(\bar{x}_1. - \bar{x}_2.)$$

95% konfidensintervallet for σ^2 er

$$\left(\frac{f_1 s_1^2}{\chi_{0.975}^2(f_1)}, \frac{f_1 s_1^2}{\chi_{0.25}^2(f_1)} \right)$$

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_1 (fortsat)

Eksempel 1.5

Den observerede værdi af teststørrelsen $t(\mathbf{x})$ er

$$t(\mathbf{x}) = \frac{2.8072 - 2.7154}{\sqrt{1.064638 \left(\frac{1}{16} + \frac{1}{15}\right)}} = \frac{0.0918}{0.3708} = 0.2475.$$

så hypotesen $H_{0\mu} : \mu_1 = \mu_2$ forkastes ikke, da

$$p_{obs}(\mathbf{x}) = 2 [1 - F_{t(f_1)}(|t(\mathbf{x})|)] = 2 [1 - F_{t(29)}(0.2475)] = 0.81,$$

Da $t_{0.975}(29) = 2.0452$, bliver 95% konfidensintervallet for $\mu_1 - \mu_2$

$$0.0918 \pm 0.3708 \cdot 2.0452 = [-0.6666, 0.8501].$$

Faglig konklusion

I forsøget er det ikke påvist, at kontakttiderne har nogen indflydelse på reaktionstiderne

Eksempel 1.5 - transformation af parametre

Parameterestimer og tilhørende konfidensintervaller i M_0 findes i Tabel 2.2.

Kontaktid	Estimer	
	Middelværdi μ	Varsians σ^2
30 sekunder	2.8072	1.102779
60 sekunder	2.7154	1.023778
95% Konfidensintervaller		
30 sekunder	[2.2476, 3.3668]	[0.6018, 2.6416]
60 sekunder	[2.1551, 3.2757]	[0.5489, 2.5469]

Konfidensintervallerne for μ_1 og μ_2 kan transformeres til konfidensintervaller for e^{μ_1} og e^{μ_2} og disse findes til [9.47, 28.98] og [8.63, 26.46].

Bemærk at e^{μ_i} $i = 1, 2$ er medianen (ikke middelværdien) i fordelingerne af de ikke-transformerede reaktionstider.

Eksempel 1.5 - transformation af parametre

I M_1 fandt vi 95% konfidensintervallet for $\mu_1 - \mu_2$ til $[-0.6666, 0.8501]$.

Dette kan transformeres til et konfidensinterval for $e^{\mu_1 - \mu_2} = e^{\mu_1} / e^{\mu_2}$. Det transformerede konfidensinterval findes til

$$[\exp(-0.6666), \exp(0.8502)] = [0.51, 2.34].$$

Dette er som udgangspunkt et forhold mellem medianerne, men da $U \sim N(\mu, \sigma^2) \Rightarrow \mathbb{E}[e^U] = e^{\mu + \sigma^2/2}$ kan det også fortolkes som et forhold mellem middelværdierne af de ikke-transformerede reaktionstider i M_1 .

Ens varians og ens middelværdi

Modellen M_2

Forkastes hypotesen $H_{0\mu} : \mu_1 = \mu_2$ ikke ved test i modellen M_1 , reduceres M_1 til

$$M_2 : X_{ij} \sim N(\mu, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.}$$

dvs. alle observationerne har samme fordeling og kan betragtes som én observationsrække.

Estimerer i M_2

$$\mu \leftarrow \bar{X}_{..} \quad \text{hvor} \quad \bar{X}_{..} \sim N\left(\mu, \frac{\sigma^2}{n_{..}}\right)$$

$$\sigma^2 \leftarrow s^2(\mathbf{X}) \quad \text{hvor} \quad s^2(\mathbf{X}) \sim \sigma^2 \chi^2(n_{..} - 1)/(n_{..} - 1)$$

hvor $n_{..} = n_1 + n_2$.

Beregninger i R

Alle de gennemgående udtryk kan beregnes i **R** ved hjælp af funktioner som **mean**, **sd** og **var**.

T-test for $H_0 : \mu = \mu_0$ i én observationsrække (med ukendt varians) og $H_{0\mu} : \mu_1 = \mu_2$ i to observationsrækker kan foretages med **t.test**. Ved at specificere **var.equal = TRUE** eller **var.equal = FALSE** kan man angive, om man ønsker at testet skal udføres under antagelse varianshomogenitet eller ikke. *F*-testet for varianshomogenitet $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$ i to

observationsrækker kan udføres ved hjælp af kommandoen **var.test**.