

Matematisk Statistik

To normalfordelte observationsrækker

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

To normalfordelte observationsrækker
Forskellig varians

Eksempel 3.1

Fagligt problem og data

Ældre kvinder er i risiko for knogleskørhed og man ønsker at undersøge effekten af en behandling for dette. Ved hjælp af røntgen-absorptionsmetri foretages derfor calciummålinger i albueknoglen på 31 ældre kvinder. $n_1 = 16$ tilhører en behandlingsgruppe og $n_2 = 15$ tilhører en kontrolgruppe.

Model og modelkontrol


Lad x_{ij} være den j te observation i den i te gruppe. Vi betragter da modellen

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed. }$$

Idet $i = 1$ svarer til behandlingsgruppen og $i = 2$ til kontrolgruppen, er $n_1 = 16$ og $n_2 = 15$.

Den faglige problemstilling kan undersøges ved at sammenligne middelværdierne i de to grupper.

Eksempel 3.1 - Modelkontrol



Data fremstår pænt normalfordelt, bortset muligvis fra en enkelt outlier i kontrolgruppen.

Er data normalfordelt: qqplots

To qqplots i samme figur:

```
datrange <- range(kontrolgruppe,behandlingsgruppe)
qqnorm(kontrolgruppe,ylim=datrange,pch=15)
qqnormobj <- qqnorm(behandlingsgruppe,plot=FALSE)
points(qqnormobj,col=2,pch=16)
legend("topleft",legend=c("kontrolgruppe",
                           "behandlingsgruppe"),col=c(1,2),pch=c(15,16))
```

Eksempel 3.1

Estimation i

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.}$$

$$\mu_1 \leftarrow \bar{x}_{1.} = -3.55625 \quad \text{hvor} \quad \bar{X}_{1.} \sim N(\mu_1, \sigma_1^2/n_1),$$

$$\mu_2 \leftarrow \bar{x}_{2.} = -7.59333 \quad \text{hvor} \quad \bar{X}_{2.} \sim N(\mu_2, \sigma_2^2/n_2),$$

$$\sigma_1^2 \leftarrow s_{(1)}^2 = 7.367958 \quad \text{hvor} \quad s_{(1)}^2(\mathbf{X}) \sim \sigma_1^2 \chi^2(f_{(1)})/f_{(1)},$$

$$\sigma_2^2 \leftarrow s_{(2)}^2 = 18.38495 \quad \text{hvor} \quad s_{(2)}^2(\mathbf{X}) \sim \sigma_2^2 \chi^2(f_{(2)})/f_{(2)}.$$

De 4 stokastiske variable er uafhængige.

Eksempel 3.1: test af $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$

Ved hjælp af estimerne findes teststørrelsen

$$\mathcal{F} = \frac{s_{(1)}^2}{s_{(2)}^2} = \frac{7.367958}{18.38495} = 0.40076$$

som under hypotesen er udfald af en $F(15, 14)$ -fordeling.

p -værdien findes til

$$p_{obs}(\mathbf{x}) = 2F_{F(15,14)}(0.40076) = 0.08974.$$

$H_{0\sigma^2}$ kan ikke afvises, men p -værdien er lav og vi alligevel gerne undersøge $H_{0\mu} : \mu_1 = \mu_2$ uden at gøre nogen antagelser om variansen.

Test af $H_{0\mu} : \mu_1 = \mu_2$ i M_0

$$I \quad M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i, \text{ testes} \\ H_{0\mu} : \mu_1 = \mu_2$$

ved hjælp testoren

$$t(\mathbf{X}) = \frac{\bar{X}_{1\cdot} - \bar{X}_{2\cdot}}{\sqrt{s_{(1)}^2/n_1 + s_{(2)}^2/n_2}} \approx t(\bar{f}),$$

hvor

$$\bar{f} = \frac{\left(\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2}\right)^2}{\frac{\left(\frac{s_{(1)}^2}{n_1}\right)^2}{f_{(1)}} + \frac{\left(\frac{s_{(2)}^2}{n_2}\right)^2}{f_{(2)}}}.$$

Testsandsynligheden er

$$p_{obs} = 2(1 - F_{t(\bar{f})}(|t(\mathbf{X})|)).$$

Konfidensinterval for $\mu_1 - \mu_2$ i M_0

Da den estimerede spredning på $\bar{x}_1. - \bar{x}_2.$ er

$$\text{StdError}(\bar{x}_1. - \bar{x}_2.) = \sqrt{s_{(1)}^2/n_1 + s_{(2)}^2/n_2}$$

bliver 95 % konfidensintervallet for $\mu_1 - \mu_2$

$$\bar{x}_1. - \bar{x}_2. \pm t_{0.975}(\bar{f}) \text{StdError}(\bar{x}_1. - \bar{x}_2.).$$

Eksempel 3.1: Test af $H_{0\mu} : \mu_1 = \mu_2$

Den observerede værdi af teststørrelsen $t(\mathbf{x})$ er

$$t(\mathbf{x}) = \frac{-3.55625 - (-7.593333)}{\sqrt{0.460497 + 1.22566}} = \frac{4.03708}{1.29852} = 3.10898.$$

$\bar{f}$ beregnes til 23.41172 så

$$p_{obs} = 2(1 - F_{t(23.41172)}(|3.10898|)) = 0.0048743,$$

og hypotesen $H_{0\mu} : \mu_1 = \mu_2$ forkastes.

Da $t_{0.975}(23.41172) = 2.066646$, bliver 95% konfidensintervallet for $\mu_1 - \mu_2$

$$4.03708 \pm 2.066646 \cdot 1.29852 = [1.353496, 6.720670].$$

Faglig konklusion

Det kan ikke antages, at middelværdien af calciumindholdet er ens i de to grupper. Da estimatet for behandlingsgruppen er højere end for kontrolgruppen, tyder data på, at patienterne i førstnævnte har haft gavn af behandlingen.