

Matematisk Statistik

k normalfordelte observationsrækker

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

k normalfordelte observationsrækker

Modellen for k normalfordelte observationsrækker med hver sin middelværdi og hver sin varians er, at data

$$\begin{array}{ccccccc} x_{11} & \dots & x_{1j} & \dots & x_{1n_1} & & \\ & & \vdots & & \vdots & & \\ x_{i1} & \dots & x_{ij} & \dots & x_{in_i} & & \\ & & \vdots & & \vdots & & \\ x_{k1} & \dots & x_{kj} & \dots & x_{kn_k} & & \end{array}$$

er realisationer af uafhængige, normalfordelte stokastiske variable, dvs.

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

Modeller og hypoteser

I $M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i$,
betragtes *hypotesen om varianshomogenitet*

$$H_{0\sigma^2} : \sigma_1^2 = \dots = \sigma_k^2.$$

som reducerer M_0 til modellen for k normalfordelte observationsrækker med hver sin middelværdi og samme varians

$$M_1 : X_{ij} \sim (\mu_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

I M_1 betragtes *hypotesen om ens middelværdier*

$$H_{0\mu} : \mu_1 = \dots = \mu_k$$

som reducerer M_2 til modellen for én normalfordelt observationsrække

$$M_2 : X_{ij} \sim (\mu, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

k observationsrækker: notation

Notation vedrørende modellen

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

I den i te række er:

- antallet af observationer: n_i
- den empiriske middelværdi eller gennemsnittet:

$$\bar{x}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} x_{ij}$$

- den empiriske varians

$$s_{(i)}^2 = \frac{1}{n_i - 1} \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i\cdot})^2$$

- antallet af frihedsgrader: $f_{(i)} = n_i - 1$.

Eksempel 3.2

Fagligt problem

Hvordan påvirker stress væksten af sojabønner?

52 stiklinger blev plantet i pletter, én i hver plette. De 52 stiklinger blev tilfældigt inddelt i fire grupper med 13 i hver. Stiklingerne i to af grupperne blev stresset ved at blive rystet i tyve minutter dagligt, mens stiklingerne i de to andre grupper ikke blev rystet. Desuden voksede to af grupperne i svagt lys, og de andre to grupper i moderat lys, således at de fire grupper fik hver sin behandling:

Gruppe 1 : svagt lys, ingen stress

Gruppe 2 : svagt lys, stress

Gruppe 3 : moderat lys, ingen stress

Gruppe 4 : moderat lys, stress

Eksempel 3.2 - data

Samlet areal i cm ²			
Gruppe			
1	2	3	4
200	163	268	201
215	182	271	216
225	188	273	241
229	195	282	257
230	202	285	259
232	205	299	267
241	212	309	269
253	214	310	282
256	215	314	283
264	230	320	291
268	235	337	291
288	255	340	312
288	272	345	326
Middelværdier			
245.31	212.92	304.08	268.85

Tabel 1: Gruppe 1: svagt lys, ingen stress; Gruppe 2: svagt lys, stress; Gruppe 3: moderat lys, ingen stress; Gruppe 4: moderat lys, stress.

Eksempel 3.2

Model og modelkontrol


Lad x_{ij} være bladarealet efter 16 dages vækst for den j te plante i den i te gruppe. Vi betragter da modellen

$$M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

med $k = 4$ og $n_1 = n_2 = n_3 = n_4 = 13$.

Fraktildiagrammerne i Figur 3.2 strider ikke mod denne model. De rette linjer, som punkterne fordeler sig om, har ikke meget forskellige hældninger, så fraktildiagrammerne tyder på, at varianserne er ens. Til gengæld er fraktildiagrammerne forskudt i forhold til hinanden og det tyder på forskellig middelværdi i de fire observationsrækker.

Eksempel 3.2 - fraktildiagram



Figur 1: Fraktildiagrammer for data i Tabel 3.4.

Estimation i M_0

Estimation i

$$M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

$$\begin{array}{ll} \mu_i \leftarrow \bar{X}_{i.} & \text{hvor} \quad \bar{X}_{i.} \sim N(\mu_i, \sigma_i^2/n_i), \\ \sigma_i^2 \leftarrow s_{(i)}^2 & \text{hvor} \quad s_{(i)}^2(\mathbf{X}) \sim \sigma_i^2 \chi^2(f_{(i)})/f_{(i)}. \end{array}$$

De $2k$ estimatorer er uafhængige.

Estimaterne for varianserne findes til

$$s_{(1)}^2 = 730.231 \quad s_{(2)}^2 = 884.910 \quad s_{(3)}^2 = 724.910 \quad s_{(4)}^2 = 1241.308$$

Estimation i M_1

Estimation i

$$M_1 : X_{ij} \sim (\mu_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

middelværdier

$$\mu_i \leftarrow \bar{X}_i.$$

fælles varians

Med $f_1 = f_{(1)} + \dots + f_{(k)}$ har vi

$$\begin{aligned} s_1^2 &= \frac{\text{SSD}_1}{f_1} = \frac{\text{SSD}_{(1)} + \dots + \text{SSD}_{(k)}}{f_{(1)} + \dots + f_{(k)}} \\ &= \frac{f_{(1)} s_{(1)}^2 + \dots + f_{(k)} s_{(k)}^2}{f_{(1)} + \dots + f_{(k)}}. \end{aligned}$$

Den tilsvarende estimator er $\sigma^2 \chi^2(f_1)/f_1$ -fordelt.

De i alt $k + 1$ estimatorer er uafhængige.

Test af fælles varians

Hypotesen om varianshomogenitet

$$H_{0\sigma^2} : \sigma_1^2 = \dots \sigma_k^2 = \sigma^2$$

testes med udgangspunktet i skønnene $s_{(1)}^2, \dots, s_{(k)}^2$ over varianserne $\sigma_1^2, \dots, \sigma_k^2$ i M_0 .

Hvis Q er likelihood ratio testet baseret på variansskønnenes fordeling

$$s_{(i)}^2 \sim \sigma_i^2 \chi^2(f_{(i)})/f_{(i)}, \quad i = 1, \dots, k,$$

gælder der at

$$-2 \ln Q(\mathbf{x}) = f_1 \ln s_1^2 - \sum_{i=1}^k f_{(i)} \ln s_{(i)}^2.$$

Detaljer til Bartlett's test

Udgangspunkt: k grupper, uden () om indekser.

Fra hver gruppe et variansskøn s_j^2 , $j = 1, \dots, k$, uafhængige

Model: s_j^2 er udfald af $S_j^2 \sim \sigma_j^2 \chi^2(f_j)/f_j$ eller $\frac{f_j S_j^2}{\sigma_j^2} \sim \chi^2(f_j)$

Hypotese: $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$

Test: tage udgangspunkt i likelihood ratio test

Tæthed for $\chi^2(f)$ fordeling (MSRR B.10/A.3.2)

$$f(x) = \frac{x^{f/2-1}}{2^{f/2}\Gamma(f/2)} e^{-x/2} \quad 0 \leq x < \infty$$

Detaljer til Bartlett's test

Likelihoodfunktion for j 'te led:

$$L_j(\sigma_j^2) = K(f_j, s_j^2) \frac{1}{(\sigma_j^2)^{f_j/2}} e^{-\frac{1}{2} f_j s_j^2 / \sigma_j^2}$$

Fra dette udledes: $\hat{\sigma}_j^2 = s_j^2$ og $L_j(\hat{\sigma}_j^2) = K(f_j, s_j^2) \frac{1}{(s_j^2)^{f_j/2}} e^{-\frac{1}{2} f_j}$

Den fulde likelihoodfunktion bliver derfor:

$$L(\sigma_1^2, \dots, \sigma_k^2) = L_1(\sigma_1^2) \cdots L_k(\sigma_k^2), \quad \text{og}$$

$$L(\hat{\sigma}_1^2, \dots, \hat{\sigma}_k^2) = L_1(s_1^2) \cdots L_k(s_k^2)$$

Detaljer til Bartlett's test

Når varianserne er ens har vi med $f = f_1 + \dots + f_k$

$$L(\sigma^2, \dots, \sigma^2) = \left(\prod_j K(f_j, s_j^2) \right) \frac{1}{(\sigma^2)^{f/2}} e^{-\frac{1}{2}f(\sum_j f_j s_j^2 / f) / \sigma^2}$$

som giver

$$\hat{\sigma}^2 = \frac{\sum_j f_j s_j^2}{f} = s^2$$

og

$$L(s^2, \dots, s^2) = \left(\prod_j K(f_j, s_j^2) \right) \frac{1}{(s^2)^{f/2}} e^{-\frac{1}{2}f}$$

Detaljer til Bartlett's test

Likelihood ratio teststørrelse bliver

$$Q = \frac{L(s^2, \dots, s^2)}{L(s_1^2, \dots, s_k^2)} = \frac{\frac{1}{(s^2)^{f/2}} e^{-\frac{1}{2}f}}{\prod_j \frac{1}{(s_j^2)^{f_j/2}} e^{-\frac{1}{2}f_j}}$$

og dermed

$$-2 \log(Q) = f \log(s^2) - \sum_j f_j \log(s_j^2).$$

Test af fælles varians

Approksimativt gælder der for store værdier af $f_{(i)}$, at

$$-2 \ln Q(\mathbf{x}) \sim \chi^2(k-1)$$

fordi man reducerer fra en model med k parametre $\sigma_1^2, \dots, \sigma_k^2$ til en model med 1 parameter σ^2 .

M.S. Bartlett viste i 1937, at approksimationen til χ^2 -fordelingen kunne forbedres, hvis man dividerer $-2 \ln Q$ med konstanten

$$C = 1 + \frac{1}{3(k-1)} \left[\left(\sum_{i=1}^k \frac{1}{f_{(i)}} \right) - \frac{1}{f_1} \right].$$

Teststørrelsen

$$Ba = \frac{-2 \ln Q(\mathbf{x})}{C}$$

kaldes *Bartletts test*. Approksimationen til $\chi^2(k-1)$ -fordelingen er tilfredsstillende, hvis $f_{(i)} \geq 2$ for $i = 1, \dots, k$, dvs. hvis $n_i \geq 3$, $i = 1, \dots, k$, altså der er mindst tre observationer i hver observationsrække.

Test af fælles varians

Da $-2 \log Q$ er et likelihood ratio test, er det små værdier af Q , der er kritiske for nulhypotesen, og dermed store værdier af $-2 \log Q$, der er kritiske for nulhypotesen.

Testsandsynligheden beregnes derfor som

$$p_{\text{obs}}(\mathbf{x}) = 1 - F_{\chi^2(k-1)}(Ba),$$

hvor $F_{\chi^2(k-1)}$ er fordelingsfunktionen for χ^2 -fordelingen med $k - 1$ frihedsgrader.

Test af fælles varians - Eksempel 3.2

Estimatet for den fælles varians i M_1 findes til

$$s_1^2 = \frac{730.231 + 884.910 + 724.910 + 1241.308}{4} = 895.340.$$

Vi finder derved

$$-2 \ln Q = 1.1999,$$

og

$$C = 1.03472,$$

og dermed

$$Ba = \frac{-2 \ln Q}{C} = \frac{1.1999}{1.03472} = 1.160$$

Vi kan da finde testsandsynligheden:

$$p_{obs}(\mathbf{x}) = 1 - F_{\chi^2(3)}(1.160) = 0.763,$$

så hypotesen om varianshomogenitet forkastes ikke.

Faglig konklusion

Data strider ikke mod antagelsen om ens varians i de fire grupper.

Test af fælles middelværdi

I $M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i$,
ønsker vi at teste *hypotesen om ens middelværdier*

$$H_{0\mu} : \mu_1 = \mu_2 = \dots = \mu_k .$$

Vi går frem således

- Angiver likelihood ratio testoren Q
- Viser Q er ækvivalent med en F-teststørrelse
- Fortolker F-teststørrelsen, angiver dens fordeling og testsandsynligheden.

Test af fælles middelværdi

Vi viser senere at M_1 og M_2 er eksempler på *lineære normale modeller* og og når man reducerer fra en lineær model til en undermodel bliver likelihood ratio testet

$$Q(\mathbf{x}) = \left[\frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} \right]^{\frac{n}{2}},$$

hvor $\hat{\sigma}_i^2$, $i = 1, 2$ er maksimum likelihood estimerne for varianserne i M_1 og M_2 .

I dette tilfælde gælder

$$\hat{\sigma}_2^2 = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{..})^2 \stackrel{\text{def}}{=} \frac{1}{n} \text{SSD}_T$$

og


$$\hat{\sigma}_1^2 = \frac{1}{n} (\text{SSD}_{(1)} + \text{SSD}_{(2)} + \cdots + \text{SSD}_{(k)}).$$

Test af fælles middelværdi

Der gælder at

$$SSD_T = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{..})^2 = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.})^2 + \sum_{i=1}^k n_i (\bar{x}_{i.} - \bar{x}_{..})^2 = \underbrace{\sum_{i=1}^k SSD_{(i)}}_{SSD_E} + \underbrace{\sum_{i=1}^k n_i (\bar{x}_{i.} - \bar{x}_{..})^2}_{SSD_H}.$$

Hvor SSD_E fortolkes som variationen indenfor grupper og SSD_H fortolkes som variationen mellem grupper.



Test af fælles middelværdi

Vi har følgende omskrivning af Q :

$$\begin{aligned} Q(\mathbf{x}) &= \left[\frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} \right]^{\frac{n}{2}} = \left[\frac{\frac{1}{n} \text{SSD}_E}{\frac{1}{n} \text{SSD}_T} \right]^{\frac{n}{2}} \\ &= \left[\frac{1}{1 + \frac{\text{SSD}_H}{\text{SSD}_E}} \right]^{\frac{n}{2}} = \left[\frac{1}{1 + \frac{k-1}{n-k} \mathcal{F}(\mathbf{x})} \right]^{\frac{n}{2}}, \end{aligned}$$

hvor $\mathcal{F}(\mathbf{x}) \stackrel{\text{def}}{=} \frac{\text{SSD}_H}{k-1} / \frac{\text{SSD}_E}{n-k} = \frac{\text{SSD}_H}{k-1} / s_1^2$ Bemærk at $\mathcal{F}(\mathbf{x})$ er en aftagende funktion af $Q(\mathbf{x})$ og omvendt, så små værdier af Q vil svare til store værdier af $\mathcal{F}$.

Test af fælles middelværdi

Vi viser senere at under $H_{0\mu}$ gælder det at

$$\mathcal{F}(\mathbf{X}) = \frac{\frac{SSD_H}{k-1}}{s_1^2} \sim F(k-1, n-k).$$

Små værdier af Q er kritiske for $H_{0\mu}$. Små værdier af Q svarer til store værdier af $\mathcal{F}$, *så store værdier af $\mathcal{F}$ er kritiske*, hvilket svarer til, at variationen mellem grupper er stor i forhold til variationen indenfor grupper.

Testsandsynligheden beregnes derfor som

$$p_{obs} = \mathbb{P}(\mathcal{F}(\mathbf{X}) \geq \mathcal{F}(\mathbf{x})) = 1 - F_{F(k-1, n-k)}(\mathcal{F}(\mathbf{x})),$$

hvor $F_{F(k-1, n-k)}$ er fordelingsfunktionen for F -fordelingen med $k-1$ frihedsgrader i tælleren og $f_1 = n-k$ frihedsgrader i nævneren.

Test af fælles middelværdi

Eksempel 3.2

I dette tilfælde finder vi

$$SSD_H = 100612.673 - 42976.308 = 57636.365$$

og dermed

$$\frac{SSD_H}{k-1} = \frac{57636.365}{3} = 19212.122.$$

kan teststørrelsen $\mathcal{F}$ beregnes som

$$\mathcal{F}(\mathbf{x}) = \frac{19212.122}{895.340} = 21.46.$$

$\mathcal{F}$ skal vurderes i en $F(3, 48)$ fordeling, og da kun store værdier er kritiske, er

$$p_{obs} = 1 - F_{F(3,48)}(21.46) = 0.000000006.$$

Eksempel 3.2 (fortsat)

Da $p_{obs} < 0.05$ forkastes $H_{0\mu}$, og dermed reduktionen til modellen M_2 . Modellen for data er stadig M_1 : fire normalfordelte observationsrækker med hver sin middelværdi og fælles varians.

Faglig konklusion

Forsøget viser, at lys og stress påvirker væksten af sojabønner.

Oplagt opfølgende spørgsmål: Hvordan på virker lys og stress *hver for sig* væksten af sojabønner?