

Matematisk Statistik

Lineær regression

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Eksempel 4.1

Fagligt problem


Det er vigtigt at kunne foretage hurtig E. coli-detektion for opdage aktuel forurening af vand, men sædvanlige målemetoder er langsomme. Man er derfor interesseret i at udvikle alternative målemetoder, og en mulighed er at måle *GLUase-aktivitet*. Vi ønsker at vurdere muligheden for at angive indholdet af E. coli ud fra målinger af GLUase-aktivitet.

Data

Data består af 98 samhørende målinger af logaritmen til mængden af E.coli og logaritmen til GLUase aktiviteten fra vandprøver fra forskellige Østrigske floder indsamlet gennem 1998 og 1999.

Eksempel 4.1

logColi	logGlu
2.80	-1.05
2.86	-1.04
2.88	-1.10
$\vdots$	$\vdots$
3.38	-1.01
2.83	-1.05



Del af datasæt fra Eksempel 4.1 samt scatterplot.

Model

Modellen for lineær regression svarende til talparrene (t_i, x_i) , $i = 1, \dots, n$, hvor t -erne er faste (ikke-stokastiske), er

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n.$$

og X_i -erne er uafhængige.

- Modellen omtales som en lineær regression af x på t
- Den rette linje $x(t) = \alpha + \beta t$ kaldes *regressionslinjen*
- Parameteren α kaldes afskæringen (intercept)
- Parameteren β kaldes hældningen (slope) eller regressionskoefficienten
- t kaldes den uafhængige eller den forklarende variabel
- x kaldes den afhængige variabel eller responsen

I Eksempel 4.1 er

- $n = 98$
- t_i den i te måling af logaritmen til mængden af E.coli
- x_i den i te måling af logaritmen til GLUase-aktiviteten

Ifølge modellen

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n.$$

er $\alpha + \beta t$ den forventende af logaritmen til GLUase-aktiviteten når logaritmen til mængden af E.coli er t .

- den forventede GLUase aktivitet afhænger lineært af logaritmen til mængden af E.coli
- variansen på målingerne af GLUase aktiviteten afhænger ikke af logaritmen til mængden af E.coli
- variationen omkring linjen er normalfordelt

I M_2 er likelihoodfunktionen

$$\begin{aligned} L(\alpha, \beta, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \alpha - \beta t_i)^2} \\ &= \frac{1}{\sqrt{2\pi\sigma^2}^n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \alpha - \beta t_i)^2}. \end{aligned}$$

så log likelihoodfunktionen er

$$l(\alpha, \beta, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n \{x_i - (\alpha + \beta t_i)\}^2.$$

Estimation

Det vises, at

$$\hat{\beta} = \frac{\text{SPD}_{\mathbf{xt}}}{\text{SSD}_{\mathbf{t}}}, \quad \hat{\alpha} = \bar{x} - \hat{\beta}\bar{t} \quad \text{og}$$
$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \{x_i - (\hat{\alpha} + \hat{\beta}t_i)\}^2$$


Som estimator for σ^2 benyttes

$$s_{02}^2(\mathbf{X}) = \frac{1}{n-2} \sum_{i=1}^n \{X_i - (\hat{\alpha} + \hat{\beta}t_i)\}^2 \sim \sigma^2 \chi^2(f_{02})/f_{02}$$

med $f_{02} = n - 2$, som har middelværdi σ^2 .

Bemærk, at antallet af frihedsgrader for variansskønnet s_{02}^2 er lig med antallet af observationer minus antallet af ukendte parametre i middelværdien.

Eksempel 4.1, estimation.



Figur 1: Scatterplot, med estimeret regressionslinje indtegnet, samt to parallelle linjer i afstanden $\pm 2s_{02}$.

For data i Eksempel 4.1 findes estimerterne i M_2 :

$$\alpha \leftarrow \hat{\alpha} = -3.887245 \quad \beta \leftarrow \hat{\beta} = 0.8493586 \quad \sigma^2 \leftarrow s_{02}^2 = 0.09575192$$

Estimatet for linjens værdi i t_i er den *prædikterede værdi* eller den *fittede værdi* for x_i

$$\hat{x}_i \stackrel{\text{def}}{=} \hat{\alpha} + \hat{\beta}t_i.$$

Residualerne er forskellen mellem observationerne og de fittede værdier:

$$r_i \stackrel{\text{def}}{=} x_i - (\hat{\alpha} + \hat{\beta}t_i).$$

Fordeling af estimatorer

I modellen

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

har vi følgende fordelinger af forskellige estimatorer:

$$\text{Skæring: } \hat{\alpha}(\mathbf{X}) \sim N\left(\alpha, \sigma^2 \left[\frac{1}{n} + \frac{\bar{t}^2}{\text{SSD}_t} \right] \right),$$

$$\text{Hældning: } \hat{\beta}(\mathbf{X}) \sim N\left(\beta, \frac{\sigma^2}{\text{SSD}_t}\right),$$

$$\text{Linjens værdi: } \hat{\alpha} + \hat{\beta}t \sim N\left(\alpha + \beta t, \sigma^2 \left(\frac{1}{n} + \frac{(t - \bar{t})^2}{\text{SSD}_t} \right) \right)$$


$$\text{Varianssskøn: } s_{02}^2(\mathbf{X}) \sim \sigma^2 \chi^2(n-2)/(n-2).$$

Desuden gælder der, at fordelingen for $(\hat{\alpha}, \hat{\beta})$ er uafhængig af fordelingen for s_{02}^2 , samt at $\hat{\beta}$ og $\bar{X}$ er uafhængige.


Varians på estimer

$$\hat{\beta} : \frac{\sigma^2}{SSD_t}$$



SSD_t stor



SSD_t lille



$$\hat{\alpha} : \sigma^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{SSD_t} \right)$$



t-værdier langt fra nul

Der er i fire centrale antagelser i den lineære regressionsmodel

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

- *Linearitet*: Middelværdien af responsen er en lineær funktion af den forklarende variabel t .
- *Varianshomogenitet*: Variansen af X_i er identisk for alle i og afhænger ikke af t_i , $i = 1, \dots, n$.
- *Normalfordeling*: X_i , $i = 1, \dots, n$ er normalfordelte.
- *Uafhængighed*: $X_1, \dots, X_n$ er uafhængige.

De første tre antagelser kan vurderes ved hjælp af kontroltegninger.

Ved hjælp af et scatterplot af punkterne (t_i, x_i) , $i = 1, \dots, n$ kan man vurdere antagelserne om linearitet og varianshomogenitet i modellen:


$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n.$$

Punkterne i plottet skal ligge

- omkring en ret linje (linearitet af middelværdien)
- i et bånd af nogenlunde konstant bredde (konstant varians)

Scatterplottet i Eksempel 4.1 strider ikke mod modellen M_2 .



Modelkontrol



Figur 2: Tre figurer baseret på samme datasæt: Til venstre et scatterplot, i midten et residualplot og til højre er residualerne plottet med de fittede værdier.

Varianshomogenitet kan yderligere kontrolleres ved hjælp af et *residualplot*, hvor residualerne afsættes mod den forklarende variabel, dvs. en figur med punkterne (t_i, r_i) eller ved at afsætte residualerne afsættes mod de fittede værdier.



Modelkontrol. Eksempel 1: ikke-linearitet



Data er simuleret fra en $N(t_i + 0.6t_i^2, 0.1^2)$ -fordeling.

Analyse lavet i model $X_i \sim N(\alpha + \beta t_i, \sigma^2)$

Modelkontrol. Eksempel 2: stigende varians



Data er simuleret fra en $N(3 + 5t_i, 0.4 + 0.9 \cdot t_i)$ -fordeling.

Analyse lavet i model $X_i \sim N(\alpha + \beta t_i, \sigma^2)$

Residualer - fordelingsresultater

Modelkontrol af antagelsen normalfordeling baseres på residualerne.

Hvis

$$R_i = X_i - \hat{\alpha}(\mathbf{X}) - \hat{\beta}(\mathbf{X})t_i$$

har vi

$$R_i = X_i - \hat{\alpha}(\mathbf{X}) - \hat{\beta}(\mathbf{X})t_i \sim N\left(0, \sigma^2\left(1 - \frac{1}{n} - \frac{(t_i - \bar{t})^2}{\text{SSD}_t}\right)\right).$$

Variansen på R_i kan skrives som $\sigma^2(1 - h_i)$ hvor

$$h_i = \frac{1}{n} + \frac{(t_i - \bar{t})^2}{\text{SSD}_t}.$$

Størrelsen h_i kaldes *leverage*.

Bemærk at variansen på R_i -erne ikke er konstant.

Residualer - fordelingsresultater

For at opnå ens varians betragtes de *skalerede* residualer

$$r_i^\dagger = \frac{r_i}{\sqrt{1 - h_i}}.$$


I M_2 gælder at $r_i^\dagger$ erne er udfald af en $N(0, \sigma^2)$ fordeling.

Afhængigheden af σ^2 kan fjernes ved at dividere med σ og vi betragter derfor de *studentiserede skalerede residualer* (eng.: *studentized residuals*)


$$r_i^{\dagger \text{ def}} = \frac{r_i}{\sqrt{s^2 (1 - h_i)}}.$$

Disse vil have en *approksimativ t*-fordeling, som i forbindelse med kontroltegninger vil opfatte som en approksimativ normalfordeling.

Modelkontrol, Eksempel 4.1



Residualplot



Fraktilplot for studentiserede residualer

Hypoteser, test og konfidensintervaller

Generelt resultat: Antag, at vi har et estimator $\hat{\xi}$ for parameteren ξ således, at

$$\hat{\xi} \sim N(\xi, k\sigma^2)$$

hvor k er en kendt konstant og σ^2 er ukendt, samt en estimator

$$\sigma^2 \leftarrow s^2 \sim \sigma^2 \chi^2(f)/f$$

således at $\hat{\xi}$ og s^2 er uafhængige.

Da testes hypotesen $\xi = \xi_0$, hvor ξ_0 er kendt, ved t -testørrelsen

$$t = \frac{\hat{\xi} - \xi_0}{\sqrt{ks^2}} = \frac{\hat{\xi} - \xi_0}{\text{StdError}(\hat{\xi})} \sim t(f),$$

hvor store værdier af $|t|$ er kritiske.

$(1 - \alpha)$ -konfidensintervallet for ξ har grænser:

$$[\hat{\xi} - \sqrt{s^2 k} t_{1-\alpha/2}(f), \hat{\xi} + \sqrt{s^2 k} t_{1-\alpha/2}(f)].$$

Konfidensintervaller

I M_2 er der følgende $(1 - \alpha)$ konfidensintervaller:

Afskæringen α :

$$\left[\hat{\alpha} - \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{SSD_t} \right)} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{SSD_t} \right)} t_{1-\alpha/2}(f_{02}) \right],$$

Hældningen β :

$$\left[\hat{\beta} - \sqrt{\frac{s_{02}^2}{SSD_t}} t_{1-\alpha/2}(f_{02}), \hat{\beta} + \sqrt{\frac{s_{02}^2}{SSD_t}} t_{1-\alpha/2}(f_{02}) \right].$$

Værdien af $\alpha + \beta t_0$ (linjens værdi i t_0):

$$\left[\hat{\alpha} + \hat{\beta} t_0 - s_{02} \sqrt{\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \hat{\beta} t_0 + s_{02} \sqrt{\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}) \right].$$

Variansen σ^2 (findes som i Afsnit 2.2.1)

$$\left[\frac{s_{02}^2}{\chi_{1-\alpha/2}^2(f_{02})/f_{02}}, \frac{s_{02}^2}{\chi_{\alpha/2}^2(f_{02})/f_{02}} \right].$$

Prædiktionsintervaller

Hvis t_0 er en værdi af den forklarende variabel ønsker vi at udtale os om værdien af en tilhørende “ny” observation X_0 fra M_2 .

Matematisk: Antag $X_0 \sim N(\alpha + \beta t_0, \sigma^2)$ er uafhængig af $X_1, \dots, X_n$.

Vi har da

$$X_0 - (\hat{\alpha} + \hat{\beta}t_0) \sim N\left(0, \sigma^2\left(1 + \frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}\right)\right)$$

og dermed

$$\frac{X_0 - (\hat{\alpha} + \hat{\beta}t_0)}{\sqrt{s_{02}^2 \left(1 + \frac{1}{n} + \frac{(t - \bar{t})^2}{SSD_t}\right)}} \sim t(f_{02})$$

således at uligheden

$$-t_{1-\alpha/2}(f_{02}) < \frac{X_0 - (\hat{\alpha} + \hat{\beta}t_0)}{\sqrt{s_{02}^2 \left(1 + \frac{1}{n} + \frac{(t - \bar{t})^2}{SSD_t}\right)}} < t_{1-\alpha/2}(f_{02})$$

holder med sandsynlighed $1 - \alpha$.

Prædiktionsintervaller

Vi finder dermed $1 - \alpha$ *prædiktionsintervallet*

$$\left[\hat{\alpha} + \hat{\beta}t_0 - s_{02}\sqrt{1 + \frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \hat{\beta}t_0 + s_{02}\sqrt{1 + \frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}) \right] .$$

Sammenlign med konfidensinterval for linjens værdi i t_0 :

$$\left[\hat{\alpha} + \hat{\beta}t_0 - s_{02}\sqrt{\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \hat{\beta}t_0 + s_{02}\sqrt{\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{SSD_t}} t_{1-\alpha/2}(f_{02}) \right] .$$

Eksempel 4.1

For data i Eksempel 4.1 finder vi:


<i>logColi</i>	fittet værdi	95 % konfidensinterval	95 % prædiktionsinterval
4.9	0.2746	(0.2092,0.3401)	(-0.3431,0.8923)
5.7	0.9541	(0.8634,1.0448)	(0.3332,1.5750)
6.8	1.8884	(1.7455,2.0312)	(1.2578,2.5190)

Tabel 1: Beregnede 95 % konfidensintervaller og 95 % prædiktionsintervaller svarende til værdierne 4.9, 5.7 og 6.8 af *logColi*. Endvidere er de fittede værdier også angivet.


Bredden på konfidensintervallerne er henholdsvis:
0.1309,0.1814,0.2857.

Bredden på prædiktionsintervallerne er henholdsvis:
1.2354,1.2418,1.2612.

Eksempel 4.1



Fittede værdier for $\log\text{Coli}$ på 4.9, 5.7 og 6.8 sammen med 95 % konfidensintervaller



Fittede værdier for $\log\text{Coli}$ på 4.9, 5.7 og 6.8 sammen med 95 % prædiktionsintervaller .

Lineær regression med gentagelser - Eksempel 4.2

Fagligt problem Model for sigtning af sand

Hvis man placerer noget sand, hvor alle sandkornene cirka har den samme størrelse, på en sigte og roterer den, vil der i begyndelsen komme meget sand igennem sigten, men gradvist mindre og mindre. Denne observation kan formuleres således: den mængde sand, der passerer sigten per tidsenhed er proportional med den mængde sand, der er tilbage på sigten. Hvis $x(t)$ betegner vægten af den mængde sand, der til tid t er tilbage i sigten, kan modellen formuleres

$$\frac{dx(t)}{dt} = cx(t).$$

Denne differentialligning har løsningen

$$x(t) = x(0)e^{ct},$$

hvor c er en negativ konstant, da mængden af sand i sigten aftager som tiden går. $x(0)$ er vægten af sandet i sigten til tid 0.

Lineær regression med gentagelser - Eksempel 4.2

Tages logaritmen på begge sider af fås

$$\ln x(t) = \ln x(0) + ct.$$

Logaritmen til massen af det sand, som er tilbage på sigten, er altså en lineær funktion af tiden.

Data I Tabel 4.3 er gengivet resultatet af i alt 12 sigtninger af den samme portion sand. Vægten af denne er 60 g. I de fire af sigtningerne er sigten roteret 170 gange (maskinen kører med konstant hastighed og foretager 43 rotationer per minut), i fire andre er der foretaget 530 rotationer, og i de fire sidste er der foretaget 880 rotationer. Tallene i Tabel 4.3 angiver logaritmen til den masse (målt i gram), der er tilbage på sigten efter det nævnte antal rotationer.

Regression med gentagelser


Under specifikke omstændigheder kan man teste hypoteserne om konstant varians og hypotesen om lineær regression. Det kan man, hvis flere observationspar har den samme værdi af responsen, således at data kan opdeles i k observationsrækker:

<i>Responsvariabel :</i>	<i>Forklarende variabel</i>
$x_{11} \quad \dots \quad x_{1j} \quad \dots \quad x_{1n_1}$	$t_1 = t_{1j}, \quad j = 1, \dots, n_1$
$\vdots$	
$x_{i1} \quad \dots \quad x_{ij} \quad \dots \quad x_{in_i}$	$t_i = t_{ij}, \quad j = 1, \dots, n_i$
$\vdots$	
$x_{k1} \quad \dots \quad x_{kj} \quad \dots \quad x_{kn_k}$	$t_k = t_{kj}, \quad j = 1, \dots, n_k$

De n_i observationer i gruppe i har samme værdi af den uafhængige variabel, og den fælles værdi betegnes med t_i .

I Eksempel 4.2 er der tre observationsrækker hver med fire observationer, dvs $k = 3$ og $n_1 = n_2 = n_3 = 4$.

Lineær regression med gentagelser - Eksempel 4.2



Scatterplot af masse mod rotationer indikerer

- lineært forløb.
- varianshomogenitet
- observationerne (logaritmen til masse) er normalfordelt.

Man ville umiddelbart godt kunne acceptere regressionsmodellen M_2 . Men vi ønsker at tage så lidt som muligt for givet og kontrollere så meget som muligt.

Modeller og hypoteser

I modellen for k normalfordelte observationsrækker med hver sin middelværdi og hver sin varians

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i,$$

betragtes hypotesen om varianshomogenitet

$$H_{01} : \sigma_1^2 = \dots \sigma_k^2 = \sigma^2$$

som reducerer M_0 til modellen for k normalfordelte observationsrækker med hver sin middelværdi og samme varians

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i,$$

I M_1 betragtes hypotesen om lineær regression

$$H_{02} : \mu_i = \alpha + \beta t_i \quad i = 1, 2, \dots, k$$

som reducerer M_1 til modellen for lineær regression

$$M_2 : X_{ij} \sim N(\alpha + \beta t_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i.$$

Eksempel 4.2 - reduktion fra M_0 til M_1


Da der kun er fire observationer i hver observationsrække i M_0 , giver det ikke mening at lave fraktildiagrammer til modelkontrol.

Reduktionen fra M_0 til M_1 foretages ved hjælp af Bartlett's test.


Teststørrelsen beregnes til $Ba = 0.82107$, som skal testes i en χ^2 -fordeling med $k - 1 = 2$ frihedsgrader. p -værdien er

$$p_{obs} = 1 - F_{\chi^2(2)}(0.82107) = 0.6633.$$

Test af lineær regression: F -test



Gruppegennemsnit er markeret med • og forbundet en linie der knækker ved 530 rotationer.



Indtegnet regressionslinje og prædikterede værdier markeret med •.

I M_1 hver gruppe sin egen middelværdi, som er den prædikterede værdi svarende til t_i $i = 1, 2, 3$.

I M_2 er den prædikterede værdi bestemt af regressionslinjen.

Test af lineær regression: F -test

Hvis SSD_1 betegner variationen indenfor grupper og SSD_2 betegner variationen omkring regressionslinjen, dvs

$$SSD_1 = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2 \quad \text{og} \quad SSD_2 = \sum_{i=1}^k n_i (\bar{x}_i - (\hat{\alpha} + \hat{\beta} t_i))^2$$

betragtes teststørrelsen

$$\mathcal{F}(\mathbf{x}) = \frac{s_2^2}{s_1^2}$$

hvor $s_1 = \frac{SSD_1}{n-k}$ og $s_2^2 = \frac{SSD_2}{k-2}$.

Store værdier af F -teststørrelsen er kritiske, da variationen omkring regressionslinjen i så tilfælde er stor i forhold til variationen indenfor grupper.

Test af lineær regression: F -test

I dette tilfælde findes tælleren til 0.0052 og teststørrelsen bliver dermed

$$\mathcal{F}(\mathbf{x}) = \frac{0.0052}{0.002022} = 2.57 ,$$


som skal testes i $F(1, 9)$ fordeling. Vi finder testsandsynligheden

$$p_{obs}(\mathbf{x}) = 1 - F_{F(1,9)}(2.57) = 0.14 ,$$

og da denne er større en 0.05 accepterer vi hypotesen on lineær regression.

Regression som kalibreringskurve

Chart 1: A linear calibration function of an instrument's Absorbance (A) vs. Analyte's Concentration ($\mu\text{g/l}$)



Kalibrering

Prøver laves med kendt indhold af t , respons x måles

$$\text{Model: } X_i \sim N(\alpha + \beta t_i, \sigma^2) \rightarrow \hat{\alpha}, \hat{\beta}, s_{02}^2$$

Nye responsmålinger $y_1, \dots, y_m$ alle med samme ukendte værdi af t

ukendte værdi: parameter, kaldes θ

$$\bar{Y} \sim N(\alpha + \beta\theta, \sigma^2/m)$$

skøn over θ : $\hat{\theta} = (\bar{y} - \alpha)/\beta$, bruger $\hat{\theta} = (\bar{y} - \hat{\alpha})/\hat{\beta}$

Konfidensinterval for θ :

$$\text{Benyt: } \bar{Y} - (\hat{\alpha} + \hat{\beta}\theta) \sim N\left(0, \sigma^2 \left\{ \frac{1}{m} + \frac{1}{n} + \frac{(\theta - \bar{t})^2}{\text{SSD}_t} \right\}\right)$$

Kalibrering

Prøver laves med kendt indhold af t , respons x måles

$$\text{Model: } X_i \sim N(\alpha + \beta t_i, \sigma^2) \rightarrow \hat{\alpha}, \hat{\beta}, s_{02}^2$$

Nye responsmålinger $y_1, \dots, y_m$ alle med samme ukendte værdi af t

ukendte værdi: parameter, kaldes θ

$$\bar{Y}. \sim N(\alpha + \beta\theta, \sigma^2/m)$$

skøn over θ : $\hat{\theta} = (\bar{y}. - \alpha)/\beta$, bruger $\hat{\theta} = (\bar{y}. - \hat{\alpha})/\hat{\beta}$

Konfidensinterval for θ :

$$\text{Benyt: } \bar{Y}. - (\hat{\alpha} + \hat{\beta}\theta) \sim N\left(0, \sigma^2 \left\{ \frac{1}{m} + \frac{1}{n} + \frac{(\theta - \bar{t}.)^2}{\text{SSD}_t} \right\}\right)$$

Kalibrering

Dette giver:

$$t(\theta) = \frac{\bar{Y} - (\hat{\alpha} + \hat{\beta}\theta)}{s_{02} \sqrt{\frac{1}{m} + \frac{1}{n} + \frac{(\theta - \bar{t})^2}{SSD_t}}} \sim t(n-2)$$

Konfidensinterval: $\theta : -t_0 \leq t(\theta) \leq t_0$

$$t_0 = t_{0.975}(n-2)$$

Løse andengradsligning: benytte [inversReg](#):

giver nedre og øvre grænse i konfidensintervallet

Andengradsledning

$$(\bar{Y} - (\hat{\alpha} + \hat{\beta}\theta))^2 = t_0^2 s_{02}^2 \left(\frac{1}{m} + \frac{1}{n} + \frac{(\theta - \bar{t})^2}{SSD_t} \right)$$

eller

$$\hat{\beta}^2 (\theta - \hat{\theta})^2 = t_0^2 s_{02}^2 \left(\frac{1}{m} + \frac{1}{n} + \frac{(\theta - \hat{\theta} + \hat{\theta} - \bar{t})^2}{SSD_t} \right)$$

$$(\theta - \hat{\theta})^2: \hat{\beta}^2 - t_0^2 s_{02}^2 / SSD_t$$

$$(\theta - \hat{\theta}): -2t_0^2 s_{02}^2 \frac{\hat{\theta} - \bar{t}}{SSD_t} = -2t_0^2 s_{02}^2 \frac{\bar{y} - \bar{x}}{\hat{\beta} SSD_t}$$

Eksempel 4.1


Betragtes en enkelt måling af $\log Glu$ på 1.05 bliver intervallet

$$(5.085127, 6.552178).$$

Hvis vi i stedet antager, at der er foretaget fire målinger af $\log Glu$, som alle er 1.05, findes det tilsvarende interval for $\log Coli$ til

$$(5.439088, 6.198216).$$


Eksempel 4.1



Resultat af kalibrering for **én** måling af $\log \text{Glu}$ på 1.05

Resultat af kalibrering for **fire** målinger af $\log \text{Glu}$ på 1.05

Hypoteser og modeller



M_3 : Kendt hældning $\beta = \beta_0$

M_3^* : Kendt afskæring $\alpha = \alpha_0$

M_4 : Kendt afskæring og hældning $\alpha = \alpha_0 \quad \beta = \beta_0$

$$H_{03} : \beta = \beta_0$$

- $\hat{\beta}(\mathbf{X}) \sim N\left(\beta, \frac{\sigma^2}{\text{SSD}_t}\right)$
- $t(\mathbf{X}) = \frac{\hat{\beta} - \beta_0}{\sqrt{s_{02}^2 / \text{SSD}_t}} = \frac{\hat{\beta} - \beta_0}{\text{StdError}(\hat{\beta})} \sim t(n - 2)$
- $p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-2)}(-|t(\mathbf{x})|) = 2(1 - F_{t(n-2)}(|t(\mathbf{x})|))$
- $\text{StdError}(\hat{\beta}) = \sqrt{s_{02}^2 / \text{SSD}_t}$
- 95% konfidensintervallet for β har grænser
$$\hat{\beta} \pm t_{0.975}(n - 2) \text{StdError}(\hat{\beta})$$

$$H_{03}^* : \alpha = \alpha_0$$

- $\hat{\alpha}(\mathbf{X}) \sim N(\alpha, \sigma^2 \left(\frac{1}{n} + \frac{\bar{t}_t^2}{\text{SSD}_t} \right))$
- $t(\mathbf{X}) = \frac{\hat{\alpha} - \alpha_0}{\sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}_t^2}{\text{SSD}_t} \right)}} = \frac{\hat{\alpha} - \alpha_0}{\text{StdError}(\hat{\alpha})}$
- $p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-2)}(-|t(\mathbf{x})|) = 2(1 - F_{t(n-2)}(|t(\mathbf{x})|))$
- $\text{StdError}(\hat{\alpha}) = \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}_t^2}{\text{SSD}_t} \right)}$
- 95% konfidensintervallet for α har grænser

$$\hat{\alpha} \pm t_{0.975}(n-2) \text{StdError}(\hat{\alpha})$$

$$M_3 : X_i \sim N(\alpha + \beta_0 t_i, \sigma^2)$$

Estimator

$$\alpha \leftarrow \hat{\alpha}_{M_3} = \bar{X} - \beta_0 \bar{t} \quad \text{hvor} \quad \bar{X} - \beta_0 \bar{t} \sim N\left(\alpha, \frac{\sigma^2}{n}\right),$$

$$\sigma^2 \leftarrow s_{03}^2 = \frac{1}{n-1} \sum_{i=1}^n \{x_i - (\hat{\alpha}_{M_3} + \beta_0 t_i)\}^2 = \frac{1}{n-1} [\text{SSD}_{02} + (\hat{\beta} - \beta_0)^2 \text{SSD}_t]$$

Test af $H_{04} : \alpha = \alpha_0$

- $t(\mathbf{X}) = \frac{\hat{\alpha} - \alpha_0}{\sqrt{s_{03}^2/n}} \sim t(n-1)$
- $p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-1)}(-|t(\mathbf{x})|) = 2(1 - F_{t(n-1)}(|t(\mathbf{x})|))$
- 95% konfidensintervallet for α har grænser

$$\hat{\alpha}_{M_3} \pm t_{0.975}(n-1) \sqrt{s_{03}^2/n}$$

$$M_3^* : X_i \sim N(\alpha_0 + \beta t_i, \sigma^2)$$

Estimator

$$\beta \leftarrow \hat{\beta}_{M_3^*} = \frac{\sum_{i=1}^n t_i (X_i - \alpha_0)}{\sum_{i=1}^n t_i^2} \quad \text{hvor} \quad \frac{\sum_{i=1}^n t_i (X_i - \alpha_0)}{\sum_{i=1}^n t_i^2} \sim N\left(\beta, \frac{\sigma^2}{\text{USS}_t}\right),$$

$$\sigma^2 \leftarrow s_{03}^{*2} = \frac{1}{n-1} \sum_{i=1}^n \left\{ X_i - \left(\alpha_0 + \hat{\beta}_{M_3^*} t_i \right) \right\}^2 = \frac{1}{n-1} \left[\text{USS}_x + n\alpha_0^2 - 2\alpha_0 \bar{x} - \hat{\beta}_{M_3^*}^2 \text{USS}_t \right].$$

Test af $H_{04}^* : \beta = \beta_0$

- $t(\mathbf{x}) = \frac{\hat{\beta}_{M_3^*} - \beta_0}{\sqrt{s_{03}^{*2} / \text{USS}_t}} \quad \text{hvor} \quad t(\mathbf{X}) \sim t(n-1).$
- $p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-1)}(-|t(\mathbf{x})|) = 2(1 - F_{t(n-1)}(|t(\mathbf{x})|))$
- 95% konfidensintervallet for β har grænser

$$\hat{\beta}_{M_3^*} \pm t_{0.975}(n-1) \sqrt{s_{03}^{*2} / \text{USS}_t}$$

$$M_4^* : X_i \sim N(\alpha_0 + \beta_0 t_i, \sigma^2)$$

Til slut har vi estimatet for parameteren i M_4

$$\sigma^2 \leftarrow s_{04}^2 = \frac{1}{n} \sum_{i=1}^n \{x_i - (\alpha_0 + \beta_0 t_i)\}^2$$

hvor den tilsvarende estimator har en $\chi^2(n)/n$ fordeling.

Eksempel 4.2

I Eksempel 4.2 havde vi modellen

$$\ln x(t) = \ln x(0) + ct,$$

hvor $x(t)$ er tilbageværende masse til tid t . I M_2 er $\alpha = \ln x(0)$ en fri parameter, der estimeres ud fra data, men hvis beskrivelsen af eksperimentet er korrekt skal der gælde at $\alpha = \ln 60$ og vi opstiller derfor hypotesen

$$H_{03}^* : \alpha = \alpha_0 = \ln 60 = 4.0943.$$

t -teststørrelsen findes til

$$t(\mathbf{x}) = \frac{4.0581 - 4.0943}{\sqrt{0.002342 \left(\frac{1}{12} + \frac{(6320/12)^2}{1008266.67} \right)}} = -1.249.$$

Testsandsynligheden findes til

$$p_{\text{obs}}(\mathbf{x}) = 2 F_{t(10)}(-|-1.249|) = 0.24.$$

Eksempel 4.2

Slutmodellen bliver derfor

$$M_3^* : X_{ij} \sim N(\alpha_0 + \beta t_i, \sigma^2),$$

hvor estimatet for β beregnes til

$$\beta_{M_3^*} = \frac{21984.8 - 4.0943 \cdot 6320}{4336800} = -0.00089725.$$

Tilsvarende findes estimatet i M_2 til -0.000844 , så de to estimater er stort set ens. Konfidensintervallet i M_3^* er dog cirka halvt så bredt som konfidensintervallet i M_2 .

Faglig konklusion: Det er rimeligt at beskrive den mængde sand, der passerer sigten per tidsenhed som værende proportional med den mængde sand, der til tid t er tilbage i sigten.