

Matematisk Statistik

Lineære Normale Modeller

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Den lineære normale model, Afsnit 5.1

Lad $x_1, \dots, x_n$ være realisationer af uafhængige normalfordelte stokastiske variable $X_1, \dots, X_n$, hvor

$$X_i \sim N(\mu_i, \sigma^2), \quad i = 1, \dots, n.$$

Bemærk, at alle observationerne forudsættes at have **samme varians**.

Opfattes observationerne og middelværdierne som søjlevektorer i $\mathbb{R}^n$,

$$\begin{aligned}\mathbf{x} &= (x_1, \dots, x_n)^* \\ \boldsymbol{\mu} &= (\mu_1, \dots, \mu_n)^*,\end{aligned}$$

har vi en *lineær normal model* M specificeret ved underrummet L af $\mathbb{R}^n$, hvis

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^* \in L.$$

Vi sætter $\dim L = d$ og skriver kort

$$M : \boldsymbol{\mu} \in L.$$

Vi vil omtale $n - d$ som *fejlladets frihedsgrader*.

Den lineære normale model, Afsnit 5.1

Lad $x_1, \dots, x_n$ være realisationer af uafhængige normalfordelte stokastiske variable $X_1, \dots, X_n$, hvor

$$X_i \sim N(\mu_i, \sigma^2), \quad i = 1, \dots, n.$$

Bemærk, at alle observationerne forudsættes at have **samme varians**.

Opfattes observationerne og middelværdierne som søjlevektorer i $\mathbb{R}^n$,

$$\mathbf{x} = (x_1, \dots, x_n)^*$$

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^*,$$

har vi en *lineær normal model* M specificeret ved underrummet L af $\mathbb{R}^n$, hvis

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^* \in L.$$

Vi sætter $\dim L = d$ og skriver kort

$$M : \boldsymbol{\mu} \in L.$$

Vi vil omtale $n - d$ som *fejlladets frihedsgrader*.

Den lineære normale model, Afsnit 5.1

Lad $x_1, \dots, x_n$ være realisationer af uafhængige normalfordelte stokastiske variable $X_1, \dots, X_n$, hvor

$$X_i \sim N(\mu_i, \sigma^2), \quad i = 1, \dots, n.$$

Bemærk, at alle observationerne forudsættes at have **samme varians**.

Opfattes observationerne og middelværdierne som søjlevektorer i $\mathbb{R}^n$,

$$\mathbf{x} = (x_1, \dots, x_n)^*$$

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^*,$$

har vi en *lineær normal model* M specificeret ved underrummet L af $\mathbb{R}^n$, hvis

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^* \in L.$$

Vi sætter $\dim L = d$ og skriver kort

$$M : \boldsymbol{\mu} \in L.$$

Vi vil omtale $n - d$ som *fejlladets frihedsgrader*.

Eksempler, én observationsrække.

Her er $\mu_i = \mu$ for alle i , så

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix} = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \mu \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Med andre ord gælder der at $\boldsymbol{\mu} \in L$ hvor

$$L = \text{span}\left(\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}\right).$$

Vi definerer $\mathbf{1} \stackrel{\text{def}}{=} (1, \dots, 1)^*$ således at $L = \text{span}(\mathbf{1})$. Bemærk at dimensionen af L er $d = 1$.

Eksempler, én observationsrække.

Her er $\mu_i = \mu$ for alle i , så

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix} = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \mu \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Med andre ord gælder der at $\boldsymbol{\mu} \in L$ hvor

$$L = \text{span}\left(\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}\right).$$

Vi definerer $\mathbf{1} \stackrel{\text{def}}{=} (1, \dots, 1)^*$ således at $L = \text{span}(\mathbf{1})$. Bemærk at dimensionen af L er $d = 1$.

Eksempler, én observationsrække.

Her er $\mu_i = \mu$ for alle i , så

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix} = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \mu \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Med andre ord gælder der at $\boldsymbol{\mu} \in L$ hvor

$$L = \text{span}\left(\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}\right).$$

Vi definerer $\mathbf{1} \stackrel{\text{def}}{=} (1, \dots, 1)^*$ således at $L = \text{span}(\mathbf{1})$. Bemærk at dimensionen af L er $d = 1$.

Eksempler, To observationsrækker.

Her er $n = n_1 + n_2$ og $\mu_i = \eta_1, i = 1, \dots, n_1$, og $\mu_i = \eta_2, i = n_1 + 1, \dots, n_1 + n_2$. Derfor er

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_{n_1} \\ \mu_{n_1+1} \\ \vdots \\ \mu_{n_1+n_2} \end{pmatrix} = \eta_1 \begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \eta_2 \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \left. \begin{array}{l} \left. \vphantom{\begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}} \right\} n_1 \text{ gange} \\ \left. \vphantom{\begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix}} \right\} n_2 \text{ gange} \end{array} \right\} (1)$$

Vektorerne på højresiden af (1) indføres nu som $\mathbf{1}_1$ og $\mathbf{1}_2$, hvor koordinaterne for $\mathbf{1}_1$ og $\mathbf{1}_2$ altså er givet ved henholdsvis

$$(\mathbf{1}_1)_j = \begin{cases} 1, & \text{for } j = 1, \dots, n_1, \\ 0, & \text{for } j = n_1 + 1, \dots, n_1 + n_2, \end{cases}$$

og

$$(\mathbf{1}_2)_j = \begin{cases} 0, & \text{for } j = 1, \dots, n_1, \\ 1, & \text{for } j = n_1 + 1, \dots, n_1 + n_2. \end{cases}$$

således at vi har $\boldsymbol{\mu} \in L$ for

$$L = \text{span}(\mathbf{1}_1, \mathbf{1}_2).$$

Dimensionen af L er $d = 2$, da $\mathbf{1}_1$ og $\mathbf{1}_2$ er lineært uafhængige.

Eksempler, To observationsrækker.

Her er $n = n_1 + n_2$ og $\mu_i = \eta_1, i = 1, \dots, n_1$, og $\mu_i = \eta_2, i = n_1 + 1, \dots, n_1 + n_2$. Derfor er

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_{n_1} \\ \mu_{n_1+1} \\ \vdots \\ \mu_{n_1+n_2} \end{pmatrix} = \eta_1 \begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \eta_2 \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \left. \begin{array}{l} \left. \vphantom{\begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}} \right\} n_1 \text{ gange} \\ \left. \vphantom{\begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix}} \right\} n_2 \text{ gange} \end{array} \right\} \quad (1)$$

Vektorerne på højresiden af (1) indføres nu som $\mathbf{1}_1$ og $\mathbf{1}_2$, hvor koordinaterne for $\mathbf{1}_1$ og $\mathbf{1}_2$ altså er givet ved henholdsvis

$$(\mathbf{1}_1)_j = \begin{cases} 1, & \text{for } j = 1, \dots, n_1, \\ 0, & \text{for } j = n_1 + 1, \dots, n_1 + n_2, \end{cases}$$

og

$$(\mathbf{1}_2)_j = \begin{cases} 0, & \text{for } j = 1, \dots, n_1, \\ 1, & \text{for } j = n_1 + 1, \dots, n_1 + n_2. \end{cases}$$

således at vi har $\boldsymbol{\mu} \in L$ for

$$L = \text{span}(\mathbf{1}_1, \mathbf{1}_2).$$

Dimensionen af L er $d = 2$, da $\mathbf{1}_1$ og $\mathbf{1}_2$ er lineært uafhængige.

Eksempler, To observationsrækker.

Her er $n = n_1 + n_2$ og $\mu_i = \eta_1, i = 1, \dots, n_1$, og $\mu_i = \eta_2, i = n_1 + 1, \dots, n_1 + n_2$. Derfor er

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_{n_1} \\ \mu_{n_1+1} \\ \vdots \\ \mu_{n_1+n_2} \end{pmatrix} = \eta_1 \begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \eta_2 \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \left. \begin{array}{l} \left. \vphantom{\begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}} \right\} n_1 \text{ gange} \\ \left. \vphantom{\begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix}} \right\} n_2 \text{ gange} \end{array} \right\} \quad (1)$$

Vektorerne på højresiden af (1) indføres nu som $\mathbf{1}_1$ og $\mathbf{1}_2$, hvor koordinaterne for $\mathbf{1}_1$ og $\mathbf{1}_2$ altså er givet ved henholdsvis

$$(\mathbf{1}_1)_j = \begin{cases} 1, & \text{for } j = 1, \dots, n_1, \\ 0, & \text{for } j = n_1 + 1, \dots, n_1 + n_2, \end{cases}$$

og

$$(\mathbf{1}_2)_j = \begin{cases} 0, & \text{for } j = 1, \dots, n_1, \\ 1, & \text{for } j = n_1 + 1, \dots, n_1 + n_2. \end{cases}$$

således at vi har $\boldsymbol{\mu} \in L$ for

$$L = \text{span}(\mathbf{1}_1, \mathbf{1}_2).$$

Dimensionen af L er $d = 2$, da $\mathbf{1}_1$ og $\mathbf{1}_2$ er lineært uafhængige.

k normalfordelte observationsrækker

For generelt k skriver vi

$$X_{ij} \sim N(\eta_i, \sigma^2), \quad j = 1, \dots, n_i, i = 1, \dots, k.$$

Hvis

$$\mathbf{x} = (x_{11}, \dots, x_{1n_1}, \dots, x_{i1}, \dots, x_{in_i}, \dots, x_{k1}, \dots, x_{kn_k})^*$$

$$\boldsymbol{\mu} = (\eta_1, \dots, \eta_1, \dots, \eta_i, \dots, \eta_i, \dots, \eta_k, \dots, \eta_k)^*$$

$$\mathbf{1}_i = (0, \dots, 0, \dots, 1, \dots, 1, \dots, 0, \dots, 0)^*, \quad i = 1, \dots, k$$

er

$$\boldsymbol{\mu} = \eta_1 \mathbf{1}_1 + \dots + \eta_i \mathbf{1}_i + \dots + \eta_k \mathbf{1}_k,$$

så

$$L = \text{span}\{\mathbf{1}_1, \dots, \mathbf{1}_i, \dots, \mathbf{1}_k\} \quad \text{og} \quad d = k.$$

Lineær regression, designmatrix/modelmatrix

Her er $\mu_i = \alpha + \beta t_i$, så

$$\boldsymbol{\mu} = \begin{pmatrix} \alpha + \beta t_1 \\ \alpha + \beta t_2 \\ \vdots \\ \alpha + \beta t_n \end{pmatrix} = \alpha \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} + \beta \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{pmatrix}.$$

Man ser, at $L = \text{span}(\mathbf{1}, \mathbf{t})$, hvor $\mathbf{1}$ er defineret tidligere, og

$$\mathbf{t} = (t_1, \dots, t_n)^*.$$

Dimensionen af L er 2, hvis der er mindst to forskellige værdier af den uafhængige variabel t .

Bemærk at når $L = \text{span}(\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)})$ kaldes matricen

$$\mathbf{T} = \{\mathbf{t}_{(1)}, \mathbf{t}_{(2)}, \dots, \mathbf{t}_{(q)}\},$$

for en *designmatrix* eller en *modelmatrix*, og L er således søjlerummet for designmatricen.

Lineær regression, designmatrix/modelmatrix

Her er $\mu_i = \alpha + \beta t_i$, så

$$\boldsymbol{\mu} = \begin{pmatrix} \alpha + \beta t_1 \\ \alpha + \beta t_2 \\ \vdots \\ \alpha + \beta t_n \end{pmatrix} = \alpha \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} + \beta \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{pmatrix}.$$

Man ser, at $L = \text{span}(\mathbf{1}, \mathbf{t})$, hvor $\mathbf{1}$ er defineret tidligere, og

$$\mathbf{t} = (t_1, \dots, t_n)^*.$$

Dimensionen af L er 2, hvis der er mindst to forskellige værdier af den uafhængige variabel t .

Bemærk at når $L = \text{span}(\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)})$ kaldes matricen

$$\mathbf{T} = \{\mathbf{t}_{(1)}, \mathbf{t}_{(2)}, \dots, \mathbf{t}_{(q)}\},$$

for en *designmatrix* eller en *modelmatrix*, og L er således søjlerummet for designmatricen.

Lineær regression, designmatrix/modelmatrix

Her er $\mu_i = \alpha + \beta t_i$, så

$$\boldsymbol{\mu} = \begin{pmatrix} \alpha + \beta t_1 \\ \alpha + \beta t_2 \\ \vdots \\ \alpha + \beta t_n \end{pmatrix} = \alpha \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} + \beta \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{pmatrix}.$$

Man ser, at $L = \text{span}(\mathbf{1}, \mathbf{t})$, hvor $\mathbf{1}$ er defineret tidligere, og

$$\mathbf{t} = (t_1, \dots, t_n)^*.$$

Dimensionen af L er 2, hvis der er mindst to forskellige værdier af den uafhængige variabel t .

Bemærk at når $L = \text{span}(\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)})$ kaldes matricen

$$\mathbf{T} = \{\mathbf{t}_{(1)}, \mathbf{t}_{(2)}, \dots, \mathbf{t}_{(q)}\},$$

for en *designmatrix* eller en *modelmatrix*, og L er således søjlerummet for designmatricen.

Lineær normale modeller, estimation, Afsnit 5.2

Først opskrives likelihood funktionen:

$$L(\boldsymbol{\mu}, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu_i)^2} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}\|^2}.$$

For fast σ^2 finder vi at

$$L(\boldsymbol{\mu}, \sigma^2) \leq L(P(\mathbf{x}), \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - P(\mathbf{x})\|^2}.$$

hvor $P(\mathbf{x})$ betegner den ortogonale projektion af $\mathbf{x}$ på L .

Vi finder dernæst

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Likelihood funktionens maksimum findes til:

$$L(\hat{\boldsymbol{\mu}}, \hat{\sigma}^2) = L(P(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2) = \left(\frac{n}{2\pi \|\mathbf{x} - P(\mathbf{x})\|^2} \right)^{\frac{n}{2}} e^{-\frac{n}{2}}.$$

Lineær normale modeller, estimation, Afsnit 5.2

Først opskrives likelihood funktionen:

$$L(\boldsymbol{\mu}, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu_i)^2} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}\|^2}.$$

For fast σ^2 finder vi at

$$L(\boldsymbol{\mu}, \sigma^2) \leq L(P(\mathbf{x}), \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - P(\mathbf{x})\|^2}.$$

hvor $P(\mathbf{x})$ betegner den ortogonale projektion af $\mathbf{x}$ på L .

Vi finder dernæst

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Likelihood funktionens maksimum findes til:

$$L(\hat{\boldsymbol{\mu}}, \hat{\sigma}^2) = L(P(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2) = \left(\frac{n}{2\pi \|\mathbf{x} - P(\mathbf{x})\|^2} \right)^{\frac{n}{2}} e^{-\frac{n}{2}}.$$

Lineær normale modeller, estimation, Afsnit 5.2

Først opskrives likelihood funktionen:

$$L(\boldsymbol{\mu}, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu_i)^2} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}\|^2}.$$

For fast σ^2 finder vi at

$$L(\boldsymbol{\mu}, \sigma^2) \leq L(P(\mathbf{x}), \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - P(\mathbf{x})\|^2}.$$

hvor $P(\mathbf{x})$ betegner den ortogonale projektion af $\mathbf{x}$ på L .

Vi finder dernæst

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Likelihood funktionens maksimum findes til:

$$L(\hat{\boldsymbol{\mu}}, \hat{\sigma}^2) = L(P(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2) = \left(\frac{n}{2\pi \|\mathbf{x} - P(\mathbf{x})\|^2} \right)^{\frac{n}{2}} e^{-\frac{n}{2}}.$$

Lineær normale modeller, estimation, Afsnit 5.2

Først opskrives likelihood funktionen:

$$L(\boldsymbol{\mu}, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu_i)^2} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2}\|\mathbf{x} - \boldsymbol{\mu}\|^2}.$$

For fast σ^2 finder vi at

$$L(\boldsymbol{\mu}, \sigma^2) \leq L(P(\mathbf{x}), \sigma^2) = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2}\|\mathbf{x} - P(\mathbf{x})\|^2}.$$

hvor $P(\mathbf{x})$ betegner den ortogonale projektion af $\mathbf{x}$ på L .


Vi finder dernæst

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Likelihood funktionens maksimum findes til:

$$L(\hat{\boldsymbol{\mu}}, \hat{\sigma}^2) = L(P(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2) = \left(\frac{n}{2\pi \|\mathbf{x} - P(\mathbf{x})\|^2}\right)^{\frac{n}{2}} e^{-\frac{n}{2}}.$$

Geometrien for estimation i en lineær normal model



Geometrien for estimation i en lineær normal model.

Når vi ønsker at reducere fra en lineær normal model M_1 til en anden model M_2 vil vi stå med to underrum L_1 og L_2 som skal opfylde $L_2 \subset L_1$.

Under M_1 gælder der altså at $\mu \in L_1$ og under M_2 gælder der at $\mu \in L_2$, eller, formuleret ved hjælp af en hypotese: I grundmodellen har vi

$$M_1 : \mu \in L_1$$

og ønsker at undersøge hypotesen

$$H_1 : \mu \in L_2 .$$

Likelihood ratio testet for hypotesen findes til

$$Q(\mathbf{x}) = \frac{L\left(P_2(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_2(\mathbf{x})\|^2\right)}{L\left(P_1(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_1(\mathbf{x})\|^2\right)} = \left(\frac{\|\mathbf{x} - P_1(\mathbf{x})\|^2}{\|\mathbf{x} - P_2(\mathbf{x})\|^2}\right)^{\frac{n}{2}} .$$

Når vi ønsker at reducere fra en lineær normal model M_1 til en anden model M_2 vil vi stå med to underrum L_1 og L_2 som skal opfylde $L_2 \subset L_1$.

Under M_1 gælder der altså at $\mu \in L_1$ og under M_2 gælder der at $\mu \in L_2$, eller, formuleret ved hjælp af en hypotese: I grundmodellen har vi

$$M_1 : \mu \in L_1$$

og ønsker at undersøge hypotesen

$$H_1 : \mu \in L_2 .$$

Likelihood ratio testet for hypotesen findes til

$$Q(\mathbf{x}) = \frac{L\left(P_2(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_2(\mathbf{x})\|^2\right)}{L\left(P_1(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_1(\mathbf{x})\|^2\right)} = \left(\frac{\|\mathbf{x} - P_1(\mathbf{x})\|^2}{\|\mathbf{x} - P_2(\mathbf{x})\|^2}\right)^{\frac{n}{2}} .$$

Test: Notation

model	M_1	M_2
underrum	L_1	L_2
dimension	d_1	d_2
estimat for μ	$P_1(\mathbf{x})$	$P_2(\mathbf{x})$
estimat for σ^2	$\frac{\ \mathbf{x} - P_1(\mathbf{x})\ ^2}{n - d_1}$	$\frac{\ \mathbf{x} - P_2(\mathbf{x})\ ^2}{n - d_2}$
frihedsgrader	$n - d_1$	$n - d_2$
$e^{\frac{n}{2}} L(\hat{\mu}, \hat{\sigma}^2)$	$\left(\frac{n}{2\pi \ \mathbf{x} - P_1(\mathbf{x})\ ^2} \right)^{\frac{n}{2}}$	$\left(\frac{n}{2\pi \ \mathbf{x} - P_2(\mathbf{x})\ ^2} \right)^{\frac{n}{2}}$

F-testet.

Ved at benytte Pythagoras' Sætning fås, at idet d_i betegner dimensionen af L_i har vi

$$Q(\mathbf{x}) = \left(\frac{1}{1 + \frac{d_1 - d_2}{n - d_1} F(\mathbf{x})} \right)^{\frac{n}{2}},$$

hvor

$$F(\mathbf{x}) = \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2 / (d_1 - d_2)}{\|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - d_1)}.$$

Det kan vises at $F(\mathbf{x})$ er et udfald fra en $F(d_1 - d_2, n - d_1)$ -fordeling forudsat H_1 er sand, og vi får således

$$p_{obs}(\mathbf{x}) = 1 - F_{F(d_1 - d_2, n - d_1)}(F(\mathbf{x})).$$

F-testet.

Ved at benytte Pythagoras' Sætning fås, at idet d_i betegner dimensionen af L_i har vi

$$Q(\mathbf{x}) = \left(\frac{1}{1 + \frac{d_1 - d_2}{n - d_1} F(\mathbf{x})} \right)^{\frac{n}{2}},$$

hvor

$$F(\mathbf{x}) = \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2 / (d_1 - d_2)}{\|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - d_1)}.$$

Det kan vises at $F(\mathbf{x})$ er et udfald fra en $F(d_1 - d_2, n - d_1)$ -fordeling forudsat H_1 er sand, og vi får således

$$p_{obs}(\mathbf{x}) = 1 - F_{F(d_1 - d_2, n - d_1)}(F(\mathbf{x})).$$

Geometrien for test i en lineær normal model




Illustration af de centrale størrelser i test af reduktionen fra M_1 til M_2

Lineære normale modeller i R

Forsimpelt kald til **lm** :

```
lm(formula, data = navn på datasæt)
```

Modelformel:

```
responsvariabel ~ liste med forklarende variable
```

Data fra Eksempel 2.1

```
Volt <- c(21.89, 22.20, ..., 21.94, 22.29)
```

Fitte model for én observationsrække:

```
lmfit <- lm(Volt ~ 1)
```

Køres `anova(lmfit)` fås *variansanalysetabellen* for den fittede model

```
Analysis of Variance Table
```

```
Response: Volt
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Residuals	29	3.5636	0.12288		

Sammenlign med s. (2.10) i de supplerende noter

$$s^2(\mathbf{x}) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{3.5636}{29} = 0.122883.$$

Hypotesetest med **anova**

anova kan bruges til at reducere fra en lineær normal model til en lineær normal undermodel.

I Eksempel 2.1 ønsker vi at undersøge $H : \mu = 22.0$ i M_1 hvor

$$M_1 : X_i \sim N(\mu, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed,}$$

det vil sige reducere M_1 til M_2 , hvor

$$M_2 : X_i \sim N(22.0, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

Men M_2 er *ikke* en lineær normal model.

Hypotesetest med **anova**

Løsning: Træk 22.0 fra alle variable $\tilde{X}_i = X_i - 22.0 \quad i = 1, \dots, 30$
og undersøge om

$$M_1 : \tilde{X}_i \sim N(\tilde{\mu}, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed,}$$

hvor $\tilde{\mu} = \mu - 22.0$ kan reduceres til

$$M_2 : \tilde{X}_i \sim N(0, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed.}$$

Både M_1 og M_2 er lineære normale modeller og M_2 er en delmodel af M_1 .

Hypotesetest med **anova**

Variansanalysetabellen for reduktionen fra M_1 til M_2 kan nu dannes:

```
Volt_minus_22 <- Volt - 22
lmfit_m1 <- lm(Volt_minus_22 ~ 1)
lmfit_m2 <- lm(Volt_minus_22 ~ 0)
anova(lmfit_m2, lmfit_m1)
```

Analysis of Variance Table

Model 1: Volt_minus_22 ~ 0

Model 2: Volt_minus_22 ~ 1

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	30	4.3316				
2	29	3.5636	1	0.768	6.2499	0.01833 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Sammenlign med (2.12):

$$p_{\text{obs}} = 2(1 - F_{t(29)}(2.49997)) = 0.0183265.$$

og bemærk at

$$t(\mathbf{x})^2 = 2.49997^2 \approx 6.2499 = F$$

Variansanalysetabellen

Indholdet af variansanalysetabellen er

Analysis of Variance Table						
Model 1: Modelformel for M_2						
Model 2: Modelformel for M_1						
	Res.df.	RSS	Df	Sum of Sq	F	Pr(>F)
1	$n - d_2$	$\ \mathbf{x} - P_2(\mathbf{x})\ ^2$				
2	$n - d_1$	$\ \mathbf{x} - P_1(\mathbf{x})\ ^2$	$d_1 - d_2$	$\ P_1(\mathbf{x}) - P_2(\mathbf{x})\ ^2$	$F(M_1, M_2)$	p_{obs}

hvor $F(M_1, M_2)$ og p_{obs} er henholdsvis

$$F(M_1, M_2) = \mathcal{F}(\mathbf{x}) = \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2 / (d_1 - d_2)}{\|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - d_1)} \quad \text{og}$$

$$p_{obs} = p_{obs}(\mathbf{x}) = 1 - F_{F(d_1 - d_2, n - d_1)}(\mathcal{F}(\mathbf{x})).$$

Hypotesetest med **anova** - k - observationsrækker

Først indlæses data fra Eksempel 3.2 indlæses og vises

```
soya <- read.csv(file="soya.csv",stringsAsFactors=TRUE)
head(soya)
```

	area	light	stress	group
1	200	low	low	A
2	215	low	low	A
3	225	low	low	A
4	229	low	low	A
5	230	low	low	A
6	232	low	low	A

stringsAsFactors sikrer at **group** opfattes som faktorvariabel.

Hypotesetest med **anova** - k - observationsrækker

For at undersøge $H_{0\mu}$ fittes modellerne til data og vi kalder **anova** .

```
lmfit_m1 <- lm(area~group,data=soya)
lmfit_m2 <- lm(area~1,data=soya)
anova(lmfit_m2,lmfit_m1)
```

Analysis of Variance Table

Model 1: area ~ 1

Model 2: area ~ group

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	51	100613				
2	48	42976	3	57636	21.458	5.867e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

På side 55 fandt vi

$$SSD_H = 100612.673 - 42976.308 = 57636.365 \quad \text{og} \quad \frac{SSD_H}{k-1} = \frac{57636.365}{3} = 19212.122$$

$$\mathcal{F}(\mathbf{x}) = \frac{19212.122}{895.340} = 21.46.$$

Hypotesetest med **anova** - lineær regression

Data fra Tabel 4.3 indlæses:

```
rotationer <- rep(c(170, 530, 880), each=4)
masse <- c(3.89, 3.95, 3.85, 3.91, ..., 3.71, 3.30, 3.26, 3.30, 3.34)
```

Som i Appendiks til Afsnit 4.1 fittes modellen for simpel lineær regression:

```
lmfit_m2 = lm(masse ~ 1 + rotationer)
```

Når vi undersøger hypotesen om lineær regression tager vi udgangspunkt i en model med $k = 3$ observationsrækker (én for hver forskellig værdi af rotationer), og derfor skal **rotationer** opfattes som en faktorvariabel:

```
rotationer_som_faktor = as.factor(rotationer)
```

Hypotesetest med **anova** - lineær regression

Vi kan nu fitte modellen for k observationsrækker (M_1) og undersøge om vi kan reducere til modellen for simpel lineær regression (M_2)

```
lmfit_m1 = lm(masse ~ 1 + rotationer_som_faktor)
anova(lmfit_m2, lmfit_m1)
```

Analysis of Variance Table

Model 1: masse ~ 1 + rotationer

Model 2: masse ~ 1 + rotationer_som_faktor

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	10	0.023415				
2	9	0.018200	1	0.0052153	2.579	0.1428

Fra (4.23) har vi

$$p_{obs}(\mathbf{x}) = 1 - F_{F(1,9)}(2.57) = 0.14,$$

Bartlett's test i R

Bartlett's test kan udføres med `bartlett.test`

```
bartlett.test(masse ~ 1 + rotationer_som_faktor)
```

Output bliver

```
Bartlett test of homogeneity of variances

data:  masse by rotationer_som_faktor
Bartlett's K-squared = 0.82107, df = 2, p-value = 0.6633
```

Som stemmer overens med det vi tidligere regnede ud.

Hypotesetest med **anova** - lineær regression

I modellen M_2 for simpel lineær regression ønsker vi til slut at undersøge

$$H_{03}^* : \alpha = \alpha_0 = \ln 60 = 4.0943.$$

Som i Appendix til afsnit 4.1 betragter vi transformerede variable $\tilde{X}_i = X_i - \ln 60$. I M_2 vil der gælde at

$$\tilde{X}_i \sim N(\tilde{\alpha} + \beta t_i, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed}$$

hvor $\tilde{\alpha} = 0$, således at hypotesen kan formuleres som

$$H_{03}^* : \tilde{\alpha} = 0.$$

Hypotesetest med **anova** - lineær regression

For at undersøge H_{03}^* køres nedenstående R-kode, hvor vi bemærker at **1** i M_2 udskiftes med **0** i M_3^* .

```
masse_minus_ln60 = masse - log(60)
lmfit_m2 = lm(masse_minus_ln60 ~ 1 + rotationer)
lmfit_m3star = lm(masse_minus_ln60 ~ 0 + rotationer)
anova(lmfit_m3star, lmfit_m2)
```

Variansanalysetabellen bliver

Analysis of Variance Table

Model 1: masse_minus_ln60 ~ 0 + rotationer

Model 2: masse_minus_ln60 ~ 1 + rotationer

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	11	0.027081				
2	10	0.023415	1	0.0036659	1.5656	0.2393

Bemærk at

$$t(\mathbf{x}) = (-1.249)^2 \approx 1.5656 = \mathbf{F},$$

samt at p -værdien stemmer overens med (4.27).