

Matematisk Statistik

Tosidet variansanalyse

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Tilbage til Eksempel 3.2

Fagligt problem

Hvordan påvirker stress væksten af sojabønner?

52 stiklinger blev plantet i potter, én i hver potte. De 52 stiklinger blev tilfældigt inddelt i fire grupper med 13 i hver. Stiklingerne i to af grupperne blev stresset ved at blive rystet i tyve minutter dagligt, mens stiklingerne i de to andre grupper ikke blev rystet. Desuden voksede to af grupperne i svagt lys, og de andre to grupper i moderat lys, således at de fire grupper fik hver sin behandling:

Gruppe 1 : svagt lys, ingen stress

Gruppe 2 : svagt lys, stress

Gruppe 3 : moderat lys, ingen stress

Gruppe 4 : moderat lys, stress

Kan vi sige noget om effekten af lys og effekten af stress hver for sig?

Eksempel 3.2 - data

Samlet areal i cm ²			
Gruppe			
1	2	3	4
200	163	268	201
215	182	271	216
225	188	273	241
229	195	282	257
230	202	285	259
232	205	299	267
241	212	309	269
253	214	310	282
256	215	314	283
264	230	320	291
268	235	337	291
288	255	340	312
288	272	345	326
Middelværdier			
245.31	212.92	304.08	268.85

Tabel 1: Gruppe 1: svagt lys, ingen stress; Gruppe 2: svagt lys, stress; Gruppe 3: moderat lys, ingen stress; Gruppe 4: moderat lys, stress.

Eksempel 3.2

Konklusion fra Afsnit 3.2:

$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, 3, 4 \quad j = 1, \dots, 13 \quad + \text{ uafhængighed.}$

Estimater for middelværdier:

$$\begin{aligned}\mu_1 &\leftarrow \bar{x}_{1\cdot} = 245.308 & \mu_2 &\leftarrow \bar{x}_{2\cdot} = 212.923 \\ \mu_3 &\leftarrow \bar{x}_{3\cdot} = 304.077 & \mu_4 &\leftarrow \bar{x}_{4\cdot} = 268.846.\end{aligned}$$

Først: Parametertabellen i ensidet variansanalyse.

summary - k - observationsrækker

Først præsenteres parametertabellen for k -observationsrækker ved hjælp af Eksempel 3.2.

Soya-datasættet indlæses

```
soya <- read.csv(file="soya.csv",stringsAsFactors=TRUE)
head(soya)
```

	area	light	stress	group
1	200	low	low	A
2	215	low	low	A
3	225	low	low	A
4	229	low	low	A
5	230	low	low	A
6	232	low	low	A

summary - k - observationsrækker

Modellen M_1 fittes:

```
lmfit_m1 <- lm(area ~ 1 + group, data=soya)
```

Skriver vi $\text{group}_i = \zeta_i$ kan modelformlen læses som

$$\alpha \cdot 1 + \zeta_i \quad i = 1, 2, 3, 4.$$

I denne opskrivning er der 5 parametre:

$$\alpha, \zeta_1, \zeta_2, \zeta_3, \zeta_4$$

og modellen er *overparametriseret*, fordi vi betragter parametrene relativt til en referencegruppe. Relationen til μ_i erne er:

$$\begin{aligned} \alpha &= \mu_1 & \zeta_1 &= \mu_1 - \mu_1 = 0 & \zeta_2 &= \mu_2 - \mu_1 \\ \zeta_3 &= \mu_3 - \mu_1 & \zeta_4 &= \mu_4 - \mu_1 \end{aligned}$$

summary - k - observationsrækker

Køres `summary(lmfit_m1)` fås parametertabellen:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	245.308	8.299	29.559	< 2e-16 ***
groupB	-32.385	11.736	-2.759	0.00817 **
groupC	58.769	11.736	5.007	7.86e-06 ***
groupD	23.538	11.736	2.006	0.05056 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.92 on 48 degrees of freedom

Multiple R-squared: 0.5729, Adjusted R-squared: 0.5462

F-statistic: 21.46 on 3 and 48 DF, p-value: 5.867e-09

Vi ser at $\hat{\alpha} = \hat{\mu}_1 = 245.308$ og

$$\hat{\zeta}_2 = \hat{\mu}_2 - \hat{\mu}_1 = 212.923 - 245.308 = -32.385$$

$$\hat{\zeta}_3 = \hat{\mu}_3 - \hat{\mu}_1 = 304.077 - 245.308 = 58.769$$

$$\hat{\zeta}_4 = \hat{\mu}_4 - \hat{\mu}_1 = 268.846 - 245.308 = 23.538$$

summary - k - observationsrækker

Information om niveauerne for en faktorvariabel kan fås med **levels**

Valg af referencegruppe kan foretages med **relevel**, f.eks. giver

```
levels(soya$group)
```

```
[1] "A" "B" "C" "D"
```

```
groupBref <- relevel(soya$group, "B")  
levels(groupBref)
```

```
[1] "B" "A" "C" "D"
```

summary - k - observationsrækker

Hvis 0 tilføjes til modelformlen, fjernes interceptet.

```
lmfit_m1 <- lm(area ~ 0 + group, data=soya)
```

Køres `summary(lmfit_m1)` fås parametertabellen:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
groupA	245.308	8.299	29.56	<2e-16	***
groupB	212.923	8.299	25.66	<2e-16	***
groupC	304.077	8.299	36.64	<2e-16	***
groupD	268.846	8.299	32.40	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 29.92 on 48 degrees of freedom

Multiple R-squared: 0.9879, Adjusted R-squared: 0.9869

F-statistic: 981 on 4 and 48 DF, p-value: < 2.2e-16


Vi har fittet *to forskellige parametriseringer af samme model.*

Eksempel 3.2




Den ekstra tilvækst ved moderat lys, ser ikke ud til afhænge af stress/ikke stress, og effekten af stress ser ikke til at afhænge af lys.

Kontroltegning - interaktionsplot



Interaktionsplot for *lys*.
Gruppegennemsnit er markeret med •.



Interaktionsplot for *stress*.
Gruppegennemsnit er markeret med •.

Eksempel 3.2

Ny opstilling af data fra Eksempel 3.2:

		Stress	
		Ingen stress	Stress
Lys	Svagt	200 215	163 182
		225 229	188 195
		230 232	202 205
		241 253	212 214
		256 264	215 230
		268 288	235 255
		288	272
	Moderat	268 271	201 216
		273 282	241 257
		285 299	259 267
		309 310	269 282
		314 320	283 291
		337 340	291 312
		345	326

Tilsvarende indesksering:

$$M_1 : X_{ijk} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, 2, \quad j = 1, 2, \quad k = 1, \dots, 13.$$

Eksempel 3.2 - additivitetsmodellen

Ønsker at undersøge om vi kan reducere til *additivitetsmodellen*

$$M_2 : X_{ijk} \sim N(\alpha_i + \beta_j, \sigma^2), \quad i = 1, 2, j = 1, 2, k = 1, \dots, 13,$$

I additivitetsmodellen er der ikke *vekselvirkning* mellem *lys* og *stress* og vi kan der sige noget om *virkningen* af lys og stress hver for sig.

De interessante parametre i M_2 :

- $\alpha_1 - \alpha_2$ (*virkning* af lys)
- $\beta_1 - \beta_2$ (*virkning* af stress)

Additiv effekt

Forskel af stress under additive model:

Ingen Stress – Stress

Svagt lys	$\beta_1 - \beta_2$	$\gamma = \beta_1 - \beta_2$
Moderat lys	$\beta_1 - \beta_2$	

Forskel af stress er det samme for de to niveauer af lys

Forskel af lys under additive model:

	Ingen Stress	Stress	$\delta = \alpha_1 - \alpha_2$
Svagt lys – Moderat lys	$\alpha_1 - \alpha_2$	$\alpha_1 - \alpha_2$	

Forskel af lys er det samme for de to niveauer af stress

Med $\mu = \alpha_2 + \beta_2$ har vi:

	Ingen Stress	Stress	3 parametre.
Svagt lys	$\mu + \gamma + \delta$	$\mu + \delta$	
Moderat lys	$\mu + \gamma$	μ	

Additiv model og i vekselvirkning **R**

For at undersøge reduktionen fra M_1 til M_2 skal vi fitte de to modeller og bruge **anova** .
 M_1 fittes med kaldet

```
lmfit_m1 <- lm(area ~ light+stress+light:stress, data=soya)
```

Leddet **stress:light** er et *vekselvirkningsled* - en faktor, der giver samme inddeling som **group** .

M_2 fittes ved hjælp af kaldet

```
lmfit_m2 <- lm(area ~ light+stress, data=soya)
```

Køres **anova**(lmfit_m2, lmfit_m1) fås variansanalysetabellen

Analysis of Variance Table

Model 1: area ~ light + stress

Model 2: area ~ light + stress + light:stress

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	49	43003				
2	48	42976	1	26.327	0.0294	0.8646

Reduktionen til M_2 afvises ikke, og denne er modellen for data.

Rækkeeffekter og søjleeffekter

I M_2 kan vi undersøge om stress har betydning for væksten:

$$M_3^r : X_{ijk} \sim N(\alpha_i, \sigma^2), \quad i = 1, 2, j = 1, 2, k = 1, \dots, 13,$$

I M_3^r har kun **r**ækkerne (lys) en effekt.

Vi kan også undersøge om lys har betydning for væksten

$$M_3^s : X_{ijk} \sim N(\beta_j, \sigma^2), \quad i = 1, 2, j = 1, 2, k = 1, \dots, 13.$$

I M_3^s har kun **s**øjlerne (stress) en effekt.

Rækkeeffekter og søjleffekter i R

Både M_3^r og M_3^s er modeller for $k = 2$ observationsrækker og fittes som sådan:

```
lmfit_m3s <- lm(area ~ stress, data=soya)
lmfit_m3r <- lm(area ~ light, data=soya)
anova(lmfit_m3s, lmfit_m2)
anova(lmfit_m3r, lmfit_m2)
```

Variansanalysetabellerne bliver

Analysis of Variance Table

Model 1: area ~ stress

Model 2: area ~ light + stress

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	50	85754				
2	49	43003	1	42752	48.714	7.136e-09 ***

og

Analysis of Variance Table

Model 1: area ~ light

Model 2: area ~ light + stress

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	50	57861				
2	49	43003	1	14858	16.931	0.0001479 ***

Estimater i additivitetsmodellen

Estimaterne i additivitetsmodellen findes i parametertabellen, som vi får med `summary(lmfit_m2)` :

```
Call:
lm(formula = area ~ light + stress, data = soya)

Residuals:
    Min       1Q   Median       3Q      Max
-68.558 -19.029  -0.385  18.846  59.788

Coefficients:
              Estimate Std. Error  t value    Pr(>t)
(Intercept)   $\hat{\alpha}_2 + \hat{\beta}_2 =$  269.558      7.116    37.883 < 2e-16 ***
lightlow      $\hat{\alpha}_1 - \hat{\alpha}_2 =$  -57.346      8.216    -6.980 7.14e-09 ***
stresslow     $\hat{\beta}_1 - \hat{\beta}_2 =$  33.808      8.216     4.115 0.000148 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.62 on 49 degrees of freedom
Multiple R-squared:  0.5726,    Adjusted R-squared:  0.5551
F-statistic: 32.82 on 2 and 49 DF,  p-value: 9.029e-10
```

Parametriseringen forstås ved at skrive:

$$\alpha_i + \beta_j = (\alpha_2 + \beta_2) + (\alpha_i - \alpha_2) + (\beta_j - \beta_2) = 1 + \text{light} + \text{stress}$$

Estimer i additivitetsmodellen

Estimaterne findes dermed til:

$$\begin{array}{llll} \text{Lys:} & \alpha_1 - \alpha_2 & \leftarrow & -57 \text{ cm}^2 \\ \text{Stress:} & \beta_1 - \beta_2 & \leftarrow & 34 \text{ cm}^2 \end{array} \quad \begin{array}{l} [-74 \text{ cm}^2, -41 \text{ cm}^2] \\ [17 \text{ cm}^2, 50 \text{ cm}^2] \end{array}$$

Konfidensintervallerne kan findes med `confint(lmfit_m2)`

```
          2.5 %    97.5 %  
(Intercept) 255.25846 283.85692  
lightlow     -73.85748 -40.83482  
stresslow     17.29636  50.31902
```

Parametrisering med vekselvirkningsled

Da vi fittede M_1 brugte vi modelformlen `area ~ light+stress+light:stress`

Køres `summary(lmfit_m1)` fås parametertabellen:

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    268.846      8.299   32.395 < 2e-16 ***
lightlow       -55.923     11.736   -4.765 1.79e-05 ***
stresslow       35.231     11.736    3.002 0.00425 **
lightlow:stresslow -2.846    16.598   -0.171 0.86457
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Bruges indeksering fra (5.18) kan parametriseringen forstås ved at skrive:

$$\mu_{ij} = \mu_{22} + (\mu_{i2} - \mu_{22}) + (\mu_{2j} - \mu_{22}) + (\mu_{ij} - \mu_{i2} - \mu_{2j} + \mu_{22})$$
$$1 + \text{light} + \text{stress} + \text{light:stress}$$

og benytte

$$\begin{aligned}\mu_{11} &\leftarrow \hat{\mu}_{11} = \bar{x}_{11.} = 245.308 & \mu_{12} &\leftarrow \hat{\mu}_{12} = \bar{x}_{12.} = 212.923 \\ \mu_{21} &\leftarrow \hat{\mu}_{21} = \bar{x}_{21.} = 304.077 & \mu_{22} &\leftarrow \hat{\mu}_{22} = \bar{x}_{22.} = 268.846.\end{aligned}$$

For eksempel er `(Intercept)` = $\hat{\mu}_{22}$ og `lightlow` = $\hat{\mu}_{12} - \hat{\mu}_{22}$ og
`lightlow:stresslow` = $\hat{\mu}_{22} - \hat{\mu}_{21} - \hat{\mu}_{12} + \hat{\mu}_{11}$.

Generelt om tosidet variansanalyse

Generelt i tosidet variansanalyse tænker vi på en faktor R med r niveauer og en faktor S med s niveauer. Data er organiseret i en $r \times s$ tabel med rs celler.

Vi betragter 5 modeller:

Grundmodellen

$$M_1 : \quad X_{ijk} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$

Additivitetsmodellen

$$M_2 : \quad X_{ijk} \sim N(\alpha_i + \beta_j, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$

Modellen med *kun rækkevirkning*

$$M_3^r : \quad X_{ijk} \sim N(\alpha_i, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$

Modellen med *kun søjlevirkning*


$$M_3^s : \quad X_{ijk} \sim N(\beta_j, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$

Modellen for *én observationsrække*

$$M_\infty : \quad X_{ijk} \sim N(\mu, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$

Generelt om tosidet variansanalyse

Det indbyrdes forhold mellem additivitetsmodellen og dennes undermodeller er:



Additivitetsmodellen

Den centrale egenskab ved additivitetsmodellen er at forskellen i middelværdi mellem to forskellige rækker g og h ikke afhænger af søjlen:

$$EX_{gjk} - EX_{hjk} = (\alpha_g + \beta_j) - (\alpha_h + \beta_j) = \alpha_g - \alpha_h.$$

og forskellen i middelværdi mellem to forskellige søjler l og m ikke afhænger rækken:

$$EX_{ilk} - EX_{imk} = (\alpha_i + \beta_l) - (\alpha_i + \beta_m) = \beta_l - \beta_m.$$

Modelkontrol - interaktionsplot

Vi kan lave modelkontrol af additivitetsmodellen ved at lave *interaktionsplot*, som er baseret på skønnene over middelværiderne $EX_{ijk} \leftarrow \bar{x}_{ij}$.

Interaktionsplot for rækkerne:

Afsæt punkterne $(j, \bar{x}_{ij.})$ for $j = 1, \dots, s$.

Disse skal give r kurver med konstant lodret afstand.

Interaktionsplot for søjlerne:

Afsæt punkterne $(i, \bar{x}_{ij.})$ for $i = 1, \dots, r$.

Disse skal give s kurver med konstant lodret afstand.

Kan laves i **R** med `interaction.plot`.

Fortolkning og antal gentagelser n_{ij}

Når modellerne regnes igennem i **R** er der ikke nogen krav på antallet af observationer i den ij -te celler.

Der er fortolkningsmæssige fordele, hvis der gælder at

$$n_{ij} = \frac{n_{i.} \cdot n_{.j}}{n_{..}}, \quad (\spadesuit)$$

En af fordelene er at det er let at regne estimer ud. Når betingelsen er opfyldt gælder der i M_2 at $\bar{X}_{i.} \sim N(\alpha_i + \bar{\beta}_{.}, \sigma^2/n_{i.})$, hvor

$$\bar{\beta}_{.} = \frac{1}{n_{..}} \sum_{j=1}^s n_{.j} \beta_j,$$

så skønnet over forskellen i virkning mellem niveau g og h af R er

$$\alpha_g - \alpha_h \leftarrow \bar{X}_{g.} - \bar{X}_{h.} \sim N(\alpha_g - \alpha_h, \sigma^2(1/n_{g.} + 1/n_{h.})).$$

Hvis $(\spadesuit)$ ikke er opfyldt afhænger fordelingen af $\bar{X}_{g.} - \bar{X}_{h.}$ af β_j -erne og kan *ikke* anvendes som skøn over $\alpha_g - \alpha_h$.

Et tilsvarende resultat gælder for estimation af virkningen af søjlerne.

Fortolkning og antal gentagelser n_{ij}

En yderligere fordel når ($\spadesuit$) er opfyldt er at skønnet over forskellen mellem virkningerne på to niveauer af R er det samme i modellen M_2 som i M_3^r . Med andre ord afhænger skønnet ikke af, om S har en betydning. Et tilsvarende udsagn gælder, hvis vi bytter om på rollerne af rækker og søjler.

Dette stemmer overens med den fortolkning som ønsker at have af M_2 .

En sidste fordel er at testet for om R har en betydning *sjældent* vil afhænge af om dette undersøges i M_2 eller i M_3^r , idet tællerne i F -testet i de to situationer vil være identiske.

Eksempel 5.7

Data i dette eksempel stammer fra seks boringer i et givent område. For hver boring er der taget en borekerne af jord, og man har målt pH-værdien af jorden i toppen, i midten og i bunden af borekernen. Da de seks boringer er foretaget i et større område, er det ikke rimeligt at anse de seks boringer for gentagne målinger af den samme størrelse. Det er heller ikke rimeligt at betragte de tre målinger fra hver borekernes top, midte og bund som gentagne målinger af samme størrelse, fordi man netop forventer en systematisk ændring af surhedsgraden ned gennem kernen.

Indledningsvis arbejdes der derfor med en model, hvor alle observationer er uafhængige, og hver observation har sin egen middelværdi. Vi forudsætter, at alle målingerne er normalfordelte med samme varians,

Eksempel 5.7

kerne	bund	midte	top	<i>gennemsnit</i>
1	7.2	7.6	7.5	7.43
2	6.7	7.1	7.2	7.00
3	7.0	7.2	7.3	7.17
4	7.0	7.4	7.5	7.30
5	7.0	7.7	7.7	7.47
6	6.9	7.7	7.6	7.40
<i>gennemsnit</i>	6.97	7.45	7.47	7.29


Udgangspunktet er modellen M_1 hvor alle observationer har deres egen middelværdi og med en fælles varians.

$$M_1 : X_{ij} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, \dots, 6, j = 1, 2, 3,$$

Denne model kan ikke kontrolleres og vi kan ikke lave et test for om vi kan reducere til M_2 .


Vi betragter interaktionsplot.

Eksempel 5.7



Figur 1: Grafisk kontrol af additivetsmodellen M_2 . Under M_2 er de tre kurver parallelforskuet i forhold til hinanden bortset fra tilfældige udsving.

Eksempel 5.7



Figur 2: Grafisk kontrol af additivetsmodellen M_2 . Under M_2 er de seks kurver parallelforskuet i forhold til hinanden bortset fra tilfældige udsving.

Eksempel 5.7

Kontroltegningerne gør at vi godt bruge additivitetsmodellen.
Yderligere modelreduktion viser sig ikke at være mulig.