

Matematisk Statistik

Gruppespecifik regression

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

m lineære regressioner

Udgangspunktet er modellen for m lineære regressioner

$$M_0 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma_i^2).$$

hvor X_{ij} er indbyrdes uafhængige $i = 1, \dots, m, j = 1, \dots, n_i$, og (t_{ij}, X_{ij}) er sammenhørende observationer af den afhængige variabel X_{ij} og den uafhængige variabel t_{ij} .

Sammenligning af de m regressionslinjer udføres ved hjælp af teorien for lineære normale modeller, hvilket kræver, at alle observationer har samme varians, det vil sige, at hypotesen

$$H_{01} : \sigma_1^2 = \dots = \sigma_m^2$$

ikke forkastes.

Test af varianshomogenitet

Hypotesen om varianshomogenitet

$$H_{01} : \sigma_1^2 = \dots = \sigma_m^2$$

testes ved hjælp af de uafhængige estimatorer for varianserne $s_{(i)}^2$ i de m regressioner, idet

$$s_{(i)}^2 \sim \sigma_i^2 \chi(n_i - 2)/(n_i - 2) \quad , \quad i = 1, \dots, m.$$

Hypotesen H_{01} testes ved hjælp af

- F -test, hvis $m = 2$
- Bartlett's test, hvis $m \geq 3$ og $n_i \geq 4$

Forkastes H_{01} ikke, reduceres modellen M_0 til den lineære normale model

$$M_1 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma^2) \quad i = 1, \dots, m, j = 1, \dots, n_i.$$


hvor X_{ij} erne er uafhængige.

Vi betragter følgende lineære normale regressionsmodeller

- $M_1 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma^2),$ *samme* varians.
- $M_2 : X_{ij} \sim N(\alpha + \beta_i t_{ij}, \sigma^2),$ *samme* afskæring.
- $M_2^* : X_{ij} \sim N(\alpha_i + \beta t_{ij}, \sigma^2),$ *samme* hældning.
- $M_3 : X_{ij} \sim N(\alpha + \beta t_{ij}, \sigma^2),$ *sammenfaldende* regressionslinjer.

Modeller og hypoteser

De fire modeller og de hypoteser, der giver sammenhængen mellem dem, kan skematisk angives således



Alle modellerne er eksempler på lineære normale modeller og kan behandles med **lm**.

Eksempel 5.8


Fagligt problem

Det er velkendt, at menneskers blodtryk stiger med alderen, men har denne stigning noget med ens profession at gøre?

Data

I Tabel 5.5 er alder og systolisk blodtryk angivet for 28 mænd, som endvidere er inddelt i to grupper efter deres profession. De 13 er journalister og de 15 er universitetslærere. I Figur 5.10 findes et scatterplot af data med alder ud ad førsteaksen og blodtryk op ad andenaksen, og man ser man begge professioner, at blodtrykket tilsyneladende stiger lineært med alderen

Eksempel 5.8



Figur 1: Separate tegninger for de to professioner.

Estimator i M_1

Data indlæses:

```
Blodtryk = read.csv("blodtryk.csv", header = TRUE, stringsAsFactors = TRUE)
head(Blodtryk)
```

Første 6 observationer:

	stilling	alder	blodtryk
1	Journalist	68	188.7
2	Underviser	55	162.9
3	Journalist	62	184.2
4	Underviser	49	155.9
5	Journalist	49	151.3
6	Underviser	60	170.5

Analysen af M_0 kan foretages ved at opdele datasættet i to datasæt:

```
Journalister <- subset(Blodtryk, subset = stilling == "Journalist")
Undervisere <- subset(Blodtryk, subset = stilling == "Underviser")
```

Eksempel 5.8

I modellen for to regressionslinjer med hver sin varians

$$M_0 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma_i^2) \quad i = 1, 2, j = 1, \dots, n_i$$

hvor $n_1 = 13$ og $n_2 = 15$, er estimerterne

Gruppe	α	β	σ^2
<i>journalist</i>	84.99521966	1.52956813	18.14950
<i>universitetslærer</i>	75.62986190	1.56238397	19.44954

Test af $H_{01} : \sigma_1^2 = \sigma_2^2$:

F -teststørrelsen for H_{01} er

$$\mathcal{F} = \frac{18.14950}{19.44954} = 0.933.$$

var.test kan benyttes.

p -værdien er 0.92 og H_{01} afvises ikke.

Eksempel 5.8

F -testet for varianshomogenitet bør benyttes her, for der er to variansskøn. Hvis vi alligevel ønskede at benytte Bartlett's test, kan dette gøres med

```
LM_Journalister <- lm(blodtryk ~ 1+alder, data = Journalister)
LM_Undervisere <- lm(blodtryk ~ 1+alder, data = Undervisere)

bartlett.test(list(LM_Journalister, LM_Undervisere))
```

Output bliver da

```
Bartlett test of homogeneity of variances

data:  list(LM_Journalister, LM_Undervisere)
Bartlett's K-squared = 0.013654, df = 1, p-value = 0.907
```

Eksempel 5.8

I modellen for to regressionslinjer med fælles varians

$$M_1 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma^2) \quad i = 1, 2, j = 1, \dots, n_i$$

beregnes estimatet for σ^2 som det vægtede gennemsnit, med frihedsgraderne som vægte, af estimerterne for σ^2 i de to grupper under M_0 :

$$s_{01}^2 = \frac{11 \cdot 18.14950 + 13 \cdot 19.44954}{11 + 13} = 18.85369.$$

Estimaterne i M_1 er

Gruppe	α	β	σ^2
<i>journalist</i>	84.99521966	1.52956813	18.85369
<i>universitetslærer</i>	75.62986190	1.56238397	

Gruppespecifik regression som lineær normal model

Vi betragter situationen med 2 grupper.

De stokastiske variable i M_1 er normalfordelte, uafhængige og har ens varians.

Middelværdivektoren skrives som $\xi = \alpha_1 \mathbf{1}_1 + \alpha_2 \mathbf{1}_2 + \beta_1 \mathbf{t}_1 + \beta_2 \mathbf{t}_2$

hvor

$$\mathbf{1}_1 = \begin{cases} 1 & \text{på gruppe 1} \\ 0 & \text{på gruppe 2} \end{cases} \quad \mathbf{1}_2 = \begin{cases} 0 & \text{på gruppe 1} \\ 1 & \text{på gruppe 2} \end{cases}$$

og

$$\mathbf{t}_1 = \begin{cases} t_{ij} & \text{på gruppe 1} \\ 0 & \text{på gruppe 2} \end{cases} \quad \mathbf{t}_2 = \begin{cases} 0 & \text{på gruppe 1} \\ t_{ij} & \text{på gruppe 2} \end{cases} .$$

Det vil sige at M_1 er en lineær normal model specificeret ved

$$L = \text{span}\{\mathbf{1}_1, \mathbf{1}_2, \mathbf{t}_1, \mathbf{t}_2\} .$$

Estimator i M_1

Vi kan fitte M_1 til datasættet ved hjælp af

```
LM_Blodtryk_M1 <- lm(blodtryk~1+stilling+alder+alder:stilling, data=Blodtryk)
```

Modelformlen kan læses som

$$\alpha \cdot 1 + \zeta_{\text{stl}} + \beta \cdot \text{alder} + \eta_{\text{stl}} \cdot \text{alder} \quad \text{stl} \in \{\text{journalist}, \text{underviser}\}.$$

I denne opskrivning er der 6 parametre:

$$\alpha, \zeta_{\text{journalist}}, \zeta_{\text{underviser}}, \beta, \eta_{\text{journalist}} \quad \text{og} \quad \eta_{\text{underviser}}$$

og modellen er *overparametriseret*, fordi vi betragter parametrene relativt til en referencegruppe. Relationen til “oprindelige” parametre er:

$$\begin{aligned} \alpha &= \alpha_1, & \zeta_{\text{journalist}} &= \alpha_1 - \alpha_1 = 0, & \zeta_{\text{underviser}} &= \alpha_2 - \alpha_1 & \text{og} \\ \beta &= \beta_1, & \eta_{\text{journalist}} &= \beta_1 - \beta_1 = 0, & \eta_{\text{underviser}} &= \beta_2 - \beta_1. \end{aligned}$$

Estimater i M_1

Parametertabellen fås ved at køre `summary(LM_Blodtryk_M1)`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	$\hat{\alpha} = 84.99522$	7.74255	10.978	7.71e-11 ***
stillingUnderviser	$\hat{\zeta}_{\text{underviser}} = -9.36536$	12.74975	-0.735	0.470
alder	$\hat{\beta} = 1.52957$	0.13509	11.322	4.12e-11 ***
stillingUnderviser:alder	$\hat{\eta}_{\text{underviser}} = 0.03282$	0.22419	0.146	0.885

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: $\hat{\sigma} = 4.342$ on 24 degrees of freedom

Multiple R-squared: 0.9049, Adjusted R-squared: 0.893

F-statistic: 76.13 on 3 and 24 DF, p-value: 2.103e-12

Sammenlign med estimaterne fra tabellen:

Gruppe	α	β	σ^2
journalist	84.99521966	1.52956813	18.85369
universitetslærer	75.62986190	1.56238397	

Estimater i M_1

Hvis vi ønsker at få estimaterne for de oprindelige parametre, kan vi opnå dette ved at fitte modellen uden intercept og alder-leddet.

```
LM_Blodtryk_M1_nooverparm <- lm(blodtryk~0+stilling+alder:stilling,data=Blodtryk)
```

Parametertabellen bliver da

```
Call:
lm(formula = blodtryk ~ 0 + stilling + alder:stilling, data = Blodtryk)
```

Residuals:

Min	1Q	Median	3Q	Max
-8.644	-3.019	1.201	1.785	7.219

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
stillingJournalist	84.9952	7.7426	10.978	7.71e-11	***
stillingUnderviser	75.6299	10.1296	7.466	1.05e-07	***
stillingJournalist:alder	1.5296	0.1351	11.322	4.12e-11	***
stillingUnderviser:alder	1.5624	0.1789	8.732	6.47e-09	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 4.342 on 24 degrees of freedom

Multiple R-squared: 0.9994, Adjusted R-squared: 0.9993

F-statistic: 1.045e+04 on 4 and 24 DF, p-value: < 2.2e-16

Modeller og hypoteser

Delmodeller af M_1



Hvilken af de to hypoteser $H_{02} : \alpha_i = \alpha$ og $H_{02}^* : \beta_i = \beta$, der skal testes afhænger af den faglige sammenhæng.

For dette datasæt må det være faglige og ikke statistiske grunde, der afgør valget mellem de to modeller. Det skal vi ikke komme ind på her, men i første omgang antage, at vi foretrækker H_{02} , dvs. testet fra M_1 til M_2 .

Test: $M_1 \rightarrow M_2 - H_{02} : \alpha_h = \alpha$

Det fremgår af parametertabellen fra `summary(LM_Blodtryk_M1)`, at vi godt kan acceptere H_{02} idet linjen ud for `stillingUnderviser` fortæller os at testsandsynligheden for hypotesen $H : \zeta_{\text{underviser}} = 0$ er 0.470 og da $\zeta_{\text{underviser}} = \alpha_2 - \alpha_1$ betyder det netop at der er ens afskæring i modellen.

Vi kan også teste hypotesen med `anova` ved først at fitte M_2 :

```
LM_BlodTryk_M2 <- lm(blodtryk~1+alder+alder:stilling,data=Blodtryk)
```

Bemærk at `stilling` er fjernet så modelformlen kan læses som

$$\alpha \cdot 1 + \beta \cdot \text{alder} + \eta_{\text{stl}} \cdot \text{alder} \quad \text{stl} \in \{\text{journalist}, \text{underviser}\}.$$

hvor parameteren ζ_{stl} er fjernet fra det tidligere udtryk.

Køres `anova(LM_BlodTryk_M2, LM_BlodTryk_M1)` fås

Analysis of Variance Table

Model 1: blodtryk ~ 1 + alder + alder:stilling

Model 2: blodtryk ~ 1 + stilling + alder + alder:stilling

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	25	462.66				
2	24	452.49	1	10.173	0.5396	0.4697

Bemærk at $t \text{ value}^2 = t(\mathbf{x})^2 = (-0.735)^2 \approx 0.5396 = F$

Estimater i M_2

Parametertabellen for M_2 fås ved at køre

summary (LM.Blodtryk_M2) fås parametertabellen:

```
Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)      81.54148      6.09451  13.379 6.74e-13 ***
alder              1.58910      0.10709   14.839 6.69e-14 ***
alder:stillingUnderviser -0.13049      0.02867   -4.551 0.000119 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.302 on 25 degrees of freedom
Multiple R-squared:  0.9028,    Adjusted R-squared:  0.895
F-statistic: 116.1 on 2 and 25 DF,  p-value: 2.225e-13
```

hvilket svarer til estimaterne

<i>Gruppe</i>	α	β	σ^2
<i>journalist</i>	81.54148011	1.58909585	18.50645
<i>universitetslærer</i>		1.45860666	

Tabel 1: Estimaterne for parametrene i modellen M_2 .

Test: $M_2 \rightarrow M_3 - H_{03} : \beta_h = \beta$

Det fremgår af linjen `alder:stillingUnderviser` at denne hypotese afvises. Det kan også bekræftes ved følgende kørsel af `anova` :

```
LM_Blodtryk_M3 <- lm(blodtryk~1+alder,data=Blodtryk)
anova(LM_Blodtryk_M3,LM_Blodtryk_M2)
```

med output

Analysis of Variance Table

Model 1: blodtryk ~ 1 + alder


Model 2: blodtryk ~ 1 + alder + alder:stilling

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	26	845.97				
2	25	462.66	1	383.31	20.712	0.0001193 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Modeller og hypoteser

For illustrationens skyld, tester vi nu efter følgende plan:



Figur 2: Undermodeller og hypoteser i lineær regression.

Test: $M_1 \rightarrow M_2^* - H_{02}^* : \beta_i = \beta$

Vi ved fra parametertabellen fra `summary(LM_Blodtryk_M1)` at hypotesen accepteres med en p -værdi på 0.885.

Vi kan også se det ved at fitte M_2^* med

```
LM_Blodtryk_M2star <- lm(blodtryk~1+stilling+alder, data=Blodtryk)
```

Leddene `alder:stilling` som svarer til η_{stl} er fjernet fra modelformlen. Det betyder svarer til at

$$\alpha \cdot 1 + \zeta_{stl} + \beta \cdot alder + \eta_{stl} \cdot alder \quad stl \in \{\text{journalist, underviser}\}.$$

bliver til

$$\alpha \cdot 1 + \zeta_{stl} + \beta \cdot alder \quad stl \in \{\text{journalist, underviser}\}.$$

Køres `anova(LM_Blodtryk_M2star, LM_Blodtryk_M1)` fås variansanalysetabellen

Analysis of Variance Table

Model 1: blodtryk ~ 1 + stilling + alder

Model 2: blodtryk ~ 1 + stilling + alder + alder:stilling

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	25	452.89				
2	24	452.49	1	0.40394	0.0214	0.8849

Test: $M_1 \rightarrow M_2^* - H_{02}^* : \beta_i = \beta$

Parametertabellen for **summary** (LM_Blodtryk_M2star) bliver

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	84.32064421	6.09856330	13.82631	3.2555e-13 ***
stillingUnderviser	-7.51476484	1.61325341	-4.65814	9.0379e-05 ***
alder	1.54148319	0.10568193	14.58606	9.8526e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.256254 on 25 degrees of freedom

Multiple R-squared: 0.90482708, Adjusted R-squared: 0.89721324

F-statistic: 118.83988 on 2 and 25 DF, p-value: 1.7037957e-13


hvilket svarer til

Gruppe	α	β	σ^2
<i>journalist</i>	84.32064422	1.54148319	18.11570
<i>universitetslærer</i>	76.80587938		

Tabel 2: Estimer for parametrene i modellen M_2^* .


Vi ser at parametertabellen at yderligere reduktion ikke er mulig.

Indtegnede regressionlinjer



Figur 3: Estimerede regressionlinjer i M_1

Indtegnede regressionslinjer



Figur 4: Estimerede regressionslinjer i modellen M_2 : samme afskæring. 24/31


Additiv fortolkning af parallelle regressionslinjer

Fortolkningen af M_2^* svarer til additivitetsmodellen fra tosidet variansanalyse:

Uanset alder, er der den samme forskel i middelværdi mellem de stillinger (“virkning” af stilling).


Uanset stilling, er der den samme forskel i middelværdi mellem to værdier af alder.

Indtegnede regressionlinjer



Figur 5: Estimerede regressionlinjer i M_2^* : parallelle regressionslinjer

Indtegnede regressionslinjer



Figur 6: Regressionslinjer i modellen M_3 : sammenfaldende regressionslinjer. Det fremgår klart, at modellen er urimelig, idet de to professioner overvejende ligger på hver sin side af regressionslinjen.

Parametriseringer

Nedenfor ses yderligere parametriseringer for gruppespecifik regression:

Model	Modelformel	Parametre
M_1	$gr * t$	$(\alpha_1, \alpha_2 - \alpha_1, \dots, \alpha_k - \alpha_1, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$
M_1	$gr + t + gr:t$	$(\alpha_1, \alpha_2 - \alpha_1, \dots, \alpha_k - \alpha_1, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$
M_1	$0 + gr + gr:t$	$(\alpha_1, \alpha_2, \dots, \alpha_k, \beta_1, \beta_2, \dots, \beta_k)$
M_1	$0 + gr + t + gr:t$	$(\alpha_1, \alpha_2, \dots, \alpha_k, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$
M_2	$gr + t$	$(\alpha_1, \alpha_2 - \alpha_1, \dots, \alpha_k - \alpha_1, \beta)$
M_2	$0 + gr + t$	$(\alpha_1, \alpha_2, \dots, \alpha_k, \beta)$
M_2^*	$t + gr:t$	$(\alpha, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$
M_2^*	$gr:t$	$(\alpha, \beta_1, \beta_2, \dots, \beta_k)$
M_3	t	(α, β)

Variansanalysetabel

Vi bruger primært **anova** til undersøge reduktionen fra en lineær normal model til en undermodel.

Køres **anova** med én fittet model, hvor modelformlen er

$$x \sim A_k + A_{k-1} + \dots + A_i + \dots + A_2 + A_1$$

Laves en variansanalysetabel med hvis indhold er

Analysis of Variance Table

Response: x

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
A_k	$d_k - d_{k+1}$	$\ P_k(\mathbf{x}) - P_{k+1}(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	(*)
A_{k-1}	$d_{k-1} - d_k$	$\ P_{k-1}(\mathbf{x}) - P_k(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
A_i	$d_i - d_{i+1}$	$\ P_i(\mathbf{x}) - P_{i+1}(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
A_1	$d_1 - d_2$	$\ P_1(\mathbf{x}) - P_2(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	

Variansanalysetabel

Variansanalysetabellen kan give et groft overblik over en model reduktion af formen

$$M_1 \rightarrow M_2 \rightarrow \dots \rightarrow M_k \rightarrow M_{k+1}$$

hvor

$$M_1: \quad x \sim A_k + A_{k-1} + \dots + A_1 + \dots + A_2 + A_1$$

$$M_2: \quad x \sim A_k + A_{k-1} + \dots + A_1 + \dots + A_2$$

$\vdots$

$$M_i: \quad x \sim A_k + A_{k-1} + \dots + A_1$$

$\vdots$

$$M_k: \quad x \sim A_k$$

$$M_{k+1}: \quad x \sim 1$$

Det vil sige, hvor der successivt fjernes led fra højre mod venstre i modelformlen. Man skal dog være opmærksom på at det er variansskønnet s_1^2 fra den fulde model der bruges når F -teststørrelserne beregnes, således at p -værdierne til højre ikke svarer til de værdier, man vil beregne, hvis man løbende opdaterer sin model.

Variansanalysetabel

Køres følgende kode med M_1 :

```
LM_Blodtryk_M1 <- lm(blodtryk~1+stilling+alder+alder:stilling, data=Blodtryk)
anova(LM_Blodtryk_M1)
```

fås variansanalysetabellen

Analysis of Variance Table

Response: blodtryk

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
stilling	1	451.6	451.6	23.9509	5.44e-05 ***
alder	1	3854.2	3854.2	204.4254	3.07e-13 ***
stilling:alder	1	0.4	0.4	0.0214	0.8849
Residuals	24	452.5	18.9		

Læses R-udskriften nedefra, at vi godt kan reducere fra M_1 til M_2^* men at vi næppe kan reducere til en model hvor **alder** ikke er med.