

Matematisk Statistik

Multipel regression

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Multipel regression

I simpel lineær regression betragtede vi en situation med én responsvariabel og én forklarende variabel. Data bestod af talpar:

$$(t_1, x_1), (t_2, x_2), \dots, (t_n, x_n)$$

I Multipel regression betragter vi modeller, hvor der er flere (d) forklarende variable.

Data består af $(d+1)$ -tupler:

$$(t_{11}, \dots, t_{1d}, x_1), (t_{21}, \dots, t_{2d}, x_1), \dots, (t_{n1}, \dots, t_{nd}, x_n)$$

Vi indfører

$$\mathbf{t}_{(j)} = (t_{1j}, t_{2j}, \dots, t_{nj})^* \in \mathbb{R}^n \quad \text{og} \quad \mathbf{t}_i = (t_{i1}, t_{i2}, \dots, t_{id})^* \in \mathbb{R}^d$$

og kan skrive datasættet som

$$(\mathbf{t}_1^*, x_1), (\mathbf{t}_2^*, x_2), \dots, (\mathbf{t}_n^*, x_n)$$

Multipel regression

Modellen er at x_i erne ud udfald X_i , $i = 1, \dots, n$, som er uafhængige stokastiske variable, der opfylder

$$M_1 : X_i \sim N(\alpha + t_{i1} \beta_1 + \dots + t_{id} \beta_d, \sigma^2), \quad i = 1, \dots, n.$$

De forklarende variable kaldes også *regressionsvariable*, og de ukendte parametre $\beta_1, \dots, \beta_d$ kaldes *regressionskoefficienter*.

- *Linearitet*: Middelværdien af responsen er en lineær funktion af de forklarende variable.
- *Varianshomogenitet*: Variansen af X_i er identisk for alle i og afhænger ikke af t_i , $i = 1, \dots, n$.
- *Normalfordeling*: X_i , $i = 1, \dots, n$ er normalfordelte.
- *Uafhængighed*: $X_1, \dots, X_n$ er uafhængige.

Modelkontrollen foretages ved hjælp af kontroltegninger.

Multipel regression - Eksempel 5.9

Fagligt problem

Hvordan hænger volumen sammen med diameter og højde for kirsebærtræer?

Data

Som datasæt benyttede det i `R` indbyggede `trees` data.


Datasættet indeholder målinger af diameter, højde og volumen for 31 fældede kirsebærtræer.

log Volume er responsen.

log Diameter og *Log Height* er forklarende variable.

Multipel regression - Eksempel 5.9

Først tegnes scatterplots for de tre par af variable.



Vi bemærker at *log Diameter* beskriver *log Volumen* godt, men hældningen for *log Volume* på *log Diameter* estimeres til 2.2.

Endvidere fremstår *log Diameter* og *Log Height* korrelerede.

I Afsnit 1.2 indførte vi den *empiriske fordelings funktion* $\hat{F}_n$ svarende til observationerne $x_1, x_2, \dots, x_n \in \mathbb{R}$:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{(-\infty, x]}(x_i).$$

Denne giver os den *empiriske fordeling* knyttet til $x_1, x_2, \dots, x_n$. Mere generelt kan vi for en følge $\mathbf{x}_1, \dots, \mathbf{x}_n$ i $\mathbb{R}^k$ betragte det til følgen hørende *empiriske mål* ved

$$\mathbb{P}_e(\cdot) = \frac{1}{n} \sum_{i=1}^n \delta_{\mathbf{x}_i}(\cdot),$$

hvor for $\mathbf{x} \in \mathbb{R}^k$, $\delta_{\mathbf{x}}(\cdot)$ betegner *punktmålet*: $\delta_{\mathbf{x}}(A) = \mathbb{1}_A(\mathbf{x})$, $A \subseteq \mathbb{R}^k$.

Hvis $\mathbf{X}$ er en stokastisk vektor som følger den empiriske fordeling for talfølgen $\mathbf{x}_1, \dots, \mathbf{x}_n$ så gælder

$$\mathbb{P}(\mathbf{X} = \mathbf{x}_i) = \frac{\#\{j \in \{1, 2, \dots, n\} \mid \mathbf{x}_j = \mathbf{x}_i\}}{n}.$$

Specielt gælder at hvis alle $\mathbf{x}_i$ -erne er forskellige er $\mathbb{P}(\mathbf{X} = \mathbf{x}_i) = 1/n$.

Hvis vi betragter en følge $\mathbf{x} = x_1, \dots, x_n$ af reelle tal samt en stokastisk variabel X med den tilknyttede empiriske fordeling gælder

$$\mathbb{E} X = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}. \quad \text{og} \quad \mathbb{V}\text{ar } X = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \text{SSD}_{\mathbf{x}}.$$

Vi betragter nu en følge $(x_1, y_1), \dots, (x_n, y_n)$ i $\mathbb{R}^2$ og lader (X, Y) betegne en stokastisk vektor, hvis fordeling er den tilknyttede empiriske fordeling.

Så gælder at fordelingen af X (henholdsvis Y) er den empiriske fordeling for følgen $x_1, \dots, x_n$ (henholdsvis $y_1, \dots, y_n$).

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}),$$

samt at korrelationen (den *empiriske korrelation*) mellem X og Y er

$$\text{Cor}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\text{SPD}_{\mathbf{xy}}}{\sqrt{\text{SSD}_{\mathbf{x}} \text{SSD}_{\mathbf{y}}}} \stackrel{\text{def}}{=} r_{\mathbf{xy}}.$$

For data fra en lineær regressionsmodel (t_i, x_i) ser vi

$$\hat{\beta} = \frac{\sqrt{\text{SSD}_{\mathbf{x}}}}{\sqrt{\text{SSD}_{\mathbf{t}}}} r_{\mathbf{tx}} = \frac{\sigma_{\mathbf{x}}}{\sigma_{\mathbf{t}}} r_{\mathbf{tx}},$$

hvor $\sigma_{\mathbf{x}} = \sqrt{\text{SSD}_{\mathbf{x}}/n}$ og $\sigma_{\mathbf{t}} = \sqrt{\text{SSD}_{\mathbf{t}}/n}$.

Multipel regression - Eksempel 5.9

Lader vi x_i betegne den i -te værdi af *log Volume* og t_{i1} , t_{i2} tilsvarende betegne henholdsvis *log Diameter* og *log Height*, betragter vi modellen:

$$M_1 : X_i \sim N(\alpha + \beta_1 t_{i1} + \beta_2 t_{i2}, \sigma^2), \quad i = 1, \dots, n, \quad + \text{uafhængighed.}$$



Eller: $\log \text{Volume}_i \sim N(\xi_i, \sigma^2)$ hvor

$$\xi_i = \alpha + \beta_{\log \text{Diameter}} \log \text{Diameter}_i + \beta_{\log \text{Height}} \log \text{Height}_i.$$

Først ønskes kontroltegninger. Data indlæses og M_1 fittes:

```
trees$LogDiameter = log(trees$Girth)
trees$LogHeight = log(trees$Height)
trees$LogVolume = log(trees$Volume)
lmfit <- lm(LogVolume ~ LogDiameter + LogHeight, data=trees)
```

Multipel regression - Eksempel 5.9



Residualer og prædikterede værdier findes ved hjælp af

```
residualer <- residuals(lmfit)
prædikterede_værdier <- predict(lmfit)
stud_resid <- rstandard(lmfit)
```

Multipel regression - Eksempel 5.9

Parameterestimer og tilhørende tests findes ved hjælp af parametertabellen fra `summary(lmfit)` :

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -6.63162    0.79979  -8.292 5.06e-09 ***
LogDiameter  1.98265    0.07501  26.432 < 2e-16 ***
LogHeight    1.11712    0.20444   5.464 7.81e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.08139 on 28 degrees of freedom
Multiple R-squared:  0.9777,    Adjusted R-squared:  0.9761
F-statistic: 613.2 on 2 and 28 DF,  p-value: < 2.2e-16
```

Vi aflæser at

$$\hat{\alpha} = -6.63162 \quad \hat{\beta}_{\text{LogDiameter}} = 1.98265 \quad \hat{\beta}_{\text{LogHeight}} = 1.11712$$

hvilket svarer til at *Volumen* cirka er proportional med $\text{Diameter}^2 \text{Højde}$.

Multipel regression - Eksempel 5.9

Prædiktions- og konfidensintervaller findes som for simpel lineær regression:


```
nytData = data.frame(LogDiameter=c(2.5,2.2),LogHeight=c(4.3,4.1))  
predict(lmfit,nytData,interval="confidence")  
predict(lmfit,nytData,interval="prediction")
```

Output:

```
> predict(lmfit,nytData,interval="confidence")  
      fit      lwr      upr  
1 3.128638 3.097052 3.160224  
2 2.310418 2.224244 2.396593  
> predict(lmfit,nytData,interval="prediction")  
      fit      lwr      upr  
1 3.128638 2.958960 3.298316  
2 2.310418 2.122752 2.498085
```

Multipel regression

Multipel regression: auktionspriser på bornholmerure



Auktionspris for bornholmerure


Ønsker tommelfingerregel for pris af bornholmerure

Hvordan skal vi beskrive pris ud fra *alder* på ur og *bydere* til auktion ?

Data for 32 bornholmerure			
Nummer	Alder (år)	Antal Bydere	Pris (pund)
1	127	13	1235
2	115	12	1080
⋮			
31	194	5	1356
32	168	7	1262

Plot af data

Respons: pris, Forklarende variable: alder, byder



Punkter med numerisk største residualer ved regression af pris på alder er markeret.

Afvielser ved regression af *pris* på *alder* kan måske forklares ved antallet *bydere*

alder og *bydere* tilsammen vil nok give bedre beskrivelse af data end *alder* alene.

Regression

Model: $\text{Pris}_i \sim N(\xi_i, \sigma^2)$

data er normalfordelt med ens varianser

$\xi_i = \alpha + \beta_{\text{alder}} \cdot \text{alder}_i + \beta_{\text{byder}} \cdot \text{byder}_i$ (multipel regression)

Fittede værdier: $\hat{\xi}_i = \hat{x}_i = \hat{\alpha} + \hat{\beta}_{\text{alder}} \cdot \text{alder}_i + \hat{\beta}_{\text{byder}} \cdot \text{byder}_i$,

Residual: $r_i = x_i - \hat{\xi}_i$





alder og byder er *regressionsvariable*

Kørsel i **R**: `lm (pris~alder+byder)`

Residualplot fra pris~alder+byder

Forventede: $\hat{\xi}_i = \hat{\alpha} + \hat{\beta}_{\text{alder}} \cdot \text{alder}_i + \hat{\beta}_{\text{byder}} \cdot \text{byder}_i$,

Residual: $r_i = \text{pris}_i - \hat{\xi}_i$



Spredningen i den multiple regressionsmodel estimeres til 133.4847.

Parametertabel

Model: $\text{pris}_i \sim N(\alpha + \beta_{\text{alder}} \cdot \text{alder}_i + \beta_{\text{byder}} \cdot \text{byder}_i, \sigma^2)$

R: `lm(pris~alder+byder)`

`summary(lmfit)`

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -1338.9513    173.8095  -7.704 1.71e-08 ***
alder         12.7406     0.9047   14.082 1.69e-14 ***
bydere        85.9530     8.7285    9.847 9.34e-11 ***
Residual standard error: 133.5 on 29 degrees of freedom
```


Intercept: $\hat{\alpha}$, alder: $\hat{\beta}_{\text{alder}}$, byder: $\hat{\beta}_{\text{byder}}$

T-test: både alder og byder er vigtige for at beskrive data

```
confint(lmfit)
              2.5 %      97.5 %
(Intercept) -1694.43162 -983.47106
alder         10.89017   14.59098
bydere        68.10115  103.80482
```

Kan vi gøre det bedre ?

Hvis vi opdeler i grupper baseret på antal bydere ser vi følgende:



Ikke additivitet: tyder på interaktion

Inkludere interaktion

Model: $\text{Pris}_i \sim N(\alpha + \beta_{\text{alder}} \cdot \text{alder}_i + \beta_{\text{byder}} \cdot \text{byder}_i + \beta_{AB} AB_i, \sigma^2)$

$$AB_i = \text{alder}_i \cdot \text{byder}_i$$

```
AB = alder*bydere  
lmfit = lm(pris~alder+bydere+AB)  
summary(lmfit)
```

Coefficients:





	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	320.4580	295.1413	1.086	0.28684	
alder	0.8781	2.0322	0.432	0.66896	
bydere	-93.2648	29.8916	-3.120	0.00416	**
AB	1.2978	0.2123	6.112	1.35e-06	***

Residual standard error: 88.91 on 28 degrees of freedom

Vi bemærker at den nye regressionskoefficient er signifikant og at spredningsskønnet går fra 133 til 88.

Residualplot fra pris~alder+byder+AB

Forventede: $\hat{\xi}_i = \hat{\alpha} + \hat{\beta}_{\text{alder}} \cdot \text{alder}_i + \hat{\beta}_{\text{byder}} \cdot \text{byder}_i + \hat{\beta}_{\text{AB}} \cdot \text{AB}_i$



Model selektion

Vi vil omtale to metoder til *model selektion* (variabel selektion):

- Backward-selektion
- Forward-selektion

Backward-selektion: Opstil “fuld model” og reducer i denne.

Forward-selektion: Byg model op “fra bunden”.

Flere andre metoder, f.eks.: *Best-Subset Selection* og *LASSO-regression*.

Backward-selektion

Ved **Backward-selektion** forstås følgende procedure:

I hvert trin køres `summary(lm(modelformel))` for den aktuelle model. Den største p -værdi blandt t -testene, for at en regressionskoefficient er nul, identificeres. Hvis denne p -værdi er større end en selvvalgt grænse (for eksempel 0.05), fjernes den tilhørende regressionsvariabel fra modellen. Proceduren stopper, når ingen af p -værdierne er over grænsen, og den tilhørende model kaldes slutmodellen.

Backward-selektion

Analyse af nedsivnings-data.



Nedsivningsdata

Patle, G. T., et al. (2018). *Geology, Ecology, and Landscapes*

Fagligt problem: Vandnedsivning er en vigtig parameter for udnyttelse af jord, og skal kunne beskrive hvis man ønsker forudsige hvor meget der skal vandes.

Respons: Infiltration Rate (IR) (nedsivning)

Regressionsvariable: Sand, Silt, BD (bulk density), PD (particle density), MC (moisture content), OC (organic carbon)


Sa, Si, BD, PD, MC, OC

Backward selection: inkluder alle 6 variable, fjern de “overflødige”

Forward selection: inkluder variable enkeltvis sålænge det giver forbedring

OBS: 6 forklarende variable, men kun $n = 25$ observationer.

Figur med data. Farve fra Sa-IR relation



R-kode: Backward selection

Vi fitter modellen alle 6 variable og betragter parametertabellen:

```
summary( lm(IR~Sa+Si+BD+PD+MC+OC) )
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-58.6841	18.0818	-3.245	0.00449	**
Sa	0.7766	0.1500	5.178	6.33e-05	***
Si	0.1483	0.2486	0.596	0.55835	
BD	-13.8184	5.5728	-2.480	0.02327	*
PD	3.1628	2.5295	1.250	0.22717	
MC	0.3375	0.1498	2.253	0.03698	*
OC	31.5894	33.9847	0.930	0.36492	

Residual standard error: 2.428 on 18 degrees of freedom
Multiple R-squared: 0.7776, Adjusted R-squared: 0.7035

Vi *vælger* at fjerne `Si`, som har den højeste p -værdi for hypotesen $\beta_{\text{variabel}} = 0$

R-kode, trin 2

```
summary(lm(IR~Sa+BD+PD+MC+OC))
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-55.0772	16.7489	-3.288	0.00386	**
Sa	0.7097	0.0978	7.256	6.92e-07	***
BD	-14.2181	5.4378	-2.615	0.01704	*
PD	3.0177	2.4747	1.219	0.23761	
MC	0.3688	0.1379	2.674	0.01502	*
OC	42.5031	28.1472	1.510	0.14749	

Residual standard error: 2.386 on 19 degrees of freedom
Multiple R-squared: 0.7732, Adjusted R-squared: 0.7136

Vi *vælger* at fjerne PD: p -værdi = 0.24

R-kode, trin 3

```
summary(lm(IR~Sa+BD+MC+OC))
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-53.00517	16.86407	-3.143	0.00512	**
Sa	0.69996	0.09866	7.095	7.07e-07	***
BD	-14.10503	5.50275	-2.563	0.01854	*
MC	0.36462	0.13955	2.613	0.01666	*
OC	60.96554	24.01541	2.539	0.01955	*

Residual standard error: 2.415 on 20 degrees of freedom
Multiple R-squared: 0.7555, Adjusted R-squared: 0.7066

Ved grænse på 0.05: fjerner ikke flere led

Slutmodel $E(\text{IR}) = \alpha + \beta_{\text{Sa}} \cdot \text{Sa} + \beta_{\text{BD}} \cdot \text{BD} + \beta_{\text{MC}} \cdot \text{MC} + \beta_{\text{OC}} \cdot \text{OC}$

Skøn over spredning σ : 2.42

Test fra startmodel til slutmodel:

```
anova(lm(IR~Sa+BD+MC+OC), lm(IR~Sa+Si+BD+PD+MC+OC))
```

p -værdi = 0.4256

Bekymring

Fire variable, men kun 25 observationer: måske overfitting

Tre variable er kun svagt signifikante

Prøve med lavere grænse: 0.01

```
anova(lm(IR~Sa+BD+MC+OC))
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-53.00517	16.86407	-3.143	0.00512	**
Sa	0.69996	0.09866	7.095	7.07e-07	***
BD	-14.10503	5.50275	-2.563	0.01854	*
MC	0.36462	0.13955	2.613	0.01666	*
OC	60.96554	24.01541	2.539	0.01955	*

Residual standard error: 2.415 on 20 degrees of freedom
Multiple R-squared: 0.7555, Adjusted R-squared: 0.7066

Vi *vælger* at fjerne OC : p -værdi = 0.020

R-kode, trin 4

```
anova(lm(IR~Sa+BD+MC))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-21.9224	13.0133	-1.685	0.1069	
Sa	0.6449	0.1080	5.971	6.31e-06	***
BD	-15.9413	6.1214	-2.604	0.0166	*
MC	0.2291	0.1447	1.584	0.1282	

Residual standard error: 2.71 on 21 degrees of freedom
Multiple R-squared: 0.6767, Adjusted R-squared: 0.6305

Vi *vælger* at fjerne MC : p -værdi = 0.13

R-kode, trin 5

```
anova (lm (IR~Sa+BD))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-14.5180	12.5536	-1.156	0.2599
Sa	0.5697	0.1003	5.682	1.03e-05 ***
BD	-13.5907	6.1389	-2.214	0.0375 *

Residual standard error: 2.801 on 22 degrees of freedom
Multiple R-squared: 0.6381, Adjusted R-squared: 0.6052

Vi *vælger* at beholde BD da modellen kun har to led

Slutmodel $E(IR) = \alpha + \beta_{Sa} \cdot Sa + \beta_{BD} \cdot BD$

Skøn over spredning σ : 2.80

Test fra startmodel til slutmodel:

```
anova (lm (IR~Sa+BD) , lm (IR~Sa+Si+BD+PD+MC+OC) )
```

p -værdi = 0.06

Fortolkning af slutmodel


Variablen S_a angiver procentdel af sand:

jo mere sand jo nemmere trænger vand ned

Variablen BD angiver bulk density: vægt divideret med volumen af jordprøve

jo større tæthed jo sværere for vandet at trænge ned

Modelkontrol. Modelformel: $IR \sim Sa + BD$



Hvor god er modellen ?

Kan vi forudsige middel-nedsivningsraten for et nyt datasæt med værdierne:

$(\tilde{S}a, \tilde{B}D)$?

Simpel lineær regression: “linjens værdi i et punkt”

Multipel regression: *prædikteret værdi*:

$$\hat{\xi}^P = \hat{x} = -14.52 + 0.57 \cdot \tilde{S}a - 13.59 \cdot \tilde{B}D$$

Konfidensinterval for ξ^P

Prædiktionsinterval for ny måling: $\hat{x} + \text{støj}$

Prædiktion, beregning i **R**

Eksempel:

Udelad obs nummer 25, genestimer model, lav prædiktion

```
IR1=IR[-25]; Sa1=Sa[-25]; BD1=BD[-25];  
  
lmfit=lm(IR1~Sa1+BD1)  
NyData=data.frame(Sa1=Sa[25],BD1=BD[25])
```

```
predict(lmfit,NyData,interval="confidence")
```

giver interval: [9.1, 13.7]

```
predict(lmfit,NyData,interval="prediction")
```

giver interval: [5.2, 17.5]

observeret værdi: 15.3

Backward-selektion, Eksempel 5.10

Fagligt problem

Hvilke variable beskriver den globale temperatur?

Data


Respons:

Globale temperaturs afvigelse fra et 30 års gennemsnit for årene 1979 - 2010 (32 observationer)


Forklarende variable:

Målinger af CO_2 , solens udstråling, vulkanaktivitet og *El Niño*-effekten.

Backward-selektion, Eksempel 5.10




Temperatur (sort) og CO₂ (grøn).



Temperatur afsat mod CO₂.

Figur 1: Udvikling af temperatur og CO₂ fra 1979 til 2010.

Backward-selektion, Eksempel 5.10



Udvikling fra 1979 til 2010 af de fire forklarende variable fra Eksempel 5.10

Backward-selektion, Eksempel 5.10

Lad X være temperaturen, C mængden af CO_2 i atmosfæren, S solens udstråling, V vulkanaktiviteten og E El Niño-effekten.

Vi vil også inddrage interaktion, ved at medtage produkterne:

$$\begin{aligned}CS &= C \cdot S, & CV &= C \cdot V, & CE &= C \cdot E, \\SV &= S \cdot V, & SE &= S \cdot E, & VE &= V \cdot E.\end{aligned}$$

Med disse betegnelser kan vi opstille den multiple regressionsmodel som følger:

$$\begin{aligned}X_i &\sim N(\xi_i, \sigma^2), \quad i = 1, \dots, 32, \quad + \text{uafhængighed}, \\ \text{hvor} \quad \xi_i &= \alpha + \beta_C \cdot C_i + \beta_S \cdot S_i + \beta_V \cdot V_i + \beta_E \cdot E_i \\ &\quad + \beta_{CS} CS_i + \beta_{CV} CV_i + \beta_{CE} CE_i + \beta_{SV} SV_i \\ &\quad + \beta_{SE} SE_i + \beta_{VE} VE_i.\end{aligned}$$

Backward-selektion, Eksempel 5.10

Data indlæses fra *co2data.csv* til `co2data` og variablene standardiseres.

```
C = co2data$C; S = co2data$S; V = co2data$V; E = co2data$E; Temp = co2data$Temp;  
C=(C-mean(C))/sd(C)  
S=(S-mean(S))/sd(S)  
V=(V-mean(V))/sd(V)  
E=(E-mean(E))/sd(E)  
  
CS=C*S; CV=C*V; CE=C*E; SV=S*V; SE=S*E; VE=V*E  
  
lmfit <- lm(Temp ~ C + S + V + E + C + S + CV + CE + SV + SE + VE )
```

Backward-selektion, Eksempel 5.10

Køres `summary(lmfit)` fås parametertabellen:

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   30.363      1.803   16.841 1.13e-13 ***
C              15.464      1.547    9.996 1.95e-09 ***
S              8.067      1.766    4.568 0.000167 ***
V             14.453      4.371    3.307 0.003358 **
E              5.542      1.202    4.610 0.000151 ***
CS            -1.156      1.025   -1.128 0.272145
CV              3.602      2.151    1.674 0.108935
CE              1.609      1.434    1.122 0.274616
SV            -10.760      4.106   -2.620 0.015984 *
SE              1.424      1.315    1.083 0.291211
VE              1.200      2.320    0.517 0.610266
```

og vi ser at `VE` er første variabel der kan fjernes.

Backward-selektion, Eksempel 5.10

Slutmodellen bliver

$$X_i \sim N(\alpha + \beta_C C_i + \beta_S S_i + \beta_V V_i + \beta_E E_i + \beta_{SV} \cdot SV_i, \sigma^2), \quad i = 1, \dots, 32,$$

og p -værdien for reduktionen fra startmodel til slutmodel findes til 0.2137.

Parametrene i slutmodellen er:

	α	C	S	V	E	SV
Estimate	31.5334	16.1674	6.8994	12.3519	5.7220	-10.4519
Std. Error	1.3215	1.3633	1.6971	3.0498	1.1519	4.2719
ρ_{obs}	0.0000	0.0000	0.0004	0.0004	0.0000	0.0215

Den empiriske spredning på C er 15.3 så regressionskoefficienten for de ikke-standardiserede variable er $16.2/15.3 \approx 1$.

Forward-selektion

Vi betragter nu *forward-selektion*.


Ved forward-selektion forestiller os at vi starter med modellen for en normalfordelt observationsrække. Derefter tilføjer vi trinvis nye variable.

Proceduren kan beskrives som følger:

I hvert trin prøver man på skift at inkludere en af de variable, der endnu ikke er med i modellen. Fra parametertabellen, for modellen med den ekstra variabel inkluderet, findes spredningsskønnet $s(M)$ og p -værdien for test af hypotesen, at regressionskoefficienten hørende til den ekstra variabel er nul. Når alle variable er afprøvet, vælges den variabel med det laveste spredningsskøn, og hvis den tilhørende p -værdi er under en selvvalgt grænse (for eksempel 0.05), inkluderes variabelen i modellen, og forward-selektions proceduren fortsættes. Proceduren stopper, når p -værdien for den valgte variabel er over grænsen.

Illustration af forward-selektion

Forward stepwise selection example with 5 variables:



Forward-selektion på nedsivnings-data

Laver regression af IR på en enkelt variabel.

Først køres `summary(lm(IR~Sa))`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-36.8688	8.0691	-4.569	0.000136	***
Sa	0.5827	0.1083	5.383	1.81e-05	***

Residual standard error: 3.03 on 23 degrees of freedom

Dernæst køres `summary(lm(IR~Si))`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	13.1153	3.2181	4.076	0.000466	***
Si	-0.4677	0.2180	-2.146	0.042663	*

Residual standard error: 4.157 on 23 degrees of freedom

Variabel	Sa	Si	BD	PD	MC	OC
<i>p</i> -værdi	0.000	0.043	-	-	-	-
<i>s</i> (<i>M</i>)	3.030	4.157	-	-	-	-

Forward selection

Vi fortsætter med de resterende variable:

`lm(IR~Sa)` , `lm(IR~Sa)` , ..., `lm(IR~OC)` ,

Variabel	Sa	Si	BD	PD	MC	OC
p -værdi	0.000	0.043	0.110	0.396	0.292	0.294
$s(M)$	3.030	4.157	4.304	4.482	4.444	4.445

p -værdi: test for $\beta = 0$

$s(M)$: spredningsskøn

Vi *vælger* at inkludere variabelen Sa

Forward-selektion på nedsivnings-data

Vi betragter dernæst modeller hvor Sa er med sammen med en af de andre variable ad gangen:

Først køres `summary(lm(IR~Sa + Si))`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-62.1123	14.6171	-4.249	0.000328	***
Sa	0.8315	0.1597	5.206	3.2e-05	***
Si	0.4733	0.2344	2.020	0.055774	.

Residual standard error: 2.845 on 22 degrees of freedom

Variabel	Sa	Si	BD	PD	MC	OC
<i>p</i> -værdi	*	0.056	-	-	-	-
<i>s</i> (<i>M</i>)	*	2.845	-	-	-	-

Dernæst køres `summary(lm(IR~Sa + BD))` og så fremdeles.

Forward-selektion på nedsivnings-data

Laver regression af IR på en enkelt variabel udover Sa

P -værdi: test for $\beta_{\text{variabel}} = 0$

`lm(IR~Sa+Si)` , `lm(IR~Sa+BD)` , ..., `lm(IR~Sa+OC)` ,

Variabel	Sa	Si	BD	PD	MC	OC
p -værdi	-	0.056	0.038	0.083	0.392	0.081
$s(M)$	-	2.845	2.801	2.888	3.045	2.887

Vi *vælger* at inkludere variabelen BD udover Sa

Forward selection

Laver regression af IR på en enkelt variabel udover Sa og BD, det vil sige at vi **summary** på følgende:

`lm(IR~Sa+BD+Si)` , `lm(IR~Sa+BD+PD)`

`lm(IR~Sa+BD+MC)` , `lm(IR~Sa+BD+OC)`

Variabel	Sa	Si	BD	PD	MC	OC
p -værdi	-	0.084	-	0.104	0.128	0.155
$s(M)$	-	2.666	-	2.689	2.710	2.730

Vi *inkluderer ikke* flere variable

Slutmodel Forward: Sa + BD

$$s(M_F) = 2.80$$

Slutmodel (5% grænse) Backward: Sa + BD + MC + OC

$$s(M_B) = 2.42$$

forward

forward funktionen fra *Rfunktioner.txt* kan benyttes:

```
bT = cbind(Sa, Si, BD, PD, MC, OC)
forward(bT, IR)
```

```
$sny
[1] 3.029664

$med
[1] 1

$pval
           [,1]
Intercept 0.0001362327
X          0.0000181329
```

Dernæst køres **forward**(bT, IR, c(1))

Køres

```
forward(bT, IR, c(1))
```

bliver output:

```
$sny
[1] 2.801384

$med
[1] 1 3

$pval
      [,1]
Intercept 0.2598898772
Sa         0.0000102851
BD         0.0375102028
```

Opsummering

Forward og backward selection giver generelt forskellige modeller

For nedsivningsdata: ingen af modellerne er “fantastisk”:

$$s/\text{mean}(\text{IR}) \approx 0.4$$

Stor spredning: svært at prædiktere nedsivning

Foregående eksamen viser at vi inden for multipel regression godt kan betragte forklarende variable, der er konstrueret som ikke-lineære funktioner af andre forklarende variable. Vi illustrerer dette med *polynomiel regression*.

På R-koden simuleres 30 uafhængige observatoier af t og x hvor


$$X = 3t^2 - 2t - 1 + N(0, 1),$$

```
set.seed(1)
n = 30
bt = seq(from = -1,to=1,length.out=n)
bx = 3*bt^2-2*bt-1 + rnorm(n)
```

x	t	t^2
3.37	-1.00	1.00
3.65	-0.93	0.87
2.12	-0.86	0.74
$\vdots$	$\vdots$	$\vdots$
0.42	1.00	1.00

Tabellen viser værdierne af x og t samt t^2 . Som det fremgår består t variabelen af 30 ækvidistante punkter i intervallet $[-3, 3]$.

På et scatterplot af t på x ses en tydelig kvadratisk sammenhæng. Vi ville ikke opstille en model for simpel lineær regression for dette datasæt.



Vi kan inkludere t^2 som forklarende variabel på flere måder. Funktionen `I` gør at vi kan lave aritmetiske operationer inde i selve modelformlen. Funktionen `poly` giver her et 2.grad polynomium. Funktionen giver *ortogonale* polynomier som default, derfor skrives `raw=TRUE` .

```
bt2 = bt^2
lmfit <- lm(bx~bt+bt2)
lmfit <- lm(bx~bt+I(bt^2))
lmfit <- lm(bx~poly(bt,2,raw=TRUE))
```

`summary(lmfit)` vil returnere det samme i alle tre tilfælde, bortset fra navngivningen af koefficienterne.


	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-0.7094	0.2553	-2.779	0.009814	**
bt	-2.1689	0.2849	-7.613	3.45e-08	***
I(bt^2)	2.4160	0.5345	4.520	0.000111	***

Vi ser, at det estimerede andengradspolynomium er

$$f(t) = -0.7094 - 2.1689 t + 2.4160 t^2,$$

samt at koefficienten til t^2 er signifikant.

Polynomiel regression kan let resultere i *overfitting*.



Til venstre er det estimerede 2.gradspolynomium indtegnet. På figuren til højre er et estimerede 10.gradspolynomium indtegnet.

Underfitting, overfitting og model selektion

Sande model: $E(X_i) = \alpha + \beta_1 t_i + \beta_1 t_i^2$

Fitter model: $E(X_i) = \alpha + \beta_1 t_i + \beta_2 t_i^2 + \cdots + \beta_k t_i^k$

Hvor skal k vælges, hvis f.eks. forward- og backward-selektion giver forskellige svar?

Både underfitting og overfitting er problematisk, men overfitting kan være sværere at "se":

Typisk: jo større k er, jo bedre et fit får vi: $s(M_k)$ er lille.

Husk

$$s^2 = \frac{1}{n-d} \|\mathbf{x} - P(\mathbf{x})\|^2.$$

Hvis $k = n$ er $s(M_k) = 0$!

Overfitting: problem

En god model skal kunne forudsige nye observationer.

Overfitting giver dårlig *predictor* (linear prediction function):

Generel formulering - vi betragter en multipel regressionsmodel:

Data: $x_i, t_{1i}, t_{2i}, \dots, t_{ki}, \quad i = 1, \dots, n$

Model: $E(X_i) = \alpha + \beta_1 t_{1i} + \beta_2 t_{2i} + \dots + \beta_k t_{ki}$

Fitted modellen kan vi finde estimator: $\hat{\alpha}, \hat{\beta}_1, \dots, \hat{\beta}_k, \quad s(M)$

En "predictor" returnerer estimeret middelværdi (prædikeret værdi) svarende til nye værdier $\tilde{t}_1, \tilde{t}_2, \dots, \tilde{t}_k$:

$$\text{Predictor}(\tilde{t}_1, \tilde{t}_2, \dots, \tilde{t}_k) = \hat{\alpha} + \hat{\beta}_1 \tilde{t}_1 + \dots + \hat{\beta}_k \tilde{t}_k$$

Predictor i polynomiell regression:

$$\text{Predictor}(\tilde{t}_{ny}) = \hat{\alpha} + \hat{\beta}_1 \tilde{t}_{ny} + \dots + \hat{\beta}_k \tilde{t}_{ny}^k$$

Beregning i R: benyt *predict*

Prædiktionsevne

$\hat{\beta}$ estimeres ud fra data (træningsdata)

Hvor gode er vi til at forudsige respons $\tilde{X}$ hørende til nye værdier $\tilde{t}_1, \dots, \tilde{t}_k$

Prædiktion: $\hat{\beta}_1 \tilde{t}_1 + \dots + \hat{\beta}_k \tilde{t}_k$

Idé: Vælge model, som er bedst til at prædiktere.

PrædiktionsMeanSquaredError: $E\{(\tilde{X} - (\hat{\beta}_1 \tilde{t}_1 + \dots + \hat{\beta}_k \tilde{t}_k))^2 | \text{data}\}$

$= E\{(\tilde{X} - (\beta_1 \tilde{t}_1 + \dots + \beta_k \tilde{t}_k) - ((\hat{\beta}_1 - \beta_1) \tilde{t}_1 + \dots + (\hat{\beta}_k - \beta_k) \tilde{t}_k))^2 | \text{data}\}$

$= \sigma^2 + \{(\hat{\beta}_1 - \beta_1) \tilde{t}_1 + \dots + (\hat{\beta}_k - \beta_k) \tilde{t}_k\}^2 = \sigma^2 + \{(\hat{\beta} - \beta)^T \tilde{\mathbf{t}}\}^2$

Kaldes *prædiktionsMSE* eller *prædiktionsvarsians*.

Angiver hvor gode vi er til prædiktere ny observation *for de specifikke værdier af $\tilde{t}_1, \dots, \tilde{t}_k$* .

Afhænger af de ukendte parametre.


Overfitting: problem

Hvis vi overfitter giver dette typisk en dårligere prediktor:

$E\{(X_{ny} - \text{Prediktor}(t_{ny}))^2\}$ bliver større

k=1	k=2	k = 3	k=4	k=5	k=6	k=8	k=12	k=15
0.832	0.049	0.0503	0.495	0.121	0.153	0.165	0.277	0.454

Betragter data fra Afsnit 5.7.1, k graden af fittet polynomium, t_{ny} uniform .



To problematikker:

Hvordan vælger vi en simpel model ? og Hvordan måler vi overfitting ?

Forslag

Beregne prædiktionsvarians (prædiktionsMSE) ud fra et *testsæt*
 $(\tilde{t}_{i1}, \dots, \tilde{t}_{ik}, \tilde{x}_i) \ i = 1, \dots, m$

Skøn over prædiktionsvariansen:

$$\frac{1}{m} \sum_{i=1}^m (\tilde{x}_i - (\hat{\beta}_1 \tilde{t}_{i1} + \dots + \hat{\beta}_k \tilde{t}_{ik}))^2$$

MEN: typisk har vi ikke et testsæt til rådighed

Alternativ: Dele oprindelige datasæt op i et "træningssæt" og et "testsæt"

crossvalidation

Træningssæt:

Data $x_1, \dots, x_n$ bruges til at estimere model

$$X_i \sim N(\alpha + \beta_1 t_{i1} + \dots + \beta_k t_{ik}, \sigma^2)$$

$t_1, \dots, t_k$: forklarende variable (regressionsvariable)

Testsæt: $\tilde{x}_i, \tilde{t}_{i1}, \dots, \tilde{t}_{ik}, i = 1, \dots, m$


data der IKKE blev brugt til at finde skøn $\hat{\alpha}, \hat{\beta}$

Beregn prædikterede værdier $\hat{x}_i = \hat{\alpha} + \hat{\beta}_1 \tilde{t}_{i1} + \dots + \hat{\beta}_k \tilde{t}_{ik}$

Skøn over prædiktionsspredning: $s_P = \sqrt{\frac{1}{m} \sum_{i=1}^m (\tilde{x}_i - \hat{x}_i)^2}$

Illustration af overfitting

1.-akse: antal variable i model; 2.-akse: hvor godt passer model til data



Blå kurve viser bedre og bedre tilpasning til trænings-data ved inkludering af flere variable

Rød kurve viser prædiktionsspredning på test-data

Testdata - crossvalidation

Hvordan vurderer vi om vi overfitter, hvis vi ikke har et test-datasæt ?

Crossvalidation: Data deles op i forskellige *træningssæt* og *testsæt*

Træningssættet bruges til at estimere parametre i model M

Testsættet bruges til at beregne prædikterede værdier $\tilde{\xi}_i^P(M)$ baseret på estimerede parametre fra træningssættet og de forklarende variable i testsættet, index i løber over testsæt

giver bidrag til prædiktionsvariansen på formen $(x_i - \hat{\xi}_i^P)^2$

Prædiktionsspredning ved crossvalidation: $s_{cv} = \sqrt{\frac{1}{m} \sum (x_i - \hat{\xi}_i^P)^2}$

m er antal led i summen

Eksempel: 5-fold crossvalidation

5-fold crossvalidation:

Betragt tilfælde med 50 observationer

Vi deler dem op i 5 blokke: 1-10, 11-20, 21-30, 31-40 og 41-50

1° estimerer model baseret på 1-40, tester på 41-50

2° estimerer model baseret på 1-30 + 41-50 og tester på 31-40


⋮

5° estimerer model baseret på 11-50 og tester på 1-10

I beregning af prædiktionsspredningen får vi nu 50 led

Eventuelt gentage flere gange med forskellige opdelinger.

Illustration of 5-fold crossvalidation



Leave one out crossvalidation

Leave one out crossvalidation (LOOCV):

Specialtilfælde af crossvalidation, hvor testsættet kun består af 1 observation:

- 1° observation i tages ud
- 2° model M estimeres fra de resterende $n - 1$ observationer
- 3° prædikteret værdi $\hat{x}^{-i}$ beregnes for den udeladte observation

Prædiktionsspredning ved crossvalidation

$$s_{cv} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}^{-i})^2}$$

Illustration of LOOCV



Beregning

Prædiktionsspredning ved crossvalidation : $s_{cv} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}^{-i})^2}$

Sætter vi

$$r^{-i} \stackrel{\text{def}}{=} x_i - \hat{x}^{-i} \quad i = 1, \dots, n$$

fås de *rå sletningsresidualer*.

Det kan vises at

$$r^{-i} = \frac{r_i}{1 - h_i}$$

hvor r_i er (det almindelige) i -te residual og h_i er *leverage* for den i -te observation.

For simpel lineær regression gælder der ifølge (4.10)

$$h_i = \frac{1}{n} + \frac{(t_i - \bar{t})^2}{SSD_t}.$$

For en fittet model kan vektoren $\mathbf{h} = (h_1, \dots, h_n)^*$ beregnes i **R** ved hjælp af

```
lm.influence(fit) $h
```

Prædiktionsspredningen kan derfor beregnes som

```
loocv=function(fit){  
  h=lm.influence(fit) $h  
  return(sqrt(mean((residuals(fit)/(1-h))^2)))  
}
```

Overfitting: eksempel

Sande model: $E(X_i) = \alpha + \beta_1 t_i$


Fitter model: $E(X_i) = \alpha + \beta_1 t_i + \beta_2 t_i^2 + \cdots + \beta_k t_i^k$

Typisk: jo større k er, jo bedre et fit får vi: $s(M_k)$ er lille


hvis $k = n$ er $s(M_k) = 0$!

Fitte polynomium: LOOCV


$k = 1$ $s = 2.84$ $scv = 3.18$




$k = 2$ $s = 2.86$ $scv = 3.25$




$k = 3$ $s = 1.99$ $scv = 3.01$




$k = 4$ $s = 2.18$ $scv = 9.39$



$k = 6$ $s = 1.68$ $scv = 324.25$




$k = 8$ $s = 1.07$ $scv = 224205.5$



Fitte 4.gradspolynomium: LOOCV

Fitter 4.gradspolynomium med et punkt udeladt



$$s_{cv}^2 = \frac{1}{10}((-9.2)^2 + (5.41)^2 + (-5.27)^2 + \dots + (-14.97)^2 + (22.62)^2) = 9.39^2$$

LOOCV for multipel regressionsmodel

Model: $X_i \sim N(\alpha + \beta_1 t_{i1} + \dots + \beta_k t_{ik}, \sigma^2)$

Observation i udelades, model estimeres:

estimator: $\hat{\alpha}^{-i}, \hat{\beta}_1^{-i}, \dots, \hat{\beta}_k^{-i}$

Prædikteret værdi beregnes:

$$\hat{x}_i^{-i} = \hat{\alpha}^{-i} + \hat{\beta}_1^{-i} t_{i1} + \dots + \hat{\beta}_k^{-i} t_{ik}$$

prædiktionsfejl: $x_i - \hat{x}_i^{-i}$

Prædiktionsspredning:

$$s_{cv} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i^{-i})^2}$$

LOOCV for nedsivnings-data

Respons: Infiltration Rate (IR)

Regressionsvariable: Sand, Silt, BD (bulk density), PD (particle density), MC (moisture content), OC (organic carbon)

Sa, Si, BD, PD, MC, OC

Backward selection: Sa+BD+MC+OC

$$s(M_B) = 2.42, \quad s_{cv}(M_B) = 3.02 \quad \text{lm}(\text{IR} \sim \text{Sa} + \text{BD} + \text{MC} + \text{OC})$$

Forward selection: Sa+BD

$$s(M_F) = 2.80, \quad s_{cv}(M_F) = 3.12 \quad \text{lm}(\text{IR} \sim \text{Sa} + \text{BD})$$

s_{cv} afspejler både usikkerhed i skøn $\hat{\xi}_i^{-i}$ og spredning σ i model

Begge modeller er lige gode, ingen tegn på overfitting

Konklusion

LOOCV i en multipel regressionsmodel er vist

I multiple regressionsmodeller med få variable bibringer crossvalidation ofte ikke noget nyt

Næste: Multipel regression med mange variable

Data

Data er analyseret i artiklen "Application of near-infrared reflectance spectroscopy to compositional analysis of biscuits and biscuit dough", Journal of the Science of Food and Agriculture, 1984

Ønsker at kunne prædiktere mængden af vand i dej ud fra gennemlysning med lys


NIR: Near Infrared Reflectance spectroscopy
måler refleksion ved 700 bølgelængder i intervallet 1100-2500 nm

Data: vektor x med vandindhold i $n = 39$ prøver

39×700 matrix med refleksioner
hver række giver spektrum for prøve, hver søjle er en forklarende variabel

multipl regression med 700 forklarende variable!


Tre spektre




Respons: Vandindhold. Forklarende variable: Bølgelængder.

Regression på individuelle spektre

$$\hat{\alpha} = -2.64 \quad \hat{\beta} = 42.16$$




$$\hat{\alpha} = -4.8 \quad \hat{\beta} = 49.5$$




Søjle 114

$$\hat{\alpha} = -2 \quad \hat{\beta} = 27.72$$



Søjle 85



$$\hat{\alpha} = -1.89 \quad \hat{\beta} = 18.43$$






Forward

Når antal forklarende variable er større end antal prøver:
de forventede værdier i multipel regresion = responsværdier
 $s^2(M) = 0$

Enten lægge restriktioner på $\hat{\beta}$ (ridge-regression,
LASSO-regression)
eller: forward selektion
nødvendigt med crossvalidation.



Vise beregninger til figur



Venstre figur: `sigma(lm(x~tj))`

Midterste figur: `sigma(lm(x~t114+tj))`

Højre figur:





`sigma(lm(x~t114+t85+t142+t285+t78+t75+tj))`

I alle figurer: $j = 1, \dots, 700$

Illustration af residualer

r1: residual fra $x \sim t114$, v1: residual fra $t85 \sim t114$

r2: residual fra $x \sim t85 + t114$, v1: residual fra $t142 \sim t85 + t114$



R-beregning: crossvalidation

OBS: ikke crossvalidation som for en given multipel regressionsmodel

LOOCV med j led i forward algoritme: Fjerner observation i fra datasæt, kører forward selektion på reducerede datasæt indtil j variable er inkluderet



Finde cross validation prædiktionspredning:

```
cvForward(T, x, m)
```

m : det maksimale antal led der ønskes undersøgt

R-beregning: crossvalidation

Figur for Dej-data



Crossvalidation prædictionsspredninger fra FWcrossval:

1	2	3	4	5	6	7	8	9	10
0.92	0.61	0.47	0.33	0.24	0.22	0.24	0.25	0.26	0.28

Tyder på at 6 variable er et godt valg

Prædiktionsspredning fra ægte testsæt

Der er indsamlet 31 nye prøver

Beregner prædiktionsspredning på disse baseret på forward selektion på oprindelige data (træningssæt) med 2 til 10 variable.

Antal	1	2	3	4	5	6	7	8	9	10
Variabelnummer	114	+85	+142	+285	+78	+75	+81	+206	+166	+205
Prædiktionsspredning	0.80	0.39	0.39	0.28	0.30	0.26	0.25	0.25	0.24	0.25

Tyder på at vi godt kan tage lidt flere end 6 variable

