

Matematisk Statistik

Multipel regression som lineær normal model

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Multipl regression

Når vi skal beskrive multipl regression som lineær normal model er det nyttigt at benytte følgende opskrivning:

$$M_1 : X_i \sim N(t_{i1}\beta_1 + t_{i2}\beta_2 + \cdots + t_{id}\beta_d, \sigma^2), \quad i = 1, \dots, n.$$

Hvis $t_{11} = t_{21} = \cdots = t_{n1} = 1$ fås et intercept-led som tidligere.

Sættes $\beta \stackrel{\text{def}}{=} (\beta_1, \beta_2, \dots, \beta_d)^*$ og $\mathbf{t}_i = (t_{i1}, t_{i2}, \dots, t_{id})^*$ kan modellen skrives

$$X_i \sim N(\mathbf{t}_i^* \beta, \sigma^2).$$

Designmatricen

Betragtes middelværdivektoren $\boldsymbol{\mu} = (\mathbb{E}[X_1], \mathbb{E}[X_2], \dots, \mathbb{E}[X_n])^*$ har vi

$$\boldsymbol{\mu} = \begin{pmatrix} \mathbf{t}_1^* \boldsymbol{\beta} \\ \vdots \\ \mathbf{t}_i^* \boldsymbol{\beta} \\ \vdots \\ \mathbf{t}_n^* \boldsymbol{\beta} \end{pmatrix} = \mathbf{T} \boldsymbol{\beta}$$

hvor $\mathbf{T}$ er $n \times d$ matricen, hvis i -te række er $\mathbf{t}_i^*$, det vil sige

$$\mathbf{T} \stackrel{\text{def}}{=} \left\{ \begin{pmatrix} \mathbf{t}_1^* \\ \vdots \\ \mathbf{t}_i^* \\ \vdots \\ \mathbf{t}_n^* \end{pmatrix} \right\}.$$

Vi vil antage at $d < n$ samt at $\mathbf{T}$ har fuld rang d . Matricen $\mathbf{T}$ kaldes en *designmatrix* eller en *modelmatrix*.

Designmatricen

Værdierne af den j -te forklarende variabel er:

$$\mathbf{t}_{(j)} = (t_{1j}, t_{2j}, \dots, t_{nj})^*.$$

og disse udgør *søjlerne* i *søjlerne* i $\mathbf{T}$:

$$\mathbf{T} = \{ \mathbf{t}_{(1)} , \mathbf{t}_{(2)} , \dots , \mathbf{t}_{(d)} \} .$$

Vi har dermed

$$\mu = \mathbf{T}\boldsymbol{\beta} = \mathbf{t}_{(1)}\beta_1 + \mathbf{t}_{(2)}\beta_2 + \dots + \mathbf{t}_{(d)}\beta_d .$$

Det betyder at modellen kan opfattes som en lineær normal model specificeret ved $L = \text{col}(\mathbf{T}) = \textit{søjlerummet}$ for $\mathbf{T}$

Designmatricen

For lineære normale modeller har vi generelt

$$\hat{\mu} = P(\mathbf{x}) \quad \text{og} \quad \hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2,$$

hvor $P(\mathbf{x})$ er *projektionen* af $\mathbf{x}$ ned L . Projektionen kan udtrykkes ved hjælp af designmatricen: $P = \mathbf{T}(\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^*$.

I multipel regression gælder derfor

$$\hat{\mu} = \mathbf{T}(\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x} \quad \text{og} \quad \hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - \mathbf{T}(\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x}\|^2.$$

Maksimum likelihood estimat for β

Maksimum likelihood estimatet for β findes ved opskrive likelihoodfunktionen:

$$\begin{aligned} L(\beta, \sigma^2) &= L(\beta_1, \beta_2, \dots, \beta_d, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mathbf{t}_i^* \beta)^2} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mathbf{t}_i^* \beta)^2} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \mathbf{T}\beta\|^2}. \end{aligned}$$

Der gælder at

$$\|\mathbf{x} - \mathbf{T}\beta\|^2 = \|\mathbf{T}(\beta - \hat{\beta})\|^2 + k,$$

hvor $k \in \mathbb{R}$ ikke afhænger af β og

$$\hat{\beta} \stackrel{\text{def}}{=} (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x}$$

Vi ser dermed at $\hat{\beta}$ er maksimum likelihood esimtatet for β .

Designmatricer for lineære normale modeller

Eksempler på designmatricer for forskellige modeller findes ved hjælp af afsnit 5.1:

- Én observationsrække kan specificeres ved $\mathbf{T} = \mathbf{1}$, hvor $\mathbf{1}$ blev defineret i Eksempel 5.1.
- To observationsrækker kan specificeres ved $\mathbf{T} = \{\mathbf{1}_1 \quad \mathbf{1}_2\}$ hvor $\mathbf{1}_1$ og $\mathbf{1}_2$ blev defineret i Eksempel 5.3
- k observationsrækker kan specificeres ved $\mathbf{T} = \{\mathbf{1}_1 \quad \mathbf{1}_2 \quad \dots \quad \mathbf{1}_k\}$ hvor $\mathbf{1}_i$ erne blev defineret i Eksempel 5.4
- Simpel lineær regression kan specificeres ved $\mathbf{T} = \{\mathbf{1} \quad \mathbf{t}\}$ hvor $\mathbf{t}$ blev defineret i Eksempel 5.6

Designmatricer er *ikke* unikke: Forskellige designmatricer kan svare til *forskellige parametriseringer* af *samme model*.

Designmatricen

Modellen for to observationsrækker, hvor x_{ij} er udfald af

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.}$$

svarer f.eks. til designmatricerne $\mathbf{T}$ og $\tilde{\mathbf{T}}$

$$\mathbf{T} = \{\mathbf{1}_1 \quad \mathbf{1}_2\} = \begin{Bmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 0 & 1 \\ \vdots & \vdots \\ 0 & 1 \end{Bmatrix} \quad \tilde{\mathbf{T}} = \{\mathbf{1} \quad \mathbf{1}_2\} = \begin{Bmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{Bmatrix} \quad \left. \begin{array}{l} \left. \begin{array}{l} \vdots \\ \vdots \end{array} \right\} n_1 \text{ gange} \\ \left. \begin{array}{l} \vdots \\ \vdots \end{array} \right\} n_2 \text{ gange} \end{array} \right\}$$

Vi ser at $\mathbf{T}$ svarer til parametriseringen hvor $\beta_1 = \mu_1$ og $\beta_2 = \mu_2$,
og $\tilde{\mathbf{T}}$ svarer til parametriseringen hvor $\beta_1 = \mu_1$ og $\beta_2 = \mu_2 - \mu_1$.

Dette svarer til at:

$$\hat{\beta} = (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x} = \begin{Bmatrix} \frac{1}{n_1} & 0 \\ 0 & \frac{1}{n_2} \end{Bmatrix} \begin{pmatrix} x_{1\cdot} \\ x_{2\cdot} \end{pmatrix} = \begin{pmatrix} \bar{x}_{1\cdot} \\ \bar{x}_{2\cdot} \end{pmatrix},$$

$$\hat{\tilde{\beta}} = (\tilde{\mathbf{T}}^* \tilde{\mathbf{T}})^{-1} \tilde{\mathbf{T}}^* \mathbf{x} = \begin{Bmatrix} \frac{1}{n_1} & -\frac{1}{n_1} \\ -\frac{1}{n_1} & \frac{1}{n_1} + \frac{1}{n_2} \end{Bmatrix} \begin{pmatrix} x_{1\cdot} + x_{2\cdot} \\ x_{2\cdot} \end{pmatrix} = \begin{pmatrix} \bar{x}_{1\cdot} \\ \bar{x}_{2\cdot} - \bar{x}_{1\cdot} \end{pmatrix}.$$

Designmatricen i R

Designmatricen kan findes ved hjælp af `model.matrix`.
Vi betragter Eksempel 1.5.

```
grp30 <- c(3,5,5,7,9,9,10,12,20,24,24,34,43,46,58,140)
grp60 <- c(2,5,5,7,8,9,14,18,24,26,26,34,37,42,90)
loggrp30 <- log(grp30)
loggrp60 <- log(grp60)
gruppe = rep(c("loggrp30", "loggrp60"), c(16,15))
flies = data.frame(reac = c(loggrp30, loggrp60), gruppe = gruppe)
lmfit = lm(reac~1+gruppe, data=flies)
```

Køres `model.matrix(lmfit)` fås

	(Intercept)	gruppeloggrp60
1	1	0
2	1	0
⋮		
15	1	0
16	1	0
17	1	1
18	1	1
⋮		
30	1	1
31	1	1

hvilket svarer til $\tilde{T}$.

Fittes modellen uden intercept ledet:

```
lmfit = lm(reac~0+gruppe,data=flies)
```

bliver output af **model.matrix**(lmfit)

```
(Intercept)  gruppeloggrp60
1           1             0
2           1             0
⋮
15          1             0
16          1             0
17          0             1
18          0             1
⋮
30          0             1
31          0             1
```

hvilket svarer til **T**.

Designmatricen i R

Estimaterne i Eksempel 1.5 fandtes i Tabel 3.1 til

Kontaktid	Middelværdi μ	Varians σ^2
30 sekunder	2.8072	1.064638
60 sekunder	2.7154	

Dette passer med at

```
summary(lm(reac~1+gruppe, data=flies))
```

er

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	2.80722	0.25793	10.883	9.35e-12	***
gruppeloggrp60	-0.09168	0.37080	-0.247	0.806	

mens output af

```
summary(lm(reac~0+gruppe, data=flies))
```

er

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
gruppeloggrp30	2.8072	0.2579	10.88	9.35e-12	***
gruppeloggrp60	2.7155	0.2664	10.19	4.26e-11	***

Designmatricen i R

model.matrix kan også køres med en modelformel som input, og det er ikke nødvendigt at angive nogen responsvariabel i denne.

```
fac1 <- factor(c("A", "A", "B", "B", "B"))  
model.matrix(~fac1)
```

giver output

```
(Intercept)  facB  
1           1     0  
2           1     0  
3           1     1  
4           1     1  
5           1     1
```

```
model.matrix(~0+fac1)
```

giver output

```
fac1A fac1B  
1     1     0  
2     1     0  
3     0     1  
4     0     1  
5     0     1
```

Designmatricen i R

Følgende eksempler viser designmatricen, når vi inkluderer kontinuerte variable:

```
bt = c(1.1, 2.0, 3.2, 4.5, 5.0)
model.matrix(~bt)
```

```
      (Intercept)  bt
1             1  1.1
2             1  2.0
3             1  3.2
4             1  4.5
5             1  5.0
```

```
bt1 = c(0.0, 1.0, 3.2, 4.5, 5.0)
bt2 = c(3.1, 3.0, 2.6, 5.0, 5.0)
model.matrix(~bt1 + bt2 + exp(bt1))
```

```
      (Intercept)  bt1  bt2    exp(bt1)
1             1  0.0  3.1    1.000000
2             1  1.0  3.0    2.718282
3             1  3.2  2.6   24.532530
4             1  4.5  5.0   90.017131
5             1  5.0  5.0  148.413159
```

Som det fremgår tilføjes der en søjle for hver forklarende variabel.

Når en faktor indgår i modelformlen, vil der som udgangspunkt tilføjes et antal søjler svarende til antallet niveauer. Dog skal designmatricen stadig have fuld rang.

Designmatricen i R

I følgende eksempel introduceres en ny faktor og vi angiver modelformlen for additivitetsmodellen i tosidet variansanalyse:

```
fac1 <- factor(c("A", "A", "B", "B", "B"))  
fac2 <- factor(c("C", "C", "C", "D", "D"))  
model.matrix(~fac1+fac2)
```

Designmatricen bliver da

	(Intercept)	fac1B	fac2D
1	1	0	0
2	1	0	0
3	1	1	0
4	1	1	1
5	1	1	1

Designmatricen i R

Sidste eksempel på en designmatrix er fra gruppespecifik regression:

```
fac1 <- factor(c("A","A","B","B","C"))
bt = c(1.1,2.0,3.2,4.5,5.0)
model.matrix(~fac1 + bt + fac1:bt)
```

Dette giver output

	(Intercept)	fac1B	fac1C	bt	fac1B:bt	fac1C:bt
1	1	0	0	1.1	0.0	0
2	1	0	0	2.0	0.0	0
3	1	1	0	3.2	3.2	0
4	1	1	0	4.5	4.5	0
5	1	0	1	5.0	0.0	5

Bemærk at leddet `fac1:bt` giver en ny søjle i designmatricen, for hvert niveau af `fac`, med undtagelse af referenceniveauet.

Fordelingsresultater i multipel regression

Hvis vi betragter estimatoren svarende til

$$s^2 = \frac{1}{n-d} \|\mathbf{x} - \mathbf{T}\hat{\beta}\|^2,$$

så gælder der

$$s^2 \sim \sigma^2 \chi^2(n-d)/(n-d),$$

Hvis vi betragter estimatoren svarende til

$$s^2 = \frac{1}{n-d} \|\mathbf{x} - \mathbf{T}\hat{\beta}\|^2,$$

så vil

$$s^2 \sim \sigma^2 \chi^2(n-d)/(n-d),$$

og hvis vi betragter estimatoren svarende til $\hat{\beta}$, så vil

$$\hat{\beta} \sim N_d(\beta, \sigma^2(\mathbf{T}^* \mathbf{T})^{-1}),$$

hvilket betyder at $\hat{\beta}$ er d -dimensionalt normalfordelt med middelværdivektor β og kovariansmatrix $\sigma^2(\mathbf{T}^* \mathbf{T})^{-1}$.

fordelingsresultater i multipel regression

En stokastisk vektor $\mathbf{X} = (X_1, \dots, X_p)^*$ siges at være *p-dimensional normalfordelt*, hvis det for enhver vektor $\mathbf{a} = (a_1, \dots, a_p) \in \mathbb{R}^p$ gælder, at

$$\mathbf{a} \cdot \mathbf{X} = a_1 X_1 + a_2 X_2 + \dots + a_p X_p$$

er normalfordelt.

Hvis $X_1, \dots, X_p$ er uafhængige stokastiske variable med $X_i \sim N(\mu_i, \sigma_i^2)$, vil der gælde, at

$$\begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix} = \mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \text{ hvor } \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{pmatrix} \text{ og } \boldsymbol{\Sigma} = \begin{Bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_p^2 \end{Bmatrix}.$$

Specielt gælder at hvis $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_n^2 = \sigma^2$ så er $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_p)$, hvor $\mathbf{I}_p$ er den $p \times p$ -dimensionale identitetsmatrix.

Fordelingsresultater i multipel regression

Føromtalte resultater følger af fordelingsresultater:

Proposition

Lad $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\mathbf{B}$ en $k \times p$ matriks og $\boldsymbol{\eta} \in \mathbb{R}^k$, da er

$$\mathbf{Y} = \boldsymbol{\eta} + \mathbf{B}\mathbf{X} \sim N_k(\boldsymbol{\eta} + \mathbf{B}\boldsymbol{\mu}, \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}^*).$$

Proposition

Hvis $\mathbf{Y}$ er $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ fordelt og $\mathbf{B}$ er en $k \times p$ matriks og $\mathbf{C}$ er en $m \times p$ matrix, så er $\mathbf{B}\mathbf{Y}$ og $\mathbf{C}\mathbf{Y}$ uafhængige, hvis og kun hvis $\mathbf{B}\boldsymbol{\Sigma}\mathbf{C}^* = \mathbf{0}$.

Specielt gælder, at hvis $\boldsymbol{\Sigma} = \sigma^2 \mathbf{I}_p$ med $\sigma^2 > 0$ vil $\mathbf{B}\mathbf{X}$ og $\mathbf{C}\mathbf{X}$ være uafhængige hvis og kun hvis $\mathbf{B}\mathbf{C}^* = \mathbf{0}$.

Proposition

Antag $\mathbf{Y} \sim N_p(\mathbf{0}, \sigma^2 \mathbf{I}_p)$ og at $\mathbf{B}$ er en $p \times p$ matrix som opfylder $\mathbf{B}^2 = \mathbf{B}$ (idempotent) og $\mathbf{B}^* = \mathbf{B}$ (symmetrisk). Så gælder det, at

$$\|\mathbf{B}\mathbf{Y}\|^2 \sim \sigma^2 \chi^2(k)$$

hvor k er rangen af $\mathbf{B}$.

fordelingsresultater i multipel regression

Det følger af

$$\hat{\beta} \sim N_d(\beta, \sigma^2(\mathbf{T}^* \mathbf{T})^{-1}),$$

af

$$\hat{\beta}_j \sim N(\beta_j, \sigma^2 c^{jj}). \quad (1)$$

hvor c^{jj} er den j -te diagonalindgang i $(\mathbf{T}^* \mathbf{T})^{-1}$.

Da s^2 er uafhængig af $\hat{\beta}$ gælder under $H : \beta_j = 0$ at

$$t_j = \frac{\hat{\beta}_j}{\sqrt{s^2 c^{jj}}} \sim t(n-d), \quad (2)$$

Derudover findes spredningen på estimatet,

$$\text{std error}(\hat{\beta}_j) = \sqrt{s^2 c^{jj}}, \quad (3)$$

og testsandsynligheden for $H : \beta_j = 0$

$$p_{obs} = 2 (1 - F_{t(n-d)}(|t_j|)), \quad (4)$$

hvor $F_{t(n-d)}$ betegner fordelingsfunktionen for t fordelingen med $n-d$ frihedsgrader.

Estimaterne svarende til (1),(2),(3), og (4) er netop, hvad **R** udskriver, når parametertabellen beregnes ved hjælp af **summary**.

Multiple R-squared

I udskriften fra **summary** findes **Multiple R-squared** og **Adjusted R-squared**. Disse kan findes ved at tage udgangspunkt i en multipel regressionsmodel, og denne betragte undermodellen, hvor alle observationer har samme middelværdi.

I denne har vi dekompositionen af den total variation SSD_T :

$$SSD_T = SSD_E + SSD_H,$$

i den del af variationen der forklares af hypotesen (SSD_H) der er forklaret af modellen og uforklaret variation (SSD_E):

$$SSD_E = \sum_{i=1}^n (x_i - \hat{x}_i)^2 \quad \text{og} \quad SSD_H = \sum_{i=1}^n (\hat{x}_i - \bar{x})^2.$$

Vi har da:

$$R^2 = \frac{SSD_H}{SSD_T} = 1 - \frac{SSD_E}{SSD_T} \quad \text{og} \quad R_{adj}^2 = 1 - \frac{\frac{SSD_E}{n-d}}{\frac{SSD_T}{n-1}}.$$

Når der kun er én forklarende variabel er R^2 lig kvadratet på den empiriske korrelationskoefficient mellem responsvariablen og den forklarende variabel.