

Matematisk Statistik

Grundbegreber indenfor statistisk analyse

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Modelopstilling og modelkontrol

Vi betragter et datasæt $\mathbf{x}$, der opfattes som en realisation af en stokastisk vektor $\mathbf{X}$.

- $\mathbf{x} \in \mathcal{X}$ hvor $\mathcal{X}$ kaldes *udfaldsrummet* - i praksis $\mathbb{N}^n/\mathbb{Z}^n$ eller $\mathbb{R}_+^n/\mathbb{R}^n$.
- Fordeling af $\mathbf{X}$ beskrives ved CDF F eller PMF/PDF f .

Statistisk model i praksis: En parametriseret klasse af fordelingsfunktioner, $\mathcal{F} = \{F_\theta | \theta \in \Theta\}$, eller en parametriseret klasse af tætheder $\{f(\cdot; \theta) | \theta \in \Theta\}$, hvor Θ kaldes parametermængden. Parameteren θ er en vektor, $\theta = (\theta_1, \dots, \theta_k)^*$.

Funktionen

$$\begin{aligned}\mathcal{X} \times \Theta &\rightarrow \mathbb{R} \\ (\mathbf{x}, \theta) &\mapsto f(\mathbf{x}; \theta)\end{aligned}$$

kaldes for *modelfunktionen*. Modelfunktionen er tætheden som funktion af både udfaldet $\mathbf{x}$ og parameteren θ .

Modelopstilling og modelkontrol

De indledende skridt i analysen af data er

- Modelopstilling (primært et spørgsmål om at identificere en relevant fordelingsklasse).
- Modelkontrol (indledningsvist grafisk: histogrammer, fraktildiagrammer, scatterplots).

Modelkontrollen er ikke nødvendigvis begrænset til kun at finde sted indledningsvist.

Statistisk inferens

Efter valget af statistisk model ønsker vi at formulere udsagn om parameteren θ - og dermed om det faglige problem - på baggrund af data $\mathbf{x}$.

Først ønskes et bud på θ :

$$\begin{aligned}\tilde{\theta} : \mathcal{X} &\rightarrow \Theta \\ \mathbf{x} &\mapsto \tilde{\theta}(\mathbf{x}),\end{aligned}\tag{1}$$

der til data $\mathbf{x}$ tilordner en bestemt parameter værdi $\tilde{\theta}(\mathbf{x})$.

Terminologi:

- $\theta \leftarrow \tilde{\theta} = \tilde{\theta}(\mathbf{x})$ et *estimat*.
- $\tilde{\theta}(\mathbf{X})$ en *estimator*.

Estimatorer har egenskaber som *bias*, *MSE* etc.

Estimer er “bare” tal.

En normalfordelt observationsrække - en normalfordelt stikprøve

Supp. §2

Middelværdi og varians ukendt.

- $x_1, \dots, x_n$ realisationer af *uafhængige og identisk fordelte* stokastiske variable $X_1, \dots, X_n$.
- $X_i \sim N(\mu, \sigma^2)$ $i = 1, \dots, n$
- $\mathcal{X} = \mathbb{R}^n$
- $\theta = (\mu, \sigma^2)$ $\Theta = \mathbb{R} \times \mathbb{R}_+$

Varians kendt $\sigma^2 = \sigma_0^2$, middelværdi ukendt.

- $\theta = \mu$ $\Theta = \mathbb{R}$

Estimator for middelværdi:

$$\bar{X}_{\cdot} = \frac{1}{n} \sum_{i=1}^n X_i,$$

Estimatorer for varians:

$$\hat{\sigma}^2 = \hat{\sigma}^2(\mathbf{X}) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_{\cdot})^2 \quad \text{eller} \quad s^2 = s^2(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_{\cdot})^2.$$

En metode til at udlede estimatorer når vi står med en stikprøve er den såkaldte *moment metode*. Her finder vi først funktioner

$$\begin{aligned}\mathbb{E}_{\theta}[X] &= g_1(\theta_1, \dots, \theta_k) \\ \mathbb{E}_{\theta}[X^2] &= g_2(\theta_1, \dots, \theta_k) \\ &\vdots \\ \mathbb{E}_{\theta}[X^k] &= g_k(\theta_1, \dots, \theta_k)\end{aligned}$$

og sætter disse lig de tilsvarende *empiriske* momenter

$$M_j = \frac{1}{n} \sum_{i=1}^n X_i^j \quad j = 1, \dots, k,$$

og løses for $\theta_1, \dots, \theta_k$.

- $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d}}{\sim} \text{Unif}[0, \beta]: \hat{\beta}^m = 2\bar{X}.$
- $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d}}{\sim} E(\lambda): \hat{\lambda}^m = 1/\bar{X}.$
- $X_1, X_2, \dots, X_n$ i.i.d hvor X_i har pdf $f(x; \lambda, \delta) = \lambda e^{-\lambda(x-\delta)}, x > \delta :$
 $1/\lambda = \sqrt{m_2 - \bar{X}^2}$ og $\delta = \bar{X} - \sqrt{m_2 - \bar{X}^2}$ hvor $m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$

Vi ønsker at undersøge om data kan en simplere statistisk model, end den først opstillede og betragter derfor for $\Theta_0 \subset \Theta$ *hypotesen*:

$$H_0 : \theta \in \Theta_0 .$$

Hvis $\Theta_0 = \{\theta_0\}$ kaldes hypotesen *simpel* og ellers *sammensat*.

Vi ønsker på baggrund af data $\mathbf{x}$ at afgøre om vi kan forkaste H_0 og et *test* er derfor en partition af $\mathcal{X}$ i

$$R = \{\mathbf{x} \in \mathcal{X} : H_0 \text{ forkastes på grundlag af } \mathbf{x}\}$$

$$A = \{\mathbf{x} \in \mathcal{X} : H_0 \text{ forkastes ikke på grundlag af } \mathbf{x}\} .$$

Ofte fås denne opdeling som urbillede af en funktion $T : \mathcal{X} \mapsto \mathbb{R}$, hvorom der gælder at $\mathcal{T} \stackrel{\text{def}}{=} T(\mathcal{X}) = \mathcal{T}_R \cup \mathcal{T}_A$ og

$$R = T^{-1}(\mathcal{T}_R) = \{\mathbf{x} \in \mathcal{X} : T(\mathbf{x}) \in \mathcal{T}_R\}$$

$$A = T^{-1}(\mathcal{T}_A) = \{\mathbf{x} \in \mathcal{X} : T(\mathbf{x}) \in \mathcal{T}_A\} ,$$

Testteori

I denne situation betegnes $T = T(\mathbf{X})$ som en *testor* af H_0 og $T(\mathbf{x})$ omtales som *teststørrelsen*.

I praksis er T et (relativt) mål for, hvor kritisk $\mathbf{x}$ er for H_0 i den forstand at vi kan sige at $\mathbf{x}_1$ er ligeså eller mere kritisk for H_0 end $\mathbf{x}_2$ hvis

$$T(\mathbf{x}_1) \geq T(\mathbf{x}_2),$$

(eller omvendt). Mængden $\{\mathbf{y} \in \mathcal{X} \mid T(\mathbf{y}) \geq T(\mathbf{x})\}$ er da alle de udfald, som er mere kritiske for H_0 end $\mathbf{x}$.

Hvis vi betragter en simpel hypotese $H: \theta = \theta_0$ kan vi i dette tilfælde angive sandsynligheden for denne mængde under antagelse af at hypotesen er sand som

$$p_{\text{obs}}(\mathbf{x}) = \mathbb{P}_{\theta_0}(\{\mathbf{y} \in \mathcal{X} \mid T(\mathbf{y}) \geq T(\mathbf{x})\}) = \mathbb{P}_{\theta_0}(T(\mathbf{X}) \geq T(\mathbf{x})).$$

Bemærk at $p_{\text{obs}}(\mathbf{x})$ afhænger af data $\mathbf{x}$ og vi kan derfor betragte den stokastiske variabel $p_{\text{obs}}(\mathbf{X})$. Under relativt svage betingelser gælder at $p_{\text{obs}}(\mathbf{X}) \sim U(0, 1)$ når hypotesen er sand.

- Hvis $X_1, \dots, X_n$ er uafhængige og identisk fordelte $X_i \sim N(\mu, \sigma_0^2)$, så er $|u(\mathbf{X})|$, hvor

$$u(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{\sigma_0^2/n}}$$

en testor for hypotesen $H_0 : \mu = \mu_0$.

- Hvis variansen er ukendt er $|t(\mathbf{X})|$ en testor for H_0 , hvor


$$t(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{s^2(\mathbf{X})/n}}.$$

Målet i likelihood inferens er at finde en generel metodik til at finde estimatorer og testorer. Udgangspunktet er *likelihoodfunktionen*. Likelihoodfunktionen er modelfunktionen betragtet som funktion af θ .

$$L(\theta) = f(\mathbf{x}; \theta) \quad \theta \in \Theta, \quad (2)$$

Motivationen er fortolkningen (i rette forstand) af modelfunktionen som sandsynligheden for at observere $\mathbf{x}$ når parameteren er θ .

Figure 6.2 Estimate of area under curve by rectangle.



Likelihoodfunktionen

- fortolkes som graden af *trolighed* af parameteren θ i lyset af data $\mathbf{x}$.
- laver en ordning i parametermængden Θ i den forstand at hvis $L(\theta_1) > L(\theta_2)$ så tror vi mere på θ_1 end θ_2 i lyset af data $\mathbf{x}$.

Idé: Vælg θ til at være den *mest* trolige værdi:

$$L(\hat{\theta}) > L(\theta) \quad \text{for alle } \theta \in \Theta \text{ således at } \theta \neq \hat{\theta},$$

(underforstået at denne eksisterer). Dette er *maksimum likelihood estimation*. Vi skriver:

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} L(\theta).$$

Dette er maksimum likelihood estimatet (MLE). Bemærk at $\hat{\theta}$ kan opfattes som en funktion af $\mathbf{x}$, dvs. $\hat{\theta} = \hat{\theta}(\mathbf{x})$.

Bemærkninger:

- Ofte lettere at betragte log likelihood funktionen

$$l(\theta) = \ln L(\theta) \quad \theta \in \Theta.$$

- MLE kan findes ved at løse

$$\frac{\partial l}{\partial \theta_j}(\theta) = 0, \quad j = 1, 2, \dots, k. \quad (3)$$

(enten eksakt eller numerisk) og undersøge om der er tale om et maksimum.

- Den afledte af log likelihood funktionen betegnes *score funktionen*.
- Hvis data udgør en stikprøve vil L og l splitte op:

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

og

$$l(\theta) = \sum_{i=1}^n \ln f(x_i; \theta).$$

$L(\hat{\theta}(\mathbf{x}))$, fortolkes som maksimale sandsynlighed for data $\mathbf{x}$ i den givne statistiske model. For en hypotese $H : \theta \in \Theta_0$ kan vi lade $\hat{\theta}_0(\mathbf{x})$ betegne maksimum likelihood estimatet for θ under H_0 og betragter *Likelihood ratio teststørrelsen* $Q(\mathbf{x})$:

$$Q(\mathbf{x}) = \frac{\max_{\theta \in \Theta_0} L(\theta)}{\max_{\theta \in \Theta} L(\theta)} = \frac{L(\hat{\theta}_0(\mathbf{x}))}{L(\hat{\theta}(\mathbf{x}))}. \quad (4)$$

Fortolkningen af denne er at $\mathbf{x}$ er kritisk for H_0 hvis $Q(\mathbf{x})$ er lille og at $\mathbf{x}_1$ er mere (eller lige så) kritisk for H_0 som $\mathbf{x}_2$, hvis

$$Q(\mathbf{x}_1) \leq Q(\mathbf{x}_2).$$

Hvis $\Theta = \{\theta_0\}$ kan testsandsynligheden beregnes som

$$p_{obs}(\mathbf{x}) = P_{\theta_0}(\{\mathbf{y} \in \mathcal{X} : Q(\mathbf{y}) \leq Q(\mathbf{x})\}) = P_{\theta_0}(Q(\mathbf{X}) \leq Q(\mathbf{x})). \quad (5)$$

Hvis hypotesen er sammensat beregnes p-værdien som

$$p_{obs}(\mathbf{x}) = \sup_{\theta \in \Theta_0} \mathbb{P}_{\theta}(Q(\mathbf{X}) \leq Q(\mathbf{x})).$$

Hvis p_{obs} er lille forkastes H_0 . Hvad der er “lille”?

Specificeres af *signifikansniveauet* α , som er den værdi ved hvilken vi vælger at forkaste H_0 , d.v.s. vi forkaster H_0 hvis $p_{obs}(\mathbf{x}) \leq \alpha$.

Ofte vælge $\alpha = 0.05$.

- Proposition 6.1 / 6.1.1 i MSRR, Example 8.10 i IPSR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p) = \text{Binomial}(1, p)$

$$\hat{p} = \frac{X}{n} \quad \text{hvor } X = \sum_{i=1}^n X_i$$

- Example 6.2 i MSRR, Example 8.10 i IPSR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} E(\lambda)$

$$\hat{\lambda} = \frac{1}{\bar{X}}$$

- Example 6.4 i MSRR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} U[0, \beta]$

$$\hat{\beta} = X_{(n)}$$

- Example 6.56 i MSRR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} U(0, \beta)$

$\hat{\beta}$ eksisterer ikke.

● Example 6.7 i MSRR

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Cauchy}(\theta)$
fælles tæthed :

$$f(x; \theta) = \frac{1}{\pi(1 + (x - \theta)^2)}$$

Likelihood:

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\pi(1 + (x_i - \theta)^2)}$$

Log likelihood:

$$\ell(\theta; x_1, \dots, x_n) = -n \log \pi - \sum_{i=1}^n \log(1 + (x_i - \theta)^2)$$

Maximeres numerisk

Afsnit 2.3.3 i Supp.

Example 8.26 i [Chihara and Hesterberg(2022)]

Example 8.24 i [Chihara and Hesterberg(2018)]

En stikprøve $x_1, \dots, x_n$ fra normal fordelingen, d.v.s. x_i -erne er udfald af $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$

$$L(\mu, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2},$$

og log likelihood funktionen er

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Vi finder

$$\hat{\mu} = \bar{x} \stackrel{\text{def}}{=} \frac{1}{n} \sum_{i=1}^n x_i$$

Vi finder derved

$$\ell(\mu, \sigma^2) \leq \ell(\bar{x}, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Dette maksimeres med hensyn til σ^2 og vi finder

$$\hat{\sigma}^2 = \hat{\sigma}^2(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Samlet:

$$(\hat{\mu}, \hat{\sigma}^2) = \left(\bar{x}, \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right).$$

Likelihood test for $H : \mu = \mu_0$.

Likelihood ratio teststørrelsen

$$Q(\mathbf{x}) \stackrel{\text{def}}{=} \frac{\max_{\sigma^2 \in \mathbb{R}_+} L(\mu_0, \sigma^2)}{\max_{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+} L(\mu, \sigma^2)} = \frac{L\left(\mu_0, \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2\right)}{L(\bar{x}, \hat{\sigma}^2)},$$

og vi finder

$$Q(\mathbf{x}) = \left[\frac{1}{1 + \frac{t^2(\mathbf{x})}{n-1}} \right]^{\frac{n}{2}} \quad \text{hvor} \quad t(\mathbf{x}) = \frac{\bar{x} - \mu_0}{\sqrt{\frac{s^2(\mathbf{x})}{n}}}.$$

Vi ser at likelihood ratio testet er *ækvivalent* med t -testet, i den forstand at

$$p_{\text{obs}}(\mathbf{x}) = \sup_{\theta \in \Theta_0} P_{\theta}(Q(\mathbf{X}) \leq Q(\mathbf{x})) = P_{\mu_0}(|t(\mathbf{X})| \geq |t(\mathbf{x})|)$$

Estimatorernes egenskaber

- Bias
- Efficiens
- MSE (mean square error)
- konsistens
- omparametrisering, Jensens ulighed
- Asymptotisk normalitet af ML estimatorer

For nemheds skyld betragter vi en en-dimensional parameter θ .

Bias for en estimator $\hat{\theta} = \hat{\theta}(\mathbf{X})$ er givet ved

$$\text{Bias}[\hat{\theta}] = E_{\theta}[\hat{\theta}] - \theta$$

Unbiased (eller *Middelværdiret*, *central*) estimator: $E_{\theta}[\hat{\theta}] = \theta$ d.v.s.

$\text{Bias}[\hat{\theta}] = 0$ for alle $\theta \in \Theta$.

Eksempler

- (Proposition 6.3/6.3.1 i MSRR) $X_1, X_2, \dots, X_n \sim \text{Bern}(p)$ så er $\mathbb{E}[\hat{p}] = p$, hvor $\hat{p} = \bar{X}$.
- Hvis $X_1, \dots, X_n$ er en i.i.d. følge med $\text{Var}[X_i] = \sigma^2 < \infty$. Så er *stikprøvevariansen/den empiriske varians*

$$s^2 = s^2(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

unbiased som estimator for σ^2 .

Bemærk at $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ er biased.

- For $X_1, \dots, X_n \stackrel{i.i.d}{\sim} U[0, \beta]$ er MLE for β lig $\hat{\beta} = X_{(n)}$. Der gælder at

$$\mathbb{E}[X_{(n)}] = \frac{n}{n+1} \beta,$$

så estimatoren er biased, men $\frac{n+1}{n} X_{(n)}$ er unbiased.

Limitations of Unbiasedness

(Afsnit 6.3.1.1 i [Chihara and Hesterberg(2018)])

Middelværdirethed/unbiasedness er “nice to have”, men ikke “need to have”.

- Det kan være umuligt at finde en unbiased estimator.
- Unbiased estimatorer kan “urimelige” (f.eks. unbiased estimator for p i en geometrisk fordeling).
- Unbiased estimation kan upraktisk (f.eks. for standardafvigelsen σ)
- Et krav om at en estimator kan være unbiased kan resultere i en høj MSE.

Asymptotisk middelværdiret estimator

(Afsnit 6.3.1.2 i [Chihara and Hesterberg(2018)])

Ofte afhænger bias for en estimator af antallet af observationer n , og hvis bias forsvinder når n går mod uendeligt siger vi at estimatoren er asymptotisk unbiased. (strengt taget, følgen af estimators)

Eksempler:

$$\lim_{n \rightarrow \infty} \mathbb{E}[\hat{\sigma}^2] = \lim_{n \rightarrow \infty} \frac{n-1}{n} \sigma^2 = \sigma^2.$$

MLE for β for en stikprøve fra $U[0, \beta]$ -fordelingen er $X_{(n)}$. Vi har

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_{(n)}] = \lim_{n \rightarrow \infty} \frac{n}{n+1} \beta = \beta.$$

Motivation

Tit findes mange middelværdirette estimatorer for den samme parameter — hvilken skal så foretrækkes?

Eksempel

Hvis X_1, X_2, X_3 er *i.i.d.* med middelværdi μ og varians σ^2 da er både

$$\bar{X} = \frac{1}{3}(X_1 + X_2 + X_3)$$

og

$$Y = \frac{1}{6}X_1 + \frac{1}{3}X_2 + \frac{1}{2}X_3$$

middelværdirette estimatorer for μ .

Men

$$\text{Var}(\bar{X}) = \frac{1}{3}\sigma^2 \quad \text{mens} \quad \text{Var}(Y) = \frac{7}{18}\sigma^2.$$

Definition

Hvis $\hat{\theta}_1$ og $\hat{\theta}_2$ begge er middelværdirette estimatorer til samme parameter θ , men $\mathbb{V}\text{ar}(\hat{\theta}_1) < \mathbb{V}\text{ar}(\hat{\theta}_2)$, så kaldes $\hat{\theta}_1$ for mere efficient end $\hat{\theta}_2$.

Den *relative efficiens* af middelværdirette estimatorer $\hat{\theta}_1$ og $\hat{\theta}_2$ defineres som

$$e(\hat{\theta}_1, \hat{\theta}_2) = \frac{\mathbb{V}\text{ar}[\hat{\theta}_1]}{\mathbb{V}\text{ar}[\hat{\theta}_2]}$$

Betragt igen $X_1, X_2, \dots, X_n \stackrel{i.i.d}{\sim} U[0, \beta]$. Hvilken af de to unbiased estimatorer $2\bar{X}$ og $\frac{n+1}{n}X_{(n)}$ er mest efficient?

Cramér-Rao ulighed

(Afsnit 6.3.2.1 i [Chihara and Hesterberg(2018)])

Lad $X_1, \dots, X_n$ betegne en stikprøve med n observationer. Ifølge Cramér-Rao uligheden under visse betingelser gælder at en unbiased estimator $\hat{\theta}$ for θ opfylder uligheden:

$$\mathbb{V}\text{ar}_{\theta}[\hat{\theta}] \geq \frac{1}{n\mathcal{I}(\theta)}.$$

Udtrykket i nævneren kaldes for *Fisher information*,

$$\mathcal{I}(\theta) := E \left[\left(\frac{\partial}{\partial \theta} \log(f(X; \theta)) \right)^2 \right].$$

Dette er variansen af score funktionen (fra MLE). Bemærk at der under svage antagelser gælder at

$$\mathcal{I}(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log(f(X; \theta)) \right].$$

Mean squared error kombinerer præcision og nøjagtighed i ét mål:
Mean square error af en estimator $\hat{\theta}$ er defineret som

$$\text{MSE}[\hat{\theta}] = \mathbb{E}_{\theta}[(\hat{\theta} - \theta)^2]$$

og vi har Proposition 6.3.3 i MSRR (Bias-variance decomposition)

$$\text{MSE}[\hat{\theta}] = \text{Var}[\hat{\theta}] + (\text{Bias } \hat{\theta})^2$$

Ex. 6.15 i MSRR : Estimatorer til p i binomialfordelingen

Der betragtes antal af success i n uafhængige Bernoulli eksperimenter, altså en stokastisk variabel $X \sim \text{Binom}(n, p)$, med n kendt og p ukendt. ML estimator til successraten:

$$\hat{p}_1 = \frac{X}{n}$$

$$\mathbb{E}[\hat{p}_1] = p, \quad \text{Var}[\hat{p}_1] = \frac{p(1-p)}{n} \Rightarrow \text{MSE}[\hat{p}_1] = \frac{p(1-p)}{n}$$

har stor MSE når p ligger i nærheden af 0.5. Alternativ estimator:

$$\hat{p}_2 = \frac{X+1}{n+2}$$

$$\mathbb{E}[\hat{p}_2] = \frac{np+1}{n+2}, \quad \text{Var}[\hat{p}_2] = \frac{np(1-p)}{(n+2)^2} \Rightarrow$$

$$\text{MSE}[\hat{p}_2] = \frac{np(1-p)}{(n+2)^2} + \left(\frac{np+1}{n+2} - p \right)^2 = \frac{np(1-p) + (1-2p)^2}{(n+2)^2}$$

Den nye estimator er biased, men har mindre MSE for mellemstore værdier af p , som ikke ligger tæt ved 0 eller 1.

Ex. 6.15, fortsat




Figure 6.6 Mean square error against p , $n = 16$.

Vi lader (som altid) n betegne antallet af observationer og betragter nu en følge af estimatorer $\{\hat{\theta}_n\}_{n=1}^{\infty}$ for parameteren θ . Vi siger følgen er konsistent hvis og kun hvis

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\theta}_n - \theta| < \epsilon) = 1$$

for alle $\epsilon > 0$.

Betingelsen er ækvivalent med $\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\theta}_n - \theta| \geq \epsilon) = 0$ og skrives

$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta.$$

Vi er sjældent interesseret i estimatorer, der ikke er konsistente.

Følgen er *konvergent i sandsynlighed*, se §7.2.5 i [Pishro-Nik(2014)].

Tilstrækkelige betingelser for konsistens

Proposition 6.5 i [Chihara and Hesterberg(2022)]

Proposition 6.3.4 i [Chihara and Hesterberg(2018)]

Lad $\hat{\theta}_n$ være en følge af estimatorer for θ , som opfylder

$$\lim_{n \rightarrow \infty} \mathbb{E}[\hat{\theta}_n] = \theta \quad \text{og} \quad \lim_{n \rightarrow \infty} \text{Var}[\hat{\theta}_n] = 0.$$

Så er $\{\hat{\theta}_n\}_{n=1}^{\infty}$ en konsistent følge af estimatorer for θ .

Eksempel 6.18: Cauchy-fordelingen

Lad $X_1, \dots, X_n$ være en stikprøve fra Cauchy-fordelingen, d.v.s fælles tæthed

$$f(x; \theta) = \frac{1}{\pi(1 + (x - \theta)^2)}$$

- $\bar{X}$ er *ikke* konsistent for θ .
- medianen er konsistent (illustreres ved simulation).

Markovs ulighed og Chebyshevs ulighed

(§6.2.2 i [Pishro-Nik(2014)], ikke pensum på ISS)

Markovs ulighed:

Lad X være en stokastisk variabel, $X \geq 0$, og lad $c > 0$. Så gælder

$$\mathbb{P}(X \geq c) \leq \frac{E[X]}{c}$$

Chebyshevs ulighed:

(Theorem A.11 i [Chihara and Hesterberg(2022)],

Theorem A.6.2 i [Chihara and Hesterberg(2018)])

Lad X være en stokastisk variabel med endelig middelværdi μ og endelig varians σ^2 . Så gælder for alle $k > 0$

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}$$

Et umiddelbart korollar er at $\bar{X}_n$ er konsistent for μ når både μ og σ^2 er endelige.

Transformation af middelværdirette estimators

Antag, at $\hat{\theta}$ er en god estimator for θ . Vi vil dog gerne estimere $g(\theta)$ for en given bijektiv funktion g . Er $g(\hat{\theta})$ også en god estimator? Svar:

- Hvis $\hat{\theta}$ er MLE for θ , så er $g(\hat{\theta})$ også MLE estimator for $g(\theta)$.
- Hvis $\hat{\theta}$ er en middelværdiret estimator for θ , så er $g(\hat{\theta})$ generelt *ikke* middelværdiret for $g(\theta)$.

Eksempel (MSRR, s. 163 / s. 166) For en stikprøve fra $U[0, \beta]$ har vi at momentmetoden for β var $\hat{\beta}^m = 2\bar{X}$. og denne er unbiased. Er $(\hat{\beta}^m)^2$ en unbiased estimator for β^2 ?

$$\begin{aligned}\mathbb{E}[(\hat{\beta}^m)^2] &= \mathbb{E}[(2\bar{X})^2] = 4 \mathbb{E}[\bar{X}^2] = 4(\text{Var}[\bar{X}] + \mathbb{E}[\bar{X}]^2) \\ &= 4 \left(\frac{\beta^2}{12n} + \left(\frac{\beta^2}{2} \right)^2 \right) = \beta^2 + \frac{\beta^2}{3n}\end{aligned}$$

Så der gælder altså at $\mathbb{E}[(\hat{\beta}^m)^2] > \beta^2$.

Transformation af middelværdirette estimerer, Jensens ulighed

Generelt har vi (en udgave af) *Jensens Ulighed* som siger:

Sætning

Lad g være en strengt konveks funktion og X en ikke degenereret stokastisk variabel. Så er

$$\mathbb{E} g(X) > g(\mathbb{E}[X])$$

Det følger at hvis $\hat{\theta}$ er en unbiased estimator for θ og hvis g er en strengt konveks funktion, så er

$$\mathbb{E}[g(\hat{\theta})] > g(\theta).$$

Asymptotisk normalitet af ML estimatorer

MSRR § 6.3.6, Supp § 6.7

Vi betragter som tidligere en stikprøve med n observationer, hvor vi tænker på at n vokser, og lader $\hat{\theta}_n$ betegne MLE for n observationer. Når visse betingelser er opfyldt, vil maksimum likelihood estimatorer være approksimativt normalfordelt:

$$\hat{\theta}_n \approx N\left(\theta, \frac{1}{n\mathcal{I}(\theta)}\right) \quad (\spadesuit)$$

hvor $\mathcal{I}(\theta)$ er Fisher informationen fra C-R uligheden

$$\mathcal{I}(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log(f(X; \theta)) \right)^2 \right] = -E \left[\left(\frac{\partial^2}{\partial^2 \theta} \log(f(X; \theta)) \right) \right].$$

Bemærk at $(\spadesuit)$ medfører at

$$n\mathcal{I}(\theta) (\hat{\theta}_n - \theta)^2 \approx \chi^2(1)$$

Approximativ likelihood teori Supp § 6.7

Ved at lave en anden ordens Taylor udviklinger af log likelihood funktionen om MLE fås approksimationen

$$l(\theta) - l(\hat{\theta}) \approx (\theta - \hat{\theta})l'(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^2 l''(\hat{\theta}) = \frac{1}{2}(\theta - \hat{\theta})^2 l''(\hat{\theta}).$$

Indfører vi nu $j(\theta; \mathbf{x}) = -l''(\theta; \mathbf{x})$ kan dette skrives som

$$l(\theta) - l(\hat{\theta}) \approx -\frac{1}{2}(\theta - \hat{\theta})^2 j(\theta; \mathbf{x})$$


Bemærk at $j(\theta; \mathbf{x})$ er den observerede udgave af $j(\theta; \mathbf{X})$ og at der for en stikprøve gælder at

$$\mathbb{E}_{\theta} j(\theta; \mathbf{X}) = n\mathcal{I}(\theta).$$

På grund af den asymptotiske normalitet af MLE virker det derfor ikke helt urimeligt at tro at

$$\begin{aligned} -2 \ln(Q(\mathbf{x})) &= -2 \ln\left(\frac{L(\theta)}{L(\hat{\theta})}\right) = \\ &-2(l(\theta) - l(\hat{\theta})) \approx (\theta - \hat{\theta})^2 j(\theta; \mathbf{x}) \approx n\mathcal{I}(\theta)(\theta - \hat{\theta})^2 \approx \chi^2(1) \end{aligned}$$

Figur 6.6



Den normerede log likelihood funktion $\bar{l}(\cdot) = l(\cdot) - l(\hat{\theta})$ og den approksimerende parabel $p(\cdot)$ svarende til observationen $x = 8$ i binomialmodellen med sandsynlighedsparameter θ og antalsparameter $n = 20$.

Bibliografi

 Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (2nd edition).
John Wiley & Sons, 2018.

 Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (3rd edition).
John Wiley & Sons, 2022.

 H. Pishro-Nik.

Introduction to Probability, Statistics, and Random Processes.
Kappa Research, LLC, 2014.
ISBN 9780990637202.

URL

https://books.google.dk/books?id=3yq_oQEACAAJ.