

Matematisk Statistik

Permutationstest

Lars Nørvang Andersen

Institut for Matematik
Aarhus Universitet

Hvad kan man stille op, hvis man ikke kan finde en god model for sit datasæt eller hvis man ikke kan udlede fordelingen for en testor?

I sådanne situationer kan *permutationstests* være en mulighed.

Vi husker vores indledende fortolkning af testorer som stikprøvefunktioner, der måler hvor kritisk et givet datasæt $\mathbf{x}$ er for en hypotese H_0 .

Introducerende eksempel

Løber mus, der får medicin langsommere igennem en labyrint?

Drug			Control		
30	25	20	18	21	22

Model:

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.}$$

hvor $n_1 = n_2 = 3$

Undersøge $H : \mu_1 = \mu_2$ mod $H_A : \mu_1 > \mu_2$.

T testor:

$$T(\mathbf{X}) = \frac{\bar{X}_{1\cdot} - \bar{X}_{2\cdot}}{\sqrt{s^2(\mathbf{X}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \underset{\sim}{\text{under } H_0 \mu} t(n_1 + n_2 - 2).$$

p -værdi i ensidet test

$$1 - F_{t(n_1+n_2-2)}(t(\mathbf{x}))$$

```
behandling = c(30,25,20)
kontrol = c(18,21,22)
t.test(behandling, kontrol, alt="greater")
```

```
data:  behandling and kontrol
t = 1.4924, df = 4, p-value = 0.1049
alternative hypothesis: true difference in means is greater than 0
```

Introducerende eksempel

Løber mus, der får medicin langsommere igennem en labyrint?

Drug			Control		
30	25	20	18	21	22

Differens i middelværdier:

$$25s - 20.33s = 4.67s$$

Hvis medicinen ingen effekt har, burde det være ligeså sandsynligt at vi havde observeret:

Drug			Control		
30	25	18	20	21	22

Her bliver differensen i middelværdi 3.33s.

Introducerende eksempel

Vi kan finde alle $\binom{6}{3} = 20$ kombinationer:

Table 3.1 All possible distributions of {30, 25, 20, 18, 21, 22} into two sets.

Drug						Control	$\bar{X}_D$	$\bar{X}_C$	Difference in means
18	20	21	22	25	30	19.67	25.67	-6.00	
18	20	22	21	25	30	20	25.33	-5.33	
18	20	25	21	22	30	21	24.33	-3.33	
18	20	30	21	22	25	22.67	22.67	0.00	
18	21	22	20	25	30	20.33	25	-4.67	
18	21	25	20	22	30	21.33	24	-2.67	
18	21	30	20	22	25	23	22.33	0.67	
18	22	25	20	21	30	21.67	23.67	-2.00	
18	22	30	20	21	25	23.33	22	1.33	
18	25	30	20	21	22	24.33	21	3.33	
20	21	22	18	25	30	21	24.33	-3.33	
20	21	25	18	22	30	22	23.33	-1.33	
20	21	30	18	22	25	23.67	21.67	2.00	
20	22	25	18	21	30	22.33	23	-0.67	
20	22	30	18	21	25	24	21.33	2.67	
20	25	30	18	21	22	25	20.33	4.67 *	
21	22	25	18	20	30	22.67	22.67	0.00	
21	22	30	18	20	25	24.33	21	3.33	
21	25	30	18	20	22	25.33	20	5.33 *	
22	25	30	18	20	21	25.67	19.67	6.00 *	

Rows where the difference in means exceeds the original value are highlighted.

Vi ser at 3 af de 20 muligheder har differens der er ligeså eller større end 4.67s hvilket her giver en p -værdi på $3/20 = 0.15$.

Beerwings -eksempel

I Beerwings -datasættet angives antal spiste hotwings sammen med køn (15 M/K). Vi ønsker at undersøge

$$H_0 : \mu_M - \mu_F = 0 \quad \text{versus} \quad H_A : \mu_M - \mu_F > 0$$

Table 3.2 Hot wings consumption.

Females					Males				
4	5	5	6	7	7	8	8	11	13
7	8	9	11	12	13	14	16	16	17
12	13	13	14	14	17	18	18	21	21

Vi betragter $\bar{X}_M - \bar{X}_F$ og har en observeret værdi på $t = 5.2$.

Idé: Hvis der ikke er forskel på de på to grupper vil enhver inddeling af observationerne være lige sandsynlig - f.eks.

Females					Males				
5	6	7	7	8	4	5	7	8	9
8	11	12	13	14	11	12	13	13	13
14	14	16	16	21	17	17	18	18	21

Her er differensen 0.93. Problem: Der er $\binom{30}{15} = 155\,117\,520$ kombinationer.

Løsning: Vælg et stort antal tilfældige inddelinger/kombinationer.
Lad t betegne testteststørrelsen $t = T(\mathbf{x})$.

- Generer N tilfældige inddelinger $\mathbf{X}_1^*, \mathbf{X}_2^*, \dots, \mathbf{X}_N^*$ af datasættet $\mathbf{x}$.
- Beregn

$$p = p_{\text{stor}} = \frac{1}{N+1} \left(1 + \sum_{i=1}^N \mathbb{1}(T(\mathbf{X}_i^*) \geq t) \right)$$

når store T betragtes som kritiske og

$$p = p_{\text{lille}} = \frac{1}{N+1} \left(1 + \sum_{i=1}^N \mathbb{1}(T(\mathbf{X}_i^*) \leq t) \right)$$

når små T betragtes som kritiske.

- Ved tosidet test beregnes p_{obs} som $p = 2 \min(p_{\text{lille}}, p_{\text{stor}})$

Implementation - Beerwings

Testoren er $T(\mathbf{x}) = \bar{x}_1. - \bar{x}_2.$

```
library(dplyr)
Beerwings %>% group_by(Gender) %>% summarize(mean(Hotwings))

tapply(Beerwings$Hotwings, Beerwings$Gender, mean)
observed <- 14.5333 - 9.3333

hotwings <- Beerwings$Hotwings
N <- 10^5 - 1 # number of times to repeat this process
result <- numeric(N) # space to save the random differences
for (i in 1:N)
{ # sample of size 15, from 1 to 30, without replacement
  index <- sample(30, size = 15, replace = FALSE)
  result[i] <- mean(hotwings[index]) - mean(hotwings[-index]) holder værdier af T
}

(sum(result >= observed) + 1)/(N + 1)
```


0.00091

Kaldet `sample(30, size = 15, replace = FALSE)` vælger 15 af tallene 1, 2, ..., 30 uden tilbagelægning.

Implementation - Beerwings

```
hist(result, xlab = "xbar1 - xbar2",  
      main = "Permutation Distribution for hot wings")  
abline(v = observed, col = "blue")
```

Permutation Distribution for hot wings



Alternativ implementation - Beerwings

```
# Alternativ implementation - benyt sample direkte på hotwings

hotwings = Beerwings$Hotwings
gender = factor(Beerwings$Gender)
result <- numeric(N) # space to save the random differences
for (i in 1:N) {
  gennemsnitMK = tapply(sample(hotwings), gender, mean)
  result[i] = gennemsnitMK[2] - gennemsnitMK[1]
}
```

Her bruges **sample** til at blande (“permutere”) observationerne i
hotwings

Implementation

- Valg af testor.
- Læg 1 til i tæller og nævner.
- Sample with replacement *blandt resamples/inddelinger*.
- Flere samples giver mere præcision.

Verizon eksempel

Er Verizon hurtigere til at reparere for egne kunder (ILEC) (gennemsnit 8.4 timer) end for andre kunder (CLEC) (gennemsnit 16.5 timer) ?




Figure 3.4 Distribution of repair times for Verizon (ILEC) and competitor (CLEC) customers. Note that the Y-axis scales are different.

Almindeligt (ensidet) t -test giver p -værdi på 0.03, men kan vi stole på det?

Verizon eksempel - implementation

```
Time <- subset(Verizon, select = Time, drop = TRUE)
Time.ILEC <- subset(Verizon, select = Time,
                    subset = Group == "ILEC", drop = TRUE)
Time.CLEC <- subset(Verizon, select = Time,
                    subset = Group == "CLEC", drop = TRUE)

# Observeret differens:
observed <- mean(Time.ILEC) - mean(Time.CLEC)

N <- 10^4 - 1
result <- numeric(N)
for (i in 1:N)
{
  index <- sample(1687, size = 1664, replace = FALSE)
  result[i] <- mean(Time[index]) - mean(Time[-index])
}


(sum(result <= observed) + 1)/(N + 1)
```

Der er 1664 ILEC kunder ud af 1687 i alt, derfor

```
index <- sample(1687, size = 1664, replace = FALSE) .
```

Verizon eksempel

Verizon eksemplet kan også bruges til at illustrere at permutationstest er fleksible mht. valg af testor:



Obs: Man må ikke “fiske” efter statistisk signifikans, ved at prøve at masse forskellige testorer af!

Navnet “Permutationstest” kommer fra at vi løst sagt antager at alle permutationer af datasættet er lige sandsynlige.

En *permutation* σ af $1, \dots, n$ er en bijektiv afbildning af $\{1, \dots, n\}$ på $\{1, \dots, n\}$ og for en stokastisk vektor $\mathbf{X} = (X_1, \dots, X_n)$ definerer vi

$$\mathbf{X}_\sigma = (X_{\sigma(1)}, X_{\sigma(2)}, \dots, X_{\sigma(n)})$$

og under antagelsen er at $\mathbf{X}_\sigma \sim \mathbf{X}$.

Table 3.3 Partial view of Beerwings data set.

Gender		Hot wings	Gender		Hot wings
1	F	4	11	F	9
2	F	5	26	F	17
3	F	5	25	F	17
4	F	6	2	F	5
5	F	7	4	F	6
6	F	7	8	F	8
7	M	7	3	M	5
8	F	8	20	F	14
9	M	8	10	M	8
10	M	8	18	M	13
$\vdots$			$\vdots$		

The Gender column is held fixed and the rows of the Hotwings variable are permuted. The first column indicates which rows of the hot wing values were permuted.

Vi kan bruge denne fortolkning og ændre implementation af eksemplerne, så vi direkte samler en permutation og bruger denne til at simulere et udfald af vores testor.

Vi kan også belyse hvornår permutationstestet ikke fungerer - f.eks. vil det ikke fungere i en situation hvor vi har to meget ubalancerede observationsrækker med forskellig varians

$$X_{ij} \sim N(0, \sigma_i^2) \quad i = 1, 2 \quad j = 1, \dots, n_i$$

hvor $\sigma_1^2 = 10^6$, $\sigma_2^2 = 1$, $n_1 = 10^2$ og $n_2 = 10^6$. Vi kan illustrere dette ved simulation.

Hvis data er fremkommet ved at man har foretaget flere målinger på samme objekt/samme individ, kan det ofte være mest relevant at se på differenser af målinger for de enkelte individer. I bogen betragtes point for udspring ved et svømmestævne:

Table 3.4 Partial view of diving scores in file `Diving2017`.

Name	Country	Semifinal	Final
Cheog Jun Hoong	Malaysia	325.5	397.5
Si Yajie	China	382.8	396.00
Ren Qian	China	367.5	391.95
Kim Mi Rae	North Korea	346.00	385.55
:			

Vi ønsker at undersøge om der er forskel på middelværdien af pointene ved hhv. semifinalen og finalen og her vil det være mest relevant at betragte differenserne - den centrale observation er at hvis der ikke er forskel vil det være lige så sandsynligt at observere “finale - semifinale” som “semifinale - finale” og dette bruges til at lave et permutationstest.

Matched pairs - implementation

```
obs = mean(Diving2017$Semifinal) - mean(Diving2017$Final)

d = Diving2017$Semifinal - Diving2017$Final
n = length(d)

N <- 10^4 - 1
result <- numeric(N)
for (i in 1:N)
{
  signs <- sample(c(-1,1),n,replace=TRUE)
  result[i] <- mean(signs*d)
}
```

Vektoren `d` indeholder differenser. `sample` tilordner tilfældige fortegn.