

Matematisk Statistik

Multinomialmodellen

Lars Nørvang Andersen

Multinomialmodellen




Binomial: falde i en ud af to kasser



Multinomial: falde i en ud af 6 kasser

Multinomial: Inddele data i k kasser



Teste hypotese om sandsynlighederne for at falde i kasserne
Eksempel: Teste at en terning er "fair"

seks kasser, teste sandsynlighed er $\frac{1}{6}$ for hver kasse

Multinomialfordeling

Binomialmodel: n delforsøg hver med to kasser (1 eller 2)

X = antal gange hvor kasse 1 rammes ($n - X$ rammer kasse 2)

Multinomial: n delforsøg hver med k kasser ($1, 2, \dots, k$)

A_j = antal gange kasse j rammes: $A_1 + A_2 + \dots + A_k = n$

π_j : sandsynlighed for at ramme kasse j : $\pi_1 + \pi_2 + \dots + \pi_k = 1$

$(A_1, A_2, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \pi_2, \dots, \pi_k))$

I ord: multinomialfordelt med antalsværdi n og sandsynlighedsparameter $\pi = (\pi_1, \dots, \pi_k)$

Eksempel: Embryoer af zebrafisk i nanopartikelopløsning



Dødstidspunkt delt op på 3 kasser:

kasse 1: 0-48 timer, kasse 2: 48-96 timer, kasse 3: over 96 timer

$$a_1 = 15, \quad a_2 = 19, \quad a_3 = 66, \quad n = 100$$

Hypotese: Samme dødsrate i de tre perioder

Hypotese: $P(\text{kasse 1}) = \theta$, $P(\text{kasse 2}) = (1 - \theta)\theta$, $P(\text{kasse 3}) = (1 - \theta)^2$

Skøn over θ : $\hat{\theta} = \frac{a_1 + a_2}{a_1 + a_2 + a_2 + 2a_3} = 0.1838$ (metode: se senere)

Zebrafisk: test

Forventede under hypotesen:

$$e_1 = n\hat{\theta}, \quad e_2 = n(1 - \hat{\theta})\hat{\theta}, \quad e_3 = n(1 - \hat{\theta})^2$$

Kasse	1	2	3	Total
Observerede a_j	15	19	66	100
Forventede e_j	18.38	15.00	66.62	100

Hvordan skal man sammenligne 3 observerede tal med 3 forventede ?


Teststørrelse forklares nedenfor

$$\begin{aligned} \text{Teststørrelse: } G &= 2 \left(a_1 \cdot \log \left(\frac{a_1}{e_1} \right) + a_2 \cdot \log \left(\frac{a_2}{e_2} \right) + a_3 \cdot \log \left(\frac{a_3}{e_3} \right) \right) \\ &= 2 \left(15 \cdot \log \left(\frac{15}{18.38} \right) + 19 \cdot \log \left(\frac{19}{15.00} \right) + 66 \cdot \log \left(\frac{66}{66.62} \right) \right) = 1.6522 \end{aligned}$$

Store værdier er kritiske for hypotesen

Zebrafisk: test

$$p\text{-værdi} \\ = P(G(X) \geq 1.6522):$$



Hvor ofte vil man ved gentagelse af eksperimentet få en værdi større end 1.6522 under forudsætning af samme dødelighed (hypotesen)?

P-værdi kan ikke beregnes eksakt, og vi benytter approksimativ likelihood teori. Man kan vise at fordelingen af den stokastiske variabel G ligner en χ^2 -fordeling.

Approximation gyldig hvis alle $e_j \geq 5$:

$$p\text{-værdi} \approx 1 - F_{\chi^2(3-1-1)}(1.6522) = 0.199$$

Data strider ikke mod samme dødsrate da $p\text{-værdi} > 0.05$

beregninger i R

På nedenstående R-kode gennemføres beregningerne i R.

```
observerede = c(15,19,66) #indtast datasæt
n = 100
thetahat = 0.1838
forventede = n*c(thetahat, (1-thetahat)*thetahat, (1-thetahat)^2) #beregner forventede
Gobs = 2*sum((observerede*log(observerede/forventede))) #beregner teststørrelse
1-pchisq(Gobs, 3-1-1) #beregner p-værdi
```

Output bliver:

```
> Gobs
[1] 1.651205
> 1-pchisq(Gobs, 3-1-1)
[1] 0.198795
```

Vi kan benytte et simulationseksperiment til at illustrere at når hypotesen er sand, har G en $\chi^2(1)$ fordeling og sammenligne med G_{obs} .

Simulationseksperiment

```
nsim=1000000
th=0.1838
n=100

#Nedenstående giver en 1000000 x 3 vektor med multinomialfordelte udfald
x=t(rmultinom(nsim,n,c(th, (1-th)*th, (1-th)^2)))

thhat=(x[,1]+x[,2])/(x[,1]+2*x[,2]+2*x[,3])
e1=n*thhat; e2=n*thhat*(1-thhat); e3=n*(1-thhat)^2
x1=ifelse(x==0,1,x)
G=2*(x[,1]*log(x1[,1]/e1)+x[,2]*log(x1[,2]/e2)+
        x[,3]*log(x1[,3]/e3))

hist(G,breaks=seq(from=0,to=ceiling(max(G)),length.out=100),probability=TRUE)
curve(dchisq(x,df=1),from=0,to=20,add=TRUE,lwd=2)
abline(v = 1.6522,col="red",lwd=2)
mean(G >1.6522)
```

Multinomialmodel: detaljer

$$P((A_1, A_2, \dots, A_k) = (a_1, a_2, \dots, a_k)) = \binom{n}{a_1 \dots a_k} \pi_1^{a_1} \pi_2^{a_2} \dots \pi_k^{a_k}$$

Model M_0 : π kan variere frit:

$$\pi_j \geq 0, \pi_1 + \pi_2 + \dots + \pi_k = 1$$

skøn over π_j : observeret frekvens: $\hat{\pi}_j(M_0) = \frac{a_j}{n}, \quad j = 1, \dots, k$

Dette er maksimumspunktet for likelihoodfunktionen:

$$L(\pi) = \binom{n}{a_1 \dots a_k} \pi_1^{a_1} \cdot \pi_2^{a_2} \dots \pi_k^{a_k}$$

= sandsynligheden for det observerede som funktion af parameteren

Bevis

Hvis $(A_1, A_2, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \pi_2, \dots, \pi_k))$ så er

$$A_1 \sim \text{binom}(n, \pi_1)$$

skøn over π_1 : maximere $L_{A_1}(\pi_1) \propto \pi_1^{A_1} (1 - \pi_1)^{n-A_1}$, $\hat{\pi}_1 = \frac{A_1}{n}$

Generelt: Likelihoodfunktion $L(\pi_1, \dots, \pi_k) \propto \pi_1^{A_1} \pi_2^{A_2} \dots \pi_k^{A_k}$

indfør $\pi_1 = p$, $v_j = \frac{\pi_j}{1-p}$, $v_j \geq 0$, $v_2 + \dots + v_k = 1$ så

$$\pi_1^{A_1} \pi_2^{A_2} \dots \pi_k^{A_k} = \left\{ p^{A_1} (1 - p)^{n-A_1} \right\} \cdot \left\{ v_2^{A_2} \dots v_k^{A_k} \right\},$$

p og $(v_2 \dots v_k)$ varierer uafhængigt af hinanden og de to udtryk kan maximeres hver for sig.

Ovenstående svarer til opsplitting:

$$L(\pi_1, \dots, \pi_k) = L_{A_1}(\pi_1) L_{A|A_1}(\pi_1, \dots, \pi_k)$$

Multinomialkoefficient

Fortolkning: antallet af måder, hvorpå man kan fordele n elementer i k kasser, med a_j elementer i kasse j , $j = 1, \dots, k$.

formel:
$$\binom{n}{a_1 \dots a_k} = \frac{n!}{a_1! \cdot a_2! \cdot \dots \cdot a_k!}$$

Eksempel: $\binom{4}{2,1,1} = \frac{24}{2 \cdot 1 \cdot 1} = 12$

A	B	C	D
1	1	2	3
1	1	3	2
1	2	1	3
1	3	1	2
1	2	3	1
1	3	2	1
2	1	1	3
3	1	1	2
2	1	3	1
3	1	2	1
2	3	1	1
3	2	1	1

Hypotese og test

Hypotese fra Zebrafisk-eksempel (model M_1): $(\pi_1, \dots, \pi_k)$ har en bestemt form

$$\pi_j = p_j(\theta), \quad p_j \text{ kendt funktion, } \theta \text{ ukendt parameter}$$

$$\theta \text{ har } d \text{ koordinater, } \theta \in \mathbb{R}^d$$

Skøn over θ : den værdi der maksimerer $L(p_1(\theta), \dots, p_k(\theta))$

$$\hat{\pi}_j(M_1) = p_j(\hat{\theta}), \quad \text{forventede } e_j = n \cdot p_j(\hat{\theta})$$

I Zebrafisk-eksemplet er $\theta = \theta$ og

$$\begin{aligned} L(\theta, \theta(1 - \theta), (1 - \theta)^2) &= \theta^{A_1} (\theta(1 - \theta))^{A_2} ((1 - \theta)^2)^{A_3} \\ &= \theta^{A_1 + A_2} (1 - \theta)^{A_2 + 2A_3} \end{aligned}$$

$$\hat{\theta} = \frac{A_1 + A_2}{A_1 + A_2 + A_2 + 2A_3}$$

Hypotese og test

Tesstørrelse: $G = 2 \sum_{i=1}^k A_j \log \left(\frac{A_j}{e_j} \right)$

$$G = -2 \log(Q) = -2 \log \left(\frac{\max_{M_1} L(\pi)}{\max_{M_0} L(\pi)} \right) = -2 \log \left(\frac{L(\hat{\pi}_1(M_1), \dots, \hat{\pi}_k(M_1))}{L(\hat{\pi}_1(M_0), \dots, \hat{\pi}_k(M_0))} \right)$$

p-værdi fra approksimativ likelihood teori: $p\text{-værdi} \approx 1 - F_{\chi^2(k-1-d)}(G)$
(hvis alle $e_j \geq 5$)


$k - 1$: frie parametre i grundmodellen

d : frie parametre under hypotesen

Baggrund - illustration


$\pi_1, \pi_2, \pi_3 = 1 - \pi_1 - \pi_2$, (π_1, π_2) varierer i trekant i M_0

Under M_1 : $(\pi_1, \pi_2) = (\theta, (1 - \theta)\theta)$



Trekant: ML-estimat i M_0 : $(\hat{\pi}_1, \hat{\pi}_2)$, Cirkel: ML-estimat i M_1 : $(\hat{\theta}, \hat{\theta}(1 - \hat{\theta}))$

Baggrund - yderligere illustration



$M_0: (\pi_1, \dots, \pi_k)$ kan variere frit

$$\hat{\pi}_j(M_0) = \frac{A_j}{n}$$

$$L(\hat{\pi}_1(M_0), \dots, \hat{\pi}_k(M_0)) = \binom{n}{A_1, \dots, A_k} \left(\frac{A_1}{n}\right)^{A_1} \dots \left(\frac{A_k}{n}\right)^{A_k}$$

$M_1: \pi_j = p_j(\theta), \quad \theta$ "kan variere frit"

$$\hat{\pi}_j(M_1) = p_j(\hat{\theta})$$

$$L(\hat{\pi}_1(M_1), \dots, \hat{\pi}_k(M_1)) = \binom{n}{A_1, \dots, A_k} p_1(\hat{\theta})^{A_1} \dots p_k(\hat{\theta})^{A_k}$$

$$Q = \frac{\binom{n}{A_1, \dots, A_k} p_1(\hat{\theta})^{A_1} \dots p_k(\hat{\theta})^{A_k}}{\binom{n}{A_1, \dots, A_k} \left(\frac{A_1}{n}\right)^{A_1} \dots \left(\frac{A_k}{n}\right)^{A_k}} = \frac{1}{\left(\frac{A_1}{np_1(\hat{\theta})}\right)^{A_1} \dots \left(\frac{A_k}{np_k(\hat{\theta})}\right)^{A_k}} = \frac{1}{\left(\frac{A_1}{e_1}\right)^{A_1} \dots \left(\frac{A_k}{e_k}\right)^{A_k}},$$

Likelihoodratioetest generelt

$$G = -2 \log(Q) = -2 \log \left(\frac{\max_{M_1} L(\pi)}{\max_{M_0} L(\pi)} \right) = 2 \sum_{j=1}^k A_j \log \left(\frac{A_j}{e_j} \right)$$

Generelt vil G som en approksimation følge en $\chi^2(f)$ med

$$f = d_0 - d_1$$

d er antallet af frie parametre i modellen

Fulde multinomialmodel:

$$\pi_j \geq 0 \quad \pi_1 + \cdots + \pi_k = 1 \text{ har } k - 1 \text{ frie parametre}$$

Model $(\pi_1, \dots, \pi_k) = (\theta, \theta(1 - \theta), (1 - \theta)^2)$ har 1 fri parameter

Resultat 8.3.1

Betragt multinomialmodellen $(A_1, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k))$, $\pi_j \geq 0$, $\pi_1 + \dots + \pi_k = 1$ (model M_0) og hypotesen $\pi_j = p_j(\theta)$, $j = 1, \dots, k$, hvor θ har d frie parametre (model M_1). Betragt testoren

$$G = -2 \ln(Q) = 2 \sum_{j=1}^k A_j \ln \left(\frac{A_j}{e_j} \right), \quad e_j = np_j(\hat{\theta}),$$

og lad G_{obs} være den tilsvarende observerede værdi. Hvis alle de forventede $e_j = np_j(\hat{\theta})$ er større end eller lig med 5, har vi approksimativt

$$p\text{-værdi} = P(G \geq G_{\text{obs}}) = 1 - F_{\chi^2(k-1-d)}(G_{\text{obs}}).$$

Sceneskift

Fra: generelt test i multinomialmodel

Til: teste at data følger en bestemt fordeling




Klassisk goodness of fit test

Bortkiewicz: $n = 280$ observationer af dødsfald ved hestespark inden for et år (20 år, 14 regimenter). Observationer: $x_1, \dots, x_n$, total: 196 dødsfald.

Lad X være antal dødsfald i et år

Undersøge om $X \sim \text{pois}(\lambda)$ for et $\lambda \geq 0$

Skabe overblik over data gennem antalshistogram (søjlehøjde er *antal* i interval).



Grafisk sammenligning

Vælg λ således at poissonssandsynligheder passer bedst med histogram

$$\hat{\lambda} = \bar{x} = \frac{196}{280} = 0.7 \text{ (næste slide)}$$


forventede med værdi 0: $e_1 = 280 \cdot \text{dpois}(0, \hat{\lambda})$

forventede med værdi 1: $e_2 = 280 \cdot \text{dpois}(1, \hat{\lambda})$,

⋮

forventede med værdi ≥ 4 : $e_5 = 280 \cdot (1 - \text{ppois}(3, \hat{\lambda}))$

R : `dpois` (x, λ) udregner sandsynligheder i en $\text{pois}(\lambda)$ -fordeling



Estimation i poissonfordeling

Model: $X_i \sim \text{poisson}(\lambda)$

Likelihoodfunktion: $L(\lambda) = \prod_i \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum x_i}}{\prod x_i!} e^{-n\lambda}$

$$\frac{d}{d\lambda} \log(L(\lambda)) = \frac{\sum x_i}{\lambda} - n \Rightarrow \hat{\lambda} = \frac{1}{n} \sum x_i = \bar{x}.$$

Multinomialmodel

Når vi laver et antalshistogram bliver vi naturligt ledt over i multinomialmodel

A_1 : antal med værdien 0, A_2 : antal med værdien 1

A_3 : antal med værdien 2, A_4 : antal med værdien 3

A_5 : antal med værdier ≥ 4

Model M_0 : $(A_1, \dots, A_5) \sim \text{multinom}(n, \pi)$

π_j vilkårlig, $\pi_1 + \pi_2 + \pi_3 + \pi_4 + \pi_5 = 1$

fortolkning: $\pi_1 = P(X = 0)$, $\pi_2 = P(X = 1)$, $\pi_3 = P(X = 2)$

$\pi_4 = P(X = 3)$, $\pi_5 = P(X \geq 4)$

Multinomialmodel

Hypotese: $\pi_1, \pi_2, \pi_3, \pi_4, \pi_5$ er givet ved at X er poissonfordelt:

der findes $\lambda \geq 0$ således at

$$\pi_1 = \frac{\lambda^0}{0!} e^{-\lambda}, \quad \pi_2 = \frac{\lambda^1}{1!} e^{-\lambda}, \quad \pi_3 = \frac{\lambda^2}{2!} e^{-\lambda}$$

$$\pi_4 = \frac{\lambda^3}{3!} e^{-\lambda}, \quad \pi_5 = 1 - \pi_1 - \pi_2 - \pi_3 - \pi_4$$

Under hypotesen betegnes modellen med M_1 :

teste reduktion fra model M_0 til model M_1

Skøn over λ : benytter $\hat{\lambda} = \bar{x}$.

([Chihara and Hesterberg(2022)] Prop 6.2

[Chihara and Hesterberg(2018)] Prop 6.1.2)

Observerede og forventede

Index	1	2	3	4	5
Værdi	0	1	2	3	≥ 4
A_j	144	91	32	11	2
e_j	139.04	97.33	34.07	7.95	1.61

$$\hat{\lambda} = \frac{196}{280} = 0.7$$

$$e_1 = 280 \cdot \text{dpois}(0, 0.7) = 139.04, \quad e_5 = 280 \cdot (1 - \text{ppois}(3, 0.7)) = 1.61$$

Ønsker $e_j \geq 5$: nødvendigt at slå kasse 4 og 5 sammen

Index	1	2	3	4
Værdi	0	1	2	≥ 3
A_j	144	91	32	13
e_j	139.04	97.33	34.07	9.56

Slå sammen

Index	1	2	3	4
Værdi	0	1	2	≥ 3
A_j	144	91	32	13
e_j	139.04	97.33	34.07	9.56

$k = 4$ kasser, $d = 1$ parameter

$$\text{teststørrelse: } G = 2 \sum_j a_j \log \left(\frac{a_j}{e_j} \right) = 1.84$$

$$p\text{-værdi} = 1 - \text{pchisq}(1.84, 4 - 1 - 1) = 0.399$$

Konklusion: data strider ikke mod poissonfordelingen

Goodness of fit test generelt

Målinger $x_1, x_2, \dots, x_n$ fra stokastisk variabel X

Del talakse op i intervaller:

endepunkter: $z_0, z_1, \dots, z_k$ ($z_0 : -\infty, z_k : +\infty$)

A_j : antal i interval $(z_{j-1}, z_j]$

Model M_0 : $(A_1, \dots, A_k) \sim \text{multinom}(n, \pi)$

π_j vilkårlig, $\pi_1 + \pi_2 + \dots + \pi_k = 1$;

fortolkning: $\pi_j = P(z_{j-1} < X \leq z_j)$

Model M_1 : $\pi_j = p_j(\theta) = F(z_j, \theta) - F(z_{j-1}, \theta), j = 1, \dots, k$

θ ukendt parameter

$P(X \leq z)$ er givet ved $F(z, \theta)$

Poissoneksemplet ovenfor $\theta = \lambda$ - $F(z, \lambda) = \sum_{x=0}^z \frac{\lambda^x}{x!} e^{-\lambda}$


Goodness of fit test generelt

- Find skøn $\hat{\theta}$ over θ
- Udregn $\hat{\pi}_j(M_1) = p_j(\hat{\theta}) = F(z_j, \hat{\theta}) - F(z_j - 1, \hat{\theta})$
- Udregn forventede: $e_j = n \cdot p_j(\hat{\theta})$
- slå eventuelt kasser sammen
- Beregn G -teststørrelse og p -værdi

$$G = 2 \sum \text{observerede} \log \left(\frac{\text{observerede}}{\text{forventede}} \right)$$

Kontinuert variabel: alle værdier er mulige

The average drive distance (in yards) for 199 professional golfers during a week on the men's PGA tour in 2015 (DASL)



Forventede antal i interval $(a, b]$: $\approx n \cdot P(a < X \leq b) = n \int_a^b f(x)dx$

Goodness of fit test: data

Indlæsning: `golfd rives=scan("golf2015.txt")`

Intervalinddeling: `endePkt=260+c(0:12)*5`

antal i intervaller: `a=hist(golfd rives,breaks=endePkt)$counts`

Model $M_0: (A_1, \dots, A_{12}) \sim (\text{multinom}(199, (\pi_1, \dots, \pi_{12})))$
 $(\pi_1, \dots, \pi_{12})$ kan variere frit

Hypotese (model M_1): der findes μ og σ således at:

$$\pi_1 = p_1(\mu, \sigma) = \text{pnorm}(265, \mu, \sigma),$$

$$\pi_2 = p_2(\mu, \sigma) = \text{pnorm}(270, \mu, \sigma) - \text{pnorm}(265, \mu, \sigma), \dots$$

$$\pi_{11} = p_{11}(\mu, \sigma) = \text{pnorm}(315, \mu, \sigma) - \text{pnorm}(310, \mu, \sigma),$$

$$\pi_{12} = p_{12}(\mu, \sigma) = 1 - \text{pnorm}(315, \mu, \sigma)$$

Goodness of fit test: Finde parameterskøn

Strengt taget bør vi ikke benytte *ML*-estimerne fra en observationsrække.

I stedet:

```
endePkt=260+c(0:12)*5
a=hist(golfdrives,breaks=endePkt,plot=FALSE)$counts

loglik=function(th){
  prob=pnorm(endePkt[2:12],th[1],th[2])
  probInterval=c(prob,1)-c(0,prob)
  return(sum(-a*log(probInterval)))
}

nlm(loglik,c(288,9))
```

Goodness of fit test: forventede

Skøn over μ og σ : $\hat{\mu} = 288.5796$ og $\hat{\sigma} = 9.1315$

(**mean**(golfdrives) = 288.6854 **sd**(golfdrives) = 9.2811)

Beregning af forventede:

```
endePkt=260+c(0:12)*5
```

```
prob=pnorm(endePkt[2:12],288.5796,9.1315)
```

```
ex=199*(c(prob,1)-c(0,prob))
```

Kasse	1	2	3	4	5	6	7	8	9	10	11	12
a_j	1	2	9	23	34	47	37	24	12	9	0	1
e_j	1.0	3.2	9.5	20.9	34.6	42.6	39.2	27.0	13.8	5.3	1.5	0.4

Goodness of fit test: forventede

Vi slår kasse 1 og 2 samme og kasserne 10, 11 og 12 (Cochrans regel)

Kasse	1+2	3	4	5	6	7	8	9	10-12
a_{1j}	3	9	23	34	47	37	24	12	10
e_{1j}	4.2	9.5	20.9	34.6	42.6	39.2	27.0	13.8	7.2


Beregning af G og p -værdi:

```
G=2*sum(a1*log(a1/e1))
```

```
c(G,1-pchisq(G,9-1-2))
```

```
[1] 2.7293672 0.8419664
```

Goodness of fit test: figur



Teste samme rate i flere poissonfordelinger

8 dør af hestespark i løbet af 20 år i regiment 1

17 dør af hestespark i løbet af 20 år i regiment 2

hypotese: samme rate af dødsfald i de to regimenter

Model: $X_1 \sim \text{poisson}(20\lambda_1)$, $X_2 \sim \text{poisson}(20\lambda_2)$

hypotese: $\lambda_1 = \lambda_2$

Intuitivt: hvis samme rate skal de 25 dødsfald fordeles tilfældigt på de to regimenter

Teste proportionale poissonparametre

Generelt: $X_i \sim \text{poisson}(\lambda_i)$, $i = 1, \dots, k$

hypotese: $\lambda_i = m_i \lambda$, m_i kendte tal

Lad $n = X_1 + \dots + X_k$. For "fastholdt" n vil vi have modellen

$$(X_1, X_2, \dots, X_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k))$$
$$\pi_j = \lambda_j / \lambda_{\cdot}, j = 1, \dots, k, \lambda_{\cdot} = \sum_j \lambda_j$$

I denne model testes hypotesen

$$\pi_j = \frac{m_j}{m_{\cdot}}, j = 1, \dots, k, m_{\cdot} = m_1 + \dots + m_k$$

$$\text{Forventede: } e_j = n \frac{m_j}{m_{\cdot}}, j = 1, \dots, k,$$

$$\text{Beregn } G \text{ og } p\text{-værdi} = 1 - \chi_{\text{cdf}}^2(G, k - 1 - 0)$$

Bevis for betingning

$X_i \sim \text{poisson}(\lambda_i), i = 1, \dots, k, X_{\cdot} = X_1 + \dots + X_k \sim \text{poisson}(\lambda_{\cdot})$

$$\lambda_{\cdot} = \lambda_1 + \dots + \lambda_k$$

$$P(X_1 = x_1, \dots, X_k = x_k | X_{\cdot} = n) = \frac{P(X_1 = x_1, \dots, X_k = x_k)}{P(X_{\cdot} = n)} = \frac{\prod_j \frac{\lambda_j^{x_j}}{x_j!} e^{-\lambda_j}}{\frac{\lambda_{\cdot}^n}{n!} e^{-\lambda_{\cdot}}}$$

$$\binom{n}{x_1, \dots, x_k} \left(\frac{\lambda_1}{\lambda_{\cdot}}\right)^{x_1} \dots \left(\frac{\lambda_k}{\lambda_{\cdot}}\right)^{x_k}$$

$$\sim \text{multinom}(n, (\pi_1, \dots, \pi_k)), \pi_j = \frac{\lambda_j}{\lambda_{\cdot}}$$

χ^2 -test

I webbogen bruges teststørrelsen: $G = 2 \sum \text{observeret} \cdot \log \left(\frac{\text{observeret}}{\text{forventet}} \right)$

Ude i verden (og i MSRR) bruges ofte af historiske grunde:

$$C = \sum \frac{(\text{observeret} - \text{forventet})^2}{\text{forventet}}$$

For store datasæt er der ikke forskel. For små datasæt kan χ^2 -approximationen være lidt bedre for G end for C

Bibliografi



Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (2nd edition).

John Wiley & Sons, 2018.



Laura M Chihara and Tim C Hesterberg.

Mathematical statistics with resampling and R (3rd edition).

John Wiley & Sons, 2022.