

# Matematisk Statistik

Homogenitetstest og test for uafhængighed

Lars Nørvang Andersen



Det er undersøgelser af fedme og overvægt blandt unge på session, der har dokumenteret problemet. Billedet af de værnepligtige er taget på Høvelte Kaserne i anden anledning. Arkivfoto: Carsten Lundager

Kurven er knækket:

## Færre fede unge

**Nye sessionstal for værnepligtige viser  
overraskende dyk i antallet af fede unge**

Af Morten Herrup Poulsen  
[mhp@sorndagsavisen.dk](mailto:mhp@sorndagsavisen.dk)

Den eksplosive udvikling af fedme blandt unge har måske kulmineret. Søndagsavisen har gransket de seneste data fra de værnepligtiges session fra andet halvår

2003. De viser overraskende, at andelen af smækfede unge på session er faldet i perioden fra første halvår 2003 til andet halvår 2003.

Det er netop undersøgelser af fedme og overvægt blandt unge på session, der har været med til at dokumentere, at fedme er et hastigt voksende problem i Danmark.

**SIDE 3**

| Periode         | Antal på session | Antal med BMI > 30 | Procent |
|-----------------|------------------|--------------------|---------|
| 1. halvdel 2003 | 11 527           | 796                | 6,9%    |
| 2. halvdel 2003 | 12 259           | 825                | 6,7%    |

Har søndagsavisen ret ?

Umiddelbare formulering: er der forskel mellem de to halvår ?

Eller er data i overensstemmelse med en hypotese om ingen forskel ?

*hypotese*: Der er samme sandsynlighed for højt BMI i de to halvår.

# Statistisk model

|       |          | Kasse 1 | Kasse 2     | Total |
|-------|----------|---------|-------------|-------|
| Data: | Gruppe 1 | $a_1$   | $n_1 - a_1$ | $n_1$ |
|       | Gruppe 2 | $a_2$   | $n_2 - a_2$ | $n_2$ |
|       | Sum      | $a.$    | $n - a.$    | $n$   |

*Statistisk Model* (model  $M_0$ ):

$$A_1 \sim \text{binomial}(n_1, p_1), \quad A_2 \sim \text{binomial}(n_2, p_2) \quad A_1 \perp\!\!\!\perp A_2$$

Hypotese:  $p_1 = p_2$  (model  $M_1$ )

Parameterskøn under  $M_0$ :  $\hat{p}_1 = \frac{A_1}{n_1}$ ,  $\hat{p}_2 = \frac{A_2}{n_2}$

Parameterskøn under  $M_1$ :  $\hat{p} = \frac{A.}{n}$   $A. = A_1 + A_2$

# Likelihoodratio test

Likelihoodfunktion:  $L(p_1, p_2) = \binom{n_1}{A_1} p_1^{A_1} (1 - p_1)^{n_1 - A_1} \binom{n_2}{A_2} p_2^{A_2} (1 - p_2)^{n_2 - A_2}$

$$Q = \frac{\max_p L(p, p)}{\max_{p_1, p_2} L(p_1, p_2)} = \frac{\hat{p}^{A_1} (1 - \hat{p})^{n_1 - A_1} \hat{p}^{A_2} (1 - \hat{p})^{n_2 - A_2}}{\left(\frac{A_1}{n_1}\right)^{A_1} \left(1 - \frac{A_1}{n_1}\right)^{n_1 - A_1} \left(\frac{A_2}{n_2}\right)^{A_2} \left(1 - \frac{A_2}{n_2}\right)^{n_2 - A_2}}$$
$$= \frac{1}{\left(\frac{A_1}{n_1 \hat{p}}\right)^{A_1} \left(\frac{n_1 - A_1}{n_1 (1 - \hat{p})}\right)^{n_1 - A_1} \left(\frac{A_2}{n_2 \hat{p}}\right)^{A_2} \left(\frac{1 - A_2}{n_2 (1 - \hat{p})}\right)^{n_2 - A_2}}$$

**Teststørrelse:**  $G = -2 \log Q$ :

$$G = 2 \sum_{4 \text{ celler}} \text{observeret} \cdot \log \left( \frac{\text{observeret}}{\text{forventet}} \right)$$

Forventede:  $e_{11} = n_1 \hat{p}$ ,  $e_{12} = n_1 (1 - \hat{p})$ ,  $e_{21} = n_2 \hat{p}$ ,  $e_{22} = n_2 (1 - \hat{p})$

Kritiske værdier:  $Q$  lille eller  $G = -2 \log(Q)$  stor

Approximation:  $G \approx \chi^2(1)$

# Sessionstal

## Observeret

|        | BMI < 30 | BMI > 30 | Total |
|--------|----------|----------|-------|
| 2003-1 | 11527    | 796      | 12323 |
| 2003-2 | 12259    | 825      | 13084 |
| Sum    | 23786    | 1621     | 25407 |

## Forventet

|        | BMI < 30 | BMI > 30 |
|--------|----------|----------|
| 2003-1 | 11536.78 | 786.22   |
| 2003-2 | 12249.22 | 834.78   |

$$e_{11} = 12323 \cdot \frac{23786}{25407} = 11536.78$$

$$G = 2 \left[ 11527 \cdot \log \left( \frac{11527}{11536.78} \right) + 796 \cdot \log \left( \frac{796}{786.2236} \right) \right. \\ \left. + 12259 \cdot \log \left( \frac{12259}{12249.22} \right) + 825 \cdot \log \left( \frac{825}{834.7764} \right) \right] = 0.2520978$$

$$p_{\text{obs}} = 1 - F_{\chi^2(1)}(0.2520978) = 0.6156$$

# Generel formulering

$A_{ij}$ : Antal i kasse  $j$  i den  $i$ 'te række

|           | kasse    |          |     |          |     |          |       |
|-----------|----------|----------|-----|----------|-----|----------|-------|
|           | 1        | 2        | ... | j        | ... | k        | sum   |
| række 1   | $a_{11}$ | $a_{12}$ | ... | $a_{1j}$ | ... | $a_{1k}$ | $n_1$ |
| række 2   | $a_{21}$ | $a_{22}$ | ... | $a_{2j}$ | ... | $a_{2k}$ | $n_2$ |
| ⋮         |          |          |     |          |     |          | ⋮     |
| række $i$ | $a_{i1}$ | $a_{i2}$ | ... | $a_{ij}$ | ... | $a_{ik}$ | $n_i$ |
| ⋮         |          |          |     |          |     |          | ⋮     |
| række $r$ | $a_{r1}$ | $a_{r2}$ | ... | $a_{rk}$ | ... | $a_{rk}$ | $n_r$ |
| sum       | $a_{.1}$ | $a_{.2}$ | ... | $a_{.j}$ | ... | $a_{.k}$ | $n$   |

Række  $i$ :  $\mathbf{a}_{i*} = (a_{i1}, a_{i2}, \dots, a_{ik})$

Søjlesum:  $a_{.j} = a_{1j} + a_{2j} + \dots + a_{rj}$

# Homogenitetshypotesen

$r$  grupper eller rækker,  $\mathbf{a}_{i*} = (a_{i1}, \dots, a_{ik})$ ,  $\boldsymbol{\pi}_{i*} = (\pi_{i1}, \dots, \pi_{ik})$

Model  $M_0$  :  $\mathbf{A}_{1*} \sim \text{multinom}(n_1, \boldsymbol{\pi}_{1*})$   
 $\mathbf{A}_{2*} \sim \text{multinom}(n_2, \boldsymbol{\pi}_{2*})$   
 $\vdots$   
 $\mathbf{A}_{r*} \sim \text{multinom}(n_r, \boldsymbol{\pi}_{r*})$

Rækker er uafhængige, sandsynligheder er vilkårlige i hver række

Homogenitetshypotesen: alle grupperne (eller rækkerne) har det samme sæt sandsynligheder  $(\pi_1, \pi_2, \dots, \pi_k)$  (model  $M_1$ ):

Eller:  $\boldsymbol{\pi}_{1*} = \boldsymbol{\pi}_{2*} = \dots = \boldsymbol{\pi}_{r*}$

# Homogenitetshypotesen

Fulde model ( $M_0$ ):

|           | kasse      |            |     |            | sum |
|-----------|------------|------------|-----|------------|-----|
|           | 1          | 2          | ... | $k$        |     |
| række 1   | $\pi_{11}$ | $\pi_{12}$ | ... | $\pi_{1k}$ | 1   |
| række 2   | $\pi_{21}$ | $\pi_{22}$ | ... | $\pi_{2k}$ | 1   |
| $\vdots$  |            |            |     |            |     |
| række $r$ | $\pi_{r1}$ | $\pi_{r2}$ | ... | $\pi_{rk}$ | 1   |

Hypotese (model  $M_1$ ):

|           | kasse   |         |     |         | sum |
|-----------|---------|---------|-----|---------|-----|
|           | 1       | 2       | ... | $k$     |     |
| række 1   | $\pi_1$ | $\pi_2$ | ... | $\pi_k$ | 1   |
| række 2   | $\pi_1$ | $\pi_2$ | ... | $\pi_k$ | 1   |
| $\vdots$  |         |         |     |         |     |
| række $r$ | $\pi_1$ | $\pi_2$ | ... | $\pi_k$ | 1   |

# Estimation

Vi kender estimerterne i en multinomialmodel med frie parametre: under  $M_0$ :  $\hat{\pi}_{ij} = \frac{a_{ij}}{n_i}$

Under model  $M_1$  er likelihoodfunktionen

$$L_{M_1}(\pi_1, \dots, \pi_k) = \prod_{i=1}^r \binom{n_i}{\mathbf{a}_{i*}} \pi_1^{a_{i1}} \dots \pi_k^{a_{ik}} \propto \pi_1^{a_{\cdot 1}} \dots \pi_k^{a_{\cdot k}}$$

Estimation af  $(\pi_1 \dots \pi_k)$  under model  $M_1$  svarer til at bruge

$$(\mathbf{A}_{\cdot 1} \dots, \mathbf{A}_{\cdot k}) \sim \text{multinom}(n, (\pi_1 \dots \pi_k))$$

# Forventede

Under hypotesen estimeres den fælles  $\pi$  ved de observerede frekvenser for de  $k$  kasser

$$\hat{\pi}_j = \frac{\sum_i a_{ij}}{n} = \frac{a_{.j}}{n}, j = 1, \dots, k, \quad n = n_1 + \dots + n_k$$

De *forventede* i kasse  $j$  for den  $i$ 'te gruppe:  $e_{ij} = n_i \hat{\pi}_j = \frac{n_i a_{.j}}{n}$

antal i gruppe  $i$  gange skøn over sandsynlighed for kasse  $j$

rækkesum gange søjlesum divideret med samlede antal

# Likelihood ratio

Likelihoodratio teststørrelse  $Q$ :

$$\begin{aligned} Q &= \frac{\max_{M_1} L}{\max_{M_0} L} = \frac{\prod_i \binom{n_i}{\mathbf{a}_{i*}} \hat{\pi}_1^{a_{i1}} \dots \hat{\pi}_k^{a_{ik}}}{\prod_i \binom{n_i}{\mathbf{a}_{i*}} \hat{\pi}_{i1}^{a_{i1}} \dots \hat{\pi}_{ik}^{a_{ik}}} \\ &= \prod_i \prod_j \frac{\hat{\pi}_j^{a_{ij}}}{\hat{\pi}_{ij}^{a_{ij}}} = \prod_i \prod_j \frac{1}{\left( \frac{a_{ij}}{(n_i a_{.j})/n} \right)^{a_{ij}}} \end{aligned}$$

Små værdier af  $Q$  er det samme som store værdier af  $G = -2 \log(Q)$

$$G = 2 \sum_{i=1}^r \sum_{j=1}^k a_{ij} \log \left( \frac{a_{ij}}{e_{ij}} \right), \quad e_{ij} = \frac{n_i a_{.j}}{n}$$

# P-værdi

*Teststørrelse*:  $G_{\text{obs}} = 2 \cdot \sum_{i=1}^r \sum_{j=1}^k a_{ij} \log\left(\frac{a_{ij}}{e_{ij}}\right)$

Approximativ  $p$ -værdi: *Hvis*  $e_{ij} \geq 5$ , for alle  $i, j$ :

$$p\text{-værdi} \approx 1 - F_{\chi^2((r-1)(k-1))}(G_{\text{obs}}) = 1 - \text{pchisq}(G_{\text{obs}}, (r-1)(k-1))$$

Frihedsgrader =  $(r-1)(k-1)$ : antal rækker minus 1 gange antal søjler minus 1

# Nakkesmerter ved brug af smartphone

Observeret antal:

| Tidsforbrug | Nakkesmerter |    | Total |
|-------------|--------------|----|-------|
|             | Nej          | Ja |       |
| Lav         | 16           | 4  | 20    |
| Medium      | 15           | 19 | 24    |
| Høj         | 7            | 30 | 37    |
| sum         | 38           | 53 | 91    |

$\text{Pers}_{ij} \quad i = L, M, H \text{ (lav, medium, høj)}, j = \text{Nej, Ja}$

Model:

$$\begin{aligned}(\text{Pers}_{L,\text{Nej}}, \text{Pers}_{L,\text{Ja}}) &\sim \text{multinom}(20, (\pi_{L,\text{Nej}}, \pi_{L,\text{Ja}})) \\ &\quad \pi_{L,j} \geq 0, \pi_{L,\text{Nej}} + \pi_{L,\text{Ja}} = 1 \\ (\text{Pers}_{M,\text{Nej}}, \text{Pers}_{M,\text{Ja}}) &\sim \text{multinom}(24, (\pi_{M,\text{Nej}}, \pi_{M,\text{Ja}})) \\ &\quad \pi_{M,j} \geq 0, \pi_{M,\text{Nej}} + \pi_{M,\text{Ja}} = 1 \\ (\text{Pers}_{H,\text{Nej}}, \text{Pers}_{H,\text{Ja}}) &\sim \text{multinom}(37, (\pi_{H,\text{Nej}}, \pi_{H,\text{Ja}})) \\ &\quad \pi_{H,j} \geq 0, \pi_{H,\text{Nej}} + \pi_{H,\text{Ja}} = 1\end{aligned}$$

Hypotese:  $(\pi_{L,\text{Nej}}, \pi_{L,\text{Ja}}) = (\pi_{M,\text{Nej}}, \pi_{M,\text{Ja}}) = (\pi_{H,\text{Nej}}, \pi_{H,\text{Ja}})$

# Beregning i R

```
obs=rbind(c(16,4),c(15,19),c(7,30))

ex=outer(rowSums(obs),colSums(obs))/sum(obs)

obs1=ifelse(obs==0,1,obs)
G=2*sum(obs*log(obs1/ex))

pval=1-pchisq(G,(dim(obs)[1]-1)*(dim(obs)[2]-1))

list(Forventede=ex,G=G,Pvaerdi=pval)
```

rowSums: rækkesummer;      colSums: søjlesummer

**outer** (**x**,**y**):  $3 \times 2$  matriks indgange  $x_i y_j$

# Baggrund: Antal frihedsgrader i $\chi^2$ -fordeling generelt

Data  $\sim$  model  $M_0$

Hypotese: Data  $\sim$  model  $M_1$

Test:  $Q = \frac{\max_{M_1} L}{\max_{M_0} L}, \quad G = -2 \log(Q)$

$$p_{\text{obs}} \approx 1 - F_{\chi^2(df)}(G)$$

$df = \text{antal frie parametre i } M_1 - \text{antal frie parametre i } M_2$

Goodness of fit:  $df = (k - 1) - d$

Homogenitetstest:  $df = r(k - 1) - (k - 1) = (r - 1)(k - 1)$

# Introduktion til uafhængighedstest

Skema angiver sandsynlighed for at en tilfældig stoppet bilist jævnligt taler i mobiltelefon under kørsel, og om vedkommende har været indblandet i trafikuheld indenfor de seneste to år:

|            | uheld | ikke uheld | sum |
|------------|-------|------------|-----|
| mobil      | 0.1   | 0.1        | 0.2 |
| ikke mobil | 0.1   | 0.7        | 0.8 |
| sum        | 0.2   | 0.8        | 1.0 |

Er risikoen for at have været indblandet i et trafikuheld uafhængig af bilisten snakker i mobil?

# Introduktion til uafhængighedstest

Skema angiver sandsynlighed for at en tilfældig person er ryger og om vedkommende er kaffedrikker:

|            | ryger | ikke ryger | sum  |
|------------|-------|------------|------|
| kaffe      | 0.10  | 0.30       | 0.40 |
| ikke kaffe | 0.15  | 0.45       | 0.60 |
| sum        | 0.25  | 0.75       | 1.00 |

Er rygevaner uafhængig af kaffedrikning?

# Uafhængighed

|            | ryger          | ikke ryger           | sum       |
|------------|----------------|----------------------|-----------|
| kaffe      | $\alpha p$     | $(1 - \alpha)p$      | $p$       |
| ikke kaffe | $\beta(1 - p)$ | $(1 - \beta)(1 - p)$ | $(1 - p)$ |
| sum        | —              | —                    | 1         |

Uafhængighed:  $\frac{\alpha p}{(1 - \alpha)p} = \frac{\beta(1 - p)}{(1 - \beta)(1 - p)}$  eller  $\frac{\alpha}{1 - \alpha} = \frac{\beta}{1 - \beta}$

Eller:  $\alpha = \beta$

|            | ryger           | ikke ryger            | sum       |
|------------|-----------------|-----------------------|-----------|
| kaffe      | $\alpha p$      | $(1 - \alpha)p$       | $p$       |
| ikke kaffe | $\alpha(1 - p)$ | $(1 - \alpha)(1 - p)$ | $(1 - p)$ |
| sum        | $\alpha$        | $1 - \alpha$          | 1         |

Produkt!

# Uafhængighed

Definition fra ISS :  $X$  og  $Y$  er uafhængige hvis

$$P(X = x, Y = y) = P(X = x) \cdot P(Y = y)$$

|            | ryger           | ikke ryger            | sum       |
|------------|-----------------|-----------------------|-----------|
| kaffe      | $\alpha p$      | $(1 - \alpha)p$       | $p$       |
| ikke kaffe | $\alpha(1 - p)$ | $(1 - \alpha)(1 - p)$ | $(1 - p)$ |
| sum        | $\alpha$        | $1 - \alpha$          | 1         |

# Test for uafhængighed

## Data




Figure 8-16  
*Biology of Plants, Seventh Edition*  
© 2005 W.H. Freeman and Company

# Data

Genetisk eksperiment: nedarves farve *uafhængigt* af form (tomater)

|     | nonbeaked | beaked | sum |
|-----|-----------|--------|-----|
| rød | 142       | 112    | 254 |
| gul | 113       | 133    | 246 |
| sum | 255       | 245    | 500 |

$A_{ij}$ : antal i række  $i$  og søjle  $j$ ,  $i = 1, 2$ ,  $j = 1, 2$

$$n = A_{11} + A_{12} + A_{21} + A_{22} = 500$$

Multinomialmodel  $M_0$ :

$$(A_{11}, A_{12}, A_{21}, A_{22}) \sim \text{multinom}(500, (\pi_{11}, \pi_{12}, \pi_{21}, \pi_{22}))$$

$$\pi_{ij} \geq 0, \pi_{11} + \pi_{12} + \pi_{21} + \pi_{22} = 1$$

Uafhængighedshypotese (model  $M_1$ ):  $\pi_{ij} = \alpha_i \beta_j$ ,

$$\alpha_1 + \alpha_2 = 1, \beta_1 + \beta_2 = 1$$

# G-teststørrelse

Likelihood:  $L(\pi) = \binom{n}{\mathbf{A}} \prod_{i,j} \pi_{ij}^{A_{ij}}$

Model  $M_0$ :  $\pi$ -erne varierer frit,  $\hat{\pi}_{ij} = \frac{A_{ij}}{n}$

Model  $M_1$ :  $\pi_{ij} = \alpha_i \beta_j$        $\alpha_i \geq 0, \alpha_{\cdot} = 1$        $\beta_j \geq 0, \beta_{\cdot} = 1$

$$L(\{\alpha_i \beta_j\}) = \binom{n}{\mathbf{A}} \alpha_1^{A_{1\cdot}} \alpha_2^{A_{2\cdot}} \beta_1^{A_{\cdot 1}} \beta_2^{A_{\cdot 2}}$$

$$\hat{\alpha}_1 = \frac{A_{1\cdot}}{n}, \quad \hat{\beta}_1 = \frac{A_{\cdot 1}}{n}$$

$$A_{i\cdot} = A_{i1} + \cdots + A_{ik}, \text{ rækkesum}$$

$$A_{\cdot j} = A_{1j} + \cdots + A_{rj}, \text{ søjlesum}$$

Forventede under  $M_1$ :  $e_{ij} = n \hat{\alpha}_i \hat{\beta}_j = \frac{A_{i\cdot} A_{\cdot j}}{n}$

$$G\text{-test: } G = -2 \log \left( \frac{\max_{M_1} L}{\max_{M_0} L} \right) = 2 \sum_{ij} a_{ij} \log \left( \frac{a_{ij}}{e_{ij}} \right)$$

# G-test

|     | nonbeaked | beaked | sum |
|-----|-----------|--------|-----|
| rød | 142       | 112    | 254 |
| gul | 113       | 133    | 246 |
| sum | 255       | 245    | 500 |

|     | <i>Forventede</i> |        |
|-----|-------------------|--------|
|     | nonbeaked         | beaked |
| rød | 129.54            | 124.46 |
| gul | 125.46            | 120.54 |

$$G = 2 \left\{ 142 \cdot \log\left(\frac{142}{129.54}\right) + 112 \cdot \log\left(\frac{112}{124.46}\right) + 113 \cdot \log\left(\frac{113}{125.46}\right) + 133 \cdot \log\left(\frac{133}{120.54}\right) \right\} = 4.98$$

Da alle forventede er  $\geq 5$  bruger vi:

$$p_{\text{værdi}} = 1 - F_{\chi^2(3-2)}(4.98) = 0.026$$

Konklusion: data giver anledning til skepsis over for uafhængighed.

*Bemærk:* Samme beregning som ved test for homogenitet!

# Forbindelse til homogenitetstest

Erstat  $\pi_{ij}$  med  $\alpha_i \gamma_{ij}$  ( $r$  rækker,  $k$  søjler)

$\alpha_i$  sandsynlighed for at falde i række  $i$

$\gamma_{ij}$  betingede ss for at falde i søjle  $j$  givet række  $i$

Model  $M_{I0}$ :  $(A_{1,1}, \dots, A_{r,k}) \sim \text{multinom}(n, (\pi_{11}, \dots, \pi_{rk}))$ ,  $\pi_{ij} = \alpha_i \gamma_{ij}$

$$\alpha_1 + \dots + \alpha_r = 1, \quad \gamma_{i1} + \gamma_{i2} + \dots + \gamma_{ik} = 1, \quad i = 1, \dots, r$$

$$\mathbf{A}_{* \cdot} = (A_{1 \cdot}, \dots, A_{r \cdot}) \sim \text{multinom}(n, (\alpha_1, \dots, \alpha_r))$$

uafhængighed:  $\gamma_{ij} = \beta_j$  afhænger ikke af  $i$

Næste slide: fra  $M_{I0}$  til  $M_0$  fra homogenitetstestet via betingning

## Betinge med rækkesummer

$$\begin{aligned}P(\mathbf{A} = \mathbf{a} | A_{1\cdot} = a_{1\cdot}, \dots, A_{r\cdot} = a_{r\cdot}) &= \frac{\binom{n}{\mathbf{a}} \prod_{ij} (\alpha_i \gamma_{ij})^{a_{ij}}}{\binom{n}{\mathbf{a}_{* \cdot}} \prod_i \alpha_i^{a_{i \cdot}}} \\&= \prod_i \binom{a_{i \cdot}}{a_{i*}} \gamma_{i1}^{a_{i1}} \cdots \gamma_{ik}^{a_{ik}}\end{aligned}$$

Dette er model  $M_0$  fra homogenitetstest:  $r$  multinomialfordelinger

uafhængighedshypotesen = homogenitetshypotesen

Derfor: samme  $G$  og skal vurderes i samme  $\chi^2$ -fordeling:

Frihedsgrader:  $(rs - 1) - \{(r - 1) + (k - 1)\} = (r - 1)(k - 1)$

# Rækkesummer og søjlesummer

Under hypotesen om uafhængighed og givet rækkesummer:

rækker er uafhængige og  $\text{multinom}(A_{i.}, \beta)$

Summen af rækkerne (= søjlesummer), givet rækkesummer, er derfor

$\text{multinom}(n, \beta), \quad n = \sum_i A_{i.}$

denne afhænger ikke af  $A_{*.}$ , derfor uafhængighed

mellem rækkesummer og søjlesummer!

# Betinge med rækkesummer og søjlesummer

Vi har vist følgende opsplitning

$$L_{\mathbf{A}}(\{\alpha_i \beta_j\}) \propto L_{\mathbf{A}_{* \cdot}}(\alpha) L_{\mathbf{A}_{\cdot *}}(\beta)$$

Inferens om  $\alpha$  baseres på rækkesummerne

og inferens om  $\beta$  baseres på søjlesummerne

# Cochrans regel

*Contingency tables with more than 1 d.f. If relatively few expectations are less than 5 (say in 1 cell out of 5 or more, or 2 cells out of 10 or more), a minimum expectation of 1 is allowable in computing  $X^2$ . (Cochran 1954, p. 420).*

Alle forventede skal være større end eller lig med 1

højst 20 procent må være under 5

Lad os vende tilbage til Goodness Of Fit (GOF).

# Cochrans regel

|       |        |       |       |      |          |
|-------|--------|-------|-------|------|----------|
| Index | 1      | 2     | 3     | 4    | 5        |
| Værdi | 0      | 1     | 2     | 3    | $\geq 4$ |
| $A_j$ | 144    | 91    | 32    | 11   | 2        |
| $e_j$ | 139.04 | 97.33 | 34.07 | 7.95 | 1.61     |

Slår to sidste kasser sammen:  $G = 1.84$ ,  $p$ -værdi = 0.399

Slår ikke sammen:  $G = 1.86$ ,  $p$ -værdi = 0.603

|       |     |     |     |      |      |      |      |      |      |     |     |     |
|-------|-----|-----|-----|------|------|------|------|------|------|-----|-----|-----|
| Kasse | 1   | 2   | 3   | 4    | 5    | 6    | 7    | 8    | 9    | 10  | 11  | 12  |
| $a_j$ | 1   | 2   | 9   | 23   | 34   | 47   | 37   | 24   | 12   | 9   | 0   | 1   |
| $e_j$ | 1.0 | 3.2 | 9.5 | 20.9 | 34.6 | 42.6 | 39.2 | 27.0 | 13.8 | 5.3 | 1.5 | 0.4 |

Slår to første og tre sidste kasser sammen:  $G = 2.73$ ,  $p$ -værdi = 0.84

Slår to første og to sidste kasser sammen:  $G = 3.57$ ,  $p$ -værdi = 0.83

# $\chi^2$ -test $C$ - og $G$ -teststørrelsen

I noterne bruges teststørrelsen:  $G = 2 \sum \text{observeret} \cdot \log \left( \frac{\text{observeret}}{\text{forventet}} \right)$

Ude i verden (og i MSRR) bruges ofte af historiske grunde:

$$C = \sum \frac{(\text{observeret} - \text{forventet})^2}{\text{forventet}}$$

For store datasæt er der ikke forskel. For små datasæt kan  $\chi^2$ -approximationen være lidt bedre for  $G$  end for  $C$ .

**R** bruger denne i `chisq.test(obs)`