

Matematisk Statistik

Fishers eksakte test

Lars Nørvang Andersen

Tea party - Fishers eksakte test

En person bliver givet 8 kopper med te og mælk blandet sammen. De 4 af kopperne er lavet ved at der først er hældt te i koppen og dernæst mælk, og de 4 andre kopper er lavet ved at mælk er hældt i først og dernæst te. Personen ved ikke noget om hvordan de 8 kopper er fordelt på de to typer.

Hypotese: Person kan ikke kende forskel (= vælger tilfældigt)

X_1 antal gange der siges "te først" blandt de 4 med te først

X_2 antal gange der siges "te først" blandt de 4 med mælk først

Model: $X_1 \sim \text{binom}(4, p_1)$, $X_2 \sim \text{binom}(4, p_2)$

Hypotese $p_1 = p_2$

Tea party

Observerede			Forventede		
	Siger te	Siger mælk		Siger te	Siger mælk
Te først	$x_1 = 4$	0	Te først	2	2
Mælk først	$x_2 = 0$	4	Mælk først	2	2

Kan ikke bruge Cochrans regel

Der er 25 kombinationer af x_1 og x_2 med $n_1 = n_2 = 4$ men kun 7 forskellige værdier af G (p = fælles værdi af $p_1 = p_2$)

G	0.00	0.54	1.53	2.09	3.45	6.09	11.09
$Prob, p = 0.5$	0.273	0.375	0.062	0.125	0.094	0.062	0.008
$P_{val}, p = 0.5$	1.00	0.726	0.351	0.289	0.164	0.07	0.008
$Prob, p = 0.1$	0.518	0.029	0.383	0.002	0.064	0.005	0.000
$P_{val}, p = 0.1$	1.00	0.483	0.454	0.071	0.069	0.005	0.00
$\chi^2(1), \geq$	1.000	0.462	0.216	0.148	0.063	0.014	0.001

Fishers eksakte test

Hvis $p_1 = p_2$ så er $X_1 + X_2 \sim \text{binom}(n_1 + n_2, p)$, $\hat{p} = \frac{X_1 + X_2}{n_1 + n_2}$

vi er ikke interesseret i p , kun i spørgsmålet $p_1 = p_2$

Betinge med værdien af $X_1 + X_2$:

0 4 4	1 3 4	2 2 4	3 1 4	4 0 4
4 0 4	3 1 4	2 2 4	1 3 4	0 4 4
4 4 8	4 4 8	4 4 8	4 4 8	4 4 8

G	11.09	2.09	0.00	2.09	11.09
$P()$	0.014	0.229	0.514	0.229	0.014

P -værdi fra betingede test = $0.014 + 0.014 = 0.028$ (uafhængig af p under hypotesen)

Betinge i 2×2 tabel

Model: $X_1 \sim \text{binom}(n_1, p)$, $X_2 \sim \text{binom}(n_2, p)$, $X_1 \perp\!\!\!\perp X_2$.

Betinge med $X_1 + X_2$

$$P(X_1 = x_1, X_2 = x_2 | X_1 + X_2 = k)$$

$$= \frac{\binom{n_1}{x_1} p^{x_1} (1-p)^{n_1-x_1} \binom{n_2}{k-x_1} p^{k-x_1} (1-p)^{n_2-(k-x_1)}}{\binom{n}{k} p^k (1-p)^{n-k}}, \quad x_1 + x_2 = k, \quad n_1 + n_2 = n$$

$$= \frac{\binom{n_1}{x_1} \binom{n_2}{k-x_1}}{\binom{n}{k}}$$

Afhænger IKKE af p derfor "eksakt" test

Beregning af betingede sandsynlighed i R: `dhyper(x, b, c, d)`

x	b-x	b
d-x	c-d+x	c
d	n-d	n=b+c

Kritisk område

Hvad er "mere kritisk" i betingede fordeling ?

$\mathbf{R}$, `fisher.test` : alle udfald hvor betingede sandsynlighed er $\leq$ betingede sandsynlighed for faktiske observation

Alternativ: alle udfald i betingede fordeling med $G(x) \geq G(x_{\text{obs}})$

Sceneskift

Næste: Fishers eksakte test for 2×3 tabel

x_{11}	x_{12}	x_{13}	n_1
x_{21}	x_{22}	x_{23}	n_2
$a = x_{11} + x_{21} \quad b = x_{12} + x_{22} \quad c = x_{13} + x_{23}$			$n = n_1 + n_2$

Betinge i 2×3 tabel

Model:

$(X_{11}, X_{12}, X_{13}) \sim \text{multinom}(n_1, \pi)$, $(X_{21}, X_{22}, X_{23}) \sim \text{multinom}(n_2, \pi)$,
betinge med $(X_{11} + X_{21}, X_{12} + X_{22}, X_{13} + X_{23})$

$$P(X_{11} = x, X_{12} = y | X_{11} + X_{21} = a, X_{12} + X_{22} = b, X_{13} + X_{23} = c)$$

$$= \binom{n_1}{x, y, n_1 - x - y} \binom{n_2}{a - x, b - y, n_2 - (a - x) - (b - y)} / \binom{n}{a, b, c}$$

Eksempel: defingrupperes aktivitetsmønster

	Rejse	Spise	Leg	Sum
Morgen	6	28	38	72
Aften	13	56	10	79
Sum	19	84	48	151

```
obs=rbind(c(6,28,38),c(13,56,10))  
fisher.test(obs)
```

Giver $p_{obs} = 4.867e - 07$, (praktisk talt) samme som approksimativt test baseret på G-teststørelsen.

Cereals

Datasæt fra MSRR: cereals.csv

$n = 43$ morgenmadsprodukter klassificeret efter

Rettet mod "adult" eller "children" (H)

Placering på hyld: bottom, middle, top (M)

	ID	Age	Shelf	Sodiumgram	Proteingram
1	1	adult	bottom	0.007000000	0.10000000
2	2	children	bottom	0.006666667	0.06666667
...					
42	42	adult	top	0.000000000	0.09259259
43	43	adult	top	0.002452830	0.09433962

Fulde data på individniveau

n individer inddeles efter to inddelingskriterier, H og M

data: $(H_1, M_1), (H_2, M_2), \dots, (H_n, M_n)$

H har r niveauer, M har k niveauer

$$P(H = i) = \alpha_i, \quad P(M = j | H = i) = \gamma_{ij}$$

Samlet sandsynlighed: $P(\text{Data}) = \prod_{u=1}^n \alpha_{h_u} \gamma_{h_u, m_u}$

Hypotese om uafhængighed: $\gamma_{ij} = \beta_j$

$$P(\text{Data}) = \prod_u \alpha_{h_u} \beta_{m_u}$$

Fordeling af $(H_1, \dots, H_n)$ er irrelevant for spørgsmålet om uafhængighed

Første betingning

Betingelser med $H_1, \dots, H_n$

$$P(\text{Data}|H) = \frac{\prod_u \alpha_{h_u} \gamma_{h_u, m_u}}{\prod_u \alpha_{h_u}} = \prod_u \gamma_{h_u, m_u}$$

hypotese om uafhængighed: $P(\text{Data}|H) = \prod_u \beta_{m_u}$

Fordeling af M ($\beta_1, \dots, \beta_k$) er irrelevant for spørgsmålet om uafhængighed

betingelser med hvor mange der er på hvert niveau

$B_j =$ antal M_u -er med værdien j , $j = 1, \dots, k$, $B_j = \sum_u 1(M_u = j)$

$(B_1, \dots, B_k) \sim \text{multinom}(n, (\beta_1, \dots, \beta_k))$

Anden betingning

$$P(\text{Data}|H, B) = \frac{\prod_u \beta_{m_u}}{\binom{n}{b_1, \dots, b_k} \beta_1^{b_1} \dots \beta_k^{b_k}} = \frac{1}{\binom{n}{b_1, \dots, b_k}}$$

I den betingede fordeling er alle kombinationer af $(m_1, m_2, \dots, m_n)$, som opfylder at antal med værdien j er b_j , $j = 1, \dots, k$, lige sandsynlige

Vi kan simulere betingede fordeling ved at lave tilfældige permutationer af dataværdierne $m_1, \dots, m_n$

R: `sample(m)` m er en vektor med $m_1, \dots, m_n$

Næste slide: grundlæggende dele af program

Simulere

Vi kan simulere p -værdi for test i den dobbelt-betingede fordeling baseret på en teststørrelse der beregnes i *testFct*:

```
nSim=10000
tval=rep(0,nSim)

for (i in 1:nSim){
  msamp=sample(m)
  datsamp=table(h,msamp)
  tval[i]=testFct(datsamp)
}

tobs=testFct(table(h,m))
pval=(1+sum(tval>=tobs))/(1+nSim)
```

Teststørrelse

Vi mangler at specificere en teststørrelse

Fra fulde data til $r \times k$ tabel:

$$A_{ij} = \sum_{u=1}^n 1(H_u = i, M_u = j), \quad i = 1, \dots, r, \quad j = 1, \dots, k$$

Model M_{I0} : $(A_{1,1}, \dots, A_{r,k}) \sim \text{multinom}(n, (\pi_{11}, \dots, \pi_{rk}))$

Teste *uafhængighedshypotesen*: der eksisterer et sæt sandsynligheder $(\alpha_1 \dots, \alpha_r)$ og et andet sæt sandsynligheder $(\beta_1 \dots \beta_k)$ således at

$$\pi_{ij} = \alpha_i \beta_j \text{ for alle } i, j \text{ (model } M_{I1})$$

Bruge G-teststørrelsen i simulationsbaserede metode

R-kørsel

Simuleret p -værdi når der bruges teststørrelsen $C = \sum_{ij} (A_{ij} - e_{ij})^2 / e_{ij}$:

```
chisq.test(obs, simulate.p.value=TRUE, B=9999)
```