

Supplerende noter til Matematisk Statistik

Lars Nørvang Andersen



Udgave: 4. april 2025

© Lars Nørvang Andersen

Institut for Matematiske Fag
Det Naturvidenskabelige Fakultet
Aarhus Universitet
April 2025

Indhold

Indledning	1
1 Indledende undersøgelser	3
1.1 Histogrammer	3
1.2 Fraktiler og fraktildiagrammer	5
1.3 Transformation af data	10
2 Én observationsrække	15
2.1 Én observationsrække med kendt varians	16
2.2 Én observationsrække med ukendt varians	20
2.2.1 Test af hypotesen $H_0 : \sigma^2 = \sigma_0^2$	22
2.2.2 Beregninger og terminologi	23
2.2.3 Transformation af parametre	24
2.2.4 Varians kontra spredning	25
2.3 Likelihood metoden for én normalfordelt observationsrække	26
2.3.1 Variansen kendt: $\sigma^2 = \sigma_0^2$	26
2.3.2 Test af hypotesen $H_0 : \mu = \mu_0$	28
2.3.3 Ukendt varians	28
3 Flere observationsrækker	33
3.1 To observationsrækker	35
3.1.1 Test for varianshomogenitet for to observationsrækker	35
3.1.2 Test for ens middelværdi ved varianshomogenitet	36
3.1.3 To observationsrækker uden varianshomogenitet	39
Appendiks til Afsnit 3.1	43
3.2 k observationsrækker	48
3.2.1 Bartlett's test af hypotesen om en fælles varians	48
3.2.2 Test af hypotesen om en fælles middelværdi	52
4 Lineær regression	57
4.1 Den lineære regressionsmodel	58
4.1.1 Modelkontrol	62
4.1.2 Konfidensintervaller og test i simpel lineær regression	64
4.1.3 Prædiktionsinterval for en ny observation	66
4.1.4 Test af hypotesen om lineær regression	68
4.1.5 Kalibrering (invers regression)	71

4.1.6	Yderligere modeller inden for lineær regression	72
	Appendiks til Afsnit 4.1	76
5	Lineære normale modeller	83
5.1	Den lineære normale model	83
5.2	Inferens i lineære normale modeller	86
5.2.1	Estimation	86
5.2.2	Test	88
5.2.3	Hvilke modeller er <i>lineære</i> normale modeller?	92
	Appendiks til Afsnit 5.2	93
5.3	Tosidet variansanalyse	100
5.3.1	Generelt om tosidet variansanalyse	104
	Appendiks til Afsnit 5.3	112
5.4	Sammenligning af flere regressionslinjer	120
	Appendiks til Afsnit 5.4	128
5.5	Multipel regression	139
5.6	Model selektion	141
5.6.1	Backward-selektion	142
5.6.2	Datasæt med et stort antal forklarende variable - forward-selektion	145
5.6.3	Cross-validation	148
5.6.4	Prædiktion på nyt datasæt	150
5.7	Multipel regression og lineære normal modeller	151
5.7.1	Polynomiell regression	156
	Appendiks til Afsnit 5.7	160
5.7.2	Polynomiell regression i R	171
6	Statistisk analyse	173
6.1	Data	173
6.2	Modelopstilling	174
6.3	Modelkontrol	175
6.4	Statistisk inferens	175
6.5	Likelihood inferens	180
6.6	Begreber fra generel testteori	185
6.7	Approksimativ likelihood teori	187
6.8	Afsluttende bemærkninger	191
7	Estimatorers egenskaber	193
7.1	Tilstrækkelig betingelse for konsistens	193
7.2	Jensens ulighed	194
8	Multinomialmodellen	197
8.1	Multinomialmodellen	198
8.1.1	Multinomialkoefficienten	199
8.1.2	Estimation i den fulde model	200
8.2	Indledning til G -test	201
8.2.1	Inferens om fraktion	202

8.3	<i>G</i> -teststørrelsen	203
8.4	Goodness of fit test	207
8.5	Homogenitetstest: hypotesen	209
8.6	Estimation og Test	211
8.6.1	Test	211
8.7	Test for uafhængighed	213
8.8	Permutationstest og Fishers eksakte test	215
8.8.1	Fishers eksakte test	217
	Appendiks til Afsnit 8.8	219
8.8.2	Multinomialfordelingen i R	219
	Appendiks til Matematisk Statistik	229
A.1	Kumulative fordelingsfunktioner	229
A.1.1	Højre- og venstrekontinuitet	229
A.1.2	Funktioner af uafhængige stokastiske variable	231
A.2	Lineær algebra	231
A.2.1	Sum, differens og produkt	233
A.2.2	Specielle matricer	235
A.2.3	Vektorrum og lineære underrum	236
A.2.4	Spor	238
A.2.5	Determinant	239
A.2.6	Invers	240
A.2.7	Matricer som lineære afbildninger	240
A.2.8	Rang	241
A.2.9	Ortogonale projektioner	242
A.2.10	Kvadratkomplettering	243
A.2.11	Middelværdier og kovarianser	244
A.3	Fordelinger i statistik	246
A.3.1	Normalfordelingen	246
A.3.2	χ^2 -fordelingen	248
A.3.3	<i>t</i> -fordelingen	249
A.3.4	<i>F</i> -fordelingen	250
A.3.5	Gammafordelingen	251
A.3.6	Betafordelingen	252
A.3.7	Den flerdimensionale normalfordeling	253
A.3.8	Empirisk fordeling, punktmål	255
	Litteratur	257

Indledning

Disse noter er beregnet til kurset Matematisk Statistik. Notesættet er baseret på – og låner meget fra – ældre notesæt af Preben Blæsild og Jørgen Granfeldt, som blandt andet blev benyttet på kurserne Statistik 1 og Statistik α . Formålet med denne udgave af notesættet er at supplere [Chihara and Hesterberg \[2022\]](#) de steder, hvor dette forekommer nødvendigt. Der er tale om et notesæt, der løbende bliver redigeret, så der kan utvivlsomt snige sig trykfejl ind, som undertegnede naturligvis gerne vil høre om.

Lars Nørvang Andersen

Kapitel 1

Indledende undersøgelser

Dette kapitel supplerer kapitel 2 *Exploratory Data Analysis* i [Chihara and Hesterberg \[2022\]](#).

1.1 Histogrammer

Hvis data er kontinuerte, laver man ofte et histogram for at få et indtryk af, hvorledes tæthedsfunktionen for den underliggende fordeling ser ud. Histogrammer er derfor en stor hjælp, når klassen af fordelinger i den statistiske model skal vælges.

Et histogram konstrueres på følgende måde. De n observationer $x_1, x_2, \dots, x_n$ grupperes i m intervaller. Lad $t_1, t_2, \dots, t_m$ og $\Delta t_1, \Delta t_2, \dots, \Delta t_m$ betegne henholdsvis midtpunkterne og længderne af disse intervaller. Hvis a_j betegner antallet af observationer i det j te interval og $h_j = a_j/n$ den relative hyppighed af observationer i det j te interval, $j = 1, 2, \dots, m$, er histogrammet den trappefunktion h , der er givet ved

$$h(t) = \frac{h_j}{\Delta t_j}, \quad \text{hvis } t \in]t_j - \frac{\Delta t_j}{2}, t_j + \frac{\Delta t_j}{2}] \quad (1.1)$$

eller, hvis vi ønsker at opskrive ved hjælp af indikatorfunktioner*:


$$h(t) = \sum_{j=1}^m \frac{h_j}{\Delta t_j} \mathbb{1}_{]t_j - \frac{\Delta t_j}{2}, t_j + \frac{\Delta t_j}{2}]}(t). \quad (1.2)$$

Bemærk, at i et histogram repræsenteres den relative hyppighed h_j som arealet af et rektangel, som har sidelængderne Δt_j og $h_j/\Delta t_j$. Derfor er det totale areal under trappefunktionen h lig med 1. Hvis de m intervaller har samme længde Δt , det vil sige hvis $\Delta t_1 = \Delta t_2 = \dots = \Delta t_m = \Delta t$, kan man også betragte funktionen


$$\tilde{h} = n\Delta t h(t) = a_j, \quad \text{hvis } t \in]t_j - \frac{\Delta t}{2}, t_j + \frac{\Delta t}{2}] \quad (1.3)$$

i stedet for h . En tegning af denne funktion kaldes også et histogram. Bemærk, at arealet under $\tilde{h}$ er $n\Delta t$. Dog vil histogrammer af typen (1.1)/(1.2) oftest være at foretrække, da man her vil kunne sammenligne med en teoretisk tæthedsfunktion, se Figur 1.1.

*se (A.1) for definition af indikatorfunktioner.




Figur 1.1: Histogram for 10000 simulerede udfald fra eksponentialfordelingen med parameter 1, sammen tætheden $f(x) = e^{-x}$ $x > 0$.



Figur 1.2: 3 histogrammer for Weight variablen fra datasættet TXBirths2004, [Chihara and Hesterberg \[2022\]](#), baseret på forskellige antal interval-inddelinger.

Det er vigtigt at vælge et passende antal intervaller for at få et indtryk af tæthedsfunktionen for den underliggende fordeling. For mange intervaller giver et irregulært indtryk af tæthedsfunktionen, og for få intervaller giver for groft et indtryk, se Figur 1.2.

Man skal endvidere være opmærksom på at histogrammer kan være “ustabile”, som det illustreres i Figur 1.3, hvor to histogrammer baseret på samme datasæt er vist. De to histogrammer har begge



Figur 1.3: To histogrammer for samme datasæt med $\Delta t_i = 20$ for alle i . Det venstre histogram har $t_1 = 1400$ mens det højre har $t_1 = 1409$. Figuren er tilpasset fra Izenman [2008].

$\Delta t_i = 20$ for alle i men adskiller sig fra hinanden i valget af t_1 , og som det ses får denne forskel de to histogrammer til at fremstå kvalitativt forskellige.

1.2 Fraktiler og fraktildiagrammer

I dette afsnit vil vi indføre *fraktiler* (engl: *quantiles*) og *fraktildiagrammer* (engl: *quantile-quantile plots* forkortet QQ plot). Ved hjælp af fraktildiagrammer kan man vurdere den antagelse, at n observationer $x_1, x_2, \dots, x_n$ kan opfattes som realisationer af uafhængige identisk fordelte stokastiske variable $X_1, X_2, \dots, X_n$, hvis fælles fordelingsfunktion er $F(x) = \mathbb{P}(X_i \leq x)$, eller med andre ord om $x_1, x_2, \dots, x_n$ kan opfattes som én observationsrække fra fordelingen med fordelingsfunktion F . I dette afsnit giver vi først en generel diskussion af fraktiler og fraktildiagrammer og betragter dernæst specialtilfældet, hvor F er fordelingsfunktionen for en normalfordeling. Vi får flere gange brug for at betragte det sorterede datasæt

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)},$$

hvilket vi, som det fremgår, vil indikere med parenteser omkring indekset.

Vi starter diskussionen af fraktildiagrammer med at give definitionen af *p-fraktilen* for en fordelingsfunktion F . Definitionen og de vigtigste egenskaber for fordelingsfunktioner er givet i Afsnit A.1 og vi minder om at fordelingsfunktioner er højrekontinuerte med venstre grænseværdier. Hvis $F(x^-)$ betegner grænseværdien fra venstre for F i punktet x , er definitionen:

Definition 1.1 Lad F være en fordelingsfunktion for en stokastisk variabel X . For ethvert $p \in [0, 1]$ er *p-fraktilen* for F mængden x_p givet ved

$$x_p = \{x \in \mathbb{R} : F(x^-) \leq p \leq F(x)\}.$$

Bemærkning 1.2 Selvom fraktiler altså strengt taget er mængder af tal, undertrykkes dette ofte, og man skriver, f.eks., $x_{0.1} = 0.632$ som i Figur 1.4. Det er ligeledes ikke usædvanligt at kalde *tallene* i x_p for p -fraktiler og generelt er der en vis tvetydighed i statistiklitteraturen omkring præcis hvad der forstås ved ordet *fraktil*. ▼

Bemærkning 1.3 Visse p -fraktiler har særlige navne - f.eks. kaldes (et tal i) $x_{0.50}$ for en *median* for F , mens $x_{0.25}$ og $x_{0.75}$ kaldes henholdsvis første/nedre og tredje/øvre kvartil for F (engl: *first quartile* og *third quartile*). ▼

Der gælder følgende sætning:

Sætning 1.4

- a Lad F betegne fordelingsfunktionen for en stokastisk variabel X . Da er F karakteriseret ved sine fraktiler, det vil sige ved mængden af mængder $\{x_p : p \in [0, 1]\}$, i den forstand, at kender vi F kan vi finde mængden x_p for alle $p \in [0, 1]$ og omvendt.
- b Lad Y betegne en stokastisk variabel med fordelingsfunktion F_Y og lad $\alpha \in \mathbb{R}$ og $\beta > 0$. Fordelingsfunktionen F_X for den stokastiske variabel $X = \alpha + \beta Y$ er da

$$F_X(x) = F_Y\left(\frac{x - \alpha}{\beta}\right), \quad x \in \mathbb{R}.$$

Hvis endvidere y_p og x_p betegner p -fraktilen for henholdsvis Y og X , gælder der for $p \in [0, 1]$, at

$$y_p = \frac{x_p - \alpha}{\beta} = \left\{ \frac{x - \alpha}{\beta} : x \in x_p \right\}.$$

En *fraktilfunktion* en funktion, der til $0 < p < 1$ knytter en fraktil og et eksempel er

$$F^-(p) \stackrel{\text{def}}{=} \min\{x \in \mathbb{R} : p \leq F(x)\}.$$


Bemærk at $\{x \in \mathbb{R} : p \leq F(x)\}$ er et interval der indeholder sit venstre endepunkt da F er højrekontinuert. Vi kalder denne funktion fraktilfunktionen eller for en *generaliseret invers* til F . Et eksempel er givet i Figur 1.5.

Hvis F er kontinuert og strengt voksende består x_p kun af ét punkt, nemlig $F^{-1}(p)$, og vi skriver

$$x_p = F^{-1}(p), \quad p \in]0, 1[.$$

I et *fraktildiagram* foretages en sammenligning af den teoretiske fordelingsfunktion F og den empiriske fordelingsfunktion $\hat{F}_n$ svarende til observationerne $x_1, x_2, \dots, x_n$, som er defineret ved

$$\hat{F}_n(x) = \frac{\#\{x_i \leq x\}}{n} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{(-\infty, x]}(x_i).$$



Figur 1.4: Illustration af fraktiler for en fordelingsfunktion F . Det ses at $x_{0.1} = 0.632$, $x_{0.4} = x_{0.5} = 1$ og $x_{0.8} = [2, 3]$.

Bemærk, at den empiriske fordelingsfunktion $\hat{F}_n$ er en trappefunktion, hvis spring er multipla af $1/n$ og at springene sker i observationerne. Hvis alle observationerne er forskellige, er springene lig $1/n$. Fortolkningen af $\hat{F}_n(x)$ er at for ethvert $x \in \mathbb{R}$ er tallet $\hat{F}_n(x)$ blot den relative hyppighed af observationer i datasættet som er mindre end eller lig med x . Vi noterer desuden følgende sammenhæng mellem $\hat{F}_n(x)$ og medianen for *talfølgen* $x_1, \dots, x_n$ d.v.s.

$$\text{med}(x_1, \dots, x_n) = \begin{cases} x_{(\frac{n+1}{2})} & \text{for } n \text{ ulige,} \\ \frac{1}{2} (x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}) & \text{for } n \text{ lige,} \end{cases}$$


at $\text{med}(x_1, \dots, x_n)$ netop er en median for $\hat{F}_n(x)$.

Hvis vi i stedet for den empiriske fordelingsfunktion for datasættet, betragter den empiriske fordelingsfunktion for de bagvedliggende stokastisk variable, altså

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{(-\infty, x]}(X_i)$$

så vil der på grund af de store tals lov gælde, at $\hat{F}_n(x)$ konvergerer mod $F(x)$ i sandsynlighed,

$$\hat{F}_n(x) \xrightarrow{\mathbb{P}} F(x) \quad n \rightarrow \infty,$$



Figur 1.5: Illustration af fraktilfunktionen F^- svarende til fordelingsfunktionen i Figur 1.4

for $x \in \mathbb{R}$. For store værdier af n vil $\hat{F}_n(x)$ derfor approksimere $F(x) = \mathbb{P}(X \leq x)$, det vil sige, at $\hat{F}_n(x)$ approksimerer sandsynligheden for, at den stokastiske variabel X er mindre end eller lig med x . Jo større n er, desto bedre er approksimationen af $F(x)$ med $\hat{F}_n(x)$. Eksempler på empiriske fordelingsfunktioner kan findes i [Chihara and Hesterberg \[2022\]](#).

Antagelsen om at F er den fælles fordelingsfunktion for de stokastiske variable $X_1, X_2, \dots, X_n$, kan vurderes ved at sammenligne graferne for F og $\hat{F}_n$. Denne sammenligning besværliggøres dog af, at det er forholdsvis svært at sammenligne to kurvede grafer, specielt når graferne er i nærheden af 0 og 1. I stedet sammenlignes fraktilerne for F og $\hat{F}_n$. Idéen bag denne fremgangsmåde er, at vi fra Sætning 1.4 ved, at en fordelingsfunktion er karakteriseret ved sine fraktiler. I et fraktildiagram tegnes p -fraktiler for den empiriske fordelingsfunktion $\hat{F}_n$ op mod p -fraktiler for F (eller vice versa) for et passende valg af p .

Som det specifikke valg af fraktiler vælges sædvanligvis $p_i = (i-1/2)/n$, $i = 1, \dots, n$, hvilket betyder at fraktildiagrammet består af punkterne

$$\left(F^-\left(\frac{i-1/2}{n}\right), \hat{F}_n^-\left(\frac{i-1/2}{n}\right) \right) \quad i = 1, \dots, n.$$

Udtrykket kan forsimples idet der gælder at $\hat{F}_n^-\left(\frac{i-1/2}{n}\right) = x_{(i)}$ hvor $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ betegner det sorterede datasæt og da vi endvidere i praksis er interesserede i situationer hvor F har en

(sædvanlig) invers F^{-1} vil fraktildiagrammet bestå af punkterne

$$\left(F^{-1}\left(\frac{i - \frac{1}{2}}{n}\right), x_{(i)}\right) \quad i = 1, \dots, n. \quad (1.4)$$

For at F kan bruges som fordelingen i den statistiske model for observationerne $x_1, x_2, \dots, x_n$, skal punkterne i fraktildiagrammet variere omkring *identitetslinjen*. Sammenligningen af de to funktioner $\hat{F}_n$ og F er hermed reduceret til at vurdere, om punkter i et koordinatsystem udviser et passende lineært forløb.

Ved hjælp af ovenstående procedure kan vi undersøge om den fælles fordeling for X_i -erne er en specifik fordeling, for eksempel $N(0, 1)$ -fordelingen. Ofte er vi dog ikke interesserede i at finde en enkelt specifik fordeling F til beskrivelse af data, men derimod i at finde en klasse af fordelinger, som kan beskrive data, for eksempel $N(\mu, \sigma^2)$ hvor μ og σ^2 ikke er specificerede. Dette kan fraktildiagrammet også bruges til, idet vi ved hjælp af fraktildiagrammet kan vurdere om den fælles fordeling tilhører en såkaldt *position-skala* familie $\mathcal{F}$ i følgende forstand. Antag, at Y er en stokastisk variabel med en fordelingsfunktion F_Y . For alle $\mu \in \mathbb{R}$ og for alle $\sigma > 0$ gælder da, at $X = \sigma Y + \mu$ er en stokastisk variabel med fordelingsfunktion

$$F_X(x) = F_Y\left(\frac{x - \mu}{\sigma}\right). \quad (1.5)$$

Klassen af fordelinger

$$\mathcal{F} = \left\{F_Y\left(\frac{x - \mu}{\sigma}\right) \mid \mu \in \mathbb{R}, \sigma > 0\right\}$$

kaldes *positions-skala familien frembragt af F_Y* . Med betegnelserne fra **b** i Sætning 1.4 gælder at

$$y_p = \frac{x_p - \mu}{\sigma}. \quad (1.6)$$

Det ses af formel (1.6), at ønsker vi at vurdere, om fordelingsfunktionen F_X giver en tilfredsstillende beskrivelse af observationerne $x_1, x_2, \dots, x_n$, kan vi tegne p -fraktilerne for $\hat{F}_n$ op mod p -fraktilerne for F_Y og vurdere, om disse punkter ligger tilstrækkelig pænt omkring en ret linje – vel at mærke en generel ret linje, og ikke identitetslinjen specifikt.

Vi er oftest interesseret i at undersøge om den fælles fordeling er en normalfordeling. Antag, at en stokastisk variabel U er standard normalfordelt, det vil sige $U \sim N(0, 1)$, og lad $\mu \in \mathbb{R}$ og $\sigma > 0$. Der gælder at $X = \sigma U + \mu \sim N(\mu, \sigma^2)$, hvilket viser, at klassen af alle normalfordelinger $\mathcal{N} = \{N(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$ er position-skala familien frembragt af standard normalfordelingen $N(0, 1)$. Af ovenstående diskussionen fås derfor, at rimeligheden af en statistisk model for observationerne $x_1, x_2, \dots, x_n$ baseret på normalfordelingen kan vurderes ved at tegne p -fraktilerne for den empiriske fordelingsfunktion $\hat{F}_n$ op mod p -fraktilerne for standard normalfordelingen. Konkret kan dette gøres ved at plote punkterne

$$\left(\Phi^{-1}\left(\frac{i - \frac{1}{2}}{n}\right), x_{(i)}\right) \quad i = 1, \dots, n, \quad (1.7)$$

hvor (som før) $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ er det sorterede datasæt og Φ er fordelingsfunktionen for standard normalfordelingen.

		reaktionstid i sekunder							
$n_1 = 16$	kontakttid	3	5	5	7	9	9	10	12
	30 sekunder	20	24	24	34	43	46	58	140
$n_2 = 15$	kontakttid	2	5	5	7	8	9	14	18
	60 sekunder	24	26	26	34	37	42	90	

Tabel 1.1: Reaktionstider for fluer

Ved vurderingen af om punkterne fraktildiagrammet udviser et passende lineært forløb, således at det er rimeligt at antage, at observationerne kan betragtes som én observationsrække fra normalfordelingen, skal følgende tre punkter tages i betragtning:

1. Jo større n er jo mindre variation omkring en ret linje vil man forvente.
2. Punkterne i et fraktildiagram er korrelerede og har derfor en tendens til at sno sig omkring linjen.
3. Variationen af punkterne omkring linjen er størst i enderne af diagrammet og man skal derfor lægge mest vægt på punkterne i midten af diagrammet.

En statistisk model baseret på normalfordelingen afvises først og fremmest, hvis punkterne i diagrammet udviser en *systematisk afvigelse* fra en ret linje, som det illustreres i næste afsnit.


1.3 Transformation af data

Hvis det ikke er muligt at finde en forholdsvis simpel statistisk model for de oprindelige data $x_1, x_2, \dots, x_n$, kan dette undertiden opnås for en *transformeret* version af data, det vil sige for $y_1, y_2, \dots, y_n$, hvor $y_i = h(x_i)$, $i = 1, 2, \dots, n$, og hvor h er en kendt bijektiv funktion. Ofte giver den faglige problemstilling specielle grunde til at betragte en bestemt transformation. De mest brugte transformationer er $h(x) = \ln(x)$, $h(x) = \sqrt{x}$ og $h(x) = 1/x$. Når man leder efter en transformation, skal man være opmærksom på, at alle hyppigt anvendte transformationer er lokalt lineære, så hvis observationerne ligger i et snævert interval, vil vurderingen af fraktildiagrammet være den samme både for de transformerede og de utransformerede data. En tommelfingerregel for logaritmetransformationen er, at der helst skal være mindst en faktor 10 og gerne en faktor 100 i forskel mellem den største og den mindste observation hvis transformation skal gøre en visuel forskel. Vi vil nu præsentere et eksempel hvor en indledende undersøgelse ved hjælp af et fraktildiagram er faldet negativ ud i den forstand, at en statistisk model baseret på normalfordelingen ikke er rimelig for de oprindelige observationer $x_1, x_2, \dots, x_n$, men hvor antagelsen om normalfordelingen er rimelig for logaritmetransformerede data.


Eksempel 1.5.

Data i dette eksempel stammer fra to eksperimenter, hvor man målte fluers reaktion, efter de var blevet udsat for en nervegas. Målingen for den enkelte flue består i den tid – reaktionstiden – der

går fra fluen bringes i kontakt med giften og indtil den ikke længere kan stå på benene. I det første eksperiment blev fluerne udsat for giften i 30 sekunder og i det andet i 60 sekunder. Målingerne af reaktionstiden ses i Tabel 1.1. På Figur 1.6 er vist et fraktildiagram for datasættet, hvor det skal bemærkes at har de empiriske fraktiler på x -aksen og de teoretiske fraktiler på y -aksen, hvilket ikke er default-indstillingen i **R** rutinen `qqnorm`, men kan opnås ved at tilføje `datax = TRUE`. Det er indlysende, ud fra Figur 1.6, at punkterne i de tilsvarende fraktildiagrammer afviger systematisk fra en ret linje. Faktisk minder forløbet af punkterne i Figur 1.6 om grafen for logaritme-funktionen, hvilket antyder, at observationerne efter en logaritmisk transformation muligvis er normalfordelte. Fraktildiagrammerne for de logaritme transformerede data fremkommer ud fra de oprindelige diagrammer ved at bruge en logaritmisk skala på førsteaksen. Dette er gjort i Figur 1.7, som viser, at de transformerede data kan betragtes som normalfordelte.



Figur 1.6: Fraktildiagrammer for reaktionstiderne i Eksempel 1.5.



Figur 1.7: Fraktildiagrammer for logaritmen til reaktionstiderne i Eksempel 1.5.

Normalfordelte data

I de kommende kapitler behandles en række modeller, som alle har det til fælles, at observationerne er normalfordelte. Forskellene mellem modellerne består i, hvor kompliceret middelværdistrukturen og variansstrukturen er. De forskellige modeller gennemgås og omtales under følgende overskrifter:

- Én observationsrække
- Flere observationsrækker
- Lineær regression

Disse modeller er forholdsvis enkle, men de er alligevel fleksible nok til at finde anvendelse i en lang række praktiske problemstillinger. Eksemplerne spænder fra industriel produktion over naturvidenskab (herunder geologi og biologi) til lægevidenskab og samfundsvidenskab.

På den anden side omfatter modellerne ikke alle tænkelige tilfælde af normalfordelte data, som en statistiker kan få brug for. Ikke desto mindre gør det begrebsapparat og de færdigheder, man udvikler gennem arbejdet med de enkle modeller, en i stand til at håndtere mere komplicerede situationer.

Den simpleste model er én observationsrække, og derfor behandles den først. Derudover bruges den til at introducere en række statistiske grundbegreber såsom estimation, test, signifikansniveau, testsandsynlighed og konfidensinterval.

I alle modeller antager vi, at data består af n observationer, som betegnes med små x -er. Disse opfattes som realisationer af stokastiske variable, betegnet med store X -er. Vi benytter en indeksering, der passer til den ønskede model.

I én enkelt observationsrække vil observationerne typisk hedde $x_1, x_2, \dots, x_n$, og de betragtes som udfald af stokastiske variable $X_1, X_2, \dots, X_n$. For modeller med flere observationsrækker kan notation blive mere kompleks. Uanset modellen betegner $\mathbf{x}$ en n -dimensional vektor, der indeholder alle observationerne. Tilsvarende betegner $\mathbf{X}$ en vektor, der indeholder alle de stokastiske variable.

Kapitel 2

En observationsrække

En observationsrække er det simpleste eksempel på en statistisk model. Med én observationsrække på n observationer forstår vi n uafhængige observationer fra samme fordeling. Vi kan også benytte ordet *stikprøve* eller det engelske ord *sample*. Ved normalfordelte data er F en normalfordeling. De faglige problemstillinger, der måtte ligge bag indsamlingen af data, skal oversættes til egenskaber ved F , og det vil typisk være middelværdi og varians.

I Eksempel 1.5 var der to observationsrækker, én for hver kontakttid, idet der ikke på forhånd er grund til at tro, at reaktionstiden for fluerne er den samme, når de ikke har været udsat for nervegiften lige længe. Det er faktisk formålet med undersøgelsen at belyse, hvorvidt det er tilfældet. Her er normalfordelingen en model for logaritmen til reaktionstiden. Det er klart, at middelværdien direkte afspejler, hvor lang reaktionstiden er, og variansen, hvor forskelligt fluerne reagerer på nervegiften.

Når man behandler én observationsrække, er der tradition for at skelne mellem, om normalfordelingen har kendt varians eller ukendt varians. Desuden er tilfældet med kendt varians det enkleste, så man starter med dette. Sædvanligvis kender man ikke variansen i biologiske eller geologiske undersøgelser, men ved målerutiner i laboratorier er det muligt at kende variansen, og det samme gælder i industriel produktion.

Eksempel 2.1.

I forbindelse med en automatiseret svejsningsproces foretages der periodevis målinger af forskellige kritiske størrelser, der skal holde sig inden for et specifikt interval for at sikre, at svejsningen foregår korrekt. Et eksempel på en sådan størrelse er spændingen, målt i volt. Ved en kvalitetskontrol er der foretaget $n = 30$ målinger af spændingen, og disse målinger fremgår af Tabel 2.1.


For at sikre, at svejsningen er af ordentlig kvalitet, ønsker man, at spændingen holder sig i intervallet $[21.1 - 25.0]$ med en ideel værdi på 22.0 V. Man ønsker derfor at vurdere sandsynligheden for, at en måling falder uden for dette interval. $\square$

Til dette formål opstilles en statistisk model for data, og denne vælges til “én normalfordelt observationsrække”. I konkrete situationer vil man ofte have erfaring med, hvilken type modeller der beskriver den type data, man står med, men det er ikke desto mindre vigtigt at kontrollere den

21.89	22.25	21.95	22.45	22.37
22.20	22.41	21.27	22.36	22.10
21.80	22.35	22.56	22.48	22.07
22.75	22.01	22.11	22.43	21.56
22.26	22.71	22.19	22.16	21.94
21.88	22.22	22.42	21.36	22.29

Tabel 2.1: Målinger af spænding ved en automatiseret svejsningsproces.

model, som man ønsker at anvende. I dette tilfælde består modelkontrollen af et fraktildiagram, som findes på Figur 2.1. Vi ser i figuren, at datapunkterne snor sig om en ret linje, hvilket er i overensstemmelse med antagelsen om, at data er udfald af uafhængige normalfordelte stokastiske variable, og vi siger, med en mundret men dog lidt upræcis sprogbrug, at *“vi antager, at data er normalfordelt”*.



Figur 2.1: Fraktildiagram for de 30 målinger af spændingen, som er angivet i Tabel 2.1. Datapunkterne smyer sig om en ret linje, og diagrammet giver ikke anledning til at betvivle, at data kan antages at udgøre udfald fra en normalfordelt observationsrække.

2.1 Én observationsrække med kendt varians

Efter den indledende modelkontrol kan vi opstille modellen for data, og vi vil i første omgang benytte en normalfordeling med *kendt* varians. Dette kan for eksempel være relevant, hvis det givne datasæt

er del af en løbende kvalitetskontrol, og man derfor har erfaring fra tidligere målinger til rådighed. Vi antager, at værdien af den kendte varians er $\sigma_0^2 = 0.23 \text{ V}^2$, eller, om man vil, at spredningen er kendt til at være $\sigma_0 = \sqrt{0.23} \text{ V}$. Idet vi lader $x_1, \dots, x_n$ betegne de $n = 30$ observationer fra Tabel 2.1, kan vi nu angive modellen for datasættet, idet vi betragter x_i erne som realisationer af stokastiske variable X_i , hvor

$$M_1 : X_i \sim N(\mu, \sigma_0^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed.} \quad (2.1)$$

Her dækker “+ uafhængighed” over, at $X_1, \dots, X_n$ udgør en følge af stokastisk uafhængige variable. Vi bemærker, at X_i erne altså udgør en følge af uafhængige identisk fordelte stokastiske variable og bruger den tilsvarende engelske forkortelse *i.i.d* (independent, identically distributed).

I modellen M_1 fra (2.1) er der én ukendt parameter, middelværdien $\mu \in \mathbb{R}$, som vi ønsker at *estimere* (“*skønne*”) ud fra data, og resultatet af denne procedure kaldes et *estimat* eller et *skøn*. Tankegangen er her, at datasættet kan opfattes som værende genereret af en normalfordeling med en parameter μ , som har en “sand”, men for os ukendt værdi.

Som estimat for middelværdien μ bruger vi gennemsnittet af observationerne

$$\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = 22.16 \text{ V}.$$

I udtrykket for gennemsnittet udskifter vi indekset, i , med et punkt, $\cdot$, for at indikere, at vi summerer over det pågældende indeks, og den overliggende bar betyder i denne sammenhæng, at vi dividerer summen $x = 664.8$ med antallet af observationer $n = 30$. Denne notation er nyttig, når der er flere indekser på observationerne.

Gennemsnittet $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ er en funktion af datapunkterne $x_1, \dots, x_n$ (en *stikprøvefunktion*), og som sådan er det en realisation af en stokastisk variabel $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, hvis fordeling vi kan angive i M_1 idet vi fra A.3.1.3 har

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma_0^2}{n}\right). \quad (2.2)$$

En stokastisk variabel, der fremkommer som den stokastiske pendant til et estimat, kaldes en *estimator*. Fortolkningen er, at estimatet er en konkret observeret størrelse (et tal), mens estimatoren er den tilsvarende stokastiske variabel, der via sandsynlighedsteorien beskriver de mulige værdier, som estimatet kunne have antaget. I dette tilfælde ser vi, at $\bar{X}$ har nogle egenskaber, der intuitivt er fornuftige for en estimator: Middelværdien af $\bar{X}$ er lig med den sande værdi, $\mathbb{E}(\bar{X}) = \mu$, og variansen $\text{Var}(\bar{X}) = \frac{\sigma_0^2}{n}$ aftager med antallet af observationer og ville være 0 i den hypotetiske situation, at vi havde uendeligt mange observationer til rådighed.

Det næste, vi ønsker, er at vurdere, om den ukendte middelværdi kan antages at være lig den ideelle værdi på $\mu_0 = 22.0 \text{ V}$, hvilket vi gør ved at opstille *hypotesen* $H : \mu = \mu_0$. I første omgang synes det rimeligt at vurdere dette ved at betragte forskellen mellem estimatet for middelværdien i vores model og under vores hypotese, dvs.

$$\bar{x} - \mu_0 = 22.16 \text{ V} - 22.0 \text{ V} = 0.16 \text{ V}.$$

Som det fremgår, afhænger denne forskel af den skala, som data er målt på, og vi kan derfor ikke umiddelbart sige, om 0.16 er en stor eller en lille forskel. Løsningen på denne problemstilling er at standardisere forskellen ved at dividere med spredningen af gennemsnittet (se (2.2)), det vil sige, vi betragter

$$u(\mathbf{x}) = u(x_1, \dots, x_n) = \frac{\bar{x} - \mu_0}{\sqrt{\frac{\sigma_0^2}{n}}} = 1.827329. \quad (2.3)$$

Dette er et eksempel på en *teststørrelse*, da det er en stikprøvefunktion, der kan bruges til at undersøge en hypotese, og i litteraturen kaldes denne specifikke teststørrelse for *u*-teststørrelsen. På samme måde som vi betragtede estimatet som en realisation af en estimator, vil vi også betragte $u(\mathbf{x})$ som en realisation af en stokastisk variabel, nemlig

$$u(\mathbf{X}) = u(X_1, \dots, X_n) = \frac{\bar{X} - \mu_0}{\sqrt{\frac{\sigma_0^2}{n}}} \quad (2.4)$$

som under hypotesen vil have en $N(0, 1)$ fordeling. En stokastisk variabel der fremkommer på denne måde, vil vi kalde en *testor*.

Vi kan altså notationsmæssigt skelne mellem teststørrelsen $u(\mathbf{x})$ og testoren $u(\mathbf{X})$, ved at angive, om u skal opfattes som en funktion af $\mathbf{x}$ eller $\mathbf{X}$, men vil også til tider droppe $\mathbf{x}/\mathbf{X}$ og blot skrive u for teststørrelse eller testor, hvis det er oplagt ud fra sammenhængen, hvad der er tale om. Dette vil også gælde for estimator, estimatorer og andre teststørrelser og testorer, som vi senere hen indfører.

Den sidste ingrediens, som vi mangler for at kunne afgøre, hvorvidt vi tror på H_0 i vores model, er at få beskrevet, hvilke hypotetiske datasæt $\mathbf{y} \in \mathbb{R}^n$, der ville have gjort os mere skeptiske overfor H_0 end det observerede datasæt $\mathbf{x}$. I lyset af definitionen af *u*-teststørrelsen er det rimeligt at sige, at datasæt $\mathbf{y}$, der giver anledning til store værdier af $|u(\mathbf{y})|$, er kritiske for hypotesen.

Vi kan nu beregne *p-værdien* som sandsynligheden for at observere et “kritisk” datasæt, hvis H_0 er sand – eller med andre ord, *sandsynligheden under nulhypotesen for en mere kritisk værdi af teststørrelsen end den observerede*. I vores eksempel finder vi denne til

$$\begin{aligned} p_{\text{obs}}(\mathbf{x}) &= \mathbb{P}_{\mu_0}(|U(\mathbf{X})| \geq |u(\mathbf{x})|) \\ &= \mathbb{P}_{\mu_0}(U(\mathbf{X}) \geq |u(\mathbf{x})|) + \mathbb{P}_{\mu_0}(U(\mathbf{X}) \leq -|u(\mathbf{x})|) \\ &= 1 - \Phi(|u(\mathbf{x})|) + \Phi(-|u(\mathbf{x})|) \\ &= 2(1 - \Phi(|u(\mathbf{x})|)) = 2(1 - \Phi(1.827329)) = 0.06765035, \end{aligned} \quad (2.5)$$

hvor $\Phi(\cdot)$ betegner fordelingsfunktionen for $N(0, 1)$ -fordelingen og det understillede μ_0 i $\mathbb{P}_{\mu_0}$ indikerer, at vi regner under H_0 .

En fortolkning af denne *p*-værdi er, at hvis vi gentog forsøget med 30 målinger et stort antal gange, ville vi – under forudsætning af H_0 – i cirka 6.7 % af tilfældene få en værdi af u mere kritisk for H_0 end den observerede værdi med datasættet fra Tabel 2.1.

Tankegangen er, at hvis p -værdien er under en kritisk grænse (kaldet *signifikansniveauet* og betegnet α), vil vi forkaste H_0 . Sædvanligvis er α lig med 0.05 eller 0.01, og vi vil benytte $\alpha = 0.05$, med mindre andet er nævnt. Vi kan dermed konstatere, at i modellen M_1 fra (2.1) – med kendt varians $\sigma_0 = 0.23$ – kan vi ikke forkaste hypotesen $H_0 : \mu = 22.0$, når vi benytter $\alpha = 0.05$. Vi siger at hypotesen $H_0 : \mu = \mu_0$ accepteres[†] på niveau α .

Vi vil nu generelt undersøge hvilke $\mu_0 \in \mathbb{R}$ der har den egenskab at hypotesen $H_0 : \mu = \mu_0$ accepteres på niveau α . Ved at benytte (2.5) ser vi at denne mængde kan beskrives som

$$\begin{aligned} \{\mu_0 \in \mathbb{R} \mid p_{obs} \geq \alpha\} &= \{\mu_0 \in \mathbb{R} \mid 2(1 - \Phi(|u(\mathbf{x})|)) \geq \alpha\} \\ &= \{\mu_0 \in \mathbb{R} \mid |u(\mathbf{x})| \leq u_{1-\alpha/2}\} \\ &= \{\mu_0 \in \mathbb{R} \mid \left| \frac{\bar{x} - \mu_0}{\sqrt{\sigma_0^2/n}} \right| \leq u_{1-\alpha/2}\} \\ &= \{\mu_0 \in \mathbb{R} \mid \bar{x} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \leq \mu_0 \leq \bar{x} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2}\}. \end{aligned} \quad (2.6)$$

Vi ser altså at intervallet

$$\left[\bar{x} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2}, \bar{x} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \right] \quad (2.7)$$

vil indeholde de μ_0 for hvilke vi vil acceptere hypotesen $H_0 : \mu = \mu_0$, for det givne datasæt. Hvis vi indsætter de bagvedliggende stokastiske variable i (2.7) og betragter

$$\left[\bar{X} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2}, \bar{X} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \right] \quad (2.8)$$

fås et stokastisk interval defineret ved de to endepunkter

$$L = \bar{X} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \quad \text{og} \quad U = \bar{X} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2},$$

der – som det fremgår – er stokastiske variable.

Da intervallet i (2.8) er stokastisk kan vi stille spørgsmålet “Hvad er sandsynligheden for at (2.8) indeholder den sande værdi μ ?”. Beregningen af denne sandsynlighed minder til forveksling om (2.6), dog skriver vi μ i stedet for μ_0 , da vi nu betragter den ukendte parameter μ . Endvidere bruger vi, at $-u_{1-\alpha/2} = u_{\alpha/2}$.

$$\mathbb{P} \left[\bar{X} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \leq \mu \leq \bar{X} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \right] = \mathbb{P} \left[u_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sqrt{\sigma_0^2/n}} \leq u_{1-\alpha/2} \right] = 1 - \alpha.$$

Vi er at uligheden

$$\bar{X} - \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2} \leq \mu \leq \bar{X} + \sqrt{\frac{\sigma_0^2}{n}} u_{1-\alpha/2}$$

[†]Man kan argumentere for, at man bør sige, at H_0 “ikke afvises” snarere end “accepteres”. Vi kan jo ikke udelukke, at andre hypoteser også ville give anledning til en stor p -værdi, eller at flere observationer ville kunne føre til en p -værdi under signifikansniveauet.

holder med sandsynlighed $1 - \alpha$ og både intervallet (2.7) og dets stokastiske modstykke (2.8) kaldes af denne årsag et $1 - \alpha$ *konfidensinterval* for middelværdien. Vi bemærker at konfidensintervallet får to fortolkninger: Dels en fortolkning, som knytter sig til hypotesetest og siger, at konfidensintervallet indeholder præcis de tal, som vi kan teste parameteren til at være, og dels, at konfidensintervallet (i sin stokastiske udgave) indeholder den sande parameter med høj sandsynlighed.

For datasættet fra Tabel 2.1 finder vi

$$\left[22.16 \pm 1.960 \cdot \sqrt{\frac{0.23}{30}} \right] = [21.9883, 22.3316] \text{ V}$$

hvilket, som forventet, indeholder den ideelle værdi på 22.0 V.

2.2 Én observationsrække med ukendt varians

I Afsnit 2.2 gjorde vi fra start den antagelse, at vi kendte variansen i vores normalfordeling. I dette afsnit vil vi droppe denne antagelse og i stedet tage udgangspunkt i en model, hvor variansen er ukendt. I denne model er datasættet $x_1, \dots, x_n$ udfald af $X_1, \dots, X_n$ hvor

$$M_1 : X_i \sim N(\mu, \sigma^2) \quad i = 1, \dots, n \quad + \text{ uafhængighed.} \quad (2.9)$$

Modellen ligner den fra (2.1) til forveksling, men med den væsentlige forskel, at der nu er *to* parametre, der skal estimeres fra data: middelværdien $\mu \in \mathbb{R}$ og variansen $\sigma^2 > 0$.

I Afsnit 2.2 brugte vi blandt andet antagelsen om kendt varians, da vi skulle vurdere, om differensen $\bar{x} - \mu_0$ kunne betragtes som “stor.” Her dividerede vi differensen med $\sqrt{\sigma_0^2/n}$, hvilket også er spredningen på $\bar{X}$, og vi kom frem til *u*-teststørrelsen (2.4). Et naturligt skridt, når man står med et udtryk, der involverer en ukendt parameter, er at estimere parameteren ved hjælp af data og derefter arbejde videre med de udtryk, der fremkommer på denne måde.

Vores første opgave er derfor at redegøre for, hvordan vi estimerer σ^2 .

Estimatet for σ^2 betegnes med s^2 og er

$$s^2(\mathbf{x}) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{3.5636}{29} = 0.122883. \quad (2.10)$$

Den tilsvarende estimator er

$$s^2(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

som i M_1 har en $\sigma^2 \chi^2(n-1)/(n-1)$ fordeling. Se Afsnit A.3.2 for notation vedrørende χ^2 -fordelingen. Der gælder dermed at

$$\mathbb{E}[s^2(\mathbf{X})] = \sigma^2$$

samt

$$\text{Var}[s^2(\mathbf{X})] = \frac{2\sigma^4}{n-1}.$$

Vi konstaterer at s^2 er unbiased som estimator for σ^2 (da den har den “rigtige” middelværdi) samt at variansen aftager med antallet af observationer. Indsættes $s^2(\mathbf{x})$ i stedet for σ_0^2 i (2.3) fås *t-teststørrelsen*:

$$t(\mathbf{x}) = t(x_1, \dots, x_n) = \frac{\bar{x} - \mu_0}{\sqrt{\frac{s^2(\mathbf{x})}{n}}} = 2.49997. \quad (2.11)$$

Den tilsvarende stokastiske variabel (*t-testoren*) er

$$t(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{\frac{s^2(\mathbf{X})}{n}}},$$

som under hypotesen $H_0 : \mu = \mu_0$ har en $t(n-1)$ fordeling (se Afsnit A.3.3.1). Som i Afsnit 2.1 vil vi betragte små numerisk store værdier af teststørrelsen som værende kritiske for hypotesen, og da *t*-fordelingerne ligesom standard normalfordelingen er symmetrisk omkring 0 giver en beregning svarende til den i (2.5) at

$$\begin{aligned} p_{\text{obs}} &= \mathbb{P}_{\mu_0}(|T(\mathbf{X})| \geq |t(\mathbf{x})|) \\ &= 2(1 - F_{t(n-1)}(|t(\mathbf{x})|)) \\ &= 2(1 - F_{t(29)}(2.49997)) = 0.0183265. \end{aligned} \quad (2.12)$$

Vi konstaterer at *p*-værdien er under 0.05 og afviser dermed H_0 . I modellen (2.1), hvor vi antog, at variansen var $\sigma_0^2 = 0.23$, kunne vi godt acceptere hypotesen, så spørgsmålet er nu, hvilken af de to modeller vi tror mest på. Vi vender tilbage til dette spørgsmål i Afsnit 2.2.1.

Først vil vi, i lighed med Afsnit 2.1, undersøge, hvilke værdier af μ_0 vi kan teste μ til at være i vores nuværende model. Beregningen er næsten identisk med (2.6), hvor vi bare skal erstatte fordelingsfunktion og fraktiler fra $N(0,1)$ -fordelingen med de tilsvarende størrelser fra $t(n-1)$ -fordelingen, og det leder os frem til intervallet

$$\left[\bar{x} - \sqrt{\frac{s^2}{n}} t_{1-\alpha/2}(n-1), \bar{x} + \sqrt{\frac{s^2}{n}} t_{1-\alpha/2}(n-1) \right].$$

Her betegner $t_{1-\alpha/2}(n-1)$ $(1-\alpha/2)$ -fraktilen i *t*-fordelingen med $n-1$ frihedsgrader, og generelt vil $t_p(f)$ betegne *p*-fraktilen i *t*-fordelingen med *f* frihedsgrader. I lighed med Afsnit 2.1 har vi på denne måde udledt et $(1-\alpha)$ -konfidensinterval, idet:

$$\begin{aligned} \mathbb{P} \left[\bar{X} - \sqrt{\frac{s^2(\mathbf{X})}{n}} t_{1-\alpha/2}(n-1) \leq \mu \leq \bar{X} + \sqrt{\frac{s^2(\mathbf{X})}{n}} t_{1-\alpha/2}(n-1) \right] &= \\ = \mathbb{P} \left[t_{\alpha/2}(n-1) \leq \frac{\bar{X} - \mu}{\sqrt{s^2(\mathbf{X})/n}} \leq t_{1-\alpha/2}(n-1) \right] &= 1 - \alpha. \end{aligned}$$

I omskrivningen er det benyttet, at $t_{\alpha/2}(f) = -t_{1-\alpha/2}(f)$.

For vores konkrete datasæt finder vi 95%-konfidensintervallet til at være

$$\left[22.16 \pm 2.0452 \cdot \sqrt{\frac{0.122883}{30}} \right] = [22.0291, 22.2909].$$

2.2.1 Test af hypotesen $H_0 : \sigma^2 = \sigma_0^2$

I Afsnit 2.1 og 2.2 så vi, at konklusionen vedrørende hypotesen $H_0 : \mu = \mu_0$ afhænger af, hvilken antagelse vi gør om variansen i vores model – mere specifikt om vi antager, at variansen er $\sigma^2 = 0.23$, eller om den er ukendt og skal estimeres fra data.

For at afgøre, hvilken model vi har mest tiltro til, må vi vurdere, hvor meget vi stoler på antagelsen $\sigma^2 = 0.23$. I dette afsnit vil vi derfor tage stilling til dette spørgsmål ved at forudsætte modellen (2.9) og i denne betragte et test for hypotesen $H_0 : \sigma^2 = \sigma_0^2$.

Testet er baseret på iagttagelsen af, at hvis hypotesen er sand, vil teststørrelsen $s^2(\mathbf{x})/\sigma_0^2$ være tæt på 1. Endvidere gælder under H_0 for den tilsvarende teststørrelse, at

$$\frac{s^2(\mathbf{X})}{\sigma_0^2} \sim \frac{\chi^2(f)}{f}.$$

For at kunne beregne en p -værdi ud fra denne skal vi, som i de foregående afsnit, tage stilling til, hvad vi opfatter som kritisk for hypotesen H_0 . Men hvor vi tidligere betragtede teststørrelser ($u(\mathbf{x})$ og $t(\mathbf{x})$), hvor det var intuitivt rimeligt at betragte numerisk store værdier som kritiske, er situationen for $s^2(\mathbf{x})/\sigma_0^2$ lidt mindre ligetil. Det er oplagt, at værdier af s^2/σ_0^2 , der er *mindre* end den observerede værdi 0.555742, vil være kritiske, og der vil også være *store* værdier af s^2/σ_0^2 , som vil være kritiske. Men specifikt hvilke store værdier er ikke oplagt. En mulig løsning på dette problem er at beregne p_{obs} som to gange sandsynligheden under H_0 for, at $\frac{s^2(\mathbf{X})}{\sigma_0^2}$ er mindre end $\frac{s^2(\mathbf{x})}{\sigma_0^2}$. Sætter vi $f = n - 1$ får vi

$$\begin{aligned} p_{obs} &= 2\mathbb{P}_{\sigma_0^2}(s^2(\mathbf{X})/\sigma_0^2 \leq s^2(\mathbf{x})/\sigma_0^2) \\ &= 2F_{\chi^2(f)/f}(s^2(\mathbf{x})/\sigma_0^2) = 2F_{\chi^2(f)}(fs^2(\mathbf{x})/\sigma_0^2) = 2F_{\chi^2(29)}(29 \cdot 0.534273) = 0.038458. \end{aligned} \quad (2.13)$$

Da p_{obs} er under 0.05, vil vi være mest tilbøjelige til at tro på modellen (2.9) med ukendt varians.

Hvis vi havde stået med en stor værdi af $s^2(\mathbf{x})/\sigma_0^2$ ville vi omvendt have beregnet p_{obs} som $2\mathbb{P}_{\sigma_0^2}(s^2(\mathbf{X}) \geq s^2(\mathbf{x}))$, og vi kan angive et generelt udtryk for p_{obs} , hvis vi lægger os fast på *præcis* hvornår vi angiver sidstnævnte som p_{obs} , og hvornår vi bruger udtrykket fra (2.13). Et naturligt første valg er at betragte værdier af teststørrelsen som kritiske når $s(\mathbf{x})^2/\sigma_0^2 \leq 1$ og dermed beregne p -værdien som

$$\tilde{p}_{obs}(\mathbf{x}) = \begin{cases} 2F_{\chi^2(f)/f}\left(\frac{s^2}{\sigma_0^2}\right), & \text{hvis } \frac{s^2}{\sigma_0^2} \leq 1, \\ 2\left(1 - F_{\chi^2(f)/f}\left(\frac{s^2}{\sigma_0^2}\right)\right), & \text{hvis } \frac{s^2}{\sigma_0^2} \geq 1. \end{cases} \quad (2.14)$$

Dette valg betyder dog, at p -værdien kan blive større end 1, hvilket strider mod vores fortolkning af p -værdien som en sandsynlighed. En anden mulighed er at bruge medianen af $\chi^2(f)/f$ -fordelingen som afskæring, i den forstand at vi for $m \stackrel{\text{def}}{=} \chi_{1/2}^2(f)/f$ bruger

$$p_{obs}(\mathbf{x}) = \begin{cases} 2F_{\chi^2(f)/f}\left(\frac{s^2}{\sigma_0^2}\right), & \text{hvis } \frac{s^2}{\sigma_0^2} \leq m \\ 2\left(1 - F_{\chi^2(f)/f}\left(\frac{s^2}{\sigma_0^2}\right)\right), & \text{hvis } \frac{s^2}{\sigma_0^2} \geq m \end{cases} \quad (2.15)$$

som p -værdi.

Dette kan ved første øjekast virke besværligt, men er faktisk simplere end (2.14), da der gælder

$$p_{obs}(\mathbf{x}) = 2 \min \left\{ F_{\chi^2(f)/f} \left(\frac{s^2}{\sigma_0^2} \right), 1 - F_{\chi^2(f)/f} \left(\frac{s^2}{\sigma_0^2} \right) \right\}. \quad (2.16)$$

Vi ser, at (2.16) er simplere at beregne, og den løser det førnævnte problem med p -værdier, der kan blive større end 1. Da medianen i $\chi^2(f)/f$ -fordelingen alligevel er tæt på 1, vil vi foretrække at bruge (2.16).

Vi kan også opstille et konfidensinterval om variansen. Her tager vi udgangspunkt observationen at $s^2(\mathbf{X})/\sigma^2$ er $\chi^2(f)/f$ fordelt i (2.9) hvor $f = n - 1$, og dermed har vi

$$\begin{aligned} 1 - \alpha &= \mathbb{P} \left[\frac{\chi_{\alpha/2}^2(f)}{f} \leq \frac{s^2(\mathbf{X})}{\sigma^2} \leq \frac{\chi_{1-\alpha/2}^2(f)}{f} \right] \\ &= \mathbb{P} \left[\frac{f s^2(\mathbf{X})}{\chi_{1-\alpha/2}^2(f)} \leq \sigma^2 \leq \frac{f s^2(\mathbf{X})}{\chi_{\alpha/2}^2(f)} \right]. \end{aligned}$$

Det vil sige, at uligheden

$$\frac{f s^2(\mathbf{X})}{\chi_{1-\alpha/2}^2(f)} \leq \sigma^2 \leq \frac{f s^2(\mathbf{X})}{\chi_{\alpha/2}^2(f)}$$

holder med sandsynlighed $1 - \alpha$, og intervallet

$$\left[\frac{f s^2(\mathbf{X})}{\chi_{1-\alpha/2}^2(f)}, \frac{f s^2(\mathbf{X})}{\chi_{\alpha/2}^2(f)} \right] \quad (2.17)$$

er et $1 - \alpha$ konfidensinterval. Intervallet er identisk med det, vi var kommet frem til hvis vi havde beregnet $\{\sigma_0^2 \mid p_{obs}(\mathbf{x}) > \alpha\}$, hvilket er yderligere et argument for at bruge (2.16) som p -værdi.

For datasættet i eksemplet fås

$$\left[\frac{f s^2(\mathbf{x})}{\chi_{1-\alpha/2}^2(f)}, \frac{f s^2(\mathbf{x})}{\chi_{\alpha/2}^2(f)} \right] = \left[29 \cdot \frac{0.12288}{45.7223}, 29 \cdot \frac{0.12288}{16.0471} \right] = [0.07794011, 0.22207167]$$

Vi konstaterer, i overensstemmelse med det foregående, at 0.23 ikke ligger i dette interval.

2.2.2 Beregninger og terminologi

Vi har i de foregående afsnit betragtet formlerne for $\bar{x}$. og s^2 :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{og} \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Summen

$$\sum_{i=1}^n (x_i - \bar{x})^2$$

udtrykker, hvor meget observationerne afviger fra deres middelværdi og betegnes SSD, som står for *Sum of Squares of Deviations* eller *Sum of Squared Deviations*. Summer af denne type optræder ofte i modeller inden for normalfordelingen, og vi bruger generelt betegnelsen “SSD-størrelse” om en sum af kvadrater på afvigelser mellem observationer og de tilsvarende middelværdier. SSD-størrelsen afhænger af $\mathbf{x}$, og hvis vi ønsker at understrege dette, benytter vi notationen $\text{SSD}(\mathbf{x})$ eller $\text{SSD}_{\mathbf{x}}$.

I denne sammenhæng giver det mening at kalde summen af observationernes kvadrater som “Uncorrected Sum of Squares”, forkortet $\text{USS}_{\mathbf{x}}$. Med disse betegnelser har vi følgende trivielle, men nyttige beregningsformel:

$$\begin{aligned}\text{SSD}(\mathbf{x}) &= \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \sum_{i=1}^n (x_i^2 + \bar{x}^2 - 2x_i\bar{x}) \\ &= \text{USS}_{\mathbf{x}} + n\bar{x}^2 - 2\bar{x} \cdot x \\ &= \text{USS}_{\mathbf{x}} - \frac{x^2}{n},\end{aligned}$$

Bemærk også, at

$$s^2 = \frac{\text{SSD}}{n-1}.$$

2.2.3 Transformation af parametre

I Afsnit 1.3 betragtede vi en situation, hvor det var nødvendigt at transformere datapunkterne, før antagelsen om normalfordeling var rimelig. I dette afsnit vil vi diskutere fortolkningen af de transformerede parametre.

Eksempel 1.5 (fortsat).

I dette eksempel så vi på reaktionstiderne for fluer, der blev udsat for nervegas, og vi bemærkede, at de logaritmetransformerede reaktionstider kunne betragtes som normalfordelte. Vi opstiller derfor, for begge de to kontakttider, modellen (2.9) for logaritmen til reaktionstiderne og kan nu, ved hjælp af resultaterne fra Afsnit 2.2, finde estimater for parametrene samt de tilhørende konfidensintervaller, som er angivet i Tabel 2.2.

Kontaktid	Estimater	
	Middelværdi μ	Varians σ^2
30 sekunder	2.8072	1.102779
60 sekunder	2.7154	1.023778
95% Konfidensintervaller		
30 sekunder	[2.2476, 3.3668]	[0.6018, 2.6416]
60 sekunder	[2.1551, 3.2757]	[0.5489, 2.5469]

Tabel 2.2: Estimater og konfidensintervaller for de logaritmetransformerede data.

Middelværdien i modellen er middelværdien af logaritmen til reaktionstiden målt i sekunder, og det er mest naturligt at transformere tilbage og angive resultaterne i sekunder, som kan fortolkes umiddelbart.

For en kontakttid på 30 sekunder får man

$$e^{\mu_{30}} \leftarrow e^{\bar{x} \cdot 30} \text{ sekunder} = 16.56 \text{ sekunder},$$

og 95%-konfidensintervallet for den transformerede middelværdi er

$$[9.47, 28.98] \text{ sekunder}.$$

For en kontakttid på 60 sekunder får man

$$e^{\mu_{60}} \leftarrow e^{\bar{x} \cdot 60} \text{ sekunder} = 15.11 \text{ sekunder},$$

med 95%-konfidensintervallet

$$[8.63, 26.46] \text{ sekunder}.$$

Bemærk, at $e^{\mu_{30}}$ og $e^{\mu_{60}}$ ikke er middelværdierne i fordelingen af reaktionstider, da middelværdien kun bevares under lineære transformationer. Til gengæld er middelværdien for en normalfordeling også 50%-fraktilen (medianen), og denne egenskab bevares under en monoton transformation. Derfor er $e^{\bar{x} \cdot 30}$ og $e^{\bar{x} \cdot 60}$ skøn over 50%-fraktilen for reaktionstiderne. Med andre ord er de et skøn over, hvor lang tid der går, før 50% af fluerne er faldet om. $\square$

2.2.4 Varians kontra spredning

I de foregående eksempler har vi angivet skøn over variansen σ^2 og det tilhørende konfidensinterval. Derudover har vi angivet estimat og konfidensinterval for spredningen σ . Det kan forekomme overflødigt at angive begge skøn og tilhørende konfidensintervaller, da spredningen står i 1-til-1-korrespondance med variansen. Sidstnævnte (spredningen) vil endvidere ofte være lettere at fortolke: Dels er den estimerede spredning angivet på samme skala som de oprindelige datapunkter, og dels er den teoretiske spredning lettere at illustrere på en graf for normalfordelingen. For eksempel kan vi bemærke, at inden for intervaller af længde 2σ , 4σ og 6σ , centreret om middelværdien μ , ligger henholdsvis 68.27%, 95.45% og 99.7% af observationerne i en $N(\mu, \sigma^2)$ -fordeling (se Opgave 1.2 i opgavesamlingen).

Til gengæld er variansen lettere at arbejde med teoretisk, da regnereglerne for variansen er enklere at formulere end de tilsvarende regneregler for spredningen. (For eksempel er variansen af en sum af uafhængige stokastiske variable lig summen af varianserne på de enkelte stokastiske variable.) Endvidere er de estimatorer for variansen, som optræder, når man betragter normalfordelte data, χ^2 -fordelte. Denne χ^2 -fordeling er en standardfordeling inden for sandsynlighedsteori og statistik, da den er et specialtilfælde af Gamma-fordelingen (se A.3.2).

Derfor bliver test af hypoteser om spredningen normalt formuleret som hypoteser om variansen og testet ved hjælp af χ^2 -fordelingen. Tilsvarende bliver præcisionen af estimatet for spredningen,

i form af et konfidensinterval for σ , først fastlagt som et konfidensinterval for σ^2 ved hjælp af χ^2 -fordelingen efter formlen (2.17) for derefter at blive transformeret til et konfidensinterval for spredningen σ .

Denne rollefordeling mellem varians og spredning fortsætter i de senere kapitler, som omhandler modeller baseret på normalfordelingen. Tests baseres på skøn over varianser og deres fordeling. Først ved afslutningen af analysen, når modellen og dens parametre fortolkes, formulerer man sig ved hjælp af spredninger.

Til slut vil vi nævne, at vi i dette notesæt fortrinsvis bruger betegnelsen “spredning” om kvadratoden af variansen. En alternativ betegnelse er *standardafvigelse*, som er en direkte oversættelse af den engelske betegnelse *standard deviation*. En anden engelsk betegnelse, som man ofte støder på, er *standard error*, der dækker over spredningen af en estimator. *Standard error* er dermed et andet ord for spredningen, når den er knyttet til en specifik stokastisk variabel.

2.3 Likelihood metoden for én normalfordelt observationsrække

I de foregående afsnit har vi udledt udtryk for estimator og tests ud fra heuristiske argumenter om, hvad vi betragtede som intuitivt rimeligt i de givne situationer. Dette kan først og fremmest lade sig gøre, fordi vi har valgt at betragte en simpel model for vores datasæt. Vi kan dog ikke regne med, at dette altid vil kunne lade sig gøre i mere komplicerede modeller, og vi ønsker derfor en generel metodik, baseret på simple principper, der anviser estimatorer og testorer i flere forskellige situationer. Den metodik, som vi vil betragte, er *likelihood inferens* og bygger på *likelihoodfunktionen*.

Vi vil senere omtale metoden mere generelt, men vi vil i første omgang vise, at vi i simple situationer genfinder de kendte estimator og tests, og forhåbningen er, at vi derved kan øge tilliden til de tests og estimator, som metoden giver i mere komplicerede modeller.

Først behandles tilfældet σ^2 kendt, og herunder udledes både maksimum likelihood estimatet for μ og likelihood ratio testet for $H_0 : \mu = \mu_0$. Dernæst behandles tilfældet σ^2 ukendt, og estimatorne for μ og σ^2 udledes. Endelig udledes, i kort form, likelihood ratio testet for $H_0 : \mu = \mu_0$.

2.3.1 Variansen kendt: $\sigma^2 = \sigma_0^2$

Vi betragter modellen fra (2.1), hvor observationerne $x_1, \dots, x_n$ er realisationer af uafhængige og identisk fordelte stokastiske variable $X_1, \dots, X_n$, med $X_i \sim N(\mu, \sigma_0^2)$ for $i = 1, \dots, n$.

Likelihoodfunktionen. Likelihoodfunktionen er den simultane tæthed for observationerne, opfat-

tet som en funktion af den ukendte middelværdi μ . Den simultane tæthed er:

$$\begin{aligned} p(\mathbf{x}; \mu) &= f_{\mathbf{X}}(\mathbf{x}) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_0^2}} e^{-\frac{1}{2\sigma_0^2}(x_i - \mu)^2} \\ &= \left(\frac{1}{2\pi\sigma_0^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2}, \end{aligned}$$

og derfor er likelihoodfunktionen, traditionelt betegnet ved L , givet ved

$$L(\mu) = \left(\frac{1}{2\pi\sigma_0^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2}.$$

Den fortolkning som vi ønsker at tillægge likelihoodfunktionen er, at den udtrykker sandsynligheden for de observerede data som en funktion af parameteren μ . Ved at maksimere $L(\mu)$ finder vi den værdi af parameteren, der tillægger størst sandsynlighed til de observerede data. Denne fortolkning er umiddelbar for diskrete data, mens den for kontinuerte data skal tages med forbehold, som vi vil uddybe senere. Under alle omstændigheder betragter vi den parameterværdi, der maksimerer $L(\mu)$, som den, der bedst forklarer det observerede datasæt.

Maksimum likelihood estimatet. Når man skal finde maksimum likelihood estimatet, er det ofte lettere at arbejde med logaritmen til likelihoodfunktionen. Denne kaldes *log likelihoodfunktionen* og betegnes med ℓ . Da logaritmefunktionen er voksende, vil den værdi, der maksimerer $\ell(\mu)$, også maksimere $L(\mu)$. I vores eksempel er log likelihoodfunktionen

$$\ell(\mu) = -\frac{n}{2} \ln(2\pi\sigma_0^2) - \frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Differentieres ℓ én gang med hensyn til μ og sættes lig med 0, fås *likelihood ligningen*

$$0 = \frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma_0^2} \sum_{i=1}^n (x_i - \mu).$$

Løses ligningen med hensyn til μ fås løsningen

$$\hat{\mu}(\mathbf{x}) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

som maksimerer ℓ . Maksimum likelihood estimatet for middelværdien μ er gennemsnittet af observationerne, hvilket som tidligere nævnt også er et intuitivt rimeligt estimat for μ , da det er en realisation af den stokastiske variabel

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma_0^2}{n}\right).$$

2.3.2 Test af hypotesen $H_0 : \mu = \mu_0$

I Afsnit 2.1 udledte vi testet for $H_0 : \mu = \mu_0$ ved at betragte u -teststørrelsen fra (2.3)

$$u(\mathbf{x}) = u(x_1, \dots, x_n) = \frac{\bar{x} - \mu_0}{\sqrt{\sigma_0^2/n}}, \quad (2.18)$$

og tog udgangspunkt i den observation, at små værdier af u kan opfattes som værende kritiske for H_0 . Vi vil nu se på *likelihood ratio-teststørrelsen*. Denne teststørrelse, betegnet $Q(\mathbf{x})$, er forholdet mellem maksimum af likelihoodfunktionen under H_0 og maksimum af likelihoodfunktionen i grundmodellen:

$$Q(\mathbf{x}) = \frac{\max_{\mu \in H_0} L(\mu)}{\max_{\mu \in \mathbb{R}} L(\mu)} = \frac{L(\mu_0)}{L(\bar{x}.)}.$$

Hvis $Q(\mathbf{x})$ er meget lille, forklares observationerne betydeligt dårligere under H_0 end grundmodellen, som vi antager er korrekt. Vi vil derfor betragte små værdier af Q som værende kritiske for hypotesen. Vi regner nu på $\ln Q$:

$$\ln Q(\mathbf{x}) = l(\mu_0) - l(\bar{x}.) = -\frac{1}{2\sigma_0^2} \left[\sum_{i=1}^n (x_i - \mu_0)^2 - \sum_{i=1}^n (x_i - \bar{x}.)^2 \right] = -\frac{n(\bar{x} - \mu_0)^2}{2\sigma_0^2} = -\frac{1}{2} u^2(\mathbf{x}),$$

hvor $u(\mathbf{x})$ netop er u -teststørrelsen fra (2.18). De observationer, som er mere kritiske for H_0 end observationen $\mathbf{x}$ er

$$\begin{aligned} \{\mathbf{y} \mid Q(\mathbf{y}) \leq Q(\mathbf{x})\} &= \{\mathbf{y} \mid -2 \ln Q(\mathbf{y}) \geq -2 \ln Q(\mathbf{x})\} \\ &= \{\mathbf{y} \mid u^2(\mathbf{y}) \geq u^2(\mathbf{x})\} \\ &= \{\mathbf{y} \mid |u(\mathbf{y})| \geq |u(\mathbf{x})|\}, \end{aligned}$$

og man ser, at likelihood ratio testet for H_0 er identisk med (2.5) idet

$$p_{\text{obs}}(\mathbf{x}) = \mathbb{P}_{\mu_0}(Q(\mathbf{X}) \leq Q(\mathbf{x})) = \mathbb{P}_{\mu_0}(|U(\mathbf{X})| \geq |u(\mathbf{x})|) = 2(1 - \Phi(|u(\mathbf{x})|)).$$

Vi siger i denne situation at likelihood ratio testet for H_0 er *ækvivalent* med u -testet.

2.3.3 Ukendt varians

Vi vil nu betragte modellen (2.9) hvor variansen betragtes som ukendt. Når vi skal maksimere likelihoodfunktionen for vi brug for simpelt, men nyttigt lemma.

Lemma 2.2 Lad $a, b, c > 0$. Da gælder, at funktionerne

$$x \mapsto -b \ln(cx) - \frac{a}{x} \quad \text{og} \quad x \mapsto \frac{1}{(cx)^b} e^{-\frac{a}{x}} \quad x > 0$$

har et entydigt maksimum for $x = \frac{a}{b}$. ♦

Bevis. Først bemærker vi, at den første funktion er logaritmen til den anden funktion, og da $\ln$ er strengt voksende, maksimeres de to funktioner samme sted. Sætter vi $g(x) = -b \ln(cx) - a/x$ kan vi finde de to første afledede til

$$g'(x) = -\frac{b}{x} + \frac{a}{x^2} \quad \text{og} \quad g''(x) = \frac{b}{x^2} - \frac{2a}{x^3}.$$

Det ønskede følger nu af, at $g'(x) = 0 \Leftrightarrow x = \frac{a}{b}$, hvilket dermed er det eneste kritiske punkt, samt at $g''(a/b) = -b^3/a^2 < 0$, hvorved $x = \frac{a}{b}$ giver et (entydigt) maksimum. □

Likelihoodfunktionen og log likelihoodfunktionen er nu funktioner af to parametre:

$$L(\mu, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}, \quad (2.19)$$

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2. \quad (2.20)$$

Vi ønsker nu at maksimere ℓ med hensyn til de to parametre μ og σ^2 . Den teknik, som vi benytter til at maksimere ℓ kaldes *profilmaksimering*, og går ud på, at vi først holder den ene parameter (σ^2) fast og maksimerer med hensyn til den anden (μ). Derefter maksimerer vi med hensyn til den nu fastholdte parameter. Denne fremgangsmåde fungerer godt i vores tilfælde, fordi det viser sig, at den værdi af μ vi finder i første skridt ikke afhænger af det fastholdte σ^2 .

Vi holder altså σ^2 fast og maksimerer m.h.t. μ . Likelihood-ligningen for μ er

$$\frac{\partial \ell}{\partial \mu}(\mu, \sigma^2) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0,$$

og ved at løse for μ findes $\hat{\mu}$ til $\bar{x}$. hvor

$$\hat{\mu}(\mathbf{x}) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

som det observeres maksimerer (2.20). Da $\hat{\mu} = \bar{x}$. ikke afhænger af σ^2 gælder at

$$\ell(\mu, \sigma^2) \leq \ell(\bar{x}, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (2.21)$$

Vi kan nu benytte Lemma 2.2 til at konkludere, at $\sigma^2 \mapsto \ell(\bar{x}, \sigma^2)$ maksimeres entydigt af

$$\hat{\sigma}^2 = \hat{\sigma}^2(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \text{SSD}(\mathbf{x}), \quad (2.22)$$

således at

$$\ell(\mu, \sigma^2) \leq \ell(\bar{x}, \sigma^2) \leq \ell(\bar{x}, \hat{\sigma}^2),$$

og vi konkluderer at maksimum likelihood estimatet for (μ, σ^2) er

$$(\hat{\mu}(\mathbf{x}), \hat{\sigma}^2(\mathbf{x})) = \left(\bar{x}, \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right).$$

Vi gør os nu to vigtige observationer:

For det første ser vi, at maksimum likelihood estimatet for μ er gennemsnittet af observationerne $\bar{x}$, hvilket også var det estimat, vi brugte i Afsnit 2.2. Til gengæld gælder der for variansen, at

$$s^2(\mathbf{x}) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} \hat{\sigma}^2(\mathbf{x}).$$

Disse to estimater er altså *ikke* identiske, da kvadratsummen skales med henholdsvis $1/(n-1)$ for s^2 og $1/n$ for $\hat{\sigma}^2$. Vi minder om at skaleringen af s^2 skyldes at der i modellen fra (2.9) gælder

$$\text{SSD}(\mathbf{X}) = \sum_{i=1}^n (X_i - \hat{\mu}(\mathbf{X}))^2 = \sum_{i=1}^n (X_i - \bar{X})^2 \sim \sigma^2 \chi^2(n-1), \quad (2.23)$$

og skaleringen er valgt så s^2 bliver unbiased. Det er værd at bemærke at der i modellen (2.9) gælder at

$$\sum_{i=1}^n (X_i - \mu)^2 \sim \sigma^2 \chi^2(n),$$

og vi ser at det “koster” én frihedsgrad i χ^2 -fordelingen når vi i $\text{SSD}(\mathbf{X})$ estimerer μ frem for at bruge den sande værdi. Dette viser sig at være et eksempel på et generelt fænomen for de *lineære normale modeller* som vi indfører senere. Her har estimatoren for variansen en χ^2 -fordeling med $n-d$ frihedsgrader, hvor n er antallet af observationer og d er antallet af parametre, der bruges til at beskrive middelværdien.

For det andet bemærker vi, at hvis vores model skal give et bud på værdien af den *ite* observation, må dette bud nødvendigvis blive $\hat{\mu}$. Kvadratsummen i (2.23) kan derfor læses som summen af kvadraterne af X_i minus deres *prædikterede* værdi. Dette er ligeledes et generelt fænomen i lineære normale modeller.

I vores model er vi interesserede i hypotesen $H_0 : \mu = \mu_0$. Likelihood ratio teststørrelsen er

$$Q(\mathbf{x}) = \frac{\max_{\sigma^2 \in \mathbb{R}_+} L(\mu_0, \sigma^2)}{\max_{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+} L(\mu, \sigma^2)} = \frac{L\left(\mu_0, \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2\right)}{L(\bar{x}, \hat{\sigma}^2)},$$

hvor nævneren findes ved hjælp af (2.19) og ovenstående udtryk til

$$L(\bar{x}, \hat{\sigma}^2) = L\left(\bar{x}, \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right) = \frac{1}{\left(2\pi \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^{\frac{n}{2}}} e^{-\frac{n}{2}} = \frac{1}{(2\pi \hat{\sigma}^2)^2} e^{-\frac{n}{2}},$$

og tælleren findes ved hjælp af lignende udregninger til

$$L\left(\mu_0, \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2\right) = \frac{1}{\left(2\pi \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2\right)^{\frac{n}{2}}} e^{-\frac{n}{2}}.$$

Det følger at

$$\begin{aligned}
 Q(\mathbf{x}) &= \left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \mu_0)^2} \right]^{\frac{n}{2}} = \left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu_0)^2} \right]^{\frac{n}{2}} \\
 &= \left[\frac{1}{1 + \frac{n(\bar{x} - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} \right]^{\frac{n}{2}} = \left[\frac{1}{1 + \frac{t^2(\mathbf{x})}{n-1}} \right]^{\frac{n}{2}},
 \end{aligned} \tag{2.24}$$

hvor $t(\mathbf{x})$ er t -teststørrelsen fra (2.11)

$$t(\mathbf{x}) = \frac{\bar{x} - \mu_0}{\sqrt{\frac{s^2(\mathbf{x})}{n}}}. \tag{2.25}$$

Vi bemærker nu, at $t(\mathbf{X})$ er $t(n-1)$ -fordelt under H_0 , og det fremgår af (2.24), at $Q(\mathbf{x})$ kan skrives som en funktion af $t^2(\mathbf{x})$ da $Q(\mathbf{x}) = G(t^2(\mathbf{x}))$ hvor $G(x) = (1/(1 + x/(n-1)))^{n/2}$. Denne funktion er strengt aftagende for $x \geq 0$ og har derfor en invers, hvilket gør, at vi kan omskrive udtrykket for p -værdien på følgende vis:

$$\begin{aligned}
 p_{obs}(\mathbf{x}) &= \mathbb{P}_{\mu_0}(Q(\mathbf{X}) \leq Q(\mathbf{x})) \\
 &= \mathbb{P}_{\mu_0}(G(t^2(\mathbf{X})) \leq G(t^2(\mathbf{x}))) \\
 &= \mathbb{P}_{\mu_0}(t^2(\mathbf{X}) \geq t^2(\mathbf{x})) \\
 &= \mathbb{P}_{\mu_0}(|t(\mathbf{X})| \geq |t(\mathbf{x})|).
 \end{aligned}$$

Ovenstående overvejelser kan opsummeres i udsagnet, at “små værdier af $Q(\mathbf{x})$ er kritiske for H_0 , og dette er ækvivalent med store værdier af $|t(\mathbf{x})|$.”

Som for u -testet ser vi, at likelihood ratio testet er ækvivalent med t -testet, og vi kan angive p -værdien til

$$p_{obs}(\mathbf{x}) = 2 \left[1 - F_{t(n-1)}(|t(\mathbf{x})|) \right]. \tag{2.26}$$

Kapitel 3

Flere observationsrækker

I dette kapitel undersøger vi modeller med k uafhængige observationsrækker. Vores data vil derfor bestå af k grupper med n_k observationer i hver:

$$\begin{array}{cccccc}
 \text{Gruppe 1} & x_{11} & \dots & x_{1j} & \dots & x_{1n_1} \\
 \vdots & & & \vdots & & \vdots \\
 \text{Gruppe } i & x_{i1} & \dots & x_{ij} & \dots & x_{in_i} \\
 \vdots & & & \vdots & & \vdots \\
 \text{Gruppe } k & x_{k1} & \dots & x_{kj} & \dots & x_{kn_k}
 \end{array} \tag{3.1}$$

Som det fremgår, bruger vi i til at indeksere observationsrækkerne (grupperne) og j til at indeksere observationerne inden for hver række. Antallet af observationer i den i -te række betegnes n_i , og der er ingen krav om, at samtlige rækker har lige mange observationer.

Vi lader n betegne det samlede antal observationer i datasættet, dvs. $n = n_{\cdot} = n_1 + \dots + n_k$. Datasættet repræsenteres fortsat af en vektor

$$\mathbf{x} = (x_{11}, x_{12}, \dots, x_{kn_k})^* \in \mathbb{R}^n,$$

som vi opfatter som en realisation af en stokastisk vektor $\mathbf{X}$, hvis fordeling vi specificerer, når vi angiver modellen.

Udgangspunktet for k normalfordelte observationsrækker er, at data er realisationer af uafhængige, normalfordelte stokastiske variable, dvs. modellen

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, \dots, k, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed }, \tag{3.2}$$

hvor både middelværdier og varianser er ukendte (se Opgave 1.11 for situationen med kendt varians). Vi vil altså fortsat betragte uafhængige normalfordelte data og vil undersøge hypotesen om ens varianser (*varianshomogenitet*)

$$H_{0\sigma^2} : \sigma_1^2 = \dots = \sigma_k^2.$$

og hypotesen om ens middelværdier

$$H_{0\mu} : \mu_1 = \dots = \mu_k$$

Vi skelner i behandlingen af flere observationsrækker mellem de to situationer $k = 2$ og $k > 2$. I det første tilfælde (hvor $k = 2$) kan vi både angive et test for $H_{0\sigma^2}$ og undersøge $H_{0\mu}$, uanset om vi antager, at varianserne er ens eller ej. I det andet tilfælde (hvor $k > 2$) vil vi udelukkende angive et test for $H_{0\mu}$ under antagelse af, at varianserne er ens.

I hver observationsrække beregnes skøn over både middelværdi og varians. I den i -te række er skønnet over middelværdien simpelthen gennemsnittet:

$$\bar{x}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} x_{ij}.$$

Vi benytter her den samme notation som på side 17, hvor vi lader “ $\cdot$ ” angive summation over det pågældende indeks, og “ $-$ ” betyder division med antallet af summander.

Skønnet over variansen i den i -te række betegnes $s_{(i)}^2$. Parentesen om i i $s_{(i)}^2$ skal hjælpe os med at skelne disse estimater fra størrelserne s_1^2 og s_2^2 , som indføres senere i dette afsnit. For frihedsgraderne benytter vi en tilsvarende notation, således at $f_{(i)} = n_i - 1$ betegner frihedsgraderne for $s_{(i)}^2$.

Idet $\text{SSD}_{(i)}$ angiver SSD (Sum of Squared Deviations, jvf. Afsnit 2.2.2) i den i -te række, det vil sige

$$\text{SSD}_{(i)} = \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i\cdot})^2,$$

har vi dermed

$$s_{(i)}^2 = \frac{\text{SSD}_{(i)}}{f_{(i)}}. \quad (3.3)$$

Estimaterne som vi bruger er i overensstemmelse med det man kommer frem til hvis man benytter likelihood metoden som er gennemgået i Afsnit 2.3. Likelihood funktionen L er nu en funktion af de $2k$ ukendte parametre $\mu_1, \dots, \mu_k, \sigma_1^2, \dots, \sigma_k^2$, men vil på grund af uafhængigheden splitte op i k funktioner:

$$L(\mu_1, \mu_2, \dots, \mu_k, \sigma_1^2, \sigma_2^2, \dots, \sigma_k^2) = L_1(\mu_1, \sigma_1^2) L_2(\mu_2, \sigma_2^2) \dots L_k(\mu_k, \sigma_k^2) \quad (3.4)$$

som alle er på formen fra (2.19) og kan maksimeres hver for sig. Maksimum likelihood estimaterne bliver dermed

$$\hat{\mu}_i(\mathbf{x}) = \bar{x}_{i\cdot} \quad \hat{\sigma}_i^2(\mathbf{x}) = \frac{\text{SSD}_{(i)}}{n_i}.$$

Som i Afsnit 2.3 ser vi at skønnene over varianserne bliver biased, hvilket er årsagen til at vi i stedet benytter (3.3).

3.1 To observationsrækker

Vi betragter nu situationen, hvor datasættet består af $k = 2$ uafhængige observationsrækker. Det vil sige, at vi har to grupper:

$$x_{11}, x_{12}, \dots, x_{1n_1} \quad \text{og} \quad x_{21}, x_{22}, \dots, x_{2n_2},$$

der anses for at være realisationer af uafhængige, normalfordelte stokastiske variable. Modellen vi tager udgangspunkt i er

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.} \quad (3.5)$$

Vi beskriver først hvordan vi kan teste hypotesen $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2$.

3.1.1 Test for varianshomogenitet for to observationsrækker

Gennemgangen baseres på Eksempel 1.5.

Eksempel 1.5 (fortsat).

Vi minder om, at observationerne udgøres af den naturlige logaritme til fluers reaktionstider på en nervegift, samt at fluerne i den ene gruppe ($i = 1$) har været udsat for nervegiften i 30 sekunder, mens fluerne i den anden gruppe ($i = 2$) har været udsat i 60 sekunder.

Estimaterne for varianserne er angivet i Tabel 2.2:

$$\begin{aligned} \sigma_1^2 &\leftarrow s_{(1)}^2 = 1.102779, \\ \sigma_2^2 &\leftarrow s_{(2)}^2 = 1.023778. \end{aligned}$$

De tilsvarende estimatorer, $s_{(1)}^2(\mathbf{X})$ og $s_{(2)}^2(\mathbf{X})$, er henholdsvis $\sigma_1^2 \chi^2(15)/15$ og $\sigma_2^2 \chi^2(14)/14$ -fordelte. Endvidere er de to estimatorer uafhængige, da de "arver" uafhængigheden fra de to observationsrækker (se A.1.2).

Hvis varianserne σ_1^2 og σ_2^2 er ens vil σ_1^2/σ_2^2 være lig 1, og det er derfor oplagt at bruge forholdet mellem variansskønnene som teststørrelse

$$\mathcal{F}(\mathbf{x}) = \frac{s_{(1)}^2(\mathbf{x})}{s_{(2)}^2(\mathbf{x})} = \frac{1.102779}{1.023778} = 1.077. \quad (3.6)$$

Store og små værdier af teststørrelsen er kritiske for $H_{0\sigma^2}$, for de afspejler store forskelle i variansskønnene. Derimod er værdier omkring 1 ikke kritiske. Da estimatorerne $s_{(i)}^2(\mathbf{X})$ $i = 1, 2$ som nævnt er uafhængige vil testoren svarende til (3.6), være F -fordelt hvis H_0 er sand, se (se Afsnit A.3.4). I dette eksempel er

$$\begin{aligned} \mathbb{P}[\mathcal{F}(\mathbf{X}) > 1.077] &= 1 - F_{F(f_{(1)}, f_{(2)})}(1.077) \\ &= 0.447 \end{aligned}$$

hvor $F(f_{(1)}, f_{(2)})$ er F -fordelingen med $f_{(1)} = n_1 - 1$ frihedsgrader i tælleren og $f_{(2)} = n_2 - 1$ frihedsgrader i nævneren.

Da små værdier også er kritiske for $H_{0\sigma^2}$ vælger man at sætte testsandsynligheden til

$$p_{obs}(\mathbf{x}) = 2\mathbb{P}(\mathcal{F}(\mathbf{X}) > 1.077) = 0.894 \quad (3.7)$$

Det strider ikke mod $H_{0\sigma^2}$, som således accepteres.

Når vi skal angive et generelt udtryk for p_{obs} , står vi i samme situation som i Afsnit 2.2.1, hvor vi har en teststørrelse (her (3.6)) med 1 som den “mindst kritiske” værdi for den betragtede hypotese.

Det er derfor nærliggende at angive en p -værdi svarende til $\tilde{p}_{obs}$ fra (2.14). Dette valg giver imidlertid anledning til det samme problem, som omtalt i Afsnit 2.2.1. Derfor vil vi – med samme argumentation som i 2.2.1 – betegne p -værdien ved

$$p_{obs}(\mathbf{x}) = 2 \min \left\{ F_{F(f_{(1)}, f_{(2)})} \left(\frac{s_{(1)}^2}{s_{(2)}^2} \right), 1 - F_{F(f_{(1)}, f_{(2)})} \left(\frac{s_{(1)}^2}{s_{(2)}^2} \right) \right\}. \quad (3.8)$$

□

3.1.2 Test for ens middelværdi ved varianshomogenitet

I lyset af resultaterne fra Afsnit 3.1.1 kan vi opstille en ny model for datasættet, idet vi vil betragte observationerne x_{ij} som realisationer af

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed}. \quad (3.9)$$

Hvor der - i modsætning til udtrykket (3.5) for M_0 - ikke er noget indeks i på variansen.

Estimerne i M_1 kan nu findes ved hjælp af likelihood metoden, hvilket er gjort i Opgave 1.1 og vi har

$$\hat{\mu}_1 = \hat{\mu}_1(\mathbf{x}) = \bar{x}_1, \quad \hat{\mu}_2 = \hat{\mu}_2(\mathbf{x}) = \bar{x}_2, \quad \hat{\sigma}^2 = \frac{\text{SSD}_{(1)} + \text{SSD}_{(2)}}{n_1 + n_2}. \quad (3.10)$$

Ved at bruge A.1.2 og A.43 ser vi at $\text{SSD}_{(1)} + \text{SSD}_{(2)}$ er udfald af en $\sigma^2 \chi^2(n_1 + n_2 - 2)$ -fordeling. Som estimat for σ^2 benyttes derfor

$$s_1^2 = \frac{\text{SSD}_{(1)} + \text{SSD}_{(2)}}{n_1 + n_2 - 2} = \frac{\text{SSD}_{(1)} + \text{SSD}_{(2)}}{f_{(1)} + f_{(2)}} = \frac{f_{(1)}}{f_{(1)} + f_{(2)}} s_{(1)}^2 + \frac{f_{(2)}}{f_{(1)} + f_{(2)}} s_{(2)}^2.$$

Bemærk at s_1^2 fremkommer som et vægtet gennemsnit af $s_{(i)}^2$ erne, hvor der gives størst vægt til variansskøn der er baseret på (relativt) mange observationer, samt at den er udfald af en $\sigma^2 \chi^2(n_1 + n_2 - 2)/(n_1 + n_2 - 2)$ -fordelt stokastisk variabel. Vi kan nu opdatere Tabel 2.2 med estimatet for den fælles varians, hvilket er gjort i Tabel 3.1.

Kontaktid	Middelværdi μ	Varians σ^2
30 sekunder	2.8072	1.064638
60 sekunder	2.7154	

Tabel 3.1: Estimer og konfidensintervaller for logaritmetransformerede data.

Vi vil nu vise, hvordan man i en modellen M_1 fra (3.9) med varianshomogenitet kan undersøge hypotesen $H_{0\mu} : \mu_1 = \mu_2$. Det test, vi udleder, er et t -test, og idéen bag det er den samme som for

t -testet udledt i Afsnit 2.2. Vi betragter differensen af middelværdierne, der under hypotesen vil være 0, og for at få et mål, som er uafhængigt af måleskalaen, dividerer vi med spredningen. Dette kan gøres præcist ved at betragte de tilhørende estimatorer. Vi har at

$$\bar{X}_{1.} \sim N\left(\mu_1, \frac{\sigma^2}{n_1}\right) \quad \text{og} \quad \bar{X}_{2.} \sim N\left(\mu_2, \frac{\sigma^2}{n_2}\right),$$

og da fordelingerne er uafhængige har vi

$$\bar{X}_{1.} - \bar{X}_{2.} \sim N\left(\mu_1 - \mu_2, \sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)\right),$$

og dermed under $H_{\mu 0}$

$$\bar{X}_{1.} - \bar{X}_{2.} \sim N\left(0, \sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)\right).$$

Derfor er

$$\frac{\bar{X}_{1.} - \bar{X}_{2.}}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1). \quad (3.11)$$

Som tidligere erstattes den ukendte varians σ^2 med den tilsvarende estimator $s_1^2(\mathbf{X})$ og da denne er uafhængig af $\bar{X}_{1.} - \bar{X}_{2.}$ og har en $\sigma^2 \chi^2(f_1)/f_1$ -fordeling fås t -testoren

$$\frac{\bar{X}_{1.} - \bar{X}_{2.}}{\sqrt{s^2(\mathbf{X}) \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} = \frac{\bar{X}_{1.} - \bar{X}_{2.}}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)} \sqrt{\frac{s^2(\mathbf{X})}{\sigma^2}}} \underset{\text{under } H_{0\mu}}{\sim} t(f_1). \quad (3.12)$$

Vi finder værdien af t -teststørrelsen i vores eksempel til

$$t(\mathbf{x}) = \frac{\bar{x}_{1.} - \bar{x}_{2.}}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} = \frac{2.8072 - 2.7154}{\sqrt{1.064638 \left(\frac{1}{16} + \frac{1}{15}\right)}} = \frac{0.0918}{0.3708} = 0.2475.$$

Både store og små værdier er kritiske og p -værdien beregnes som i Afsnit 2.2

$$p_{obs}(\mathbf{x}) = 2 [1 - F_{t(f_1)}(|t(\mathbf{x})|)] = 2 [1 - F_{t(29)}(0.2475)] = 0.81, \quad (3.13)$$

hvor antallet af frihedsgrader $f_1 = n_{(1)} + n_{(2)} - 2$ kommer fra (3.12).

Da vi ikke kan afvise at hypotesen om at middelværdierne er ens opstiller vi en ny model for data:

$$M_2 : X_{ij} \sim (\mu, \sigma^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.} \quad (3.14)$$

Vi ser, at vi dermed er tilbage i modellen for én normalfordelt observationsrække fra Afsnit fra (2.2) og vi kan nu afslutte behandlingen af datasættet, ved at angive estimator og konfidensintervaller, som findes i Tabel 3.2. To forhold er værd at bemærke:

1. Estimatet for variansen og fordelingen af den tilsvarende estimator er forskellige i M_1 og M_2 . Når vi ændrer antagelserne i modellen, ændres estimator og estimatorer som udgangspunkt også.

Kontakttdid	Estimater		
	Middelværdi μ	Varians σ^2	Spredning σ
30 & 60 sekunder	2.762677	1.031464	1.01561
95% Konfidensintervaller			
30 & 60 sekunder	[2.3903, 3.1353]	[0.6587, 1.8429]	[0.8116, 1.3575]

Tabel 3.2: Estimer og konfidensintervaller i M_2 .

2. Konfidensintervallerne i Tabel 3.2 er smallere end de konfidensintervaller, der fremgik af Tabel 2.2. Dette skyldes, at konfidensintervallerne i (3.2) er baseret på *alle* 31 observationer i datasættet, mens konfidensintervallerne i (2.2) var baseret på de to observationsrækker hver for sig ($n_{(1)} = 16$ og $n_{(2)} = 15$).

Til slut minder vi om, at modellerne $M_0 - M_2$ alle vedrører logaritmen til reaktionstiden. Vi ønsker derfor, som beskrevet i Afsnit 2.2.3, at transformere datasættet tilbage, når vi angiver de endelige estimer. Gør vi dette, fås estimatet

$$e^{2.762677} = 15.842$$

for e^μ (som nævnt i Afsnit 2.2.3 er dette medianen i fordelingen af reaktionstider). Det tilsvarende 95 % konfidensinterval findes til

$$[10.91, 22.99] \text{ sekunder.}$$

Konfidensintervaller i to observationsrækker med varianshomogenitet

I det foregående afsnit betragtede vi M_2 , fordi hypotesen om ens middelværdi ikke blev forkastet. Var hypotesen derimod blevet forkastet, ville det naturligt have været af interesse at angive et konfidensinterval for $\mu_1 - \mu_2$.

Selv i den nuværende situation, hvor vi accepterer $H_{\mu 0}$, kan det stadig være relevant at beregne et sådant konfidensinterval, fordi intervallets bredde i den konkrete sammenhæng siger noget om, hvor præcist forskellen mellem de to grupper er fastlagt. Vi går derfor tilbage til modellen (3.9) og udtrykket for konfidensintervallet kan da findes ud fra (3.12) til

$$\left\{ \bar{x}_1 - \bar{x}_2 - \sqrt{s_1^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} t_{1-\alpha/2}(f_1) \leq \mu_1 - \mu_2 \leq \bar{x}_1 - \bar{x}_2 + \sqrt{s_1^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} t_{1-\alpha/2}(f_1) \right\}. \quad (3.15)$$

Eksempel 1.5 (fortsat).

I dette eksempel finder vi ved hjælp af (3.15) og tidligere beregnede størrelser 95% konfidensintervallet til

$$\bar{x}_1 - \bar{x}_2 \pm \sqrt{s_1^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} t_{0.975}(29) = 0.0918 \pm 0.3708 \cdot 2.0452 = [-0.6666, 0.8501].$$

Som før skal vi transformere konfidensintervallet for at kunne fortolke det i den oprindelige skala. I dette tilfælde fremkommer et interval for forholdet mellem reaktionstiderne, da $\exp(\mu_1 - \mu_2) = \exp(-\mu_1)/\exp(-\mu_2)$. Som tidligere er der her tale om et konfidensinterval for medianen snarere end for middelværdien.

Det transformerede konfidensinterval findes til

$$[\exp(-0.6666), \exp(0.8502)] = [0.51, 2.34]. \quad \square$$

Vi ser altså, at dette 95 % konfidensinterval for forholdet mellem de to tidspunkter, hvor halvdelen af fluerne er faldet om i hver gruppe, ligger mellem 0.51 og 2.34. Med andre ord er det påståede tidspunkt, hvor halvdelen af fluerne er faldet om, mellem halv så stort og mere end dobbelt så stort i de to grupper. Man kan derfor konkludere, at konfidensintervallet er relativt bredt, og at forskellen mellem de to grupper ikke er fastlagt med særlig stor præcision.

3.1.3 To observationsrækker uden varianshomogenitet

Vi vil i dette afsnit gå tilbage til modellen M_0 fra (3.5), det vil sige

$$M_0 : X_{ij} \sim (\mu_i, \sigma_i^2) \quad i = 1, 2, \quad j = 1, \dots, n_i \quad + \text{ uafhængighed },$$

og nu diskutere, hvordan vi kan teste $H_{0\mu} : \mu_1 = \mu_2$ uden antagelsen om varianshomogenitet. Dette vil i sagens natur være interessant, hvis vi har afvist $H_{0\sigma^2}$, men kan også være interessant alene ud fra den betragtning, at vores primære interesse er for middelværdierne, og vi derfor ønsker at gøre så få antagelser som muligt om varianserne. Testet som vi omtaler, går under navnet “Welch’s t -test”.

Eksempel 3.1.

I dette datasæt betragtes calciummålinger i albueknoglen hos ældre kvinder, målt ved hjælp af røntgen-absorptionsmetri. Hver kvinde har fået målt calciumindholdet fire gange med et års mellemrum.

Der foreligger målinger fra i alt 31 kvinder, hvoraf $n_1 = 16$ tilhører en behandlingsgruppe, mens $n_2 = 15$ er i en kontrolgruppe. Datasættet er oprindeligt fra [Johnson and Wichern \[2007\]](#). Her betragter vi ændringen fra første til fjerde år, som angivet i Tabel 3.3. Fraktildiagrammerne er vist i Figur 3.1, og hvis vi ser bort fra en enkelt outlier i kontrolgruppen, fremstår data pænt normalfordelte, hvilket understøtter antagelsen om modellen (3.5).

Vi undersøger først $H_{0\sigma^2}$. Teststørrelsen fra (3.6) findes til

$$\mathcal{F} = \frac{s_{(1)}^2}{s_{(2)}^2} = \frac{7.367958}{18.38495} = 0.40076$$

og p -værdien findes til

$$p_{obs}(\mathbf{x}) = 2F_{F(15,14)}(0.40076) = 0.08974.$$

Selvom p -værdien ud fra det sædvanlige signifikansniveau på 0.05 ikke giver anledning til at afvise $H_{0\sigma^2}$, ønsker vi – som nævnt ovenfor – alligevel at gennemføre testen for ens middelværdi uden at antage varianshomogenitet.

Behandling	Kontrol
-1.40	-11.80
-3.50	-5.40
-4.80	-7.20
-7.50	-5.30
0.10	-5.90
-0.50	-10.60
-3.70	0.90
-0.70	-4.40
-5.20	-18.30
-8.10	-4.90
-0.20	-7.80
-1.10	-9.90
-5.00	-10.00
-5.10	-7.10
-7.10	-6.20
-3.10	

Tabel 3.3: Ændring i calciumindholdet hos ældre kvinder over fire år. De fleste oplever et fald i calciumindholdet i løbet af perioden, men forhåbningen er, at behandlingsgruppen oplever et mindre fald end kontrolgruppen.

Vi fortsætter derfor med at arbejde inden for modellen M_0 og undersøger $H_{0\mu}$ under denne. $\square$

Tankegangen er som tidligere at undersøge differensen mellem estimatorne for middelværdierne, og ved at argumentere på præcis samme måde som på side 37 kommer vi her frem til:


$$\frac{\bar{X}_{1\cdot} - \bar{X}_{2\cdot}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \underset{\text{under } H_{0\mu}}{\sim} N(0, 1).$$

En oplagt testor fås ved at indsætte estimatorer i stedet for de ukendte parametre:

$$\frac{\bar{X}_{1\cdot} - \bar{X}_{2\cdot}}{\sqrt{\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2}}} . \quad (3.16)$$

Som det fremgår, svarer denne testor ikke nøjagtigt til formen i (A.49) og er derfor ikke eksakt t -fordelt. Den er derimod *approksimativt* t -fordelt med $\bar{f}$ frihedsgrader, hvor

$$\bar{f} = \frac{\left(\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2}\right)^2}{\frac{\left(\frac{s_{(1)}^2}{n_1}\right)^2}{f_{(1)}} + \frac{\left(\frac{s_{(2)}^2}{n_2}\right)^2}{f_{(2)}}} . \quad (3.17)$$



Figur 3.1: Fraktildiagrammer for calciumindhold fra Tabel 3.3.

Bemærk at $\bar{f}$ ikke nødvendigvis er heltallig, men hvis vi betragter tætheden for t -fordelingen som fremgår af (A.50) ser vi, at der ikke i dette udtryk er noget der forhindrer ikke-heltallige frihedsgrader, når blot $f > 0$.

Et heuristisk argument for $\bar{f}$ er følgende: Vi ønsker at finde $\bar{f}$ så vi kan approksimere

$$\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2} \approx \left(\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} \right) \chi^2(\bar{f})/\bar{f} \quad (3.18)$$

Ved at bruge egenskaberne for χ^2 fordelingen som findes i Afsnit A.3.2, særligt (A.42) og (A.43) fås

$$\begin{aligned} \mathbb{V}\text{ar} \left[\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2} \right] &= \frac{2\sigma_1^4}{n_1^2 f_{(1)}} + \frac{2\sigma_2^4}{n_2^2 f_{(2)}}, \quad \text{og} \\ \mathbb{V}\text{ar} \left[\left(\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} \right) \frac{\chi^2(\bar{f})}{\bar{f}} \right] &= \left(\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} \right)^2 \frac{2}{\bar{f}}. \end{aligned}$$

og vi kan derfor tage variansen på begge sider af $\approx$ -tegnet i (3.18) og løse for $\bar{f}$:

$$\begin{aligned}\bar{f}^{-1} &= \frac{1}{\left(\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right)^2} \left(\frac{\sigma_1^4}{n_1^2 f_{(1)}} + \frac{\sigma_2^4}{n_2^2 f_{(2)}} \right) \\ &= \left[\frac{\frac{\sigma_1^2}{n_1}}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]^2 \frac{1}{f_{(1)}} + \left[\frac{\frac{\sigma_2^2}{n_2}}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]^2 \frac{1}{f_{(2)}} \\ &= \frac{\left(\frac{\sigma_1^2}{n_1}\right)^2}{\frac{f_{(1)}}{f_{(1)}} + \frac{f_{(2)}}{f_{(2)}}} + \frac{\left(\frac{\sigma_2^2}{n_2}\right)^2}{\frac{f_{(1)}}{f_{(1)}} + \frac{f_{(2)}}{f_{(2)}}} \\ &= \frac{\left(\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right)^2}{\left(\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right)^2}.\end{aligned}$$

Udtrykket i (3.17) findes nu ved at erstatte $\sigma_{(1)}^2$ og $\sigma_{(2)}^2$ med $s_{(1)}^2$ og $s_{(2)}^2$.

Eksempel 3.1 (fortsat).

For datasættet fra Tabel 3.3 har vi estimerne

$$\begin{aligned}\mu_1 &\leftarrow \bar{x}_{1\cdot} = -3.55625 & \mu_2 &\leftarrow \bar{x}_{2\cdot} = -7.59333 \\ \sigma_1^2 &\leftarrow s_{(1)}^2 = 7.367958 & \sigma_2^2 &\leftarrow s_{(2)}^2 = 18.38495.\end{aligned}$$

Ved hjælp af disse findes først t -teststørrelsen til

$$t(\mathbf{x}) = \frac{-3.55625 - (-7.59333)}{\sqrt{0.460497 + 1.22566}} = \frac{4.03708}{1.29852} = 3.10898$$

som skal undersøges i t -fordeling med $\bar{f} = 23.41172$ frihedsgrader, således at p -værdi findes til

$$p_{obs} = 2(1 - F_{t(23.41172)}(|3.10898|)) = 0.0048743.$$

Dermed afvises hypotesen om ens middelværdi i de to grupper. Da estimatet for behandlingsgruppen er højere end for kontrolgruppen, tyder data på, at patienterne i førstnævnte har haft gavn af behandlingen. $\square$

Vi afslutter dette afsnit med at bemærke, at man også kan finde et $(1 - \alpha)$ -konfidensinterval for $\mu_1 - \mu_2$ ud fra vores resultat om den approksimative t -fordeling i (3.16).

Med t -teststørrelsen

$$t(\mathbf{x}) = \frac{\bar{x}_{1\cdot} - \bar{x}_{2\cdot}}{\sqrt{\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2}}},$$

findes dette til

$$\left\{ \bar{x}_{1\cdot} - \bar{x}_{2\cdot} - \sqrt{\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2}} t_{1-\alpha/2}(\bar{f}) \leq \mu_1 - \mu_2 \leq \bar{x}_{1\cdot} - \bar{x}_{2\cdot} + \sqrt{\frac{s_{(1)}^2}{n_1} + \frac{s_{(2)}^2}{n_2}} t_{1-\alpha/2}(\bar{f}) \right\}. \quad (3.19)$$

For di denne udledning benytter en *approksimativ* t -fordeling, er konfidensintervallet også strengt taget kun et *approksimativt* konfidensinterval. Selv når $\mu_1 = \mu_2$ kan man kun konkludere, at den stokastiske pendant til (3.19) indeholder $\mu_1 - \mu_2$ med *omtrent* $(1 - \alpha)\%$ sandsynlighed.

Appendiks til Afsnit 3.1

Beregninger i R

Alle de udtryk, som er gennemgået i Kapitel 2 og Afsnit 3.1, kan udregnes ved at bruge R som “lommeregner” og benytte funktioner som `mean`, `sd` og `var` til henholdsvis gennemsnit, empirisk spredning og empirisk varians. Dette gælder også t -testet for én observationsrække med ukendt varians, som blev omtalt i Afsnit 2.2.

R har imidlertid en indbygget funktion beregnet til dette formål, nemlig `t.test`. Hvis vores data ligger i en vektor `x`, og vi ønsker at teste hypotesen om, at middelværdien f.eks. er lig 22.0, kan vi kalde

R-kode 3.1

```
t.test(x, mu=22.0)
```

Hvis `mu` ikke specificeres i kaldet, laves der et test for, at middelværdien er nul. Hvis output fra `t.test` placeres i `tTestUD`, vil denne blandt andet indeholde følgende:

<code>tTestUD\$statistic</code>	t -teststørrelsen
<code>tTestUD\$par</code>	frihedsgrader i t -fordelingen
<code>tTestUD\$p.value</code>	p -værdi for testet
<code>tTestUD\$conf.int</code>	95%-konfidensinterval for middelværdien

Vi betragter nu Eksempel 2.1, der omhandlede målinger af spænding ved en automatiseret svejsningsproces. På R-kode 3.2 er indholdet i Tabel 2.1 indlæst i en vektor `Volt`.

R-kode 3.2:

```
Volt <- c(21.89, 22.20, 21.80, 22.75, 22.26, 21.88, 22.25,
         22.41, 22.35, 22.01, 22.71, 22.22, 21.95, 21.27, 22.56,
         22.11, 22.19, 22.42, 22.45, 22.36, 22.48, 22.43, 22.16,
         21.36, 22.37, 22.10, 22.07, 21.56, 21.94, 22.29)
```

Kører vi `t.test` som på R-kode 3.3

R-kode 3.3:

```
t.test(Volt, mu=22.0)
```

fås output som fremgår af R-udskrift 3.1.

R-udskrift 3.1:

```

One Sample t-test

data:  Volt
t = 2.5, df = 29, p-value = 0.01833
alternative hypothesis: true mean is not equal to 22
95 percent confidence interval:
 22.0291 22.2909
sample estimates:
mean of x
 22.16

```

I R-output 3.1 genkendes en lang række af de størrelser som blev beregnet i Afsnit 6.2.2, herunder p -værdien fra (2.12).

Vi betragter nu beregninger i **R** for modellen med to normalfordelte observationsrækker.

I modellen M_0 fra (3.5) med to normalfordelte observationsrækker kan man lave F -testet for hypotesen om ens varianser med **R**-funktionen **var.test**. Hvis data ligger i to vektorer **x1** og **x2**, ser kaldet således ud:

R-kode 3.4

```
var.test(x1, x2)
```

I output kan man finde F -teststørrelsen (**statistic**) samt de tilhørende antal frihedsgrader (**parameter**), og p -værdien (**p.value**). Der angives også et 95%-konfidensinterval for *forholdet* mellem de to variansparametre σ_1^2/σ_2^2 .

Vi illustrerer dette med data fra Eksempel 1.5, der omhandlede reaktionstiden for to grupper (30 sekunder og 60 sekunder) af fluer, som var blevet udsat for en nervegas. Data findes i Tabel 1.1, og i R-kode 3.5 indlæses det oprindelige datasæt, hvorefter de logaritmetransformerede data dannes (jf. Afsnit 1.3). Til sidst køres **var.test** på de logaritmetransformerede data.

R-kode 3.5:

```

grp30 <- c(3,5,5,7,9,9,10,12,20,24,24,34,43,46,58,140)
grp60 <- c(2,5,5,7,8,9,14,18,24,26,26,34,37,42,90)
loggrp30 <- log(grp30)
loggrp60 <- log(grp60)
var.test(loggrp30, loggrp60)

```

På R-udskrift 3.2 ses resultatet af ovenstående.

R-udskrift 3.2

```

F test to compare two variances

data:  loggrp30 and loggrp60
F = 1.0774, num df = 15, denom df = 14, p-value = 0.894
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.365299 3.115233
sample estimates:
ratio of variances
 1.077384

```

Vi genkender de størrelser, som blev beregnet i Afsnit 3.1.1, herunder p -værdien fra (3.7).

For at teste om middelværdierne er ens i to normalfordelinger, skal man enten bruge t -testet fra Afsnit 3.1.2, hvis de to varianser er ens, eller også bruge Welch's test, hvis de to varianser ikke er ens. Begge de to tests udregnes med `t.test`. Hvis data ligger i to vektorer `x1` og `x2` bliver kaldet, hvis de to varianser er ens,

R-kode 3.6

```
t.test(x1,x2,var.equal=TRUE)
```

og hvis de to varianser er forskellige,

R-kode 3.7

```
t.test(x1,x2,var.equal=FALSE)
```

Output indeholder t -teststørrelsen (`statistic`), antallet af frihedsgrader (`parameter`) og p -værdien (`pvalue`) for test af hypotesen, om at de to middelværdier er ens. Desuden angives et 95%-konfidensinterval for forskellen i middelværdi (`conf.int`), det vil sige for parameteren $\delta = \mu_1 - \mu_2$.

For t -testet med varianshomogenitet betragtes igen data fra Eksempel 1.5.

Køres `t.test(loggrp30,loggrp60,var.equal = TRUE)` fås

R-udskrift 3.3

```

Two Sample t-test

data:  loggrp30 and loggrp60
t = 0.24725, df = 29, p-value = 0.8065
alternative hypothesis: true difference in means is not equal to 0

```

```
95 percent confidence interval:
 -0.6666972  0.8500595
sample estimates:
mean of x mean of y
 2.807217  2.715536
```

I R-udskrift 3.3 genfinder vi blandt andet p -værdi og 95%-konfidensinterval fra Afsnit 3.1.2.

Welch's test illustreres ved hjælp af datasættet fra Tabel 3.3.

R-kode 3.8

```
kontrolgruppe <- c(-11.8, -5.4, -7.2, -5.3, -5.9,
                  -10.6, 0.9, -4.4, -18.3, -4.9, -7.8,
                  -9.9, -10.0, -7.1, -6.2)
behandlingsgruppe <- c(-1.4, -3.5, -4.8, -7.5, 0.1,
                       -0.5, -3.7, -0.7, -5.2, -8.1, -0.2,
                       -1.1, -5.0, -5.1, -7.1, -3.1)
t.test(behandlingsgruppe, kontrolgruppe, var.equal = FALSE)
```

Outputtet bliver

R-udskrift 3.4

```
Welch Two Sample t-test

data:  behandlingsgruppe and kontrolgruppe
t = 3.109, df = 23.412, p-value = 0.004874
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 1.353496 6.720670
sample estimates:
mean of x mean of y
-3.556250 -7.593333
```

Vi genfinder de beregnede størrelser fra Afsnit 3.1.3, herunder p -værdien og frihedsgraderne $\bar{f} = 23.41172$ fra den approksimative t -fordeling.

Til slut vil vi bemærke, at ovenstående kald til `t.test` og `var.test` også kan foretages ved hjælp af "formel-syntaksen", som vi senere vil benytte, når vi skal se nærmere på `lm`. For at gøre dette, skal vi først oprette en `data.frame`. Vi illustrerer dette med data fra Tabel 3.3.

R-kode 3.9

```

gruppe <- c(rep("kontrol", 15), rep("behandling", 16))
calc <- c(kontrolgruppe, behandlingsgruppe)
calcium <- data.frame(calc=calc, gruppe=gruppe)

```

Køres kommandoen `head(calcium)` fås

R-udskrift 3.5

```

      calc gruppe
1 -11.8 kontrol
2  -5.4 kontrol
3  -7.2 kontrol
4  -5.3 kontrol
5  -5.9 kontrol
6 -10.6 kontrol

```

Som det fremgår, indeholder `calcium` målingerne af calcium i `calc` variabelen og gruppen i faktorvariabelen `gruppe`. Welch's *t*-test kan nu køres ved hjælp af

R-kode 3.10

```

t.test(calc~gruppe, data=calcium, var.equal=FALSE)

```

Bemærk, at i R-kode 3.10 indeholder kaldet til `t.test` `calc~gruppe`, hvilket har formen *interessevariabel ~ forklarende variabel*. Outputtet fra R-kode 3.10 kan ses i R-udskrift 3.6, og er — ud over kosmetiske forskelle — identisk med R-udskrift 3.4.

R-udskrift 3.6

```

Welch Two Sample t-test

data:  calc by gruppe
t = 3.109, df = 23.412, p-value = 0.004874
alternative hypothesis: true difference in means between group behandling
      and group kontrol is not equal to 0
95 percent confidence interval:
 1.353496 6.720670
sample estimates:
mean in group behandling      mean in group kontrol
      -3.556250                -7.593333

```

3.2 k observationsrækker

Vi vil i dette afsnit betragte modellen med k uafhængige observationsrækker, som blev indført i (3.2), det vil sige modellen hvor data x_{ij} betragtes som udfald af stokastiske variable X_{ij} hvor

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.} \quad (3.20)$$

Vi omtaler k observationsrækker i forbindelse med Eksempel 3.2, der er beskrevet i Blæsild and Granfeldt [2002].

Eksempel 3.2.

En plantefysiolog undersøgte virkningen af mekanisk stress på væksten af sojabønner. 52 stiklinger blev plantet i pletter, én i hver plette. De 52 stiklinger blev tilfældigt inddelt i fire grupper med 13 i hver. Stiklingerne i to af grupperne blev stresset ved at blive rystet i tyve minutter dagligt, mens stiklingerne i de to andre grupper ikke blev rystet. Desuden voksede to af grupperne i svagt lys, og de andre to grupper i moderat lys, således at de fire grupper fik hver sin behandling:

- Gruppe 1 : svagt lys, ingen stress
- Gruppe 2 : svagt lys, stress
- Gruppe 3 : moderat lys, ingen stress
- Gruppe 4 : moderat lys, stress

Målingerne findes i Tabel 3.4. Efter 16 dages vækst blev planterne høstet, og det samlede bladareal på hver plante blev målt. Resultaterne, ordnet efter størrelse, er vist i Tabel 3.4. Modelkontrollen består først i at vi tegner fraktildiagrammer for at undersøge antagelsen om data er normalfordelt. Dette er gjort i Figur 3.2 og vi konstaterer at data ser fint normalfordelt ud. Vi bemærker også at punkterne i de fire grupper fordeler sig omkring fire nogenlunde parallelle linjer, hvilket antyder varianserne i grupperne godt kunne være ens, jvf. Opgave 1.5 i opgavesamlingen. $\square$


Vi vil derfor betragte (3.2) som model for data, og vil først betragte et egentligt test for om vi kan antage at varianserne i grupperne er ens.

3.2.1 Bartlett's test af hypotesen om en fælles varians

Vi vil i dette afsnit betragte hypotesen om varianshomogenitet, $H_{0\sigma^2} : \sigma_1^2 = \dots = \sigma_k^2 = \sigma^2$. Vores motivation er modellen (3.2), men vi er interesserede i at undersøge varianshomogenitet i nogle mere generelle modeller end (3.2). Vi betragter derfor ikke den fulde likelihood funktion som er antydnet i (3.4), men tager i stedet udgangspunkt i skønnene $s_{(1)}^2, \dots, s_{(k)}^2$ over varianserne $\sigma_1^2, \dots, \sigma_k^2$ og opskriver en likelihoodfunktion for disse.

Variansskønnenes fordeling er

$$s_{(i)}^2 \sim \sigma_i^2 \chi^2(f_{(i)})/f_{(i)}, \quad i = 1, \dots, k,$$



Figur 3.2: Fraktildiagrammer for data i Tabel 3.4.

og estimatorerne er uafhængige. Man kan derfor opskrive den simultane tæthed for $s_{(1)}^2, \dots, s_{(k)}^2$, og opfattet som funktion af $\sigma_1^2, \dots, \sigma_k^2$ er det en likelihood funktion. Tætheden findes i Afsnit A.3.2 og likelihood funktionen er

$$L(\sigma_1^2, \dots, \sigma_k^2) = \prod_{i=1}^k \left[\frac{\left(\frac{f(i)}{2\sigma_i^2}\right)^{\frac{f(i)}{2}}}{\Gamma\left(\frac{f(i)}{2}\right)} \left(s_{(i)}^2\right)^{\frac{f(i)}{2}-1} e^{-\frac{f(i)s_{(i)}^2}{2\sigma_i^2}} \right] \quad (3.21)$$

$$= \prod_{i=1}^k \left[\frac{\left(\frac{f(i)}{2}\right)^{\frac{f(i)}{2}}}{\Gamma\left(\frac{f(i)}{2}\right)} \left(s_{(i)}^2\right)^{\frac{f(i)}{2}-1} \left(\frac{1}{\sigma_i^2}\right)^{\frac{f(i)}{2}} e^{-\frac{f(i)s_{(i)}^2}{2\sigma_i^2}} \right] \quad (3.22)$$

Samlet areal i cm ²			
Gruppe			
1	2	3	4
200	163	268	201
215	182	271	216
225	188	273	241
229	195	282	257
230	202	285	259
232	205	299	267
241	212	309	269
253	214	310	282
256	215	314	283
264	230	320	291
268	235	337	291
288	255	340	312
288	272	345	326
Middelværdier			
245.31	212.92	304.08	268.85

Tabel 3.4: Gruppe 1: svagt lys, ingen stress; Gruppe 2: svagt lys, stress; Gruppe 3: moderat lys, ingen stress; Gruppe 4: moderat lys, stress.

Vi ser af (3.22) at L er et produkt af k funktioner der hver afhænger af hver sin af de k parametre $\sigma_1^2, \dots, \sigma_k^2$ og vi kan maksimere likelihoodfunktionen ved at finde maksimum af hver af de k funktioner for sig. Man finder derfor, at maksimum af likelihoodfunktionen antages for $\sigma_i^2 = s_{(i)}^2$, og at maksimum af likelihoodfunktionen er

$$L(s_{(1)}^2, \dots, s_{(k)}^2) = \prod_{i=1}^k \left[\frac{\left(\frac{f_{(i)}}{2}\right)^{\frac{f_{(i)}}{2}}}{\Gamma\left(\frac{f_{(i)}}{2}\right)} \frac{1}{s_{(i)}^2} e^{-\frac{f_{(i)}}{2}} \right]. \quad (3.23)$$

Under $H_{0\sigma^2}$ er $\sigma_1^2 = \dots = \sigma_k^2 = \sigma^2$, og likelihoodfunktionen bliver

$$\begin{aligned} L(\sigma^2) &= \prod_{i=1}^k \left[\frac{\left(\frac{f_{(i)}}{2}\right)^{\frac{f_{(i)}}{2}}}{\Gamma\left(\frac{f_{(i)}}{2}\right)} \left(s_{(i)}^2\right)^{\frac{f_{(i)}}{2}-1} \left(\frac{1}{\sigma^2}\right)^{\frac{f_{(i)}}{2}} e^{-\frac{f_{(i)} s_{(i)}^2}{2\sigma^2}} \right] \\ &= \prod_{i=1}^k \left[\frac{\left(\frac{f_{(i)}}{2}\right)^{\frac{f_{(i)}}{2}}}{\Gamma\left(\frac{f_{(i)}}{2}\right)} \frac{1}{s_{(i)}^2} \right] \prod_{i=1}^k \left[\left(s_{(i)}^2\right)^{\frac{f_{(i)}}{2}} \left(\frac{1}{\sigma^2}\right)^{\frac{f_{(i)}}{2}} e^{-\frac{f_{(i)} s_{(i)}^2}{2\sigma^2}} \right], \end{aligned}$$

hvor vi benytter, at $\sum_{i=1}^k f_{(i)} s_{(i)}^2 = \sum_{i=1}^k \text{SSD}_{(i)} = f_1 s_1^2$ med $f_1 = \sum_{i=1}^k f_{(i)} = n - k$. $L(\sigma^2)$ antager

sit maksimum for $\sigma^2 = s_1^2$. Det betyder, at estimatet for σ^2 , når $\sigma_1^2 = \dots \sigma_k^2 = \sigma^2$, er

$$\begin{aligned} s_1^2 &= \frac{\text{SSD}_1}{f_1} = \frac{\text{SSD}_{(1)} + \dots + \text{SSD}_{(k)}}{f_{(1)} + \dots + f_{(k)}} \\ &= \frac{f_{(1)}s_{(1)}^2 + \dots + f_{(k)}s_{(k)}^2}{f_{(1)} + \dots + f_{(k)}}. \end{aligned} \quad (3.24)$$

Maksimum af likelihoodfunktionen under $H_{0\sigma^2}$ er

$$L(s_1^2) = \prod_{i=1}^k \left[\frac{\left(\frac{f(i)}{2}\right)^{\frac{f(i)}{2}}}{\Gamma\left(\frac{f(i)}{2}\right)} \frac{1}{s^2(i)} \right] \prod_{i=1}^k [s_{(i)}^2]^{\frac{f(i)}{2}} \left(\frac{1}{s_1^2}\right)^{\frac{f_1}{2}} e^{-\frac{f_1}{2}}. \quad (3.25)$$

Likelihood ratio teststørrelsen, $Q(\mathbf{x})$, er forholdet mellem (3.23) og (3.25), så

$$Q(\mathbf{x}) = \frac{\prod_{i=1}^k s_{(i)}^{\frac{f(i)}{2}}}{s_1^{\frac{f_1}{2}}}$$

og dermed er

$$-2 \ln Q(\mathbf{x}) = f_1 \ln s_1^2 - \sum_{i=1}^k f_{(i)} \ln s_{(i)}^2 \quad (3.26)$$

Ved hjælp af asymptotisk likelihood-teori kan det vises, at $-2 \ln Q$ approksimativt er χ^2 -fordelt med $k - 1$ frihedsgrader. Dette skyldes, at man går fra en model med k parametre $(\sigma_1^2, \dots, \sigma_k^2)$ til en model med én parameter σ^2 .

M.S. Bartlett viste i 1937, at denne approksimation til χ^2 -fordelingen kan forbedres, hvis man dividerer $-2 \ln Q(\mathbf{x})$ med konstanten

$$C = 1 + \frac{1}{3(k-1)} \left[\left(\sum_{i=1}^k \frac{1}{f_{(i)}} \right) - \frac{1}{f_1} \right].$$

Teststørrelsen

$$Ba = \frac{-2 \ln Q(\mathbf{x})}{C}$$

kaldes *Bartletts test*. Approksimationen til $\chi^2(k-1)$ -fordelingen er tilfredsstillende, hvis $f_{(i)} \geq 2$ for $i = 1, \dots, k$, dvs. hvis der er mindst tre observationer i hver observationsrække.

Da $-2 \ln Q$ stammer fra et likelihood ratio test, er det små værdier af Q , der er kritiske for nulhypotesen, og dermed store værdier af $-2 \ln Q$, der er kritiske. Testsandsynligheden beregnes derfor som

$$p_{\text{obs}}(\mathbf{x}) = 1 - F_{\chi^2(k-1)}(Ba),$$

hvor $F_{\chi^2(k-1)}$ er fordelingsfunktionen for χ^2 -fordelingen med $k - 1$ frihedsgrader.

Eksempel 3.2 (fortsat).

Estimatet s_1^2 for den fælles varians under $H_{0\sigma^2}$ er som tidligere nævnt et vægtet gennemsnit af estimerne for varianserne i M_0 , men da der i dette tilfælde er $n_i = 13$ observationer i alle observationsrækker vil her være tale om et simpelt gennemsnit. Estimerne udregnes til

$$\begin{aligned} s_{(1)}^2 &= 730.231 & s_{(2)}^2 &= 884.910 & s_{(3)}^2 &= 724.910 & s_{(4)}^2 &= 1241.308 \\ s_1^2 &= \frac{730.231 + 884.910 + 724.910 + 1241.308}{4} = 895.340. \end{aligned} \quad (3.27)$$

Vi finder derved

$$-2 \ln Q = 1.1999,$$

og

$$C = 1.03472,$$

og dermed

$$Ba = \frac{-2 \ln Q}{C} = \frac{1.1999}{1.03472} = 1.160$$

Vi kan da finde testsandsynligheden:

$$p_{obs}(\mathbf{x}) = 1 - F_{\chi^2(3)}(1.160) = 0.763.$$

Vi kan altså ikke afvise $H_{0\sigma^2}$ og betragter derfor fremadrettet en model med ens varians. $\square$

3.2.2 Test af hypotesen om en fælles middelværdi

Vi vil nu betragte modellen

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \dots, k \quad j = 1, \dots, n_i \quad + \text{ uafhængighed.} \quad (3.28)$$

Estimerne for middelværdierne i modellen er (stadig) $\bar{x}_i$, $i = 1, \dots, k$ og estimatet for variansen for variansen er s_1^2 fra (3.24) som i M_1 er en realisation af en $\sigma^2 \chi^2(f_1)/f_1$ fordeling.

I M_1 vil vi være interesserede i hypotesen om at middelværdierne er ens, altså hypotesen

$$H_{0\mu} : \mu_1 = \mu_2 = \dots = \mu_k.$$

Hvis $H_{0\mu}$ ikke afvises, vil vi antage alle middelværdierne er ens og vi vil derfor være i modellen for én observationsrække, som vi her vil betegne M_2 . Vi siger at vi *reducerer* fra modellen M_1 til modellen M_2 .

Vi viser senere nogle generelle resultater om *lineære normal modeller* og både M_1 og M_2 er et eksempel på en sådan modeller. Vi viser, at når man skal reducere fra en lineær normal model M_1 til en undermodel M_2 , der også er en lineær normal model, så bliver likelihood ratio testet lig med

$$Q(\mathbf{x}) = \left[\frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} \right]^{\frac{n}{2}}, \quad (3.29)$$

hvor $\hat{\sigma}_i^2$ $i = 1, 2$ er *maksimum likelihood estimatorne* for varianserne i de respektive modeller. Modelreduktion inden for lineære normale modeller foretages altså ved at undersøge hvor meget estimatet for variansen ændrer sig, når vi går fra en grundmodel M_1 til en undermodel M_2 og analyser af denne typer går ofte under navnet *variansanalyse* eller *analysis of variance*, forkortet *ANOVA*. Den analyse som omtales i dette afsnit, kaldes specifikt *ensidet variansanalyse* eller *one-way ANOVA*. I afsnit 5.3 omtales tosidet variansanalyse, der også kaldes *two-way ANOVA*.

Vi vil nu regne videre på udtrykket i (3.29). Dette vil vi dels gøre, fordi vi derved kan give likelihood ratio testet yderligere fortolkning og dels fordi vi derved udleder nogle størrelser som gengives af statistiske programpakker.

Som tidligere bemærket er M_2 modellen for én observationsrække, der blot her er udtrykt med en lidt mere kompliceret notation. Vi får derfor fra (2.22) at maksimum likelihood estimatet $\hat{\sigma}_2^2$ for variansen under M_2 er

$$\hat{\sigma}_2^2 = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{..})^2 \stackrel{\text{def}}{=} \frac{1}{n} \text{SSD}_T \quad (3.30)$$

Her har vi indført betegnelsen SSD_T indikerer at vi fortolker udtrykket som den *Totale variation* af observationerne omkring $\bar{x}_{..}$, det vil sige om det totale gennemsnit. Maksimum likelihood estimatet $\hat{\sigma}_1^2$ er angivet i (3.10) for $k = 2$ som summen af $\text{SSD}_{(i)}$ $i = 1, 2$ divideret med n og dette generaliserer naturligt til k grupper idet der for generelt k gælder at

$$\hat{\sigma}_1^2 = \frac{1}{n} (\text{SSD}_{(1)} + \text{SSD}_{(2)} + \cdots + \text{SSD}_{(k)}) . \quad (3.31)$$

Vi kan dekomponere den totale variation i to led SSD_E og SSD_H , hvor betegnelserne dækker over SSD_{Error} og $\text{SSD}_{Hypothesis}$:

$$\begin{aligned} \text{SSD}_T &= \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{..})^2 \\ &= \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.} + \bar{x}_{i.} - \bar{x}_{..})^2 \\ &= \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.})^2 + \sum_{i=1}^k n_i (\bar{x}_{i.} - \bar{x}_{..})^2 \\ &\quad + 2 \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.}) (\bar{x}_{i.} - \bar{x}_{..}) \\ &= \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.})^2 + \sum_{i=1}^k n_i (\bar{x}_{i.} - \bar{x}_{..})^2 \\ &= \underbrace{\sum_{i=1}^k \text{SSD}_{(i)}}_{\text{SSD}_E} + \underbrace{\sum_{i=1}^k n_i (\bar{x}_{i.} - \bar{x}_{..})^2}_{\text{SSD}_H} . \end{aligned} \quad (3.32)$$

hvor det dobbelte produkt giver 0 da

$$2 \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.})(\bar{x}_{i.} - \bar{x}_{..}) = 2 \sum_{i=1}^k (\bar{x}_{i.} - \bar{x}_{..}) \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.}) = 0.$$

Som det fremgår, sammenfatter SSD_E observationernes variation omkring gennemsnittene $\bar{x}_{i.}$ i de k grupper, mens SSD_H beskriver variation af disse gennemsnit omkring det totale gennemsnit $\bar{x}_{..}$.

Figur 3.3a illustrerer de tre typer variation ved at vise observationerne i de fire observationsrækker sammen med de tilhørende gruppegennemsnit (markeret med ●) samt det totale gennemsnit (markeret med en vandret linje).

Fortolkningen af SSD_T , SSD_E og SSD_H er, at hvis der *ikke* er nogen gruppeinddeling i vores data (det vil sige, at M_2 er sand), vil SSD_T danne grundlag for estimation af variansen (jf. (3.30)), mens det i grundmodellen M_1 er SSD_E , som danner grundlag for estimation af variansen (jf. (3.31)). Vi siger derfor, at SSD_H er den del af variationen, der er "forklaret" af modellen M_1 , mens SSD_E er den uforklarede variation i M_1 . I M_2 er det al variationen, dvs. SSD_T , som er uforklaret.

På grund af denne fortolkning er det nærliggende at undersøge $H_{0\mu}$ ved at vurdere, om SSD_H er stor i forhold til SSD_E . Hvis dette er tilfældet, vil modellen forklare en stor del af den variation, vi observerer i datasættet, og vi vil derfor være tilbøjelige til at afvise $H_{0\mu}$.

Denne intuition stemmer overens med likelihood-ratio-testen, hvilket vi nu viser ved at regne videre på (3.33) under anvendelse af (3.30), (3.31) og (3.32):

$$\begin{aligned} Q(\mathbf{x}) &= \left[\frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} \right]^{\frac{n}{2}} = \left[\frac{\frac{1}{n} SSD_E}{\frac{1}{n} SSD_T} \right]^{\frac{n}{2}} \\ &= \left[\frac{1}{1 + \frac{SSD_H}{SSD_E}} \right]^{\frac{n}{2}} = \left[\frac{1}{1 + \frac{k-1}{n-k} \mathcal{F}(\mathbf{x})} \right]^{\frac{n}{2}}, \end{aligned} \quad (3.33)$$

hvor

$$\mathcal{F}(\mathbf{x}) \stackrel{\text{def}}{=} \frac{\frac{SSD_H}{k-1}}{\frac{SSD_E}{n-k}} = \frac{SSD_H}{s_1^2}.$$

Det ses af (3.33) at $\mathcal{F}(\mathbf{x})$ er en aftagende funktion af $Q(\mathbf{x})$ og omvendt og små værdier af Q vil derfor svare til store værdier af $\mathcal{F}(\mathbf{x})$. Det kan vises at hvis $H_{0\mu}$ er sand vil de stokastiske variable svarende til SSD_E og SSD_H være uafhængige og henholdsvis $\chi^2(k-1)$ og $\chi^2(n-k)$ fordelt, og vi kan derfor opskrive p_{obs}

$$p_{obs} = \mathbb{P}(Q(\mathbf{X}) \leq Q(\mathbf{x})) = \mathbb{P}(\mathcal{F}(\mathbf{X}) \geq \mathcal{F}(\mathbf{x})) = 1 - F_{F(k-1, n-k)}(\mathcal{F}(\mathbf{x})), \quad (3.34)$$

hvor det er underforstået at sandsynlighederne er udregnet under $H_{0\mu}$.

Eksempel 3.2 (fortsat).

Vi kan beregne $\mathcal{F}(x)$ ud fra s_1^2 og SSD_H . I dette eksempel er s_1^2 beregnet i (3.27) hvor vi fandt

$$s_1^2 = 895.340.$$

SSD_H vil ofte være lettest at beregne som $\text{SSD}_T - \text{SSD}_E$ da SSD_E kan findes som $(n-k)s_1^2$ og SSD_T vil være $n-1$ ganget med variansestimateret, når hele datasættet opfattes som en observationsrække. I dette tilfælde finder vi

$$\text{SSD}_H = 100612.673 - 42976.308 = 57636.365$$

og dermed

$$\frac{\text{SSD}_H}{k-1} = \frac{57636.365}{3} = 19212.122.$$

Vi kan derfor beregne F -teststørrelsen til

$$\mathcal{F}(\mathbf{x}) = \frac{19212.122}{895.340} = 21.46.$$


Hvis hypotesen er korrekt, er dette udfald af en $F(3, 48)$ fordeling, og som nævnt ovenfor, vil større værdier være at betragte som kritiske for hypotesen. Vi finder derved

$$p_{obs} = 1 - F_{F(3,48)}(21.46) = 0.000000006.$$

På grund af den lave p -værdi er meget sikre på at vi kan forkaste $H_{0\mu}$, og betragter derfor modellen M_1 for datasættet. I denne model har vi estimererne

$$\mu_1 \leftarrow 245.3 \quad \mu_2 \leftarrow 212.9 \quad \mu_3 \leftarrow 304.1 \quad \mu_4 \leftarrow 268.8.$$

Hvis vi går tilbage til udgangspunktet for eksperimentet, kunne det være interessant at sige noget om hvordan lys og stress hver for sig påvirker bladvæksten, men det er svært at sige udtale sig i denne model. Vi vil senere vende tilbage til denne problemstilling, når vi undersøger modellen for *tosidet variansanalyse*.



(a) Den horisontale linie markerer det totale gennemsnit for alle observationer, mens gruppegennemsnit er markeret med ●.

(b) Boxplot af datasættet.

Figur 3.3: To illustrationer af datasættet fra Tabel 3.4.

Kapitel 4

Lineær regression

I dette kapitel skal vi betragte modellen *lineær regression*. Vores datasæt består af n talpar (t_i, x_i) $i = 1, \dots, n$, hvor vi opfatter $x_1, \dots, x_n$ som realisationer af stokastiske variable $X_1, \dots, X_n$, mens $t_1, \dots, t_n$ opfattes som faste.

Vi vil betragte to eksempler, og indleder med Eksempel 4.1.


logColi	logGlu
2.80	-1.05
2.86	-1.04
2.88	-1.10
2.86	-1.21
3.07	-1.28
$\vdots$	$\vdots$
3.38	-1.01
2.83	-1.05

Tabel 4.1: Del af datasættet fra Eksempel 4.1, der består af samhörrende målinger af logaritmen til mængden af E.coli og logaritmen til GLUase aktiviteten.

Eksempel 4.1.

Måling af mængden af E. coli bakterier i vandprøver bruges som mål for forureningsgraden af prøven. Målemetoden betragtes som præcis, men er langsom, og man er derfor interesseret i alternativer. Data i dette eksempel vedrører brugen af GLUase-aktivitet som et alternativ. Data er aflæst fra figur i artiklen [Farnleitner et al. \[2001\]](#) og består af 98 samhörrende værdier af variablene *logColi* og *logGlu* med henholdsvis logaritmen til mængden af E.coli (log cfu E. coli pr. 100 ml) og logaritmen til GLUase aktiviteten (log nM MUF pr. minut). Vandprøverne stammer fra forskellige østrigske floder og blev indsamlet i 1998–1999.

En del af datasættet er vist i Tabel 4.1, mens det fulde datasæt er vist i Tabel 4.4. Figur 4.1 viser et scatterplot, hvor *logGlu* er afsat mod *logColi*.



Figur 4.1: Scatterplot af data fra Eksempel 4.1

4.1 Den lineære regressionsmodel

Den lineære regressionsmodel for data (t_i, x_i) , $i = 1, \dots, n$, er at x_i 'erne er realisationer af uafhængige stokastiske variable X_i , som har fordelingen

$$M_2 : X_i \sim N(\alpha + \beta t_i, \sigma^2), \quad i = 1, \dots, n. \quad (4.1)$$

Modellen omtales som en lineær regression af x på t . Linjen $x(t) = \alpha + \beta t$ kaldes *regressionslinjen*. Parameteren α er regressionslinjens skæring med andenaksen, og β er hældningen. Parameteren α kaldes *afskæringen* (*intercept*), og β kaldes *hældningen* (*slope*) eller *regressionskoefficienten*. Variablen x kaldes den *afhængige variabel*, og t omtales som den *uafhængige variabel*. Denne sprogbrug opstår ved at betragte x som en funktion af t ; “uafhængighed” i denne sammenhæng skal ikke forveksles med uafhængighed af stokastiske variable. Alternativt kan x kaldes *responsen*, mens t kan kaldes den *forklarende variabel*, og dette vil være vores foretrukne betegnelser.

Estimation i modellen M_2 foretages med likelihood metoden. Likelihoodfunktion findes til

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \alpha - \beta t_i)^2} = \frac{1}{\sqrt{2\pi\sigma^2}^n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \alpha - \beta t_i)^2}.$$

og log likelihoodfunktionen er

$$l(\alpha, \beta, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n \{x_i - (\alpha + \beta t_i)\}^2.$$

Først maksimeres log likelihoodfunktionen for fast σ^2 . Differentieres med hensyn til α og β fås følgende to likelihoodligninger til bestemmelse af estimaterne

$$\begin{aligned} \sum_{i=1}^n \{x_i - (\hat{\alpha} + \hat{\beta} t_i)\} &= 0, \\ \sum_{i=1}^n \{x_i - (\hat{\alpha} + \hat{\beta} t_i)\} t_i &= 0. \end{aligned}$$

Løses første ligning for $\hat{\alpha}$ fås $\hat{\alpha} = \bar{x} - \hat{\beta} \bar{t}$. og indsættes dette i anden ligning fås

$$\sum_{i=1}^n \{x_i - \bar{x} - \hat{\beta}(t_i - \bar{t})\} t_i = 0$$

som løses til

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x}) t_i}{\sum_{i=1}^n (t_i - \bar{t}) t_i} = \frac{\sum_{i=1}^n (x_i - \bar{x})(t_i - \bar{t})}{\sum_{i=1}^n (t_i - \bar{t})^2}, \quad (4.2)$$

hvor vi i andet lighedstegn benytter at $\sum_{i=1}^n (x_i - \bar{x}) \bar{t} = 0$ og $\sum_{i=1}^n (t_i - \bar{t}) \bar{t} = 0$. At de fundne udtryk for $\hat{\alpha}$ og $\hat{\beta}$ vitterligt maksimale følger af at ℓ går mod minus uendelig når α og β går mod uendelig. Der gælder dermed

$$l(\alpha, \beta, \sigma^2) \leq l(\hat{\alpha}, \hat{\beta}, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n \{x_i - (\hat{\alpha} + \hat{\beta} t_i)\}^2.$$

Vi kan nu benytte Lemma 2.2 til at konkludere at

$$\hat{\sigma}^2(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \{x_i - (\hat{\alpha} + \hat{\beta} t_i)\}^2. \quad (4.3)$$

Middelværdien af X_i er $\alpha + \beta t_i$ og hvis vi ikke kendte x_i ville vores bedste bud på denne være estimatet

$$\hat{x}_i \stackrel{\text{def}}{=} \hat{\alpha} + \hat{\beta} t_i. \quad (4.4)$$

Vi har tidligere indført betegnelsen den *prædikterede værdi* (engelsk: *predicted value*) for vores bud på x_i , denne vil vi også kalde for den *fittede værdi* (engelsk: *fitted value*).

Vi ser at $\hat{\sigma}^2$ er en skaleret SSD størrelse, som vi betegner SSD_{02} , og bemærker at den måler afstanden mellem observationerne og de tilsvarende prædikterede værdier, jævnfør bemærkning s. 30.

For $i = 1, \dots, n$ kaldes størrelsen

$$r_i \stackrel{\text{def}}{=} x_i - (\hat{\alpha} + \hat{\beta} t_i) \quad (4.5)$$

for det *ite* residual, og med denne betegnelse er SSD-størrelsen fra (4.3) summen af kvadraterne på residualerne. Vi vender tilbage til residualerne i Afsnit 4.1.1, da disse spiller en vigtig rolle når vi skal udføre modelkontrol.

Hvis vi betragter SSD størrelsen med sande parametre indsat, det vil sige

$$\sum_{i=1}^n (X_i - (\alpha + \beta t_i))^2,$$

vil denne have en $\sigma^2 \chi^2(n)$ fordeling. Det kan vises at

$$\text{SSD}_{02}(\mathbf{X}) = \sum_{i=1}^n (X_i - (\hat{\alpha} + \hat{\beta} t_i))^2 \sim \sigma^2 \chi^2(n-2),$$

og vi bemærker - igen jævnfør bemærkning s. 30 - at der her 2 parametre i middelværdien og det her "koster" 2 frihedsgrader i χ^2 -fordelingen at estimere disse. Vi benytter som vanligt den middelværdirette estimator, således at estimatorerne for parametrene i modellen er

$$\alpha \leftarrow \hat{\alpha} = \bar{x} - \hat{\beta} \bar{t}, \quad \beta \leftarrow \hat{\beta} = \frac{\text{SPD}_{\mathbf{xt}}}{\text{SSD}_{\mathbf{t}}}, \quad \sigma^2 \leftarrow s_{02}^2 = \frac{1}{n-2} \sum_{i=1}^n \{x_i - (\hat{\alpha} + \hat{\beta} t_i)\}^2 = \frac{\text{SSD}_{02}}{n-2}. \quad (4.6)$$

Her har vi benyttet $\text{SPD}_{\mathbf{xt}} \stackrel{\text{def}}{=} \sum_{i=1}^n (x_i - \bar{x})(t_i - \bar{t})$. Forkortelsen står for *Sum of Product Deviations*. Jævnført afsnit 2.2.2 har vi desuden brugt $\text{SSD}_{\mathbf{t}} \stackrel{\text{def}}{=} \sum_{i=1}^n (t_i - \bar{t})^2$. Bemærk, at med definitionen af residualerne fra (4.5) har vi

$$s_{02}^2 = \frac{1}{n-2} \sum_{i=1}^n r_i^2.$$

Fordelingerne af de tilsvarende estimatorer er

$$\hat{\alpha}(\mathbf{X}) \sim N\left(\alpha, \sigma^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{\text{SSD}_{\mathbf{t}}}\right)\right) \quad \hat{\beta}(\mathbf{X}) \sim N\left(\beta, \frac{\sigma^2}{\text{SSD}_{\mathbf{t}}}\right) \quad s_{02}^2(\mathbf{X}) \sim \sigma^2 \chi^2(f_{02})/f_{02} \quad (4.7)$$

hvor $f_{02} = n - 2$.

Det kan vises at $(\hat{\alpha}(\mathbf{X}), \hat{\beta}(\mathbf{X}))$ er uafhængig af $s^2(\mathbf{X})$, samt at $\bar{X}$ er uafhængig af $\hat{\beta}(\mathbf{X})$.

Fordelingen af $\hat{\beta}(\mathbf{X})$ findes ved omskrive tælleren som i (4.2):

$$\hat{\beta}(\mathbf{X}) = \frac{\sum_{i=1}^n (X_i - \bar{X})(t_i - \bar{t})}{\text{SSD}_{\mathbf{t}}} = \frac{\sum_{i=1}^n X_i(t_i - \bar{t})}{\text{SSD}_{\mathbf{t}}} = \sum_{i=1}^n a_i X_i \quad \text{hvor } a_i \stackrel{\text{def}}{=} \frac{t_i - \bar{t}}{\text{SSD}_{\mathbf{t}}}$$

Fordelingen af $\bar{X}$ findes ved hjælp af regneregler fra Afsnit A.3.1.3 til

$$\bar{X} \sim N\left(\alpha + \beta \bar{t}, \frac{\sigma^2}{n}\right).$$

Ved at benytte den omtalte uafhængig mellem $\bar{X}$ og $\hat{\beta}(\mathbf{X})$ findes fordelingen af $\hat{\alpha}(\mathbf{X})$:

$$\hat{\alpha}(\mathbf{X}) = \bar{X} - \hat{\beta}(\mathbf{X}) \bar{t} \sim N\left(\alpha, \sigma^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{\text{SSD}_{\mathbf{t}}}\right)\right).$$

Til sidst bemærker vi, at vi også kan udnytte uafhængigheden mellem $\bar{X}$. og $\hat{\beta}(\mathbf{X})$ til at finde fordelingen af $\hat{\alpha}(\mathbf{X}) + \hat{\beta}(\mathbf{X})t$ for $t \in \mathbb{R}$:

$$\hat{\alpha}(\mathbf{X}) + \hat{\beta}(\mathbf{X})t = \bar{X}. + \hat{\beta}(\mathbf{X})(t - \bar{t}.) \sim N\left(\alpha + \beta t, \sigma^2\left(\frac{1}{n} + \frac{(t - \bar{t}.)^2}{\text{SSD}_{\mathbf{t}}}\right)\right). \quad (4.8)$$

Vi ser af (4.7) at variansen på $\hat{\beta}$ er $\sigma^2/\text{SSD}_{\mathbf{t}}$. Jo større $\text{SSD}_{\mathbf{t}}$ er, desto mindre bliver denne varians, og desto bedre er β estimeret. $\text{SSD}_{\mathbf{t}}$ kan opfattes som et mål for, hvor meget den forklarende variabel varierer omkring sit gennemsnit. Dette bør man have for øje, hvis man udfører et forsøg, hvor man selv kan vælge værdierne af t .

Endvidere fremgår det af udtrykket for variansen på $\hat{\alpha}$, at α kan være meningsløs at fortolke, hvis t_i 'erne ligger langt fra 0. I sådanne tilfælde gør faktoren $\bar{t}$. estimatet for α upræcist, idet variansen på $\hat{\alpha}$ bliver stor.

Variansen på $\hat{\alpha} + \hat{\beta}t$ afhænger af den forklarende variabel t gennem $(t - \bar{t}.)^2$. Variansen er mindst for $t = \bar{t}$., og da er den σ^2/n , hvilket giver god mening, idet $\hat{\alpha} + \hat{\beta}\bar{t}. = \bar{x}$.. Vi konkluderer derfor, at $\hat{\alpha} + \hat{\beta}t$ er bedst estimeret for værdier af t , der ligger i midten af det interval, hvor den forklarende variabel varierer.

Lader vi R_i betegne den stokastiske variabel svarende til det i te residual, d.v.s. $R_i = X_i - \hat{\alpha}(\mathbf{X}) - \hat{\beta}(\mathbf{X})t_i$ kan det at vises R_i er uafhængig af $\hat{\alpha}(\mathbf{X}) + \hat{\beta}(\mathbf{X})t_i$ og ved at tage udgangspunkt i $X_i = R_i + \hat{\alpha}(\mathbf{X}) + \hat{\beta}(\mathbf{X})t_i$ finder vi fordelingen af det i te residual til

$$R_i = X_i - \hat{\alpha}(\mathbf{X}) - \hat{\beta}(\mathbf{X})t_i \sim N\left(0, \sigma^2\left(1 - \frac{1}{n} - \frac{(t_i - \bar{t}.)^2}{\text{SSD}_{\mathbf{t}}}\right)\right). \quad (4.9)$$

Indfører vi størrelsen

$$h_i = \frac{1}{n} + \frac{(t_i - \bar{t}.)^2}{\text{SSD}_{\mathbf{t}}} \quad (4.10)$$

kan vi skrive fordelingen som $N(0, \sigma^2(1 - h_i))$. h_i kaldes *leverage* og fortolkes som et mål for graden af indflydelse som den i te værdi af den forklarende variabel har på regressionen.

Vi slutter af med at bemærke følgende nyttige regneregler for SSD_{02} . Vi bemærker først at

$$\hat{\alpha} + \hat{\beta}t_i = \bar{x}. - \hat{\beta}\bar{t}. + \hat{\beta}t_i = \bar{x}. + \hat{\beta}(t_i - \bar{t}.),$$

og vi finder derved

$$\begin{aligned}
 \text{SSD}_{02} &= \sum_{i=1}^n \left\{ x_i - (\hat{\alpha} + \hat{\beta}t_i) \right\}^2 \\
 &= \sum_{i=1}^n \left\{ x_i - \bar{x} - \hat{\beta}(t_i - \bar{t}) \right\}^2 \\
 &= \sum_{i=1}^n \left\{ (x_i - \bar{x})^2 + \hat{\beta}^2(t_i - \bar{t})^2 - 2\hat{\beta}(x_i - \bar{x})(t_i - \bar{t}) \right\} \\
 &= \text{SSD}_{\mathbf{x}} + \hat{\beta}^2 \text{SSD}_{\mathbf{t}} - 2\hat{\beta} \text{SPD}_{\mathbf{xt}} \\
 &= \text{SSD}_{\mathbf{x}} - \frac{\text{SPD}_{\mathbf{xt}}^2}{\text{SSD}_{\mathbf{t}}}.
 \end{aligned} \tag{4.11}$$

4.1.1 Modelkontrol

Der er i fire antagelser i den lineære regressionsmodel (4.1):

- Linearitet: Middelværdien af responsen er en lineær funktion af den forklarende variabel t .
- Varianshomogenitet: Variansen af X_i er identisk for alle i og afhænger ikke af t_i , $i = 1, \dots, n$.
- Normalfordeling: X_i , $i = 1, \dots, n$ er normalfordelte.
- Uafhængighed: $X_1, \dots, X_n$ er uafhængige.

Af disse antagelser vil vi kontrollere de tre første, idet uafhængigheden normalt forudsættes ud fra den måde, data er indsamlet på.

Linearitetsantagelsen kan kontrolleres ved at tegne et *scatterplot*, hvor responsen afsættes mod den forklarende variabel, dvs. en figur med punkterne (t_i, x_i) for $i = 1, \dots, n$. I et sådant plot skal punkterne sprede sig i en "sky" omkring den estimerede regressionslinje. Hvis punkterne derimod danner en krum form, kan *polynomial regression* (omtalt senere) være en bedre model.

Scatterplottet kan også afsløre afvigelser fra antagelsen om varianshomogenitet. For at denne antagelse skal være rimelig, skal punkternes spredning omkring regressionslinjen være nogenlunde uafhængig af værdien af den forklarende variabel. Hvis fx spredningen ser ud til at vokse med værdien af den forklarende variabel, får man grund til at tvivle på antagelsen om varianshomogenitet.

Som supplement til scatterplottet kan vi benytte et *residualplot*, hvor residualerne afsættes mod den forklarende variabel, altså en figur med punkterne (t_i, r_i) . I et residualplot vil vi især kigge efter systematiske afvigelser fra nullinjen, og det kan være lettere at opdage afvigelser fra linearitets- og varianshomogenitetsantagelserne i et residualplot.

Et alternativ til et residualplot er at afsætte residualerne mod de fittede værdier, altså at tegne $(\hat{x}_i, r_i)$ for $i = 1, \dots, n$ (se Figur 4.2). I modellen M_2 er der kun én forklarende variabel, nemlig t .

Denne situation kaldes *simpel lineær regression* for at skelne fra situationen med flere forklarende variable. I simpel lineær regression er der ingen grundlæggende forskel mellem de to slags plots, men når der er flere forklarende variable, bliver et plot af r_i mod $\hat{x}_i$ mere relevant.


Den sidste antagelse, vi kan undersøge grafisk, er antagelsen om normalfordeling. Som det fremgår af (4.9), vil residualerne være normalfordelte i M_2 , men de har ikke ens varians. Vi kan opnå ens varians ved at betragte de *skalerede* residualer

$$r_i^\dagger \stackrel{\text{def}}{=} \frac{r_i}{\sqrt{1-h_i}},$$

hvor h_i er leverage for den i -te observation (jf. (4.10)). I vores model vil disse være udfald af en $N(0, \sigma^2)$ -fordeling, og vi kan derfor kontrollere modellen ved hjælp af $r_i^\dagger$. Fordelingen af $r_i^\dagger$ afhænger dog af σ^2 , og vi kan eliminere denne afhængighed ved at dividere med spredningen, dvs. betragte $\frac{r_i}{\sqrt{\sigma^2(1-h_i)}}$. Da σ^2 er ukendt, anvendes i stedet de studentiserede skalerede residualer (eng.: *studentized residuals*)

$$r_i^\ddagger \stackrel{\text{def}}{=} \frac{r_i}{\sqrt{s^2(1-h_i)}}, \quad (4.12)$$

hvor σ^2 er erstattet af estimatet s^2 . Betegnelsen *studentized* henviser til den samme procedure, som ved udledningen af Students t -test, hvor σ^2 ligeledes blev erstattet med et estimat s^2 . Dengang var estimatoren, der svarer til s^2 , uafhængig af det udtryk, som vi indsatte den i, således at det resulterende udtryk fik en t -fordeling. Det er ikke tilfældet her, og derfor har estimatoren, der hører til $r_i^\ddagger$, ikke en eksakt, men en *approximativ* t -fordeling.




Figur 4.2: Tre figurer baseret på samme datasæt: Til venstre et scatterplot, i midten et residualplot og til højre er residualerne plottet med de fittede værdier.

Eksempel 4.1 (fortsat).

Vi tager udgangspunkt i en lineær regression af $\log Glu$ på $\log Coli$. Logaritmen til GLUase-aktiviteten betragtes altså som responsvariablen x , og logaritmen til mængden af *E. coli* betragtes som den forklarende variabel t . På baggrund af Figur 4.1 ønsker vi at benytte modellen (4.1).

I modelkontrollen suppleres Figur 4.1 med et scatterplot, hvor den estimerede regressionslinje er indtegnet, og to parallelle linjer i afstanden $\pm s_{02}$. Derudover omfatter modelkontrollen også et residualplot (Figur 4.4a) og et fraktildiagram for de studentiserede residualer (Figur 4.4b). Ingen af kontroltegningerne strider mod antagelsen om lineær regression.



Figur 4.3: Scatterplot for data fra Eksempel 4.1 med indtegnet estimeret regressionslinje samt $\pm 2s_{02}$.

$$\alpha \leftarrow \hat{\alpha} = -3.887245 \quad \beta \leftarrow \hat{\beta} = 0.8493586 \quad \sigma^2 \leftarrow s_{02}^2 = 0.09575192 \quad (4.13)$$


□

Fordelingerne af de tilsvarende estimatorer fremgår af (4.7).

4.1.2 Konfidensintervaller og test i simpel lineær regression

I modellen M_2 fra (4.1) kan hypotesen $H : \alpha = \alpha_0$ om at afskæringen har en kendt værdi $\alpha_0 \in \mathbb{R}$ undersøges ved hjælp af t -testoren

$$t(\mathbf{X}) = \frac{\hat{\alpha} - \alpha_0}{\sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{\text{SSD}_t} \right)}} = \frac{\hat{\alpha} - \alpha_0}{\text{sd}(\hat{\alpha})} \sim t(n-2), \quad \text{hvor} \quad \text{sd}(\hat{\alpha}) = \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{\text{SSD}_t} \right)},$$



(a) Residualplot for data fra Eksempel 4.1. (b) Fraktilplot for studentiserede residualer fra (4.12)

Figur 4.4: Figurer til modelkontrol af modellen for lineær regression for data fra Eksempel 4.1.

og hypotesen $H : \beta = \beta_0$ om at hældningen har en kendt værdi $\beta_0 \in \mathbb{R}$ ved t -testoren

$$t(\mathbf{X}) = \frac{\hat{\beta} - \beta_0}{\sqrt{s_{02}^2 / \text{SSD}_{\mathbf{t}}}} = \frac{\hat{\beta} - \beta_0}{\text{sd}(\hat{\beta})} \sim t(n-2), \quad \text{hvor} \quad \text{sd}(\hat{\beta}) = \sqrt{s_{02}^2 / \text{SSD}_{\mathbf{t}}}.$$

I begge tilfælde findes p -værdien ved hjælp af t -teststørrelsen $t(\mathbf{x})$ som $p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-2)}(-|t(\mathbf{x})|) = 2(1 - F_{t(n-2)}(|t(\mathbf{x})|))$.

Konfidensintervaller for parametrene α , β og $\alpha + \beta t$ følger en generel form for konfidensintervaller for parametre, hvis estimatorer er normalfordelte med varians $k\sigma^2$. Her er k en kendt konstant, mens σ^2 er ukendt, men estimeres ved s^2 . Vi antager samtidig, at den tilsvarende estimator er $\sigma^2\chi^2(f)/f$ -fordelt samt uafhængig af estimatoren for parameteren. Hvis ξ er en sådan parameter, og estimatet betegnes $\hat{\xi}$, så er følgende et $(1 - \alpha)$ -konfidensinterval for ξ :

$$[\hat{\xi} - \sqrt{s^2 k} t_{1-\alpha/2}(f), \hat{\xi} + \sqrt{s^2 k} t_{1-\alpha/2}(f)]. \quad (4.14)$$

Bemærk, at $\sqrt{s^2 k}$ er et estimat for spredningen på $\hat{\xi}$, og at statistikpakker normalt rapporterer et skøn for spredningen på estimatet som **Standard Error**, sammen med selve estimatet.

$(1 - \alpha)$ -konfidensintervaller for α og β er

$$\hat{\alpha} \pm t_{1-\frac{\alpha}{2}}(f_{02}) \text{sd}(\hat{\alpha}) \quad \text{og} \quad \hat{\beta} \pm t_{1-\frac{\alpha}{2}}(f_{02}) \text{sd}(\hat{\beta})$$

hvor $t_{1-\alpha/2}(f_{02})$ er $1 - \alpha$ fraktilen i t -fordelingen. Skrives konfidensintervallerne ud fås

$$\left[\hat{\alpha} - \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{\text{SSD}_{\mathbf{t}}} \right)} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{\text{SSD}_{\mathbf{t}}} \right)} t_{1-\alpha/2}(f_{02}) \right], \quad (4.15)$$

og

$$\left[\hat{\beta} - \sqrt{\frac{s_{02}^2}{\text{SSD}_t}} t_{1-\alpha/2}(f_{02}), \hat{\beta} + \sqrt{\frac{s_{02}^2}{\text{SSD}_t}} t_{1-\alpha/2}(f_{02}) \right].$$

Konfidensintervallet for variansen findes på samme måde i afsnit 2.2.1 hvor (2.17) her tager formen:

$$\left[\frac{s_{02}^2}{\chi_{1-\alpha/2}^2(f_{02})/f_{02}}, \frac{s_{02}^2}{\chi_{\alpha/2}^2(f_{02})/f_{02}} \right].$$

I (4.15) udledte vi et konfidensinterval for α , som er regressionslinjens værdi ved $t = 0$. Mere generelt kan vi være interesserede i regressionslinjens værdi for en given værdi t_0 af den forklarende variabel, altså parameteren $\theta = \alpha + \beta t_0$. Vi bemærker, at dette er en funktion af parametrene i modellen, på samme måde som vi i Afsnit 2.2.3 var interesserede i $\theta = e^\mu$, hvor μ var middelværdien i vores model. I dette tilfælde kan vi benytte (4.8), der giver

$$\begin{aligned} & \left[\hat{\alpha} + \hat{\beta} t_0 \pm \text{sd}(\hat{\alpha} + \hat{\beta} t_0) \right] = \\ & \left[\hat{\alpha} + \hat{\beta} t_0 - \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{\text{SSD}_t} \right)} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \hat{\beta} t_0 + \sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{(t_0 - \bar{t})^2}{\text{SSD}_t} \right)} t_{1-\alpha/2}(f_{02}) \right]. \end{aligned} \quad (4.16)$$

Vi bemærker at ovenstående reduceres til (4.15) for $t_0 = 0$.

4.1.3 Prædiktionsinterval for en ny observation

I dette afsnit vil vi behandle *prædiktion* som en generel problemstilling. Begrebet ”prædiktion” dækker over følgende spørgsmål:

Givet et datasæt og en statistisk model, hvad kan vi sige om en ny værdi af responsvariablen?

Vi har tidligere berørt dette spørgsmål på side 30 og 59, hvor vi betragtede prædikterede værdier. I begge tilfælde var der tale om tal, som vi anså for et ”bedste bud”, men som ikke i sig selv sagde noget om den usikkerhed, der nødvendigvis vil være tilknyttet en sådan størrelse. Denne problemstilling minder om den, vi står overfor inden for parameterestimation, hvor estimerer udgør det ”bedste bud” på en parameter, og hvor konfidensintervallet bruges til at vurdere sikkerheden på det pågældende estimat. Tilsvarende kan vi udtrykke usikkerheden knyttet til en prædikteret værdi gennem et *prædiktionsinterval*.

Før vi udleder prædiktionsintervaller i lineær regression, vil vi omtale situationen i en normalfordelt observationsrække fra (2.9), det vil sige en i.i.d. følge $X_1, \dots, X_n$ fra $N(\mu, \sigma^2)$ fordelingen.

Lad X_0 være en stokastisk variabel, der svarer til vores nye værdi. At den er ”ny” betyder matematisk, at vi antager, den er uafhængig af X_i erne. Fra Opgave 1.3 i opgavesamlingen, har vi at hvis vi lader $s^2(\mathbf{X})$ betegne estimatoren for σ^2 da vil følgende ulighed holde med sandsynlighed $1 - \alpha$:

$$\bar{X} - t_{1-\alpha/2}(n-1)s(\mathbf{X})\sqrt{1+1/n} < X_0 < \bar{X} + t_{1-\alpha/2}(n-1)s(\mathbf{X})\sqrt{1+1/n}, \quad (4.17)$$

og vi omtaler derfor intervallet

$$[\bar{x} \pm t_{1-\alpha/2}(n-1)s\sqrt{1+1/n}]$$

som et $(1 - \alpha)$ -prædiktionsinterval.

Vi betragter nu den lineære regressions model (4.1) samt en værdi t_0 af den forklarende variabel og lader X_0 betegne fordelingen til en ny observation, således at X_0 antages at være uafhængig af $X_1, \dots, X_n$. Denne uafhængighed sammen med (4.8) gør at

$$X_0 - (\hat{\alpha} + \hat{\beta}t_0) \sim N\left(0, \sigma^2\left(1 + \frac{1}{n} + \frac{(t - \bar{t})^2}{\text{SSD}_t}\right)\right)$$

og dermed, da $s_{02}^2(\mathbf{X})$ er uafhængig af $X_0 - (\hat{\alpha} + \hat{\beta}t_0)$,

$$\frac{X_0 - (\hat{\alpha} + \hat{\beta}t_0)}{\sqrt{s_{02}^2\left(1 + \frac{1}{n} + \frac{(t - \bar{t})^2}{\text{SSD}_t}\right)}} \sim t(f_{02})$$

og derfor holder ulighederne,

$$-t_{1-\alpha/2}(f_{02}) < \frac{X_0 - (\hat{\alpha} + \hat{\beta}t_0)}{\sqrt{s_{02}^2\left(1 + \frac{1}{n} + \frac{(t - \bar{t})^2}{\text{SSD}_t}\right)}} < t_{1-\alpha/2}(f_{02})$$

med sandsynlighed $1 - \alpha$ og vi finder på denne måde $1 - \alpha$ prædiktionsintervallet:

$$\left[\hat{\alpha} + \hat{\beta}t_0 - s_{02}\sqrt{\left(1 + \frac{1}{n} + \frac{(t_0 - \bar{t})^2}{\text{SSD}_t}\right)} t_{1-\alpha/2}(f_{02}), \hat{\alpha} + \hat{\beta}t_0 + s_{02}\sqrt{\left(1 + \frac{1}{n} + \frac{(t_0 - \bar{t})^2}{\text{SSD}_t}\right)} t_{1-\alpha/2}(f_{02}) \right].$$


Intervallet ligner - ikke overraskende - konfidensintervallet (4.16) til forveksling, men bliver brede-re, da intervallet ikke blot beskriver den usikkerhed der er knyttet til estimerne, men også det yderligere usikkerhed der knyttet til den nye observation.

Eksempel 4.1 (fortsat).

I Tabel 4.2 er 95 % konfidensinterval og 95 % prædiktionsinterval beregnet for værdierne 4.9 5.7 og 6.8. Beregningerne er foretaget i **R**. På Figur 4.5a og 4.5b er henholdsvis 95 % konfidensinterval og 95 % prædiktionsinterval indtegnet på scatterplot.

<i>logColi</i>	fittet værdi	95 % konfidensinterval	95 % prædiktionsinterval
4.9	0.2746	(0.2092, 0.3401)	(-0.3431, 0.8923)
5.7	0.9541	(0.8634, 1.0448)	(0.3332, 1.5750)
6.8	1.8884	(1.7455, 2.0312)	(1.2578, 2.5190)

Tabel 4.2: Beregnede 95 % konfidensintervaller og 95 % prædiktionsintervaller svarende til værdierne 4.9, 5.7 og 6.8 af *logColi*. Endvidere er de fittede værdier også angivet.



(a) Fittede værdier for $\log Coli$ på 4.9, 5.7 og 6.8 sammen med 95 % konfidensintervaller

(b) Fittede værdier for $\log Coli$ på 4.9, 5.7 og 6.8 sammen med 95 % prædiktionsintervaller .

Figur 4.5: Scatterplots med indtegnede konfidensintervaller og prædiktionsintervaller.

4.1.4 Test af hypotesen om lineær regression

I dette afsnit vil vi diskutere et tilfælde hvor man, som en del af modelkontrollen, kan udføre et egentligt test, der svarer til at teste for hypotesen om lineær regression. Situation illustreres ved hjælp af Eksempel 4.2, der er beskrevet i [Blæsild and Granfeldt \[2002\]](#).

Eksempel 4.2.

Hvis man placerer noget sand, hvor alle sandkornene cirka har den samme størrelse, på en sigte og roterer den, vil der i begyndelsen komme meget sand igennem sigten, men gradvist mindre og mindre. Denne observation fra barndommens sandkasse kan formuleres således: den mængde sand, der passerer sigten per tidsenhed er proportional med den mængde sand, der er tilbage på sigten. Hvis $x(t)$ betegner vægten af den mængde sand, der til tid t er tilbage i sigten, kan modellen formuleres

$$\frac{dx(t)}{dt} = cx(t),$$

hvor c er en negativ konstant, fordi mængden af sand i sigten aftager med tiden. Denne differentiaalligning har løsningen

$$x(t) = x(0)e^{ct}, \quad (4.18)$$

hvor $x(0)$ er vægten af sandet i sigten ved tid 0. Tager man logaritmen på begge sider af (4.18), fås

$$\ln x(t) = \ln x(0) + ct, \quad (4.19)$$

hvilket viser, at logaritmen til massen af det sand, som er tilbage i sigten, er en lineær funktion af tiden.

I Tabel 4.3 er gengivet resultaterne af i alt 12 sigtninger af den samme portion sand, der vejer 60 g. I fire af sigtningerne er sigten roteret 170 gange (maskinen kører med konstant hastighed og foretager 43 rotationer pr. minut), i fire andre er der foretaget 530 rotationer, og i de sidste fire er der foretaget 880 rotationer. Tallene i Tabel 4.3 angiver logaritmen til den masse (målt i gram), der er tilbage i sigten efter det nævnte antal rotationer.

Det er vigtigt, at sigten roterer med konstant hastighed, så antallet af rotationer bliver proportionalt med tiden, og modellen i (4.19) derfor gælder, uanset om t betegner den forløbne tid eller antallet af rotationer. I det følgende er antallet af rotationer den forklarende variabel, som betegnes t . $\square$

Som det fremgår af Tabel 4.3, befinder vi os i en situation, hvor der foreligger flere observationer af responsvariablen til hver værdi af den forklarende variabel. Vi tænker på vores datasæt som værende inddelt i grupper svarende til de forskellige værdier af den forklarende variabel og kan derfor opstille et skema lignende (3.1).

$$\begin{array}{cccccc} t_1 & x_{11} & \dots & x_{1j} & \dots & x_{1n_1} \\ \vdots & & \vdots & & \vdots & \\ t_i & x_{i1} & \dots & x_{ij} & \dots & x_{in_i} \\ \vdots & & \vdots & & \vdots & \\ t_k & x_{k1} & \dots & x_{kj} & \dots & x_{kn_k} \end{array}$$

Datasættet består således af (t_{ij}, x_{ij}) hvor $i = 1, \dots, k$ indikerer gruppen med $t_{ij} = t_i$ og $j = 1, \dots, n_i$ indikerer observationerne indenfor den enkelte gruppe.

Datasættet er indtegnet på Figur 4.6. I Figur 4.6a er de tre gruppegennemsnit (som også er angivet i Tabel 4.3) forbundet med en linje, hvor man aner et knæk på midten.


Antal rotationer	Logaritme af tilbageværende masse i g				gennemsnit
170	3.89	3.95	3.85	3.91	3.9
530	3.61	3.58	3.66	3.71	3.64
880	3.30	3.26	3.30	3.34	3.3

Tabel 4.3: Tabel over antal rotationer og logaritme af tilbageværende masse. Til højre er gennemsnit for de tre forskellige antal rotationer.

For at starte med at gøre færrest mulig antagelser om vores datasæt vil vi først opstille modellen med tre uafhængige observationsrækker med forskellig middelværdi og varians, det vil sige M_0 som først blev betragtet i (3.20):

$$M_0 : X_{ij} \sim N(\mu_i, \sigma_i^2) \quad i = 1, 2, 3 \quad j = 1, 2, 3, 4 \quad + \text{ uafhængighed.} \quad (4.20)$$

Bemærk at den forklarende variable, antallet af rotationer, her kun indgår indirekte idet den giver vores gruppestilordning. Vi starter med at undersøge $H_{0\sigma^2} : \sigma_1^2 = \sigma_2^2 = \sigma_3^2$ ved hjælp af Bartlett's



(a) Gruppegennemsnit er markeret med $\bullet$ og forbundet en linie der knækker ved 530 rotationer. (b) Indtegnet regressionslinje og prædikterede værdier markeret med $\bullet$.

Figur 4.6: To illustrationer af datasættet fra Tabel 4.3.

test, som er beskrevet i Afsnit 3.2.1. Vi udelader detaljerne i beregningerne - teststørrelsen findes til $Ba = 0.82107$ og denne skal testes i en χ^2 fordeling med $k - 1 = 2$ frihedsgrader. p -værdien findes til $p_{obs} = 1 - F_{\chi^2(2)}(0.82107) = 0.6633$. Vi opstiller dernæst

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, 3 \quad j = 1, 2, 3, 4 \quad + \text{ uafhængighed.} \quad (4.21)$$

og ønsker altså at reducere denne til M_2 :

$$M_2 : X_{ij} \sim N(\alpha + \beta t_i, \sigma^2) \quad i = 1, 2, 3 \quad j = 1, 2, 3, 4 \quad + \text{ uafhængighed.} \quad (4.22)$$

Vi kan gennemføre denne reduktion, fordi både M_1 og M_2 er lineære normale modeller, og fordi M_2 er en undermodel af M_1 . Dette betyder, at M_2 har en enklere middelværdistruktur i den forstand, at middelværdierne i M_1 er μ_1, μ_2, μ_3 , som alle kan variere frit, mens middelværdierne i M_2 mere specifikt har formen

$$\mu_1 = \alpha + \beta t_1, \quad \mu_2 = \alpha + \beta t_2, \quad \mu_3 = \alpha + \beta t_3,$$

hvor α og β kan variere frit.

I Afsnit 3.2.2 nævnte vi at likelihood ratio testet i dette tilfælde var ratioen mellem maksimum likelihood estimaterne for varianserne i de to modeller og vi omskrev denne til en F -fordelt testor, der i Afsnit 3.2.2 var på formen

$$\mathcal{F}(\mathbf{x}) = \frac{\frac{\text{SSD}_H}{k-1}}{s_1^2}.$$

I nærværende tilfælde vil nævneren ligesom i Afsnit 3.2.2 være estimeret for variansen i M_1 som kan findes ved hjælp af (3.24) til $s_1^2 = 0.002022$. Tælleren bliver anderledes i dette tilfælde og vi vender

senere tilbage til hvordan denne beregnes. I dette tilfælde findes tælleren til 0.0052 og teststørrelsen bliver dermed


$$\mathcal{F}(\mathbf{x}) = \frac{0.0052}{0.002022} = 2.57,$$

som skal testes i $F(1, 9)$ fordeling. Vi finder testsandsynligheden

$$p_{obs}(\mathbf{x}) = 1 - F_{F(1,9)}(2.57) = 0.14, \quad (4.23)$$

og da denne er større en 0.05 accepterer vi hypotesen om lineær regression.

Selvom vi har gennemført et test for hypotesen om lineær regression, bør vi stadig lave modelkontrol som det er beskrevet i afsnit 4.1.1. I Figur 4.7a er residualerne afsat mod de prædikterede værdier og i Figur 4.7b vises et fraktilplot for de studentiserede residualer.



(a) Residualer afsat mod prædikterede værdier i modellen. (b) Fraktilplot for studentiserede residualer fra (4.12).

Figur 4.7: Figurer til modelkontrol af modellen for lineær regression (4.22) for data fra Tabel 4.3.

4.1.5 Kalibrering (invers regression)

Inden for kemi anvendes lineære sammenhænge ofte til at opstille et “måleapparat”, hvor værdien af den forklarende variabel bestemmes ud fra responsen (også omtalt som ”invers regression”). Når den lineære regressionsmodel etableres ud fra data, taler man om at *kalibrere* målemetoden. Et eksempel kan være en række prøver med en kendt koncentration af et stof, hvor man måler lysets intensitet efter passage af prøven. Typisk er der en lineær sammenhæng mellem logaritmen til lysintensiteten og koncentrationen. Bagefter kan man for en prøve med ukendt koncentration måle lysintensiteten og herefter estimere koncentrationen med den etablerede lineære sammenhæng.

I Eksempel 4.1 om forurenede vandprøver ønsker man, efter at have fastlagt sammenhængen mellem GLUase og antallet af bakterier, at benytte sammenhængen til at bestemme antallet af bakterier ud fra en måling af GLUase.

Dette kan formuleres generelt på følgende vis. Ud fra de indsamlede data har vi estimeret parametrene i modellen $X_i \sim N(\alpha + \beta t_i, \sigma^2)$, $i = 1, \dots, n$. For en ny værdi τ af den forklarende variabel t betragtes m målinger $Y_1, \dots, Y_m$ fra modellen $Y_i \sim N(\alpha + \beta\tau, \sigma^2)$. Vi ønsker at lave inferens om τ baseret på både $X_1, \dots, X_n$ og på $Y_1, \dots, Y_m$. Ved beregninger af samme type som i forbindelse med Afsnit 4.1.2 kan man indse, at

$$t(\tau) = \frac{\bar{Y} - (\hat{\alpha} + \hat{\beta}\tau)}{s_r \sqrt{\frac{1}{m} + \frac{1}{n} + \frac{(\tau - \bar{t})^2}{\text{SSD}_t}}} \sim t(n-2),$$

hvor $\bar{Y} = (Y_1 + \dots + Y_m)/m$. Man kan derfor konstruere et 95%-konfidensinterval for τ som de værdier af τ , for hvilke

$$-t_{0.975}(n-2) \leq t(\tau) \leq t_{0.975}(n-2) \quad (4.24)$$

For at finde de relevante værdier af τ skal man løse en andengradsligning.

Eksempel 4.1 (fortsat).

Vi antager nu, at vi med en enkelt måling af *logGlu* på 1.05 ønsker at konstruere det tilsvarende interval for *logColi*. Det svarer til at løse den andengradsligning, som er underforstået i (4.24), hvilket vi overlader til **R**. Som det fremgår af R-udskrift 4.6, bliver intervallet

$$(5.085127, 6.552178). \quad (4.25)$$

Hvis vi i stedet antager, at der er foretaget fire målinger af *logGlu*, som alle er 1.05, findes det tilsvarende interval for *logColi* til


$$(5.439088, 6.198216),$$

hvilket naturligvis er noget smallere end intervallet fra (4.25). Begge intervaller kan transformeres til intervaller for mængden af *E. coli* ved at eksponentiere. Herved fås

$$(161.6004, 700.7684) \quad \text{og} \quad (230.2321, 491.8709). \quad \square$$

4.1.6 Yderligere modeller inden for lineær regression

I dette afsnit vil vi omtale yderligere undermodeller indenfor lineær regression. Modeller og hypoteser er illustreret i Figur 4.8. De to hypoteser H_{03} og H_{03}^* vedrører reduktion fra grundmodellen M_2 (4.1) og er allerede omtalt i Afsnit 4.1.2. Det to andre hypoteser vedrører testet for kendt afskæring i en model med kendt hældning (H_{04}) og testet for kendt hældning i en model med kendt afskæring (H_{04}^*). Bemærk at selvom om hypoteserne H_{03} og H_{04}^* begge er $\beta = \beta_0$ giver de ikke anledning til samme test, da grundmodellerne er forskellige. En tilsvarende bemærkning gælder H_{03}^* og H_{04} . Vi opremser teststørrelser, testsandsynligheder og estimater uden bevis, da alle resultater følger som i Afsnit 4.1.2.



Figur 4.8: Undermodeller og hypoteser i lineær regression.

Estimator for parametrene i M_3

Estimator for afskæring og varians i M_3 er

$$\alpha \leftarrow \hat{\alpha}_{M_3} = \bar{x} - \beta_0 \bar{t}. \quad \text{hvor} \quad \bar{X} - \beta_0 \bar{t} \sim N\left(\alpha, \frac{\sigma^2}{n}\right),$$

$$\sigma^2 \leftarrow s_{03}^2 = \frac{1}{n-1} \sum_{i=1}^n \{x_i - (\hat{\alpha}_{M_3} + \beta_0 t_i)\}^2 = \frac{1}{n-1} \left[\text{SSD}_{02} + (\hat{\beta} - \beta_0)^2 \text{SSD}_{\mathbf{t}} \right]$$

hvor SSD_{02} er givet i (4.11). Den tilsvarende estimator $\sigma^2(\mathbf{X})$ har en $\sigma^2 \chi^2(n-1)/(n-1)$ fordeling.

*Estimator for parametrene i M_3^**

Estimator for afskæring og varians i M_3^* er

$$\beta \leftarrow \hat{\beta}_{M_3^*} = \frac{\sum_{i=1}^n t_i (x_i - \alpha_0)}{\sum_{i=1}^n t_i^2} \quad \text{hvor} \quad \frac{\sum_{i=1}^n t_i (X_i - \alpha_0)}{\sum_{i=1}^n t_i^2} \sim N\left(\beta, \frac{\sigma^2}{\text{USS}_{\mathbf{t}}}\right),$$

$$\sigma^2 \leftarrow s_{03}^{*2} = \frac{1}{n-1} \sum_{i=1}^n \left\{ x_i - \left(\alpha_0 + \hat{\beta}_{M_3^*} t_i \right) \right\}^2 = \frac{1}{n-1} \left[\text{USS}_{\mathbf{x}} + n\alpha_0^2 - 2\alpha_0 \bar{x} - \hat{\beta}_{M_3^*}^2 \text{USS}_{\mathbf{t}} \right].$$

Den tilsvarende estimator $\sigma^2(\mathbf{X})$ har ligesom i M_3 en $\sigma^2 \chi^2(n-1)/(n-1)$ fordeling.

Test af $H_{04}^ : \beta = \beta_0$:*

$$t(\mathbf{x}) = \frac{\hat{\beta}_{M_3^*} - \beta_0}{\sqrt{s_{03}^{*2} / \text{USS}_{\mathbf{t}}}} \quad \text{hvor} \quad t(\mathbf{X}) \stackrel{\text{under } H_{04}^*}{\sim} t(n-1).$$

Testsandsynlighed

$$p_{\text{obs}}(\mathbf{x}) = 2F_{t(n-1)}(-|t(\mathbf{x})|)$$

Test af $H_{04} : \alpha = \alpha_0$:

$$t(\mathbf{x}) = \frac{\hat{\alpha}_{M_3} - \alpha_0}{\sqrt{s_{03}^2 / n}}. \quad \text{hvor} \quad t(\mathbf{X}) \stackrel{\text{under } H_{04}}{\sim} t(n-1).$$

Testsandsynlighed

$$p_{obs}(\mathbf{x}) = 2F_{t(n-1)}(-|t(\mathbf{x})|)$$

Til slut har vi estimatet for parameteren i M_4

$$\sigma^2 \leftarrow s_{04}^2 = \frac{1}{n} \sum_{i=1}^n \{x_i - (\alpha_0 + \beta_0 t_i)\}^2$$

hvor den tilsvarende estimator har en $\chi^2(n)/n$ fordeling.

Eksempel 4.2 (fortsat).

Vi endte med at betragte modellen

$$\ln x(t) = \ln x(0) + ct,$$

hvor $x(t)$ er den tilbageværende masse til tid t . I M_2 er afskæringen $\alpha = \ln x(0)$ en fri parameter, men ifølge vores model er den netop logaritmen til vægten af sandprøven ved $t = 0$. Vi ved, at denne vægt er 60 g. Derfor er det interessant at teste hypotesen

$$H_{03}^* : \alpha = \alpha_0 = \ln 60 = 4.0943.$$

Vi beregner den relevante teststørrelse og finder

$$\begin{aligned} t(\mathbf{x}) &= \frac{\hat{\alpha} - \alpha_0}{\sqrt{s_{02}^2 \left(\frac{1}{n} + \frac{\bar{t}^2}{SSD_t} \right)}} \\ &= \frac{4.0581 - 4.0943}{\sqrt{0.002342 \left(\frac{1}{12} + \frac{(6320/12)^2}{1008266.67} \right)}} \\ &= -1.249. \end{aligned} \tag{4.26}$$

Testsandsynligheden er

$$p_{obs}(\mathbf{x}) = 2F_{t(10)}(-|-1.249|) = 0.24, \tag{4.27}$$

så hypotesen accepteres. Vi betragter derfor modellen

$$M_3^* : X_{ij} \sim N(\alpha_0 + \beta t_i, \sigma^2), \tag{4.28}$$

hvor estimatet for β beregnes til

$$\beta_{M_3^*} = \frac{21984.8 - 4.0943 \cdot 6320}{4336800} = -0.00089725. \tag{4.29}$$

Tilsvarende findes estimatet i M_2 til -0.000844 , så de to estimater er stort set ens. Som det fremgår ovenfor, er varianserne på de tilhørende estimater forskellige, nemlig σ^2/SSD_t for M_2 og σ^2/USS_t for M_3^* . Denne forskel afspejles i den præcision, hvormed β er bestemt i de to modeller. Hvis man beregner konfidensintervaller i henholdsvis M_2 og M_3^* , ser man, at konfidensintervallet i M_2 er omtrent dobbelt så bredt som i vores slutmodel M_3^* . $\square$

logColi	logGlu	logColi	logGlu	logColi	logGlu	logColi	logGlu
2.80	-1.05	4.68	0.32	3.72	-1.06	2.83	-1.05
2.86	-1.04	4.67	0.21	3.74	-1.17	3.38	-1.01
2.88	-1.10	4.88	0.04	3.79	-1.04	3.32	-1.06
2.86	-1.21	4.98	-0.29	3.84	-1.03	3.79	-1.08
3.07	-1.28	4.88	0.37	3.84	-1.07	4.00	-0.75
3.10	-1.57	5.02	0.45	3.82	-0.26	5.79	0.70
3.19	-0.56	5.14	0.56	3.88	-0.32	5.79	0.67
3.33	-0.54	5.23	0.14	3.85	-0.54	5.55	0.99
3.32	-0.59	5.24	0.89	3.81	-0.61	5.52	1.06
3.32	-0.68	5.35	0.78	3.87	-0.68	5.50	1.06
3.41	-0.77	5.33	0.89	3.87	-0.75	5.49	1.12
3.26	-1.12	5.31	1.01	3.88	-0.80	6.89	1.53
3.28	-1.02	5.39	1.08	3.98	-0.79	6.74	1.83
3.35	-1.32	5.43	1.22	3.97	-0.65	6.29	1.01
3.34	-1.28	5.44	1.10	4.02	-0.71	6.19	1.03
3.33	-1.16	5.48	1.15	4.04	-0.66	6.34	1.22
3.40	-1.10	5.51	1.08	4.06	-0.59	6.32	1.42
3.47	-1.07	5.53	1.04	4.23	-0.79	6.33	1.79
3.44	-0.99	5.56	0.97	4.52	-0.86	6.11	1.73
3.50	-0.85	5.64	1.12	4.28	-0.53	5.99	1.56
3.36	-1.05	5.66	1.35	4.35	-0.34	5.77	0.64
3.61	-1.06	5.73	1.49	4.43	-0.33	5.79	0.77
3.65	-0.78	5.79	1.28	4.52	-0.40	5.85	0.83
3.75	-0.82	5.90	1.09	4.36	-0.10		
3.72	-0.90	5.83	1.06	5.86	1.00		

Tabel 4.4: Det fulde datasæt i Eksempel 4.4

Appendiks til Afsnit 4.1

Beregninger i R

Vi viser her ud fra data fra Eksempel 4.1, hvordan man kan beregne estimater for hældning og afskæring, samt hvordan vi ud fra disse kan beregne prædikterede værdier og residualer. Datasættet findes i Tabel 4.4 samt på filen `GLUase.csv` hvorfra det indlæses på R-kode 4.1

R-kode 4.1

```
dat = read.csv("GLUase.csv")
logColi = dat$logColi
logGlu = dat$logGlu
```

Estimaterne i M_2 beregnes ved hjælp af formlerne i (4.6):

R-kode 4.2

```
SPDxt <- sum((logGlu - mean(logGlu)) * (logColi - mean(logColi)))
SSDt <- sum((logColi - mean(logColi))^2)
betahat <- SPDxt / SSDt
alphahat <- mean(logGlu) - betahat * mean(logColi)
alphahat
betahat
```

Dette giver os estimaterne $\hat{\alpha}$ og $\hat{\beta}$

R-udskrift 4.1

```
> alphahat
[1] -3.887245
> betahat
[1] 0.8493586
```

Vi kan derefter beregne vektoren af residualer og ud fra denne s_{02}^2

R-kode 4.3

```
n <- length(logColi)
prædikterede_værdier <- alphahat + betahat * logColi
residualer <- logGlu - prædikterede_værdier
s2 <- sum(residualer^2) / (n - 2)
```

Værdien af `s2` er 0.09575192 og vi kan beregne estimatet for spredningen

$$\sigma \leftarrow s_{02} = \sqrt{0.09575192} = 0.3094381.$$

Når vi har beregnet residualer og prædikterede værdier kan vi lave residualplot og plotte residualer afsat mod de prædikterede værdier ved at benytte `plot` sammen med de relevante vektorer. Endeligt kan vi beregne leverage fra formel (4.10) og studentiserede residualer fra formel (4.12)

R-kode 4.4

```
leverage <- 1/n + (logColi - mean(logColi))^2/SSDt
stud_resid <- residualer/sqrt(s2*(1-leverage))
```

Disse kan derefter plottes med `qqnorm` - et eksempel på et sådant plot findes på Figur 4.7b.

Lineær regression er et eksempel på en *lineær normal model*, som i **R** analyseres ved hjælp af kommandoen `lm`. Vi vil først omtale `lm` i forbindelse med simpel lineær regression og senere give en mere detaljeret beskrivelse af funktionen. Når man kalder `lm`, udfører den en række statistiske beregninger, men skriver kun få resultater ud. Derfor anvendes `lm` normalt i kombination med funktionen `summary` for at få flere oplysninger om den statistiske model, der betragtes.

Modelformlen er det input til `lm`, som, løst sagt, beskriver, hvordan responsvariablen x skal forbindes med den forklarende variabel t . I regressionsmodellen fra (4.1), hvor vektoren med responsværdier hedder $\mathbf{x}$, og vektoren med værdier af den forklarende variabel hedder $\mathbf{t}$, er modelformlen blot $\mathbf{x} \sim \mathbf{t}$. På venstre side af tildesymbolet skal responsvariablen stå, og på højre side skal strukturen af middelværdien angives. For den lineære regressionsmodel angives middelværdien $\mathbb{E}[X] = \alpha + \beta t$ blot ved at skrive navnet på regressionsvariablen ($\mathbf{t}$). Man kan også skrive $\mathbf{x} \sim 1 + \mathbf{t}$ for at gøre det eksplicit, at højresiden består af et led svarende til α og et led svarende til βt . Men udelader man `1`, vil **R** som udgangspunkt selv tilføje det.

Analysen af regressionsmodellen kan nu laves i **R** med kommandoen:

R-kode 4.5

```
summary(lm(x~t))
```

I nogle situationer vil det være relevant at gemme output for at kunne regne videre på elementer af output. Hvis man kalder output fra `lm` for `lmfit` og output fra `summary` for `sumfit`, bliver kaldene

R-kode 4.6

```
lmfit <- lm(x~t)
```

R-kode 4.7

```
sumfit <- summary(lmfit)
```

Output fra **summary** består af en *parametertabel* med overskrift **Coefficients**, hvor der er fire søjler: parameterskøn, standard error, *t*-teststørrelse og en *p*-værdi, og tabellen indeholder en række for hver parameter i middelværdimodellen:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	—	—	—	—
t	—	—	—	—

Den simple lineære regressionsmodel $E(X_i) = \alpha + \beta t_i$ har to parametre: skæring α (intercept) og regressionskoefficienten β , som navngives efter navnet på den forklarende variabel. Søjlen med *Standard error* angiver et skøn over spredningen på parameterskønnet.

For at teste hypotesen om, at den sande parameterværdi er nul, anvendes en *t*-teststørrelse, som er lig med parameterskønnet divideret med dets standard error. Endelig er søjlen med *p*-værdier fundet ved hjælp af en *t*-fordeling med et passende antal frihedsgrader. Dette frihedsgradstal kan aflæses nedst i parametertabellen, hvor skønnet s_{02} over spredningen af punkterne omkring regressionslinjen er angivet (**Residual standard error**) sammen med antallet af frihedsgrader.

Man kan finde de forskellige elementer i output, samt finde konfidensintervaller for parametrene, ved følgende kommandoer:

<code>sumfit\$sigma</code>	skøn s_{02} over spredning
<code>sumfit\$df[2]</code>	frihedsgrader knyttet til s_{02}^2
<code>sumfit\$coefficients</code>	parametertabel
<code>lmfit\$fitted.values</code>	$\hat{\xi}_i = \hat{\alpha} + \hat{\beta}t_i$ (forventede værdier)
<code>lmfit\$residuals</code>	residualer $r_i = x_i - \hat{\xi}_i$
<code>confint(lmfit)</code>	95%-konfidensintervaller for parametre

Når kører **lm** siger vi, at vi *fit*ter modellen specificeret ved modelformlen. På R-kode 4.8 fittes model for simpel lineær regression til data fra Eksempel 4.1, hvorefter vi laver parametertabellen ved hjælp af **summary**.

R-kode 4.8

```
lmfit <- lm(logGlu ~ logColi)
summary(lmfit)
```

En del af output fra R-kode 4.8 findes på R-udskrift 4.2, hvor vi genfinder en lang række af de størrelser som er beregnet ovenfor.

R-udskrift 4.2

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -3.8872      0.1334  -29.14  <2e-16 ***
logColi       0.8494      0.0286   29.69  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3094 on 96 degrees of freedom
Multiple R-squared:  0.9018,    Adjusted R-squared:  0.9008
F-statistic: 881.7 on 1 and 96 DF,  p-value: < 2.2e-16

```

Vi vil også benytte Eksempel 4.1 til at illustrere beregninger af konfidensintervaller og prædiktionsintervaller. For at gøre dette i **R** skal vi først definere et nyt datasæt, der indeholder de ønskede værdier af den forklarende variabel. I R-kode 4.9 danner vi først et datasæt med variabelen *logColi*, som antager værdierne 4.9, 5.7 og 6.8. Derefter bruger vi **predict**-funktionen til at beregne 95%-konfidensintervaller (ved at angive `interval = "confidence"`) og 95%-prædiktionsintervaller (ved at angive `interval = "prediction"`).

R-kode 4.9

```

nyData = data.frame(logColi = c(4.9,5.7,6.8))
predict(lmfit,nyData,interval = "confidence")
predict(lmfit,nyData,interval = "prediction")

```

Output fra ovenstående kode bliver

R-kode 4.10

```

> predict(lmfit,nyData,interval = "confidence")
      fit      lwr      upr
1 0.2746120 0.2091721 0.3400519
2 0.9540989 0.8633519 1.0448458
3 1.8883933 1.7455389 2.0312478
> predict(lmfit,nyData,interval = "prediction")
      fit      lwr      upr
1 0.2746120 -0.3430939 0.8923178
2 0.9540989  0.3332018 1.5749959
3 1.8883933  1.2577702 2.5190165

```

Beregninger til Eksempel 4.2

Vi viser her ud fra data fra Tabel 4.3 hvordan man kan beregne estimater for hældning og afskæring, samt hvordan vi ud fra disse kan beregne prædikterede værdier og residualer. Da der er tale om et lille datasæt, kan dette indlæses direkte som vektorer, hvilket er gjort på R-kode 4.11.

R-kode 4.11

```
rotationer <- c(170,170,170,170,530,530,530,530,880,880,880,880)
masse <- c(3.89,3.95,3.85,3.91,3.61,3.58,3.66,3.71,3.30,3.26,3.30,3.34)
```

Estimaterne i M_2 beregnes ved hjælp af formlerne i (4.6) eller vi kan fitte modellen for simpel lineær regression og køre **summary** som på 4.12

R-kode 4.12

```
lmfit_m2 <- lm(masse ~ 1 + rotationer)
summary(lmfit_m2)
```

Parametertabellen for M_2 er

R-udskrift 4.3

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.058e+00  2.897e-02  140.08  < 2e-16 ***
rotationer   -8.445e-04  4.819e-05  -17.52  7.78e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04839 on 10 degrees of freedom
Multiple R-squared:  0.9685,    Adjusted R-squared:  0.9653
F-statistic: 307.1 on 1 and 10 DF,  p-value: 7.78e-09
```

Til slut i Eksempel 4.2 undersøgte vi, om M_2 kunne reduceres til M_3^* fra (4.28), det vil sige, om afskæringen kunne antages at være $\alpha_0 = \ln(60)$. Parametertabellen i R-udskrift 4.3 indeholder et t -test for hypotesen $H : \alpha = \alpha_0 = 0$, hvilket ikke umiddelbart er det, vi ønsker at teste. Løsningen er at definere en ny vektor `masse_minus_ln60`, hvor man trækker $\ln(60)$ fra alle observationer af `masse`. På den måde vil hypotesen $H : \alpha_0 = \ln(60)$ svare til $\tilde{\alpha} = 0$ for denne transformerede variabel.

I R-kode 4.13 defineres en sådan variabel, og modellen fittes til den transformerede variabel. Den tilsvarende parametertabel findes i R-udskrift 4.4, hvor man bl.a. genfinder p -værdien 0.24 fra t -testet i (4.27).

R-kode 4.13

```
masse_minus_ln60 <- masse - log(60)
lmfit_m2 <- lm(masse_minus_ln60 ~ 1 + rotationer)
summary(lmfit_m2)
```

R-udskrift 4.4

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -3.625e-02  2.897e-02  -1.251    0.239
rotationer  -8.445e-04  4.819e-05 -17.524 7.78e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04839 on 10 degrees of freedom
Multiple R-squared:  0.9685,    Adjusted R-squared:  0.9653
F-statistic: 307.1 on 1 and 10 DF,  p-value: 7.78e-09
```

Til slut ønsker vi at estimere hældningen i modellen M_3^* fra (4.28), hvor afskæringen α_0 er kendt og lig $\ln(60)$. I stedet for direkte at specificere $\alpha_0 = \ln(60)$, benytter vi en ækvivalent tilgang: Vi betragter den transformerede variabel og specificerer, at afskæringen i denne model er 0. Dette ses i R-kode 4.14, hvor 1 i modelformlen er erstattet med 0.

R-kode 4.14

```
lmfit_m3star <- lm(masse_minus_ln60 ~ 0 + rotationer)
summary(lmfit_m3star)
```

Parametertabellen svarende til 4.14 bliver

R-udskrift 4.5

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
rotationer -8.973e-04  2.383e-05 -37.66 5.59e-13 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04962 on 11 degrees of freedom
Multiple R-squared:  0.9923,    Adjusted R-squared:  0.9916
F-statistic: 1418 on 1 and 11 DF,  p-value: 5.588e-13
```

I R-udskrift 4.5 genkendes estimatet for $\hat{\beta}$ på -0.0008973 fra (4.29).

Invers regression i R

Når vi skal lave invers regression fra Afsnit 4.1.5 i R, benytter vi funktionen `inversReg`, som kan hentes fra kursushjemmesiden. Når denne er hentet ind i R, kan vi udføre invers regression på data fra Eksempel 4.1 ved først at fitte regressionsmodellen og dernæst give denne som input til `inversReg`, som vist i R-kode 4.15.

R-kode 4.15

```
lmfit=lm(logGlu~logColi)

invRegLog=inversReg(lmfit,1.05)
invRegLog$Konfidensinterval
exp(invRegLog$Konfidensinterval
```

Output fra ovenstående findes i R-udskrift 4.6

R-udskrift 4.6

```
5.085127 6.552178
161.6004 700.7684
```

Forestiller vi os dernæst at vi har foretaget fire målinger af $\log Glu$, der alle har givet værdien 1.05 kan vi beregne det tilhørende interval for $\log Coli$ ved hjælp af R-kode 4.16

R-kode 4.16

```
lmfit=lm(logGlu~logColi)

invRegLog=inversReg(lmfit,rep(1.05,4))
invRegLog$Konfidensinterval
exp(invRegLog$Konfidensinterval
```

Som det fremgår af R-udskrift 4.7, bliver de tilhørende intervaller i dette tilfælde noget smallere.

R-udskrift 4.7

```
5.439088 6.198216
230.2321 491.8709
```

Kapitel 5

Lineære normale modeller

I de foregående kapitler har vi betragtet en række forskellige modeller for normalfordelte data: Én, to og flere observationsrækker, samt lineær regression.

Trods modellernes forskellighed, som forstærkes af de forskellige faglige problemstillinger, de kan behandle, er de fra et matematisk synspunkt blot eksempler på *den lineære normale model*. Det er denne egenskab, som gør, at beregningerne i statistiske programpakker kan varetages af den samme procedure.

En lang række vigtige modeller udover dem, vi allerede har behandlet, er eksempler på den lineære normale model. Vi behandler først den lineære normale model generelt i Afsnit 5.1 og viser, hvordan man tester og estimerer i denne model. Dernæst ser vi, hvordan man finder de nødvendige størrelser i **R**. Under behandlingen af den lineære normale model, benytter vi de velkendte modeller for én, to og flere observationsrækker, samt lineær regression, som eksempler. Senere vil vi omtale *flere regressionslinjer* og *tosidet variansanalyse*, der er nye eksempler på lineære normale modeller.

5.1 Den lineære normale model

Lad $x_1, \dots, x_n$ være realisationer af uafhængige normalfordelte stokastiske variable $X_1, \dots, X_n$, hvor

$$X_i \sim N(\mu_i, \sigma^2), \quad i = 1, \dots, n.$$

Bemærk, at alle observationerne forudsættes at have **samme varians**. Dette kaldes *varianshomogenitet* eller *homoskedasticitet*, og er en fundamental forudsætning for lineære normal modeller, som i så vidt muligt omfang skal kontrolleres. Vi opfatter observationerne som en vektor i $\mathbb{R}^n$

$$\mathbf{x} = (x_1, \dots, x_n)^*,$$

og tilsvarende opfattes middelværdierne som en vektor, som kaldes *middelværdivektoren*

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^*.$$

Vi opfatter vektorerne som søjlevektorer, og minder om at $*$ betegner transponering af en vektor.

Lineære normal modeller specificeres ved at middelværdivektoren tilhører *lineære underrum* af $\mathbb{R}^n$. Lineære underrum og tilhørende begreber fra lineær algebra er forklaret i Appendiks afsnit A.2, særligt Afsnit A.2.3.

Ved den lineære normale model M specificeret ved underrummet L (kaldet *middelværdiunderrummet*) forstår vi, at $x_1, \dots, x_n$ er realisationer af uafhængige normalfordelte stokastiske variable $X_1, \dots, X_n$, hvor $X_i \sim N(\mu_i, \sigma^2)$ og

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^* \in L.$$

Vi vil kort skrive denne model

$$M : \boldsymbol{\mu} \in L,$$

idet vi underforstår uafhængigheden af observationerne, samt at de er normalfordelt. Lineære normale modeller er altså, som det fremgår, modeller for middelværdivektoren.

Vi har tidligere været inde på, at antallet af parametre i middelværdien i en model sammen med antallet af observationer bestemte antallet af frihedsgrader f i variansskønnets $\chi^2(f)/f$ -fordeling, se for eksempel side 30 eller 60. Disse bestemmer dermed også frihedsgraderne i F -testene. En matematisk præcis formulering af antal parametre i middelværdien er dimensionen af underrummet, der specificerer middelværdien. Vi skal derfor hele tiden bemærke dimensionen, d , af vektorrummet L .

Eksempel 5.1 (Én observationsrække).

I dette eksempel vil vi redegøre for at modellen fra (2.9) er en lineær normal model. Her er $\mu_i = \mu$ for alle i , så

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix} = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \mu \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}. \quad (5.1)$$

Når modellen for én observationsrække skal skrives som en lineær normal model, skal vi finde et underrum L så $\boldsymbol{\mu} \in L$. Vi indfører derfor vektoren $\mathbf{1} \stackrel{\text{def}}{=} (1, \dots, 1)^*$, og underrummet som er frembragt af $\mathbf{1}$ det vil sige

$$L = \text{span}(\mathbf{1}) = \text{span}\left(\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}\right).$$

Af (5.1) ses det, at modellen for én observationsrække da kan skrives som $\boldsymbol{\mu} \in L$, og vi siger at modellen for én observationsrække er *specificeret ved underrummet* L . Bemærk at dimensionen af L er $d = 1$.

Bemærkning 5.2 På side 17 betragtede vi hypotesen $H : \mu = \mu_0$ hvor μ_0 var et kendt, fast tal, og spørgsmålet er nu om den tilsvarende model er en lineær normal model. I dette tilfælde er $\boldsymbol{\mu} = (\mu_0, \dots, \mu_0)^* = \mu_0 \mathbf{1}$. Vi konstaterer at dette er *ikke generelt* er en lineær normal model, fordi $L = \{\mu_0 \mathbf{1}\}$ ikke udgør et lineært underrum, med mindre $\mu_0 = 0$. ▼

Eksempel 5.3 (To observationsrækker).

Bemærk først at modellen fra (3.5) *ikke* specificerer en lineær normal model, fordi der ikke antages varianshomogenitet. Vi betragter derfor modellen fra (3.9). Her er $n = n_1 + n_2$ og $\mu_i = \eta_1$, $i = 1, \dots, n_1$, og $\mu_i = \eta_2$, $i = n_1 + 1, \dots, n_1 + n_2$.[‡] Derfor er

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_{n_1} \\ \mu_{n_1+1} \\ \vdots \\ \mu_{n_1+n_2} \end{pmatrix} = \eta_1 \begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \eta_2 \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \left. \begin{array}{l} \left. \vphantom{\begin{pmatrix} 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}} \right\} n_1 \text{ gange} \\ \left. \vphantom{\begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix}} \right\} n_2 \text{ gange} \end{array} \right\} \quad (5.2)$$

Vektorerne på højresiden af (5.2) indføres nu som $\mathbf{1}_1$ og $\mathbf{1}_2$, hvor koordinaterne for $\mathbf{1}_1$ og $\mathbf{1}_2$ altså er givet ved henholdsvis

$$(\mathbf{1}_1)_j = \begin{cases} 1, & \text{for } j = 1, \dots, n_1, \\ 0, & \text{for } j = n_1 + 1, \dots, n_1 + n_2, \end{cases}$$

og

$$(\mathbf{1}_2)_j = \begin{cases} 0, & \text{for } j = 1, \dots, n_1, \\ 1, & \text{for } j = n_1 + 1, \dots, n_1 + n_2. \end{cases}$$

Vi kan da skrive (5.2) kort som

$$\boldsymbol{\mu} = \eta_1 \mathbf{1}_1 + \eta_2 \mathbf{1}_2.$$

Modellen for to observationsrækker er således specificeret ved underrummet L , som er frembragt af vektorerne $\mathbf{1}_1$ og $\mathbf{1}_2$, det vil sige

$$L = \text{span}(\mathbf{1}_1, \mathbf{1}_2).$$

Dimensionen af L er $d = 2$, da $\mathbf{1}_1$ og $\mathbf{1}_2$ er lineært uafhængige. □

Eksempel 5.4 (k observationsrækker).

I dette eksempel betragtes modellen fra (3.28). I analogi med Eksempel 5.3 ser man, at modellen for k observationsrækker er den lineære normale model specificeret ved

$$L = \text{span}\{\mathbf{1}_1, \dots, \mathbf{1}_k\},$$

hvor vektorerne er defineret ved inddelingen af observationerne i de k observationsrækker. Således er

$$(\mathbf{1}_i)_j = \begin{cases} 1, & \text{hvis } x_j \text{ tilhører } i\text{te række,} \\ 0, & \text{ellers.} \end{cases} \quad \square$$

Dimensionen af L er k , da $\mathbf{1}_1, \dots, \mathbf{1}_k$ er lineært uafhængige.

[‡]Sædvanligvis betegnes middelværdierne i de to grupper μ_1 og μ_2 , men denne betegnelse skal her bruges til den første henholdsvis anden indgang i $\boldsymbol{\mu}$.

Bemærkning 5.5 Vi bemærker at vektorerne $\mathbf{1}_i$ fra Eksempel 5.3 og 5.4 kan opskrives ved hjælp af indikatorfunktioner, idet f.eks. $(\mathbf{1}_1)_j = 1_{\{1, \dots, n_1\}}(j)$, $(\mathbf{1}_2)_j = 1_{\{n_1+1, \dots, n_2\}}(j)$ osv. Denne observation kan være nyttig, for eksempel når man skal forstå hvorledes de statistiske procedurer konkret implementeres i statistiske programpakker som **SAS** eller **R**. ▼

Eksempel 5.6 (Simpel lineær regression).

Hvor betragter her modellen (4.1). I denne gælder $\mu_i = \alpha + \beta t_i$, så

$$\boldsymbol{\mu} = \begin{pmatrix} \alpha + \beta t_1 \\ \alpha + \beta t_2 \\ \vdots \\ \alpha + \beta t_n \end{pmatrix} = \alpha \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} + \beta \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{pmatrix}. \quad (5.3)$$

Man ser, at $L = \text{span}(\mathbf{1}, \mathbf{t})$, hvor $\mathbf{1}$ er defineret i Eksempel 5.1, og

$$\mathbf{t} = (t_1, \dots, t_n)^*.$$

Dimensionen af L er 2, hvis der er mindst to forskellige værdier af den uafhængige variabel t . □

5.2 Inferens i lineære normale modeller

5.2.1 Estimation

I det afsnit vil vi omtale estimation og test i lineære normale modeller. Vi benytter likelihood teori som omtalt i Afsnit 2.3 og vil derfor først finde maksimum likelihood estimaterne. Vi opstiller derfor likelihood funktionen, der er funktion af middelværdierne $\mu_1, \mu_2, \dots, \mu_n$ og variansen σ^2 .

Likelihoodfunktionen er


$$\begin{aligned} L(\boldsymbol{\mu}, \sigma^2) &= L(\mu_1, \mu_2, \dots, \mu_n, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i - \mu_i)^2} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_i)^2} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}\|^2}, \end{aligned} \quad (5.4)$$

hvor længden af en vektor $\mathbf{v} = (v_1, \dots, v_n)$ betegnes med

$$\|\mathbf{v}\| = \sqrt{v_1^2 + \dots + v_n^2}.$$

Som tidligere maksimeres L med hensyn til $\boldsymbol{\mu}$ for fast σ^2 . På grund af minusset i eksponenten svarer det at maksimere $L(\boldsymbol{\mu}, \sigma^2)$ med hensyn til $\boldsymbol{\mu}$, til at minimere kvadratlængden $\|\mathbf{x} - \boldsymbol{\mu}\|^2$ med hensyn til $\boldsymbol{\mu}$. Maksimum likelihood estimatet $\hat{\boldsymbol{\mu}}$ for $\boldsymbol{\mu}$ er den værdi af $\boldsymbol{\mu}$ i L , som opfylder

$$\|\mathbf{x} - \hat{\boldsymbol{\mu}}\|^2 = \min_{\boldsymbol{\mu} \in L} \|\mathbf{x} - \boldsymbol{\mu}\|^2. \quad (5.5)$$



Figur 5.1: Geometrien for estimation i en lineær normal model.

Estimatet $\hat{\boldsymbol{\mu}}$ er altså den værdi i L , som har den korteste afstand til $\mathbf{x}$ eller, med andre ord, ligger nærmest ved $\mathbf{x}$.

Man kan vise, at der er netop ét punkt i L , som er nærmest ved $\mathbf{x}$. Dette punkt kaldes *projektionen af $\mathbf{x}$ på L* . Vi betegner det $P(\mathbf{x})$ og der gælder dermed at $\hat{\boldsymbol{\mu}} = P(\mathbf{x})$. Man kan endvidere vise, at $P(\mathbf{x})$ er karakteriseret ved, at $\mathbf{x} - P(\mathbf{x})$ står vinkelret på enhver vektor i L . Specielt er trekanten med hjørner $\mathbf{0}$, $\mathbf{x}$ og $P(\mathbf{x})$ en retvinklet trekant, som det er antydnet i Figur 5.1.

Endvidere kan $P(\mathbf{x})$ altid beregnes, når man kender de vektorer, som frembringer L .

Vi har nu fundet maksimum likelihood estimatet for $\boldsymbol{\mu}$ og kan konstatere, at det ikke afhænger af σ^2 . For alle σ^2 er

$$L(\boldsymbol{\mu}, \sigma^2) \leq L(P(\mathbf{x}), \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - P(\mathbf{x})\|^2}. \quad (5.6)$$

Vi kan nu benytte Lemma 2.2 til at maksimere højresiden af (5.6) som funktion af σ^2 og får derved løsningen

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2. \quad (5.7)$$

I overensstemmelse med tidligere vil vi undertiden bruge betegnelsen SSD for $\|\mathbf{x} - P(\mathbf{x})\|^2$. Det kan vises at (5.7) generaliserer de tidligere fundne SSD-størrelser, (2.22), (3.10) og (4.3).

Vi noterer til senere brug, at hvis $\hat{\sigma}^2$ indsættes i højresiden af (5.6), finder man, at likelihood funktionens maksimum er

$$L(\hat{\boldsymbol{\mu}}, \hat{\sigma}^2) = L(P(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2) = \left(\frac{n}{2\pi \|\mathbf{x} - P(\mathbf{x})\|^2} \right)^{\frac{n}{2}} e^{-\frac{n}{2}}. \quad (5.8)$$

Det følger af Sætning A.5


$$\|\mathbf{X} - P(\mathbf{X})\|^2 \sim \sigma^2 \chi^2(n - d), \quad (5.9)$$

hvor d er dimensionen af L , så som skøn over σ^2 bruges

$$s^2 = \frac{1}{n - d} \|\mathbf{x} - P(\mathbf{x})\|^2, \quad (5.10)$$

der vil være en realisation af en $\sigma^2 \chi^2(n - d)/(n - d)$ fordelt stokastisk variabel.

5.2.2 Test



Figur 5.2: De centrale størrelser i test af reduktionen fra M_1 til M_2 er sidelængderne i den fuldt optrukne trekant. Relationen mellem sidelængderne er givet i (5.12).

Vi skal nu betragte flere modeller samtidigt, og indicerer derfor modeller, underrum, dimensioner, projektioner og variansskøn. For modellen M_i betegnes de henholdsvis L_i , d_i , $P_i(\mathbf{x})$ og s_{0i}^2 . Endvidere er $SSD_{0i} = \|\mathbf{x} - P_i(\mathbf{x})\|^2$.


Vi betragter grundmodellen

$$M_1 : \quad \boldsymbol{\mu} \in L_1,$$

og vil teste reduktionen til modellen

$$M_2 : \quad \boldsymbol{\mu} \in L_2,$$

hvor M_2 giver en simpleere beskrivelse af data end M_1 . Det vil sige, at L_2 er et underrum af L_1 . Det skriver vi $L_2 \subset L_1$. Vi siger, at modellen M_2 er indeholdt i M_1 , hvis de tilhørende underrum opfylder $L_2 \subset L_1$. Geometrien i de to modeller er illustreret i Figur 5.3.



Figur 5.3: Geometrien i lineære normale modeller specificeret ved underrum $L_2 \subset L_1$.

Det følger af Afsnit 5.2.1 at maksimum likelihood estimaterne for $\boldsymbol{\mu}$ og σ^2 i M_1 er

$$\hat{\boldsymbol{\mu}} = P_1(\mathbf{x}) \quad \text{og} \quad \hat{\sigma}_{01}^2 = \frac{1}{n} \|\mathbf{x} - P_1(\mathbf{x})\|^2,$$

mens de i M_2 er

$$\hat{\boldsymbol{\mu}} = P_2(\mathbf{x}) \quad \text{og} \quad \hat{\sigma}_{02}^2 = \frac{1}{n} \|\mathbf{x} - P_2(\mathbf{x})\|^2.$$

Vi kan nu udlede likelihood ratio testet for reduktionen fra M_1 til M_2 . Likelihood funktionens maksimum under de to modeller kan aflæses af (5.8), og man finder, at

$$\begin{aligned} Q(\mathbf{x}) &= \frac{L\left(P_2(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_2(\mathbf{x})\|^2\right)}{L\left(P_1(\mathbf{x}), \frac{1}{n} \|\mathbf{x} - P_1(\mathbf{x})\|^2\right)} \\ &= \left(\frac{\|\mathbf{x} - P_1(\mathbf{x})\|^2}{\|\mathbf{x} - P_2(\mathbf{x})\|^2} \right)^{\frac{n}{2}} = \left(\frac{\hat{\sigma}_{01}^2}{\hat{\sigma}_{02}^2} \right)^{\frac{n}{2}}. \end{aligned} \quad (5.11)$$

Dette resultat blev anvendt i 3.33. Selv om udtrykket i (5.11) for $Q(\mathbf{x})$ er enkelt og let at beregne, fortsætter vi omskrivningen for at udtrykke $Q(\mathbf{x})$ som en funktion af en F -fordelt stokastisk variabel.

Da $L_2 \subset L_1$ er $P_1(\mathbf{x}) - P_2(\mathbf{x}) \in L_1$, så $\mathbf{x} - P_1(\mathbf{x})$ står vinkelret på $P_1(\mathbf{x}) - P_2(\mathbf{x})$. Trekanten med hjørner $\mathbf{x}$, $P_1(\mathbf{x})$ og $P_2(\mathbf{x})$ er dermed en retvinklet trekant. Ifølge Pythagoras er

$$\|\mathbf{x} - P_2(\mathbf{x})\|^2 = \|\mathbf{x} - P_1(\mathbf{x})\|^2 + \|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2, \quad (5.12)$$

så Q kan omskrives på følgende måde

$$\begin{aligned} Q(\mathbf{x}) &= \left(\frac{\|\mathbf{x} - P_1(\mathbf{x})\|^2}{\|\mathbf{x} - P_2(\mathbf{x})\|^2} \right)^{\frac{n}{2}} \\ &= \left(\frac{\|\mathbf{x} - P_1(\mathbf{x})\|^2}{\|\mathbf{x} - P_1(\mathbf{x})\|^2 + \|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2} \right)^{\frac{n}{2}} \\ &= \left(\frac{1}{1 + \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2}{\|\mathbf{x} - P_1(\mathbf{x})\|^2}} \right)^{\frac{n}{2}} \\ &= \left(\frac{1}{1 + \frac{d_1 - d_2}{n - d_1} F} \right)^{\frac{n}{2}}, \end{aligned}$$

hvor

$$\mathcal{F}(\mathbf{x}) = \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2 / (d_1 - d_2)}{\|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - d_1)}. \quad (5.13)$$

Små værdier af Q er kritiske for reduktionen til M_2 , og det svarer til store værdier af $\mathcal{F}(\mathbf{x})$. Man kan vise, at under modellen M_2 er $\mathcal{F}(\mathbf{X})$ en realisation af en F -fordelt stokastisk variabel med $d_1 - d_2$ frihedsgrader i tælleren og $n - d_1$ frihedsgrader i nævneren, så testsandsynligheden beregnes som

$$p_{obs}(\mathbf{x}) = 1 - F_{F(d_1 - d_2, n - d_1)}(\mathcal{F}(\mathbf{x})). \quad (5.14)$$

Vi nævner igen, at dimensionen af underrummet er en præcis formulering af antallet af parametre i middelværdien, så fortolkningen af frihedsgraderne for tælleren i F -fordelingen er reduktionen i

antallet af parametre ved at gå fra M_1 til M_2 . Frihedsgraderne i nævneren er antallet af observationer minus antallet af parametre i M_1 , og det kan fortolkes som reduktionen i antal parametre ved at gå fra en model, hvor hver observation har sin parameter til modellen M_1 . Til slut bemærker vi, jævnfør formel (5.10) at nævneren i (5.13), $\|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - d_1)$ er lig variansskønnet i M_1 , og vi kunne derfor også skrive

$$\mathcal{F}(\mathbf{x}) = \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2 / (d_1 - d_2)}{s_{01}^2}. \quad (5.15)$$

Eksempel 5.1 (fortsat).

Lad vektorrummet L i Eksempel 5.1 være L_1 . Da $\dim L_1 = 1$, er eneste mulighed for et underrum, som er indeholdt i L_1 , det nul-dimensionale underrum $L_2 = \{\mathbf{0}\}$. Da svarer M_2 til modellen, at alle observationer har middelværdi 0.

Denne reduktion af modellen blev i Afsnit 2.2 testet med et t -test, jævnfør (2.12) eller side 31. Kvadratet på t -teststørrelsen er netop F -testet i (5.13)/(5.15) (se (A.54)), og p -værdien afhænger ikke af, hvilket af de to tests man anvender. De to tests er med andre ord ækvivalente. $\square$

Eksempel 5.3 (fortsat).

Lad L_1 være vektorrummet L fra Eksempel 5.3. Modellen specificeret ved $L_2 = \text{span}\{\mathbf{e}_1 + \mathbf{e}_2\} = \text{span}\{\mathbf{e}\}$ er modellen for én observationsrække. Dimensionerne er $d_1 = 2$ og $d_2 = 1$, så frihedsgraderne for F -testet for reduktionen fra M_1 til M_2 er $d_1 - d_2 = 1$ for tælleren og $n - d_1 = n - 2$ for nævneren.

Denne reduktion af modellen blev i Afsnit 3.1.2 testet med et t -test, jævnfør side 37. Kvadratet på t -teststørrelsen er netop F -testet i (5.13)/(5.15), og testsandsynligheden afhænger heller ikke her af, hvilket af de to test man anvender. $\square$

Eksempel 5.4 (fortsat).

Lad L_1 være det k -dimensionale underrum fra Eksempel 5.4. Modellen specificeret ved $L_2 = \text{span}\{\mathbf{e}_1 + \cdots + \mathbf{e}_k\} = \text{span}\{\mathbf{e}\}$ er modellen for én observationsrække.

Det var den reduktion, der var emnet for Afsnit 3.2.2, og F -testet fra (3.34) er et specialtilfælde af (5.13)/(5.15). Side 53 viste vi i Afsnit (3.2.2) en opdeling af den totale variation SSD_T i komponenterne SSD_E og SSD_H . Den opsplitning er (5.12) opskrevet i dette konkrete tilfælde, og

$$\text{SSD}_T = \|\mathbf{x} - P_2(\mathbf{x})\|^2, \quad \text{SSD}_E = \|\mathbf{x} - P_1(\mathbf{x})\|^2 \quad \text{og} \quad \text{SSD}_H = \|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2. \quad \square$$

Men her er flere muligheder for modeller, når $k > 2$. Underrummet $L_2 = \text{span}\{\mathbf{e}_1 + \cdots + \mathbf{e}_i, \mathbf{e}_{i+1} + \cdots + \mathbf{e}_k\}$ giver modellen, hvor data er opdelt i to grupper med forskellig middelværdi i hver gruppe. Vi vender tilbage til den model i forbindelse med en genoptagelse af Eksempel 3.2.

Eksempel 5.6 (fortsat).

L_1 er det to-dimensionale underrum i Eksempel 5.6. Her er to muligheder for L_2 .

$L_2 = \text{span}\{\mathbf{e}\}$ er modellen for én observationsrække og testet for reduktionen til M_2 svarer til at teste $\beta = 0$. F -testet i (5.13), som får $d_1 - d_2 = 2 - 1 = 1$ frihedsgrader i tælleren og $n - d_1 = n - 2$ frihedsgrader i nævneren, er kvadratet på t -testet for $\beta = 0$, som vi angav i Afsnit 4.1.2, og testsandsynligheden er den samme, uanset om man bruger t - eller F -test.

Den anden oplagte mulighed er M_2^* specificeret ved $L_2^* = \text{span}\{\mathbf{t}\}$. Reduktionen til M_2^* svarer til at teste $\alpha = 0$, og der er naturligvis også her ækvivalens mellem at bruge t -testet i Afsnit 4.1.2 og F -testet i (5.13)/(5.15). $\square$

5.2.3 Hvilke modeller er *lineære normale modeller*?

Det er klart, at udfordringen består i, hvilke modeller der er specificeret ved et lineært underrum. Svaret er, at det er alle modeller, der kan specificeres ved, at middelværdierne er ens i grupper, eller at de afhænger lineært af én eller flere forklarende variable, eventuelt med forskellig regressionskoeficient og/eller forskellig afskæring i grupper.

Det eneste krav er, at parametrene i modellen skal være uspecificerede. En lineær regressionsmodel, hvor hældningen skal være 2, er for eksempel ikke en lineær normal model. Dette udgør dog ingen reel begrænsning af de lineære normale modeller. Hvis $\mathbf{x}$ følger en lineær normal model med underrum $L = \text{span}\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_d\}$, og der er behov for at betragte koefficienten til $\mathbf{1}_1$ som fast, fx β_{01} , så vil den justerede respons $\mathbf{x} - \beta_{01} \mathbf{1}_1$ følge en lineær normal model med underrum $\tilde{L} = \text{span}\{\mathbf{1}_2, \dots, \mathbf{1}_d\}$.

I Eksempel 4.2 havde man som udgangspunkt en regressionsmodel med underrum $L = \text{span}\{\mathbf{1}, \mathbf{t}\}$, hvor $\mathbf{t}$ indeholdt antallet af rotationer. I det tilfælde var det rimeligt at arbejde med modellen, hvor afskæringen på andenaksen er $\ln 60$, dvs. koefficienten til $\mathbf{1}$ er $\ln 60$. Da følger $\mathbf{x} - \ln 60 \mathbf{1}$ en lineær normal model med underrum $\text{span}\{\mathbf{t}\}$.

Det vigtigste spørgsmål set fra et anvendelsesmæssigt perspektiv er, hvordan man kan specificere modellerne i en programpakke samt afgøre, hvornår en ny model er indeholdt i en tidligere model, så reduktionen kan testes. I det næste afsnit gennemgås specifikationen af de lineære normale modeller, som vi har mødt på kurset.

Appendiks til Afsnit 5.2

Beregninger i R

Som nævnt i den indledende omtale af lineære normale modeller, er mange af de modeller, vi har gennemgået, eksempler på netop lineære normale modeller. I R behandles sådanne modeller med kommandoen `lm`, som blev omtalt i Appendiks til Afsnit 4.1. Her vil vi gå mere i detaljer med `lm`.

Et forsimplet kald til `lm` ser ud som vist i R-kode 5.1:

R-kode 5.1:

```
lm(formula, data = navn på datasæt)
```

Her er `formula` *modelformlen*, der benyttes til at angive det lineære underrum L , som specificerer den lineære normale model. Vi vil i dette afsnit vise, hvordan dette gøres for de gennemgåede eksempler. Modelformlen har generelt den form, der er vist i R-kode 5.2:

R-kode 5.2:

```
responsvariabel ~ liste med forklarende variable
```

Betegnelserne “responsvariabel” og “forklarende variabel” blev indført på side 58, og som i dét afsnit anvendes betegnelsen “responsvariabel” om den variabel, hvis middelværdi vi ønsker at beskrive. Betegnelsen “forklarende variabel” blev i Afsnit 4.1 brugt om den *kontinuerte* variabel t , men som vi skal se i de kommende afsnit, vil betegnelsen generelt dække flere forskelligartede størrelser, der kan benyttes til at beskrive middelværdien.

Én observationsrække

Vi starter med modellen for én observationsrække, der i Eksempel 5.1 blev omtalt som en lineær normal model, og hvor det tilhørende dataeksempel var Eksempel 2.1 om spændingsmålinger ved en automatiseret svejsningsproces. Eksemplet er meget enkelt, så vi behøver ikke indlæse et egentligt datasæt, men kan nøjes med at taste indholdet af Tabel 2.1 ind i vektoren `Volt`, som vist i R-kode 5.3.

R-kode 5.3:

```
Volt <- c(21.89, 22.20, 21.80, 22.75, 22.26, 21.88, 22.25,
         22.41, 22.35, 22.01, 22.71, 22.22, 21.95, 21.27, 22.56,
         22.11, 22.19, 22.42, 22.45, 22.36, 22.48, 22.43, 22.16,
         21.36, 22.37, 22.10, 22.07, 21.56, 21.94, 22.29)
```

Med vektoren `Volt` kan vi køre `lm` og gemme resultatet i `lmfit`.

R-kode 5.4

```
lmfit <- lm(Volt ~ 1)
```

Når vi kører `lm`, siger vi – som tidligere nævnt – at vi *fitter modellen*, hvilket her specifikt er modellen for én observationsrække. Vi ser endvidere, at modellen angives ved `1` som forklarende variabel. Dette kan forstås sådan, at middelværdien er $\mu \cdot 1$, hvor μ er fælles for alle observationerne.

Den fittede model lagres i objektet `lmfit`, og vi kan trække oplysninger ud af dette objekt ved hjælp af en række **R**-funktioner. I dette afsnit vil vi fokusere på én af disse, nemlig `anova`-kommandoen, som blandt andet kan bruges til at undersøge, om vi kan reducere fra en lineær normal model til en anden. Når `anova` køres på den fittede model med `anova(lmfit)`, vises en *variansanalysetabel* for modellen.

R-udskrift 5.1

```
Analysis of Variance Table
```

```
Response: Volt
```

```
          Df Sum Sq Mean Sq F value Pr(>F)
```

```
Residuals 29  3.5636  0.12288
```

Vi uddyber indholdet af variansanalysetabellen senere, men vil indtil videre bemærke, at tallene i R-udskrift 5.1 alle genkendes fra tidligere. $Df = 29$ er nemlig antallet af frihedsgrader i estimatoren for variansskønnet, og både $\text{Sum Sq} = 3.5636$ og $\text{Mean Sq} = 0.12288$ findes i (2.10).

Vi har nu fittet M_1 fra (2.9) til vores datasæt. Vi minder om at $\mu_0 = 22.0\text{ V}$ betragtes som den ideelle spændingsværdi, og vi ønsker derfor at teste hypotesen $H : \mu = 22.0$ i M_1 . Som nævnt i Bemærkning 5.2 vil data *ikke* følge en lineær normal model under denne hypotese. Med andre ord udgør modellen M_2 , hvor X_i erne er uafhængige og identisk $N(22, \sigma^2)$ -fordelte, *ikke* en lineær normal model.

Dette problem løses ved at trække $\mu_0 = 22$ fra alle observationer, hvilket svarer til at betragte de transformerede variable

$$\tilde{X}_i := X_i - 22, \quad i = 1, \dots, n.$$

Under M_1 vil disse udgøre én observationsrække med middelværdi $\tilde{\mu} = \mu - 22$. Under hypotesen (M_2) vil de derimod udgøre én observationsrække med kendt middelværdi $\tilde{\mu} = 0$. Sidstnævnte *er* en lineær normal model (jf. Eksempel 5.1 side 91), og vi kan derfor anvende teorien fra Afsnit 5.2.2 til at undersøge hypotesen.

I praksis udføres testet ved at fitte de to modeller M_1 og M_2 og give dem som argumenter til `anova`, hvorved man får variansanalysetabellen *for reduktionen fra M_1 til M_2* . I R-kode 5.5 ses, hvordan vi først trækker 22 fra alle de oprindelige observationer og fitter modellen M_1 til disse. Dernæst fitter vi modellen `lm(Volt_minus_22 ~ 0)`, der svarer til M_2 med middelværdi 0 for alle observationer. Denne model angives altså ved at specificere `0` som forklarende variabel.

R-kode 5.5:

```
Volt_minus_22 <- Volt - 22
lmfit_m1 <- lm(Volt_minus_22 ~ 1)
lmfit_m2 <- lm(Volt_minus_22 ~ 0)
anova(lmfit_m2, lmfit_m1)
```

Variansanalysetabellen fremgår på R-udskrift 5.2. Vi genkender $p_{obs} = 0.01833$ fra (2.12) og bemærker at $F = 6.2499$ er lig 2.49997^2 , hvor 2.49997 var t -teststørrelsen fra (2.11) jvf. (A.54).

R-udskrift 5.2

```
Analysis of Variance Table

Model 1: Volt_minus_22 ~ 0
Model 2: Volt_minus_22 ~ 1
  Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1      30 4.3316
2      29 3.5636  1      0.768 6.2499 0.01833 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Generelt kan indholdet af variansanalysetabellen når vi kalder **anova** med to fittede modeller beskrives ved hjælp af de størrelser som blev indført i Afsnit 5.2.2 og dette er gjort Tabel 5.1.

Analysis of Variance Table						
Model 1: Modelformel for M_2						
Model 2: Modelformel for M_1						
	Res.df.	RSS	Df	Sum of Sq	F	Pr(>F)
1	$n - d_2$	$\ \mathbf{x} - P_2(\mathbf{x})\ ^2$				
2	$n - d_1$	$\ \mathbf{x} - P_1(\mathbf{x})\ ^2$	$d_1 - d_2$	$\ P_1(\mathbf{x}) - P_2(\mathbf{x})\ ^2$	$F(M_1, M_2)$	p_{obs}

Tabel 5.1: Variansanalysetabellen for reduktion fra M_1 til M_2 . Bemærk at modelformlen for M_1 står ud for Model 2 og vice versa.

hvor $F(M_1, M_2)$ og p_{obs} er fra henholdsvis (5.13) og (5.14):

$$F(M_1, M_2) = \mathcal{F}(\mathbf{x}) = \frac{\|P_1(\mathbf{x}) - P_2(\mathbf{x})\|^2 / (d_1 - d_2)}{\|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - d_1)} \quad \text{og}$$

$$p_{obs} = p_{obs}(\mathbf{x}) = 1 - F_{F(d_1 - d_2, n - d_1)}(\mathcal{F}(\mathbf{x})).$$

Indholdet i Tabel 5.1 kan også udtrykkes ved hjælp af SSD-størrelserne. Dette er gjort i Tabel 5.2:

Analysis of Variance Table

Model 1: Modelformel for M_2 Model 2: Modelformel for M_1

	Res.df.	RSS	Df	Sum of Sq	F	Pr(>F)
1	$n - d_2$	SSD_{02}				
2	$n - d_1$	SSD_{01}	$d_1 - d_2$	$SSD_{02} - SSD_{01}$	$F(M_1, M_2)$	p_{obs}

Tabel 5.2: Variansanalysetabellen for reduktion fra M_1 til M_2 k observationsrækker

Vi vil nu beskrive, hvordan man specificerer modellen for k observationsrækker fra (3.28). Dette omfatter naturligvis også modellen for to observationsrækker, der blev gennemgået i Afsnit 3.1. Når vi betragter de to modeller som lineære normale modeller, er der dog ingen grund til at behandle de to tilfælde separat.

Vi minder om, at dataeksemplet for k observationsrækker var Eksempel 3.2, der omhandlede bladarealet for fire grupper af sojabønner. Hele datasættet findes i Tabel 3.4. På R-kode 5.6 indlæses datasættet, hvorefter kommandoen **head** anvendes til at vise de første seks observationer.

R-kode 5.6

```
soya <- read.csv(file="soya.csv", stringsAsFactors=TRUE)
head(soya)
```

R-udskrift 5.3

```
  area light stress group
1  200   low    low     A
2  215   low    low     A
3  225   low    low     A
4  229   low    low     A
5  230   low    low     A
6  232   low    low     A
```

Som det fremgår af R-udskrift 5.3, består datasættet af fire søjler: `area`, `light`, `stress` og `group`. Søjlen `area` indeholder bladarealet, mens `group` angiver gruppen. Vi bemærker, at grupperne 1, 2, 3 og 4 her benævnes henholdsvis A, B, C og D. Variablen `group` er et eksempel på en *faktorvariabel* (ofte blot kaldet en *faktor*), og formålet med `stringsAsFactors=TRUE` i R-kode 5.6 er at sikre, at **R** opfatter `group` netop på denne måde. I første omgang skal vi kun bruge søjlerne `area` og `group`.

Vi kan nu fitte modellen for k observationsrækker ved hjælp af kaldet på R-kode 5.7

R-kode 5.7

```
lmfit_m1 <- lm(area~group,data=soya)
```

Løst sagt kan man læse modelformlen i R-kode 5.7 som “middelværdien af arealet afhænger af gruppen”. I Eksempel 3.2 var vi interesserede i hypotesen $H_{\mu 0}$ om ens middelværdier i de fire grupper, hvilket svarer til, at data kan beskrives som én observationsrække. Vi kan derfor undersøge $H_{\mu 0}$ ved at fitte modellen for én observationsrække og benytte **anova** til at beregne de relevante størrelser — herunder særligt p -værdien. Dette er gjort i R-kode 5.8, og det tilhørende output fremgår af R-udskrift 5.4.

R-kode 5.8

```
lmfit_m2 <- lm(area~1,data=soya)
anova(lmfit_m2,lmfit_m1)
```

R-udskrift 5.4

```
Analysis of Variance Table

Model 1: area ~ 1
Model 2: area ~ group
  Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1      51 100613
2      48  42976  3      57636 21.458 5.867e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Vi genkender flere af størrelserne fra den tidligere gennemregning, som findes på side 55. Det gælder især $\mathcal{F} = 21.458$ og SSD_H , der med tre decimalers præcision tidligere blev fundet til 57636.365. Endelig bemærker vi, at skønnet over variansen kan aflæses af R-udskrift 5.4 som

$$\frac{42976}{48} = 895.3,$$

hvilket stemmer overens med værdien beregnet på side 55.

Simpel lineær regression

Den sidste model, som vi vil omtale i dette afsnit, er modellen for simpel lineær regression fra (4.1), illustreret med dataeksemplet fra Tabel 4.3. Som tidligere bemærket kan datasættet indlæses direkte som vektorer, hvilket blev gjort i R-kode 4.11. Det kan dog også klares ved hjælp af R-kode 5.9, hvor kommandoen **rep** anvendes.

R-kode 5.9

```
rotationer <- rep(c(170, 530, 880), each=4)
masse <- c(3.89, 3.95, 3.85, 3.91, 3.61, 3.58, 3.66, 3.71, 3.30, 3.26, 3.30, 3.34)
```

Vi kan nu fitte modellen for simpel lineær regression d.v.s. M_2 fra (4.1) ved hjælp af kaldet som blev vist på R-kode 4.12

R-kode 5.10

```
lmfit_m2 = lm(masse ~ 1 + rotationer)
```

Modelformlen kan her læses som:

$$\mathbb{E}[\text{masse}] = \alpha \cdot 1 + \beta \cdot \text{rotationer},$$

således at ligheden mellem syntaksen i modelformlen og notationen i modelopskrivningen (4.1) er tydelig.[§]

Vi bemærker også forskellen mellem at have faktorvariabel `group` som forklarende variabel i R-kode 5.7 og den kontinuerte variabel `rotationer` som forklarende variabel i R-kode 5.10. I det første tilfælde specificeres en model, hvor middelværdien afhænger af gruppen — mere præcist er der en parameter μ_i for $i = 1, \dots, 4$ ved hvert *niveau* af faktoren `group`. `group` giver dermed anledning til fire parametre i middelværdien. I det andet tilfælde bidrager `rotationer` derimod i sig selv kun med een parameter, nemlig hældningen β , i middelværdien.

I Afsnit 4.1.4 testede vi hypotesen om lineær regression ved først at opstille en model med tre uafhængige observationsrækker (4.21) — én for hver værdi af den forklarende variabel (`rotationer`) — og derefter undersøge, om denne model kunne reduceres til en lineær regressionsmodel (4.22). Med andre ord betragtede vi i første omgang `rotationer` som en *faktorvariabel*, og derefter som en *kontinueret* variabel. I R-kode 5.11 definerer vi ved hjælp af kommandoen **`as.factor`** en faktorvariabel ud fra `rotationer`, hvilket netop sætter os i stand til at teste hypotesen fra Afsnit 4.1.4.

R-kode 5.11

```
rotationer_som_faktor = as.factor(rotationer)
lmfit_m1 = lm(masse ~ 1 + rotationer_som_faktor)
anova(lmfit_m2, lmfit_m1)
```

Outputtet fra R-kode 5.11 findes på R-udskrift 5.5. Vi genkender tidligere beregnede størrelser, herunder *p*-værdien fra (4.23) som ledte os frem til, at vi godt kunne acceptere hypotesen.

[§]Som det tidligere er nævnt er `1` strengt taget overflødigt i modelformlen, og `masse ~ rotationer` vil give samme resultat, fordi **R** selv tilføjer `1` til modelformlen, medmindre man eksplicit beder den om at lade være ved at tilføje `0` eller `-1`.

R-udskrift 5.5

```

Analysis of Variance Table

Model 1: masse ~ 1 + rotationer
Model 2: masse ~ 1 + rotationer_som_faktor
  Res.Df      RSS Df Sum of Sq    F Pr(>F)
1      10 0.023415
2       9 0.018200  1 0.0052153 2.579 0.1428

```

Til slut i Eksempel 4.2 undersøgte vi, om M_2 kunne reduceres til M_3^* fra (4.28), det vil sige, om afskæringen kunne antages at være $\alpha_0 = \ln(60)$. Denne hypotese kan også undersøges ved hjælp af **anova**, men ligesom i Eksempel 2.1 kan vi med **anova** ikke direkte teste, om en parameter er lig med en vilkårlig fast værdi. Vi kan kun undersøge, om en parameter er lig med nul. Løsningen er, som på side 95, igen at definere en ny variabel. I dette tilfælde opretter vi `masse_minus_ln60` ved at trække $\ln(60)$ fra alle observationerne i `masse`. Derved kommer hypotesen til at svare til $\tilde{\alpha} = 0$ for den transformerede variabel.

R-kode 5.12

```

masse_minus_ln60 = masse - log(60)
lmfit_m2 = lm(masse_minus_ln60 ~ 1 + rotationer)
lmfit_m3star = lm(masse_minus_ln60 ~ 0 + rotationer)
anova(lmfit_m3star, lmfit_m2)

```

Bemærk at `1` i den oprindelige modelformel erstattes med `0`, hvilket netop svarer til at vi ønsker at undersøge om afskæringen er lig 0, mens hældningen β , der ganges på `rotationer`, stadig er en fri paramter.

Output fra R-kode 5.12 findes på R-output 5.6. Vi genkender p -værdien (4.27) og bemærker endvidere at F -teststørrelsen på 1.5656 er lig kvadratet på t -teststørrelsen på -1.249 som fandtes i (4.26).

R-udskrift 5.6

```

Analysis of Variance Table

Model 1: masse_minus_ln60 ~ 0 + rotationer
Model 2: masse_minus_ln60 ~ 1 + rotationer
  Res.Df      RSS Df Sum of Sq    F Pr(>F)
1      11 0.027081
2      10 0.023415  1 0.0036659 1.5656 0.2393

```

5.3 Tosidet variansanalyse

Gennemgangen af tosidet variansanalyse tager udgangspunkt i Eksempel 3.2. Vi lægger ud med at gentage beskrivelsen af eksperimentet med henblik på at kunne præsentere datasættet som i Tabel 5.3, der er det naturlige udgangspunkt for tosidet variansanalyse.

Eksempel 3.2 (fortsat).

En plantefysiolog undersøgte virkningen af mekanisk stress på sojabønneplanter. Af 52 stiklinger blev halvdelen udsat for mekanisk stress ved at blive rystet i tyve minutter dagligt, mens resten ikke blev udsat for stress. For at se om en eventuel virkning af stress afhænger af lysforholdene, blev halvdelen af de stressede og halvdelen af de ikke-stressede stiklinger dyrket ved svagt lys. Resten af planterne blev dyrket ved en større (moderat) lysmængde. Responsen er det samlede bladareal efter 16 dages vækst. Data er blev gengivet i Tabel 3.4 men er gentaget i Tabel 5.3 i et format, der er nyttigt til at illustrere tosidet variansanalyse. Data er tegnet op i Figur 5.4.

		Stress			
		Ingen stress		Stress	
Lys	Svagt	200	215	163	182
		225	229	188	195
		230	232	202	205
		241	253	212	214
		256	264	215	230
		268	288	235	255
		288		272	
		268	271	201	216
	Moderat	273	282	241	257
		285	299	259	267
		309	310	269	282
		314	320	283	291
		337	340	291	312
		345		326	


Tabel 5.3: Samlet bladareal for 52 sojaplanter under forskellige vækstbetingelser.

Vi betragtede data fra dette forsøg i Afsnit 3.2, hvor vi gennemførte en *ensidet* variansanalyse. Vi har fået bekræftet, at data kan antages at være normalfordelt, og at variansen ikke afhænger af de fire behandlinger. Desuden testede vi hypotesen om, at alle observationer har samme middelværdi, men den hypotese blev forkastet. Vores slutmodel blev da:

$$M_1 : X_{ij} \sim N(\mu_i, \sigma^2) \quad i = 1, 2, \dots, 4 \quad j = 1, \dots, 13 \quad + \text{ uafhængighed.} \quad (5.16)$$

hvor i indikerer de 4 grupper er beskrevet på s. 48. Estimerne for parametrene var

$$\mu_1 \leftarrow \bar{x}_{1.} = 245.308 \quad \mu_2 \leftarrow \bar{x}_{2.} = 212.923 \quad \mu_3 \leftarrow \bar{x}_{3.} = 304.077 \quad \mu_4 \leftarrow \bar{x}_{4.} = 268.846. \quad (5.17)$$



Figur 5.4: Samlet bladareal tegnet op mod behandling.

Konklusionen er dermed, at behandlingerne påvirker det samlede bladareal, men vi mangler fortsat at beskrive, hvordan lys og stress indvirker på bladarealet.

Dette er et eksempel på et planlagt forsøg, hvor et antal veldefinerede behandlinger anvendes på delmængder af det forsøgsmateriale, der er til rådighed.

Behandlingerne er i dette tilfælde de to faktorer *lys* og *stress*, og de inddeler forsøgsmaterialet i undergrupper, som får forskellige behandlinger. Som tidligere nævnt kaldes de forskellige behandlinger for *faktorniveauer* eller blot *niveauer*, og i dette eksempel har begge faktorer to niveauer. Når en faktor har to niveauer, omtaler man dem ofte som henholdsvis et *lavt* og et *højt* niveau. Det giver især mening, når niveauerne repræsenterer doseringer af samme behandling. Her er “moderat lys” det høje niveau for faktoren *lys*, og “ingen stress” er det lave niveau for faktoren *stress*.

Når faktorerne *lys* og *stress* betragtes sammen, danner de en faktor med fire niveauer svarende til de fire kombinationer af niveauerne for lys og stress.

Udgangspunktet for den videre analyse er den kendte model for 4 uafhængige observationsrækker

som blev opskrevet i (5.16), men hvor indekseringen afspejler de 2 faktorer og deres niveauer:

$$M_1 : X_{ijk} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, 2, \quad j = 1, 2, \quad k = 1, \dots, 13. \quad (5.18)$$

Her indicerer $i = 1, 2$ de to niveauer af lys, $j = 1, 2$ de to niveauer af stress og $k = 1, \dots, 13$ observationerne, som har fået samme behandling.

På Figur 5.4 ses tydeligt, at bladarealet er lavere, når planterne er blevet stresset, og at bladarealet er lavere ved svagt lys end ved moderat lys. Figuren antyder altså, at stress har en virkning (bladarealet nedsættes ved stress), og at lyset også spiller en rolle, idet svagere lys giver mindre bladareal.

Indtil nu har beskrivelsen af behandlingernes effekt været kvalitativ og baseret på ændringen i positionen af de forskellige observationsrækker for de forskellige behandlinger. Hvis vi ønsker at kvantificere virkningerne, gør vi det via middelværdierne for fordelingerne. De estimerede middelværdier er vist med prikker i Figur 5.4.

Virksomheden af en faktor med to niveauer definerer vi som forskellen i middelværdi mellem det lave og det høje niveau af faktoren. Det er dog ikke altid meningsfuldt at tale om virkningen af en faktor, fordi denne kan afhænge af niveauerne for andre faktorer. I dette eksempel var det på forhånd ikke utænkeligt, at stress ville have en anden virkning ved lavt lys end ved moderat lys. Hvis det var tilfældet, kunne man ikke tale om virkningen af hverken lys eller stress uden at specificere, hvilket niveau af den anden faktor man befinder sig på, og man ville i så fald sige, at der er *vekselvirkning* mellem lys og stress.

Vender vi tilbage til Figur 5.4, ser det ud til, at faldet i bladareal, når planterne udsættes for stress, ikke afhænger af, om planterne vokser ved svagt eller moderat lys. Tilsvarende synes faldet i bladareal, når planterne vokser i svagt lys, ikke at afhænge af, om planterne udsættes for stress. Det betyder at Figur 5.4 peger på *additivitetsmodellen*

$$M_2 : X_{ijk} \sim N(\alpha_i + \beta_j, \sigma^2), \quad i = 1, 2, \quad j = 1, 2, \quad k = 1, \dots, 13, \quad (5.19)$$

der netop beskriver, at virkningen af én behandling ikke afhænger af niveauet af en anden. Derfor kaldes modellen også *modellen for ingen vekselvirkning*.

De interessante parametre er ikke α_i og β_j i sig selv, men derimod $\alpha_1 - \alpha_2$ og $\beta_1 - \beta_2$. Her angiver differensen $\alpha_1 - \alpha_2$ forskellen i bladarealet mellem de to niveauer af lys, mens differensen $\beta_1 - \beta_2$ angiver forskellen i bladarealet mellem de to niveauer af stress.

Disse to differenser beskriver sammen med $\alpha_2 + \beta_2$ middelværdien for de fire behandlinger under modellen M_2 . Dette illustrerer, at M_2 har $d_2 = 3$ parametre. Vi omtaler senere, hvordan parametrene estimeres.

På R-udskrift 5.9 aflæses testet for reduktionen fra M_1 til M_2 til

$$\mathcal{F} = \frac{\frac{26.327}{1}}{\frac{42976}{48}} = 0.0294.$$

p -værdien aflæses til

$$p_{obs}(\mathbf{x}) = 1 - F_{F(1,48)}(0.0294) = 0.8646.$$

Det strider ikke mod reduktionen til M_2 , som dermed overtager rollen som model.

Herefter kan man enten undersøge, om modellen kan reduceres til

$$M_3^r : X_{ijk} \sim N(\alpha_i, \sigma^2), \quad i = 1, 2, j = 1, 2, k = 1, \dots, 13,$$

eller til

$$M_3^s : X_{ijk} \sim N(\beta_j, \sigma^2), \quad i = 1, 2, j = 1, 2, k = 1, \dots, 13.$$

I modellen M_3^r afhænger middelværdien kun af niveauet af lys, så testet for reduktionen til M_3^r er testet for, at stress ingen betydning har for bladarealet. Superskriptet r på M_3^r minder om, at modellen kun indeholder *rækkeeffekterne*.

Tilsvarende afhænger middelværdien kun af niveauet af stress i M_3^s , så testet for reduktionen til M_3^s er testet for, at lys ingen betydning har for bladarealet. Her minder superskriptet s på M_3^s om, at modellen kun indeholder *søjleffekterne*.

Modellerne M_3^r og M_3^s er sideordnede, det vil sige, at den ene ikke er indeholdt i den anden. Begge modellerne er iøvrigt den velkendte model for to observationsrækker. I M_3^r udgør rækkerne i Tabel 5.3 de to observationsrækker, og i M_3^s er observationsrækkerne søjlerne i Tabel 5.3.

Vi tester først reduktionen til M_3^s . Udskrifterne fra estimation i modellerne M_2 og M_3^s findes på R-udskrift 5.10. Teststørrelsen er

$$\mathcal{F} = \frac{\frac{42752}{1}}{\frac{43003}{49}} = 48.71,$$

og det giver p -værdien

$$p_{obs}(\mathbf{x}) = 1 - F_{F(1,49)}(48.71) = 7 \cdot 10^{-9}.$$

Reduktionen til M_3^s bliver altså forkastet, og det bekræfter, at lys har betydning for bladarealet.

Testet for reduktionen til M_3^r modellerne M_2 og M_3^r findes på R-udskrift 5.11.

$$\mathcal{F} = \frac{\frac{14858}{1}}{\frac{43003}{49}} = 16.93,$$

og testsandsynligheden bliver

$$p_{obs}(\mathbf{x}) = 1 - F_{F(1,49)}(16.93) = 0.00015.$$

Reduktionen til M_3^r bliver altså også forkastet, og det bekræfter, at stress har betydning for bladvæksten.

Slutmodellen for data er M_2 . Ifølge denne model har både lys og stress betydning for bladarealet, og virkningen er *additiv*. Det vil sige, at stress virker ens for begge lysmængder, og at lys virker ens, uanset om planterne bliver stresset eller ej.

Vi vil senere, i Afsnit 5.3.1.2, omtale en betingelse på antallet af observationer i de forskellige celler, som gør, at de matematiske udtryk for estimaterne bliver relativt enkle, og som er opfyldt af datasættet i dette eksempel.

Som estimat for virkningen af lys beregnes

$$\hat{\alpha}_1 - \hat{\alpha}_2 = \bar{x}_{1..} - \bar{x}_{2..} = \frac{245.31 + 212.92}{2} - \frac{304.08 + 268.85}{2} = -57.35 \text{ cm}^2, \quad (5.20)$$

hvor $\bar{X}_{1..} - \bar{X}_{2..} \sim N(\alpha_1 - \alpha_2, \sigma^2/13)$.

Estimatet er altså forskellen i middelværdi af det totale bladareal mellem planter, der vokser ved lavt og højt niveau af lys. Værdien er negativ, fordi middelværdien af det totale bladareal er mindre for planter, der vokser ved lav lysintensitet. Værdierne for $\bar{x}_{1..}$ og $\bar{x}_{2..}$ er beregnet ud fra de fire gennemsnit inden for grupperne i Tabel 3.4.

Tilsvarende beregner man skøn over virkningen af stress som

$$\hat{\beta}_1 - \hat{\beta}_2 = \bar{x}_{.1} - \bar{x}_{.2} = 33.81 \text{ cm}^2, \quad (5.21)$$

hvilket er et estimat for forskellen i middelværdi af det totale bladareal mellem planter, der vokser ved lavt og højt niveau af stress. Estimatoren har i dette tilfælde en $N(\beta_1 - \beta_2, \sigma^2/13)$ fordeling.

Som sædvanlig bruger vi fordelingen af disse estimater til at beregne 95 % konfidensintervaller for virkningerne, så vi får en idé om forsøgets præcision. Estimatet for σ i M_2 fremgår af R-udskrift 5.12 og er 29.62. På baggrund af dette kan vi beregne de ønskede konfidensintervaller, idet vi også fra R-udskrift 5.12 ser, at estimatoren svarende til σ^2 er χ^2 -fordelt med 49 frihedsgrader.

$$\begin{array}{llll} \text{Lys:} & \alpha_1 - \alpha_2 & \leftarrow & -57 \text{ cm}^2 \quad \left[-74 \text{ cm}^2, -41 \text{ cm}^2 \right] \\ \text{Stress:} & \beta_1 - \beta_2 & \leftarrow & 34 \text{ cm}^2 \quad \left[17 \text{ cm}^2, 50 \text{ cm}^2 \right] \end{array} \quad \square$$

Man omtaler somme tider virkningen divideret med spredningen som en standardiseret *effektstørrelse*, og en effektstørrelse over 1 anses for stor. Her er skønnet over den standardiserede effektstørrelsen for stress $34/29.62 = 1.148$.

5.3.1 Generelt om tosidet variansanalyse

I Eksempel 3.2 havde man fire behandlinger, nemlig alle kombinationer af to behandlinger (stress og lysmængde), hvor hver behandling havde to niveauer. Formålet med analysen var at vurdere virkningen af disse to behandlinger.

Generelt kan man forestille sig rs behandlinger, som udgøres af alle kombinationer af en behandling R med r niveauer og en behandling S med s niveauer. Observationerne betegnes x_{ijk} , hvor $i = 1, \dots, r$ indikerer de r niveauer af R , $j = 1, \dots, s$ indikerer de s niveauer af S , og $k = 1, \dots, n_{ij}$ indikerer de observationer, der alle har fået behandling (i, j) . Man kan opskrive observationerne i en tabel med r rækker og s søjler og n_{ij} observationer i celle i, j , svarende til eksempelvis Tabel 3.4. Hvis vi, som sædvanlig, forudsætter, at alle observationer er udfald af uafhængige stokastiske variable X_{ijk} , kan de modeller, vi vil betragte, skrives således:

Grundmodellen

$$M_1 : X_{ijk} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$

Additivitetsmodellen

$$M_2 : X_{ijk} \sim N(\alpha_i + \beta_j, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$

Modellen med kun rækkevirkning

$$M_3^r : X_{ijk} \sim N(\alpha_i, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$


Modellen med kun søjlevirkning

$$M_3^s : X_{ijk} \sim N(\beta_j, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$

Modellen for én observationsrække

$$M_\infty : X_{ijk} \sim N(\mu, \sigma^2), \quad i = 1, \dots, r, \quad j = 1, \dots, s, \quad k = 1, \dots, n_{ij}.$$

Det indbyrdes forhold mellem modellerne M_2 , M_3^r , M_3^s og M_∞ er angivet i nedenstående skema.



Figur 5.5: Undermodeller og hypoteser i tosidet variansanalyse.

5.3.1.1 Additivitetsmodellen

Vi vil koncentrere omtalen om additivitetsmodellen, da modellerne M_1 , M_3^r , M_3^s og M_∞ blot er de velkendte modeller for henholdsvis rs , r , s og 1 observationsrækker.

M_2 er en lineær normal model, og man kan vise, at det tilhørende underrum har dimension $d_2 = r + s - 1$, så F -testet for reduktionen fra M_1 til M_2 får $d_1 - d_2 = rs - (r + s - 1) = (r - 1)(s - 1)$ frihedsgrader i tælleren og $n_{..} - rs$ frihedsgrader i nævneren. Her er $n_{..}$ det totale antal observationer.

F -testet for reduktionen fra M_1 til M_2 kan og bør suppleres med en tegning. På side 102 argumenterede vi netop for additivitetsmodellen på grundlag af Figur 5.4. Med mere end to rækker og søjler vil en tegning som Figur 5.4 blive uoverskuelig, og man laver derfor nogle andre tegninger for at vurdere additivitetsmodellen.

Under M_2 afhænger forskellen i middelværdi mellem to forskellige rækker g og h ikke af, i hvilken søjle man måler forskellen, da

$$EX_{gjk} - EX_{hjk} = (\alpha_g + \beta_j) - (\alpha_h + \beta_j) = \alpha_g - \alpha_h. \quad (5.22)$$

Tilsvarende afhænger forskellen i middelværdi mellem to forskellige søjler l og m ikke af, i hvilken række man måler forskellen, da

$$EX_{ilk} - EX_{imk} = (\alpha_i + \beta_l) - (\alpha_i + \beta_m) = \beta_l - \beta_m. \quad (5.23)$$

Ved hjælp af skønnene over middelværdierne, $EX_{ijk} \leftarrow \bar{x}_{ij}$, kan man modelkontrol for den additive model, ved hjælp af de såkaldte *interaktionsplot*, der i **R** laves ved hjælp af `interaction.plot`.

I et interaktionsplot afsættes gennemsnittene mod niveauerne for den ene faktor, og alle gennemsnit, der ligger på det samme niveau af den anden faktor, forbindes med en kurve. Betragter vi for eksempel rækkerne, vil vi for hver række i afsætte punkterne $(j, \bar{x}_{ij})$ for $j = 1, \dots, s$. På grund af (5.22) fremkommer der da r kurver, som – bortset fra tilfældige udsving – har konstant lodret afstand. Figur 5.8 på side 110 er et eksempel på en sådan tegning baseret på data i Tabel 5.4, som danner grundlaget for næste eksempel.

Hvis man tilsvarende, for hver fast søjle j , afsætter og forbinder punkterne $(i, \bar{x}_{ij})$ for $i = 1, \dots, r$, skal man ifølge (5.23) få s kurver, som – igen bortset fra tilfældige udsving – har konstant lodret afstand. Figur 5.7 på side 110 viser denne tegning, der ligeledes er baseret på data i Tabel 5.4.

Når man betragter et interaktionsplot, kigger man især efter, om afstanden mellem kurverne vokser, når gennemsnittene $\bar{x}_{ij}$ er store. Det kan være et tegn på en multiplikativ struktur i middelværdierne, hvilket ville betyde, at man skal tage logaritmen til observationerne for at opnå den additive struktur, som model M_2 forudsætter. Når antallet af gentagelser n_{ij} er 1, kan reduktionen til M_2 ikke testes med et F -test, og i så fald er disse tegninger den eneste mulighed for at kontrollere modellen.

Eksempel 3.2 (fortsat).

Selv for tabeller med kun to rækker og søjler er disse tegninger meget informative, som det er illustreret i Figur 5.6, der med fordel kan sammenlignes med Figur 5.4.


I dette tilfælde kan man næsten ikke skelne afvigelse fra parallelitet af de to linjer, der forbinder gennemsnit i grupper med samme niveau af lys (venstre tegning) eller grupper med samme niveau af stress (højre tegning). Når der som her er flere observationer i hver observationsrække skal vurderingen af om en afvigelse fra parallelitet strider mod M_2 vurderes på baggrund af variationen inden for observationsrækker. Med den variation, der her er inden for observationsrækker, ville man kunne acceptere betydeligt større afvigelse fra parallelitet uden at det alvorligt stred mod M_2 . $\square$

5.3.1.2 Krav til antal gentagelser n_{ij}

Når man anvender en statistisk programpakke til tosidet variansanalyse, er der ingen beregningstekniske krav om, at hver kombination af i og j (n_{ij}) skal have et bestemt antal gentagelser. Reduktioner af modellerne testes med F -tests som beskrevet i (5.13), og programmet leverer estimerne $\hat{\alpha}_i - \hat{\alpha}_r$ og $\hat{\beta}_j - \hat{\beta}_s$.

Der er dog fortolkningsmæssige fordele ved at sikre, at antallene opfylder

$$n_{ij} = \frac{n_{i.} n_{.j}}{n_{..}}, \quad (5.24)$$



(a) Interaktionsplot for *lys*. Gruppegennemsnit er markeret med •.

(b) Interaktionsplot for *stress*. Gruppegennemsnit er markeret med •.

Figur 5.6: Samlet bladareal tegnet op mod behandling.

hvor $n_{i.}$, $n_{.j}$ og $n_{..}$ betegner henholdsvis antal observationer i den i te række, antal observationer i den j te søjle og det totale antal observationer (jf. side 17). Særligt er (5.24) opfyldt, hvis n_{ij} er ens for alle kombinationer af i og j . I så fald skriver vi blot n i stedet for n_{ij} .

En af fordelene er, at tælleren i F -testet for reduktionen fra M_2 til M_3^s er den samme som i F -testet for reduktionen fra M_3^r til M_∞ . Begge reduktioner siger, at der ikke er forskel på niveauerne af R . Men ved reduktionen fra M_3^r til M_∞ har man forinden accepteret, at der ikke er forskel på niveauerne af S . At tællerne i de to F -tests er identiske indebærer, at udfaldet af testet for, om niveauerne af R har betydning, *sjældent* afhænger af, om man forinden har testet, om niveauerne af S har betydning.

Det irriterende forbehold “*sjældent*” er nødvendigt, fordi nævnerne i de to F -tests er henholdsvis s_{02}^2 og s_{03r}^2 , som dels vil være forskellige, dels har forskellige frihedsgrader. Derfor skal de to F -tests vurderes i forskellige F -fordelinger.

Tilsvarende gælder for testene, der reducerer M_2 til M_3^r og M_3^s til M_∞ .

Når (5.24) er opfyldt, undgår man som nævnt oftest den situation, at man f.eks. må konkludere, at S ingen virkning har, når man befinder sig i M_2 , mens S pludselig har en effekt, når man i stedet bruger modellen M_3^s .

En anden beslægtet fordel, når (5.24) er opfyldt, er at skønnet over forskellen mellem virkningerne på to niveauer af behandlingen R er det samme i modellen M_2 som i M_3^r . Med andre ord afhænger skønnet ikke af, om S har en betydning. Dette kan sammenlignes med Eksempel 4.2 side 74, hvor vi fandt to numerisk forskellige estimater for hældningen β , afhængigt af, om vi var i modellen M_2

eller M_3^* .

5.3.1.3 Estimation i M_2 af $\alpha_g - \alpha_h$ og $\beta_l - \beta_m$

Resultaterne i dette afsnit forudsætter at (5.24) er opfyldt. I M_2 er $\bar{X}_{i..} \sim N(\alpha_i + \bar{\beta}, \sigma^2/n_{i.})$, hvor

$$\bar{\beta} = \frac{1}{n_{..}} \sum_{j=1}^s n_{.j} \beta_j,$$

så skønnet over forskellen i virkning mellem niveau g og h af R er

$$\alpha_g - \alpha_h \leftarrow \bar{X}_{g..} - \bar{X}_{h..} \sim N(\alpha_g - \alpha_h, \sigma^2(1/n_{g.} + 1/n_{h.})). \quad (5.25)$$

Vi understreger, at hvis (5.24) *ikke* var opfyldt, ville fordelingen af $\bar{X}_{g..} - \bar{X}_{h..}$ afhænge af β_j -leddene. I så fald ville $\bar{X}_{g..} - \bar{X}_{h..}$ ikke kunne anvendes som skøn over $\alpha_g - \alpha_h$.

Tilsvarende er skønnet over forskellen i virkning mellem niveauerne l og m af S

$$\beta_l - \beta_m \leftarrow \bar{X}_{.l.} - \bar{X}_{.m.} \sim N(\beta_l - \beta_m, \sigma^2(1/n_{.l} + 1/n_{.m})), \quad (5.26)$$

når (5.24) er opfyldt.

Modellen M_3^r er som nævnt blot er modellen for r observationsrækker, er her er det velkendt, at forskellen i virkning mellem niveauerne g og h af R er givet ved (5.25).

Tilsvarende er forskellen i virkning mellem niveauerne l og m i modellen M_3^s givet ved (5.26).

Eksempel 3.2 (fortsat).

Betingelsen (5.24) er opfyldt i dette eksempel, idet $n = n_{ij} = 13$. I (5.20) og (5.21) angav vi estimerne for $\hat{\alpha}_1 - \hat{\alpha}_2$ og $\hat{\beta}_1 - \hat{\beta}_2$ som

$$\hat{\alpha}_1 - \hat{\alpha}_2 = \bar{x}_{1..} - \bar{x}_{2..} = -57.35 \text{ cm}^2 \quad \text{og} \quad \hat{\beta}_1 - \hat{\beta}_2 = \bar{x}_{.1.} - \bar{x}_{.2.} = 33.81 \text{ cm}^2.$$

Vi bemærker, at de tilsvarende fordelinger $N(\alpha_1 - \alpha_2, \sigma^2/13)$ og $N(\beta_1 - \beta_2, \sigma^2/13)$ stemmer overens med (5.25) og (5.26). Betragter man R-udskrift 5.12 fra M_2 , genfinder man estimerne under `Estimate`. Under `Std. Error` finder man skønnet over spredningen på estimerne:

$$\sqrt{s_{02}^2 \left(\frac{1}{26} + \frac{1}{26} \right)} = 8.216,$$

i overensstemmelse med (5.25) og (5.26).

I R-udskrift 5.13 findes samme estimat for $\hat{\alpha}_1 - \hat{\alpha}_2$ i modellen M_3^r , men `Std. Error` er nu

$$\sqrt{s_{03r}^2 \left(\frac{1}{26} + \frac{1}{26} \right)} = 11.486,$$

□

hvilket er væsentligt større end i den "rigtige" model M_2 . Så selv om estimatet for $\alpha_1 - \alpha_2$ ikke ændrer sig, skal man anvende skønnet over spredningen fra den rette model.

Eksempel 5.7.

Data i Tabel 5.4 stammer fra seks borer i et givent område. For hver boring er der taget en borekerne af jord, og man har målt pH-værdien af jorden i toppen, i midten og i bunden af borekernen. Da de seks borer er foretaget i et større område, er det ikke rimeligt at anse de seks borer for gentagne målinger af den samme størrelse. Det er heller ikke rimeligt at betragte de tre målinger fra hver borekernes top, midte og bund som gentagne målinger af samme størrelse, fordi man netop forventer en systematisk ændring af surhedsgraden ned gennem kernen.

Indledningsvis arbejdes der derfor med en model, hvor alle observationer er uafhængige, og hver observation har sin egen middelværdi. Vi forudsætter, at alle målingerne er normalfordelte med samme varians,

$$M_1 : X_{ij} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, \dots, 6, \quad j = 1, 2, 3,$$

men i modsætning til tidligere kan denne antagelse ikke kontrolleres, da $n_{ij} = 1$. En konsekvens af, at $n_{ij} = 1$, er at $L_1 = \mathbb{R}^n$, hvorefter $P_1(\mathbf{x}) = \mathbf{x}$ og $d_1 = n$. Herved er variansskønnet $s_{01}^2 = \|\mathbf{x} - P_1(\mathbf{x})\|^2 / (n - n) = 0/0$ udefineret.

Additivitetsmodellen

$$M_2 : X_{ij} \sim N(\alpha_i + \beta_j, \sigma^2), \quad i = 1, \dots, 6, \quad j = 1, 2, 3,$$

giver en forholdsvis simpel beskrivelse af data, og den er bekvem for videre analyse. Men reduktionen fra M_1 til M_2 kan ikke testes med et F -test på sædvanlig måde, fordi man ikke kan estimere variansen i M_1 , så nævneren i F -testet er udefineret.


kerne	bund	midte	top	<i>gennemsnit</i>
1	7.2	7.6	7.5	7.43
2	6.7	7.1	7.2	7.00
3	7.0	7.2	7.3	7.17
4	7.0	7.4	7.5	7.30
5	7.0	7.7	7.7	7.47
6	6.9	7.7	7.6	7.40
<i>gennemsnit</i>	6.97	7.45	7.47	7.29

Tabel 5.4: pH målt i bunden, midten og i toppen af 6 borekerner jord.


Tegningerne i Figur 5.7 og Figur 5.8 viser ikke systematiske afvigelser fra det parallelle forløb, som de skal udvise under additivitetsmodellen, så M_2 accepteres.

Vi tester først reduktionen til M_3^r . Udskrifterne fra estimation i modellerne M_2 og M_3^r findes side på R-udskrift 5.15. Teststørrelsen er

$$\mathcal{F} = \frac{\frac{0.96778}{2}}{\frac{0.15222}{10}} = 31.79,$$



Figur 5.7: Grafisk kontrol af additivitetsmodellen M_2 . Under M_2 er de tre kurver parallelforskudt i forhold til hinanden bortset fra tilfældige udsving.



Figur 5.8: Grafisk kontrol af additivitetsmodellen M_2 . Under M_2 er de seks kurver parallelforskudt i forhold til hinanden bortset fra tilfældige udsving.

hvilket giver testsandsynligheden

$$p_{obs}(\mathbf{x}) = 1 - F_{F(2,10)}(31.79) = 0.000046.$$

Reduktionen til M_3^r kan altså ikke accepteres, og vi har fået bekræftet, at der er forskel på pH værdien de tre steder i borekernen.

Testet for reduktionen til M_3^s findes side på R-udskrift [5.16](#)

$$\mathcal{F} = \frac{\frac{0.48944}{5}}{\frac{0.15222}{10}} = 6.43,$$

og testsandsynligheden bliver

$$p_{obs}(\mathbf{x}) = 1 - F_{F(5,10)}(6.43) = 0.0063.$$

Reduktionen til M_3^s bliver derfor heller ikke accepteret, og det bekræfter, at pH værdien varierer mellem de seks borekerner.

Slutmodellen for data er M_2 , som siger, at pH værdien afhænger både af boringen, og af hvor i borekernen pH værdien måles. Men pH værdien afhænger ifølge M_2 *additivt* af boringen og af positionen i borekernen, det vil sige, at forskellen mellem pH i *top* og *midten* og mellem *top* og *bund* af borekernen er den samme for alle boringer, og at forskellen mellem boringer er den samme både i *toppen*, i *midten* og i *bunden* af borekernen. Denne konklusion bekræftes af kontroltegningerne i Figur [5.7](#) og Figur [5.8](#).

Estimer for forskelle i pH mellem boringer og mellem position i borekernen findes i R-udskrift [5.17](#).

De kan også let findes ved hjælp af [\(5.25\)](#) og [\(5.26\)](#), idet række- og søjlegennemsnit er givet i marginalerne i Tabel [5.4](#). $\square$

Appendiks til Afsnit 5.3

Beregninger i R

Før vi kommer til modellerne indenfor tosidet variansanalyse, vil vi først vise hvordan *parametertabellen* ser ud, når vi laver ensidet variansanalyse.

Eksempel 3.2 (fortsat).

Vi minder om, at datasættet `soya` indeholder variablene `stress`, `light` og `group`, som det fremgår af R-udskrift 5.3. I R-kode 5.13 fitter vi modellen for fire observationsrækker – præcis som i R-kode 5.7. For at forstå parametriseringen kan det dog være hjælpsomt at inkludere interceptleddet `1` eksplicit.

R-kode 5.13

```
lmfit_m1 <- lm(area ~ 1 + group, data=soya)
```

Modelformlen i R-kode 5.13 kan læses på følgende måde, hvor leddet ζ_i svarer til `group`:

$$\alpha \cdot 1 + \zeta_i \quad i = 1, 2, 3, 4. \quad (5.27)$$

Opskrivningen i (5.27) er *overparametriseret* i den forstand, at den beskriver middelværdistrukturen i M_1 fra (5.16) ved hjælp af fem parametre, $\zeta_1, \zeta_2, \zeta_3, \zeta_4$ og α , selvom der kun er fire parametre i modellen. Overparametriseringen kan forstås sådan, at **R** angiver parametrene *relativt til en referencegruppe*. I dette tilfælde er referencegruppen gruppe 1, dvs. **A**, og derfor kan parametrene fra (5.27) udtrykkes ved hjælp af μ_i $i = 1, 2, 3, 4$ fra (5.16) som

$$\alpha = \mu_1 \quad \zeta_1 = \mu_1 - \mu_1 = 0 \quad \zeta_2 = \mu_2 - \mu_1 \quad \zeta_3 = \mu_3 - \mu_1 \quad \zeta_4 = \mu_4 - \mu_1 \quad (5.28)$$

De tilsvarende estimater fremgår af parametertabellen, som fås ved at køre `summary(lmfit_m1)`:

R-udskrift 5.7

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  245.308      8.299   29.559 < 2e-16 ***
groupB       -32.385     11.736   -2.759  0.00817 **
groupC        58.769     11.736    5.007 7.86e-06 ***
groupD        23.538     11.736    2.006  0.05056 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.92 on 48 degrees of freedom
Multiple R-squared:  0.5729,    Adjusted R-squared:  0.5462
F-statistic: 21.46 on 3 and 48 DF,  p-value: 5.867e-09
```

I R-udskrift 5.7 genkender vi estimatet for μ_1 på 245.308 under (Intercept) , jf. (5.28). Parameteren ζ_1 er nul, så dens estimat angives ikke. De tre resterende estimater, der fremgår, er

$$\begin{aligned}\hat{\zeta}_2 &= -32.385 = 212.923 - 245.308, & \hat{\zeta}_3 &= 58.769 = 304.077 - 245.308, \\ \hat{\zeta}_4 &= 23.538 = 268.846 - 245.308.\end{aligned}\quad \square$$

Årsagen til, at man benytter denne – ved første øjekast ret besværlige – overparametrisering er, at vi som hovedregel er mere interesserede i *forskellen* mellem de grupper, der findes i vores datasæt. Som det fremgår, viser netop denne parametrisering de pågældende forskelle (og de tilhørende p -værdier for hypotesen om, at de er lig 0). Desuden vil konfidensintervaller typisk være af interesse, og disse kan frembringes ved at køre `confint(lmfit_m1)`.

Ud fra vores viden om at `group` har niveauerne A, B, C og D ser vi af R-udskrift 5.7, at **R** benytter A som referencegruppe. Skulle man komme i tvivl, kan man køre `levels` kommandoen. Køres `levels(soya$group)` fås "A" "B" "C" "D". Har man brug for en anden referencegruppe, kan `relevel` benyttes. For eksempel vil `relevel(soya$group, "B")` returnere en faktor, hvor B fungerer som referencegruppe.

Som det er antydnet i (5.27) skyldes **R**s valg af parametrisering, at modelformlen i R-kode 5.13 indeholdt interceptleddet 1. Hvis dette udelades, benyttes μ_i $i = 1, \dots, 4$ som parametre.

R-kode 5.14

```
lmfit_m1 <- lm(area ~ 0 + group, data=soya)
```

Køres `summary(lmfit_m1)` fås parametertabellen:

R-udskrift 5.8

```
Coefficients:
      Estimate Std. Error t value Pr(>|t|)
groupA  245.308      8.299   29.56  <2e-16 ***
groupB  212.923      8.299   25.66  <2e-16 ***
groupC  304.077      8.299   36.64  <2e-16 ***
groupD  268.846      8.299   32.40  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.92 on 48 degrees of freedom
Multiple R-squared:  0.9879,    Adjusted R-squared:  0.9869
F-statistic:  981 on 4 and 48 DF,  p-value: < 2.2e-16
```

I R-udskrift 5.8 genfinder vi umiddelbart estimaterne fra (5.17), men de tilhørende p -værdier er af mindre interesse. Bemærk desuden, at R-kode 5.13 og R-kode 5.14 specificerer den samme model – blot parametriseret på to forskellige måder.

Vi viser nu, hvordan man specificerer de relevante modeller i en tosidet variansanalyse i de to eksempler som dannede baggrund for behandlingen i Afsnit 5.3. Som vi tidligere har nævnt vil **R** automatisk inkludere et intercept-led 1, så dette udelades i modelformlerne i resten af dette afsnit.

Det første vi ønsker er at undersøge hypotesen om ingen vekselvirkning, altså om vi kan reducere fra M_1 fra (5.18) til M_2 fra (5.19)

For at undersøge dette køres koden i R-kode 5.15.

R-kode 5.15

```
lmfit_m1 <- lm(area ~ light+stress+light:stress, data=soya)
lmfit_m2 <- lm(area ~ light+stress, data=soya)
anova(lmfit_m2, lmfit_m1)
```

I modelformlen for M_1 ovenfor optræder ledet `light:stress`. Dette led er et *vekselvirkningsled/interaktionsled* (engl: *interaction term*) og angiver en faktor der er identisk med `group` i den forstand at den giver anledning til samme inddeling af data. I modelformlen der svarer til M_2 er dette led fjernet, og syntaksen af modelformlen svarer opskrivningen af additivitetsmodellen (5.19).

R-udskrift 5.9

```
Analysis of Variance Table

Model 1: area ~ light + stress
Model 2: area ~ light + stress + light:stress
  Res.Df  RSS Df Sum of Sq    F Pr(>F)
1      49 43003
2      48 42976   1    26.327 0.0294 0.8646
```

Vi genkender `F` p -værdien, som leder os frem til at acceptere M_2 .

Den videre reduktion til enten M_3^r eller M_3^s er nu forholdsvis simpel, da modellerne begge er de kendte modeller for 2 observationsrækker. På R-kode 5.16 fittes modellerne og **anova** kaldes. De tilhørende variansanalysetabeller findes på R-udskrifterne 5.10 og 5.11

R-kode 5.16

```
lmfit_m3s <- lm(area ~ stress, data=soya)
lmfit_m3r <- lm(area ~ light, data=soya)
anova(lmfit_m3s, lmfit_m2)
anova(lmfit_m3r, lmfit_m2)
```

R-udskrift 5.10

```

Analysis of Variance Table

Model 1: area ~ stress
Model 2: area ~ light + stress
  Res.Df  RSS Df Sum of Sq    F    Pr(>F)
1     50 85754
2     49 43003   1     42752 48.714 7.136e-09 ***

```

R-udskrift 5.11

```

Analysis of Variance Table

Model 1: area ~ light
Model 2: area ~ light + stress
  Res.Df  RSS Df Sum of Sq    F    Pr(>F)
1     50 57861
2     49 43003   1     14858 16.931 0.0001479 ***

```

For at få estimater ud den fittede additive model køres `summary(lmfit_m2)`. Outputtet findes i R-udskrift 5.12.

R-udskrift 5.12

```

Call:
lm(formula = area ~ light + stress, data = soya)

Residuals:
    Min       1Q   Median       3Q      Max
-68.558 -19.029  -0.385   18.846   59.788

Coefficients:
            Estimate Std. Error t value Pr(>t)
(Intercept)  269.558      7.116   37.883  < 2e-16 ***
lightlow     -57.346      8.216   -6.980 7.14e-09 ***
stresslow     33.808      8.216    4.115 0.000148 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.62 on 49 degrees of freedom
Multiple R-squared:  0.5726,    Adjusted R-squared:  0.5551
F-statistic: 32.82 on 2 and 49 DF,  p-value: 9.029e-10

```

(Intercept) linjen indeholder estimeret middelværdi og tilhørende størrelser for observationsrækken i cellen i det nederste højre hjørne i tabellen, som fik behandlingen med stress og lys på deres høje niveau. I notation, der bruges i (5.19) er estimatet $\hat{\alpha}_2 + \hat{\beta}_2$. Estimatet for $\hat{\alpha}_1 - \hat{\alpha}_2$ og

dets spredning med videre findes i linjen `lightlow` i `Estimate` søjlen, og tilsvarende findes estimatet $\hat{\beta}_1 - \hat{\beta}_2$ i linjen `stresslow`.

Vi kan forstå relationen mellem modelformlen og parametriseringen ved huske at $\alpha_1 - \alpha_2$ er virkningen af lys, $\beta_1 - \beta_2$ er virkningen af stress og skrive

$$\alpha_i + \beta_j = (\alpha_2 + \beta_2) + (\alpha_i - \alpha_2) + (\beta_j - \beta_2) = 1 + \text{light} + \text{stress}$$

for $i = 1, 2$ og $j = 1, 2$.

Køres `summary(lmfit_m3r)` fås R-udskrift 5.13

R-udskrift 5.13

```
Call:
lm(formula = area ~ light, data = soya)

Residuals:
    Min       1Q   Median       3Q      Max
-85.462 -18.712  -0.788   25.625   58.885

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   286.462      6.671   42.938 < 2e-16 ***
lightlow     -57.346      9.435   -6.078 1.66e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 34.02 on 50 degrees of freedom
Multiple R-squared:  0.4249,    Adjusted R-squared:  0.4134
F-statistic: 36.94 on 1 and 50 DF,  p-value: 1.655e-07
```

Selvom M_2 ender med at være slutmodel, er det instruktivt at se på parametertabellen for M_1 for at beskrive den parametrisering som modelformlen giver anledning til.

R-udskrift 5.14

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   268.846      8.299   32.395 < 2e-16 ***
lightlow     -55.923     11.736   -4.765 1.79e-05 ***
stresslow      35.231     11.736    3.002 0.00425 **
lightlow:stresslow -2.846     16.598   -0.171 0.86457
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.92 on 48 degrees of freedom
Multiple R-squared:  0.5729,    Adjusted R-squared:  0.5462
F-statistic: 21.46 on 3 and 48 DF,  p-value: 5.867e-09
```

For at forstå parametriseringen benytter vi indekseringen fra (5.18). Med denne indeksering kan estimerterne fra (5.17) skrives som

$$\begin{aligned}\mu_{11} &\leftarrow \hat{\mu}_{11} = \bar{x}_{11.} = 245.308, & \mu_{12} &\leftarrow \hat{\mu}_{12} = \bar{x}_{12.} = 212.923, \\ \mu_{21} &\leftarrow \hat{\mu}_{21} = \bar{x}_{21.} = 304.077, & \mu_{22} &\leftarrow \hat{\mu}_{22} = \bar{x}_{22.} = 268.846.\end{aligned}$$

Parametriseringen forstås da ved at skrive

$$\mu_{ij} = \mu_{22} + (\mu_{i2} - \mu_{22}) + (\mu_{2j} - \mu_{22}) + (\mu_{ij} - \mu_{i2} - \mu_{2j} + \mu_{22})$$

$$1 + \text{light} + \text{stress} + \text{light:stress}$$

for $i = 1, 2$ og $j = 1, 2$ og sammenholde dette med at

$$\begin{aligned}\hat{\mu}_{22} &= 268.846 \\ \hat{\mu}_{12} &= 268.846 - 55.923 \\ \hat{\mu}_{21} &= 268.846 + 35.231 \\ \hat{\mu}_{11} &= 268.846 - 55.923 + 35.231 - 2.846,\end{aligned}$$

hvor tallene på højre side af lighedstegnene er aflæst fra R-udskrift 5.14.

Eksempel 5.7 (fortsat).

Formuleringen af modellerne adskiller sig ikke fra formuleringen i Eksempel 3.2, men programmet gengives alligevel for fuldstændighedens skyld. Datasættet `boring` indeholder de tre variable `pH`, `kerne` og `position`, hvis værdier er angivet i Tabel 5.4. Både `kerne` og `position` er faktorvariable.

R-udskrift 5.15

```
Analysis of Variance Table

Model 1: pH ~ kerne
Model 2: pH ~ kerne + position
  Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1      12 1.12000
2      10 0.15222  2    0.96778 31.788 4.638e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

R-udskrift 5.16

```
Analysis of Variance Table

Model 1: pH ~ position
Model 2: pH ~ kerne + position
  Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1      15 0.64167
2      10 0.15222  5    0.48944 6.4307 0.006338 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Som det fremgår ender slutmodellen med at være den additive model M_2 . Estimer for virkningerne findes nu ved at køre **summary**:

R-udskrift 5.17

```
Call:
lm(formula = pH ~ kerne + position, data = boring)

Residuals:
    Min       1Q   Median       3Q      Max
-0.17222 -0.05556  0.02778  0.05278  0.16111

Coefficients:
            Estimate Std. Error t value Pr(>t)
(Intercept)   7.10556    0.08225  86.387 1.06e-15 ***
kerne2        -0.43333    0.10074  -4.302  0.00156 **
kerne3        -0.26667    0.10074  -2.647  0.02443 *
kerne4        -0.13333    0.10074  -1.324  0.21511
```

```
kerne5      0.03333    0.10074    0.331    0.74756
kerne6     -0.03333    0.10074   -0.331    0.74756
positionmidte 0.48333    0.07123    6.785 4.83e-05 ***
positiontop   0.50000    0.07123    7.019 3.63e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1234 on 10 degrees of freedom
Multiple R-squared:  0.9054,    Adjusted R-squared:  0.8392
F-statistic: 13.68 on 7 and 10 DF,  p-value: 0.000217
```

5.4 Sammenligning af flere regressionslinjer

Vi vil nu omtale en situation, hvor datasættet kan opfattes som inddelt i grupper, og hvor man kan foretage lineær regression inden for disse grupper, således at flere regressionslinjer er i betragtning. Modellen omtales til tider som *gruppespecifik regression*.

Udgangspunktet for sammenligning af flere regressionslinjer er modellen, hvor X_{ij} for $i = 1, \dots, m$ og $j = 1, \dots, n_i$ er uafhængige stokastiske variable, og hvor

$$M_0 : X_{ij} \sim N(\alpha_i + \beta_i t_{ij}, \sigma_i^2).$$


Her betegner (t_{ij}, x_{ij}) parvise observationer af responsvariablen X_{ij} og den forklarende variabel t_{ij} . Modellen M_0 fås ved at betragte de m lineære regressioner hver for sig.

De modeller, vi vil interessere os for i det følgende er

$$\begin{aligned} M_1 : X_{ij} &\sim N(\alpha_i + \beta_i t_{ij}, \sigma^2), & \text{samme varians for alle } m \text{ regressionslinjer.} \\ M_2 : X_{ij} &\sim N(\alpha + \beta_i t_{ij}, \sigma^2), & \text{samme afskæring.} \\ M_2^* : X_{ij} &\sim N(\alpha_i + \beta t_{ij}, \sigma^2), & \text{samme hældning.} \\ M_3 : X_{ij} &\sim N(\alpha + \beta t_{ij}, \sigma^2), & \text{sammenfaldende regressionslinjer.} \end{aligned}$$

Man bemærker, at først når man har reduceret til M_1 , har man en lineær normal model. Reduktionen til M_1 sker enten med Bartlett's test baseret på variansskønnene i hver af de m regressionslinjer hvis $m > 2$, eller ved at sammenligne de to variansskøn med et F -test, som beskrevet side 35, hvis $m = 2$.

Sammenhængen mellem de fire modeller kan angives i et diagram, hvor en pil går fra en model til en simple model:



Figur 5.9: Undermodeller og hypoteser i lineær regression.

Skemaet understreger, at modellerne M_2 og M_2^* er sideordnede, det vil sige, at ingen af dem er indeholdt i den anden. Man kan vælge først at teste, om afskæringerne af andenaksen er ens, eller først at teste, om hældningerne er ens. Hvad der er rimeligt, afhænger af den faglige sammenhæng.

Eksempel 5.8.

For 13 mandlige journalister og 15 mandlige universitetslærere har man registreret deres systoliske blodtryk og deres alder. For begge professioner har vi beskrevet data som lineære regressioner med

Journalister		Universitetslærere	
Alder	Blodtryk	Alder	Blodtryk
68	188.7	55	162.9
62	184.2	49	155.9
49	151.3	60	170.5
62	182.4	54	154.5
34	138.3	58	158.0
66	181.8	51	155.4
45	155.1	43	143.3
60	178.3	52	157.3
57	179.4	53	160.2
57	171.5	61	164.3
63	177.9	61	167.5
56	172.5	57	171.5
57	169.3	57	166.0
		70	190.3
		63	175.5

Tabel 5.5: Systolisk blodtryk og alder for 13 journalister og 15 universitetslærere.

systolisk blodtryk som responsvariabel (X) og alder som forklarende variabel (t). Data er vist i Tabel 5.5 og på Figur 5.10 vises et scatterplot af data sammen med de estimerede regressionslinjer i modellen M_1 (og M_0). Sammen med et residualplot som ikke er vist, bekræftes rimeligheden af M_0 .

Gruppe	α	β	σ^2
<i>journalist</i>	84.99521966	1.52956813	18.14950
<i>universitetslærer</i>	75.62986190	1.56238397	19.44954

Tabel 5.6: Estimerterne for parametrene i modellen M_0 , gengivet fra R-udskrifterne 5.20 og 5.21.

Reduktionen fra M_0 til M_1 er et spørgsmål om at acceptere hypotesen $H_{01} : \sigma_1^2 = \sigma_2^2$. Testet for H_{01} er baseret på sammenligning af estimerterne for varianserne, jævnfør side 35.


F -teststørrelsen for H_{01} er

$$\mathcal{F} = \frac{18.14950}{19.44954} = 0.933,$$

som skal vurderes i en F -fordeling med 11 frihedsgrader i tælleren og 13 i nævneren. p -værdien findes til 0.92 så vi accepterer H_{01} , og M_1 er nu modellen for data.

Estimerterne for regressionslinjernes hældning og afskæring af andenaksen er de samme i M_1 som i M_0 . Estimatet for σ^2 i M_1 kan beregnes som det vægtede gennemsnit, med frihedsgraderne som vægte, af estimerterne for σ^2 i de to grupper under M_0 :

$$s_{01}^2 = \frac{11 \cdot 18.14950 + 13 \cdot 19.44954}{11 + 13} = 18.85369.$$



Figur 5.10: Separate tegninger for de to professioner.

Estimaterne angives i Tabel 5.7.

Gruppe	α	β	σ^2
<i>journalist</i>	84.99521966	1.52956813	18.85369
<i>universitetslærer</i>	75.62986190	1.56238397	

Tabel 5.7: Estimaterne for parametrene i modellen M_1 .

Selv om vi hermed har alle estimaterne for de ukendte parametre i M_1 , har vi alligevel estimeret i M_1 ved hjælp af **R**. Estimaterne for regressionskoefficienterne angives nemlig på en speciel måde i **R** (og mange andre programpakker), og desuden skal vi bruge udskriften for at se, om modellen kan reduceres yderligere.

Udskrifterne fra M_1 findes i R-udskrift 5.22 og R-udskrift 5.23.

I R-udskrift 5.23 kan estimaterne for α_1, α_2 og β_1, β_2 fra Tabel 5.7 umiddelbart genfindes. Vi betragter nu R-udskrift 5.22. Her ses, at spredningen er 4.342, og dermed genfindes variansskønnet under

M_1 på 18.853, som allerede er angivet i Tabel 5.7. Det kan være en smule sværere at identificere estimaterne for afskæringerne på andenaksen og hældningerne, men de findes nederst i udskriften under `Coefficients:`. Man genkender dog kun estimaterne for α_1 (84.99521966) og β_1 (1.52956813).

I linjen `stillingUnderviser:alder` ses estimatet for $\beta_2 - \beta_1$, som er 0.03282, og i linjen `stillingUnderviser` findes estimatet for $\alpha_2 - \alpha_1$, nemlig -9.365366. Vi finder dermed estimaterne for α_2 og β_2 som:

$$\alpha_2 = \alpha_1 + (\alpha_2 - \alpha_1) = 84.99521966 - 9.365366 = 75.62985366,$$

og

$$\beta_2 = \beta_1 + (\beta_2 - \beta_1) = 1.52956813 + 0.03282 = 1.56238813.$$

Det kan umiddelbart virke besværligt, men er i praksis ganske smart. De t -tests, der er angivet sammen med disse differenseestimater, tester nemlig, om hver af de pågældende forskelle er nul.

I linjen, hvor estimatet for $\alpha_1 - \alpha_2$ angives, finder man t -testet for $H_{02} : \alpha_1 = \alpha_2$, dvs. for reduktionen fra M_1 til M_2 . Vi skal senere se, at dette test er ækvivalent med F -testet for reduktionen, idet $t^2 = F$, og at testsandsynlighederne derfor er identiske.

Tilsvarende finder man t -testet for $H_{02}^* : \beta_1 = \beta_2$, dvs. for reduktionen fra M_1 til M_2^* i linjen, hvor estimatet for $\beta_1 - \beta_2$ er angivet.

Testsandsynlighederne er henholdsvis 0.4697 og 0.8849. Man kan således enten acceptere H_{02} og dermed ende med modellen M_2 , eller acceptere H_{02}^* og dermed ende med modellen M_2^* .

For dette datasæt bør valget mellem de to modeller baseres på faglige snarere end statistiske overvejelser. Vi går i første omgang ikke ind i disse overvejelser, men antager at vi foretrækker M_2 .


Estimater af parametrene i M_2 er samlet i Tabel 5.8. Estimatet for α , den fælles afskæring, og β_1 findes direkte i R-udskrift 5.24, mens estimatet for β_2 beregnes som en sum af estimatet for β_1 og estimatet for $\beta_2 - \beta_1$, -0.13048919, findes i linjen `alder:stillingUnderviser`

Gruppe	α	β	σ^2
<i>journalist</i>	81.54148011	1.58909585	18.50645
<i>universitetslærer</i>		1.45860666	

Tabel 5.8: Estimaterne for parametrene i modellen M_2 .

Vi skal nu på sædvanlig måde beregne F -testet i formel (5.13) ved at bruge R-udskrift 5.25 for reduktionen fra M_1 til M_2 , for at illustrere, at det, som påstået, er ækvivalent med det t -test, som blev angivet i R-udskrift 5.22:

$$\mathcal{F} = \frac{10.17283}{\frac{452.48851}{24}} = \frac{10.17283}{18.85369} = 0.5396. \quad (5.29)$$



Figur 5.11: Estimerede regressionslinjer i modellen M_2 : samme afskæring. Sammenlign med estimerede regressionslinjer i modellen M_1 , som er vist i Figur 5.10 side 122.

Testsandsynligheden er 0.4697, præcis som det også fremgår af linjen `stillingUnderviser` i udskriften fra M_1 . Begrundelsen for de identiske testsandsynligheder er identiteten


$$t^2 = (-0.735)^2 \approx 0.540 = \mathcal{F}$$

De estimerede regressionslinjer i modellen M_2 er indtegnet i Figur 5.11.

Vender man sig til spørgsmålet om, hvorvidt man kan reducere fra M_2 til M_3 - “sammenfaldende regressionslinjer” - fremgår det umiddelbart af t -testet for $H_{03} : \beta_1 = \beta_2$ (angivet i linjen `alder:stillingUnderviser` i udskriften fra M_2), at denne reduktion ikke er mulig. t -testet er -4.551 , og p -værdien er 0.000119.

Trods dette er den estimerede fælles regressionslinje i modellen M_3 alligevel indtegnet i Figur 5.13. Tegningen modsiger da også kraftigt M_3 , idet observationerne for de to professioner næsten udelukkende ligger på hver sin side af den fælles regressionslinje.

Det følgende gengiver forløbet af analysen, hvis man i stedet for M_2 havde valgt at betragte M_2^* først.

Figur 5.12: Regressionslinjer i modellen M_2^* : parallelle regressionslinjer

Gruppe	α	β	σ^2
<i>journalist</i>	84.32064422	1.54148319	18.11570
<i>universitetslærer</i>	76.80587938		

Tabel 5.9: Estimer for parametrene i modellen M_2^* .


Estimaterne af parametrene i modellen M_2^* findes ved hjælp af R-udskrift 5.26 og er samlet i Tabel 5.9. F -testet for reduktionen fra M_1 til M_2^* findes i R-udskrift 5.27

$$\mathcal{F} = \frac{0.403935}{\frac{452.48851}{24}} = \frac{0.403935}{18.853688} = 0.02142, \quad (5.30)$$

Vi bemærker igen, at

$$t^2 = 0.146^2 \approx 0.0214 = \mathcal{F}$$

for endnu engang at understrege, at testet for reduktionen fra M_1 til M_2^* er givet i udskriften fra M_1 . Man finder det i linjen `alder:stillingUnderviser`, idet det er testet for parallelle regressionslinjer, $H_{02}^* : \beta_1 = \beta_2$. p -værdien aflæses til 0.8849 begge steder.



Figur 5.13: Regressionslinjer i modellen M_3 : sammenfaldende regressionslinjer. Det fremgår klart, at modellen er urimelig, idet de to professioner overvejende ligger på hver sin side af regressionslinjen.

Yderligere reduktion er ikke mulig. Man ser nemlig af udskriften fra M_2^* , at t -teststørrelsen for $H_{03}^* : \alpha_1 = \alpha_2$ har en værdi på -4.65814 med en testsandsynlighed under 0.0001. Til senere brug noterer vi alligevel F -testet for reduktionen fra M_2^* til M_3 fines i R-udskrift 5.28 til

$$\mathcal{F} = \frac{393.079753}{\frac{452.89}{25}} = \frac{393.079753}{18.115698} = 21.698. \quad (5.31)$$

□

De estimerede regressionslinjer i modellen M_2^* , som er vist i Figur 5.12, er umulige at skelne fra dem i Figur 5.10, der gengiver de estimerede regressionslinjer i modellerne M_0 og M_1 .

Analysen af dette datasæt viste, at to forskellige modeller (M_2 og M_2^*) beskriver data næsten lige godt. Parameterestimaterne er præsenteret i henholdsvis Tabel 5.8 og Tabel 5.9. Begge modeller er enige om, at universitetslæreres blodtryk er lavere end jævnaldrende journalisters. Det er netop det indtryk, Figur 5.11 og Figur 5.12 efterlader, og vi har nu påvist, at forskellen er signifikant.

Derudover er de to modeller vidt forskellige. Ifølge M_2 stiger forskellen i blodtryk med alderen, mens de to professioner ifølge M_2^* har samme stigning i blodtrykket over tid.

Med det foreliggende datasæt er det umuligt at afgøre, hvilken af de to modeller der er korrekt. Det vil dog være relativt ligetil at planlægge en ny undersøgelse for at belyse spørgsmålet yderligere. Til dette formål bør man sikre, at der indsamles mange data fra både yngre (30–40 år) og ældre (55–65 år) deltagere. For en god ordens skyld skal det nævnes, at de to professioner i eksemplet var opdigtede.

I eksemplet betragtede vi kun sammenligning af to regressionslinjer, men man kan på helt tilsvarende måde sammenligne m regressionslinjer. Der er dog to modifikationer. For det første skal reduktionen fra M_0 til M_1 testes med Bartletts test, og for det andet kan hypoteserne om fælles afskæring og fælles hældning kun testes med F -test, når der er mere end to regressionslinjer.

Appendiks til Afsnit 5.4

Beregninger i R

Vi viser, hvordan man specificerer modellerne til sammenligning af m regressionslinjer i R ved at gengive programmet, som udfører beregningerne i Eksempel 5.8.

Eksempel 5.8 (fortsat).

Det første vi ønsker, er at behandle de to grupper separat og fitte en simpel lineær regression for henholdsvis journalister og undervisere. Data fra Tabel 5.5 er indlæst fra filen `blodtryk.csv` i datasættet `Blodtryk`. En kørsel af `head(Blodtryk)` giver output som vist i R-udskrift 5.18. Som det fremgår, indeholder datasættet tre variable: `stilling`, `alder` og `blodtryk`.

R-udskrift 5.18

	stilling	alder	blodtryk
1	Journalist	68	188.7
2	Underviser	55	162.9
3	Journalist	62	184.2
4	Underviser	49	155.9
5	Journalist	49	151.3
6	Underviser	60	170.5

Det næste vi gør, er at lave separate datasæt for de to stillingskategorier. Der er mange måder at gøre dette på i R og en er at bruge `subset` kommandoen, som det er gjort på R-kode 5.17

R-kode 5.17

```
Journalister <- subset(Blodtryk, subset = stilling == "Journalist")
Undervisere <- subset(Blodtryk, subset = stilling == "Underviser")
```

Efter kørslen af R-kode 5.17 har vi nu to datasæt `Journalister` og `Undervisere` med samme variable som det oprindelige datasæt (`Blodtryk`), men hvor observationerne svarer til henholdsvis journalister og undervisere. Vi kan derefter fitte to lineære regressionsmodeller på samme måde som det blev gjort på side 98.

R-kode 5.18

```
LM_Journalister <- lm(blodtryk ~ 1+alder, data = Journalister)
LM_Undervisere <- lm(blodtryk ~ 1+alder, data = Undervisere)
```

Hvis vi udelukkende er interesserede i estimater for parametrene i modellen kan vi bruge kommandoerne `coef` og `sigma`. Betragter vi for eksempel journalisterne vil `coef(LM_Journalister)` give output fra R-kode 5.19

R-udskrift 5.19

(Intercept)	alder
84.995220	1.529568

Som det fremgår står estimatet for afskæringen α under (Intercept) og estimatet for hældningen β under alder, der jo er navnet på den tilsvarende variabel. Estimatet for standardafvigelsen fås ved at køre `sigma(LM_Journalister)` og giver 4.260223 og ved at kvadrere dette fås estimatet for σ^2 på 18.1495 som fremgår af Tabel 5.5. Et alternativ til at køre `coef` og `sigma` er at køre `summary`. Køres `summary` som på R-kode 5.19 fås output som fra R-udskrift 5.20

R-kode 5.19

```
summary(LM_Journalister)
```

R-udskrift 5.20

```
Call:
lm(formula = blodtryk ~ 1 + alder, data = Journalister)

Residuals:
    Min       1Q   Median       3Q      Max
-8.644 -2.881  1.274  1.849  7.219

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   84.9952     7.5966   11.19 2.38e-07 ***
alder          1.5296     0.1325   11.54 1.74e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.26 on 11 degrees of freedom
Multiple R-squared:  0.9237,    Adjusted R-squared:  0.9168
F-statistic: 133.2 on 1 and 11 DF,  p-value: 1.737e-07
```

Som omtalt i Appendiks til Afsnit 4.1 genfinder vi i R-udskrift 5.20 parameterestimerne i parameter tabellen. Derudover indeholder output fra `summary` (under `Call:`) den kommando som blev brugt til at fitte modellen. Dernæst findes under `Residuals:` et *five number summary* af residualerne. Indholdet af de to sidste linjer forklares senere.

I R-udskrift 5.21 findes output fra `summary` for `LM_Undervisere`. For at få flere betydende cifre med bruges kommandoen `print(summary(LM_Undervisere), digits = 8)`.

R-udskrift 5.21

```
Call:
lm(formula = blodtryk ~ 1 + alder, data = Undervisere)

Residuals:
    Min       1Q   Median       3Q      Max
-8.2481322 -1.6733643  1.1270998  1.6018678  6.8142518

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 75.62986190 10.28843126  7.35096 5.5757e-06 ***
alder        1.56238397  0.18172789  8.59738 1.0078e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.410163 on 13 degrees of freedom
Multiple R-squared:  0.85042852,    Adjusted R-squared:  0.83892302
F-statistic: 73.914963 on 1 and 13 DF,  p-value: 1.007752e-06
```

Som vist i Afsnit 5.4 kan vi ikke afvise hypotesen om varianshomogenitet, og vi fitter derfor M_1 ved hjælp af kommandoen på R-kode 5.20.

R-kode 5.20

```
LM_Blodtryk_M1 <-
  lm(blodtryk~1+stilling+alder+alder:stilling,data=Blodtryk)
```

Da **summary** indeholder information om parametrene er det vigtigt at forstå hvordan **R** parametriserer modellen, hvilket i mindre grad var tilfældet da vi kørte **anova**. Parametriseringen for simpel lineær regression er i Afsnit 5.4, hvor det gennemgås hvordan man kan genfinde estimaterne ud fra outputtet fra **summary**. Vi vil nu gennemgå parametriseringen af M_1 , hvor der er flere regressionslinjer.

For at forstå modelformlen i R-kode 5.20 er det vigtigt at huske at **stilling** er en faktor variabel med niveauerne **Journalist** og **Underviser** samt at **alder** er en kontinuert variabel. Ledet **alder:stilling** kan opfattes som et interaktionsled mellem **alder** og **stilling**.

Idet vi skriver “stl” for “stilling” kan vi da læse modelformlen i R-kode 5.20 på følgende måde:

$$\alpha \cdot 1 + \zeta_{\text{stl}} + \beta \cdot \text{alder} + \eta_{\text{stl}} \cdot \text{alder} \quad \text{stl} \in \{\text{journalist}, \text{underviser}\}. \quad (5.32)$$

Som i Appendiks til Afsnit 5.3 ser vi at opskrivningen i (5.32) er *overparametriseret* i den forstand at den beskriver middelværdien hjælp af 6 parametre: $\alpha, \zeta_{\text{journalist}}, \zeta_{\text{underviser}}, \beta, \eta_{\text{journalist}}, \eta_{\text{underviser}}$, mens vi kun skal bruge 4 parametre (to hældninger og to afskæringer) til at beskrive middelværdien i M_1 . Overparametriseringen kan også her forstås på den måde at **R** angiver parametrene *relativt til*

en referencegruppe. Referencegruppen er i dette tilfælde `journalist`. Benytter vi betegnelserne 1 og 2 for henholdsvis journalister og undervisere bliver parametrene derfor

$$\begin{aligned}\alpha &= \alpha_1, & \zeta_{\text{journalist}} &= \alpha_1 - \alpha_1 = 0, & \zeta_{\text{underviser}} &= \alpha_2 - \alpha_1 & \text{og} \\ \beta &= \beta_1, & \eta_{\text{journalist}} &= \beta_1 - \beta_1 = 0, & \eta_{\text{underviser}} &= \beta_2 - \beta_1.\end{aligned}\quad (5.33)$$

Køres `summary(LM_Blodtryk_M1)` fås parametertabellen for M_1 med den anvendte parametrisering:

R-udskrift 5.22

```
Call:
lm(formula = blodtryk ~ 1 + stilling + alder + alder:stilling,
    data = Blodtryk)

Residuals:
    Min       1Q   Median       3Q      Max
-8.644 -3.019  1.201  1.785  7.219

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)      84.99522     7.74255  10.978 7.71e-11 ***
stillingUnderviser -9.36536    12.74975  -0.735  0.470
alder              1.52957     0.13509  11.322 4.12e-11 ***
stillingUnderviser:alder 0.03282     0.22419   0.146  0.885
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.342 on 24 degrees of freedom
Multiple R-squared:  0.9049,    Adjusted R-squared:  0.893
F-statistic: 76.13 on 3 and 24 DF,  p-value: 2.103e-12
```

Som det er vist på side 123 er det derfor ganske simpelt at finde estimaterne for hældningerne og afskæringerne i modellen, og med betegnelserne fra (5.32) og (5.33) ser vi, at `summary` udskriver estimaterne $\hat{\alpha}$, $\hat{\zeta}_{\text{underviser}}$, $\hat{\beta}$ og $\hat{\eta}_{\text{underviser}}$.

Vi kan også fitte M_1 med kaldet `lm(blodtryk~stilling*alder,data=Blodtryk)` da `stilling*alder` er en forkortelse af `stilling+alder+stilling:alder` og **R** som tidligere nævnt automatisk tilføjer 1 til modelformlen, med mindre andre specificeres. I forlængelse af denne bemærkning, kan vi opskrive modelformlen, hvis vi *ikke* ønsker at overparametrisere. Dette er gjort på R-kode 5.21

R-kode 5.21

```
LM_Blodtryk_M1_nooverparm <-
  lm(blodtryk~0+stilling+alder:stilling,data=Blodtryk)
```

Output fra 5.21 findes på 5.23. Som det fremgår kan parametrene fra Tabel 5.7 umiddelbart aflæses, men til gengæld er de tilhørende p -værdier ikke interessante.

R-udskrift 5.23

```
Call:
lm(formula = blodtryk ~ 0 + stilling + alder:stilling, data = Blodtryk)

Residuals:
    Min       1Q   Median       3Q      Max
-8.644 -3.019  1.201  1.785  7.219

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
stillingJournalist      84.9952     7.7426  10.978 7.71e-11 ***
stillingUnderviser      75.6299    10.1296   7.466 1.05e-07 ***
stillingJournalist:alder   1.5296     0.1351  11.322 4.12e-11 ***
stillingUnderviser:alder   1.5624     0.1789   8.732 6.47e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.342 on 24 degrees of freedom
Multiple R-squared:  0.9994,    Adjusted R-squared:  0.9993
F-statistic: 1.045e+04 on 4 and 24 DF,  p-value: < 2.2e-16
```

Vi fitter nu modellen M_2 . Dette gøres ved modelformlen som er vist i R-kode 5.22

R-kode 5.22

```
LM_Blodtryk_M2 <- lm(blodtryk~1+alder+alder:stilling,data=Blodtryk)
```

Sammenligner vi med modelformlen i R-kode 5.20 ser vi at `stilling` er fjernet fra modelformlen, hvilket i opskrivningen fra (5.32) svarer til fjerne ζ_{st1} således at vi ender med én parameter α der er fælles for de to grupper. Kører vi `summary` på modellen fra R-kode 5.22 fås R-udskrift 5.24

R-udskrift 5.24

```
Call:
lm(formula = blodtryk ~ 1 + alder + alder:stilling, data = Blodtryk)

Residuals:
    Min       1Q   Median       3Q      Max
-8.1406661 -2.8690789  1.2265472  2.1333699  7.2800569

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)      81.54148011   6.09450878  13.37950 6.7356e-13 ***
alder              1.58909584   0.10708631  14.83939 6.6872e-14 ***
```

```

alder:stillingUnderviser -0.13048919  0.02867217 -4.55107  0.0001193 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.301913 on 25 degrees of freedom
Multiple R-squared:  0.9027742, Adjusted R-squared:  0.89499613
F-statistic: 116.06669 on 2 and 25 DF,  p-value: 2.2246884e-13

```

Som omtalt på side 5.8 indeholder parametertabellen estimatet for den fælles afskæring samt hældningskoefficienten for journalisterne og differencen mellem de to hældningskoefficienter. Med betegnelserne fra (5.32) og (5.33) er der tale om $\hat{\alpha}$, $\hat{\beta}$ og $\hat{\eta}_{\text{underviser}}$.

Vi kan også bruge **anova** til at finde variansanalysetabellen, svarende til reduktionen fra M_1 til M_2 ved hjælp af de fittede modeller. Køres **anova**(LM_Blodtryk_M2, LM_Blodtryk_M1) fås variansanalysetabellen i R-udskrift 5.25.

R-udskrift 5.25

```

Analysis of Variance Table

Model 1: blodtryk ~ 1 + alder + alder:stilling
Model 2: blodtryk ~ 1 + stilling + alder + alder:stilling
  Res.Df    RSS Df Sum of Sq    F Pr(>F)
1      25 462.66
2      24 452.49  1    10.173 0.5396 0.4697

```

Vi genkender F -teststørrelsen fra (5.29) og p -værdien fra R-udskrift fra 5.22 som bemærket på side 123.

Reduktionen fra M_1 til M_2^* behandles tilsvarende. I dette tilfælde er at det **alder:stilling** der skal fjernes fra modelformlen, som fremgår af R-kode 5.23

R-kode 5.23

```
LM_Blodtryk_M2star <- lm(blodtryk~1+stilling+alder, data=Blodtryk)
```

Sammenligner vi igen modelformlen i R-kode 5.20 ser vi at det nu er leddet η_{stl} der er fjernet, således at vi ender med én parameter β , der er fælles for hældningen i de to grupper. Kører vi **summary** på modellen fra R-kode 5.23 fås R-udskrift 5.26

R-udskrift 5.26

```

Call:
lm(formula = blodtryk ~ 1 + stilling + alder, data = Blodtryk)

Residuals:

```

```

      Min      1Q      Median      3Q      Max
-8.5533203 -2.9979778  1.2588374  1.7357081  7.2148142

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    84.32064421   6.09856330  13.82631 3.2555e-13 ***
stillingUnderviser -7.51476484   1.61325341  -4.65814 9.0379e-05 ***
alder           1.54148319   0.10568193  14.58606 9.8526e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.256254 on 25 degrees of freedom
Multiple R-squared:  0.90482708,    Adjusted R-squared:  0.89721324
F-statistic: 118.83988 on 2 and 25 DF,  p-value: 1.7037957e-13

```

Endeligt kan vi finde variansanalysetabellen, svarende til reduktionen fra M_1 til M_2^* ved hjælp af de fittede modeller. Køres `anova(LM_Blodtryk_M2star, LM_Blodtryk_M1)` fås variansanalysetabellen i R-udskrift 5.27.

R-udskrift 5.27

```

Analysis of Variance Table

Model 1: blodtryk ~ 1 + stilling + alder
Model 2: blodtryk ~ 1 + stilling + alder + alder:stilling
  Res.Df    RSS Df Sum of Sq    F Pr(>F)
1      25 452.89
2      24 452.49  1    0.40394 0.0214 0.8849

```

Vi ved allerede ud fra de forskellige kald til `summary` at vi hverken kan reducere fra M_2 til M_3 eller fra M_2^* til M_3 . Sidstnævnte kan også ses af et kald til `anova`. Fitter vi M_3 ved hjælp af R-kode 5.24

R-kode 5.24

```
LM_Blodtryk_M3 <- lm(blodtryk~1+alder,data=Blodtryk)
```

findes følgende variansanalysetabel ved hjælp af `anova(LM_Blodtryk_M3, LM_Blodtryk_M2star)`

R-udskrift 5.28

```

Analysis of Variance Table

Model 1: blodtryk ~ alder
Model 2: blodtryk ~ 1 + stilling + alder
  Res.Df    RSS Df Sum of Sq    F    Pr(>F)

```

```

1      26 845.97
2      25 452.89  1      393.08 21.698 9.038e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Vi har ovenfor beskrevet forskellige parametriseringer af modeller inden for *gruppespecifik regression*, illustreret ved Eksempel 5.8. Hvis vi generelt forestiller os en situation, hvor t er en forklarende variabel, og gr er en faktor, der inddeler data i k grupper, vil modelformlen `gr + t + gr:t` fitte en model med k regressionslinjer. Modelformlen `gr * t` kan bruges synonymt. **R** vil omskrive denne til `gr + t + gr:t`.

Følgende tabel giver alternative måder at skrive modelformlen på og de tilhørende parametriseringer i **R**.

Model	Modelformel	Parametre	
M_1	<code>gr*t</code>	$(\alpha_1, \alpha_2 - \alpha_1, \dots, \alpha_k - \alpha_1, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$	
M_1	<code>gr + t + gr:t</code>	$(\alpha_1, \alpha_2 - \alpha_1, \dots, \alpha_k - \alpha_1, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$	
M_1	<code>0 + gr + gr:t</code>	$(\alpha_1, \alpha_2, \dots, \alpha_k, \beta_1, \beta_2, \dots, \beta_k)$	
M_1	<code>0 + gr + t + gr:t</code>	$(\alpha_1, \alpha_2, \dots, \alpha_k, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$	
M_2	<code>gr + t</code>	$(\alpha_1, \alpha_2 - \alpha_1, \dots, \alpha_k - \alpha_1, \beta)$	(5.34)
M_2	<code>0 + gr + t</code>	$(\alpha_1, \alpha_2, \dots, \alpha_k, \beta)$	
M_2^*	<code>t + gr:t</code>	$(\alpha, \beta_1, \beta_2 - \beta_1, \dots, \beta_k - \beta_1)$	
M_2^*	<code>gr:t</code>	$(\alpha, \beta_1, \beta_2, \dots, \beta_k)$	
M_3	<code>t</code>	(α, β)	

Som beskrevet i afsnit 5.2.3 bruges **anova** når vi skal vurdere om vi kan reducere fra en lineær normal model til en undermodel, og vi gør dette ved at give begge de fittede modeller som argument. Men som det er nævnt kan **anova** også kaldes med én fittet model, og vil da lave en variansanalysetabel, hvis indhold vi nu vil gennemgå.

Modelformlen der blev brugt til at specificere modellen M_1 i programmet på R-kode 5.20 var `blodtryk ~ 1+stilling+alder+alder:stilling` men vi vil først gennemgå den variansanalysetabel, der opstår, når man bytter rundt på `stilling` og `alder` som det er gjort i R-kode 5.25. Vær opmærksom på at de to modelformler svarer til samme statistiske model.

R-kode 5.25

```

LM_Blodtryk_M1 <-
  lm(blodtryk~1+alder+stilling+alder:stilling, data=Blodtryk)

```

Køres kommandoen `anova(LM_Blodtryk_M1)` fås

R-udskrift 5.29

Analysis of Variance Table						
Response: blodtryk						
	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
alder	1	3912.6549	3912.6549	207.52730	2.609e-13	***
stilling	1	393.0798	393.0798	20.84896	0.00012519	***
alder:stilling	1	0.4039	0.4039	0.02142	0.88485028	
Residuals	24	452.4885	18.8537			

Signif. codes:	0	'***'	0.001	'**'	0.01	'*' 0.05
						'.' 0.1
						' ' 1

Indgangene i variansanalysetabellen er knyttet til nogle af de F -test for model-reduktion, som blev brugt i analysen af Eksempel 5.8 i Afsnit 5.4. For bekvem reference kopierer vi F -testene for reduktionen fra M_1 til M_2^* som blev givet i formel (5.30),

$$\mathcal{F} = \frac{0.403935}{18.853688} = 0.02142, \quad (5.35)$$

og F -testet for reduktionen fra M_2^* til M_3 , som blev givet i (5.31),

$$\mathcal{F} = \frac{393.079753}{18.115698} = 21.70. \quad (5.36)$$

□

Den nederste række i variansanalysetabellen fra R-udskrift 5.29 viser F -testet og de tilknyttede størrelser for reduktionen fra M_1 til M_2^* . I (5.35) genkender vi frihedsgraderne for tælleren i F -testet i DF-søjlen, tælleren i F -testet i Mean Square-søjlen, F -teststørrelsen i F Value-søjlen og testsandsynligheden baseret på $F(1, 24)$ -fordelingen i Pr(>F)-søjlen.

Rækken ovenover, som har `stilling` i venstre søjle, giver **ikke** F -testet for reduktionen fra M_2^* til M_3 , men der står alligevel nogle beslægtede størrelser, som kan være nyttige: frihedsgraderne for tælleren af F -testet står i DF-søjlen og tælleren for F -testet står i Mean Square-søjlen. Derimod er F value ikke F -testet i (5.36), men den eneste forskel er at den estimerede varians i M_1 , $s_1^2 = 18.853688$, bruges som nævner i stedet for den estimerede varians i M_2^* , $s_{02}^{2*} = 18.115698$. Testsandsynligheden Pr(>F) beregnes ud fra $F(1, 24)$ -fordelingen.

Det, der ovenfor blev beskrevet for model M_1 i Eksempel 5.8, vil nu blive gennemgået mere generelt. Når **R** udskriver en variansanalysetabel ud fra en modelformel som på R-kode 5.26, hvor A_i ($i = 1, \dots, k$) kan være en faktor, en kontinuert variabel eller et produkt af variable/faktorer, vil **R** generere et output, hvis indhold fremgår af Tabel 5.10.

R-kode 5.26

```
x ~ A_k + A_{k-1} + ... + A_i + ... + A_2 + A_1
```

Analysis of Variance Table

Response: x

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
A _k	$d_k - d_{k+1}$	$\ P_k(\mathbf{x}) - P_{k+1}(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	(*)
A _{k-1}	$d_{k-1} - d_k$	$\ P_{k-1}(\mathbf{x}) - P_k(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	
⋮	⋮	⋮	⋮	⋮	⋮	
A _i	$d_i - d_{i+1}$	$\ P_i(\mathbf{x}) - P_{i+1}(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	
⋮	⋮	⋮	⋮	⋮	⋮	
A ₁	$d_1 - d_2$	$\ P_1(\mathbf{x}) - P_2(\mathbf{x})\ ^2$	SS/DF	MS/s_1^2	$1 - F(F)$	

Tabel 5.10: Variansanalysetabellen fra modellen M_1

Tankegangen er at en modelformel med k led definerer en følge af $k + 1$ simple modeller, $M_1 \rightarrow M_2 \rightarrow \dots \rightarrow M_k \rightarrow M_{k+1}$, hvor M_1 er lig med den fulde modelformel og de følgende modeller er afledt fra M_1 ved successivt at fjerne led fra modelformlen fra højre, først A_1 , så A_2 , og således videre.

$$\begin{aligned}
 M_1: & \quad \mathbf{x} \sim A_k + A_{k-1} + \dots + A_i + \dots + A_2 + A_1 \\
 M_2: & \quad \mathbf{x} \sim A_k + A_{k-1} + \dots + A_i + \dots + A_2 \\
 & \quad \vdots \\
 M_i: & \quad \mathbf{x} \sim A_k + A_{k-1} + \dots + A_i \\
 & \quad \vdots \\
 M_k: & \quad \mathbf{x} \sim A_k \\
 M_{k+1}: & \quad \mathbf{x} \sim 1
 \end{aligned}$$

Modellen M_{k+1} er modellen for én observationsrække, hvor alle observationer er uafhængige og identisk fordelte. Denne model betegnes M_∞ , fordi det er den samme model uanset antallet af led i den oprindelige modelformel.

Med notationen fra lineære normale modeller kan vi forklare indholdet af variansanalysetabellen, som det er gjort i Tabel 5.10. Vi minder om, at n betegner antallet af observationer, L_i er det lineære underrum for modellen M_i , og d_i er dimensionen af L_i . Den ortogonale projektion på L_i betegnes med P_i , og endelig betegner s_{0i}^2 estimatet for variansen i M_i , bortset fra i M_1 , hvor variansskønnet betegnes s_1^2 .

Hvis man er interesseret i en bestemt aftagende følge af modeller, kan man prøve at formulere modellen på en sådan måde i modelformlen, at denne modelrække fremgår af variansanalysetabellen. Typisk vil man først se på Sum Sq-søjlen for at vurdere, hvilke led i modellen der bidrager mest til den totale sum. Dernæst kan man kigge på Pr(>F) for at se, hvilke bidrag der muligvis er signifikante. Eftersom F -testene ikke benytter opdaterede variansskøn i nævnerne, vil man dog kun betragte testsandsynlighederne som vejledende.

Som eksempel kan man fitte M_1 ved at køre

```
blodtryk ~ 1 + stilling + alder + alder:stilling
```

og derefter udføre **anova**. Det fører til R-udskrift 5.30. Denne variansanalysetabel svarer til først at undersøge reduktionen fra M_1 til M_2^* og dernæst undersøge, om den fælles hældning kan antages at være lig 0.

R-udskrift 5.30

```
Analysis of Variance Table

Response: blodtryk
      Df    Sum Sq  Mean Sq  F value    Pr(>F)
stilling    1  451.5619   451.5619   23.95085 5.4396e-05 ***
alder        1 3854.1728  3854.1728  204.42540 3.0696e-13 ***
stilling:alder 1    0.4039    0.4039    0.02142  0.88485
Residuals   24  452.4885   18.8537
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Læses R-udskrift 5.30 nedefra, at vi godt kan reducere fra M_1 til M_2^* men at vi ikke kan reducere til en model hvor **alder** ikke er med.

5.5 Multipel regression

I Afsnit 4.1 omtalte vi simpel lineær regression, hvor vi for responsvariablen x havde én forklarende variabel t , og datasættet bestod af talpar $(x_1, t_1), \dots, (x_n, t_n)$. I dette afsnit vil vi diskutere situationen, hvor der er flere (d) forklarende variable. Værdierne af den j -te forklarende variabel $j = 1, \dots, d$ betegnes t_{ij} for $i = 1, \dots, n$, og vi lader $\mathbf{t}_{(j)}$ betegne den n -dimensionale vektor, der består af alle disse værdier, dvs.

$$\mathbf{t}_{(j)} = (t_{1j}, t_{2j}, \dots, t_{nj})^*. \quad (5.37)$$

Vores model er, at X_i , $i = 1, \dots, n$ er uafhængige stokastiske variable, der opfylder

$$M_1 : X_i \sim N(\alpha + t_{i1}\beta_1 + \dots + t_{id}\beta_d, \sigma^2), \quad i = 1, \dots, n. \quad (5.38)$$

De forklarende variable kaldes også *regressionsvariable*, og de ukendte parametre $\beta_1, \dots, \beta_d$ kaldes *regressionskoefficienter*.

<i>Log Diameter</i>	<i>Log Height</i>	<i>Log Volume</i>
2.12	4.25	2.33
2.15	4.17	2.33
2.17	4.14	2.32
$\vdots$	$\vdots$	$\vdots$
3.03	4.47	4.34

Eksempel 5.9.

I **R** findes et indbygget datasæt kaldet `trees`. Beskrivelsen af datasættet er følgende:


This data set provides measurements of the diameter, height and volume of timber in 31 felled black cherry trees. Note that the diameter (in inches) is erroneously labelled Girth in the data. It is measured at 4 ft 6 in above the ground.

Datasættet indeholder tre kontinuerte variable, *Girth*, *Height* og *Volume*, hvor *Girth* i det følgende benævnes *Diameter*. Figur 5.14 viser logaritmen til volumen afsat mod henholdsvis logaritmen til diameter og logaritmen til højden. Den sidste delfigur viser logaritmen til højden afsat mod logaritmen til diameteren. Af figurerne ses det, at både diameteren og højden hver især indeholder information om volumen, men at diameteren bedst kan bruges til at forudsige volumen, idet variationen omkring den estimerede regressionslinje her er mindst.

Som det fremgår af det første scatterplot, er hældningen for *log Volume* på *log Diameter* estimeret til 2.2. Det svarer til, at medianen af volumen er proportional med diameter opløftet i 2.2, hvilket umiddelbart kan være svært at fortolke. Vi betragter derfor en *multipel* regressionsmodel, hvor *log Volume* fungerer som respons, mens *log Height* og *log Diameter* begge indgår som forklarende variable. Lad x_i betegne den i -te værdi af *log Volume* og t_{i1} , t_{i2} tilsvarende betegne henholdsvis *log Diameter* og *log Height*. Modellen kan da skrives som

$$M_1 : X_i \sim N(\alpha + \beta_1 t_{i1} + \beta_2 t_{i2}, \sigma^2), \quad i = 1, \dots, n, \quad + \text{ uafhængighed.} \quad (5.39)$$

□



Figur 5.14: Scatterplots for `cherry` datasættet for de tre par af variable med indtegnede estimerede regressionslinjer. Estimerer for afskæring og hældning er angivet i overskriften.

Det sidste af de tre scatterplots i Figur 5.14 viser, som nævnt, *log Height* afsat mod *log Diameter*, og overskriften angiver afskæring og hældning for den estimerede regressionslinje. Vi bemærker, at *log Height* og *log Diameter* i intuitiv forstand ikke er uafhængige, og at vi gerne vil opfatte dem som "korrelerede". Det kan virke ulogisk, da korrelationsbegrebet (ligesom kovariansbegrebet) som udgangspunkt er indført for stokastiske variable, mens vi i (5.39) betragter de forklarende variable som faste tal.

Alligevel siger vi, at de forklarende variable er korrelerede, fordi vi benytter *den empiriske korrelation*, som defineres via *den empiriske fordeling* (jf. Afsnit A.3.8). Endvidere vises i Afsnit A.3.8, at en positiv hældningskoefficient i en estimeret regressionslinje modsvarer en positiv (empirisk) korrelation. Derfor vil vi opfatte *log Height* og *log Diameter* som positivt korrelerede.


På Figur 5.15 findes kontroltegninger for den multiple regressionsmodel. På Figur 5.15a er residualerne afsat mod de forventede værdier og på 5.15b ses normal fraktilplot for de standardiserede residualer, som er beregnet ved hjælp af (4.12) med generaliseret udtryk for h_i . Begge tegninger er i overensstemmelse med (5.39). Parameterestimererne aflæses i R-udskrift 5.31 til

$$\hat{\alpha} = -6.63162 \quad \hat{\beta}_1 = 1.98265 \quad \hat{\beta}_2 = 1.11712$$

Det fremgår også af R-udskrift 5.31 at begge de to forklarende variable er signifikante da de to *t*-tests svarende til hypoteserne $H : \beta_1 = 0$ og $H : \beta_2 = 0$ begge er < 0.05 . Vi bemærker endvidere at $\hat{\beta}_1 \approx 2$ og $\hat{\beta}_2 \approx 1$ hvilket svarer til det intuitivt rimelige resultat at volumen af træerne er proportional med *diameter*²*højde*.

Som for simpel lineær regression kan vi finde konfidensintervaller for linjens værdi og prædiktionsintervaller for nye observationer. Her vil vi dog undlade at udlede eksplicitte formler og i stedet benytte **R** til at foretage beregningerne.

I Tabel 5.11 findes observationer for logaritmen til diameter og logaritmen til højde for to træer.



Figur 5.15: Kontroltegninger til modellen for multipel regression for `trees` datasættet.

	Log Diameter	Log Højde
Træ 1	2.5	4.3
Træ 2	2.2	4.1

Tabel 5.11: Eksempel på en tabel over logaritmen af diameter og højde for to træer.

Tabel 5.12 indeholder de tilhørende fittede værdier samt konfidensintervaller for linjens værdi og prædiktionsintervaller, som er fundet på R-udskrift 5.32.

	fit	Konfidensinterval		Prædiktionsinterval	
		nedre grænse	øvre grænse	nedre grænse	øvre grænse
Træ 1	3.128638	3.097052	3.160224	2.958960	3.298316
Træ 2	2.310418	2.224244	2.396593	2.122752	2.498085

Tabel 5.12: Konfidensinterval og prædiktionsinterval for de to træer fra Tabel 5.11

5.6 Model selektion

I en multipel regressionssituation ved man typisk ikke på forhånd, om alle de forklarende variable bidrager med information om responsvariablen. Hvis man inkluderer mange variable, der ikke er relevante, kan dette give et forkert billede af afhængigheden af de relevante variable, og kan give et forkert indtryk af, hvor godt responsen kan beskrives.

I dette afsnit vil vi lade $s(M)$ betegne den estimerede spredning i en model M . Viser $s(M)$ sig at være lille, afspejler det ikke nødvendigvis, at modellen er god, men kan snarere skyldes, at man har medtaget “for mange” forklarende variable. Man taler i den sammenhæng om *overfitting*. Hvis man f.eks. har n observationer og n eller flere forklarende variable, vil den multiple regressionsmodel give $s(M) = 0$, og de prædikterede værdier $\hat{x}_i$ vil være identiske med de observerede værdier. Vores mål må derfor være at finde en delmængde af de forklarende variable, der giver en god beskrivelse af responsen, uden at *overfitte*. I en model med få forklarende variable er fortolkningen lettere, og parametrene vil være bedre bestemt end i en model med mange variable.

Vi vil beskrive to metoder til at udvælge de forklarende variable, som vi ønsker at medtage i vores model: *backward-selektion* og *forward-selektion*. *Backward-selektion* minder om den fremgangsmåde, vi hidtil har benyttet, når vi finder en model for data: Vi starter med den *fulde* regressionsmodel (dvs. alle forklarende variable) og forsimpler modellen ved at fjerne variable. Mere præcist fjerner man successivt én af de forklarende variable baseret på p -værdierne fra t -test af, om de pågældende regressionskoefficienter er nul.

5.6.1 Backward-selektion

Ved **Backward-selektion** forstås følgende procedure:

I hvert trin køres `summary(lm(modelformel))` for den aktuelle model. Den største p -værdi blandt t -testene, for at en regressionskoefficient er nul, identificeres. Hvis denne p -værdi er større end en selvvalgt grænse (for eksempel 0.05), fjernes den tilhørende regressionsvariabel fra modellen. Proceduren stopper, når ingen af p -værdierne er over grænsen, og den tilhørende model kaldes slutmodellen.


Typisk vil man også supplere testene med en registrering af udviklingen af spredningsskønnet $s(M)$ i hvert trin, og til sidst lave et F -test for reduktion fra startmodellen til slutmodellen.

Eksempel 5.10.

Dette eksempel handler om en beskrivelse af den globale årstemperatur ud fra forskellige forklarende variable. Eksemplet er baseret på fremstillingen i artiklen [Using Data from Climate Science to Teach Introductory Statistics](#), og en beskrivelse af datakilderne til eksemplet findes på side 172.

Figur 5.16 viser den globale temperaturs afvigelse fra et 30 års gennemsnit for årene 1979 til 2010 (afvigelse i °C ganget med 100) samt udviklingen af CO₂-niveauet i atmosfæren i samme periode (målt i *ppm*, parts per million). Begge grafer viser en stigende tendens over perioden, og derfor vil en regression af temperaturen på CO₂ også vise en tydelig sammenhæng, som det fremgår af Figur 5.16b.

Spørgsmålet er, om der findes andre effekter end CO₂, der kan forklare temperaturstigningen. De kandidater, vi vil betragte, er solens udstråling (*solar irradiance*, målt i watt/m²), vulkanaktivitet og et mål for *El Niño*-effekten.



(a) Temperatur (sort) og CO₂ (grøn) fra 1979 til 2010. Enheder for temperatur til på akse til venstre, enheder for CO₂ på akse til højre.

(b) Temperatur afsat mod CO₂.

Figur 5.16: Udvikling af temperatur og CO₂ fra 1979 til 2010.

Vulkanaktiviteten måles ved hjælp af *MLO apparent transmission values*, som angiver den procentdel af solens udstråling, der rammer jordoverfladen. *El Niño*-effekten måles som en temperaturafvigelse i grader celsius. I Figur 5.17 vises de fire forklarende variable som funktion af tidspunkt.

Umiddelbart viser ingen af de tre nye forklarende variable en entydig stigende eller faldende tendens over perioden, men måske er der samspil mellem dem, som ikke umiddelbart kan ses. Dette kan undersøges ved at benytte en multipel regressionsmodel.

Lad X være temperaturen, C mængden af CO₂ i atmosfæren, S solens udstråling, V vulkanaktiviteten og E El Niño-effekten. Udover de fire forklarende variable vil vi også inddrage interaktion mellem disse ved at medtage deres produkter:


$$CS = C \cdot S, \quad CV = C \cdot V, \quad CE = C \cdot E, \quad SV = S \cdot V, \quad SE = S \cdot E, \quad VE = V \cdot E. \quad (5.40)$$

Med disse betegnelser kan vi opstille den multiple regressionsmodel som følger:

$$\begin{aligned} X_i &\sim N(\xi_i, \sigma^2), \quad i = 1, \dots, 32, \quad + \text{ uafhængighed,} \\ \text{hvor } \xi_i &= \alpha + \beta_C \cdot C_i + \beta_S \cdot S_i + \beta_V \cdot V_i + \beta_E \cdot E_i \\ &\quad + \beta_{CS} \cdot CS_i + \beta_{CV} \cdot CV_i + \beta_{CE} \cdot CE_i + \beta_{SV} \cdot SV_i + \beta_{SE} \cdot SE_i + \beta_{VE} \cdot VE_i. \end{aligned}$$

idet f.eks. C_i betegner den i te måling af CO₂.

Modellen analyseres på R-kode 5.30. For at stabilisere de numeriske beregninger foretages først en normalisering af de fire forklarende variable. Det vil sige, at for hver variabel fratrækkes gennemsnit, og der divideres med den empiriske spredning.



Figur 5.17: Udvikling fra 1979 til 2010 af de fire forklarende variable fra Eksempel 5.10

Fra parametertabellen i R-udskrift 5.34 ses det, at t -testet for $\beta_{VE} = 0$ giver en p -værdi på 0.61, hvilket er den største p -værdi blandt de ti regressionsparametre. Da denne p -værdi er langt over 0.05, fjerner vi VE -leddet fra modellen. I R-kode 5.31 fittes modellen igen, nu uden VE i modelformlen. Som vist i R-udskrift 5.34 fjernes dernæst SE .

Fortsætter man på denne måde, fås at CE , CS og CV ligeledes kan fjernes.

I modellen med multipel regression på C , S , V , E og SV ses p -værdierne for de tilhørende regres-

sionskoefficienter både i R-udskrift 5.35 og i Tabel 5.13. Som det fremgår, er disse værdier meget små – bortset fra for SV . Vi vælger dog ikke at reducere modellen yderligere. Et F -test for reduktion fra den fulde model til slutmodellen laves via R-kode 5.33, og ifølge R-udskrift 5.37 fås en p -værdi på 0.21.

Slutmodellen er altså

$$X_i \sim N(\alpha + \beta_C C_i + \beta_S S_i + \beta_V V_i + \beta_E E_i + \beta_{SV} \cdot SV_i, \sigma^2), \quad i = 1, \dots, 32, \quad \square$$

Parametertabellen fra R-udskrift 5.35 er gengivet i Tabel 5.13. Regressionskoefficienterne hører her til de standardiserede variable. For eksempel er spredningen på CO_2 -værdierne 15.3, hvorfor skøn over regressionskoefficienten der ganges på de oprindelige CO_2 -værdier er $16.2/15.3 \approx 1$.

	α	C	S	V	E	SV
Estimate	31.5334	16.1674	6.8994	12.3519	5.7220	-10.4519
Std. Error	1.3215	1.3633	1.6971	3.0498	1.1519	4.2719
p_{obs}	0.0000	0.0000	0.0004	0.0004	0.0000	0.0215

Tabel 5.13: Estimer, standard error og p -værdier i slutmodellen.


Det er usædvanligt, at man med kun 32 datapunkter og fem forklarende variable finder, at fire af disse er stærkt signifikante (p -værdier langt under 0.05). Som nævnt ovenfor ligger regressionskoefficienten for CO_2 omkring 1, hvilket indebærer, at en stigning på 100 ppm i mængden af CO_2 ifølge denne meget enkle model ville føre til en stigning på $1^\circ C$ i den globale temperatur.

5.6.2 Datasæt med et stort antal forklarende variable - forward-selektion

Near-infrared spectroscopy (NIRS) er en måleteknik, der i stigende grad benyttes i fødevareindustrien og inden for mange andre områder. Ideen er, at man sender lys af forskellige bølgelængder gennem en prøve for at få information om prøvens sammensætning. For eksempel kan man ønske at vurdere mængden af fedtstoffer (responsen) ud fra lysabsorptionen ved en række forskellige bølgelængder. Her er lysabsorptionen ved en bestemt bølgelængde en forklarende variabel, og antallet af forklarende variable bliver det antal bølgelængder, der måles ved. Lysabsorptionen ved de forskellige bølgelængder kaldes *spektrum* for prøven.

Som et konkret eksempel vil vi betragte brugen af NIRS til at bedømme, hvor moden frugt er. Man ønsker at bestemme **Brix**-værdien, som er et mål for den samlede mængde opløste faste stoffer (*total soluble solids*, TSS), og som i frugt overvejende består af sukker. Vi benytter data, der er tilgængelige på [GitHub](#), og som også anvendes på [Daniel Pelliccias](#) blog og firmahjemmeside. Disse data vedrører sukkerindholdet i ferskner. En tidlig beskrivelse af brugen af NIRS til analyse af ferskner findes i artiklen [Determination of Sugar Content in Intact Peaches by Near Infrared Spectroscopy with Fiber Optics in Interactance Mode](#).

Datasættet indeholder målinger fra 50 ferskner, men vi vil kun bruge de første 40 af disse til at opstille en model. Derefter anvender vi denne model til at lave prædiktioner på de sidste 10 ferskner.




For de data, vi betragter, er lysabsorptionen målt ved 600 bølglængder i intervallet 1100–2300 nanometer. Figur 5.18 viser spektret for prøven med den laveste brixværdi (11.2), for prøven med den højeste brixværdi (20.0), samt for en prøve med en brixværdi midt imellem disse to.

I det konkrete eksempel har vi altså langt flere forklarende variable end datapunkter, hvilket gør det vanskeligt at konstruere en multipel regressionsmodel. Hvis man forsøger at lave regression på alle variablene, ender man med at fitte en model, hvor de forventede værdier præcist rammer de observerede responsværdier – og skønnet over spredningen bliver dermed $s(M) = 0$. Dette er en ekstrem form for “overfitting”.

I en situation med mange forklarende variable kan man således ikke bruge backward-selektion til at reducere modellen. I stedet vil vi benytte en alternativ metode, kaldet *forward-selektion*, til at etablere en model. Ved *forward-selektion* starter man med den mindst mulige model, dvs. uden nogen forklarende variable, så alle stokastiske variable har samme middelværdi. Man bygger derefter modellen op trinvis ved i hvert trin at inkludere én ny forklarende variabel, baseret på en væsentlig reduktion i spredningsskønnet $s(M)$.

Ved forward-selektion forstår vi konkret følgende procedure:




Figur 5.18: Spektre svarende til tre forskellige brixværdier

I hvert trin prøver man på skift at inkludere en af de variable, der endnu ikke er med i modellen. Fra parametertabellen, for modellen med den ekstra variabel inkluderet, findes spredningsskønnet $s(M)$ og p -værdien for test af hypotesen, at regressionskoefficienten hørende til den ekstra variabel er nul. Når alle variable er afprøvet, vælges den variabel med det laveste spredningsskøn, og hvis den tilhørende p -værdi er under en selvvalgt grænse (for eksempel 0.05), inkluderes variabelen i modellen, og forward-selektions proceduren fortsættes. Proceduren stopper, når p -værdien for den valgte variabel er over grænsen.

Figur 5.19 viser resultatet af at gennemføre forward-selektion i dette eksempel. Den sorte kurve i Figur 5.19a illustrerer udviklingen af spredningsskønnet $s(M_j)$ som funktion af antallet j af forklarende variable, der er inkluderet i modellen undervejs i forward-selektionen (den røde kurve forklares i Afsnit 5.6.3). På Figur 5.19b ses p -værdien for test af $\beta = 0$, hvor β er regressionskoefficienten for det sidst inkluderede led i modellen.

Figuren viser, at spredningsskønnet $s(M)$ falder, når modellen udvides fra én variabel til to ved forward-selektion, og at der samtidig optræder små p -værdier for testet af, om regressionskoeffi-



(a) Spredningsskønnet $s(M_j)$ som funktion af antal variable j . Den sorte kurve er det almindelige spredningsskøn, den grønne er baseret på cross-validation. (b) p -værdier for test for at den senest inkluderede regressionskoefficient er 0. Første p -værdi over 0.05 forekommer ved tre inkluderede variable.

Figur 5.19: Resultater for forward-selektion på spektroskopi-data.

enten for det sidst inkluderede led er nul. For de næste fire variable er der næsten ingen yderligere reduktion i $s(M)$, og p -værdierne ligger over 0.05. Ved den syvende variabel falder $s(M)$ igen, og tilhørende p -værdi er lille. Dette mønster gentager sig med de næste fem variable. Hvis man følger den formelle definition af forward-selektion, stopper man efter at have medtaget to variable, hvor spredningsskønnet er 1.81 (se R-udskrift 5.39). Vælger man i stedet syv variable, ender man med et $s(M)$ på 1.54.

Da variable i forward-selektion vælges med det formål at minimere $s(M)$, kan man ikke forvente, at dette skøn afspejler variationen omkring middelværdi-modellen særlig godt. Har man mange forklarende variable, vil flere af dem tilfældigvis kunne se korrelerede ud med responsen (i den betydning at den estimerede hældningskoefficient er forskellig fra nul) og dermed blive inkluderet i modellen. Derfor er der behov for en anden metode til at lave et retvisende skøn for variationen. Den grønne kurve i 5.19a repræsenterer netop en alternativ metode, som gennemgås i Afsnit 5.6.3. Denne metode viser, at forward-selektion med seks variable er passende for disse data og giver et spredningsskøn (eller snarere et skøn over prædiktionsfejlen, jf. Afsnit 5.6.3) på 1.98. At kun seks variable inkluderes afspejler desuden, at man blot har 40 prøver til rådighed for at opstille modellen. Med flere prøver ville det være forventeligt, at forward-selektion kunne omfatte flere variable.

5.6.3 Cross-validation

Motivationen for at betragte NIR-spektret i Afsnit 5.6.2 er, at vi ønsker at konstruere en metode, der kan anvendes til at prædiktere responsvariablen (her: brixværdien i ferskner). Det er derfor naturligt at vurdere metodens kvalitet ud fra dens evne til at prædiktere et nyt sæt observationer. Man taler generelt om *prædiktionsspredningen* (Root Mean Squared Error of Prediction, RMSEP) og *prædiktionsvariansen*, hvor sidstnævnte opnås ved at tage gennemsnit af de kvadrerede prædiktionsfejl –

dvs. afstanden mellem den observerede værdi og den prædikterede værdi.

Udfordringen er, at man som regel ikke råder over et nyt sæt observationer. I stedet deler man derfor ofte det oprindelige datasæt op i et *træningssæt* og et *testsæt*, hvor træningssættet bruges til at konstruere prædiktionsmetoden, mens testsættet anvendes til at vurdere, hvor god metoden er. Typisk laver man flere forskellige opdelinger i træningssæt og testsæt, således at testsættet på skift udgør forskellige dele af det oprindelige datasæt. Dette bærer navnet **crossvalidation** (*krydsvalidering*).

Fordi vi her lægger vægten på prædiktionsspredningen, kan man se den multiple regressionsmodel som en del af *machine learning*.

Vi giver først en abstrakt beskrivelse af cross-validation. Antag, at vi har n datapunkter og ønsker at vurdere en given estimationsmetode. Cross-validation kan da sammenfattes i følgende trin:

1. Del data op i et *træningssæt* og et *testsæt*.
2. Udfør estimationsmetoden på træningssættet for at finde skøn over de parametre, der indgår i den endelige model.
3. For hver prøve i testsættet beregnes en prædikteret værdi, baseret på de forklarende variable i prøven og parametrene fra trin 2. Man får således en *prædiktionsfejl* for hver prøve ved at trække den prædikterede værdi fra den observerede responsværdi.
4. Gentag trin 1–3 for andre opdelinger af datasættet, således at hver del af datasættet på skift bliver testsæt.
5. Beregn *prædiktionsvariansen* som gennemsnittet af alle kvadrerede prædiktionsfejl fra alle testinddelinger. Definér til sidst *prædiktionsspredningen* (Root Mean Squared Error of Prediction, RMSEP) som kvadratroden af prædiktionsvariansen.

Vi vil nu betragte *cross-validation* i forbindelse med forward-selektion i en multipel regressionsmodel. Antag, at vi i træningsdelen af data har udvalgt de forklarende variable $j_1, j_2, \dots, j_k$ og har fundet estimerne $\hat{\alpha}, \hat{\beta}_1, \dots, \hat{\beta}_k$ i den multiple regressionsmodel

$$X_i \sim N(\alpha + \beta_1 t_{ij_1} + \dots + \beta_k t_{ij_k}, \sigma^2).$$

For et observationsnummer i i *testsættet* er den prædikterede værdi

$$\hat{x}_i^{\text{cv}} = \hat{\alpha} + \hat{\beta}_1 t_{ij_1} + \dots + \hat{\beta}_k t_{ij_k},$$

og bidraget til *prædiktionsvariansen* bliver $(x_i - \hat{x}_i^{\text{cv}})^2$.

I *leave-one-out cross-validation* (LOOCV) lader man testsættet bestå af netop én enkelt observation, mens træningssættet består af de resterende $n - 1$ observationer. Dette gentages n gange, således at observation nummer i udgør testsættet i trin i . Lader vi $\hat{x}_i^{(-i)}$ betegne den prædikterede værdi for

observation i , når træningssættet består af alle observationer undtagen den i te, kan crossvalidation-skønnet for prædiktionsspredningen skrives som

$$s_{cv} = \sqrt{\frac{1}{n} \sum_{i=1}^n \left(x_i - \hat{x}_i^{(-i)} \right)^2}.$$

I *K-fold cross-validation* deler man datasættet op i K cirka lige store dele, og hver del er så efter tur testsættet. Opdelingen er tilfældig og kan eventuelt gentages en række gange.

I Figur 5.16a, hvor spredningsskønnet er illustreret, fremgår den grønne kurve fra en *leave-one-out cross-validation*. For j variable (hvor j er vist på førsteaksen i nævnte figur) foregår beregningen således: I trin i fjernes observation i fra datasættet. Dernæst udføres *forward*-selektion på de resterende $(n-1)$ observationer for at finde en model med j variable. Den multiple regressionsmodel estimeres derefter, og man laver en prædiktions for observation i , som netop ikke var med i træningssættet. Bidraget til prædiktionsvariansen beregnes som kvadratet af forskellen mellem den observerede og den prædikterede værdi. Dette gentages for $i = 1, \dots, n$. Til sidst beregner man kvadratroden af gennemsnittet af de n kvadrerede prædiktionsfejl.

Figur 5.16a indikerer, at efter man har inkluderet seks variable ved forward-selektion, sker der ikke længere en forbedring i modellens evne til at forudsige brixværdien i ferskner. Cross-validation fører altså i brix-eksemplet til et højere antal variable, end den formelle stopregel for forward-selektion, som blot giver to variable.


5.6.4 Prædiktions på nyt datasæt

For data omkring brixværdien i ferskner i de foregående afsnit brugte vi kun de 40 første ud af i alt 50 målinger i analysen. Vi kan derfor bruge de sidste 10 målinger som et testsæt til at vurdere den model vi er kommet frem til. Hvor vi i Afsnit 5.6.3 beregnede en prædiktionsspredning baseret på leave one out crossvalidation, kan vi her beregne en prædiktionsspredning baseret på de 10 sidste målinger.

På R-kode 5.38 vises beregningen for data omkring brixværdien i tilfældet med 4 forklarende variable fra forward selektion. Køres R-kode 5.38 fås at prædiktionsspredningen fra det uafhængige testsæt er 1.69. Vi fandt tidligere at prædiktionsspredningen fra crossvalidation var 2.14, og testsættet viser derfor ikke en yderligere afvigelse, end den der ses gennem crossvalidation.

Figur 5.20 viser Figur 5.16a med spredningskøn $s(M)$ (sort) og prædiktionsspredningen fra crossvalidation (grøn), og hvor nu også prædiktionsspredningen fra det uafhængige testsæt er inkluderet (gul).

For data omkring brixværdien ser vi, at kurven (gul kurve) baseret på de sidste 10 målinger generelt har et lidt atypisk forløb, idet den for op til 11 variable ligger under den sorte kurve. Den har et lokalt minimum for 3 variable, men en noget mindre værdi for 10 variable. Udover eventuelle særheder ved data kan dette afspejle, at kurven kun er baseret på 10 målinger.



Figur 5.20: Spredningsskønnet $s(M_j)$ som funktion af antal variable j . Den sorte kurve er det spredningsskøn på træningssettet, den grønne er baseret på cross-validation og den gule er spredningsskøn på testdata.

5.7 Multipel regression og lineære normal modeller

I dette afsnit vil vi uddybe sammenhængen mellem modellen for multipel regression som blev indført i Afsnit 5.5 og de lineære normale modeller fra Kapitel 5. Det viser sig, at de to begreber dækker over samme klasse af modeller, og formuleringen som multipel regression kan bruges til at forklare hvordan **R** beregner indholdet af parametertabellen.

I dette afsnit vil vi benytte en opskrivning af multipel regression, der afviger en smule fra (5.38). Konkret undlader vi at betragte afskæringen separat, hvilket i praksis er mere bekvemt notationsmæssigt. Modellen er

$$M_1 : X_i \sim N(t_{i1}\beta_1 + t_{i2}\beta_2 + \dots + t_{id}\beta_d, \sigma^2), \quad i = 1, \dots, n. \quad + \text{ uafhængighed.} \quad (5.41)$$

Hvis vi ønsker et afskæringsled som i (5.38), kan vi opnå dette ved at lade $\mathbf{t}_{(1)} = (1, 1, \dots, 1)^*$. Vi vil fortsat referere til $\mathbf{t}_{(j)}$ -erne som “forklarende variable”, selvom dette skal forstås en smule mere generelt end tidligere.

Lader vi $\boldsymbol{\beta}$ og $\mathbf{t}_i$ betegne vektorerne $\boldsymbol{\beta} = (\beta_1, \beta_2, \dots, \beta_d)^* \in \mathbb{R}^d$ og $\mathbf{t}_i = (t_{i1}, t_{i2}, \dots, t_{id})^* \in \mathbb{R}^d$ kan (5.41) skrives

$$X_i \sim N(\mathbf{t}_i^* \boldsymbol{\beta}, \sigma^2).$$

Betragter vi middelværdivektoren som blev indført i Afsnit 5.1 har vi

$$\boldsymbol{\mu} = \begin{pmatrix} \mathbf{t}_1^* \boldsymbol{\beta} \\ \vdots \\ \mathbf{t}_i^* \boldsymbol{\beta} \\ \vdots \\ \mathbf{t}_n^* \boldsymbol{\beta} \end{pmatrix} = \mathbf{T} \boldsymbol{\beta}, \quad (5.42)$$

hvor $\mathbf{T}$ er $n \times d$ matricen, hvis i -te række er $\mathbf{t}_i^*$, det vil sige

$$\mathbf{T} \stackrel{\text{def}}{=} \begin{pmatrix} \mathbf{t}_1^* \\ \vdots \\ \mathbf{t}_i^* \\ \vdots \\ \mathbf{t}_n^* \end{pmatrix}. \quad (5.43)$$

Vi vil antage at $d < n$ samt at $\mathbf{T}$ har fuld rang d . Matricen $\mathbf{T}$ kaldes en *designmatrix* eller en *modelmatrix*. Bemærk at $\mathbf{t}_{(j)}$ -erne som blev indført i (5.37) udgør søjlerne i $\mathbf{T}$:

$$\mathbf{T} = \{ \mathbf{t}_{(1)} \quad \mathbf{t}_{(2)} \quad \dots \quad \mathbf{t}_{(d)} \}. \quad (5.44)$$

Ved at kombinere (5.42) med opskrivningen af $\mathbf{T}$ fra (5.44) ses at

$$\boldsymbol{\mu} = \mathbf{T} \boldsymbol{\beta} = \mathbf{t}_{(1)} \beta_1 + \mathbf{t}_{(2)} \beta_2 + \dots + \mathbf{t}_{(d)} \beta_d,$$

således at når $\boldsymbol{\beta}$ varierer i $\mathbb{R}^d$, vil $\boldsymbol{\mu}$ variere i søjlerummet for $\mathbf{T}$ (jf. Afsnit A.2.3.3). Dette betyder, at den multiple regressionsmodel udgør en lineær normal model specificeret ved det lineære underrum $\text{col}(\mathbf{T})$. En multipel regressionsmodel er derfor en lineær normal model, og da man kan vise, at enhver lineær normal model kan formuleres som en multipel regressionsmodel, er de to modelklasser identiske.

Det følger, at modellen (5.41) kun afhænger af t_{ij} -erne gennem søjlerummet $\text{col}(\mathbf{T})$. To designmatricer, f.eks. $\mathbf{T}_1$ og $\mathbf{T}_2$, vil derfor specificere *samme* statistiske model, hvis $\text{col}(\mathbf{T}_1) = \text{col}(\mathbf{T}_2)$. Som det fremgår af eksemplerne nedenfor, svarer $\mathbf{T}_1$ og $\mathbf{T}_2$ da til forskellige *parametriseringer* af *samme* statistiske model.

I Kapitel 5 så vi, at for en lineær normal model, som er specificeret ved et lineært underrum L (dvs. $M : \boldsymbol{\mu} \in L$), gælder

$$\hat{\boldsymbol{\mu}} = P(\mathbf{x}) \quad \text{og} \quad \hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - P(\mathbf{x})\|^2,$$

hvor $P(\mathbf{x})$ er projektionen af $\mathbf{x}$ ned på L . Mere præcist er $P(\cdot)$ den *ortogonale* projektion på L . Vi så desuden i Kapitel 5, at F -testet for en reduktion fra én lineær normal model til en undermodel (jf. (5.14)) afhænger af projektionerne på de involverede underrum.

Da projektioner er lineære afbildninger kan de repræsenteres ved matricer, i den forstand at der eksisterer en matrix $\mathbf{P}$, således at $P(\mathbf{x}) = \mathbf{P}\mathbf{x}$. Det kan vises, at når $L = \text{col}(\mathbf{T})$, og søjlerne i $\mathbf{T}$ er

lineært uafhængige (hvilket vi antager), så gælder

$$\mathbf{P} = \mathbf{T} (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^*.$$

Flere egenskaber ved ortogonale projektioner er omtalt i Afsnit A.2.9.

Vi kan nu finde eksplicitte udtryk for $\hat{\boldsymbol{\mu}}$, $\hat{\sigma}^2$ og F -testet fra (5.14). For eksempel gælder

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - \mathbf{T} (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x}\|^2. \quad (5.45)$$

Vi gentager her, at udtrykket i (5.45) kun afhænger af $\mathbf{T}$ gennem søjlerummet $\text{col}(\mathbf{T})$. Hvis $\tilde{\mathbf{T}}$ er en anden matrix med $\text{col}(\mathbf{T}) = \text{col}(\tilde{\mathbf{T}})$, gælder

$$\mathbf{T} (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* = \tilde{\mathbf{T}} (\tilde{\mathbf{T}}^* \tilde{\mathbf{T}})^{-1} \tilde{\mathbf{T}}^*,$$

og dermed

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{x} - \tilde{\mathbf{T}} (\tilde{\mathbf{T}}^* \tilde{\mathbf{T}})^{-1} \tilde{\mathbf{T}}^* \mathbf{x}\|^2.$$

Derimod vil skønnet $\hat{\boldsymbol{\beta}}$ for $\boldsymbol{\beta}$ afhænge af den konkrete matrix $\mathbf{T}$, som vi vil se i eksemplerne herunder. Først udleder vi $\hat{\boldsymbol{\beta}}$.

Vi opskriver likelihood funktionen:

$$\begin{aligned} L(\boldsymbol{\beta}, \sigma^2) &= L(\beta_1, \beta_2, \dots, \beta_d, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2} (x_i - \mathbf{t}_i^* \boldsymbol{\beta})^2} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mathbf{t}_i^* \boldsymbol{\beta})^2} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \|\mathbf{x} - \mathbf{T}\boldsymbol{\beta}\|^2}, \end{aligned} \quad (5.46)$$

hvor sidste lighed følger af

$$\|\mathbf{x} - \mathbf{T}\boldsymbol{\beta}\|^2 = \left\| \begin{pmatrix} x_1 - \mathbf{t}_1^* \boldsymbol{\beta} \\ x_2 - \mathbf{t}_2^* \boldsymbol{\beta} \\ \vdots \\ x_n - \mathbf{t}_n^* \boldsymbol{\beta} \end{pmatrix} \right\|^2 = \sum_{i=1}^n (x_i - \mathbf{t}_i^* \boldsymbol{\beta})^2. \quad (5.47)$$

Som tidligere maksimeres L først for fastholdt σ^2 og som det fremgår af (5.46) betyder dette at vi ønsker at minimere $\|\mathbf{x} - \mathbf{T}\boldsymbol{\beta}\|^2$ med hensyn til $\boldsymbol{\beta}$. Vi definerer nu

$$\hat{\boldsymbol{\beta}} = (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x}. \quad (5.48)$$

Fra Afsnit A.2.10 har vi

$$\|\mathbf{x} - \mathbf{T}\boldsymbol{\beta}\|^2 = \|\mathbf{T}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})\|^2 + k,$$

hvor $k \in \mathbb{R}$ ikke afhænger af β . Heraf følger, at $\|\mathbf{x} - \mathbf{T}\beta\|^2$ minimeres, når $\mathbf{T}(\beta - \hat{\beta}) = \mathbf{0}$. Da $\mathbf{T}$ har fuld rang, sker dette kun, hvis $\beta = \hat{\beta}$, som altså er maksimum-likelihood-estimatet. Vi bemærker at

$$L(\beta, \sigma^2) \leq L(\hat{\beta}, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2}\|\mathbf{x} - \mathbf{T}\hat{\beta}\|^2},$$

og ved at anvende Lemma 2.2 fås

$$\hat{\sigma}^2 = \frac{1}{n}\|\mathbf{x} - \mathbf{T}\hat{\beta}\|^2,$$

i overensstemmelse med (5.45).

For at kunne anvende formler som (5.48) og (5.45) har vi brug for at kende $\mathbf{T}$. Vi ønsker derfor at finde designmatricer for de modeller, vi har gennemgået i de foregående kapitler. Her kan Kapitel 5 igen hjælpe. Vi observerer nemlig, at det er fælles for Eksemplerne 5.1–5.6, at L fremkommer som et lineært underrum udspændt af d søjlevektorer $\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(d)}$, alle i $\mathbb{R}^n$. Vi kan samle disse vektorer til en $n \times d$ designmatrix $\mathbf{T}$. Gør vi dette, bliver $\mathbf{T}$ -matricerne for de enkelte eksempler:

- En observationsrække (2.9) kan specificeres ved $\mathbf{T} = \mathbf{1}$, hvor $\mathbf{1}$ blev defineret i Eksempel 5.1.
- To observationsrækker (3.9) kan specificeres ved $\mathbf{T} = \{\mathbf{1}_1 \quad \mathbf{1}_2\}$ hvor $\mathbf{1}_1$ og $\mathbf{1}_2$ blev defineret i Eksempel 5.3
- k observationsrækker (3.28) kan specificeres ved $\mathbf{T} = \{\mathbf{1}_1 \quad \mathbf{1}_2 \quad \dots \quad \mathbf{1}_k\}$ hvor $\mathbf{1}_i$ erne blev defineret i Eksempel 5.4
- Simpel lineær regression (4.1) kan specificeres ved $\mathbf{T} = \{\mathbf{1} \quad \mathbf{t}\}$ hvor $\mathbf{t}$ blev defineret i Eksempel 5.6

Flere eksempler findes i appendikset til dette afsnit. Her demonstrerer vi også, at **R** kan give den benyttede designmatrix for en givet fittet model via funktionen **model.matrix**.

Som nævnt kan forskellige designmatricer specificere samme model, hvilket kan illustreres ved hjælp af Eksempel 5.3 med to observationsrækker, dvs. modellen M_1 fra (3.9). I (5.49) vises to designmatricer, $\mathbf{T}$ og $\tilde{\mathbf{T}}$, der begge specificer modellen (3.9):

$$\mathbf{T} = \{\mathbf{1}_1 \quad \mathbf{1}_2\} = \left\{ \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 0 & 1 \\ \vdots & \vdots \\ 0 & 1 \end{pmatrix} \right\} \quad \tilde{\mathbf{T}} = \{\mathbf{1} \quad \mathbf{1}_2\} = \left\{ \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{pmatrix} \right\} \quad \left. \begin{matrix} \left. \begin{matrix} \left. \begin{matrix} \vdots & \vdots \end{matrix} \right\} \right\} n_1 \text{ gange} \\ \left. \begin{matrix} \vdots & \vdots \end{matrix} \right\} n_2 \text{ gange} \end{matrix} \right\} \quad (5.49)$$

De to forskellige designmatricer svarer til to forskellige parametriseringer af modellen. Dette ses ved i første omgang at antage at $n_1 = n_2 = 1$.

I dette tilfælde kommer (5.42) til at svare til henholdsvis

$$\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} = \begin{Bmatrix} 1 & 0 \\ 0 & 1 \end{Bmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} \quad \text{og} \quad \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} = \begin{Bmatrix} 1 & 0 \\ 1 & 1 \end{Bmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix},$$

og vi ser af ligheden til venstre, at $\boldsymbol{\mu} = \mathbf{T}\boldsymbol{\beta}$ svarer til

$$\beta_1 = \mu_1 \quad \text{og} \quad \beta_2 = \mu_2.$$

Dette kaldes “middelværdi-parametriseringen”. Her vil $H : \beta_2 = 0$ svare til hypotesen $\mu_2 = 0$. Derimod vil $\boldsymbol{\mu} = \tilde{\mathbf{T}}\boldsymbol{\beta}$ for ligheden til højre svare til

$$\beta_1 = \mu_1 \quad \text{og} \quad \beta_2 = \mu_2 - \mu_1,$$

og kaldes “effekt-parametriseringen”. Som det ses, svarer $H : \beta_2 = 0$ til $H_{0\mu} : \mu_1 = \mu_2$.

Bemærk endvidere, at $\tilde{\mathbf{T}}$ indeholder et interceptled, mens $\mathbf{T}$ ikke gør det. Dette stemmer overens med, at $\tilde{\mathbf{T}}$ svarer til den parametrisering, der blev beskrevet i (5.27) – som $\mathbf{R}$ benytter som standard – mens $\mathbf{T}$ svarer til den parametrisering, der anvendes af $\mathbf{R}$, når vi eksplicit fjerner interceptleddet ved at skrive 0 i modelformlen.

Vi dropper nu antagelsen om at $n_1 = n_2 = 1$ og beregner for illustrationens skyld maksimum likelihood estimaterne for regressionsparametrene ud fra de to designmatricer.

$$\begin{aligned} \mathbf{T}^*\mathbf{T} &= \begin{Bmatrix} n_1 & 0 \\ 0 & n_2 \end{Bmatrix} \quad \text{så} \quad (\mathbf{T}^*\mathbf{T})^{-1} = \begin{Bmatrix} \frac{1}{n_1} & 0 \\ 0 & \frac{1}{n_2} \end{Bmatrix}. \\ \tilde{\mathbf{T}}^*\tilde{\mathbf{T}} &= \begin{Bmatrix} n_1 + n_2 & n_2 \\ n_2 & n_2 \end{Bmatrix} \quad \text{så} \quad (\tilde{\mathbf{T}}^*\tilde{\mathbf{T}})^{-1} = \begin{Bmatrix} \frac{1}{n_1} & -\frac{1}{n_1} \\ -\frac{1}{n_1} & \frac{1}{n_1} + \frac{1}{n_2} \end{Bmatrix}. \end{aligned}$$

Lader vi nu $\mathbf{x} = (x_{11}, \dots, x_{1n_1}, x_{21}, \dots, x_{2n_2})^*$ betegne datasættet og $\hat{\beta}$ og $\hat{\tilde{\beta}}$ betegne estimaterne svarende til henholdsvis $\mathbf{T}$ og $\tilde{\mathbf{T}}$ så

$$\hat{\beta} = (\mathbf{T}^*\mathbf{T})^{-1}\mathbf{T}^*\mathbf{x} = \begin{Bmatrix} \frac{1}{n_1} & 0 \\ 0 & \frac{1}{n_2} \end{Bmatrix} \begin{pmatrix} x_{1\cdot} \\ x_{2\cdot} \end{pmatrix} = \begin{pmatrix} \bar{x}_{1\cdot} \\ \bar{x}_{2\cdot} \end{pmatrix}, \quad (5.50)$$

$$\hat{\tilde{\beta}} = (\tilde{\mathbf{T}}^*\tilde{\mathbf{T}})^{-1}\tilde{\mathbf{T}}^*\mathbf{x} = \begin{Bmatrix} \frac{1}{n_1} & -\frac{1}{n_1} \\ -\frac{1}{n_1} & \frac{1}{n_1} + \frac{1}{n_2} \end{Bmatrix} \begin{pmatrix} x_{1\cdot} + x_{2\cdot} \\ x_{2\cdot} \end{pmatrix} = \begin{pmatrix} \bar{x}_{1\cdot} \\ \bar{x}_{2\cdot} - \bar{x}_{1\cdot} \end{pmatrix}. \quad (5.51)$$

Dette er igen i overensstemmelse med, hvad vi tidligere har set, da vi betragtede parametertabellen for k observationsrækker. Når der er et interceptled i modellen, giver $\mathbf{R}$ estimatet for μ_1 under (Intercept) og dernæst estimatet af differensen $\mu_2 - \mu_1$, hvilket stemmer overens med (5.51). Fjerner man derimod interceptleddet, vil $\mathbf{R}$ i stedet angive estimaterne for μ_1 og μ_2 .

Vi afslutter dette kapitel med en række fordelingsresultater. Beviser for resultaterne er skitseret i Afsnit A.3.7.

Som i tidligere tilfælde er maksimumlikelihood estimatoren for variansen ikke middelværdiret, men hvis vi betragter estimatoren svarende til

$$s^2 = \frac{1}{n-d} \|\mathbf{x} - \mathbf{T}\hat{\boldsymbol{\beta}}\|^2, \quad (5.52)$$

så vil

$$s^2 \sim \sigma^2 \chi^2(n-d)/(n-d),$$

således at (5.52) vil være et middelværdiret skøn over σ^2 . I Afsnit A.3.7 vises det også at maksimum likelihood estimatoren $\hat{\boldsymbol{\beta}} = (\mathbf{T}^*\mathbf{T})^{-1}\mathbf{T}^*\mathbf{X}$ opfylder at

$$\hat{\boldsymbol{\beta}} \sim N_d(\boldsymbol{\beta}, \sigma^2(\mathbf{T}^*\mathbf{T})^{-1}),$$

hvilket vil sige at $\hat{\boldsymbol{\beta}}$ er *d-dimensionalt normalfordelt* med middelværdivektor $\boldsymbol{\beta}$ og kovariansmatrix $\sigma^2(\mathbf{T}^*\mathbf{T})^{-1}$. Det, som er væsentligt i denne sammenhæng, er at vi derudfra kan angive fordelingen til estimatoren for den j te regressionskoefficient. Idet vi betegner det (i, j) te element i $(\mathbf{T}^*\mathbf{T})^{-1}$ med c^{ij} gælder der

$$\hat{\beta}_j \sim N(\beta_j, \sigma^2 c^{jj}). \quad (5.53)$$

Det vises også i Afsnit A.3.7 at s^2 er uafhængig af $\boldsymbol{\beta}$ og under $H_0 : \beta_j = 0$ gælder derfor at

$$t_j = \frac{\hat{\beta}_j}{\sqrt{s^2 c^{jj}}} \sim t(n-d), \quad (5.54)$$

hvilket kan benyttes til at teste hypotesen H_0 . Når vi udskriver parametertabellen fra **summary** vil **R** for hver regressionskoefficient β_j , både angive estimatet, $\hat{\beta}_j$, skøn over spredningen på estimatet,

$$\text{std error}(\hat{\beta}_j) = \sqrt{s^2 c^{jj}}, \quad (5.55)$$

t teststørrelsen (5.54), samt testsandsynligheden for $H : \beta_j = 0$

$$p_{obs} = 2(1 - F_{t(n-d)}(|t_j|)), \quad (5.56)$$


hvor $F_{t(n-d)}$ betegner fordelingsfunktionen for t fordelingen med $n-d$ frihedsgrader.

Ved hjælp af ovenstående resultater kan vi undersøge hypoteser vedrørende individuelle regressionskoefficienter. Ønsker man at teste andre hypoteser, kan man udnytte, at multiple regressionsmodeller er lineære normale modeller (som defineret i Kapitel 5), og bruge resultaterne derfra til modelreduktion.

5.7.1 Polynomiel regression

Som det fremgår af (5.41), er en grundlæggende antagelse i regression, at middelværdien afhænger lineært af de forklarende variable. Dette udelukker dog ikke, at *ikke-lineære funktioner* af de forklarende variable kan indgå, hvilket vi nu vil illustrere med *polynomiel regression*. Figur 5.21 viser et scatterplot fra et simuleret datasæt med to variable t og x . Her er der simuleret $n = 30$ uafhængige observationer via

$$X = 3t^2 - 2t - 1 + N(0, 1),$$



Figur 5.21: Scatterplot af data med kvadratisk tendens.

x	t	t^2
3.37	-1.00	1.00
3.65	-0.93	0.87
2.12	-0.86	0.74
$\vdots$	$\vdots$	$\vdots$
0.42	1.00	1.00


Tabel 5.14: Samhørende værdier af x og t samt t^2 for et simuleret datasæt.

således at den “sande sammenhæng” mellem x og t er kvadratisk. En del af datasættet er gengivet i Tabel 5.14, hvor der ligeledes er angivet værdier af t^2 .

Pointen er nu, at man kan lade t^2 indgå som en forklarende variabel, og fordi polynomier er lineære i deres koefficienter, får vi derved en *multiple* regressionsmodel. Fra R-udskrift 5.48 kan vi aflæse de estimerede koefficienter, og vi ser, at det estimerede andengradspolynomium er

$$f(t) = -0.7094 - 2.1689t + 2.4160t^2,$$

samt at koefficienten til t^2 er signifikant. Figur 5.22a viser datasættet sammen med det estimerede andengradspolynomium. Det er naturligt at spørge, om man kan fitte højere-ordens polynomier, og det kan man i princippet, op til en grænse givet ved antallet af observerede datapunkter. Som vi også tidligere har omtalt, kan problemet med *overfitting* dog opstå, hvis man betragter modeller med mange forklarende variable, da modellen derved begynder at tilpasse sig støjen i data. I Figur 5.22b er et fittet 10.-gradspolynomium indtegnet, hvilket illustrerer dette fænomen.



(a) Datasæt fra Tabel 5.14 med indtegnet estimeret 2.gradspolynomie. (b) Datasæt fra Tabel 5.14 med indtegnet estimeret 10.-gradspolynomie.

Figur 5.22: Estimeret anden- og tiendegradspolynomium fittet til simuleret data. Vi vil sige at tiendegradspolynomiet overfitter.

I appendikset viser vi, hvordan man i praksis inkluderer funktioner af de forklarende variable i **R**.

5.7.1.1 Multiple R-squared.

For fuldstændighedens skyld vises her formlerne for *Multiple R-squared* og *adjusted Multiple R-squared*, som **R** udskriver som en del af parametertabellen. *Multiple R-squared* omtales desuden ofte som den *multiple korrelationskoefficient*.

I (3.32) så vi en dekomposition af $SSD_T = \sum_{i=1}^n (x_i - \bar{x})^2$ i to dele: én del, som var den andel af variationen, modellen for k observationsrækker kunne forklare, og en del kaldet uforklaret variation. I (5.12) mødte vi en tilsvarende dekomposition for lineære normale modeller. Lader vi $\hat{\mathbf{x}} = \mathbf{T}\hat{\beta}$ betegne de prædikterede værdier i en multipel regressionsmodel, har vi

$$SSD_T = SSD_E + SSD_H,$$

hvor

$$SSD_E = \sum_{i=1}^n (x_i - \hat{x}_i)^2 \quad \text{og} \quad SSD_H = \sum_{i=1}^n (\hat{x}_i - \bar{x})^2.$$

Da SSD_T er den totale variation, SSD_H er den forklarede variation, og SSD_E er den uforklarede variation, kan vi definere *Multiple R-squared* som

$$R^2 = \frac{SSD_H}{SSD_T} = 1 - \frac{SSD_E}{SSD_T}.$$

I R-udskrifterne findes også *Adjusted R-squared*. Denne findes ved at dividere SSD_H og SSD_T med de tilsvarende antal frihedsgrader,

$$R_{\text{adj}}^2 = 1 - \frac{\frac{SSD_E}{n-d}}{\frac{SSD_T}{n-1}}.$$

Når der kun er én forklarende variabel er R^2 lig kvadratet på den empiriske korrelationskoefficient mellem responsvariablen og den forklarende variabel.

Appendiks til Afsnit 5.7

Beregninger i R

I Afsnit 4.1.6 regnede vi estimater og residualer ud ved hjælp af eksplicitte formler, som vi havde til rådighed for simpel lineær regression. I dette afsnit bruger vi **R** til at beregne disse størrelser ud fra en fittet *multiple* regressionsmodel. Vi betragter det indbyggede datasæt `trees`. I R-kode 5.27 oprettes de logaritme transformerede variable, og vi fitter M_1 fra (5.39).

R-kode 5.27

```
trees$LogDiameter = log(trees$Girth)
trees$LogHeight = log(trees$Height)
trees$LogVolume = log(trees$Volume)
lmfit <- lm(LogVolume ~ LogDiameter + LogHeight, data=trees)
```

For at tegne kontroltegningerne fra Figur 5.15 skal vi beregne residualer, prædikterede værdier og studentiserede skalerede residualer. Disse beregnes ved hjælp kommandoerne **residuals**, **predict** og **rstandard** som det fremgår på R-kode 5.28.

R-kode 5.28

```
residualer <- residuals(lmfit)
prædikterede_værdier <- predict(lmfit)
stud_resid <- rstandard(lmfit)
```

Disse kan nu bruges sammen med **plot** og **qqnorm**.

Parameterestimater og tilhørende tests fås ved at køre **summary(lmfit)**. Outputtet findes på R-udskrift 5.31.

R-udskrift 5.31

```
Call:
lm(formula = LogVolume ~ LogDiameter + LogHeight, data = trees)

Residuals:
    Min       1Q   Median       3Q      Max
-0.168561 -0.048488  0.002431  0.063637  0.129223

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -6.63162     0.79979  -8.292 5.06e-09 ***
LogDiameter  1.98265     0.07501  26.432 < 2e-16 ***
LogHeight    1.11712     0.20444   5.464 7.81e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.08139 on 28 degrees of freedom
Multiple R-squared: 0.9777, Adjusted R-squared: 0.9761
F-statistic: 613.2 on 2 and 28 DF, p-value: < 2.2e-16
```

Hvis vi ønsker at lave konfidens- og prædiktionsintervaller skal vi først lave et nyt datasæt, og der efter bruge dette som input til **predict** funktionen, som det er gjort i R-kode 5.29.

R-kode 5.29

```
nytData = data.frame(LogDiameter=c(2.5,2.2),LogHeight=c(4.3,4.1))
predict(lmfit,nytData,interval="confidence")
predict(lmfit,nytData,interval="prediction")
```

Outputtet fra R-kode 5.29 findes i Tabel 5.12 og er taget fra R-udskrift 5.32.

R-udskrift 5.32

```
> predict(lmfit,nytData,interval="confidence")
      fit      lwr      upr
1 3.128638 3.097052 3.160224
2 2.310418 2.224244 2.396593
> predict(lmfit,nytData,interval="prediction")
      fit      lwr      upr
1 3.128638 2.958960 3.298316
2 2.310418 2.122752 2.498085
```

R-kode til model selektion

Vi begynder med *backward*-selektion. Funktionen **step** kan anvendes til en variant af backward-selektion, men gennemfører metodens skridt ved hjælp af de rutiner, som vi allerede kender.

Data til Eksempel 5.10 indlæses fra filen *co2data.csv* til datasættet `co2data`. Køres **head(co2data)** fås

R-udskrift 5.33

	Temp	C	S	V	E
1	8	336.6667	1366.433	0.9283333	0.075
2	19	338.5000	1366.517	0.9300000	0.375
3	26	340.0000	1366.517	0.9300000	-0.250
4	4	341.3333	1366.167	0.8533333	0.450
5	25	342.6667	1366.183	0.8975000	1.225
6	9	344.1667	1365.717	0.9166667	-0.500

Som det fremgår indeholder `Temp` værdierne af temperaturmålingerne og navngivningen af de andre variable følger beskrivelsen på side 143. På R-kode 5.30 standardiseres variablene og vi indfører deres produkter som i (5.40), hvorefter den fulde model fittes til data

R-kode 5.30

```
C = co2data$C; S = co2data$S; V = co2data$V; E = co2data$E; Temp =
  co2data$Temp;
C=(C-mean(C))/sd(C)
S=(S-mean(S))/sd(S)
V=(V-mean(V))/sd(V)
E=(E-mean(E))/sd(E)

CS=C*S; CV=C*V; CE=C*E; SV=S*V; SE=S*E; VE=V*E

lmfit <- lm(Temp ~ C + S + V + E + C + S + CV + CE + SV + SE + VE )
summary(lmfit)
```

Parametertabellen fra R-kode 5.30 findes på R-udskrift 5.34.

R-udskrift 5.34

Coefficients:					
	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	30.363	1.803	16.841	1.13e-13	***
C	15.464	1.547	9.996	1.95e-09	***
S	8.067	1.766	4.568	0.000167	***
V	14.453	4.371	3.307	0.003358	**
E	5.542	1.202	4.610	0.000151	***
CS	-1.156	1.025	-1.128	0.272145	
CV	3.602	2.151	1.674	0.108935	
CE	1.609	1.434	1.122	0.274616	
SV	-10.760	4.106	-2.620	0.015984	*
SE	1.424	1.315	1.083	0.291211	
VE	1.200	2.320	0.517	0.610266	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1					
Residual standard error: 5.506 on 22 degrees of freedom					
Multiple R-squared: 0.9359, Adjusted R-squared: 0.9097					
F-statistic: 35.71 on 9 and 22 DF, p-value: 4.351e-11					

Det fremgår af R-udskrift 5.34 at t -testet svarende β_{VE} har den største p -værdi og `VE` fjernes fra modelformlen, hvorefter modellen fittes igen:

R-kode 5.31

```
lmfit = lm(Temp ~ C + S + V + E + C + S + CV + CE + SV + SE)
summary(lmfit)
```

Den nye parametertabel bliver:

R-udskrift 5.35

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   29.829      1.454   20.521 7.78e-16 ***
C              15.164      1.410   10.756 3.15e-10 ***
S              7.884      1.701    4.634 0.000128 ***
V             15.870      3.349    4.739 9.93e-05 ***
E              5.796      1.079    5.372 2.15e-05 ***
CS             -1.176      1.007   -1.168 0.255315
CV              4.049      1.937    2.090 0.048362 *
CE              1.924      1.277    1.507 0.145968
SV            -10.844      4.034   -2.688 0.013432 *
SE              1.432      1.293    1.107 0.280072
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.381 on 22 degrees of freedom
Multiple R-squared:  0.9388,    Adjusted R-squared:  0.9138
F-statistic: 37.52 on 9 and 22 DF,  p-value: 2.645e-11
```

Ovenstående fortsættes indtil ingen p -værdier er større end 0.05. På R-kode 5.32 fittes den fundne slutmodel og vi finder den tilknyttede parametertabel.

R-kode 5.32

```
lm Slut <- lm(Temp ~ C + S + V + E + SV)
summary(lm Slut)
```

Til slut beregnes også p -værdien for reduktionen fra den fulde model (startmodellen) til slutmodellen. Dette gøres ved at fitte startmodellen (igen) og benytte **anova**

R-kode 5.33

```
lmstart <- lm(Temp ~ C + S + V + E + CS + CV + CE + SV + SE + VE)
anova(lm Slut, lmstart)
```

Output fra R-kode 5.32 findes på R-udskrift 5.36 og output fra R-kode 5.33 findes på R-udskrift 5.37.

R-udskrift 5.36

```

Call:
lm(formula = Temp ~ C + S + V + E + SV)

Residuals:
    Min       1Q   Median       3Q      Max
-9.2880 -3.4259 -0.3515  4.4085 10.4484

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   31.533      1.322   23.862 < 2e-16 ***
C              16.167      1.363   11.859 5.45e-12 ***
S              6.899      1.697    4.065 0.000394 ***
V             12.352      3.050    4.050 0.000410 ***
E              5.722      1.152    4.967 3.66e-05 ***
SV            -10.452      4.272   -2.447 0.021492 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.761 on 26 degrees of freedom
Multiple R-squared:  0.9171,    Adjusted R-squared:  0.9012
F-statistic: 57.54 on 5 and 26 DF,  p-value: 3.126e-13

```

R-udskrift 5.37

```

Analysis of Variance Table

Model 1: Temp ~ C + S + V + E + SV
Model 2: Temp ~ C + S + V + E + CS + CV + CE + SV + SE + VE
  Res.Df    RSS Df Sum of Sq    F Pr(>F)
1      26 862.99
2      21 628.90  5      234.1 1.5634 0.2137

```

Forward-selektion i R

Der findes indbyggede funktioner i **R**, der kan bruges til at foretage forward-selektion, blandt andet **add1** og **step**, men vi benytter en “hjemmestrikket” funktion.

I filen *Rfunktioner.txt* findes funktionen **forward**, som udfører beregninger til et enkelt trin i forward-selektion. Funktionen har som input en $n \times d$ matrix, der rummer værdierne af de d forklarende variable for n prøver, en vektor med responsværdierne samt en vektor med numrene på de variable, der allerede er inkluderet i modellen. Hvis matricen hedder **bT** og responsvektoren **x**, starter man med kaldet **forward(bT, x)**. Fra output ses, hvilken variabel man vil starte med at inkludere i modellen, og næste kald til funktionen bliver **forward(bT, x, c(j₁))**, hvor j_1 er nummeret på den valgte variabel. Efter at variabelen j_1 er inkluderet, finder man det næste led ved kaldet **forward(bT, x, c(j₁))** igen, derefter **forward(bT, x, c(j₁, j₂))**, osv.

Outputtet fra et kald til **forward** er spredningsskønnet $s(M)$ fra den multiple regressionsmodel, efter at et nyt led er tilføjet (dvs. et led mere end i det forrige kald til **forward**), en vektor med numrene på de variable i modellen samt en vektor med p -værdierne for test af, om en regressionskoefficient er nul. Det er den sidste indgang i p -værdivektoren, man benytter til at bestemme, om man vil beholde det sidst fundne led i modellen, og dermed om man fortsætter *forward*-selektionsproceduren.

På R-kode 5.34 hentes datasættet fra filen *peachspec.csv*, hvorefter de forklarende variable gemmes i `spec`, idet vi som nævnt i Afsnit 5.6.2 kun benytter de første 40 variable. Responsvektoren er første søjle i *peachspec.csv* og denne gemmes i `brix`.

Derefter køres **forward** med henblik på at udvælge første forklarende variabel til modellen.

R-kode 5.34

```
dat <- read.csv("peachspec.csv")

obsrange = 1:40
spec = as.matrix(dat[obsrange, 2:601])
brix = dat[obsrange, 1]

forward(spec, brix)
```

Output fra 5.34 findes på R-udskrift 5.38

R-udskrift 5.38

```
$sny
[1] 2.15689

$med
[1] 151

$pval
      [,1]
Intercept 7.089108e-05
X          1.794433e-02
```

Af R-udskrift 5.38 fremgår det, at den første variabel, der skal inkluderes, svarer til søjle nummer 151 i `spec`. Når denne variabel er medtaget i modellen, er p -værdien for testet, om den tilhørende regressionskoefficient er nul, 0.0179. Derefter fortsætter *forward*-selektionsproceduren med denne variabel ved at kalde **forward**, som vist i R-kode 5.35.

R-kode 5.35

```
forward(spec, brix, c(151))
```

Output fra R-kode 5.35 findes på R-udskrift 5.39, hvor det fremgår at næste variabel der inkluderes er nummer 221.

R-udskrift 5.39

```
$sny
[1] 1.814245

$med
[1] 151 221

$pval
      [,1]
Intercept 1.180563e-07
wl151      1.296450e-05
wl221      2.250705e-04
```

Vi bemærker spredningskønnet falder relativt meget fra R-udskrift 5.38 til 5.39 og at begge de inkluderede variable er signifikante. Køres et skridt mere ved hjælp af

R-kode 5.36

```
forward(spec,brix,c(151,221))
```

fås

R-udskrift 5.40

```
$sny
[1] 1.833239

$med
[1] 151 221 1

$pval
      [,1]
Intercept 2.493936e-02
wl151      1.537318e-05
wl221      3.195670e-04
wl1        6.291458e-01
```

Vi bemærker, at spredningsskønnet stiger en anelse fra R-udskrift 5.39 til R-udskrift 5.40, og at p -værdien for den nyinkluderede variabel (som viser sig at være nummer 1) er 0.629. Derfor kunne man vælge at standse forward-selektionen allerede med to variable, men som omtalt i Afsnit 5.6.2 er der gode argumenter for at fortsætte.

Cross-validation i R

For at udføre *leave-one-out-crossvalidation* for en forward-selektionsmodel med et givet antal variable (som beskrevet i Afsnit 5.6.3) benytter vi funktionen **cvForward**, der findes i *Rfunktioner.txt*. Funktionens input er den $n \times d$ matrix, som rummer de forklarende variable for n prøver, en vektor med responsværdierne samt et tal, der angiver antallet af led, der skal medtages i *forward-selektionen*.

I R-kode 5.37 nedenfor kaldes funktionen med værdien 3 for antallet af led som skal medtages i forward-selektionsmodellen. Outputtet fra **cvForward** er en vektor med *prædiktionsspredningen*, beregnet ved *leave-one-out-crossvalidation*, når man medtager henholdsvis 1, 2 og 3 variable i forward-selektionen (hvor 3 var den værdi, man angav i kaldet). Bemærk, at det kan tage noget tid at køre **cvForward**.

R-kode 5.37

```
cvForward(spek,brix,3)
```

R-udskrift 5.41

```
[1] 2.322577 1.985431 2.029210
```

Dette er de første 3 punkter på den grønne kurve i Figur 5.16a.

Afslutningsvis ønsker vi at lave en prædiktions på et testdatasæt. Vi benytter den model med fire valgte forklarende variable (151, 221, 1, 384), som blev fundet ved hjælp af forward-selektion. For at gøre dette anvendes **predict**, idet vi først definerer trænings- og testdata ud fra **dat**, som blev indlæst i R-kode 5.34.

R-kode 5.38

```
traindat <- dat[1:40,]
testdat <- dat[41:50,]
lmfit <- lm(brix~w1151+w1221+w11+w1384,data=traindat)
prædiktioner <- predict(lmfit,testdat)
sqrt(mean((testdat$Brix-prædiktioner)^2))
```

Køres R-kode 5.38 beregnes prædiktionsspredningen på det uafhængige testsæt til 1.689891.

Designmatricen i R

I Afsnit 5.7 defineres *designmatricen* $\mathbf{T}$. I R kan man beregne designmatricen ved at bruge kommandoen `model.matrix()`.

Denne kommando kan enten køres på en fittet model via `model.matrix(lmfit)`, eller på en modelformel, som vi gør i R-kode 5.39. Her definerer vi først en faktor med to niveauer og beder dernæst R om at beregne `model.matrix()` ud fra en modelformel, der specificerer en model med to observationsrækker. Vi behøver ingen responsvariabel, da denne jo alligevel ikke vil indgå i designmatricen.

R-kode 5.39

```
fac1 <- factor(c("A", "A", "B", "B", "B"))
model.matrix(~fac1)
```

En del af outputtet ovenstående findes i R-udskrift 5.42 og kan sammenlignes med $\tilde{\mathbf{T}}$ fra (5.49).

R-udskrift 5.42

	(Intercept)	facB
1	1	0
2	1	0
3	1	1
4	1	1
5	1	1

Interceptleddet kan fjernes ved i stedet at kalde `model.matrix(~0+fac1)` og output vil da være som i R-udskrift 5.43. I dette tilfælde sammenlignes med $\mathbf{T}$ fra (5.49).

R-udskrift 5.43

	fac1A	fac1B
1	1	0
2	1	0
3	0	1
4	0	1
5	0	1

På R-kode 5.40 definerer vi en kontinuert variabel, som vi herefter bruger til beregne en designmatrix der vil svare til simpel lineær regression.

R-kode 5.40

```
bt = c(1.1, 2.0, 3.2, 4.5, 5.0)
model.matrix(~bt)
```

Designmatricen bliver da

R-udskrift 5.44

	(Intercept)	bt
1	1	1.1
2	1	2.0
3	1	3.2
4	1	4.5
5	1	5.0

Som forventet fås søjlerne **1** og **t**. I R-kode 5.41 defineres to vektorer, som derefter bruges som forklarende variable i sig selv, sammen med leddet `exp(bt1)`, der – som det fremgår af R-udskrift 5.45 – beregner eksponentialfunktionen af den første variabel:

R-kode 5.41

```
bt1 = c(0.0, 1.0, 3.2, 4.5, 5.0)
bt2 = c(3.1, 3.0, 2.6, 5.0, 5.0)
model.matrix(~bt1 + bt2 + exp(bt1))
```

R-udskrift 5.45

	(Intercept)	bt1	bt2	exp(bt1)
1	1	0.0	3.1	1.000000
2	1	1.0	3.0	2.718282
3	1	3.2	2.6	24.532530
4	1	4.5	5.0	90.017131
5	1	5.0	5.0	148.413159

Ved at sammenligne designmatricerne fra R-udskrift 5.42 til R-udskrift 5.45 kan vi se et generelt princip for de modeller som vi betragter:

- Hvis **R** i modelformlen ser en *kontinueret* forklarende variabel, tilføjes én søjle til designmatricen, som indeholder værdierne af den pågældende variabel.
- Hvis **R** ser en *faktor* som forklarende variabel, vil den *som udgangspunkt* tilføje et antal søjler svarende til antallet af niveauer for den pågældende faktor.

Bemærk dog, at **R** stadig kræver, at designmatricen har fuld rang. Derfor vil **R** om nødvendigt fjerne én eller flere søjler. Dette ses eksempelvis i designmatricen fra R-udskrift 5.42, hvor de søjler, der fjernes, bliver dem, som specificerer *referencegruppen*.

Ovenstående princip ses også, når vi introducerer vi en ny faktor og angiver modelformlen for additivitetsmodellen i tosidet variansanalyse:

R-kode 5.42

```
fac1 <- factor(c("A", "A", "B", "B", "B"))
fac2 <- factor(c("C", "C", "C", "D", "D"))
model.matrix(~fac1+fac2)
```

Designmatricen bliver da som vist i R-udskrift 5.46, og vi ser, at denne stemmer overens med parametertabellen fra R-udskrift 5.12.

R-udskrift 5.46

	(Intercept)	fac1B	fac2D
1	1	0	0
2	1	0	0
3	1	1	0
4	1	1	1
5	1	1	1

Som det sidste eksempel vil vi vise en designmatrix, der svarer til gruppespecifik regression.

R-kode 5.43

```
fac1 <- factor(c("A", "A", "B", "B", "C"))
bt = c(1.1, 2.0, 3.2, 4.5, 5.0)
model.matrix(~fac1 + bt + fac1:bt)
```

R-udskrift 5.47

	(Intercept)	fac1B	fac1C	bt	fac1B:bt	fac1C:bt
1	1	0	0	1.1	0.0	0
2	1	0	0	2.0	0.0	0
3	1	1	0	3.2	3.2	0
4	1	1	0	4.5	4.5	0
5	1	0	1	5.0	0.0	5

Her bemærker vi, at interaktionsleddet `fac1:bt` tilføjer et led for hvert niveau af faktorvariablen, hvor værdien af den kontinuerte variabel ganges på. Dog udelades leddet, der svarer til referencegruppen, da matricen ellers ikke ville have fuld rang.

5.7.2 Polynomiel regression i R

Datasættet, der gennemgås i Afsnit 5.7.1, er genereret ved hjælp af R-kode 5.44.

R-kode 5.44

```
set.seed(1)
n = 30
bt = seq(from = -1,to=1,length.out=n)
bx = 3*bt^2-2*bt-1 + rnorm(n)
```

Når vi skal fitte modellen for polynomiel regression, skal vi beregne kvadraterne på `bt`. En mulighed er at gøre dette med `bt^2` og gemme resultatet som en ny variabel. Vi kan også tilføje `bt^2` direkte til modelformlen, men hvis dette gøres, skal vi benytte `I()`-funktionen, som vist i R-kode 5.45. Dette skyldes, at R har flere forskellige måder at fortolke symbolet `^` på i en modelformel, og ved at tilføje `I()` sikrer vi, at R opfatter `^` som en aritmetisk operation.

R-kode 5.45

```
lmfit <- lm(bx~bt+I(bt^2))
```

Køres `summary(lmfit)` fås

R-udskrift 5.48

```
Call:
lm(formula = bx ~ bt + bt^2 + I(bt^2))

Residuals:
    Min       1Q   Median       3Q      Max
-2.5165 -0.4587  0.1577  0.6649  1.5381

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.7094     0.2553  -2.779  0.009814 **
bt           -2.1689     0.2849  -7.613  3.45e-08 ***
I(bt^2)       2.4160     0.5345   4.520  0.000111 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9314 on 27 degrees of freedom
Multiple R-squared:  0.7438,    Adjusted R-squared:  0.7248
F-statistic: 39.2 on 2 and 27 DF,  p-value: 1.036e-08
```

Datakilder til Eksempel 5.10

Fremstillingen i eksempel 5.10 er som nævnt inspireret af artiklen [Using Data from Climate Science to Teach Introductory Statistics](#). Data for temperatur, solens udstråling og CO₂ er taget fra artiklen, men stammer oprindeligt for temperaturens vedkommende fra [NASA Goddard Institute for Space Studies \(GISS\)](#), data for solens udstråling stammer fra [The Physikalisch-Meteorologisches Observatorium Davos/World Radiation Center](#), og data for CO₂ stammer fra [Earth System Research Laboratory of the National Oceanic and Atmospheric Administration \(NOAA\)](#). Data for vulkanaktivitet og el Nino effekten er ikke givet i artiklen, men der er givet links til data. Data for vulkanaktivitet er fra [Earth System Research Laboratories](#) og data for el Nino effekten er fra [Climate Prediction Center](#).

Kapitel 6

Statistisk analyse

Dette kapitel indeholder en beskrivelse af de vigtigste ingredienser i en statistisk analyse samt en præsentation af de basale matematiske og/eller filosofiske begreber, der ligger til grund for de statistiske metoder, vi beskæftiger os med på dette kursus. Formålet med kapitlet er at fremstille de grundlæggende begreber og idéer så overskueligt som muligt, hvilket gøres ved hjælp af få, udvalgte eksempler.

Afsnit 6.1 vedrører videnskabelige eksperimenter og data. Vi har valgt at fokusere på tre hovedingredienser eller aktiviteter i en statistisk analyse

- i) modelopstilling
- ii) modelkontrol
- iii) statistisk inferens

som omtales i Afsnit 6.2 - 6.4. Statistik inferens baseret på begrebet *likelihood* diskuteres i Afsnit 6.5 og i Afsnit 6.6 omtales nogle få begreber fra den generelle testteori. Approksimative statistiske metoder omtales i Afsnit 6.7 og endelig indeholder Afsnit 6.8 nogle afsluttende bemærkninger.

6.1 Data

Vi tager udgangspunkt i en simpel situation, hvor datasættet består af n observationer $x_1, \dots, x_n$. Disse samles i en søjlevektor $\mathbf{x} = (x_1, \dots, x_n)^* \in \mathbb{R}^n$. Vi forestiller os, at $\mathbf{x}$ er resultatet af et *eksperiment* eller et *observationelt studie*, udført med det formål at få indblik i en specifik *faglig sammenhæng*.

Disse betegnelser skal forstås i bred forstand. Selvom det i vores forsimplede beskrivelse kan være mest oplagt at tænke på data som målinger (fx vandstand, vandtemperatur, blodtryk) eller registreringer/optegnelser (fx huspriser, aktiekurser, prisindekser), kan data i princippet også være informationer, som man ikke umiddelbart opfatter som “kvantitative” — fx videooptagelser eller tekst.

6.2 Modelopstilling

Karakteristisk for et datasæt $\mathbf{x}$ i et eksperiment er, at det er *stokastisk*. Det vil sige, at hvis man gentager eksperimentet eller foretager nye observationer under lignende omstændigheder, bliver resultatet ikke nødvendigvis $\mathbf{x}$. Dette adskiller sig fra en deterministisk situation, hvor udfaldet kan forudsiges med sikkerhed på forhånd.

Alligevel ses der ofte en vis "regelmæssighed" på et højere niveau, når forsøget gentages mange gange. Det redskab, vi benytter til at beskrive denne regelmæssighed, er en *sandsynlighedsteoretisk model*, som giver en matematisk beskrivelse af den mekanisme, der genererede datasættet.

Formelt består en sandsynlighedsteoretisk model af tre komponenter: 1) *udfaldsrummet* $\mathcal{X}$, som er samtlige værdier (udfald), eksperimentet kan antage; 2) *hændelsessystemet* $\mathcal{A}$, som omfatter alle de hændelser, vi vil betragte; og 3) *sandsynlighedsmålet* P , der angiver sandsynligheden for alle hændelser i $\mathcal{A}$.

Det stokastiske element i eksperimentet beskrives af hændelsessystemet og sandsynlighedsmålet, der tilsammen beskriver de hændelser, vi er interesserede i, og deres sandsynligheder. Når vi har med et datasæt at gøre, opfatter vi $\mathbf{x}$ som en realisation af en stokastisk vektor $\mathbf{X}$.

Vi indskrænker os til kun at betragte *diskrete* og *kontinuerte* stokastiske vektorer. Det betyder, at vi i høj grad fokuserer på udfaldsrum som $\mathbb{N}^n$ og $\mathbb{Z}^n$, der hører til diskrete data, samt udfaldsrum som $\mathbb{R}_+^n$ og $\mathbb{R}^n$, der hører til kontinuerte data. Hændelsessystemet vil omfatte alle etpunktsmængder, alle intervaller og alle mængder, der kan dannes ud fra disse ved de sædvanlige mængdeoperationer (foreningsmængde, fællesmængde, komplementærmængde).

Sandsynlighedsmålene på disse hændelsessystemer kan repræsenteres enten ved deres *fordelingsfunktion* F (CDF) eller deres *tæthedsfunktion* (PMF/PDF) f .

En *statistisk model* er en *parametriseret* mængde af sandsynlighedsteoretiske modeller. Typisk er udfaldsrummene og hændelsessystemerne de samme for alle de sandsynlighedsteoretiske modeller, og i så fald kan man betragte en statistisk model som en sandsynlighedsteoretisk model, hvor sandsynlighedsmålet er erstattet af en parametriseret klasse af sandsynlighedsmål, $\mathcal{P} = \{P_{\boldsymbol{\theta}} \mid \boldsymbol{\theta} \in \Theta\}$. I praksis repræsenteres disse enten ved en parametriseret klasse af fordelingsfunktioner, $\mathcal{F} = \{F_{\boldsymbol{\theta}} \mid \boldsymbol{\theta} \in \Theta\}$, eller en parametriseret klasse af tætheder $\{f(\cdot; \boldsymbol{\theta}) \mid \boldsymbol{\theta} \in \Theta\}$. Her er *parameteren* $\boldsymbol{\theta} = (\theta_1, \dots, \theta_k)^*$, og vi antager, at Θ , *parameterrummet* (eller *parametermængden*), er en delmængde af $\mathbb{R}^k$. Vi vil henvise til både $\boldsymbol{\theta}$ og dens komponenter θ_i , $i = 1, \dots, k$ som *parametre*. Ønsker man en sproglig skelnen, kan man kalde $\boldsymbol{\theta}$ for en *parametervektor*.

Parameteren $\boldsymbol{\theta}$ bør vælges, så den er relevant for det faglige problem, der ligger til grund for eksperimentet. Det vil sige, at parameteren skal vælges, så udsagn vedrørende det faglige problem kan formuleres ved hjælp af $\boldsymbol{\theta}$.

De statistiske modeller er altså i denne situation på formen

$$(\mathcal{X}, \mathcal{A}; \mathcal{P}) = (\mathcal{X}, \mathcal{A}; \{P_{\boldsymbol{\theta}} \mid \boldsymbol{\theta} \in \Theta\}).$$

Vores foretrukne repræsentation af sandsynlighedsmålene er via tætheder, og vi kalder funktionen

$$\begin{aligned}\mathcal{X} \times \Theta &\rightarrow \mathbb{R} \\ (\mathbf{x}, \boldsymbol{\theta}) &\mapsto f(\mathbf{x}; \boldsymbol{\theta})\end{aligned}\tag{6.1}$$

for *modelfunktionen*. Modelfunktionen er tætheden som funktion af både udfaldet $\mathbf{x}$ og parameteren $\boldsymbol{\theta}$.

For at gøre de matematiske overvejelser lettere antager vi at parametermængden Θ er et *område* i $\mathbb{R}^k$, dvs. at Θ er en *åben* og *sammenhængende* delmængde af $\mathbb{R}^k$.

Vi har nu fået fastlagt de termer og den notation, vi vil anvende i omtalen af statistiske modeller. *Modelopstilling* opfatter vi som den proces, hvor man identificerer komponenterne i den statistiske model: udfaldsrum, hændelsessystem og klassen af fordelinger. Ofte er det uproblematisk at fastlægge udfaldsrummet, og dermed er hændelsessystemet også givet. Det væsentligste arbejde ligger sædvanligvis i at vælge en *parametriseret klasse af fordelinger*, som skal anvendes. Derfor udelader man i praksis ofte at nævne hele triplet $(\mathcal{X}, \mathcal{A}; \{P_{\boldsymbol{\theta}} \mid \boldsymbol{\theta} \in \Theta\})$ og fokuserer i stedet på fordelingerne $\{P_{\boldsymbol{\theta}} \mid \boldsymbol{\theta} \in \Theta\}$.

Har man endda allerede besluttet sig for en specifik fordelingsklasse, kan man nøjes med at specificere *parametermængden* Θ . De øvrige elementer – udfaldsrum og hændelsessystem – vil da være underforstået.

6.3 Modelkontrol

Dette punkt i en statistisk analyse vedrører vurdering af rimeligheden af den opstillede statistiske model. Her undersøges, om data $\mathbf{x}$ strider mod én eller flere væsentlige konsekvenser af modellen. Hvis dette er tilfældet, forkastes modellen, og en ny opstilles; hvis ikke, er man klar til at fortsætte til næste punkt i analysen, *statistisk inferens*. Det skal understreges, at man ved denne fremgangsmåde på ingen måde opnår sikkerhed for, at modellen er korrekt. Det er vanskeligt at give en generel beskrivelse af dette punkt i en statistisk analyse, fordi metoderne dels afhænger af selve modellen og dels af de aspekter ved modellen, som man lægger vægt på.

Indledningsvis vil modelkontrollen typisk være grafisk, fx med fraktildiagrammer eller scatterplots, men det er værd at understrege, at modelkontrol ikke er begrænset til indledende faser af en statistisk undersøgelse. I mange modeller, fx i regressionsmodeller, sker en væsentlig del af modelkontrollen netop efter, at man har estimeret i modellen.

6.4 Statistisk inferens

Intentionen med en statistisk analyse er at opnå indsigt i det faglige problem, der gav anledning til eksperimentet. Ved modelopstillingen blev $\boldsymbol{\theta}$ derfor valgt, så den repræsenterer de aspekter af det faglige problem, som har særlig interesse. *Statistisk inferens* handler dernæst om at formulere udsagn om parameteren $\boldsymbol{\theta}$ — og dermed om det faglige problem — på baggrund af data $\mathbf{x}$, som er udfaldet af eksperimentet.

Formålet med disse udsagn er at angive, i hvilken grad forskellige parameterværdier θ — eller mere præcist de tilsvarende fordelingsfunktioner F_θ (eller tæthedsfunktioner $f(\cdot; \theta)$) — må anses for at beskrive datasættet $\mathbf{x}$ på en rimelig måde. De to væsentligste discipliner inden for statistisk inferens er traditionelt *estimationsteori* og *testteori*.

I estimationsteorien søges en afbildning

$$\begin{aligned}\tilde{\theta} : \mathcal{X} &\rightarrow \Theta \\ \mathbf{x} &\mapsto \tilde{\theta}(\mathbf{x}),\end{aligned}\tag{6.2}$$

der til data $\mathbf{x}$ tilordner en bestemt parameterværdi $\tilde{\theta}(\mathbf{x})$, se Figur 6.1. Denne værdi omtales som *estimatet* for (*skønnet* over) parameteren θ . Den tilsvarende stokastiske vektor $\tilde{\theta}(\mathbf{X})$ omtales som en *estimator* for θ . Vi benytter $\theta \leftarrow \tilde{\theta} = \tilde{\theta}(\mathbf{x})$ til at indikere, at $\tilde{\theta}$ er et estimat for θ .

En lille krølle på ovenstående definition er at vi i praksis ofte vil estimere de enkelte indgange i θ hver for sig - for eksempel, vil vi gerne kunne tale om en estimator for middelværdien μ i en normalfordeling, uden samtidigt at tale om hvordan variansen σ^2 estimeres. Vi vil derfor også kalde indgangene i $\tilde{\theta}$ for estimators.

Definitionen af en estimator er således meget generel, og den eneste egentlige begrænsning er, at definitionsområdet for $\tilde{\theta}(\cdot)$ skal være $\mathcal{X}$. Det betyder, at vi skal kunne beregne estimatorerne ud fra data alene, uden at de afhænger af modellens parametre. Vi er interesserede i estimators med gode egenskaber og indfører derfor *bias* af en estimator som

$$\text{bias}(\tilde{\theta}(\mathbf{X})) = \mathbb{E}_\theta \tilde{\theta}(\mathbf{X}) - \theta.$$

En estimator siges at være *unbiased* (dansk: *middelværdiret*), hvis $\text{bias}(\tilde{\theta}(\mathbf{X})) = 0$, altså hvis

$$\mathbb{E}_\theta \tilde{\theta}(\mathbf{X}) = \theta \quad \text{for alle } \theta \in \Theta.$$

En estimator er altså middelværdiret, hvis middelværdien $\tilde{\theta}(\mathbf{X})$ beregnet under sandsynlighedsmålet $\mathbb{P}_\theta$ er θ , eller, løst sagt, estimatoren har den “rigtige” middelværdi.

Blandt andre vigtige egenskaber for estimators kan nævnes *efficiens*, *MSE* (mean square error) og *konsistens*. Disse er beskrevet nærmere i Chihara and Hesterberg [2022].

Eksempel 6.1.

Et eksempel på en statistisk model er én normalfordelt observationsrække, hvor både middelværdi og varians er ukendte (jf. Afsnit 2.2). I denne model er observationerne $x_1, \dots, x_n$ realisationer af de uafhængige og identisk fordelte stokastiske variable $X_1, \dots, X_n$, hvor $X_i \sim N(\mu, \sigma^2)$ for $i = 1, \dots, n$. Her betragtes altså en statistisk model, hvis sandsynlighedsmål er parametriseret ved $\theta = (\mu, \sigma^2)$, som varierer i $\Theta = \mathbb{R} \times \mathbb{R}_+$. Antages variansen derimod at være kendt ($\sigma^2 = \sigma_0^2$), bliver $\theta = \mu$, og parametermængden er $\mathbb{R}$.

I begge tilfælde er den empiriske middelværdi $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ en *unbiased* estimator for μ . Hvis variansen er ukendt, kan σ^2 eksempelvis estimeres ved

$$\hat{\sigma}^2(\mathbf{X}) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

eller ved

$$s^2(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Her er $\hat{\sigma}^2$ en *biased* estimator for σ^2 , mens s^2 er *unbiased*. □

Eksempel 6.2.


En metode til at udlede estimators er den såkaldte *momentmetode* (engelsk: *method of moments*), som gennemgås i [Chihara and Hesterberg \[2022\]](#). Metoden anvendes, når man ønsker at finde estimators ud fra en stikprøve $X_1, \dots, X_n$. Grundidéen er, at man i den statistiske model udtrykker de første k momenter $\mu_j = \mathbb{E}_{\boldsymbol{\theta}}[X^j]$ (bemærk, at middelværdien ikke afhænger af, hvilket X_i vi betragter, så indekset i udelades) som funktioner af $\boldsymbol{\theta}$. Mere præcist finder man k funktioner, så

$$\begin{aligned} \mathbb{E}_{\boldsymbol{\theta}}[X] &= g_1(\theta_1, \dots, \theta_k) \\ \mathbb{E}_{\boldsymbol{\theta}}[X^2] &= g_2(\theta_1, \dots, \theta_k) \\ &\vdots \\ \mathbb{E}_{\boldsymbol{\theta}}[X^k] &= g_k(\theta_1, \dots, \theta_k). \end{aligned}$$

Derefter sætter man disse lig med de tilsvarende *empiriske* momenter

$$M_j = \frac{1}{n} \sum_{i=1}^n X_i^j, \quad j = 1, \dots, k,$$

og løser ligningerne for $\theta_1, \dots, \theta_k$. I [Chihara and Hesterberg \[2022\]](#) gives en række konkrete eksempler på, hvordan denne fremgangsmåde kan anvendes. □



Figur 6.1: Illustration af en estimator $\tilde{\boldsymbol{\theta}}$.

Det er ofte en del af en statistisk analyse at undersøge, om en enklere statistisk model end den, der som udgangspunkt blev opstillet, giver en tilfredsstillende beskrivelse af data. Det kan netop

være på den måde, man formulerer og besvarer et relevant fagligt spørgsmål. Lad Θ_0 betegne en delmængde af parameterummet Θ . Hypotesen

$$H_0 : \boldsymbol{\theta} \in \Theta_0 \quad (6.3)$$

repræsenterer da en *reduktion* af den statistiske model. Hvis Θ_0 kun har ét element $\boldsymbol{\theta}_0$, omtales hypotesen som en *simpel hypotese* eller som en *punkthypotese*. I modsat fald betegnes hypotesen som *sammensat*. *Testteorien* angiver metoder til at vurdere, om hypotesen H_0 er rimelig eller ej på grundlag af data $\mathbf{x}$. Matematisk set er et test blot en opdeling af værdimængden $\mathcal{X}$ i to disjunkte mængder

$$R = \{\mathbf{x} \in \mathcal{X} : H_0 \text{ forkastes på grundlag af } \mathbf{x}\} \quad (6.4)$$

$$A = \{\mathbf{x} \in \mathcal{X} : H_0 \text{ forkastes ikke på grundlag af } \mathbf{x}\},$$

der betegnes som henholdsvis *forkastelses-* og *acceptområdet* for H_0 . Mængden R omtales undertiden også som det *kritiske område* for H_0 .

Ofte fås den betragtede opdeling af værdimængden $\mathcal{X}$ på følgende måde: Lad T være en afbildning af $\mathcal{X}$ ind i $\mathbb{R}$ og lad $\mathcal{T}_R$ og $\mathcal{T}_A$ være en opdeling af værdimængden $\mathcal{T} = T(\mathcal{X})$ i to disjunkte mængder. Hvis

$$R = T^{-1}(\mathcal{T}_R) = \{\mathbf{x} \in \mathcal{X} : T(\mathbf{x}) \in \mathcal{T}_R\} \quad (6.5)$$

$$A = T^{-1}(\mathcal{T}_A) = \{\mathbf{x} \in \mathcal{X} : T(\mathbf{x}) \in \mathcal{T}_A\},$$

omtales $T = T(\mathbf{X})$ som en *testor* af hypotesen H_0 . Værdien $T(\mathbf{x})$ af T svarende til data $\mathbf{x}$ omtales som *teststørrelsen*.

I praksis vil T ofte kunne opfattes som et kvantitativt mål for, hvor *kritisk* en observation $\mathbf{x}$ er for H_0 , i den forstand at vi kan sige at $\mathbf{x}_1$ er ligeså eller mere kritisk for H_0 end $\mathbf{x}_2$ hvis

$$T(\mathbf{x}_1) \geq T(\mathbf{x}_2),$$

og vi kan i dette tilfælde angive de udfald, der er ligeså, eller mere kritiske end et observeret udfald $\mathbf{x}$ som $\{\mathbf{y} \in \mathcal{X} \mid T(\mathbf{y}) \geq T(\mathbf{x})\}$. Se Figur 6.2 og 6.3 for illustrationer.

Hvis vi betragter en simpel hypotese $H : \boldsymbol{\theta} = \boldsymbol{\theta}_0$ kan vi i dette tilfælde angive sandsynligheden for denne mængde under antagelse af at hypotesen er sand som

$$p_{\text{obs}}(\mathbf{x}) = \mathbb{P}_{\boldsymbol{\theta}_0}(\{\mathbf{y} \in \mathcal{X} \mid T(\mathbf{y}) \geq T(\mathbf{x})\}) = \mathbb{P}_{\boldsymbol{\theta}_0}(T(\mathbf{X}) \geq T(\mathbf{x})).$$

Denne sandsynlighed kaldes *p-værdien*.

Eksempel 6.3.


Eksempler på estimatorer er *u-testoren* og *t-testoren*, som blev gennemgået i Kapitel 2. Hvis $\mathbf{X} = (X_1, \dots, X_n)^*$ er en normalfordelt stikprøve med kendt varians σ_0^2 (dvs. $X_1, \dots, X_n$ er uafhængige og identisk fordelte $X_i \sim N(\mu, \sigma_0^2)$), er $|u(\mathbf{X})|$, hvor

$$u(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{\sigma_0^2/n}},$$


en *testor* for hypotesen $H_0 : \mu = \mu_0$. Hvis variansen σ^2 er ukendt, kan $|t(\mathbf{X})|$ benyttes som testor for den samme hypotese, hvor

$$t(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{s^2(\mathbf{X})/n}}. \quad \square$$

Ud fra heuristiske argumenter er det ofte muligt at angive estimatorer og testorer i simple, konkrete situationer. Imidlertid er det naturligvis af værdi at have en generel metodik, baseret på simple principper, der anviser estimatorer og testorer også i mere komplicerede situationer. Den metodik, vi skal omtale i det følgende, baserer sig på *likelihoodfunktionen*, som introduceres i næste afsnit. De hertil hørende størrelser omtales som henholdsvis *maksimum likelihood estimatoren* og *likelihood ratio testoren*.



Figur 6.2: Illustration af en testor T for hypotesen H_0 .



Figur 6.3: Illustration af en testor T i situationen hvor T kan opfattes som et mål for hvor kritisk $\mathbf{x}$ er for H_0 .

6.5 Likelihood inferens

Ideerne bag likelihood inferens og de første grundliggende udviklinger af dette begreb skyldes den engelske statistiker R. A. Fisher. Likelihood inferens er baseret på *likelihoodfunktionen*, som vi nu introducerer og diskuterer.

Fra formuleringen af den statistiske model i Afsnit 6.2 ses det, at for fast værdi af parameteren θ er modelfunktionen $f(\mathbf{x}; \theta)$ tæthedsfunktionen for den stokastiske vektor $\mathbf{X}$. Hvis P_θ betegner sandsynligheds målet svarende til tæthedsfunktionen $f(\mathbf{x}; \theta)$ har vi derfor, at

$$f(\mathbf{x}; \theta) = P_\theta(\mathbf{X} = \mathbf{x}), \quad (6.6)$$

hvis $\mathbf{X}$ er diskret. Hvis $\mathbf{X}$ er kontinuert, er relationen mellem $f(\mathbf{x}; \theta)$ og P_θ givet ved

$$f(\mathbf{x}; \theta) d\mathbf{x} \approx P_\theta(\mathbf{X} \in I_{\mathbf{x}}), \quad (6.7)$$

hvor $I_{\mathbf{x}}$, løst sagt, er en lille mængde omkring $\mathbf{x}$, hvis volumen er $d\mathbf{x}$.

For fast værdi af θ beskriver modelfunktionen altså sandsynlighederne knyttet til alle mulige realisationer af $\mathbf{X}$. Data $\mathbf{x}$ er imidlertid en bestemt og fast realisation af $\mathbf{X}$, og da vi ønsker at udtale os om forskellige værdier af θ i lys af data $\mathbf{x}$, kunne vi prøve at betragte modelfunktionen som funktion af θ for fastholdt $\mathbf{x}$.


Vi har da (i rette forstand) stadig fortolkningen, at $f(\mathbf{x}; \theta)$ er sandsynligheden af observationen $\mathbf{x}$, hvis parameteren er θ . Det har vi direkte via (6.6), hvis $\mathbf{X}$ er diskret, eller via fortolkningen i (6.7), hvis $\mathbf{X}$ er kontinuert. I den forstand er $f(\mathbf{x}; \theta)$ et udtryk for troligheden eller rimeligheden af θ i lys af data $\mathbf{x}$. R.A. Fisher valgte termen *likelihood*, fordi likelihood i lighed med probability i engelsk daglig tale bruges til at udtrykke grader af tiltro. Ved at vælge en anden term end “probability” understregede Fisher, at vi ikke har at gøre med sandsynligheder på parametrene.

Termen likelihood er ikke oversat til dansk, og vi kalder $f(\mathbf{x}; \theta)$ som funktion af θ for *likelihood-funktionen* og betegner den

$$L(\theta) = f(\mathbf{x}; \theta) \quad \theta \in \Theta, \quad (6.8)$$

idet vi underforstår afhængigheden af de observerede data. Men hvis vi ønsker at understrege, at vi betragter funktionen svarende til data $\mathbf{x}$, skriver vi $L(\theta; \mathbf{x})$ i stedet for $L(\theta)$. Et eksempel på en likelihoodfunktion kan ses i Figur 6.4. Likelihoodfunktionen laver en ordning i parametermængden. Hvis vi et øjeblik betragter kun to parameter værdier θ_1 og θ_2 , og på baggrund af data $\mathbf{x}$ ønsker at vælge, hvilken af de to parameter værdier, der bedst forklarer data, må det blive den, som har den største værdi af likelihoodfunktionen $L(\theta)$, fordi det er den, som gør data mest sandsynlig. Vi siger, at værdien θ_1 er mere *likely* end θ_2 i lys af data $\mathbf{x}$, hvis $L(\theta_1) > L(\theta_2)$. På dansk vil vi undertiden bruge ordet *trolig* i denne tekniske betydning, og altså sige, at θ_1 er mere *trolig* end θ_2 i lys af data $\mathbf{x}$, hvis $L(\theta_1) > L(\theta_2)$.

Likelihoodfunktionens ordning af parametermængden leder umiddelbart til, at hvis vi vil angive én parameter værdi, som er i bedst overensstemmelse med data $\mathbf{x}$, må det blive den værdi, som gør de observerede data mest sandsynlige, det vil sige den værdi, hvor likelihoodfunktionen antager sit maksimum. Vi har hermed introduceret begrebet *maksimum likelihood estimation*. Hvis der



Figur 6.4: Likelihoodfunktionen $L(\theta)$ svarende til observationen $x = 8$ i en statistik model baseret på binomialfordelingen med sandsynlighedsparameter θ og antalsparameter $n = 20$.

eksisterer en entydigt bestemt værdi $\hat{\theta}$, for hvilken likelihoodfunktionen $L(\cdot)$ antager sit maksimum, det vil sige

$$L(\hat{\theta}) > L(\theta) \quad \text{for alle } \theta \in \Theta \text{ således at } \theta \neq \hat{\theta},$$

kaldes denne værdi $\hat{\theta}$ af parameteren for *maksimum likelihood estimatet* for θ . Med andre ord er maksimum likelihood estimatet $\hat{\theta} = \hat{\theta}(\mathbf{x})$ den mest trolige værdi af parameteren θ i lys af data $\mathbf{x}$. Den tilsvarende stokastiske vektor $\hat{\theta}(\mathbf{X})$ omtales som *maksimum likelihood estimatoren*. Notationen $\arg \max_{\theta \in \Theta} L(\theta)$ betegner generelt mængden af de punkter, hvor L opnår sit maksimum (og denne mængde kan i princippet være tom). Vi vil dog undertiden skrive $\hat{\theta} = \arg \max_{\theta \in \Theta} L(\theta)$, hvor det da er underforstået, at den maksimerende θ er entydig.

Som regel er det lettere at maksimere *log likelihoodfunktionen*

$$l(\theta) = \ln L(\theta) \quad \theta \in \Theta, \quad (6.9)$$

end selve likelihoodfunktionen $L(\cdot)$. I de modeller, vi betragter, er likelihoodfunktionen (mindst) to gange differentiabel med kontinuerte (partielle) afledede, og det letter arbejdet med at finde den værdi, hvor likelihoodfunktionen antager sit maksimum. Hvis de rette matematiske betingelser er tilstede har vi $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_k)^*$ findes som en løsning til ligningerne

$$\frac{\partial l}{\partial \theta_j}(\theta) = 0, \quad j = 1, 2, \dots, k. \quad (6.10)$$

Disse ligninger, der kaldes *likelihood ligningerne*, kan undertiden løses eksplicit, men i nogle tilfælde må man benytte numeriske procedurer for at finde $\hat{\theta}$. Desuden må man også vurdere om en løsning til likelihood ligningerne er et punkt, hvor likelihoodfunktionen antager sit maksimum. Dette kan i simple tilfælde afgøres ved at beregne matricen af anden afledede af log likelihoodfunktionen og

undersøge dennes egenskaber. Ofte er log likelihoodfunktionen konkav og en eventuel løsning til likelihood ligningerne er et globalt maksimumspunkt.

Hvis data udgør en *stikprøve*, det vil sige, hvis vi som model kan benytte, at $x_1, \dots, x_n$ er udfald af uafhængige og identisk fordelte stokastiske variable $X_1, \dots, X_n$, hvor tæthedsfunktionen for X_i er $f(x_i; \theta)$, $i = 1, \dots, n$, vil likelihoodfunktionen splitte op produktet af de indgående tætheder. Der gælder nemlig – som bekendt fra sandsynlighedsteorien – at tæthedsfunktionen for $\mathbf{X}$ er produktet af tæthedsfunktionerne for X_i , $i = 1, \dots, n$. Likelihoodfunktionen $L(\cdot)$ og log likelihoodfunktionen $l(\cdot)$ bliver derfor i denne situation henholdsvis

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) \quad (6.11)$$

og

$$l(\theta) = \sum_{i=1}^n \ln f(x_i; \theta). \quad (6.12)$$

Vi giver nu en diskussion af testteori baseret på likelihoodfunktionen. Indledningsvis bemærker vi to ting. For det første er værdien af likelihoodfunktionen beregnet i maksimum likelihood estimatet, $L(\hat{\theta}(\mathbf{x}))$, en funktion af data $\mathbf{x}$, og dermed en realisation af en stokastisk variabel. For det andet er fortolkningen af $L(\hat{\theta}(\mathbf{x}))$, at det er den maksimale sandsynlighed for data i $\mathbf{x}$ i den givne statistiske model, i den tidligere omtalte forstand.

Antag, at vi i en statistisk model med parametermængde Θ og på grundlag af data $\mathbf{x}$ ønsker at undersøge, om data kan beskrives med delmodellen Θ_0 , hvor Θ_0 betegner en delmængde af Θ , det vil sige $\Theta_0 \subseteq \Theta$.

Vi bruger sprogbugen, at vi ønsker at teste hypotesen

$$H_0 : \theta \in \Theta_0.$$

Lad $\hat{\theta}(\mathbf{x})$ betegne maksimum likelihood estimatet for θ i den oprindelige model, og lad $\hat{\theta}_0(\mathbf{x})$ betegne maksimum likelihood estimatet for θ under H_0 , det vil sige i den statistiske model med parametermængde Θ_0 . *Likelihood ratio teststørrelsen* $Q(\mathbf{x})$ defineres da som:

$$Q(\mathbf{x}) = \frac{\max_{\theta \in \Theta_0} L(\theta)}{\max_{\theta \in \Theta} L(\theta)} = \frac{L(\hat{\theta}_0(\mathbf{x}))}{L(\hat{\theta}(\mathbf{x}))}. \quad (6.13)$$

Man bemærker, at $Q(\mathbf{x}) \leq 1$ fordi det er samme funktion, der maksimeres i tæller og nævner og at der maksimeres over en mindre mængde i tælleren. Desuden er $0 < Q(\mathbf{x})$, da $Q(\mathbf{x})$ er et forhold mellem to tætheder. Alt i alt er altså $0 < Q(\mathbf{x}) \leq 1$.

Vi ser dernæst på fortolkningen af likelihood ratio teststørrelsen. $Q(\mathbf{x})$ er troværdighedsforholdet mellem den mest trolige værdi $\hat{\theta}_0$ af θ under H_0 og den mest trolige værdi $\hat{\theta}$ af θ i grundmodellen. Hvis $Q(\mathbf{x}) \approx 1$, er $L(\hat{\theta}_0) \approx L(\hat{\theta})$. Der eksisterer altså en værdi af parameteren under hypotesen,

der er næsten lige så trolig som den mest trolige værdi i en model vi tror på, og vi har derfor ingen grund til at betvivle H_0 i denne situation.

Hvis derimod $Q(\mathbf{x}) \approx 0$, er $L(\hat{\boldsymbol{\theta}}_0) \ll L(\hat{\boldsymbol{\theta}})$. Den mest trolige værdi under hypotesen er altså væsentligt mindre trolig end den mest trolige værdi i det hele taget, og derfor bør vi betvivle H_0 . Med andre ord er observationen $\mathbf{x}$ *kritisk* for H_0 , hvis $Q(\mathbf{x})$ er lille.

Helt på samme måde som likelihoodfunktionen lavede en ordning i parametermængden Θ , laver likelihood ratio teststørrelsen en ordning i udfaldsrummet $\mathcal{X}$. Vi siger, at $\mathbf{x}_1$ er *mere (eller sige så) kritisk* for H_0 som $\mathbf{x}_2$, hvis

$$Q(\mathbf{x}_1) \leq Q(\mathbf{x}_2).$$

Begrundelsen er, at $Q(\mathbf{x})$ er forholdet mellem den maksimale sandsynlighed for data under hypotesen relativt til den maksimale sandsynlighed under modellen.

For at få et indtryk af hvor lille $Q(\mathbf{x})$ skal være, før vi forkaster H_0 , betragtes mængden af alle mulige udfald $\mathbf{y}$ af eksperimentet, som er mindst lige så kritiske for H_0 som det observerede udfald $\mathbf{x}$, det vil sige mængden

$$\{\mathbf{y} \in \mathcal{X} : Q(\mathbf{y}) \leq Q(\mathbf{x})\}. \quad (6.14)$$

For at vurdere størrelsen af mængden i (6.14) relativt til størrelsen af $\mathcal{X}$ benytter vi sandsynlighedsteorien.

Hvis hypotesen H_0 er *simpel*, dvs. hvis $\Theta_0 = \{\boldsymbol{\theta}_0\}$, omtales sandsynligheden for mængden i (6.14),

$$p_{\text{obs}}(\mathbf{x}) = P_{\boldsymbol{\theta}_0}(\{\mathbf{y} \in \mathcal{X} \mid Q(\mathbf{y}) \leq Q(\mathbf{x})\}), \quad (6.15)$$

som *testsandsynligheden* (også kaldet *det observerede signifikansniveau* eller *p-værdien*). Af (6.15) fremgår det, at testsandsynligheden er *sandsynligheden – beregnet under H_0 – for de mulige udfald $\mathbf{y}$, der er mindst lige så kritiske for H_0 som det observerede udfald $\mathbf{x}$* . Er $p_{\text{obs}}(\mathbf{x})$ lille, betyder det, at der ikke er stor sandsynlighed for at få udfald, der er mindst lige så kritiske for H_0 som $\mathbf{x}$, og derfor forkaster vi H_0 . Altså, *hvis $p_{\text{obs}}(\mathbf{x})$ er lille, forkastes H_0* .

Er $p_{\text{obs}}(\mathbf{x})$ derimod stor, er der høj sandsynlighed for udfald, der er mindst lige så kritiske som $\mathbf{x}$. Følgelig er der ingen grund til at forkaste H_0 . Vi siger da, at “data strider ikke mod nulhypotesen H_0 ” eller undertiden endda, at “ H_0 accepteres”. Med andre ord: *hvis $p_{\text{obs}}(\mathbf{x})$ er stor, strider data ikke mod H_0* .

Man skal være opmærksom på, at observation af en testsandsynlighed, som er så stor, at H_0 ikke forkastes, på ingen måde har bevist rigtigheden af H_0 , men blot at vi ikke har observeret signifikante afvigelser fra H_0 . På den baggrund skal man passe på med at lægge for meget i sprogbugen “at H_0 accepteres”.

Lad os for en sikkerheds skyld fremhæve logikken bag argumentet, der fører til, at hypotesen H_0 forkastes, hvis den observerede testsandsynlighed $p_{\text{obs}}(\mathbf{x})$ er lille. Argumentet bygger på to præmisser:

- 1) “Enten er hypotesen H_0 falsk, eller også er en hændelse med lille sandsynlighed indtruffet.”
- 2) “En hændelse med lille sandsynlighed indtræffer ikke.”

Ud fra disse to præmisser drages på sædvanlig logisk vis konklusionen: “Hypotesen H_0 er falsk.”

Et spørgsmål er stadig ubesvaret. Hvor lille skal testsandsynligheden $p_{\text{obs}}(\mathbf{x})$ være, før vi forkaster H_0 ? Principielt afhænger svaret af hypotesens natur. For eksperimentelt at afvise velrenommerede videnskabelige hypoteser, som for eksempel Newtons 2. lov, kræves, at der konstateres stærkt signifikante afvigelser fra hypotesen, det vil sige at testsandsynligheden skal være meget lille, for eksempel 0.1%. Mindre velbegrundede hypoteser, såsom at indholdet af et bestemt mineral i et klippestykke er 20% eller at der ikke er forskel på længden af kronbladet hos de to plantearter *Iris versicolor* og *Iris virginica*, forkastes for langt større testsandsynligheder (1 eller 5%).

Likelihood ratio testet med *signifikansniveau* α forkaster hypotesen H_0 , hvis

$$p_{\text{obs}}(\mathbf{x}) \leq \alpha, \quad (6.16)$$

hvilket medfører, at det tilsvarende forkastelsesområde (eller kritiske område) R_α er

$$R_\alpha = \{\mathbf{x} \in \mathcal{X} \mid p_{\text{obs}}(\mathbf{x}) \leq \alpha\} \quad (6.17)$$

samt at det tilsvarende acceptområde er

$$A_\alpha = \{\mathbf{x} \in \mathcal{X} \mid p_{\text{obs}}(\mathbf{x}) > \alpha\}. \quad (6.18)$$

I den statistiske litteratur er det foretrukne signifikansniveau traditionelt 5%, men også niveauet 1% benyttes i forbindelse med mere velbegrundede hypoteser. På dette kursus benyttes test på 5%-niveau, medmindre andet er nævnt.

Hvis fordelingsfunktionen for Q betegnes $F_{Q(\mathbf{X})}$ kan (6.15) skrives som

$$p_{\text{obs}}(\mathbf{x}) = F_{Q(\mathbf{X})}(Q(\mathbf{x})) \quad (6.19)$$

Det fremgår af (6.15) at p -værdien afhænger af data $\mathbf{x}$ og den kan derfor opfattes som udfald af en stokastisk variabel $p_{\text{obs}}(\mathbf{X})$, og ved at benytte opskrivningen (6.19) ses det, at $p_{\text{obs}}(\mathbf{X})$ vil være uniformt fordelt på $[0, 1]$, hvis hypotesen er sand og $F_{Q(\mathbf{X})}(\cdot)$ er “pæn”. Beskrivelsen af hvad der skal forstås ved “pæn” i denne sammenhæng overlades til mere avancerede kurser, men en tilstrækkelig betingelse er at $F_{Q(\mathbf{X})}(\cdot)$ er strengt voksende og kontinuert (under H_0).

Vi afslutter dette afsnit med nogle bemærkninger vedrørende likelihood ratio testet i det tilfælde, hvor hypotesen H_0 er sammensat, det vil sige hvor delmængden Θ_0 , der specificerer hypotesen, har mere end ét element. I dette tilfælde defineres testsandsynligheden for likelihood ratio testet som

$$p_{\text{obs}}(\mathbf{x}) = \sup_{\theta \in \Theta_0} P_\theta(\{\mathbf{y} \in \mathcal{X} \mid Q(\mathbf{y}) \leq Q(\mathbf{x})\}), \quad (6.20)$$

altså som den største af sandsynlighederne – under H_0 – for mængden i (6.14).

Forkastelses- og acceptområdet defineres også i dette tilfælde som i formlerne (6.17) og (6.18). Vi bemærker iøvrigt, at p -værdien fra (6.20) kan udtrykkes som

$$p_{obs}(\mathbf{x}) = \sup_{\theta \in \Theta_0} \mathbb{P}_\theta(Q(\mathbf{X}) \leq Q(\mathbf{x})). \quad (6.21)$$

Temmelig ofte er det vanskeligt (eller umuligt) at beregne de eksakte værdier af testsandsynligheden for likelihood ratio testet som defineret i (6.15) eller (6.20). I Afsnit 6.7 diskuterer vi, hvorledes man beregner approksimationer for testsandsynlighederne i sådanne situationer.

6.6 Begreber fra generel testteori

I Afsnit 6.5 har vi diskuteret et specielt signifikanstest, nemlig likelihood ratio testet. Som nævnt er det undertiden vanskeligt at finde testsandsynligheden for dette test og derfor også de tilsvarende forkastelses- og acceptområder. I sådanne situationer betragter man sommetider alternative teststørrelser, der findes ved hjælp af heuristiske argumenter og/eller sandsynlighedsteoretiske overvejelser. I dette afsnit giver vi en kortfattet omtale af egenskaber ved en generel teststørrelse T som defineret i Afsnit 6.4. Bemærkningerne er derfor gyldige for såvel likelihood ratio testet som for de alternative test.

Signifikanstestet af hypotesen $H_0 : \theta \in \Theta_0$ svarende til testoren T siges at have *signifikansniveau* α (eller kort, T er et *test på niveau* α), hvis

$$\sup_{\theta \in \Theta_0} P_\theta(\mathbf{X} \in R) = \alpha, \quad (6.22)$$

det vil sige, hvis den største sandsynlighed for at forkaste H_0 – beregnet under H_0 – er α . Med andre ord, signifikansniveauet α for et test er mål for risikoen for at forkaste en sand hypotese. Det er indlysende, at det ville være ønskeligt, at α var 0, men sådanne signifikanstest findes ikke.

Som det fremgår af 6.15 er p -værdien funktion af data og kan således opfattes som udfald af en stokastisk variabel med en vis fordeling. Selv hvis H_0 er sand, er der en vis sandsynlighed for, at testsandsynligheden er lille, og at H_0 dermed forkastes på fejlagtigt grundlag (en fejl af type I). Omvendt, selv hvis H_0 er falsk, kan det ske, at testsandsynligheden er så stor, at vi ikke forkaster H_0 (en fejl af type II). Disse to fejltyper er vist skematisk i Tabel 6.1. Bemærk, at sandsynligheden for at begå en fejl af type I netop er signifikansniveauet α .

	H_0 forkastes	H_0 accepteres
H_0 sand	type I	ingen
H_0 falsk	ingen	type II

Tabel 6.1: De forskellige typer af fejl i testteorien.

Kvaliteten af et statistisk test afhænger blandt andet af dets evne til at afsløre signifikante afvigelser fra hypotesen H_0 , hvilket kan udtrykkes ved *styrkefunktionen* for testet. Med betegnelserne fra Afsnit


6.4 er styrkefunktionen for testoren T af hypotesen $H_0 : \boldsymbol{\theta} \in \Theta_0$ defineret som

$$\text{pow}(\boldsymbol{\theta}) = P_{\boldsymbol{\theta}}(T \in \mathcal{T}_R),$$

det vil sige, at for enhver værdi af parameteren $\boldsymbol{\theta}$ er styrken $\text{pow}(\boldsymbol{\theta})$ sandsynligheden – beregnet ved hjælp af sandsynlighedsmålet svarende til $\boldsymbol{\theta}$ – for at forkaste hypotesen H_0 . Bemærk, at hvis hypotesen er simpel, $\Theta_0 = \{\boldsymbol{\theta}_0\}$, så er $\text{pow}(\boldsymbol{\theta}_0)$ netop lig med signifikansniveauet α , samt at hvis vi for $\boldsymbol{\theta} \neq \boldsymbol{\theta}_0$ lader $\beta(\boldsymbol{\theta})$ betegne sandsynlighed for fejl af type II – svarende til parameterværdien $\boldsymbol{\theta}$ – så er

$$\beta(\boldsymbol{\theta}) = 1 - \text{pow}(\boldsymbol{\theta}).$$

Ideelt set burde værdien af styrkefunktionen for en simpel hypotese $H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0$ derfor være konstant lig med 1 med undtagelse af værdien i $\boldsymbol{\theta}_0$, som burde være 0. Som nævnt ovenfor findes der imidlertid ikke testorer med en sådan styrkefunktion. Et eksempel på en styrkefunktion er vist i Figur 6.5.



Figur 6.5: Styrkefunktionen for et u -test for hypotesen $H_0 : \mu = 0$, med kendt varians $\sigma_0 = 1$ og stikprøvestørrelse $n = 10$

Vi afslutter dette afsnit med at omtale konfidensområder, som er et begreb, hvis definition er relateret til testteorien og som ofte benyttes i anvendelser. I lys af data $\mathbf{x}$ er $(1 - \alpha)$ *konfidensområdet for parameteren $\boldsymbol{\theta}$* defineret som

$$C_{1-\alpha}(\mathbf{x}) = \{\boldsymbol{\theta}_0 \mid \text{hypotesen } H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \text{ accepteres ved et signifikantest på niveau } \alpha \text{ på grundlag af data } \mathbf{x} \}. \quad (6.23)$$

Hvis parameteren er en-dimensional er området typisk et interval, $(1 - \alpha)$ *konfidensintervallet*. Det er indlysende, at konfidensområdet afhænger af det betragtede test samt det valgte signifikansniveau. Test udføres sædvanligvis på niveau 5%, og de tilsvarende områder er i så tilfælde 95% konfidensområder.

Konfidensområdet i (6.23) er en fast mængde for det givne datasæt $\mathbf{x}$. En anden måde at indføre konfidensområder på er ved at sige at $1 - \alpha$ konfidensområder er (stokastiske) mængder. For en stokastisk mængde $R(\mathbf{X})$ og en parameter $\theta_0 \in \Theta$ indfører vi *dækningsgraden* til at være

$$\mathbb{P}_{\theta_0}(\theta_0 \in R(\mathbf{X})),$$

hvilket i ord betyder sandsynligheden for at $R(\mathbf{X})$ indeholder den sande parameter, når denne er θ_0 . Et $1 - \alpha$ konfidensområde indføres da som en mængde hvor dækningsgraden er mindst $1 - \alpha$ uanset hvad den sande parameter er, d.v.s. hvis

$$\mathbb{P}_{\theta_0}(\theta_0 \in R(\mathbf{X})) \geq 1 - \alpha \quad \theta_0 \in \Theta. \quad (6.24)$$

Det kan vises, at hvis konfidensområderne som blev indført i (6.23) opfattes som stokastiske mængder, vil de ofte have egenskaben indført i (6.24) og vi vil på dette kursus derfor ikke skelne mellem om vi betragter konfidensintervaller indført på den ene eller den anden måde.

En fortolkning af 95% konfidensområder baserer sig på fortolkningen af sandsynligheder som grænseværdier af relative hyppigheder. Antag, at man udførte uendeligt mange uafhængige eksperimenter (som ikke behøver at være gentagelser af samme eksperiment), hvor grundmodellen i alle tilfælde var korrekt. Hvis man for hvert eksperimentet beregnede området $C_{1-\alpha}(\mathbf{y})$ vil dette indeholde den sande værdi af parameteren for det tilhørende eksperiment i 95% af tilfældene.

Denne fortolkning er naturligvis ikke så gavnlig, når man står med sit interval $C_{1-\alpha}(\mathbf{x})$ beregnet på grundlag af data $\mathbf{x}$. Men det er samme fortolkning, som vi har mødt i forbindelse med test. Enten omfatter intervallet $C_{1-\alpha}(\mathbf{x})$ den sande parameter eller også er der indtruffet en hændelse med en sandsynlighed mindre end α .

Undertiden omtales konfidensintervallet for θ som *intervalestimatet* for θ . Et sædvanligt estimat, for eksempel maksimum likelihood estimatet $\hat{\theta}(\mathbf{x})$, udpeger kun én værdi af parameteren i lys af data $\mathbf{x}$. Konfidensintervallet eller intervalestimatet $C_{1-\alpha}(\mathbf{x})$ er i praksis værdifuldt, fordi det ikke blot udpeger en enkelt værdi af θ men er et udtryk for, hvor meget information data $\mathbf{x}$ indeholder vedrørende den ukendte parameter θ . Hvis konfidensintervallet er stort, er der mange værdier af parameteren θ , der giver en rimelig beskrivelse af data $\mathbf{x}$, og i så tilfælde indeholder $\mathbf{x}$ begrænset information om θ . Hvis derimod konfidensintervallet er lille, er der relativt få værdier af parameteren, der giver en fornuftig beskrivelse af data $\mathbf{x}$, og $\mathbf{x}$ indeholder derfor megen information om værdien af θ .

6.7 Approksimativ likelihood teori

Som bemærket i Afsnit 6.5 er det undertiden vanskeligt eller umuligt, at beregne den eksakte værdi af testsandsynligheden $p_{obs}(\mathbf{x})$ for likelihood ratio testet i (6.15) eller (6.20). I dette afsnit

diskuterer vi, hvorledes testsandsynligheden $p_{obs}(\mathbf{x})$ kan approksimeres. Desuden omtales approksimationer af fordelingen af maksimum likelihood estimatoren $\hat{\theta} = \hat{\theta}(\mathbf{X})$. Som tidligere bemærket er testsandsynligheden i (6.15) præcis er værdien af fordelingsfunktionen for likelihood ratio testoren $Q(\mathbf{X})$ beregnet i den observerede værdi $Q(\mathbf{x})$, det vil sige

$$p_{obs}(\mathbf{x}) = F_{Q(\mathbf{X})}(Q(\mathbf{x})). \quad (6.25)$$

Spørgsmålet om at approksimere testsandsynligheden i (6.15) eller (6.25) er derfor ækvivalent med at finde approksimationer til fordelingen – under H_0 – af likelihood ratio testoren. Lignende bemærkninger gælder i det tilfælde, hvor H_0 er en sammensat hypotese, det vil sige i det tilfælde, hvor testsandsynligheden beregnes ved hjælp af (6.20).

Approksimationerne, der omtales i det følgende, er baseret på anden ordens Taylor udviklinger af log likelihoodfunktionen. Approksimationerne opskrives både for et generelt k , men er i første omgang lettest forstå for tilfældet $k = 1$, som af denne årsag også opskrives. Approksimationerne er gyldige, idet det er antaget, at parameterrummet Θ er et område i $\mathbb{R}^k$ samt at log likelihoodfunktionen l er mindst to gange differentiabel med kontinuerte (partielle) afledede. Mere præcist har vi

$$l(\theta) - l(\hat{\theta}) \approx \sum_{r=1}^k (\theta_r - \hat{\theta}_r) \frac{\partial l}{\partial \theta_r}(\hat{\theta}) + \frac{1}{2} \sum_{r=1}^k \sum_{s=1}^k (\theta_r - \hat{\theta}_r)(\theta_s - \hat{\theta}_s) \frac{\partial^2 l}{\partial \theta_r \partial \theta_s}(\hat{\theta}), \quad (6.26)$$

eller, når $k = 1$,

$$l(\theta) - l(\hat{\theta}) \approx (\theta - \hat{\theta})l'(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^2 l''(\hat{\theta}) \quad (6.27)$$

hvor $\approx$ indikerer approksimationen, og hvor udtrykket på højre side er Taylor polynomiet af anden grad for l omkring maksimum likelihood estimatet $\hat{\theta}$. Lad $j(\theta; \mathbf{x})$ betegne den symmetriske $k \times k$ matrix, hvis (r, s) te element er

$$j_{rs}(\theta; \mathbf{x}) = -\frac{\partial^2 l}{\partial \theta_r \partial \theta_s}(\theta; \mathbf{x}) \quad \text{eller, når } k = 1: \quad j(\theta; \mathbf{x}) = -l''(\theta; \mathbf{x}). \quad (6.28)$$

Idet $\hat{\theta}$ er en løsning til likelihoodligningerne (6.10) fås af (6.26) - i matrix notation - at

$$l(\theta) - l(\hat{\theta}) \approx -\frac{1}{2}(\hat{\theta} - \theta)^* j(\hat{\theta}; \mathbf{x})(\hat{\theta} - \theta) \quad \text{eller, når } k = 1: \quad l(\theta) - l(\hat{\theta}) \approx -\frac{1}{2}(\theta - \hat{\theta})^2 j(\theta; \mathbf{x}), \quad (6.29)$$

hvor $*$ betyder transponering. Funktionen $\bar{l}(\cdot) = l(\cdot) - l(\hat{\theta})$ kaldes den *normerede log likelihood funktion* og matricen $j(\theta; \mathbf{x})$ omtales som den *observerede informationsmatrix* svarende til data $\mathbf{x}$. Middelværdien af den tilsvarende stokastiske matrix $j(\theta; \mathbf{X})$, det vil sige


$$i(\theta) = E_{\theta}\{j(\theta; \mathbf{X})\}, \quad (6.30)$$

kaldes den *forventede informationsmatrix* eller *Fishers informationsmatrix*.

For at forklare, hvorfor ordet „information“ benyttes i denne sammenhæng, vil vi for en stund antage, at parameteren θ er en-dimensional, det vil sige $k = 1$. Fra (6.29) ses det, at i dette tilfælde kan den normerede log likelihood funktion $\bar{l}$ i en omegn af $\hat{\theta}$ approksimeres ved parablen

$$p(\theta) = -\frac{1}{2}j(\hat{\theta}; \mathbf{x})(\hat{\theta} - \theta)^2, \quad (6.31)$$

se Figur 6.6. I (6.31) er $j(\hat{\theta}; \mathbf{x}) > 0$, idet $\hat{\theta}$ er et maksimumspunkt for l . Jo større $j(\hat{\theta}; \mathbf{x})$ er, jo mere koncentrerer denne parabel sig om punktet $\hat{\theta}$, og kun for værdier af θ , der ligger meget tæt på $\hat{\theta}$, er $l(\theta)$ (eller $L(\theta)$) af samme størrelsesorden som $l(\hat{\theta})$ (eller $L(\hat{\theta})$). Følgelig er $j(\hat{\theta}; \mathbf{x})$ et mål for den information, som data $\mathbf{x}$ giver om værdien af den ukendte parameter θ .



Figur 6.6: Den normerede log likelihood funktion $\bar{l}(\cdot) = l(\cdot) - l(\hat{\omega})$ og den approksimerende parabel $p(\cdot)$ svarende til observationen $x = 8$ i binomialmodellen med sandsynlighedsparameter θ og antalsparameter $n = 20$, se også Figur 6.4.

Vi vender os nu mod en diskussion af, hvorledes fordelingen af henholdsvis maksimum likelihood estimatoren $\hat{\theta} = \hat{\theta}(\mathbf{X})$ og likelihood ratio testoren $Q = Q(\mathbf{X})$ kan approksimeres i det generelle tilfælde, hvor parameteren θ er k -dimensional. Det kan vises, at fordelingen af $\hat{\theta}$ - beregnet under fordelingen svarende til parameteren θ - kan approksimeres ved en k -dimensional normalfordeling (jf. A.3.7) med middelværdivektor θ og kovariansmatrix $i(\theta)^{-1}$, som er den inverse til den forventede informationsmatrix $i(\theta)$. Dette resultat skrives på følgende måde:

$$\hat{\theta} \approx N_k(\theta, i(\theta)^{-1}) \quad \text{eller, når } k = 1: \quad \hat{\theta} \approx N(\theta, \frac{1}{i(\theta)}). \quad (6.32)$$

Approximationen kan vises at være speciel god i det tilfælde, hvor data $\mathbf{x}$ er én observationsrække $x_1, \dots, x_n$ fra en fordeling og hvor n er stor.

I lyset af $k = 1$ -tilfældet i (6.32) gælder approksimationen

$$(\hat{\theta} - \theta)^2 i(\theta) \approx \chi^2(1),$$

og ved at benytte et resultat fra sandsynlighedsteorien, der giver en relation mellem den k -dimensionale normalfordeling og chi-i-anden fordelingen med k frihedsgrader, $\chi^2(k)$, kan det indses, at (6.32) for et generelt k medfører følgende approksimation:

$$(\hat{\theta} - \theta)^* i(\theta) (\hat{\theta} - \theta) \approx \chi^2(k). \quad (6.33)$$

Yderligere kan man undertiden i dette udtryk erstatte den forventede informationsmatrix $i(\theta)$ med den forventede eller den observerede informationsmatrix beregnet i $\hat{\theta}$, det vil sige med $i(\hat{\theta})$ eller $j(\hat{\theta}) = j(\hat{\theta}; \mathbf{x})$. Benyttes den sidstnævnte, opnås approksimationen

$$(\hat{\theta} - \theta)^* j(\hat{\theta}) (\hat{\theta} - \theta) \approx \chi^2(k) \quad \text{eller, når } k = 1: \quad (\hat{\theta} - \theta)^2 j(\hat{\theta}) \approx \chi^2(1). \quad (6.34)$$

Igen er denne approksimation god, hvis $\mathbf{x}$ er én observationsrække $x_1, \dots, x_n$ fra en fordeling og n er stor.

I stedet for at approksimere fordelingen for likelihood ratio testoren $Q(\mathbf{X})$, betragter man sædvanligvis approksimationer for fordelingen af størrelsen $-2 \ln Q(\mathbf{X})$. Den approksimerende fordeling afhænger af, om hypotesen, der testes, er simpel eller sammensat. Mere præcist har man følgende approksimative resultat for fordelingen af $-2 \ln Q(\mathbf{X})$ i det tilfælde, hvor hypotesen H_0 er en *simpel* hypotese, der siger, at værdien af den k -dimensionale parameter er θ

$$-2 \ln Q(\mathbf{X}) \approx \chi^2(k). \quad (6.35)$$

Approksimationen er en konsekvens af formlerne (6.29) og (6.34), idet man ved hjælp af disse formler finder, at

$$\begin{aligned} -2 \ln Q(\mathbf{X}) &= -2 \ln \frac{L(\theta)}{L(\hat{\theta})} \\ &= -2(l(\theta) - l(\hat{\theta})) \\ &\approx (\hat{\theta} - \theta)^* j(\hat{\theta}) (\hat{\theta} - \theta) \\ &\approx \chi^2(k). \end{aligned}$$

Små værdier af likelihood ratio testoren Q er kritiske for H_0 , hvilket er ækvivalent med at store værdier af $-2 \ln Q(\mathbf{X})$ er kritiske. Af formel (6.35) får vi derfor følgende vigtige *approksimation for testsandsynligheden for likelihood ratio testet for den simple hypotese θ*

$$p_{obs}(\mathbf{x}) \doteq 1 - F_{\chi^2(k)}(-2 \ln Q(\mathbf{x})), \quad (6.36)$$

idet vi ved hjælp af (6.15) finder, at

$$\begin{aligned} p_{obs}(\mathbf{x}) &= P_{\theta}(Q(\mathbf{X}) \leq Q(\mathbf{x})) \\ &= P_{\theta}(-2 \ln Q(\mathbf{X}) \geq -2 \ln Q(\mathbf{x})) \\ &= 1 - P_{\theta}(-2 \ln Q(\mathbf{X}) < -2 \ln Q(\mathbf{x})) \\ &\doteq 1 - F_{\chi^2(k)}(-2 \ln Q(\mathbf{x})). \end{aligned}$$

Her har vi ved $\doteq$ brugt formel (6.35) samt den kendsgerning, at fordelingsfunktionen for $\chi^2(k)$ -fordelingen er kontinuert.

For likelihood ratio testoren af en *sammensat hypotese* $H_0 : \boldsymbol{\theta} \in \Theta_0$, hvor $\Theta_0 \subseteq \Theta$, gælder der approksimationer analoge til (6.35) og (6.36). For at formulere disse resultater behøver vi følgende notation. En hypotese $H_0 : \boldsymbol{\theta} \in \Theta_0$ siges at have d *frie parametre* $\check{\theta}_1, \dots, \check{\theta}_d$, hvis der eksisterer et område $\check{\Theta} \subset \mathbb{R}^d$ og en en-entydig afbildning af $\check{\Theta}$ på Ω_0 , det vil sige

$$\begin{aligned} \check{\Theta} \subseteq \mathbb{R}^d &\rightarrow \Theta_0 \subseteq \mathbb{R}^k \\ \check{\boldsymbol{\theta}} = (\check{\theta}_1, \dots, \check{\theta}_d)^* &\rightarrow \boldsymbol{\theta}(\check{\boldsymbol{\theta}}) = (\theta_1(\check{\boldsymbol{\theta}}), \dots, \theta_k(\check{\boldsymbol{\theta}}))^*. \end{aligned} \quad (6.37)$$

Bemærk, at idet vi har antaget, at parameterrummet Θ er et område, kan grundmodellen betragtes som en hypotese med de k frie parametre $\theta_1, \dots, \theta_k$. Bemærk endvidere, at for en simpel hypotese er $d = 0$.

Under visse regularitetsbetingelser, som stort set altid er opfyldt i praksis, har vi følgende *approximationer for likelihood ratio testoren af en sammensat hypotese med d frie parametre*

$$-2 \ln Q(\mathbf{X}) \approx \chi^2(k - d), \quad (6.38)$$

og

$$p_{obs}(\mathbf{x}) \doteq 1 - F_{\chi^2(k-d)}(-2 \ln Q(\mathbf{x})). \quad (6.39)$$

Det ses af (6.38), at antallet af frihedsgrader i den approksimerende χ^2 -fordeling er lig med $k - d$, hvor k er antallet af frie parametre i grundmodellen (svarende til Θ) og d er antallet af frie parametre i hypotesen (svarende til Θ_0).

6.8 Afsluttende bemærkninger

Som nævnt i indledningen opfatter vi hovedbestanddelene i en statistisk analyse som

- i) modelopstilling
- ii) modelkontrol
- iii) statistisk inferens

Som regel gennemløber analysen en eller flere cykliske faser, idet man ved ii) eller iii) opdager utilfredsstillende træk ved modellen og derfor går tilbage til i) for at revidere den.

Vi har tidligere i dette afsnit bemærket at det ofte er en del af en statistisk analyse at undersøge, om en enklere statistisk model end den, der som udgangspunkt blev opstillet, giver en tilfredsstillende beskrivelse af data, og vi har skitseret, hvordan vi bruger statistiske tests til at vurdere det. Det er her meget vigtigt at være opmærksom på, at man aldrig med statistiske tests kan bevise noget. Man kan kun modbevise i den forstand, at man kan overbevise sig om, at data strider mod en simplere model. Hvis man har begrænsede data kan man risikere ikke at kunne afvise reduktionen til en simpel model, som måske i virkeligheden er forkert. Det er derfor et moralsk krav helst på forhånd at sikre sig at man har en chance for at opdage at en hypotese er falsk.

Kapitel 7

Estimatorers egenskaber

I dette kapitel giver vi forskellige uddybende bemærkninger vedrørende estimatorer og disses egenskaber. Kapitlet er et supplement til afsnit 6.3 i [Chihara and Hesterberg \[2018\]](#).

7.1 Tilstrækkelig betingelse for konsistens

Ved hjælp af Markovs ulighed kan Proposition 6.5 i [Chihara and Hesterberg \[2022\]](#) (Proposition 6.3.4 i [Chihara and Hesterberg \[2018\]](#)) bevises.

Sætning 7.1 (Markovs ulighed)

Lad X være en ikke-negativ stokastisk variabel. Så gælder for alle $c > 0$

$$\mathbb{P}(X \geq c) \leq \frac{EX}{c}. \quad (7.1)$$

♦

Bevis. Bevises her for en kontinuert stokastisk variabel X med tæthed f :

$$\begin{aligned} EX &= \int_0^\infty xf(x)dx \\ &\geq \int_c^\infty xf(x)dx \\ &\geq \int_c^\infty cf(x)dx \\ &= c\mathbb{P}(X \geq c). \end{aligned} \quad \square$$

Til beviset i bogen af Proposition [7.2](#) bruges Chebyshevs ulighed (se nedenfor), men det er lettere at bruge Markovs ulighed. Propositionen er formuleret som Proposition 6.5 i [Chihara and Hesterberg \[2022\]](#) (Proposition 6.3.4 i [Chihara and Hesterberg \[2018\]](#)).

Proposition 7.2

Lad $\{\hat{\theta}_n\}$ være en følge af estimatorer for θ . Hvis

$$\lim_{n \rightarrow \infty} E[\hat{\theta}_n] = \theta \quad \text{og} \quad \lim_{n \rightarrow \infty} \text{Var}[\hat{\theta}_n] = 0,$$

så er $\{\hat{\theta}_n\}$ en konsistent følge for θ . ♦

Bevis. Vi skal vise, at der for alle $\epsilon > 0$ gælder at $\mathbb{P}(|\hat{\theta}_n - \theta| \geq \epsilon) \xrightarrow{n \rightarrow \infty} 0$.

$$\begin{aligned} \mathbb{P}(|\hat{\theta}_n - \theta| \geq \epsilon) &= \mathbb{P}((\hat{\theta}_n - \theta)^2 \geq \epsilon^2) \\ &\leq \frac{E[(\hat{\theta}_n - \theta)^2]}{\epsilon^2} \\ &= \frac{\text{Var } \hat{\theta}_n + (\text{Bias } \hat{\theta}_n)^2}{\epsilon^2} \xrightarrow{n \rightarrow \infty} 0. \end{aligned} \quad \square$$

Markovs ulighed kan også bruges til at vise Chebyshevs ulighed:

Sætning 7.3 (Chebyshevs ulighed)

Betragt en stokastisk variabel X med endelig middelværdi μ og varians σ^2 , dvs $EX = \mu < \infty$ og $\text{Var } X = \sigma^2 < \infty$. Så gælder der for alle $k > 0$, at

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2} \quad \diamond$$

Bevis.

$$\begin{aligned} \mathbb{P}(|X - \mu| \geq k) &= \mathbb{P}((X - \mu)^2 \geq k^2) \\ &\leq \frac{E[(X - \mu)^2]}{k^2} \\ &= \frac{\text{Var } X}{k^2} = \frac{\sigma^2}{k^2}. \end{aligned} \quad \square$$

Der følger umiddelbart, at stikprøvegennemsnit er en konsistent estimator for middelværdien, hvis middelværdi og varians er endelige.

Korollar 7.4 (Konsistens af stikprøvegennemsnit)

Lad $\bar{X}_n$ være følgen af gennemsnittene af stikprøver af størrelse n fra en fordeling med endelig middelværdi μ og endelig varians σ^2 . Så gælder

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \xrightarrow{n \rightarrow \infty} 0. \quad \diamond$$

7.2 Jensens ulighed

I [Chihara and Hesterberg \[2022\]](#) Afsnit 6.3.5, omtales *transformationsinvariants* af maksimum likelihood estimatoren. Ved dette menes at hvis vi skifter fra parameteren θ til en parameter ρ på formen $\rho = h(\theta)$ hvor h er en bijektiv funktion, så gælder at hvis $\hat{\theta}$ er maksimum likelihood estimator for parameteren θ , så er $\hat{\rho} = h(\hat{\theta})$ maksimum likelihood estimator for $\rho = h(\theta)$.

Eksempel 7.5.

Familien af eksponentialfordelinger $E(\lambda)$, givet ved fordelingsfunktionen

$$F(x; \lambda) = 1 - e^{-\lambda x}$$

kan i **R** specificeres ved enten parameteren **rate**, som svarer til vores λ , eller ved parameteren **scale**, som er givet ved $1/\lambda$. Scale parameteren betegnes tit med symbolet β . Vi kan altså skrive fordelingsfunktionerne som

$$F(x; \beta) = 1 - e^{-x/\beta},$$

og den bijektive afbildning der afbilleder parametrene på hinanden er

$$h : \lambda \mapsto \beta, \quad \beta = 1/\lambda.$$

□

Desværre nedarves unbiasedness ikke på samme måde. Dette følger af en velkendt sætning af den danske ingeniør og (amatør)matematiker Johan Jensen*.

I sætningen omtales en *ikke-degenereret* stokastisk variabel. En stokastisk variabel er *degenereret*, hvis den er konstant med sandsynlighed 1, altså, hvis der eksisterer c så $\mathbb{P}(X = c) = 1$, og en stokastisk variabel er *ikke-degenereret*, hvis den ikke er degenereret.

Sætning 7.6 (Jensens ulighed) Lad X være en stokastisk variabel med værdier i $\mathbb{R}$, med middelværdi $\mu = EX$, og lad $g : \mathbb{R} \rightarrow \mathbb{R}$ være en *konveks* funktion. Så gælder der, at

$$E[g(X)] \geq g(EX).$$

Når g er strengt konveks, og X er ikke-degenereret, så er $Eg(X) > g(EX)$. For *konkave* funktioner h gælder omvendt, at $Eh(X) \leq h(EX)$. ♦

Hvad er en konveks funktion? Grafen af konveks funktion er opad hult, og hvis man tegner en korde, så ligger grafen i intervallet mellem de to skæringspunkter under korden. Når man tegner en tangent, så ligger hele grafen over tangenten, se Figur 7.1. Dette udnyttes i beviset.

Bevis (Jensens ulighed). Betragt en stokastisk variabel X med værdier i $\mathbb{R}$, som ikke er en konstant. Vi antager også, at middelværdien $\mu = EX$ er et reelt tal. Lad $g : \mathbb{R} \rightarrow \mathbb{R}$ være en strengt konveks funktion, og lad tangenten af g i punktet $x = \mu$ være givet ved

$$t(x) = g(\mu) + m \cdot (x - \mu).$$

Tallet m er tangentens hældning, og når g er differentiabel, så er $m = g'(\mu)$. Da g er strengt konveks, så gælder, at


$$g(x) > t(x) \quad x \neq \mu.$$

Da X ikke er konstant, gælder

$$\begin{aligned} g(x) > t(x), \quad x \neq \mu &\implies E[g(X)] > Et(X) \\ &= E[g(\mu) + m \cdot (X - \mu)] \\ &= E[g(\mu)] + m \cdot (E[X] - E[\mu]) \\ &= g(\mu). \end{aligned}$$

□

*selvom han ikke havde PhD i matematik var han alligevel formand for Dansk Matematisk Forening fra 1892–1903



Figur 7.1: Ved konvekse funktioner ligger tangenter under grafen, mens de ved konkave funktioner ligger over grafen.

Beviset for konkave funktioner følger ved at bruge, at for enhver konkav funktion h gælder, at g , givet ved $g(x) = -h(x)$, er konveks.

Remark Hvis en funktion g er to gange differentiabel, så er g strengt konveks hvis $g''(x) > 0$ for alle x i definitionsmængden, og strengt konkav, hvis $g''(x) < 0$ for alle x i definitionsmængden. $\square$

Kapitel 8

Multinomialmodellen

Mon ikke de fleste kender fornemmelsen af, at der aldrig kommer nogen seksere på terningen, når man spiller ludo. Man taler generelt om, at en terning er “ærlig”, hvis de seks sider kommer op lige ofte. Hvis man skal teste, om en ludoterning er ærlig, vil man nok kaste den et stort antal gange og tælle op, hvor ofte side 1 kom op, hvor ofte side 2 og så videre. På denne måde får man seks observerede antal, der skal sammenlignes med seks ens forventede antal. Hvordan skal man foretage denne sammenligning?


Situationen med terningeksperimentet er en generalisation af binomialmodellen. I binomialmodellen har hvert “kast” to mulige udfald. Vi siger, at kastet kan ramme ned i en af to “kasser”. I terningsituationen kan man i hvert kast ramme ned i en af seks kasser. Modellen til at beskrive denne situation generelt hedder *multinomialmodellen* og beskrives i Afsnit 8.1.

I eksemplet ovenfor med terningekast er hypotesen, at de seks sandsynligheder for de seks sider af terningen alle er $\frac{1}{6}$. Under hypotesen kender vi altså sandsynlighederne for at falde i de forskellige “kasser”, og på denne måde ligner dette situationen med test for en given værdi af sandsynlighedsparmeteren i en binomialmodel. Mere generelt kan en hypotese dog bestå i, at der lægges restriktioner på, hvordan sandsynlighederne kan variere, uden at angive sandsynlighederne med en numerisk værdi. Et eksempel på dette er, hvor en genetisk egenskab er bestemt af to *alleler*. Hvis de to alleler kaldes a og A , har vi tre *genotyper* aa , aA og AA . Hvis en population er i *Hardy-Weinberg ligevægt* er sandsynlighederne for de tre genotyper θ^2 , $2\theta(1 - \theta)$ og $(1 - \theta)^2$, hvor θ , $0 \leq \theta \leq 1$, er en ukendt parameter, der fortolkes som andelen af a -allelen i populationen, se Figur 8.1 for en illustration. I afsnittene 8.2 og 8.3 indføres et generelt test (likelihood ratio test) for at håndtere denne type situation. Testet indføres først i binomialmodellen for at gøre beskrivelsen mere simpel.

Testet kan blandt andet bruges til at undersøge, om en række observationer $x_1, \dots, x_n$ stammer fra en bestemt fordeling. Man taler i denne sammenhæng om et *goodness of fit test*. Dette beskrives og eksemplificeres i Afsnit 8.4

Kapitel 8 afsluttes med at se på situationen, hvor der er flere grupper af multinomialfordelte data, og man ønsker at sammenligne disse. For det biologiske eksempel ovenfor med en opdeling på tre genotyper aa , aA og AA , kan vi have data fra forskellige lokationer og ønsker at se, om der er samme

fordeling på de tre genotyper. Dette beskrives i afsnittene 8.5 og 8.6. Endelig omtales i Afsnit 8.8 hvordan en p -værdi kan beregnes ved simulationer.



Figur 8.1: Illustration of Hardy-Weinberg ligevægt. Den grønne trekant er sandsynlighederne p_1, p_2, p_3 der opfylder at $p_1 + p_2 + p_3 = 1$. Den røde kurve svarer til Hardy-Weinberg ligevægt, hvor $p_1 = \theta^2$, $p_2 = 2(1 - \theta)\theta^2$ og $p_3 = (1 - \theta)^2$ for $0 \leq \theta \leq 1$.

8.1 Multinomialmodellen

Vi indfører multinomialmodellen ved først at vende tilbage til binomialmodellen. Hvis $X \sim \text{binom}(n, p)$, kan vi skrive

$$X = B_1 + B_2 + \cdots + B_n,$$


hvor B_i 'erne er uafhængige *Bernoulli*(p) variable, dvs. stokastiske variable, der antager værdien 0 eller 1 med sandsynlighederne henholdsvis $1 - p$ og p . Billedligt kan dette opfattes sådan, at data inddeles i to kasser: alle B_i 'er, der er 0, havner i den ene kasse, mens dem med værdien 1 havner i den anden kasse.

I multinomialmodellen er der flere end to kasser, lad os sige k kasser, og vi kan betragte modellen som en beskrivelse af n uafhængige kast med en generaliseret k -sided terning. Hvert kast svarer til en stokastisk variabel B_i , $i = 1, \dots, n$, hvor mulige værdier er $1, 2, \dots, k$. Vi kan billedligt sige, at hvert kast "lander" i én af de k kasser.

Den stokastiske variabel A_j , $j = 1, \dots, k$, angiver, hvor mange af de n kast der lander i kasse j . Sandsynligheden for at landet i kasse j i det enkelte kast er π_j , hvor $\pi_j \geq 0$ og $\pi_1 + \cdots + \pi_k = 1$. Vektoren $(A_1, \dots, A_k)$ af antallet i de k kasser siges at være *multinomialfordelt*:

$$(A_1, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k))$$

med antalsværdi n og sandsynlighedsparameter $(\pi_1, \dots, \pi_k)$.



Figur 8.2: Illustration of multinomialfordelingen

For multinomialmodellen har vi følgende resultater:

Model: $(A_1, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k))$, $\pi_j \geq 0$, $\pi_1 + \dots + \pi_k = 1$:

$$P((A_1, \dots, A_k) = (a_1, \dots, a_k)) = \binom{n}{a_1, \dots, a_k} \pi_1^{a_1} \cdots \pi_k^{a_k}, \quad a_j \geq 0, \quad a_1 + \dots + a_k = n,$$

$$A_j \sim \text{binom}(n, \pi_j), \quad \mathbb{E}(A_j) = n\pi_j, \quad \text{Var}(A_j) = n\pi_j(1 - \pi_j).$$

Multinomialkoefficienten $\binom{n}{a_1, \dots, a_k}$ er defineret som $\frac{n!}{a_1! \cdots a_k!}$ og kan fortolkes som antallet af måder, hvorpå man kan vælge $b_1, \dots, b_n$, således at a_1 af dem har værdien 1, a_2 har værdien 2, og så fremdeles, indtil a_k har værdien k . At A_j er binomialfordelt følger af, at man kan reducere problemet til, om det enkelte kast falder i kasse j eller ikke.

8.1.1 Multinomialkoefficienten

Binomialkoefficienten $\binom{n}{x} = n!/(x!(n-x)!)$ angiver, hvor mange måder man kan udvælge x elementer fra n elementer. Dette kan vises ved induktion. Lader vi $c_{n,x}$ betegne antallet af måder at vælge x ud af n elementer, kan man argumentere for, at

$$c_{n+1,x} = c_{n,x-1} + c_{n,x},$$

fordi man deler op efter, om man blandt de n første elementer allerede har valgt x eller $x-1$. Ved hjælp af induktion kan man nu vise, at

$$c_{n,x} = \frac{n!}{x!(n-x)!}.$$

Hvis vi i stedet betragter antallet af måder, hvorpå man kan fordele n elementer i k kasser, med a_j elementer i kasse j , $j = 1, \dots, k$, kan man først udvælge dem, der skal i kasse 1, dernæst dem, der

skal i kasse 2, og så fremdeles. Dette giver at antallet af måder er

$$\begin{aligned} c_{n,a_1} c_{n-a_1,a_2} c_{n-a_1-a_2,a_3} \cdots c_{a_k,a_k} &= \frac{n!}{a_1!(n-a_1)!} \frac{(n-a_1)!}{a_2!(n-a_1-a_2)!} \frac{(n-a_1-a_2)!}{a_3!(n-a_1-a_2-a_3)!} \cdots 1 \\ &= \frac{n!}{a_1!a_2! \cdots a_k!}. \end{aligned}$$

Dette giver formelen for multinomialkoefficienten $\binom{n}{a_1, a_2, \dots, a_k}$.

8.1.2 Estimation i den fulde model

I multinomialmodellen $(A_1, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k))$ er likelihoodfunktionen

$$L(\pi_1, \dots, \pi_k) = \binom{n}{a_1, \dots, a_k} \pi_1^{a_1} \cdots \pi_k^{a_k}, \quad (8.1)$$

og maksimum af denne funktion over området $\pi_j \geq 0$, $\pi_1 + \cdots + \pi_k = 1$ (kaldet den *fulde model*), fås i punktet

$$\hat{\pi}_j = \frac{a_j}{n}, \quad j = 1, \dots, k.$$

Eftersom $A_j \sim \text{binom}(n, \pi_j)$, er dette helt i overensstemmelse med estimationen i binomialmodellen i Proposition 6.1 i [Chihara and Hesterberg \[2022\]](#) *. I ord estimeres sandsynligheden for at falde i kasse j med den observerede frekvens i kasse j .

Bevis for estimator

I ved fra binomialmodellen, at maksimum af $p^x(1-p)^{n-x}$, $0 \leq p \leq 1$ opnås for $\hat{p} = x/n$. Dette gælder også, hvis $x = 0$ eller $x = n$. Når $\pi_1^{a_1} \pi_2^{a_2} \cdots \pi_k^{a_k}$ skal maksimeres over mængden $\{\pi_j \geq 0, \pi_1 + \cdots + \pi_k = 1\}$, laver vi en omparametrisering og skriver

$$\begin{aligned} \pi_1 &= p, \pi_2 = (1-p)v_2, \pi_3 = (1-p)v_3, \dots, \pi_k = (1-p)v_k, \\ (p, v_2, \dots, v_k) &\in [0, 1] \times \{v_j \geq 0, v_2 + \cdots + v_k = 1\}. \end{aligned}$$

Med denne omparametrisering opnås

$$\pi_1^{a_1} \pi_2^{a_2} \cdots \pi_k^{a_k} = \left\{ p^{a_1} (1-p)^{n-a_1} \right\} \cdot \left\{ v_2^{a_2} \cdots v_k^{a_k} \right\},$$

og maksimum findes ved at maksimere hvert led for sig. Det første led er som likelihoodfunktionen i binomialmodellen, og vi ved derfor, at


$$\hat{\pi}_1 = \hat{p} = \frac{a_1}{n}.$$

I ovenstående argument lavede vi omparametriseringen med udgangspunkt i π_1 , men kunne have brugt et vilkårligt π_j , $j = 1, \dots, k$, som udgangspunkt. Vi har derfor generelt, at $\hat{\pi}_j = a_j/n$, $j = 1, \dots, k$.

*Proposition 6.1.1 i [Chihara and Hesterberg \[2018\]](#)

8.2 Indledning til G-test

Hvis vi betragter $X \sim \text{binom}(n, p)$, er dette et specialtilfælde af multinomialmodellen, idet $(X, n - X) \sim \text{multinom}(n, (p, 1 - p))$. I Afsnit 6.1.1 i [Chihara and Hesterberg \[2022\]](#) bruges likelihood-funktionen $L(p)$ til at finde et skøn over p . Vi anvender nemlig den værdi $\hat{p}$, der maksimerer likelihood-funktionen. Dette er illustreret i Figur 8.3, hvor vi afbilder log-likelihoodfunktionen baseret på observationen 19 fra en $\text{binom}(25, p)$ -fordeling.



Figur 8.3: log-likelihoodfunktionen for $x = 19$ i $\text{binom}(25, p)$ -fordelingen

I Afsnit 8.1.2 i [Chihara and Hesterberg \[2022\]](#) vurderes holdbarheden af hypotesen $p = p_0$ ved at se på, hvor langt X ligger fra det forventede np_0 , eller ækvivalent hvor langt $\hat{p} = \frac{X}{n}$ ligger fra p_0 . Dette svarer til den med grønt markerede afstand på førsteaksen i Figur 8.3. Vi kan imidlertid også bruge likelihoodfunktionen til at konstruere et test af hypotesen $p = p_0$. Til dette formål betragter vi likelihood ratio teststørrelsen

$$Q = \frac{L(p_0)}{L(\hat{p})},$$

Dette svarer til den gule markerede afstand på andenaksen i Figur 8.3. Fordelen ved at bruge Q er, at denne metode let kan generaliseres til mere komplekse situationer. Det gør vi i 8.3, hvor vi tester en hypotese i multinomialmodellen.

Som omtalt i Kapitel 6 ligger værdien af Q mellem 0 og 1, og små værdier er kritiske for hypotesen. En lille værdi betyder, at sandsynligheden for det observerede er betydeligt mindre under $p = p_0$ end under $p = \hat{p}$. Traditionelt transformerer man Q til

$$G = -2 \ln(Q),$$

hvor store værdier nu er kritiske for hypotesen. Da $\hat{p} = X/n$, får man

$$Q = \frac{\binom{n}{X} p_0^X (1-p_0)^{n-X}}{\binom{n}{X} \left(\frac{X}{n}\right)^X \left(1 - \frac{X}{n}\right)^{n-X}} = \frac{1}{\left(\frac{X}{np_0}\right)^X \left(\frac{n-X}{n(1-p_0)}\right)^{n-X}},$$

og dermed

$$G = -2 \log(Q) = 2 \left(X \log\left(\frac{X}{np_0}\right) + (n-X) \log\left(\frac{n-X}{n(1-p_0)}\right) \right).$$

Idet vi betragter $(X, n-X)$ som multinomialfordelt, er np_0 og $n(1-p_0)$ de forventede antal i de to "kasser" under hypotesen $p = p_0$. Ovenstående udtryk for G kan derfor læses som *2 gange summen over kasser af det observerede antal ganget med logaritmen til det observerede antal divideret med det forventede antal*. I 8.3 vil vi genfinde netop dette udtryk i en mere generel form.

8.2.1 Inferens om fraktion

Betragt binomialmodellen $X \sim \text{binom}(n, p)$, hvor vi ønsker at teste hypotesen $p = p_0$ baseret på en observation x . Hvis alternativet er tosidet, $p \neq p_0$, angiver Chihara and Hesterberg [2022] i Afsnit 8.1.2 p -værdien som

$$p\text{-værdi} = \begin{cases} 2P(X \leq x) & x \leq np_0, \\ 2P(X \geq x) & x > np_0. \end{cases}$$

Metoden med at gange med to skyldes, at man vil gøre beregningerne simple, men det betyder, at denne p -værdi ikke følger den generelle definition, hvor p -værdien er sandsynligheden for det, der er lige så kritisk eller mere kritisk end det observerede. Med **R** til rådighed kan vi sagtens lave metoder, der følger definitionen.

Vi gennemgår tre metoder. Med brug af **R**-notation for binomialsandsynligheder kan alle tre metoder skrives på formen

$$p\text{-værdi} = \sum_{z \in K(x)} \text{dbinom}(z, n, p_0),$$

hvor de tre metoder svarer til valgene

$$\begin{aligned} \text{Afstand: } K(x) &= \{z : |z - np_0| \geq |x - np_0|\}, \\ \text{Tæthed: } K(x) &= \{z : \text{dbinom}(z, n, p_0) \leq \text{dbinom}(x, n, p_0)\}, \\ \text{Likelihoodratio: } K(x) &= \{z : Q(z) \leq Q(x)\}. \end{aligned} \tag{8.2}$$

De tre metoder er implementeret på R-kode 8.3, hvor p -værdien for hypotesen om at sandsynligheden for at slå 6 er 1/6 i en situation hvor vi har slået 10 seksere i 100 slag er beregnet. Vi ser af R-udskrift 8.3 at p -værdien ved de tre metoder beregnes til

Afstand	Tæthed	LikRat
0.08056	0.08056	0.064399

Som konfidensinterval for sandsynlighedsparameteren p i binomialmodellen bruger vi (7.15) og (7.16) i [Chihara and Hesterberg \[2022\]](#), som kan skrives kort som

$$\frac{x + \frac{u^2}{2} \pm u \sqrt{\frac{x(n-x)}{n} + \frac{u^2}{4}}}{n + u^2},$$

hvor $u = 1.96$ for at få et approksimativt 95%-konfidensinterval. I dette tilfælde findes konfidensintervallet på R-kode [8.4](#) til (0.05523, 0.1747).

Vi vil nu betragte et eksempel på en hypotese i multinomialmodellen

Eksempel 8.1.

Data i tabellen nedenfor viser, for 100 kvinder (alle rygere og alle med et ønske om at blive gravide), hvor mange menstruationscyklusser der forløber, inden det lykkes at blive gravid. Af de 100 kvinder bliver 29 gravide ved første forsøg, 16 ved andet forsøg osv.

Cyklusnummer	1	2	3	4	5	6	≥ 7
Antal kvinder	29	16	17	4	3	9	22

Tabel 8.1: Antal kvinder fordelt på cyklusnummer

Det er naturligt at tænke på data i tabellen som et udfald fra en multinomialmodel,

$$(A_1, \dots, A_7) \sim \text{multinom}(100, (\pi_1, \dots, \pi_7)), \quad \pi_j \geq 0, \quad \pi_1 + \dots + \pi_7 = 1.$$

Hvis sandsynligheden for at blive gravid i et enkelt forsøg er θ for alle kvinderne, er det relevant at betragte hypotesen

$$H_0 : \pi_1 = \theta, \quad \pi_2 = (1 - \theta)\theta, \quad \pi_3 = (1 - \theta)^2\theta, \dots, \pi_6 = (1 - \theta)^5\theta, \quad \pi_7 = (1 - \theta)^6, \quad 0 < \theta < 1. \quad (8.3)$$

For at blive gravid i andet forsøg kræves det, at man *ikke* bliver gravid i første forsøg (sandsynlighed $1 - \theta$) og *derefter* bliver gravid i andet forsøg (sandsynlighed θ). Derfor er sandsynligheden $\pi_2 = (1 - \theta)\theta$. Sandsynligheden for *ikke* at blive gravid i nogen af de seks første forsøg er $\pi_7 = (1 - \theta)^6$.

Hypotesen, der er beskrevet her, svarer til at antallet af forsøg, der kræves for at opnå graviditet, er *geometrisk fordelt*. En stokastisk variabel X siges at være geometrisk fordelt med parameter θ , hvis

$$P(X = x) = (1 - \theta)^{x-1} \theta, \quad x = 1, 2, 3, \dots$$

Data i dette eksempel stammer fra artiklen [The Beta-geometric distribution applied to comparative fecundability studies](#). □

8.3 G-teststørrelsen

Vi vil nu formulere en generel hypotese i multinomialfordelingen.

Udgangspunktet er modellen

$$M_0 : (A_1, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k)), \quad \pi_j \geq 0, \quad \pi_1 + \dots + \pi_k = 1. \quad (8.4)$$

I hypotesen indgår en ukendt parametervektor $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_d)^*$, der, som indikeret, generelt ligger $\mathbb{R}^d$. Hvis $d = 1$ er $\boldsymbol{\theta} = \theta$ og der er én parameter. Dette var situationen i Eksempel 8.1. I dette tilfælde kan vi opskrive hypotesen som

$$H_0 : \pi_j = p_j(\theta), \quad j = 1, \dots, k, \quad \theta \in \Theta, \quad (8.5)$$

hvor $p_j(\cdot)$ er kendte funktioner af θ , og Θ er en åben delmængde af $\mathbb{R}$. I Eksempel 8.1 var $\Theta =]0, 1[$. Hypotesen lægger altså begrænsninger på variationsområdet for $(\pi_1, \dots, \pi_k)$. For generelt d kan hypotesen skrives som

$$H_0 : \pi_j = p_j(\boldsymbol{\theta}), \quad j = 1, \dots, k, \quad \boldsymbol{\theta} \in \Theta, \quad (8.6)$$

hvor Θ er et område (jvf. s. 175) i $\mathbb{R}^d$. I både (8.5) og (8.6) betragtes $\boldsymbol{\theta}$ som ukendt og skal estimeres fra data. Da $\boldsymbol{\theta} = (\theta_1, \dots, \theta_d)^*$ varierer i $\mathbb{R}^d$ vil vi sige at modellen har d frie parametre. Under hypotesen betegnes den statistiske model med M_1 , og vores ønske om at teste hypotesen kan også formuleres som at vi ønsker at teste reduktion fra model M_0 til model M_1 .

Formelt beskrives modellerne ved delmængder af $\mathbb{R}^k$. Betegnes vektoren af sandsynligheder med $\boldsymbol{\pi}$, dvs. $\boldsymbol{\pi} = (\pi_1, \pi_2, \dots, \pi_k)^*$ vil variationsområdet for $\boldsymbol{\pi}$ under M_0 fra (8.4) være

$$\Pi_0 = \left\{ \boldsymbol{\pi} \in \mathbb{R}^k \mid \pi_j > 0, \quad j = 1, \dots, k, \quad \sum_{j=1}^k \pi_j = 1 \right\}$$

og M_0 kan kort formuleres

$$M_0 : \boldsymbol{\pi} \in \Pi_0.$$

Hypotesen kan specificeres ved hjælp af billedmængden $\boldsymbol{\pi}(\Theta) = \Pi$ som

$$M_1 : \boldsymbol{\pi} \in \Pi.$$

Som skøn over $\boldsymbol{\theta}$ bruges den værdi, der giver maksimum af likelihoodfunktionen $L_1(\boldsymbol{\theta})$:

$$L_1(\boldsymbol{\theta}) = L(p_1(\boldsymbol{\theta}), \dots, p_k(\boldsymbol{\theta})),$$

hvor $L(\cdot)$ er givet i ligning (8.1).

Vi kan nu beregne *likelihoodratio teststørrelsen* Q , som er forholdet mellem den maksimale værdi af likelihoodfunktionen under model M_1 og den maksimale værdi af likelihoodfunktionen under model M_0 . Ved samme beregning som i Afsnit 8.2 finder vi

$$Q = \frac{\binom{n}{A_1, \dots, A_k} p_1(\hat{\boldsymbol{\theta}})^{A_1} \dots p_k(\hat{\boldsymbol{\theta}})^{A_k}}{\binom{n}{A_1, \dots, A_k} \left(\frac{A_1}{n}\right)^{A_1} \dots \left(\frac{A_k}{n}\right)^{A_k}} = \frac{1}{\left(\frac{A_1}{np_1(\hat{\boldsymbol{\theta}})}\right)^{A_1} \dots \left(\frac{A_k}{np_k(\hat{\boldsymbol{\theta}})}\right)^{A_k}},$$

og dermed

$$G = -2 \ln(Q) = 2 \sum_{j=1}^k A_j \ln\left(\frac{A_j}{e_j}\right), \quad e_j = np_j(\hat{\theta}). \quad (8.7)$$

Her kaldes e_j det *forventede antal* i kasse j under hypotesen (under model M_1).

En lille værdi af Q betyder som bekendt, at data beskrives meget dårligere under model M_1 end under model M_0 . Jo mindre værdi af Q , jo mere kritisk for hypotesen. Dette er det samme som, at jo større G er, jo mere kritisk. P -værdien for et test baseret på G er derfor sandsynligheden for ved gentagelse af eksperimentet at få en værdi af G , der er større end eller lig med den faktisk observerede værdi af G . Til beregning af p -værdien har vi følgende resultat.

Resultat 8.3.1

Betragt multinomialmodellen $(A_1, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k))$, $\pi_j \geq 0$, $\pi_1 + \dots + \pi_k = 1$ (model M_0) og hypotesen $\pi_j = p_j(\theta)$, $j = 1, \dots, k$, hvor θ har d frie parametre (model M_1).
Betragt testoren

$$G = -2 \ln(Q) = 2 \sum_{j=1}^k A_j \ln\left(\frac{A_j}{e_j}\right), \quad e_j = np_j(\hat{\theta}),$$

og lad G_{obs} være den tilsvarende observerede værdi. Hvis alle de forventede $e_j = np_j(\hat{\theta})$ er større end eller lig med 5, har vi approksimativt

$$p\text{-værdi} = P(G \geq G_{\text{obs}}) = 1 - F_{\chi^2(k-1-d)}(G_{\text{obs}}).$$

Beviset for Resultat 8.3.1 er ikke nemt, men argumenterne er skitseret i Afsnit 6.7. Antallet af frihedsgrader $k - 1 - d$ i χ^2 -fordelingen er generelt $d(M_0) - d(M_1)$, hvor $d(M_j)$ er antallet af frie parametre i model M_j . I model M_0 har vi bindingen, at $\pi_1 + \dots + \pi_k = 1$, så antallet af frie parametre er $k - 1$.

Eksempel 8.1 (fortsat).

Vi vender tilbage til data omkring antal forsøg for at blive gravid, og laver G -testet for hypotesen beskrevet der.

Først skal vi finde et skøn over parameteren θ , hvor $\pi_j = (1 - \theta)^{j-1}\theta$, $j \leq 6$, og $\pi_7 = (1 - \theta)^6$. Likelihoodfunktionen bliver

$$\begin{aligned} L_1(\theta) &= \binom{100}{29, \dots, 18} \theta^{29} ((1 - \theta)\theta)^{16} ((1 - \theta)^2\theta)^{17} ((1 - \theta)^3\theta)^4 ((1 - \theta)^4\theta)^3 ((1 - \theta)^5\theta)^9 ((1 - \theta)^6)^{22} \\ &= \binom{100}{29, \dots, 22} \theta^{78} (1 - \theta)^{251}. \end{aligned} \quad (8.8)$$

□

Ved sammenligning med likelihoodfunktionen i binomialmodellen (jvf. Proposition 6.1 i [Chihara and Hesterberg \[2022\]](#)[†]) ses, at $\hat{\theta} = 78/(78 + 251) = 0.2371$.


[†]Proposition 6.1.1 i [Chihara and Hesterberg \[2018\]](#)

Dernæst beregnes de forventede antal som $e_j = 100 \cdot (1 - \hat{\theta})^{j-1} \hat{\theta}$, $j \leq 6$, og $e_7 = 100 \cdot (1 - \hat{\theta})^6$. Dette giver følgende tabel (forventede er afrundet til én decimal).

Cykelnummer	1	2	3	4	5	6	≥ 7
Antal kvinder	29	16	17	4	3	9	22
Forventede	23.7	18.1	13.8	10.5	8.0	6.1	19.7

Da alle de forventede værdier er mindst 5, beregner vi G -teststørrelsen og den approksimative p -værdi ud fra en χ^2 -fordeling med $7 - 1 - 1$ frihedsgrader. Ved beregning af frihedsgrader benyttes, at multinomialmodellen her opdeler observationerne i syv kasser, og at den testede hypotese indeholder én parameter (nemlig θ). Beregningen af teststørrelse og p -værdi er vist på side 221 og på R-udskrift 8.5 ser vi at $G_{\text{obs}} = 12.9$ og en p -værdi på 0.024. Fordi p -værdien er lav, er vi skeptiske over for holdbarheden af vores hypotese. På Figur 8.4 er den observerede værdi af teststørrelsen tegnet ind på tætheden for $\chi^2(5)$ -fordelingen sammen med den tilknyttede 95%-fraktil.

En mulig forklaring på resultatet er, at hver kvinde har sin egen værdi af θ , dvs. sin egen sandsynlighed for at blive gravid i ét enkelt forsøg. I så fald vil data repræsentere en blanding, der ikke kan beskrives på samme måde som den enkelte kvinde.



Figur 8.4: Tætheden for en $\chi^2(5)$ fordeling. Den grønne lodrette streg markerer og 95%-fraktilen og den gule markerer den observerede værdi af G -teststoren fra Eksempel 8.1.

8.4 Goodness of fit test

Vi skal nu bruge det generelle G -test i multinomialmodellen fra det foregående afsnit til at teste, at indsamlede data $x_1, x_2, \dots, x_n$ følger en bestemt fordeling. Dette går under navnet *Goodness of fit test*.

Ideen er, at talaksen deles op i en række intervaller, lad os sige k intervaller,

$$(-\infty, z_1], (z_1, z_2], \dots, (z_{k-2}, z_{k-1}], (z_{k-1}, \infty),$$

hvorefter der tælles op, hvor mange af observationerne $x_1, \dots, x_n$ der ligger i de forskellige intervaller

$$a_j = \{\text{antal } x_i\text{-er, der ligger i intervallet } (z_{j-1}, z_j]\}, \quad j = 1, \dots, k,$$

(her bruger vi $z_0 = -\infty$ og $z_k = \infty$, og intervallet $(a, b]$ går fra a til b med b , men ikke a , indeholdt i intervallet). Dette svarer til, at de n observationer er fordelt på k kasser, og de tilhørende stokastiske variable for antallene er derfor multinomialfordelt,

$$(A_1, \dots, A_k) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k)).$$

På grund af den måde data er indsamlet på, kan vi skrive

$$\pi_j = P(z_{j-1} < X \leq z_j), \quad j = 1, \dots, k.$$

I modellen M_0 er disse sandsynligheder vilkårlige:

$$M_0: \quad \pi_j \geq 0, \quad \sum_j \pi_j = 1.$$

Vi ønsker at teste, at X har en bestemt fordeling, der eventuelt afhænger af en parameter θ , der kan variere i området Θ . For at formulere dette betegnes fordelingsfunktionen (sandsynligheden for at ligge til venstre for et punkt) med $F(x, \theta)$. Vi kan nu formulere en ny model, eller specificere en hypotese, ved

$$M_1: \quad \pi_j = F(z_j, \theta) - F(z_{j-1}, \theta), \quad j = 1, \dots, k, \quad \theta \in \Theta.$$

Her skal $F(-\infty, \theta)$ erstattes af 0, og $F(\infty, \theta)$ skal erstattes af 1. Situationen her svarer til det generelle G -test med hypotesen $p_j(\theta) = F(z_j, \theta) - F(z_{j-1}, \theta)$, se ligning (8.5). Når skøn $\hat{\theta}$ over θ er fundet, bliver de forventede antal


$$e_j = n(F(z_j, \hat{\theta}) - F(z_{j-1}, \hat{\theta})), \quad j = 1, \dots, k.$$

For at bruge Resultat 8.3.1 skal man have, at alle de forventede er større end eller lig med 5. Hvis dette ikke er opfyldt, gør man traditionelt det, at man slår kasser sammen for at få kravet opfyldt.

Typisk vil man, når man laver et goodness of fit test, lave en grafisk fremstilling af data i form af et histogram, og i dette histogram indtegne tætheden for den fordeling, der undersøges.

Eksempel 8.2.

Data i denne opgave består af den daglige middelvind i Tirstrup gennem hele 2019. Data er hentet hos [Iowa Environmental Mesonet](#), og de daglige middelvinde er givet i kilometer per time. Et histogram er vist i Figur 8.5 Data af denne type beskrives ofte med [Weibullfordelingen](#), og i opgaven her



Figur 8.5: Histogram for målinger af middelvind fra Eksempel 8.2, sammen med tætheden for den estimerede Weibullfordeling.

skal der laves et goodness of fit test for, om Weibullfordelingen beskriver data. Hvis den stokastiske variabel X er Weibullfordelt, gælder der

$$P(X > x) = e^{-(x/\lambda)^\alpha}, \quad x \geq 0, \quad (8.9)$$

hvor α kaldes en formparameter og λ en skalaparameter.

Til at lave goodness of fit testet skal der benyttes en intervalinddeling med intervaller af længde 3 startende i nul. Desuden skal der bruges, at maksimum likelihood skønnene baseret på antallene i de forskellige intervaller er $\hat{\alpha} = 3.8851$ og $\hat{\lambda} = 36.1116$.

Idet den største værdi i data er 54, laver vi intervalinddelingen

$$(-\infty, 3], (3, 6], \dots, (48, 51], (51, \infty). \quad (8.10)$$

Antallene i de forskellige intervaller betegnes $(a_1, \dots, a_{18})$ og for de tilhørende stokastiske variable vælges modellen

$$(A_1, \dots, A_{18}) \sim \text{multinom}(365, (\pi_1, \dots, \pi_{18})), \quad \pi_j \geq 0, \quad \sum_j \pi_j = 1.$$

Vi ønsker at teste hypotesen

$$\begin{aligned} \pi_j &= F(3j, \alpha, \lambda) - F(3(j-1), \alpha, \lambda), \quad j = 1, \dots, 17, \\ \pi_{18} &= 1 - F(51, \alpha, \lambda), \quad \alpha, \lambda > 0, \end{aligned}$$

hvor $F(x, \alpha, \lambda)$ er fordelingsfunktionen for Weibullfordelingen, dvs. $F(x, \alpha, \lambda) = 1 - P(X > x)$. Ved at maksimere likelihoodfunktionen numerisk fås, at skønnene over de ukendte parametre er

$\hat{\alpha} = 3.8851$ og $\hat{\lambda} = 36.1116$. De forventede kan derfor beregnes som

$$\begin{aligned} e_j &= 365 \cdot (F(3j, 3.8851, 36.1116) - F(3(j-1), 3.8851, 36.1116)), \quad j = 1, \dots, 17, \\ e_{18} &= 1 - F(51, 3.8851, 36.1116). \end{aligned} \quad (8.11)$$

Fra R-kode 8.6 fås de observerede forventede for intervallerne fra (8.10), og disse er vist i Tabel 8.2.

Interval	$(-\infty, 3]$	$(3, 6]$	$(6, 9]$	$(9, 12]$	$(12, 15]$	$(15, 18]$	$(18, 21]$	$(21, 24]$	$(24, 27]$
Antal	0	0	0	1	9	12	22	26	37
Forventet	0.0	0.3	1.3	3.4	6.8	11.8	18.2	25.7	33.3

Interval	$(27, 30]$	$(30, 33]$	$(33, 36]$	$(36, 39]$	$(39, 42]$	$(42, 45]$	$(45, 48]$	$(48, 51]$	$(51, \infty)$
Antal	45	37	38	36	35	33	15	13	6
Forventet	39.8	44.0	44.5	41.1	34.3	25.7	17.0	9.8	8.0

Tabel 8.2: Observerede og forventede antal observationer for intervalinddelingen fra (8.10).

Som det fremgår af Tabel 8.2 er der nogle intervaller, hvor de forventede antal er under 5, hvilket ikke opfylder kravet i Resultat 8.3.1. For at sikre, at alle de forventede værdier er mindst 5, slår vi derfor de fire første kasser sammen. Dette giver det observerede antal 1 og det forventede antal 5.02. Efter denne sammenlægning er der 15 kasser i alt, og dermed bliver antallet af frihedsgrader for χ^2 -fordelingen $15 - 1 - 2 = 12$, idet vi under hypotesen har to frie parametre (α og λ).

G -teststørrelsen for vores hypotese beregnes ud fra formlen

$$G = 2 \sum_j \tilde{a}_j \log\left(\frac{\tilde{a}_j}{\tilde{e}_j}\right),$$

hvor $\tilde{a}_j$ og $\tilde{e}_j$ er de observerede og forventede antal, *efter* at kasser er slået sammen. Beregningen i R fra R-udskrift 8.7 viser, at $G = 13.72$, og den tilhørende p -værdi er

$$P(G \geq 13.72) = 1 - F_{\chi^2(12)}(13.72) = 0.32. \quad \square$$

Da p -værdien ligger betydeligt over 0.05, strider data ikke mod hypotesen om, at de daglige middelvinde følger en Weibullfordeling.

8.5 Homogenitetstest: hypotesen

Indtil nu har vi i dette kapitel udelukkende set på observationer fra én multinomialfordeling. Ofte vil man have observationer fra flere “populationer” og ønsker at sammenligne disse for at se, om der er samme forhold i populationerne. Her skal population forstås bredt. Det kan være biologiske populationer, men kan også være undersøgelser lavet på forskellige tidspunkter, eller for eksempel eksperimenter der gentages.

Eksempel 8.3.

Data i dette eksempel vedrører aktivitetsmønster for grupper af delfiner. Datasættet består af 72 delfingrupper observeret om morgenen, og 79 delfingrupper observeret om aftenen tæt på Keflavik



□

på Island. Data er af Marianne Rasmussen (SDU) lagt op på [StatSci.org](https://statsci.org). Delfingrupperne er klassificeret efter hovedaktivitet, som kan være enten *Rejse*, *Spise* eller *Leg*. Fordelingen på de tre aktivitetskategorier er som følger:

	Rejse	Spise	Leg	Total
Morgen	6	28	38	72
Aften	13	56	10	79

Biologerne ønsker at vurdere, om der er samme aktivitetsmønster om morgenen som om aftenen.

Vi vil nu formulere situationen generelt. Vi betragter r populationer, og i den i te population er der i alt n_i observationer. For hver population kategoriseres data i k kasser, og antallene i disse kasser tælles: $(A_{i1}, A_{i2}, \dots, A_{ik})$ er antallene i den i te population, hvor $A_{i1} + A_{i2} + \dots + A_{ik} = n_i$. Som statistisk model benyttes

$$M_0 : (A_{i1}, \dots, A_{ik}) \sim \text{multinom}(n_i, (\pi_{i1}, \dots, \pi_{ik})), \quad \pi_{ij} \geq 0, \quad \pi_{i1} + \dots + \pi_{ik} = 1, \quad i = 1, \dots, r,$$

og de r populationer antages at være uafhængige.

Vi ønsker at teste hypotesen, at forholdene er ens i alle r populationer. Dette betyder, at sandsynligheden for at falde i kasse j er den samme på tværs af alle r populationer, og dette gælder for alle kasser $j = 1, \dots, k$. Formelt kan det skrives som en ny model M_1 , hvorefter der eksisterer et sæt sandsynligheder $\pi_1, \dots, \pi_k$, $\pi_j \geq 0$, $\sum_{j=1}^k \pi_j = 1$, således at

$$M_1 : \pi_{ij} = \pi_j, \quad i = 1, \dots, r, \quad \text{for alle } j = 1, \dots, k.$$

Hvis vi samler alle sandsynligheder i en $r \times k$ matrix, kan hypotesen skrives på formen

$$\begin{array}{c|cccc} & 1 & 2 & \cdots & k \\ \hline 1 & \pi_{11} & \pi_{12} & \cdots & \pi_{1k} \\ 2 & \pi_{21} & \pi_{22} & \cdots & \pi_{2k} \\ \vdots & \vdots & & & \vdots \\ r & \pi_{r1} & \pi_{r2} & \cdots & \pi_{rk} \end{array} = \begin{array}{c|cccc} & 1 & 2 & \cdots & k \\ \hline 1 & \pi_1 & \pi_2 & \cdots & \pi_k \\ 2 & \pi_1 & \pi_2 & \cdots & \pi_k \\ \vdots & \vdots & & & \vdots \\ r & \pi_1 & \pi_2 & \cdots & \pi_k \end{array}$$

Hypotesen kaldes *homogenitetshypotesen* for kategoriske data.

8.6 Estimation og Test

Under model M_0 kan estimation foretages for hver af de r multinomialmodeller under brug af resultatet i underafsnit 8.1.2. Dette giver

$$M_0 : \quad \hat{\pi}_{ij} = \frac{A_{ij}}{n_i}, \quad j = 1, \dots, k, \quad i = 1, \dots, r.$$

Under model M_1 skal det fælles sæt sandsynligheder $(\pi_1, \dots, \pi_k)$ estimeres. Opstiller man likelihoodfunktionen, kan man indse, at estimaterne opnås ved at bruge

$$(A_{.1}, A_{.2}, \dots, A_{.k}) \sim \text{multinom}(n, (\pi_1, \dots, \pi_k)),$$

hvor $A_{.j} = A_{1j} + A_{2j} + \dots + A_{rj}$ er den j 'te søjlesum og $n = n_1 + n_2 + \dots + n_r$. Igen kan vi bruge resultatet i underafsnit 8.1.2 og får

$$M_1 : \quad \hat{\pi}_j = \frac{A_{.j}}{n}, \quad j = 1, \dots, k.$$

Vi kan nu beregne de forventede under model M_1 . Idet e_{ij} er det forventede antal i kasse j for population i , er denne

$$e_{ij} = n_i \hat{\pi}_j = \frac{n_i A_{.j}}{n}, \quad j = 1, \dots, k, \quad i = 1, \dots, r. \quad (8.12)$$

Denne formel kan læses som "rækkesum gange søjlesum divideret med den totale sum".

8.6.1 Test

For at lave et test for reduktion fra model M_0 til model M_1 bruges igen likelihood ratio teststørrelsen på formen $G = -2 \log(Q)$, hvor Q er forholdet mellem maksimum af likelihoodfunktionen under de to modeller:

$$Q = \frac{\max_{M_1} L}{\max_{M_0} L} = \prod_i \prod_j \frac{\hat{\pi}_j^{A_{ij}}}{\hat{\pi}_{ij}^{A_{ij}}} = \prod_i \prod_j \frac{1}{\left(\frac{A_{ij}}{(n_i A_{.j})/n}\right)^{A_{ij}}},$$

og dermed

$$G = 2 \sum_{i=1}^r \sum_{j=1}^k A_{ij} \log \left(\frac{A_{ij}}{e_{ij}} \right). \quad (8.13)$$

I ord kan vi sige dette, som at G er 2 gange sum over celler af det observerede antal ganget med logaritmen til det observerede antal divideret med det forventede antal. Med *celler* mener vi indgangene i $r \times k$ matrixen med antallene A_{ij} .

Resultat 8.6.1

Betragt modellerne M_0 og M_1 som beskrevet i dette afsnit. Hvis alle de forventede er større end eller lig med 5, $e_{ij} \geq 5$, kan vi approksimativt beregne p -værdien for test af reduktion fra model M_0 til model M_1 baseret på den observerede værdi G_{obs} af teststørrelsen G ved

$$p\text{-værdi} = P(G \geq G_{\text{obs}}) = 1 - F_{\chi^2((r-1)(k-1))}(G_{\text{obs}}).$$

Antallet af frihedsgrader følger den generelle regel med antallet af frie parametre i M_0 minus antallet af frie parametre i M_1 :

$$(r(k-1)) - (k-1) = (r-1)(k-1).$$

Eksempel 8.3 (fortsat).

Vi fortsætter med data omkring aktivitetsmønster for grupper af delfiner fra Eksempel 8.3.

Først opstilles en statistisk model for data. Lad Delf_{ij} , $i = M, A$ (Morgen, Aften), $j = R, S, L$ (Rejse, Spise, Leg), være den stokastiske variabel, der angiver antal grupper i aktivitetskategori j til tidspunkt i . Vi benytter modellen

$$\begin{aligned} (\text{Delf}_{MR}, \text{Delf}_{MS}, \text{Delf}_{ML}) &\sim \text{multinom}(72, (\pi_{MR}, \pi_{MS}, \pi_{ML})), \quad \pi_{Mj} \geq 0, \quad \pi_{MR} + \pi_{MS} + \pi_{ML} = 1, \\ (\text{Delf}_{AR}, \text{Delf}_{AS}, \text{Delf}_{AL}) &\sim \text{multinom}(79, (\pi_{AR}, \pi_{AS}, \pi_{AL})), \quad \pi_{Aj} \geq 0, \quad \pi_{AR} + \pi_{AS} + \pi_{AL} = 1. \end{aligned}$$

Under denne model ønsker vi at teste hypotesen om samme fordeling af aktivitet på de to tidspunkter,

$$(\pi_{MR}, \pi_{MS}, \pi_{ML}) = (\pi_{AR}, \pi_{AS}, \pi_{AL}).$$

Først findes de forventede antal under hypotesen som rækkesum gange søjlesum divideret med det totale antal. Beregningen er foretaget på R-kode 8.14 nedenstående værdier findes på R-udskrift 8.9 Afrundet til 2 decimaler findes de forventede til

	Rejse	Spise	Leg	Total
Morgen	9.06	40.05	22.89	72
Aften	9.94	43.95	25.11	79

Dernæst beregnes G -teststørrelsen ved hjælp af (8.13):

$$G = 2 \left\{ 6 \cdot \log \left(\frac{6}{9.06} \right) + \cdots + 10 \cdot \log \left(\frac{10}{25.11} \right) \right\} = 29.25.$$

Da alle de forventede er større end fem (den mindste er 9.06), bruges χ^2 -approksimationen til fordelingen af G , og vi får

$$p\text{-værdi} = 1 - F_{\chi^2((2-1)(3-1))}(29.25) = 4.5 \cdot 10^{-7}.$$

Denne p -værdi er meget lille, hvorfor data strider mod hypotesen om samme aktivitetsmønster på de to tidspunkter. Data tyder i grove træk på, at om morgenen spiser og leger grupperne, hvorimod grupperne er fokuseret på at spise om aftenen. $\square$

8.7 Test for uafhængighed

Eksempel 8.4.

I artiklen [Upper Extremity Injuries in Homer's Iliad](#) har forfatterne læst Homers Illiade og registreret 146 personskader i kampene omkring Troja. Skaderne er delt op efter området på kroppen og om personen dør eller ikke dør. Her vil vi nøjes med at se på skader, der vedrører arme og ben.

Sted	Død	Ikke Død
Hånd	0	4
Arm	3	6
Skulder	9	3
Ben	1	8

Tabel 8.3: Skader under slaget ved Troja fordelt på sted og udfald.

Er der uafhængighed mellem, hvor man får en skade, og om man overlever? Kunne de gamle grækere ved at bruge statistik have fået viden om, hvor de skulle forbedre kampuniformen?

I en generel formulering betragtes n individer, der inddeles efter to kriterier. De oprindelige data skrives på formen (H_u, M_u) , $u = 1, \dots, n$, hvor H_u er kategorien efter det første kriterie (med r katagorier) for observation nummer u , og M_u er kategorien efter det anden kriterie (med k katagorier). Fra disse data dannes en $r \times k$ tabel med antal A_{ij} , hvor A_{ij} tæller op antallet af observationer, hvor $H_u = i$ og $M_u = j$. Som startmodel bruger vi

$$M_{I0} : (A_{11}, A_{12}, \dots, A_{rk}) \sim \text{multinom}(n, (\pi_{11}, \pi_{12}, \dots, \pi_{rk})),$$

$$\pi_{ij} \geq 0, \quad \pi_{11} + \pi_{12} + \dots + \pi_{rk} = 1.$$

Hypotesen om uafhængighed siger, at sandsynligheden for at falde i den (i, j) 'te celle, π_{ij} , kan skrives som produktet af en sandsynlighed (kaldet α_i nedenfor) for at falde i kasse i med hensyn til det første kriterie og en sandsynlighed (kaldet β_j nedenfor) for at falde i kasse j med hensyn til det andet kriterie. Dette giver modellen

$$M_{I1} : \pi_{ij} = \pi_{ij}(\alpha, \beta) = \alpha_i \beta_j, \quad i = 1, \dots, r, \quad j = 1, \dots, k, \quad (8.14)$$

$$\alpha_i \geq 0, \quad \alpha_1 + \dots + \alpha_r = 1, \quad \beta_j \geq 0, \quad \beta_1 + \dots + \beta_k = 1.$$

Lad os starte med lidt notation. Vektoren med alle antallene A_{ij} kaldes $\mathbf{A}$, og tilsvarende er $\boldsymbol{\pi}$ vektoren med alle indgangene π_{ij} . Den i 'te rækkesum er $A_{i\cdot} = A_{i1} + \dots + A_{ik}$, og den j 'te søjlesum er $A_{\cdot j} = A_{1j} + \dots + A_{rj}$, og vektorerne med disse summer betegnes $\mathbf{A}_{\star}$ og $\mathbf{A}_{\cdot}$. Bemærk, at da rækkesummerne svarer til, at vi kun inddeler data efter det første kriterie, vil vektoren $\mathbf{A}_{\star}$ med disse summer være multinomialfordelt. Det samme gælder for søjlesummerne.

Resultat 8.7.1

Et test for uafhængighedshypotesen M_{I1} foretages ved at beregne G -teststørrelsen fra (8.13) og beregne p -værdi som beskrevet i Resultat 8.6.1.

For at lave inferens om parameteren α under uafhængighedsmodellen M_{I1} benyttes multinomialmodellen for rækkesummerne, $\mathbf{A}_* \sim \text{multinom}(n, \alpha)$, og for at lave inferens om β benyttes $\mathbf{A}_* \sim \text{multinom}(n, \beta)$.

Likelihoodfunktionen under model M_{I0} er $L(\pi) = \binom{n}{\mathbf{A}} \prod_{ij} \pi_{ij}^{A_{ij}}$, og likelihoodfunktionen under uafhængighedshypotesen er

$$L(\pi(\alpha, \beta)) = \binom{n}{\mathbf{A}} \prod_{ij} (\alpha_i \beta_j)^{A_{ij}} = \binom{n}{\mathbf{A}} \left\{ \prod_i \alpha_i^{A_{i\cdot}} \right\} \left\{ \prod_j \beta_j^{A_{\cdot j}} \right\}.$$

De to led i krøllede parenteser har samme struktur som likelihoodfunktionen fra en multinomialmodel, hvorfor vi umiddelbart har

$$\hat{\alpha}_i = \frac{A_{i\cdot}}{n}, \quad i = 1, \dots, r, \quad \text{og} \quad \hat{\beta}_j = \frac{A_{\cdot j}}{n}, \quad j = 1, \dots, k.$$

Ved simpel indsættelse kan man nu se, at likelihood ratio teststørrelsen Q vil være som i afsnit 8.6 for homogenitetstestet.

Vi vil nu give en uddybende forklaring på at de to test er ens. Vi starter med at lave en omparametrisering af model M_{I0} , idet vi skriver

$$\begin{aligned} \pi_{ij} &= \alpha_i \gamma_{ij}, \quad \alpha_i \geq 0, \quad \alpha_1 + \dots + \alpha_r = 1, \\ \gamma_{ij} &\geq 0, \quad \gamma_{i1} + \dots + \gamma_{ik} = 1, \quad i = 1, \dots, r, \end{aligned}$$

og alle parametrene kan variere uafhængigt af hinanden. Dette kan se lidt voldsomt ud, men her står blot, at α_i er sandsynligheden for at falde i kategori i med hensyn til det første kriterie, og givet dette, er sandsynligheden for at falde i kategori j med hensyn til det andet kriterie givet som γ_{ij} . Hypotesen om uafhængighed, $\pi_{ij} = \alpha_i \beta_j$, bliver i denne formulering

$$(\gamma_{11}, \dots, \gamma_{1k}) = (\gamma_{21}, \dots, \gamma_{2k}) = \dots = (\gamma_{r1}, \dots, \gamma_{rk}), \quad (8.15)$$

hvor den fælles værdi af disse sandsynlighedsvektorer svarer til $(\beta_1, \dots, \beta_k)$.

Den betingede sandsynlighed for hele tabellen $\mathbf{A}$, givet rækkesummerne $\mathbf{A}_*$, er

$$\begin{aligned} \frac{P(\mathbf{A} = \mathbf{a})}{P(\mathbf{A}_* = \mathbf{a}_*)} &= \frac{\binom{n}{\mathbf{a}} \prod_{i,j} (\alpha_i \gamma_{ij})^{a_{ij}}}{\binom{n}{\mathbf{a}_*} \prod_i \alpha_i^{a_{i\cdot}}} \\ &= \prod_{i=1}^r \left\{ \binom{a_{i\cdot}}{a_{i1}, \dots, a_{ik}} \prod_j \gamma_{ij}^{a_{ij}} \right\}. \end{aligned}$$

Her står to ting. For det første, at rækkerne er uafhængige givet rækkesummerne (på grund af produktstrukturen), og for det andet, at den i 'te række givet rækkesummen er multinomialfordelt med antalsværdi $a_{i\cdot}$ og sandsynlighedsvektor $(\gamma_{i1}, \dots, \gamma_{ik})$. Sammenfattende har vi, at givet

rækkesummerne svarer uafhængighedshypotesen (8.15) til hypotesen om homogenitet af r multinomialfordelinger fra afsnit 8.6.

Hvis man mere direkte skriver likelihood ratio teststørrelsen Q op for reduktion fra model M_{I0} til model M_{I1} , vil man se, at maksimum af leddet svarende til multinomialfordelingen for rækkesummerne forkorter ud, og tilbage er der produktet af multinomialfordelingerne for rækkerne givet rækkesummerne, og derfor bliver Q identisk med likelihood ratio teststørrelsen udregnet i underafsnit 8.6.1.

På tilsvarende vis vil man finde, at likelihoodratio teststørrelsen for en hypotese om α , under uafhængighedsmodellen M_{I1} , kun afhænger af rækkesummerne $\mathbf{A}_*$. Dette er baggrunden for, at der i Resultat 8.7.1 siges, at inferens om α baseres på multinomialmodellen for rækkesummerne.

Under uafhængighedshypotesen har vi, at den i te række $(A_{i1}, \dots, A_{ik})$ givet rækkesummerne $\mathbf{A}_*$ er multinomialfordelt med antalsværdi A_i og sandsynlighedsvektor β . Da der er samme sandsynlighedsvektor for $i = 1, \dots, r$, bliver summen af rækkerne, som netop er vektoren $\mathbf{A}_*$ af søjlesummer, multinomialfordelt med antalværdi n og sandsynlighedsvektor β . Dette er fordelingen givet rækkesummerne $\mathbf{A}_*$, men da denne betingede fordeling ikke afhænger af rækkesummerne, får vi ud-sagnet, at rækkesummer og søjlesummer er stokastisk uafhængige under uafhængighedshypotesen. Dette resultat vil vi bruge til at udlede et permutationstest i Afsnit 8.8.

Chi-square test i stedet for G-test

Før G -testet, baseret på et likelihood ratio test, blev indført, benyttede man et andet test kaldet **chi-squared test**. Hvis vi kalder teststørrelsen for C , er de to teststørrelser

$$G = 2 \sum \text{observeret} \cdot \log \left(\frac{\text{observeret}}{\text{forventet}} \right) \quad \text{og} \quad C = \sum \frac{(\text{observeret} - \text{forventet})^2}{\text{forventet}}.$$

C -teststørrelsen vurderes i den samme χ^2 -fordeling som G -teststørrelsen og med samme krav om, at de forventede antal skal være større end eller lig med 5.

Chi-squared testet benyttes stadig meget, men G -testet er at foretrække på grund af dets forbindelse til generelle metoder. I Chihara and Hesterberg [2022] Kapitel 10 benyttes næsten udelukkende C -testet, og dette er også standard i forskellige **R**-funktioner.

8.8 Permutationstest og Fishers eksakte test

Hvis vi prøver at lave uafhængighedstestet for data fra Tabel 8.3, finder man, at G -teststørrelsen er 14.0, og de forventede antal er

Sted	Død	Ikke Død
Hånd	1.5	2.5
Arm	3.4	5.6
Skulder	4.6	7.4
Ben	3.4	5.6

Vi kan se her, at de forventede antal er ikke alle større end eller lig med 5, og vi kan ikke umiddelbart bruge Resultat 8.7.1. Ofte bruger man et mindre restriktivt krav, der kendes under betegnelsen **Cochran regel**. Denne regel siger, at alle de forventede skal være større end eller lig med 1, og højst 20 procent må være under 5. I eksemplet ovenfor med data fra Homers Illiade er der 5 ud af 8 forventede antal, der er under 5, hvilket er langt over grænsen på de 20 procent. Vi bør derfor ikke bruge χ^2 -fordelingen til at beregne en approksimativ p -værdi (hvis vi gør det alligevel, bliver p -værdien 0.0029).

Vi vil nu beskrive en måde til at simulere en p -værdi for test af uafhængighedshypotesen M_{I1} fra (8.14). De underliggende data består af kategorierne (H_u, M_u) for n elementer $u = 1, \dots, n$, hvor H_u er kategorien efter det første kriterie, og M_u er kategorien efter det andet kriterie.

Nedenfor vises det at under uafhængighedshypotesen M_{I1} vil $(H_1, M_1), \dots, (H_n, M_n)$ være uniformt fordelt i den betingede fordeling givet rækkesummerne $A_1, \dots, A_r$ og søjlesummerne $A_1, \dots, A_k$.

Lad $h_1^0, \dots, h_n^0$ være en fast følge, hvor antallet i de forskellige kategorier efter det første inddelingskriterie er $a_1, \dots, a_r$, og lad $m_1^0, \dots, m_n^0$ være en fast følge, hvor antallet i de forskellige kategorier efter det andet inddelingskriterie er $a_1, \dots, a_k$. Så siger resultatet, at alle mulige ombytninger af $h_1^0, \dots, h_n^0$ og alle mulige ombytninger af $m_1^0, \dots, m_n^0$ er lige sandsynlige i den betingede fordeling givet rækkesummer og søjlesummer. En simuleret p -værdi kan nu findes ved for hver simuleret ombytning at finde antallene A_{ij} i de $r \cdot k$ celler af tabellen, beregne G -teststørrelsen og se, hvor ofte vi får en værdi, der ligger over G -teststørrelsen for de oprindelige data, G_{obs} .

Resultat 8.8.1

Permutationstest for uafhængighedshypotesen

Lad $V = (V_1, \dots, V_n)$ være en tilfældig permutation af tallene $1, \dots, n$, og lad $h_i^V = h_{V_i}^0$ være de ombyttede h^0 -værdier. Dan ud fra data $(h_1^V, m_1^0), \dots, (h_n^V, m_n^0)$ en tabel $\mathbf{A}^V$ med antallene i de $r \cdot k$ celler, og dan ud fra denne tabel G -teststørrelsen betegnet med G^V . Så gælder, at

$$P(G \geq G_{\text{obs}} | (\mathbf{A}_{\star\cdot}, \mathbf{A}_{\cdot\star})) = P(G^V \geq G_{\text{obs}}).$$

Under uafhængighedshypotesen betragtes den betingede fordeling af $(H_1, M_1), \dots, (H_n, M_n)$ givet rækkesummerne $(A_1, \dots, A_r)$ og søjlesummerne $(A_1, \dots, A_k)$. For at finde den betingede fordeling bruges at

$$P((H_1, M_1) = (h_1, m_1), \dots, (H_n, M_n) = (h_n, m_n)) = \prod_u \alpha_{h_u} \beta_{m_u} = \left\{ \prod_i \alpha_i^{a_{i\cdot}} \right\} \left\{ \prod_j \beta_j^{a_{\cdot j}} \right\}.$$

Idet rækkesummer og søjlesummer er uafhængige (se skjulte punkt i 8.7), kan den betingede sandsynlighed nu skrives som

$$\frac{\prod_u \alpha_{h_u} \beta_{m_u}}{\left\{ \binom{n}{\mathbf{a}_{\star\cdot}} \prod_i \alpha_i^{a_{i\cdot}} \right\} \left\{ \binom{n}{\mathbf{a}_{\cdot\star}} \prod_j \beta_j^{a_{\cdot j}} \right\}} = \frac{1}{\binom{n}{\mathbf{a}_{\star\cdot}} \binom{n}{\mathbf{a}_{\cdot\star}}}.$$

Da denne sandsynlighed ikke afhænger af $(h_1, m_1), \dots, (h_n, m_n)$, har alle værdier af disse, der opfylder at rækkesummerne er $a_1, \dots, a_r$ og søjlesummerne er $a_1, \dots, a_k$, lige stor sandsynlighed.

8.8.1 Fishers eksakte test

Den betingede fordeling, der simuleres i permutationstestet ovenfor, kan beregnes direkte i en 2×2 tabel. Når vi betinger med de to rækkesummer og de to søjlesummer, er der kun én indgang tilbage i 2×2 matricen A , der kan variere frit. Lad $A_{1.} = b$, $A_{2.} = c$, $A_{.1} = d$ og $A_{.2} = e$, så kan vi skrive A som

Rækkesum			$\max\{0, d - c\} \leq x \leq \min\{b, d\}$.
x	$b - x$	b	
$d - x$	$x + c - d$	c	
Søjlesum	d	e	n

Den betingede sandsynlighed $h(x, b, c, d)$ kan beregnes som

$$\begin{aligned}
 h(x, b, c, d) &= \frac{P(A_{11} = x, A_{12} = b - x, A_{21} = d - x, A_{22} = x + c - d)}{P(A_{1.} = b, A_{2.} = c)P(A_{.1} = d, A_{.2} = b + c - d)} \\
 &= \frac{\binom{n}{x, b-x, d-x, x+c-d} (\alpha_1 \beta_1)^x (\alpha_1 \beta_2)^{b-x} (\alpha_2 \beta_1)^{d-x} (\alpha_2 \beta_2)^{x+c-d}}{\binom{n}{b} \binom{n}{d} \alpha_1^b \alpha_2^c \beta_1^d \beta_2^{b+c-d}} \\
 &= \frac{n!b!c!}{x!(b-x)!(d-x)!(x+c-d)!\binom{n}{d}} = \frac{\binom{b}{x} \binom{c}{d-x}}{\binom{b+c}{d}}.
 \end{aligned}$$

Fordelingen, der optræder her, kendes under navnet den **hypergeometriske fordeling**. For enhver mulig værdi af x beregner vi G -teststørrelsen, $G(x)$, og beregner p -værdien for uafhængighedstestet som

$$p\text{-værdi} = \sum_{x: G(x) \geq G_{\text{obs}}} h(x, b, c, d). \quad (8.16)$$

Testet baseret på den betingede fordeling kaldes **Fishers eksakte test**. I **R** er dette test implementeret i funktionen **fisher.test**, men her beregnes p -værdien lidt anderledes end i (8.16). Når vi bruger (8.16), rangordnes de forskellige udfald x , det vil sige $(1, 1)$ -indgangen i A matricen, ud fra G -teststørrelsen. I **fisher.test** rangordnes udfaldene efter værdien af den betingede sandsynlighed $h(x, b, c, d)$, således at p -værdien er

$$p\text{-værdi}_{\text{fisher.test}} = \sum_{x: h(x, b, c, d) \leq h(x_{\text{obs}}, b, c, d)} h(x, b, c, d). \quad (8.17)$$

Eksempel 8.4 (fortsat).

Vi betragter igen data fra Homers Illiade fra Tabel 8.3, men benytter kun data fra 13 hændelser, hvor skaden er på enten hånd eller arm:

De forventede antal under hypotesen om uafhængighed mellem sted på kroppen og dødelighed er 0.9 og 3.1 i første række samt 2.1 og 6.9 i anden række. Disse opfylder ikke Cochran's regel, og man kan derfor ikke stole på p -værdien beregnet ud fra en χ^2 -fordeling. Gennemfører man ikke desto mindre beregningerne, fås $G_{\text{obs}} = 2.59$ og $1 - F_{\chi^2(1)}(2.59) = 0.11$.

Sted	Død	Ikke Død	Rækkesum
Hånd	0	4	4
Arm	3	6	9
Søjlesum	3	10	13

Tabel 8.4: Fordeling af skader under slaget ved Troja - skader på hånd og arm.

I R-kode 8.19 beregnes det eksakte test, baseret på den betingede fordeling givet række- og søjlesummer. Det betingede test, der bygger på G -teststørrelsen (8.16), fører til en p -værdi på 0.31, mens det betingede test, der bygger på (8.17), giver en p -værdi på 0.50. Begge disse p -værdier er noget højere end den approksimative χ^2 -baserede værdi.

Forskellen mellem de to betingede tests ligger i, at det sidste test beregner sin p -værdi ud fra de tre mulige udfald (0, 2 eller 3 døde, når skaden er i hånden), hvorimod G -test-størrelsen kun medtager udfaldene 0 og 3.

Appendiks til Afsnit 8.8

8.8.2 Multinomialfordelingen i R

I **R** kan man beregne sandsynlighederne i en multinomialfordeling med kommandoen

R-kode 8.1

```
dmultinom((a1, ..., ak), n, (π1, ..., πk))
```

Man kan simulere nye udfald som vist på R-kode 8.2.

R-kode 8.2

```
rmultinom(1, 3, rep(1/6, 6))
```

Her simuleres 1 udfald fra en multinomialfordeling, svarende til at en ærlig sekskantet terning kastes 3 gange. Output fra R-kode 8.2 vil være forskelligt fra gang til gang, men kan f.eks. være som i R-udskrift 8.1

R-udskrift 8.1

	[, 1]
[1,]	0
[2,]	2
[3,]	1
[4,]	0
[5,]	0
[6,]	0

Det svarer til udfaldet (0, 2, 1, 0, 0, 0) dvs. 2 toere og 1 treer.

Kørte vi i stedet **rmultinom**(4, 3, rep(1/6, 6)) ville output være på formen

R-udskrift 8.2

	[, 1]	[, 2]	[, 3]	[, 4]
[1,]	1	1	1	0
[2,]	0	1	0	1
[3,]	0	0	2	1
[4,]	0	0	0	0
[5,]	0	0	0	1
[6,]	2	1	0	0

Som nævnt i Afsnit 8.2.1 kan betragte hypotesen $H : p = 1/6$ hvor p angiver sandsynligheden for at slå en sekser en terning. Hvis vi forestiller os at vi har slået 10 seksere i 100 slag, kan p -værdien beregnes på tre måder som er nævnt i (8.2). De tre metoder er implementeret på R-kode 8.3.

R-kode 8.3

```
n=100
x=10
p0=1/6
z=c(0:n)
a=abs(z-n*p0)
a0=a[x+1]
d=dbinom(z,n,p0)
d0=d[x+1]
Q=p0^z*(1-p0)^(n-z)/((z/n)^z*(1-z/n)^(n-z))
Q0=Q[x+1]

pval1=sum(d[a>=a0])
pval2=sum(d[d<=d0])
pval3=sum(d[Q<=Q0])

c(Afstand=pval1,Taethed=pval2,LikRat=pval3)
```

Output fra R-kode 8.3 findes på R-udskrift 8.3.

R-udskrift 8.3

```
      Afstand      Taethed      LikRat
0.08056005 0.08056005 0.06439906
```

Bemærk at metode 1 kan også kan regnes som `pbinom(10,100,1/6)+1-pbinom(23,100,1/6)`.

Metode 2 er implementeret i `binom.test`.

Konfidensintervallet for parameteren findes `prop.test(x,n,correct=FALSE)$conf.int`.

I dette tilfælde bliver output fra `prop.test(10,100,correct=FALSE)$conf.int`

R-udskrift 8.4

```
[1] 0.05522914 0.17436566
attr(,"conf.level")
[1] 0.95
```

Beregning i R af G -test

Her vises beregningen af G -testet fra Eksempel 8.1.

Først indlæses data fra Tabel 8.1

R-kode 8.4

```
a=c(29,16,17,4,3,9,22)
n=sum(a)
```

Som det fremgår af (8.8) kan estimatet for parameteren i eksemplet beregnes som

$$\frac{\sum_{j=1}^6 a_j}{\sum_{j=1}^6 a_j + \sum_{j=1}^6 j a_{j+1}}$$

hvilket i **R** kan implementeres ved

R-kode 8.5

```
th=sum(a[1:6])/(sum(a[1:6])+sum(c(1,2,3,4,5,6)*a[-1]))
```

og de forventede kan dernæst beregnes

R-kode 8.6

```
ex=n*c(th,th*(1-th),th*(1-th)^2,th*(1-th)^3,th*(1-th)^4,th*(1-th)^5,(1-th)^6)
```

Til slut beregnes teststørrelse og p-værdi fra Resultat 8.3.1:

R-kode 8.7

```
gTest=2*sum(a*log(a/ex))
pval=1-pchisq(gTest,7-1-1)
c(Gteststørrelse=gTest,Pværdi=pval)
```

Output fra R-kode 8.7 bliver

R-udskrift 8.5

Gteststørrelse	Pværdi
12.94120031	0.02393606

Beregninger goodness-of-fit test

På R-kode 8.8 indlæser vi først data fra filen *tirstrup.csv* og dette gemmes i vektoren `vind`. Dernæst benyttes **hist** kommandoen til finde antallene i de forskellige intervaller givet i 8.10.

R-kode 8.8

```
dat = read.csv(file="tirstrup.csv")
vind = dat$vind
endePkt=c(0:18)*3
antal=hist(vind,breaks=endePkt,probability=TRUE)$counts
```

Tæthedsfunktionen og fordelingsfunktionen for en Weibullfordeling beregnes i **R** med kommandoerne **dweibull**(x, α, λ) og **pweibull**(x, α, λ). På R-kode 8.9 bruges **pweibull** til at beregne de forventede fra (8.11)

R-kode 8.9

```
endePkt0=endePkt[2:18]
pr0=pweibull(endePkt0,3.8851,36.1116)
pr=c(pr0,1)-c(0,pr0)
ex=365*pr
```

Køres nu **antal** og **round(ex,1)**, fås

R-udskrift 8.6

0	0	0	1	9	12	22	26	37	45	37	38	36	35	33	15	13	6
0.0	0.3	1.3	3.4	6.8	11.8	18.2	25.7	33.3	39.8	44.0	44.5	41.1	34.3	25.7	17.0	9.8	8.0

Som det fremgår af R-output 8.6 er nogle af de forventede mindre end 5. Vi kan råde bod på dette ved at slå de pågældende kasser sammen hvilket gøres i de første to linjer af R-kode 8.10. Dernæst beregnes G -teststørrelsen og p -værdien og til slut samles værdierne i en liste, som udskrives på R-udskrift 8.7.

R-kode 8.10

```
antal1=c(sum(antal[1:4]),antal[5:18])
ex1=c(sum(ex[1:4]),ex[5:18])

gTest=2*sum(antal1*log(antal1/ex1))
pval=1-pchisq(gTest,15-1-2)

list(Observerede=antal1,Forventede=ex1,G=gTest,Pvaerdi=pval)
```

R-udskrift 8.7

```
$Observerede
[1] 1 9 12 22 26 37 45 37 38 36 35 33 15 13 6

$Forventede
[1] 5.016547 6.807883 11.785709 18.218322 25.669843 33.285739 39.840321 43.960454
    44.524532 41.120276 34.336217 25.664851
[13] 16.977919 9.816159 7.975228

$G
[1] 13.71594

$Pvaerdi
[1] 0.3192144
```

Homogenitetstest i R Først gennemgås beregningen for homogenitetstestet ved hjælp af følgende data

	1	2	Sum
1	10	10	20
2	10	30	40
3	20	20	40
Sum	40	60	100

Først dannes matricen 3×2 som `obs` indeholder datasættet.

R-kode 8.11

```
obs=rbind(c(10,10),c(10,30),c(20,20))
```

Dernæst foretages en eksPLICIT beregning af de forventede antal.

R-kode 8.12

```
rs=rowSums(obs)
cs=colSums(obs)
rscs=outer(rs,cs)
ex=rscs/sum(obs)
```

Funktionen `rowSums` beregner rækkesummer, og giver derfor en vektor af længde 3. Funktionen `colSums` beregner søjlesummer, og giver derfor en vektor af længde 2. Funktionen `outer` tager to vektorer som input og danner en matris, hvor den (i, j) 'te indgang er den i 'te indgang i den første vektor ganget med den j 'te indgang i den anden vektor, og derfor bliver `ex` matricen med de forventede antal, (jf. (8.12)).

Til slut beregnes G -tesstørrelsen og den tilhørende p -værdi ved hjælp af (8.13) og Resultat 8.6.1.

R-kode 8.13

```
gTest=2*sum(obs*log(obs/ex))
pval=1-pchisq(gTest, (3-1)*(2-1))
list(rs=rs, cs=cs, rscs=rscs, ex=ex, G=gTest, Pvaerdi=pval)
```

Køres R-kode 8.11 - 8.13 fås følgende output:

R-udskrift 8.8

```
$rs
[1] 20 40 40

$cs
[1] 40 60

$rscs
      [,1] [,2]
[1,]   800 1200
[2,]  1600 2400
[3,]  1600 2400

$ex
      [,1] [,2]
[1,]     8   12
[2,]    16   24
[3,]    16   24

$G
[1] 6.43786

$Pvaerdi
[1] 0.03999783
```

Gennemregningen af data fra Eksempel 8.3 er vist i en kortere version på R-kode 8.14

R-kode 8.14

```
obs=rbind(c(6,28,38),c(13,56,10))

ex=outer(rowSums(obs),colSums(obs))/sum(obs)
gTest=2*sum(obs*log(obs/ex))
pval=1-pchisq(gTest, (dim(obs)[1]-1)*(dim(obs)[2]-1))

list(Forventede=ex, G=gTest, Pvaerdi=pval)
```

Output fra R-kode 8.14 findes på R-udskrift 8.9:

R-udskrift 8.9

\$Forventede			
	[,1]	[,2]	[,3]
[1,]	9.059603	40.05298	22.88742
[2,]	9.940397	43.94702	25.11258
\$G			
[1]	29.24552		
\$Pvaerdi			
[1]	4.46084e-07		

Permutationstest for uafhængighed

I de følgende kodevinduer simuleres p -værdien for uafhængighedstestet for data fra Homers Illiade.

Først indskrives datasættet fra Tabel 8.3 og række- og søjlersummer beregnes. Dernæst findes, til senere brug, vektorerne `h` og `m` der indeholder gentagelser af hhv. 1, 2, 3, 4 og 1, 2 svarende til række- og søjlesummer. F.eks. er vektoren `h`

R-udskrift 8.10

h																																		
[1]	1	1	1	1	2	2	2	2	2	2	2	2	2	3	3	3	3	3	3	3	3	3	3	3	3	4	4	4	4	4	4	4	4	4

R-kode 8.15

obs= rbind (c (0,4), c (3,6), c (9,3), c (1,8))	
r= dim (obs)[1]; k= dim (obs)[2]	
rs=rowSums(obs)	
cs=colSums(obs)	
h= rep (c (1:r),rs)	
m= rep (c (1:k),cs)	

Dernæst defineres funktionen `Gfct`. Denne beregner G -testørrelsen baseret på en matriks A med antallene i de forskellige kategorier. I G -teststørrelsen vil vi få et problem, hvis det observerede antal i et af leddene er nul, idet **R** ikke kan beregne $0 \cdot \log(0)$. For at få den rigtige værdi, nemlig nul, skriver vi i stedet $0 \cdot \log(1)$.

R-kode 8.16

```
Gfct=function(Amat) {
  ex=outer(rowSums(Amat),colSums(Amat))/sum(Amat)
  A1=ifelse(Amat==0,1,Amat)
  return(2*sum(Amat*log(A1/ex)))
}
Gobs=Gfct(obs)
```

Efter dette køres simulationen. I hver gennemkørsel af `for`-loopet findes først en tilfældig ombytning (permutation) af elementerne i `m` ved hjælp af kommandoen `sample(m)` og dernæst bruges funktionen `table` til at lave matricen med de observerede antal i kategorierne (i, j) , $i = 1, \dots, r$ og $j = 1, \dots, k$ svarende til vektorerne `h` og `msamp`. Til sidst bruges funktionen `Gfct` fra R-kode 8.16 til at beregne den tilhørende værdi af G -teststørrelsen.

R-kode 8.17

```
nSim=10^4-1
Gval=rep(0,nSim)

for (i in 1:nSim){
  msamp=sample(m)
  tabelsamp=table(h,msamp)
  Gval[i]=Gfct(tabelsamp)
}

pval=(1+sum(Gval>=Gobs))/(1+nSim)
c(G=Gobs,pværdi=pval)
```

Til slut beregnes hvor andelen af simulerede G -teststørrelser sammen med den observerede værdi, der er større end eller lig den observerede værdi. Output fra R-kode 8.15 - 8.17 vil variere fra simulation til simulation, men p_{obs} vil konsekvent være under 0.05.

R-udskrift 8.11

G	pværdi
14.00161	0.00570

Fishers eksakte test i R

Fishers eksakte test er implementeret i funktionen `fisher.test`. Som nævnt

R-kode 8.18

```
Aobs=rbind(c(0,4),c(3,6))
fisher.test(Aobs)
```

Output fra R-kode 8.18 findes på R-udskrift 8.12.

R-udskrift 8.12

```
Fisher's Exact Test for Count Data

data:  Aobs
p-value = 0.4965
alternative hypothesis: true odds ratio is not equal to 1
95 percent confidence interval:
 0.000000 5.665105
sample estimates:
odds ratio
          0
```

På R-kode 8.19 beregnes p -værdien ud fra formel (8.16).

R-kode 8.19

```
Aobs=rbind(c(0,4),c(3,6))
b=sum(Aobs[1,]); c=sum(Aobs[2,]); d=sum(Aobs[,1])

xvek=c(max(c(0,d-c)):min(b,d))
hxvek=dhyper(xvek,b,c,d)

Gfct=function(Amat){
ex=outer(rowSums(Amat),colSums(Amat))/sum(Amat)
A1=ifelse(Amat==0,1,Amat)
return(2*sum(Amat*log(A1/ex)))
}

Gobs=Gfct(Aobs)
hxobs=dhyper(Aobs[1,1],b,c,d)

Gxvek=c()
for (x in xvek){
Gxvek=c(Gxvek,Gfct(rbind(c(x,b-x),c(d-x,x+c-d))))
}

c(Gtest=sum(hxvek[Gxvek>=Gobs]),RtestMin=sum(hxvek[hxvek<=hxobs]),
  Rtest=fisher.test(Aobs)$p.value)
```

Som det fremgår af 8.19 indskrives vi først datasættet og beregner derefter, med betegnelserne fra Afsnit 8.8.1, værdierne b, c og d . Vektoren `xvek` indeholder de mulige værdier af $(1, 1)$ -indgangen i datamatricen A , når rækkesummer og søjlesummer holdes fast. I det konkrete eksempel bliver dette værdierne 0, 1, 2 og 3. Dernæst benyttes funktionen **dhyper** til at beregne de relevante sandsynligheder fra den hypergeometriske fordeling. Funktionen `Gfct` er tidligere defineret på R-kode 8.16 og giver G -teststørrelsen for en given tabel af data. Ved hjælp af disse størrelser kan (8.16) nu beregnes, idet vektoren `Gxvek` indeholder de mulige værdier af G -teststørrelsen og `Gobs` indeholder den observerede værdier, således at `Gxvek>=Gobs` vil være sand for de indekser som vi ønsker at danne summen over.

Output fra R-kode 8.19 findes på R-udskrift 8.13.

R-udskrift 8.13

Gtest	RtestMin	Rtest
0.3076923	0.4965035	0.4965035

Appendiks

A.1 Kumulative fordelingsfunktioner

Den kumulative fordelingsfunktion (CDF) (eller bare *fordelingsfunktionen*) er en matematisk funktion, der beskriver sandsynligheden for, at en stokastisk variabel X vil antage en værdi, der er mindre end eller lig med en specifik værdi x . Formelt er CDF'en for en stokastisk variabel X , betegnet som $F_X(x)$, defineret som:

$$F_X(x) = P(X \leq x)$$

De vigtigste egenskaber ved en fordelingsfunktion er:

- Ikke-aftagende: $F_X(x_1) \leq F_X(x_2)$ for $x_1 \leq x_2$
- Grænser: $\lim_{x \rightarrow -\infty} F_X(x) = 0$ og $\lim_{x \rightarrow \infty} F_X(x) = 1$
- Højrekontinuert: $F_X(x^+) \stackrel{\text{def}}{=} \lim_{t \rightarrow x^+} F_X(t) = F_X(x)$
- Grænseværdier fra venstre eksisterer: $F_X(x^-) \stackrel{\text{def}}{=} \lim_{t \rightarrow x^-} F_X(t)$ (følger af ovenstående)
- Sandsynligheden $P(X < x)$ beregnes som:

$$P(X < x) = F_X(x) - P(X = x)$$

For kontinuerte stokastiske variable forenkles dette til $P(X < x) = F_X(x)$, da $P(X = x) = 0$.

- Alternativt kan $P(X < x)$ også beregnes ved hjælp af grænsen fra venstre som:

$$P(X < x) = F_X(x^-)$$

A.1.1 Højre- og venstrekontinuitet

Højrekontinuitet og venstrekontinuitet er begreber, der handler om, hvordan funktioner af reelle variable opfører sig, når man nærmer sig et punkt x fra enten højre eller venstre side.

Man kan for eksempel forestille sig, at man går langs grafen af en funktion og bevæger sig imod et bestemt punkt fra højre. Højrekontinuitet betyder, at funktionsværdien ved punktet er præcis, hvad man forventer baseret, på funktionsværdierne, når man nærmer sig punktet fra højre. Med andre ord “hopper” eller “ændrer” funktionen sig ikke pludseligt, når du når frem til punktet – der er ingen *diskontinuitet*.

Vi illustrerer her med et eksempel og overlader den stringente matematiske definition til andre kurser. Eksemplet formuleres ved hjælp af *indikatorfunktioner*. Generelt er indikatorfunktionen for en mængde A , ofte skrevet som $\mathbb{1}_A(x)$ eller $\chi_A(x)$ defineret ved

$$\mathbb{1}_A(x) \stackrel{\text{def}}{=} \begin{cases} 1 & \text{hvis } x \in A, \\ 0 & \text{hvis } x \notin A. \end{cases} \quad (\text{A.1})$$

Funktionen er altså lig 1, hvis x tilhører A , og 0 ellers.


Betragt funktionerne

$$\mathbb{1}_{[0,\infty)}(x) = \begin{cases} 1 & \text{if } x \geq 0 \\ 0 & \text{if } x < 0 \end{cases} \quad \text{og} \quad \mathbb{1}_{(0,\infty)}(x) = \begin{cases} 1 & \text{if } x > 0 \\ 0 & \text{if } x \leq 0 \end{cases}.$$

Graferne for funktionerne er findes på Figur A.1. Vi bemærker at $\mathbb{1}_{[0,\infty)}(0) = 1$ og $\mathbb{1}_{(0,\infty)}(0) = 0$ og nærmer vi os $x = 0$ fra højre vil funktionen $\mathbb{1}_{[0,\infty)}$ blive i funktionens værdi 1, mens funktionen $\mathbb{1}_{(0,\infty)}$ springer til værdien 0. Der gælder dermed at

$$\mathbb{1}_{[0,\infty)}(0^+) = 1 = \mathbb{1}_{[0,\infty)}(0) \quad \text{hvorimod} \quad \mathbb{1}_{(0,\infty)}(0^+) = 1 \neq 0 = \mathbb{1}_{(0,\infty)}(0).$$

Funktionen $\mathbb{1}_{[0,\infty)}$ er dermed *højrekontinuert* i $x = 0$ og da punktet er det eneste springpunkt siger vi at $\mathbb{1}_{[0,\infty)}$ er højrekontinuert. Funktionen $\mathbb{1}_{(0,\infty)}$ er, som det fremgår, ikke højrekontinuert, men vil derimod *venstrekontinuert*.



Figur A.1: Grafer for indikatorfunktionerne for henholdsvis $[0, \infty)$ (til venstre) og $(0, \infty)$ (til højre).

A.1.2 Funktioner af uafhængige stokastiske variable

På kurset danner vi ofte stokastiske variable $Y_1, \dots, Y_m$, som er funktioner af uafhængige stokastiske variable $X_1, \dots, X_n$. Løst sagt vil Y_i erne være uafhængige, hvis der ikke nogen af X_i erne som går igen i flere af udtrykkene for Y_i erne. Lidt mere formelt kan vi sige følgende:

Lad $X_1, X_2, \dots, X_n$ være en følge af uafhængige stokastiske variable, og betragt m disjunkte delmængder af indeksene $I_1, I_2, \dots, I_m \subseteq \{1, 2, \dots, n\}$, dvs. således at $I_i \cap I_j = \emptyset$ for alle $i \neq j$ og $\bigcup_{i=1}^m I_i \subseteq \{1, 2, \dots, n\}$.

Definerer vi nye stokastiske variable Y_i som funktioner af de stokastiske variable, der er indekseret af I_i , dvs.,

$$Y_i = g_i(\{X_j : j \in I_i\}), \quad i = 1, 2, \dots, m,$$

da er de stokastiske variable $Y_1, Y_2, \dots, Y_m$ uafhængige.

A.2 Lineær algebra

På kurset bruger vi begreber fra lineær algebra i forbindelse med behandlingen af lineære normale modeller, og de begreber, som vi særligt har brug for er *lineært underrum*, *dimension* og *projektion*. Disse omtales i Afsnit [A.2.3](#), [A.2.3.1](#) og [A.2.9](#). For at gøre notesættet så selvindeholdt som muligt, omtales først en række generelle begreber fra lineær algebra.

På kurset betragtes udelukkende reelle matricer, så en $m \times n$ *matrix* $\mathbf{A}$ er et rektangulært array af reelle tal bestående af m rækker og n søjler, det vil sige

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1j} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2j} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots & & \vdots \\ a_{i1} & a_{i2} & \cdots & a_{ij} & \cdots & a_{in} \\ \vdots & \vdots & & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mj} & \cdots & a_{mn} \end{pmatrix}$$

Dette skrives kort

$$\mathbf{A} = \{a_{ij}\}_{i=1}^m \quad {}_n^{j=1},$$

eller, kortere, hvor dimensionerne underforstået,

$$\mathbf{A} = \{a_{ij}\}.$$

Undertiden skriver vi $(\mathbf{A})_{ij}$ i stedet for a_{ij} .

Den *transponerede* $\mathbf{A}^*$ af $\mathbf{A}$ er $n \times m$ matricen, der fremkommer ved at ombytte rækker og søjler i $\mathbf{A}$, det vil sige

$$\mathbf{A}^* = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{j1} & \cdots & a_{m1} \\ a_{12} & a_{22} & \cdots & a_{j2} & \cdots & a_{m2} \\ \vdots & \vdots & & \vdots & & \vdots \\ a_{1i} & a_{2i} & \cdots & a_{ji} & \cdots & a_{mi} \\ \vdots & \vdots & & \vdots & & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{jn} & \cdots & a_{mn} \end{pmatrix},$$

eller kort

$$\mathbf{A}^* = \{a_{ij}^*\} = \{a_{ji}\}$$

En matrix $\mathbf{A}$ er *symmetrisk*, hvis den er lig sig selv transponeret, $\mathbf{A}^* = \mathbf{A}$, det vil sige hvis $a_{ij} = a_{ji}$. En matrix $\mathbf{A}$ er *kvadratisk*, hvis antallet af rækker i $\mathbf{A}$ er lig med antallet af søjler i $\mathbf{A}$, altså dimensionen er $n \times n$. En symmetrisk matrix er nødvendigvis kvadratisk. En $m \times 1$ matrix kaldes en *m-dimensional søjlevektor*, så

$$\mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{pmatrix}$$

er en søjlevektor med m indgange. I dette notat vil elementer i $\mathbb{R}^m$ blive opfattet som m -dimensionale søjlevektorer og kort omtalt som m -dimensionale *vektorer*. En $1 \times n$ matrix kaldes en *rækkevektor* og den skrives som den transponerede af en (søjle)vektor, det vil sige

$$\mathbf{a}^* = (a_1, a_2, \dots, a_n).$$

Som antydnet ovenover, betegnes (søjle)vektorer med små bogstaver i fed skrift, mens matricer skrives med store bogstaver i fed skrift. De n søjler i $m \times n$ matricen $\mathbf{A}$ betegnes med $\mathbf{a}_{(1)}, \mathbf{a}_{(2)}, \dots, \mathbf{a}_{(j)}, \dots, \mathbf{a}_{(n)}$, mens de m rækker, skrevet som søjlevektorer, kaldes $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_i, \dots, \mathbf{a}_m$, det vil sige, at

$$\mathbf{a}_{(j)} = \begin{pmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{ij} \\ \vdots \\ a_{mj} \end{pmatrix}, \quad \mathbf{a}_i = \begin{pmatrix} a_{i1} \\ a_{i2} \\ \vdots \\ a_{ij} \\ \vdots \\ a_{in} \end{pmatrix}$$

og

$$\mathbf{A} = \{\mathbf{a}_{(1)} \quad \mathbf{a}_{(2)} \quad \cdots \quad \mathbf{a}_{(j)} \quad \cdots \quad \mathbf{a}_{(n)}\} = \begin{pmatrix} \mathbf{a}_1^* \\ \mathbf{a}_2^* \\ \vdots \\ \mathbf{a}_i^* \\ \vdots \\ \mathbf{a}_m^* \end{pmatrix}.$$

Med denne notation kan den transponerede $\mathbf{A}^*$ opskrives

$$\mathbf{A}^* = \begin{pmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_j & \cdots & \mathbf{a}_m \end{pmatrix} = \begin{pmatrix} \mathbf{a}_{(1)}^* \\ \mathbf{a}_{(2)}^* \\ \vdots \\ \mathbf{a}_{(i)}^* \\ \vdots \\ \mathbf{a}_{(n)}^* \end{pmatrix}.$$

A.2.1 Sum, differens og produkt

Hvis $\mathbf{A} = \{a_{ij}\}$ og $\mathbf{B} = \{b_{ij}\}$ er to $m \times n$ matricer er *summen* $\mathbf{A} + \mathbf{B}$ og *differensen* $\mathbf{A} - \mathbf{B}$ begge $m \times n$ matricer givet ved

$$(\mathbf{A} + \mathbf{B})_{ij} = a_{ij} + b_{ij}$$

og

$$(\mathbf{A} - \mathbf{B})_{ij} = a_{ij} - b_{ij}.$$

Hvis $\mathbf{A} = \{a_{ij}\}$ en $m \times n$ matrix og α er en skalar, er $\alpha\mathbf{A}$ den $m \times n$ matrix, hvis elementer er

$$(\alpha\mathbf{A})_{ij} = \alpha\mathbf{A}_{ij} = \alpha a_{ij}.$$

Produktet $\mathbf{AB}$ af $m \times n$ matricen $\mathbf{A} = \{a_{ij}\}$ og $n \times p$ matricen $\mathbf{B} = \{b_{jk}\}$ er $m \times p$ matricen med elementer

$$(\mathbf{AB})_{ik} = \sum_{j=1}^n a_{ij}b_{jk}.$$

Produktet er kun defineret, hvis antallet af søjler i første faktor ($\mathbf{A}$) er lig med antallet af rækker i anden faktor ($\mathbf{B}$).

Hvis $\mathbf{a}$ og $\mathbf{b}$ er n -dimensionale vektorer, kaldes tallet

$$\mathbf{a}^*\mathbf{b} = (a_1, a_2, \dots, a_n) \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix} = \sum_{j=1}^n a_j b_j$$

for *skalar produktet*, *prik produktet* eller det *indre produkt* mellem $\mathbf{a}$ og $\mathbf{b}$ og man benytter ofte notationen $\langle \mathbf{a}, \mathbf{b} \rangle$ eller $\mathbf{a} \cdot \mathbf{b}$. Endvidere omtales $n \times n$ matricen

$$\mathbf{ab}^* = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix} (b_1, b_2, \dots, b_n) = \begin{pmatrix} a_1b_1 & a_1b_2 & \cdots & a_1b_n \\ a_2b_1 & a_2b_2 & \cdots & a_2b_n \\ \vdots & \vdots & & \vdots \\ a_nb_1 & a_nb_2 & \cdots & a_nb_n \end{pmatrix}$$

som det *ydre produkt* mellem $\mathbf{a}$ og $\mathbf{b}$. Bemærk, at det (i, k) te element i $\mathbf{AB}$ er skalar produktet mellem den i te række $\mathbf{a}_i^*$ i $\mathbf{A}$ (betragtet som en søjlevektor) og den k te søjle $\mathbf{b}_{(k)}$ i $\mathbf{B}$, idet

$$(\mathbf{AB})_{ik} = \mathbf{a}_i^*\mathbf{b}_{(k)}.$$

En regneregul som er særligt nyttig i statistik er at udtrykke matrixprodukter, som summer af ydre produkter. Vi lader som før $\mathbf{A}$ være en $m \times n$ matrix, mens $\mathbf{B}$ nu er en $p \times n$ matrix. Da gælder

$$\mathbf{AB}^* = \begin{Bmatrix} \mathbf{a}_{(1)} & \mathbf{a}_{(2)} & \cdots & \mathbf{a}_{(n)} \end{Bmatrix} \begin{Bmatrix} \mathbf{b}_{(1)}^* \\ \mathbf{b}_{(2)}^* \\ \vdots \\ \mathbf{b}_{(n)}^* \end{Bmatrix} = \sum_{i=1}^n \mathbf{a}_{(i)} \mathbf{b}_{(i)}^* . \quad (\text{A.2})$$

To andre opskrivninger for et matrixprodukt er nyttige. Vi lader her $\mathbf{A}$ være en $m \times n$ matrix, $\mathbf{X}$ være en $n \times p$ matrix og $\mathbf{B}$ være en $p \times q$ matrix, og husker at notation for rækkerne i $\mathbf{X}$ er $\mathbf{x}_i^*$ og for søjlerne er $\mathbf{x}_{(j)}$. Da gælder

$$\mathbf{AX} = \begin{Bmatrix} \mathbf{Ax}_{(1)} & \mathbf{Ax}_{(2)} & \cdots & \mathbf{Ax}_{(p)} \end{Bmatrix} , \quad (\text{A.3})$$

og

$$\mathbf{XB} = \begin{Bmatrix} \mathbf{x}_1^* \mathbf{B} \\ \mathbf{x}_2^* \mathbf{B} \\ \vdots \\ \mathbf{x}_n^* \mathbf{B} \end{Bmatrix} . \quad (\text{A.4})$$

Den første regneregul siger at et matrixprodukt kan dannes ved at gange faktoren til venstre ind på søjlerne i faktoren til højre, og den anden siger at et matrixprodukt kan dannes ved at gange faktoren til højre ind på rækkerne i faktoren til venstre.

To vektorer $\mathbf{a}$ og $\mathbf{b}$ siges at være *ortogonale* hvis deres skalar produkt er 0, det vil sige hvis

$$\mathbf{a}^* \mathbf{b} = 0.$$

Normen eller *længden* $\|\mathbf{a}\|$ af en vektor $\mathbf{a}$ er

$$\|\mathbf{a}\| = \sqrt{\mathbf{a}^* \mathbf{a}} = \sqrt{a_1^2 + \cdots + a_n^2} . \quad (\text{A.5})$$

A.2.1.1 Regneregler for summer og produkter

De følgende formler gælder for vilkårlige skalarer α og β og vilkårlige matricer $\mathbf{A}$, $\mathbf{B}$ og $\mathbf{C}$ for hvilke de involverede operationer er veldefinerede:

- $\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}$
- $(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C})$
- $(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC})$
- $\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{AB} + \mathbf{AC}$
- $(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{AC} + \mathbf{BC}$
- $(\alpha\beta)\mathbf{A} = \alpha(\beta\mathbf{A})$
- $\alpha(\mathbf{AB}) = (\alpha\mathbf{A})\mathbf{B} = \mathbf{A}(\alpha\mathbf{B})$
- $(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A}$
- $\alpha(\mathbf{A} + \mathbf{B}) = \alpha\mathbf{A} + \alpha\mathbf{B}$

A.2.1.2 Regneregler for transponering

De følgende formler gælder for en vilkårlig skalar α for og vilkårlige matricer $\mathbf{A}$ og $\mathbf{B}$ for hvilke de involverede operationer er veldefinerede:

- $(\mathbf{A}^*)^* = \mathbf{A}$
- $(\alpha\mathbf{A})^* = \alpha\mathbf{A}^*$
- $(\mathbf{A} + \mathbf{B})^* = \mathbf{A}^* + \mathbf{B}^*$
- $(\mathbf{AB})^* = \mathbf{B}^*\mathbf{A}^*$

A.2.2 Specielle matricer

$\mathbf{A}$ er en *diagonalmatrix*, hvis $a_{ij} = 0$, hvis $i \neq j$, det vil sige hvis

$$\mathbf{A} = \begin{pmatrix} a_{11} & 0 & \cdots & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & & \vdots \\ 0 & 0 & \cdots & a_{ii} & \cdots & 0 \\ \vdots & \vdots & & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & \cdots & a_{nn} \end{pmatrix},$$

hvilket også kort skrives som

$$\mathbf{A} = \text{diag}(a_{11}, a_{22}, \dots, a_{ii}, \dots, a_{nn}).$$

Identitetsmatricen $\mathbf{I}_n$ er diagonalmatricen med 1-taller i diagonalen,

$$\mathbf{I}_n = \text{diag}(1, 1, \dots, 1, \dots, 1) = \begin{pmatrix} 1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & & \vdots & & \vdots \\ 0 & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \vdots & & \vdots & & \vdots \\ 0 & 0 & \cdots & 0 & \cdots & 1 \end{pmatrix}.$$

Den n -dimensionale søjlevektor, hvis indgange alle er 1, betegnes $\mathbf{1}$ eller $\mathbf{1}_n$, hvis vi ønsker at specificere dimensionen,

$$\mathbf{1} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix},$$

mens matricen, hvis elementer alle er 1, betegnes $\mathbf{E}_n$, det vil sige

$$\mathbf{E}_n = \mathbf{1}_n \mathbf{1}_n^* = \begin{pmatrix} 1 & 1 & \cdots & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 & \cdots & 1 \\ \vdots & \vdots & & \vdots & & \vdots \\ 1 & 1 & \cdots & 1 & \cdots & 1 \\ \vdots & \vdots & & \vdots & & \vdots \\ 1 & 1 & \cdots & 1 & \cdots & 1 \end{pmatrix}.$$

A.2.3 Vektorrum og lineære underrum

$\mathbb{R}^n$ er et *vektorrum* med $\mathbf{0}$ som neutral element og $-\mathbf{x}$ som inverst element til $\mathbf{x}$.

Vektorerne $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$ siges at være *lineært afhængige*, hvis der findes reelle tal $\alpha_1, \alpha_2, \dots, \alpha_k$, som ikke alle er 0, således at

$$\alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \cdots + \alpha_k \mathbf{x}_k = \mathbf{0}.$$

Ellers er de k vektorer *lineært uafhængige*. Vektorerne $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$ er altså lineært uafhængige, hvis

$$c_1 \mathbf{x}_1 + c_2 \mathbf{x}_2 + \cdots + c_k \mathbf{x}_k = \mathbf{0}$$

medfører, at $c_1 = c_2 = \cdots = c_k = 0$. Samles $\mathbf{x}_i$ erne i matricen $\mathbf{X}^*$ og c_i erne vektoren $\mathbf{c}$ kan dette udtrykkes

$$\mathbf{X}^* \mathbf{c} = \mathbf{0} \Rightarrow \mathbf{c} = \mathbf{0}.$$

En ikke-tom delmængde L af $\mathbb{R}^n$ kaldes et (*lineært*) *underrum*, hvis det for alle $\mathbf{x}$ og $\mathbf{y}$ i L og for alle α og β i $\mathbb{R}$ gælder, at $\alpha \mathbf{x} + \beta \mathbf{y} \in L$.

Hvis $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$ er k vektorer i $\mathbb{R}^n$, er mængden af alle lineære kombinationer af disse vektorer et lineært underrum, som siges at være *udspændt* af vektorerne og som betegnes $\text{span}(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k)$, det vil sige

$$\text{span}(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k) = \{ \mathbf{x} \in \mathbb{R}^n \mid \mathbf{x} = \alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \cdots + \alpha_k \mathbf{x}_k, \alpha_i \in \mathbb{R}, i = 1, \dots, k \}.$$

A.2.3.1 Basis, dimension og basisskift

En *basis* for et lineært underrum L er en (ordnet) mængde $(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_d)$ af lineært uafhængige vektorer som udspænder L , det vil sige

$$L = \text{span}(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_d).$$

Dimensionen af L er antallet af elementer i en vilkårlig basis for L , det vil sige

$$\dim L = d.$$

En *ortogonal* basis $\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_d$ har ortogonale elementer, det vil sige, at $\mathbf{o}_i^* \mathbf{o}_j = 0$ hvis $i \neq j$, og en *ortonormal* basis er en ortogonal basis, hvis elementer har norm (eller længde) 1, det vil sige,

$$\mathbf{o}_i^* \mathbf{o}_j = \begin{cases} 1 & \text{hvis } i = j \\ 0 & \text{hvis } i \neq j \end{cases}.$$

Standardbasen, også kaldet den *kanoniske basis* for $\mathbb{R}^n$ er basen, hvis elementer er $\mathbf{e}_1 = (1, 0, \dots, 0)^*$, $\mathbf{e}_2 = (0, 1, 0, \dots, 0)^*$, $\dots$, $\mathbf{e}_n = (0, 0, \dots, 0, 1)^*$

Vi kan skifte mellem to baser ved hjælp af *Koordinattransformationsmatricen*. Vi vil specifikt være interesseret i situationen hvor vi ønsker at skifte mellem to baser for $\mathbb{R}^n$, så lad $\mathcal{V} = (\mathbf{v}_{(1)}, \dots, \mathbf{v}_{(n)})$ og $\mathcal{V}' = (\mathbf{v}'_{(1)}, \dots, \mathbf{v}'_{(n)})$ betegne to baser for $\mathbb{R}^n$ og lad $\mathbf{w} \in \mathbb{R}^n$. *Koordinatvektorerne* $[\mathbf{w}]_{\mathcal{V}}$ og $[\mathbf{w}]_{\mathcal{V}'}$ udtrykker $\mathbf{w}$ i de respektive baser, det vil sige at hvis vi lader r_i henholdsvis r'_i betegne indgangene i $[\mathbf{w}]_{\mathcal{V}}$ henholdsvis $[\mathbf{w}]_{\mathcal{V}'}$, da vil

$$\mathbf{w} = r_1 \mathbf{v}_{(1)} + r_2 \mathbf{v}_{(2)} + \dots + r_n \mathbf{v}_{(n)} = r'_1 \mathbf{v}'_{(1)} + r'_2 \mathbf{v}'_{(2)} + \dots + r'_n \mathbf{v}'_{(n)}. \quad (\text{A.6})$$

Samles basisvektorerne til matricer $\mathbf{V} = \{\mathbf{v}_{(1)}, \dots, \mathbf{v}_{(n)}\}$, $\mathbf{V}' = \{\mathbf{v}'_{(1)}, \dots, \mathbf{v}'_{(n)}\}$ kan (A.6) udtrykkes som

$$\mathbf{V}[\mathbf{w}]_{\mathcal{V}} = \mathbf{V}'[\mathbf{w}]_{\mathcal{V}'},$$

og da (f.eks.) $\mathbf{v}_{(i)}$ erne er lineært uafhængige vil $\mathbf{V}$ være invertibel, således at

$$[\mathbf{w}]_{\mathcal{V}} = \mathbf{V}^{-1} \mathbf{V}' [\mathbf{w}]_{\mathcal{V}'}. \quad (\text{A.7})$$

Et specialtilfælde af (A.7) opstår når vi ønsker at skifte fra den kanoniske basis til en orthonormal basis $\mathcal{O} = (\mathbf{o}_1, \dots, \mathbf{o}_n)$. Det er notationsmæssigt bekvemt i denne sammenhæng at lade matricen $\mathbf{O}^* = \{\mathbf{o}_1, \dots, \mathbf{o}_n\}$ spille rollen som $\mathbf{V}$ idet vi samler $\mathbf{o}_i$ erne som rækker i matricen $\mathbf{O}$. Koordinatvektoren for $\mathbf{w}$ med hensyn til den kanoniske basis er $\mathbf{w}$ selv, og da matricen bliver ortogonal fås da

$$[\mathbf{w}]_{\mathcal{O}} = \mathbf{O} \mathbf{w}. \quad (\text{A.8})$$

En fortolkning af (A.8) er at multiplikation (fra højre) med en ortogonal matrix $\mathbf{O}$ svarer til et basis skift til basen der udgøres af rækkerne i $\mathbf{O}$.

A.2.3.2 Ortogonale underrum

To underrum L og M siges at være *ortogonale*, kort $L \perp M$, hvis

$$\mathbf{x}^* \mathbf{y} = 0 \text{ for alle } \mathbf{x} \in L \text{ og for alle } \mathbf{y} \in M.$$

A.2.3.3 Rækkerum og søjlerum

Hvis $\mathbf{A}$ er $m \times n$ matricen

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_{(1)} & \mathbf{a}_{(2)} & \dots & \mathbf{a}_{(j)} & \dots & \mathbf{a}_{(n)} \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^* \\ \mathbf{a}_2^* \\ \vdots \\ \mathbf{a}_i^* \\ \vdots \\ \mathbf{a}_m^* \end{bmatrix}.$$

vil vi her betegne *søjlerummet* for $\mathbf{A}$, det vil sige underrummet af $\mathbb{R}^m$ udspændt af søjlerne i $\mathbf{A}$, med $\text{col}(\mathbf{A})$, så

$$\text{col}(\mathbf{A}) = \text{span}(\mathbf{a}_{(1)}, \mathbf{a}_{(2)}, \dots, \mathbf{a}_{(n)}),$$

mens *rækkerummet* $\text{row}(\mathbf{A})$ for $\mathbf{A}$ er

$$\text{row}(\mathbf{A}) = \text{span}(\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_m)$$

er underrummet af $\mathbb{R}^n$ udspændt af rækkerne i $\mathbf{A}$ (opfattet som søjlevektorer).

A.2.3.4 Snit og sum af underrum

Snittet og *summen* af to underrum L og M er underrummene

$$L \cap M = \{\mathbf{x} \in \mathbb{R}^n \mid \mathbf{x} \in L, \mathbf{x} \in M\}$$

og

$$L + M = \{\mathbf{x} \in \mathbb{R}^n \mid \mathbf{x} = \mathbf{y} + \mathbf{z}, \mathbf{y} \in L, \mathbf{z} \in M\}$$

Hvis $L \cap M = \{\mathbf{0}\}$, siges L og M at være *disjunkte*. Summen af to disjunkte underrum L og M kaldes en *direkte sum* og betegnes $L \oplus M$. Elementer $\mathbf{x}$ i $L \oplus M$ har en entydig repræsentation som $\mathbf{x} = \mathbf{y} + \mathbf{z}$, hvor $\mathbf{y} \in L$ og $\mathbf{z} \in M$ og

$$\dim L \oplus M = \dim L + \dim M.$$

A.2.4 Spor

Sporet $\text{tr}(\mathbf{A})$ af den kvadratiske $n \times n$ matrix $\mathbf{A} = \{a_{ij}\}$ defineres som summen af diagonalelementerne, det vil sige

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

Sporet af et tal α er således tallet selv, $\text{tr}(\alpha) = \alpha$.

A.2.4.1 Regneregler for spor

Hvis α er et reelt tal og $\mathbf{B}$ ($n \times n$), $\mathbf{C}$ ($p \times n$) og $\mathbf{D}$ ($n \times p$) er matricer, gælder der

- $\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr} \mathbf{A} + \text{tr} \mathbf{B}$,
- $\text{tr}(\alpha \mathbf{A}) = \alpha \text{tr} \mathbf{A}$,
- $\text{tr} \mathbf{CD} = \text{tr} \mathbf{DC}$.

Vi har desuden, at hvis $\mathbf{A} = \{a_{ij}\}$, $\mathbf{B} = \{b_{ij}\}$ med dimensioner så produktet $\mathbf{A}^* \mathbf{B}$ har mening gælder der at

$$\text{tr}(\mathbf{A}^* \mathbf{B}) = \sum_{i,j} a_{ij} b_{ij}.$$

Resultatet følger umiddelbart ved at skrive diagonalindgangene af $\mathbf{A}^* \mathbf{B}$ ned. Bemærk endvidere, at resultatet medfører at der for reelle matricer gælder at $\text{tr}(\mathbf{A}^* \mathbf{A}) = \mathbf{0} \Leftrightarrow \mathbf{A} = \mathbf{0}$.

A.2.5 Determinant

Determinanten $|\mathbf{A}|$ af den kvadratiske $n \times n$ matrix $\mathbf{A} = \{a_{ij}\}$ defineres som

$$|\mathbf{A}| = \left| \begin{pmatrix} a_{11} & \cdots & a_{1j} & \cdots & a_{1n} \\ \vdots & & \vdots & & \vdots \\ a_{i1} & \cdots & a_{ij} & \cdots & a_{in} \\ \vdots & & \vdots & & \vdots \\ a_{n1} & \cdots & a_{nj} & \cdots & a_{nn} \end{pmatrix} \right| = \sum_{\pi} (-1)^{|\pi|} a_{1\pi(1)} \cdots a_{n\pi(n)},$$

hvor summen er over alle permutationer π af $(1, 2, \dots, n)$, og $|\pi| = +1$ eller -1 alt efter om π er bestemt ved henholdsvis et lige eller ulige antal ombytninger af to elementer.

Determinanten kan beregnes som

$$|\mathbf{A}| = \sum_{j=1}^n a_{ij} A_{ij} = \sum_{i=1}^n a_{ij} A_{ij} \quad \text{for ethvert } i, j.$$

Her er A_{ij} *kofaktoren* af a_{ij} , det vil sige

$$A_{ij} = (-1)^{i+j} |\mathbf{M}_{ij}|, \quad (\text{A.9})$$

hvor $\mathbf{M}_{ij}$ er *komplementet (minor)* til a_{ij} , det vil sige $(n-1) \times (n-1)$ matrixen, der fremkommer ved at slette den i te række og den j te søjle i $\mathbf{A}$. Hvis $n = 2$, er

$$|\mathbf{A}| = \left| \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \right| = a_{11}a_{22} - a_{12}a_{21}, \quad (\text{A.10})$$

og hvis $n = 3$, er

$$|\mathbf{A}| = \left| \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} \right| = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{13}a_{22}a_{31} - a_{23}a_{32}a_{11} - a_{33}a_{12}a_{21}.$$

A.2.5.1 Regneregler for determinant

$$|\mathbf{A}^*| = |\mathbf{A}|$$

Determinanten af en diagonalmatrix er produktet af diagonalelementerne, det vil sige

$$|\text{diag}(a_{11}, \dots, a_{ii}, \dots, a_{nn})| = \prod_{i=1}^n a_{ii}.$$

For en $n \times n$ matrix $\mathbf{A}$ og $c \in \mathbb{R}$, er

$$|c\mathbf{A}| = c^n |\mathbf{A}|$$

og hvis $\mathbf{B}$ er en $n \times n$ matrix er

$$|\mathbf{AB}| = |\mathbf{A}| |\mathbf{B}| = |\mathbf{BA}|. \quad (\text{A.11})$$

Bemærk at der ikke i almindelighed gælder $|\mathbf{AB}| = |\mathbf{BA}|$ hvis ikke $\mathbf{A}$ og $\mathbf{B}$ har ens dimensioner, som det blev forudsat i (A.11).

A.2.6 Invers

Den *inverse* af en kvadratisk $n \times n$ matrix $\mathbf{A} = \{a_{ij}\}$ er den entydigt bestemte kvadratiske $n \times n$ matrix $\mathbf{A}^{-1}$, således at

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_n.$$

En matrix $\mathbf{A}$ har en invers – eller er *invertibel* – hvis og kun hvis den er *ikke-singulær*, det vil sige hvis og kun hvis $|\mathbf{A}| \neq 0$. Lad $\mathbf{A}^{-1} = \{a^{ij}\}$ betegne indgange i $\mathbf{A}^{-1}$. Der gælder, at

$$a^{ij} = \frac{1}{|\mathbf{A}|}(A_{ji}),$$

hvor A_{ji} er kofaktoren af a_{ji} (se A.9).

Hvis $n = 2$, er

$$\mathbf{A}^{-1} = \frac{1}{a_{11}a_{22} - a_{12}a_{21}} \begin{Bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{Bmatrix}.$$

A.2.6.1 Betingelser for invertibilitet

En $n \times n$ $\mathbf{A}$ er invertibel hvis og kun hvis den har fuld rang, det vil sige $r(\mathbf{A}) = n$ og hvis og kun hvis 0 ikke er en egenværdi for $\mathbf{A}$.

A.2.6.2 Regneregler for inverse

Hvis $c \neq 0$ og $\mathbf{A}$ er invertibel, er

$$(c\mathbf{A})^{-1} = c^{-1}\mathbf{A}^{-1}.$$

Hvis $\mathbf{A}$ og $\mathbf{B}$ er invertible $n \times n$ matricer, er $\mathbf{AB}$ invertibel og

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}.$$

A.2.7 Matricer som lineære afbildninger

En $m \times n$ matrix $\mathbf{A}$ definerer en lineær afbildning

$$\begin{aligned} \mathbf{A} : \mathbb{R}^n &\rightarrow \mathbb{R}^m \\ \mathbf{x} &\rightarrow \mathbf{Ax}. \end{aligned}$$

Da $\mathbf{A} = \{\mathbf{a}_{(1)} \quad \dots \quad \mathbf{a}_{(j)} \quad \dots \quad \mathbf{a}_{(n)}\}$, hvor $\mathbf{a}_{(j)} (\in \mathbb{R}^m)$ er den j 'te søjle i $\mathbf{A}$, og $\mathbf{x} = (x_1, \dots, x_n)^*$, er

$$\mathbf{Ax} = \{\mathbf{a}_{(1)} \quad \dots \quad \mathbf{a}_{(j)} \quad \dots \quad \mathbf{a}_{(n)}\} \begin{Bmatrix} x_1 \\ \vdots \\ x_j \\ \vdots \\ x_n \end{Bmatrix} = x_1\mathbf{a}_{(1)} + \dots + x_j\mathbf{a}_{(j)} + \dots + x_n\mathbf{a}_{(n)}.$$

Specielt hvis $\mathbf{x} = \mathbf{e}_j$, er

$$\mathbf{A}\mathbf{e}_j = \mathbf{a}_{(j)}.$$

Der gælder desuden, at søjlerummet $\text{col}(\mathbf{A})$ for $\mathbf{A}$ er lig med billedrummet $\mathbf{A}(\mathbb{R}^n)$ for $\mathbf{A}$, der traditionelt betegnes med $\mathcal{R}(\mathbf{A})$, det vil sige

$$\text{col}(\mathbf{A}) = \mathcal{R}(\mathbf{A}) (= \mathbf{A}(\mathbb{R}^n)).$$

A.2.8 Rang

Rangen $r(\mathbf{A})$ af en $m \times n$ matrix defineres som dimensionen af søjlerummet $\text{col}(\mathbf{A})$ for $\mathbf{A}$, det vil sige

$$r(\mathbf{A}) \stackrel{\text{def}}{=} \dim \text{col}(\mathbf{A}).$$

Da $\text{col}(\mathbf{A}) = \mathcal{R}(\mathbf{A})$ gælder det, at rangen $r(\mathbf{A})$ alternativt kan udtrykkes som dimensionen af billedrummet for $\mathbf{A}$,

$$r(\mathbf{A}) = \dim \mathcal{R}(\mathbf{A}).$$

Det kan endvidere vises, at

$$r(\mathbf{A}) = \dim \text{col}(\mathbf{A}) = \dim \text{row}(\mathbf{A}). \quad (\text{A.12})$$

A.2.8.1 Rang og dimensioner af underrum

Lad $\mathcal{N}(\mathbf{A})$ betegne *nulrummet* for $\mathbf{A}$, det vil sige

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^n \mid \mathbf{A}\mathbf{x} = \mathbf{0}\}$$

og lad $\nu(\mathbf{A})$ være dimensionen af nulrummet,

$$\nu(\mathbf{A}) = \dim \mathcal{N}(\mathbf{A}).$$

Så er

$$n = \nu(\mathbf{A}) + r(\mathbf{A}) \quad (\text{A.13})$$

eller

$$n = \dim \mathcal{N}(\mathbf{A}) + \dim \mathcal{R}(\mathbf{A}).$$

Hvis $\mathcal{O}(\mathbf{A})$ betegner det ortogonale komplement til $\mathcal{R}(\mathbf{A})$ i $\mathbb{R}^m$, det vil sige

$$\mathcal{O}(\mathbf{A}) = \mathcal{R}(\mathbf{A})^\perp = \{\mathbf{x} \in \mathbb{R}^m \mid \mathbf{x}^* \mathbf{y} = 0, \mathbf{y} \in \mathcal{R}(\mathbf{A})\}$$

så gælder

$$m = r(\mathbf{A}) + \dim \mathcal{O}(\mathbf{A}).$$

A.2.8.2 Regneregler for rang

Yderligere resultater vedrørende rangen af matricer er:

$$0 \leq r(\mathbf{A}) \leq \min(m, n) \quad (\text{A.14})$$

$$r(\mathbf{A}) = r(\mathbf{A}^*)$$

$$r(\mathbf{A} + \mathbf{B}) \leq r(\mathbf{A}) + r(\mathbf{B})$$

$$r(\mathbf{AB}) \leq \min\{r(\mathbf{A}), r(\mathbf{B})\} \quad (\text{A.15})$$

$$r(\mathbf{AA}^*) = r(\mathbf{A}^* \mathbf{A}) = r(\mathbf{A}) \quad (\text{A.16})$$

Hvis en $m \times n$ matrix $\mathbf{A}$ opfylder $r(\mathbf{A}) = \min(m, n)$ siger vi på grund af (A.14) at matricen har *fuld rang*.

Lad $\mathbf{A}$ være en $m \times n$ matrix og lad $\mathbf{B}$ være en $n \times k$ matrix. Da gælder *Sylvester's rank inequality*

$$r(\mathbf{A}) + r(\mathbf{B}) - n \leq r(\mathbf{AB}). \quad (\text{A.17})$$

Ved at kombinere (A.15) og (A.17) fås at hvis $r(\mathbf{B}) = n$ gælder at

$$r(\mathbf{AB}) = r(\mathbf{A}) \quad (\text{A.18})$$

Tilsvarende gælder at hvis $\mathbf{C}$ er en $l \times m$ med $r(\mathbf{C}) = m$ har vi

$$r(\mathbf{CA}) = r(\mathbf{A}). \quad (\text{A.19})$$

Vi bemærker følgende specialtilfælde af (A.18) og (A.19): Hvis $\mathbf{A}$ er en $n \times m$ matrix og $\mathbf{B}, \mathbf{C}$ er invertible matricer, således at matrixproduktet $\mathbf{CAB}$ er veldefineret, da gælder

$$r(\mathbf{CAB}) = r(\mathbf{A}). \quad (\text{A.20})$$

A.2.9 Ortogonale projektioner

I dette afsnit omtales ortogonale projektioner med hensyn til det sædvanlige indre produkt (skalarproduktet) på $\mathbb{R}^n$, det vil sige

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^* \mathbf{y},$$

for $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$.

Lad $\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)}$ betegne q lineært uafhængige vektorer i $\mathbb{R}^n$ og lad L betegne det lineære underrum $L = \text{span}(\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)})$. Enhver vektor $\mathbf{x} \in \mathbb{R}^n$ en entydig fremstilling

$$\mathbf{x} = \mathbf{x}_L + \mathbf{x}_{L^\perp}, \quad (\text{A.21})$$

hvor $\mathbf{x}_L \in L$ og $\mathbf{x}_{L^\perp} \in L^\perp$ hvor $L^\perp$ betegner det ortogonale komplement til L . Lad $\mathbf{P}$ betegne afbildningen

$$\begin{aligned} \mathbf{P} : \mathbb{R}^n &\rightarrow \mathbb{R}^n \\ \mathbf{x} &\mapsto \mathbf{x}_L. \end{aligned}$$

Denne afbildning kaldes den ortogonale projektion på L . Den ortogonale projektion $\mathbf{P}$ er en lineær afbildning og derfor kan repræsenteres ved en matrix $\mathbf{P}$, således at $\mathbf{P}(\mathbf{x}) = \mathbf{Px}$. Generelt vil vi ved opskrivningen $\mathbf{Px}$ ikke skelne mellem om $\mathbf{P}$ skal opfattes som en afbildning eller en matrix og projektionsmatricen $\mathbf{P}$ omtales som “den ortogonale projektion ned på L ”, eller blot “den ortogonale projektion”, når L er underforstået. $\mathbf{P}$ har følgende egenskaber.

$$\mathbf{P} \text{ er symmetrisk, dvs. } \mathbf{P}^* = \mathbf{P}, \quad (\text{A.22})$$

$$\mathbf{P} \text{ er idempotent, dvs. } \mathbf{P}^2 = \mathbf{P}. \quad (\text{A.23})$$

Vi noterer os følgende simple konsekvens af (A.22) og (A.23) for beregningen af prikproduktet

$$\mathbf{Px} \cdot \mathbf{Py} = (\mathbf{Px})^* \mathbf{Py} = \mathbf{x}^* \mathbf{P}^* \mathbf{Py} = \mathbf{x}^* \mathbf{P} \mathbf{Py} = \mathbf{x}^* \mathbf{Py}. \quad (\text{A.24})$$

Specielt for kvadrat længder af vektorer

$$\|\mathbf{Px}\|^2 = \mathbf{Px} \cdot \mathbf{Px} = (\mathbf{Px})^*(\mathbf{Px}) = \mathbf{x}^* \mathbf{P}^* \mathbf{Px} = \mathbf{x}^* \mathbf{P} \mathbf{Px} = \mathbf{x}^* \mathbf{Px}, \quad (\text{A.25})$$

som altså gælder for enhver projektionsmatrix $\mathbf{P}$. Hvis vi endvidere lader $\mathbf{P}_1$ og $\mathbf{P}_2$ betegne ortogonal projektioner ned på underrummene L_1 og L_2 , hvor der gælder at $L_2 \subset L_1$ vil der gælde at $\mathbf{P}_1 - \mathbf{P}_2$ er den ortogonale projektionen ned på $L_1 \cap L_2^\perp$, hvor $L_2^\perp$ betegne L_2 s ortogonal komplement. Matricen $\mathbf{P}_1 - \mathbf{P}_2$ opfylder derfor (A.22) og (A.23) og specielt gælder at for et under rum L med tilhørende ortogonal projektion $\mathbf{P}$ følger det at $\mathbf{I}_n - \mathbf{P}$ er den ortogonale projektion på $L^\perp$, hvor $\mathbf{I}_n$ er den $n \times n$ -dimensionale identitetsmatrix.

Hvis $L \subset \mathbb{R}^n$ er et q -dimensionalt under rum, som er udspændt af vektorerne $\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)}$, dvs. $L = \text{span}(\mathbf{t}_{(1)}, \dots, \mathbf{t}_{(q)})$ (L er altså søjlerummet $\text{col}(\mathbf{T})$), har vi følgende udtryk for $\mathbf{P}$,

$$\mathbf{P} = \mathbf{T}(\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^*, \quad (\text{A.26})$$

hvor $\mathbf{T}$ er $n \times q$ matricen, hvis søjler er $\mathbf{t}_{(i)}$ erne, dvs.:

$$\mathbf{T} = \{\mathbf{t}_{(1)} \quad \mathbf{t}_{(2)} \quad \dots \quad \mathbf{t}_{(q)}\}$$

Et specialtilfælde af (A.26) opstår når vi ønsker opskrive den ortogonale projektion i situationen hvor L er udspændt af en orthonormal basis $\mathbf{o}_1, \dots, \mathbf{o}_q$. Matricen $\mathbf{O}^* = \{\mathbf{o}_1, \dots, \mathbf{o}_q\}$, vil da opfylde at $\mathbf{O} \mathbf{O}^* = \mathbf{I}_q$ og den ortogonale projektion kan opskrives

$$\mathbf{O}^* \mathbf{O} = \sum_{i=1}^q \mathbf{o}_i \mathbf{o}_i^*. \quad (\text{A.27})$$

Bemærkning A.1 Til sidst minder vi om følgende vigtige resultat, der i vidt omfang er årsagen til at vi overhovedet interesserer os for ortogonale projektioner i statistik. Lad L betegne et lineært under rum af $\mathbb{R}^n$ og lad $\mathbf{x} \in \mathbb{R}^n$ opfylde

$$\mathbf{x} = \mathbf{x}_L + \mathbf{x}_{L^\perp}$$

som i (A.21). Da gælder

$$\|\mathbf{x} - \mathbf{x}_L\| < \|\mathbf{x} - \mathbf{y}\|$$

for alle $\mathbf{y} \in L \setminus \{\mathbf{x}_L\}$. Med andre ord kan $\mathbf{x}_L$ fortolkes som det element i L , der er tættest på $\mathbf{x}$. Dette resultat kan sammenfattes som

$$\|\mathbf{x} - \mathbf{x}_L\| = \min_{\mathbf{y} \in L} \|\mathbf{x} - \mathbf{y}\|.$$

A.2.10 Kvadratkomplettering

For andengrads ligninger kendes omskrivningen “Kvadratkomplettering” / “Kvadratets fuldstændiggørelse” (eng. “*completing the square*”). Der findes en lignende omskrivning for kvadratiske polynomier i flere variable. Lad $\mathbf{z} \in \mathbb{R}^n$ og betragt

$$\mathbf{z}^* \mathbf{A} \mathbf{z} + \mathbf{b}^* \mathbf{z} + c,$$

hvor $\mathbf{A}$ er en symmetrisk $n \times n$ matrix, $\mathbf{b} \in \mathbb{R}^n$ og $c \in \mathbb{R}$ er en reel skalar. Da gælder

$$\mathbf{z}^* \mathbf{A} \mathbf{z} + \mathbf{b}^* \mathbf{z} + c = \left(\mathbf{z} + \frac{1}{2} \mathbf{A}^{-1} \mathbf{b} \right)^* \mathbf{A} \left(\mathbf{z} + \frac{1}{2} \mathbf{A}^{-1} \mathbf{b} \right) + \left(c - \frac{1}{4} \mathbf{b}^* \mathbf{A}^{-1} \mathbf{b} \right).$$

Ligheden kan også skrives på følgende måde:

$$\mathbf{z}^* \mathbf{A} \mathbf{z} + \mathbf{b}^* \mathbf{z} + c = (\mathbf{z} - \mathbf{h})^* \mathbf{A} (\mathbf{z} - \mathbf{h}) + k$$

hvor

- $\mathbf{h} = -\frac{1}{2} \mathbf{A}^{-1} \mathbf{b}$
- $k = c - \frac{1}{4} \mathbf{b}^* \mathbf{A}^{-1} \mathbf{b}$.

En anvendelse som er relevant inden for multipel regression er følgende: For $\mathbf{T}(n \times d)$, $\boldsymbol{\beta}(d \times 1)$ og $\mathbf{x}(n \times 1)$, hvor $d \leq n$ og $\mathbf{T}$ har fuld rang d gælder

$$\begin{aligned} \|\mathbf{x} - \mathbf{T}\boldsymbol{\beta}\|^2 &= (\mathbf{x} - \mathbf{T}\boldsymbol{\beta})^* (\mathbf{x} - \mathbf{T}\boldsymbol{\beta}) \\ &= (\mathbf{T}\boldsymbol{\beta})^* (\mathbf{T}\boldsymbol{\beta}) - \mathbf{x}^* \mathbf{T}\boldsymbol{\beta} - (\mathbf{T}\boldsymbol{\beta})^* \mathbf{x} + \mathbf{x}^* \mathbf{x} \\ &= \boldsymbol{\beta}^* \mathbf{T}^* \mathbf{T} \boldsymbol{\beta} - 2\mathbf{x}^* \mathbf{T}\boldsymbol{\beta} + \mathbf{x}^* \mathbf{x} \\ &= (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^* \mathbf{T}^* \mathbf{T} (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) + k \\ &= \|\mathbf{T}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})\|^2 + k \end{aligned}$$

hvor

- $\hat{\boldsymbol{\beta}} = (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{x}$
- $k = \mathbf{x}^* \mathbf{x} - \mathbf{x}^* \mathbf{T}^* (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T} \mathbf{x}$.

A.2.11 Middelværdier og kovarianser

For en stokastisk vektor eller matrix $\mathbf{X}$ vil den tilknyttede middelværdivektor eller middelværdimatrix have samme dimensioner som $\mathbf{X}$. Det vil sige at hvis $\mathbf{X} = (X_1, X_2, \dots, X_p)^*$ er en p dimensional søjlevektor, så vil den tilknyttede middelværdivektor være

$$\mathbf{E} \mathbf{X} = \begin{pmatrix} \mathbf{E} X_1 \\ \mathbf{E} X_2 \\ \vdots \\ \mathbf{E} X_p \end{pmatrix}.$$

Når vi opskriver middelværdier på denne måde, antager vi implicit at disse er veldefinerede.

Det følger at hvis $\mathbf{a}$ er en $k \times 1$ dimensional søjlevektor og $\mathbf{A}$ er en $k \times n$ matrix (begge er ikke-stokastiske), da gælder

$$\mathbf{E}[\mathbf{a} + \mathbf{A}\mathbf{X}] = \mathbf{a} + \mathbf{A} \mathbf{E} \mathbf{X}.$$

Kovariansmatricen for en p -dimensional stokastisk vektor $\mathbf{X}$ er

$$\text{Cov } \mathbf{X} \stackrel{\text{def}}{=} \begin{Bmatrix} \text{Var } X_1 & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Var } X_2 & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \text{Cov}(X_p, X_2) & \cdots & \text{Var } X_p \end{Bmatrix}. \quad (\text{A.28})$$

Bemærk at diagonalindgangene også kan opfattes som kovarianser idet vi husker at $\text{Var } X_i = \text{Cov}(X_i, X_i)$. Kovariansmatricen er symmetrisk da $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$. “Kovariansmatricen” omtales til tider også som “Varians-kovariansmatricen” eller blot “Variansen”. Når $\mathbf{X}$ er en $p \times 1$ søjlevektor med middelværdivektor $\mathbf{E} \mathbf{X}$ har vi

$$\text{Cov } \mathbf{X} = \mathbf{E}[(\mathbf{X} - \mathbf{E} \mathbf{X})(\mathbf{X} - \mathbf{E} \mathbf{X})^*]. \quad (\text{A.29})$$

Kovariansen mellem to vektorer $\mathbf{X}$, $\mathbf{Y}$, til tider omtalt som *krydskovariansen*, er matricen der består af kovariansenerne $\text{Cov}(X_i, Y_j)$, der kan dannes mellem indgangene i $\mathbf{X}$ og indgangene i $\mathbf{Y}$. Mere præcist gælder at for en $p \times 1$ søjlevektor $\mathbf{X} = (X_1, X_2, \dots, X_p)^*$ og en $q \times 1$ søjlevektor $\mathbf{Y} = (Y_1, Y_2, \dots, Y_q)^*$ har vi at kovariansen mellem $\mathbf{X}$ og $\mathbf{Y}$ er $p \times q$ matrix

$$\begin{aligned} \text{Cov}(\mathbf{X}, \mathbf{Y}) &= \mathbf{E}[(\mathbf{X} - \mathbf{E} \mathbf{X})(\mathbf{Y} - \mathbf{E} \mathbf{Y})^*] \\ &= \begin{Bmatrix} \text{Cov}(X_1, Y_1) & \text{Cov}(X_1, Y_2) & \cdots & \text{Cov}(X_1, Y_q) \\ \text{Cov}(X_2, Y_1) & \text{Cov}(X_2, Y_2) & \cdots & \text{Cov}(X_2, Y_q) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, Y_1) & \text{Cov}(X_p, Y_2) & \cdots & \text{Cov}(X_p, Y_q) \end{Bmatrix}. \end{aligned} \quad (\text{A.30})$$

Bemærk kovariansen $\text{Cov}(\cdot, \cdot)$ mellem stokastiske vektorer i modsætning til kovariansen mellem stokastiske variable *ikke* er symmetrisk i sine argumenter, idet det hovedsageligt er tilfældet at $\text{Cov}(\mathbf{X}, \mathbf{Y}) \neq \text{Cov}(\mathbf{Y}, \mathbf{X})$. Den er generelt heller ikke en symmetrisk matrix (i modsætning til kovariansmatricen $\text{Cov } \mathbf{X}$). Bemærk desuden at kovariansen mellem $\mathbf{X}$ og $\mathbf{X}$ selv, er kovariansmatricen for $\mathbf{X}$, dvs. $\text{Cov}(\mathbf{X}, \mathbf{X}) = \text{Cov } \mathbf{X}$. Endeligt har vi følgende regneregler for kovariansen mellem $\mathbf{A} \mathbf{X}$ og $\mathbf{B} \mathbf{Y}$, hvor $\mathbf{A}$ og $\mathbf{B}$ er matricer så de angivne matrixprodukter er veldefinerede

$$\text{Cov}(\mathbf{A} \mathbf{X}, \mathbf{B} \mathbf{Y}) = \mathbf{A} \text{Cov}(\mathbf{X}, \mathbf{Y}) \mathbf{B}^*. \quad (\text{A.31})$$

Ved at benytte ovenstående med $\mathbf{Y} = \mathbf{X}$ og $\mathbf{B} = \mathbf{A}$ fås følgende regneregler for kovariansmatricen

$$\text{Cov}(\mathbf{A} \mathbf{X}) = \mathbf{A} \text{Cov}(\mathbf{X}) \mathbf{A}^*. \quad (\text{A.32})$$

Betragt kovariansmatricen $\Sigma = \text{Cov } \mathbf{X}$ for en p -dimensional stokastisk søjlevektor $\mathbf{X} = (X_1, X_2, \dots, X_p)^*$ og lad σ_{ij} betegne indgangene i Σ , det vil sige

$$\Sigma = \begin{Bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{12} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{1p} & \sigma_{2p} & \cdots & \sigma_{pp} \end{Bmatrix}. \quad (\text{A.33})$$

Bemærkning A.2 Bemærk at diagonalindgangene σ_{ii} er varianserne $\mathbb{V}\text{ar } X_i$, men at vi i opskrivningen (A.33) ikke skriver disse op som kvadrater, σ^2 , hvilket man ellers er vant til fra det én-dimensionale tilfælde. En alternativ opskrivning af kovariansmatricer, hvor kvadraterne indgår, er

$$\Sigma = \begin{Bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{12} & \sigma_2^2 & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{1p} & \sigma_{2p} & \cdots & \sigma_p^2 \end{Bmatrix}. \quad (\text{A.34})$$

Vi er ofte interesserede i korrelationen mellem par af stokastiske variable, og vi vil derfor definere korrelationsmatricen. Korrelationskoefficienten ρ_{ij} er, med betegnelserne fra (A.33)

$$\rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}}\sqrt{\sigma_{jj}}},$$

med kovariansen i tælleren og produktet af standard afvigelse i nævneren.

Korrelationsmatricen er nu den symmetriske $p \times p$ matrix

$$\rho = \begin{Bmatrix} \frac{\sigma_{11}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{11}}} & \frac{\sigma_{12}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}} & \cdots & \frac{\sigma_{1p}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{pp}}} \\ \frac{\sigma_{12}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}} & \frac{\sigma_{22}}{\sqrt{\sigma_{22}}\sqrt{\sigma_{22}}} & \cdots & \frac{\sigma_{2p}}{\sqrt{\sigma_{22}}\sqrt{\sigma_{pp}}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\sigma_{1p}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{pp}}} & \frac{\sigma_{2p}}{\sqrt{\sigma_{22}}\sqrt{\sigma_{pp}}} & \cdots & \frac{\sigma_{pp}}{\sqrt{\sigma_{pp}}\sqrt{\sigma_{pp}}} \end{Bmatrix} = \begin{Bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{12} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{1p} & \rho_{2p} & \cdots & 1 \end{Bmatrix}. \quad (\text{A.35})$$

Hvis vi indfører en $p \times p$ diagonalmatrix, hvis indgange er standardafvigelse $\sqrt{\sigma_{ii}}$, det vil sige

$$\mathbf{D} = \begin{Bmatrix} \sqrt{\sigma_{11}} & 0 & \cdots & 0 \\ 0 & \sqrt{\sigma_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{\sigma_{pp}} \end{Bmatrix}$$

har vi regnereglerne

$$\mathbf{D}\rho\mathbf{D} = \Sigma,$$

og

$$\rho = \mathbf{D}^{-1}\Sigma\mathbf{D}^{-1}.$$

A.3 Fordelinger i statistik

A.3.1 Normalfordelingen

A.3.1.1 Definition

En kontinuert stokastisk variabel X er normalfordelt med middelværdi μ ($\in \mathbb{R}$) og varians σ^2 (> 0), hvis tæthedsfunktionen for X er

$$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad x \in \mathbb{R}. \quad (\text{A.36})$$

Fordelingen betegnes $N(\mu, \sigma^2)$, og hvis X har tæthedsfunktionen A.36 skriver vi $X \sim N(\mu, \sigma^2)$. Vi vil desuden lade $N(\mu, 0)$ betegne fordelingen der er koncentreret i μ , dvs. hvis $X \sim N(\mu, 0)$ gælder der at $\mathbb{P}(X = \mu) = 1$, men man skal være opmærksom på at fordelingsresultater, der involverer division med σ implicit forudsætter $\sigma > 0$.

Fordelingen $N(0, 1)$ refereres til som *standard normalfordelingen*. Dens tæthedsfunktion betegnes traditionelt med φ og fordelingsfunktionen med Φ , det vil sige

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad \text{og} \quad (\text{A.37})$$

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz. \quad (\text{A.38})$$

Der gælder at

$$X \sim N(\mu, \sigma^2) \Leftrightarrow \frac{X - \mu}{\sigma} \sim N(0, 1), \quad (\text{A.39})$$

og dermed vil fordelingsfunktion og tæthed være

$$\begin{aligned} F_X(x) &= \Phi\left(\frac{x - \mu}{\sigma}\right) \quad \text{og} \\ f_X(x) &= \frac{1}{\sigma} \varphi\left(\frac{x - \mu}{\sigma}\right). \end{aligned} \quad (\text{A.40})$$

A.3.1.2 Middelværdi og varians

Parametrene μ og σ^2 betegnes middelværdi og varians, idet der for $X \sim N(\mu, \sigma^2)$ gælder at

$$\mathbb{E} X = \mu \quad \text{og} \quad \mathbb{V}\text{ar} X = \sigma^2.$$

A.3.1.3 Fordelingsegenskaber

Lad $X_1, \dots, X_n$ være uafhængige stokastiske variable så $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, \dots, n$. Hvis Y er en affin funktion af X -erne, det vil sige at Y er på formen

$$Y = c_0 + c_1 X_1 + \dots + c_n X_n$$

for $c_i \in \mathbb{R}$, $i = 1, \dots, n$, har vi

$$Y \sim N(c_0 + c_1 \mu_1 + \dots + c_n \mu_n, c_1^2 \sigma_1^2 + \dots + c_n^2 \sigma_n^2).$$

Specielt gælder at når X -erne er en i.i.d. følge med fælles middelværdi μ og varians σ^2 vil

$$X. \stackrel{\text{def}}{=} \sum_{i=1}^n X_i \sim N(n\mu, n\sigma^2) \quad \text{og} \quad \bar{X} \stackrel{\text{def}}{=} \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Sidstnævnte genkendes som maksimum likelihood estimatoren for μ i en normalfordelt observationsrække.

Som det fremgår af ovenstående, er affine funktioner af uafhængige normalfordelte stokastiske variable igen normalfordelte. Hvis vi har to sådanne variable, altså Y_1 og Y_2 , hvor

$$Y_1 = a_0 + a_1X_1 + \cdots + a_nX_n \quad \text{og} \quad Y_2 = b_0 + b_1X_1 + \cdots + b_nX_n,$$

så gælder

$$\text{Cov}(Y_1, Y_2) = a_1b_1\sigma_1^2 + \cdots + a_nb_n\sigma_n^2,$$

samt at Y_1 og Y_2 er uafhængige hvis (og kun hvis) $\text{Cov}(Y_1, Y_2) = 0$.

Endeligt benyttes betegnelsen u_p for p -fraktilen i $N(0, 1)$ -fordelingen, dvs. $u_p = \Phi^{-1}(p)$ og hvis x_p betegner p -fraktilen for en $N(\mu, \sigma^2)$ fordeling gælder pga. (A.40) og reglen for den inverse af en sammensat funktion at

$$u_p = \frac{x_p - \mu}{\sigma}.$$

A.3.2 χ^2 -fordelingen

A.3.2.1 Definition

Lad $X_1, X_2, \dots, X_n$ betegne en følge af uafhængige $N(0, 1)$ -fordelte stokastiske variable. Fordelingen af $\mathcal{X}$ hvor

$$\mathcal{X} = X_1^2 + X_2^2 + \cdots + X_n^2, \tag{A.41}$$

betegnes χ^2 -fordelingen med n frihedsgrader eller $\chi^2(n)$ -fordelingen. Antallet af frihedsgrader benævnes traditionelt f , hvilket vi også vil gøre i det efterfølgende. Tæthedsfunktion for $\chi^2(f)$ -fordelingen er

$$f_{\chi^2(f)}(x) = \frac{\left(\frac{1}{2}\right)^{\frac{f}{2}}}{\Gamma\left(\frac{f}{2}\right)} x^{\frac{f}{2}-1} e^{-\frac{x}{2}}, \quad x > 0,$$

hvor $\Gamma(\cdot)$ er gammafunktionen. $\chi^2(f)$ -fordelingen optræder blandt andet når man betragter estimators for variansen i lineære normale modeller, og på grund af formen af disse estimators benytter man notationen $\sigma^2\chi^2(f)$ for fordelingen af en stokastisk variabel Y med den egenskab at $Y/\sigma^2 \sim \chi^2(f)$ og tilsvarende for $\chi^2(f)/f$ og $\sigma^2\chi^2(f)/f$. Betydningen af denne notation er altså at

$$X \sim \sigma^2\chi^2(f)/f \quad \Leftrightarrow \quad \frac{f}{\sigma^2}X \sim \chi^2(f).$$

A.3.2.2 Middelværdi, varians og fordelingsresultater

$\chi^2(f)$ -fordelingen er et specialtilfælde af gammafordelingen (se A.3.5), idet

$$\chi^2(f) = \Gamma\left(\frac{f}{2}, \frac{1}{2}\right),$$

og mange af fordelingsens egenskaber følger derfor direkte af de tilsvarende egenskaber for gammafordelingen. For eksempel fås, ved hjælp af (A.57), at hvis $X \sim \chi^2(f)$, så gælder at

$$\mathbb{E} X = f \quad \text{og} \quad \text{Var} X = 2f. \tag{A.42}$$

Ved at benytte (A.56) fås

$$\sigma^2 \chi^2(f) \sim \Gamma\left(\frac{f}{2}, \frac{1}{2\sigma^2}\right) \quad , \quad \chi^2(f)/f \sim \Gamma\left(\frac{f}{2}, \frac{f}{2}\right) \quad \text{og} \quad \sigma^2 \chi^2(f)/f \sim \Gamma\left(\frac{f}{2}, \frac{f}{2\sigma^2}\right).$$

Hvis X_1 og X_2 er uafhængige stokastiske variable gælder der, at

$$X_i \sim \chi^2(f_i), \quad i = 1, 2 \quad \Rightarrow \quad X_1 + X_2 \sim \chi^2(f_1 + f_2), \quad (\text{A.43})$$

og ved at benytte (A.39) fås, at hvis $X_1, X_2, \dots, X_n$ er en følge af uafhængige $N(0, \sigma^2)$ -fordelte stokastiske variable da gælder

$$X_1^2 + X_2^2 + \dots + X_n^2 \sim \sigma^2 \chi^2(n). \quad (\text{A.44})$$

Ved at kombinere (A.39) og (A.41) fås, at hvis $X_1, \dots, X_n$ er en i.i.d. følge af $N(\mu, \sigma^2)$ -fordelte stokastiske variable gælder

$$\sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2} \sim \chi^2(n),$$

eller, ækvivalent hermed,

$$\sum_{i=1}^n (X_i - \mu)^2 \sim \sigma^2 \chi^2(n). \quad (\text{A.45})$$

Hvis middelværdien μ i ovenstående erstattes $\bar{X}$. altså, estimatet for middelværdien, gælder

$$\sum_{i=1}^n (X_i - \bar{X})^2 \sim \sigma^2 \chi^2(n-1), \quad (\text{A.46})$$

og ved at sammenligne (A.45) og (A.46) ser vi, at når vi erstatter den sande middelværdi med den tilsvarende estimator reduceres antallet af frihedsgrader i den tilhørende χ^2 fordeling med én. Der gælder yderligere at de stokastiske variable $\bar{X}$. og $\sum_{i=1}^n (X_i - \bar{X})^2$ er uafhængige og derfor

$$s^2(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \sigma^2 \chi^2(n-1)/(n-1) \quad (\text{A.47})$$

samt $\bar{X}$. og $s^2(\mathbf{X})$ er stokastisk uafhængige. Bemærk at $s^2(\mathbf{X})$ er estimatoren for variansen i en observationsrække fra normalfordelingen.

A.3.3 t -fordelingen

A.3.3.1 Definition

Hvis U og Z er to uafhængige stokastiske variable således at $U \sim N(0, 1)$ og $Z \sim \chi^2(f)/f$, er størrelsen

$$t = \frac{U}{\sqrt{Z}} \quad (\text{A.48})$$

t -fordelt med f frihedsgrader og vi skriver $t \sim t(f)$. Symbolsk kan definitionen af t -fordelingen gængives som

$$t(f) = \frac{N(0, 1)}{\sqrt{\chi^2(f)/f}}, \quad (\text{A.49})$$

hvis vi husker på at tæller og nævner symboliserer *uafhængige* stokastiske variable. Fordelingen kaldes undertiden *Student* fordelingen eller *Student's t*-fordeling. Som for χ^2 fordelingen er det fraktilerne for $t(f)$ -fordelingen, der er af primær interesse i forbindelse med inferens i modeller baseret på normalfordelingen, og ikke selve tæthedsfunktionen, som er

$$f_{t(f)}(x) = \frac{1}{\sqrt{f}B(1/2, f/2)} \left(1 + \frac{x^2}{f}\right)^{-(f+1)/2}, \quad x \in R, \quad (\text{A.50})$$

hvor $B(\cdot, \cdot)$ betegner betafunktionen defineret i formel (A.58) nedenfor.

A.3.3.2 Fordelingsresultater

Antag, at $X_1, \dots, X_n$ er uafhængige og identisk $N(\mu, \sigma^2)$ fordelte og lad $\bar{X}$ og $s^2(\mathbf{X})$ betegne estimatorerne for henholdsvis middelværdi og varians. Det følger da af (A.3.1.3), (A.47) og (A.48) samt uafhængigheden af $\bar{X}$ og $s^2(\mathbf{X})$ at

$$t = \frac{\bar{X} - \mu}{\sqrt{s^2(\mathbf{X})/n}} \sim t(n-1).$$

A.3.4 F -fordelingen

A.3.4.1 Definition

Lad Z_1 og Z_2 være to uafhængige stokastiske variable så $Z_i \sim \chi^2(f_i)/f_i$, $i = 1, 2$. Da er den stokastiske variabel

$$F = \frac{Z_1}{Z_2} \quad (\text{A.51})$$

F -fordelt med (f_1, f_2) frihedsgrader, eller med f_1 frihedsgrader i tælleren og f_2 frihedsgrader i nævneren og vi skriver $F \sim F(f_1, f_2)$. Fordelingen kan skrives som

$$F(f_1, f_2) = \frac{\chi^2(f_1)/f_1}{\chi^2(f_2)/f_2}, \quad (\text{A.52})$$

hvor tæller og nævner symboliserer *uafhængige* stokastiske variable. Fordelingens tæthed er

$$f_{F(f_1, f_2)}(x) = \frac{f_1^{f_1/2} f_2^{f_2/2}}{B(f_1/2, f_2/2)} x^{f_1/2-1} (f_2 + f_1 x)^{-(f_1+f_2)/2} \quad x > 0 \quad (\text{A.53})$$

hvor $B(\cdot, \cdot)$ er betafunktionen se (A.58).

Ved at kombinere (A.48) med (A.51) fås kvadratet på en t -fordelt stokastisk variabel er F -fordelt, da der gælder at

$$T \sim t(f) \Rightarrow T^2 \sim F(1, f). \quad (\text{A.54})$$

A.3.4.2 Fordelingsresultater

I statistik dukker F -fordelingen op i variansanalyse, hvor man sammenligner to empiriske varianser i en model med normalfordelte data. Antag, at vi betragter to uafhængige normalfordelte observationsrækker med samme varians. Det vil sige, vi betragter uafhængige stokastiske variable $X_1, \dots, X_n$ og $Y_1, \dots, Y_m$, således at

$$X_i \sim N(\mu_X, \sigma^2), \quad i = 1, \dots, n, \quad \text{og} \quad Y_j \sim N(\mu_Y, \sigma^2), \quad j = 1, \dots, m.$$

Bemærk, at varianserne er ens for samtlige stokastiske variable.

Vi betragter da estimatorerne for variansen inden for hver gruppe (se A.47), dvs. $s^2(\mathbf{X})$ og $s^2(\mathbf{Y})$ hvor

$$s^2(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \sigma^2 \chi^2(n-1)/(n-1)$$

og

$$s^2(\mathbf{Y}) = \frac{1}{m-1} \sum_{i=1}^m (Y_i - \bar{Y})^2 \sim \sigma^2 \chi^2(m-1)/(m-1).$$

Da $s^2(\mathbf{X})$ og $s^2(\mathbf{Y})$ er stokastisk uafhængige fås af formel (A.51)

$$F = \frac{s^2(\mathbf{X})}{s^2(\mathbf{Y})} \sim F(n-1, m-1).$$

Det følger desuden umiddelbart fra (A.51) at

$$X \sim F(f_1, f_2) \Rightarrow \frac{1}{X} \sim F(f_2, f_1) \quad (\text{A.55})$$

A.3.5 Gammafordelingen

A.3.5.1 Definition

Gammafordelingen $\Gamma(\alpha, \beta)$ er fordelingen på $]0, \infty[$ med tæthedsfunktion

$$\gamma(x; \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0,$$

hvor parametrene opfylder $\alpha, \beta > 0$ og $\Gamma(\cdot)$ betegner gammafunktionen

$$\Gamma(\alpha) \stackrel{\text{def}}{=} \int_0^\infty x^{\alpha-1} e^{-x} dx$$

A.3.5.2 Fordelingsresultater

Vi skriver $X \sim \Gamma(\alpha, \beta)$ når X har ovenstående tæthed. α kaldes *formparameteren*, og β kaldes *rateparameteren* eller *invers skala parameter*, idet der for $\lambda > 0$ gælder at

$$X \sim \Gamma(\alpha, \beta) \Rightarrow \lambda X \sim \Gamma(\alpha, \frac{\beta}{\lambda}). \quad (\text{A.56})$$

For middelværdi og varians gælder at hvis $X \sim \Gamma(\alpha, \beta)$ er

$$E X = \frac{\alpha}{\beta} \quad \text{og} \quad \text{Var } X = \frac{\alpha}{\beta^2}. \quad (\text{A.57})$$

Hvis X_1 og X_2 er uafhængige stokastiske variable med $X_i \sim \Gamma(\alpha_i, \beta)$, da gælder

$$X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta).$$

A.3.6 Betafordelingen

Betafordelingen med parametre $\alpha_1 > 0$ og $\alpha_2 > 0$ betegnes $B(\alpha_1, \alpha_2)$ og har tæthedsfunktionen

$$\beta(x; \alpha_1, \alpha_2) = \frac{1}{B(\alpha_1, \alpha_2)} x^{\alpha_1-1} (1-x)^{\alpha_2-1}, \quad x \in [0, 1].$$

Her er $B(\alpha_1, \alpha_2)$ *betafunktionen*, som er defineret ved

$$B(\alpha_1, \alpha_2) \stackrel{\text{def}}{=} \int_0^1 x^{\alpha_1-1} (1-x)^{\alpha_2-1} dx. \quad (\text{A.58})$$

Betafunktionen kan udtrykkes ved Gammafunktionen, idet der gælder at

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

og dermed specielt, idet $\Gamma(1/2) = \sqrt{\pi}$,

$$B(1/2, f/2) = \sqrt{\pi} \frac{\Gamma(\frac{f}{2})}{\Gamma(\frac{f+1}{2})}.$$

A.3.6.1 Produkt af Betafordelte stokastiske variable

Produktet af to uafhængige Betafordelte stokastiske variable er Betafordelt, hvis parametrene “passer sammen” i følgende forstand: Lad U og V være uafhængige stokastiske variable, således at

$$U \sim B(a, b), \quad V \sim B(a + b, c).$$

Da gælder

$$UV \sim B(a, b + c).$$

A.3.6.2 Relation til gammafordelingen

Betafordelingen er relateret til gammafordelingen, idet der gælder, at hvis $X_1, \dots, X_n$ er uafhængige og $X_i \sim \Gamma(\alpha_i, \lambda)$ $i = 1, \dots, n$, så gælder

$$Y_j = \frac{\sum_{i=1}^j X_i}{\sum_{i=1}^{j+1} X_i} \sim B\left(\sum_{i=1}^j \alpha_i, \alpha_{j+1}\right)$$

for $j = 1, \dots, n-1$, og endvidere er Y_j erne og $\sum_{i=1}^{j+1} X_i$ indbyrdes uafhængige. På grund af relationen mellem χ^2 fordelingen og Γ fordelingen fås specialtilfældet, at hvis X_1 og X_2 er uafhængige $\sigma^2\chi^2(f_i)$ -fordelte stokastiske variable, da er

$$\begin{aligned} \frac{X_1}{X_1 + X_2} &\sim B\left(\frac{f_1}{2}, \frac{f_2}{2}\right) \quad \text{og} \\ \frac{X_1}{X_1 + X_2} &\text{ er uafhængig af } X_1 + X_2. \end{aligned} \quad (\text{A.59})$$

Bemærk at det følger af (A.43) $X_1 + X_2 \sim \sigma^2\chi^2(f_1 + f_2)$.

A.3.6.3 Relation til F -Fordelingen

Betafordelingen er nært knyttet til F -fordelingen. Sammenhængen kan udtrykkes som

$$X \sim F(f_1, f_2) \Rightarrow \frac{f_1 X}{f_2 + f_1 X} \sim B(f_1/2, f_2/2),$$

og den omvendte relation

$$X \sim B(f_1/2, f_2/2) \Rightarrow \frac{f_2}{f_1} \frac{X}{(1-X)} \sim F(f_1, f_2).$$

På grund af (A.55) kan sammenhængen mellem Beta og F -fordelingen også udtrykkes i relationerne

$$X \sim F(f_2, f_1) \Rightarrow \frac{1}{1 + \frac{f_2}{f_1} X} \sim B(f_1/2, f_2/2),$$

og

$$X \sim B(f_1/2, f_2/2) \Rightarrow \frac{f_1}{f_2} \frac{1-X}{X} \sim F(f_2, f_1).$$

A.3.7 Den flerdimensionale normalfordeling

En stokastisk vektor $\mathbf{X} = (X_1, \dots, X_p)^*$ siges at være *p -dimensionalt normalfordelt*, hvis det for enhver vektor $\mathbf{a} = (a_1, \dots, a_p) \in \mathbb{R}^p$ gælder, at

$$\mathbf{a} \cdot \mathbf{X} = a_1 X_1 + a_2 X_2 + \dots + a_p X_p$$

er normalfordelt, jf. Afsnit (A.3.1).

Den flerdimensionale normalfordeling er karakteriseret ved sin middelværdivektor $\boldsymbol{\mu}$ og sin kovariansmatriks $\boldsymbol{\Sigma}$, og vi skriver

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}).$$

På grund af resultaterne i afsnit A.3.1.3 har vi, at hvis $X_1, \dots, X_p$ er uafhængige stokastiske variable med $X_i \sim N(\mu_i, \sigma_i^2)$, vil der gælde, at

$$\begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix} = \mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad \text{hvor} \quad \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{pmatrix} \quad \text{og} \quad \boldsymbol{\Sigma} = \begin{pmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_p^2 \end{pmatrix}.$$

Hvis varianserne alle er ens, $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_p^2 = \sigma^2$, har vi specielt $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_p)$, hvor $\mathbf{I}_p$ er den $p \times p$ -dimensionale identitetsmatrix.

Proposition A.3 Lad $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\mathbf{B}$ en $k \times p$ matrix og $\boldsymbol{\eta} \in \mathbb{R}^k$, da er

$$\mathbf{Y} = \boldsymbol{\eta} + \mathbf{B}\mathbf{X} \sim N_k(\boldsymbol{\eta} + \mathbf{B}\boldsymbol{\mu}, \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}^*). \quad \blacklozenge$$

Proposition A.4 Hvis $\mathbf{Y}$ er $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ fordelt og $\mathbf{B}$ er en $k \times p$ matrix og $\mathbf{C}$ er en $m \times p$ matrix, så er $\mathbf{B}\mathbf{Y}$ og $\mathbf{C}\mathbf{Y}$ uafhængige, hvis og kun hvis $\mathbf{B}\boldsymbol{\Sigma}\mathbf{C}^* = \mathbf{0}$. $\blacklozenge$

Specielt gælder, at hvis $\boldsymbol{\Sigma} = \sigma^2 \mathbf{I}_p$ med $\sigma^2 > 0$ vil $\mathbf{B}\mathbf{X}$ og $\mathbf{C}\mathbf{X}$ være uafhængige hvis og kun hvis $\mathbf{B}\mathbf{C}^* = \mathbf{0}$.

Proposition A.5 Antag $\mathbf{Y} \sim N_p(\mathbf{0}, \sigma^2 \mathbf{I}_p)$ og at $\mathbf{B}$ er en $p \times p$ matrix som opfylder $\mathbf{B}^2 = \mathbf{B}$ (idempotent) og $\mathbf{B}^* = \mathbf{B}$ (symmetrisk). Så gælder det, at

$$\|\mathbf{B}\mathbf{Y}\|^2 \sim \sigma^2 \chi^2(k)$$

hvor k er rangen af $\mathbf{B}$. $\blacklozenge$

Bemærk, at de to betingelser på $\mathbf{B}$ (idempotent og symmetrisk) betyder et $\mathbf{B}$ er (matrix repræsentation for) en ortogonal projektion (på søjlerummet af $\mathbf{B}$) samt at rangen af $\mathbf{B}$ er lig sporet af $\mathbf{B}$.

Betragt en multipel regressionsmodel, det vil sige, hvor X_i , $i = 1, \dots, n$, er uafhængige stokastiske variable med $X_i \sim N(\mathbf{t}_i^* \boldsymbol{\beta}, \sigma^2)$ $i = 1, \dots, n$. Det følger da, at

$$\mathbf{X} \sim N_n(\mathbf{T}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n),$$

hvor $\mathbf{T}$ ($n \times d$) er designmatricen defineret ved

$$\mathbf{T} \stackrel{\text{def}}{=} \begin{pmatrix} \mathbf{t}_1^* \\ \vdots \\ \mathbf{t}_i^* \\ \vdots \\ \mathbf{t}_n^* \end{pmatrix}.$$

Hvis $\mathbf{T}$ har fuld rang d , dvs. at kolonnerne i $\mathbf{T}$ er lineært uafhængige, så er maksimum likelihood estimatoren for $\boldsymbol{\beta}$ givet ved

$$\hat{\boldsymbol{\beta}} = (\mathbf{T}^* \mathbf{T})^{-1} \mathbf{T}^* \mathbf{X}.$$

Ifølge Proposition A.3 gælder der

$$\hat{\boldsymbol{\beta}} \sim N_d(\boldsymbol{\beta}, \sigma^2 (\mathbf{T}^* \mathbf{T})^{-1}). \quad (\text{A.60})$$

Hvis vi definerer $\mathbf{P} = \mathbf{T}(\mathbf{T}^*\mathbf{T})^{-1}\mathbf{T}^*$ kan residualerne udtrykkes som $\mathbf{r} \stackrel{\text{def}}{=} \mathbf{X} - \mathbf{T}\hat{\boldsymbol{\beta}} = (\mathbf{I}_n - \mathbf{P})\mathbf{X}$ og vil ifølge Proposition A.3 opfylde

$$\mathbf{r} \sim N_n(\mathbf{0}, \sigma^2(\mathbf{I}_n - \mathbf{P})) . \quad (\text{A.61})$$

På grund af A.4 vil $\hat{\boldsymbol{\beta}}$ og $\mathbf{r}$ være uafhængige. Vi bemærker at $\mathbf{P}$ er symmetrisk og idempotent og det samme gælder $\mathbf{I}_n - \mathbf{P}$. Definerer vi $\mathbf{Y} = \mathbf{X} - \mathbf{T}\hat{\boldsymbol{\beta}}$ har vi $\mathbf{Y} \sim N_n(\mathbf{0}, \sigma^2\mathbf{I}_n)$, og der vil gælde $(\mathbf{I}_n - \mathbf{P})\mathbf{Y} = (\mathbf{I}_n - \mathbf{P})\mathbf{X}$ og dermed $\|(\mathbf{I}_n - \mathbf{P})\mathbf{Y}\|^2 = \|(\mathbf{I}_n - \mathbf{P})\mathbf{X}\|^2 = \|\mathbf{r}\|^2$. På grund af Proposition A.5 og da der gælder at rangen af $\mathbf{I} - \mathbf{P}$ er $n - d$ kan vi derfor konkludere at

$$\|\mathbf{r}\|^2 \sim \chi^2(n - d) ,$$

og dermed

$$s^2 = \frac{1}{n - d} \|\mathbf{r}\|^2 = \frac{1}{n - d} \sum_{i=1}^n (X_i - \mathbf{t}_i^* \hat{\boldsymbol{\beta}})^2 \sim \chi^2(n - d)/(n - d) ,$$

som altså er uafhængig af $\hat{\boldsymbol{\beta}}$, da den er en funktion af $\mathbf{r}$.

A.3.8 Empirisk fordeling, punktmål

I Afsnit 1.2 omtales den empiriske fordelingsfunktion. Den tilhørende fordeling er et eksempel på en *empirisk fordeling*, som her betragtes for $\mathbb{R}^k$.

For $\mathbf{x} \in \mathbb{R}^k$ betegner $\delta_{\mathbf{x}}(\cdot)$ *punktmålet* (eller *Dirac målet*) i punktet $\mathbf{x}$ det vil sige målet der for $A \subseteq \mathbb{R}^k$ opfylder at

$$\delta_{\mathbf{x}}(A) = \mathbb{1}_A(\mathbf{x}) = \begin{cases} 1 & \text{hvis } \mathbf{x} \in A \\ 0 & \text{ellers} \end{cases} .$$

Punktmålene bruges til at definere diskrete mål, og en særlig variant af disse er de empiriske mål. For en følge $\mathbf{x}_1, \dots, \mathbf{x}_n$ i $\mathbb{R}^k$ defineres det til følgen hørende *empiriske mål* ved

$$\mathbb{P}(\cdot) = \frac{1}{n} \sum_{i=1}^n \delta_{\mathbf{x}_i}(\cdot) , \quad (\text{A.62})$$

og da (A.62) definerer at sandsynlighedsmål, omtales dette også som den *empiriske fordeling*. Definitionen i (A.62) kan virke lidt abstrakt, men dækker blot over at hvis $\mathbf{X}$ er en stokastisk vektor som følger den empiriske fordeling for talfølgen $\mathbf{x}_1, \dots, \mathbf{x}_n$ så er sandsynligheden $\mathbb{P}(\mathbf{X} = \mathbf{x}_i)$ antallet af gange $\mathbf{x}_i$ optræder i følgen, divideret med n :

$$\mathbb{P}(\mathbf{X} = \mathbf{x}_i) = \frac{\#\{j \in \{1, 2, \dots, n\} \mid \mathbf{x}_j = \mathbf{x}_i\}}{n} .$$

Specielt gælder at hvis alle $\mathbf{x}_i$ -erne er forskellige er $\mathbb{P}(\mathbf{X} = \mathbf{x}_i) = 1/n$.

Lad nu $k = 1$ og betragt en følge $\mathbf{x} = x_1, \dots, x_n$ af reelle tal samt en stokastisk variabel X , hvis fordelingsmål er givet ved (A.62), og altså er talfølgens empiriske fordeling. Da gælder at

$$\mathbb{E} X = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} ,$$

og

$$\text{Var } X = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \text{SSD}_{\mathbf{x}} . \quad (\text{A.63})$$

Hvis vi dernæst betragter en følge $(x_1, y_1), \dots, (x_n, y_n)$ i $\mathbb{R}^2$ og lader (X, Y) betegne en stokastisk vektor, hvis fordelingsmål er den tilknyttede empiriske fordeling gælder at den marginale fordeling for X (henholdsvis Y) er den empiriske fordeling for følgen $x_1, \dots, x_n$ (henholdsvis $y_1, \dots, y_n$). Ved hjælp af dette fås

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) ,$$

samt at korrelationen (den *empiriske korrelation*) mellem X og Y er

$$\text{Cor}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\text{SPD}_{\mathbf{xy}}}{\sqrt{\text{SSD}_{\mathbf{x}} \text{SSD}_{\mathbf{y}}}} \stackrel{\text{def}}{=} r_{\mathbf{xy}} ,$$

hvor $\text{SPD}_{\mathbf{xy}}$ er defineret på side 60.

Vi slutter af med at notere en vigtig sammenhæng mellem den empiriske korrelation og den estimerede hældningskoefficient i lineær regression. For data i en lineær regressionsmodel (t_i, x_i) , $i = 1, \dots, n$, blev den estimerede hældningskoefficient i (4.2) fundet til

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(t_i - \bar{t})}{\sum_{i=1}^n (t_i - \bar{t})^2} = \frac{\text{SPD}_{\mathbf{xt}}}{\text{SSD}_{\mathbf{t}}} ,$$

og vi ser at

$$\hat{\beta} = \frac{\sqrt{\text{SSD}_{\mathbf{x}}}}{\sqrt{\text{SSD}_{\mathbf{t}}}} r_{\mathbf{tx}} . \quad (\text{A.64})$$

Lader vi $\sigma_{\mathbf{x}} = \sqrt{\text{SSD}_{\mathbf{x}}/n}$ og betegne den spredningen i den empiriske fordeling (jvf. A.63) for $x_1, \dots, x_n$ og tilsvarende for $\sigma_{\mathbf{t}} = \sqrt{\text{SSD}_{\mathbf{t}}/n}$ kan (A.64) skrives som

$$\hat{\beta} = \frac{\sigma_{\mathbf{x}}}{\sigma_{\mathbf{t}}} r_{\mathbf{tx}} .$$

Bemærk, at $\hat{\beta}$ og $r_{\mathbf{tx}}$ altid har samme fortegn: En estimeret regressionslinje med positiv hældning svarer til en positiv empirisk korrelation og omvendt.

Litteratur

Preben Blæsild and Jørgen Granfeldt. *Statistics with Applications in Biology and Geology*. Chapman & Hall, United Kingdom, 2002. ISBN 9781482285888.

Laura M Chihara and Tim C Hesterberg. *Mathematical statistics with resampling and R (2nd edition)*. John Wiley & Sons, 2018.

Laura M Chihara and Tim C Hesterberg. *Mathematical statistics with resampling and R (3rd edition)*. John Wiley & Sons, 2022.

A.H. Farnleitner, L. Hocke, C. Beiwl, G.C. Kavka, T. Zechmeister, A.K.T. Kirschner, and R.L. Mach. Rapid enzymatic detection of escherichia coli contamination in polluted river water. *Letters in Applied Microbiology*, 33(3):246–250, 2001. doi: <https://doi.org/10.1046/j.1472-765x.2001.00990.x>. URL <https://enviromicro-journals.onlinelibrary.wiley.com/doi/abs/10.1046/j.1472-765x.2001.00990.x>.

Alan Julian Izenman. *Modern multivariate statistical techniques*. Springer Texts in Statistics. Springer, New York, 2008. ISBN 978-0-387-78188-4. doi: 10.1007/978-0-387-78189-1. URL <https://doi.org/10.1007/978-0-387-78189-1>. Regression, classification, and manifold learning.

Richard A. Johnson and Dean W. Wichern. *Applied multivariate statistical analysis*. Pearson Prentice Hall, Upper Saddle River, NJ, sixth edition, 2007. ISBN 978-0-13-187715-3; 0-13-187715-1.